End-to-End Data Analytics
AI VIETNAM

eDA Book: End-to-end Data Analytics

Nhóm Giảng viên khóa eDA

Nguyễn Thái Hà (PhD)
Nguyễn Thanh Hà (MSc.)
Nguyễn Đình Vinh (PhD)
Phạm Hải Hà (PhD)
Nguyễn Quốc Thái (MSc.)
Đinh Quang Vinh (PhD)

Nhóm Mentor hỗ trợ cho các domain

Trần Hoàng Anh (SaaS/Game)
Trần Nguyễn Vân Anh (Finance/Sales)
Đinh Tiến Anh (Finance/Marketing)
Huỳnh Thị Khánh Chi (Supply Chain)
Nguyễn Thị Hồng Diễm (Sales/Growth)
Lâm Đạt (Logistic/E-commerce)
Nguyễn Bảo Thi (Finance/Transp.)
Trần Đình Hùng (Game/Marketing)
Đinh Thị Thu Hà (Sales/Marketing)
Vũ Quang Huy (Finance/Banking)
Đinh Thị Lan Hương (Finance/Banking)
Huỳnh Lê Kim Long (Mobile App/Game)
Nguyễn Thảo Nhi (Game/HR)
Nguyễn Thị Nga (Sales/Supply)
Nguyễn Phúc Nguyên (Sales/Operations)

Nhóm hỗ trợ lớp eDA và các chứng chỉ

Tạ Hữu Anh Dương (AWS/DE)
Nguyễn Thế Hào (DS/DE)
Nguyễn Dương Thuận (AWS/DE)
Nguyễn Đặng Duy Tân (Conquer Prog.)
Lê Tấn Anh Huy (System)
Nguyễn Đăng Nhã (DS/DE)
Nguyễn Hồng Phúc (PhD; eDA Manager)
Nguyễn Lê Minh Thông (MSc.; QA/QC)

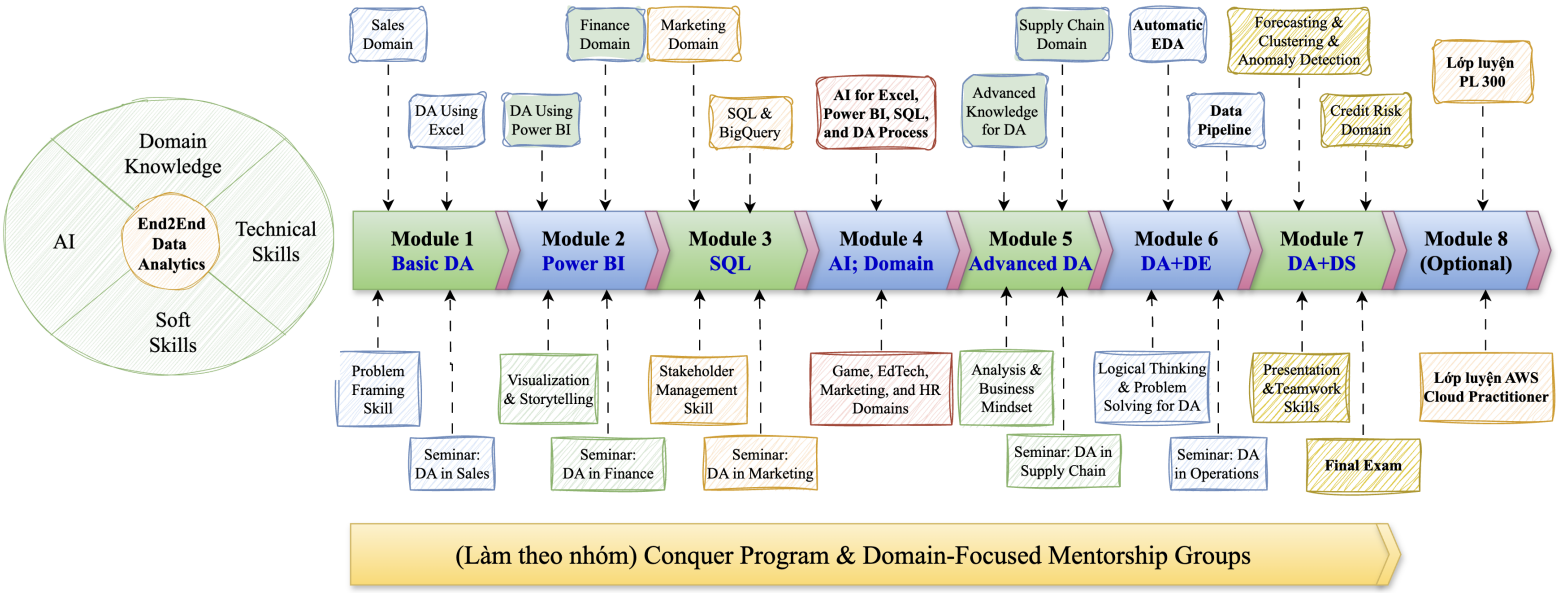

CÁC NHÓM CHỦ ĐỀ CHÍNH

01	**Excel**	Trang **23 - 97**
02	**Tableau**	Trang **98 - 275**
03	**Power BI**	Trang **276 - 444**
04	**SQL**	Trang **445 - 543**
05	**Project: Marketing Analytics**	Trang **544 - 683**
06	**Project: Retail Analytics**	Trang **684 - 762**
07	**DA+DS Projects**	Trang **763 - 938**

Phần mở rộng trong 9 tháng tới

01	**Hướng dẫn ôn thi PL 300**
02	**6 project ở các domain khác nhau**
03	**5 kỹ năng mềm quan trọng cho DA**
04	**Cách dùng các Cloud phổ biến cho DA**

Mục lục

Sử dụng Excel cho Data Analysis . . . **20**

I. Giới thiệu . . . **20**

II. Nội dung . . . **22**

II.1. Excel và ngôn ngữ lập trình . . . 22

II.2. Các hàm Excel quan trọng . . . 23

II.3. Phân tích dữ liệu nhanh với Pivot Table . . . 30

III. Tài liệu tham khảo . . . **40**

EDA với Excel . . . **41**

I. Giới thiệu . . . **41**

II. Nội dung chính . . . **43**

II.1. Bước 1: Làm sạch và chuẩn hóa dữ liệu . . . 43

II.2. Bước 2: Phân tích thống kê mô tả (Descriptive Statistics) . . . 46

II.3. Bước 3: Trực quan hóa dữ liệu (Data Visualization) . . . 47

II.4. Bước 4: Tổng hợp dữ liệu với PivotTable . . . 53

III. Câu hỏi trắc nghiệm . . . **57**

IV. Tài liệu tham khảo . . . **59**

Quiz - Excel: PowerQuery . . . **60**

I. Tài liệu tham khảo . . . **70**

Phụ lục . . . **70**

Claude cho Excel . . . **71**

I. Giới thiệu . . . **71**

Tóm tắt nhanh . . . **72**

II. Claude for Excel là gì? . . . **73**

II.1. Định nghĩa . . . 73

II.2. Claude for Excel khác gì so với dùng Claude thông thường? . . . 73

II.3. Claude for Excel phù hợp với ai? . . . 74

III. Cách Claude đọc Workbook trong Excel . . . 75

III.1. Workbook, worksheet và cell . . . 75

III.2. Claude truy vết dữ liệu như thế nào? . . . 75

IV. Quy trình dùng Claude for Excel trong một workbook thực tế . . . 77

IV.1. Quy trình thao tác gợi ý . . . 77

IV.2. Thực hành trên một workbook mẫu . . . 78

IV.3. Kiểm chứng kết quả và giới hạn khi sử dụng . . . 89

V. Tổng kết . . . 90

Tài liệu tham khảo . . . 92

Phụ lục A. Bộ prompt mẫu . . . 93

Phụ lục B. Lỗi dữ liệu thường gặp và cách xử lý . . . 95

Tableau & Data Visualization: Introduction to Tableau . . . 96

I. Giới thiệu chung . . . 96

II. Giới thiệu về Tableau . . . 97

II.1. Tìm hiểu các phẩn phẩm của Tableau . . . 97

II.2. So sánh Tableau và PowerBI . . . 101

II.3. So sánh Tableau với Python Dashboard . . . 101

III. Tableau . . . 103

III.1. Tableau UI & Core Concepts . . . 103

IV. Các hàm tiền xử lý dữ liệu trong Tableau theo kiểu dữ liệu . . . 107

IV.1. Giới thiệu . . . 107

IV.2. Data Types trong Tableau . . . 108

IV.3. Preprocessing Functions theo Data Type . . . 110

IV.4. Quick Reference . . . 121

V. Các loại biểu đồ cơ bản trong Tableau . . . 123

V.1. Giới thiệu . . . 123

V.2. Bar Chart . . . 124

V.3. Line Chart . . . 128
V.4. Area Chart . . . 132
V.5. Scatter Plot Tương quan giữa hai chỉ số . . . 134
V.6. Histogram . . . 136
V.7. Box Plot (Box & Whisker) . . . 138
V.8. Text Table, Heat Map & Highlight Table . . . 140
V.9. Maps . . . 143
V.10. Tổng kết . . . 145

VI. Bài tập tổng hợp: Ứng dụng vẽ một số biểu đồ đơn giản trên Tableau 147
VI.1. Vai trò của Tableau . . . 147
VI.2. Giới thiệu về dataset . . . 147
VI.3. Quy trình xây dựng biểu đồ . . . 148

VII. Câu hỏi trắc nghiệm . . . 163

Quiz - Tableau: Introduction to Tableau . . . 168

Tableau & Data Visualization: Dashboard & Storytelling . . . 179

I. Tổng quan . . . 179

II. Ôn tập . . . 180
II.1. Vai trò của Tableau trong phân tích dữ liệu . . . 180
II.2. Cấu trúc giao diện cơ bản của Tableau . . . 180
II.3. Dimensions và Measures . . . 181
II.4. Quy trình tạo biểu đồ trong Tableau . . . 181
II.5. Từ Worksheet đến Dashboard . . . 182
II.6. Tóm tắt nội dung buổi 1 . . . 183

III. Giới thiệu . . . 183

IV. Calculated Fields nâng cao . . . 185
IV.1. Tổng quan về Calculated Fields . . . 185
IV.2. Row-level vs Aggregate Hai cấp độ tính toán . . . 187
IV.3. Các hàm Aggregation thường dùng . . . 190
IV.4. LOD Expressions . . . 191

V. Filters . . . 195
V.1. Tại sao cần Filters? . . . 195
V.2. Các loại Filters trong Tableau . . . 195
V.3. Cách tạo Filter . . . 195
V.4. Dimension Filters . . . 197
V.5. Measure Filters . . . 198
V.6. Context Filters . . . 199
V.7. Hiển thị Filter Cards trên Dashboard . . . 201
V.8. Apply to Worksheets . . . 202
VI. Parameters . . . 204
VI.1. Parameters là gì? . . . 204
VI.2. Cách tạo Parameter . . . 204
VI.3. Kiểu dữ liệu của Parameter . . . 205
VI.4. Dùng Parameter trong Calculated Field . . . 205
VI.5. Hiển thị Parameter Control . . . 205
VI.6. Ví dụ Interactive Bar Chart . . . 205
VI.7. Parameter Actions . . . 209
VI.8. Parameter vs Filter . . . 210
VII. Dashboard . . . 210
VII.1. Dashboard Layout và Containers . . . 211
VII.2. Color Principles trong Data Visualization . . . 213
VII.3. Visual Best Practices . . . 215
VIII. Dashboard Actions . . . 216
IX. Storytelling . . . 221
IX.1. Giao diện Story trong Tableau . . . 221
X. Tóm tắt buổi học . . . 223
XI. Bài tập thực hành . . . 224
XII. Câu hỏi trắc nghiệm . . . 255
Phụ lục . . . 259

Quiz - Tableau: Dashboard & Storytelling 260

Power BI & Data Visualization: Introduction to PowerBI 274

I. Giới thiệu 274

II. Giới thiệu Power BI 275

II.1. So sánh Power BI Desktop và Power BI Service 275

III. Interface Navigation 278

III.1. Màn hình chào mừng 278

III.2. Power BI User Interface Ribbon 279

III.3. Các tab chính trên thanh Ribbon 279

III.4. Navigation Pane 280

III.5. Data Pane, Visualiszation Pane và Filters pane 282

IV. Data Integration 283

IV.1. Connection Methodologies 284

IV.2. Data Refresh and Incremental Refresh 288

IV.3. Visualization Selection trong Power BI 290

V. Tổng kết 292

VI. Thực hành: Xây dựng dashboard với Power BI 293

VI.1. Bước 1: Import dữ liệu 293

VI.2. Bước 2: Kiểm tra dữ liệu 294

VI.3. Bước 3: Tạo KPI tổng quan 296

VI.4. Bước 4: Bar Chart 298

VI.5. Bước 5: Line Chart 299

VI.6. Bước 6: Map 301

VI.7. Bước 7: Top 10 sản phẩm 302

VI.8. Bước 8: Slicer 304

VI.9. Bước 9: Sắp xếp dashboard 305

VI.10. Bài tập thực hành 306

VII. Tổng kết 307

VIII. Câu hỏi trắc nghiệm 308

Phụ lục **311**

Quiz: Introduction to PowerBI **312**

Power BI: Data Transformation and Modeling **322**

I. Giới thiệu **322**

II. Data Cleaning với Power Query **324**

II.1. Power Query và M Language: Nền tảng 324

II.2. Power Query Editor: Công cụ biến đổi dữ liệu 325

II.3. Chuẩn hóa Text: Giải quyết Biến thể dữ liệu 327

II.4. Quản lý Rows và Columns 331

II.5. Change Data Types 336

II.6. Dangerous Filtering 339

III. Dimensional Modeling: Star Schema **342**

III.1. Tại sao cần tổ chức dữ liệu? 342

III.2. Fact Table vs Dimension Table 343

III.3. Thiết kế Star Schema cho dataset mẫu 344

IV. Establishing Data Relationships **351**

IV.1. Relationship là gì? 351

IV.2. Tạo Relationships trong Power BI 352

IV.3. Active vs Inactive Relationships 353

IV.4. Xử lý Many-to-Many 354

V. Introduction to DAX **355**

V.1. DAX là gì? 355

V.2. Tạo Measure đầu tiên: Total Sales 356

V.3. Các hàm DAX cơ bản 359

V.4. Bước tiếp theo: CALCULATE 361

V.5. Biến VAR: Viết DAX sạch và hiệu quả hơn 361

V.6. Iterator Functions: Hàm lặp SUMX 362

VI. Tổng kết **364**

Quiz - Power BI: Data Transformation and Modeling 365

Power BI: Enhancing Interactivity 376

I. Giới thiệu 376

II. Nguyên tắc thiết kế báo cáo hiệu quả 378

II.1. Giảm thiểu sự lộn xộn trực quan để rõ ràng 378

II.2. Thiết lập thứ bậc thông tin (Information Hierarchy) 383

II.3. Sử dụng màu sắc chiến lược để tạo điểm nhấn và insight 387

II.4. Ví dụ thực hành hoàn chỉnh: Thiết kế lại một trang dashboard 391

III. Slicers: Bộ lọc Trực quan trên Canvas 393

III.1. Slicer là gì? 393

III.2. Tạo Slicer đầu tiên 394

III.3. Các loại Slicer 396

III.4. Format và Selection Settings 399

III.5. Sync Slicers giữa các trang 400

III.6. Best Practices cho Slicers 401

IV. Cross-filtering và Cross-highlighting 402

IV.1. Hành vi mặc định 402

IV.2. Highlight vs Filter: Khác nhau thế nào? 402

IV.3. Edit Interactions: Kiểm soát tương tác 403

IV.4. Khi nào dùng None? 405

V. Drill-down: Đào sâu theo Phân cấp Dữ liệu 406

V.1. Hierarchy là gì? 406

V.2. 4 chế độ Drill-down 407

V.3. Thực hành: Drill-down trên Bar Chart 408

V.4. Drill-down trong Matrix 410

VI. Drill-through 412

VI.1. Drill-through khác Drill-down ở đâu? 412

VI.2. Tạo trang Drill-through Product Details 412

VI.3. Thiết kế Drill-through hiệu quả 414

VI.4. Sử dụng Drill-through từ trang chính . . . 414

VII. Bookmarks và Buttons . . . 416

VII.1. Bookmarks . . . 416

VII.2. Buttons . . . 417

VII.3. Toggle Panel . . . 418

VII.4. Page Navigator . . . 421

VIII. Optimizing User Experience . . . 422

VIII.1. Custom Tooltips . . . 422

VIII.2. Conditional Formatting . . . 424

VIII.3. KPI Layout và Information Hierarchy . . . 426

VIII.4. Performance Analyzer . . . 429

VIII.5. Mobile Layout (giới thiệu ngắn) . . . 431

IX. Tổng kết và So sánh . . . 432

IX.1. Bảng tổng hợp 6 tính năng tương tác . . . 432

IX.2. Checklist: Report đã đủ tương tác chưa? . . . 432

Quiz - Power BI: Enhancing Interactivity . . . 433

Introduction to Basic SQL . . . 443

I. Giới thiệu . . . 443

II. Cơ sở lý thuyết . . . 445

II.1. Database là gì? . . . 445

II.2. Table, row và column . . . 445

II.3. DBMS là gì? . . . 446

II.4. SQL query là gì? . . . 447

III. Case study: thiết kế và truy vấn bảng students . . . 448

III.1. Schema của bảng students . . . 448

III.2. Tạo bảng bằng CREATE TABLE . . . 448

III.3. Thêm dữ liệu bằng INSERT INTO . . . 449

III.4. Quan sát dữ liệu sau khi thêm . . . 450

III.5. SELECT và FROM . . . 451

III.6. WHERE . . . 452
III.7. ORDER BY . . . 452
III.8. LIMIT . . . 453
III.9. Kết hợp các statement trong một truy vấn . . . 453

Pandas & SQL for Data Analysis . . . 454

I. Data Retrieval . . . 454
I.1. Lý thuyết . . . 454
I.2. Case study: Gapminder (Simple) . . . 454
I.3. Quiz . . . 460

II. Data Cleaning . . . 472
II.1. Lý thuyết . . . 472
II.2. Case study: Air Quality (UCI) . . . 472
II.3. Quiz . . . 479

III. Data Aggregation . . . 490
III.1. Lý thuyết . . . 490
III.2. Case study . . . 490
III.3. Quiz . . . 495

IV. Window Functions . . . 508
IV.1. Lý thuyết . . . 508
IV.2. Case study: Stocks (Vega Datasets) . . . 508
IV.3. Quiz . . . 513

SQL Transformation with dbt . . . 529

I. Dẫn nhập . . . 529

II. Lý thuyết căn bản về dbt . . . 531
II.1. dbt là gì và vị trí trong Modern Data Stack . . . 531
II.2. Kiến trúc và các thành phần cốt lõi . . . 531
II.3. Quy trình phát triển với dbt . . . 535

III. Practice: dbt with PostgreSQL . . . 536
III.1. Bối cảnh dữ liệu . . . 536

III.2. Kết nối dbt với PostgreSQL . . . 537
III.3. Cấu trúc dự án . . . 538
III.4. Các lớp biến đổi dữ liệu . . . 538
III.5. Kiểm thử, tài liệu hóa và quy trình chạy . . . 539
IV. Tài liệu tham khảo . . . 541
Project: Marketing Analytics . . . 542
I. Giới thiệu . . . 542
II. Hành trình của dữ liệu . . . 543
III. Hiểu về domain: Các chỉ số chính trong digital marketing . . . 544
IV. Marketing funnel . . . 546
V. Các KPI chính để đo lường tính hiệu quả . . . 548
VI. Các câu hỏi trung tâm . . . 552
VII. Chuẩn bị dữ liệu: Từ CSV đến MySQL . . . 554
VII.1. Tạo database và bảng . . . 554
VII.2. Import 3 file CSV vào MySQL . . . 555
VII.3. Khám phá dữ liệu (EDA) . . . 557
VII.4. Xử lý dữ liệu (Data Cleaning) . . . 562
VII.5. Thống kê mô tả (sau cleaning) . . . 567
VII.6. Tính KPI bằng SQL . . . 568
VIII. Kết nối Excel → MySQL bằng Power Query . . . 574
VIII.1. Cài đặt MySQL Connector/NET . . . 574
VIII.2. Kết nối từ Excel . . . 575
VIII.3. Refresh dữ liệu . . . 580
VIII.4. Xử lý lỗi kết nối thường gặp . . . 581
VIII.5. Checklist kết nối . . . 582
VIII.6. Cách thay thế Kết nối bằng MySQL Connector/ODBC . . . 582
IX. Chuẩn bị dữ liệu trong Excel . . . 583
IX.1. Kiểm tra tổng quan dữ liệu . . . 584
IX.2. Loại bỏ dữ liệu trùng lặp . . . 584

IX.3. Xử lý cột Campaign_Date . . . 585
IX.4. Xử lý cột Channel_Used (đa giá trị) . . . 586
IX.5. Tạo các cột phân loại bổ sung . . . 587
IX.6. Tổng kết: Bảng dữ liệu sau khi chuẩn bị . . . 588

X. Pivot Table . . . 588
X.1. Tạo Pivot Table đầu tiên: Tổng quan theo Brand . . . 588
X.2. Pivot Table theo Campaign Type . . . 591
X.3. Pivot Table theo Brand × Campaign Type . . . 592
X.4. Pivot Table theo thời gian . . . 593
X.5. Pivot Table theo Customer Segment . . . 594
X.6. Pivot Table theo Channel Analysis . . . 595
X.7. Pivot Table theo ROI Distribution . . . 596
X.8. Kỹ thuật Pivot Table nâng cao . . . 597
X.9. Tổng kết Pivot Tables cần tạo . . . 599

XI. Dashboard: Trực quan hoá dữ liệu với Excel . . . 599
XI.1. Thiết kế layout Dashboard . . . 599
XI.2. KPI Summary Cards . . . 600
XI.3. Chart 1: Revenue & ROI theo Brand (Combo Chart) . . . 601
XI.4. Chart 2: Campaign Type Performance (Horizontal Bar) . . . 602
XI.5. Chart 3: Marketing Funnel . . . 603
XI.6. Chart 4: ROI Distribution (Doughnut Chart) . . . 604
XI.7. Chart 5: Monthly Revenue Trend (Line Chart) . . . 605
XI.8. Chart 6: Top 10 & Bottom 10 Campaigns . . . 605
XI.9. Hoàn thiện Dashboard - Visualization trên Excel . . . 606

XII. Dashboard: Trực quan hoá dữ liệu với Tableau . . . 608
XII.1. Kết nối dữ liệu . . . 609
XII.2. Tiền xử lý dữ liệu trong Tableau sau khi kết nối . . . 618
XII.3. Thiết lập ban đầu . . . 626
XII.4. Tab 1: Executive Overview . . . 627
XII.5. Tab 2: Campaign Performance . . . 629

XII.6. Tab 3: Platform Analysis . . . 631
XII.7. Tab 4: Audience & Segment . . . 632
XII.8. Tab 5: Cost & ROI Optimization . . . 633
XII.9. Xây dựng Dashboard trong Tableau . . . 634
XII.10. Publish và chia sẻ . . . 637
XII.11. Checklist Dashboard hoàn chỉnh . . . 638

XIII. Phân tích và Insight . . . 638
XIII.1. So sánh hiệu quả giữa các Brand . . . 639
XIII.2. Phân tích theo loại Campaign . . . 641
XIII.3. Phân tích theo kênh (Channel) . . . 643
XIII.4. Hiệu quả ngân sách & Phân bổ ROI . . . 644
XIII.5. Phân tích theo thời gian: Trend và mùa vụ . . . 648
XIII.6. Phân tích theo phân khúc khách hàng . . . 650
XIII.7. Tổng hợp toàn bộ 16 Insights . . . 653

XIV. Business Recommendations . . . 654

XV. Từ phân tích dữ liệu đến mô hình dự đoán . . . 657
XV.1. Bối cảnh từ Phase 1 . . . 657
XV.2. Ba câu hỏi Data Scientist cần trả lời . . . 657
XV.3. Tại sao chọn bài toán phân loại? . . . 657

XVI. Thiết kế thí nghiệm: Ba nhóm đặc trưng v1 / v2 / v3 . . . 658
XVI.1. Tại sao chia ba nhóm? . . . 658
XVI.2. Chi tiết ba nhóm đặc trưng . . . 658
XVI.3. Kỳ vọng lý thuyết trước thực nghiệm . . . 659

XVII. Kết quả thực nghiệm . . . 660
XVII.1. Kết quả trên tập kiểm tra . . . 660
XVII.2. Code: Huấn luyện Logistic phiên bản 1/2/3 . . . 661
XVII.3. Ma trận nhầm lẫn v3 . . . 662
XVII.4. Xếp hạng đặc trưng . . . 663

XVIII. Quét ngưỡng CPA và ngưỡng kép WATCH / STOP . . . 664
XVIII.1. Phân biệt CPA campaign cá nhân và CPA trung bình nhóm . . . 664

XVIII.2. (Code lập trình) Quét ngưỡng CPA . . . 665
XVIII.3. Bảng kết quả quét ngưỡng . . . 665
XVIII.4. Tiêu chí chọn ngưỡng . . . 666
XVIII.5. So sánh với đề xuất DA . . . 667

XIX. So sánh hiệu quả và khi nào thì cần Machine Learning? . . . 667

XIX.1. So sánh trực tiếp . . . 667
XIX.2. Ba tình huống biên mà v3 thắng . . . 668
XIX.3. Chiến lược phối hợp: Defense-in-Depth (Lớp 1 + Lớp 2) . . . 668
XIX.4. Quy trình vận hành WATCH / STOP . . . 669
XIX.5. Kết luận về ứng dụng mô hình học máy . . . 672

XX. Tổng kết . . . 673

XXI. Bảng thuật ngữ . . . 674

XXII. Câu hỏi trắc nghiệm . . . 676

Phụ lục . . . 681

Retail Analytics Forecasting . . . 682

A Giới thiệu chung . . . 682

B Phân tích dữ liệu . . . 684

I. Giới thiệu . . . 684

I.1. Cấu trúc đề thi . . . 685
I.2. Rubric: Ban giám khảo chấm những gì? . . . 685
I.3. Tổng quan quy trình . . . 686

II. Khám phá dữ liệu . . . 687

II.1. Bản đồ dữ liệu . . . 687
II.2. Quan hệ giữa các bảng . . . 687
II.3. Ba nhận xét quan trọng . . . 688

III. Thiết kế hướng phân tích . . . 689

III.1. Mapping: Data → Câu hỏi → Dashboard . . . 689
III.2. Narrative arc (mạch chuyện) . . . 689

III.3. Tại sao cần Python trước khi mở Tableau? . . . 689

IV. Chuẩn bị dữ liệu bằng Python . . . 691

IV.1. Cấu hình và helper functions . . . 691

IV.2. Tổng quan 14 bước xử lý . . . 691

IV.3. Step 1: Load dữ liệu gốc . . . 692

IV.4. Step 2: dim_products (Sản phẩm enriched) . . . 692

IV.5. Step 3 và 4: dim_geography, dim_promotions . . . 693

IV.6. Step 5: fact_orders_enriched (Bảng fact trung tâm) . . . 693

IV.7. Step 6: fact_returns_enriched . . . 695

IV.8. Step 7: RFM Segmentation (phức tạp nhất) . . . 696

IV.9. Step 8: Shipments enriched . . . 697

IV.10. Step 9: fact_sales_daily (Revenue + trends) . . . 698

IV.11. Step 10: Inventory + health labels . . . 699

IV.12. Step 11: Web traffic . . . 699

IV.13. Step 12: Cohort Retention . . . 699

IV.14. Step 13 và 14: Bảng tổng hợp . . . 700

V. Thiết lập Tableau Public . . . 702

V.1. Tạo Data Source . . . 702

V.2. Kiểm tra Data Types . . . 702

V.3. Template layout chung . . . 702

V.4. Dashboard Actions . . . 703

V.5. KPI Delta . . . 703

VI. Dashboard 1: Revenue & Profitability . . . 705

VI.1. 4 KPI Cards . . . 705

VI.2. Chart 1: Revenue Trend (Descriptive) . . . 706

VI.3. Chart 2: Gross Margin Trend (Diagnostic) . . . 707

VI.4. Chart 3: MoM Growth Heatmap (Predictive) . . . 707

VI.5. Chart 4: Category Revenue Contribution (Prescriptive) . . . 708

VI.6. Ghép Dashboard 1 . . . 709

VII. Dashboard D2 Customer Segmentation & Lifecycle . . . 710
VII.1. Tổ chức & Chuẩn bị Dữ liệu . . . 710
VII.2. Xây dựng dashboard . . . 711
VII.3. Chiến lược ghi điểm cho Dashboard 2 . . . 713
VIII. Dashboard D4 Marketing & Channel Effectiveness . . . 713
VIII.1. Tổ chức & Chuẩn bị Dữ liệu . . . 713
VIII.2. Xây dựng dashboard . . . 715
IX. Gợi mở: Dashboard tiếp theo . . . 718
IX.1. Dashboard D3: Product Analysis . . . 718
IX.2. Dashboard 5: Operations & Supply Chain . . . 718
IX.3. Story: CEO Narrative (6 Story Points) . . . 718
X. Phân tích . . . 719
X.1. Dashboard D1 Revenue & Profitability Overview . . . 719
X.2. Dashboard D2: Customer Segmentation & Lifecycle . . . 720
X.3. Dashboard D4: Marketing & Channel Effectiveness . . . 722
XI. Tổng kết . . . 724
C XÂY DỰNG MÔ HÌNH DỰ ĐOÁN . . . 725
XII. Giới thiệu . . . 725
XIII. Phát biểu bài toán . . . 726
XIII.1. Input và Output . . . 726
XIII.2. Hàm mục tiêu . . . 726
XIV. Phân tích dữ liệu . . . 727
XIV.1. Bức tranh tổng thể: Biểu đồ qua các năm . . . 727
XIV.2. Cấu trúc thời gian: Tính mùa vụ có bền vững không? . . . 728
XIV.3. Các pattern lịch biểu chi tiết . . . 729
XIV.4. Phân phối và mối liên hệ giữa hai biến mục tiêu . . . 731
XIV.5. Scatter Revenue–COGS: cơ sở cho hướng dự báo qua tỉ số . . . 733
XIV.6. Tóm tắt: từ EDA đến các quyết định mô hình . . . 734

XV. Feature Engineering . . . 735

XVI. Chiến lược validation . . . 738

XVI.1. Ba fold theo thời gian . . . 738

XVII. Lựa chọn và huấn luyện mô hình . . . 739

XVII.1. Lựa chọn mô hình như thế nào? . . . 739

XVII.2. M1: Ridge Regression . . . 739

XVII.3. M2: LightGBM với sample weighting . . . 740

XVII.4. M3: Prophet . . . 741

XVII.5. Mô hình huấn luyện theo quý . . . 742

XVIII. Chiến lược ensemble learning . . . 744

XVIII.1. Hướng 1: Ensemble đơn giản . . . 744

XVIII.2. Hướng 2: Ensemble phân tầng . . . 744

XVIII.3. Mã nguồn ensemble phân tầng . . . 746

XIX. Parameters Tuning . . . 748

XIX.1. Tổng quan: ba nhóm tham số và công cụ tuning tương ứng . . . 748

XIX.2. Chiến lược tuning cho từng nhóm . . . 748

XX. Khả năng giải thích mô hình . . . 750

XX.1. Đối tượng và công cụ giải thích . . . 750

XX.2. Global importance . . . 751

XX.3. Local effect . . . 753

XX.4. Đối chứng định lượng với Prophet . . . 756

Phụ lục . . . 760

. . . 761

I. SQL & Relational Schema . . . 761

II. Data Preprocessing . . . 778

III. Data Analysis . . . 786

IV. Machine Learning & Forecasting . . . 808

Logic Thinking and Problem Solving for Data Science and Artificial Intelligence . . . 817

I. Giới thiệu . . . 817

II. Nội dung bài học . . . 819

II.1. Nền tảng của tư duy logic và giải quyết vấn đề . . . 819

II.2. Phân rã vấn đề và nguyên tắc MECE . . . 828

II.3. Cây Logic (Logic Trees) . . . 832

II.4. Ưu tiên hóa (Prioritization) . . . 833

II.5. Thu thập và phân tích dữ liệu . . . 838

II.6. Quy trình phân tích dữ liệu . . . 842

II.7. Quy trình thiết kế giải pháp AI . . . 845

II.8. Kỹ thuật trình bày . . . 849

II.9. Tổng kết . . . 852

III. Tài liệu tham khảo . . . 855

Project: Xây dựng công cụ tối ưu hoá quy trình phân bổ hàng hoá cho chuỗi cửa hàng . . . 856

I. Giới thiệu . . . 856

II. Lý thuyết . . . 860

II.1. Tại sao cần tối ưu hóa phân bổ hàng hóa? . . . 860

II.2. Định nghĩa bài toán . . . 861

III. Xây dựng hệ thống . . . 863

III.1. Đọc dữ liệu . . . 864

III.2. Phương pháp dựa trên các luật . . . 866

III.3. Phương pháp thuật toán di truyền . . . 869

III.4. So sánh hiệu năng và lựa chọn thuật toán . . . 873

IV. Hướng cải tiến . . . 875

IV.1. Tích hợp dữ liệu thực và mô hình dự báo . . . 875

IV.2. Cải tiến và tối ưu hóa giải thuật di truyền . . . 876

IV.3. Áp dụng thuật toán đa mục tiêu (NSGA-II) . . . 877

V. Câu hỏi trắc nghiệm . . . 879

VI. Tài liệu tham khảo . . . 881

Phụ lục . . . 881

Project (Case Study): Phân cụm khách hàng dùng K-Means . . . 882

I. Phân khúc khách hàng . . . 882

II. Phân tích và làm sạch dữ liệu . . . 886

II.1. Tải và kiểm tra dữ liệu ban đầu . . . 886

II.2. Làm sạch dữ liệu . . . 887

II.3. EDA . . . 887

III. Tạo đặc trưng . . . 892

III.1. Tại sao cần mở rộng Features? . . . 892

III.2. Xây dựng bộ đặc trưng . . . 892

III.3. Chuẩn hóa và biến đổi Dữ liệu . . . 894

IV. Mô hình hóa và phân cụm . . . 897

IV.1. Giới thiệu về K-Means clustering . . . 897

IV.2. Xác định số cụm tối ưu . . . 897

IV.3. Phân tích thành phần chính (PCA) . . . 898

IV.4. So sánh phân cụm K=3 và K=4 . . . 898

IV.5. Phân tích chuyên sâu biểu đồ Radar . . . 900

IV.6. Đánh giá với thuật toán SHAP . . . 902

IV.7. Quy trình định danh khách hàng với ChatGPT . . . 905

V. Các hướng cải tiến . . . 906

VI. Câu hỏi trắc nghiệm . . . 908

VII. Tài liệu tham khảo . . . 910

Phụ lục . . . 910

Giới thiệu về thuật toán SHAP . . . 911

I. Giới thiệu . . . 911

II. Nội dung chính . . . 915

II.1. Các khái niệm trong XAI 915
II.2. Giới thiệu thuật toán SHAP 917
II.3. Phương pháp giải thích cộng tính và Kernel SHAP 920
II.4. Tổng quan thuật toán SHAP 928
II.5. Ví dụ tính toán Kernel SHAP từng bước 929

III. Câu hỏi trắc nghiệm 932

IV. Tài liệu tham khảo 935

Phụ lục 935

AI VIET NAM COURSE 2026

Sử dụng Excel cho Data Analysis

I. Giới thiệu

Trong kỷ nguyên số hóa ngày nay, mọi hoạt động của con người từ việc thực hiện mua sắm trực tuyến, tương tác trên mạng xã hội đến vận hành thiết bị IoT đều sản sinh ra một khối lượng dữ liệu khổng lồ. Tuy nhiên, dữ liệu thô (raw data) chỉ là tập hợp các con số, ký tự và sự kiện rời rạc; bản thân các dữ liệu này chưa thể giúp chúng ta đưa ra quyết định. Các dữ liệu này chưa thể sử dụng trực tiếp. Chúng cần được xử lý và bổ sung ngữ cảnh để tạo ra thông tin có giá trị sử dụng.

Hình 1: Quy trình phân tích dữ liệu với excel trong Data Analysis.

Với sự bùng nổ của **Big Data** khiến thách thức với dữ liệu ngày càng trở nên cấp bách: khối lượng dữ liệu toàn cầu dự kiến tăng từ 2 *zettabytes* năm 2010 lên 181 *zettabytes* vào năm 2025. Những con số về sự gia tăng của dữ liệu cho thấy một điều rõ ràng: con người không thể tự mình đọc, hiểu và xử lý khối lượng này nếu không có công cụ hỗ trợ. Phân tích dữ liệu **(Data Analysis)** chính là kỹ năng cốt lõi để chuyển dữ liệu thô thành thông tin hữu ích, hỗ trợ ra quyết định dựa trên bằng chứng thay vì cảm tính.

Trong số các công cụ trong việc phân tích dữ liệu, **Excel** vẫn là lựa chọn phổ biến và hiệu quả cho xử lý dữ liệu vừa và nhỏ. Excel không chỉ cung cấp các hàm tính toán và thống kê cơ bản,

mà còn cho phép trực quan hóa dữ liệu, tạo các bản báo cáo nhanh chóng và dễ dàng chia sẻ. Việc thành thạo Excel chính là nền tảng vững chắc để bước vào lĩnh vực phân tích dữ liệu chuyên sâu.

Theo đó bài viết này tập trung làm rõ cách ứng dụng Excel trong phân tích dữ liệu cơ bản, đồng thời giới thiệu các công cụ nên dùng để bạn có thể biến những con số rời rạc thành các *insight* giá trị một cách nhanh chóng nhất. Theo đó, nội dung bài viết sẽ đi sâu vào các phần chính sau:

- **Tổng quan về phân tích dữ liệu và vai trò của Excel:** Giải thích khái niệm dữ liệu và phân tích dữ liệu, lợi ích của việc phân tích dựa trên bằng chứng, các vai trò phổ biến trong ngành DS, cũng như lý do vì sao Excel vẫn quan trọng trong kỷ nguyên big data.
- **Thống kê cơ bản để nắm bắt xu hướng dữ liệu:** Trình bày các chỉ số thống kê nền tảng (trung bình, trung vị, phương sai, độ lệch chuẩn, giá trị cực trị,...), giới thiệu các hàm excel quan trọng, cùng cách sử dụng **Pivot Table** và **Data Analysis Tool** để phát hiện xu hướng nhanh chóng nhất.

II. Nội dung

II.1. Excel và ngôn ngữ lập trình

Khi bắt đầu với việc phân tích dữ liệu, Excel thường là điểm xuất phát quen thuộc và dễ tiếp cận nhất dành cho mọi người. Với giao diện trực quan, hệ thống hàm thao tác dễ hiểu và khả năng trực quan hóa cơ bản, Excel đã trở thành công cụ không thể thiếu trong nhiều doanh nghiệp. Tuy nhiên, cần xem xét liệu Excel có phù hợp với mọi loại dữ liệu và mọi yêu cầu phân tích hay không.

Trong thực tế có thể dễ dàng thấy được: khi dữ liệu trở nên phức tạp hơn, khối lượng lớn hơn và nhu cầu phân tích sâu hơn, các ngôn ngữ lập trình như Python, R hay ngôn ngữ truy vấn như SQL chứng minh sức mạnh vượt trội. Việc xác định khi nào nên sử dụng Excel và khi nào cần chuyển sang ngôn ngữ lập trình giúp lựa chọn công cụ phù hợp, nâng cao hiệu quả công việc và khai thác dữ liệu tốt hơn.

Theo đó, việc sử dụng Excel để phân tích dữ liệu vẫn là lựa chọn lý tưởng đối với các trường hợp:

- **Dữ liệu nhỏ đến vừa (dưới ∼1 triệu dòng):** Dễ dàng tải, xem và thao tác trực tiếp mà không lo vấn đề hiệu suất.
- **Phân tích nhanh và tạo biểu đồ cơ bản:** Tính toán tổng, trung bình, min/max, và tạo biểu đồ cột, đường, tròn chỉ với vài thao tác. Nếu như ta muốn phân tích nhanh một bộ dữ liệu chỉ trong 2, 3 tiếng, việc áp dụng Python ở đây sẽ không khả thi.
- **Làm việc với đối tượng không chuyên về kỹ thuật:** Giao diện quen thuộc giúp mọi người dễ hiểu và tự xử lý dữ liệu cơ bản. Với môi trường doanh nghiệp, việc mọi người hiểu được nhau đang làm gì là một điều quan trọng để dự án được diễn ra suôn sẻ.
- **Thống kê mô tả đơn giản:** Sử dụng các hàm như `AVERAGE`, `MEDIAN`, `STDEV` hoặc công cụ data analysis toolpak để tính toán nhanh.
- **Tạo báo cáo nhanh, dễ chia sẻ:** Định dạng `.xlsx` phổ biến, dễ gửi qua email hoặc chia sẻ nội bộ; nhiều phần mềm hỗ trợ mở và chỉnh sửa định dạng này.

Đối với các ngôn ngữ lập trình, chúng ta sẽ tận dụng được tối đa lợi ích chúng mang lại với các trường hợp sau:

- **Xử lý dữ liệu lớn (từ hàng triệu đến hàng tỷ dòng):** Excel sẽ chậm và giới hạn, trong khi các thư viện như `Pandas` (Python) xử lý nhanh, tối ưu bộ nhớ.
- **Xây dựng mô hình phức tạp (Machine Learning):** Excel không đáp ứng được, trong khi Python, R có hệ sinh thái thư viện mạnh mẽ.
- **Tự động hóa công việc lặp lại:** Viết script giúp thu thập, xử lý, tạo báo cáo định kỳ mà không cần thao tác thủ công.

- **Kết nối đa nguồn dữ liệu:** Lấy dữ liệu từ SQL, API, dịch vụ web hoặc kho dữ liệu đám mây để phân tích tổng hợp.
- **Phân tích phức tạp, nhiều bảng, nhiều định dạng:** Lập trình cho phép `join`, `transform`, `aggregate` dữ liệu ở mức linh hoạt cao.
- **Tạo ứng dụng và dashboard tương tác:** Với `Streamlit`, `Dash` (Python) hoặc `Shiny` (R), bạn có thể xây dựng công cụ phân tích tùy chỉnh và trực quan hơn so với Excel.

II.2. Các hàm Excel quan trọng

Để làm việc hiệu quả với dữ liệu trong Excel, việc thành thạo các hàm chính yếu là điều cốt lõi. Các hàm này chính là những công cụ giúp ta nhanh chóng biến dữ liệu thô thành những thông tin giá trị, hỗ trợ đắc lực cho việc phân tích và đưa ra quyết định. Dưới đây là các hàm Excel phổ biến được sử dụng nhiều nên ghi nhớ:

Phương thức	Hàm Excel	Cách sử dụng
Kiểm tra điều kiện	`IF()`	`=IF(điều_kiện, giá_trị_nếu_đúng, giá_trị_nếu_sai)`
Lồng nhiều điều kiện	`IFS()`	`=IFS(điều_kiện1, giá_trị1, điều_kiện2, giá_trị2...)`
Tổng có điều kiện	`SUMIF()`	`=SUMIF(phạm_vi, tiêu_chí, phạm_vi_tổng)`
Tổng nhiều điều kiện	`SUMIFS()`	`=SUMIFS(phạm_vi_tổng, phạm_vi1, tiêu_chí1, phạm_vi2, tiêu_chí2...)`
Đếm có điều kiện	`COUNTIF()`	`=COUNTIF(phạm_vi, tiêu_chí)`
Đếm nhiều điều kiện	`COUNTIFS()`	`=COUNTIFS(phạm_vi1, tiêu_chí1, phạm_vi2, tiêu_chí2...)`
Trung bình có điều kiện	`AVERAGEIF()`	`=AVERAGEIF(phạm_vi, tiêu_chí, phạm_vi_trung_bình)`
Trung bình nhiều điều kiện	`AVERAGEIFS()`	`=AVERAGEIFS(phạm_vi_trung_bình, phạm_vi1, tiêu_chí1...)`
Tìm kiếm theo hàng	`HLOOKUP()`	`=HLOOKUP(giá_trị_tìm, bảng_tìm, chỉ_số_hàng, [chính_xác])`
Tìm kiếm theo cột	`VLOOKUP()`	`=VLOOKUP(giá_trị_tìm, bảng_tìm, chỉ_số_cột, [chính_xác])`
Truy xuất dữ liệu theo vị trí	`INDEX()`	`=INDEX(mảng, số_hàng, [số_cột])`
Tìm vị trí của dữ liệu	`MATCH()`	`=MATCH(giá_trị_tìm, phạm_vi_tìm, [kiểu_đối_chiếu])`

Bảng 2: Các hàm Excel quan trọng quan trọng và cách sử dụng.

Trong số các hàm được cung cấp, có ba hàm nâng cao sử dụng có thể giúp việc xử lý dữ liệu từ đơn giản đến phức tạp được nhanh gọn và hợp thẩm mỹ hơn chính là: **VLOOKUP**, **INDEX** và **MATCH**. Các hàm này cho phép bạn dễ dàng tìm kiếm, tổng hợp dữ liệu theo điều kiện và áp dụng các logic phân loại.

II.2.1. Hàm VLOOKUP

VLOOKUP giúp bạn tìm kiếm một giá trị cụ thể trong cột đầu tiên của một bảng (hoặc một phạm vi dữ liệu) và trả về một giá trị tương ứng từ một cột khác nằm trên cùng một hàng. Để dễ hình dung, việc tìm kiếm này giống như việc thực hiện tìm kiếm số điện thoại của một người trong danh bạ: bạn tìm tên người đó và khi tìm được, bạn lấy số điện thoại tương ứng với hàng đó. Công thức của hàm **VLOOKUP** có định dạng như sau:

Công thức hàm VLOOKUP

VLOOKUP(lookup_value, table_array, col_index_num, [range_lookup])

Ví dụ sử dụng: Thực hiện tìm kiếm ngày mua hàng gần nhất từ mã khách hàng.

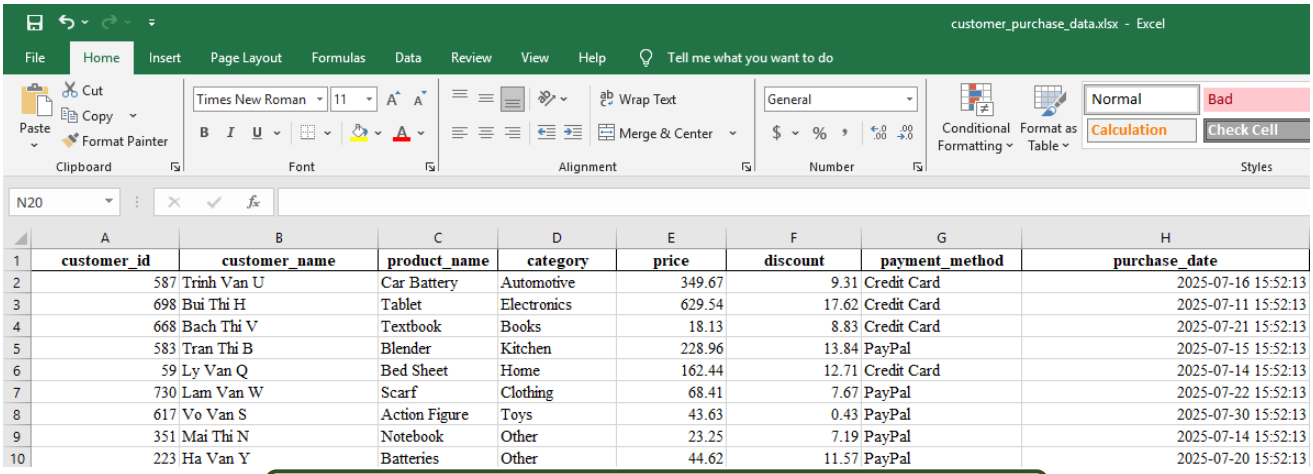

	A	B	C	D	E	F	G	H
1	customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
2	587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
3	698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
4	668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
5	583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
6	59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
7	730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
8	617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
9	351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
10	223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 2: Dữ liệu ban đầu muốn thực hiện việc tìm kiếm.

Với bảng dữ liệu gốc, xác định giá trị mà bạn muốn tìm (giả sử ở đây giá trị cần tìm nằm ở ô là ô J2 được tô màu vàng). Giá trị này sẽ đóng vai trò là từ khóa để hàm *VLOOKUP* tra cứu.

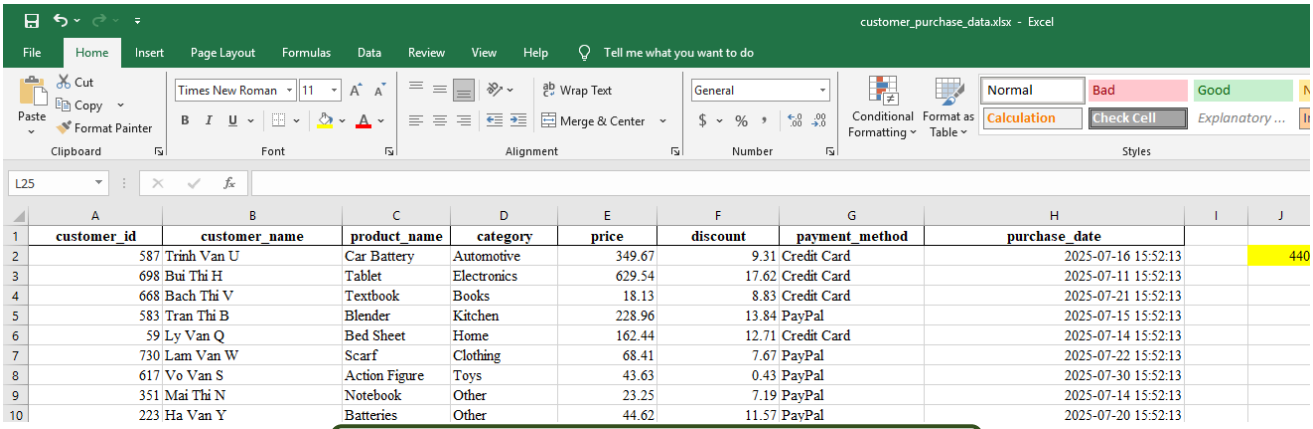

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 3: Nhập giá trị cần tìm tương ứng.

Sau khi chọn giá trị tìm kiếm, bạn nhập công thức $=VLOOKUP(...)$ vào ô cần hiển thị kết quả. Trong ví dụ này, chúng ta sẽ nhập vào ô ngay bên cạnh hoặc một vị trí bất kỳ bạn muốn lấy dữ liệu.

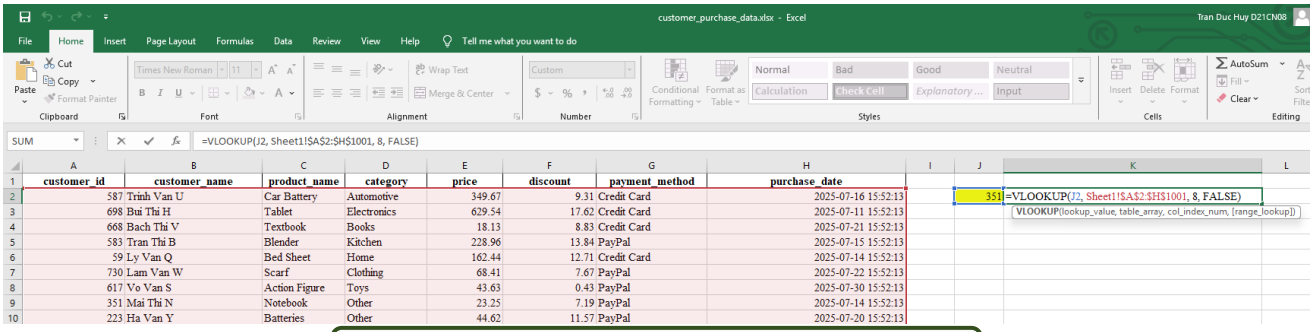

Hình 4: Nhập công thức VLOOKUP.

Trong đó:

- **J2:** Là ô chứa giá trị mã khách hàng cần tìm.
- **Sheet1!$A$2:$H$1001:** Là phạm vi bảng tra cứu, trong ví dụ này thực hiện tra cứu từ ô *A2* đến ô *H1001*.
- **8:** Vị trí cột dữ liệu trả về, trong ví dụ này thực hiện chọn cột số 8 trả về ngày mua hàng tương ứng với khách hàng có mã id trong ô **J2**.
- **FALSE:** Trả về giá trị chính xác tuyệt đối (nếu điền là **True** hàm sẽ thực hiện trả về độ chính xác gần đúng).

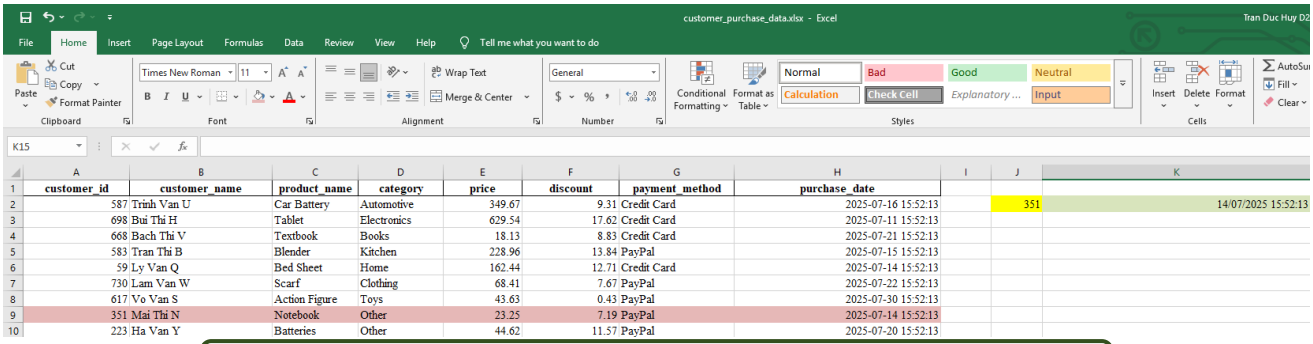

	customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date			
2	587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13		351	14/07/2025 15:52:13
3	698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13			
4	668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13			
5	583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13			
6	59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13			
7	730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13			
8	617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13			
9	351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13			
10	223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13			

Hình 5: Kết quả trả về là ngày mua hàng gần nhất (tại dòng thứ 9) tương ứng với id khách hàng được điền trong ô **J2**.

II.2.2. Hàm INDEX

INDEX giúp bạn lấy giá trị của một ô trong bảng hoặc phạm vi dữ liệu dựa trên số thứ tự hàng và số thứ tự cột. Một cách hình dung đơn giản: bạn coi bảng dữ liệu như một tấm bản đồ có tọa độ hàng và cột, hàm INDEX sẽ giúp chúng ta tìm đến đúng tọa độ đó để lấy giá trị. Hàm này tương tự việc ta lấy dữ liệu từ một ma trận trong Python.

Công thức hàm INDEX

INDEX(array, row_num, [column_num])

Ví dụ sử dụng: Lấy ra giá trị ngày mua hàng dựa trên vị trí hàng và cột trong bảng dữ liệu.

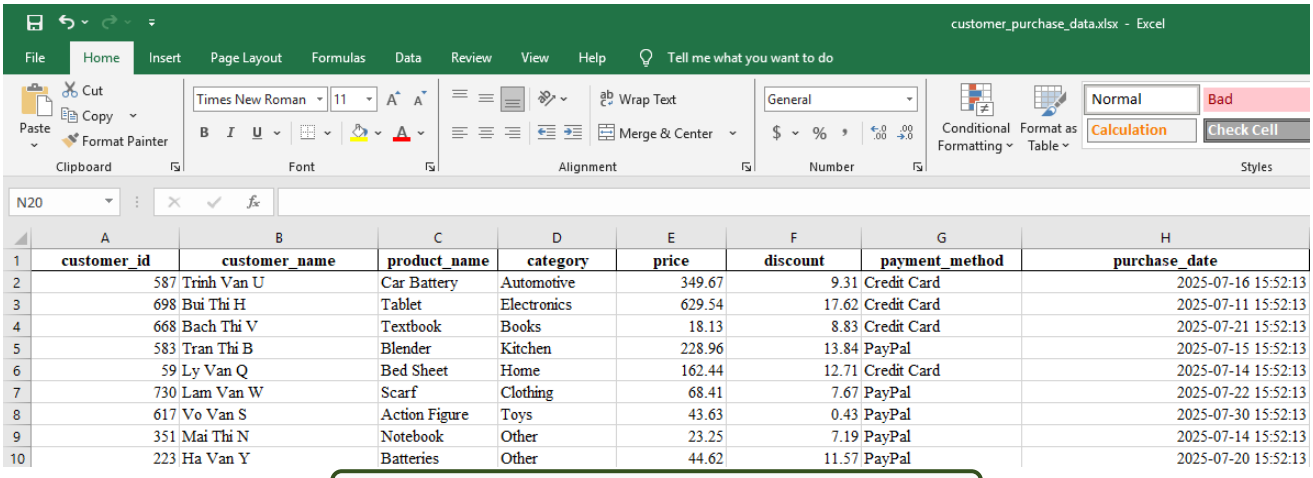

	customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
2	587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
3	698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
4	668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
5	583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
6	59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
7	730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
8	617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
9	351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
10	223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 6: Dữ liệu ban đầu muốn lấy giá trị.

Trong ví dụ này, giả sử bạn xác định trước vùng dữ liệu *A2:H10* và chọn hàng, cột tương ứng để lấy giá trị. Sau đó, nhập công thức *=INDEX(A2:H10, 9, 5)* để lấy giá trị tại hàng thứ 9 và cột thứ 5 của bảng dữ liệu.

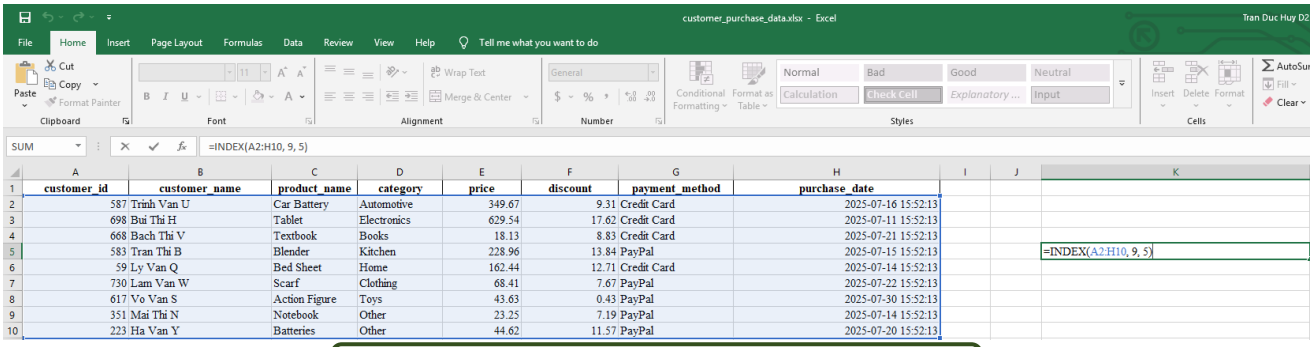

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 7: Nhập công thức INDEX.

Trong đó:

- **A2:H10:** Là vùng dữ liệu cần tra cứu.
- **9:** Vị trí hàng cần lấy dữ liệu.
- **5:** Vị trí cột cần lấy dữ liệu.

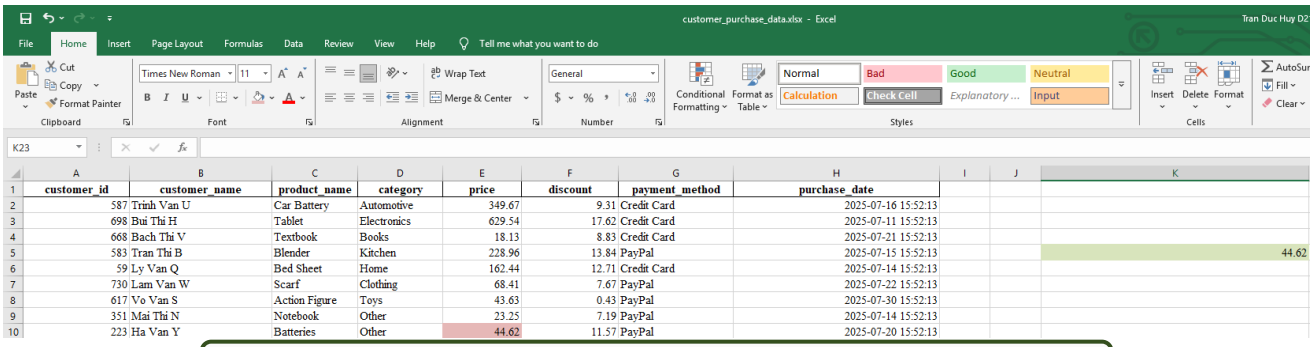

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 8: Kết quả trả về là giá mua hàng tại tọa độ (hàng 9, cột 5).

II.2.3. Hàm MATCH

MATCH giúp bạn tìm vị trí tương đối của một giá trị trong một dãy dữ liệu. Bạn có thể hình dung giống như việc dò số thứ tự của một mục trong danh sách. Ví dụ tìm xem mã khách hàng đang nằm ở dòng thứ mấy trong cột. Hàm này như việc ta sử dụng hàm where trong Python.

Công thức hàm MATCH

MATCH(lookup_value, lookup_array, [match_type])

Ví dụ sử dụng: Tìm vị trí của mã khách hàng trong cột mã ID.

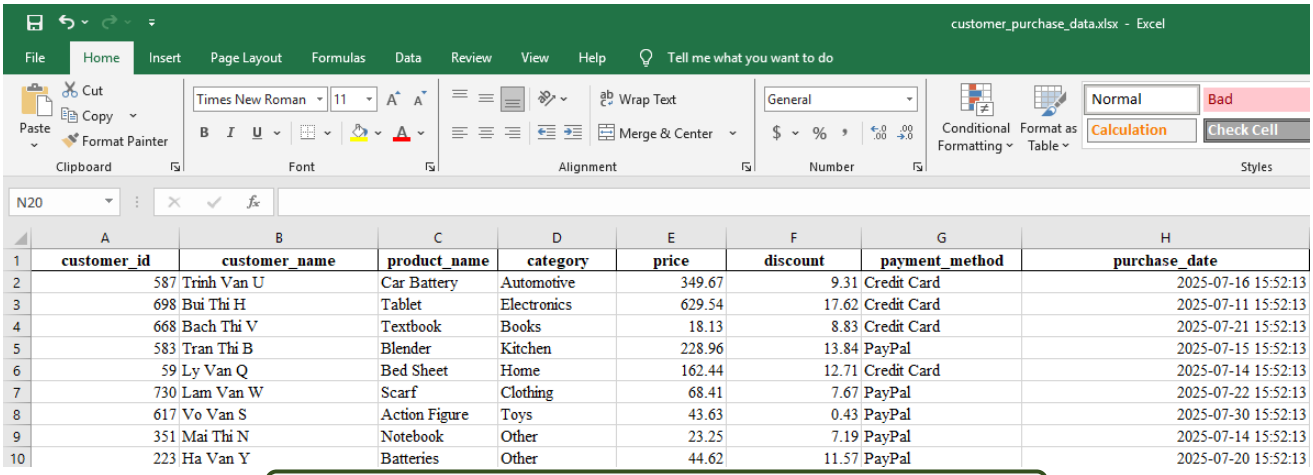

customer_purchase_data.xlsx - Excel

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13

Hình 9: Dữ liệu ban đầu muốn tìm vị trí giá trị.

Giả sử mã khách hàng cần tìm nằm ở ô **J2**. Bạn muốn biết mã này nằm ở vị trí thứ mấy trong cột *A2:A1001*.

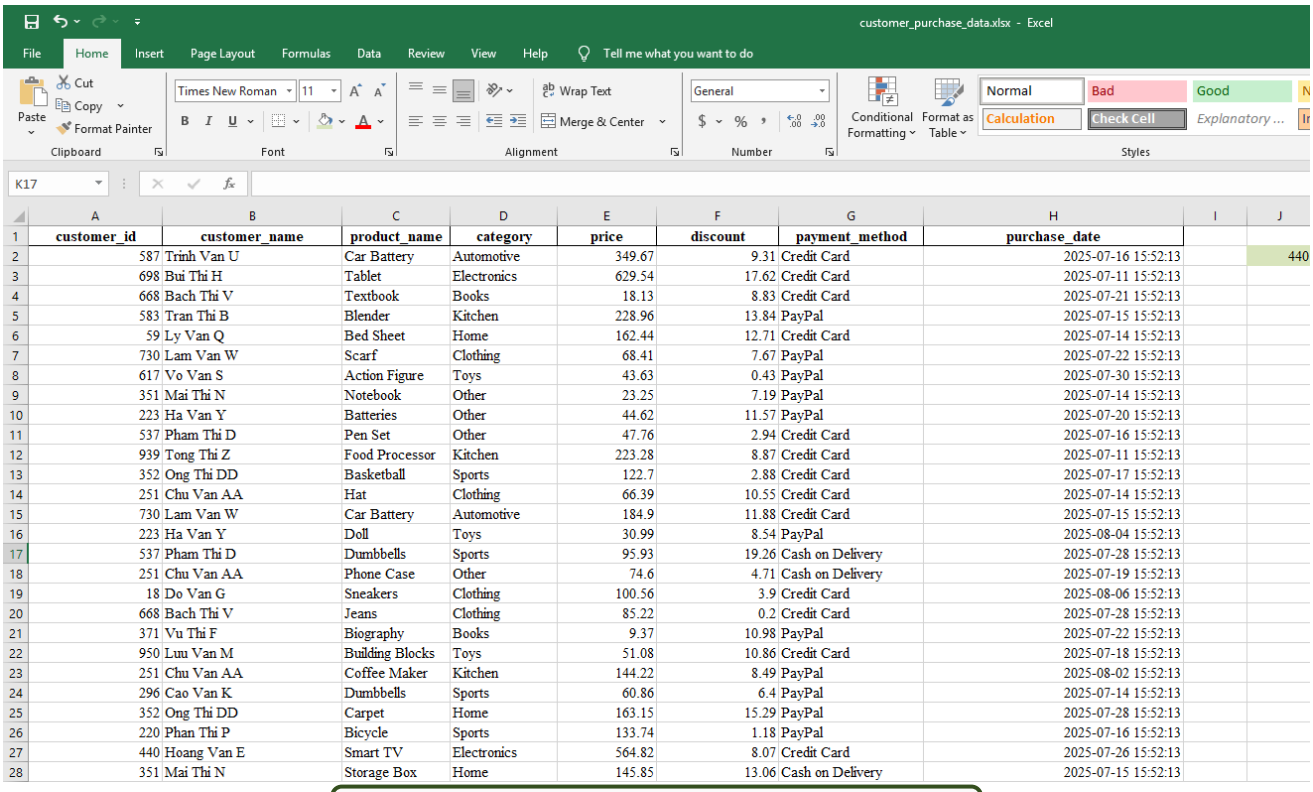

customer_purchase_data.xlsx - Excel

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13
537	Pham Thi D	Pen Set	Other	47.76	2.94	Credit Card	2025-07-16 15:52:13
939	Tong Thi Z	Food Processor	Kitchen	223.28	8.87	Credit Card	2025-07-11 15:52:13
352	Ong Thi DD	Basketball	Sports	122.7	2.88	Credit Card	2025-07-17 15:52:13
251	Chu Van AA	Hat	Clothing	66.39	10.55	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Car Battery	Automotive	184.9	11.88	Credit Card	2025-07-15 15:52:13
223	Ha Van Y	Doll	Toys	30.99	8.54	PayPal	2025-08-04 15:52:13
537	Pham Thi D	Dumbbells	Sports	95.93	19.26	Cash on Delivery	2025-07-28 15:52:13
251	Chu Van AA	Phone Case	Other	74.6	4.71	Cash on Delivery	2025-07-19 15:52:13
18	Do Van G	Sneakers	Clothing	100.56	3.9	Credit Card	2025-08-06 15:52:13
668	Bach Thi V	Jeans	Clothing	85.22	0.2	Credit Card	2025-07-28 15:52:13
371	Vu Thi F	Biography	Books	9.37	10.98	PayPal	2025-07-22 15:52:13
950	Luu Van M	Building Blocks	Toys	51.08	10.86	Credit Card	2025-07-18 15:52:13
251	Chu Van AA	Coffee Maker	Kitchen	144.22	8.49	PayPal	2025-08-02 15:52:13
296	Cao Van K	Dumbbells	Sports	60.86	6.4	PayPal	2025-07-14 15:52:13
352	Ong Thi DD	Carpet	Home	163.15	15.29	PayPal	2025-07-28 15:52:13
220	Phan Thi P	Bicycle	Sports	133.74	1.18	PayPal	2025-07-16 15:52:13
440	Hoang Van E	Smart TV	Electronics	564.82	8.07	Credit Card	2025-07-26 15:52:13
351	Mai Thi N	Storage Box	Home	145.85	13.06	Cash on Delivery	2025-07-15 15:52:13

Hình 10: Nhập giá trị cần tìm vị trí vào ô J2.

Nhập công thức *=MATCH(J2, A2:A1001, 0)* để trả về vị trí chính xác của giá trị J2 trong cột A.

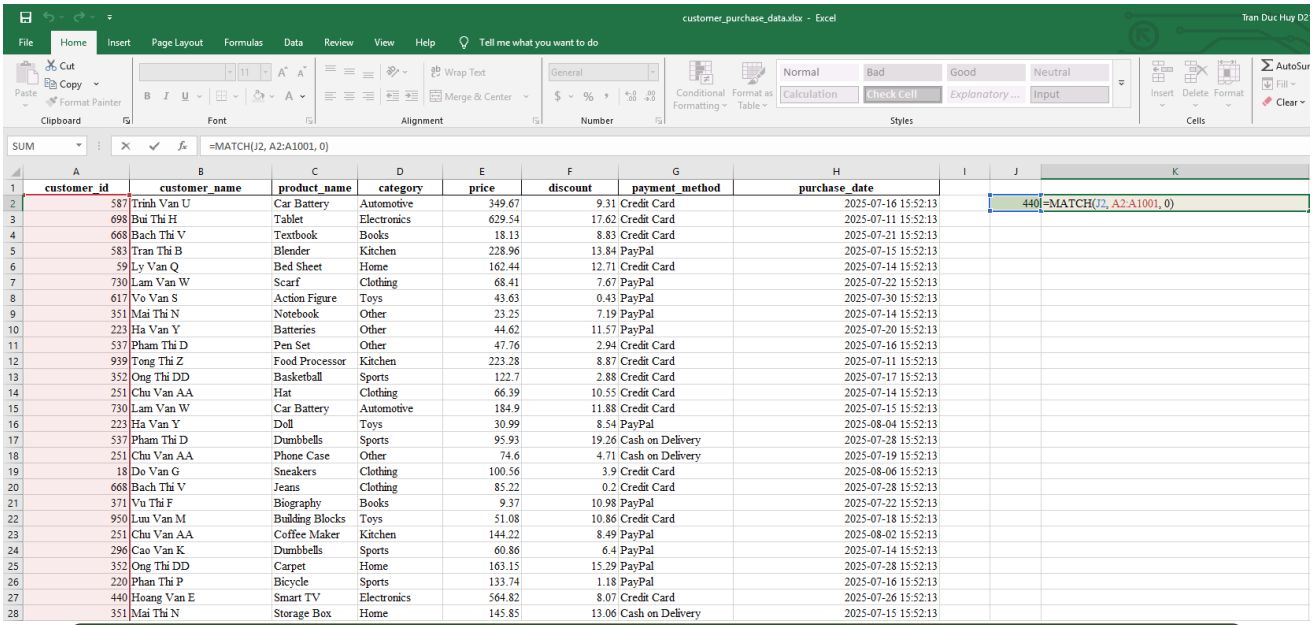

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13
537	Pham Thi D	Pen Set	Other	47.76	2.94	Credit Card	2025-07-16 15:52:13
939	Tong Thi Z	Food Processor	Kitchen	223.28	8.87	Credit Card	2025-07-11 15:52:13
352	Ong Thi DD	Basketball	Sports	122.7	2.88	Credit Card	2025-07-17 15:52:13
251	Chu Van AA	Hat	Clothing	66.39	10.55	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Car Battery	Automotive	184.9	11.88	Credit Card	2025-07-15 15:52:13
223	Ha Van Y	Doll	Toys	30.99	8.54	PayPal	2025-08-04 15:52:13
537	Pham Thi D	Dumbbells	Sports	95.93	19.26	Cash on Delivery	2025-07-28 15:52:13
251	Chu Van AA	Phone Case	Other	74.6	4.71	Cash on Delivery	2025-07-19 15:52:13
18	Do Van G	Sneakers	Clothing	100.56	3.9	Credit Card	2025-08-06 15:52:13
668	Bach Thi V	Jeans	Clothing	85.22	0.2	Credit Card	2025-07-28 15:52:13
371	Vu Thi F	Biography	Books	9.37	10.98	PayPal	2025-07-22 15:52:13
950	Luu Van M	Building Blocks	Toys	51.08	10.86	Credit Card	2025-07-18 15:52:13
251	Chu Van AA	Coffee Maker	Kitchen	144.22	8.49	PayPal	2025-08-02 15:52:13
296	Cao Van K	Dumbbells	Sports	60.86	6.4	PayPal	2025-07-14 15:52:13
352	Ong Thi DD	Carpet	Home	163.15	15.29	PayPal	2025-07-28 15:52:13
220	Phan Thi P	Bicycle	Sports	133.74	1.18	PayPal	2025-07-16 15:52:13
440	Hoang Van E	Smart TV	Electronics	564.82	8.07	Credit Card	2025-07-26 15:52:13
351	Mai Thi N	Storage Box	Home	145.85	13.06	Cash on Delivery	2025-07-15 15:52:13

Hình 11: Nhập công thức MATCH vào ô cần tìm tương ứng (giả sử là ô bên cạnh).

Trong đó:

- **J2:** Là giá trị cần tìm vị trí.
- **A2:A1001:** Là vùng dữ liệu cần tìm kiếm.
- **0:** Yêu cầu tìm kiếm chính xác tuyệt đối.

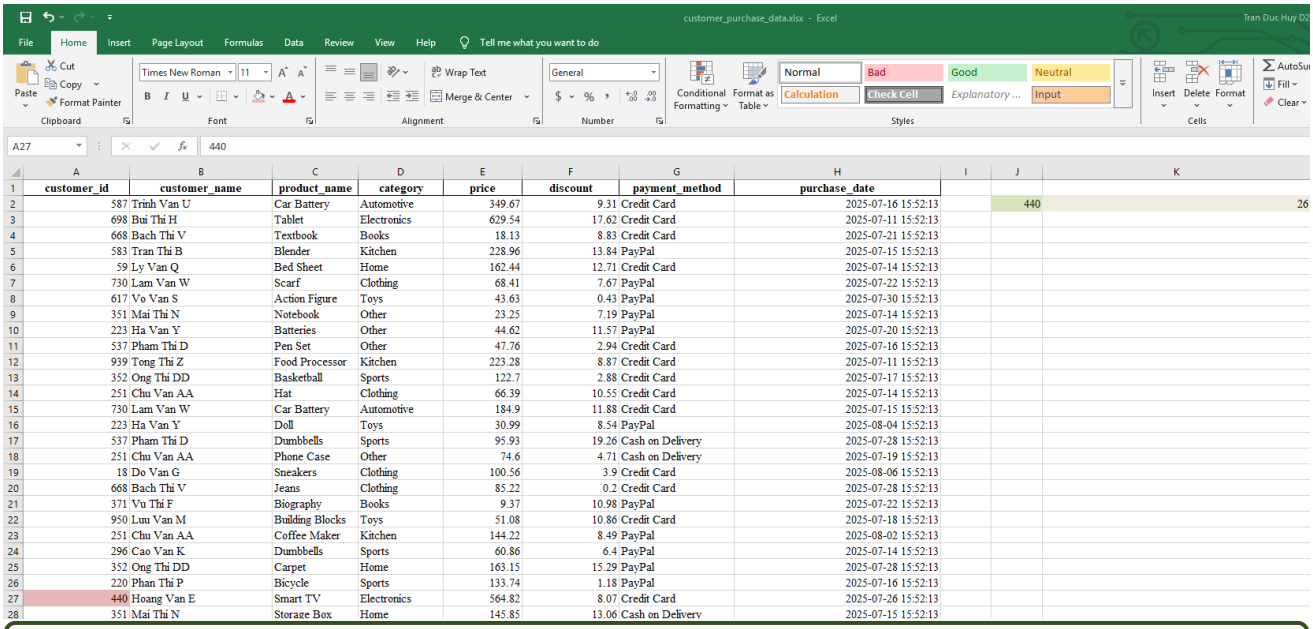

customer_id	customer_name	product_name	category	price	discount	payment_method	purchase_date
587	Trinh Van U	Car Battery	Automotive	349.67	9.31	Credit Card	2025-07-16 15:52:13
698	Bui Thi H	Tablet	Electronics	629.54	17.62	Credit Card	2025-07-11 15:52:13
668	Bach Thi V	Textbook	Books	18.13	8.83	Credit Card	2025-07-21 15:52:13
583	Tran Thi B	Blender	Kitchen	228.96	13.84	PayPal	2025-07-15 15:52:13
59	Ly Van Q	Bed Sheet	Home	162.44	12.71	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Scarf	Clothing	68.41	7.67	PayPal	2025-07-22 15:52:13
617	Vo Van S	Action Figure	Toys	43.63	0.43	PayPal	2025-07-30 15:52:13
351	Mai Thi N	Notebook	Other	23.25	7.19	PayPal	2025-07-14 15:52:13
223	Ha Van Y	Batteries	Other	44.62	11.57	PayPal	2025-07-20 15:52:13
537	Pham Thi D	Pen Set	Other	47.76	2.94	Credit Card	2025-07-16 15:52:13
939	Tong Thi Z	Food Processor	Kitchen	223.28	8.87	Credit Card	2025-07-11 15:52:13
352	Ong Thi DD	Basketball	Sports	122.7	2.88	Credit Card	2025-07-17 15:52:13
251	Chu Van AA	Hat	Clothing	66.39	10.55	Credit Card	2025-07-14 15:52:13
730	Lam Van W	Car Battery	Automotive	184.9	11.88	Credit Card	2025-07-15 15:52:13
223	Ha Van Y	Doll	Toys	30.99	8.54	PayPal	2025-08-04 15:52:13
537	Pham Thi D	Dumbbells	Sports	95.93	19.26	Cash on Delivery	2025-07-28 15:52:13
251	Chu Van AA	Phone Case	Other	74.6	4.71	Cash on Delivery	2025-07-19 15:52:13
18	Do Van G	Sneakers	Clothing	100.56	3.9	Credit Card	2025-08-06 15:52:13
668	Bach Thi V	Jeans	Clothing	85.22	0.2	Credit Card	2025-07-28 15:52:13
371	Vu Thi F	Biography	Books	9.37	10.98	PayPal	2025-07-22 15:52:13
950	Luu Van M	Building Blocks	Toys	51.08	10.86	Credit Card	2025-07-18 15:52:13
251	Chu Van AA	Coffee Maker	Kitchen	144.22	8.49	PayPal	2025-08-02 15:52:13
296	Cao Van K	Dumbbells	Sports	60.86	6.4	PayPal	2025-07-14 15:52:13
352	Ong Thi DD	Carpet	Home	163.15	15.29	PayPal	2025-07-28 15:52:13
220	Phan Thi P	Bicycle	Sports	133.74	1.18	PayPal	2025-07-16 15:52:13
440	Hoang Van E	Smart TV	Electronics	564.82	8.07	Credit Card	2025-07-26 15:52:13
351	Mai Thi N	Storage Box	Home	145.85	13.06	Cash on Delivery	2025-07-15 15:52:13

Hình 12: Kết quả trả về là vị trí tương đối của mã khách hàng trong vùng dữ liệu (vùng tìm kiếm của dữ liệu bắt đầu từ dòng 2 nên kết quả trả về theo số thứ tự là 26).

II.3. Phân tích dữ liệu nhanh với Pivot Table

Trong môi trường dữ liệu lớn hiện tại, dữ liệu được thu thập liên tục, tạo ra những tập tin khổng lồ với hàng ngàn, thậm chí hàng triệu dòng. Nhìn vào dữ liệu thô này, việc rút ra các xu hướng, quy luật hay những thông tin kinh doanh giá trị là gần như không thể. Ví dụ, làm thế nào để biết danh mục sản phẩm nào đang tạo ra doanh thu cao nhất, hoặc phương thức thanh toán nào được khách hàng ưa chuộng nhất? Trả lời những câu hỏi này theo cách thủ công sẽ tốn rất nhiều thời gian và dễ xảy ra sai sót.

Đây chính là lúc **Bảng tổng hợp** (hay **Pivot Table**), một trong những công cụ mạnh mẽ và linh hoạt nhất của Excel, phát huy tác dụng. Nó cho phép người dùng tổng hợp, sắp xếp, nhóm, đếm, tính tổng hoặc trung bình dữ liệu được lưu trữ trong một bảng một cách nhanh chóng mà không cần viết bất kỳ một công thức phức tạp nào.

II.3.1. Khởi tạo Pivot Table

Cho file Excel chứa dữ liệu bán hàng của quý trước với các cột gồm customer_id, product_name, category, price, discount, payment_method, và purchase_date. Làm cách nào để ta tạo ra báo cáo tổng quan về tình hình kinh doanh dựa vào những thông tin trên một cách nhanh chóng nhất?

Hãy tiến hành các bước sau để tạo Pivot Table đầu tiên của chúng ta:

1. **Chọn dữ liệu:** Đầu tiên, hãy bảo đảm bạn đã chọn một ô bất kỳ bên trong vùng dữ liệu của mình rồi sử dụng tổ hợp phím Ctrl+A. Excel đủ thông minh để tự động nhận diện toàn bộ bảng dữ liệu liên quan và kết nối với ô đang được chọn.
2. **Chèn bảng tổng hợp:** Trên thanh công cụ (Ribbon), đi đến tab `Insert` và nhấp vào `PivotTable`. Một hộp thoại `Create PivotTable` sẽ xuất hiện (Insert » PivotTable » From Table/Range). Giao diện của Pivot Table sẽ có dạng như bên dưới.

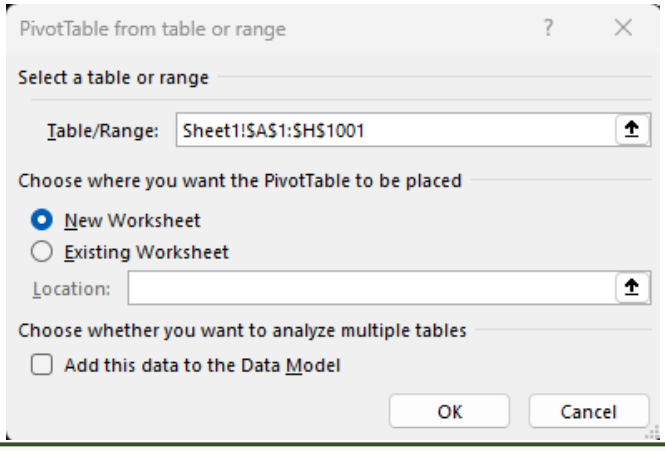

Hình 13: Hộp thoại **Create PivotTable**. Excel thường tự động phát hiện vùng dữ liệu nơi con chỏ ta đặt vào, ta có thể chỉnh vùng này ở ('Table/Range').

Sau khi nhấn OK để xác nhận, Excel sẽ tạo một trang tính mới chứa giao diện của Pivot Table.

II.3.2. Bố cục và các thành phần của Pivot Table

Sau khi tạo, khung Pivot Table sẽ nằm ở bên trái khu vực hiển thị và xuất hiện một ngăn tác vụ PivotTable Fields ở bên phải. Đây chính là vị trí chúng ta dùng để làm việc với bảng. Ngăn này bao gồm danh sách tất cả các cột từ bảng dữ liệu gốc và bốn khu vực chức năng ở phía dưới:

- **Filters**: Cho phép bạn lọc toàn bộ bảng tổng hợp dựa trên một hoặc nhiều trường. Ví dụ: chỉ hiển thị dữ liệu cho danh mục 'Electronics'.
- **Columns**: Các trường được kéo vào đây sẽ hiển thị các giá trị duy nhất của chúng dưới dạng các cột trong bảng tổng hợp.
- **Rows**: Tương tự như cột, các trường ở đây sẽ tạo ra các hàng. Đây là nơi phổ biến nhất để đặt các trường bạn muốn phân tích (ví dụ: 'category', 'product_name').
- **Values**: Khu vực quan trọng nhất. Các trường ở đây sẽ được tổng hợp. Mặc định, Excel sẽ tính tổng (Sum) cho các trường số và đếm (Count) cho các trường văn bản.

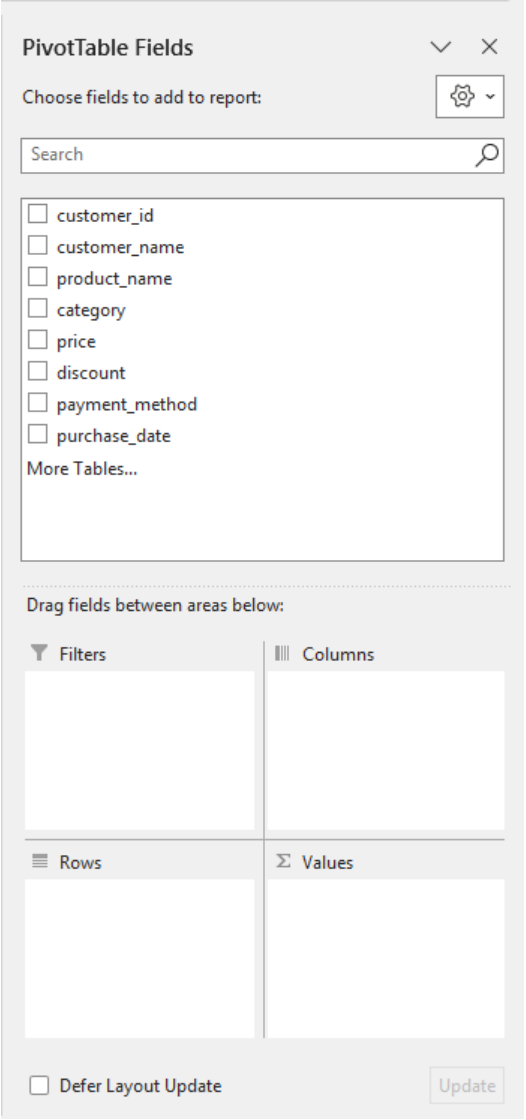

Hình 14: Giao diện *PivotTable Fields*. Khung lớn ở trên được gọi là "Fields Section" còn 4 khung nhỏ ở dưới gọi là "Areas Section".

II.3.3. Thực hành

Để làm quen với việc áp dụng Pivot Table vào những trường hợp thực tế, chúng ta hãy thử với file dữ liệu giả định ở đây: **Link**.

Doanh thu theo từng danh mục sản phẩm là bao nhiêu? (Value Field Settings)

Đây là câu hỏi cơ bản nhất. Để trả lời, hãy kéo và thả các trường như sau:

- Kéo trường 'category' vào vùng **Rows**.
- Kéo trường 'price' vào vùng **Values**. Đảm bảo là Value Field Settings > Summarize value field by > Sum.

- Định dạng số: Value Field Settings » Number Format » Currency.

Ngay lập tức, Excel sẽ cho ta một bảng tóm tắt rõ ràng. Excel sẽ tự động tính 'Sum of price' (Tổng giá) cho mỗi danh mục.

Row Labels	Sum of price
Automotive	32617.85
Beauty	6850.99
Books	2049.77
...	
Grand Total	**142370.73**

Bảng 3: Output của Excel sau khi đưa hai giá trị, một định tính, một định lượng vào "Areas Section".

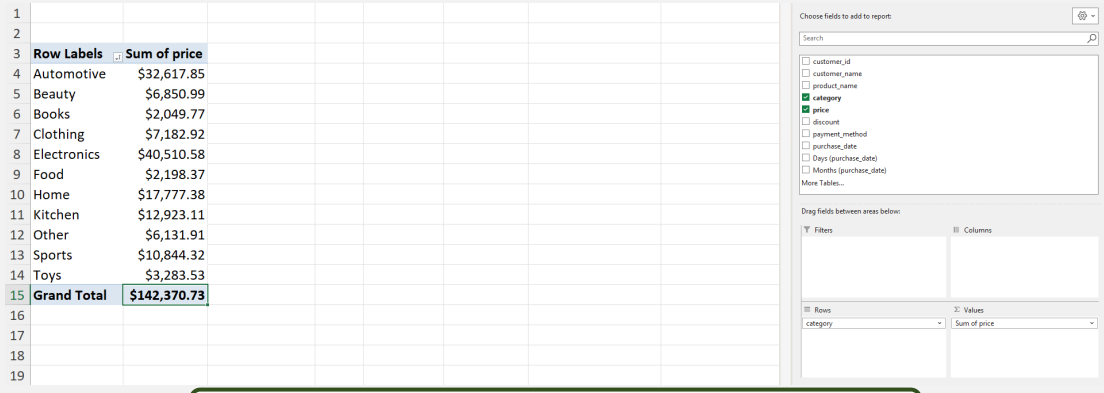

Hình 15: Tổng giá bán theo danh mục.

Phân tích phương thức thanh toán theo từng danh mục (Values)

Câu hỏi tiếp theo là *Khách hàng mua đồ điện tử thường trả bằng thẻ hay tiền mặt?*. Để trả lời, chúng ta sẽ tạo một báo cáo chéo.

- Giữ 'category' trong vùng **Rows**.
- Kéo 'payment_method' vào vùng **Columns**.
- Kéo 'customer_id' vào vùng **Values**. Excel sẽ mặc định biến này là 'Sum of customer_id'. chúng ta cần chuyển qua 'Count of customer_id' qua các bước Sum of customer_id » Value Field Settings » Summazire value field by » Count. Bằng cách này Excel cho chúng ta số lượng giao dịch, chính là điều chúng ta cần ở trường hợp này.

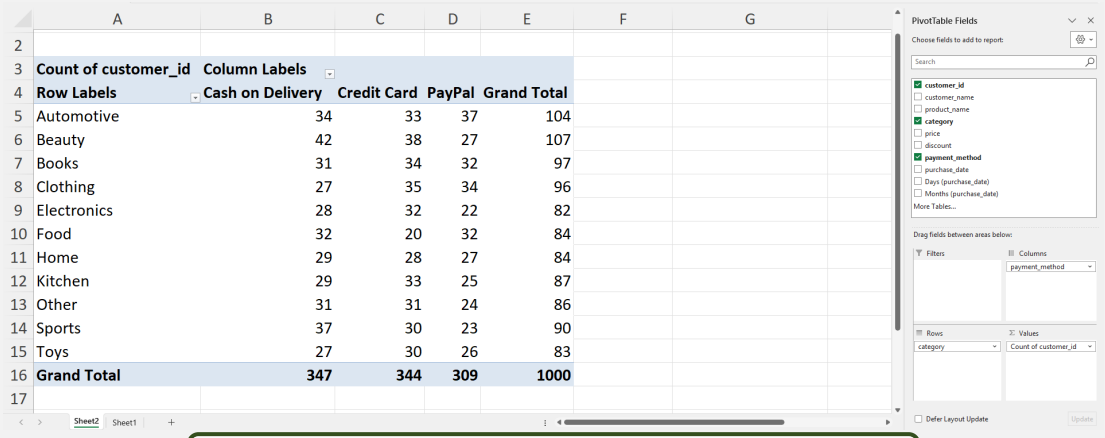

Count of customer_id	Column Labels			
Row Labels	Cash on Delivery	Credit Card	PayPal	Grand Total
Automotive	34	33	37	104
Beauty	42	38	27	107
Books	31	34	32	97
Clothing	27	35	34	96
Electronics	28	32	22	82
Food	32	20	32	84
Home	29	28	27	84
Kitchen	29	33	25	87
Other	31	31	24	86
Sports	37	30	23	90
Toys	27	30	26	83
Grand Total	**347**	**344**	**309**	**1000**

Hình 16: Báo cáo chéo phân tích số lượng giao dịch theo danh mục và phương thức thanh toán.

Tỷ trọng phương thức thanh toán theo tháng (Show Values As)

Câu hỏi là *Trong từng tháng, tỷ lệ giao dịch qua từng phương thức thanh toán là bao nhiêu?*

- Kéo 'purchase_date' vào **Rows** → Excel sẽ gộp bảng theo **Months**. Nếu chưa, bấm phải chuột vào hàng ngày → Group... » Months.
- Kéo 'payment_method' vào **Columns**.
- Kéo 'customer_id' vào **Values** và chuyển sang Value Field Settings » Count.
- Hiển thị tỷ trọng theo hàng (từng tháng): Show Values As » % of Row Total.

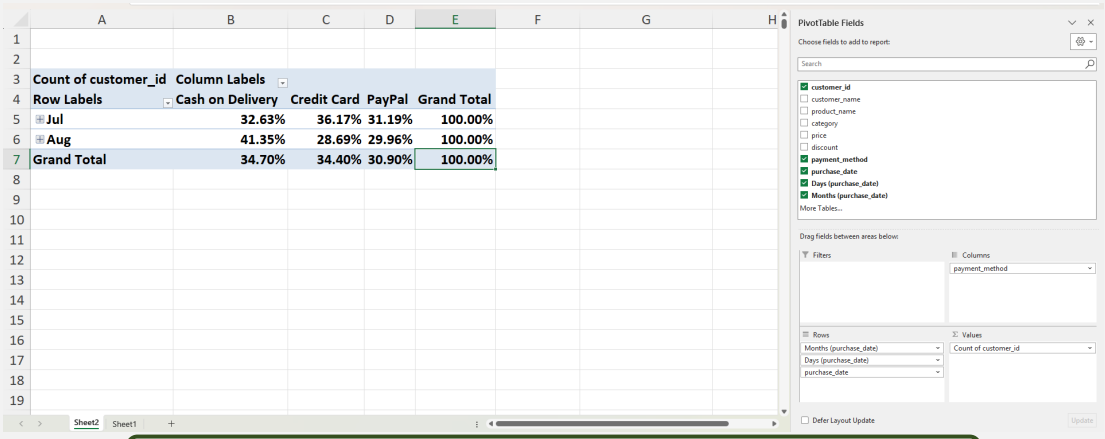

Count of customer_id	Column Labels			
Row Labels	Cash on Delivery	Credit Card	PayPal	Grand Total
Jul	32.63%	36.17%	31.19%	100.00%
Aug	41.35%	28.69%	29.96%	100.00%
Grand Total	34.70%	34.40%	30.90%	100.00%

Hình 17: Tỷ trọng phương thức thanh toán theo từng tháng.

Sản phẩm bán chạy theo danh mục (Value Filters)

Câu hỏi là *Mỗi danh mục có sản phẩm nào bán chạy nhất (nhiều giao dịch nhất)?*

- **Rows**: 'category' → 'product_name' (đặt product dưới category). Ở đây 'category' sẽ được gọi là biến cha, và 'product_name' sẽ là biến con.
- **Values**: 'customer_id' → Count.
- Bật bộ lọc Top N cho mỗi danh mục: bấm mũi tên ở trường 'product_name' → Value Filters » Top 10 → đổi *10* thành *1* để lấy Top 1 theo *Count of customer_id*.

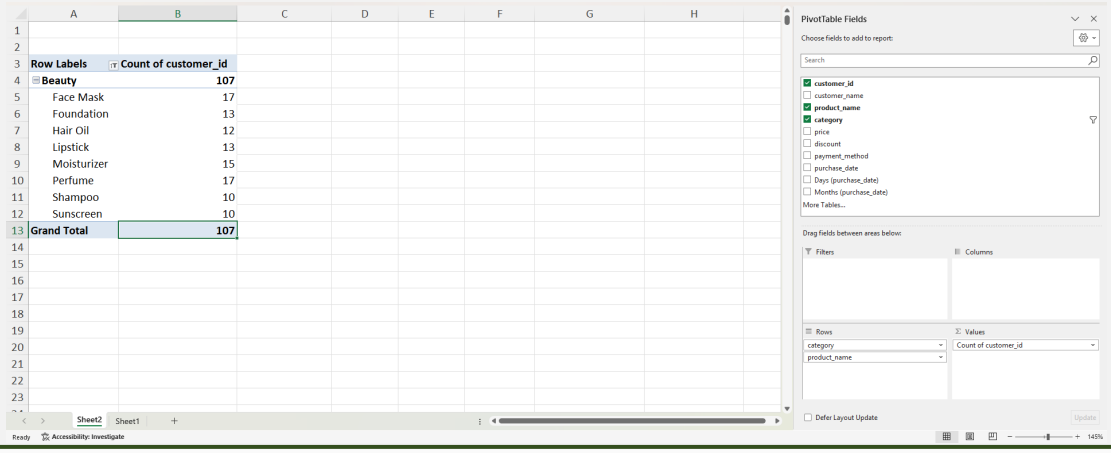

Hình 18: Top sản phẩm theo từng danh mục dựa trên số giao dịch. Ở đây ta đang sắp xếp theo 'category', thế nên Top N sẽ được thực hiện cho biến cha được nói ở trên.

Giá bán trung bình theo phương thức thanh toán

Câu hỏi là *Giá bán trung bình khác nhau thế nào giữa các phương thức thanh toán?*

- **Rows**: 'payment_method'.
- **Values**: 'price' → Value Field Settings » Average.
- Tuỳ chọn thêm số giao dịch để tham chiếu: kéo thêm 'customer_id' vào **Values** → Count.
- Định dạng 'Average of price' thành Number Format » Currency.

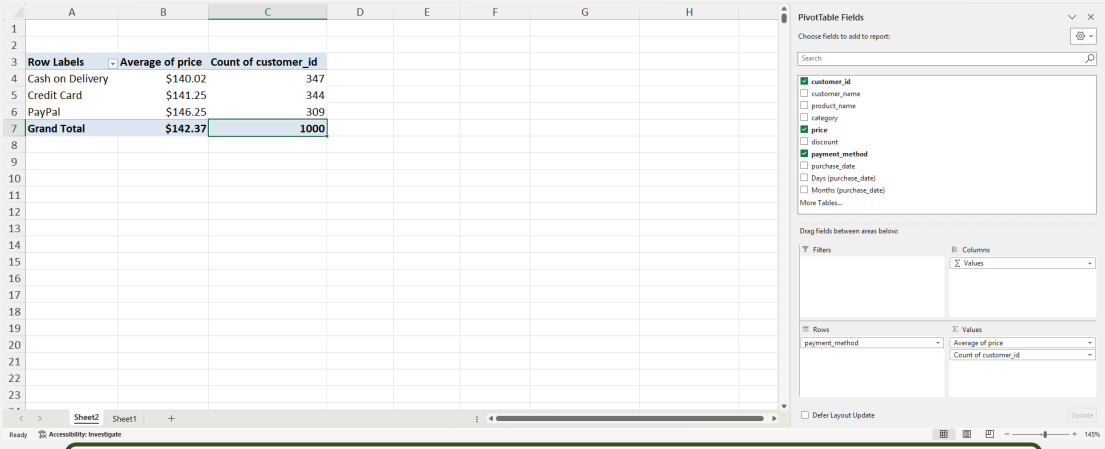

Row Labels	Average of price	Count of customer_id
Cash on Delivery	$140.02	347
Credit Card	$141.25	344
PayPal	$146.25	309
Grand Total	$142.37	1000

Hình 19: Giá bán trung bình theo phương thức thanh toán.

Mức giảm giá trung bình theo danh mục và phương thức

Câu hỏi là *Danh mục nào được giảm giá nhiều hơn, và phương thức thanh toán có ảnh hưởng không?*

- **Rows**: 'category'.
- **Columns**: 'payment_method'.
- **Values**: 'discount' → Average.
- Định dạng số thập phân phù hợp cho cột 'discount': Number Format » Number.
- (Tuỳ chọn) Tô màu theo mức cao-thấp: chọn vùng Values → Home » Conditional Formatting » Color Scales. Ở đây ta chỉ chọn vùng có dữ liệu chưa được tính tổng, ở đây là vùng "A5:E15", Excel sẽ mặc định không tô các vùng dùng làm Filter (ví du: 'Automotive', 'Beauty', ...).

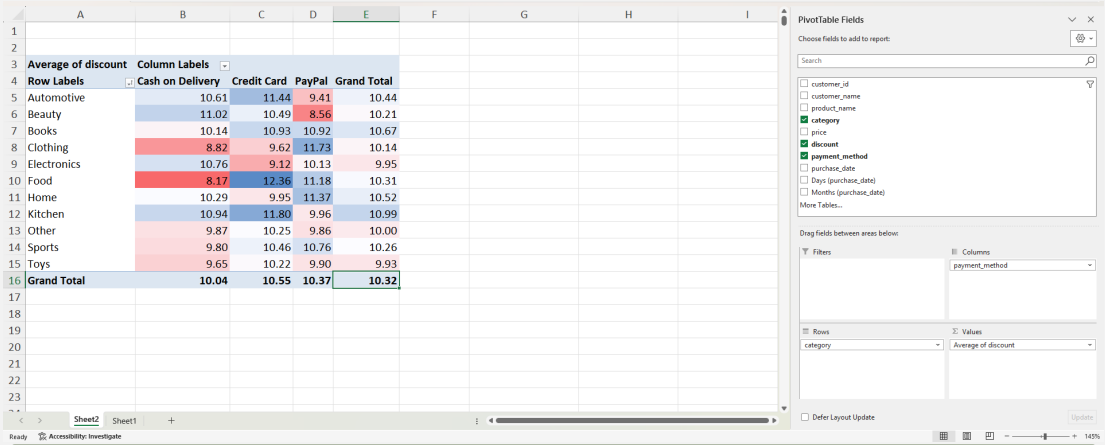

Average of discount	Column Labels			
Row Labels	Cash on Delivery	Credit Card	PayPal	Grand Total
Automotive	10.61	11.44	9.41	10.44
Beauty	11.02	10.49	8.56	10.21
Books	10.14	10.93	10.92	10.67
Clothing	8.82	9.62	11.73	10.14
Electronics	10.76	9.12	10.13	9.95
Food	8.17	12.36	11.18	10.31
Home	10.29	9.95	11.37	10.52
Kitchen	10.94	11.80	9.96	10.99
Other	9.87	10.25	9.86	10.00
Sports	9.80	10.46	10.76	10.26
Toys	9.65	10.22	9.90	9.93
Grand Total	10.04	10.55	10.37	10.32

Hình 20: Giảm giá trung bình theo danh mục và phương thức thanh toán.

Top khách hàng theo chi tiêu

Câu hỏi là *Khách hàng nào chi tiêu nhiều nhất và chiếm bao nhiêu phần trăm tổng doanh số?*

- **Rows**: 'customer_name'.
- **Values**: 'price' → Sum.
- **Lọc Top-K**: bấm mũi tên ở 'customer_name' → Value Filters » Top 10 (có thể đổi 10 thành bất kỳ K nào).
- **Giữ nguyên phân phối ban đầu bằng Pivot phụ + GETPIVOTDATA**:
  - Tạo *Pivot phụ* từ cùng nguồn dữ liệu: Insert » PivotTable. Đặt ở sheet `Totals`.
  - Trong Pivot phụ, chỉ kéo 'price' vào **Values** → Sum. Không đặt gì ở Rows/Columns/Filters để có một ô *Grand Total* duy nhất.
  - Quay lại Pivot *chính*. Ở cột trống ngay bên phải Pivot, tại dòng đầu tiên của khách hàng, nhập công thức: `=B4/GETPIVOTDATA("price",Totals!$A$3)`. Trong đó `B4` là ô "Total Buy" của khách hàng dòng đầu; `Totals!$A$3` là một ô bất kỳ nằm trong Pivot *phụ*. Hàm `GETPIVOTDATA` trả về *Grand Total* của Pivot phụ nên % luôn chia cho *tổng của toàn bộ khách*, không bị ảnh hưởng bởi lọc Top-K ở Pivot chính.
  - Đối với hàm GETPIVOTDATA ta có thể lựa chọn nhanh một giá trị bằng cách bấm vào một ô bất kì, gõ phím bắt đầu công thức "=" và sử dung con chỏ chuột click vào ô cần lấy giá trị.
  - Fill xuống cho các dòng còn lại; định dạng cột này Home » Number » Percentage (1–2 chữ số thập phân).
  - (Tuỳ chọn) Đổi tiêu đề cột thành *Percentage of Total Buy*. Bạn có thể ẩn cột *% of Column Total* mặc định nếu đã thêm trước đó để tránh nhầm lẫn.

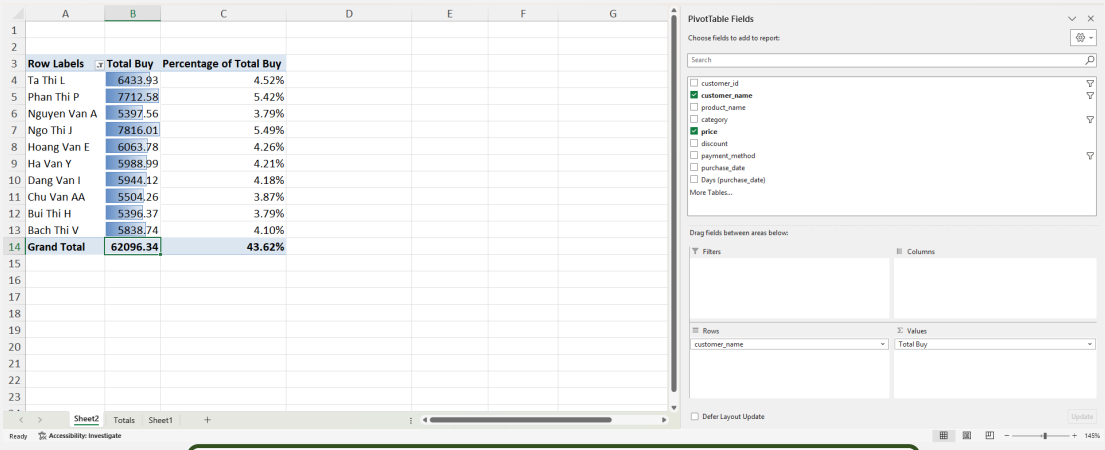

Hình 21: Top khách hàng theo tổng giá bán và tỷ trọng, với phần trăm cố định theo tổng ban đầu.

Các phân khúc giá bán

Câu hỏi là *Khách hàng có xu hướng mua sản phẩm ở tầm giá nào? Ở đây ta thấy rằng phân tích từng mức giá riêng lẻ ('price') sẽ tạo ra một bảng rất dài và vô nghĩa.*

- **Rows**: 'price'.
- **Values**: 'customer_id' → Excel sẽ mặc định là Count of customer_id.
- **Thực hiện việc gom nhóm (Grouping)**:
  - Nhấp chuột phải vào một ô bất kỳ trong cột nhãn hàng 'price'.
  - Chọn **Group...**.
  - Trong hộp thoại 'Grouping', hãy thiết lập các khoảng giá trị. Ví dụ:
    - Starting at: 0
    - Ending at: 900
    - By: 100 (tức là mỗi khoảng cách nhau 100 giá trị)
  - Nhấp OK. Bảng tổng hợp sẽ gom các mức giá vào những phân khúc bạn vừa định nghĩa.

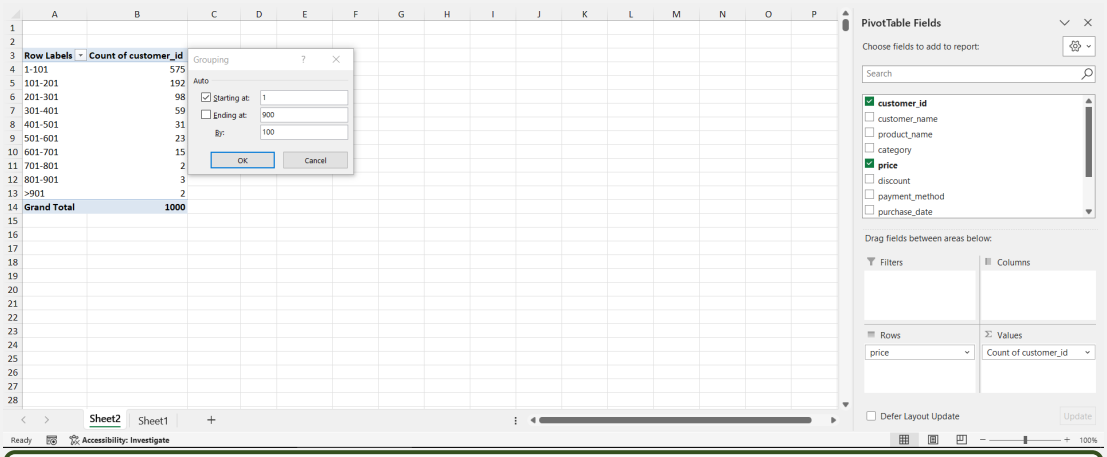

Hình 22: Hộp thoại *Grouping* cho phép bạn tạo các khoảng cho dữ liệu số hoặc ngày tháng, biến dữ liệu liên tục thành các danh mục rời rạc để phân tích.

Phân tích tăng trưởng theo thời gian (So với kỳ trước)

Câu hỏi là *Làm thế nào để tính toán và hiển thị mức tăng/giảm doanh thu mỗi tháng so với tháng liền trước đó?*

- **Rows**: 'purchase_date'. Excel thường sẽ tự động nhóm thành Days, Months. Bạn có thể giữ lại Months.
- **Values**: 'price' vào vùng này **hai lần**. Bạn sẽ có hai cột Sum of price và Sum of price2.

- **Thiết lập so sánh chênh lệch**:
  - Nhấp chuột phải vào cột thứ hai (Sum of price2).
  - Chọn **Show Values As** » **Difference From...**.
  - Trong hộp thoại mở ra, cấu hình như sau:
    - **Base Field**: Months (hoặc tên trường tháng của bạn).
    - **Base Item**: (previous).
  - Cột thứ hai giờ đây sẽ hiển thị chênh lệch doanh thu so với tháng trước.

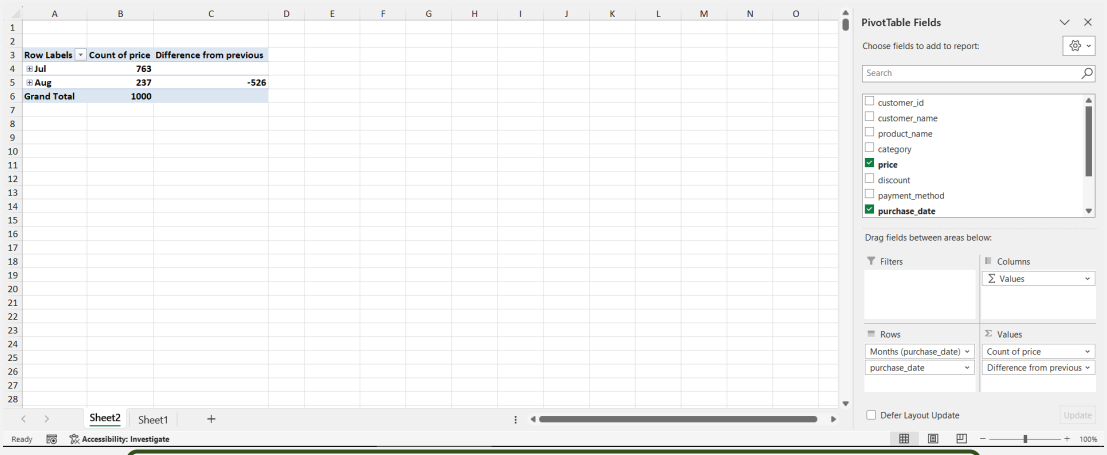

Hình 23: Báo cáo tăng trưởng theo tháng, hiển thị cả doanh thu thực tế và mức chênh lệch so với tháng trước.

II.3.4. Các lưu ý khi dùng Privot Table.

Để sử dụng Pivot Table hiệu quả, ta cần phải lưu ý những điều sau:

- **Làm mới Dữ liệu:** Pivot Table không tự động cập nhật khi dữ liệu gốc thay đổi. Nếu bạn thêm dòng dữ liệu mới, hãy nhấp chuột phải vào bảng tổng hợp và chọn Refresh. Điều này xảy ra vì mỗi lần Pivot Table được tạo ra, Excel sẽ tạo ra một bảng 'Details' riêng cho Table đó, khác với chức năng View của Excel.
- **Slicers:** Thay vì dùng ô 'Filters', hãy vào tab PivotTable Analyze » Insert Slicer. Slicer là các bộ lọc trực quan, thân thiện, cho phép bạn và người khác tương tác với báo cáo một cách dễ dàng và dễ tùy chỉnh.
- **Calculated Fields:** Bạn có thể tạo các cột mới ngay trong Pivot Table. Ví dụ, để tính doanh thu thực sau khi đã trừ đi chiết khấu, bạn có thể tạo một trường tính toán với công thức $= (\texttt{price} * (1 - \texttt{discount}))$. Lưu ý: Các hàm của Calculated Fields không tính trên tổng thể dữ liệu ban đầu mà tính trên bảng con, thế nên sẽ bị ảnh hưởng bởi 'Filters' và 'Slicers'.

III. Tài liệu tham khảo

AI VIET NAM COURSE 2026

EDA với Excel

I. Giới thiệu

Trong bất kỳ dự án khoa học dữ liệu hoặc AI nào, bước đầu tiên thường không phải là huấn luyện một mô hình phức tạp mà là tìm hiểu và khám phá dữ liệu. Hãy tưởng tượng chúng ta nhận được một tệp báo cáo bán hàng hàng quý với một bảng tính chứa hàng ngàn dòng. Trước khi dự báo doanh thu hay phân khúc khách hàng, ta phải trả lời các câu hỏi cơ bản: Dữ liệu có đầy đủ không? Có giá trị nào bất thường (ví dụ: như một đơn hàng trị giá 0 đồng)? Sản phẩm nào bán chạy nhất? Đây chính là bản chất của **Phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA)**.

EDA là một phương pháp phân tích, nơi chúng ta sử dụng các kỹ thuật thống kê và trực quan hóa để tóm tắt những đặc tính chính của bộ dữ liệu. Mục tiêu không phải là đưa ra kết luận cuối cùng, mà là để hiểu sâu sắc hơn về cấu trúc, phát hiện các điểm bất thường, kiểm tra các giả định ban đầu và giả định tiềm ẩn từ dữ liệu. Trong bối cảnh này, bài viết về **Microsoft Excel** sẽ hướng dẫn mọi người thay vì viết những dòng code phức tạp, chúng ta có thể tương tác trực tiếp với dữ liệu qua bộ công cụ Excel để nhanh chóng có được cái nhìn tổng quan đầu tiên về dữ liệu.

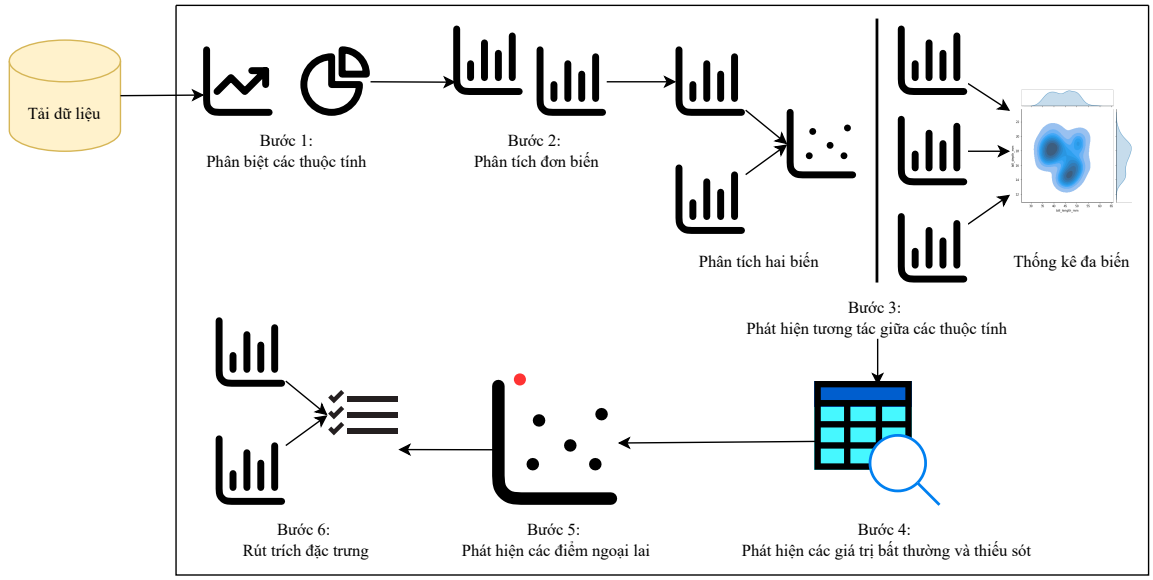

Hình 1: Minh họa quá trình biến dữ liệu thô thành insight:
Sơ đồ các bước phân tích, làm sạch và chuẩn bị dữ liệu.

Bài học này được thiết kế theo định hướng thực hành làm quen với các chức năng chính từ Excel. Chúng ta sẽ không đi sâu vào lý thuyết thống kê phức tạp mà tập trung vào việc hướng dẫn các bạn sử dụng các chức năng của Excel để thực hiện quy trình EDA một cách hiệu quả. Chúng ta sẽ đi qua các kỹ năng cốt lõi sau:

- **Làm quen và làm sạch dữ liệu:** Sử dụng các công cụ *Sort*, *Filter*, và *Conditional Formatting* để nhanh chóng xác định các giá trị bị thiếu, trùng lặp hoặc sai định dạng. Đây là bước nền tảng quyết định chất lượng của toàn bộ quá trình phân tích.
- **Phân tích thống kê mô tả (Descriptive Statistics):** Áp dụng các hàm cơ bản như 'AVERAGE', 'MEDIAN', 'STDEV.P' để tính toán các chỉ số thống kê quan trọng, giúp tóm tắt dữ liệu chỉ bằng vài cú nhấp chuột.
- **Trực quan hóa (Visualization):** Khám phá các loại biểu đồ phù hợp (cột, đường, tròn, histogram) để trực quan hóa phân phối dữ liệu và mối quan hệ giữa các biến. Một biểu đồ tốt có giá trị hơn hàng ngàn dòng dữ liệu.
- **Tổng hợp và đặt giả thuyết với PivotTable (Summarization and Hypothesis):** Sử dụng **PivotTable** để cắt lớp, tổng hợp dữ liệu theo nhiều chiều và nhanh chóng kiểm tra các giả thuyết ban đầu.

Các công cụ được liệt kê ở trên sẽ giúp chúng ta tìm ra những insight giá trị để có thể thực hiện các bước tiếp theo của một dự án AI/DS

Bảng 1: Một số hàm và công cụ Excel thiết yếu cho quá trình EDA được nhắc tới trong bài này.

Hàm / Công cụ Excel	**Ứng dụng trong EDA**
`COUNTIF(S)`, `SUMIF(S)`	Đếm và tính tổng có điều kiện để phân loại và tóm tắt dữ liệu. Ví dụ: đếm số lượng sản phẩm thuộc danh mục A.
`VLOOKUP`, `XLOOKUP`	Kết hợp dữ liệu từ các bảng khác nhau để làm giàu thông tin. Rất quan trọng khi dữ liệu bị phân mảnh.
Remove Duplicates	Nhanh chóng loại bỏ các dòng dữ liệu bị lặp lại hoàn toàn, đảm bảo tính duy nhất của các bản ghi.
Conditional Formatting	Tô màu các ô dựa trên quy tắc (ví dụ: tô đỏ các giá trị âm) để phát hiện ngay các điểm bất thường hoặc outliers.
Data Analysis ToolPak	Chạy các phân tích thống kê phức tạp hơn như hồi quy, phân tích phương sai (ANOVA), hoặc tạo histogram một cách tự động.

II. Nội dung chính

Trong phần này, chúng ta sẽ áp dụng trực tiếp các khái niệm đã thảo luận vào một bộ dữ liệu quản lý kho **(Inventory)** mẫu ở đây: Link. Bộ dữ liệu này chứa nhiều thông tin chưa được xử lý. Nhiệm vụ của chúng ta là khám phá dữ liệu bằng Excel một cách nhanh chóng nhất mà không sử dụng code.

Bảng 2: Trích đoạn bộ dữ liệu quản lý kho.

Product ID	Product Name	Opening Stock	Stock In	Units Sold	Hand-In-Stock	Cost per Unit	Cost Total
P101	Laptop	50	20	10	60	$1,200	$72,000
P102	Monitor	40	15	5	50	$500	$25,000
P103	Keyboard	60	25	15	70	$50	$3,500
...	...	...	...	...	...	...	...

Chúng ta sẽ thực hiện quy trình EDA qua bốn bước chính: làm sạch để đảm bảo dữ liệu đáng tin cậy, và sau đó sử dụng thống kê mô tả để rút ra những nhận xét tổng quan đầu tiên. Tiếp theo, chúng ta sẽ sử dụng các biểu đồ để trực quan hóa dữ liệu và kết thúc bằng việt dùng PivotTable để tạo ra các báo cáo nhanh chóng.

II.1. Bước 1: Làm sạch và chuẩn hóa dữ liệu

Một nguyên tắc cơ bản trong phân tích dữ liệu là chất lượng của kết quả đầu ra phụ thuộc trực tiếp vào chất lượng dữ liệu đầu vào. Nguyên tắc này thường được gọi là **Garbage In, Garbage Out (GIGO)** . Nếu phân tích trên dữ liệu sai, mọi kết luận của chúng ta có đều vô giá trị. Do đó, ta phải luôn bắt đầu bằng việc kiểm tra và làm sạch. Với một bộ dữ liệu lớn, các lỗi thường gặp bao gồm:

- **Dữ liệu trùng lặp (Duplicate Data):** Một sản phẩm được nhập hai lần.
- **Dữ liệu bị thiếu (Missing Values):** Một vài ô 'Cost Price' bị bỏ trống.
- **Lỗi logic nghiệp vụ (Business Logic Errors):** Số liệu tồn kho cuối kỳ không khớp với công thức: Tồn đầu kỳ + Nhập kho - Số lượng bán.

Hãy tiến hành xử lý từng vấn đề nêu trên một cách có hệ thống theo hướng dẫn như sau.

1. Phát hiện và loại bỏ dòng trùng lặp

Cách nhanh nhất để kiểm tra là sử dụng công cụ "Remove Duplicates" có sẵn của Excel. Có một lưu ý rằng công cụ này sẽ tính các kí tự trống và rỗng ở báo cáo cuối cùng sau khi chạy hàm. Cách chạy chức năng này như sau:

1. Chọn toàn bộ vùng dữ liệu của bạn (nhấn Ctrl+A).
2. Vào tab **Data** trên thanh công cụ.
3. Nhấn vào biểu tượng **Remove Duplicates**.
4. Trong hộp thoại hiện ra, hãy chọn cột định danh duy nhất, thường là **Product ID**, để tìm các sản phẩm bị nhập thừa. Sau đó nhấn OK. Các giá trị được ta chọn sẽ là các giá trị Excel kiểm tra sự trùng lặp. Nếu có trùng, toàn bộ hàng đó sẽ bị xóa bỏ. Ta có thể nói rằng các giá trị được chọn là các **khóa** của bộ dữ liệu.

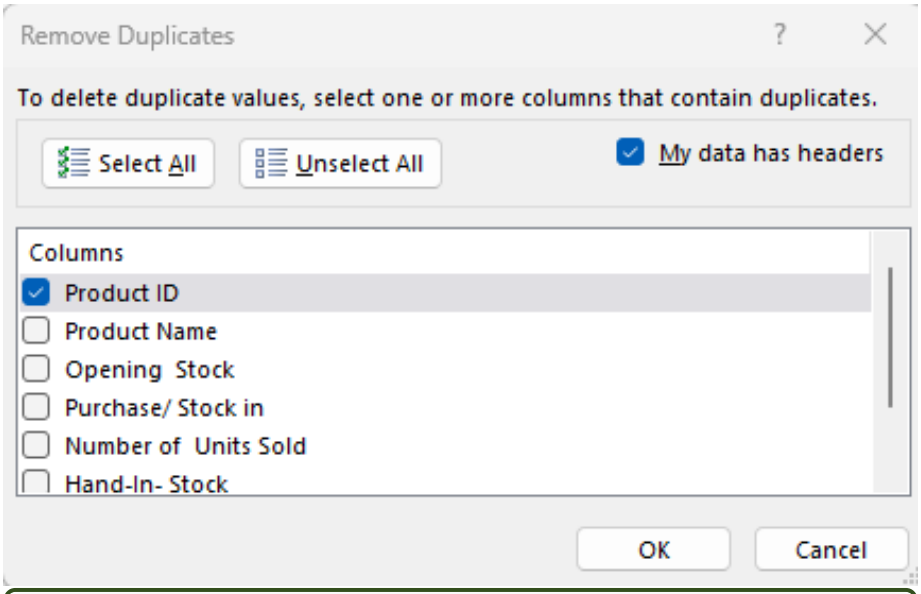

Hình 2: Giao diện công cụ Remove Duplicates của Excel.

2. Kiểm tra logic tồn kho

Một trong những bước chúng ta thường hay bỏ lỡ khi xử lý dữ liệu là bước **áp dụng kiến thức chuyên ngành** của ta vào dữ liệu. Đây là bước cực kỳ quan trọng để đảm bảo tính toàn vẹn của dữ liệu bởi vì ta không thể biết khi nào hệ thống xảy ra lỗi, hoặc do người dùng sử dụng sai chức năng thu thập dữ liệu. Ở bài toán này, ta biết rằng số lượng tồn kho cuối kỳ **(Hand-In-Stock)** phải tuân theo công thức, tiếp theo chúng ta hãy tạo một cột tạm để kiểm tra điều này.

Tại một cột trống bên cạnh bảng dữ liệu (ví dụ, cột I), đặt tên là 'Logic Check'. Tại ô `I2`, hãy nhập công thức sau và kéo xuống cho toàn bộ cột:

Công thức Excel kiểm tra logic

```
=C2+D2-E2-F2
```

Công thức này lấy *Tồn đầu kỳ + Nhập kho - Số lượng bán - Tồn cuối kỳ*. Về lý thuyết, tất cả các ô trong cột 'Logic Check' phải bằng 0. Nếu một ô nào đó khác 0, dòng tương ứng đang có lỗi

logic và cần được kiểm tra lại. Sử dụng **Filter** hoặc **Conditional Formatting** để nhanh chóng tìm ra các dòng có giá trị khác 0.

Đối với cách tiếp cận Conditional Formatting, các bước thực hiện như sau. Ta chọn dải ô `A2:I40`, sau đó chọn các chức năng Conditional Formatting » New Rule » Use a formula... tiếp theo đó nhập công thức dưới đây và chọn màu đỏ để format. Kết quả thu được như hình bên dưới.

Công thức Excel lọc giá dòng sai logic

=($I2<>0)

Công thức này lấy giá trị của cột I lần lượt bắt đầu từ index 2 tới cuối. Ở đây vì ban đầu ta chọn giải ô `A2:I40` thế nên I cuối cùng sẽ là I40. Hàm "Conditional Formatting" sẽ tự động tô đậm cả hàng ta chọn `A:I` nếu biểu thức trên là đúng (True).

Product ID	Product Name	Opening Stock	Purchase/ Stock in	Number of Units Sold	Hand-In-Stock	Cost Price Per Unit (USD)	Cost Price Total (USD)	Logic Check
P137	Printer Cable	25	10	4	29	5	145	2
P119	Gaming Headset	20	8	3	25	120	3000	0
P120	Gaming Chair	15	6	2	19	200	3800	0
P121	Gaming Monitor	25	10	4	29	400	11600	2
P117	Gaming Keyboard	25	10	4	31	100	3100	0
P141	Anti-Glare Screen Protector	25	8	3	28	10	280	2
P104	Headphones	30	10	3	37	100	3700	0
P128	Power Supply	35	15	6	44	100	4400	0
P132	Mouse Pad	50	20	8	58	10	580	4
P139	Laptop Cooling Pad	30	15	6	39	20	780	0
P103	Keyboard	60	25	15	70	50	3500	0
P126	SSD	45	20	8	57	120	6840	0
P142	USB-C Adapter	20	10	4	24	15	360	2
P144	Wireless Charger	40	18	7	51	30	1530	0
P114	Ethernet Cable	60	30	15	75	10	750	0
P138	Keyboard Cleaner	40	18	9	49	8	392	0
P146	Gaming Desk	25	10	3	28	150	4200	4
P125	RAM	50	22	11	61	80	4880	0
P109	Wireless Earbuds	35	15	7	43	80	3440	0
P122	Graphics Card	40	18	9	49	600	29400	0
P118	Gaming Mouse	30	12	6	36	80	2880	0
P130	CPU Cooler	30	12	4	34	50	1700	4

Hình 3: Các cột bị lỗi trong dữ liệu. Thông thường, ta sẽ loại bỏ hàng bị lỗi, nhưng vì ở đây ta có bộ dữ liệu nhỏ nên chúng ta sẽ giữ nguyên bộ dữ liệu ban đầu.

II.2. Bước 2: Phân tích thống kê mô tả (Descriptive Statistics)

Sau khi dữ liệu đã được làm sạch, chúng ta có thể bắt đầu tới các bước tiếp theo. Bây giờ là lúc để chúng ta thực hiện việc tóm tắt chúng. Thống kê mô tả giúp trả lời các câu hỏi như: "Trung bình mỗi sản phẩm bán được bao nhiêu đơn vị?", "Sản phẩm nào có giá vốn cao nhất?", "Mức độ biến động về giá cả giữa các sản phẩm ra sao?".

1. Tính toán các chỉ số thống kê chính

Trước khi tới các bước phức tạp hơn, chúng ta hãy tạo một bảng tóm tắt nhỏ để tính các chỉ số quan trọng cho các cột số liệu chính như 'Number of Units Sold' và 'Cost Price Per Unit (USD)' của dữ liệu. Các hàm sau đây là các hàm có thể dùng cho trường hợp này.

Bảng 3: Các hàm thống kê cơ bản trong Excel và ứng dụng để tóm tắt nhanh dữ liệu bán hàng.

Chỉ số thống kê	`Công thức Excel`	**Ý nghĩa**
Tổng số lượng bán	`=SUM(E:E)`	Tổng số sản phẩm đã bán ra trong kỳ.
Lượng bán trung bình	`=AVERAGE(E:E)`	Trung bình mỗi mã sản phẩm bán được bao nhiêu chiếc.
Sản phẩm bán chạy nhất	`=MAX(E:E)`	Tìm ra số lượng bán cao nhất của một sản phẩm.
Sản phẩm bán chậm nhất	`=MIN(E:E)`	Tìm ra số lượng bán thấp nhất của một sản phẩm.
Độ lệch chuẩn	`=STDEV.P(E:E)`	Đo lường mức độ phân tán của dữ liệu bán hàng so với giá trị trung bình.

2. Sử dụng Data Analysis ToolPak

Tuy cách vừa được trình bày ở trên có thể giúp ta có được một bảng tóm tắt hoàn chỉnh, thế nhưng để có một báo cáo thống kê đầy đủ mà không cần gõ từng hàm, chúng ta hãy sử dụng **Data Analysis ToolPak**.

Bật và sử dụng Analysis ToolPak

1. Vào tab **Data**, chọn **Data Analysis**. (Nếu không thấy, bạn cần kích hoạt nó trong File » Options » Add-ins).
2. Chọn **Descriptive Statistics** và nhấn OK.
3. Trong ô **Input Range**, chọn các cột dữ liệu số bạn muốn phân tích (ví dụ: các cột từ 'Opening Stock' đến 'Cost Price Total').
4. Đánh dấu vào ô **Labels in first row** nếu bạn có chọn cả tiêu đề cột.
5. Chọn **Output Range** để chỉ định vị trí xuất báo cáo.
6. Quan trọng nhất, hãy tick vào ô **Summary statistics**. Nhấn OK.

Excel sẽ ngay lập tức tạo ra một bảng tóm tắt chi tiết cho từng cột, bao gồm *Mean*, *Median*,

Mode, *Standard Deviation*, *Sample Variance*, *Kurtosis*, *Skewness*, và nhiều chỉ số khác. Đây là cách cực kỳ hiệu quả để có cái nhìn tổng quan về phân phối dữ liệu chỉ trong vài giây.

Ngoài ra, công cụ Data Analysis ToolPak còn có các bài test khác như: Anova, Correlation, Covariance,... Ưu điểm của công cụ này chính là giao diện được trình bày hoàn chỉnh, giúp ta không cần phải chọn cột, loại giá trị, cách gom nhóm,... thủ công. Chức năng này đồng thời cũng bỏ qua các giá trị thiếu hoặc sai nếu có, tương tự như các hàm bên trong Pandas.

Cách đọc nhanh bảng *Descriptive Statistics*

- **Count**: số quan sát hợp lệ. Nếu nhỏ hơn tổng số dòng ⇒ có thiếu dữ liệu.
- **Mean** vs **Median**: chênh lệch lớn ⇒ phân phối lệch hoặc có outlier (đặc biệt ở `Units Sold`).
- **Std. Deviation** (σ) và **Variance** (σ^2): đo mức phân tán; càng lớn ⇒ dữ liệu biến động nhiều.
- **Skewness**: > 0 lệch phải (nhiều giá trị nhỏ, vài giá trị rất lớn); < 0 lệch trái.
- **Kurtosis**: > 0 đuôi dày (nhiều outlier); < 0 đuôi mỏng.
- **Range/Min/Max**: kiểm tra giá trị bất hợp lý (`Opening Stock`, `Units Sold` không nên âm).
- **Standard Error** và **Confidence Level for Mean (95%)**: độ chính xác của ước lượng trung bình. Bạn có thể thấy hai tham số này nếu chọn option Confident Level for Mean lúc tạo bảng.

	Number of Units Sold
Mean	6.692307692
Standard Error	0.655253704
Median	5
Mode	4
Standard Deviation	4.092058073
Sample Variance	16.74493927
Kurtosis	1.784880673
Skewness	1.328795854
Range	18
Minimum	2
Maximum	20
Sum	261
Count	39

Hình 4: Kết quả từ Data Analysis ToolPak.

II.3. Bước 3: Trực quan hóa dữ liệu (Data Visualization)

Sau khi đã có những con số thống kê tóm tắt, bước tiếp theo là "vẽ" nên bức tranh tổng thể của dữ liệu. Con người xử lý thông tin hình ảnh nhanh hơn văn bản hay con số rất nhiều. Một biểu đồ được thiết kế tốt có thể ngay lập tức tiết lộ một xu hướng, một điểm bất thường hoặc một mối quan hệ mà hàng trăm dòng dữ liệu không thể hiện được. Đây chính là sức mạnh của việc **trực quan hóa dữ liệu**.

Excel cung cấp một bộ công cụ trực quan hóa đa dạng, từ những biểu đồ cơ bản đến phức tạp. Tuy nhiên, thách thức không nằm ở việc tạo ra một biểu đồ, mà là ở việc **chọn đúng loại biểu đồ** cho đúng mục đích và **thiết kế nó** một cách rõ ràng, hiệu quả.

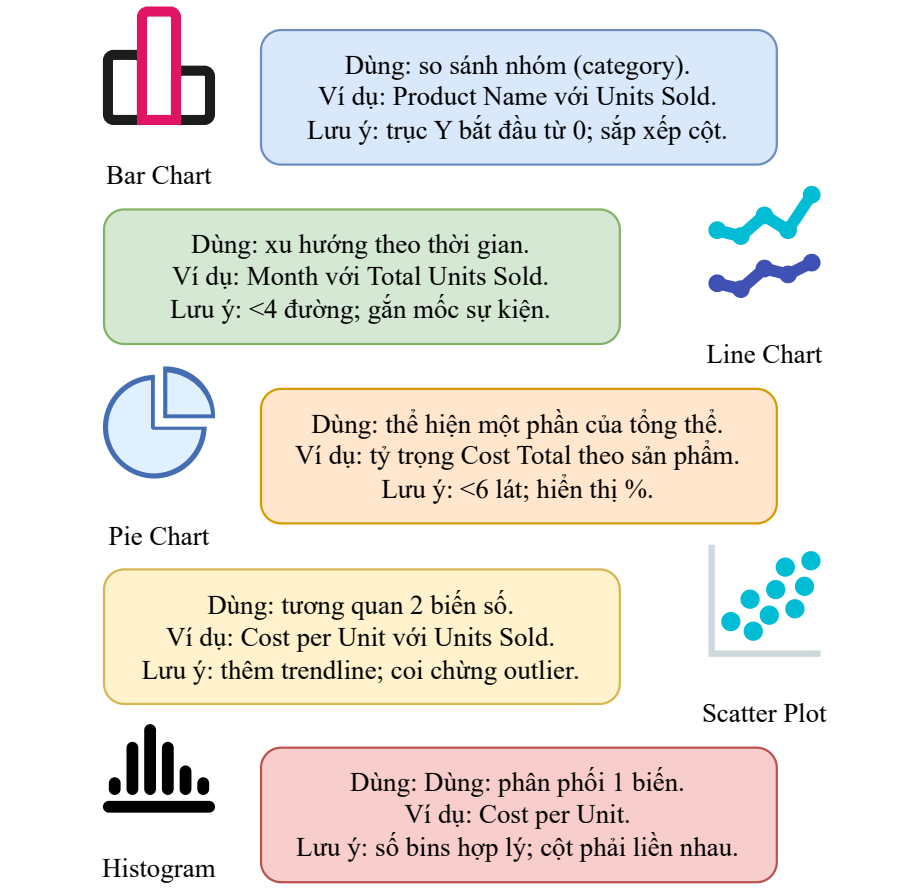

Hình 5: Các loại biểu đồ phổ biến trong phân tích dữ liệu. Hãy xem chúng như bộ "bảng chữ cái" dạng hình ảnh: mỗi loại biểu đồ là một "chữ cái" dùng để kể một loại câu chuyện dữ liệu khác nhau.

Dưới đây, chúng ta sẽ đi sâu vào các loại biểu đồ thông dụng nhất và cách áp dụng chúng vào bộ dữ liệu Inventory của chúng ta.

1. Biểu đồ cột (Bar Chart)

Trường hợp sử dụng: Đây là lựa chọn khi bạn muốn **so sánh giá trị giữa các nhóm (categories)** khác nhau. Dữ liệu của bạn thường bao gồm một biến định tính (tên sản phẩm, danh mục) và một biến định lượng (số lượng bán, doanh thu). Ví dụ, hãy dùng biểu đồ cột để so sánh số lượng bán ('Number of Units Sold') của 5 sản phẩm hàng đầu. Các lưu ý khi sử dụng bar chart như sau:

- **Luôn bắt đầu trục Y từ 0:** Việc này đảm bảo sự trung thực trong việc người đọc so sánh tỷ lệ. Bắt đầu từ một giá trị khác sẽ phóng đại sự khác biệt giữa các đối tượng với nhau, làm cho chúng lớn hơn hoặc bé hơn so với thực tế.
- **Sắp xếp các cột:** Hãy sắp xếp các cột theo thứ tự tăng dần hoặc giảm dần để người đọc dễ dàng xác định đâu là nhóm lớn nhất/nhỏ nhất.
- **Sử dụng màu sắc phù hợp:** Dùng màu sắc có chủ đích (ví dụ: màu xanh đối với các cột có chung tính chất, hoặc cặp màu tương phản giữa cột tốt nhất và xấu nhất), hoặc dùng

một màu khác biệt để nhấn mạnh cột dữ liệu quan trọng nhất. Chúng ta nên tránh dùng quá nhiều màu gây rối mắt và giữ cho màu sắc được nhất quán.
- **Giữ cho biểu đồ đơn giản:** Loại bỏ các đường lưới (gridlines) không cần thiết, tiêu đề và nhãn trục phải rõ ràng, súc tích.

2. Biểu đồ đường (Line Chart)

Trường hợp sử dụng: Khi bạn muốn **hiển thị xu hướng của dữ liệu theo thời gian** hoặc một chuỗi liên tục. Biểu đồ đường rất giỏi trong việc thể hiện sự tăng, giảm hoặc biến động. Mặc dù bộ dữ liệu Inventory hiện tại không có yếu tố thời gian, nhưng nếu có thêm cột 'Tháng', ta có thể dùng biểu đồ đường để theo dõi tổng số lượng bán ('Total Units Sold') qua từng tháng.

- **Đừng vẽ quá nhiều đường:** Một biểu đồ với hơn 3-4 đường có thể trở nên rất khó đọc. Hãy cân nhắc tách thành nhiều biểu đồ nhỏ hơn nếu cần. Nếu có quá nhiều đường cần phải vẽ trong một line chart, hình vẽ đó của chúng ta sẽ trở thành spaghetti plot và cần phải có cách xử lý khác.
- **Nhãn trục rõ ràng:** Bảo đảm trục X (thời gian) và trục Y (giá trị) được đặt tên và chia khoảng hợp lý.
- **Đánh dấu các điểm dữ liệu quan trọng:** Sử dụng các điểm đánh dấu (markers) cho các mốc sự kiện quan trọng (ví dụ: ngày ra mắt chiến dịch marketing) để xem ảnh hưởng của nó lên xu hướng. Hoặc chúng ta có thể tô đậm một khoảng thời gian nhất định để làm rõ outliner của một sự kiện kéo dài (ví dụ: covid 19 làm ảnh hưởng tới số lượng hàng hóa).

3. Biểu đồ tròn (Pie Chart)

Trường hợp sử dụng: Chỉ sử dụng biểu đồ tròn khi bạn muốn thể hiện **tỷ lệ phần trăm của các bộ phận trong một tổng thể (parts-of-a-whole)**. Tổng các phần phải bằng 100%. Ví dụ, dùng biểu đồ tròn để thể hiện tỷ trọng chi phí ('Cost Price Total') của từng sản phẩm trong tổng chi phí của cả kho hàng.

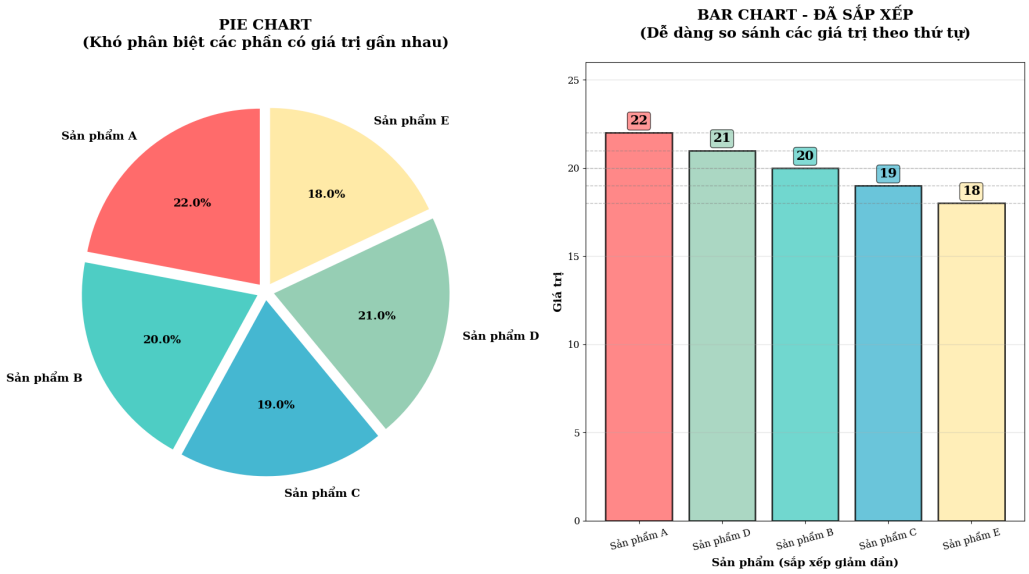

Hình 6: Với các giá trị gần nhau, ta thấy rằng ở pie chart mắt người không thể phân biệt được sản phẩm nào tốt hơn, lúc này ta nên thay thế bằng bar chart.

- **Hạn chế số lượng "miếng bánh":** Biểu đồ tròn trở nên vô dụng khi có quá nhiều lát cắt (tốt nhất là dưới 6). Nếu có nhiều nhóm nhỏ, hãy gộp chúng vào một nhóm "Khác" (Others).
- **Luôn hiển thị phần trăm:** Con người chúng ta không giỏi so sánh các góc. Hãy luôn hiển thị nhãn phần trăm trực tiếp trên từng lát cắt.
- **Cân nhắc dùng biểu đồ cột thay thế:** Trong nhiều trường hợp, biểu đồ cột thể hiện sự so sánh giữa các phần trăm tốt hơn và rõ ràng hơn biểu đồ tròn. Ngoài ra treemap và lollipop chart cũng là một cách thay thế hoàn hảo cho pie chart của chúng ta.

4. Biểu đồ phân tán (Scatter Plot)

Trường hợp sử dụng: Khi bạn muốn khám phá **mối quan hệ hoặc sự tương quan giữa hai biến định lượng**. Mỗi điểm trên biểu đồ đại diện cho một cặp giá trị (x, y). Ví dụ, hãy vẽ biểu đồ phân tán với trục X là 'Cost Price Per Unit' và trục Y là 'Number of Units Sold' để xem liệu có mối liên hệ nào giữa giá cả và số lượng bán hay không (ví dụ: giá càng cao, bán càng ít?).

- **Thêm đường xu hướng (Trendline):** Excel cho phép bạn dễ dàng thêm một đường xu hướng để làm rõ mối quan hệ (tương quan dương, âm, hay không có tương quan).
- **Cẩn thận với outliers:** Các điểm dữ liệu ngoại lai có thể ảnh hưởng lớn đến đường xu hướng và nhận định của người đọc sau khi xem qua chart này. Hãy xác định và tìm hiểu nguyên nhân của chúng. Đồng thời, chúng ta cùng cần tránh vẽ quá nhiều điểm dữ liệu ở cùng một chart vì chúng sẽ chồng chéo với nhau gây ra sự khó đọc. Với các bộ dữ liệu lớn, ta nên sử dụng cách lấy mẫu ngẫu nhiên, hoặc trong Excel ta có thể kết hợp hàm `=RAND()<=0.2` với Filter để có thể lấy mẫu ngẫu nhiên.
- **Sử dụng kích thước hoặc màu sắc để thêm chiều thứ ba:** Nếu dữ liệu chúng ta có thêm chiều thứ ba (ví dụ: 'Hand-In-Stock'), ta có thể thêm vào scatter plot bằng cách sử dụng màu sắc để biểu đồ chứa nhiều thông tin hơn.

5. Biểu đồ phân phối (Histogram)

Trường hợp sử dụng: Khi bạn muốn hiểu **sự phân phối của một biến định lượng duy nhất**. Nó nhóm các giá trị vào các khoảng (bins) và đếm tần suất xuất hiện. Ví dụ, tạo một histogram cho cột 'Cost Price Per Unit' để xem các sản phẩm tập trung ở khoảng giá nào nhiều nhất.

- **Chọn đúng số lượng bins:** Quá ít bins sẽ che giấu các mẫu hình, quá nhiều bins sẽ tạo ra nhiều nhiễu. Excel có thể tự động chọn, nhưng bạn nên thử nghiệm vài con số khác nhau để có cái nhìn tốt nhất.
- **Đây không phải là biểu đồ cột:** Các cột trong histogram phải chạm vào nhau, vì chúng đại diện cho các khoảng liên tục của một biến duy nhất.

Bảng tham khảo nhanh: Khi nào dùng biểu đồ nào?

Để tổng kết lại, bảng dưới đây sẽ là kim chỉ nam giúp bạn nhanh chóng chọn được loại biểu đồ phù hợp nhất với nhu cầu phân tích của mình.

Bảng 4: Bảng tóm tắt lựa chọn biểu đồ. Hãy dựa vào loại dữ liệu và câu hỏi bạn muốn trả lời để chọn công cụ trực quan hóa hiệu quả nhất.

Loại biểu đồ	Kiểu dữ liệu phù hợp	Mục đích sử dụng chính
Biểu đồ cột (Bar Chart)	1 biến Định tính & 1 biến Định lượng	So sánh giá trị giữa các nhóm riêng biệt.
Biểu đồ đường (Line Chart)	Dữ liệu chuỗi thời gian (Time-series)	Theo dõi sự thay đổi, xu hướng theo thời gian.
Biểu đồ tròn (Pie Chart)	Dữ liệu tỷ lệ, các phần của tổng thể	Hiển thị cấu trúc phần trăm của một tổng thể duy nhất.
Biểu đồ phân tán (Scatter Plot)	2 biến Định lượng	Tìm và thể hiện mối quan hệ/tương quan giữa hai biến.
Biểu đồ phân phối (Histogram)	1 biến Định lượng (nhiều điểm dữ liệu)	Hiểu hình dạng phân phối của dữ liệu (tập trung, lệch, trải rộng).
Biểu đồ hộp (Box Plot)	1 biến Định tính & 1 biến Định lượng	So sánh sự phân phối dữ liệu và tìm outliers giữa các nhóm.

Để các bạn có thể lựa chọn biểu đồ tốt nhất cho dữ liệu đính lượng, sau đây là một cây quyết định các biểu đồ thường dùng nhất cho các biến loại này.

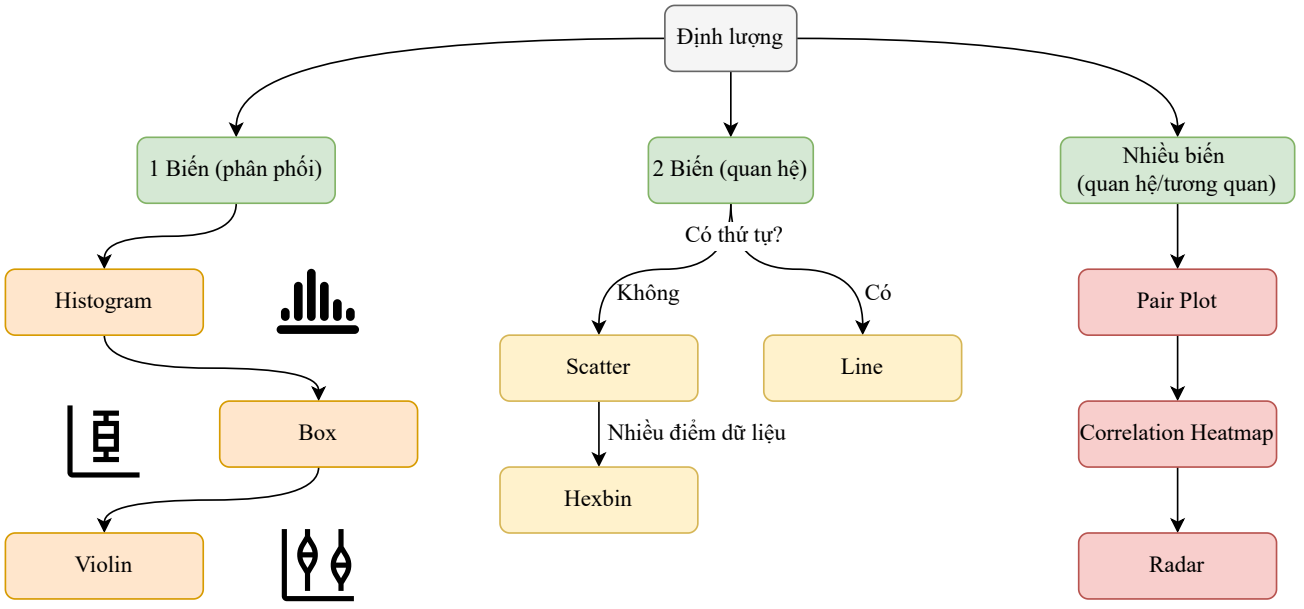

Hình 7: Cây quyết định dùng để lựa chọn chart với **biến định lượng**.

II.4. Bước 4: Tổng hợp dữ liệu với PivotTable

Ở các bước trên, chúng ta đã làm sạch dữ liệu, tính toán các chỉ số thống kê cơ bản và vẽ một vài biểu đồ. Tuy nhiên, các phân tích này còn khá tĩnh và chưa thể thích ứng với sự thay đổi của dữ liệu. Giả sử trong tương lai ta có các câu hỏi mới: "Tổng giá trị tồn kho của nhóm sản phẩm 'Laptop' là bao nhiêu?" hoặc "Sản phẩm nào trong nhóm 'Phụ kiện' đang bán chậm nhất?". Để trả lời những câu hỏi đa chiều và thay đổi góc nhìn phân tích một cách linh hoạt, chúng ta cần đến công cụ mạnh mẽ nhất của Excel cho EDA: **PivotTable**.

Một PivotTable (bảng tổng hợp) là một dạng báo cáo tương tác cho phép bạn tổng hợp và phân tích một lượng lớn dữ liệu mà không cần viết một công thức nào. Bạn có thể "xoay" (pivot) dữ liệu bằng cách kéo và thả các trường để nhanh chóng khám phá các mối quan hệ có được từ dữ liệu.

1. Tạo một PivotTable

Quy trình tạo một PivotTable đơn giản được thực hiện như sau:

Tạo PivotTable với toàn bộ dữ liệu

1. **Chọn nguồn dữ liệu:** Nhấn vào một ô bất kỳ trong bảng dữ liệu của bạn sau đó bấm tổ hợp phím Ctrl+A để chọn toàn bộ dữ liệu đang có. Bảo đảm rằng dữ liệu được chọn có tiêu đề cho mỗi cột và không có dòng hay cột trống hoàn toàn.
2. **Chèn PivotTable:** Vào tab **Insert** trên thanh công cụ và chọn **PivotTable**.
3. **Xác nhận:** Một hộp thoại sẽ hiện ra. Excel thường tự động nhận diện đúng vùng dữ liệu. Hãy chọn **New Worksheet** để tạo báo cáo trên một trang tính mới cho gọn gàng, sau đó nhấn **OK**.

Sau khi hoàn thành các bước tạo, chúng ta sẽ thấy một khung PivotTable trống bên trái và một cửa sổ **PivotTable Fields** bên phải. Đây chính là nơi chúng ta sẽ làm việc với PivotTable vừa được tạo ra.

2. Làm việc với PivotTable Fields

Cửa sổ này là nơi chúng ta dùng để chỉnh sửa PivotTable một cách nhanh chóng. Nó được chia thành hai phần chính: danh sách các trường (tên các cột từ dữ liệu) ở trên và bốn khu vực chức năng ở dưới. Việc bạn cần làm là **kéo và thả** các trường vào các khu vực này.

Cách sử dụng các trường của PivotTable

- **ROWS (Hàng):** Các trường được kéo vào đây sẽ tạo ra các tiêu đề hàng cho báo cáo của bạn. Ví dụ: kéo 'Product Name' vào đây để liệt kê mỗi sản phẩm trên một hàng. Thông thường các cột ở trường ROWS sẽ được dùng làm bộ lọc của dữ liệu, và **có thể chứa nhiều hơn một biến** ở đây.
- **COLUMNS (Cột):** Tương tự, các trường ở đây sẽ tạo ra các tiêu đề cột.
- **VALUES (Giá trị):** Khu vực quan trọng nhất. Đây là nơi bạn đặt các trường

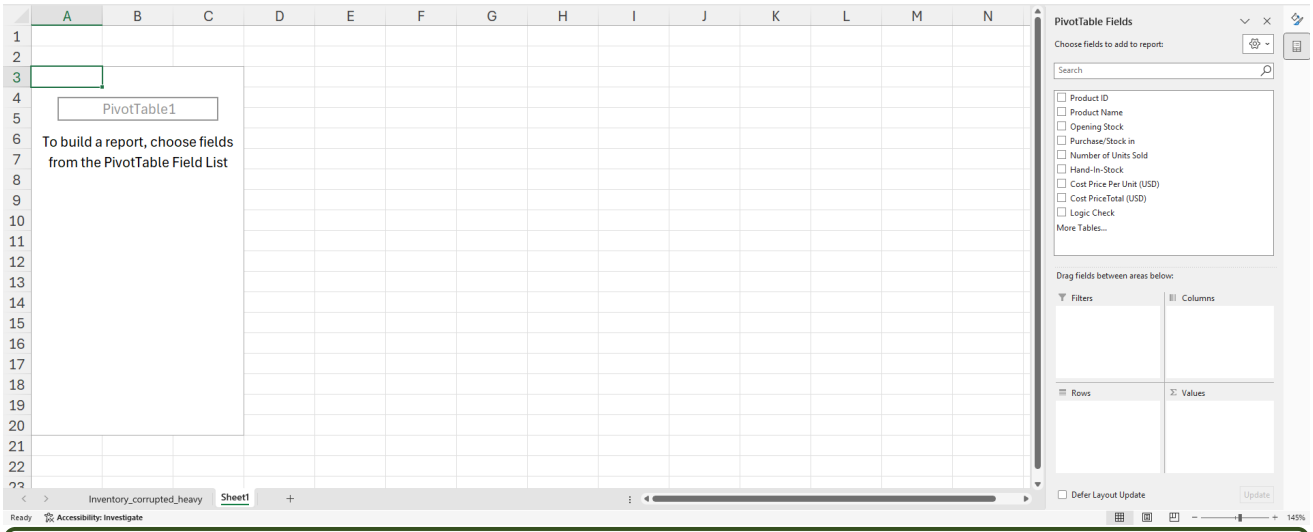

Hình 8: Bốn khu vực chức năng của PivotTable Fields. Vùng **ROWS** và **COLUMNS** định hình cấu trúc của bản ta sẽ tạo, **VALUES** thực hiện tính toán, và **FILTERS** cho phép bạn thu hẹp phạm vi phân tích của chúng ta.

số liệu mà bạn muốn tính toán (ví dụ: 'Number of Units Sold', 'Cost Price Total'). Mặc định, Excel sẽ tính **SUM** (Tổng), nhưng bạn có thể đổi thành **COUNT** (Đếm), **AVERAGE** (Trung bình), **MAX**, **MIN**,...

- **FILTERS (Bộ lọc):** Cho phép bạn lọc toàn bộ báo cáo dựa trên một hoặc nhiều trường.

3. Sử dụng PivotTable

Để có thể nắm rõ hơn cách hoạt động của PivotTable, chúng ta hãy tới các ví dụ sau:

Bài toán 1: Tổng giá trị tồn kho ('Cost Price Total') của mỗi sản phẩm là bao nhiêu?

Thiết lập PivotTable

- Kéo trường 'Product Name' vào khu vực ROWS.
- Kéo trường 'Cost Price Total (USD)' vào khu vực VALUES.

Ngay lập tức, PivotTable sẽ hiển thị một bảng tóm tắt rõ ràng, trả lời chính xác câu hỏi trên mà không cần dùng đến hàm 'SUMIF', giúp chúng ta tiết kiệm thời gian mà báo cáo sinh ra vẫn được rõ ràng.

Bài toán 2: Tỉ trọng (%) giá trị tồn kho ('Cost Price Total') của từng sản phẩm trong tổng toàn bộ là bao nhiêu?

Thiết lập PivotTable (Show Values As)

- Kéo trường 'Product Name' vào khu vực **ROWS**.
- Kéo trường 'Cost Price Total (USD)' vào khu vực **VALUES**.
  - Value Field Settings... → tab **Show Values As** → chọn **% of Column Total** (hoặc **% of Grand Total**).
- (Tùy chọn) Sort Largest to Smallest để xếp hạng sản phẩm theo mức đóng góp. Chọn More Sort Options » Descending » Sum of Cost Price.
- (Tùy chọn) Top-k để lọc ra các sản phẩm bán chạy nhất. Chọn Value Filters » Top 10 » Sum of Cost Price. Lưu ý: phần trăm giá trị mà PivotTable thể hiện sau khi lấy top-k sẽ không làm phầm trăm giá trị trên tổng thể mà được cập nhật lại trên top 10 sản phẩm. Để lấy top-k nhưng vẫn giữ được phần trăm tổng thể, ta cần phải sử dụng công cụ **Power Pivot** hoặc tạo cột phụ để làm việc này.

Sau khi thực hiện các bước trên, báo cáo trả về phần trăm đóng góp của từng sản phẩm vào tổng giá trị tồn kho, giúp chúng ta không cần thêm cột hay công thức ngoài.

4. Mẹo nâng cao: Thêm bộ lọc tương tác (Slicers)

Để làm cho báo cáo của bạn thân thiện hơn với người dùng cuối, hãy sử dụng Slicers. Slicers là các nút lọc trực quan.

1. Nhấn vào một ô bất kỳ trong PivotTable của bạn.
2. Vào tab **PivotTable Analyze**, chọn **Insert Slicer**.
3. Chọn trường bạn muốn lọc (ví dụ: 'Category'). Nhấn OK.

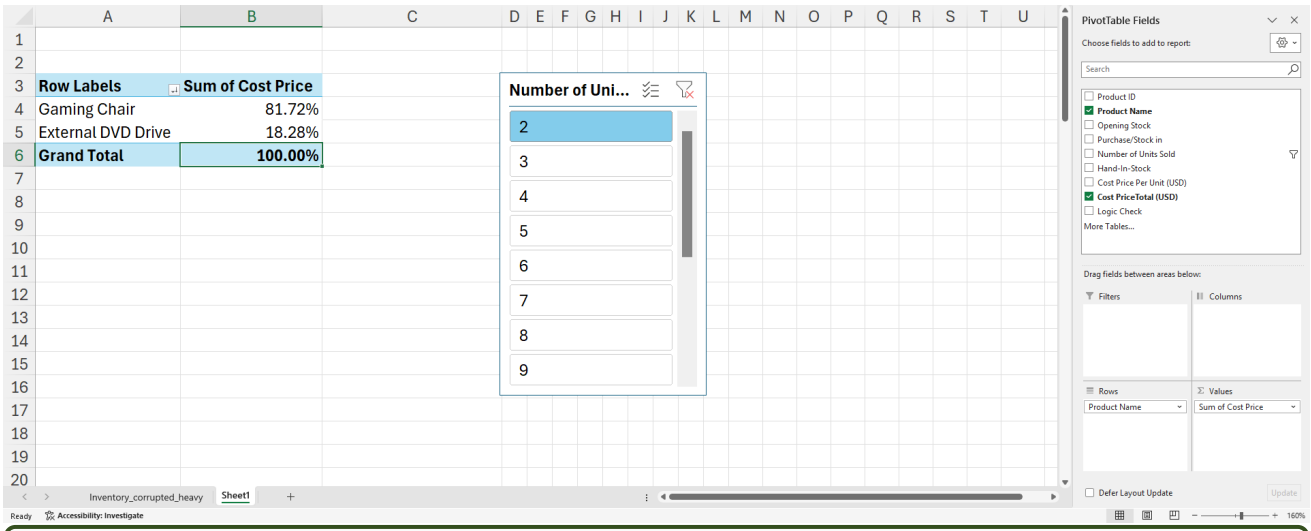

Hình 9: Sử dụng Slicer để lọc các giá trị trong PivotTable.

Qua bốn bước thực hành này, bạn đã hoàn thành một chu trình phân tích dữ liệu Khám phá cơ bản: từ việc đối mặt với một tệp dữ liệu thô, làm sạch nó, tóm tắt bằng các con số, trực quan hóa để tìm xu hướng, và cuối cùng là sử dụng PivotTable để phân tích đa chiều. Bạn đã sẵn sàng để biến những bảng tính tĩnh thành những insight động và có giá trị.

III. Câu hỏi trắc nghiệm

1. Mục đích chính của **biểu đồ cột (Bar Chart)** trong EDA là gì?

   A. Thể hiện phân phối của một biến liên tục.

   B. So sánh giá trị giữa các nhóm (categories) rời rạc.

   C. Tìm mối quan hệ giữa hai biến định lượng.

   D. Thể hiện cấu trúc phần trăm của một tổng thể.

2. Với **bar chart**, vì sao **trục Y nên bắt đầu từ 0**?

   A. Giúp đồ thị trông tối giản và đẹp mắt hơn.

   B. Tránh phóng đại/thu nhỏ chênh lệch khi người đọc so sánh các cột.

   C. Để Excel tự động thêm nhãn dữ liệu trên đỉnh cột.

   D. Bắt buộc để tính được trung bình động theo thời gian.

3. Khi các lát trong **pie chart** có giá trị rất **gần nhau**, trực quan thay thế nào giúp so sánh rõ ràng hơn?

   A. Bar chart.

   B. Treemap.

   C. Lollipop chart.

   D. Cả ba phương án trên.

4. Để tránh **"spaghetti plot"** khi một **line chart** có quá nhiều series (trên 3–4 đường), cách làm nào phù hợp nhất?

   A. Tăng độ dày nét và thêm nhiều màu sặc sỡ.

   B. Gộp tất cả thành một đường trung bình.

   C. Tách thành nhiều biểu đồ nhỏ hơn (small multiples/facet).

   D. Chuyển sang pie chart để dễ nhìn hơn.

5. Trong **scatter plot**, khi có quá nhiều điểm dẫn đến **chồng lấn**, cách nào sau đây **phù hợp** theo nội dung bài học?

   A. Lấy mẫu ngẫu nhiên dữ liệu (ví dụ dùng `=RAND()<=0.2` rồi lọc).

   B. Tự động nối các điểm lại thành đường.

   C. Chuyển trục tung về thang log để tách điểm.

   D. Luôn thêm nhãn cho mọi điểm để dễ phân biệt.

6. Muốn thêm **"chiều thứ ba"** vào **scatter plot** mà vẫn giữ mặt phẳng 2D, cách mã hoá nào hợp lý nhất?

   A. Dùng kích thước (size) hoặc màu sắc (color) của điểm.

B. Thêm trục Z và xoay đồ thị 3D.

C. Chuyển sang histogram rồi chồng nhiều lớp.

D. Dùng đường hồi quy bậc cao.

7. Phát biểu nào **đúng** về **histogram** so với **bar chart**?

A. Histogram dùng cho dữ liệu phân loại; bar chart dùng cho dữ liệu liên tục.

B. Cột trong histogram **chạm nhau** vì đại diện các **khoảng liên tục**; bar chart thường **tách rời** vì là nhóm rời rạc.

C. Histogram luôn hiển thị phần trăm; bar chart chỉ hiển thị số đếm.

D. Cả hai đều yêu cầu tổng bằng 100%.

8. Khi cần **so sánh phân phối và phát hiện outliers giữa các nhóm**, biểu đồ nào **phù hợp nhất**?

A. Pie chart.

B. Box plot.

C. Area chart.

D. Stacked bar chart.

9. Cặp **mục tiêu → loại biểu đồ** nào **khớp** nhất?

A. Theo dõi xu hướng theo thời gian → Pie chart.

B. So sánh tỷ trọng các phần của một tổng thể → Scatter plot.

C. Tìm tương quan giữa 2 biến định lượng → Scatter plot.

D. Hiểu phân phối của một biến định tính → Histogram.

10. Khi muốn xem **hình dạng phân phối** của **một biến định lượng đơn lẻ** với nhiều quan sát, nên ưu tiên biểu đồ nào?

A. Histogram.

B. Pie chart.

C. Treemap.

D. Stacked bar chart.

IV. Tài liệu tham khảo

AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM COURSE 2026

Quiz - Excel: PowerQuery

Các bạn cần tải file dữ liệu trong link này để làm các câu quiz sau.

1. Cho bảng dữ liệu sản phẩm trong sheet `Q1_VLOOKUP` với các cột: ProductID, ProductName, Category, Price, Stock. Bạn cần tìm giá (Price) của sản phẩm có tên là "Monitor". Công thức nào sau đây cho kết quả đúng là **400**?

   A. `=VLOOKUP("Monitor", A1:E6, 4, FALSE)`

   B. `=VLOOKUP("Monitor", B2:E6, 3, FALSE)`

   C. `=VLOOKUP("Monitor", A2:E6, 3, TRUE)`

   D. `=VLOOKUP("Monitor", B1:E6, 4, FALSE)`

   Đáp án B.

   Đáp án

   Cú pháp VLOOKUP: `=VLOOKUP(lookup_value, table_array, col_index_num, [range_lookup])`

   Bắt đầu từ B2 (ProductName), col_index = 3 trả về Price (cột thứ 3 từ B). TRUE = approximate match, cần FALSE cho exact match.

2. Cho bảng dữ liệu bán hàng trong sheet `Q2_SUM` với các cột: Region, Product, Salesperson, Amount. Bạn cần tính tổng doanh số (Amount) cho Region = "North" VÀ Product = "Laptop". Kết quả mong đợi là **36000**. Công thức nào sau đây đúng?

   A. `=SUMIF(A:A, "North", D:D) + SUMIF(B:B, "Laptop", D:D)`

   B. `=SUMIFS(D:D, A:A, "North", B:B, "Laptop")`

   C. `=SUMIFS(A:A, "North", B:B, "Laptop", D:D)`

   D. `=SUMIF(A:A, "North", B:B, "Laptop", D:D)`

   Đáp án B.

   Giải thích

   Cú pháp SUMIFS: `=SUMIFS(sum_range, criteria_range1, criteria1, criteria_range2, criteria2, ...)`

   SUMIFS yêu cầu sum_range đứng đầu, sau đó là các cặp (criteria_range, criteria). Kết quả = 12000 + 24000 = 36000 (2 rows thỏa mãn cả 2 điều kiện).

3. Cho bảng dữ liệu nhân viên trong sheet `Q3_COUNT` với các cột: EmployeeID, Name, Department, Salary. Bạn cần đếm số nhân viên thuộc Department = "IT" VÀ có Salary > 50000. Kết quả mong đợi là **3**. Công thức nào sau đây đúng?

   A. `=COUNTIF(C:C, "IT") + COUNTIF(D:D, ">50000")`

   B. `=COUNTIFS(D:D, "IT", C:C, ">=50000")`

   C. `=COUNTIFS(C:C, "IT", D:D, ">50000")`

   D. `=COUNT(IF(D:D="IT", IF(C:C>50000, 1)))`

   Đáp án C.

Giải thích

Cú pháp COUNTIFS: `=COUNTIFS(criteria_range1, criteria1, criteria_range2, criteria2, ...)`

Đề yêu cầu Salary > 50000 (không bao gồm 50000), nên dùng ">50000" thay vì ">=50000". Nhân viên IT thỏa mãn: John (65000), Sarah (72000), Emily (58000) = 3 người.

4. Trong sheet `Q4_PQ_Merge`, có 2 bảng: bảng Orders (OrderID, ProductID, Quantity, OrderDate) và bảng Products (ProductID, ProductName, Category, UnitPrice). Bạn cần dùng Power Query để merge hai bảng. Với OrderID = "ORD003" có ProductID = "P003", kết quả Category sau khi merge là "**Accessories**". Dựa trên hình dưới đây, đâu là thao tác được dùng?

OrderID	ProductID	Quantity	OrderDate	Category
ORD001	P001	5	15/1/25	Electronics
ORD004	P001	2	18/1/25	Electronics
ORD002	P002	3	16/1/25	Electronics
ORD003	P003	10	17/1/25	Accessories
ORD005	P004	8	19/1/25	Accessories

A. Home → Append Queries, chọn Products table

B. Home → Merge Queries, match OrderID với ProductID

C. Home → Merge Queries, match ProductID với ProductID, Join Kind = Left Outer

D. Transform → Group By, chọn ProductID

Đáp án C.

Giải thích

Power Query Merge dùng để kết hợp 2 bảng dựa trên cột chung (tương tự JOIN trong SQL).

Cần match cùng loại dữ liệu (ProductID với ProductID). Left Outer giữ tất cả rows từ bảng Orders và thêm thông tin từ Products. Sau đó Expand cột Products để lấy Category.

5. Cho bảng doanh số theo quý trong sheet `Q5_INDEX_MATCH` với cột Product và các cột Q1, Q2, Q3, Q4. Bạn cần tìm doanh số Q2 của sản phẩm "Keyboard". Kết quả mong đợi là **2400**. Công thức nào sau đây **sai**?

   A. `=INDEX(B2:E6, MATCH("Keyboard", A2:A6, 0), 2)`

   B. `=INDEX(A2:E6, MATCH("Keyboard", A2:A6, 0), MATCH("Q2", A1:E1, 0))`

   C. `=MATCH("Keyboard", A2:A6, 0) * MATCH("Q2", B1:E1, 0)`

   D. `=VLOOKUP("Keyboard", A2:E6, MATCH("Q2", A1:E1, 0), FALSE)`

   Đáp án C.

   Giải thích

   Đáp án C nhân 2 kết quả MATCH: MATCH("Keyboard") = 3, MATCH("Q2") = 2 $\rightarrow 3 \times 2 = 6$, không phải 2400.

   Các đáp án A, B, D đều đúng và trả về 2400. MATCH chỉ trả về vị trí (số thứ tự), không phải giá trị trong ô.

6. Trong sheet `Q6_PQ`, có bảng đơn hàng với cột Region chứa giá trị trống (null) ở một số dòng. Dữ liệu được nhập theo cách: chỉ ghi Region ở dòng đầu tiên của mỗi nhóm, các dòng tiếp theo để trống. Sau khi xử lý, tất cả các ô trống trong cột Region cần được điền giá trị từ ô phía trên. Thao tác Power Query nào sau đây đúng?

OrderID	Region	Product	Amount
ORD001	North	Laptop	12000
ORD002	North	Monitor	4000
ORD003	North	Keyboard	1600
ORD004	South	Laptop	18000
ORD005	South	Mouse	800
ORD006	East	Headset	2400
ORD007	East	Monitor	8000
ORD008	East	Laptop	24000

A. Transform → Replace Values → Replace null with above value

B. Transform → Fill → Down

C. Home → Merge Queries → Self-join on Region

D. Add Column → Conditional Column → If null then previous row

Đáp án B.

Giải thích

Fill Down là tính năng Power Query dùng để điền giá trị từ ô trên xuống các ô null bên dưới.

Đường dẫn: Chọn cột Region → Transform → Fill → Down. Các ô null sẽ được thay bằng giá trị gần nhất phía trên (North, South, East).

7. Cho bảng công việc trong sheet `Q7_DATE` với cột StartDate và EndDate. Task "Development" có StartDate = 2025-01-06 và EndDate = 2025-01-17. Bạn cần tính số ngày làm việc (không tính thứ 7 và Chủ nhật). Kết quả mong đợi là **10** ngày. Công thức nào sau đây đúng?

   A. `=DATEDIF(C3, D3, "D")`

   B. `=D3 - C3 + 1`

   C. `=NETWORKDAYS(C3, D3)`

   D. `=WORKDAY(C3, D3)`

   Đáp án C.

   Giải thích

   NETWORKDAYS tự động loại trừ Sat & Sun, bao gồm cả ngày bắt đầu và kết thúc.

   Từ 2025-01-06 (Mon) đến 2025-01-17 (Fri): Tuần 1 = 5 ngày (6-10), Tuần 2 = 5 ngày (13-17). Tổng = 10 ngày làm việc. WORKDAY trả về ngày cụ thể, không phải đếm số ngày.

8. Trong sheet `Q8_PQ_GroupBy`, có bảng giao dịch với các cột: TransactionID, Region, Product, Amount. Bạn cần dùng Power Query để tính tổng Amount theo từng Region. Region "North" có 5 giao dịch với tổng Amount = **42800**. Thao tác Power Query nào sau đây đúng?

OrderID	Region	Product	Amount
ORD001	North	Laptop	12000
ORD002	North	Monitor	4000
ORD003	North	Keyboard	1600
ORD004	South	Laptop	18000
ORD005	South	Mouse	800
ORD006	East	Headset	2400
ORD007	East	Monitor	8000
ORD008	East	Laptop	24000

A. Transform → Group By → Group by: Region → Operation: Count Rows

B. Transform → Group By → Group by: Region → Operation: Sum, Column: Amount

C. Home → Merge Queries → Self-join on Region

D. Transform → Pivot Column → Values Column: Amount

Đáp án B.

Giải thích

Power Query Group By tương đương với SQL GROUP BY + aggregate functions.

Chọn Group by: Region, Operation: Sum, Column: Amount. Region North có 5 giao dịch: 12000 + 1600 + 800 + 24000 + 4400 = 42800.

9. Cho bảng tỷ lệ hoa hồng trong sheet `Q9_XLOOKUP` với các cột MinSales, MaxSales, CommissionRate. Bảng định nghĩa:

MinSales	MaxSales	CommissionRate
0	999	3%
1000	4999	5%
5000	9999	8%
10000	19999	10%
20000	999999	12%

Với Sales Amount = 7500, kết quả mong đợi là "**8%**". Công thức nào sau đây đúng?

A. `=VLOOKUP(7500, A2:C6, 3, FALSE)`

B. `=XLOOKUP(7500, A2:A6, C2:C6, "", -1)`

C. `=XLOOKUP(7500, A2:A6, C2:C6, "", 0)`

D. `=INDEX(C2:C6, MATCH(7500, A2:A6, 0))`

Đáp án B.

Giải thích

Cú pháp XLOOKUP: `=XLOOKUP(lookup_value, lookup_array, return_array, [if_not_found], [match_mode])`

match_mode = -1 tìm giá trị $\leq$ lookup_value. 7500 nằm trong khoảng 5000-9999, tìm được MinSales = 5000 $\rightarrow$ CommissionRate = 8%. match_mode = 0 là exact match, sẽ không tìm thấy 7500.

10. Trong sheet `Q10_PQ_Unpivot`, có bảng doanh số dạng wide format với các cột: Product, Jan, Feb, Mar. Bảng có 4 sản phẩm (Laptop, Monitor, Keyboard, Mouse). Bạn cần dùng Power Query để chuyển sang dạng long format với 3 cột: Product, Month, Sales. Sau khi Unpivot, tổng số rows trong kết quả là bao nhiêu?

Product	Jan	Feb	Mar
Laptop	15000	18000	16000
Monitor	8000	9500	7200
Keyboard	2000	2400	2100
Mouse	1200	1500	1800

A. 4 rows (giữ nguyên số products)

B. 7 rows (4 products + 3 months)

C. 12 rows (4 products × 3 months)

D. 3 rows (chỉ giữ lại months)

Đáp án C.

Giải thích

Unpivot chuyển đổi từ wide format sang long format (normalize data).

Công thức: Rows sau Unpivot = Số identifier rows × Số cột được unpivot = 4 products × 3 months = 12 rows.

I. Tài liệu tham khảo

Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.

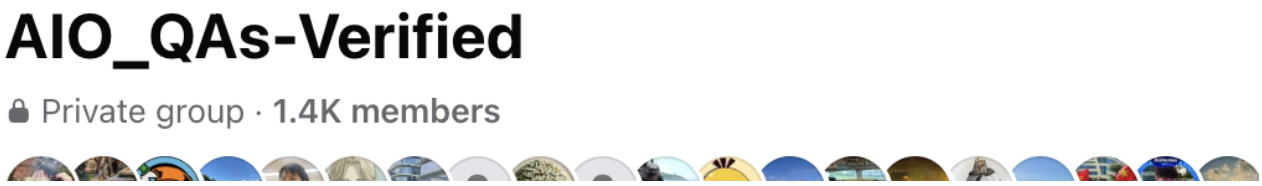

Hình 1: Hình ảnh group facebook AIO Q&A.

AI VIET NAM COURSE 2026

Claude cho Excel

I. Giới thiệu

Trong học tập, nghiên cứu và công việc, Excel là một trong những công cụ quen thuộc nhất để lưu trữ, tính toán và trình bày dữ liệu. Từ bảng điểm, bảng doanh thu, kế hoạch ngân sách, dữ liệu khảo sát cho đến mô hình tài chính nhiều sheet, Excel giúp người dùng tổ chức thông tin theo dạng bảng và thực hiện các phép tính một cách linh hoạt.

Tuy nhiên, khi một file Excel trở nên lớn hơn, việc đọc hiểu và chỉnh sửa file không còn đơn giản. Trong những trường hợp này, người dùng thường mất nhiều thời gian để trả lời các câu hỏi *File này có những sheet nào? Mỗi sheet dùng để làm gì? Công thức ở ô này đang tính gì? Lỗi trong workbook đến từ đâu? Dữ liệu nào đang ảnh hưởng đến kết quả cuối cùng?*

Claude for Excel được giới thiệu như một trợ lý AI làm việc trực tiếp trong Excel. Thay vì chỉ dùng Excel theo cách thủ công, người dùng có thể trao đổi với Claude bằng ngôn ngữ tự nhiên. Claude có thể hỗ trợ đọc hiểu workbook, giải thích công thức, tìm lỗi, cập nhật giả định, làm sạch dữ liệu, tạo báo cáo hoặc gợi ý cách trình bày dashboard.

Hình 1: Claude trong việc tối ưu các thao tác truyền thống với Excel

Tóm tắt nhanh

Phần này tóm tắt toàn bộ quy trình dùng Claude for Excel trong một trang, có thể đọc độc lập. Chi tiết từng bước và ví dụ chạy thực tế xem Mục IV.

Trước khi bắt đầu

- Cần một gói Claude trả phí (Pro, Max, Team hoặc Enterprise).
- Chỉ mở file *đáng tin cậy*; tránh template hoặc file từ nguồn ngoài chưa kiểm chứng.
- Luôn giữ lại sheet dữ liệu gốc; mọi thao tác làm sạch xuất ra sheet mới.

Quy trình gồm 9 bước và được chia thành 3 giai đoạn như sau:

1. **Chuẩn bị** (1) định dạng workbook `.xlsx`, đặt tên sheet rõ ràng; (2) kết nối Claude; (3) thiết lập Instructions cố định trong Settings.
2. **Xử lý dữ liệu** (4) yêu cầu Claude khảo sát tổng quan; (5) kiểm tra chất lượng (thiếu, trùng, bất thường); (6) làm sạch sang sheet mới, gắn cờ thay vì xóa.
3. **Tạo kết quả** (7) bảng phân tích tóm tắt theo nhóm; (8) dashboard KPI và biểu đồ; (9) kiểm chứng kết quả.

Gợi ý luyện tập

Ví dụ `doanh_thu_2024` trong bài có quy mô nhỏ để người đọc dễ theo dõi từng bước. Để thực hành với dữ liệu thực tế, người đọc có thể tải một bộ dữ liệu công khai và thực hiện lại quy trình. Dữ liệu thực tế thường chứa nhiều giá trị thiếu, lỗi định dạng hoặc giá trị không nhất quán. Có thể tham khảo các nguồn dữ liệu miễn phí sau:

- **Kaggle Datasets** (https://www.kaggle.com/datasets) cung cấp nhiều bộ dữ liệu bán hàng, tài chính và khảo sát ở dạng `.csv`.
- **UCI Machine Learning Repository**, **Google Dataset Search**, hoặc cổng dữ liệu mở `data.gov`.

Quy trình thực hành bắt đầu bằng việc tải file `.csv` và lưu thành `.xlsx`. Sau đó, mở file bằng Claude for Excel và thực hiện lần lượt 9 bước. Cần kiểm tra kỹ ở bước *kiểm tra chất lượng* và *kiểm chứng*.

Lưu ý

Nguyên tắc cốt lõi là Claude hỗ trợ rút ngắn thời gian đọc, làm sạch và tổng hợp dữ liệu. Người dùng cần kiểm chứng kết quả trước khi đưa vào báo cáo hoặc sử dụng để ra quyết định. Một cách kiểm tra là tính tổng theo hai nhóm độc lập. Hai cách tính phải cho cùng một kết quả.

II. Claude for Excel là gì?

II.1. Định nghĩa

Claude for Excel là một add-in tích hợp Claude vào Microsoft Excel, cho phép người dùng trao đổi với Claude trong sidebar để đọc hiểu, phân tích, chỉnh sửa và tạo nội dung bảng tính bằng ngôn ngữ tự nhiên.

Nói đơn giản, Claude for Excel đưa khả năng hội thoại của AI vào môi trường bảng tính. Người dùng không cần rời khỏi Excel để hỏi một chatbot riêng biệt, cũng không cần copy toàn bộ dữ liệu ra ngoài. Khi workbook đang mở, Claude có thể hỗ trợ người dùng hiểu cấu trúc file, giải thích công thức, tìm vấn đề trong dữ liệu và đề xuất thay đổi ngay trong ngữ cảnh của file đó.

Ví dụ về yêu cầu giải thích công thức

Hãy giải thích **công thức ở ô F12** trong sheet Revenue bằng ngôn ngữ đơn giản.

Claude sẽ cố gắng đọc nội dung workbook, phân tích mối quan hệ giữa các sheet hoặc các ô liên quan, sau đó đưa ra câu trả lời dễ hiểu hơn cho người dùng.

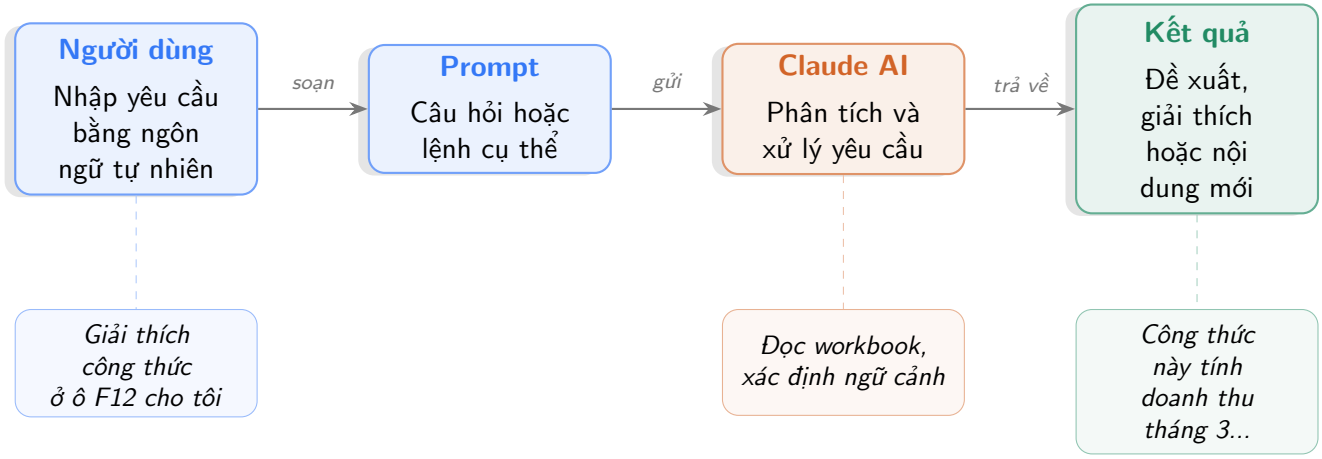

Hình 2: Quy trình xử lý yêu cầu của Claude for Excel.

II.2. Claude for Excel khác gì so với dùng Claude thông thường?

Khi dùng Claude trong trình duyệt thông thường, người dùng có thể tải file lên hoặc copy dữ liệu vào cuộc trò chuyện. Cách này phù hợp với nhiều tác vụ phân tích nhanh. Tuy nhiên, khi làm việc với Excel phức tạp, người dùng thường cần Claude hiểu workbook đang mở, thao tác trong đúng file, giữ lại công thức, định dạng và cấu trúc bảng tính.

Claude for Excel khác ở chỗ Claude được đặt ngay trong Excel. Nhờ vậy, người dùng có thể hỏi về nội dung workbook, yêu cầu chỉnh sửa hoặc cập nhật dữ liệu trong môi trường Excel hiện tại.

Claude cũng có thể dẫn chiếu đến các ô cụ thể khi giải thích kết quả, giúp người dùng kiểm tra lại nguồn thông tin dễ hơn.

Lưu ý

Claude for Excel không chỉ hỗ trợ trả lời câu hỏi. Công cụ còn hỗ trợ người dùng làm việc trong ngữ cảnh của workbook. Điều này hữu ích khi file có nhiều sheet, công thức và mối liên kết dữ liệu.

II.3. Claude for Excel phù hợp với ai?

Claude for Excel có thể hữu ích với nhiều nhóm người dùng cụ thể như sau:

- Sinh viên cần xử lý dữ liệu bài tập, bảng khảo sát hoặc báo cáo.
- Người làm phân tích dữ liệu cần làm sạch, kiểm tra và tóm tắt dữ liệu.
- Người làm tài chính cần đọc hiểu mô hình, cập nhật giả định và kiểm tra công thức.
- Người làm vận hành, marketing, kinh doanh cần tạo dashboard, báo cáo KPI hoặc phân tích doanh thu.
- Người mới học Excel muốn hiểu công thức và logic bảng tính nhanh hơn.

Ví dụ thực tế

Một file doanh thu có 12 sheet tương ứng với 12 tháng. Người dùng muốn biết sản phẩm nào bán tốt nhất, khu vực nào giảm doanh thu mạnh nhất và tháng nào vượt target. Thay vì mở từng sheet để tính thủ công, người dùng có thể yêu cầu Claude đọc workbook, tổng hợp dữ liệu và tạo báo cáo tóm tắt.

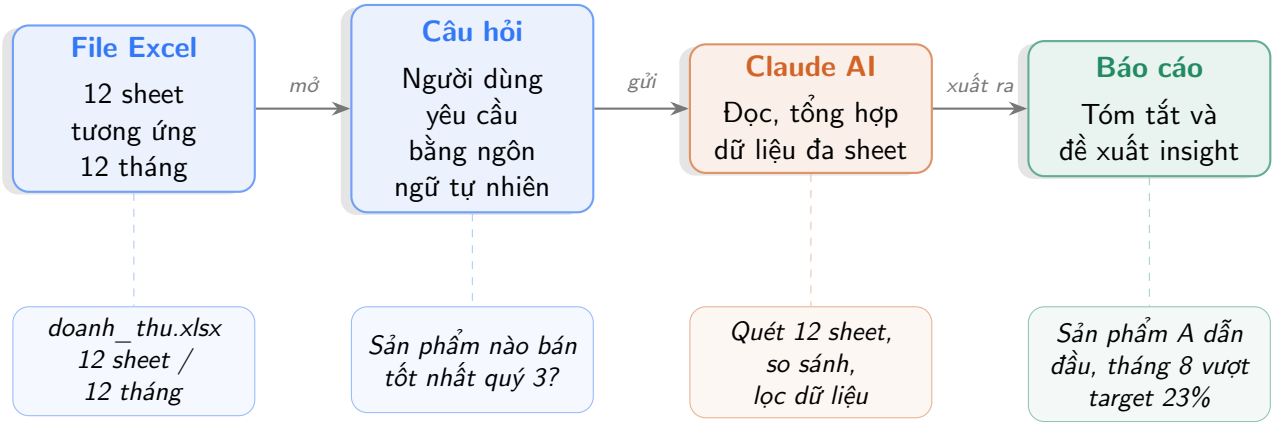

Hình 3: Claude tổng hợp dữ liệu đa sheet để tạo báo cáo doanh thu.

III. Cách Claude đọc Workbook trong Excel

III.1. Workbook, worksheet và cell

Để sử dụng Claude for Excel hiệu quả, trước hết cần hiểu cách một file Excel được tổ chức.

Định nghĩa

Workbook là toàn bộ file Excel. Trong workbook có thể có nhiều worksheet. Mỗi worksheet là một trang tính gồm nhiều ô, gọi là cell. Mỗi cell có thể chứa dữ liệu, công thức, định dạng hoặc ghi chú.

Ví dụ về cấu trúc workbook bán hàng

- `Raw_Data` chứa dữ liệu thô.
- `Product_List` chứa danh sách sản phẩm.
- `Region` chứa thông tin khu vực.
- `Calculation` chứa công thức tính toán.
- `Dashboard` chứa biểu đồ và KPI tổng hợp.

III.2. Claude truy vết dữ liệu như thế nào?

Khi người dùng hỏi Claude về workbook, Claude cần hiểu không chỉ từng ô riêng lẻ, mà còn mối quan hệ giữa các sheet. Một ô trong sheet Dashboard có thể lấy dữ liệu từ Calculation, trong khi Calculation lại lấy dữ liệu từ Raw_Data và Product_List. Vì vậy, một kết quả cuối cùng trong Excel thường là kết quả của cả một chuỗi liên kết.

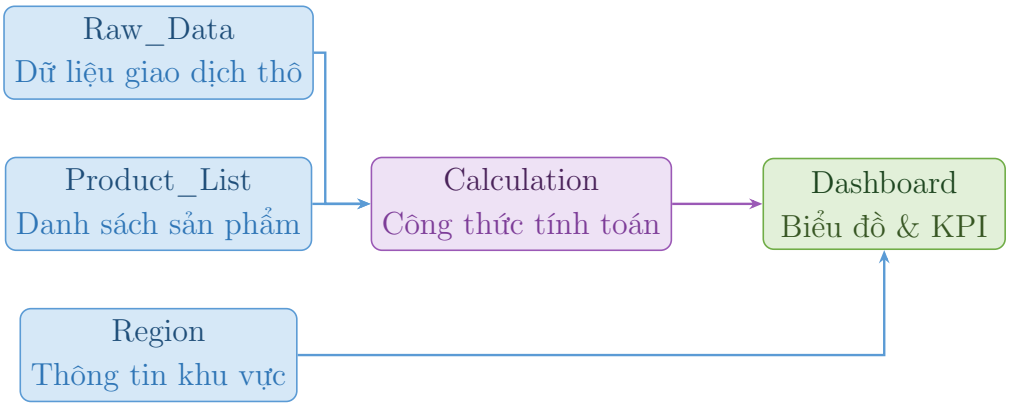

Hình 4: Cấu trúc dữ liệu và luồng xử lý trong một workbook bán hàng.

Ví dụ

Giả sử trong sheet Dashboard dưới đây, **ô B3** hiển thị tổng doanh thu. Nhưng B3 không chứa một con số, nó chứa công thức **=SUM(Calculation!C2:C100)**.

Điều này có nghĩa là dữ liệu được lấy từ **cột C** của sheet **Calculation**. Bản thân **Calculation** lại được tính từ **Raw_Data**. Như vậy, để hiểu một ô duy nhất, Claude phải lần theo cả chuỗi sheet đứng sau nó.

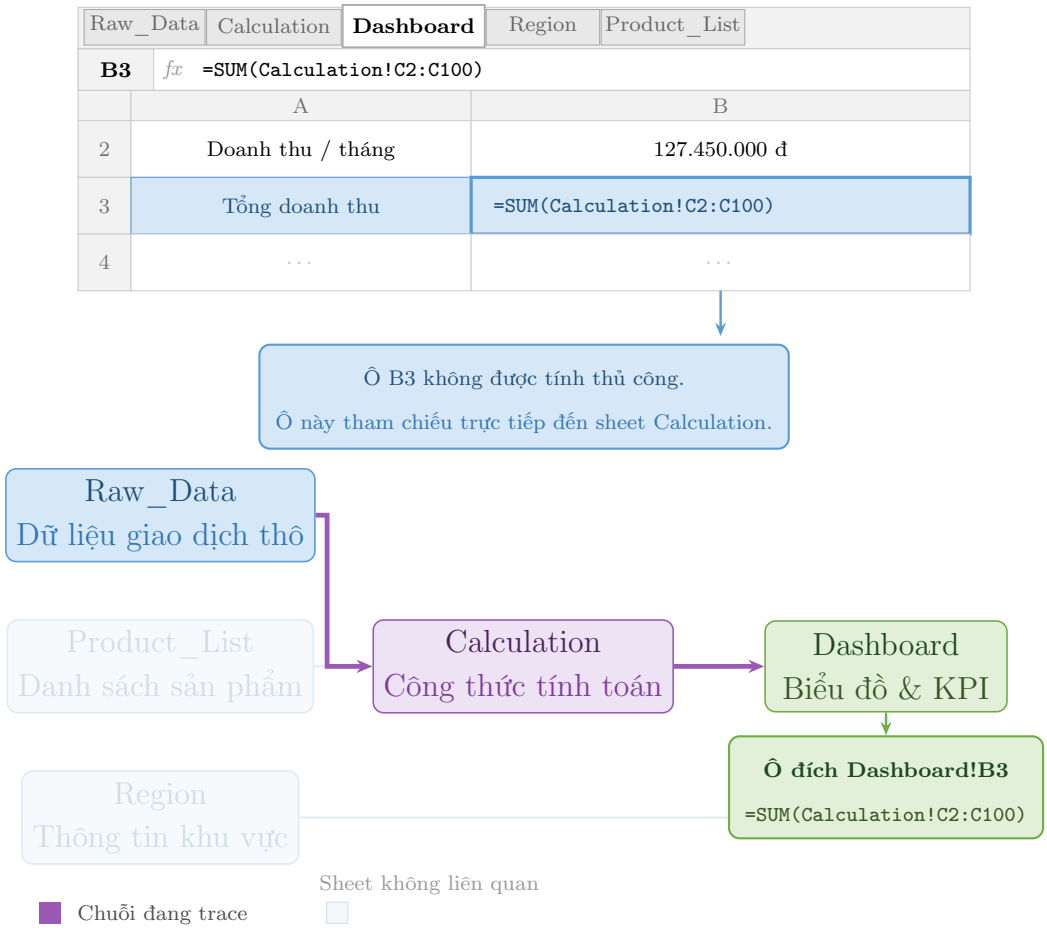

Hình 5: Claude truy vết công thức từ Dashboard về dữ liệu nguồn.

IV. Quy trình dùng Claude for Excel trong một workbook thực tế

Trong một workflow thực tế, Claude for Excel nên được xem như một trợ lý hỗ trợ người dùng đọc hiểu, xử lý và trình bày dữ liệu trong Excel. Người dùng vẫn là người quyết định mục tiêu phân tích, kiểm tra kết quả và đánh giá liệu các thay đổi do Claude đề xuất có phù hợp với dữ liệu hay không

IV.1. Quy trình thao tác gợi ý

Hình 6: Quy trình thao tác gợi ý khi làm việc với Claude for Excel

IV.2. Thực hành trên một workbook mẫu

Để minh họa quy trình thao tác, ta sử dụng một workbook mẫu tên `doanh_thu_2024.xlsx`. File này không nhằm mô phỏng một hệ thống bán hàng phức tạp, mà chỉ đóng vai trò như một ví dụ nhỏ để người đọc thấy rõ cách Claude for Excel hỗ trợ từ dữ liệu thô đến kết quả phân tích. Một số lỗi thường gặp được cố ý đưa vào dữ liệu để phục vụ các bước kiểm tra và làm sạch ở phần sau.

RAW_DATA DATA_QUALI CLEANED_D/ SUMMARY DASHBOARD

A1 *fx* RAW_DATA: dữ liệu giao dịch thô trước khi làm sạch

	A: Ngày bán	B: Sản phẩm	C: Khu vực	D: SL	E: Doanh thu	F: Ghi chú
1	2024-01-05	Áo thun	Bắc	10	2.500.000	
2	05/01/2024	Quần jean	Nam	5	3.000.000	
3	2024-01-06	áo thun	bắc	8	2.000.000	Khác cách viết hoa/thường
4	06-01-2024	Áo khoác	Trung	4	4.000.000	Định dạng ngày khác
5	2024-01-05	Áo thun	Bắc	10	2.500.000	Trùng với dòng 1
6	2024-01-07	Quần jean	NAM	6	3.800.000	Khác cách viết hoa/thường
7	07/01/2024	Ao Thun	Trung	7	1.750.000	Thiếu dấu, thừa khoảng trắng
8	2024-01-08	Áo khoác	Nam	3	*(trống)*	Thiếu doanh thu
9	2024-01-09	Quần jean	Bắc	5	3.000.000	
10	2024-01-10	Ao thun	*(trống)*	9	2.250.000	Thiếu khu vực
11	2024-01-11	Áo khoác	Trung	-2	-2.000.000	Số lượng và doanh thu âm
12	2024-01-12	Quần jean	Nam	4	2.400.000	
13	12/01/2024	Áo thun	Bắc	6	1.500.000	Định dạng ngày khác
14	2024-01-13	Áo khoác	Nam	5	999.999.999	Nghi nhập sai doanh thu
15	2024-01-14	Quần jean	Trung	3	1.800.000	

Bảng 1: `RAW_DATA` trong workbook mẫu `doanh_thu_2024.xlsx`

Lưu ý

Bảng này được thiết kế với một số lỗi thường gặp trong dữ liệu thực tế như giá trị thiếu, dòng trùng, định dạng ngày không nhất quán, cách viết hoa không thống nhất, số âm và giá trị có dấu hiệu nhập sai. Các lỗi này sẽ được sử dụng trong các bước kiểm tra chất lượng, làm sạch dữ liệu và tạo bảng phân tích ở phần sau.

IV.2.1. Chuẩn bị trước khi thao tác

Trước khi sử dụng Claude for Excel, người dùng cần chuẩn bị workbook ở định dạng phù hợp. Nếu dữ liệu gốc ở dạng `.csv`, nên lưu một bản làm việc mới dưới dạng `.xlsx`, vì `.csv` chỉ lưu dữ liệu thuần, còn `.xlsx` giữ được nhiều sheet, công thức, định dạng, biểu đồ và pivot table. Trong phần này, ta dùng file mẫu `doanh_thu_2024.xlsx`. Sheet dữ liệu thô `RAW_DATA` gồm 15 dòng giao dịch và 5 cột. Các cột lần lượt chứa ngày bán, sản phẩm, khu vực, số lượng và doanh thu.

Lưu ý

Luôn giữ lại sheet dữ liệu gốc. Nếu cần làm sạch hoặc biến đổi, hãy tạo sheet mới thay vì ghi đè trực tiếp lên dữ liệu ban đầu. Cách này giúp so sánh dữ liệu trước và sau khi xử lý, đồng thời giảm rủi ro mất dữ liệu.

Ví dụ về cách tổ chức workbook

Một workbook làm việc nên được tổ chức thành các sheet có vai trò riêng.

- `RAW_DATA` chứa dữ liệu gốc và không được chỉnh sửa trực tiếp.
- `DATA_QUALITY_CHECK` chứa kết quả kiểm tra chất lượng dữ liệu.
- `CLEANED_DATA` chứa dữ liệu đã được làm sạch.
- `SUMMARY_ANALYSIS` chứa các bảng phân tích tóm tắt.
- `DASHBOARD` trình bày các kết quả trực quan.

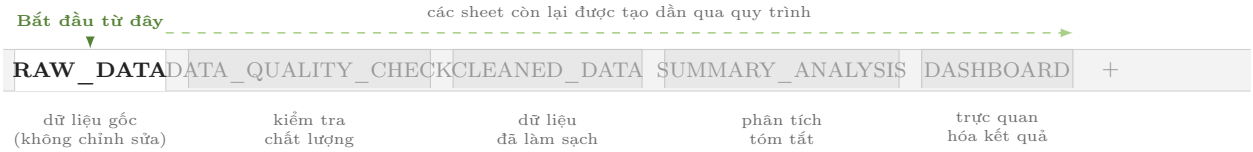

Hình 7: Cấu trúc workbook mục tiêu khi bắt đầu từ sheet `RAW_DATA`. Các sheet còn lại được tạo trong những bước tiếp theo

IV.2.2. Kết nối Claude với Excel

Sau khi workbook đã sẵn sàng, người dùng kích hoạt add-in Claude từ ribbon của Excel và đăng nhập bằng tài khoản Claude. Trên Windows, chọn Home → Add-ins. Trên Mac, chọn Tools → Add-ins. Khi sidebar Claude xuất hiện bên phải màn hình, người dùng có thể trao đổi với Claude ngay trong ngữ cảnh workbook đang mở. Ở bước này, chưa nên yêu cầu Claude chỉnh sửa file. Việc đầu tiên là xác nhận Claude đang làm việc đúng workbook và người dùng đã xác định rõ mục tiêu.

Prompt

Hãy xác nhận bạn đang làm việc với workbook hiện tại. Trước khi chỉnh sửa bất kỳ nội dung nào, hãy chỉ tóm tắt ngắn những gì bạn quan sát được từ workbook này

Lưu ý

Điều kiện sử dụng

Claude for Excel yêu cầu một gói Claude *trả phí* gồm Pro, Max, Team hoặc Enterprise. Add-in có thể được cài miễn phí từ Microsoft Marketplace, nhưng người dùng cần đăng nhập bằng tài khoản trả phí. Thông tin về các gói được trình bày tại trang giá của Claude (`claude.com/pricing`).

DOANH THU 2024

Dòng gốc	Ngày bán	Sản phẩm	Khu vực	SL	Doanh thu	Ghi chú
1	2024-01-05	Áo thun	Bắc	10	2.500.000	
2	05/01/2024	Quần jean	Nam	5	3.000.000	
3	2024-01-06	áo thun	bắc	8	2.000.000	Khác cách viết hoa/thường
4	06-01-2024	Áo khoác	Trung	4	4.000.000	Định dạng ngày khác
5	2024-01-05	Áo thun	Bắc	10	2.500.000	Trùng với dòng 1
6	2024-01-07	Quần jean	NAM	6	3.800.000	Khác cách viết hoa/thường
7	07/01/2024	Áo Thun	Trung	7	1.750.000	Thiếu dấu, thiếu khoảng trắng
8	2024-01-08	Áo khoác	Nam	3	(trống)	Thiếu doanh thu
9	2024-01-09	Quần jean	Bắc	5	3.000.000	
10	2024-01-10	Ao thun	(trống)	9	2.250.000	Thiếu khu vực
11	2024-01-11	Áo khoác	Trung	-2	-2.000.000	Số lượng và doanh thu âm
12	2024-01-12	Quần jean	Nam	4	2.400.000	
13	12/01/2024	Áo thun	Bắc	6	1.500.000	Định dạng ngày khác
14	2024-01-13	Áo khoác	Nam	5	999.999.999	Nghi nhập sai doanh thu
15	2024-01-14	Quần jean	Trung	3	1.800.000	

Hình 8: Dấu hiệu kết nối thành công
(1) sidebar Claude xuất hiện bên phải (2) tab RAW_DATA hiện ở thanh sheet (3) chưa có thay đổi nào trên dữ liệu.

IV.2.3. Thiết lập Instructions

Trước khi yêu cầu Claude phân tích hoặc chỉnh sửa, người dùng nên thiết lập Instructions. Phần này nằm trong Settings của sidebar. Các quy tắc được thiết lập tại đây áp dụng cho mọi cuộc hội thoại trong Excel và tách biệt với Instructions của Word hoặc PowerPoint.

Instructions là bộ quy tắc được sử dụng trong nhiều lượt trao đổi. Người dùng có thể thiết lập vai trò của Claude, giới hạn thao tác, ngôn ngữ trả lời và cách trình bày kết quả.

Prompt

Trong workbook này, hãy đóng vai một trợ lý phân tích dữ liệu hỗ trợ tôi xử lý dữ liệu trong Excel. Luôn trả lời bằng tiếng Việt, ngắn gọn và dễ hiểu. Trước khi chỉnh sửa workbook, hãy trình bày kế hoạch ngắn. Nêu rõ sheet sẽ được tạo và những cột sẽ được sửa hoặc bổ sung. Không chỉnh sửa sheet dữ liệu gốc nếu chưa được yêu cầu; khi cần làm sạch, hãy tạo sheet mới thay vì ghi đè. Khi tạo công thức, hãy giải thích công thức đó dùng để làm gì. Khi tạo phân tích, hãy kèm bước kiểm tra. Định dạng số có dấu phân tách hàng nghìn và in đậm tiêu đề cột.

Lưu ý

Không cần thêm quy tắc yêu cầu Claude không sử dụng VBA hoặc macro. Add-in hiện không hỗ trợ macro, VBA và data table nên Claude không thể thực hiện các thao tác này. Instructions nên tập trung vào định dạng, ngôn ngữ và quy tắc đặt tên sheet.

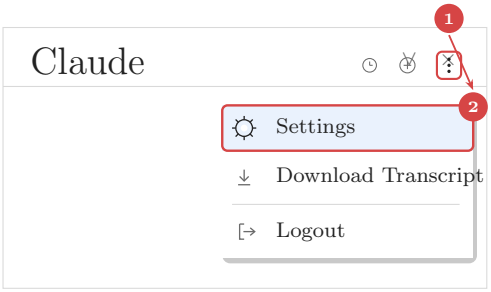

Hình 9: Cách mở Instructions. Nhấn nút (1) ở góc trên của sidebar, sau đó chọn **Settings** (2)

IV.2.4. Yêu cầu Claude khảo sát workbook và dữ liệu

Mục tiêu của bước này là hiểu dữ liệu trước khi chỉnh sửa. Người dùng cần xác định mỗi dòng đại diện cho điều gì, cột nào chứa thời gian, cột nào dùng để phân loại, cột nào chứa số đo và dữ liệu có thể trả lời những câu hỏi nào. Người dùng nên đối chiếu câu trả lời của Claude với dữ liệu thật; nếu Claude hiểu sai ý nghĩa một cột, cần điều chỉnh trước khi đi tiếp.

Prompt này được thiết kế theo nguyên tắc *khảo sát trước, phân tích sau*. Thay vì yêu cầu Claude tính toán ngay, người dùng yêu cầu Claude đọc và mô tả cấu trúc dữ liệu bằng ngôn ngữ tự nhiên. Cách làm này mang lại ba lợi ích như sau:

- Claude cần xác nhận ý nghĩa và kiểu dữ liệu của từng cột trước khi sử dụng. Điều này giúp hạn chế việc hiểu nhầm dữ liệu.
- Câu hỏi về chất lượng dữ liệu giúp người dùng chuẩn bị cho bước làm sạch ở Mục IV.2.5.
- Các câu hỏi phân tích gợi ý giúp người dùng xác định hướng xử lý dữ liệu trong những bước tiếp theo.

Lưu ý

Phản hồi có thể thay đổi theo mô hình
Nội dung phản hồi trong hình minh họa đã được rút gọn và trình bày lại để phù hợp với tài liệu. Văn phong, độ dài và cách tổ chức câu trả lời có thể thay đổi theo mô hình được sử dụng, chẳng hạn Claude Sonnet hoặc Claude Haiku. Cách viết prompt cũng có thể ảnh hưởng đến kết quả. Claude vẫn cần xác định cấu trúc dữ liệu, chỉ ra những vấn đề cần kiểm tra và gợi ý hướng phân tích phù hợp với tập dữ liệu.

Prompt

Tôi muốn hiểu dữ liệu trong sheet `RAW_DATA`. Hãy đọc sheet hiện tại và trả lời các câu hỏi sau bằng tiếng Việt.

1. Mỗi dòng dữ liệu đại diện cho điều gì?
2. Các cột chính có ý nghĩa gì? Cột nào là thời gian, phân loại, số đo?
3. Có những câu hỏi phân tích nào có thể khai thác từ dữ liệu này?
4. Trước khi phân tích sâu hơn, tôi nên kiểm tra chất lượng dữ liệu ở những điểm nào?

Phản hồi của Claude

Dưới đây là tóm tắt của tôi về sheet `RAW_DATA`:

1. Mỗi dòng đại diện cho điều gì?

Mỗi dòng là một giao dịch bán hàng: một lần bán một sản phẩm, tại một khu vực, vào một ngày, kèm số lượng và doanh thu tương ứng.

2. Ý nghĩa các cột 2. Ý nghĩa của các cột

- `ngay_ban` là cột thời gian và lưu ngày giao dịch.
- `san_pham` và `khu_vuc` là các cột phân loại. Hai cột này lưu tên sản phẩm và khu vực bán hàng.
- `so_luong` và `doanh_thu` là các cột số đo. Hai cột này lưu số sản phẩm bán được và doanh thu của giao dịch.

3. Các câu hỏi phân tích có thể khai thác

- Sản phẩm nào bán chạy nhất (theo doanh thu và theo số lượng)?
- Khu vực nào đóng góp doanh thu cao nhất?
- Doanh thu trung bình mỗi giao dịch là bao nhiêu?

4. Những điểm nên kiểm tra chất lượng trước khi phân tích

- Giá trị thiếu (một vài ô doanh thu và khu vực đang trống).
- Dòng trùng lặp hoàn toàn.
- Định dạng ngày không nhất quán (đang lẫn nhiều kiểu).
- Tên phân loại viết khác nhau (hoa/thường, thiếu dấu, thừa khoảng trắng).
- Giá trị bất thường (số lượng âm, hoặc doanh thu quá lớn nghi nhập sai).

Tôi đề xuất bước tiếp theo là tạo một sheet kiểm tra chất lượng riêng trước khi đi vào phân tích.

Hình 10: Phản hồi của Claude trong add-in trước khi dữ liệu được chỉnh sửa

IV.2.5. Kiểm tra chất lượng

Dữ liệu thực tế có thể chứa giá trị thiếu, dòng trùng, định dạng ngày không nhất quán, tên nhóm chưa được chuẩn hóa hoặc giá trị bất thường. Người dùng yêu cầu Claude tạo một sheet riêng để tổng hợp kết quả kiểm tra mà không chỉnh sửa dữ liệu gốc. Kết quả này giúp người dùng xác định cách làm sạch dữ liệu.

Prompt

Hãy kiểm tra chất lượng dữ liệu trong sheet `RAW_DATA` và tạo sheet mới tên `DATA_QUALITY_CHECK`. Bảng kết quả cần trình bày tổng số dòng, tổng số cột, tỷ lệ giá trị thiếu theo từng cột, số dòng trùng, số kiểu định dạng ngày, số giá trị riêng biệt trong các cột phân loại và các giá trị số bất thường. Không chỉnh sửa dữ liệu gốc.

Hạng mục kiểm tra	Kết quả
Tổng số dòng	15
Tổng số cột	5
Giá trị thiếu trong `doanh_thu`	1 dòng (6,7%)
Giá trị thiếu trong `khu_vuc`	1 dòng (6,7%)
Dòng trùng hoàn toàn	1 dòng
Định dạng cột ngày	3 kiểu khác nhau
Giá trị `san_pham` riêng biệt	6 biến thể (thực chất 3 sản phẩm)
`so_luong` bất thường	1 dòng giá trị âm
`doanh_thu` bất thường	1 dòng nghi nhập sai

Bảng 2: Sheet `DATA_QUALITY_CHECK`

IV.2.6. Làm sạch dữ liệu

Khi đã xác định các vấn đề cần xử lý, người dùng yêu cầu Claude tạo sheet `CLEANED_DATA` từ dữ liệu gốc và giữ nguyên `RAW_DATA` để đối chiếu.

Người dùng vẫn là người quyết định cách xử lý từng vấn đề. Một giá trị thiếu có thể xuất phát từ lỗi nhập liệu nhưng cũng có thể mang ý nghĩa riêng. Claude hỗ trợ phát hiện và đề xuất cách xử lý. Người dùng cần kiểm tra trước khi chấp nhận.

Prompt

Hãy tạo sheet mới `CLEANED_DATA` từ `RAW_DATA` và thực hiện các yêu cầu sau:

1. Chuẩn hóa cột ngày về định dạng `yyyy-mm-dd`.
2. Chuẩn hóa các cột phân loại. Loại bỏ khoảng trắng thừa, thống nhất cách viết hoa và bổ sung dấu tiếng Việt còn thiếu.

3. Loại bỏ dòng trùng hoàn toàn.
4. Thêm cột `data_issue_flag` để đánh dấu dòng có vấn đề (thiếu giá trị, số lượng âm, doanh thu nghi sai) thay vì xóa.
5. Không xóa hoặc sửa sheet gốc.
6. Tạo một bảng kiểm tra đối chiếu gồm số dòng gốc, số dòng sau khi làm sạch, số dòng bị loại, số ô còn thiếu và số dòng được gắn cờ.

	ngay_ban	san_pham	khu_vuc	SL	doanh_thu	data_issue_flag
1	2024-01-05	Áo thun	Bắc	10	2.500.000	
2	2024-01-05	Quần jean	Nam	5	3.000.000	
3	2024-01-06	Áo thun	Bắc	8	2.000.000	
4	2024-01-06	Áo khoác	Trung	4	4.000.000	
5	2024-01-07	Quần jean	Nam	6	3.800.000	
6	2024-01-07	Áo thun	Trung	7	1.750.000	
7	2024-01-08	Áo khoác	Nam	3	*(trống)*	THIẾU doanh_thu
8	2024-01-09	Quần jean	Bắc	5	3.000.000	
9	2024-01-10	Áo thun	*(trống)*	9	2.250.000	THIẾU khu_vuc
10	2024-01-11	Áo khoác	Trung	-2	-2.000.000	SL & doanh_thu âm
11	2024-01-12	Quần jean	Nam	4	2.400.000	
12	2024-01-12	Áo thun	Bắc	6	1.500.000	
13	2024-01-13	Áo khoác	Nam	5	999.999.999	Nghi nhập sai
14	2024-01-14	Quần jean	Trung	3	1.800.000	

Bảng 3: Sheet `CLEANED_DATA` gồm 14 dòng sau khi chuẩn hoá ngày, thống nhất phân loại, khử dòng trùng và gắn cờ vấn đề (giữ giá trị, không xoá).

Chỉ số đối chiếu	Giá trị
Số dòng gốc (`RAW_DATA`)	15
Số dòng sau làm sạch (`CLEANED_DATA`)	14
Số dòng bị loại (trùng hoàn toàn)	1
Số ô thiếu còn lại (được gắn cờ, không xóa)	2
Số dòng gắn `data_issue_flag`	4

Bảng 4: Kết quả kiểm tra đối chiếu trên sheet `CLEANED_DATA`

Lưu ý

Add-in có thể tạo tab `Claude Log` để ghi lại các thao tác trong từng lượt làm việc. Công cụ này lưu chuỗi hành động trong phiên. Tuy nhiên, dấu thời gian có thể được đồng bộ theo thao tác mới nhất và không phân biệt theo ngày.
`Claude Log` giúp người dùng xem lại những thao tác đã thực hiện nhưng không thay thế bước kiểm chứng kết quả ở Mục IV.3.

IV.2.7. Phân tích và tóm tắt dashboard

Từ `CLEANED_DATA`, người dùng yêu cầu Claude tạo sheet `SUMMARY_ANALYSIS`. Sheet này trình bày dữ liệu đã làm sạch dưới dạng các bảng tóm tắt.

Phân tích chỉ sử dụng những dòng hợp lệ. Các dòng có giá trị thiếu, số lượng âm hoặc doanh thu có dấu hiệu nhập sai được loại khỏi phạm vi tính toán. Sau bước lọc, dữ liệu còn 10 dòng với tổng doanh thu là 25.750.000 đồng.

Prompt

Từ sheet `CLEANED_DATA`, hãy tạo sheet `SUMMARY_ANALYSIS` và chỉ sử dụng các dòng không bị gắn cờ vấn đề.
Hãy tính tổng doanh thu và số giao dịch theo khu vực, đồng thời tính tổng doanh thu và số giao dịch theo sản phẩm. Có thể sử dụng PivotTable khi phù hợp. Kèm theo ba nhận xét ngắn bằng tiếng Việt dành cho người không chuyên.

Theo khu vực

Khu vực	Doanh thu	Số giao dịch
Nam	9.200.000	3
Bắc	9.000.000	4
Trung	7.550.000	3
Tổng	**25.750.000**	**10**

Theo sản phẩm

Sản phẩm	Doanh thu	Số giao dịch
Quần jean	14.000.000	5
Áo thun	7.750.000	4
Áo khoác	4.000.000	1
Tổng	**25.750.000**	**10**

Phản hồi của Claude

Ba nhận xét dành cho người không chuyên

-
- Quần jean có doanh thu cao nhất với 14.000.000 đồng. Sản phẩm này chiếm hơn một nửa tổng doanh thu hợp lệ và có nhiều giao dịch nhất với 5 giao dịch.
-
- Áo khoác chỉ có một giao dịch hợp lệ với doanh thu 4.000.000 đồng. Dữ liệu này chưa đủ để đưa ra kết luận vì phần lớn các giao dịch áo khoác đang nằm trong những dòng bị gắn cờ.
- Doanh thu của ba khu vực không chênh lệch nhiều. Nam đạt 9,2 triệu đồng, Bắc đạt 9 triệu đồng và Trung đạt 7,55 triệu đồng. Chênh lệch giữa khu vực cao nhất và thấp nhất khoảng 1,65 triệu đồng.

Bảng 5: Sheet `SUMMARY_ANALYSIS` và nhận xét nhanh

Cuối cùng, người dùng yêu cầu Claude tạo sheet `DASHBOARD` từ bảng tóm tắt. Sheet này gồm một số KPI chính, biểu đồ doanh thu theo sản phẩm, biểu đồ doanh thu theo khu vực và một khung nhận xét ngắn.

Prompt

Hãy tạo sheet `DASHBOARD` từ `SUMMARY_ANALYSIS`. Sheet này cần có một số thẻ KPI cho các chỉ số chính, biểu đồ cột doanh thu theo sản phẩm, biểu đồ cột doanh thu theo khu vực và một khung gồm ba nhận xét ngắn. Bố trí nội dung gọn, dễ đọc và không chỉnh sửa sheet dữ liệu gốc.

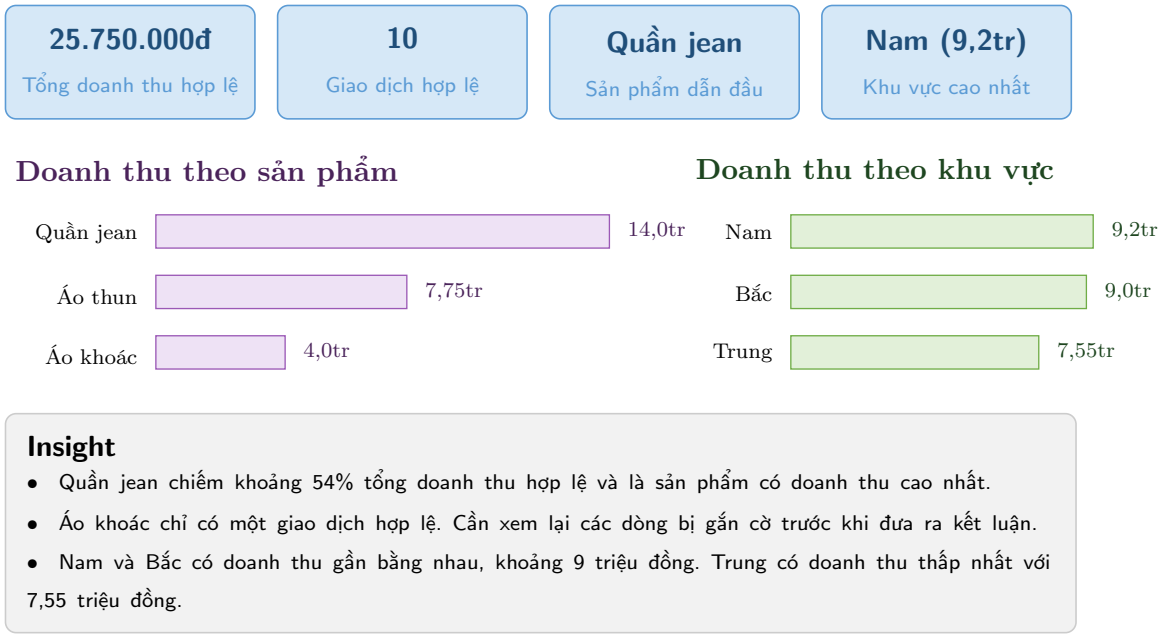

Hình 11: Sheet `DASHBOARD`

Lưu ý

Một dashboard có hình thức rõ ràng vẫn có thể cho kết quả sai nếu sử dụng nhầm vùng dữ liệu. Sau khi Claude tạo dashboard, người dùng cần kiểm tra nguồn dữ liệu của từng biểu đồ, phạm vi được chọn và PivotTable hoặc công thức dùng để tính KPI. Các kết quả này sẽ được kiểm chứng ở Mục IV.3.

IV.3. Kiểm chứng kết quả và giới hạn khi sử dụng

Các bước trước đã tạo ra bảng kiểm tra chất lượng, dữ liệu đã làm sạch, bảng tóm tắt và dashboard. Những kết quả này có thể có vẻ hợp lý nhưng vẫn chưa chắc chính xác. Claude có thể sử dụng sai vùng dữ liệu, hiểu sai ý nghĩa của một cột hoặc gộp nhầm các nhóm mà vẫn tạo ra kết quả dễ đọc.

Vì vậy, người dùng cần đối chiếu kết quả với dữ liệu gốc trước khi đưa vào báo cáo hoặc sử dụng để ra quyết định. Đây là bước giúp người dùng kiểm soát tính chính xác của kết quả.

Phần này minh họa cách kiểm chứng thủ công trên workbook mẫu `doanh_thu_2024.xlsx`. Người dùng có thể thực hiện trực tiếp từng phép kiểm tra trong Excel mà không cần Claude.

Hạng mục kiểm chứng	Cách làm thủ công	Kết quả mong đợi
Đối chiếu số dòng	Tính $15-1=14$, sau đó tính $14-4=10$	Có 10 dòng hợp lệ, khớp với KPI *Giao dịch hợp lệ*
Đối chiếu chéo tổng	Cộng tổng doanh thu theo khu vực, rồi cộng độc lập theo sản phẩm	Cả hai cùng giá trị **25.750.000đ**
Cộng doanh thu của một nhóm	Tính doanh thu khu vực Bắc bằng $2{,}5+2{,}0+3{,}0+1{,}5$ triệu đồng	Kết quả bằng 9 triệu đồng và khớp với bảng tổng hợp
Nguồn dữ liệu của KPI và biểu đồ	Kiểm tra để bảo đảm KPI và biểu đồ chỉ sử dụng 10 dòng hợp lệ, không bao gồm 4 dòng bị gắn cờ	Quần jean có doanh thu cao nhất. Nam là khu vực có doanh thu cao nhất
Kiểm tra vùng dữ liệu	Xác nhận vùng tính không còn số âm hoặc giá trị 999.999.999. Cột ngày chỉ sử dụng một định dạng	Vùng tính không còn các lỗi đã xác định

Hình 12: Năm phép kiểm chứng thủ công áp dụng trên `doanh_thu_2024.xlsx`.

Lưu ý

Một cách kiểm chứng quan trọng là tính tổng theo hai cách nhóm độc lập. Tổng doanh thu theo khu vực và tổng doanh thu theo sản phẩm phải bằng nhau. Trong ví dụ này, cả hai kết quả đều bằng 25.750.000 đồng.
Nếu hai tổng khác nhau, người dùng cần kiểm tra lại các bảng tổng hợp và điều kiện lọc những dòng hợp lệ.

Bên cạnh việc kiểm chứng, người dùng cần hiểu các giới hạn sau:

- **Claude có thể hiểu sai ý nghĩa của cột.** Một cột chứa chữ số có thể lưu mã đơn hàng thay vì một giá trị dùng để tính toán. Người dùng cần xác nhận ý nghĩa của từng cột ở bước khảo sát.

- **Công thức có thể tham chiếu sai vùng dữ liệu.** Một công thức sử dụng sai vùng dữ liệu vẫn có thể tạo ra kết quả có vẻ hợp lý. Người dùng cần kiểm tra nguồn dữ liệu của KPI và biểu đồ thay vì chỉ xem kết quả cuối cùng.
- **Người dùng quyết định cách xử lý dữ liệu.** Người dùng cần quyết định nên xóa, giữ hoặc thay thế giá trị thiếu. Tương tự, giá trị ngoại lai chỉ nên bị loại khi có căn cứ phù hợp. Claude có thể đưa ra đề xuất nhưng người dùng chịu trách nhiệm lựa chọn.
- **Add-in không hỗ trợ VBA, macro và data table.** Những thao tác này nằm ngoài khả năng của Claude trong Excel.
- `Claude Log` **chỉ là nhật ký trong phiên làm việc.** Công cụ ghi lại chuỗi thao tác nhưng dấu thời gian có thể được đồng bộ theo thao tác mới nhất và không phân biệt theo ngày. Vì vậy, nhật ký này không thay thế bước kiểm chứng kết quả.

Lưu ý

An toàn dữ liệu
Chỉ sử dụng Claude for Excel với những workbook có nguồn gốc đáng tin cậy. Các file chưa được kiểm chứng có thể chứa chỉ dẫn ẩn nhằm thao túng AI, còn gọi là *prompt injection*. Nhóm này gồm các mẫu file tải từ Internet, file do nhà cung cấp gửi, tài liệu cộng tác và dữ liệu nhập từ bên thứ ba. Người dùng cần xác nhận nguồn gốc trước khi mở file bằng Claude.
Nguyên tắc cuối cùng
Claude giúp rút ngắn thời gian xử lý nhưng không thay thế trách nhiệm kiểm tra của người dùng. Trước khi đưa một kết quả vào báo cáo hoặc sử dụng để ra quyết định, người dùng cần kiểm chứng lại bằng dữ liệu gốc.

V. Tổng kết

Qua quy trình trên, có thể thấy Claude for Excel không chỉ là một chatbot được đặt bên cạnh bảng tính, mà là một trợ lý hỗ trợ người dùng làm việc trực tiếp trong ngữ cảnh của workbook. Khi được sử dụng đúng cách, Claude có thể giúp rút ngắn thời gian đọc hiểu dữ liệu, kiểm tra chất lượng, tạo công thức, xây dựng bảng tóm tắt và hỗ trợ tạo dashboard ban đầu.

Tuy nhiên, điểm quan trọng nhất khi dùng Claude for Excel là người dùng vẫn phải giữ vai trò kiểm soát. Các kết quả do Claude tạo ra cần được đối chiếu với dữ liệu gốc, kiểm tra lại công thức, số dòng, logic phân tích và các insight trước khi sử dụng trong báo cáo hoặc ra quyết định.

Vì vậy, cách tiếp cận phù hợp không phải là giao toàn bộ file cho Claude xử lý một lần, mà là chia công việc thành từng bước nhỏ gồm thiết lập quy tắc, khảo sát dữ liệu, kiểm tra chất lượng, làm sạch, phân tích, trực quan hóa và kiểm chứng. Khi kết hợp được khả năng hỗ trợ của Claude với tư duy kiểm tra của người dùng, Claude for Excel có thể trở thành một công cụ hữu ích trong học tập, công việc văn phòng và phân tích dữ liệu thực tế.

Hình 13: Người dùng kiểm chứng kết quả trước khi sử dụng trong báo cáo hoặc ra quyết định.

Tài liệu tham khảo

[1] Anthropic, "Claude for Excel," Claude.com. https://claude.com/claude-for-excel.

[2] Anthropic, "Use Claude for Excel," Claude Help Center. https://support.claude.com/en/articles/12650343-use-claude-for-excel.

[3] Anthropic, "Advancing Claude for Financial Services," Anthropic News. https://www.anthropic.com/news/advancing-claude-for-financial-services.

[4] Microsoft, "Claude by Anthropic for Excel," Microsoft Marketplace. https://marketplace.microsoft.com/en-us/product/saas/wa200009404.

Phụ lục A. Bộ prompt mẫu

Tập hợp các prompt đã dùng xuyên suốt Mục IV, để tiện sao chép khi thực hành.

Bước 2. Kết nối và xác nhận workbook

Hãy xác nhận bạn đang làm việc với workbook hiện tại. Trước khi chỉnh sửa bất kỳ nội dung nào, hãy chỉ tóm tắt ngắn những gì bạn quan sát được từ workbook này.

Bước 3. Thiết lập Instructions trong Settings

Trong workbook này, hãy đóng vai một trợ lý phân tích dữ liệu hỗ trợ tôi xử lý dữ liệu trong Excel. Luôn trả lời bằng tiếng Việt, ngắn gọn và dễ hiểu. Trước khi chỉnh sửa workbook, hãy trình bày kế hoạch ngắn. Nêu rõ sẽ tạo sheet nào, sửa hoặc thêm cột nào. Không chỉnh sửa sheet dữ liệu gốc nếu chưa được yêu cầu. Khi cần làm sạch, hãy tạo sheet mới thay vì ghi đè. Khi tạo công thức, hãy giải thích công thức đó dùng để làm gì. Khi tạo phân tích, hãy kèm bước kiểm tra. Định dạng số có dấu phân tách hàng nghìn và in đậm tiêu đề cột.

Bước 4. Khảo sát dữ liệu

Tôi muốn hiểu dữ liệu trong sheet `RAW_DATA`. Hãy đọc sheet hiện tại và trả lời các câu hỏi sau bằng tiếng Việt.

1. Mỗi dòng đại diện cho điều gì?
2. Các cột chính có ý nghĩa gì? Cột nào chứa thời gian, thông tin phân loại và số đo?
3. Dữ liệu có thể được dùng để trả lời những câu hỏi phân tích nào?
4. Cần kiểm tra những vấn đề chất lượng nào trước khi phân tích?

Bước 5. Kiểm tra chất lượng

Hãy kiểm tra chất lượng dữ liệu trong sheet `RAW_DATA` và tạo sheet mới tên `DATA_QUALITY_CHECK`. Tôi cần bảng tóm tắt gồm tổng số dòng, tổng số cột, tỷ lệ thiếu theo từng cột, số dòng trùng, số kiểu định dạng ngày, số giá trị riêng biệt ở các cột phân loại, và các giá trị số bất thường. Không chỉnh sửa dữ liệu gốc.

Bước 6. Làm sạch dữ liệu

Hãy tạo sheet mới `CLEANED_DATA` từ `RAW_DATA` và thực hiện các yêu cầu sau.

1. Chuẩn hóa cột ngày về định dạng `yyyy-mm-dd`.
2. Chuẩn hóa các cột phân loại. Loại bỏ khoảng trắng thừa, thống nhất cách viết hoa và bổ sung dấu tiếng Việt còn thiếu.
3. Loại bỏ những dòng trùng hoàn toàn.
4. Thêm cột `data_issue_flag` để đánh dấu các dòng có vấn đề thay vì xóa.
5. Không chỉnh sửa sheet dữ liệu gốc.

6. Tạo bảng kiểm tra đối chiếu gồm số dòng gốc, số dòng sau khi làm sạch, số dòng bị loại, số ô còn thiếu và số dòng được gắn cờ.

Bước 7. Phân tích tóm tắt

Từ sheet `CLEANED_DATA`, hãy tạo sheet `SUMMARY_ANALYSIS` và chỉ sử dụng các dòng không bị gắn cờ vấn đề.
Hãy tính tổng doanh thu và số giao dịch theo khu vực, đồng thời tính tổng doanh thu và số giao dịch theo sản phẩm. Có thể sử dụng PivotTable khi phù hợp. Kèm theo ba nhận xét ngắn bằng tiếng Việt dành cho người không chuyên.

Bước 8. Tạo dashboard

Hãy tạo sheet `DASHBOARD` từ `SUMMARY_ANALYSIS`. Sheet này cần có một số thẻ KPI cho các chỉ số chính, biểu đồ cột doanh thu theo sản phẩm, biểu đồ cột doanh thu theo khu vực và một khung gồm ba nhận xét ngắn.
Bố trí nội dung gọn, dễ đọc và không chỉnh sửa sheet dữ liệu gốc.

Phụ lục B. Lỗi dữ liệu thường gặp và cách xử lý

Bảng tra nhanh cho các lỗi xuất hiện trong workbook mẫu. Với mỗi loại, Claude phát hiện và đề xuất, nhưng *người dùng quyết định* cách xử lý.

Loại lỗi	Lựa chọn xử lý	Nguyên tắc chọn
Giá trị thiếu	Xóa dòng, gắn cờ và giữ hoặc thay bằng giá trị phù hợp	Gắn cờ và giữ nếu dòng dữ liệu vẫn còn thông tin cần thiết. Chỉ xóa khi xác định dòng không còn giá trị sử dụng. Không tự thay thế giá trị nếu không có căn cứ.
Dòng trùng hoàn toàn	Loại bỏ bản trùng và giữ lại một bản	Có thể loại bỏ khi tất cả các cột đều giống nhau. Nếu chỉ trùng một phần, cần kiểm tra vì đây có thể là hai giao dịch khác nhau.
Định dạng ngày không nhất quán	Chuẩn hóa về định dạng `yyyy-mm-dd`	Cần xác nhận quy ước ngày trước khi chuẩn hóa vì `dd/mm` và `mm/dd` có thể bị hiểu nhầm.
Tên phân loại không nhất quán về cách viết hoa, khoảng trắng hoặc dấu tiếng Việt	Chuẩn hóa về một tên thống nhất	Gộp những cách viết cùng chỉ một đối tượng. Cần kiểm tra để tránh gộp nhầm hai nhóm khác nhau.
Giá trị âm bất thường	Gắn cờ và loại khỏi vùng tính hoặc sửa khi đã xác định nguyên nhân	Nếu cột không chấp nhận giá trị âm, chẳng hạn số lượng hoặc doanh thu, cần gắn cờ và không đưa dòng đó vào phép tính cho đến khi xác minh.
Giá trị ngoại lai có dấu hiệu nhập sai	Gắn cờ, đối chiếu với nguồn dữ liệu và chưa xóa ngay	Một giá trị lớn bất thường có thể xuất phát từ lỗi nhập liệu hoặc một giao dịch có giá trị cao. Cần giữ lại và xác minh trước khi quyết định.

Lưu ý

Quy tắc chung
Nên ưu tiên gắn cờ và giữ lại dữ liệu thay vì xóa ngay. Dữ liệu đã bị xóa sẽ khó khôi phục, trong khi dữ liệu được gắn cờ vẫn có thể dùng để đối chiếu và kiểm chứng.

AI VIET NAM COURSE 2026

Tableau & Data Visualization: Introduction to Tableau

I. Giới thiệu chung

Tableau là một trong những công cụ nổi tiếng trong việc hỗ trợ mạnh mẽ về phân tích và trực quan hoá dữ liệu. Bên cạnh đó còn hỗ trợ chuyển đổi số liệu, chuyển những bảng biểu phức tạp sang hiển thị qua những biểu đồ và dashboard dễ tiếp cận, dễ hiểu dữ liệu nhanh hơn. Tableau hỗ trợ tích hợp dữ liệu đến từ nhiều nguồn khác nhau, khai thác dữ liệu mạnh mẽ và còn hỗ trợ cả việc ra quyết định dựa trên nguồn thông tin đang có.

Hình 1: Phân tích dữ liệu với Tableau

II. Giới thiệu về Tableau

Tableau được đánh giá rất cao trong những tính năng hỗ trợ người dùng rất tốt ,có giao diện sử dụng rất thân thiện và khả năng tích hợp đa dạng nguồn dữ liệu. Một số thông tin về lịch sử ra đời công cụ Tableau từ trước đến ngày nay:

- **1/2003**: Tableau được sáng lập bởi các nhà nghiên cứu khoa học Christian Chabot, Pat Hanrahan và Chris Stolte tại Stanford University.
- **2004**: Phiên bản thử nghiệm ban đầu được giới thiệu, tập trung vào trực quan hóa dữ liệu tương tác.
- **2005**: Tableau phát hành phiên bản thương mại đầu tiên (Tableau 1.0) cho máy tính để bàn.
- **2010**: Tableau Software tiến hành IPO trên sàn NYSE, đánh dấu bước mở rộng mạnh mẽ về thị trường và sản phẩm.
- **2016**: Tableau mở rộng nền tảng với Tableau Online và Tableau Server, hỗ trợ chia sẻ dashboard trên môi trường đám mây.
- **2019**: Salesforce công bố mua lại Tableau, đưa Tableau vào hệ sinh thái sản phẩm dữ liệu doanh nghiệp.
- **2023–nay**: Tableau tiếp tục phát triển các tính năng AI/analytics, tăng cường khả năng phân tích tự phục vụ và tự động hóa insight.

Hiện tại, Tableau được sử dụng rộng rãi trong các lĩnh vực như tài chính, marketing, chăm sóc sức khỏe, và phân tích dữ liệu lớn (Big Data). Trở thành một trong những cộng cũ rất phổ biến được sử dụng ở rất nhiều công ty lớn nhằm mục đích phân tích và báo cáo sử dụng trong những buổi họp cấp cao đánh giá và đưa ra chiến lược kinh doanh. Tableau là công cụ hàng đầu mà Data Analyst lựa chọn trang bị vào bộ kỹ năng để xin việc ngày nay.

II.1. Tìm hiểu các phẩn phẩm của Tableau

Tableau cung cấp rất nhiều loại sản phẩm đa dang phù hợp với từng nhu cầu sử dụng của khách hàng, sử dụng cho cá nhân, nhóm, doanh nghiệp với nhiều quy mô khác nhau. Các sản phẩm này phát triển với nhiều mục đích tính năng khác nhau từ việc tạo ra báo cáo, chia sẻ dữ liệu và những tính năng xử lý dữ liệu. Tableau là một hệ sinh thái toàn vẹn, hướng đến tối ưu hoá hiệu quả phân tích dữ liệu và trực quan hoá.

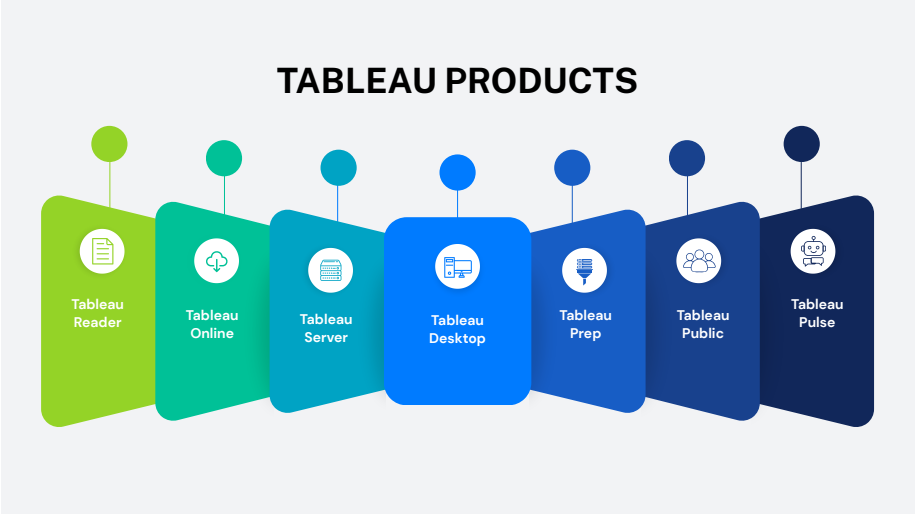

Hình 2: Tableau products

Tableau Desktop: Đây là công cụ chính mà chúng ta sẽ sử dụng khi học Tableau. Trong Tableau Desktop cho phép kết nối dữ liệu, xử lý cơ bản và tạo biểu đồ bằng cách kéo và thả rất trực quan. Và hầu hết dashboard trong doanh nghiệp đều được xây dựng từ Desktop trước, sau đó mới chia sẻ lên hệ thống chung khi hoàn thành hoặc làm việc nhóm. Ví Tableau là một hệ sinh thái, thì Desktop chính là trung tâm sáng tạo của hệ sinh thái Tableau.

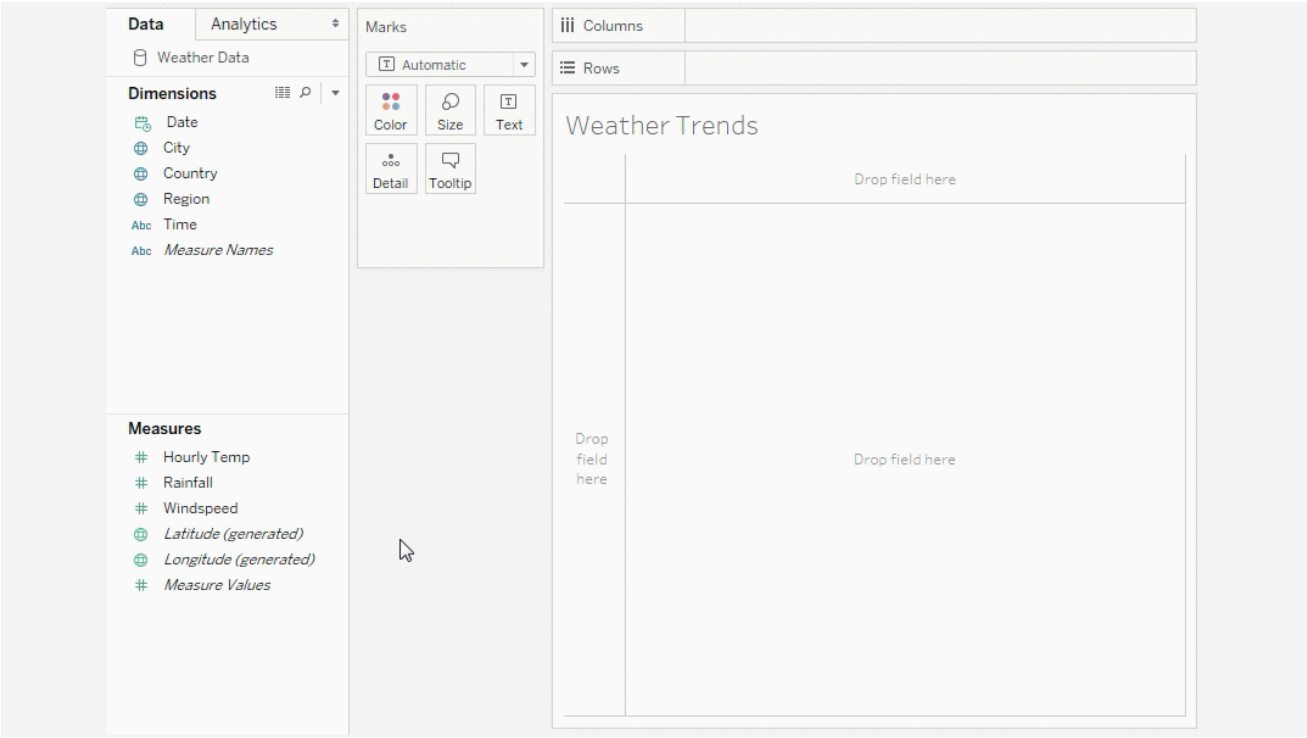

Hình 3: Tableau Desktop

Tableau Server: Tableau Server dùng khi doanh nghiệp muốn triển khai Tableau trong hệ thống nội bộ. Các dashboard sau khi làm xong sẽ được publish lên Server để mọi người trong

công ty truy cập. Server cho phép phân quyền rất chi tiết: ai được xem, ai được chỉnh sửa, ai được tải dữ liệu. Sản phẩm này phù hợp với tổ chức có nhu cầu cần dễ dàng quản lý quyền truy cập và bảo mật dữ liệu.

Tableau Online: Tableau Online là phiên bản chạy trên nền tảng đám mây, không cần cài đặt máy chủ nội bộ. Người dùng chỉ cần tài khoản và trình duyệt web để truy cập. Việc triển khai nhanh hơn Server vì không phải cấu hình hạ tầng và dễ dang mở rộng. Hiện nay Tableau Online đã được đổi tên thành Tableau Cloud.

Hình 4: Tableau Online

Tableau Public: Đây là phiên bản miễn phí của Tableau, thường sinh viên và người dùng mới học sử dụng. Public cho phép có thể tạo dashboard và đăng công khai lên Internet. Rất phù hợp để làm portfolio hoặc chia sẻ sản phẩm cá nhân. Tuy nhiên, dữ liệu trên Public là công khai, nên không dùng cho dữ liệu nhạy cảm sử dụng cho nội bộ của bất kỳ tập thể nào.

Tableau Prep: Tableau Prep là công cụ hỗ trợ xử lý và làm sạch dữ liệu trước khi phân tích. Nó hỗ trợ các thao tác như kết hợp, tách dữ liệu, loại bỏ dữ liệu không cần thiết và chuyển đổi định dạng. Tableau Prep giúp cải thiện chất lượng dữ liệu đầu vào, giúp quá trình phân tích trong Tableau Desktop hoặc Tableau Server trở nên hiệu quả và chính xác hơn.

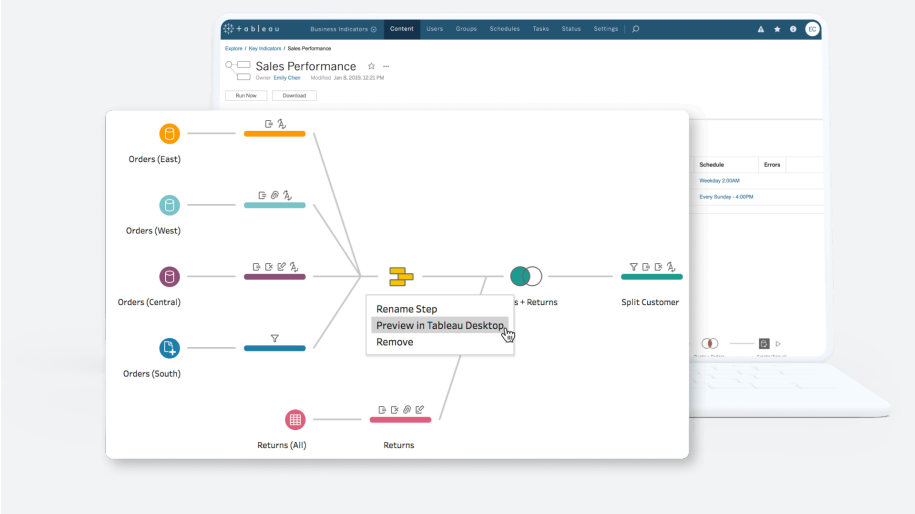

Hình 5: Tableau Prep

Tableau CRM: Tableau CRM tập trung vào phân tích dữ liệu khách hàng, đặc biệt trong môi trường Salesforce. Nó hỗ trợ phân tích hành vi khách hàng, dự báo doanh thu và theo dõi hiệu suất bán hàng. Sản phẩm này phù hợp với doanh nghiệp đã sử dụng hệ sinh thái Salesforce.

Tableau Pulse: Tableau Pulse là tính năng mới giúp theo dõi KPI theo cách chủ động hơn cho người dùng. Thay vì mở dashboard để xem số liệu, hệ thống sẽ tự động thông báo khi có biến động đáng chú ý dùng để phát hiện xu hướng tăng giảm bất thường. Rất phù hợp cho quản lý hoặc lãnh đạo cần nắm tình hình nhanh.

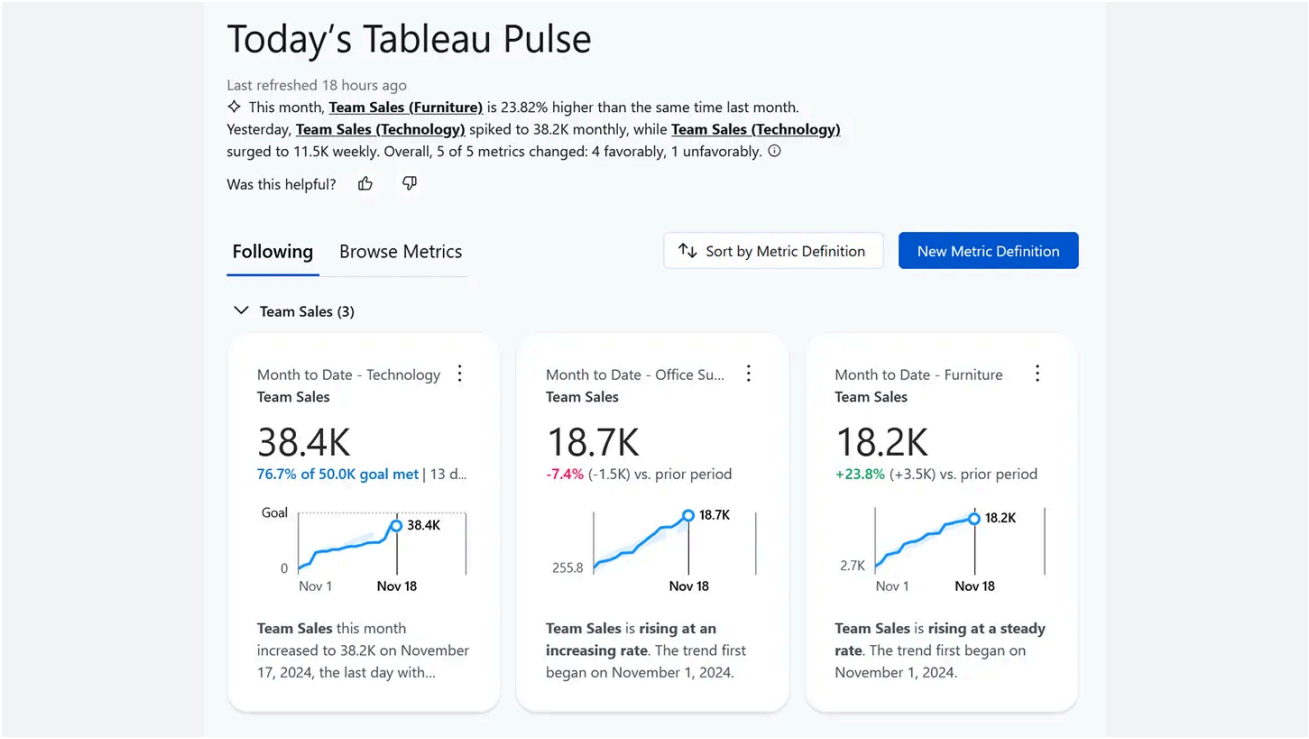

Hình 6: Tableau Pulse

Vizable và Tableau Mobile hỗ trợ xem và tương tác dashboard trên thiết bị di động. Tableau Bridge giúp kết nối dữ liệu nội bộ (on-premise) lên Tableau Cloud. Còn Tableau Reader là phần mềm miễn phí để mở file Tableau đã đóng gói mà không cần cài Tableau Desktop.

II.2. So sánh Tableau và PowerBI

Một công cụ nổi tiếng không kém gì so với Tableau được nhắc đến không thua đó là PowerBI một trong những sản phẩm của nhà Microsoft. Cả hai công cụ đều có những ưu và nhược điểm riêng, phù hợp với những đối tượng người dùng khác nhau. Để giúp đưa ra quyết định phù hợp, hãy cùng xem thử so sanh giữa hai công cụ này sau đây:

So sánh Tableau và Power BI

Tiêu chí	Tableau	Power BI
Nguồn gốc	Hiện thuộc về Salesforce	Sản phẩm của Microsoft.
Thế mạnh chính	Trực quan hóa mạnh, dashboard đẹp, tùy chỉnh linh hoạt.	Mô hình dữ liệu tốt, tích hợp hệ sinh thái Microsoft.
Tích hợp hệ sinh thái	Kết nối đa dạng nguồn dữ liệu khác nhau.	Tích hợp rất tốt với Excel, Azure, Teams, SharePoint.
Xử lý dữ liệu	Kéo thả trực quan, dễ tiếp cận với người mới.	Mạnh về Data Model và tính toán với DAX.
Chi phí	Chi phí cao hơn khi triển khai doanh nghiệp.	Chi phí thấp hơn, có bản miễn phí cá nhân.
Đối tượng phù hợp	Data Analyst, BI Developer cần thiết kế dashboard chuyên sâu.	Doanh nghiệp sử dụng Microsoft, cần triển khai nhanh.
Độ phổ biến trong doanh nghiệp	Phổ biến trong các công ty thiên về phân tích và trực quan hóa chuyên sâu.	Phổ biến trong doanh nghiệp sử dụng hạ tầng Microsoft.

Qua đây, chúng ta có thể thấy rằng Tableau và Power BI đều là những công cụ trực quan hóa dữ liệu mạnh mẽ, có những điểm mạnh riêng, được sử dụng rộng rãi trong các doanh nghiệp. Đều là những công cụ nổi tiếng hỗ trợ trực quan hoá dữ liệu, tuỳ thuộc vào nhu cầu và kinh phí của mỗi cá nhân, tập thể để đưa ra được đâu là công cụ phù hợp nhất để phục vụ tốt trong công việc.

II.3. So sánh Tableau với Python Dashboard

Python Dashboard là một ứng dụng, thường hoạt động trên nền website, được xây dựng bằng Python nhằm hiển thị thông tin dưới dạng biểu đồ, bảng dữ liệu, chỉ số tổng hợp hoặc mô hình dự đoán. Không giống với các nền tảng Business Intelligence truyền thống hoạt động theo cơ chế kéo thả như tableau, Python Dashboard lại yêu cầu kỹ thuật lập trình. Tuy nhiên, chính

đặc điểm này tạo nên ưu thế lớn về tính linh hoạt và khả năng kiểm soát toàn bộ hệ thống mà nhiều công cụ chưa hỗ trợ được bằng.

Về mặt kiến trúc, một Python Dashboard thường bao gồm ba thành phần chính: tầng dữ liệu, tầng xử lý và tầng hiển thị. Dữ liệu có thể được thu thập từ cơ sở dữ liệu, tệp tin hoặc API thời gian thực. Sau đó, dữ liệu được tiền xử lý, làm sạch và phân tích bằng các thư viện Python. Cuối cùng, kết quả được trực quan hóa thông qua các biểu đồ hoặc thành phần giao diện tương tác, cho phép người dùng lọc, tìm kiếm và khám phá thông tin theo nhiều chiều khác nhau.

So sánh Tableau và Python Dashboard

Tiêu chí	Tableau	Python Dashboard
Công cụ	Phần mềm Business Intelligence (BI) thương mại, hoạt động theo cơ chế kéo thả.	Ứng dụng được lập trình bằng Python để trực quan hóa và phân tích dữ liệu.
Cách xây dựng	Thiết kế dashboard bằng giao diện trực quan, không yêu cầu lập trình.	Xây dựng bằng code (Streamlit, Dash, Panel...), yêu cầu kỹ năng lập trình.
Mức độ tùy chỉnh	Linh hoạt trong phạm vi tính năng có sẵn.	Tùy chỉnh hoàn toàn về giao diện, thuật toán và logic xử lý.
Tích hợp Machine Learning	Hạn chế, chủ yếu kết nối mô hình từ bên ngoài.	Tích hợp trực tiếp các mô hình AI/ML trong cùng hệ thống.
Xử lý dữ liệu	Xử lý trực quan, phù hợp phân tích nghiệp vụ.	Mạnh về tiền xử lý, phân tích chuyên sâu với Pandas, NumPy, Scikit-learn.
Triển khai	Có hệ thống server và nền tảng quản trị sẵn cho doanh nghiệp.	Cần tự triển khai (server, cloud) và quản lý hệ thống.
Chi phí	Trả phí bản quyền theo người dùng hoặc doanh nghiệp.	Miễn phí (mã nguồn mở), chi phí chủ yếu là hạ tầng triển khai.
Đối tượng phù hợp	Data Analyst, Business User, doanh nghiệp cần triển khai nhanh.	Data Scientist, nhà nghiên cứu, dự án yêu cầu tích hợp AI hoặc tùy chỉnh cao.
Mục đích sử dụng phổ biến	Báo cáo kinh doanh, dashboard quản trị doanh nghiệp.	Dashboard nghiên cứu, hệ thống phân tích chuyên biệt, giám sát mô hình AI.

Python Dashboard là một hướng sử dụng cho việc xây dựng hệ thống trực quan hóa dữ liệu tùy có khả năng tuỳ chỉnh cao. Mặc dù yêu cầu kỹ năng lập trình và thời gian phát triển, nhưng lợi thế về khả năng tích hợp AI/ML, tính linh hoạt và chi phí thấp khiến Python Dashboard cũng là một trong những lựa chọn tốt cho việc trực quan dữ liệu.

III. Tableau

III.1. Tableau UI & Core Concepts

Như đã nhắc ở phía trên Tableau được thiết kế với giao diện trực quan, thân thiện với người dùng và tập trung vào trải nghiệm phân tích dữ liệu bằng thao tác kéo thả. Ngay khi khởi động và kết nối dữ liệu, người dùng sẽ làm việc chủ yếu trong không gian gọi là Worksheet, nơi các biểu đồ được xây dựng và chỉnh sửa. Giao diện tổng thể của Tableau có thể được chia thành ba khu vực chính: vùng dữ liệu (Data Pane), vùng thiết kế trực quan (Visualization Area) và các thành phần điều khiển như thanh công cụ và Marks Card.

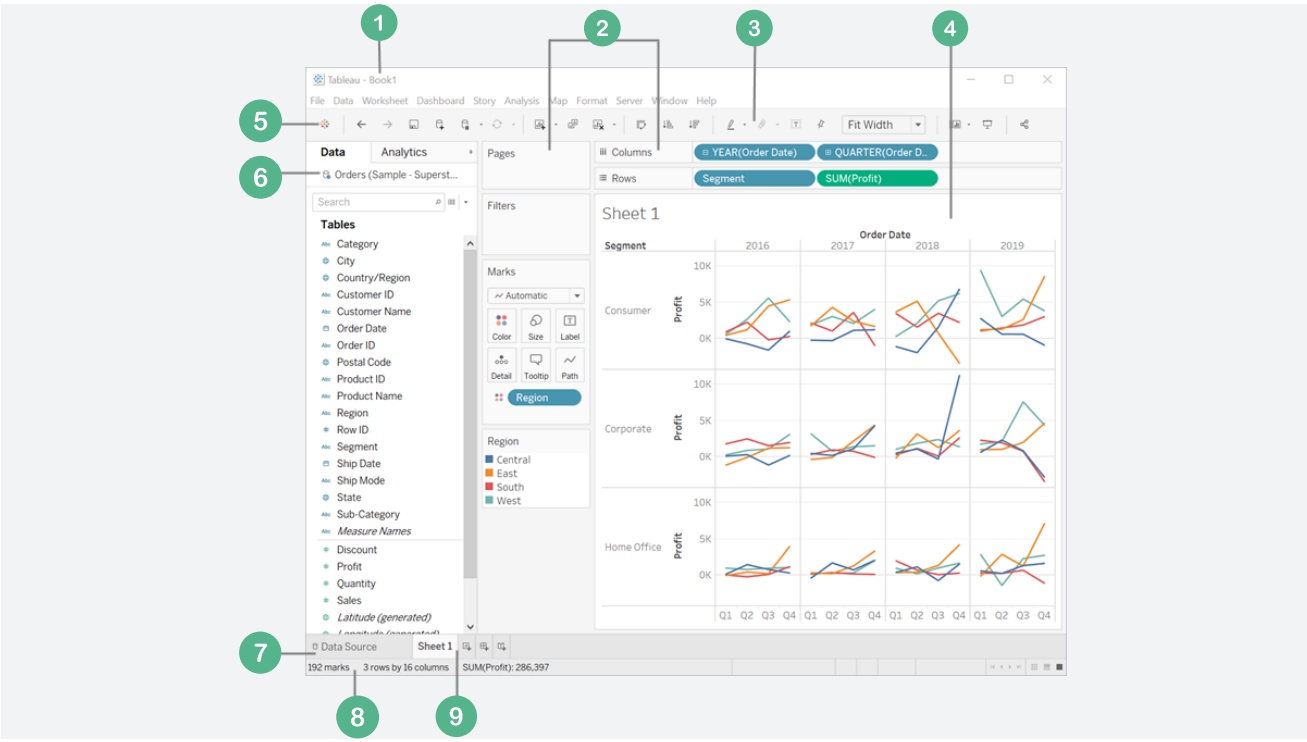

Hình 7: Khu vực không gian làm việc

1. **Tên Workbook:** Một workbook trong Tableau tương tự như một workbook trong Microsoft Excel. Nó có thể chứa một hoặc nhiều worksheet (hoặc dashboard hoặc story) và lưu trữ toàn bộ công việc của bạn. Bạn có thể lưu và chia sẻ workbook giống như bất kỳ tệp nào khác. Khi mở Tableau, một workbook trống sẽ tự động được tạo.

2. **Cards và Shelves:** Kéo các trường dữ liệu vào cards và shelves trong không gian làm việc để thêm dữ liệu vào chế độ xem. Bằng cách đặt các trường lên shelves hoặc cards, xây dựng cấu trúc của trực quan hóa.

3. **Thanh công cụ (Toolbar):** Sử dụng thanh công cụ để truy cập các lệnh, công cụ phân tích và điều hướng. Để hiểu chức năng của từng nút trên thanh công cụ, có thể tham khảo bảng hướng dẫn tương ứng.

4. **Vùng hiển thị (View):** View là khu vực làm việc trung tâm nơi bạn tạo trực quan hóa (còn gọi là "viz"). Trực quan hóa hoàn chỉnh có thể bao gồm biểu đồ, đồ thị, bản đồ và nhiều dạng hiển thị khác.

5. **Biểu tượng trang bắt đầu (Start Page):** Biểu tượng này đưa bạn đến trang Start, nơi người dùng có thể thực hiện kết nối với nguồn dữ liệu.

6. **Thanh bên (Side bar):** Trong một worksheet, thanh bên chứa Data Pane và Analytics Pane. Người dùng có thể mở rộng hoặc thu gọn thanh bên tùy nhu cầu sử dụng.

7. **Tab Data Source:** Tab này đưa người dùng đến trang Data Source, nơi bạn có thể xem và quản lý dữ liệu của mình.

8. **Thanh trạng thái (Status bar):** Thanh trạng thái hiển thị thông tin về chế độ xem hiện tại và mô tả các mục menu. Ví dụ, thanh trạng thái có thể cho biết chế độ xem đang hiển thị 192 marks trong 3 hàng và 16 cột, đồng thời hiển thị tổng SUM(Profit) của tất cả marks trong view là $286,397.

9. **Các tab Sheet:** Các tab đại diện cho từng sheet trong workbook. Mỗi tab có thể là một worksheet, dashboard hoặc story.

Data Pane nằm ở phía bên trái giao diện, chứa toàn bộ các trường dữ liệu được lấy từ nguồn dữ liệu đã kết nối. Các trường này được Tableau tự động phân loại thành hai nhóm cơ bản là Dimensions và Measures. Dimensions thường là các thuộc tính mô tả dữ liệu mang tính phân loại, chẳng hạn như tên khách hàng, khu vực, hoặc ngày tháng. Ngược lại, Measures là các giá trị số có thể tính toán và tổng hợp như doanh thu, lợi nhuận hoặc số lượng sản phẩm.

Dimensions (Thuộc tính)	**Measures (Chỉ số)**
Dữ liệu định tính	Dữ liệu định lượng
Tên, ngày tháng hoặc dữ liệu địa lý	Giá trị số và các đại lượng có thể đo lường

Bảng 1: So sánh giữa Dimensions và Measures trong Tableau

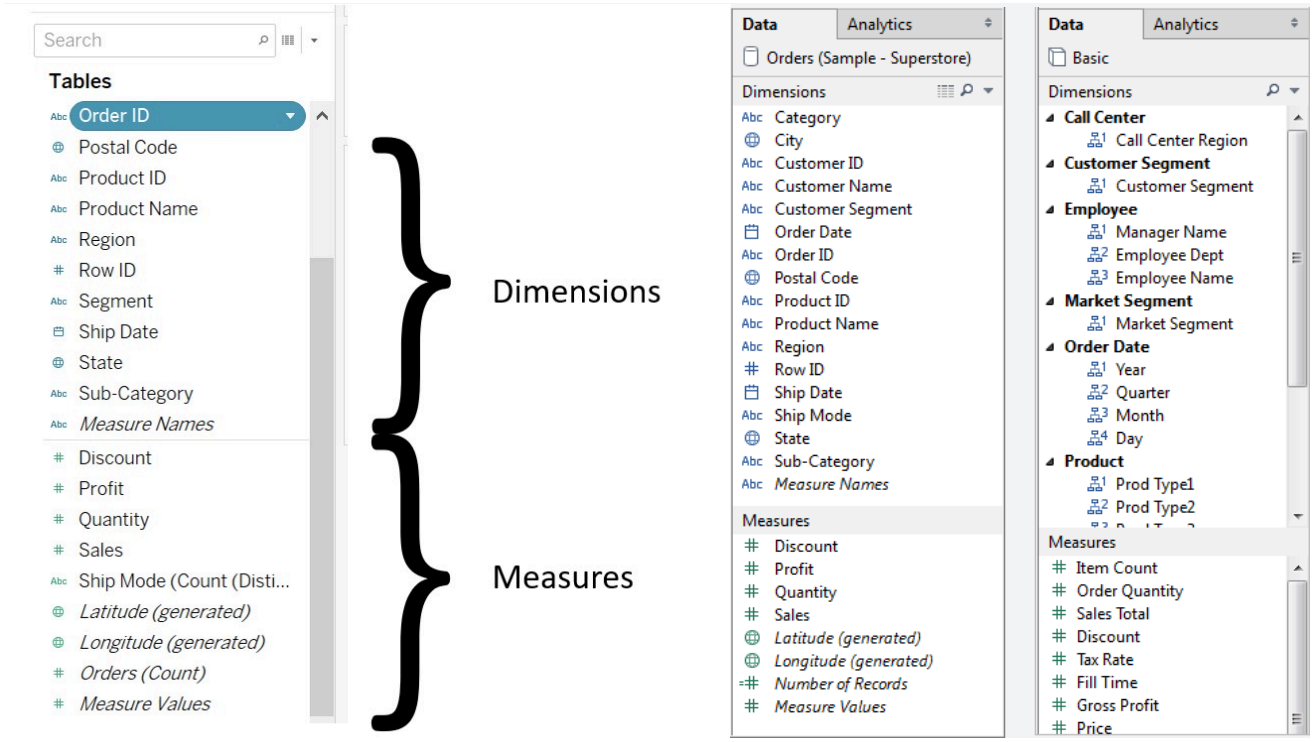

Hình 8: Giao diện Data Pane trong Tableau

Khu vực trung tâm của giao diện là nơi người dùng xây dựng biểu đồ thông qua hai thành phần quan trọng: **Rows** và **Columns**. Khi một trường dữ liệu được kéo vào Rows hoặc Columns, Tableau sẽ tự động ánh xạ dữ liệu đó lên trục ngang hoặc trục dọc của biểu đồ.

Một yếu tố trung tâm khác trong giao diện là Marks Card, cho phép kiểm soát cách dữ liệu được hiển thị. Thông qua Marks Card, người dùng có thể thay đổi loại biểu đồ (bar, line, scatter, map...), điều chỉnh màu sắc, kích thước, nhãn dữ liệu hoặc thêm thông tin chi tiết vào từng điểm dữ liệu. Đây là thành phần quyết định tính thẩm mỹ và mức độ truyền đạt thông tin của trực quan hóa cho dữ liệu.

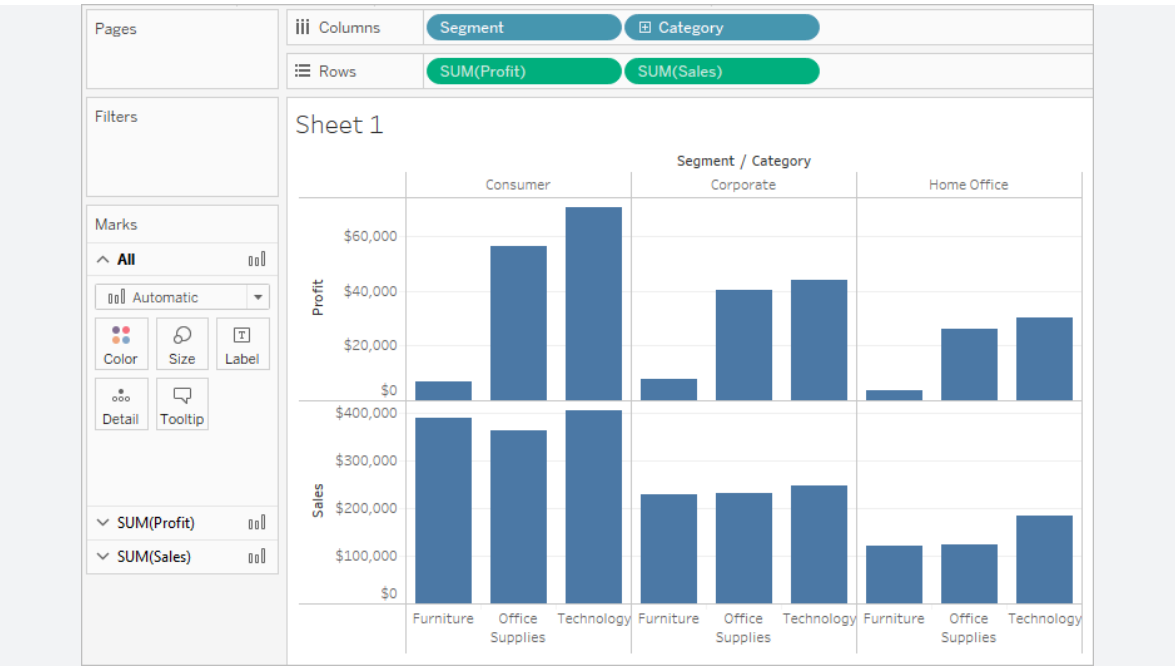

Hình 9: Khu vực kéo thả Rows và Column và vùng lựa chọn Marks Card

Bên cạnh Worksheet, Tableau còn cung cấp hai không gian làm việc mở rộng là Dashboard và Story. Dashboard cho phép kết hợp nhiều Worksheet khác nhau vào cùng một màn hình, tạo thành một bảng điều khiển tổng hợp và có tính tương tác cao, giúp người dùng thiết lập bộ lọc chung, hành động tương tác giữa các biểu đồ. Khi đó, Story hỗ trợ việc xây dựng chuỗi phân tích kể lại câu chuyện.

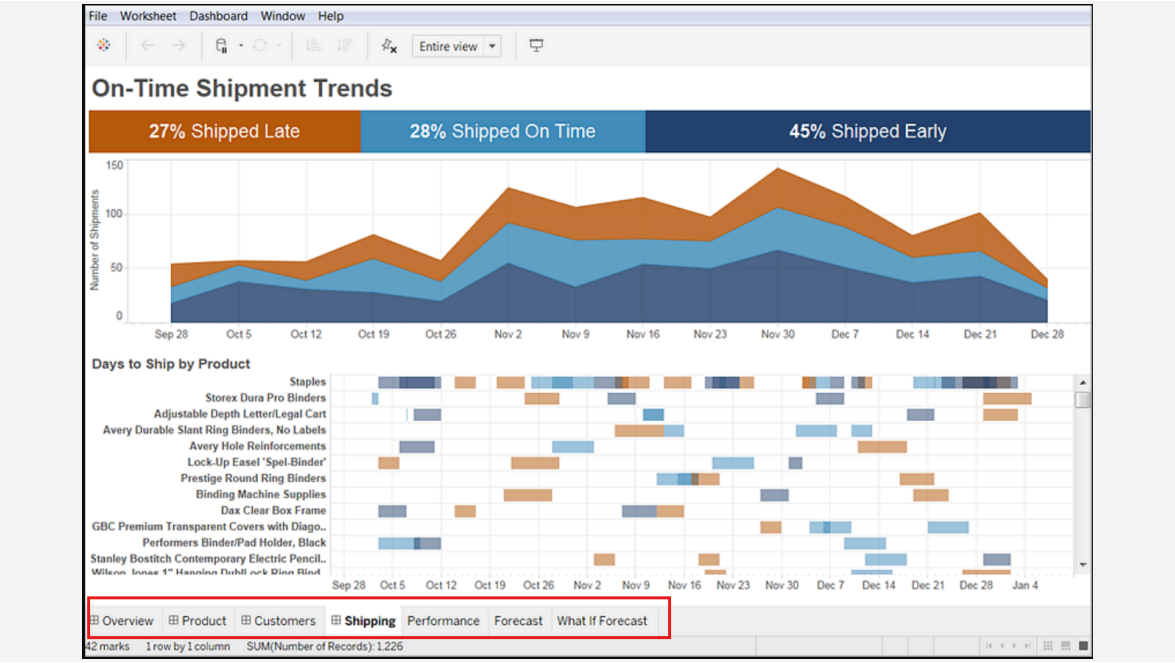

Hình 10: không gian làm việc Dashboard và Story trong Tableau

IV. Các hàm tiền xử lý dữ liệu trong Tableau theo kiểu dữ liệu

Dataset sử dụng trong ví dụ

Tableau Superstore bộ dữ liệu mẫu có sẵn trong Tableau Desktop, tại menu **Help** → **Sample Workbooks** → **Superstore**. Dataset gồm ∼10.000 dòng đơn hàng bán lẻ với các trường về sản phẩm, khách hàng, doanh thu và lợi nhuận.

IV.1. Giới thiệu

Trong thực tế, hầu hết các bộ dữ liệu đều mang theo những vấn đề tiềm ẩn mà mắt thường khó nhận ra. Một file CSV xuất từ hệ thống ERP có thể chứa tên khách hàng bị viết không nhất quán (`"nguyen van a"` và `"NGUYEN VAN A"` là hai khách hàng khác nhau trong mắt Tableau), cột ngày tháng bị lưu dưới dạng văn bản thay vì kiểu Date thực sự, hay cột doanh thu bị nhận nhầm là String khiến Tableau từ chối tính tổng.
Thông thường, các lỗi này được xử lý trong Python với Pandas trước khi đưa vào Tableau. Tuy nhiên, Tableau cung cấp một công cụ mạnh mẽ **Calculated Field** cho phép chúng ta biến đổi, chuẩn hóa và tạo cột mới. Điều này đặc biệt hữu ích khi dữ liệu được cập nhật thường xuyên và ta không muốn phải chạy lại pipeline xử lý mỗi lần.

Calculated Field (Trường tính toán)

Calculated Field là một cột dữ liệu mới được tạo ra bằng cách viết biểu thức (expression) trực tiếp trong Tableau. Calculated Field không thay đổi dữ liệu gốc, chỉ thực hiện phép tính tại thời điểm hiển thị, giống như một cột ảo được tính toán theo thời gian thực.
Cách tạo: Trên thanh menu, chọn **Analysis** → **Create Calculated Field...** Cửa sổ công thức sẽ hiện ra, nơi bạn nhập biểu thức và Tableau sẽ gợi ý hàm tự động.

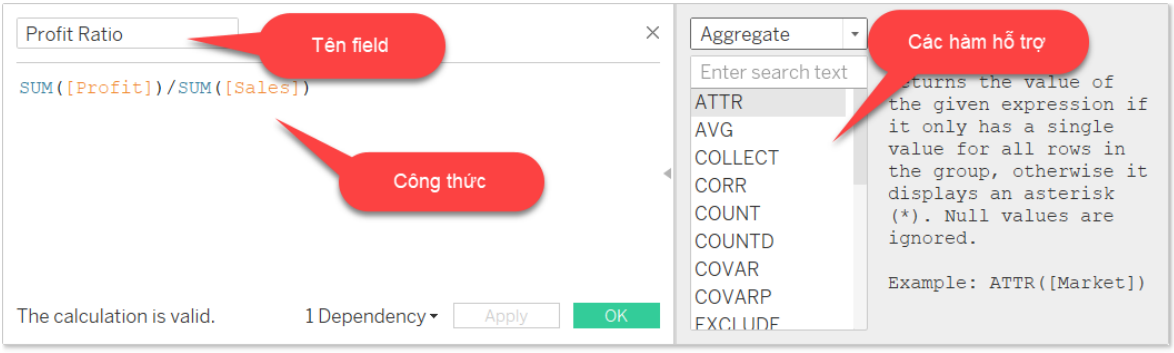

Hình 1: Cửa sổ Calculated Field có các thành phần chính gồm: (1) Tên field, (2) vùng soạn công thức, và (3) danh sách hàm hỗ trợ

Trong phần này, chúng ta sẽ khám phá các hàm preprocessing theo **kiểu dữ liệu (data type)** vì mỗi data typye có các function riêng phù hợp với đặc điểm của nó.

IV.2. Data Types trong Tableau

Khi kết nối với nguồn dữ liệu, Tableau tự động phân tích và gán **kiểu dữ liệu (data type)** cho từng cột dựa trên nội dung của nó. Mỗi data type được nhận diện thông qua một **icon đặc trưng** hiển thị bên trái tên field trong Data Pane. Việc hiểu đúng data type cực kỳ quan trọng vì nó quyết định hàm nào có thể áp dụng, loại aggregation nào được phép, và biểu đồ nào Tableau sẽ gợi ý khi bạn drag field vào canvas.

Tableau hỗ trợ 6 data type cơ bản, được tóm tắt trong bảng sau:

Icon	Data Type	Mô tả	Ví dụ trong Superstore
Abc	**String**	Văn bản hoặc chuỗi ký tự bất kỳ	`Customer Name`, `Product Name`, `Region`
#	**Number**	Số nguyên hoặc thập phân	`Sales`, `Profit`, `Quantity`, `Discount`
📅	**Date**	Ngày tháng chỉ có ngày, không có giờ	`Order Date`, `Ship Date`
📅🕐	**Date & Time**	Ngày tháng kèm giờ phút giây	Dấu thời gian giao dịch hệ thống
T|F	**Boolean**	Nhị phân chỉ có True hoặc False	Kết quả so sánh, điều kiện lọc
🌐	**Geographic**	Địa lý Tableau tự nhận diện để vẽ bản đồ	`Country`, `State`, `City`, `Postal Code`

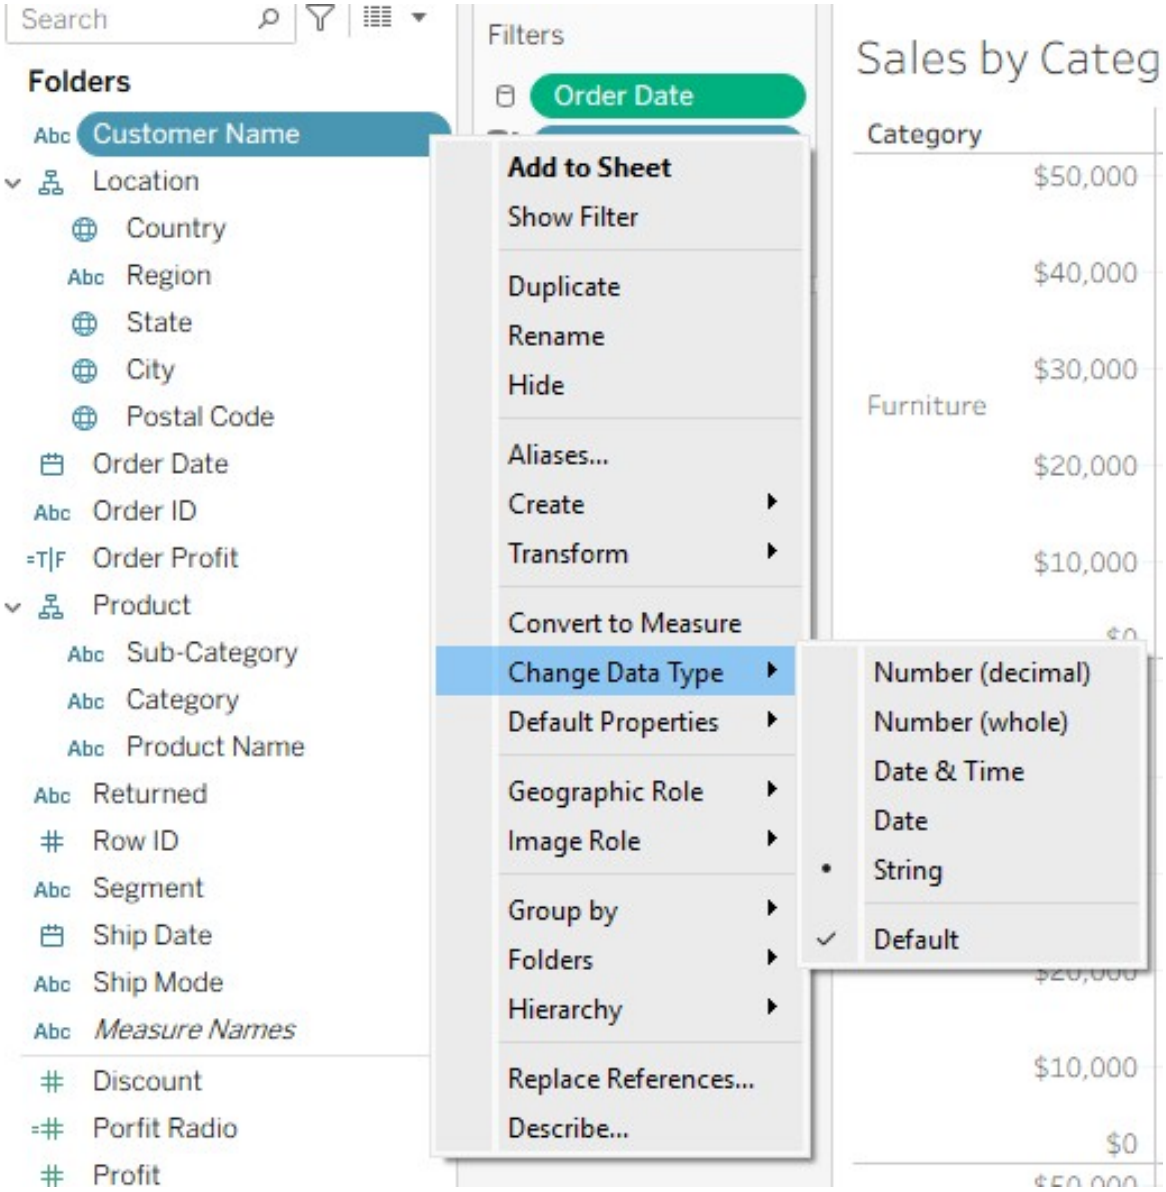

Hình 2: Data Types trong Tableau : Number (decimal và whole), Date and Time, Date, String, Boolean, và Spatial.

Lưu ý

Tableau có thể nhận sai data type. Tableau nhận diện data type dựa trên mẫu dữ liệu trong file, nhưng đôi khi mắc lỗi. Trường hợp phổ biến nhất là cột `Order Date` trong file CSV bị lưu với định dạng không chuẩn (`"15/1/2024"` thay vì `"2024-01-15"`) khiến Tableau nhận nhầm thành String mọi hàm ngày tháng sẽ thất bại.
Cách kiểm tra nhanh: Nhìn vào icon bên trái tên field trong Data Pane. Nếu thấy **Abc** cho một cột mà bạn biết là ngày tháng hoặc số, đó là dấu hiệu dữ liệu cần được chuyển đổi kiểu trước khi phân tích.

IV.3. Preprocessing Functions theo Data Type

Tableau cung cấp rất nhiều hàm preprocessing, được phân loại theo data type mà chúng xử lý. Trong thực tế, phần lớn các vấn đề tiền xử lý dữ liệu đều rơi vào 4 nhóm: **String**, **Number**, **Date**, và **Type Conversion**. Chúng ta sẽ đi sâu vào từng nhóm và ví dụ cụ thể.

IV.3.1. String Functions

Khi làm việc với dữ liệu thực tế, các trường văn bản thường là nguồn gốc của nhiều lỗi khó phát hiện nhất. Một cột `Customer Name` xuất từ hệ thống CRM có thể chứa khoảng trắng thừa ở đầu và cuối (do nhập liệu), viết hoa viết thường không nhất quán, hoặc thậm chí có ký tự đặc biệt không mong muốn. Những lỗi này không gây ra thông báo lỗi, Tableau vẫn chạy bình thường nhưng kết quả phân tích sẽ sai: cùng một khách hàng nhưng bị đếm thành nhiều người khác nhau, filter không hoạt động đúng, hay group by ra kết quả thiếu.

Tableau cung cấp một bộ hàm String phong phú để giải quyết các vấn đề này. Dưới đây là các hàm thực dụng nhất mà một nhà phân tích dữ liệu cần nắm:

- `UPPER(string)` **và** `LOWER(string)`**:** Chuyển đổi toàn bộ chuỗi sang chữ HOA hoặc chữ thường. Đây là thao tác chuẩn hóa đầu tiên khi cần so sánh hoặc nhóm dữ liệu văn bản. `"Furniture"` và `"furniture"` là hai giá trị khác nhau trong Tableau, nhưng sau khi áp dụng `LOWER()` chúng sẽ hợp nhất thành một nhóm duy nhất.
- `TRIM(string)`**:** Xóa khoảng trắng ở **đầu và cuối** chuỗi, không xóa khoảng trắng ở giữa. Đây là một trong những hàm quan trọng nhất vì khoảng trắng thừa hoàn toàn vô hình khi nhìn bằng mắt, nhưng khiến `"Hà Nội"` và `"Hà Nội"` trở thành hai chuỗi khác nhau và filter sẽ không khớp.
- `LEFT(string, number)` **và** `RIGHT(string, number)`**:** Trích xuất `n` ký tự từ bên trái hoặc bên phải của chuỗi. Ứng dụng phổ biến: trích xuất mã tỉnh/thành từ `"HN-001"` bằng `LEFT([City Code], 2)` để lấy `"HN"`.
- `MID(string, start, length)`**:** Trích xuất một đoạn con bắt đầu từ vị trí `start` (1-indexed) với độ dài `length` ký tự. Ví dụ `"US-2024-00123"`, ta có thể dùng `MID([Order ID], 4, 4)` để lấy năm `"2024"`.
- `REPLACE(string, old, new)`: Tìm và thay thế tất cả các chuỗi `old` bằng `new`. Ví dụ: `REPLACE("090-1234567", "-", "")` → `"0901234567"`
- `CONTAINS(string, substring)`**:** Kiểm tra xem chuỗi có chứa chuỗi con không, trả về `True` hoặc `False`. Ví dụ: `CONTAINS([Product Name], "Chair")` trả về True cho tất cả sản phẩm có chữ "Chair" trong tên.
- `LEN(string)`**:** Đếm tổng số ký tự trong chuỗi. Thường dùng để kiểm tra dữ liệu: nếu mã sản phẩm phải có đúng 8 ký tự, `LEN([Product ID]) != 8` sẽ phát hiện các mã bị lỗi.
- `SPLIT(string, delimiter, token_number)`**:** Tách chuỗi thành các phần dựa trên ký tự phân cách `delimiter` và lấy phần thứ `token_number`. Ví dụ `SPLIT("Furniture/Bookcases", "/", 2)` trả về `"Bookcases"`.

- **Toán tử nối chuỗi +:** Dấu cộng `+` dùng để **ghép nối (concatenate)** các chuỗi. Ví dụ: `[First Name] + " " + [Last Name]` tạo ra `"Claire Gute"`.. Lưu ý: **phải thêm khoảng trắng thủ công** vào công thức (`+ " " +`).
- `STARTSWITH(string, substring)`: Kiểm tra xem chuỗi có **bắt đầu** bằng chuỗi con `substring` không, trả về `True/False`. `STARTSWITH([Order ID], "US")` trả về True cho tất cả đơn hàng có mã bắt đầu bằng "US".
- `ENDSWITH(string, substring)`: Kiểm tra xem chuỗi có **kết thúc** bằng chuỗi con không. `ENDSWITH([File Name], ".csv")` trả về True cho các file CSV.
- `FIND(string, substring, [start])`: Tìm vị trí của chuỗi con bắt đầu từ vị trí `[start]` trả về số thứ tự ký tự `(1-indexed)`, hoặc 0 nếu không tìm thấy. Ví dụ: `FIND("CA-2024-01", "-")` = 3.
- `LTRIM(string)` **và** `RTRIM(string)`: Xóa khoảng trắng **chỉ bên trái** (`LTRIM`) hoặc **chỉ bên phải** (`RTRIM`), khác `TRIM()` vốn xóa cả 2 phía.

Ví dụ tổng hợp Chuẩn hóa tên khách hàng:

Giả sử trường `Customer Name` có giá trị lộn xộn như `"  CLAIRE GUTE  "` (thừa khoảng trắng, toàn chữ hoa). Chúng ta tạo một Calculated Field mới tên `[Customer Name Cleaned]`:

```
// Xóa khoảng trắng dư + chuyển về chữ thường để chuẩn hóa so sánh
LOWER(TRIM([Customer Name]))

// Kết quả: "claire gute"
```

Hoặc nếu muốn kiểm tra nhanh tên nào còn khoảng trắng thừa (để lọc ra dữ liệu lỗi):

```
//  True = có khoảng trắng thừa ở đầu hoặc cuối
LEN([Customer Name]) != LEN(TRIM([Customer Name]))

// Kết quả:  True /  False
```

Tableau không có hàm PROPER()

Python có `str.title()` và Excel có `PROPER()` để viết hoa chữ cái đầu mỗi từ, nhưng Tableau không có hàm tương đương sẵn có.
Giải pháp đơn giản cho chuỗi chỉ có từ :

```
UPPER(LEFT([Name], 1)) + LOWER(MID([Name], 2, LEN([Name])))
```

Tuy nhiên với tên nhiều từ ví dụ như tên người thường chỉ viết hoa được từ đầu tiên. Đối với trường hợp này, tốt hơn nên xử lý bằng Python trước khi import vào Tableau.

IV.3.2. Number Functions

Dữ liệu số trong Tableau ít gặp lỗi về kiểu hơn String, nhưng vẫn cần xử lý trong nhiều tình huống: làm tròn để hiển thị gọn gàng, lấy trị tuyệt đối khi chỉ quan tâm độ lớn, hay xử lý giá trị NULL khiến mọi phép tính đều trả về NULL thay vì giá trị thực.

Ví dụ trường `Profit` nó có thể mang giá trị âm khi đơn hàng bị lỗ, và trường `Discount` thường là số thập phân (0.1, 0.2, ...) cần làm tròn khi hiển thị. Dưới đây là các hàm Number hay dùng nhất:

- `ROUND(number, decimal_places)`: Làm tròn đến số chữ số thập phân chỉ định. `ROUND([Sales], 2)` làm tròn doanh thu đến 2 chữ số thập phân. Khi `decimal_places = 0`, hàm làm tròn về số nguyên gần nhất. Khi `decimal_places` là số âm, hàm làm tròn về hàng chục, hàng trăm... ví dụ `ROUND(1234, -2)` = 1200.
- `CEILING(number)` **và** `FLOOR(number)`: Hai hàm làm tròn lệch, `CEILING()` luôn làm tròn **lên** đến số nguyên tiếp theo (ví dụ `CEILING(3.2)` = 4), còn `FLOOR()` luôn làm tròn **xuống** (ví dụ `FLOOR(3.8)` = 3). Hữu ích trong các bài toán phân nhóm hay làm tròn giá vé, chi phí vận chuyển.
- `ABS(number)`: Trả về giá trị tuyệt đối `ABS([Profit])` cho biết độ lớn của lãi/lỗ bất kể chiều hướng. Thường dùng: `ABS([Actual] - [Target])`.
- `ZN(expression)`: Viết tắt của **"Zero if Null"** nếu biểu thức trả về NULL thì thay bằng 0, ngược lại giữ nguyên giá trị. Đây là một trong những hàm quan trọng nhất khi làm việc với dữ liệu có missing values, vì trong Tableau bất kỳ phép tính nào có NULL đều trả về NULL: `NULL + 100 = NULL`, `NULL * 5 = NULL`.
- `POWER(number, exponent)`: lũy thừa. `POWER([Sales], 2)` = Sales bình phương. Cần thiết khi tính các chỉ số thống kê hoặc chuẩn hóa dữ liệu.
- `SIGN(number)`: Trả về **−1** nếu số âm, **0** nếu bằng 0, **1** nếu dương. Kết hợp với CASE: `CASE SIGN([Profit]) WHEN 1 THEN "Lãi"WHEN -1 THEN "Lỗ"ELSE "Hòa vốn"END`.

```
    CASE SIGN([Profit]) WHEN 1 THEN "Lãi" WHEN -1 THEN "Lỗ" ELSE "Hòa vốn" END

```

- `DIV(integer1, integer2)`: Chia lấy phần nguyên trả về phần nguyên của phép chia. `DIV(7, 2)` = 3 (không phải 3.5). Hữu ích khi tính số lô hàng nguyên: `DIV([Quantity], [Batch Size])`.

Ví dụ tổng hợp Phân loại đơn hàng theo lợi nhuận:

```
// Phân loại đơn hàng: Lãi, Huề vốn, hoặc Lỗ
IF [Profit] > 0 THEN "Profitable"
ELSEIF [Profit] = 0 THEN "Break-even"
ELSE "Loss"
```

```
END

// Kết quả: "Profitable" / "Break-even" / "Loss" cho từng dòng
```

Và tính **tỷ suất lợi nhuận (profit margin)** một cách an toàn, tránh lỗi chia cho 0:

```
// ZN đảm bảo khi Sales = NULL thì kết quả = 0 thay vì NULL
ZN([Profit]) / ZN([Sales])

// Hoặc viết cẩn thận hơn để tránh lỗi chia cho 0:
IF ZN([Sales]) = 0 THEN 0
ELSE [Profit] / [Sales]
END
```

Lưu ý

NULL trong Tableau ≠ 0. Đây là một trong những điểm gây nhầm lẫn phổ biến nhất. Trong Tableau, NULL không phải là 0 mà là không có dữ liệu. Mọi phép tính số học với NULL đều trả về NULL, không phải một số.
Ví dụ thực tế: Nếu một khách hàng chưa có đơn hàng nào trong tháng, trường `Sales` của họ là NULL (không phải 0). `SUM(NULL, 50, 30)` = 80 hàm SUM bỏ qua NULL. Nhưng `NULL / 100` = NULL phép chia thất bại. Luôn dùng `ZN()` trước khi thực hiện phép chia để đảm bảo an toàn.

IV.3.3. Date Functions

Phân tích theo thời gian là một trong những yêu cầu phổ biến nhất trong Business Intelligence. Ví dụ với dataset hai trường date là `Order Date` và `Ship Date`, chúng ta cần khả năng: tách năm/quý/tháng để nhóm dữ liệu, tính khoảng cách giữa ngày đặt hàng và ngày giao hàng, hay lọc ra các đơn hàng trong 30 ngày gần nhất so với ngày hôm nay.

Trước khi bắt đầu, cần hiểu khái niệm quan trọng nhất trong Date Functions tham số `date_part`. Đây là một chuỗi chỉ định **đơn vị thời gian** mà hàm sẽ làm việc với:

Giá trị `date_part`	Ý nghĩa	Kết quả (ví dụ với 15/03/2024)
`'year'`	Năm	2024
`'quarter'`	Quý trong năm	1 (Q1: tháng 1–3)
`'month'`	Tháng trong năm	3
`'day'`	Ngày trong tháng	15
`'weekday'`	Thứ trong tuần	6 (6 = Thứ Sáu, ISO)
`'hour'`	Giờ (chỉ dùng với Date & Time)	0–23

Các Date Function thường dùng nhất trong phân tích dữ liệu bán hàng:

- `YEAR(date)`, `MONTH(date)`, `DAY(date)`: Ba hàm đơn giản nhất để trích xuất năm, tháng, ngày từ một trường Date. `YEAR([Order Date])` trả về số nguyên như 2021, 2022... Đây là cách nhanh nhất để tạo các trường phụ trợ phục vụ nhóm dữ liệu theo thời gian.
- `DATEPART(date_part, date)`: Tổng quát hơn `YEAR/MONTH/DAY`, có thể lấy bất kỳ đơn vị thời gian nào. `DATEPART('quarter', [Order Date])` trả về 1, 2, 3, hoặc 4. Kết quả là **số nguyên**, phù hợp cho tính toán.
- `DATENAME(date_part, date)`: Tương tự `DATEPART` nhưng trả về **tên dạng chuỗi**. `DATENAME('month', [Order Date])` trả về `"January"`, `"February"`... Hữu ích khi muốn hiển thị nhãn thân thiện trên biểu đồ.
- `DATEDIFF(date_part, start_date, end_date)`: Tính **khoảng cách** giữa hai ngày. `DATEDIFF('day', [Order Date], [Ship Date])` cho biết mất bao nhiêu ngày để giao hàng.
- `DATEADD(date_part, interval, date)`: Cộng (hoặc trừ nếu `interval` âm) một khoảng thời gian vào một ngày. `DATEADD('month', 3, [Order Date])` trả về ngày 3 tháng sau ngày đặt hàng.
- `TODAY()`: Trả về ngày hôm nay (không có giờ). Thường kết hợp với `DATEDIFF` để tạo filter động.
- `DATETRUNC(date_part, date)`: Đưa ngày về **đầu kỳ** tương ứng. `DATETRUNC('month', #2024-03-15#)` = **1/3/2024**; `DATETRUNC('quarter', #2024-03-15#)` = **1/1/2024**. Cực kỳ hữu ích khi cần so sánh các kỳ với nhau.
- `NOW()`: Trả về **ngày và giờ hiện tại** (Date & Time) khác với `TODAY()` chỉ trả về ngày. Lưu ý: `NOW()` tính theo múi giờ của máy chủ Tableau.
- `QUARTER(date)` **và** `WEEK(date)`: Các hàm dùng để trích xuất một thành phần thời gian cụ thể từ giá trị ngày. `QUARTER([Order Date])` trả về 1–4; `WEEK([Order Date])` trả về số tuần trong năm (1–52/53).
- `MAKEDATE(year, month, day)`: Tạo một giá trị Date từ 3 số nguyên riêng lẻ. `MAKEDATE(2024, 3, 15)` tạo ngày 15/3/2024. Hữu ích khi dữ liệu lưu riêng năm, tháng, ngày trong 3 cột Number.
- `DATEPARSE(format, string)`: Chuyển đổi một **chuỗi** có định dạng đặc biệt thành kiểu Date. Ví dụ: `DATEPARSE("MMMM,d,yy", "September,4,12")` Kết quả: 9/4/2012 (ngày tháng năm theo ISO). Các định dạng phổ biến: `yyyy` = năm 4 chữ số, `MM` = tháng 2 chữ số, `dd` = ngày 2 chữ số, `MMMM` = tên tháng đầy đủ, `MMM` = tên tháng viết tắt. Chuỗi format phải **khớp chính xác** với cấu trúc của chuỗi ngày.

Ví dụ Phân tích thời gian giao hàng:

```
// Tính số ngày giao hàng (từ Order Date đến Ship Date)
DATEDIFF('day', [Order Date], [Ship Date])
// Kết quả: 2, 3, 5... (số nguyên)
```

```
// Phân loại tốc độ giao hàng
IF DATEDIFF('day', [Order Date], [Ship Date]) <= 2
THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5
THEN "Normal (3-5 days)"
ELSE "Slow (>5 days)"
END

// Lọc đơn hàng trong 365 ngày gần nhất
DATEDIFF('day', [Order Date], TODAY()) <= 365
// Kết quả:  True /  False  dùng làm filter condition
```

DATEPART và DATENAME: khi nào dùng cái nào?

- Dùng `DATEPART('month', ...)` → kết quả là số `1, 2, ..., 12` → khi cần **tính toán** (so sánh, cộng trừ)
- Dùng `DATENAME('month', ...)` → kết quả là `"January", "February", ...` → khi cần **hiển thị nhãn** trên trục X

Lưu ý: kết quả của `DATENAME` sẽ sắp xếp theo bảng chữ cái (April, August, December...) thay vì theo thứ tự tháng. Để sắp xếp đúng, hãy dùng thêm `DATEPART` làm trường sắp xếp phụ trợ (Sort Field).

IV.3.4. Ad-hoc Calculations và xử lý giá trị NULL

Ngoài việc tạo Calculated Field đầy đủ qua menu **Analysis → Create Calculated Field...**, Tableau còn hỗ trợ một cách tạo công thức nhanh hơn gọi là **Ad-hoc Calculation**. Phương pháp này cho phép nhập công thức **trực tiếp trên Columns shelf, Rows shelf, hoặc thẻ Marks** mà không cần đặt tên hay lưu lại.

Cách tạo Ad hoc Calculation:

1. Kéo field `Profit` vào Columns shelf. Tableau hiển thị `SUM([Profit])`.
2. Nhấp đúp vào pill `SUM([Profit])` trên Columns shelf một ô nhập công thức nhỏ xuất hiện.

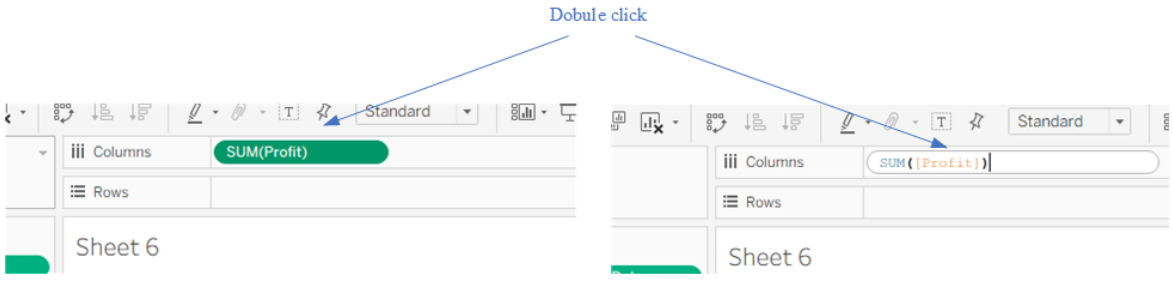

Hình 3: Tạo Ad hoc Calculation.

3. Sửa thành `SUM([Profit])/SUM([Sales])` và nhấn **Enter**. Tableau tính và hiển thị kết

quả ngay lập tức.

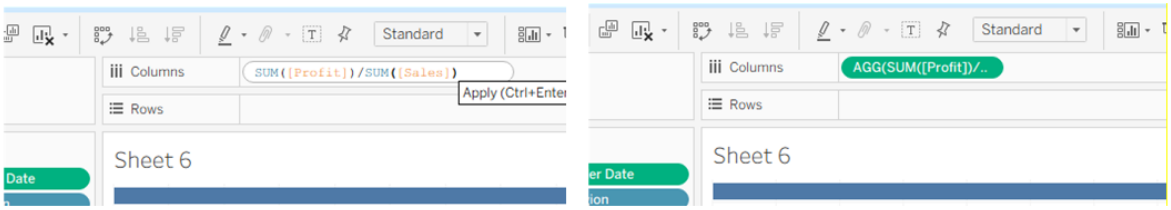

Hình 4: Edit Ad hoc Calculation.

4. Nếu muốn lưu lại: kéo từ shelf vào **Data Pane**, Tableau sẽ yêu cầu đặt tên cho Calculated Field.

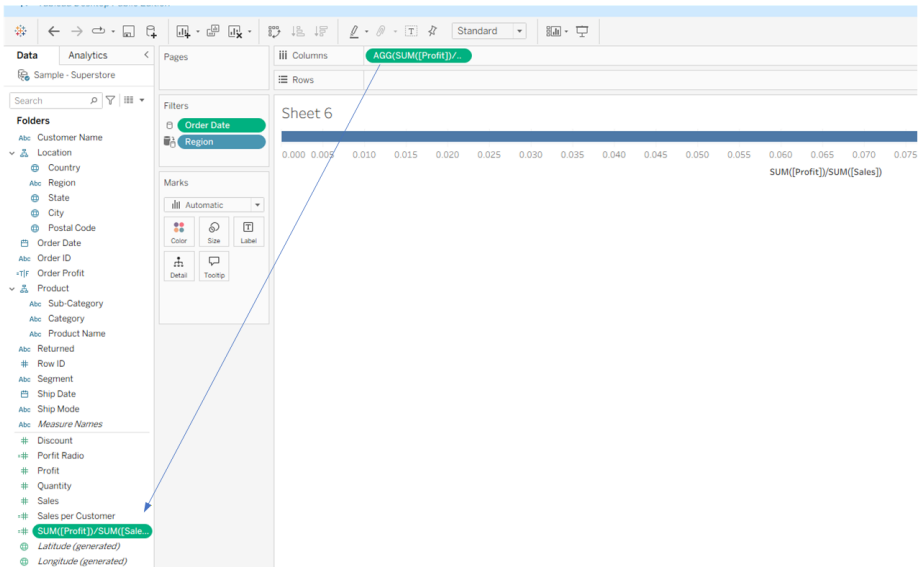

Hình 5: Save ad hoc Calculation.

Tableau có hệ thống **mã màu cú pháp** trong Formula Editor:

Màu/kiểu chữ	**Ý nghĩa**
Chữ đỏ (gạch chân)	Lỗi cú pháp, di chuột vào để xem gợi ý sửa
`// chữ màu xám`	Comment, không ảnh hưởng tính toán
[chữ màu cam]	Tên field
chữ màu xanh	Tên function
[chữ màu tím]	Parameters
chữ in đậm	Phép tính được aggregate
chữ không in đậm	Phép tính ở mức row-level

IV.3.5. Type Conversion Functions

Một trong những vấn đề phổ biến nhất khi import dữ liệu vào Tableau là **kiểu dữ liệu bị nhận sai**. Nguyên nhân thường gặp: file CSV có cột số nhưng chứa ký tự không phải số (dấu phẩy `"1,234.56"`, đơn vị tiền tệ `"$500"`), cột ngày tháng có định dạng không chuẩn, hoặc Tableau đọc toàn bộ cột là String vì có một vài ô chứa chữ.

Khi dữ liệu bị nhận sai kiểu, hậu quả rất rõ ràng: không thể tính `SUM([Revenue])` nếu Revenue là String, không thể dùng `YEAR([Order Date])` nếu Order Date là String. Type Conversion Functions cho phép chúng ta ép kiểu (cast) dữ liệu sang đúng loại:

- `INT(expression)`: Chuyển đổi sang số nguyên, cắt bỏ phần thập phân (không làm tròn `INT(3.9)` = 3, không phải 4).
- `FLOAT(expression)`: Chuyển đổi sang số thực (có phần thập phân). Thường dùng hơn `INT` vì giữ được độ chính xác. `FLOAT("1234.56")` trả về số `1234.56`.
- `STR(expression)`: Chuyển đổi **sang String**. Hữu ích khi cần ghép Number vào chuỗi: `"Order #"+ STR([Order ID])` tạo ra `"Order #12345"`.
- `DATE(expression)`: Chuyển đổi String hoặc Number sang kiểu Date. `DATE("2024-01-15")` trả về ngày 15/1/2024 với đầy đủ khả năng sử dụng các Date Functions.
- `DATETIME(expression)`: Tương tự `DATE()` nhưng tạo ra giá trị Date & Time, bao gồm cả giờ phút giây.

Ví dụ Sửa cột dữ liệu bị nhận sai kiểu:

```
// Trường hợp 1: Cột "Revenue_str" = "1234.56" (String)
// -> Chuyển thành Number để có thể SUM, AVG
FLOAT([Revenue_str])
// Kết quả: 1234.56

// Trường hợp 2: Cột "Order_Date_str" = "2024-01-15" (String)
// -> Chuyển thành Date để dùng YEAR(), DATEDIFF()...
DATE([Order_Date_str])
// Kết quả: 15/01/2024 (Date)

// Trường hợp 3: Tạo label kết hợp số và chữ
"Đơn hàng #" + STR([Order ID]) + "  " + STR([Customer Name])
// Kết quả: "Đơn hàng #12345  Claire Gute"
```

Lưu ý

Nhận biết lỗi kiểu dữ liệu ngay từ đầu Có 3 dấu hiệu rõ ràng:

1. Nhìn vào icon trong Data Pane ví dụ field có icon **Abc** trong Data Pane nhưng bạn biết nó ngày.
2. Tableau báo lỗi **"Cannot mix aggregate and non-aggregate arguments"** khi bạn cố tính SUM

3. Tableau không gợi ý **Line Chart** khi bạn drag một Date field vào Columns

Bước xử lý chuẩn: tạo Calculated Field mới dùng `FLOAT()`, `DATE()`, hay `INT()` để chuyển đổi, đặt tên rõ ràng (ví dụ `[Sales (Numeric)]`), rồi sử dụng field mới đó thay cho field gốc.

IV.3.6. Logical Functions

Nếu String Functions giúp làm sạch dữ liệu và Date Functions giúp phân tích thời gian, thì **Logical Functions** là trái tim của mọi phân tích dữ liệu có chiều sâu chúng cho phép Tableau đưa ra **quyết định** dựa trên điều kiện, phân loại dữ liệu thành nhóm, và xử lý các trường hợp đặc biệt.

IF / ELSEIF / ELSE / END Cú pháp IF là cách phổ biến nhất để phân loại dữ liệu trong Tableau:

```
IF <test1> THEN <value1>
ELSEIF <test2> THEN <value2>
...
ELSE <default_value>
END
```

- Tableau kiểm tra **lần lượt** từng điều kiện, trả về giá trị tương ứng với điều kiện đầu tiên là `True`
- `ELSEIF` và `ELSE` là tùy chọn có thể viết `IF...THEN...END` đơn giản
- Phần `ELSE` là giá trị mặc định khi không có điều kiện nào khớp nếu bỏ qua, kết quả là `NULL`

Ví dụ phân loại lợi nhuận:

```
// Tạo Calculated Field [Profit Status]
IF [Profit] > 0 THEN "Profitable"
ELSEIF [Profit] = 0 THEN "Break-even"
ELSE "Loss"
END
```

Ví dụ phân loại theo nhiều trường:

```
// Phân loại khách hàng VIP dựa trên cả Sales và Profit
IF SUM([Sales]) > 10000 AND SUM([Profit]) > 1000
THEN "VIP"
ELSEIF SUM([Sales]) > 5000
THEN "Regular"
ELSE "New"
END

// Lưu ý: Khi dùng IF kết hợp aggregate (SUM),
```

```
// cả công thức phải ở cấp aggregate
```

IIF (Inline IF)

`IIF(<test>, <then>, <else>)` là phiên bản rút gọn của IF cho trường hợp chỉ có 2 nhánh. `IIF([Profit] > 0, "Lãi", "Lỗ")` tương đương với `IF [Profit] > 0 THEN "Lãi"ELSE "Lỗ"END`. Dùng khi công thức đơn giản nhưng khi cần nhiều điều kiện, IF/ELSEIF dễ đọc hơn nhiều IIF lồng nhau.

CASE / WHEN / THEN CASE là lựa chọn tốt hơn IF khi bạn cần so sánh **một field với nhiều giá trị cụ thể**:

```
CASE <expression>
WHEN <value1> THEN <result1>
WHEN <value2> THEN <result2>
...
[ELSE <default>]
END
```

Ví dụ Dịch tên vùng sang tiếng Việt:

```
CASE [Region]
WHEN "East" THEN "Miền Đông"
WHEN "West" THEN "Miền Tây"
WHEN "North" THEN "Miền Bắc"
WHEN "South" THEN "Miền Nam"
ELSE "Không xác định"
END
```

IF vs CASE: khi nào dùng cái nào?

CASE	IF
So sánh **một field** với nhiều **giá trị rời rạc**	Kiểm tra **nhiều điều kiện phức tạp** khác nhau
`[Region] = "East", "West"...`	`[Sales] > 10000 AND [Profit] > 0...`
Cú pháp gọn hơn, dễ đọc hơn	Linh hoạt hơn, dùng được `>`, `<`, `AND`, `OR`

Toán tử logic: AND, OR, NOT Các toán tử này kết hợp nhiều điều kiện vào một biểu thức:

- `AND`: Cả hai điều kiện đều phải `True`. `[Sales] > 1000 AND [Profit] > 0`chỉ đơn hàng lãi và có doanh thu cao. .
- `OR`: Chỉ cần một trong hai điều kiện là `True`. `[Region] = "East"OR [Region] = "West"`.
- `NOT`: `NOT ISNULL([Customer ID])` chỉ giữ lại các dòng có Customer ID.

```
// Ví dụ kết hợp: đơn hàng cần chú ý
// (Lỗ lớn HOẶC chiết khấu cao) VÀ không phải khách VIP
(SUM([Profit]) < -500 OR SUM([Discount]) > 0.3)
AND NOT ([Customer Segment] = "VIP")
```

Xử lý NULL: ISNULL, IFNULL và ZN Ba hàm xử lý NULL trong Tableau, mỗi hàm phục vụ mục đích khác nhau:

Hàm	Cú pháp	Trả về	Dùng khi
`ISNULL`	`ISNULL(expr)`	`True/False`	Cần **kiểm tra** xem field có NULL không
`IFNULL`	`IFNULL(e1, e2)`	Giá trị e1 hoặc e2	Cần **thay thế NULL bằng giá trị bất kỳ**
`ZN`	`ZN(expr)`	Giá trị hoặc **0**	Cần **thay NULL bằng 0** cho phép tính số

```
// ISNULL  Phát hiện dữ liệu thiếu
ISNULL([Customer ID])
// Kết quả:  True cho các dòng chưa có Customer ID

// IFNULL  Thay NULL bằng giá trị mặc định có nghĩa
IFNULL([Assigned Region], "Chưa phân vùng")
// Kết quả: Chuỗi thực hoặc "Chưa phân vùng"

// ZN  Đảm bảo an toàn cho phép tính số
ZN([Discount]) * ZN([Sales])
// Kết quả: Nếu NULL -> kết quả là 0, không phải NULL
```

Lưu ý

IFNULL vs ZN vs ISNULL:

- `ISNULL` chỉ **phát hiện** (trả Boolean), không thay thế
- `IFNULL` thay NULL bằng **bất kỳ giá trị nào** (String, Number, Date...)
- `ZN` chỉ thay bằng **0** ngắn gọn nhưng chỉ dùng cho Number
- Với String: dùng `IFNULL([Field], "N/A")` thay vì ZN
- Với Number: có thể dùng cả `IFNULL([Field], 0)` hoặc `ZN([Field])`

IN thuộc tập giá trị `IN` kiểm tra xem một giá trị có nằm trong một danh sách hay không, ngắn gọn hơn nhiều `OR` liên tiếp:

```
// Thay vì:
[Region] = "East" OR [Region] = "West" OR [Region] = "Central"

// Dùng IN:
[Region] IN ("East", "West", "Central")
// Kết quả:  True nếu Region bằng bất kỳ giá trị nào trong danh sách
```

`IN` cũng dùng được với Sets trong Tableau: `[Customer] IN [Top 10 Customers Set]`.

IV.4. Quick Reference

Bảng dưới đây tóm tắt toàn bộ các hàm đã học, sắp xếp theo vấn đề thực tế mà bạn có thể gặp:

Data Type	Vấn đề thực tế	Hàm xử lý	Ví dụ nhanh
String	Khoảng trắng thừa	`TRIM()`, `LTRIM()`, `RTRIM()`	`TRIM([Name])`
String	Hoa/thường không nhất quán	`UPPER()`, `LOWER()`	`LOWER([Region])`
String	Trích xuất một phần	`LEFT()`, `RIGHT()`, `MID()`	`LEFT([Code], 3)`
String	Thay thế ký tự lạ	`REPLACE()`	`REPLACE([Phone], ", "")`
String	Kiểm tra chuỗi con	`CONTAINS()`, `STARTSWITH()`	`STARTSWITH([ID], "US")`
String	Tìm vị trí chuỗi con	`FIND()`	`FIND([Code], ")`
Number	Làm tròn	`ROUND()`	`ROUND([Sales], 2)`
Number	Giá trị NULL	`ZN()`	`ZN([Profit])`
Number	Trị tuyệt đối	`ABS()`	`ABS([Profit])`
Number	Hướng âm/dương	`SIGN()`	`SIGN([Profit])`
Date	Nhóm theo năm/quý/tháng	`YEAR()`, `DATEPART()`	`QUARTER([Date])`
Date	Cắt về đầu kỳ	`DATETRUNC()`	`DATETRUNC('month', [Date])`
Date	Label thân thiện	`DATENAME()`	`DATENAME('month', [Date])`
Date	Khoảng cách 2 ngày	`DATEDIFF()`	`DATEDIFF('day', [S], [E])`

Data Type	Vấn đề thực tế	Hàm xử lý	Ví dụ nhanh
Date	Ngày giờ hiện tại	`NOW()`, `TODAY()`	`TODAY()`
Data Conversion	String → Number	`FLOAT()`, `INT()`	`FLOAT([Sales_str])`
Data Conversion	String → Date	`DATE()`, `DATEPARSE()`	`DATE([Date_str])`
Data Conversion	Number → String	`STR()`	`"ID: "+ STR([ID])`
Logic	Phân loại nhiều nhánh	`IF/ELSEIF/ELSE/END`	`IF [P]>0 THEN "Lãi"...`
Logic	Phân loại theo giá trị	`CASE/WHEN/THEN/END`	`CASE [Region] WHEN ...`
Logic	Kiểm tra NULL	`ISNULL()`	`ISNULL([Customer ID])`
Logic	Thay NULL bằng default	`IFNULL()`, `ZN()`	`IFNULL([Region], "N/A")`

V. Các loại biểu đồ cơ bản trong Tableau

V.1. Giới thiệu

Một trong những kỹ năng quan trọng nhưng thường bị xem nhẹ khi làm việc với Tableau là chọn đúng loại biểu đồ cho từng **vấn đề cần phân tích**. Biểu đồ không chỉ là cách hiển thị dữ liệu, mà còn là công cụ truyền tải thông điệp. Nếu chọn sai biểu đồ, một xu hướng vốn rất rõ ràng có thể trở nên khó nhận ra, hoặc tệ hơn, khiến người xem hiểu sai dữ liệu.

Nguyên tắc quan trọng khi chọn biểu đồ là bắt đầu từ câu hỏi cần làm rõ, chứ không phải từ những trường dữ liệu đang có. Trước khi kéo bất kỳ field nào vào view, hãy tự hỏi: *"Tôi đang muốn tìm hiểu điều gì từ dữ liệu này?"* Bảng dưới đây là bảng đơn giản giúp lựa chọn loại biểu đồ phù hợp với từng dạng câu hỏi.:

Câu hỏi	Loại biểu đồ	Lý do
Danh mục nào cao nhất hoặc thấp nhất?	**Bar Chart**	Chiều dài thanh dễ so sánh
Chỉ số thay đổi theo thời gian ra sao?	**Line Chart**	Đường liên tục thể hiện xu hướng liên tục
Khối lượng tích lũy theo thời gian ra sao?	**Area Chart**	Vùng tô màu nhấn mạnh tổng khối lượng
Hai chỉ số số có mối tương quan không?	**Scatter Plot**	Vị trí điểm thể hiện mối quan hệ
Dữ liệu phân bố như thế nào?	**Histogram**	Cột tần suất cho thấy phân phối
Phân phối khác nhau giữa các nhóm?	**Box Plot**	Trung vị, IQR và outlier trong 1 hình
Cần xem giá trị chính xác?	**Text Table / Heat Map**	Bảng số liệu không mất thông tin
Dữ liệu có yếu tố địa lý?	**Maps**	Hiển thị trực quan trên bản đồ
Thành phần nào chiếm tỷ trọng lớn nhất?	**Treemap / Packed Bubbles**	Kích thước hình thể hiện tỷ trọng

Rows/Columns Shelf và Marks Card

Trong Tableau, toàn bộ quá trình xây dựng biểu đồ xoay quanh việc **kéo và thả (drag & drop)** các field vào đúng vị trí:

- **Columns shelf**: Xác định những gì hiển thị trên **trục X** (chiều ngang). Thường là Dimension hoặc Date field.
- **Rows shelf**: Xác định những gì hiển thị trên **trục Y** (chiều dọc). Thường là Measure (số liệu cần đo).
- **Marks card**: Bộ điều khiển trực quan gồm các ô **Color**, **Size**, **Label**, **Detail**, **Shape**. Kéo field vào đây để thêm lớp thông tin vào biểu đồ mà không thay đổi cấu trúc chính.

Trong phần tiếp theo, chúng ta sẽ đi qua từng loại biểu đồ theo thứu tự cố định: **khi nào dùng → cách tạo từng bước → các tùy chỉnh nâng cao phổ biến**.

V.2. Bar Chart

V.2.1. Khi nào dùng Bar Chart?

Bar Chart (biểu đồ cột) là loại biểu đồ phổ biến nhất trong phân tích kinh doanh vì lý do đơn giản: **não người rất giỏi so sánh chiều dài**. Khi bạn nhìn vào một Bar Chart, gần như ngay lập tức bạn thấy cột nào cao nhất, cột nào thấp nhất, và các cột cách nhau bao xa. Đây là lợi thế mà Pie Chart hay biểu đồ góc không có được.

Bar Chart phù hợp trong các tình huống sau: so sánh doanh thu, lợi nhuận, hay bất kỳ chỉ số nào giữa các nhóm **rời rạc** (discrete) như danh mục sản phẩm, khu vực, nhân viên, hay sản phẩm riêng lẻ. Điểm mấu chốt là các nhóm này **không có quan hệ thứ tự tự nhiên** ví dụ "Furniture" không phải đứng trước hay sau "Technology" về mặt logic. Nếu các nhóm có thứ tự thời gian (tháng 1, tháng 2...), hãy cân nhắc Line Chart.

V.2.2. Cách tạo Bar Chart trong Tableau

Để minh họa, chúng ta sẽ tạo biểu đồ so sánh tổng doanh thu (`Sales`) theo danh mục sản phẩm (`Category`).

Bước 1: Trong Data Pane, tìm `Category` trong nhóm Dimensions (Dimensions là các field màu xanh dương, chứa dữ liệu văn bản/phân loại). Kéo `Category` vào **Columns shelf**.

Bước 2: Tìm `Sales` trong nhóm Measures (màu xanh lá, chứa dữ liệu số). Kéo `Sales` vào **Rows shelf**.

Ngay lập tức, Tableau tự động tạo một **Bar Chart** với trục X là `Category` , và tổng doanh thu `SUM(Sales)` trên trục Y. Tableau tự động áp dụng hàm `SUM` vì đây là Measure.

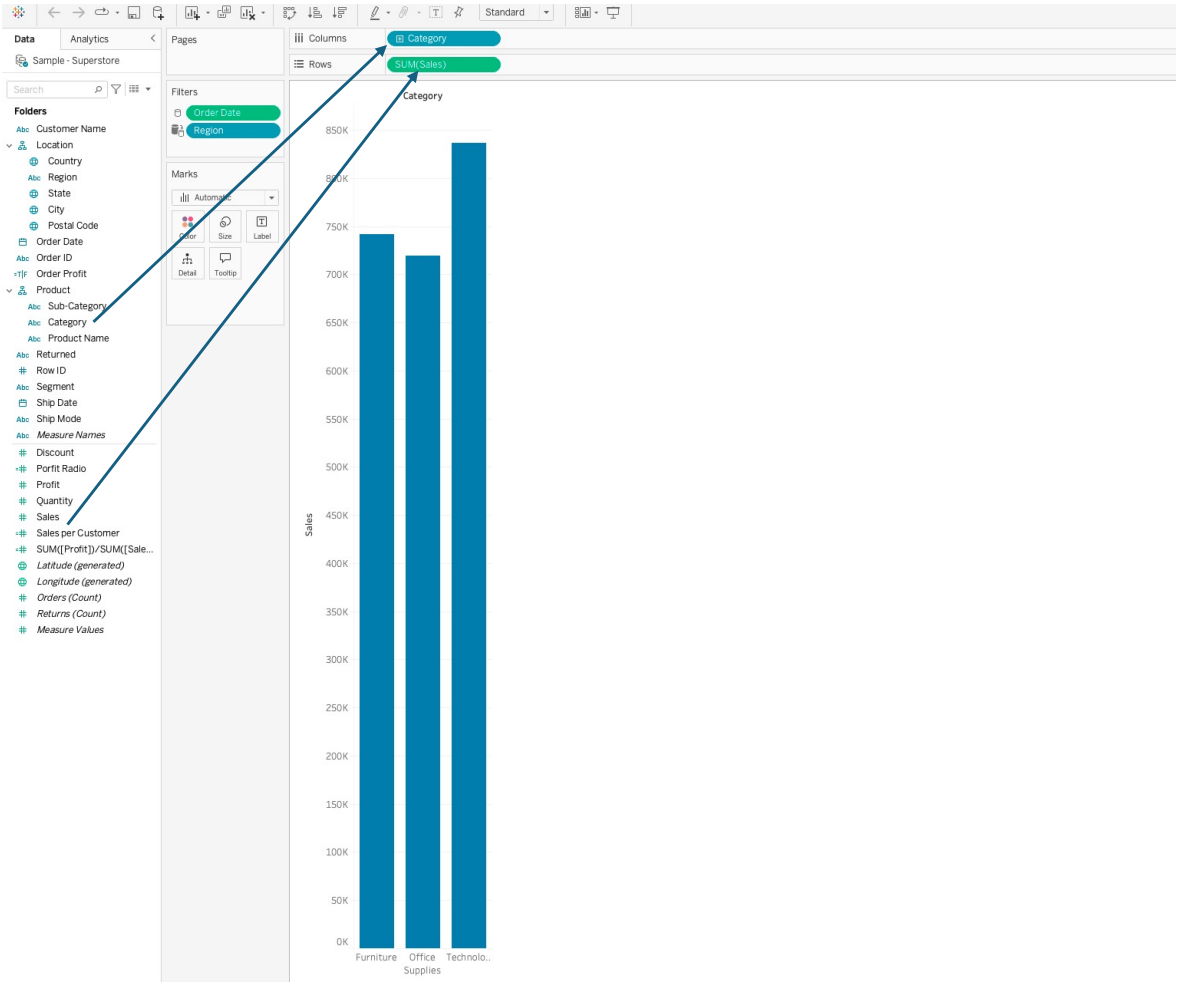

Hình 6: Bar Chart Sales by Category.

Bước 3: Sắp xếp biểu đồ từ cao đến thấp giúp người xem ngay lập tức thấy danh mục nào đứng đầu mà không cần quét qua toàn bộ biểu đồ. Tableau cung cấp 4 phương pháp sắp xếp khác nhau:

- **Cách 1: Toolbar sort button:** Nhấp vào biểu tượng **Sort Ascending/Descending** trên toolbar. Đây là cách nhanh nhất. Tableau tự động sắp xếp Dimension dựa trên Measure đang định nghĩa trục. Khi dữ liệu được cập nhật, thứ tự sắp xếp tự động cập nhật theo.

Hình 7: Biểu tượng sort trên ToolBar.

- **Cách 2: Axis sort icon:** Di chuột lên trục số (trục X hoặc Y) một biểu tượng sắp xếp nhỏ xuất hiện cạnh tên trục. Nhấp vào đó để bật sắp xếp tự động kết quả giống Cách 1 nhưng kích hoạt từ trục thay vì toolbar.

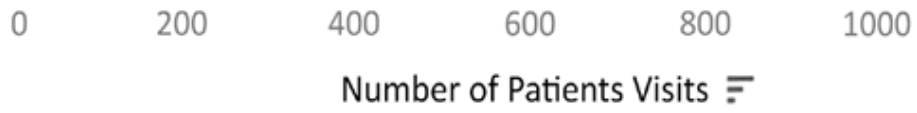

Hình 8: Axis sort icon biểu tượng sắp xếp xuất hiện trên trục khi di chuột.

- **Cách 3: Dropdown Sort menu:** Nhấp vào mũi tên bên cạnh tên Dimension trên header của biểu đồ, menu drop-down xuất hiện với 4 kiểu sắp xếp:
  - **Data source order** thứ tự trong file gốc
  - **Alphabetic** sắp xếp theo bảng chữ cái
  - **Field** sắp xếp theo Measure cụ thể (bạn chọn Measure nào)
  - **Nested** sắp xếp riêng lẻ trong mỗi Panel (khi biểu đồ có nhiều panel)

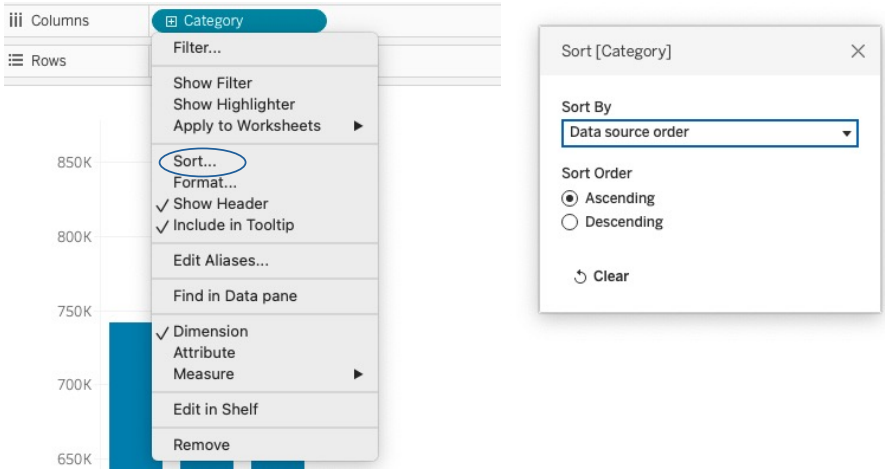

Hình 9: Dropdown Sort menu chọn Field hoặc Nested
để sắp xếp theo Measure hoặc riêng từng Panel.

- **Cách 4: Kéo thủ công (Manual sort):** Giữ và kéo các header trên biểu đồ để sắp xếp thủ công. Kết quả là sắp xếp cố định (fixed) không tự cập nhật khi dữ liệu thay đổi. Đây là cách duy nhất để định nghĩa thứ tự tùy chỉnh (ví dụ: sắp xếp theo mức ưu tiên kinh doanh, không theo con số).

Lưu ý

Mọi phương pháp sắp xếp đều **ưu tiên theo view** và ghi đè lên thứ tự mặc định trong metadata. Khi sắp xếp không còn cần, nhấp chuột phải vào field → chọn **Clear Sort** để xóa.

Bước 4: Thêm màu theo Sub-Category (nâng cao): Nếu muốn xem thêm phân rã theo danh mục con, kéo `Sub-Category` vào ô **Color** trong Marks card. Tableau tự động phân màu các điểm dữ liệu, biến biểu đồ thành **Stacked Bar Chart** mỗi cột được chia thành nhiều màu ứng với từng Sub-Category. Lúc này mỗi cột đại diện cho tổng doanh thu của một Category, các segment màu bên trong cho biết từng Sub-Category đóng góp bao nhiêu vào tổng đó.

V.2.3. Stacked Bar Chart và Percent of Total

Nếu muốn xem thêm phân rã theo danh mục con, kéo `Sub-Category` vào ô **Color** trong Marks card. Tableau tự động phân màu các điểm dữ liệu, biến biểu đồ thành **Stacked Bar Chart** mỗi cột được chia thành nhiều màu ứng với từng Sub-Category. Lúc này mỗi cột đại diện cho tổng doanh thu của một Category, các segment màu bên trong cho biết từng Sub-Category đóng góp bao nhiêu vào tổng đó.
Ngoài Stacked Bar Chart thông thường (giá trị tuyệt đối), một biến thể rất hữu ích là **Stacked Bar Chart 100%** -mỗi cột đều có chiều cao bằng nhau (= 100%) và các segment màu thể hiện **tỷ lệ phần trăm** đóng góp của từng danh mục con. Loại biểu đồ này trả lời câu hỏi *"Cơ cấu nội bộ của mỗi Category như thế nào?"* thay vì *"Category nào bán được nhiều nhất?"*.

Để tạo Stacked Bar 100%, sau khi đã có Stacked Bar Chart thông thường, thực hiện như sau:Nhấp chuột phải vào `SUM(Sales)` trên Rows shelf → chọn **Quick Table Calculation** → chọn **Percent of Total**. Tableau tính lại giá trị, mỗi segment bây giờ hiển thị tỷ lệ phần trăm thay vì giá trị tuyệt đối. Cần chỉ định **Compute Using** → **Cell** để Tableau hiểu tỷ lệ phần trăm được tính trong phạm vi mỗi Category (không phải toàn bộ dataset).

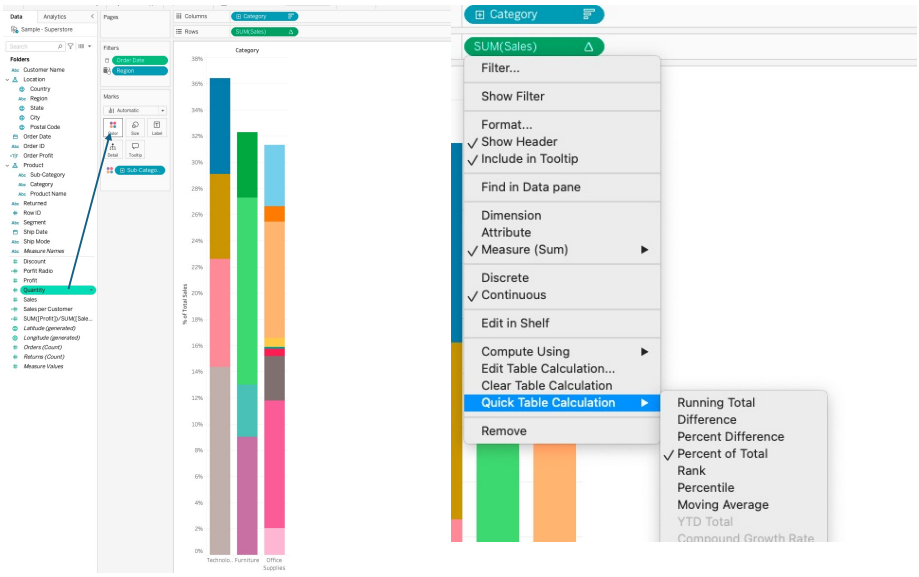

Hình 10: Stacked Bar Chart 3 cột với chiều cao bằng nhau, mỗi cột chia nhiều màu thể hiện tỷ trọng % của từng Sub-Category trong từng Category,cực kỳ hữu ích khi so sánh cơ cấu sản phẩm giữa các phân khúc thị trường.

Chuyển sang Horizontal Bar Chart

Khi tên danh mục quá dài (ví dụ tên sản phẩm đầy đủ), biểu đồ cột đứng sẽ bị chồng chéo nhãn. Giải pháp: nhấp **Ctrl + W** (hoặc vào menu **Analysis → Swap Rows and Columns**) để đổi trục, biến thành Horizontal Bar Chart. Cột ngang thoải mái hơn cho tên dài và giúp mắt đọc từ trái sang phải tự nhiên hơn.

V.3. Line Chart

V.3.1. Khi nào dùng Line Chart?

Line Chart dùng để trả lời câu hỏi **"Chỉ số này thay đổi như thế nào theo thời gian?"** Đường kẻ nối các điểm dữ liệu liên tiếp tạo ra một nội dung trực quan, giúp người xem tức thì nhận ra xu hướng tăng, giảm, hay dao động theo mùa. Đây là điều mà Bar Chart không thể làm tốt, nếu trục X là 12 tháng liên tiếp cùng một biến, Bar Chart cho 12 cột rời rạc khó nhận ra xu hướng, trong khi Line Chart cho một đường rõ ràng.

Tuy nhiên, có một nguyên tắc quan trọng cần nhớ: **chỉ dùng Line Chart khi trục X là thời gian hoặc một dãy số có thứ tự liên tục**. Dùng Line Chart cho dữ liệu phân loại rời rạc (ví dụ như các khu vực địa lý: "North", "South", "East", "West") là sai về mặt thống kê vì đường nối giữa các danh mục này không mang ý nghĩa thực sự.

V.3.2. Cách tạo Line Chart trong Tableau

Chúng ta sẽ tạo biểu đồ theo dõi xu hướng doanh thu theo từng tháng trong Superstore.

Bước 1: Kéo field `Order Date` vào **Columns shelf**. Tableau nhận đây là Date field và tự động hiển thị `YEAR(Order Date)`, tổng hợp theo năm. Bạn sẽ thấy trên biểu đồ các điểm dữ liệu rời rạc theo năm, chưa phải Line Chart.

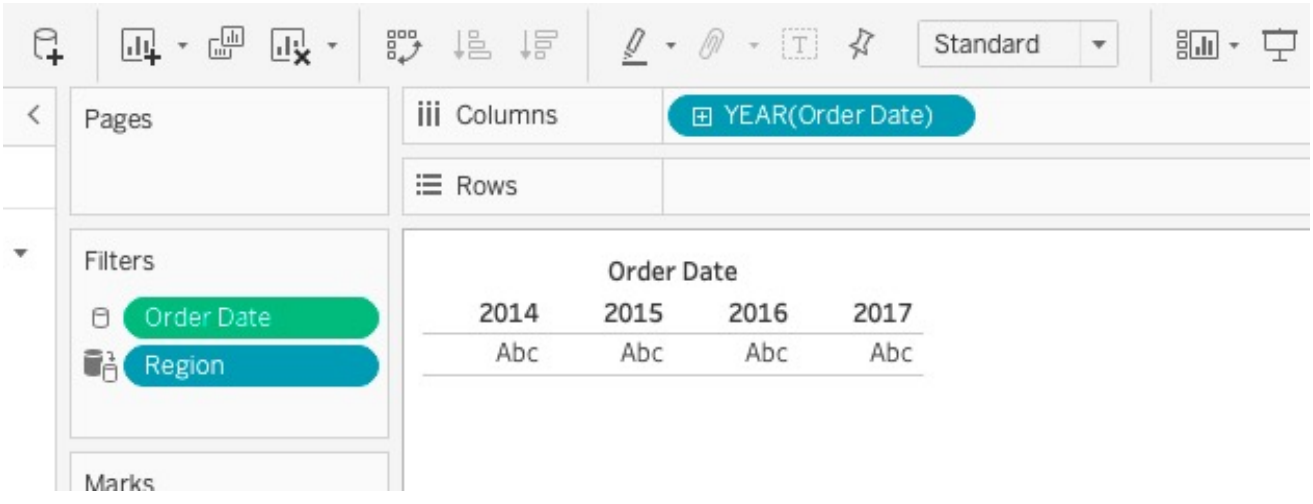

Hình 11: Order Date hiển thị điểm dữ liệu rời rạc.

Bước 2: Kéo field `Sales` vào **Rows shelf**. Lúc này Tableau đã có đủ thông tin: trục X là Date và trục Y là Measure số, nên tự động chuyển sang **Line Chart**.

Bước 3 Drill down từ Năm xuống Tháng: Hiện tại biểu đồ chỉ hiển thị theo năm quá thô để thấy xu hướng mùa vụ. Để xem chi tiết hơn, nhấp chuột phải vào `YEAR(Order Date)` đang hiển thị trên Columns shelf. Trong menu hiện ra, bạn thấy **2 nhóm tùy chọn** (tách biệt bởi đường kẻ ngang):

- Nhóm **trên** (Discrete): trả về nhãn dạng header rời rạc
- Nhóm **dưới** (Continuous): trả về trục liên tục theo thời gian

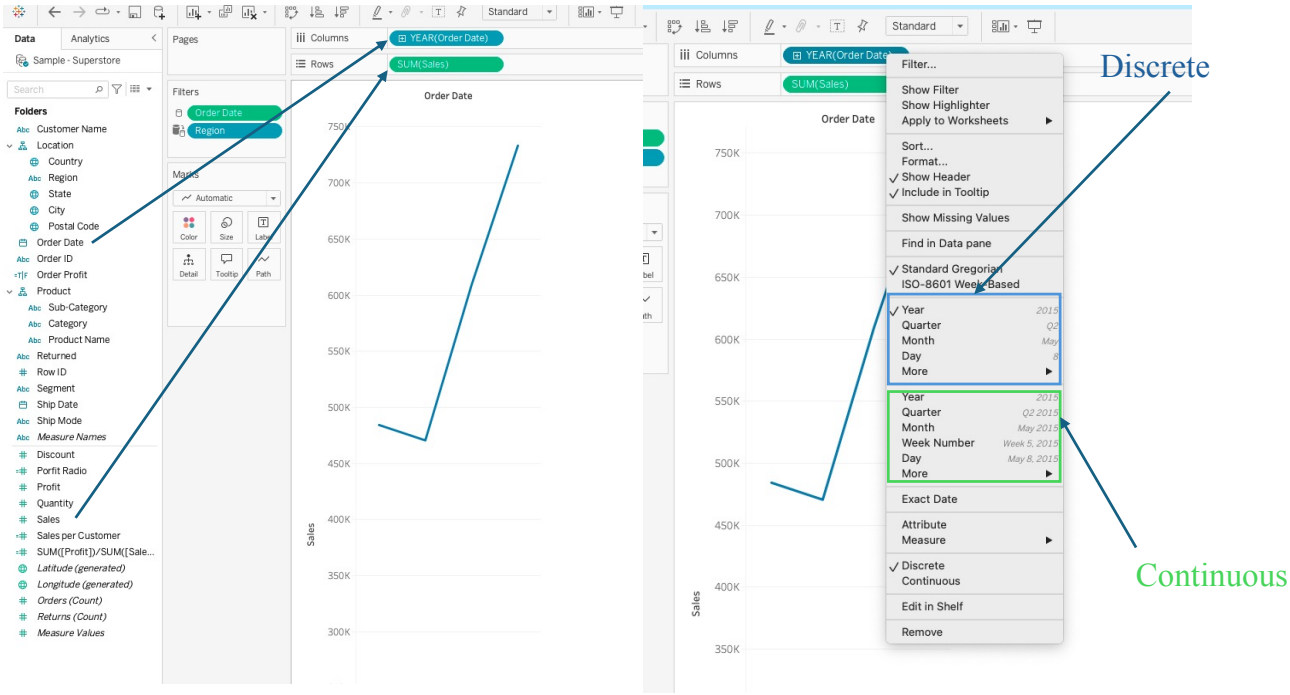

Hình 12: Line chart và Menu chọn Discrete vs Continuous Date:
hai nhóm tùy chọn khi nhấp chuột phải vào Date Order.

Chọn `Month` trong nhóm **dưới** (Continuous). Biểu đồ sẽ chuyển từ hiển thị theo năm sang theo từng tháng với trục thời gian liên tục, đường kẻ trở nên chi tiết và mượt hơn.

Bước 4 Thêm nhiều đường để so sánh: Kéo `Category` vào ô **Color** trong Marks card. Tableau sẽ vẽ **3 đường riêng biệt** mỗi đường cho mỗi Category, phân biệt bằng màu sắc. Bây giờ chúng ta có thể so sánh xu hướng doanh thu của Furniture vs Office Supplies vs Technology theo cùng trục thời gian.

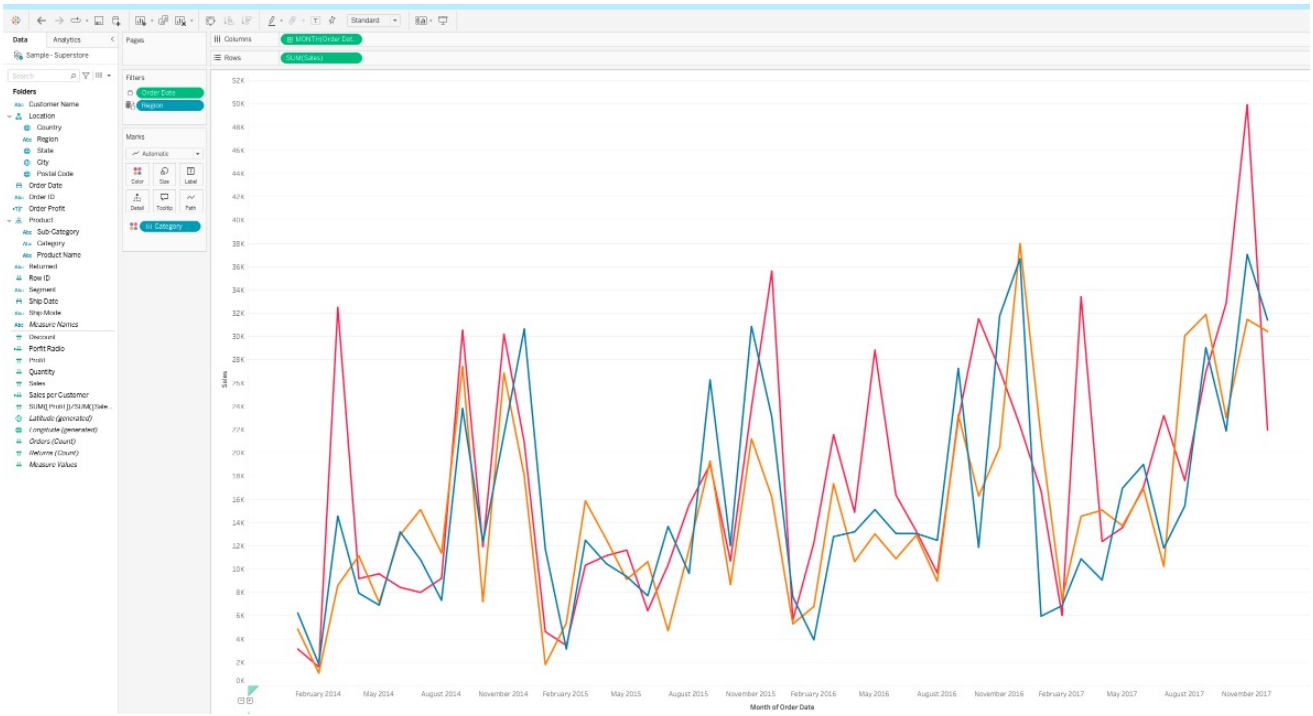

Hình 13: Line Chart Danh thu theo Order Date(Continuous Months), so sánh từng Category

V.3.3. Discrete vs Continuous Date Hiểu đúng để tạo biểu đồ thời gian chính xác

Khi làm việc với dữ liệu thời gian trong Tableau, một khái niệm rất quan trọng là sự khác biệt giữa **Discrete Date** và **Continuous Date**. Hai cách hiển thị này không chỉ khác nhau về màu trên trường thông tin (xanh dương hoặc xanh lá), mà còn ảnh hưởng trực tiếp đến cách Tableau sắp xếp dữ liệu trên trục thời gian.

Discrete Date (màu xanh dương)	**Continuous Date (màu xanh lá)**
Mỗi giá trị thời gian tạo thành một **header riêng biệt**	Toàn bộ thời gian nằm trên một **trục số liên tục**
Hiển thị như các nhãn rời rạc	Hiển thị như một timeline liên tục
`YEAR(Date)` → 2022 | 2023 | 2024	`YEAR(Date)` → trục từ 2022 đến 2024
`MONTH(Date)` → Jan, Feb, Mar ... Dec	`MONTH(Date)` → timeline theo từng tháng
Phù hợp để **so sánh từng mốc thời gian**	Phù hợp để **phân tích xu hướng theo thời gian**

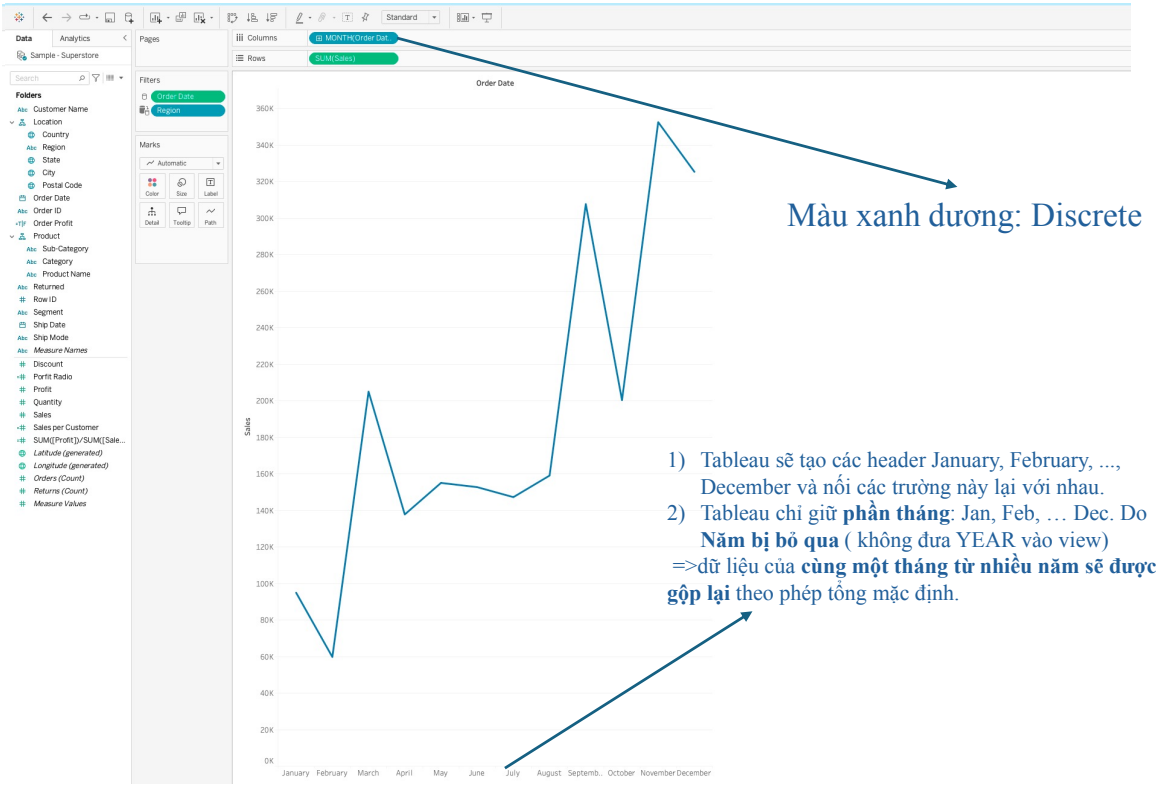

Hình 14: Discrete Line Chart

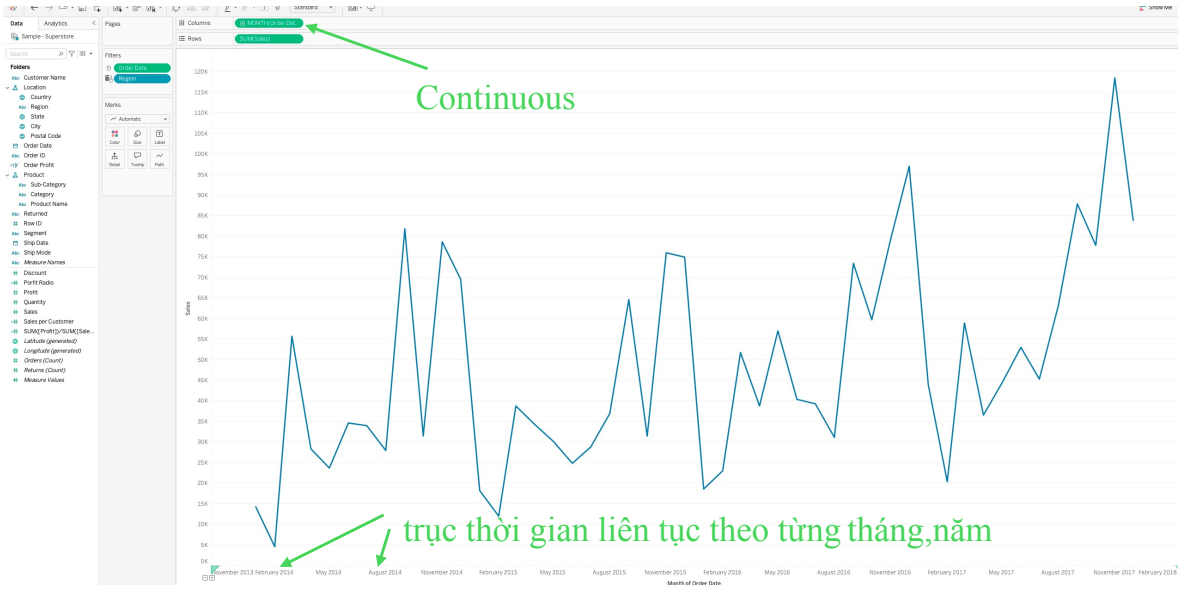

Hình 15: Discrete Line Chart

Lưu ý

Quy tắc

- Phân tích xu hướng theo thời gian (Line Chart) nên dùng **Continuous date**
- So sánh các mốc thời gian rời rạc (ví dụ bảng theo năm hoặc tháng) dùng **Discrete date**
- Nếu biểu đồ thời gian hiển thị không đúng như mong muốn, hãy kiểm tra xem trường ngày đang ở dạng Discrete hay Continuous.

V.4. Area Chart

V.4.1. Khi nào dùng Area Chart?

Area Chart thực chất là **Line Chart với vùng dưới đường được tô màu**. Sự khác biệt tuy đơn giản nhưng mang ý nghĩa quan trọng: Line Chart nhấn mạnh **xu hướng** (lên hay xuống), còn Area Chart nhấn mạnh **khối lượng tích lũy** (tổng giá trị qua thời gian).

V.4.2. Cách tạo Area Chart trong Tableau

Bước 1: Kéo `Order Date` vào **Columns**. Nhấp chuột phải → chọn **Month** (Continuous) trong nhóm dưới để có trục thời gian liên tục.

Bước 2: Kéo `Sales` vào **Rows**. Tableau tạo Line Chart mặc định.

Bước 3 Chuyển sang Area Chart: Trong **Marks card**, nhấp vào dropdown **Mark Type** (đang hiển thị "Automatic" hoặc "Line") → chọn **Area**. Vùng dưới đường kẻ lập tức được tô màu, biểu đồ bây giờ nhấn mạnh tổng khối lượng bán hàng tích lũy.

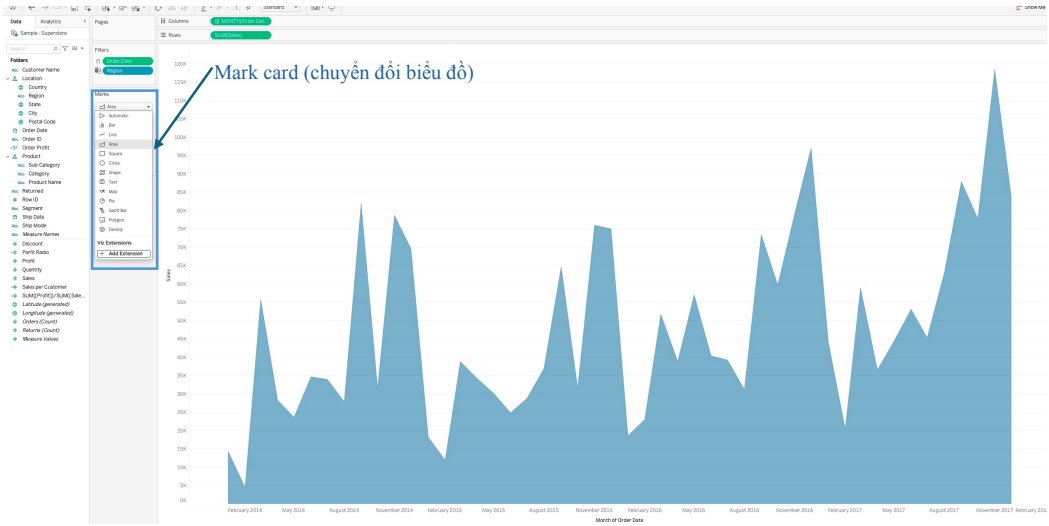

Hình 16: Area Chart

Bước 4 Stacked Area Chart: Kéo `Category` vào ô **Color** trong Marks card. Tableau tạo 3 vùng màu xếp chồng (stacked)theo `Category`. Mỗi vùng thể hiện phần đóng góp của Category đó vào tổng doanh thu. Vùng phía trên cùng chính là tổng doanh thu toàn công ty.

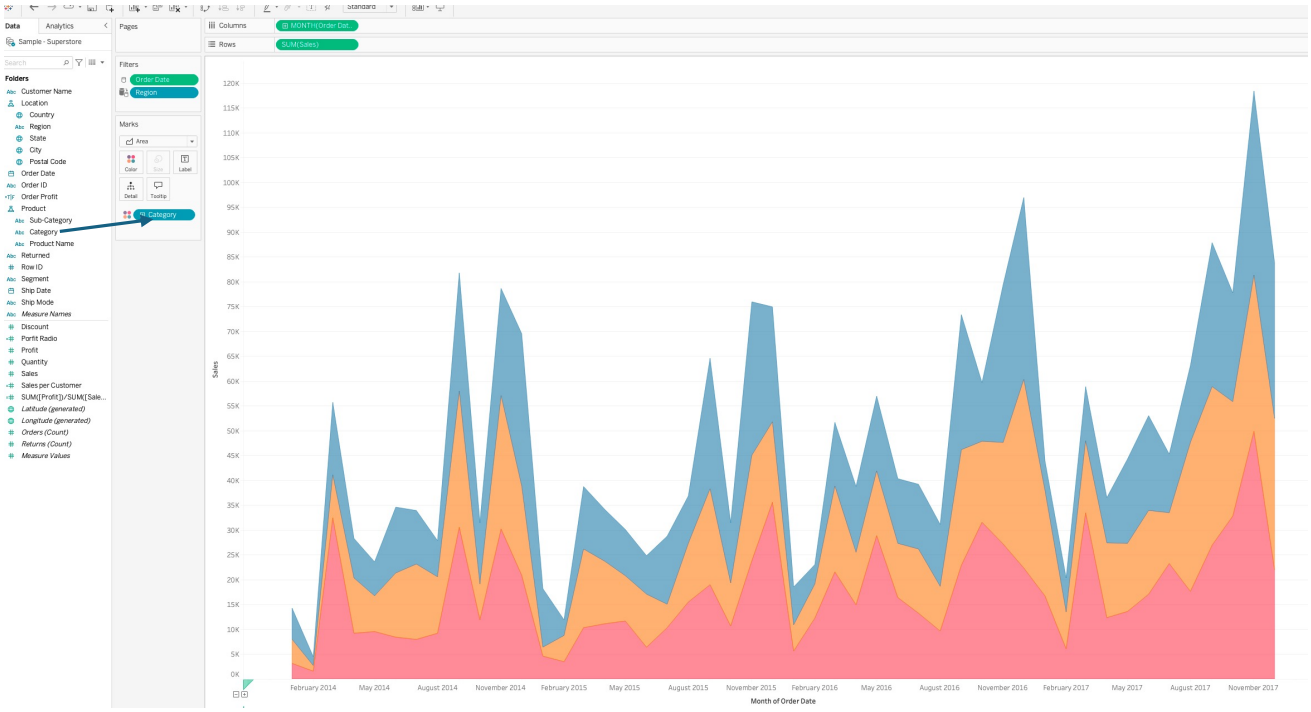

Hình 17: Stacked Area Chart

Area Chart vs Line Chart: khi nào chọn cái nào?

Tiêu chí	Line Chart	Area Chart
Mục đích chính	Xu hướng	Khối lượng / tỷ trọng
Nhiều nhóm	Dễ đọc (đường tách biệt)	Khó đọc nếu $>$ 4 nhóm (vùng chồng lấp)
Giá trị âm	Hiển thị tốt	Khó diễn giải khi tô màu vùng âm
Stacked	Không hỗ trợ	Mạnh thể hiện phần đóng góp

Quy tắc nhanh: Nếu chỉ cần xem xu hướng → Line. Nếu muốn thấy "miếng bánh" thay đổi theo thời gian → Stacked Area.

Lưu ý

Stacked Area có thể gây hiểu lầm. Trong Stacked Area, vùng trên cùng bị đẩy lên bởi các vùng bên dưới. Điều này có nghĩa **đường biên trên của một vùng KHÔNG phải là giá trị thực** của nhóm đó mà là tổng tích lũy. Nếu người đọc không hiểu điều này, họ sẽ đánh giá sai kích thước vùng trên cùng. Giải pháp: dùng **Percent of Total Stacked Area** (nhấp chuột phải vào `SUM(Sales)` → Quick Table Calculation → Percent of Total) khi muốn so sánh tỷ trọng thay vì giá trị tuyệt đối.

V.5. Scatter Plot Tương quan giữa hai chỉ số

V.5.1. Khi nào dùng Scatter Plot?

Scatter Plot (biểu đồ phân tán) là công cụ lý tưởng để trả lời câu hỏi: **"Hai chỉ số này có liên quan với nhau không?"** Mỗi điểm trên Scatter Plot đại diện cho một cá thể (sản phẩm, khách hàng, đơn hàng...) với vị trí trên trục X xác định bởi chỉ số thứ nhất và trục Y bởi chỉ số thứ hai. Nếu các điểm tập trung theo một đường chéo từ dưới-trái lên trên-phải, hai chỉ số có **tương quan thuận** (cái này tăng thì cái kia cũng tăng). Nếu ngược lại, chúng có **tương quan nghịch**.

Loại tương quan	Mô tả đám mây điểm	Ý nghĩa
Positive	Điểm từ dưới-trái lên trên-phải	Một biến tăng → biến kia cũng tăng. VD: Sales tăng đi cùng Profit tăng
Negative	Điểm từ trên-trái xuống dưới-phải	Một biến tăng → biến kia giảm. VD: Discount cao đi cùng Profit thấp
No relation	Điểm rải đều không theo hướng nào	Hai biến độc lập nhau

Scatter Plot có thể giúp trả lời những câu hỏi kinh doanh quan trọng: Các sản phẩm bán nhiều (`Sales` cao) có mang lại lợi nhuận cao (`Profit` cao) không? Hay có những sản phẩm "bán chạy nhưng lỗ" mà ta cần loại bỏ? Ngoài ra, Scatter Plot cũng giúp phát hiện **outliers** cần làm rõ.

V.5.2. Cách tạo Scatter Plot trong Tableau

Bước 1: Kéo `Sales` (Measure) vào **Columns shelf** đây sẽl à trục X.

Bước 2: Kéo `Profit` (Measure) vào **Rows shelf** đây sẽ là trục Y.

Ngay lúc này, Tableau hiển thị **chỉ 1 điểm duy nhất** ở giữa canvas. Tableau đang hiển thị `SUM(Sales)` và `SUM(Profit)` của **toàn bộ dataset** gộp lại thành một con số tổng, nên chỉ có 1 điểm. Biểu đồ này chưa có ý nghĩa phân tích.

Bước 3 Bước quan trọng nhất: Kéo `Sub-Category` vào ô **Detail** trong Marks card. Tableau hiểu rằng bây giờ chúng ta muốn nhìn từng **Sub-Category riêng** thay vì tổng hợp tất cả. Ngay lập tức, 1 điểm biến thành **nhiều điểm** mỗi điểm là một Sub-Category với tọa độ `(SUM(Sales), SUM(Profit))` của riêng nó.

Bước 4 Thêm màu và kích thước: Kéo `Category` vào **Color** để phân biệt 3 nhóm lớn bằng màu. Kéo `Quantity` vào **Size** để kích thước điểm phản ánh số lượng bán ra điểm to = bán nhiều đơn. Lúc này mỗi điểm mang 4 chiều thông tin: Sales (trục X), Profit (trục Y), Category (màu), Quantity (kích thước).

Hình 18: Scatter Plot

Bước 5 Thêm tứ phân vị (nếu cần): Vào menu **Analysis** → **Add Reference Line**. Chọn **Average** cho trục X và tương tự cho trục Y. Hai đường trung bình tạo thành 4 góc phần tư (quadrant) giúp phân loại các Sub-Category

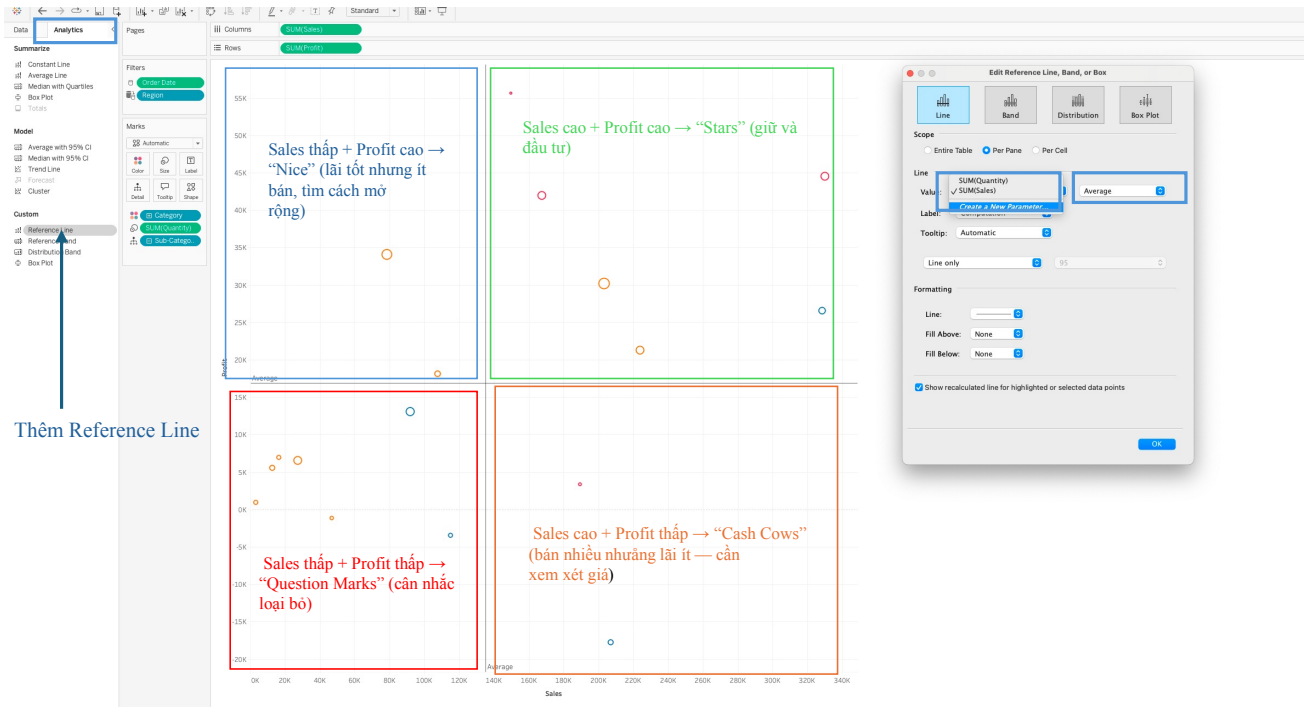

Hình 19: Scatter Plot

V.5.3. Highlighter

Khi Scatter Plot có nhiều điểm dữ liệu (hàng chục Sub-Category hoặc hàng trăm sản phẩm), rất khó nhìn ra một điểm cụ thể giữa đám mây. **Highlighter** là giải pháp: nó cho phép gõ tên để tô sáng tức thì các điểm liên quan trong khi làm mờ phần còn lại, giúp so sánh ad-hoc một cách trực quan.

Cách bật Highlighter: Nhấp chuột phải vào một Dimension field trong Marks card → chọn **Show Highlighter**. Một ô tìm kiếm nhỏ xuất hiện góc trên bên phải của biểu đồ. Khi bạn gõ, các điểm khớp với tìm kiếm sẽ được tô sáng ngay lập tức ví dụ gõ "Furniture" sẽ làm nổi bật toàn bộ điểm thuộc Sub-Category Furniture trong tất cả các điểm trên dashboard.

V.6. Histogram

V.6.1. Khi nào dùng Histogram?

Histogram trả lời câu hỏi: *"Dữ liệu phân bố như thế nào?"* đa số đơn hàng rơi vào khoảng giá nào? Có bao nhiêu kích thước đơn hàng rất lớn so với trung bình? **Histogram trông giống Bar Chart nhưng khác biệt cơ bản**: Bar Chart so sánh giữa các **danh mục rời rạc** (Furniture vs Technology), còn Histogram chia một **biến liên tục** thành các khoảng (bins) và đếm số lượng rơi vào từng khoảng.

Dùng Histogram khi:

- Muốn hiểu hình dạng phân phối của dữ liệu (chuông, lệch phải, đa đỉnh...)
- Muốn nhận ra **outlier** (giá trị bất thường) một cách trực quan
- Muốn biết **đa số** dữ liệu rơi vào khoảng nào (VD: đa số đơn hàng có giá $0 -$500)

V.6.2. Cách tạo Histogram trong Tableau

Cách 1 Dùng Show Me (nhanh nhất):

1. Trong Data Pane, nhấp chọn field `Sales` (hoặc bất kỳ Measure nào muốn xem phân phối).
2. Nhấp **Show Me** (góc trên bên phải) → chọn biểu tượng **Histogram** (hình các cột liền kề nhau). Tableau tự động tạo **Bin** và hiển thị Histogram hoàn chỉnh.

Cách 2 Tạo thủ công (kiểm soát bin size):

1. Trong Data Pane, nhấp chuột phải vào `Sales` → **Create** → **Bins...**
2. Tableau gợi ý **Bin Size** tự động (dựa trên range của dữ liệu). Bạn có thể chỉnh lại ví dụ: đặt Bin Size = **200** nghĩa là mỗi cột đại diện cho khoảng $200 (0–200, 200–400, 400–600...).

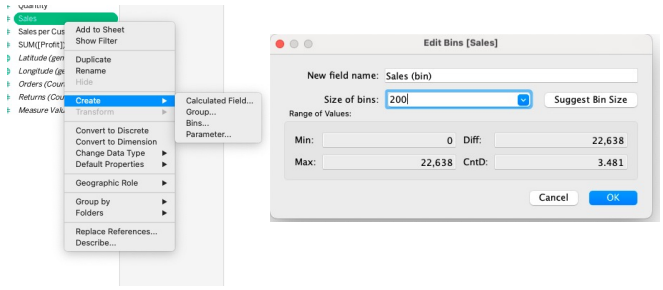

Hình 20: Create Bin Histogram

3. Trong Data Pane xuất hiện field mới `Sales (bin)` (icon giống Dimension kèm ký hiệu bin). Kéo `Sales (bin)` vào **Columns shelf**.
4. Kéo `Sales` vào **Rows shelf** → nhấp chuột phải → chọn **Measure (Count)** hoặc **CNT(Sales)**. Lúc này Histogram hoàn chỉnh: trục X là khoảng giá, trục Y là số lượng đơn hàng.

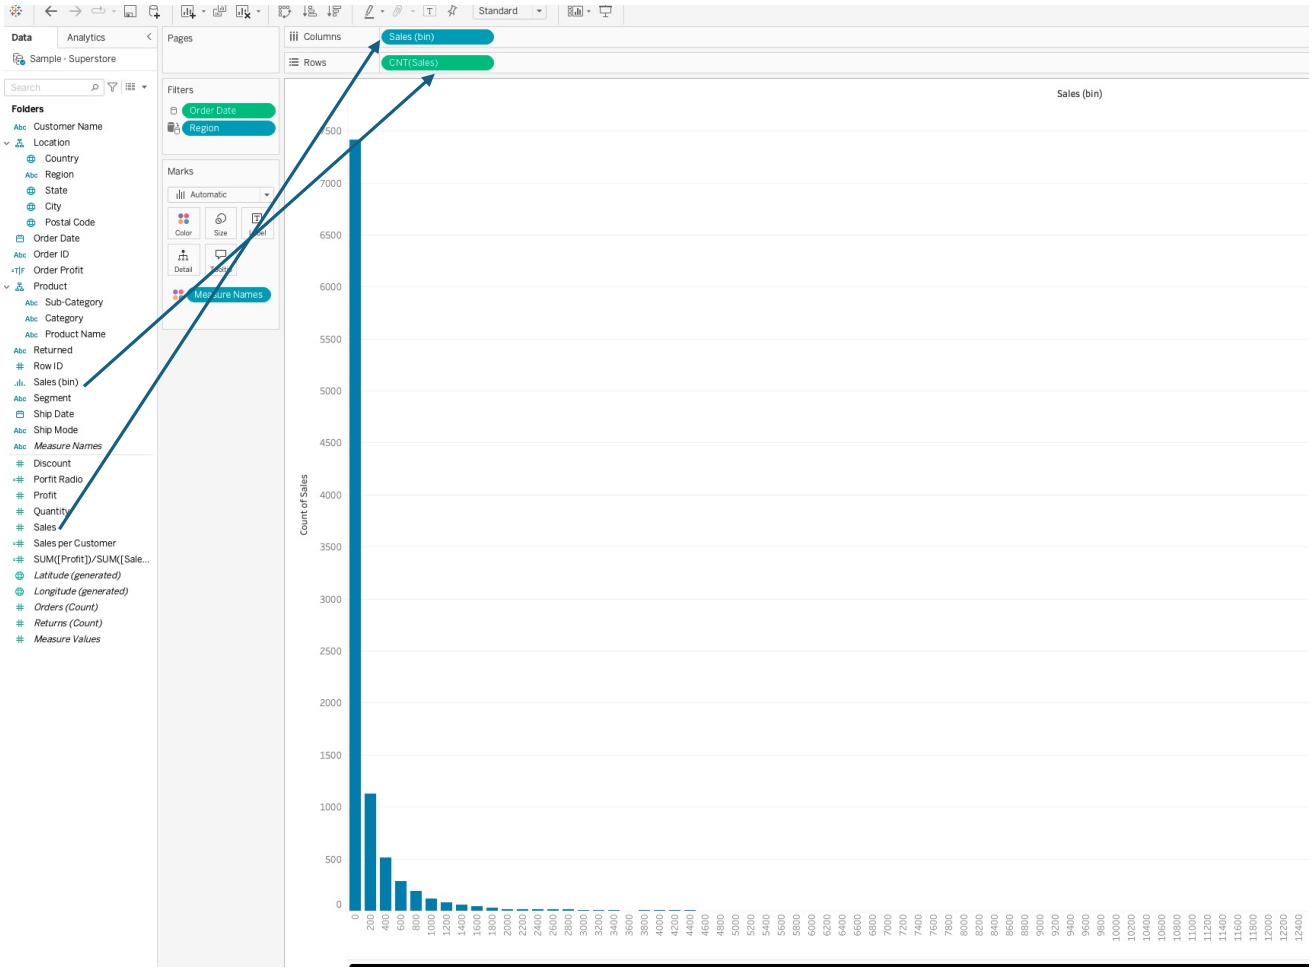

Hình 21: Create Histogram Chart

Chọn Bin Size phù hợp

Bin Size quá nhỏ → biểu đồ rối, khó thấy pattern. Bin Size quá lớn → mất chi tiết, mọi thứ dồn vào 2–3 cột. Quy tắc thực tế: bắt đầu với Bin Size mặc định của Tableau, sau đó thử tăng/giảm để tìm mức hiển thị rõ nhất hình dạng phân phối. Để chỉnh lại: nhấp chuột phải vào `Sales (bin)` trong Data Pane → **Edit...**

Lưu ý

Khác biệt Bar Chart vs Histogram:

	Bar Chart	**Histogram**
Trục X	Danh mục rời rạc (Category)	Khoảng liên tục (Bins)
Khoảng cách cột	Có gap giữa các cột	Không có gap (liền kề)
Ý nghĩa	So sánh giá trị giữa nhóm	Phân phối / tần suất

V.7. Box Plot (Box & Whisker)

V.7.1. Khi nào dùng Box Plot?

Box Plot (đôi khi gọi là Box & Whisker) là công cụ thống kê để **so sánh phân phối của một chỉ số giữa nhiều nhóm** ví dụ: mức Discount trung bình và độ biến động giữa các Region khác nhau như thế nào? Box Plot nén 5 thông tin thống kê vào 1 hình: **trung vị (median)**, **tứ phân vị 1 và 3 (Q1, Q3)**, **râu (whiskers)**, và **outlier**.

Dùng Box Plot khi:

- Muốn so sánh **độ phân tán** của dữ liệu giữa nhiều nhóm (ví dụ: Profit distribution theo Category)
- Muốn nhận ra **outlier** (giá trị nằm ngoài râu) các điểm bất thường cần điều tra
- Muốn biết **giá trị điển hình** (median) và **độ biến động** (IQR = Q3 – Q1) của mỗi nhóm

V.7.2. Cách tạo Box Plot trong Tableau

Bước 1: Kéo `Region` (Dimension) vào **Columns shelf** tạo các nhóm để so sánh.

Bước 2: Kéo `Discount` (Measure) vào **Rows shelf**. Tableau mặc định tạo Bar Chart với `SUM(Discount)`.

Bước 3 Tăng độ chi tiết: Kéo `Sub-Category` (hoặc bất kỳ Dimension nào có nhiều giá trị) vào ô **Detail** trong Marks card. Khi đó Tableau không còn gộp dữ liệu theo `Category` nữa, mà mỗi `Sub-Category` sẽ trở thành một điểm dữ liệu riêng trên biểu đồ.

Bước 4 Chuyển sang Box Plot: Nhấp **Show Me** → chọn **Box-and-Whisker Plot**. Tableau tự động tính toán median, Q1/Q3, và vẽ râu + outlier.

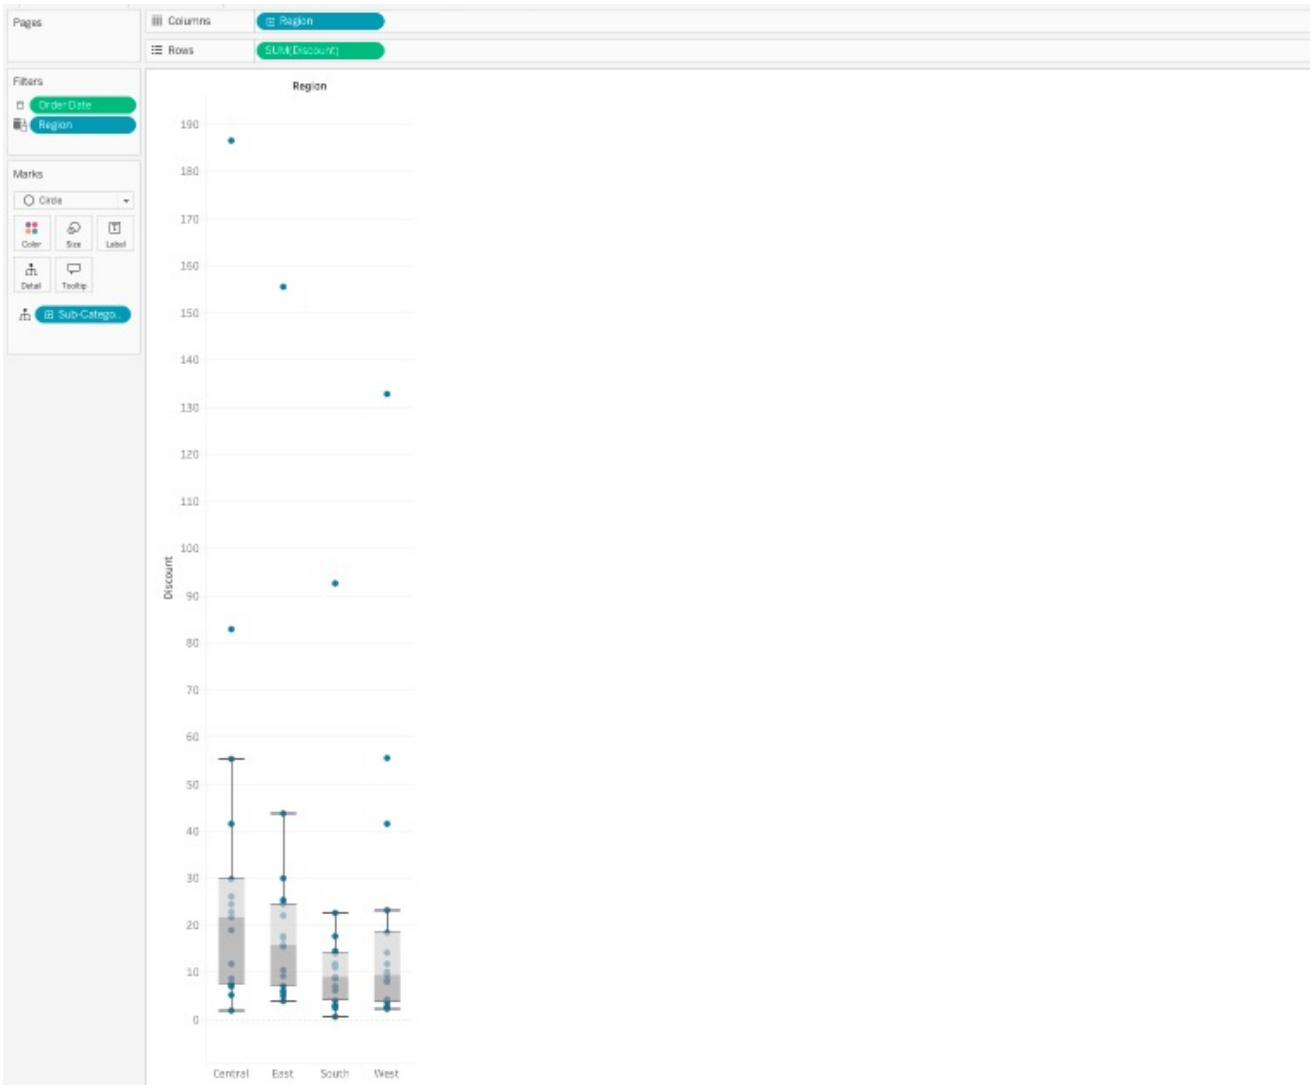

Hình 22: Create Box Plot Chart

V.7.3. Đọc hiểu Box Plot

Thành phần	Ý nghĩa
Đường nằm ngang trong hộp	**Median** giá trị trung vị (50% dữ liệu trên, 50% dưới)
Cạnh dưới hộp	**Q1** (Quartile 1) 25% dữ liệu nằm dưới mức này
Cạnh trên hộp	**Q3** (Quartile 3) 75% dữ liệu nằm dưới mức này
Chiều cao hộp (IQR)	**Q3** − **Q1** càng cao = dữ liệu càng phân tán
Râu (whiskers)	Mở rộng đến giá trị xa nhất trong khoảng 1.5 × IQR
Điểm riêng lẻ (outlier)	Giá trị nằm ngoài râu **bất thường**, cần xem xét

Tùy chỉnh hiển thị outlier

Mặc định Tableau hiển thị outlier như các điểm tròn nhỏ. Để tùy chỉnh: nhấp chuột phải vào trục Y → **Edit Reference Line** → thay đổi **Whisker** và **Outlier** style. Bạn có thể ẩn outlier hoặc đổi màu để nhấn mạnh.

V.8. Text Table, Heat Map & Highlight Table

V.8.1. Khi nào dùng Text Table?

Text Table (còn được gọi là Crosstab hay Pivot Table) là đúng tên gọi nó không vẽ hình mà chỉ hiển thị **con số cụ thể theo bảng**. Đây là lựa chọn phù hợp khi người đọc cần **tra cứu hoặc so sánh giá trị chính xác** .Ví dụ"Doanh thu của Furniture trong năm 2023 là bao nhiêu?" là câu hỏi mà Bar Chart hay Line Chart không trả lời được trực tiếp, nhưng Text Table thì có.

Tuy nhiên, Text Table cũng có nhược điểm đáng kể: rất khó nhận ra xu hướng, khó so sánh giữa nhiều con số cùng lúc, và trở nên khó đọc khi có nhiều hàng/cột. Do đó **chỉ dùng Text Table khi người xem thực sự cần con số chính xác**. Với hầu hết mục đích trình bày và phân tích xu hướng, các loại biểu đồ trực quan (Bar, Line, Area, Scatter...) sẽ hiệu quả hơn.

V.8.2. Cách tạo Text Table trong Tableau

Chúng ta sẽ tạo bảng thể hiện doanh thu (`Sales`) phân theo `Category` (hàng) và năm (cột).

Bước 1: Kéo `Category` vào **Rows**. Tableau tạo 3 hàng Furniture, Office Supplies, Technology.

Bước 2: Kéo `Order Date` vào **Columns**. Tableau mặc định tổng hợp theo `YEAR(Order Date)`, tạo ra các cột theo từng năm trong dataset.

Bước 3: Kéo `Sales` vào ô **Text** trong Marks card (không phải Rows/Columns). Tableau điền giá trị `SUM(Sales)` vào từng ô, mỗi ô là tổng doanh thu của một Category trong một năm cụ thể.

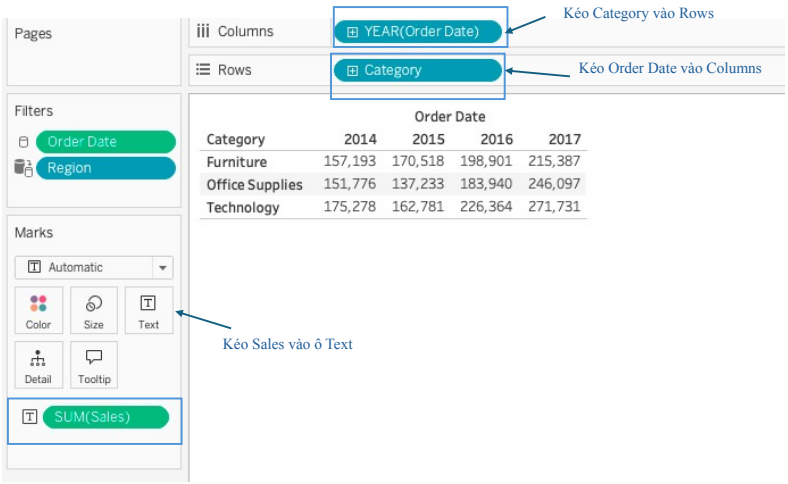

Hình 23: Create Text Table

Bước 4 Định dạng số để dễ đọc: Con số mặc định Tableau hiển thị dạng thô `"1234567.89"` khó đọc. Để định dạng, nhấp chuột phải vào `SUM(Sales)` trong Marks card, chọn **Format...**. Trong panel Format bên trái, chọn **Numbers** → **Currency (Custom)** → bật **"Include thousands separators"**. Lúc này số hiển thị dạng `"$1,234,567.89"`,dễ đọc hơn.

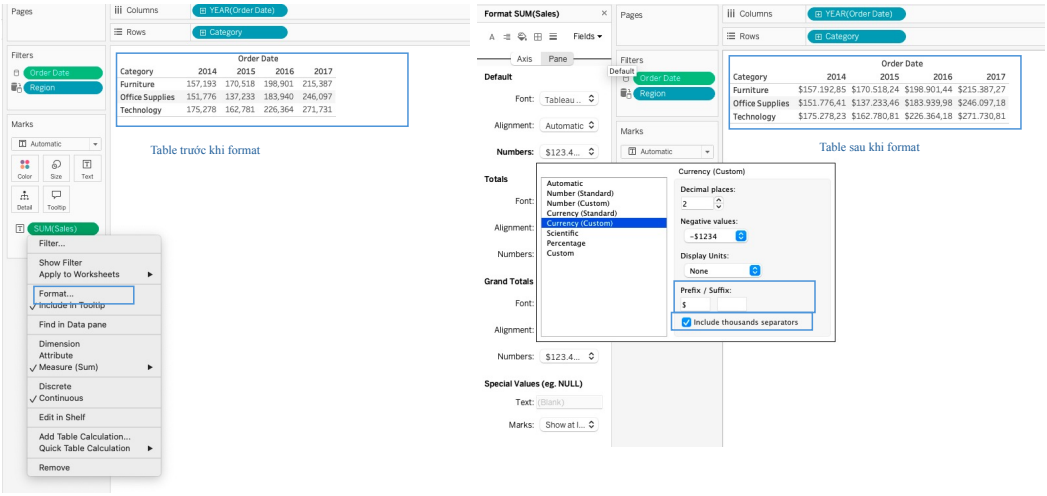

Hình 24: Format Number Text Table

Bước 5 Nâng cấp thành Highlight Table: Một biến thể mạnh mẽ hơn của Text Table là **Highlight Table** giữ nguyên con số nhưng **thêm màu nền** gradient từ nhạt (giá trị thấp) đến đậm (giá trị cao), giúp mắt ngay lập tức nhận ra ô nào có giá trị cao/thấp mà không cần đọc từng con số. Để tạo Highlight Table: kéo thêm `Sales` vào ô **Color** trong Marks card (bên cạnh `Sales` đã có ở Text), sau đó chuyển Mark type từ **Automatic** sang **Square** trong dropdown đầu Marks card.

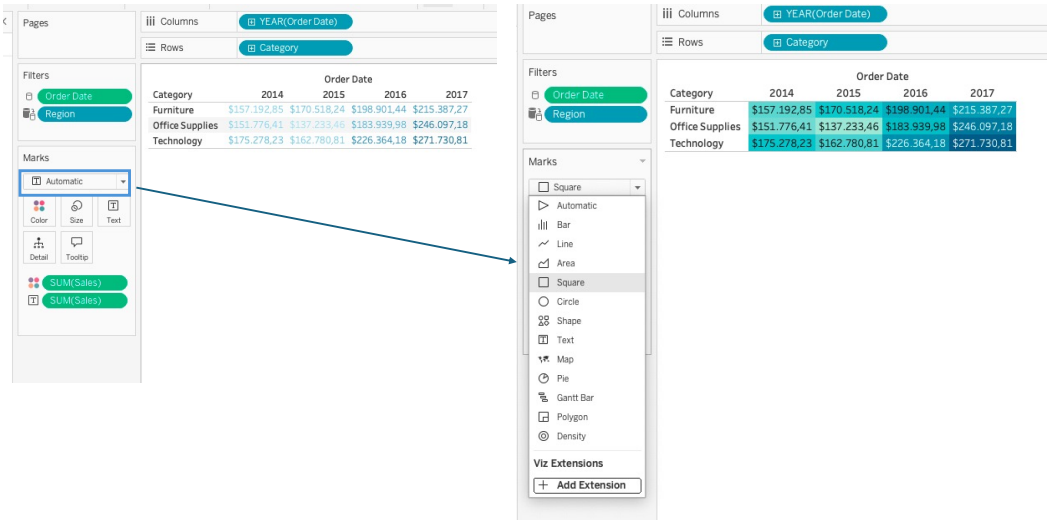

Hình 25: Format Number Text Table

V.8.3. Heat Map Không cần số, chỉ cần màu

Heat Map là biến thể cực đoan hơn của Highlight Table: **bỏ hết con số, chỉ giữ màu sắc**. Mỗi ô trong lưới được tô màu từ nhạt đến đậm dựa trên giá trị của Measure. Dùng khi:

- Có lưới lớn (nhiều hàng × nhiều cột) số quá nhiều sẽ rối, màu giúp quay nhanh
- Muốn nhận ra **pattern** trong dữ liệu (vùng nóng / vùng lạnh)
- Muốn trình bày cho đối tượng không quen đọc số

Cách tạo: giống Highlight Table nhưng **không kéo Measure vào Text** chỉ kéo vào **Color** và **Size** (nếu muốn ô lớn/nhỏ theo giá trị). Mark type = **Square** hoặc **Circle**.

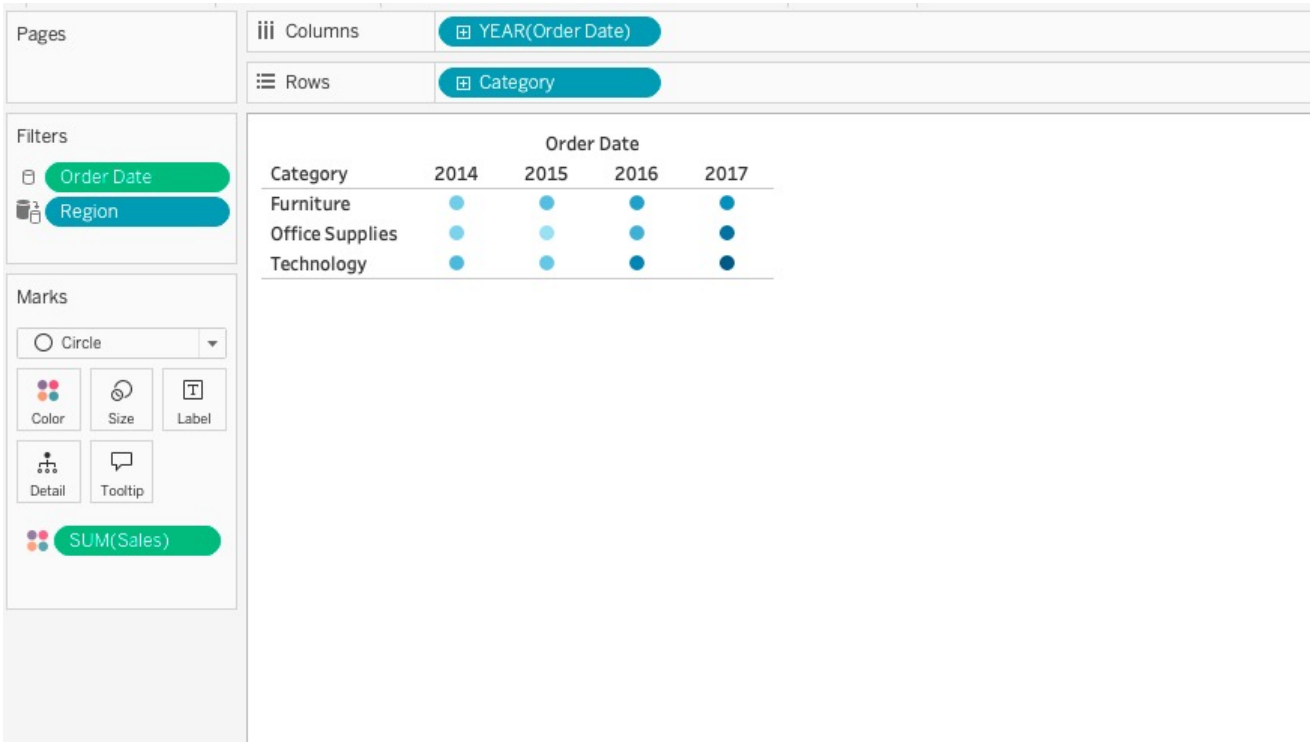

Hình 26: Format Number Text Table

Thêm Grand Total vào bảng

Để thêm hàng tổng và cột tổng vào Text Table (tương tự "Total row" trong Excel): vào menu **Analysis** → **Totals** → **Show Row Grand Totals** và **Show Column Grand Totals**. Tableau tự động tính `SUM` cho toàn bộ hàng và cột, thêm vào dưới cùng và bên phải của bảng. Rất hữu ích khi cần kiểm tra tổng doanh thu toàn công ty so với từng phân khúc.

V.9. Maps

V.9.1. Khi nào dùng Maps?

Khi dữ liệu chứa **thông tin địa lý** (Country, State, City, Postal Code), bản đồ là cách trực quan nhất để trả lời câu hỏi: *"Khu vực nào có doanh thu cao nhất? Vùng nào có nhiều khách hàng?"* Tableau tự nhận diện các field địa lý (qua icon 🌐 trong Data Pane) và tự động tạo bản đồ khi bạn sử dụng chúng.

Tableau hỗ trợ **2 loại bản đồ chính**:

Loại	Mô tả	Khi nào dùng
Symbol Map	Mỗi vị trí được đánh dấu bằng **điểm tròn** kích thước và màu thay đổi theo Measure	Dữ liệu theo điểm (thành phố, cửa hàng, khách hàng)
Filled Map	Tô màu toàn bộ **vùng** (quốc gia, bang) theo giá trị Measure	So sánh vùng/khu vực, choropleth map

V.9.2. Cách tạo Symbol Map

Bước 1: Double-click vào field `State` (hoặc bất kỳ Geographic field) trong Data Pane. Tableau tự động tạo bản đồ với các điểm đánh dấu trên từng State. Phía sau, Tableau sử dụng **Latitude (generated)** và **Longitude (generated)** để định vị.

Bước 2: Kéo `Sales` vào ô **Size** trong Marks card. Giờ các điểm có kích thước khác nhau, điểm lớn = doanh thu cao.

Bước 3: Kéo `Profit` vào ô **Color** trong Marks card. Các điểm được tô màu từ đỏ (âm / lỗ) đến xanh (dương / lãi). Lúc này bản đồ cho thấy cả **quy mô** (kích thước) và **hiệu suất** (màu) của từng State.

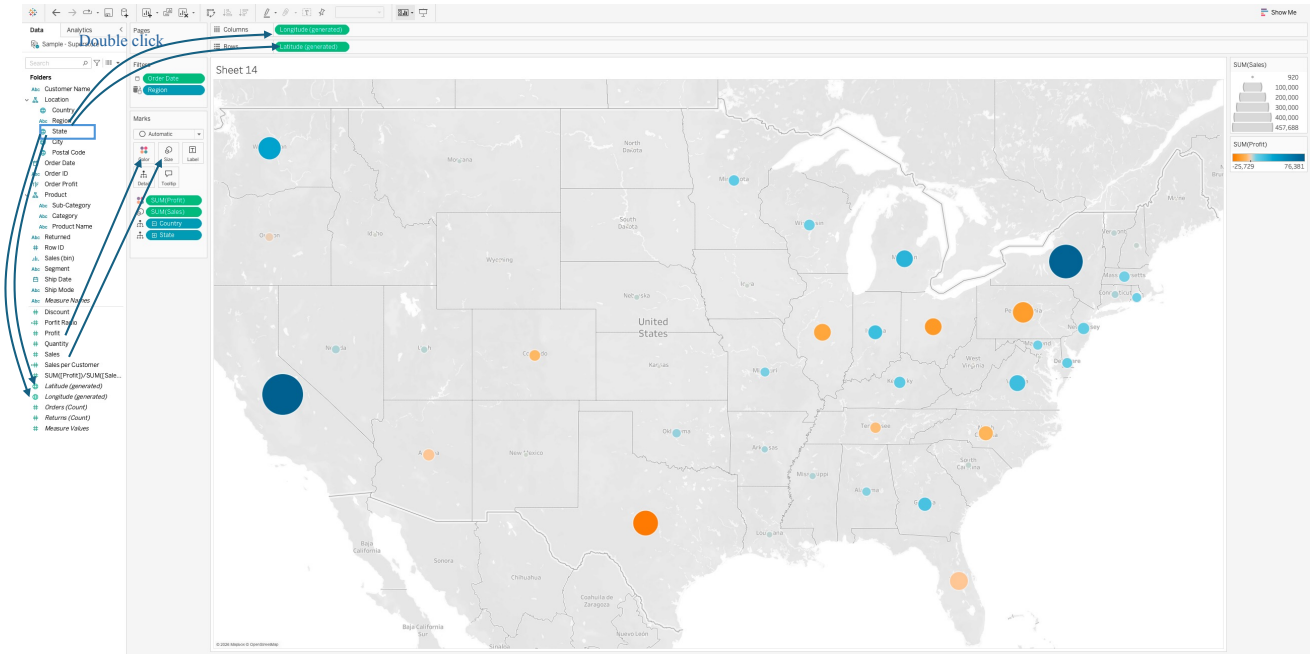

Hình 27: Create Symbol Map

V.9.3. Cách tạo Filled Map

Bước 1: Double-click vào field `State` để tạo bản đồ cơ bản.

Bước 2: Trong **Marks card**, chuyển dropdown **Mark Type** từ **Automatic** sang **Filled Map** (hoặc **Map**). Toàn bộ vùng của mỗi State được tô màu.

Bước 3: Kéo `Sales` vào **Color**. Các State có doanh thu cao sẽ có màu đậm hơn.

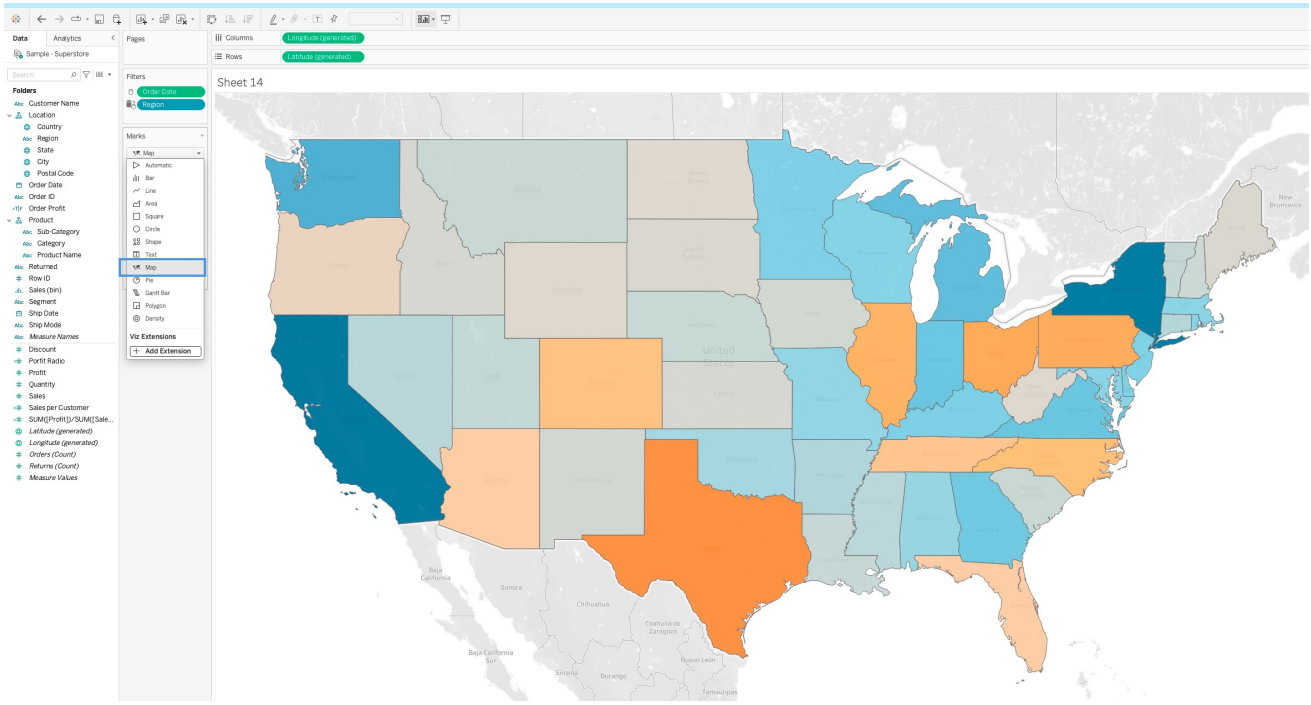

Hình 28: Create Symbol Map

Lưu ý

Xử lý vị trí không nhận được. Đôi khi Tableau không nhận ra một số địa danh góc dưới bên phải xuất hiện thông báo **"X unknown"**. Nhấp vào đó → **Edit Locations** → chỉnh sửa bằng tay (gán đúng tên quốc gia, bang/tỉnh). Với dataset Superstore (có field Country, State, City), Tableau nhận diện gần như 100% chính xác.

Symbol Map vs Filled Map: khi nào dùng cái nào?

Tiêu chí	Symbol Map	Filled Map
Phù hợp	Dữ liệu theo điểm (cửa hàng, khách hàng)	Dữ liệu theo vùng (quốc gia, bang)
Nhiều Measure	Kích thước + Màu = 2 Measure	Chỉ Màu = 1 Measure
Vùng nhỏ	Vẫn thấy rõ (điểm tròn)	Dễ bị lấp bởi vùng lớn

V.10. Tổng kết

Sau khi đã quen với cả 9 loại biểu đồ, chúng ta có thể rút gọn quy trình chọn chart thành một flow đơn giản: nhìn vào **kiểu dữ liệu** và **mục đích phân tích** để quyết định ngay.

Loại biểu đồ	Câu hỏi trả lời	Trục X cần gì	Trục Y cần gì
Bar Chart	Cái nào lớn hơn/nhỏ hơn?	Dimension	Measure
Line Chart	Xu hướng thay đổi thế nào?	Date (liên tục)	Measure
Area Chart	Khối lượng + tỷ trọng theo thời gian?	Date (liên tục)	Measure
Scatter Plot	Hai chỉ số liên quan thế nào?	Measure	Measure
Histogram	Dữ liệu phân bố như thế nào?	Bins (liên tục)	Count
Box Plot	Phân phối giữa các nhóm?	Dimension	Measure (disagg.)
Text Table	Con số chính xác? Pattern?	Dimension	Dimension
Maps	Vùng nào nổi bật?	Geographic	*(tự động)*

Bộ câu hỏi quyết định nhanh:

1. Dữ liệu có **địa lý** không? → **Maps**
2. Trục X có phải **thời gian** không?
   - Muốn xem xu hướng? → **Line Chart**
   - Muốn xem khối lượng/tỷ trọng? → **Area Chart**
3. Cả 2 trục đều là **số**? → **Scatter Plot**
4. Muốn xem **phân phối**?
   - 1 nhóm? → **Histogram**
   - Nhiều nhóm so sánh? → **Box Plot**
5. Cần **con số chính xác**? → **Text Table** (thêm màu = **Highlight Table / Heat Map**)
6. Còn lại (so sánh danh mục) → **Bar Chart**

Lưu ý

Cạm bẫy phổ biến Line Chart cho dữ liệu phân loại. Một sai lầm rất thường gặp là dùng Line Chart để so sánh các danh mục (ví dụ: 5 khu vực địa lý). Đường nối giữa "North" và "East" về mặt kỹ thuật được vẽ được, nhưng không có ý nghĩa thống kê "North" và "East" không có quan hệ liên tục. Bar Chart mới là lựa chọn đúng trong trường hợp này.

VI. Bài tập tổng hợp: Ứng dụng vẽ một số biểu đồ đơn giản trên Tableau

VI.1. Vai trò của Tableau

Tableau là một công cụ trực quan hóa dữ liệu mạnh mẽ, cho phép người dùng chuyển đổi dữ liệu thô thành các biểu đồ và hình ảnh trực quan nhằm hỗ trợ phân tích và ra quyết định. Tương tự các hệ thống trực quan hóa dữ liệu khác, Tableau giúp hiện thực hóa các ý tưởng và kế hoạch phân tích đã được xác định từ trước.

Do đó, trước khi xây dựng báo cáo, cần xác định rõ mục tiêu phân tích và phạm vi dữ liệu. Trong bài tập này, chúng ta thực hiện một báo cáo đơn giản nhằm phân tích chỉ số doanh thu theo các chiều như thời gian, không gian, ngành hàng và hình thức vận chuyển.

VI.2. Giới thiệu về dataset

Với dataset Superstore sử dụng trong bài tập, các trường dữ liệu có thể được chia thành hai nhóm chính: **Dimensions** và **Measures**.

A. Dimensions (biến phân loại / định danh)

Dimensions là các biến định tính dùng để phân nhóm, phân loại hoặc xác định đối tượng.

- **Categorical**
  - Category
  - Sub-Category
  - Segment
  - Ship Mode
- **Identifier**
  - Order ID
  - Customer ID
  - Product ID
- **Temporal**
  - Order Date
  - Ship Date
- **Spatial**
  - Country, Province

B. Measures (biến định lượng)

Measures là các biến số có thể thực hiện phép tính toán hoặc tổng hợp.

- Sales
- Profit
- Discount
- Order Quantity

VI.3. Quy trình xây dựng biểu đồ

Quy trình xây dựng biểu đồ trong Tableau thường gồm ba bước chính.

Bước 1: Xác định measure trung tâm

Trước tiên cần xác định biến định lượng chính cần phân tích, ví dụ:

- Doanh số (Sales)
- Lợi nhuận (Profit)
- Số lượng đơn hàng (Order Quantity)

Trong trường hợp measure chưa tồn tại, người dùng có thể tạo mới thông qua **Calculated Field**. Ví dụ, số lượng đơn hàng có thể được xác định bằng:

```
COUNT(Order ID)
```

Bước 2: Xây dựng biểu đồ theo mục tiêu phân tích

Sau khi xác định measure trung tâm, lựa chọn loại biểu đồ phù hợp với mục tiêu biểu diễn dữ liệu.

Lựa chọn 1: Biểu đồ đơn biến (1 measure)

Tên biểu đồ: Sales by Year

Biểu đồ này thể hiện sự thay đổi của doanh thu theo thời gian.

Cấu hình trong Tableau:

- Rows: `SUM(Sales)`
- Columns: `YEAR(Order Date)`
- Marks: Line

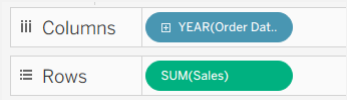

Hình 11: Cấu hình biểu đồ Sales theo YEAR(Order Date) trong Tableau.

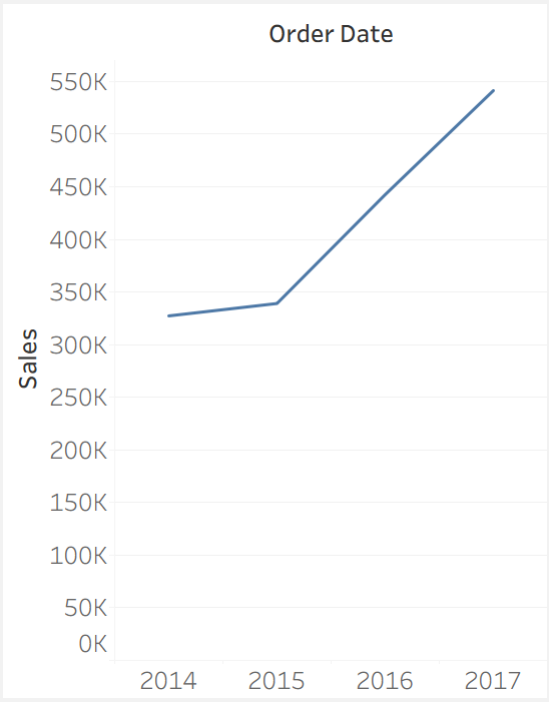

Hình 12: Biểu đồ đường thể hiện doanh thu theo năm.

Giải thích

- Biểu đồ chỉ sử dụng một measure chính là `Sales`.
- `YEAR(Order Date)` đóng vai trò là trục thời gian.
- Tableau không thực hiện so sánh giữa các nhóm đối tượng khác nhau mà chỉ thể hiện xu hướng biến động của một chỉ số theo thời gian.

Các câu hỏi phân tích có thể trả lời

Biểu đồ này giúp trả lời các câu hỏi sau:

- Doanh thu tăng hay giảm theo từng năm?
- Xu hướng tăng trưởng có ổn định hay không?
- Có tồn tại điểm thay đổi xu hướng (trend break) hay không?

Lựa chọn 2: Biểu đồ song biến (1 Measure + 1 Dimension)

Tên biểu đồ: Sales by Category

Biểu đồ này thể hiện doanh thu được phân bổ theo từng nhóm sản phẩm.
Cấu hình trong Tableau:

- Columns: `Category`
- Rows: `SUM(Sales)`
- Marks: Bar

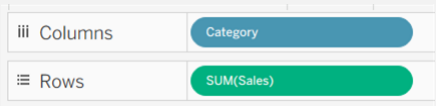

Hình 13: Cấu hình biểu đồ Sales theo Category trong Tableau.

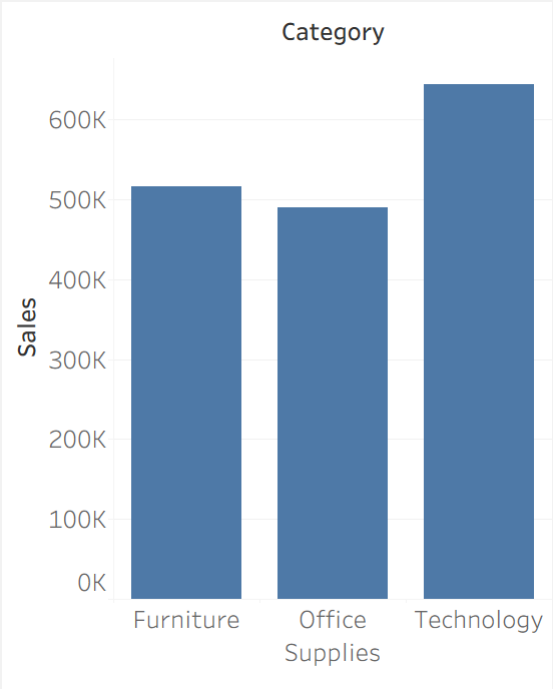

Hình 14: Biểu đồ cột thể hiện doanh thu theo nhóm sản phẩm.

Giải thích

- `Sales` là measure duy nhất được sử dụng trong biểu đồ.
- `Category` là dimension dùng để chia dữ liệu thành các nhóm khác nhau.
- Tableau sẽ tạo ra một mark (một cột) cho mỗi giá trị của `Category`.

Các câu hỏi phân tích có thể trả lời

Biểu đồ này giúp trả lời các câu hỏi sau:

- Category nào tạo ra doanh thu cao nhất?
- Chênh lệch doanh thu giữa các Category là bao nhiêu?

Lựa chọn 3: Biểu đồ song biến (2 Measure) và kết hợp Mark Cards

Tên biểu đồ: Sales vs. Profit correlation

Biểu đồ này thể hiện mối quan hệ tương quan giữa doanh thu và lợi nhuận.

Cấu hình trong Tableau

- Columns: `SUM(Profit)`
- Rows: `SUM(Sales)`
- Marks: Circle

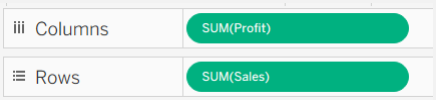

Hình 15: Cấu hình biểu đồ Sales theo Profit trong Tableau.

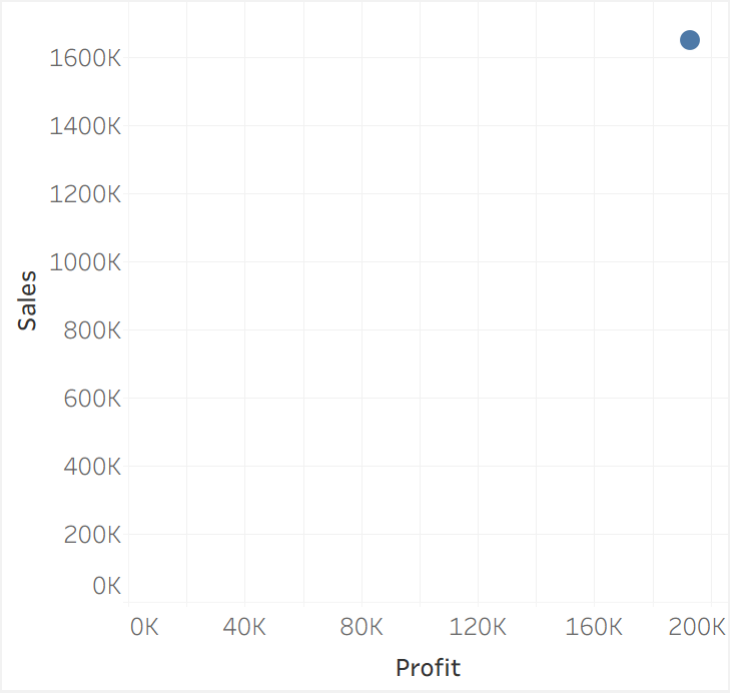

Hình 16: Biểu đồ tương quan giữa doanh thu và lợi nhuận.

Tuy nhiên ở cấu hình này Tableau chỉ tạo ra một mark duy nhất. Vì vậy biểu đồ chưa cung cấp nhiều giá trị phân tích. Để tăng mức độ chi tiết của dữ liệu, cần bổ sung thêm một dimension vào Mark Detail. Ví dụ:

- Phân tích theo từng đơn hàng: `Detail là Order ID`
- Phân tích theo từng tỉnh thành: `Detail là Province`
- Phân tích theo từng nhóm hàng: `Detail là Sub-Category`

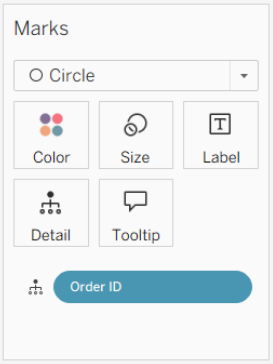

(a) Cấu hình Detail - Order ID

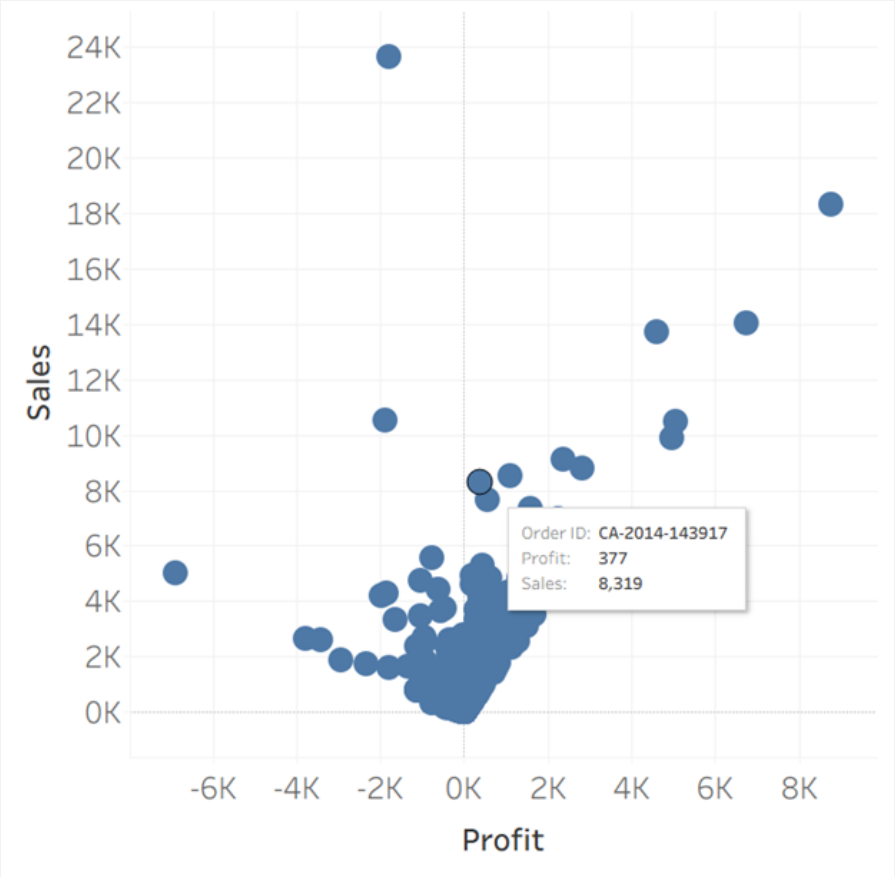

(b) Biểu đồ tương quan giữa doanh thu và lợi nhuận theo từng đơn hàng

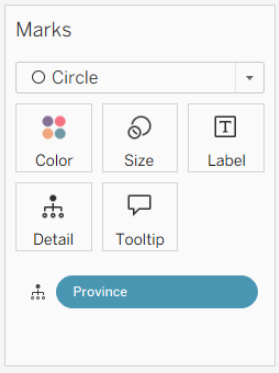

(a) Cấu hình Detail - Province

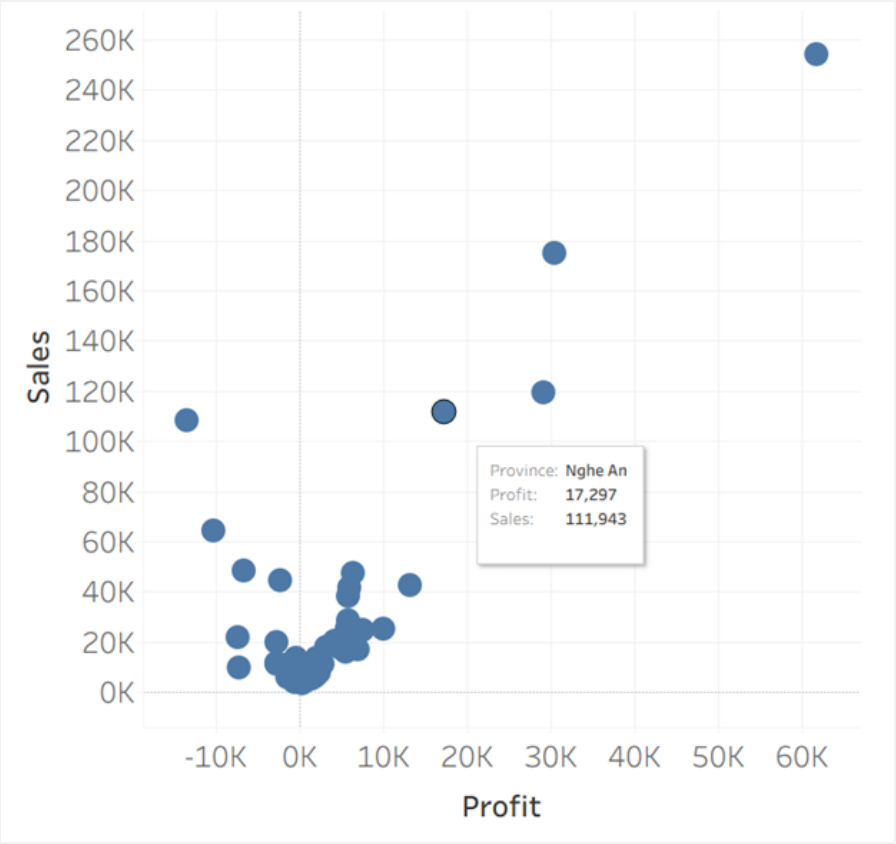

(b) Biểu đồ tương quan giữa doanh thu và lợi nhuận theo từng tỉnh thành

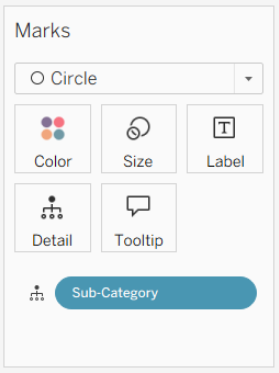

(a) Cấu hình Detail - Sub-Category

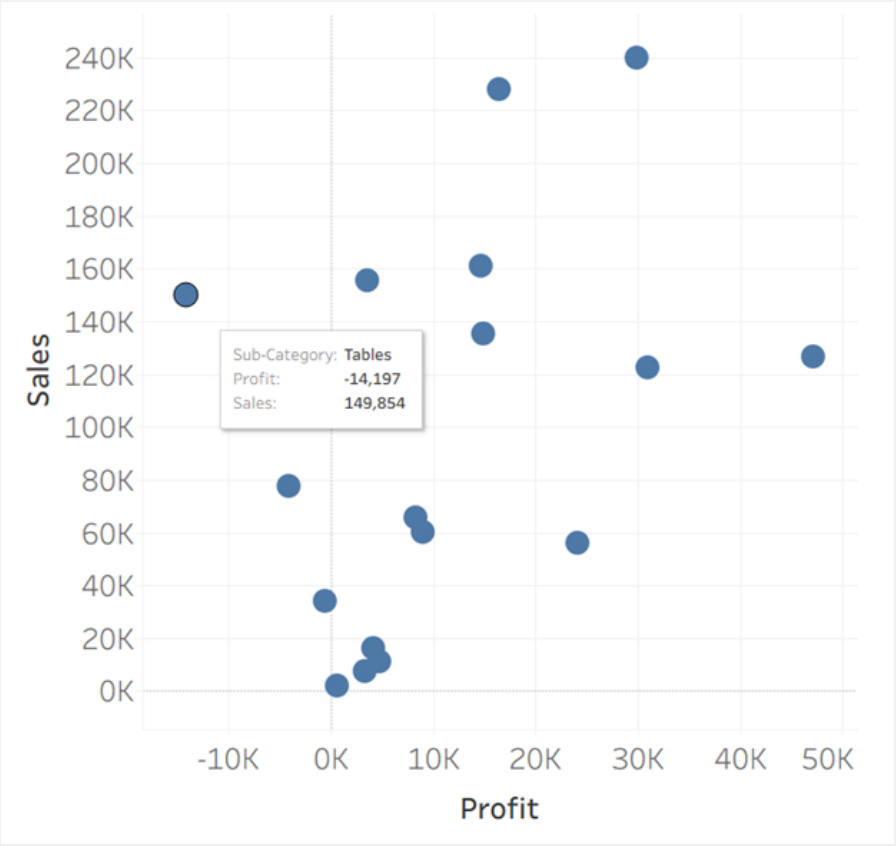

(b) Biểu đồ tương quan giữa doanh thu và lợi nhuận theo từng nhóm hàng phụ

Cấu hình trong Tableau

- Columns: `SUM(Profit)`
- Rows: `SUM(Sales)`
- Marks:
  - Type: Circle
  - Detail: `Order ID` hoặc `Province` hoặc `Sub-Category`.

Giải thích

- Hai measure `Sales` và `Profit` được mã hóa bằng vị trí của các điểm trên biểu đồ.
- `Order ID` hoặc `Province` hoặc `Sub-Category` quyết định mức độ chi tiết của dữ liệu (level of detail).
- Tableau sẽ tạo ra một mark cho mỗi giá trị của `Order ID` hoặc `Province` hoặc `Sub-Category`.

Các câu hỏi phân tích có thể trả lời

Biểu đồ này giúp trả lời các câu hỏi sau:

- Đơn hàng hoặc tỉnh thành hoặc nhóm hàng phụ nào có doanh thu cao nhưng lợi nhuận thấp?
- Có đơn hàng hoặc tỉnh thành hoặc nhóm hàng phụ nào vừa có doanh thu cao vừa có lợi nhuận cao hay không?

Lựa chọn 4: Biểu đồ song biến (2 Dimension) và kết hợp Mark Cards

Tên biểu đồ: Sales heatmap by Sub-Category and Shipping Service

Biểu đồ này thể hiện doanh thu dưới dạng bản đồ nhiệt (heatmap) dựa trên các tổ hợp của hai dimension.

Cấu hình trong Tableau:

- Columns: `Sub-Category`
- Rows: `Shipping Service`
- Marks:
  - Type: Square
  - Color: `SUM(Sales)`
  - Label: `SUM(Sales)` (hiển thị giá trị)

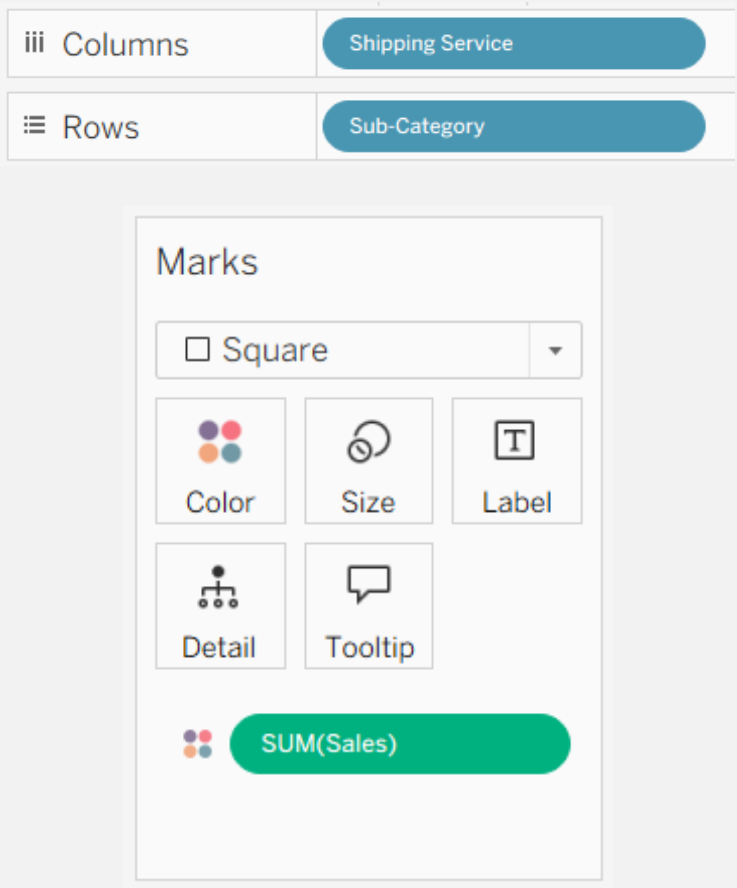

Hình 20: Cấu hình biểu đồ Sales theo Shipping Service và Sub-Category trong Tableau.

	Shipping Service			
Sub-Category	First Class	Same Day	Second Class	Standard Class
Accessories	17,996	8,235	25,774	70,649
Appliances	11,803	5,128	13,512	35,455
Art	2,351	645	2,282	11,163
Binders	23,156	4,617	15,487	91,981
Bookcases	17,007	1,261	14,006	45,518
Chairs	36,779	15,902	52,073	123,058
Copiers	37,030	4,560	12,300	72,739
Envelopes	1,507	433	1,610	7,819
Fasteners	212	67	355	1,326
Furnishings	6,426	3,452	11,750	38,706
Labels	1,199	427	1,574	4,322
Machines	17,993	14,799	21,802	100,776
Paper	8,898	2,854	11,591	32,864
Phones	40,918	6,966	44,580	147,429
Storage	18,649	5,642	34,193	102,663
Supplies	2,724	372	23,981	6,895
Tables	18,776	7,340	32,404	91,334

Hình 21: Biểu đồ nhiệt thể hiện doanh thu theo nhóm sản phẩm và dịch vụ vận chuyển.

Giải thích

- Hai dimension `Sub-Category` và `Shipping Service` xác định từng tổ hợp dữ liệu trên biểu đồ.
- Mỗi ô vuông đại diện cho một tổ hợp giữa hai dimension.
- Màu sắc của từng ô biểu diễn mức độ cao thấp của `Sales`.
- Nhãn số (Label) hiển thị giá trị cụ thể để hỗ trợ so sánh định lượng.

Các câu hỏi phân tích có thể trả lời

Biểu đồ này giúp trả lời các câu hỏi sau:

- Nhóm sản phẩm phụ nào tạo ra doanh thu cao?
- Dịch vụ vận chuyển nào được sử dụng nhiều nhất cho từng nhóm sản phẩm?

Lựa chọn 5: Bản đồ địa lý (Kinh độ và Vĩ độ) và kết hợp Mark Cards

Tên biểu đồ: Sales by Province along Vietnam

Biểu đồ này thể hiện phân bố doanh thu theo các tỉnh/thành tại Việt Nam.

Cấu hình trong Tableau

Tableau tự động nhận diện vai trò địa lý (*Geographic Role*) của trường `Province` và tạo ra kinh độ và vĩ độ tương ứng.

- Columns: Longitude (generated)
- Rows: Latitude (generated)
- Marks:
  - Size: `SUM(Sales)`
  - Detail: `Province`

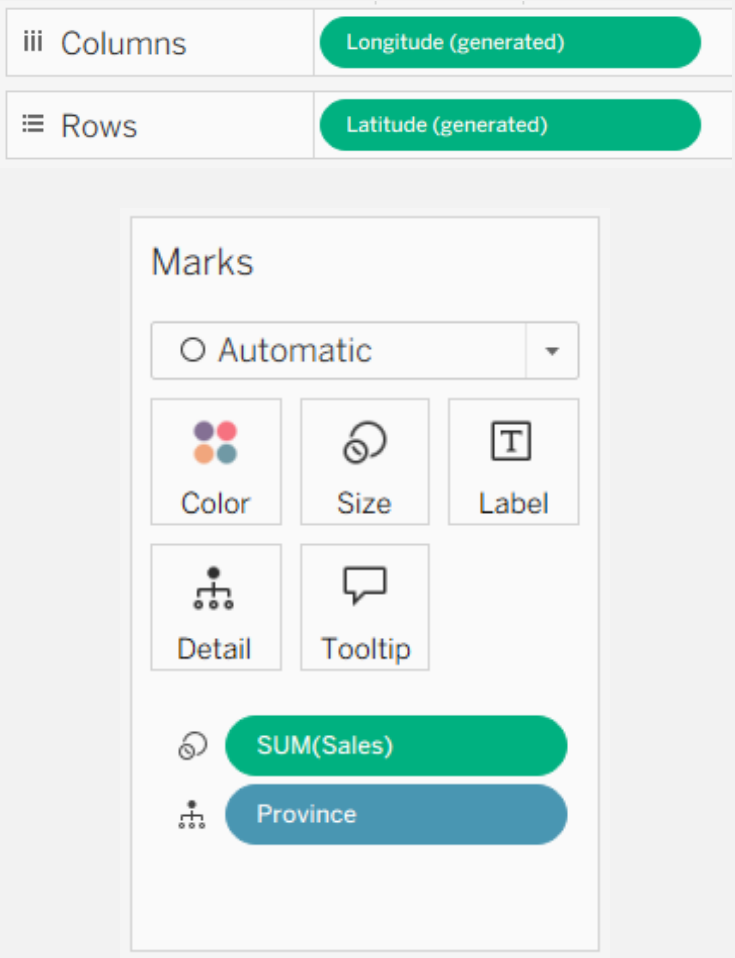

Hình 22: Cấu hình biểu đồ Sales theo Province trong Tableau.

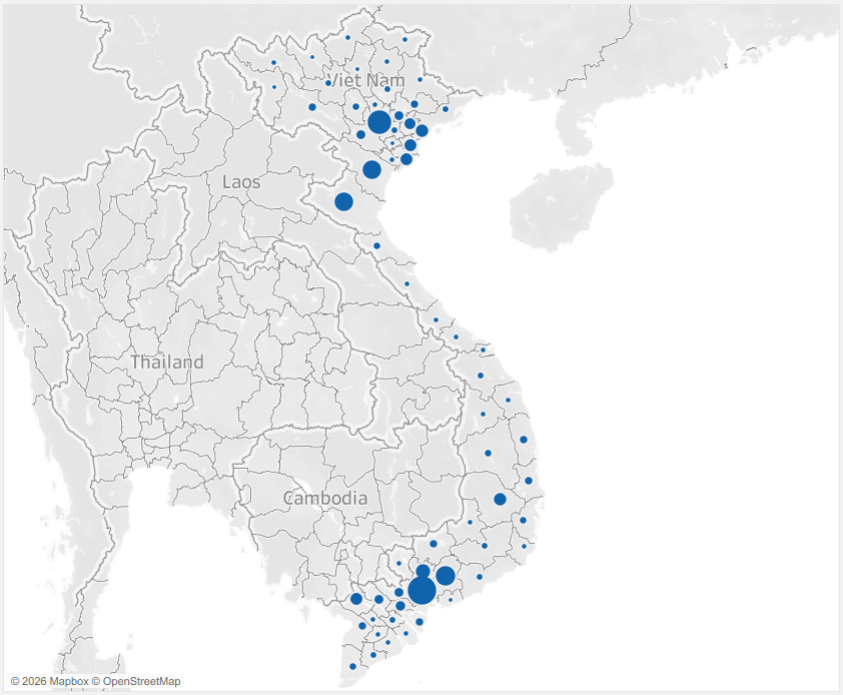

Hình 23: Biểu đồ địa lý thể hiện doanh thu theo tỉnh thành.

Giải thích

- Mỗi vòng tròn thể hiện vị trí địa lý của một tỉnh thành.
- `Province` xác định từng điểm dữ liệu trên bản đồ.
- Kích thước vòng tròn biểu diễn mức độ cao thấp của `Sales`. Vòng tròn càng lớn thì doanh thu càng cao.

Các câu hỏi phân tích có thể trả lời

Biểu đồ này giúp trả lời các câu hỏi sau:

- Tỉnh thành, khu vực nào có doanh thu cao nhất?
- Mức độ đóng góp doanh thu giữa các tỉnh thành khác nhau như thế nào?

Bước 3: Hoàn thiện về hình thức

Sau khi xác định đúng Measure, Dimension và cấu trúc biểu đồ, bước tiếp theo là hoàn thiện hình thức trình bày nhằm tăng khả năng đọc và diễn giải. Chi tiết cấu hình có trong file Tableau .twbx đi kèm bài giảng.

Hình 24: Biểu đồ đường thể hiện doanh thu theo năm.

- Đổi màu cho trục `YEAR(Order Date)`.
- Sử dụng *Line chart* kết hợp *Circle Mark* để làm nổi bật các điểm dữ liệu.
- Áp dụng dải màu thể hiện giá trị `Sales` cao thấp qua các năm.

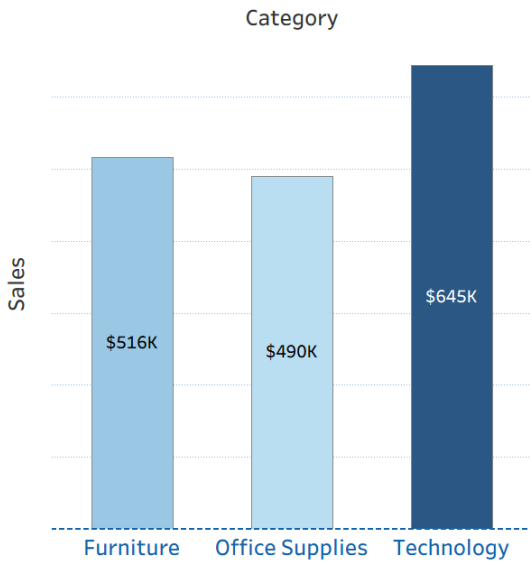

Hình 25: Biểu đồ cột thể hiện doanh thu theo nhóm sản phẩm.

- Đổi màu chữ cho trục `Category`.

- Áp dụng dải màu thể hiện giá trị `Sales` cao thấp giữa các `Category`.
- Căn chỉnh và định dạng lại giá trị `Sales`.
- Đổi màu và kiểu dáng của (*Zero Line*).

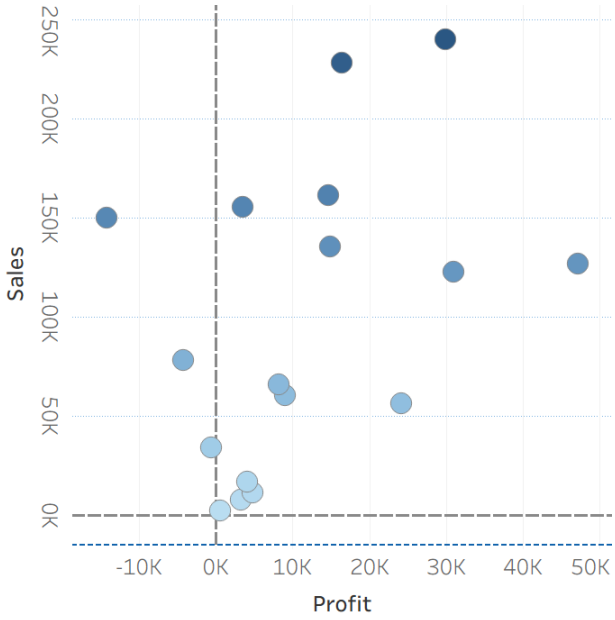

Hình 26: Biểu đồ tương quan giữa doanh thu và lợi nhuận theo từng nhóm hàng phụ.

- Đổi màu và kiểu dáng *Zero Line* để làm nổi bật các góc phần tư của biểu đồ.
- Áp dụng dải màu thể hiện giá trị `Sales` cao thấp giữa các `Sub-Category`.

	First Class	Same Day	Second Class	Standard Class
Accessories	$18.0K	$8.2K	$25.8K	$70.6K
Appliances	$11.8K	$5.1K	$13.5K	$35.5K
Art	$2.4K	$0.6K	$2.3K	$11.2K
Binders	$23.2K	$4.6K	$15.5K	$92.0K
Bookcases	$17.0K	$1.3K	$14.0K	$45.5K
Chairs	$36.8K	$15.9K	$52.1K	$123.1K
Copiers	$37.0K	$4.6K	$12.3K	$72.7K
Envelopes	$1.5K	$0.4K	$1.6K	$7.8K
Fasteners	$0.2K	$0.1K	$0.4K	$1.3K
Furnishings	$6.4K	$3.5K	$11.7K	$38.7K
Labels	$1.2K	$0.4K	$1.6K	$4.3K
Machines	$18.0K	$14.8K	$21.8K	$100.8K
Paper	$8.9K	$2.9K	$11.6K	$32.9K
Phones	$40.9K	$7.0K	$44.6K	$147.4K
Storage	$18.6K	$5.6K	$34.2K	$102.7K
Supplies	$2.7K	$0.4K	$24.0K	$6.9K
Tables	$18.8K	$7.3K	$32.4K	$91.3K

Hình 27: Biểu đồ nhiệt thể hiện doanh thu theo nhóm sản phẩm và dịch vụ vận chuyển.

- Đổi màu và kiểu dáng các đường kẻ chia ô (*divider*) trong bảng.
- Căn chỉnh và định dạng lại giá trị `Sales`.
- Áp dụng dải màu thể hiện giá trị `Sales` cao thấp qua các tổ hợp dữ liệu.

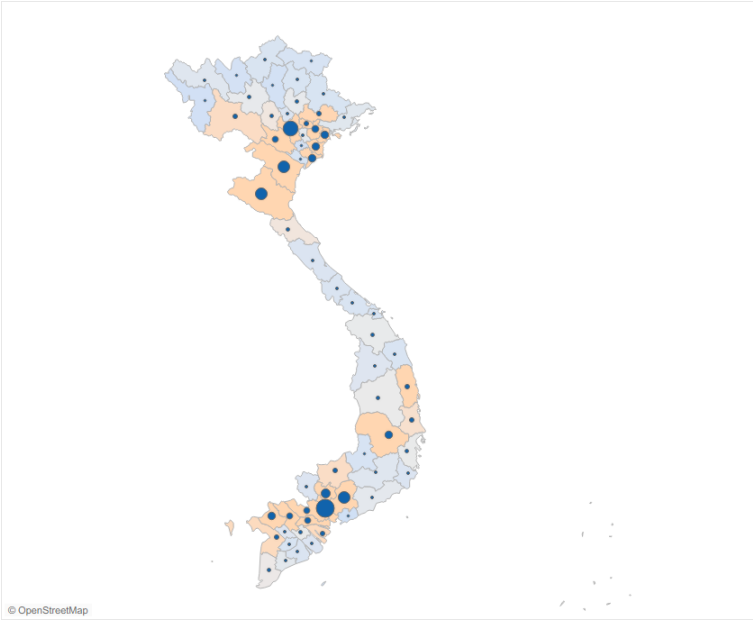

Hình 28: Biểu đồ địa lý thể hiện doanh thu theo tỉnh thành.

- Xóa *background* của bản đồ để làm nổi bật lãnh thổ Việt Nam.
- Áp dụng dải màu thể hiện giá trị `Sales` cao thấp giữa các `Province`.

VII. Câu hỏi trắc nghiệm

1. Giao diện chính của Tableau được chia thành những khu vực nào?
   (a) Data Pane, Visualization Area và các thành phần điều khiển.
   (b) Chỉ gồm Worksheet và Dashboard.
   (c) Rows và Columns.
   (d) Dimensions và Measures.

2. Trong Data Pane, Dimensions và Measures khác nhau chủ yếu ở điểm nào?
   (a) Dimensions là dữ liệu định lượng, Measures là dữ liệu định tính.
   (b) Dimensions dùng để tính toán, Measures chỉ để mô tả.
   (c) Dimensions là dữ liệu định tính, Measures là dữ liệu định lượng có thể tính toán.
   (d) Hai thành phần này hoàn toàn không khác nhau.

3. Khi kéo một trường dữ liệu vào Rows hoặc Columns, điều gì sẽ xảy ra?
   (a) Tableau tự động xóa dữ liệu cũ.
   (b) Tableau ánh xạ dữ liệu lên trục ngang hoặc trục dọc của biểu đồ.
   (c) Tableau chuyển dữ liệu thành Dashboard.
   (d) Tableau tạo một workbook mới.

4. Chức năng chính của Dashboard và Story trong Tableau là gì?
   (a) Dashboard dùng để lưu dữ liệu, Story dùng để kết nối nguồn dữ liệu.
   (b) Dashboard kết hợp nhiều worksheet vào một màn hình, Story xây dựng chuỗi phân tích kể lại câu chuyện.
   (c) Dashboard chỉ hiển thị bảng số liệu, Story chỉ hiển thị biểu đồ tròn.
   (d) Cả hai đều chỉ dùng để chỉnh sửa Data Pane.

5. (Preprocessing Functions String Functions)

   Trong dataset Superstore, cột `Order ID` có cấu trúc cố định: `"[Mã khu vực 2 ký tự]-[Năm đặt hàng 4 ký tự]-[Mã đơn hàng 6 ký tự]"`. Ví dụ: `"CA-2021-152156"`, `"US-2022-108966"`.

   Bạn cần tạo 3 Calculated Fields trong Tableau:

   - **Field 1:** Trích xuất mã khu vực (2 ký tự đầu) ví dụ `"CA"`
   - **Field 2:** Trích xuất năm đặt hàng (4 ký tự ở giữa) ví dụ `"2021"`
   - **Field 3:** Kiểm tra đơn hàng có phải khu vực "US"không ví dụ `True` hoặc `False`

   Lưu ý

   Trong Tableau, hàm `MID(string, start, length)` sử dụng chỉ mục **1-indexed** (ký tự đầu tiên ở vị trí 1).

   Câu hỏi: Bộ Calculated Fields nào sau đây cho kết quả **đúng** cho cả 3 yêu cầu trên?

A.

```
 # - Field 1 -
LEFT([Order ID], 2)
# - Field 2 -
MID([Order ID], 3, 4)
# - Field 3 -
STARTSWITH([Order ID], "US")

```

B.

```
# - Field 1 -
SPLIT([Order ID], "-", 1)
# - Field 2 -
MID([Order ID], 4, 4)
# - Field 3 -
CONTAINS([Order ID], "US")

```

C.

```
# - Field 1 -
SPLIT([Order ID], "-", 1)
# - Field 2 -
SPLIT([Order ID], "-", 2)
# - Field 3 -
STARTSWITH([Order ID], "US")

```

D.

```
# - Field 1 -
SPLIT([Order ID], "-", 2)
# - Field 2 -
SPLIT([Order ID], "-", 3)
# - Field 3 -
STARTSWITH([Order ID], "US")

```

6. (Preprocessing Functions Date Functions & NULL Handling)

   Tiếp tục với dataset Superstore, bạn cần tạo một Calculated Field `[Delivery Speed]` để phân loại tốc độ giao hàng dựa trên khoảng cách giữa `Order Date` và `Ship Date`. Quy tắc phân loại:

   - **"Fast"** nếu giao trong vòng 2 ngày ($\leq$ 2 ngày)
   - **"Normal"** nếu giao trong 3–5 ngày
   - **"Slow"** nếu giao trên 5 ngày

Ngoài ra, một số đơn hàng chưa có `Ship Date` (giá trị NULL). Với những đơn hàng này, `[Delivery Speed]` cần trả về `"Pending"` thay vì NULL.

Lưu ý

Trong Tableau, bất kỳ phép tính nào có NULL đều trả về NULL ví dụ `DATEDIFF('day', [Order Date], NULL)` = NULL, và `NULL <= 2` = NULL (không phải True hay False).

(Calculated Field `[Delivery Speed]` này sẽ được sử dụng trong Câu 7.)

Câu hỏi: Công thức Calculated Field nào sau đây cho kết quả **đúng** trong mọi trường hợp?

A.

```
IF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSE "Slow"
END
```

B.

```
IF ISNULL([Ship Date]) THEN "Pending"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSE "Slow"
END
```

C.

```
IF ZN(DATEDIFF('day', [Order Date], [Ship Date])) <= 2 THEN "Fast"
ELSEIF ZN(DATEDIFF('day', [Order Date], [Ship Date])) <= 5 THEN "Normal"
ELSEIF ISNULL([Ship Date]) THEN "Pending"
ELSE "Slow"
END
```

D.

```
IF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSEIF ISNULL([Ship Date]) THEN "Pending"
ELSE "Slow"
END
```

7. (Basic Charts Stacked Area Chart)

Sử dụng Calculated Field `[Delivery Speed]` **đã tạo ở Câu 2** (giả sử bạn đã chọn công thức đúng), bạn muốn xem xu hướng doanh thu theo tốc độ giao hàng qua thời gian. Bạn filter bỏ

các đơn hàng `"Pending"` và thực hiện các bước sau:

(a) Kéo `Order Date` vào **Columns shelf**, nhấp chuột phải → chọn **Month** (Continuous nhóm dưới, pill xanh lá)

(b) Kéo `Sales` vào **Rows shelf**

(c) Trong Marks card, chuyển **Mark Type** từ "Automatic"(đang là Line) sang **Area**

(d) Kéo `[Delivery Speed]` vào ô **Color** trong Marks card

Biểu đồ hiện tại là **Stacked Area Chart** với 3 vùng màu (Fast, Normal, Slow) xếp chồng lên nhau. Tại một tháng cụ thể, bạn nhìn vào **trục Y** và thấy **đường biên trên cùng** (top edge) của toàn bộ biểu đồ chạm khoảng **$120,000**.

Câu hỏi: Phát biểu nào mô tả **đúng nhất** cách đọc biểu đồ Stacked Area này?

A. Mỗi vùng màu hoạt động **độc lập** , đường biên trên (top edge) của mỗi vùng là giá trị `SUM(Sales)` riêng của nhóm Delivery Speed đó. Ba đường biên trên tương đương 3 đường trong Line Chart. Giá trị $120,000 là doanh thu riêng của nhóm nằm trên cùng.

B. Các vùng **xếp chồng** lên nhau, đường biên trên cùng ($120,000) là **tổng doanh thu cả 3 nhóm Delivery Speed cộng lại** tại tháng đó. **Chiều cao** (thickness) của từng vùng màu mới thể hiện `SUM(Sales)` riêng của nhóm đó. Vùng trên cùng bị "đẩy lên"bởi các vùng bên dưới, nên đường biên trên của nó **không phải** giá trị riêng.

C. Stacked Area Chart mặc định hiển thị **tỷ lệ phần trăm** , mỗi vùng thể hiện % đóng góp của nhóm Delivery Speed, tổng 3 vùng luôn = 100%. Giá trị $120,000 trên tooltip là tổng tuyệt đối, nhưng trục Y hiển thị 0–100%.

D. Stacked Area Chart tự động sắp xếp các nhóm Delivery Speed sao cho nhóm có doanh thu lớn nhất luôn nằm ở **vùng dưới cùng**. Nếu thứ tự doanh thu thay đổi qua từng tháng, thứ tự các vùng cũng thay đổi theo để luôn giữ nhóm lớn nhất ở dưới.

8. (Basic Charts Discrete vs Continuous Date)

Sau khi phân tích tốc độ giao hàng ở Câu 3, bạn muốn xem xu hướng doanh thu theo thời gian bằng **Line Chart**. Bạn kéo `Order Date` vào Columns shelf và `Sales` vào Rows shelf, sau đó nhấp chuột phải vào `Order Date` trên Columns shelf.

Menu hiện ra với 2 nhóm tùy chọn (phân cách bởi đường kẻ ngang):

- **Nhóm trên** (Discrete màu xanh dương): Year, Quarter, Month, Day...
- **Nhóm dưới** (Continuous màu xanh lá): Year, Quarter, Month, Day...

Bạn chọn `Month` từ **nhóm trên (Discrete)**. Line Chart hiển thị 12 header: January, February, ..., December. Dữ liệu Superstore có 4 năm (2021–2024).

Câu hỏi: Phát biểu nào mô tả **đúng nhất** hành vi của biểu đồ khi chọn `Month` Discrete (nhóm trên)?

A. Tableau tạo trục thời gian liên tục từ January 2021 đến December 2024, đường kẻ nối liền mạch qua 48 tháng. Chọn Discrete hay Continuous không ảnh hưởng đến cách hiển thị Line Chart.

B. Tableau tạo 12 header riêng biệt (January → December). Dữ liệu của **cùng tháng từ tất cả các năm** được gộp lại ví dụ header "March"chứa tổng `SUM(Sales)` của March 2021 + March 2022 + March 2023 + March 2024. Đường kẻ nối 12 điểm này cho thấy xu hướng theo mùa (seasonality) nhưng **không thể thấy xu hướng tăng trưởng qua các năm**.

C. Tableau tạo 48 header riêng biệt 12 tháng × 4 năm. Đường kẻ bị **đứt** tại mỗi ranh giới năm (December → January năm sau) vì Discrete Date không nối giữa các năm.

D. Tableau tạo 12 header riêng biệt (January → December) nhưng vẽ **4 đường riêng biệt**, mỗi đường cho một năm (2021, 2022, 2023, 2024), tự động phân biệt bằng màu.

9. (Bài tập tổng hợp – Xử lý `Order Date` bất thường trong Superstore.)
Trong dataset Superstore, bạn phát hiện:

- Một số dòng có `Order Date` với năm 1900 hoặc 2099 (rõ ràng là vô lý)
- Dataset có cột `Ship Date`
- Trong dữ liệu hợp lệ, khoảng thời gian giữa `Order Date` và `Ship Date` khá ổn định (ví dụ thường từ 2–5 ngày)
- Dữ liệu hợp lệ nằm trong giai đoạn 2014–2017

Mục tiêu phân tích: Phân tích xu hướng doanh thu theo thời gian mà không làm mất dữ liệu.

Cách xử lý nào dưới đây là hợp lý nhất?

A. Loại bỏ tất cả các dòng có `Order Date` vô lý

B. Thay `Order Date` vô lý bằng đúng `Ship Date`

C. Ước lượng `Order Date` bằng cách lấy `Ship Date` trừ đi khoảng thời gian giao hàng điển hình (median / mode)

D. Điền `Order Date` vô lý bằng ngày trung bình của toàn bộ dataset

10. (Bài tập tổng hợp – Xác định dạng biểu đồ phù hợp)
Bạn cần trả lời câu hỏi kinh doanh sau bằng Tableau: "Danh mục sản phẩm nào có doanh thu cao nhưng lợi nhuận thấp hoặc âm?"

Cách xây dựng biểu đồ nào dưới đây là phù hợp nhất?

A. Bar chart: `Sales` theo `Category`

B. Line chart: `Profit` theo `Order Date`

C. Scatter plot: `Sales` vs `Profit`, màu theo `Category`

D. Pie chart: Tỷ trọng `Profit` theo `Category`

AI VIET NAM COURSE 2026

Quiz - Tableau: Introduction to Tableau

1. (Kiến thức cơ bản về giao diện và thành phần của Tableau.)

Câu hỏi liên quan đến cấu trúc giao diện và cách Tableau tổ chức dữ liệu khi tạo biểu đồ trực quan.

A. Data Pane, Visualization Area và các thành phần điều khiển.

B. Chỉ gồm Worksheet và Dashboard.

C. Rows và Columns.

D. Dimensions và Measures.

Đáp án đúng: A

Giải thích chi tiết:

Giao diện chính của Tableau được tổ chức thành ba khu vực quan trọng:

- **Data Pane**: nằm ở bên trái, chứa các trường dữ liệu được chia thành `Dimensions` và `Measures`.
- **Visualization Area (View)**: khu vực trung tâm nơi các biểu đồ và bảng trực quan được hiển thị.
- **Các thành phần điều khiển**: bao gồm thanh công cụ, shelves như `Rows`, `Columns`, `Filters`, `Marks`, dùng để điều chỉnh cách dữ liệu được hiển thị.

Các lựa chọn khác chỉ là một phần nhỏ của giao diện chứ không đại diện cho cấu trúc tổng thể. Vì vậy đáp án đúng là **A**.

2. (Phân biệt `Dimensions` và `Measures` trong Data Pane của Tableau.)

Trong Tableau, các trường dữ liệu được phân loại thành hai nhóm chính trong Data Pane.

A. Dimensions là dữ liệu định lượng, Measures là dữ liệu định tính.

B. Dimensions dùng để tính toán, Measures chỉ để mô tả.

C. Dimensions là dữ liệu định tính, Measures là dữ liệu định lượng có thể tính toán.

D. Hai thành phần này hoàn toàn không khác nhau.

Đáp án đúng: C

Giải thích chi tiết:

Trong Tableau:

- **Dimensions** thường là dữ liệu **định tính (categorical)** dùng để phân nhóm hoặc mô tả dữ liệu, ví dụ: `Region`, `Category`, `Customer Name`.
- **Measures** là dữ liệu **định lượng (numerical)** có thể thực hiện các phép tính tổng hợp như `SUM`, `AVG`, `COUNT`, ví dụ: `Sales`, `Profit`, `Quantity`.

Dimensions thường được dùng để chia dữ liệu thành các nhóm, còn Measures được dùng để tính toán và hiển thị giá trị trên biểu đồ. Vì vậy đáp án đúng là **C**.

3. (Vai trò của việc kéo trường dữ liệu vào `Rows` hoặc `Columns` trong Tableau.)

Khi xây dựng biểu đồ trong Tableau, người dùng thường kéo các trường dữ liệu từ Data Pane vào các shelves.

A. Tableau tự động xóa dữ liệu cũ.

B. Tableau ánh xạ dữ liệu lên trục ngang hoặc trục dọc của biểu đồ.

C. Tableau chuyển dữ liệu thành Dashboard.

D. Tableau tạo một workbook mới.

Đáp án đúng: B

Giải thích chi tiết:

Trong Tableau, khi kéo một trường dữ liệu vào:

- `Columns`: trường dữ liệu sẽ được ánh xạ lên **trục ngang (x-axis)**.
- `Rows`: trường dữ liệu sẽ được ánh xạ lên **trục dọc (y-axis)**.

Cơ chế này giúp Tableau tự động tạo cấu trúc biểu đồ dựa trên cách người dùng sắp xếp dữ liệu trên hai trục. Vì vậy lựa chọn đúng là **B**.

4. (Chức năng của `Dashboard` và `Story` trong Tableau.)

Hai thành phần này được dùng để trình bày và truyền đạt kết quả phân tích dữ liệu.

A. Dashboard dùng để lưu dữ liệu, Story dùng để kết nối nguồn dữ liệu.

B. Dashboard kết hợp nhiều worksheet vào một màn hình, Story xây dựng chuỗi phân tích kể lại câu chuyện.

C. Dashboard chỉ hiển thị bảng số liệu, Story chỉ hiển thị biểu đồ tròn.

D. Cả hai đều chỉ dùng để chỉnh sửa Data Pane.

Đáp án đúng: B

Giải thích chi tiết:

Trong Tableau:

- **Dashboard**: cho phép kết hợp nhiều `Worksheet` (biểu đồ, bảng, bản đồ) vào cùng một màn hình để tạo một bảng điều khiển trực quan và tương tác.
- **Story**: dùng để sắp xếp các dashboard hoặc worksheet thành một **chuỗi các bước phân tích**, giúp trình bày dữ liệu theo dạng câu chuyện (data storytelling).

Dashboard giúp tổng hợp nhiều góc nhìn dữ liệu, còn Story giúp dẫn dắt người xem qua từng bước phân tích. Vì vậy đáp án đúng là **B**.

5. (String Functions)

Trong dataset Superstore, cột `Order ID` có cấu trúc cố định: `"[Mã khu vực 2 ký tự]-[Năm đặt hàng 4 ký tự]-[Mã đơn hàng 6 ký tự]"`. Ví dụ: `"CA-2021-152156"`, `"US-2022-108966"`.

Bạn cần tạo 3 Calculated Fields trong Tableau:

- **Field 1:** Trích xuất mã khu vực (2 ký tự đầu) ví dụ `"CA"`
- **Field 2:** Trích xuất năm đặt hàng (4 ký tự ở giữa) ví dụ `"2021"`
- **Field 3:** Kiểm tra đơn hàng có phải khu vực "US"không ví dụ `True` hoặc `False`

Lưu ý

Trong Tableau, hàm `MID(string, start, length)` sử dụng chỉ mục **1-indexed** (ký tự đầu tiên ở vị trí 1).

Câu hỏi: Bộ Calculated Fields nào sau đây cho kết quả **đúng** cho cả 3 yêu cầu trên?

A.

```
 # ---- Field 1 ----
LEFT([Order ID], 2)
# ---- Field 2 ----
MID([Order ID], 3, 4)
# ---- Field 3 ----
STARTSWITH([Order ID], "US")

```

B.

```
# ---- Field 1 ----
SPLIT([Order ID], "-", 1)
# ---- Field 2 ----
MID([Order ID], 4, 4)
# ---- Field 3 ----
CONTAINS([Order ID], "US")

```

C.

```
# ---- Field 1 ----
SPLIT([Order ID], "-", 1)
# ---- Field 2 ----
SPLIT([Order ID], "-", 2)
# ---- Field 3 ----
STARTSWITH([Order ID], "US")

```

D.

```
# ---- Field 1 ----
SPLIT([Order ID], "-", 2)
# ---- Field 2 ----
SPLIT([Order ID], "-", 3)
# ---- Field 3 ----
STARTSWITH([Order ID], "US")

```

Đáp án: (C)

Giải thích chi tiết: Cấu trúc Order ID: `"CA-2021-152156"` → (ký tự theo vị trí 1-indexed):

- Vị trí 1–2: `"CA"` (mã khu vực)
- Vị trí 3: `-` (dấu gạch)
- Vị trí 4–7: `"2021"` (năm đặt hàng)
- Vị trí 8: `-` (dấu gạch)
- Vị trí 9–14: `"152156"` (mã đơn hàng)

- **Câu (a) sai:**
  - Field 1: `LEFT([Order ID], 2)` → `"CA"` ✓
  - Field 2: `MID([Order ID], 3, 4)` → Bắt đầu tại vị trí 3 (ký tự `-`), lấy 4 ký tự → `"-202"` ✗ (lấy phải dấu gạch + 3 ký tự đầu của năm)
  - Field 3: `STARTSWITH([Order ID], "US")` → ✓

  → **Field 2 sai** vì start position bị lệch 1 đơn vị.
- **Câu (b) sai:**
  - Field 1: `{SPLIT([Order ID], "-", 1)` → `"CA"` ✓
  - Field 2: `MID([Order ID], 4, 4)` → `"2021"` ✓
  - Field 3: `CONTAINS([Order ID], "US")` → **Có vấn đề!** `CONTAINS` kiểm tra chuỗi con ở **bất kỳ vị trí nào**. Nếu mã đơn hàng chứa `"US"` ở phần khác (ví dụ: `"CA-2021-1US966"`), `CONTAINS` trả về `True` sai.

  → **Field 3 không chính xác**. Dù xác suất trùng thấp, `STARTSWITH` luôn là best practice khi chỉ cần check prefix.

- **Câu (c) đúng:**
  - Field 1: `{SPLIT([Order ID], "-", 1)` → `"CA"` ✓
  - Field 2: `{SPLIT([Order ID], "-", 2)` → `"2021"` ✓
  - Field 3: `STARTSWITH([Order ID], "US")` → ✓

  → **Tất cả 3 field đều đúng**, và `SPLIT` không phụ thuộc vị trí ký tự cố định.
- **Câu (d) sai:**
  - Field 1: `{SPLIT([Order ID], "-", 2)` → `"2021"` ✗ (đây là năm, không phải mã khu vực)
  - Field 2: `{SPLIT([Order ID], "-", 3)}` → `"152156"` ✗ (đây là mã đơn hàng, không phải năm)

  → **Field 1 và Field 2 đều sai** vì token_number bị lệch.

6. (Date Functions & NULL Handling)

Tiếp tục với dataset Superstore, bạn cần tạo một Calculated Field `[Delivery Speed]` để phân loại tốc độ giao hàng dựa trên khoảng cách giữa `Order Date` và `Ship Date`. Quy tắc phân loại:

- **"Fast"** nếu giao trong vòng 2 ngày ($\leq$ 2 ngày)
- **"Normal"** nếu giao trong 3–5 ngày
- **"Slow"** nếu giao trên 5 ngày

Ngoài ra, một số đơn hàng chưa có `Ship Date` (giá trị NULL). Với những đơn hàng này, `[Delivery Speed]` cần trả về `"Pending"` thay vì NULL.

Lưu ý

Trong Tableau, bất kỳ phép tính nào có NULL đều trả về NULL — ví dụ `DATEDIFF('day', [Order Date], NULL)` = NULL, và `NULL <= 2` = NULL (không phải True hay False).

(Calculated Field `[Delivery Speed]` này sẽ được sử dụng trong Câu 3.)

Câu hỏi: Công thức Calculated Field nào sau đây cho kết quả **đúng** trong mọi trường hợp?

A.

```
IF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSE "Slow"
END

```

B.

```
IF ISNULL([Ship Date]) THEN "Pending"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSE "Slow"
```

```
END
```

C.

```
IF ZN(DATEDIFF('day', [Order Date], [Ship Date])) <= 2 THEN "Fast"
ELSEIF ZN(DATEDIFF('day', [Order Date], [Ship Date])) <= 5 THEN "Normal"
ELSEIF ISNULL([Ship Date]) THEN "Pending"
ELSE "Slow"
END
```

D.

```
IF DATEDIFF('day', [Order Date], [Ship Date]) <= 2 THEN "Fast"
ELSEIF DATEDIFF('day', [Order Date], [Ship Date]) <= 5 THEN "Normal"
ELSEIF ISNULL([Ship Date]) THEN "Pending"
ELSE "Slow"
END
```

Đáp án: (B)

Giải thích chi tiết:

- **Câu (a) sai:** Công thức này **không xử lý trường hợp Ship Date = NULL**. Khi Ship Date là NULL, `DATEDIFF` trả về NULL. Trong Tableau, `NULL <= 2` trả về NULL (falsy), nên mọi điều kiện IF/ELSEIF đều không khớp → rơi vào ELSE → trả về `"Slow"`. Đơn hàng chưa giao bị phân loại sai.
- **Câu (b) đúng:** Kiểm tra NULL **trước tiên** bằng `ISNULL([Ship Date])`. Nếu NULL → trả về `"Pending"` ngay, không tính DATEDIFF. Nếu Ship Date có giá trị → tiếp tục phân loại Fast/Normal/Slow. Thứ tự kiểm tra NULL trước là quan trọng vì IF/ELSEIF đánh giá **lần lượt từ trên xuống**.
- **Câu (c) sai:** Hai vấn đề:
  1. `ZN(DATEDIFF(...))` khi Ship Date = NULL → DATEDIFF = NULL → ZN thay bằng 0 → `0 <= 2` = True → trả về `"Fast"`. Đơn hàng chưa giao bị phân loại sai thành `"Fast"`!
  2. `ISNULL` đặt **sau** 2 điều kiện DATEDIFF → không bao giờ được thực thi.
- **Câu (d) sai:** Khi Ship Date = NULL: `DATEDIFF` = NULL → `NULL <= 2` = NULL (falsy) → `NULL <= 5` = NULL (falsy) → rơi thẳng vào **ELSE** → `"Slow"`, bỏ qua `ISNULL`. Thứ tự sai ISNULL phải đứng **đầu tiên**.

7. (Stacked Area Chart)

Sử dụng Calculated Field `[Delivery Speed]` **đã tạo ở Câu 2** (giả sử bạn đã chọn công thức đúng), bạn muốn xem xu hướng doanh thu theo tốc độ giao hàng qua thời gian. Bạn filter bỏ các đơn hàng `"Pending"` và thực hiện các bước sau:

(a) Kéo `Order Date` vào **Columns shelf**, nhấp chuột phải → chọn **Month** (Continuous — nhóm dưới, pill xanh lá)

(b) Kéo `Sales` vào **Rows shelf**

(c) Trong Marks card, chuyển **Mark Type** từ "Automatic"(đang là Line) sang **Area**

(d) Kéo `[Delivery Speed]` vào ô **Color** trong Marks card

Biểu đồ hiện tại là **Stacked Area Chart** với 3 vùng màu (Fast, Normal, Slow) xếp chồng lên nhau. Tại một tháng cụ thể, bạn nhìn vào **trục Y** và thấy **đường biên trên cùng** (top edge) của toàn bộ biểu đồ chạm khoảng **$120,000**.

Câu hỏi: Phát biểu nào mô tả **đúng nhất** cách đọc biểu đồ Stacked Area này?

A. Mỗi vùng màu hoạt động **độc lập** , đường biên trên (top edge) của mỗi vùng là giá trị `SUM(Sales)` riêng của nhóm Delivery Speed đó. Ba đường biên trên tương đương 3 đường trong Line Chart. Giá trị $120,000 là doanh thu riêng của nhóm nằm trên cùng.

B. Các vùng **xếp chồng** lên nhau, đường biên trên cùng ($120,000) là **tổng doanh thu cả 3 nhóm Delivery Speed cộng lại** tại tháng đó. **Chiều cao** (thickness) của từng vùng màu mới thể hiện `SUM(Sales)` riêng của nhóm đó. Vùng trên cùng bị "đẩy lên"bởi các vùng bên dưới, nên đường biên trên của nó **không phải** giá trị riêng.

C. Stacked Area Chart mặc định hiển thị **tỷ lệ phần trăm** , mỗi vùng thể hiện % đóng góp của nhóm Delivery Speed, tổng 3 vùng luôn = 100%. Giá trị $120,000 trên tooltip là tổng tuyệt đối, nhưng trục Y hiển thị 0–100%.

D. Stacked Area Chart tự động sắp xếp các nhóm Delivery Speed sao cho nhóm có doanh thu lớn nhất luôn nằm ở **vùng dưới cùng**. Nếu thứ tự doanh thu thay đổi qua từng tháng, thứ tự các vùng cũng thay đổi theo để luôn giữ nhóm lớn nhất ở dưới.

Đáp án: (B)

Giải thích chi tiết:

- **Câu (a) sai:** Trong Stacked Area Chart, các vùng **không** hoạt động độc lập. Chúng xếp chồng vùng thứ 2 bắt đầu từ đường biên trên của vùng thứ 1, vùng thứ 3 từ đường biên trên vùng thứ 2. Đường biên trên mỗi vùng phía trên là **tổng cộng dồn**, không phải giá trị riêng. Chỉ **chiều cao** (thickness) mỗi vùng mới phản ánh đúng `SUM(Sales)` riêng. Muốn 3 đường độc lập → dùng **Line Chart**.
- **Câu (b) đúng:** Cách đọc chính xác. Khi kéo `[Delivery Speed]` vào Color với Mark Type = Area, Tableau tạo biểu đồ xếp chồng: Fast bắt đầu từ y=0, Normal xếp **trên** Fast, Slow xếp **trên cùng**. Nhìn trên trục Y, đường biên trên cùng chạm $120,000 = tổng `SUM(Sales)` cả 3 nhóm. Đây là "cạm bẫy"phổ biến nhất: người xem dễ nhầm đường biên trên cùng là doanh thu riêng của nhóm trên cùng.
- **Câu (c) sai:** Stacked Area Chart mặc định hiển thị giá trị **tuyệt đối** (`SUM(Sales)` bằng đô-la), **không phải** phần trăm. Trục Y hiển thị giá trị $ thực tế. Để có dạng % (tổng = 100%), cần thêm bước: chuột phải vào `SUM(Sales)` → **Quick Table Calculation** → **Percent of Total**.

- **Câu (d) sai:** Thứ tự nhóm trong Stacked Area Chart được **cố định** theo legend Tableau **không** tự động xếp lại thứ tự các vùng dựa trên giá trị doanh thu. Thứ tự **giữ nguyên xuyên suốt** toàn bộ trục thời gian. Muốn thay đổi → kéo thủ công trong legend.

8. (Discrete vs Continuous Date)

Sau khi phân tích tốc độ giao hàng ở Câu 3, bạn muốn xem xu hướng doanh thu theo thời gian bằng **Line Chart**. Bạn kéo `Order Date` vào Columns shelf và `Sales` vào Rows shelf, sau đó nhấp chuột phải vào `Order Date` trên Columns shelf.

Menu hiện ra với 2 nhóm tùy chọn (phân cách bởi đường kẻ ngang):

- **Nhóm trên** (Discrete màu xanh dương): Year, Quarter, Month, Day...
- **Nhóm dưới** (Continuous màu xanh lá): Year, Quarter, Month, Day...

Bạn chọn `Month` từ **nhóm trên (Discrete)**. Line Chart hiển thị 12 header: January, February, ..., December. Dữ liệu Superstore có 4 năm (2021–2024).

Câu hỏi: Phát biểu nào mô tả **đúng nhất** hành vi của biểu đồ khi chọn `Month` Discrete (nhóm trên)?

A. Tableau tạo trục thời gian liên tục từ January 2021 đến December 2024, đường kẻ nối liền mạch qua 48 tháng. Chọn Discrete hay Continuous không ảnh hưởng đến cách hiển thị Line Chart.

B. Tableau tạo 12 header riêng biệt (January → December). Dữ liệu của **cùng tháng từ tất cả các năm** được gộp lại — ví dụ header "March"chứa tổng `SUM(Sales)` của March 2021 + March 2022 + March 2023 + March 2024. Đường kẻ nối 12 điểm này cho thấy xu hướng theo mùa (seasonality) nhưng **không thể thấy xu hướng tăng trưởng qua các năm**.

C. Tableau tạo 48 header riêng biệt — 12 tháng × 4 năm. Đường kẻ bị **đứt** tại mỗi ranh giới năm (December → January năm sau) vì Discrete Date không nối giữa các năm.

D. Tableau tạo 12 header riêng biệt (January → December) nhưng vẽ **4 đường riêng biệt**, mỗi đường cho một năm (2021, 2022, 2023, 2024), tự động phân biệt bằng màu.

Đáp án: (B)

Giải thích chi tiết:

- **Câu (a) sai:** Discrete và Continuous tạo ra kết quả **rất khác nhau**. Discrete Date (pill xanh dương) tạo header riêng biệt, Continuous Date (pill xanh lá) tạo trục liên tục. Nói "không ảnh hưởng"là hoàn toàn sai.
- **Câu (b) đúng:** Khi chọn `Month` Discrete, Tableau tạo 12 header: January → December. Dữ liệu của cùng tháng từ mọi năm được **gộp lại** — ví dụ "March"chứa `SUM(Sales)` của March 2021 + 2022 + 2023 + 2024. Biểu đồ cho thấy xu hướng theo mùa nhưng mất thông tin tăng trưởng qua các năm. Muốn thấy xu hướng qua các năm → chọn `Month` Continuous (xanh lá).
- **Câu (c) sai:** Discrete `Month` **không** tạo 48 header. Chỉ tạo 12 header (January → December) và gộp dữ liệu. Để tạo header theo năm-tháng, cần thêm `YEAR` Discrete vào Columns shelf.

- **Câu (d) sai:** Discrete `Month` tự nó **không** tách 4 đường theo năm. Cần kéo thêm `YEAR(Order Date)` vào Color. Với chỉ `Month` Discrete trên Columns, Tableau gộp tất cả năm vào 12 điểm duy nhất.

9. (Xử lý `Order Date` bất thường trong Superstore.)
Trong dataset Superstore, bạn phát hiện:

- Một số dòng có `Order Date` với năm 1900 hoặc 2099 (rõ ràng là vô lý)
- Dataset có cột `Ship Date`
- Trong dữ liệu hợp lệ, khoảng thời gian giữa `Order Date` và `Ship Date` khá ổn định (ví dụ thường từ 2–5 ngày)
- Dữ liệu hợp lệ nằm trong giai đoạn 2014–2017

Mục tiêu phân tích: Phân tích xu hướng doanh thu theo thời gian mà không làm mất dữ liệu.

Cách xử lý nào dưới đây là hợp lý nhất?

A. Loại bỏ tất cả các dòng có `Order Date` vô lý

B. Thay `Order Date` vô lý bằng đúng `Ship Date`

C. Ước lượng `Order Date` bằng cách lấy `Ship Date` trừ đi khoảng thời gian giao hàng điển hình (median / mode)

D. Điền `Order Date` vô lý bằng ngày trung bình của toàn bộ dataset

Đáp án đúng: C

Giải thích chi tiết:

Mục tiêu là phân tích xu hướng doanh thu theo thời gian mà không làm mất dữ liệu, do đó không nên loại bỏ các dòng dữ liệu (loại A).

Việc thay trực tiếp `Order Date` bằng `Ship Date` (B) sẽ làm sai lệch logic nghiệp vụ vì ngày đặt hàng luôn xảy ra trước ngày giao hàng.

Điền bằng ngày trung bình của toàn bộ dataset (D) sẽ làm méo phân bố thời gian, tạo ra các cụm doanh thu giả tạo tại một thời điểm nhất định.

Do trong dữ liệu hợp lệ, khoảng thời gian giữa `Order Date` và `Ship Date` khá ổn định (thường 2–5 ngày), ta có thể ước lượng hợp lý:

$$\texttt{Order Date} \approx \texttt{Ship Date} - \text{Lead Time điển hình.}$$

Sử dụng median hoặc mode của thời gian giao hàng giúp bảo toàn cấu trúc thời gian thực tế của dữ liệu và giảm ảnh hưởng của outlier.

Vì vậy, chọn **C**.

10. (Xác định dạng biểu đồ phù hợp)
Bạn cần trả lời câu hỏi kinh doanh sau bằng Tableau: "Danh mục sản phẩm nào có doanh thu cao nhưng lợi nhuận thấp hoặc âm?"

Cách xây dựng biểu đồ nào dưới đây là phù hợp nhất?

A. Bar chart: `Sales` theo `Category`

B. Line chart: `Profit` theo `Order Date`

C. Scatter plot: `Sales` vs `Profit`, màu theo `Category`

D. Pie chart: Tỷ trọng `Profit` theo `Category`

Đáp án đúng: C

Giải thích chi tiết:

Câu hỏi yêu cầu xác định những danh mục có `Sales` cao nhưng `Profit` thấp hoặc âm. Điều này đòi hỏi phải quan sát đồng thời hai biến số định lượng: doanh thu và lợi nhuận.

Bar chart (A) chỉ thể hiện `Sales` nên không giúp đánh giá mối quan hệ với `Profit`.

Line chart (B) phù hợp để phân tích xu hướng theo thời gian, không phù hợp để so sánh hai chỉ số theo danh mục.

Pie chart (D) chỉ thể hiện tỷ trọng của một biến và không thể hiện được mối quan hệ giữa hai biến số.

Scatter plot (C) cho phép biểu diễn mỗi `Category` như một điểm trên mặt phẳng với:

$$x = \texttt{Sales}, \quad y = \texttt{Profit}.$$

Nhờ đó có thể dễ dàng nhận diện các danh mục nằm ở vùng:

`Sales cao` và `Profit thấp hoặc âm`.

Vì vậy, chọn **C**.

AI VIET NAM COURSE 2026

Tableau & Data Visualization: Dashboard & Storytelling

I. Tổng quan

Dashboard trong Tableau là một giao diện trực quan, tập hợp nhiều biểu đồ (worksheets) và hình ảnh dữ liệu trên cùng một trang, giúp theo dõi, so sánh và phân tích tổng quan các chỉ số KPI, xu hướng từ nhiều nguồn khác nhau. Nó cho phép tương tác thời gian thực thông qua bộ lọc (filters) và hành động (actions) để hiểu rõ thông tin dự án.

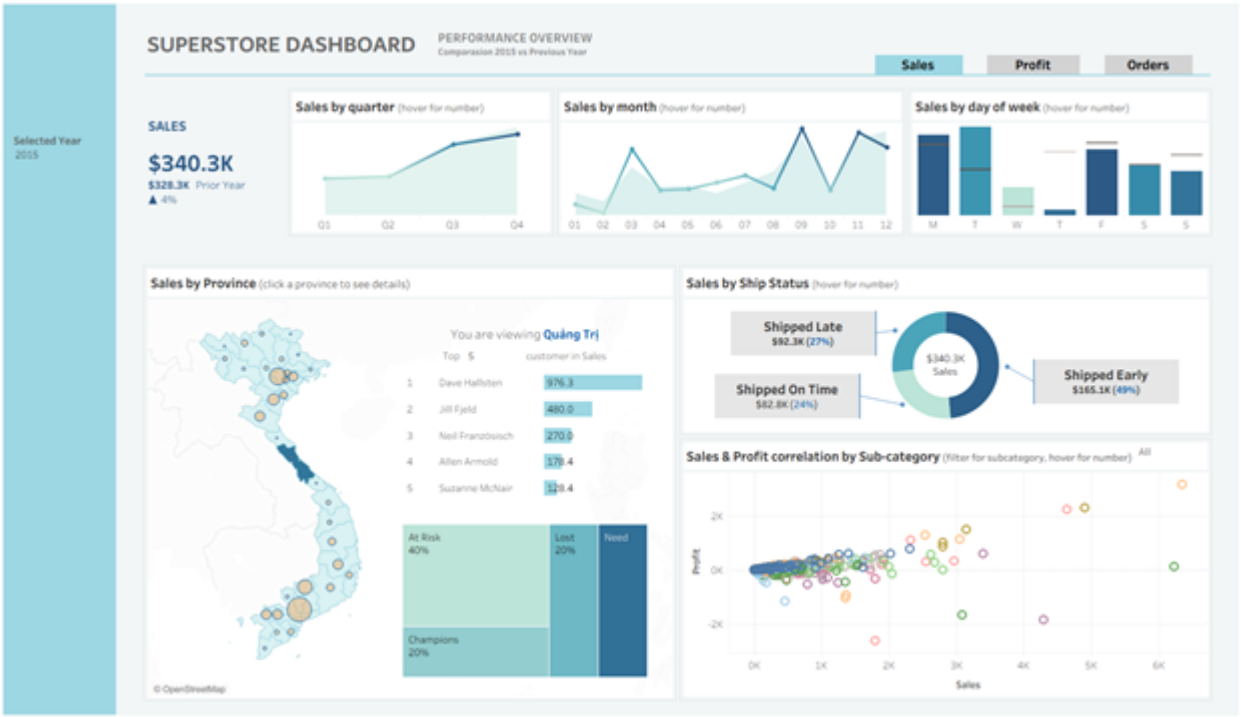

Hình 1: Giao diện dashboard hoàn chỉnh.

II. Ôn tập

Trước khi đi vào nội dung mới của buổi học thứ hai, chúng ta sẽ cùng ôn lại các khái niệm và thao tác cơ bản đã được giới thiệu trong buổi học đầu tiên. Mục tiêu của phần ôn tập này là giúp người học củng cố lại cách tiếp cận trong phân tích dữ liệu bằng Tableau, đồng thời nhắc lại các thành phần quan trọng trong giao diện cũng như quy trình xây dựng một trực quan hóa dữ liệu cơ bản.

Trong buổi học trước, chúng ta đã làm quen với ba nội dung chính: (1) vai trò của Tableau trong hệ sinh thái phân tích dữ liệu, (2) cấu trúc giao diện và các thành phần cốt lõi của Tableau, và (3) quy trình xây dựng biểu đồ thông qua thao tác kéo thả dữ liệu. Những nội dung này đóng vai trò nền tảng để có thể tiếp tục khai thác các chức năng nâng cao hơn trong các buổi học tiếp theo.

II.1. Vai trò của Tableau trong phân tích dữ liệu

Tableau là một công cụ trực quan hóa dữ liệu thuộc nhóm phần mềm *Business Intelligence (BI)*. Nhiệm vụ chính của Tableau là chuyển đổi dữ liệu thô thành các biểu đồ và dashboard trực quan nhằm hỗ trợ người dùng khám phá dữ liệu và đưa ra quyết định dựa trên dữ liệu.

Trong nhiều tổ chức hiện nay, dữ liệu thường được lưu trữ dưới dạng bảng trong các hệ thống như Excel, cơ sở dữ liệu hoặc hệ thống ERP. Những bảng dữ liệu này có thể chứa hàng nghìn hoặc hàng triệu dòng dữ liệu, khiến việc quan sát trực tiếp trở nên khó khăn. Tableau giúp giải quyết vấn đề này bằng cách biến dữ liệu thành các biểu đồ trực quan như biểu đồ cột, biểu đồ đường, biểu đồ phân tán hoặc bản đồ địa lý.

Mục tiêu của trực quan hóa dữ liệu

Trực quan hóa dữ liệu không chỉ nhằm mục đích trình bày dữ liệu một cách đẹp mắt mà còn nhằm hỗ trợ ba mục tiêu quan trọng:

- Giúp người dùng nhanh chóng nhận ra xu hướng và mẫu hình trong dữ liệu.
- Hỗ trợ phát hiện các điểm bất thường hoặc sai lệch trong dữ liệu.
- Truyền đạt thông tin phân tích một cách trực quan và dễ hiểu cho người ra quyết định.

Nhờ khả năng kết nối dữ liệu linh hoạt và thao tác trực quan bằng phương pháp kéo thả (*drag and drop*), Tableau trở thành một công cụ phổ biến trong công việc của Data Analyst, Business Analyst và các nhà quản lý cần theo dõi các chỉ số kinh doanh.

II.2. Cấu trúc giao diện cơ bản của Tableau

Khi làm việc với Tableau Desktop, người dùng chủ yếu thao tác trong môi trường gọi là *Worksheet*. Đây là nơi các biểu đồ được tạo ra và chỉnh sửa. Giao diện Tableau có thể được chia thành một số khu vực chức năng chính.

- **Data Pane**: khu vực nằm bên trái màn hình, chứa toàn bộ các trường dữ liệu được lấy từ nguồn dữ liệu. Các trường này được phân loại thành Dimensions và Measures.
- **Rows và Columns Shelf**: hai khu vực trung tâm dùng để xác định cấu trúc của biểu đồ. Field được kéo vào Columns sẽ xuất hiện trên trục ngang, trong khi field kéo vào Rows sẽ xuất hiện trên trục dọc.
- **Marks Card**: thành phần điều khiển cách dữ liệu được hiển thị. Người dùng có thể điều chỉnh màu sắc, kích thước, nhãn dữ liệu hoặc loại biểu đồ thông qua các tùy chọn trong Marks Card.
- **View**: khu vực hiển thị trực quan hóa. Đây là nơi các biểu đồ được hiển thị sau khi các field được kéo vào Rows và Columns.

Việc hiểu rõ vai trò của từng khu vực trong giao diện là bước đầu tiên để xây dựng biểu đồ hiệu quả trong Tableau.

II.3. Dimensions và Measures

Một trong những khái niệm quan trọng nhất trong Tableau là sự phân biệt giữa **Dimensions** và **Measures**. Hai nhóm dữ liệu này được Tableau tự động nhận diện khi kết nối dữ liệu.

Dimensions	**Measures**
Dữ liệu định tính (categorical)	Dữ liệu định lượng (numerical)
Dùng để phân nhóm dữ liệu	Dùng để đo lường hoặc tính toán
Ví dụ: Category, Region, Customer Name	Ví dụ: Sales, Profit, Quantity

Trong quá trình xây dựng biểu đồ, một quy tắc đơn giản thường được áp dụng là:

- **Dimension** thường được đặt trên trục phân loại của biểu đồ.
- **Measure** thường được đặt trên trục giá trị để thể hiện độ lớn của dữ liệu.

Ví dụ, khi muốn so sánh doanh thu giữa các nhóm sản phẩm, chúng ta sẽ sử dụng `Category` làm Dimension và `Sales` làm Measure.

II.4. Quy trình tạo biểu đồ trong Tableau

Trong buổi học đầu tiên, chúng ta đã làm quen với quy trình cơ bản để tạo một biểu đồ trong Tableau. Quy trình này có thể được tóm tắt qua ba bước chính.

Bước 1: Xác định chỉ số cần phân tích

Trước hết cần xác định Measure trung tâm của bài toán. Đây thường là chỉ số phản ánh mục tiêu phân tích, chẳng hạn như doanh thu, lợi nhuận hoặc số lượng đơn hàng.

Bước 2: Xác định chiều phân tích

Sau khi xác định Measure, bước tiếp theo là chọn Dimension để phân tích dữ liệu theo một chiều cụ thể, ví dụ:

- phân tích doanh thu theo thời gian,
- phân tích doanh thu theo khu vực,
- hoặc phân tích doanh thu theo nhóm sản phẩm.

Bước 3: Lựa chọn loại biểu đồ phù hợp

Loại biểu đồ được chọn phụ thuộc vào mục tiêu phân tích. Một số loại biểu đồ phổ biến đã được giới thiệu trong buổi học trước bao gồm:

- **Bar Chart**: so sánh giá trị giữa các danh mục.
- **Line Chart**: thể hiện xu hướng theo thời gian.
- **Scatter Plot**: phân tích mối quan hệ giữa hai biến số.
- **Map**: trực quan hóa dữ liệu theo vị trí địa lý.

Việc lựa chọn đúng loại biểu đồ đóng vai trò quan trọng vì mỗi loại biểu đồ được thiết kế để làm nổi bật một loại thông tin khác nhau.

II.5. Từ Worksheet đến Dashboard

Ngoài Worksheet, Tableau còn cung cấp hai không gian làm việc mở rộng là **Dashboard** và **Story**.

- **Worksheet**: nơi tạo từng biểu đồ riêng lẻ.
- **Dashboard**: nơi kết hợp nhiều worksheet vào cùng một màn hình để tạo thành một bảng điều khiển tổng hợp.
- **Story**: dùng để xây dựng một chuỗi các bước phân tích nhằm kể lại câu chuyện dữ liệu.

Trong thực tế, một dashboard hoàn chỉnh thường bao gồm nhiều biểu đồ khác nhau nhằm cung cấp cái nhìn toàn diện về dữ liệu. Ví dụ, một dashboard bán hàng có thể bao gồm biểu đồ xu hướng doanh thu theo thời gian, biểu đồ so sánh doanh thu theo khu vực và bản đồ thể hiện phân bố doanh thu theo địa lý.

II.6. Tóm tắt nội dung buổi 1

Thông qua đó, buổi học đầu tiên đã giới thiệu những nền tảng quan trọng để làm việc với Tableau. Các nội dung chính bao gồm:

- Vai trò của Tableau trong phân tích và trực quan hóa dữ liệu.
- Cấu trúc giao diện và các thành phần quan trọng như Data Pane, Rows, Columns và Marks Card.
- Sự khác biệt giữa Dimensions và Measures.
- Quy trình cơ bản để xây dựng biểu đồ từ dữ liệu.

Những kiến thức này là nền tảng để có thể tiếp tục khám phá các chức năng nâng cao của Tableau trong các phần tiếp theo, bao gồm xử lý dữ liệu, xây dựng các loại biểu đồ phức tạp hơn và thiết kế dashboard hoàn chỉnh.

Trong buổi học thứ hai về Tableau, chúng ta sẽ tiếp tục mở rộng các kiến thức nền tảng của Tableau thông qua hai nội dung chính. Trước hết, chúng ta sẽ tìm hiểu các kỹ thuật phân tích dữ liệu nâng cao như *Calculated Fields*, *Filters* và *Parameters* nhằm giúp người dùng biến đổi và kiểm soát dữ liệu linh hoạt hơn. Tiếp theo, buổi học sẽ tập trung vào việc thiết kế **Dashboard** và xây dựng **storytelling với dữ liệu**, bao gồm bố cục dashboard, nguyên tắc trực quan hóa và các cơ chế tương tác như filter, highlight và navigation actions. Cuối cùng, người học sẽ áp dụng các kỹ thuật này để xây dựng một **Sales Dashboard** hoàn chỉnh từ dữ liệu thực tế.

III. Giới thiệu

Ở buổi trước, chúng ta đã nắm được cách tạo các biểu đồ cơ bản: Bar Chart, Line Chart, Scatter Plot, Text Table ... cũng như sử dụng các Preprocessing Functions để xử lý và chuẩn hóa dữ liệu trước khi phân tích. Đó là những kỹ năng nền tảng cho phép bạn trình bày thông tin trực quan.

Nhưng một nhà phân tích dữ liệu giỏi không chỉ biết được dữ liệu. Họ còn phải hiểu được dữ liệu như biết đặt câu hỏi đúng, lọc ra thông tin cốt lõi, và tạo ra những chỉ số mới phục vụ mục tiêu cụ thể. Chẳng hạn: "Khách hàng nào mang lại lợi nhuận cao nhất?", "Doanh thu khu vực nào đang giảm?", hay "Nếu ngưỡng VIP thay đổi thì danh sách khách hàng sẽ khác thế nào?".

Trong buổi học này, chúng ta sẽ tiếp tục phát triển các kỹ năng phân tích dữ liệu trong Tableau và học cách biến các biểu đồ riêng lẻ thành một **dashboard hoàn chỉnh**, giúp người dùng dễ dàng khám phá dữ liệu và hiểu được câu chuyện phía sau các con số. Cụ thể, chúng ta sẽ làm quen với những công cụ và kỹ thuật quan trọng sau:

- **Calculated Fields**: tạo chỉ số mới từ dữ liệu hiện có (ví dụ: tỷ suất lợi nhuận, phân loại khách hàng).
- **Filters**: lọc dữ liệu để tập trung vào phần quan trọng (ví dụ: chỉ xem năm 2024, chỉ xem khách VIP).

- **Parameters**: tạo các giá trị đầu vào linh hoạt, cho phép người dùng thay đổi tiêu chí phân tích hoặc cách hiển thị dữ liệu.
- **Dashboard Layout, Containers**: tổ chức bố cục dashboard bằng các container như Tiled và Floating để sắp xếp các biểu đồ một cách rõ ràng và hợp lý.
- **Color Principles, Visual Best Practices**: sử dụng màu sắc và thiết kế trực quan để làm nổi bật thông tin quan trọng và giúp người xem dễ hiểu dữ liệu.
- **Actions (Filter, Highlight, Navigation)** tạo các tương tác giữa các biểu đồ trong dashboard, giúp người dùng khám phá dữ liệu theo nhiều góc nhìn khác nhau.

Ba công cụ phân tích **Calculated Fields, Filters và Parameters** bổ trợ cho nhau: Calculated Fields tạo ra chỉ số, Filters lọc theo chỉ số đó, và Parameters cho phép người dùng thay đổi tiêu chí phân tích một cách linh hoạt. Khi kết hợp với các kỹ thuật thiết kế dashboard và tương tác như **containers, nguyên tắc màu sắc và actions**, bạn có thể xây dựng những dashboard chuyên nghiệp mà bất kỳ ai cũng có thể sử dụng.

Hãy bắt đầu với Calculated Fields công cụ mà hầu như mọi dashboard chuyên nghiệp đều sử dụng.

IV. Calculated Fields nâng cao

IV.1. Tổng quan về Calculated Fields

Calculated Fields (trường tính toán) là cách tạo cột dữ liệu mới bằng cách viết biểu thức trực tiếp trong Tableau. Ở buổi trước, chúng ta đã dùng Calculated Fields cho các tác vụ **preprocessing** : chuyển đổi kiểu dữ liệu, làm sạch chuỗi, xử lý ngày tháng. Nhưng sức mạnh thực sự của Calculated Fields nằm ở khả năng tạo ra những **chỉ số phân tích** (analytics metrics) hoàn toàn mới, những thứ không tồn tại trong dữ liệu gốc nhưng cực kỳ có giá trị cho việc ra quyết định kinh doanh.

Tableau hỗ trợ **2 cách tạo** Calculated Field:

Cách 1: Dùng Calculated Field Editor (phổ biến nhất):

1. Click chuột phải vào vùng trống trong **Data Pane** → chọn **Create Calculated Field...**
2. Hoặc vào menu **Analysis** → **Create Calculated Field**
3. Viết biểu thức trong cửa sổ Editor → nhấn **OK**
4. Field mới xuất hiện trong Data Pane, sẵn sàng để kéo vào view

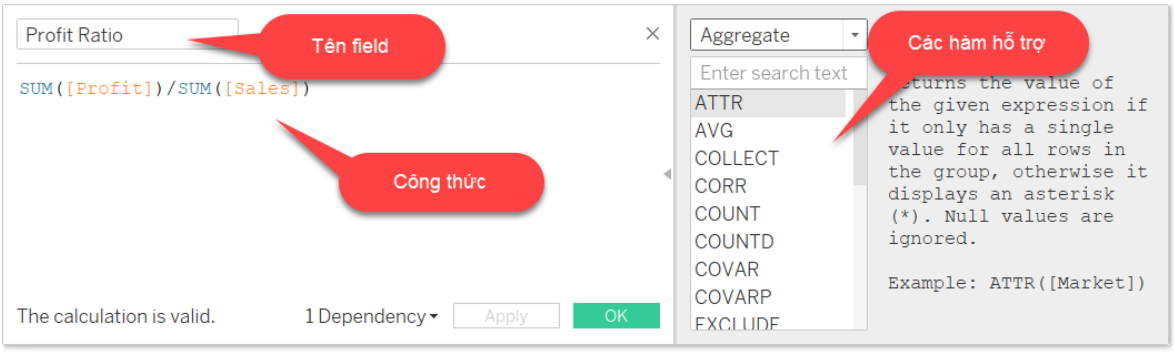

Hình 1: Cửa sổ Calculated Field các thành phần chính gồm: (1) Tên field, (2) vùng soạn công thức, và (3) danh sách hàm hỗ trợ

Cách đọc Formula Editor:

Khi viết công thức trong Calculated Field Editor, Tableau sử dụng các màu sắc khác nhau để giúp bạn nhận biết nhanh các thành phần của biểu thức và phát hiện lỗi cú pháp.

Màu / Ký hiệu	Ý nghĩa
Dòng chữ màu đỏ	Lỗi cú pháp, di chuột qua để xem hướng dẫn sửa
// văn bản màu xám	Comment, không ảnh hưởng tính toán
[text màu cam]	Tên trường dữ liệu
text màu xanh ()	Tên hàm (function)

Khi Editor hiển thị "The calculation contains errors" ở góc dưới, nghĩa là công thức có lỗi và cần chỉnh sửa. Khi hiện "The calculation is valid", bạn đã sẵn sàng nhấn OK.

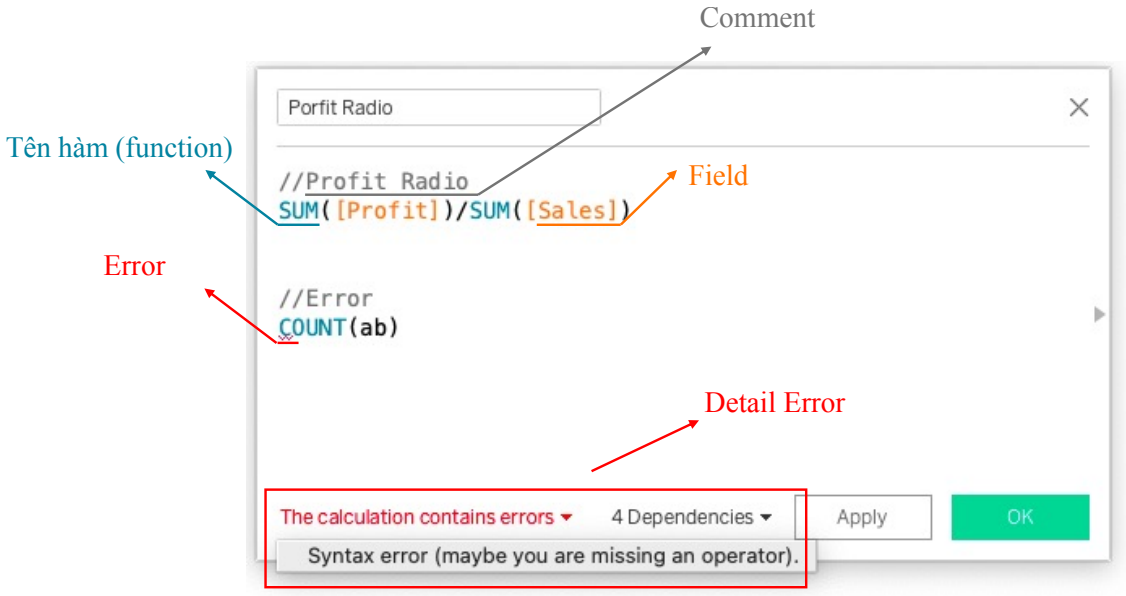

Hình 2: Cách đọc Calculated Field

Cách 2: Ad-hoc Calculation (tính nhanh, không lưu):

Nếu chỉ cần tính nhanh một biểu thức đơn giản, bạn có thể nhập trực tiếp trên **Columns**, **Rows**, hoặc **Marks** mà không cần mở Editor.

Ví dụ: double-click vào Columns shelf → gõ `SUM([Profit])/SUM([Sales])` → nhấn Enter.

Tableau sẽ hiển thị kết quả ngay lập tức. Nếu muốn lưu lại phép tính này, bạn có thể kéo nó vào Data Pane và đặt tên.

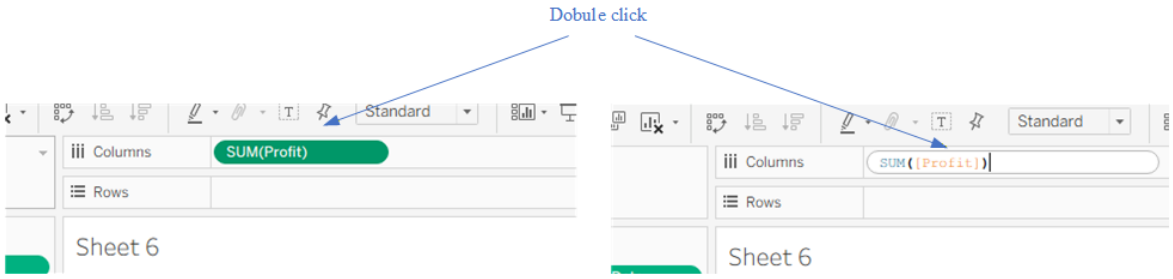

Hình 3: Ad hoc Calculation

IV.2. Row-level vs Aggregate Hai cấp độ tính toán

Tableau phân biệt rõ 2 cấp độ tính toán trong Calculated Fields. Hiểu sai sẽ cho kết quả sai hoàn toàn, nên chúng ta sẽ đi qua ví dụ cụ thể. Giả sử dataset có 4 dòng đơn hàng:

Dòng	Region	Sales	Discount
1	East	200	0.1
2	East	300	0.2
3	West	500	0.15
4	West	100	0.05

- **Row-level (cấp dòng)**: tính trên **từng dòng riêng lẻ**, trước khi Tableau gộp nhóm. Ví dụ: tạo Calculated Field `[Sales] * [Discount]` (giảm giá mỗi đơn):

Dòng	Region	Sales	Discount	Sales * Discount
1	East	200	0.1	**20**
2	East	300	0.2	**60**
3	West	500	0.15	**75**
4	West	100	0.05	**5**

  Mỗi dòng tự tính cho mình dòng 1 chỉ cần Sales=200 và Discount=0.1 của chính nó, không cần biết dòng khác. Dây là **row-level**.

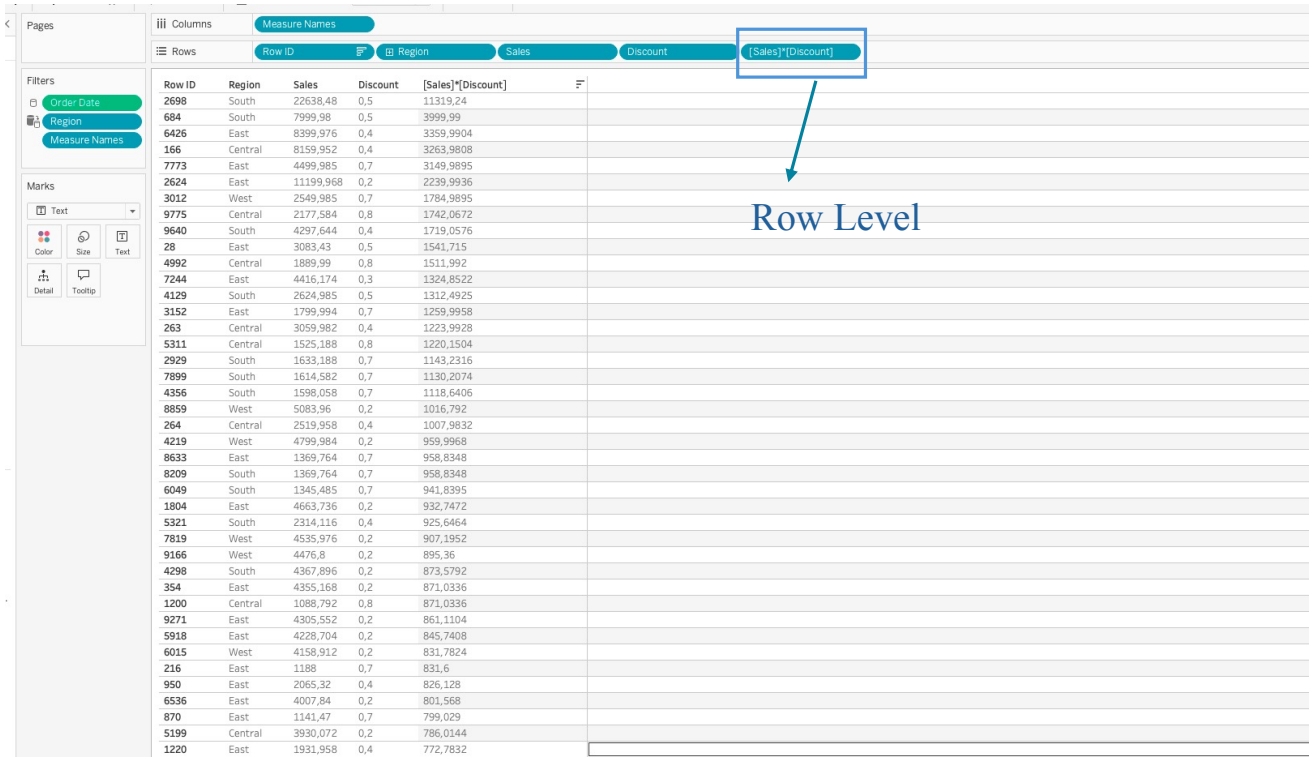

Row ID	Region	Sales	Discount	[Sales]*[Discount]
2698	South	22638,48	0,5	11319,24
684	South	7999,98	0,5	3999,99
6426	East	8399,976	0,4	3359,9904
166	Central	8159,952	0,4	3263,9808
7773	East	4499,985	0,7	3149,9895
2624	East	11199,968	0,2	2239,9936
3012	West	2549,985	0,7	1784,9895
9775	Central	2177,584	0,8	1742,0672
9640	South	4297,644	0,4	1719,0576
28	East	3083,43	0,5	1541,715
4992	Central	1889,99	0,8	1511,992
7244	East	4416,174	0,3	1324,8522
4129	South	2624,985	0,5	1312,4925
3152	East	1799,994	0,7	1259,9958
263	Central	3059,982	0,4	1223,9928
5311	Central	1525,188	0,8	1220,1504
2929	South	1633,188	0,7	1143,2316
7899	South	1614,582	0,7	1130,2074
4356	South	1598,058	0,7	1118,6406
8859	West	5083,96	0,2	1016,792
264	Central	2519,958	0,4	1007,9832
4219	West	4799,984	0,2	959,9968
8633	East	1369,764	0,7	958,8348
8209	South	1369,764	0,7	958,8348
6049	South	1345,485	0,7	941,8395
1804	East	4663,736	0,2	932,7472
5321	South	2314,116	0,4	925,6464
7819	West	4535,976	0,2	907,1952
9166	West	4476,8	0,2	895,36
4298	South	4367,896	0,2	873,5792
354	East	4355,168	0,2	871,0336
1200	Central	1088,792	0,8	871,0336
9271	East	4305,552	0,2	861,1104
5918	East	4228,704	0,2	845,7408
6015	West	4158,912	0,2	831,7824
216	East	1188	0,7	831,6
950	East	2065,32	0,4	826,128
6536	East	4007,84	0,2	801,568
870	East	1141,47	0,7	799,029
5199	Central	3930,072	0,2	786,0144
1220	East	1931,958	0,4	772,7832

Hình 4: Row level Table

- **Aggregate (cấp nhóm)** tính trên **nhóm dòng**, sau khi Tableau gộp theo dimensions trong view:

  Ví dụ: tạo Calculated Field `SUM([Sales]) / COUNT([Sales])` (doanh thu trung bình). Nếu view có Region trên Rows, Tableau gộp thành 2 nhóm rồi mới tính:

Region	Các dòng thuộc nhóm	SUM(Sales) / COUNT(Sales)
East	dòng 1 + dòng 2	(200+300) / 2 = **250**
West	dòng 3 + dòng 4	(500+100) / 2 = **300**

  Kết quả phụ thuộc vào **dimensions trong view**: nếu bỏ Region ra khỏi view, Tableau gộp cả 4 dòng thành 1 nhóm → kết quả: (200+300+500+100) / 4 = 275. Nếu thêm Sub-Category vào view, Tableau chia thành nhiều nhóm nhỏ hơn → kết quả khác nữa.

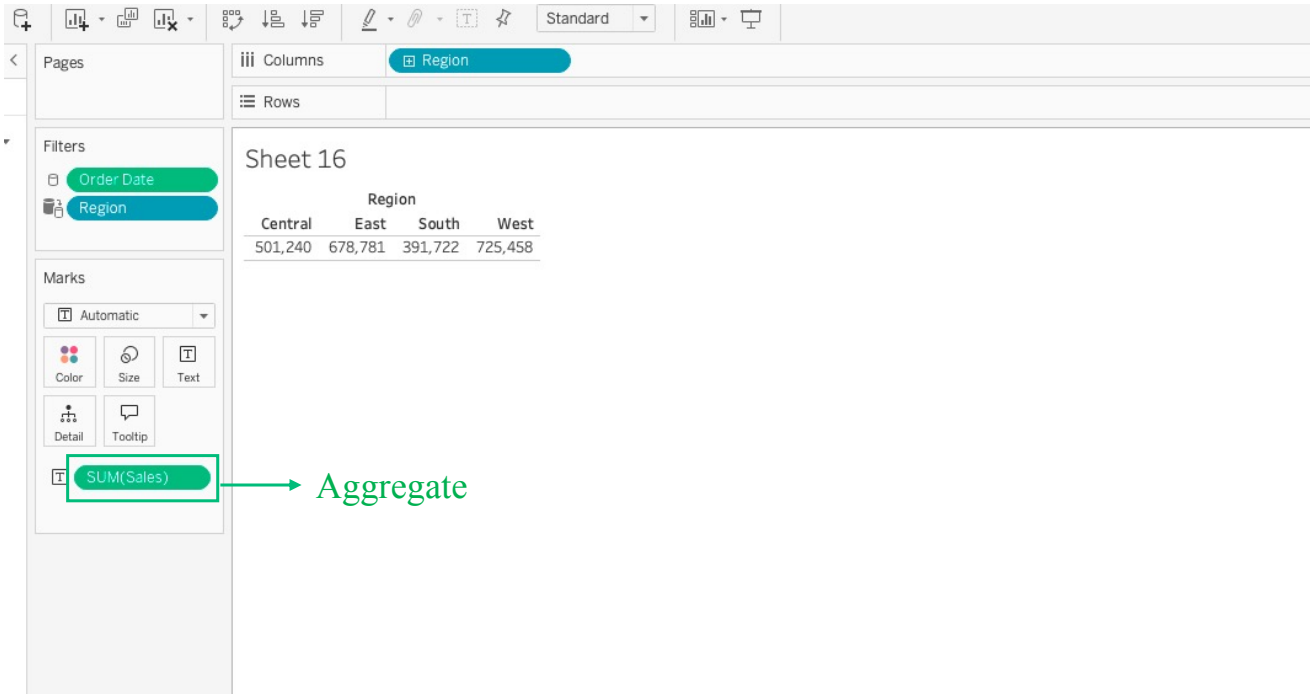

Hình 5: Aggregate level Table

	Row-level	**Aggregate**
Tính khi nào	Trước khi gộp nhóm	Sau khi gộp nhóm
Cần gì	Chỉ thông tin từ 1 dòng	Thông tin từ nhiều dòng
Kết quả đổi khi đổi view?	Không giá trị mỗi dòng cố định	Có phụ thuộc dimensions trong view
Nhận biết	Không có hàm `SUM`, `AVG`...	Có hàm `SUM()`, `AVG()`, `COUNT()`...
Ví dụ	`[Sales] * 0.1`, `DATEDIFF(...)`	`SUM([Sales])`, `AVG([Profit])`

Lỗi thường gặp 'Cannot mix aggregate and non-aggregate":

Khi bạn trộn lẫn 2 cấp trong cùng công thức, Tableau không biết xử lý thế nào và báo lỗi. Ví dụ:

```
// Lỗi: SUM là aggregate, [Discount] là row-level
SUM([Sales]) * [Discount]
```

Tableau không thể nhân tổng doanh thu cả nhóm (1 giá trị) với Discount từng dòng (nhiều giá trị). Giải pháp đưa về cùng cấp:

```
// Cách 1: cả hai đều aggregate
SUM([Sales]) * AVG([Discount])

// Cách 2: cả hai đều row-level
[Sales] * [Discount]
```

Cách 1 cho kết quả "tổng doanh thu × discount trung bình" (1 giá trị cho mỗi nhóm).

Cách 2 cho "doanh thu × discount từng dòng" (1 giá trị cho mỗi dòng, Tableau tự SUM khi hiển thị).

Nhận biết cấp độ trên view

Khi kéo Calculated Field vào view, hãy nhìn trên shelf:

- Nếu hiển thị `SUM(...)` hoặc `AVG(...)` thì Tableau đang **aggregate**.
- Nếu hiển thị tên field trực tiếp (không có hàm bao quanh) thì đó là **row-level**.

Bạn cũng có thể click vào field → chọn `Measure` để thay đổi kiểu aggregate mặc định.

IV.3. Các hàm Aggregation thường dùng

Khi viết Calculated Fields ở cấp aggregate, bạn sẽ dùng các hàm tổng hợp. Bảng dưới đây tóm tắt những hàm phổ biến nhất cùng ví dụ thực tế trên dataset Superstore:

Hàm	Ý nghĩa	Ví dụ	Khi nào dùng
`SUM()`	Tổng tất cả giá trị	`SUM([Sales])` → tổng doanh thu	So sánh tổng giữa các nhóm
`AVG()`	Trung bình cộng	`AVG([Profit])` → lợi nhuận TB	Đánh giá mức trung bình
`MIN()`	Giá trị nhỏ nhất	`MIN([Order Date])` → ngày đầu	Tìm giá trị cực tiểu
`MAX()`	Giá trị lớn nhất	`MAX([Order Date])` → ngày cuối	Tìm giá trị cực đại
`COUNT()`	Đếm số dòng	`COUNT([Order ID])` → tổng số đơn	Đếm bản ghi (có trùng)
`COUNTD()`	Đếm giá trị duy nhất	`COUNTD([Customer ID])` → số KH	Đếm không trùng

Lưu ý

COUNTD chậm với dữ liệu lớn. Hàm `COUNTD()` (Count Distinct) phải quét và so sánh từng giá trị để loại trùng, nên tốn tài nguyên hơn `COUNT()` đáng kể. Với dataset lớn (hàng triệu dòng), nên cân nhắc dùng `COUNT()` kết hợp với cách tổ chức dữ liệu hợp lý thay vì dùng `COUNTD()` ở nhiều nơi.

IV.4. LOD Expressions

LOD (Level of Detail) Expressions là tính năng nâng cao nhưng cực kỳ mạnh mẽ và cũng là chủ đề phức tạp nhất trong buổi học này. Đừng lo nếu chưa hiểu ngay lần đầu chúng ta sẽ bắt đầu với loại phổ biến nhất (FIXED) rồi mới đến INCLUDE và EXCLUDE.

Bình thường, khi bạn viết `SUM([Sales])`, Tableau tự động tính tổng theo các dimensions có trong view (ví dụ: nếu view có Region, Tableau tính SUM cho từng Region). LOD cho phép bạn **bỏ qua** mức chi tiết đang hiển thị và tính ở mức bạn muốn.

Ví dụ đơn giản: bạn muốn biết tổng doanh thu của **mỗi khách hàng**, bất kể view đang hiển thị theo Region hay Category. Với cách thông thường, bạn phải kéo Customer Name vào view. Với LOD, chỉ cần viết:

```
{ FIXED [Customer Name] : SUM([Sales]) }
```

Công thức này nói: "Tính tổng doanh thu, nhóm theo Customer Name, bất kể view đang hiển thị gì."

Tableau có **3 loại LOD**, mỗi loại phục vụ mục đích khác nhau:

Loại	Cú pháp	Ý nghĩa	Ví dụ
FIXED	`{ FIXED [Dim] : AGG() }`	Tính toán ở **mức chi tiết được chỉ định, không phụ thuộc view hiện tại**	`{ FIXED [Region] : SUM([Sales]) }`
INCLUDE	`{ INCLUDE [Dim] : AGG() }`	**Thêm dimension vào mức chi tiết của view** rồi mới tính toán	`{ INCLUDE [Category] : AVG([Profit]) }`
EXCLUDE	`{ EXCLUDE [Dim] : AGG() }`	**Loại bỏ dimension khỏi mức chi tiết của view** rồi mới tính toán	`{ EXCLUDE [Region] : SUM([Sales]) }`

Đề làm rõ hơn ý nghĩa và các tính của từng loại LOD ta sẽ đi qua các ví dụ sau:

- **NO LOD và FIXED LOD:**

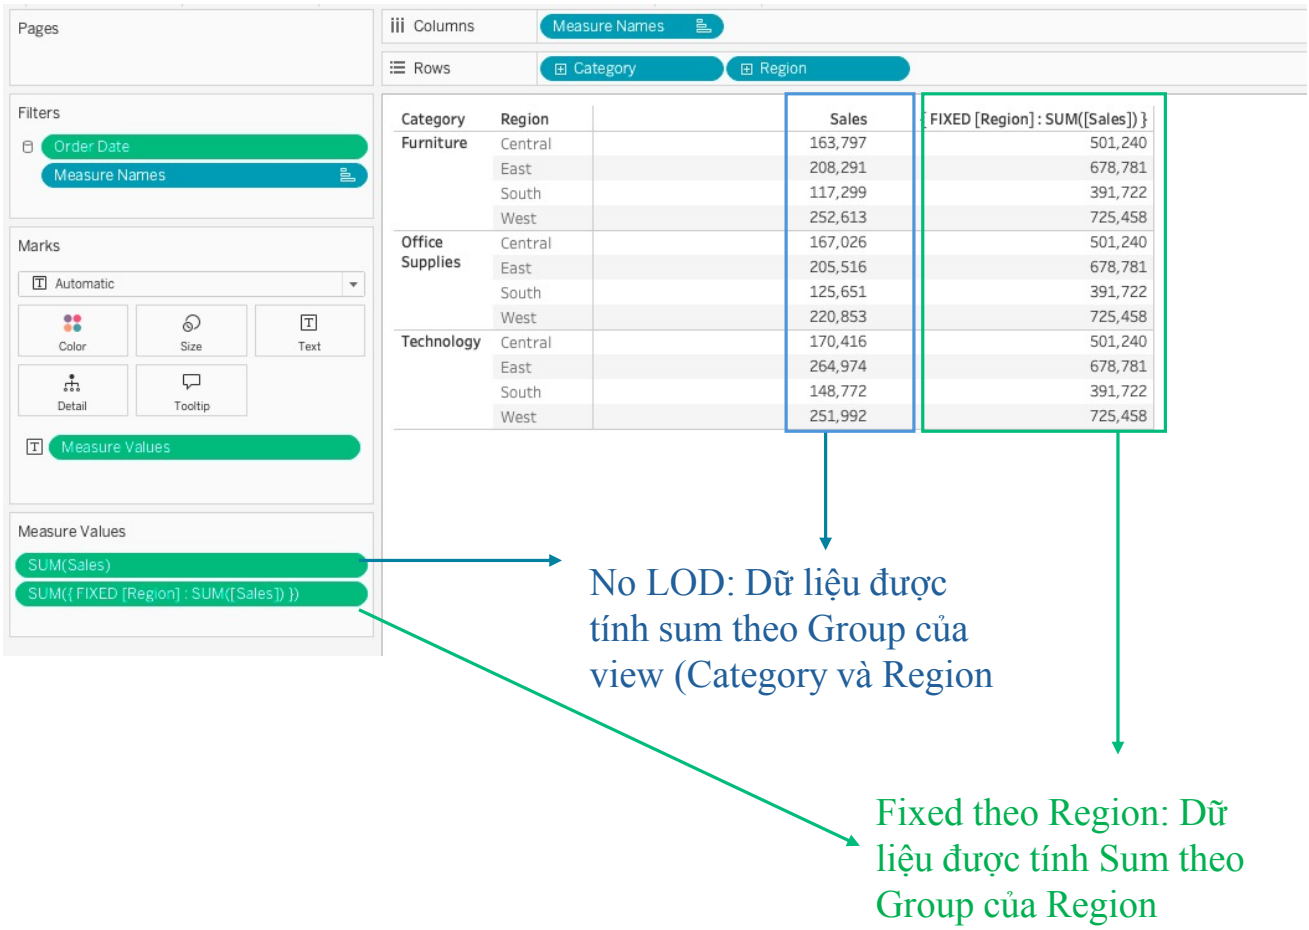

Hình 6: So sánh không có LOD và FIXED

- **FIXED và EXCLUDE:**

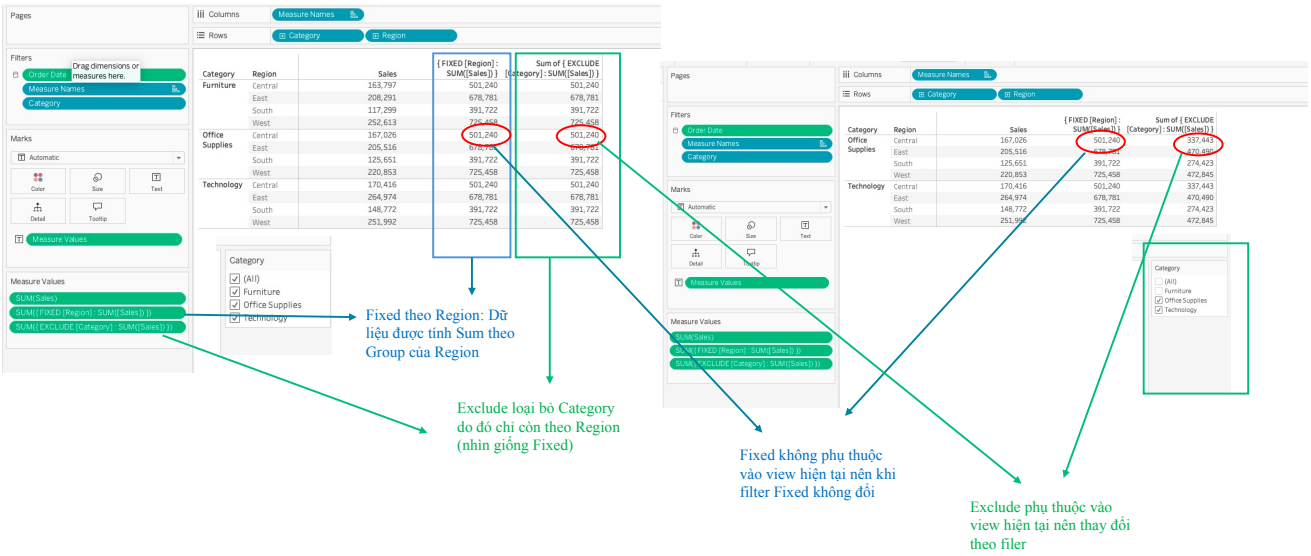

Hình 7: So sánh FIXED và EXCLUDE

- **INCLUDE:**

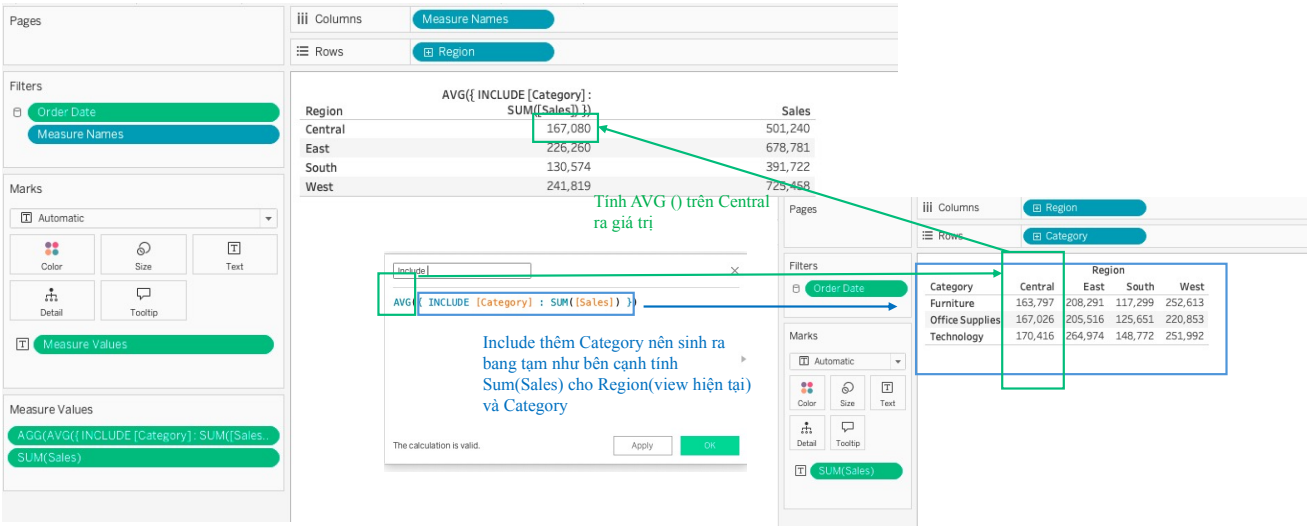

Hình 8: INCLUDE LOD

Tạo LOD nhanh bằng Ctrl+Drag

Từ phiên bản mới, bạn có thể tạo FIXED LOD nhanh mà không cần mở Editor: giữ phím **Ctrl** rồi kéo một measure lên trên một dimension. Ví dụ: giữ Ctrl, kéo **Balance** thả vào **Portfolio** → Tableau tự tạo calculated field `{ FIXED [Portfolio] : SUM([Balance]) }`.

Lưu ý

FIXED LOD và Filters. FIXED LOD được tính toán **trước** Dimension Filters trong Order of Operations của Tableau. Nghĩa là nếu bạn lọc Region = "East", FIXED LOD vẫn tính trên **toàn bộ** dữ liệu (bao gồm cả West, Central, South). Muốn FIXED LOD bị ảnh hưởng bởi filter, bạn cần đặt filter đó làm **Context Filter** (sẽ học ở phần III).

V. Filters

V.1. Tại sao cần Filters?

Khi làm việc với dataset có hàng chục nghìn dòng như Superstore, hiển thị tất cả dữ liệu cùng lúc sẽ tạo biểu đồ rối mắt, chậm, và khó rút ra insight. Filters giúp bạn ẩn hoặc hiện dữ liệu chỉ giữ lại phần quan trọng.

Nhưng filters trong Tableau không đơn giản chỉ là ẩn dữ liệu. Mỗi loại filter hoạt động ở **giai đoạn khác nhau** trong quá trình tính toán‹››, ảnh hưởng đến hiệu năng và kết quả theo cách khác nhau.

V.2. Các loại Filters trong Tableau

Tableau có **6 loại filters chính**, được áp dụng theo thứ tự sau:

#	Loại Filter	Giai đoạn trong pipeline dữ liệu	Mô tả
1	**Extract Filter**	Khi tạo **Extract (.hyper)** từ database	Chỉ các dòng thỏa điều kiện mới được lưu vào file extract. Những dòng bị loại sẽ không còn tồn tại trong dữ liệu của Tableau.
2	**Data Source Filter**	Sau khi kết nối dữ liệu, trước khi workbook sử dụng	Lọc dữ liệu ở cấp **data source**, áp dụng cho tất cả worksheet sử dụng nguồn dữ liệu này.
3	**Context Filter**	Trước các **dimension filter**	Tạo một **tập dữ liệu tạm (subset)**. Các filter phía sau sẽ được áp dụng trên tập dữ liệu này.
4	**Dimension Filter**	Trước bước **aggregation**	Lọc theo các dimension như Category, Region hoặc Customer.
5	**Measure Filter**	Sau khi dữ liệu đã được **aggregate**	Lọc dựa trên giá trị tổng hợp như `SUM(Sales)` hoặc `AVG(Profit)`.
6	**Table Calculation Filter**	Sau khi **table calculation** được tính	Chỉ ẩn kết quả hiển thị trên biểu đồ, dữ liệu vẫn được dùng trong các phép tính trước đó.

Bảng 1: Thứ tự thực thi Filter trong Tableau (Order of Operations)

Filters ở **vị trí sớm hơn** sẽ loại bỏ dữ liệu trước khi Tableau tính toán → hiệu năng tốt hơn.

V.3. Cách tạo Filter

Có 2 cách tạo filter phổ biến:

Cách 1: Kéo thả (thường hay dùng nhất):

1. Trong **Data Pane**, kéo field vào khung **Filters** (bên trái view)
2. Tableau hiện hộp thoại filter: Dimension → checkbox, Measure → range
3. Chọn giá trị cần lọc → **OK**

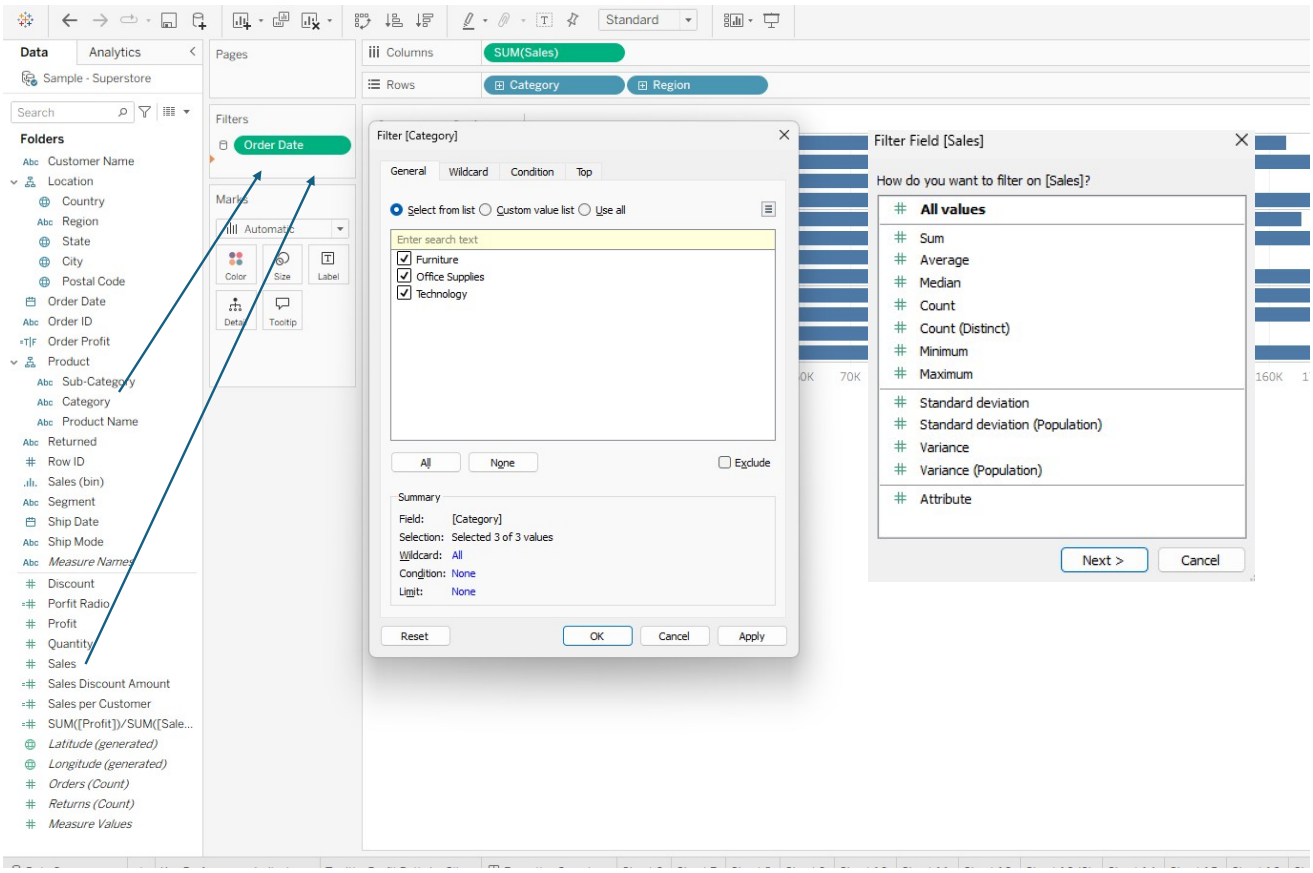

Hình 9: Create Filter

Cách 2 cick chuột phải (hiện filter control):

1. Click chuột phải vào field trong **Data Pane** hoặc trên view
2. Chọn **Show Filter**
3. Filter hiện dưới dạng control (dropdown, slider, checkbox...) ở bên phải view

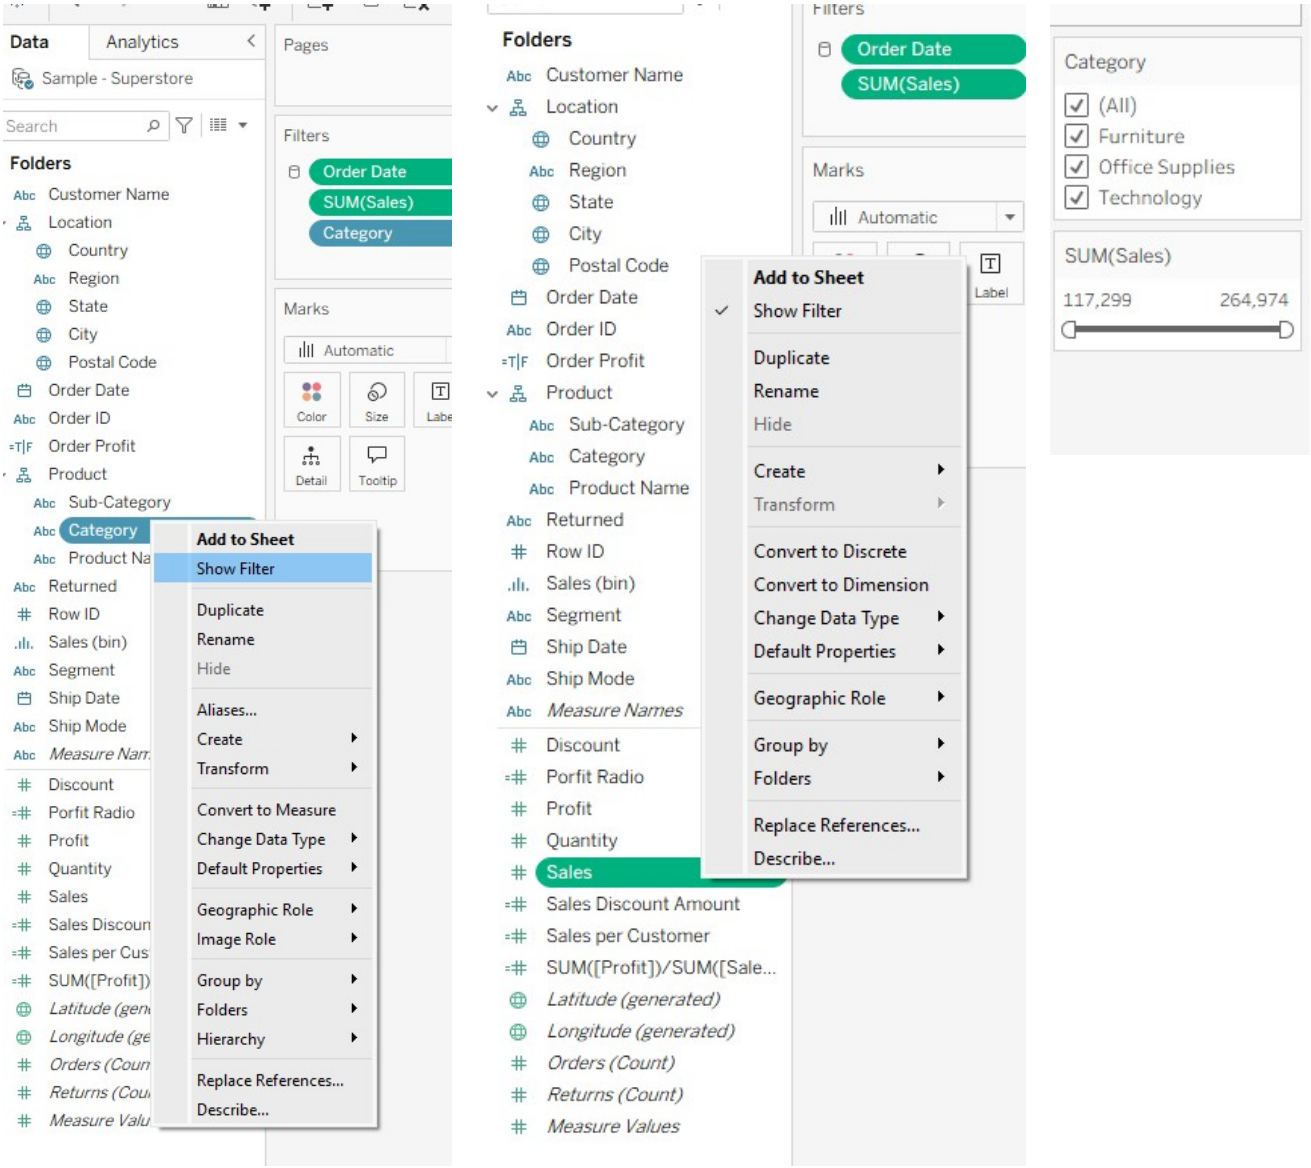

Hình 10: Create Filter by Right Click

V.4. Dimension Filters

Dimension Filters lọc theo các giá trị phân loại vis dụ Region, Category, Customer Name, Ship Mode... Khi kéo dimension vào Filters shelf, Tableau hiện hộp thoại với 4 tab:

Tab	Mô tả	Ví dụ
General	Chọn/bỏ giá trị cụ thể	Chọn East và West, bỏ Central và South
Wildcard	Lọc theo mẫu text	Khách hàng tên bắt đầu bằng "John"
Condition	Lọc theo điều kiện logic	Category có SUM(Sales) $>$ 500,000
Top	Lọc top/bottom N theo measure	Top 10 sản phẩm theo doanh thu

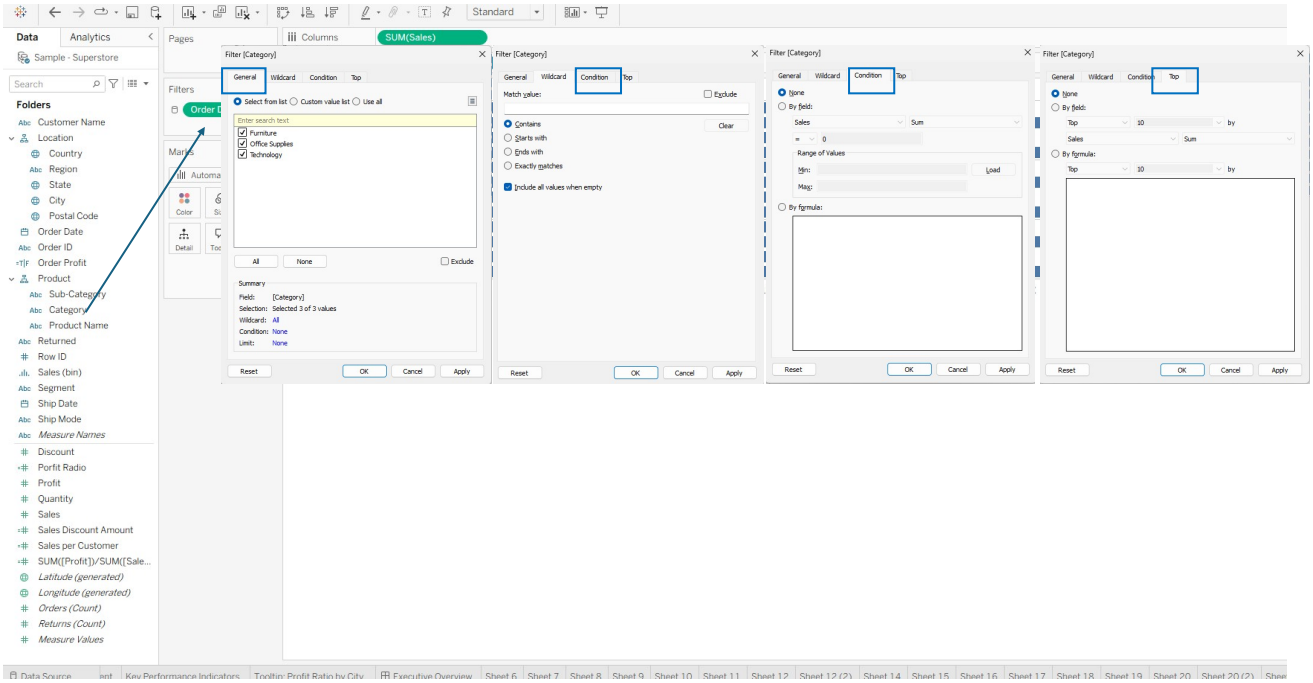

Hình 11: Dimension Filters

Bạn cũng có thể tạo Calculated Field làm dimension filter linh hoạt hơn:

```
// Tạo Calculated Field boolean
[Region] = "East" OR [Region] = "West"
```

Kéo field này vào Filters → chọn **True** → kết quả tương tự.

V.5. Measure Filters

Measure Filters lọc dựa trên giá trị số **đã aggregate**. Khi kéo measure vào Filters, Tableau yêu cầu chọn kiểu aggregation trước (SUM, AVG...), rồi mới chọn cách lọc.

Các tùy chọn lọc measure:

- **Range of values**: giá trị từ X đến Y
- **At least**: giá trị $\geq$ X
- **At most**: giá trị $\leq$ X
- **Special**: xử lý NULL values (bao gồm / loại trừ NULL)

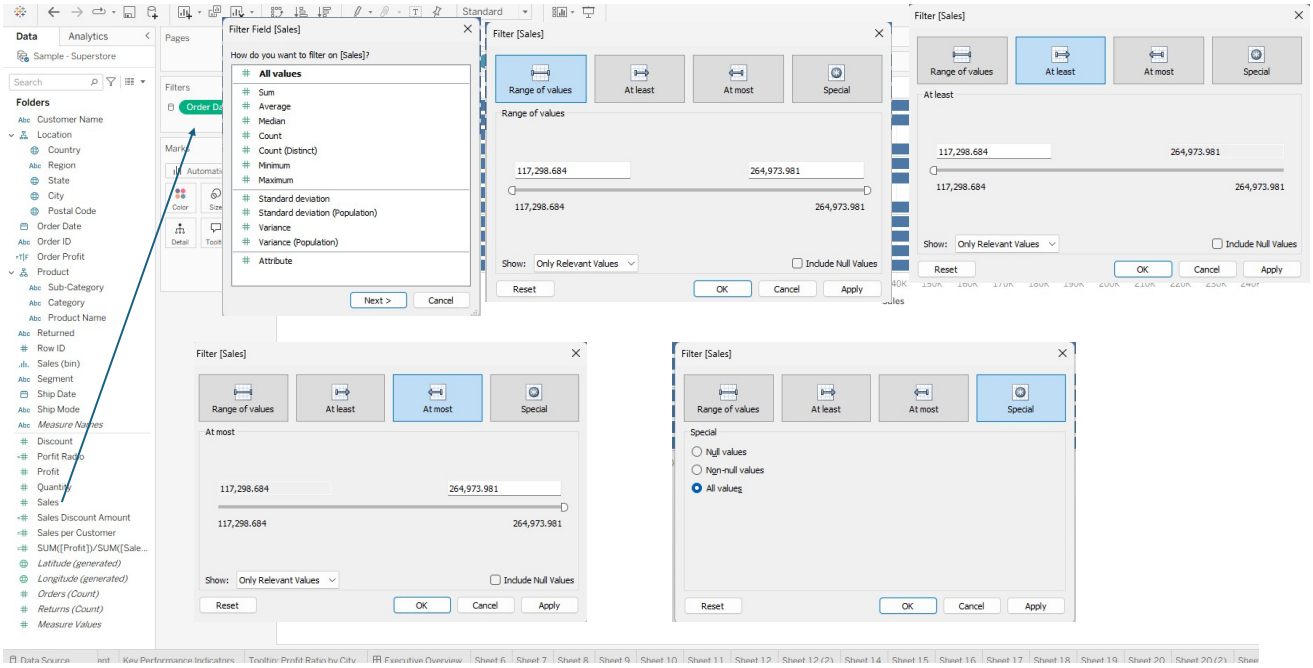

Hình 12: Measure Filters

V.6. Context Filters

Context Filter là loại filter đặc biệt. Khi bạn đánh dấu một filter là "Add to Context", nó sẽ chạy **trước** tất cả dimension filters, measure filters, và FIXED LOD.

Ví dụ: Filter Top 10 trong năm 2024:

Bạn muốn tìm top 10 sản phẩm có doanh thu cao nhất **trong năm 2024**. Nếu làm cách thông thường:

1. Kéo **Year([Order Date])** vào Filters → chọn 2024
2. Kéo **Product Name** vào Filters → tab **Top** → Top 10 by SUM(Sales)

Vấn đề: Tableau tính top 10 toàn bộ rồi mới lọc năm 2024 (vì cả hai đều là dimension filters, chạy cùng bước). Kết quả sai.

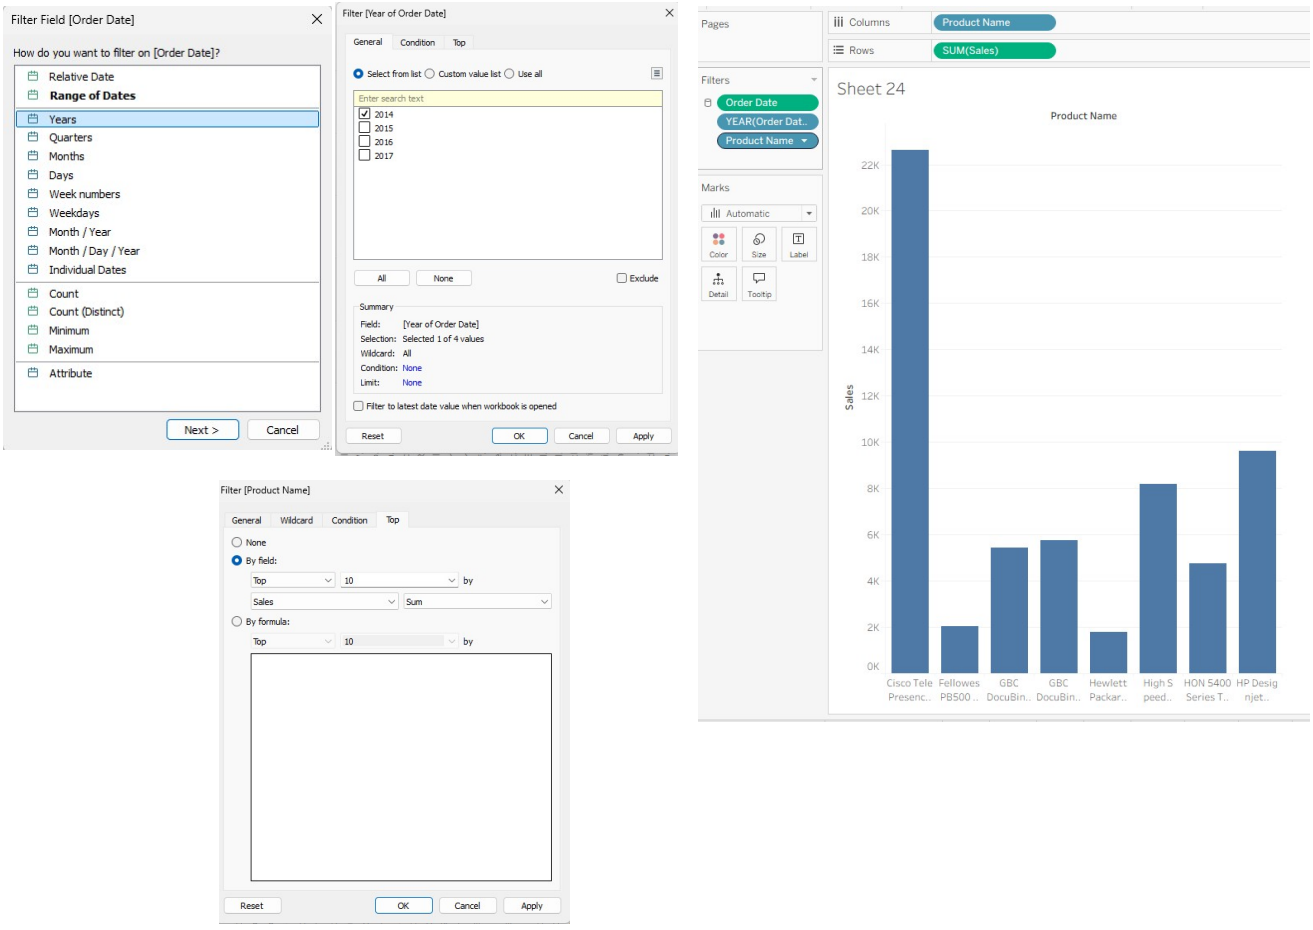

Hình 13: Filter Not Context

Giải pháp: Đặt Year filter làm Context Filter:

1. Click chuột phải vào filter **Year** trong Filters shelf
2. Chọn **Add to Context**
3. Filter chuyển sang **màu xám đậm**

Bây giờ Tableau lọc năm 2024 **trước** (bước 3), rồi mới tính top 10 (bước 4). Kết quả đúng.

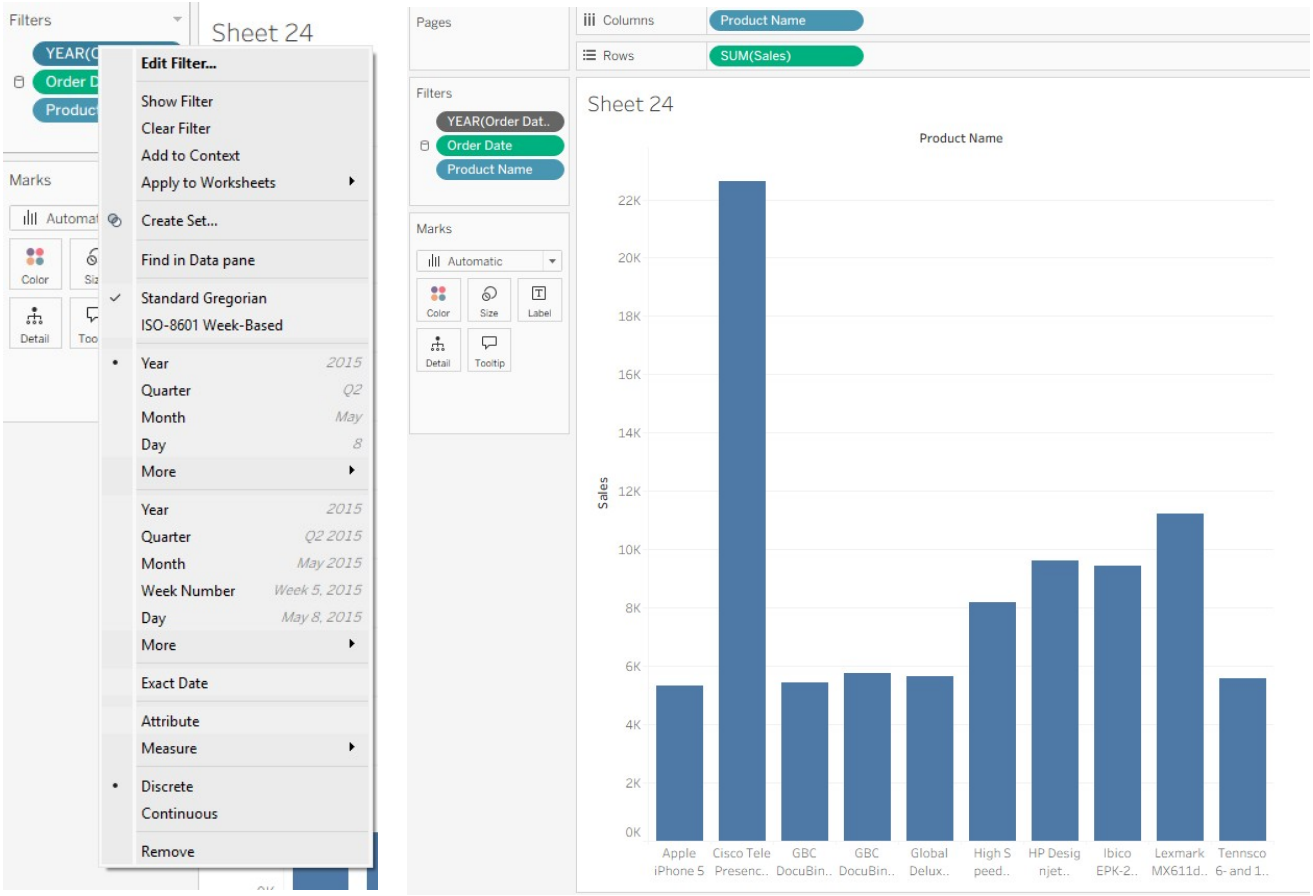

Hình 14: Filter With Context

Khi nào dùng Context Filter?

Dùng Context Filter khi bạn cần một filter chạy **trước** các filter khác. Hai trường hợp phổ biến nhất: (1) Top N kết hợp với filter khác, (2) muốn FIXED LOD bị ảnh hưởng bởi filter.

V.7. Hiển thị Filter Cards trên Dashboard

Sau khi tạo filter, bạn có thể hiển thị nó dưới dạng control tương tác:

1. Click chuột phải vào filter trong Filters shelf
2. Chọn **Show Filter**
3. Thay đổi kiểu hiển thị: click vào mũi tên bên cạnh filter card → chọn kiểu (Single Value Dropdown, Multiple Values List, Slider...)

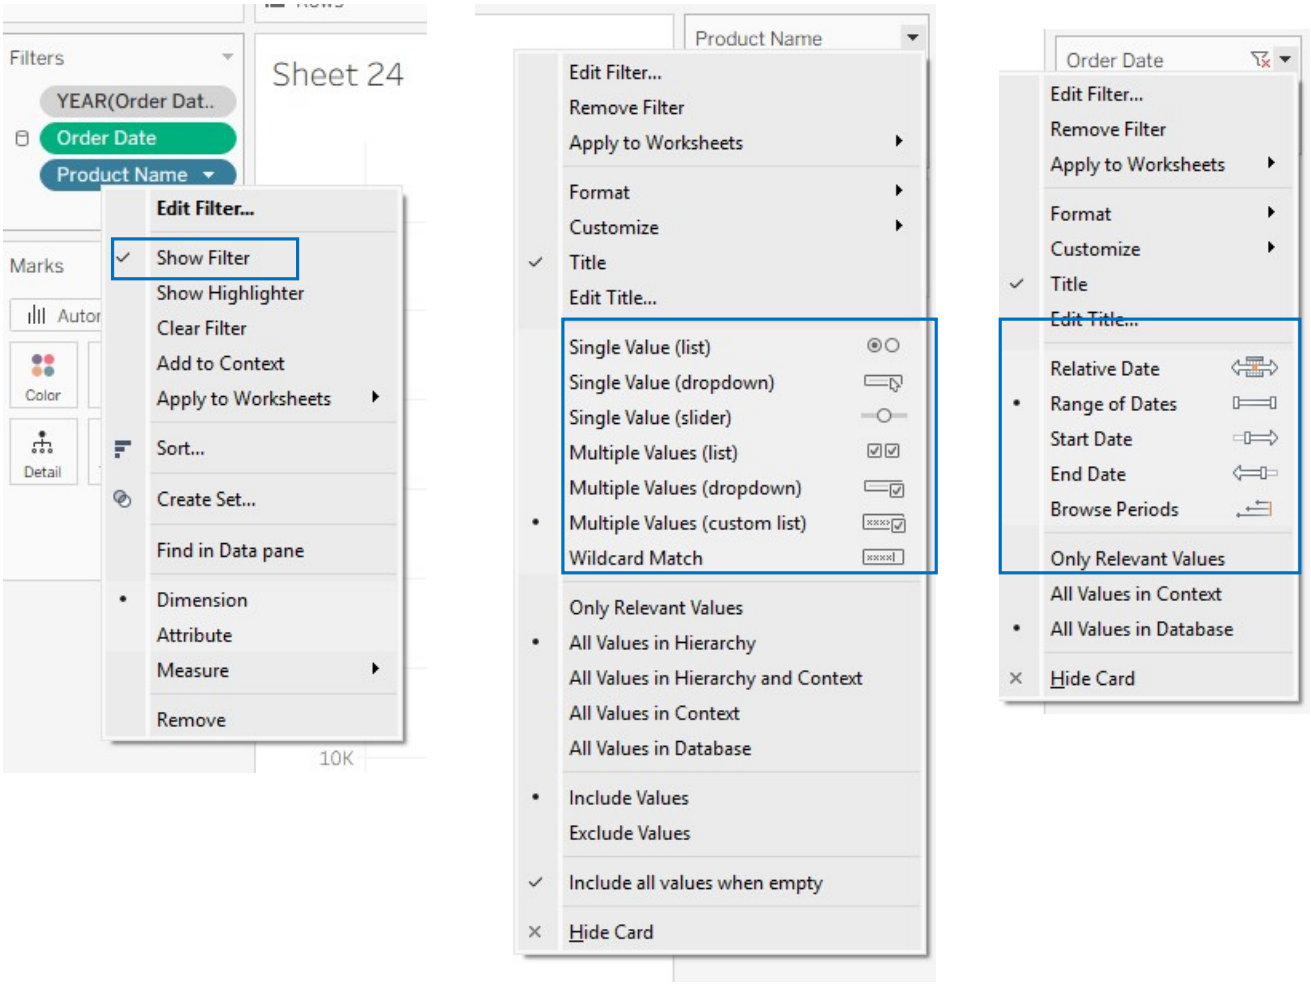

Hình 15: Show and edit Filter Card

V.8. Apply to Worksheets

Mặc định, mỗi filter chỉ ảnh hưởng worksheet hiện tại. Để filter áp dụng cho nhiều sheet:

1. Click chuột phải vào filter pill → **Apply to Worksheets**
2. Chọn: **Only This Worksheet** (mặc định), **Selected Worksheets...**, **All Using This Data Source**, hoặc **All Using Related Data Sources**

Đây là bước quan trọng khi xây dựng dashboard, nếu quên thiết lập, người dùng chọn filter trên một chart nhưng chart khác không thay đổi theo.

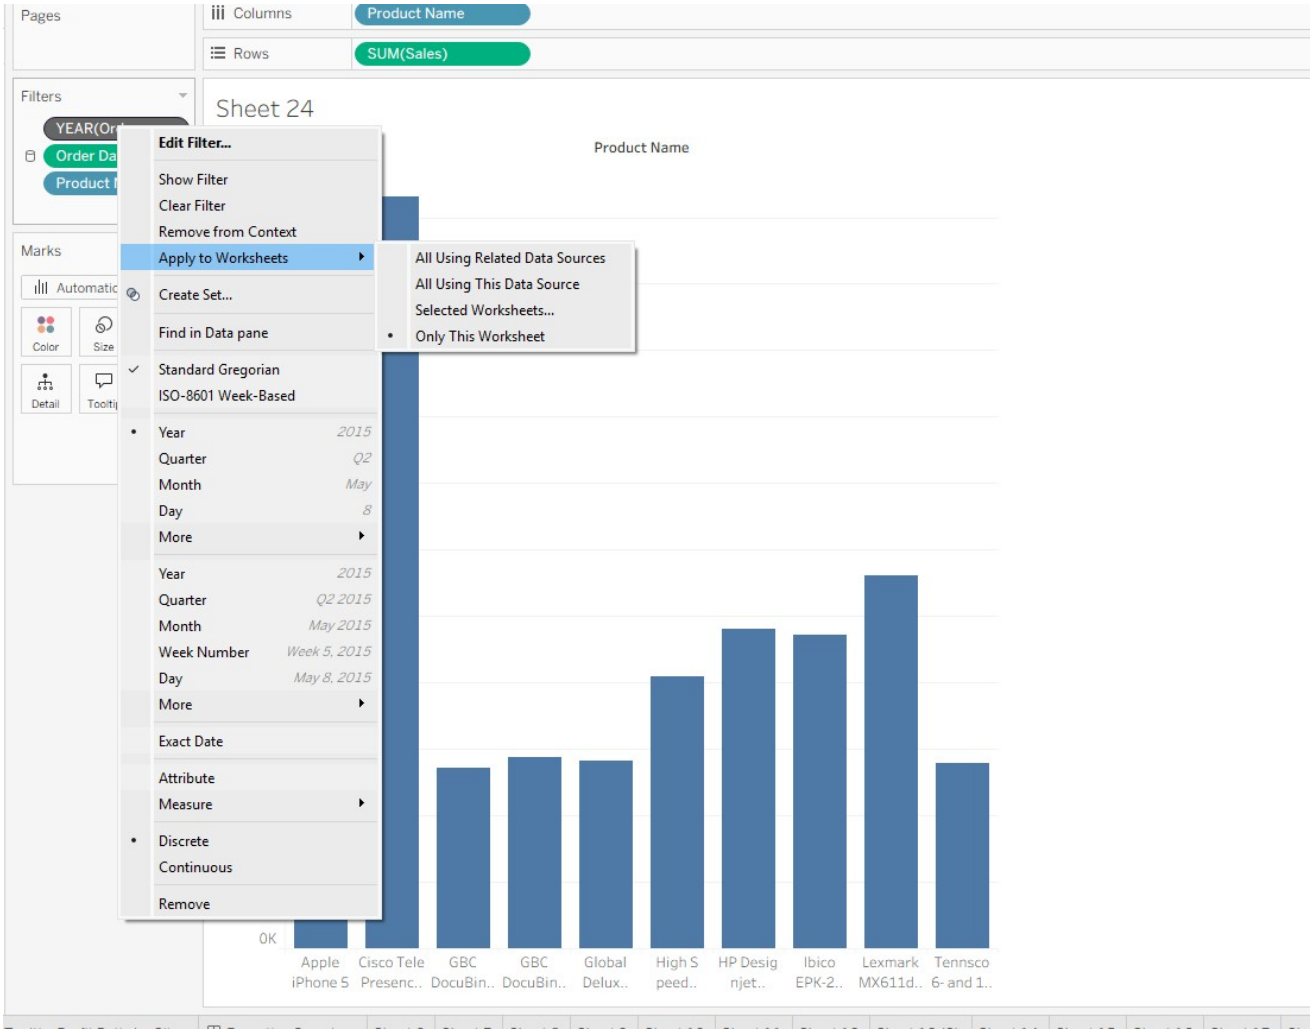

Hình 16: Apply Filter All Worksheets

VI. Parameters

VI.1. Parameters là gì?

Parameters (tham số) là giá trị động mà user nhập vào, có thể là một con số, một chuỗi, hay một ngày. Khác với Filters lấy dữ liệu từ dataset, Parameters hoàn toàn do user kiểm soát.

Nói cách khác: **Filters** trả lời "Hiện dữ liệu nào?", còn **Parameters** trả lời "Hiển thị theo cách nào?". Filters giới hạn dữ liệu, Parameters thay đổi logic phân tích.

VI.2. Cách tạo Parameter

Cách 1 Từ Data Pane:

1. Click chuột phải vào vùng trống trong **Data Pane** → **Create Parameter...**
2. Đặt tên, chọn kiểu dữ liệu, đặt giá trị mặc định
3. Cấu hình **Allowable values**: **All** (nhập bất kỳ), **List** (chọn từ danh sách), **Range** (khoảng min–max)
4. Click **OK**

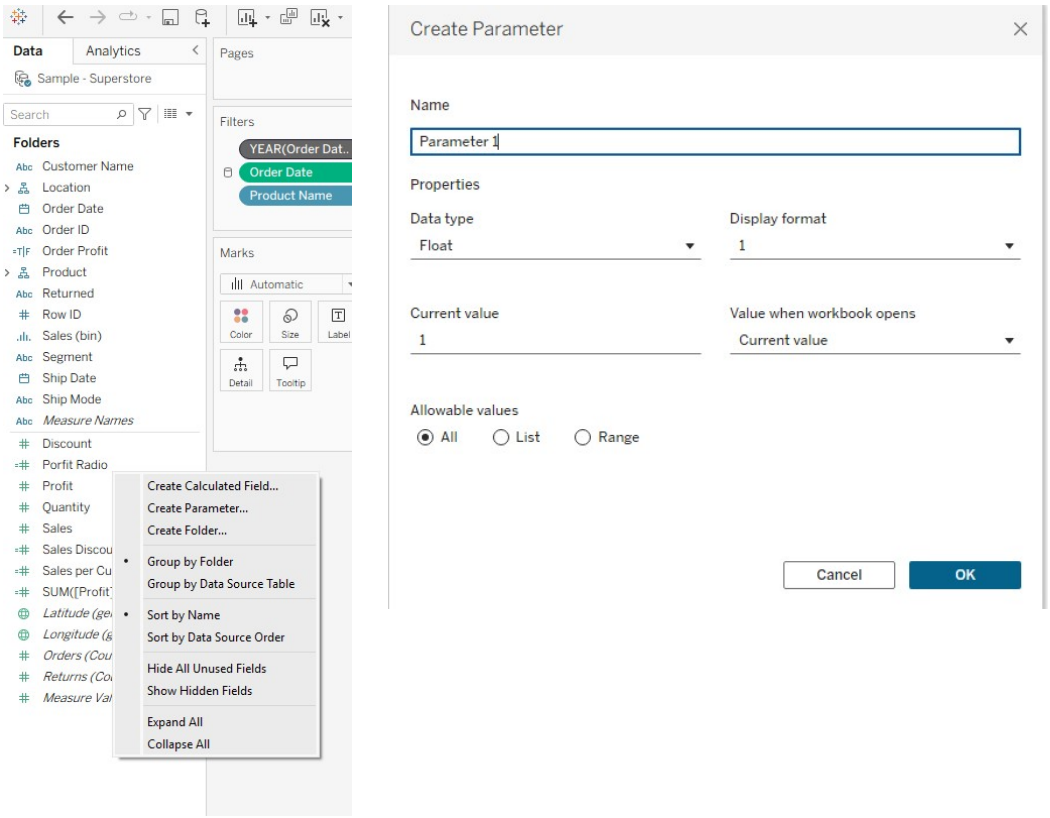

Hình 17: Create Parameter

Cách 2 Từ field có sẵn: Click chuột phải vào field → **Create** → **Parameter...** Tableau tự điền danh sách giá trị.

VI.3. Kiểu dữ liệu của Parameter

Kiểu	Mô tả	Ví dụ sử dụng
Integer	Số nguyên	Số lượng Top N (5, 10, 20)
Float	Số thập phân	Ngưỡng tỷ lệ tăng trưởng (0.05)
String	Chuỗi văn bản	Tên region, tên measure
Boolean	True/False	Bật/tắt reference line
Date	Ngày	Ngày bắt đầu / kết thúc kỳ phân tích
Date & Time	Ngày + Giờ	Thời điểm cụ thể (ít dùng)

VI.4. Dùng Parameter trong Calculated Field

Tạo parameter xong mới chỉ là bước đầu bạn cần **dùng nó trong Calculated Field** để tạo logic động.

VI.5. Hiển thị Parameter Control

1. Click chuột phải vào parameter trong Data Pane → **Show Parameter Control**
2. Kiểu hiển thị: **All/Range** → text box hoặc slider; **List** → dropdown hoặc radio buttons

VI.6. Ví dụ Interactive Bar Chart

Để hiểu rõ hơn cách **Parameter** hoạt động trong Tableau, ta sẽ đi qua một ví dụ đơn giản. Trong ví dụ này, người dùng có thể thay đổi metric hiển thị và số lượng đối tượng trên biểu đồ thông qua các parameter. Khi parameter thay đổi, biểu đồ sẽ tự động cập nhật theo logic được định nghĩa trong *Calculated Field*. Biểu đồ sử dụng hai parameter:

- **Select Measure**: chọn metric hiển thị
- **Top N**: chọn số lượng Sub-Category hiển thị

Cấu trúc biểu đồ

- Rows: Sub-Category
- Columns: Dynamic Measure
- Marks: Bar

Bước 1: Tạo parameter Select Measure

1. Trong *Data Pane* → **Create Parameter**.
2. Name: `Select Measure`
3. Data Type: `String`
4. Allowable Values: `List`
5. Values: `Sales, Profit, Quantity`
6. Click **OK** và chọn **Show Parameter**.

Bước 2: Tạo Calculated Field

```
// Calculated Field: Dynamic Measure
CASE [Select Measure]
WHEN "Sales" THEN SUM([Sales])
WHEN "Profit" THEN SUM([Profit])
WHEN "Quantity" THEN SUM([Quantity])
END
```

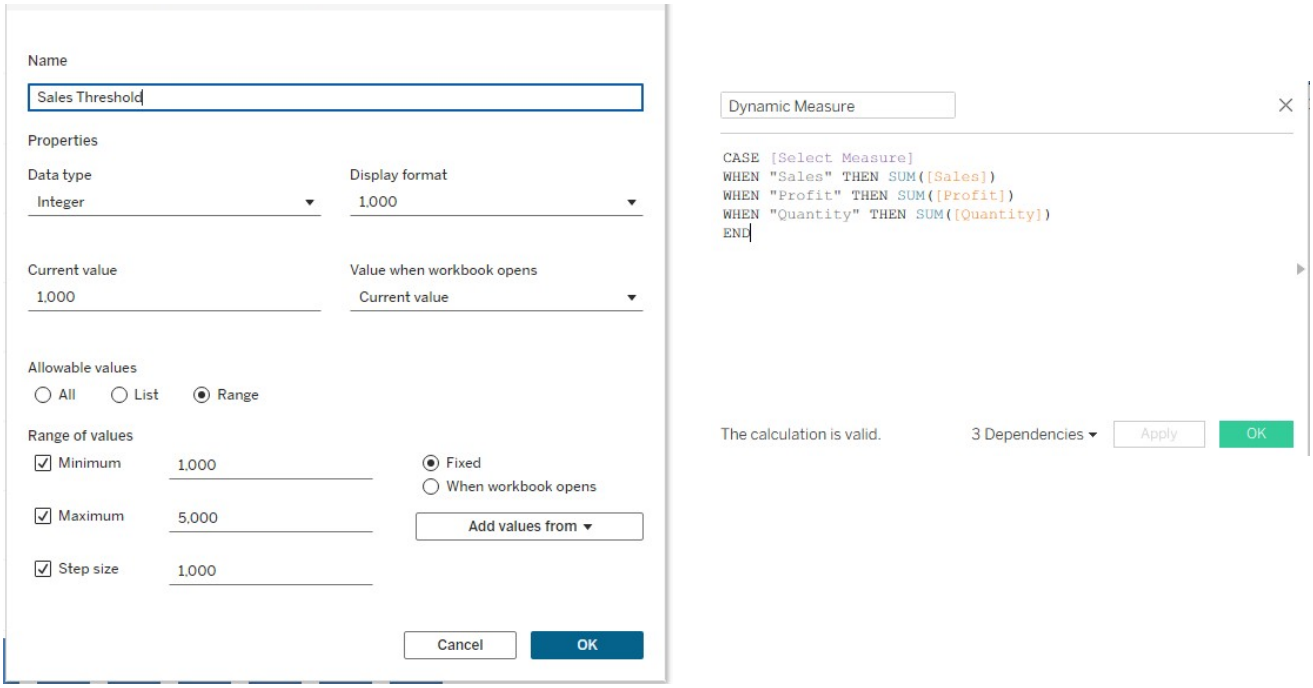

Hình 18: Create Parameter Measure and Field Dynamic Mesure

Bước 3: Tạo parameter Top N

1. Trong *Data Pane* → **Create Parameter**.
2. Name: `Top N`
3. Data Type: `Integer`
4. Current Value: `10`
5. Allowable Values: `Range (1-20)`
6. Click **OK** và chọn **Show Parameter**.

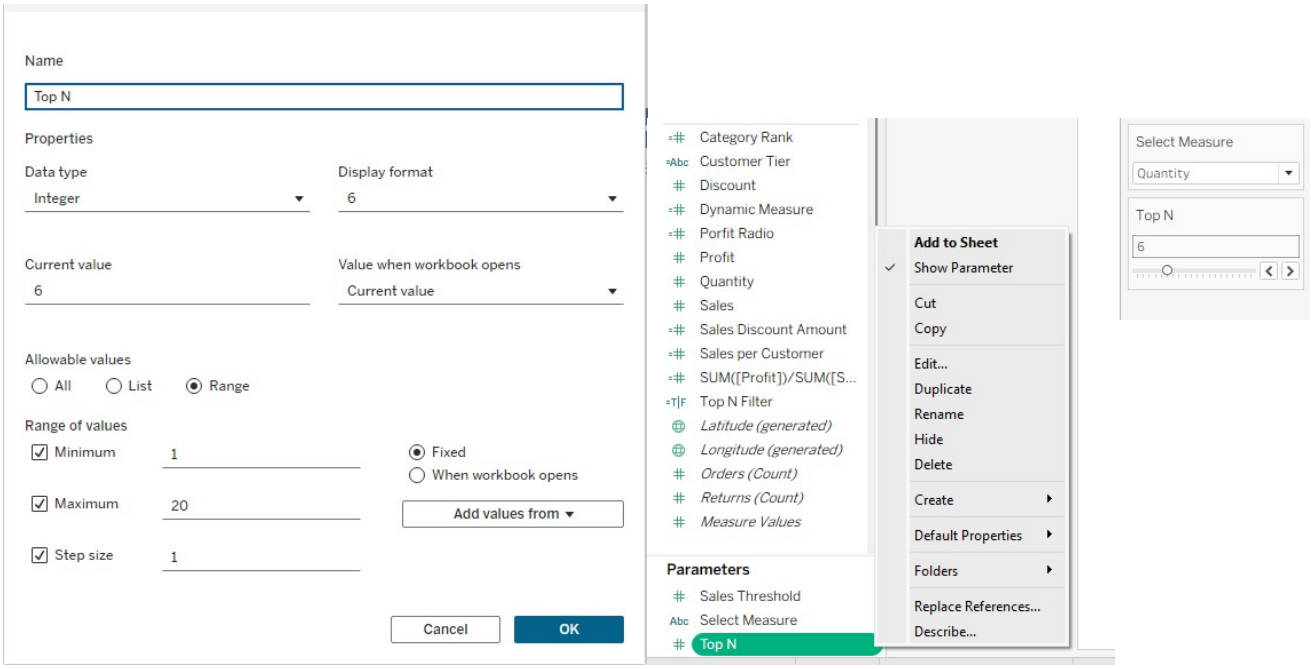

Hình 19: Create Parameter TopN

Bước 4: Tạo filter

```
// Calculated Field: Top N Filter
INDEX() <= [Top N]
```

Sau đó kéo `Top N Filter` vào **Filters** và chọn `True`.

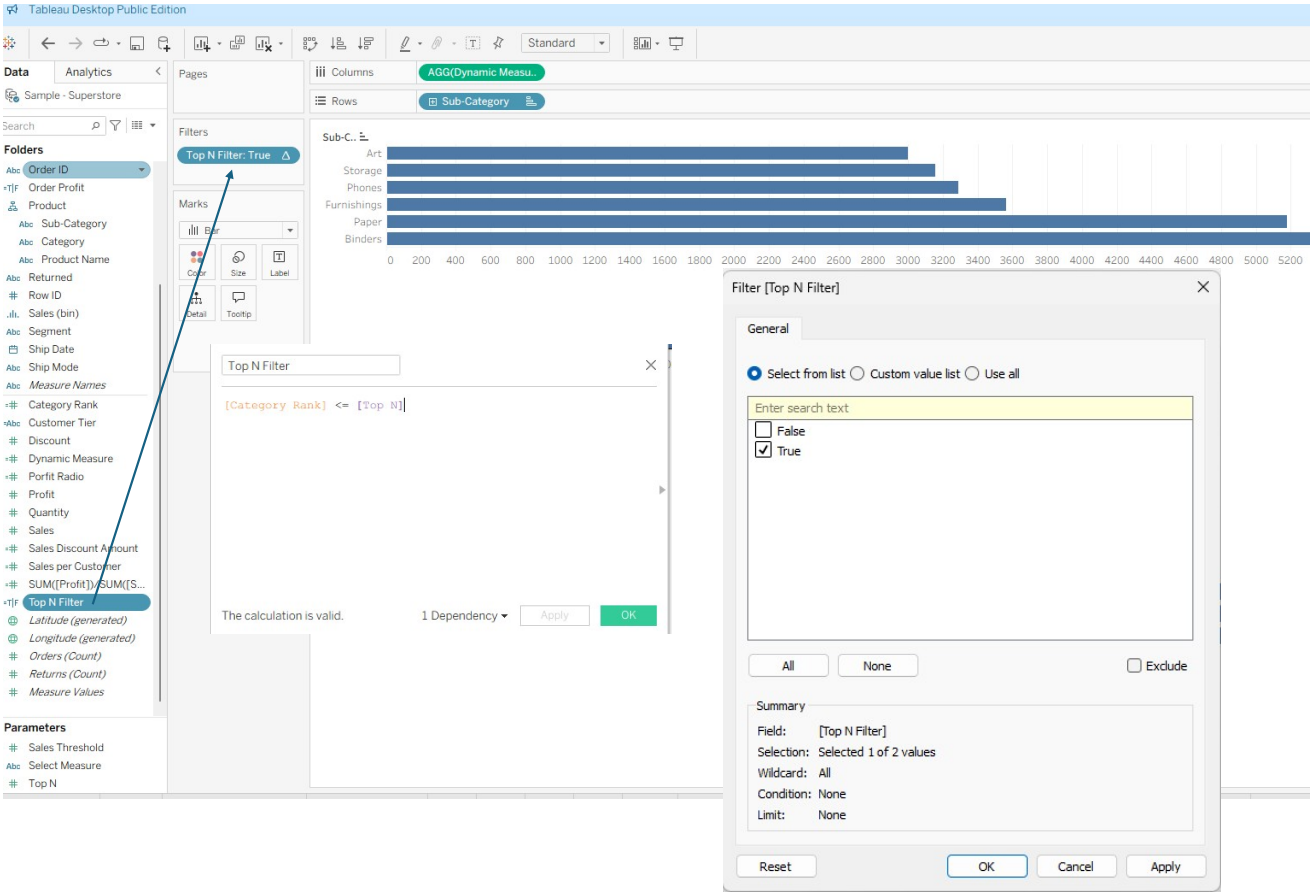

Hình 20: Create Filter Top N

Bước 5: Tạo biểu đồ

1. Kéo `Sub-Category` vào **Rows**.
2. Kéo `Dynamic Measure` vào **Columns**.
3. Chọn **Marks** → **Bar**.
4. Sắp xếp giảm dần hoặc tăng dần theo `Dynamic Measure`.

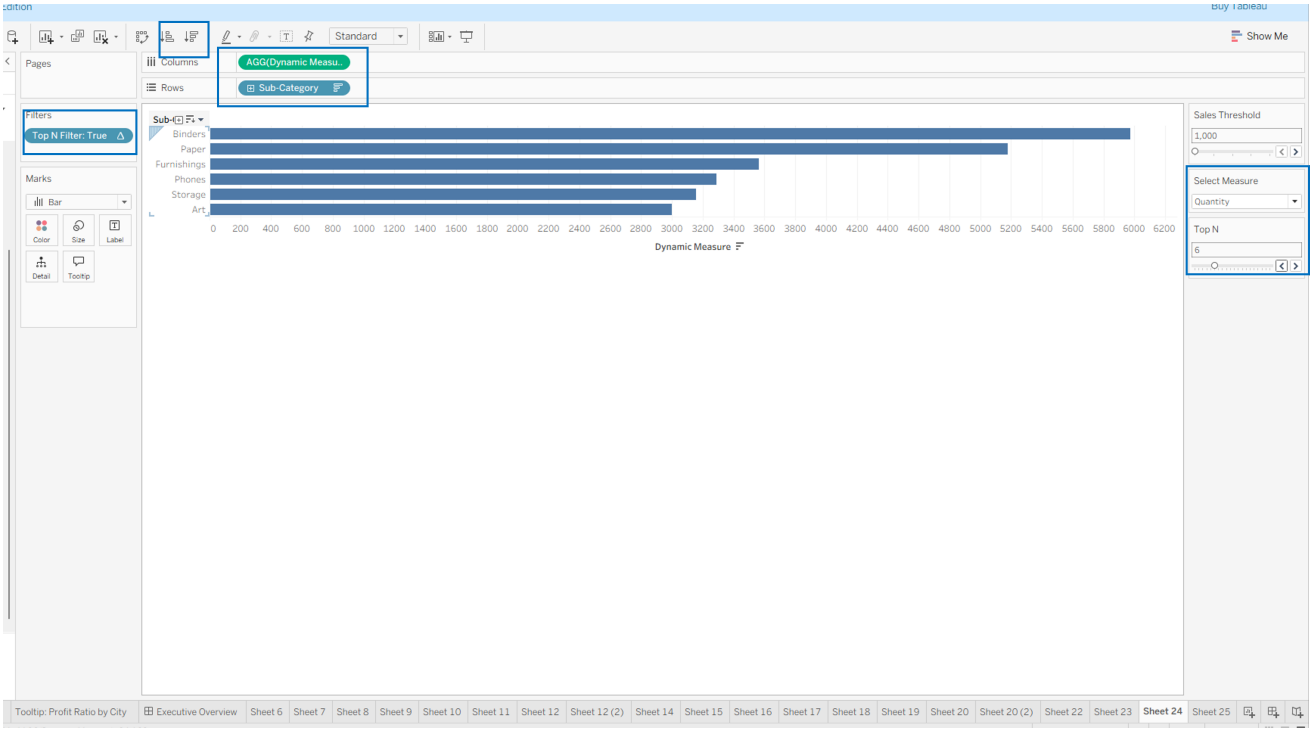

Hình 21: Create Interactive Bar Chart

VI.7. Parameter Actions

Tableau cung cấp tính năng **Parameter Actions** cho phép người dùng cập nhật giá trị của parameter thông qua các thao tác trực tiếp trên visualization.

Cách tạo:

1. Menu **Worksheet** → **Actions...**
2. Click **Add Action** → chọn **Change Parameter**
3. Chọn **Source sheet**, **Target parameter**, **Source field**
4. Cấu hình **Clearing the selection**
5. OK

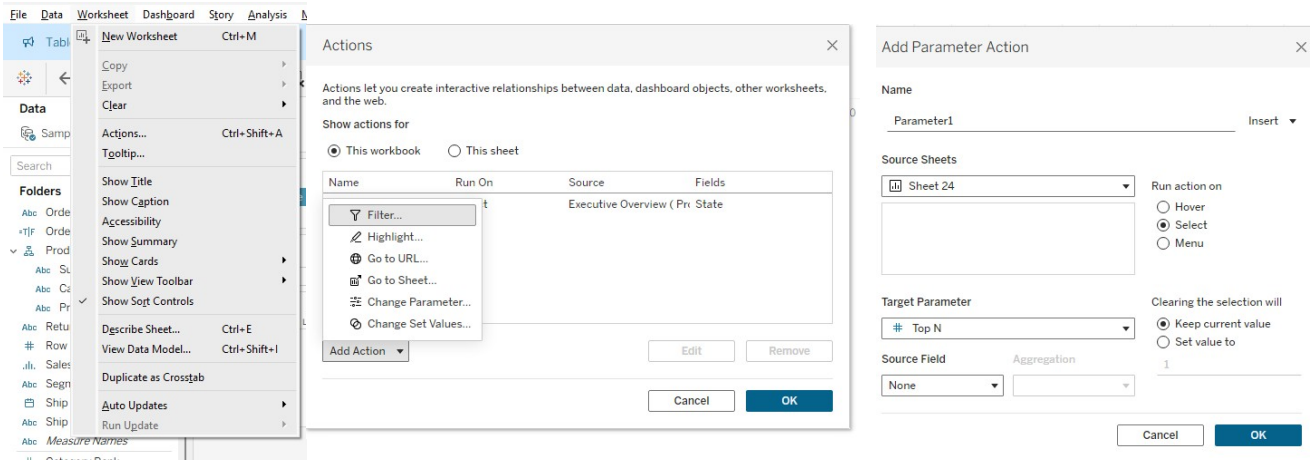

Hình 22: Create Parameter Actions

VI.8. Parameter vs Filter

Tiêu chí	Filter	Parameter
Nguồn giá trị	Lấy từ dataset (tự cập nhật)	Người dùng định nghĩa
Phạm vi	Thường 1 worksheet	Tất cả worksheets dùng nó
Loại giá trị	Chỉ từ dữ liệu có sẵn	Bất kỳ giá trị nào
Dùng khi	Lọc dữ liệu (hiện/ẩn)	Thay đổi logic phân tích

Kết hợp Filter + Parameter là cách tốt nhất parameter tạo logic, filter thực hiện lọc.

VII. Dashboard

Dashboard trong Tableau là một không gian làm việc cho phép kết hợp nhiều biểu đồ (*worksheets*) vào cùng một màn hình nhằm tạo ra một bảng điều khiển tổng hợp (*dashboard*). Dashboard giúp người dùng quan có thể quan sát dữ liệu từ nhiều góc độ khác nhau và tương tác trực tiếp với dữ liệu thông qua các bộ lọc hoặc hành động tương tác hỗ trợ trình bày bắt mắt và không cần phải chuyển nhiều worksheet khác nhau để xem.

Trong thực tế doanh nghiệp, dashboard thường được sử dụng để theo dõi các chỉ số quan trọng như doanh thu, lợi nhuận, số lượng khách hàng hoặc hiệu suất kinh doanh theo thời gian. Thay vì xem từng biểu đồ riêng lẻ, dashboard cho phép người dùng quan sát toàn bộ bức tranh dữ liệu trong một giao diện duy nhất.

Vai trò của Dashboard

Dashboard giúp giải quyết những mục tiêu quan trọng trong phân tích dữ liệu như:

- Tổng hợp nhiều nguồn thông tin vào cùng một màn hình.
- Cho phép người dùng tương tác với dữ liệu theo thời gian thực.
- Hỗ trợ truyền đạt kết quả phân tích cho người ra quyết định.

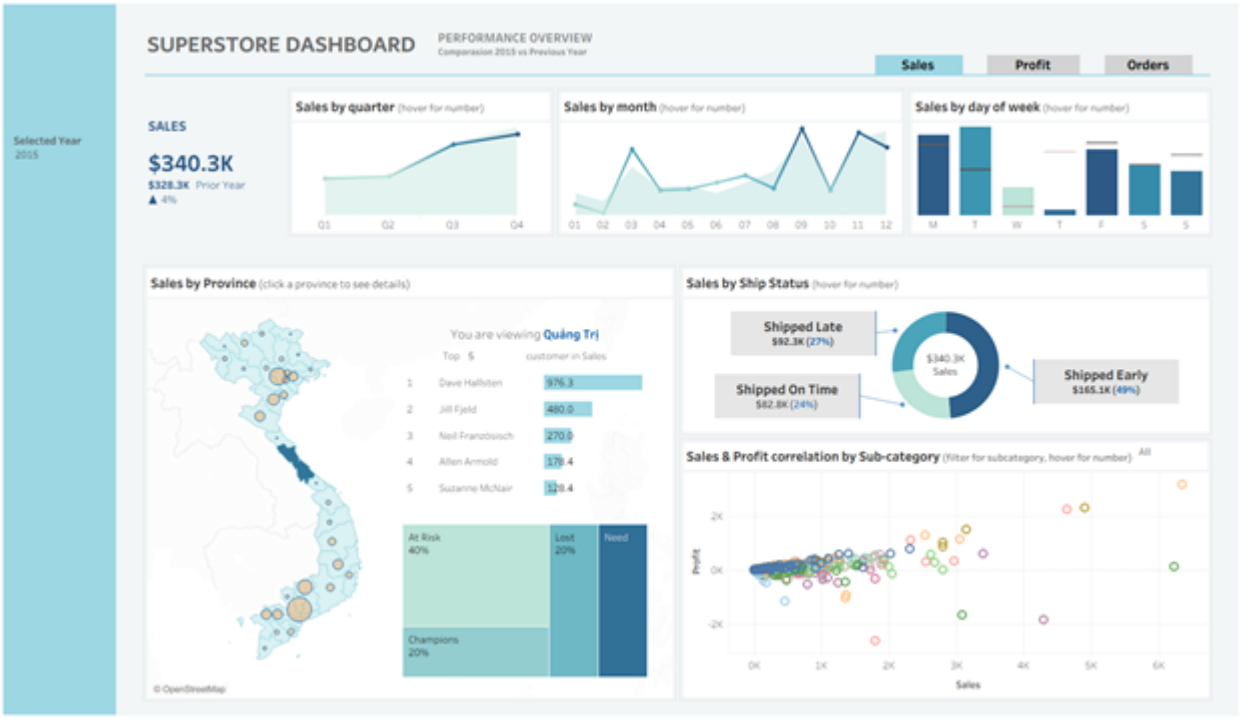

Hình 2: Dashboard trong Tableau.

VII.1. Dashboard Layout và Containers

Khi thiết kế dashboard, việc sắp xếp các thành phần trực quan đóng vai trò rất quan trọng. Tableau cung cấp hai cách bố trí chính cho các đối tượng trong dashboard là **Tiled** và **Floating**. Ngoài ra, Tableau còn cung cấp các **containers** để nhóm nhiều thành phần lại với nhau và kiểm soát bố cục dashboard một cách linh hoạt hơn.

VII.1.1. Tiled vs Floating Layouts

Trong Tableau, mỗi thành phần được đặt vào dashboard (bao gồm worksheet, image, text, container hoặc filter) sẽ thuộc một trong hai kiểu bố cục chính: **Tiled** hoặc **Floating**. Hai kiểu layout này quyết định cách các thành phần được sắp xếp và hiển thị trên dashboard.

Kiểu bố cục	Tiled Layout	Floating Layout
Cách hiển thị	Các thành phần không chồng lên nhau và được sắp xếp theo dạng lưới (grid).	Các thành phần có thể đặt tự do và chồng lên các object khác.
Khả năng thay đổi kích thước	Tự động thay đổi kích thước theo kích thước tổng thể của dashboard.	Không phụ thuộc vào grid; vị trí và kích thước được điều chỉnh thủ công.
Mức độ kiểm soát vị trí	Bị ràng buộc trong hệ thống bố cục của dashboard.	Có thể đặt tại bất kỳ vị trí nào trên dashboard.
Ví dụ sử dụng	Các biểu đồ chính của dashboard (bar chart, line chart, table...).	Logo, chú thích, bộ lọc nổi hoặc bản đồ đặt chồng lên biểu đồ khác.

Khi nào nên dùng Tiled và Floating

- **Tiled** nên được dùng cho cấu trúc chính của dashboard vì giúp bố cục ổn định và dễ căn chỉnh.
- **Floating** phù hợp cho các thành phần phụ như logo, chú thích, bộ lọc nổi hoặc các lớp phủ trực quan.

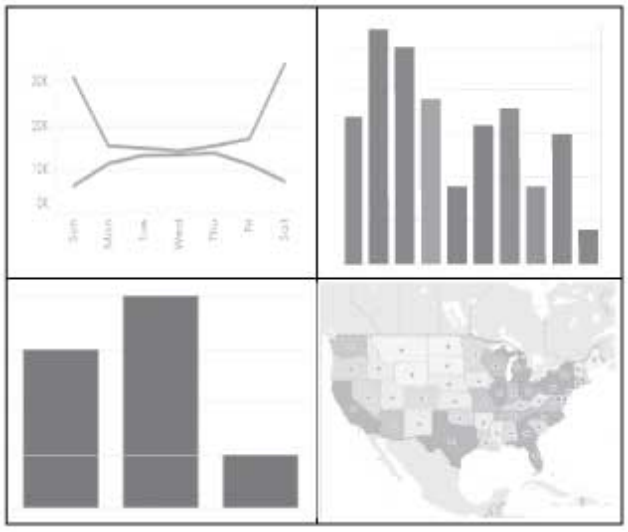

Hình 3: Tiled trong Tableau

Hình 4: Floating trong Tableau

VII.1.2. Container

Container

Container là một vùng chứa cho phép nhóm nhiều đối tượng trong dashboard lại với nhau. Khi một container được di chuyển hoặc thay đổi kích thước, toàn bộ các thành phần bên trong container cũng thay đổi theo.

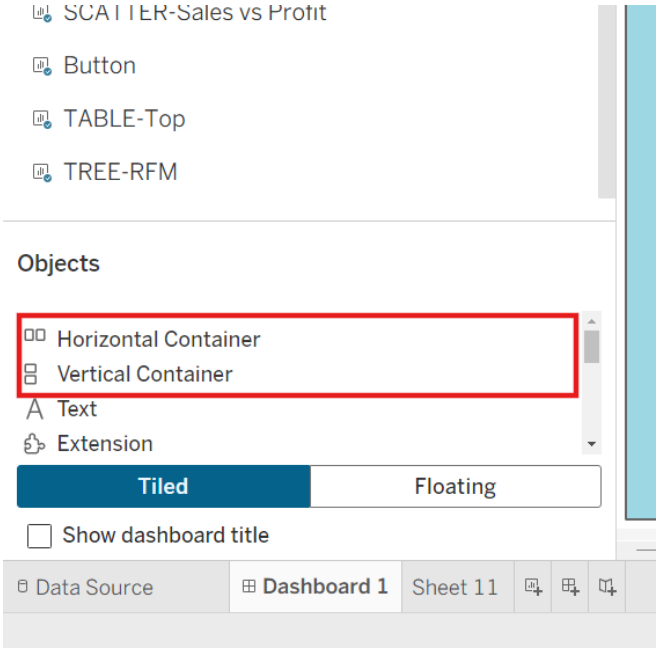

Hình 5: Trong Object hỗ trợ 2 loại là Horizontail và Vertical container

VII.2. Color Principles trong Data Visualization

Màu sắc đóng vai trò quan trọng trong việc truyền đạt thông tin trong trực quan hóa dữ liệu. Một bảng màu được sử dụng đúng cách có thể giúp người xem nhanh chóng nhận ra xu hướng, so sánh giá trị và xác định những điểm bất thường trong dữ liệu. Ngược lại, nếu sử dụng màu không hợp lý, dashboard có thể trở nên khó đọc và gây hiểu nhầm cho người xem.

Trong Tableau, màu sắc thường được sử dụng để mã hóa thông tin của một biến dữ liệu (measure hoặc dimension). Việc lựa chọn bảng màu phù hợp phụ thuộc vào loại dữ liệu mà chúng ta muốn thể hiện.

Nguyên tắc sử dụng màu

- Sử dụng màu sắc để nhấn mạnh thông tin quan trọng.
- Tránh sử dụng quá nhiều màu trong cùng một biểu đồ.
- Duy trì tính nhất quán của màu sắc trong toàn bộ dashboard.

Loại bảng màu	Mô tả	Khi nên dùng
Sequential Color	Dải màu chuyển dần từ nhạt đến đậm, thể hiện sự tăng hoặc giảm của một giá trị liên tục.	Dùng khi hiển thị một biến số liên tục như doanh thu, lợi nhuận hoặc số lượng.
Diverging Color	Hai màu đối lập xuất phát từ một giá trị trung tâm.	Dùng khi dữ liệu có điểm trung tính quan trọng (ví dụ: lãi vs lỗ, tăng vs giảm).
Categorical Color	Các màu riêng biệt không theo thứ tự.	Dùng khi phân biệt các nhóm dữ liệu rời rạc như Category, Region hoặc Segment.

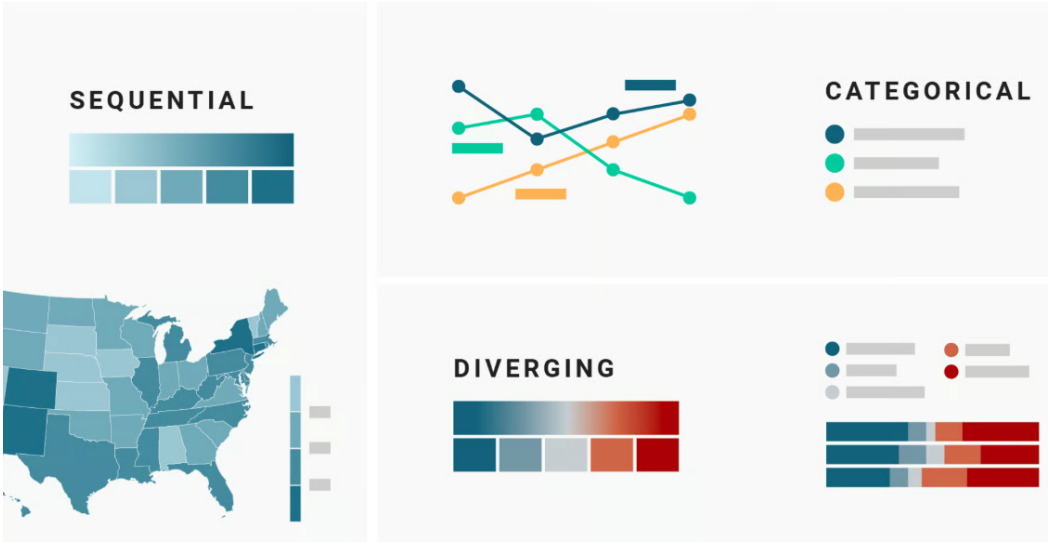

Hình 6: Ví dụ sử dụng bảng màu

Các nguyên tắc sử dụng màu trong dashboard

1. **Sử dụng màu để nhấn mạnh thông tin quan trọng**

   Không nên sử dụng quá nhiều màu sắc trong cùng một biểu đồ. Trong hầu hết dashboard, nên sử dụng một bảng màu trung tính cho phần lớn dữ liệu và chỉ dùng màu nổi bật để làm nổi bật các giá trị quan trọng.

2. **Giữ sự nhất quán giữa các biểu đồ**

   Một category nên luôn được hiển thị bằng cùng một màu trên toàn bộ dashboard. Ví dụ nếu `Technology` được hiển thị bằng màu xanh trong một biểu đồ, thì nó cũng nên giữ màu đó trong các biểu đồ khác.

3. **Tránh sử dụng quá nhiều màu**

   Khi một biểu đồ có quá nhiều màu sắc, người xem sẽ khó nhận ra pattern. Thông thường một biểu đồ chỉ nên sử dụng từ 5 đến 7 màu khác nhau.

4. **Chú ý đến khả năng phân biệt màu**

   Khoảng 8% nam giới có tình trạng mù màu đỏ–xanh. Do đó nên tránh các cặp màu khó phân biệt như đỏ–xanh lá nếu không thực sự cần thiết.

Best practice khi chọn màu trong Tableau

- Dùng **Sequential palette** cho các biểu đồ thể hiện mức độ (ví dụ heatmap).
- Dùng **Diverging palette** khi dữ liệu có điểm trung tính quan trọng.
- Dùng **Categorical palette** khi phân biệt các nhóm dữ liệu.
- Tránh sử dụng quá nhiều màu sắc trong cùng một dashboard.

VII.3. Visual Best Practices

Một dashboard hiệu quả không chỉ cần dữ liệu chính xác mà còn cần cách trình bày hợp lý. Trong thực tế, người dùng thường phải tiếp nhận thông tin từ dashboard trong thời gian rất ngắn, do đó việc tổ chức bố cục và giảm bớt yếu tố gây nhiễu là yếu tố quan trọng giúp người xem nhanh chóng hiểu được thông tin chính.

Các nguyên tắc thiết kế trực quan (visual design principles) dưới đây thường được áp dụng khi xây dựng dashboard trong Tableau cũng như trong các hệ thống Business Intelligence khác.

Nguyên tắc	Ý nghĩa
Giảm nhiễu thị giác (Visual Clutter)	Tránh đặt quá nhiều biểu đồ, màu sắc hoặc nhãn trên cùng một dashboard vì sẽ khiến người xem khó tập trung vào thông tin chính.
Tập trung vào thông tin quan trọng	Các KPI hoặc biểu đồ quan trọng nên được đặt ở khu vực dễ nhìn nhất của dashboard (thường là phía trên hoặc trung tâm).
Sử dụng layout nhất quán	Các biểu đồ nên được căn chỉnh theo một hệ lưới (grid layout) để tạo bố cục cân đối và dễ theo dõi.
Đảm bảo khả năng đọc	Tiêu đề, nhãn trục và chú thích phải rõ ràng, tránh font quá nhỏ hoặc màu khó nhìn.

Giải thích các nguyên tắc thiết kế

1. Giảm nhiễu thị giác

Một dashboard chứa quá nhiều biểu đồ hoặc quá nhiều màu sắc sẽ làm người xem khó xác định đâu là thông tin quan trọng. Vì vậy nên giới hạn số lượng biểu đồ trên một dashboard và chỉ giữ lại những thành phần thực sự cần thiết cho việc phân tích.

2. Tập trung vào thông tin quan trọng

Người dùng thường quan sát dashboard theo thứ tự từ trên xuống dưới và từ trái sang phải. Do đó các chỉ số quan trọng như doanh thu, lợi nhuận hoặc KPI chính nên được đặt ở phần trên của dashboard để người xem có thể nhận ra ngay lập tức.

3. Sử dụng layout nhất quán

Một dashboard được căn chỉnh theo layout rõ ràng sẽ giúp người xem dễ dàng so sánh các biểu đồ với nhau. Trong Tableau, việc sử dụng **containers** hoặc **tiled layout** giúp duy trì cấu trúc lưới ổn định cho dashboard.

4. Đảm bảo khả năng đọc

Các yếu tố như tiêu đề biểu đồ, nhãn trục và chú thích cần được hiển thị rõ ràng để người dùng hiểu đúng ý nghĩa của dữ liệu. Ngoài ra, nên sử dụng kích thước chữ phù hợp và tránh sử dụng quá nhiều kiểu font khác nhau trong cùng một dashboard.

Best Practices khi thiết kế Dashboard

- Mỗi dashboard nên trả lời một nhóm câu hỏi phân tích cụ thể.
- Không nên đặt quá nhiều biểu đồ trên cùng một màn hình.
- Sử dụng màu sắc có chủ đích để làm nổi bật thông tin quan trọng.
- Giữ bố cục dashboard đơn giản và nhất quán.

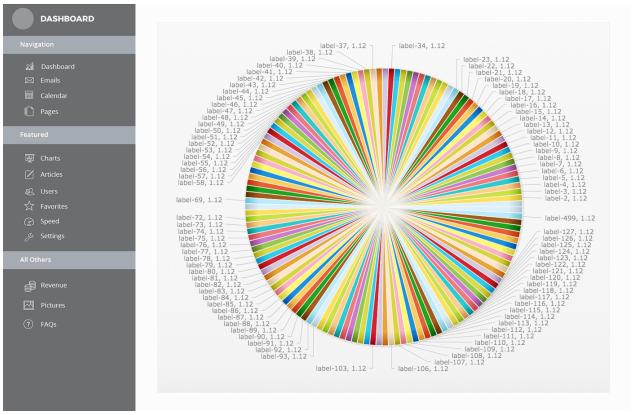

Hình 7: Ví dụ cho ghép quá nhiều thông tin vào đây

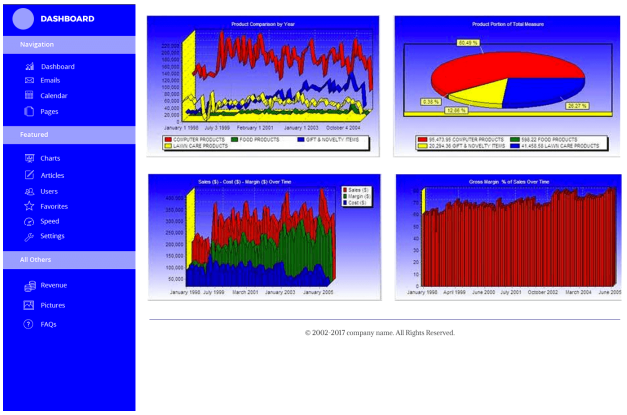

Hình 8: Ví dụ điển hình cho cách thức chọn màu không tốt

VIII. Dashboard Actions

Một trong những điểm mạnh của Tableau là khả năng tạo ra các dashboard có tính tương tác cao. Thay vì chỉ hiển thị dữ liệu tĩnh, người dùng có thể tương tác trực tiếp với các biểu đồ để khám phá dữ liệu từ nhiều góc nhìn khác nhau. Cơ chế cho phép các biểu đồ giao tiếp với nhau trong Tableau được gọi là **Dashboard Actions**. **Dashboard Action** cho phép một biểu đồ hoặc một đối tượng trên dashboard thay đổi tác động đến một hoặc nhiều các biểu đồ khác khi người dùng thực hiện thao tác nào đấy có thể là click chuột, di chuột hoặc chọn dữ liệu.

Filter Action

Filter Action là loại action phổ biến nhất trong Tableau dashboard. Khi người dùng chọn một mark trong biểu đồ nguồn, Tableau sẽ sử dụng giá trị đó làm bộ lọc cho các biểu đồ khác trên dashboard.

Ví dụ: một dashboard bán hàng có thể gồm:

- Bar chart: doanh thu theo `Category`
- Line chart: doanh thu theo `Order Date`
- Map: doanh thu theo `Region`

Khi người dùng nhấp vào `Technology` trong bar chart, line chart và map sẽ chỉ hiển thị dữ liệu của nhóm sản phẩm này.

Cách tạo Filter Action

1. Mở dashboard trong Tableau.

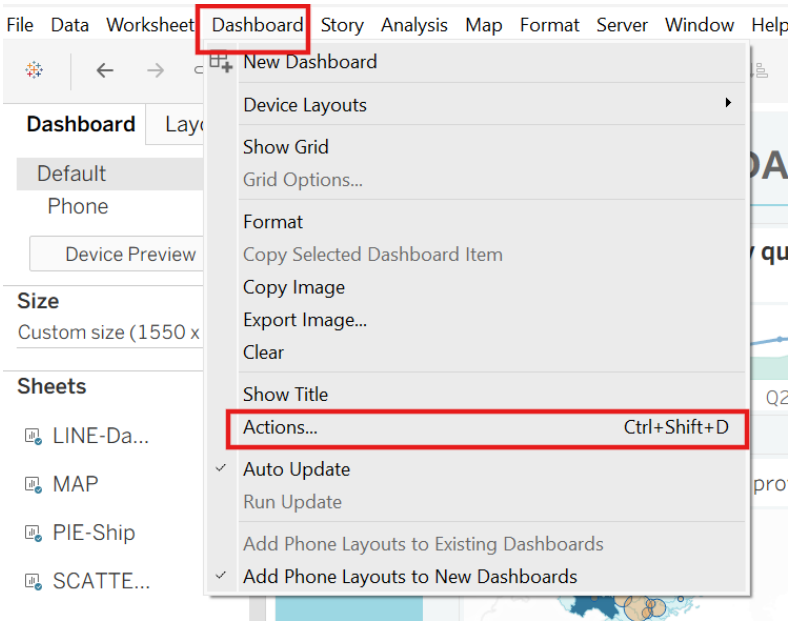

Hình 9: Chọn menu **Dashboard** → **Actions**.

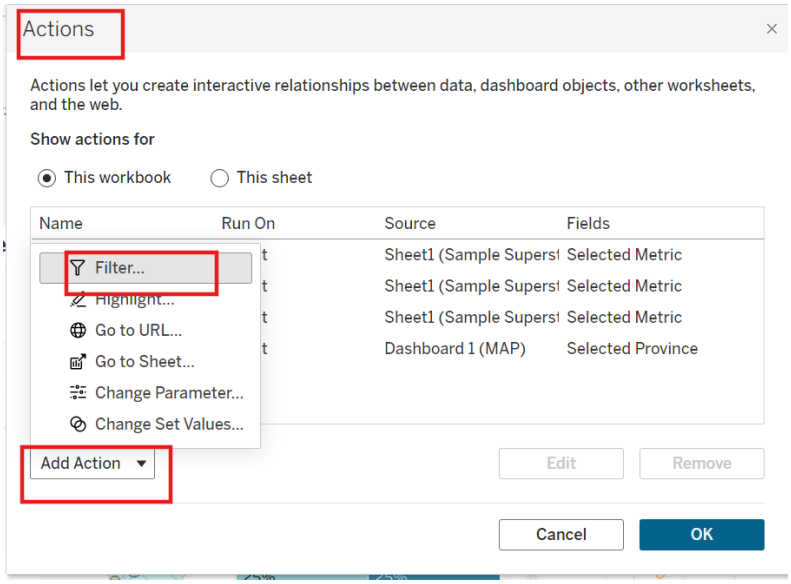

Hình 10: Nhấn **Add Action** → **Filter**.

2. Chọn **Source Sheet** và **Target Sheet**.
3. Chọn kiểu kích hoạt: **Select**, **Hover** hoặc **Menu**.

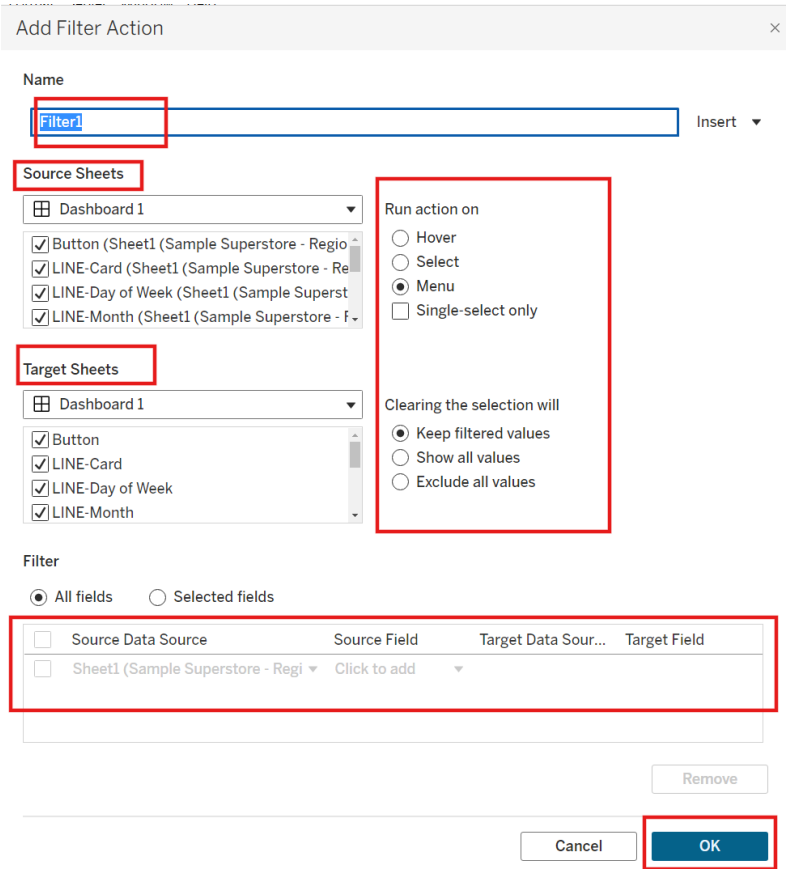

Hình 11: Nhấn OK để hoàn tất thiết lập Filter Action

Highlight Action

Highlight Action cho phép làm nổi bật dữ liệu liên quan giữa các biểu đồ mà không thay đổi dữ liệu hiển thị. Khi người dùng di chuột lên một giá trị trong biểu đồ nguồn, Tableau sẽ làm nổi bật các dữ liệu liên quan trong các biểu đồ khác.

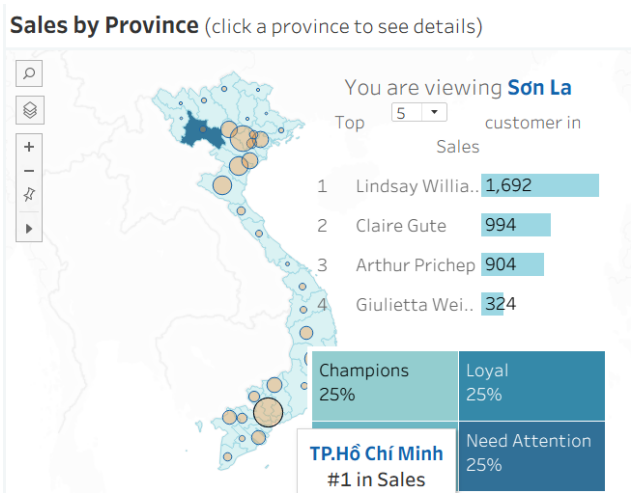

Hình 12: Ví dụ khi highlight tới Hồ Chí Minh

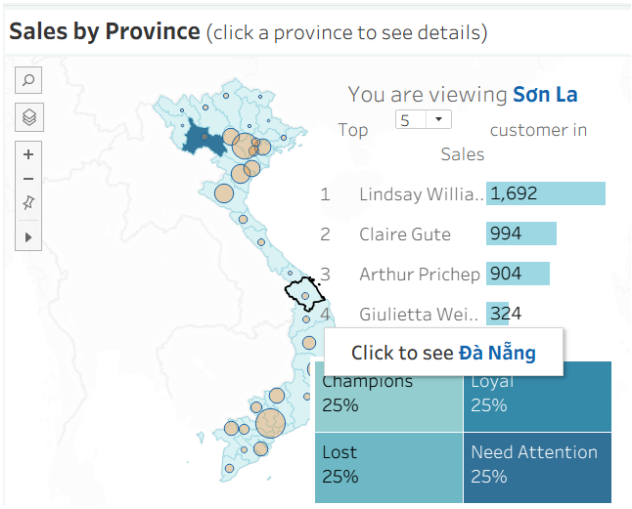

Hình 13: Ví dụ khi highlight tới Đà Nẵng

Cách tạo Highlight Action

1. Chọn **Dashboard** → **Actions**.

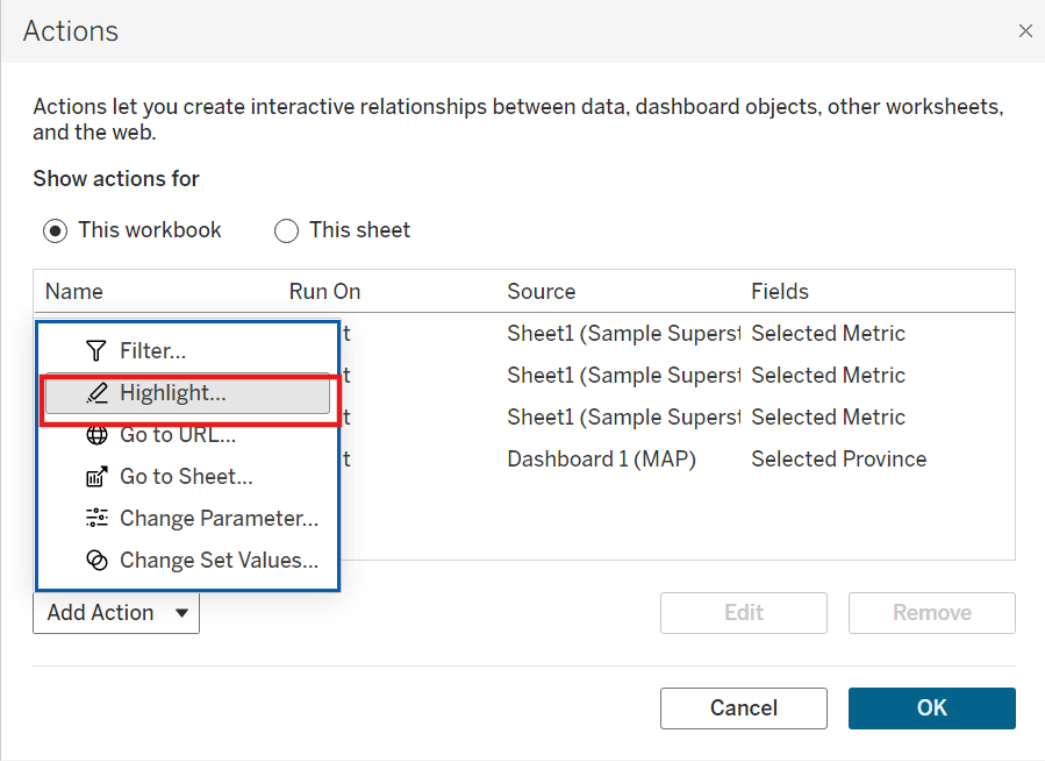

Hình 14: Chọn **Add Action** → **Highlight**

2. Chọn sheet nguồn và sheet mục tiêu.
3. Chọn cách kích hoạt (Hover hoặc Select).

Navigation Action

Navigation Action cho phép người dùng di chuyển giữa nhiều dashboard khác nhau. Điều này giúp xây dựng hệ thống dashboard có cấu trúc nhiều lớp, tương tự như một ứng dụng phân tích dữ liệu.

Cách tạo Navigation Action

1. Chọn **Dashboard** → **Actions**.
2. Chọn **Add Action** → **Go to Sheet**.
3. Chọn dashboard đích.
4. Chọn đối tượng kích hoạt (button hoặc chart).

Best Practices khi sử dụng Dashboard Actions

- Không nên sử dụng quá nhiều action trên cùng một dashboard.
- Nên sử dụng Filter Action cho các tương tác chính.
- Highlight Action phù hợp cho việc so sánh nhanh giữa các nhóm dữ liệu.
- Navigation Action nên được sử dụng để tổ chức dashboard theo nhiều cấp độ phân tích.

IX. Storytelling

IX.1. Giao diện Story trong Tableau

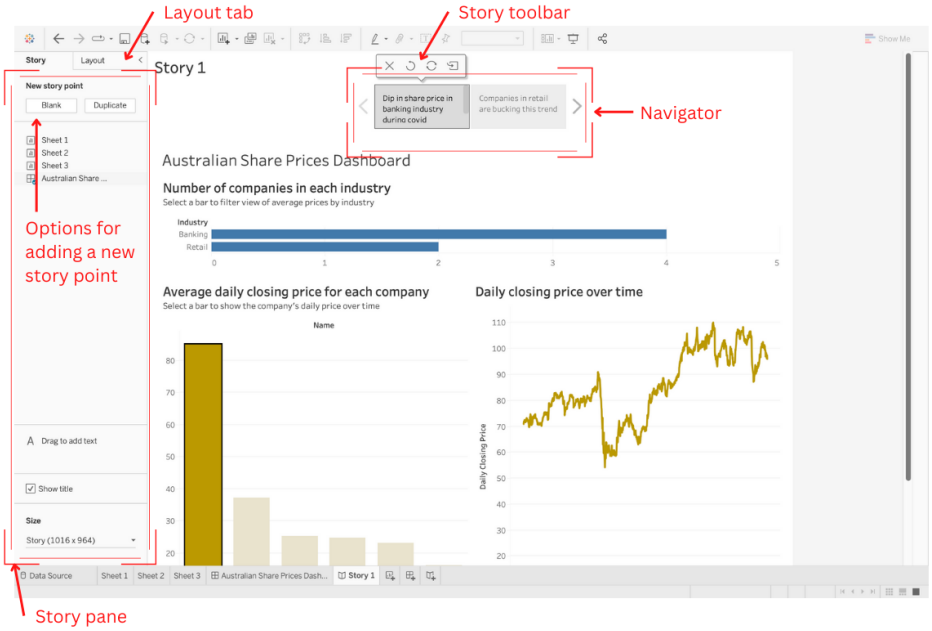

Hình 15: Giao diện Storytelling

Hình minh họa giao diện *Story* trong Tableau với các thành phần chính phục vụ cho việc xây dựng câu chuyện dữ liệu. Ở phía bên trái là *Story pane*, nơi quản lý các *story point* và cho phép người dùng kéo thả các worksheet hoặc dashboard vào từng bước của câu chuyện. Trong khu vực này, người dùng có thể tạo mới một story point bằng tùy chọn *Blank* hoặc sao chép từ bước hiện tại thông qua *Duplicate*.

Phần *Layout tab* cho phép tùy chỉnh bố cục của story, bao gồm kích thước hiển thị, tiêu đề và cách sắp xếp các thành phần. Ở phía trên là *Story toolbar*, cung cấp các công cụ thao tác nhanh như thêm hoặc xóa story point, cũng như hoàn tác và làm lại các hành động.

Khu vực *Navigator* hiển thị các story point dưới dạng các tab, giúp người dùng dễ dàng chuyển đổi giữa các bước trong câu chuyện. Trung tâm của giao diện là phần dashboard, nơi hiển thị các biểu đồ và nội dung trực quan hóa dữ liệu, đóng vai trò chính trong việc truyền tải thông

tin và insight.

Nhìn chung, giao diện Story trong Tableau giúp người dùng tổ chức và trình bày dữ liệu theo một trình tự logic, từ đó xây dựng một câu chuyện dữ liệu rõ ràng và hiệu quả.

Storytelling với dữ liệu là quá trình sử dụng trực quan hóa dữ liệu để truyền đạt một thông điệp hoặc câu chuyện cụ thể. Thay vì chỉ hiển thị các biểu đồ rời rạc, một dashboard tốt cần được thiết kế sao cho người xem có thể hiểu được bối cảnh của dữ liệu, nhận ra các insight quan trọng và đưa ra quyết định dựa trên những thông tin đó.

Trong Tableau, storytelling thường được thực hiện thông qua việc kết hợp nhiều worksheet và dashboard theo một trình tự logic. Mỗi bước trong câu chuyện sẽ dẫn dắt người xem từ việc quan sát dữ liệu ban đầu đến việc phát hiện các xu hướng, bất thường và kết luận cuối cùng.

Nguyên tắc thiết kế Data Story

1. Bắt đầu từ bức tranh tổng quan Một dashboard storytelling hiệu quả thường bắt đầu bằng các chỉ số tổng quan như KPI hoặc xu hướng tổng thể. Điều này giúp người xem nhanh chóng hiểu được bối cảnh của dữ liệu trước khi đi vào các phân tích chi tiết.

2. Dẫn dắt người xem qua từng bước Các biểu đồ nên được sắp xếp theo một trình tự hợp lý để người xem có thể theo dõi câu chuyện dữ liệu một cách tự nhiên. Ví dụ: từ tổng doanh thu $\rightarrow$ doanh thu theo khu vực $\rightarrow$ doanh thu theo từng sản phẩm.

3. Làm nổi bật insight Những điểm bất thường, xu hướng quan trọng hoặc giá trị nổi bật nên được nhấn mạnh bằng màu sắc, annotation hoặc highlight. Điều này giúp người xem nhanh chóng nhận ra thông tin quan trọng.

X. Tóm tắt buổi học

Trong buổi học này, chúng ta đã trang bị 3 công cụ cốt lõi:

Calculated Fields

- Tạo chỉ số mới: Profit Margin, Customer Tier, Delivery Days
- Phân biệt row-level (từng dòng) và aggregate (nhóm dòng)
- LOD Expressions (FIXED, INCLUDE, EXCLUDE) tính ở mức chi tiết bất kỳ
- Order of Operations thứ tự 9 bước Tableau xử lý dữ liệu
- Quick Table Calculations Running Total, Rank, Percent of Total

Filters

- 6 loại filters từ Extract đến Table Calc, mỗi loại ở giai đoạn khác nhau
- Context Filter "đẩy" filter lên trước FIXED LOD và Top N
- Dimension Filters (General, Wildcard, Condition, Top) cho categories
- Measure Filters cho giá trị số aggregate

Parameters

- Giá trị động do người dùng nhập không lấy từ dataset
- Kết hợp với Calculated Fields: ngưỡng động, measure switching, Top N
- Parameter Actions (2020+) click vào chart để thay đổi parameter
- Một parameter ảnh hưởng tất cả worksheets dùng nó

XI. Bài tập thực hành

Bài tập: Sales Analysis Dashboard

Trong phần bài tập tổng hợp của buổi 2, chúng ta sẽ nâng cấp sản phẩm đầu ra thành một bảng điều khiển (dashboard), vốn là sản phẩm chủ yếu của công việc phân tích và báo cáo tại các công ty và doanh nghiệp.

Dashboard là một giao diện trực quan **tổng hợp nhiều biểu đồ** và **thành phần tương tác** nhằm trình bày kết quả phân tích dữ liệu một cách rõ ràng và dễ hiểu. Thông qua dashboard, người dùng có thể nhanh chóng quan sát các xu hướng, so sánh dữ liệu giữa các nhóm khác nhau và khám phá những mối quan hệ quan trọng trong dữ liệu. Việc tổ chức thông tin dưới dạng dashboard giúp người xem nắm bắt bức tranh tổng thể của dữ liệu và hỗ trợ quá trình ra quyết định dựa trên dữ liệu.

Một dashboard thường bao gồm các thành phần chính sau:

1. **Tiêu đề và mô tả**: cung cấp bối cảnh và mục tiêu của dashboard.
2. **Các biểu đồ trực quan**: thể hiện dữ liệu dưới nhiều góc nhìn khác nhau.
3. **Các chỉ số tổng hợp**: hiển thị các giá trị quan trọng cần theo dõi và so sánh.
4. **Bộ lọc và thành phần tương tác**: cho phép người dùng khám phá dữ liệu theo nhiều chiều khác nhau.

Chúng ta tiếp tục sử dụng bộ dữ liệu Superstore đã được bản địa hóa tên các tỉnh thành trong bài tập này.

Để thực hiện một quy trình xây dựng dashboard hoàn chỉnh trên Tableau, ta cần đi theo các bước như sau:

Bước 1: Chuẩn bị dữ liệu và môi trường làm việc

Phụ thuộc vào nguồn dữ liệu của bạn đang nằm ở đâu, ta thực hiện các kết nối tương ứng. Trong bài này chúng ta kết nối đến nguồn dữ liệu tĩnh là các file Excel. Sau khi kết nối, kiểm tra xem các trường dữ liệu được hiển thị ổn định và chính xác hay chưa.

Thực hiện import các file dữ liệu bằng menu **Data** → **New Data Source** → **Microsoft Excel** → Chọn 2 file Excel tương ứng. Sau khi import thành công, ta kiểm tra menu `Data` sẽ thấy hiển thị như sau:

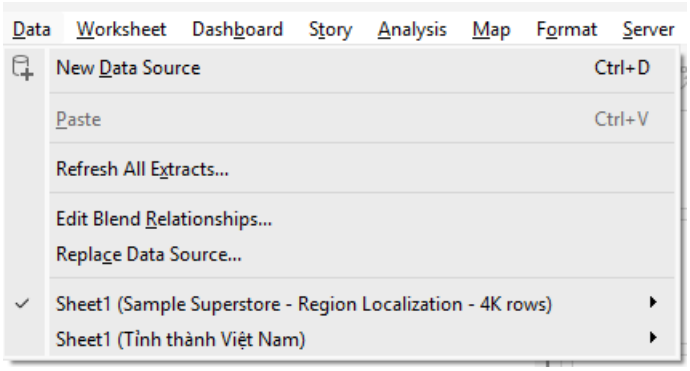

Hình 16: Menu Data sau khi import thành công hai file dữ liệu.

Bước 2: Xác định mục tiêu phân tích

Trước khi bắt đầu xây dựng dashboard, cần xác định rõ mục tiêu cho sản phẩm cuối cùng. Sau khi xác định được câu hỏi chính, ta có thể chia nhỏ thành các câu hỏi thành phần. Từng câu hỏi thành phần đó sẽ giúp xác định được các biểu đồ thành phần. Ví dụ:

- Xu hướng doanh thu theo thời gian như thế nào?
- Doanh thu phân bố theo khu vực địa lý ra sao?
- Mối quan hệ giữa doanh thu và lợi nhuận là gì?
- Hiệu quả vận chuyển đơn hàng như thế nào?
- Top những khách hàng chi tiêu cao ở mỗi khu vực địa lý?

Ở dashboard này, ta muốn đồng thời theo dõi 3 chỉ số `Sales` (doanh thu), `Profit` (lợi nhuận) và `Orders` (số lượng đơn hàng). Vì vậy cách tiếp cận là sẽ tạo một parameter để chuyển đổi giữa các chỉ số này một cách nhanh chóng và dễ dàng. Ta tạo một parameter về Chỉ số được chọn.

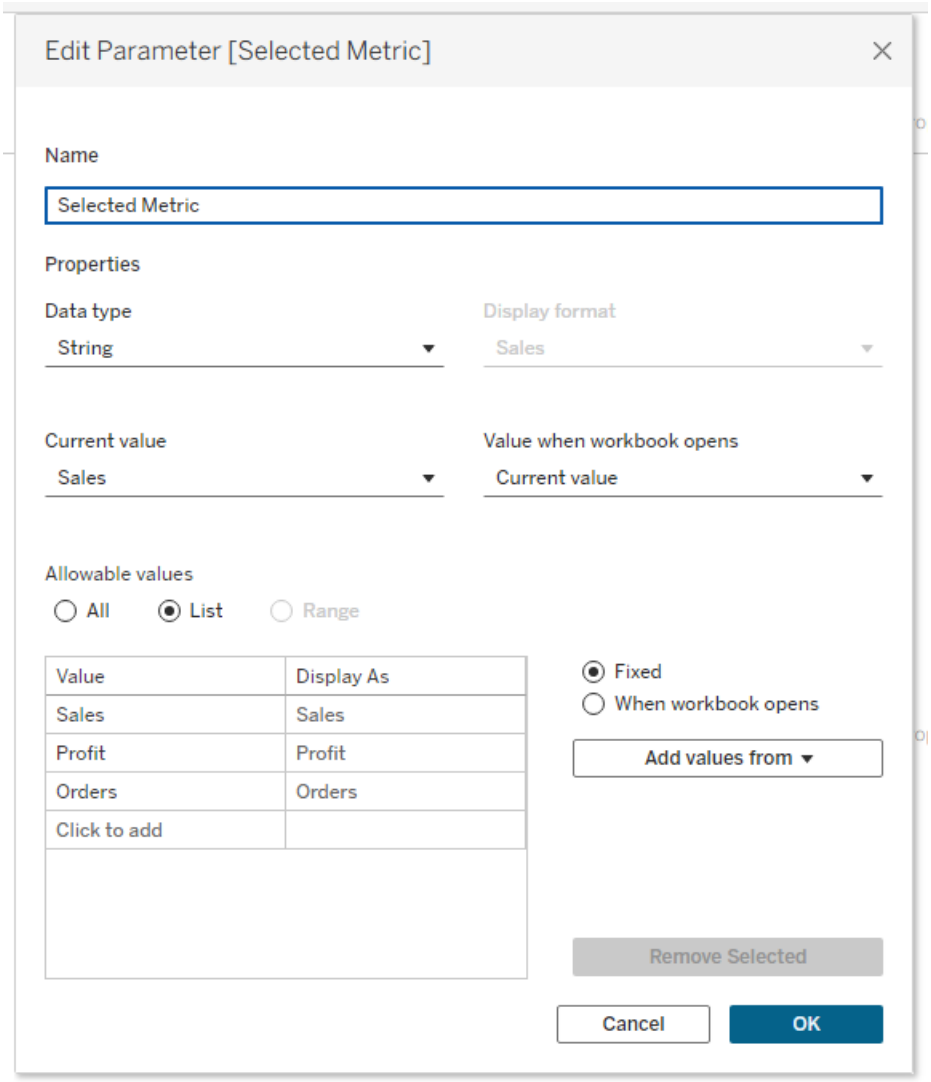

Hình 17: Cấu hình parameter `Selected Metric`.

Đồng thời, ta cũng muốn điều khiển theo năm báo cáo. Vì vậy, cần tạo một parameter về Năm được chọn.

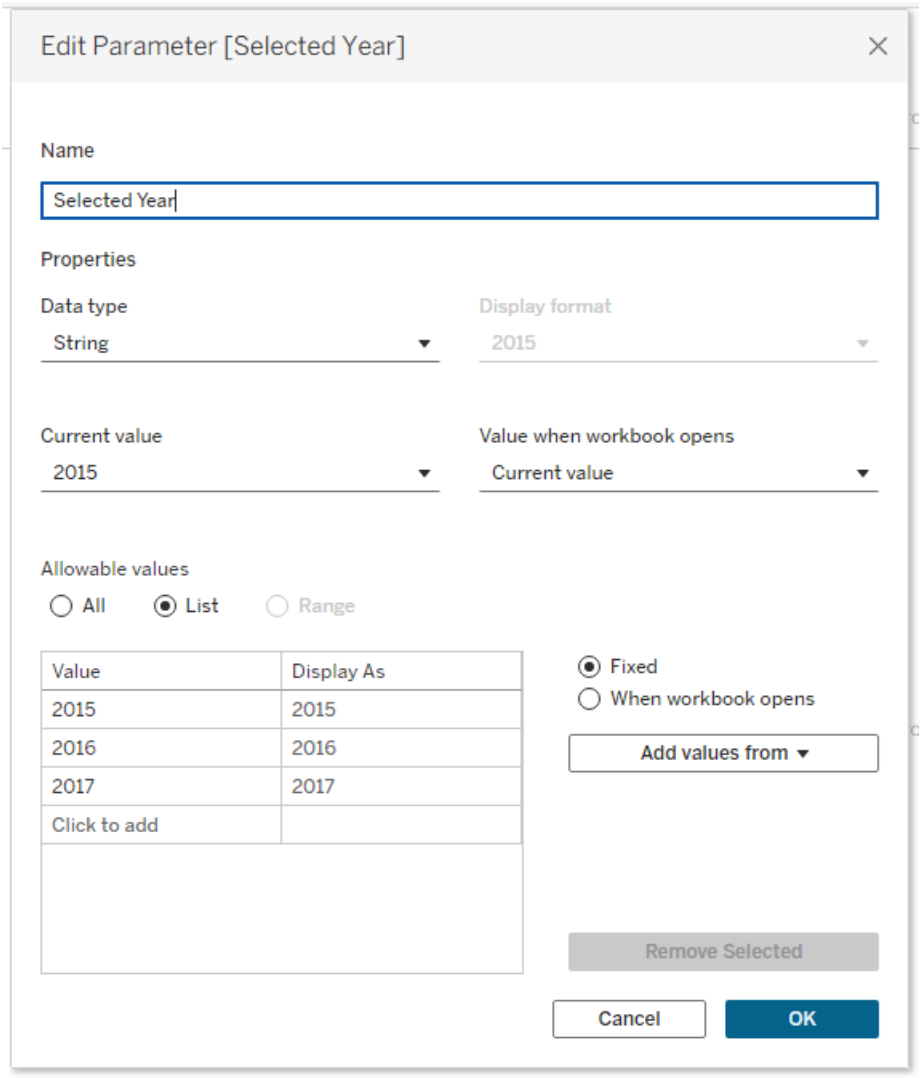

Hình 18: Cấu hình parameter `Selected Year`.

Đây là các parameter chính đầu tiên cần tạo, ảnh hưởng đến toàn bộ hoặc phần lớn các biểu đồ thành phần.

Để kết nối các parameter này với dimension hoặc measure cần điều khiển, ta tạo các calculated field sau:

Đối với parameter `Selected Year`

```
// [TIME] Selected Year
IF YEAR([Order Date]) = INT([Selected Year]) THEN TRUE END

// [TIME] Previous Year
IF YEAR([Order Date]) = INT([Selected Year])-1 THEN TRUE END
```

Kết nối parameter `Selected Year` với dimension về thời gian `Order Date` để lựa chọn được năm

hiện tại và năm trước tương ứng.

Đối với parameter `Selected Metric`

```
// [VALUE] Selected Year Sales
IF [[TIME]] Selected Year] THEN [Sales] END

// [VALUE] Selected Year Profit
IF [[TIME]] Selected Year] THEN [Profit] END

// [VALUE] Selected Year Orders
IF [[TIME]] Selected Year] THEN [Order ID] END
```

3 measure này tổng hợp lại thành:

```
// [VALUE] Selected Year Metrics
CASE [Selected Metric]
WHEN "Sales"   THEN SUM([[VALUE]] Selected Year Sales])
WHEN "Profit"  THEN SUM([[VALUE]] Selected Year Profit])
WHEN "Orders"  THEN COUNTD([[VALUE]] Selected Year Orders])
END
```

Làm tương tự để tạo ra measure `[VALUE] Previous Year Metrics`.

Bước 3: Xây dựng các biểu đồ thành phần

Bước 3.1 Xác định các dimension và measure cần có trong biểu đồ

Thông thường với các biểu đồ cơ bản, ta chỉ cần sử dụng các trường dữ liệu có sẵn. Tuy nhiên nếu muốn xây dựng các biểu đồ nâng cao hơn, có thể cần sử dụng đến calculated field và parameter.

Bước 3.2 Xây dựng biểu đồ

Trong bài tập này chúng ta cần tạo một dashboard có bố cục gồm 3 khu vực chính:

Khu vực 1: Hiện trạng Chỉ số cần theo dõi qua thời gian.

Tại đây ta có 4 biểu đồ thành phần:

- 1 scorecard thể hiện Chỉ số từ đầu năm đến nay. Mã biểu đồ `[1.1-C]`
- 1 line chart thể hiện Chỉ số tổng hợp theo quý (kết hợp với 1 area chart thể hiện Chỉ số tổng hợp theo quý cùng kỳ năm trước). Mã biểu đồ `[1.2-L]`
- 1 line chart thể hiện Chỉ số tổng hợp theo tháng (kết hợp với 1 area chart thể hiện Chỉ số tổng hợp theo tháng cùng kỳ năm trước). Mã biểu đồ `[1.3-L]`
- 1 bar chart thể hiện Chỉ số so sánh giữa các ngày trong tuần (kết hợp với 1 gantt chart thể hiện Chỉ số giữa các ngày trong tuần năm trước). Mã biểu đồ `[1.4-B]`

Khu vực 2: Chỉ số cần theo dõi qua góc nhìn địa lý.

Tại đây ta có 3 biểu đồ thành phần:

- 1 filled map thể hiện ranking của Chỉ số giữa các tỉnh thành. Mã biểu đồ `[2.1-M]`
- 1 bar chart gồm top 5 khách hàng có chi tiêu cao nhất tại tỉnh thành đang được chọn. Mã biểu đồ `[2.2-B]`
- 1 tree map thể hiện cơ cấu phân khúc khách hàng xét theo RFM tại tỉnh thành đang được chọn. Mã biểu đồ `[2.3-T]`

Khu vực 3: Chỉ số cần theo dõi qua các chiều dữ liệu mở rộng.

Tại đây ta có 2 biểu đồ thành phần:

- 1 donut chart thể hiện cơ cấu của Chỉ số phân chia theo Ship Status (Sớm – Đúng hẹn – Trễ). Mã biểu đồ `[3.1-P]`
- 1 scatter plot thể hiện mối tương quan giữa Sales và Profit của từng order theo 1 hoặc tất cả các Sub-Category. Mã biểu đồ `[3.2-S]`

Bước 3.3 Tinh chỉnh thiết kế biểu đồ

Cần đảm bảo các quy tắc thiết kế cơ bản để biểu đồ không chỉ đáp ứng được hiệu quả về tính chính xác mà còn đảm bảo tính rõ ràng và nhất quán trên một dashboard chung.

Bước 4: Thêm các bộ lọc và tương tác

Dashboard này có sử dụng parameter kết hợp với Actions để tạo trải nghiệm tương tác mượt mà giữa các biểu đồ.

Bước 5: Hoàn thiện thiết kế dashboard và kiểm tra độ ổn định

Đưa các biểu đồ thành phần lên một hoặc nhiều trang dashboard tùy vào nhu cầu. Thực hiện kiểm tra các tương tác của filter, tính chính xác của dữ liệu và khả năng hỗ trợ phân tích của dashboard. Mục tiêu cuối cùng vẫn là đáp ứng được nhu cầu ban đầu đặt ra.

Sau đây là chi tiết thực hiện từng bước:

Biểu đồ [1.1-C]

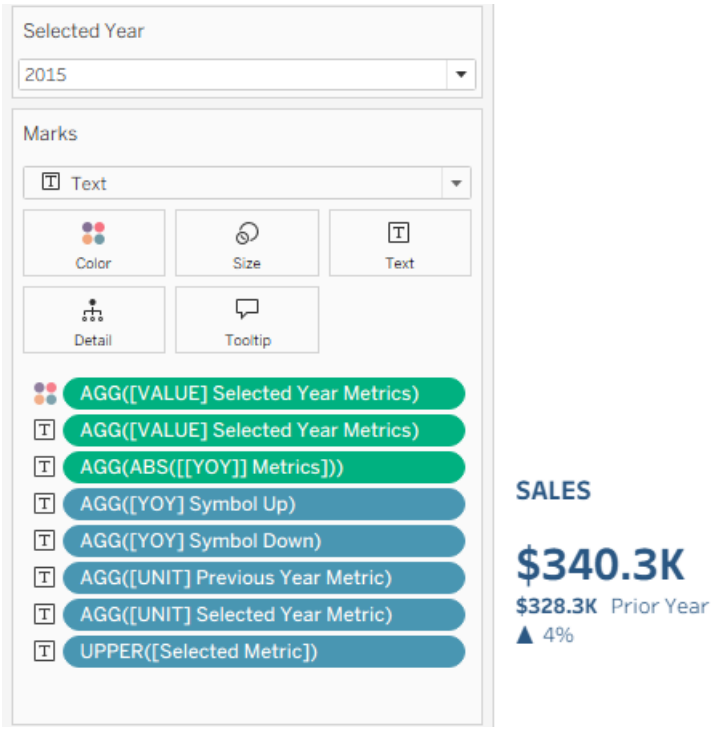

Hình 19: Cấu hình scorecard `[1.1-C]`.

Scorecard gồm chủ yếu là text nên chúng ta sẽ tạo các calculated field để đưa vào `Marks Text`:

- **[VALUE] Selected Year Metrics**: đã tạo ở mục trên.
- **ABS([[YOY]] Metrics])**: measure thể hiện số % tăng giảm so với cùng kỳ.
- **[[YOY]] Symbol Up]** và **[[YOY]] Symbol Down]**: thể hiện icon mũi tên tăng giảm tương ứng.
- **[[UNIT]] Previous Year Metric]** và **[[UNIT]] Selected Year Metric]**: giá trị tương tự với **[VALUE] Selected Year Metrics** nhưng được điều chỉnh để hiển thị đơn vị.
- **UPPER([Selected Metric])**: tên của metric được viết in hoa.

Biểu đồ [1.2-L]

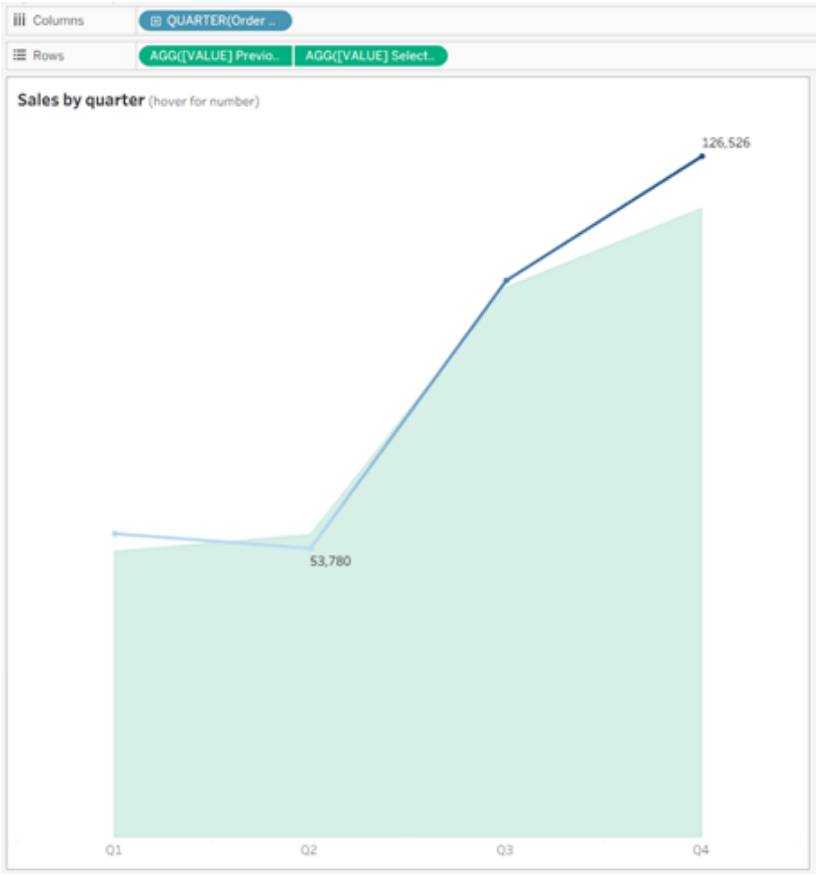

Hình 20: Cấu hình biểu đồ `[1.2-L]` – Chỉ số theo quý.

Biểu đồ gồm line chart cho năm hiện tại và area chart cho năm trước, thể hiện Chỉ số qua các quý.

- **Rows**: [[**VALUE**]] **Previous Year Metrics**] và [[**VALUE**]] **Selected Year Metrics**] (kích chuột phải vào [[**VALUE**]] **Selected Year Metrics**] và chọn `Dual Axis` để 2 biểu đồ chồng lên nhau).
- **Columns**: **DATEPART('quarter', [Order Date])**

Để tăng lượng thông tin cho biểu đồ, ta kéo các trường sau vào **Marks Tooltip** và **Color**:

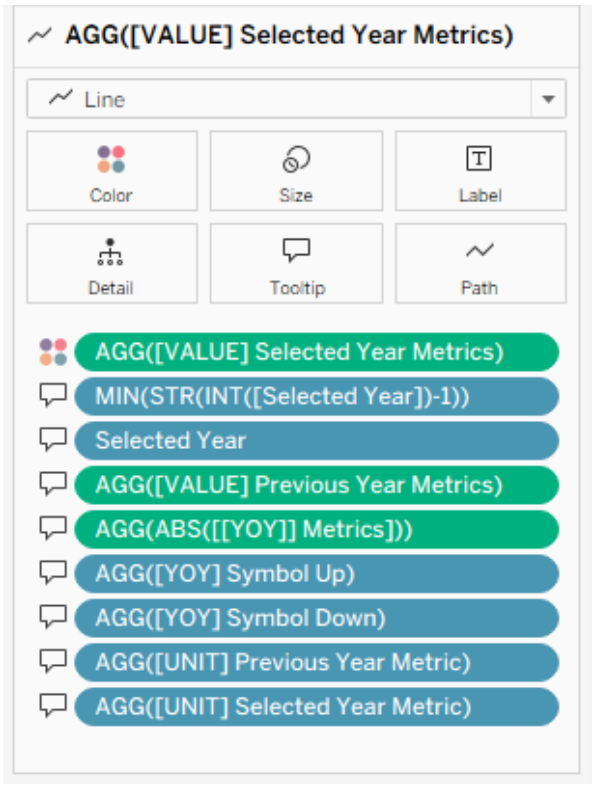

(a) Cấu hình Marks cho năm trước.

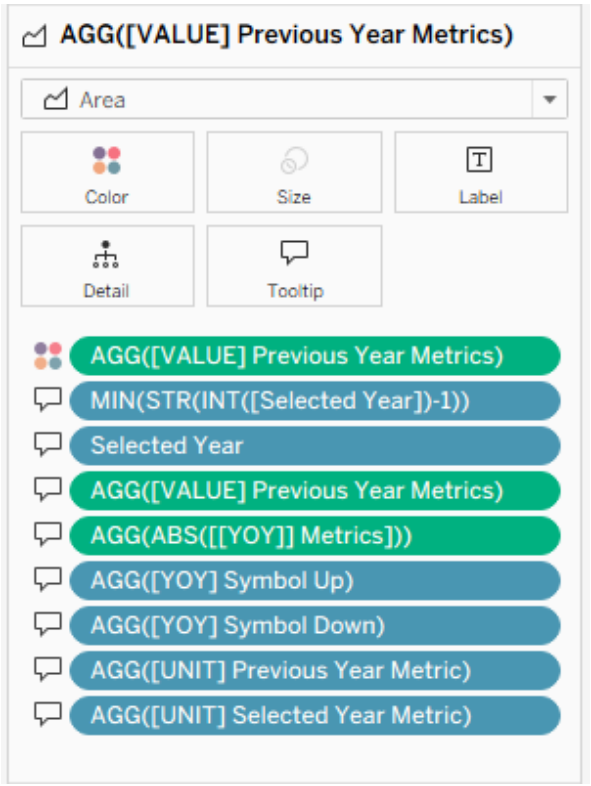

(b) Cấu hình Marks cho năm hiện tại.

Hình 21: Cấu hình Tooltip và Color cho biểu đồ `[1.2-L]`.

Kích đúp vào Title để điều chỉnh tên của biểu đồ bằng nội dung sau:

```
<Parameters.Selected Metric> by quarter (hover for number)
```

Biểu đồ [1.3-L]

Thực hiện tương tự để tạo ra biểu đồ theo tháng. Ta có thể kích chuột phải vào biểu đồ quý và chọn `Duplicate` để tiết kiệm thời gian xây biểu đồ từ đầu. Sau đó thực hiện điều chỉnh **Columns** thành **DATEPART('month', [Order Date])**.

Hình 22: Biểu đồ `[1.3-L]` – Chỉ số theo tháng.

Biểu đồ [1.4-B]

Thực hiện tương tự, chọn `Duplicate` từ biểu đồ quý, sau đó điều chỉnh **Columns** thành **DATEPART('weekday', [Order Date])**.

- Thay đổi biểu đồ dạng line cho [[**VALUE**]] **Selected Year Metrics**] thành **bar chart**.
- Thay đổi biểu đồ dạng area cho [[**VALUE**]] **Previous Year Metrics**] thành **gantt chart**.

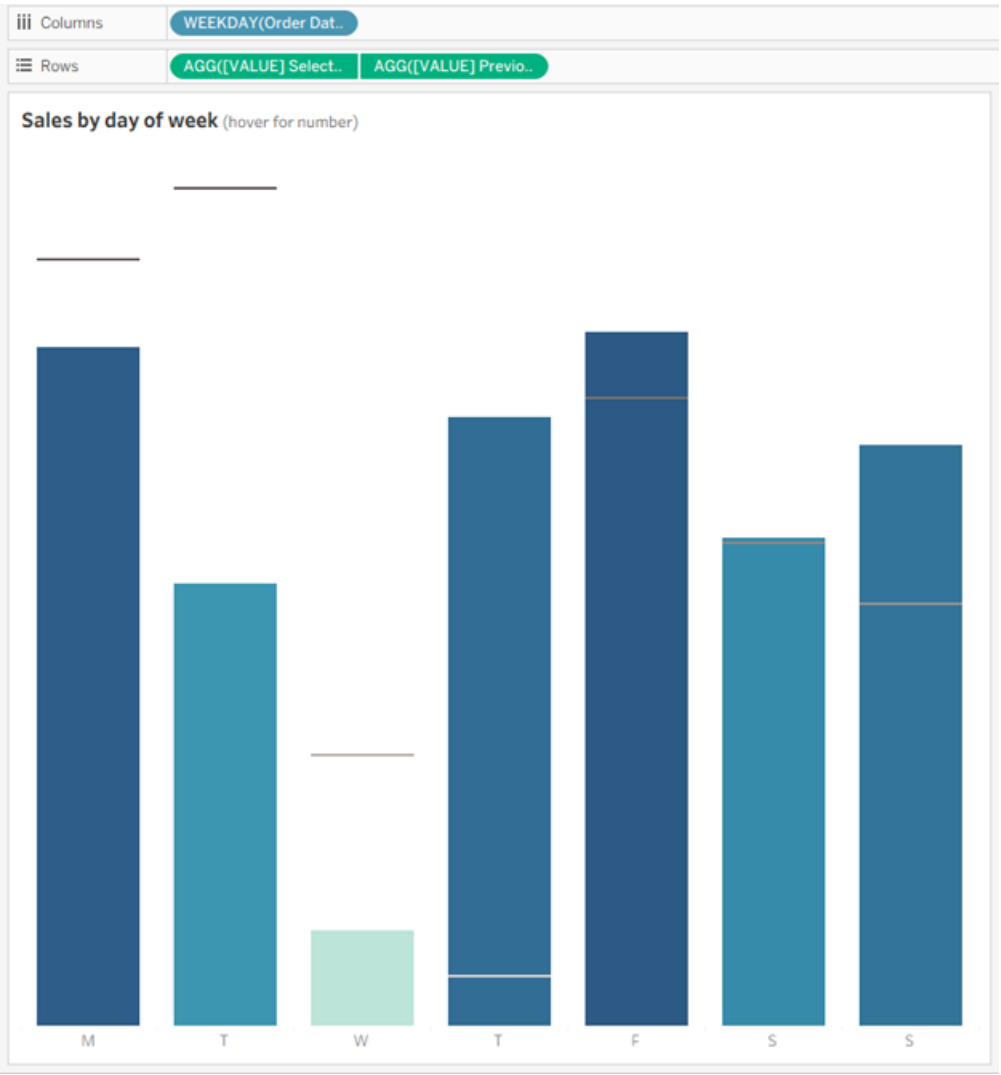

Hình 23: Biểu đồ `[1.4-B]` – Chỉ số theo ngày trong tuần.

Biểu đồ [2.1-M]

Đây là biểu đồ dạng filled map được tạo từ các tỉnh thành Việt Nam. Để đảm bảo mọi tỉnh thành đều được hiển thị (trong trường hợp hoạt động kinh doanh không được triển khai trên 100% tỉnh thành), ta cần sử dụng đến một nguồn dữ liệu khác (file Excel *Tỉnh thành Việt Nam*).

Mục tiêu của filled map này bên cạnh việc cung cấp một cái nhìn tổng thể về quy mô của từng địa phương, chúng ta còn muốn điều khiển 2 biểu đồ thành phần bằng việc kích chọn vào một tỉnh thành tương ứng trên map để cho ra dữ liệu cụ thể của riêng tỉnh thành đó. Để làm được điều này ta tiếp tục tạo parameter về các địa phương có tên `Selected Province`.

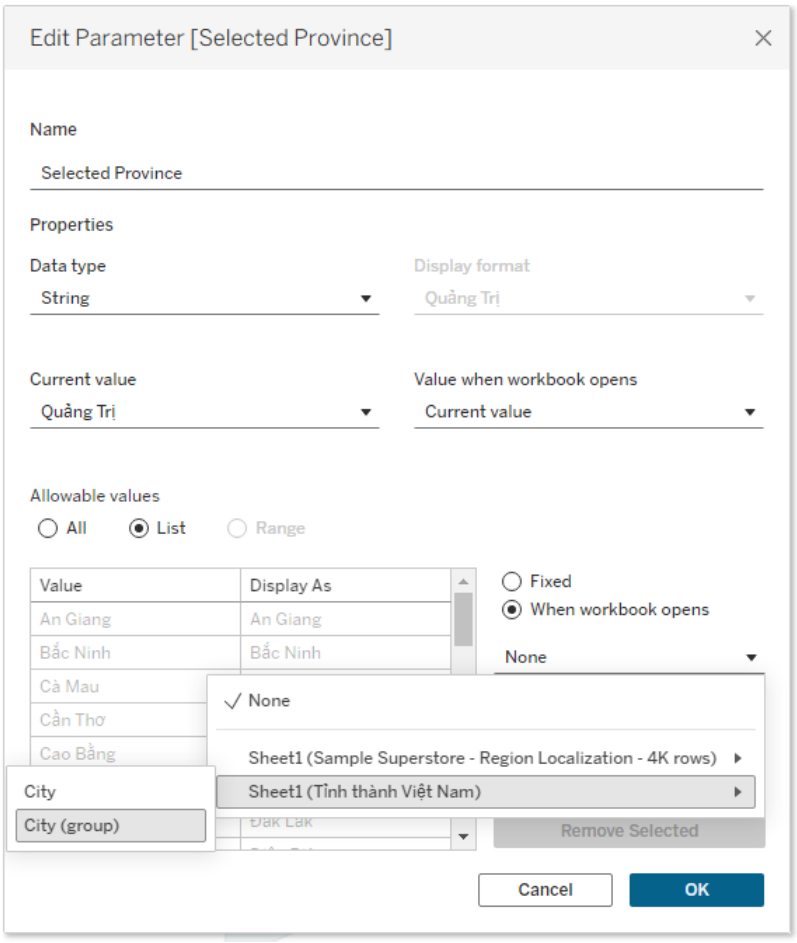

Hình 24: Cấu hình parameter `Selected Province`.

Chọn **When workbook opens** → nguồn **Sheet1 (Tỉnh thành Việt Nam)** → **City (group)** để lấy danh sách địa phương vào các giá trị của parameter > `OK`.

Để tạo nên từng điểm trên bản đồ, ta kéo **City (group)** vào **Detail**. Chuyển về dạng **Map** để từng điểm biến thành một diện tích tỉnh được tô màu.

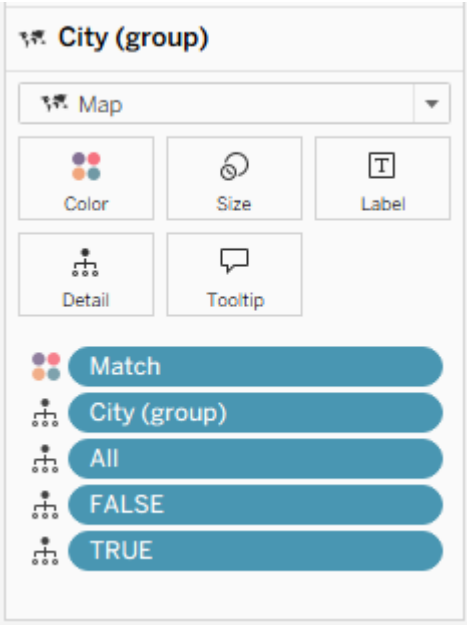

Hình 25: Cấu hình Marks cho layer filled map.

Mục tiêu của bản đồ này là cho thấy quy mô của `Sales` (hoặc `Profit` hoặc `Orders`). Vì vậy ta tạo thêm một map layer nữa để thể hiện các điểm tròn trên bản đồ với size của điểm là quy mô của từng địa phương. Tiếp tục kéo `City (group)` vào góc trên bên trái map cho đến khi hiện menu `Add a Marks Layer` và thả tạo được một map layer chồng lên map hiện tại. Chuyển về dạng **Circle**, sau đó kéo measure **[VALUE] Selected Year Metrics** vào `Size`.

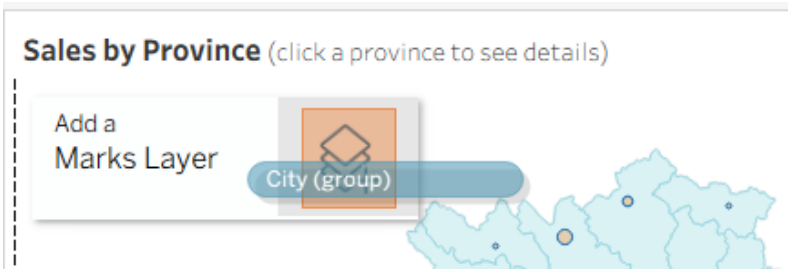

(a) Thêm map layer thứ hai.

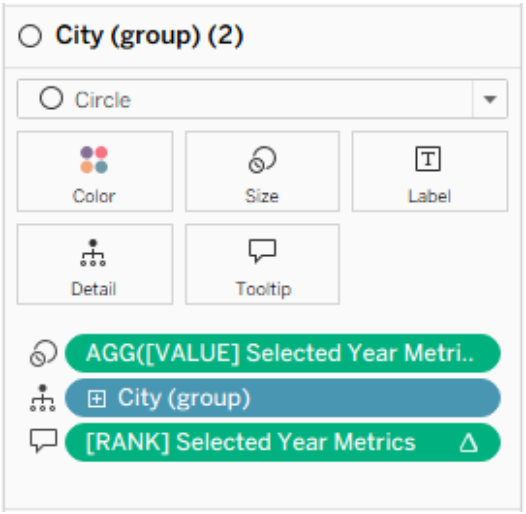

(b) Cấu hình Marks cho layer Circle.

Hình 26: Cấu hình hai layer map cho biểu đồ `[2.1-M]`.

Mục tiêu tiếp theo của bản đồ này là cho thấy xếp hạng của từng địa phương với Chỉ số được chọn thông qua thông tin trong Tooltip. Ta tạo calculated field:

```
// [RANK] Selected Year Metrics
CASE [Selected Metric]
WHEN "Sales"   THEN [[RANK]] Selected Year Sales]
WHEN "Profit"  THEN [[RANK]] Selected Year Profit]
WHEN "Orders"  THEN [[RANK]] Selected Year Orders]
END
```

Measure này được tạo từ các calculated field tính ranking theo công thức sau:

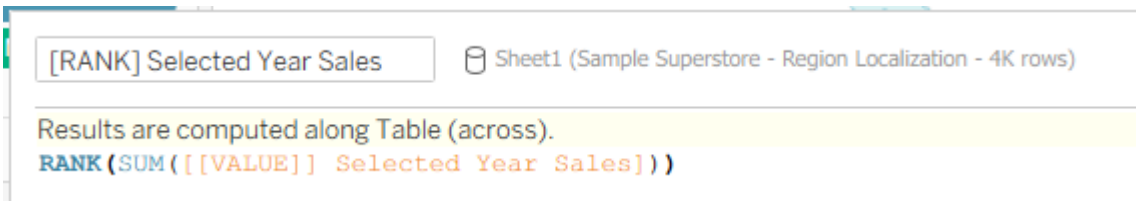

Hình 27: Công thức calculated field ranking cho `Sales`.

Làm tương tự cho `Profit` và `Orders`. Sau khi tạo đủ các trường cần thiết, kéo **[RANK] Selected Year Metrics** vào tooltip của layer map Circle.

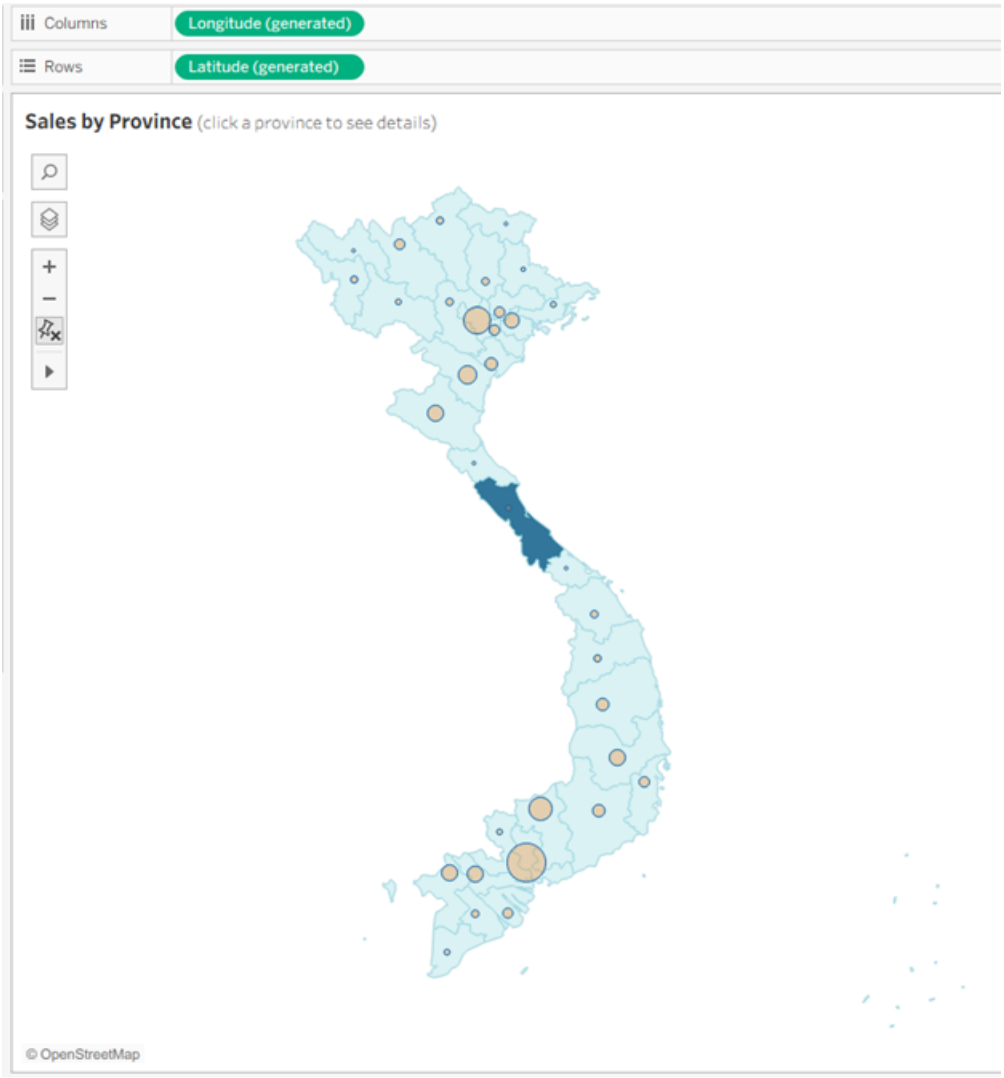

Hình 28: Biểu đồ filled map hoàn chỉnh `[2.1-M]`.

Bản đồ này cho phép ta kích vào một tỉnh thành để lọc dữ liệu. Sau đây là cách setup bằng tính năng **Actions**:

Chọn **Worksheet** → **Actions** → **Add Action** → **Change Parameter**.

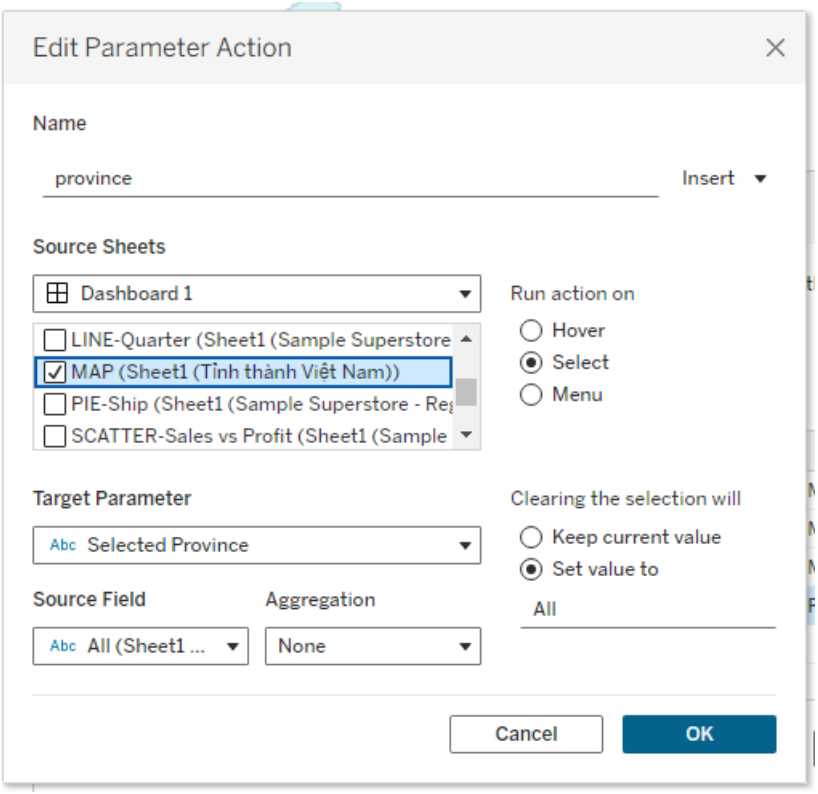

Hình 29: Cấu hình Parameter Action cho filled map.

- **Source Sheets**: MAP (Sheet1 (Tỉnh thành Việt Nam))
- **Run action on**: Select
- **Target Parameter**: Selected Province
- **Source Field**: All (Sheet1 (Tỉnh thành Việt Nam))
- **Clearing the selection will**: Set value to All

Trước đó cần tạo calculated field tên là `All` trong data source *Sheet1 (Tỉnh thành Việt Nam)* có công thức:

```
// All
IF [Selected Province] = [City (group)] THEN "All"
ELSE [City (group)]
END
```

Kéo `All` vào `Detail`, kích đúp vào bên dưới `All` và gõ thêm giá trị `TRUE` và `FALSE` vào Detail.

Để tô màu cho tỉnh thành đang được chọn, tạo thêm calculated field `Match` có công thức:

```
// Match
[Selected Province] = [City (group)]
```

Sau đó chọn 2 màu khác nhau cho tỉnh thành đang được chọn và các tỉnh còn lại.

Biểu đồ [2.2-B]

Biểu đồ này nằm trong khu vực 2 – liên quan đến filled map đã thực hiện ở `[2.1-M]`.

Về cơ bản, đây chỉ là một bar chart thông thường với **Rows** gồm 2 thông tin: tên của khách hàng có chi tiêu cao trong địa phương và xếp hạng của khách hàng đó. Ta sử dụng lại calculated field [[**RANK**]] **Selected Year Metrics** và kéo thêm dimension **Customer Name**. Mục **Columns** chọn lại [**VALUE**] **Selected Year Metrics**.

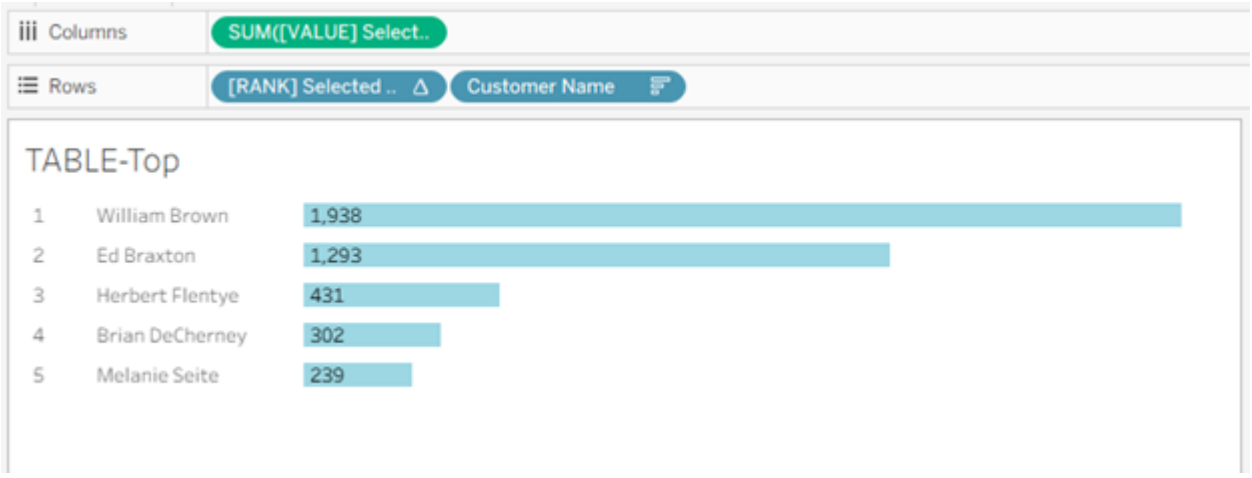

Hình 30: Cấu hình biểu đồ `[2.2-B]` – Top khách hàng theo địa phương.

Trong phần **Filters** của biểu đồ này gồm 2 tiêu chí:

Tiêu chí 1: Để kết nối giá trị của địa phương đang được chọn ở filled map với giá trị lọc của biểu đồ này, ta cần tạo:

```
// Selected Province filter
IF [City (group)] = [Selected Province] THEN [City (group)] END
```

Thả calculated field vào `Filters` và chọn **Exclude Null**.

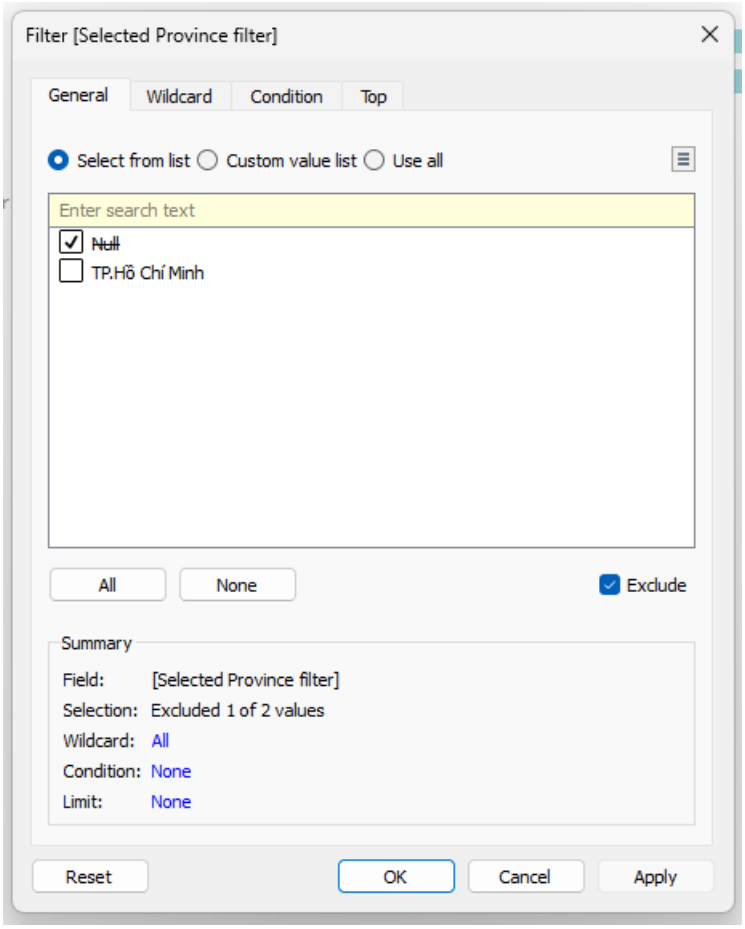

Hình 31: Cấu hình filter theo địa phương được chọn.

Tiêu chí 2: Để mở rộng tùy chọn có thể hiển thị top 3 – 5 – 10 khách hàng, ta tạo thêm parameter `Selected Top`:

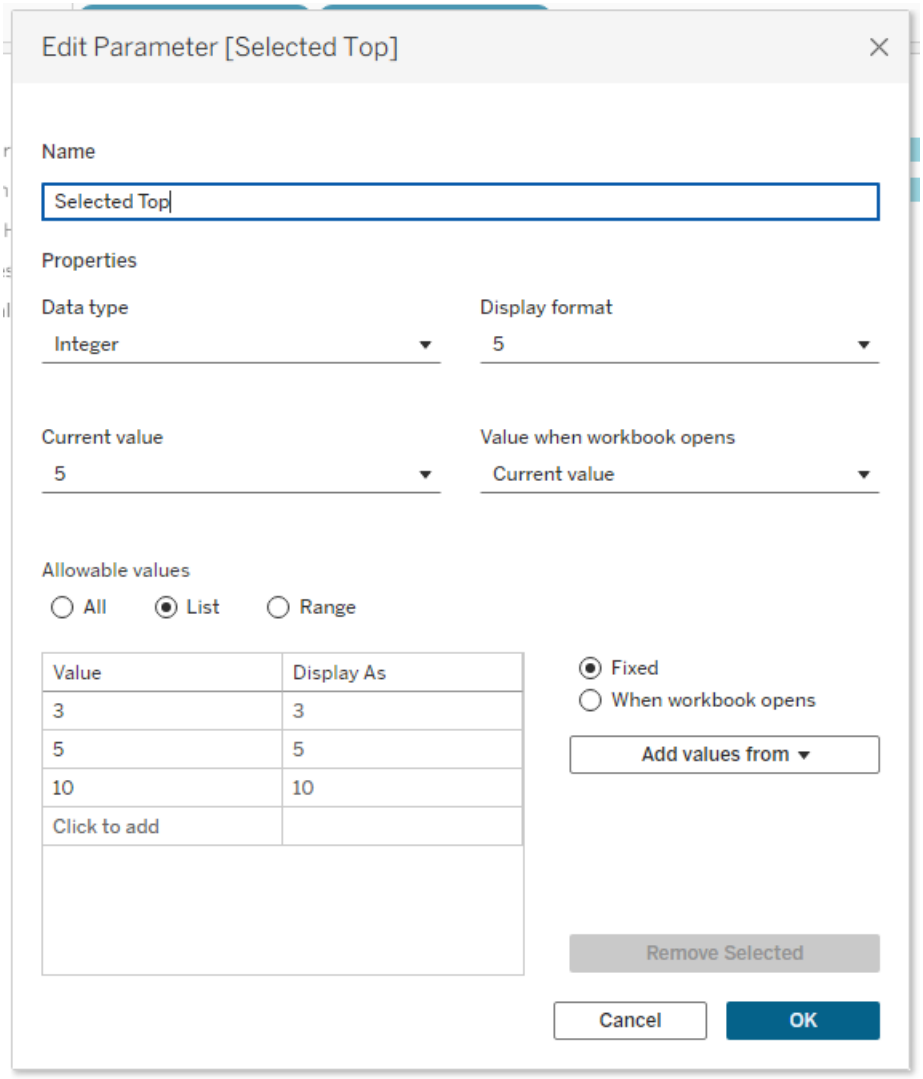

Hình 32: Cấu hình parameter `Selected Top`.

Sau đó tạo calculated field để kết nối parameter với giá trị xếp hạng của từng khách hàng:

```
// [RANK] Selected Top
[[RANK]] Selected Year Metrics] <= [Selected Top]
```

Đưa vào `Filters` và chọn **True**.

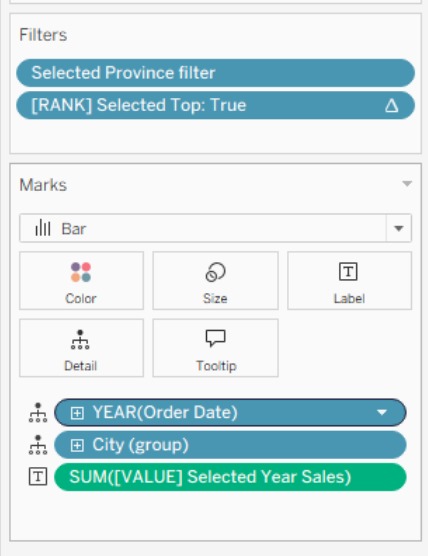

Hình 33: Cấu hình filter theo `Selected Top`.

Biểu đồ [2.3-T]

Biểu đồ này nằm trong khu vực 2 liên quan đến filled map đã thực hiện ở `[2.1-M]`.

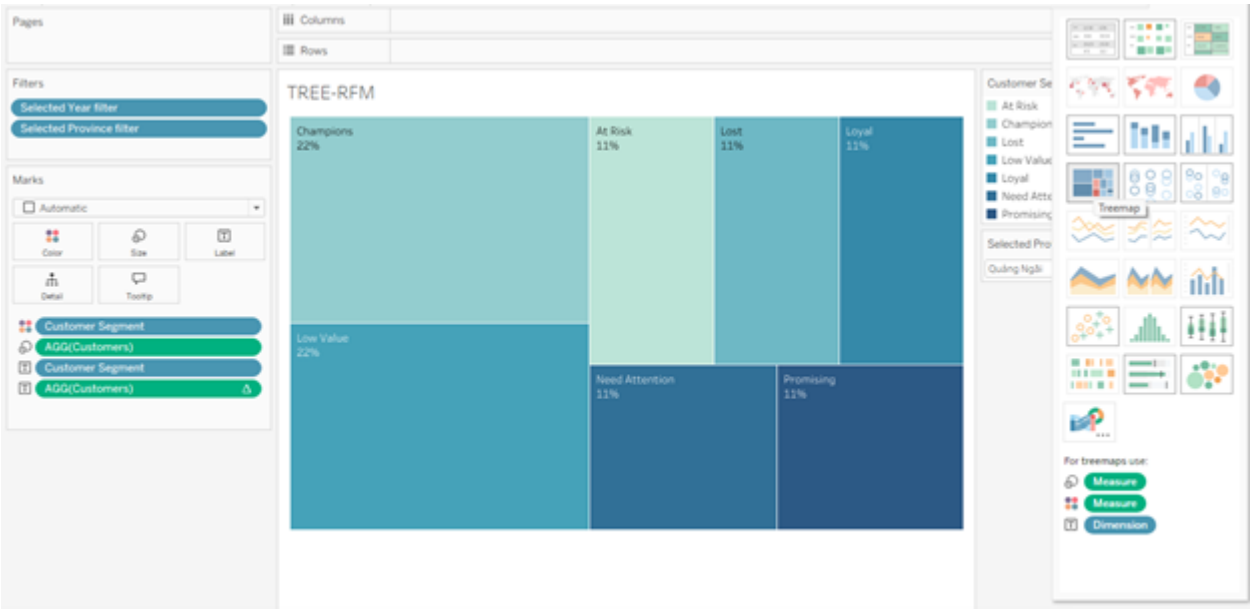

Hình 34: Biểu đồ tree map `[2.3-T]` Phân khúc khách hàng theo RFM.

Để thực hiện được biểu đồ này, ta sử dụng chức năng **Show Me** của Tableau, cung cấp cho người dùng các preset để tạo các dạng biểu đồ phổ biến. Trong trường hợp này ta chọn **Tree Map**.

Biểu đồ Tree Map này thể hiện cơ cấu phân khúc khách hàng theo mô hình RFM, sử dụng 1 dimension là `Customer Segment` (kết quả phân khúc khách hàng) và 1 measure là `Customers` (đếm unique theo `Customer ID`).

Công thức cho calculated field **Customer Segment** như sau:

```
// Customer Segment
IF [Recency Score] >= 4 AND [Frequency Score] >= 4
   AND [Monetary Score] >= 4 THEN 'Champions'
ELSEIF [Recency Score] >= 3 AND [Frequency Score] >= 3
   AND [Monetary Score] >= 3 THEN 'Loyal'
ELSEIF [Recency Score] >= 4 AND ([Frequency Score] >= 2
   OR [Monetary Score] >= 2) THEN 'Promising'
ELSEIF [Recency Score] <= 2 AND [Frequency Score] >= 3
   AND [Monetary Score] >= 3 THEN 'At Risk'
ELSEIF [Recency Score] <= 2 AND [Frequency Score] <= 2 THEN 'Lost'
ELSEIF [Monetary Score] <= 2 AND [Frequency Score] <= 2 THEN 'Low Value'
ELSE 'Need Attention'
END
```

Để cấu thành nên công thức này ta cần các calculated field thành phần là:

```
// [Recency Score]
IF [Recency] >= {FIXED YEAR([Order Date]): PERCENTILE([Recency],0.75)}
   THEN 1
ELSEIF [Recency] >= {FIXED YEAR([Order Date]): PERCENTILE([Recency],0.5)}
   THEN 2
ELSEIF [Recency] >= {FIXED YEAR([Order Date]): PERCENTILE([Recency],0.25)}
   THEN 3
ELSE 4
END

// [Frequency Score]
IF [Frequency] >= {FIXED YEAR([Order Date]): PERCENTILE([Frequency],0.75)}
   THEN 4
ELSEIF [Frequency] >= {FIXED YEAR([Order Date]): PERCENTILE([Frequency],0.5)}
   THEN 3
ELSEIF [Frequency] >= {FIXED YEAR([Order Date]): PERCENTILE([Frequency],0.25)}
   THEN 2
ELSE 1
END

// [Monetary Score]
IF [Monetary] >= {FIXED YEAR([Order Date]): PERCENTILE([Monetary],0.75)}
   THEN 4
ELSEIF [Monetary] >= {FIXED YEAR([Order Date]): PERCENTILE([Monetary],0.5)}
   THEN 3
ELSEIF [Monetary] >= {FIXED YEAR([Order Date]): PERCENTILE([Monetary],0.25)}
   THEN 2
ELSE 1
END
```

Lưu ý: công thức tính điểm này phụ thuộc vào định nghĩa của từng business.

Biểu đồ [3.1-P]

Biểu đồ nhằm thể hiện tỉ trọng của Chỉ số `Sales`, `Profit` hoặc `Orders` theo từng `Ship Status`. Vì thực hiện bằng donut chart nên ta dựng 2 pie chart đồng tâm để giả lập hiệu ứng donut (1 pie chart đường kính lớn cho biểu đồ tỉ trọng, 1 pie chart đường kính nhỏ hơn khoảng 20 - 30% giả lập phần rỗng ở giữa bằng cách tô màu trắng giống màu nền).

Ta tạo 2 measure có công thức `SUM(0)` ở **Rows**, sau đó chọn **Dual Axis** để 2 hình tròn đồng tâm tại tọa độ 0.

Với pie chart thể hiện cơ cấu, ta thả dimension **Ship Status** vào **Mark Color**, thả giá trị của Chỉ số vào **Mark Angle**. Các Tooltip bổ sung thông tin về Chỉ số so với cùng kỳ tương tự các biểu đồ trước.

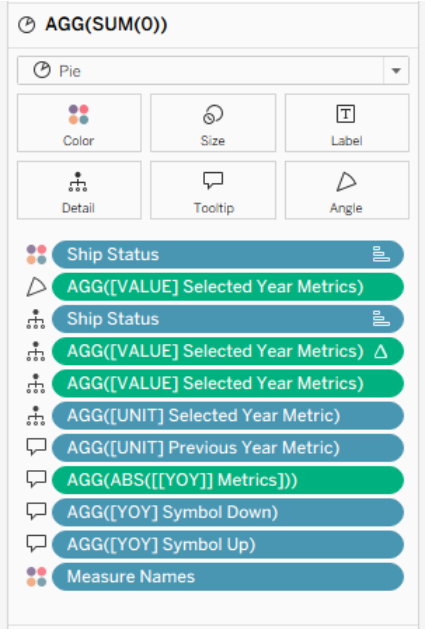

Hình 35: Cấu hình Marks cho pie chart ngoài biểu đồ `[3.1-P]`.

Với pie chart tạo hiệu ứng tâm phía trong, ta thiết lập chủ yếu về `Tooltip`. Lúc này ta không cần đến các `Mark Color` và `Angle`.

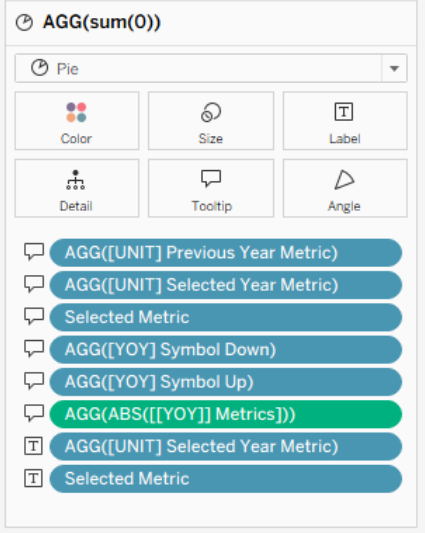

Hình 36: Cấu hình Marks cho pie chart trong tạo hiệu ứng donut.

Để hoàn thiện donut chart, kích chuột phải vào từng slice của chart, chọn `Annotate > Mark` để thêm text cho từng slice một cách linh hoạt và rõ ràng hơn.

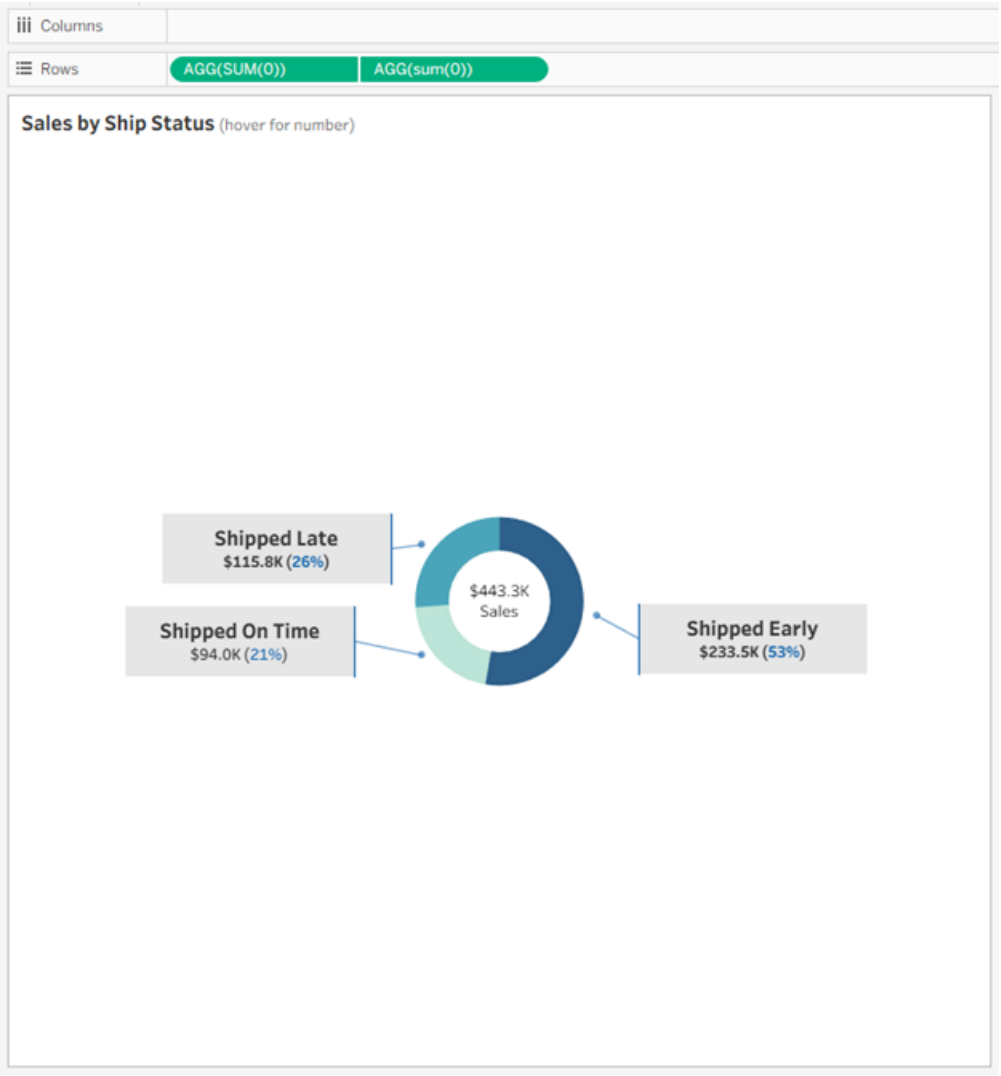

Hình 37: Biểu đồ donut chart hoàn chỉnh `[3.1-P]`.

Biểu đồ [3.2-S]

Biểu đồ nhằm thể hiện mối tương quan giữa `Sales` và `Profit` nên không cần sử dụng các measure được điều khiển bởi parameter. Ta chỉ cần kéo và thả `Sales` và `Profit` vào **Columns** và **Rows**.

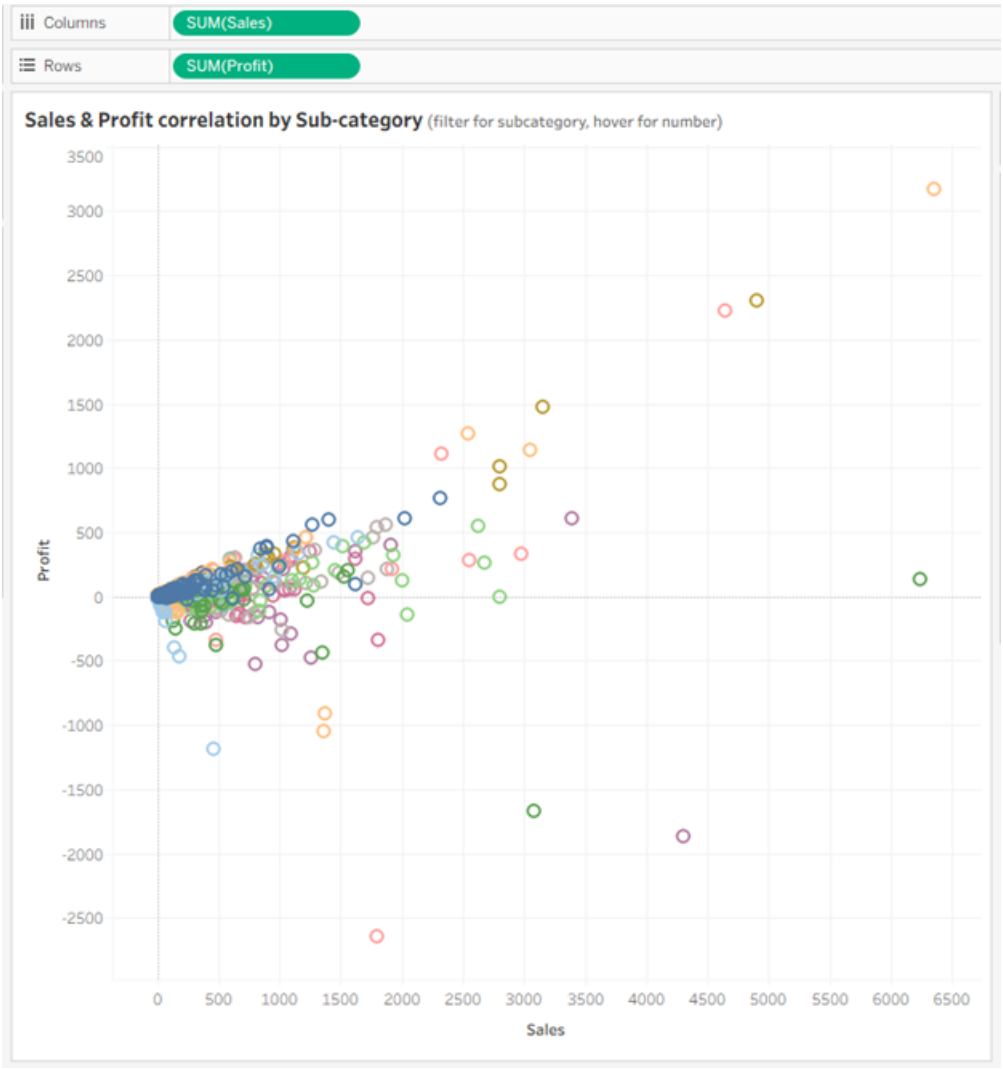

Hình 38: Cấu hình ban đầu của scatter plot `[3.2-S]`.

Sau đó để xem theo từng Order, ta kéo `Order ID` vào `Detail`, kéo `Sub-Category` vào `Color`.

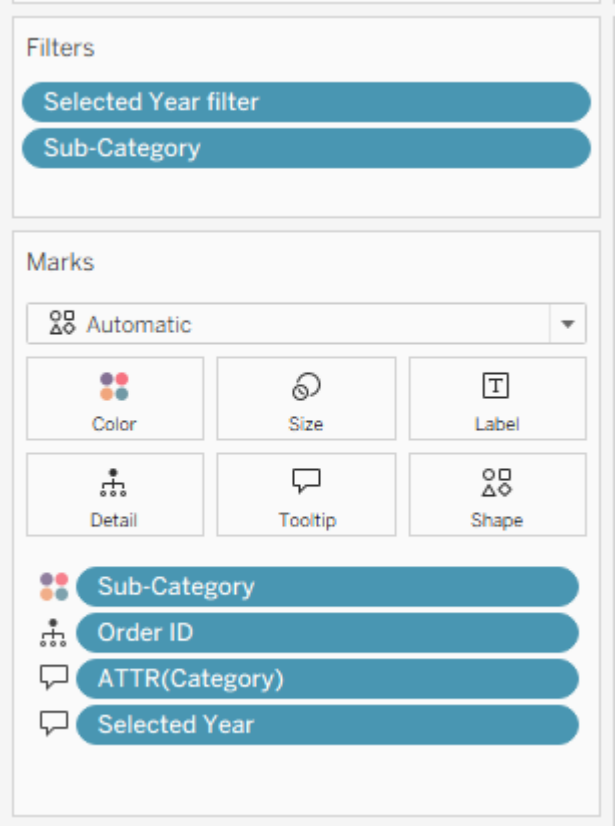

Hình 39: Cấu hình Marks chi tiết cho biểu đồ `[3.2-S]`.

Filters bao gồm:

- **Selected Year filter**: liên kết với parameter `Selected Year`.
- **Sub-Category**: bộ lọc của riêng biểu đồ này, cho phép thể hiện 1 hoặc tất cả các `Sub-Category` để phân tích mối tương quan rõ ràng hơn.

Tạo giao diện chuyển đổi giữa các Chỉ số

Mục tiêu là ta sẽ tạo một giao diện giả lập các nút bấm để chuyển sang xem theo `Sales`, `Profit` hoặc `Orders`.

Đầu tiên ta tạo một biểu đồ gồm 3 giá trị `SUM(0)` và chọn dạng **Square**.

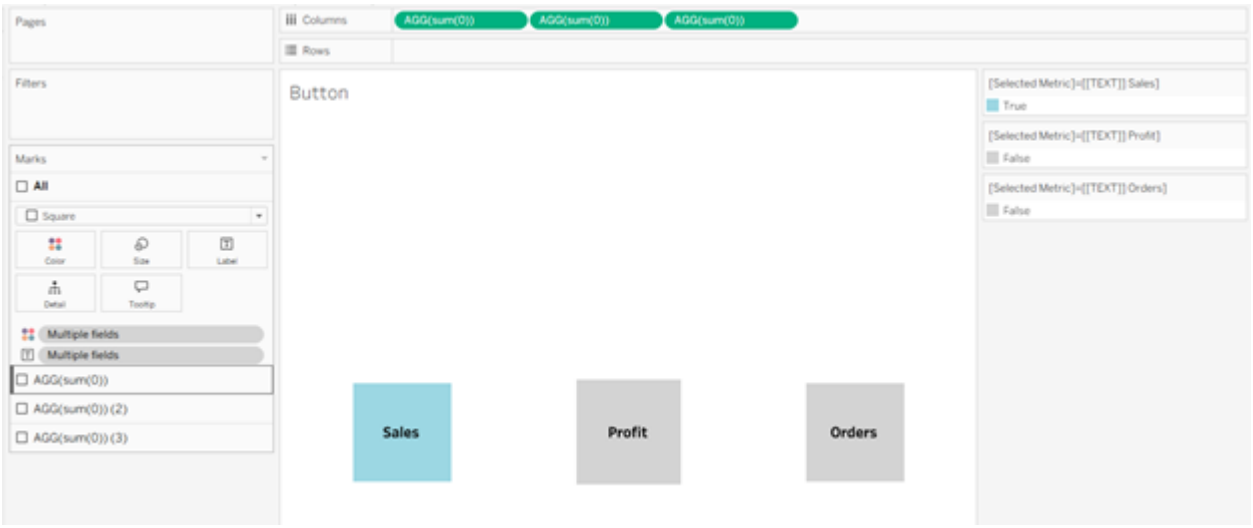

Hình 40: Biểu đồ giả lập nút bấm chuyển đổi Chỉ số.

Mỗi ô vuông được cấu hình bởi 2 yếu tố:

- Tên của metric được hiển thị (`Sales`, `Profit`, `Orders`).
- Màu của ô vuông được xác định bằng công thức `[Selected Metric] = [[TEXT]] Sales`. Sau đó ta chọn màu phù hợp cho giá trị `True` và `False` ví dụ `False` màu xám và `True` màu xanh, có nghĩa là khi parameter `Selected Metric` có giá trị là `Sales` thì ô vuông `Sales` sẽ chuyển màu xanh còn các ô vuông còn lại có màu xám.

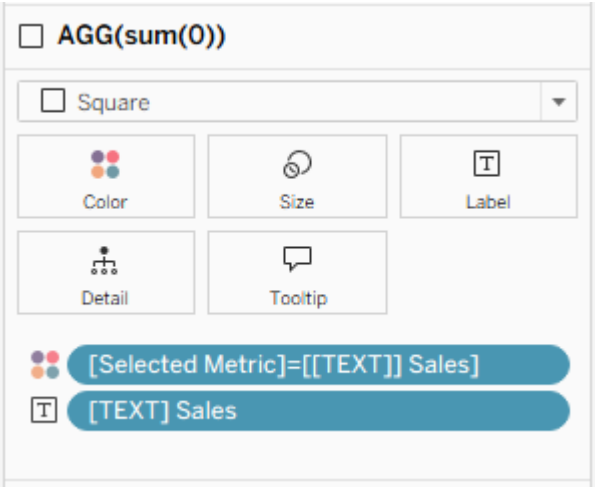

Hình 41: Cấu hình màu sắc cho nút bấm `Sales`.

Làm tương tự cho các ô vuông còn lại.

Tiếp theo, để kết nối giao diện giả lập nút bấm này với các biểu đồ đã dựng, ta sử dụng chức năng **Action** trong menu `Dashboard > Add Action > Change Parameter`. Cấu hình cho Parameter Action như sau:

- **Name**: sales
- **Source Sheets**: chọn Sheet1 (Sample Superstore – Region Localization – 4K rows). Sau đó tích vào các biểu đồ 2.1, 2.2, 2.3, 3.1, 3.2 và Button.
- **Run action on**: Select
- **Target Parameter**: Selected Metric
- **Clearing the selection will**: Keep current value
- **Source Field**: `[TEXT] Sales`

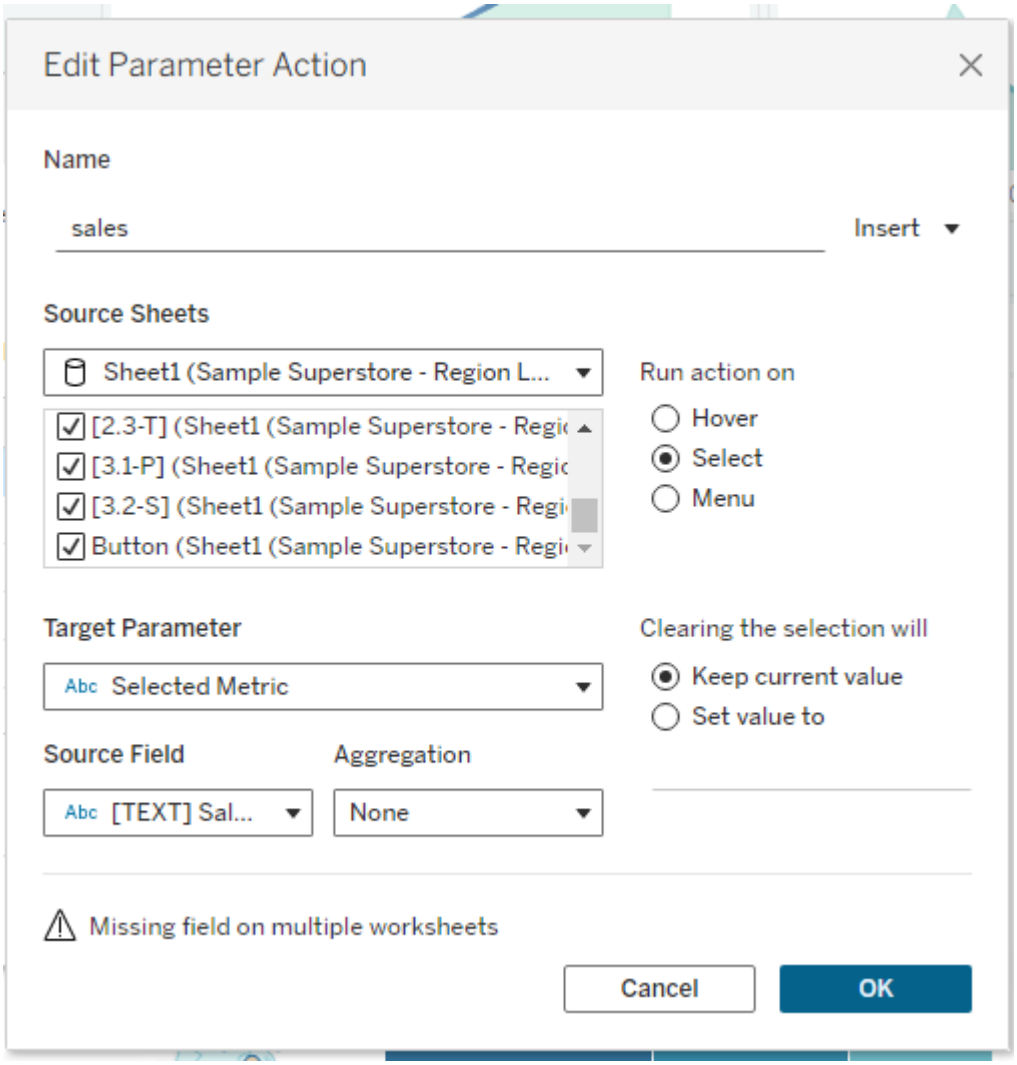

Hình 42: Cấu hình Parameter Action cho nút bấm `Sales`.

Lặp lại tương tự cho 2 Action còn lại với `Profit` và `Orders`.

Lúc này nếu bạn kích chọn ô vuông có giá trị `Profit` thì toàn bộ các biểu đồ có liên kết với parameter `Selected Metric` sẽ chuyển sang hiển thị measure là `Profit`, thay vì `Sales` hoặc `Orders`.

Kết hợp để có giao diện dashboard cuối cùng

Ta tạo dashboard mới bằng cách chọn icon thứ 2 ở thanh công cụ phía góc dưới bên trái giao diện Tableau.

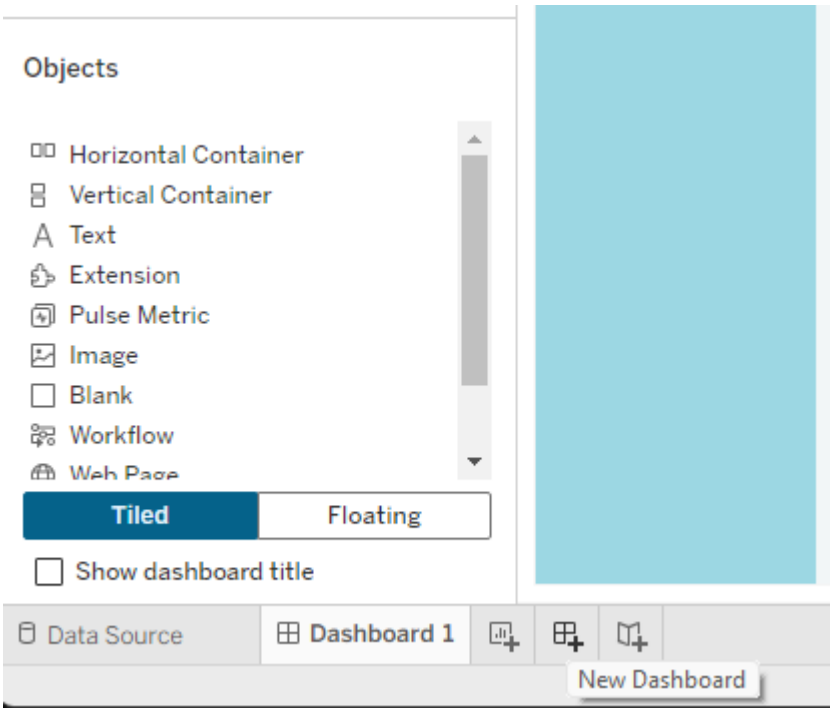

Hình 43: Tạo dashboard mới trong Tableau.

Một dashboard của Tableau được cấu thành từ các **Container**, vì vậy bạn cần tạo chúng trước để xây dựng bố cục tổng thể cho dashboard. Có 2 dạng Container là **Horizontal** (dàn theo hàng ngang) và **Vertical** (dàn theo hàng dọc), bạn có thể kết hợp chúng với nhau một cách linh hoạt để tạo ra được bố cục mong muốn.

Để thay đổi màu nền cho một item trên dashboard, ta chuyển sang tab **Layout**. Ảnh minh họa là các thông số cho item sidebar màu xanh nằm phía trái của dashboard.

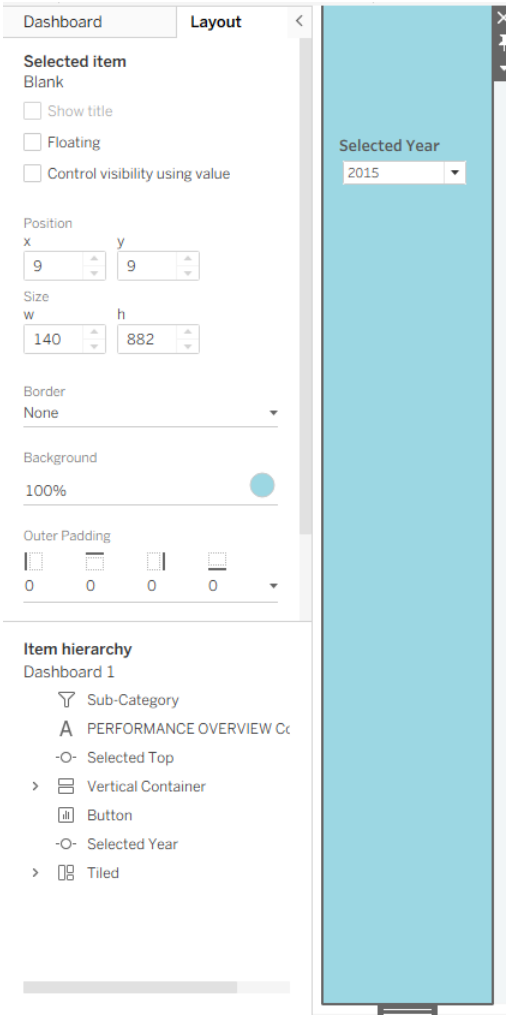

Hình 44: Cấu hình màu nền cho Container trong tab Layout.

Sau khi thực hiện dàn trang theo bố cục đã xác định trước, hãy đảm bảo:

- Chọn một tông màu tổng thể phù hợp và hài hòa cho toàn bộ dashboard.
- Các thông tin cơ bản về dashboard cần được hiển thị rõ ràng và đầy đủ.
- Các Action và Parameter hoạt động trơn chu và chính xác.

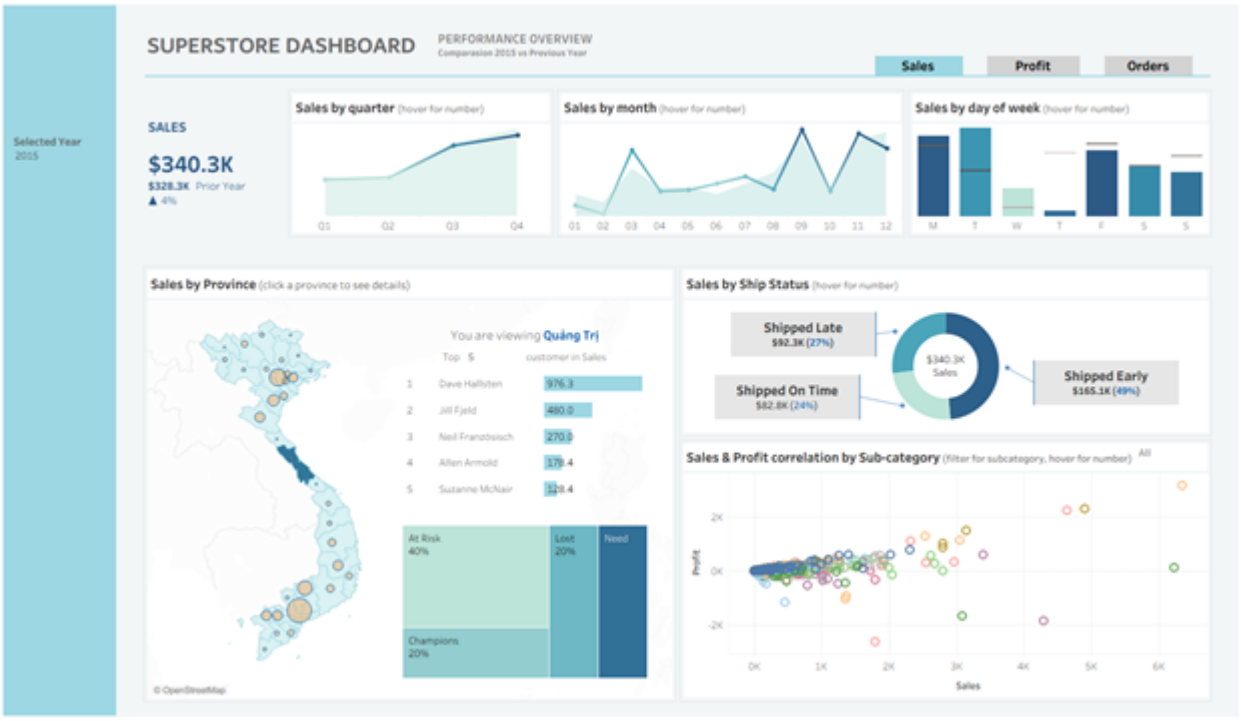

Hình 45: Giao diện dashboard hoàn chỉnh.

Tổng kết

Qua hai buổi học, chúng ta đã đi qua toàn bộ quy trình làm việc với dữ liệu trên Tableau – từ những bước nền tảng như kết nối dữ liệu, phân biệt Dimension và Measure, xây dựng các biểu đồ đơn lẻ, cho đến việc tích hợp tất cả thành một dashboard hoàn chỉnh có khả năng tương tác.

Bài tập tổng hợp là minh chứng cho thấy sức mạnh thực sự của Tableau không nằm ở từng biểu đồ riêng lẻ, mà ở khả năng kết nối chúng lại thông qua Parameter và Actions để tạo ra một công cụ phân tích linh hoạt, đáp ứng được nhiều câu hỏi kinh doanh khác nhau chỉ trên một giao diện duy nhất.

Điều quan trọng cần ghi nhớ là kỹ thuật, công cụ chỉ là phương tiện mọi lựa chọn về biểu đồ, bộ lọc hay cách trình bày đều cần xuất phát từ câu hỏi phân tích cụ thể. Một dashboard tốt không phải là dashboard có nhiều tính năng nhất, mà là dashboard giúp người xem ra quyết định nhanh và chính xác nhất.

XII. Câu hỏi trắc nghiệm

1. Cho dataset sau:

Row	Region	Sales	Discount
1	East	200	0.1
2	East	300	0.2
3	West	150	0.15
4	West	350	0.05

Bạn tạo 3 Calculated Field trong Tableau:

```
// Formula X
[Sales] * (1 - [Discount])

// Formula Y
[Sales] - SUM([Sales]) / 4

// Formula Z
SUM([Sales]) / COUNT([Sales])
```

Formula nào sẽ gây lỗi **"Cannot mix aggregate and non-aggregate arguments"** trong Tableau, và cách sửa đúng là gì?

(a) Formula X gây lỗi vì nhân hai field row-level. Sửa: `SUM([Sales]) * (1 - SUM([Discount]))`.

(b) Formula Y gây lỗi vì trộn `[Sales]` (row-level) với `SUM([Sales])` (aggregate). Sửa: `SUM([Sales]) - SUM([Sales]) / 4`.

(c) Formula Z gây lỗi vì chia hai aggregate function. Sửa: tách thành 2 Calculated Field riêng.

(d) Cả 3 formula đều hợp lệ, không có lỗi nào.

2. Cho dataset sau:

Row	Region	Category	Sales
1	East	Tech	400
2	East	Tech	100
3	East	Furniture	300
4	West	Tech	100
5	West	Furniture	500
6	West	Furniture	100

View hiển thị **Region** trên Rows (chỉ có 1 dimension trong view). Bạn tạo LOD expression:

`{ INCLUDE [Category] : SUM([Sales]) }`

Bạn kéo INCLUDE LOD field vào view và chọn aggregation là `AVG`. Giá trị hiển thị cho Region **"West"** là bao nhiêu?

(a) 200

(b) 350

(c) 400

(d) 700

3. Cho dataset sau:

Region	Category	Sales
East	Tech	500
East	Furniture	300
West	Tech	400
West	Furniture	200

Bạn tạo FIXED LOD: `{ FIXED [Region] : SUM([Sales]) }`

View có **Region** và **Category** trên Rows. Bạn áp dụng filter: `Category = "Tech"`.

Scenario A: Category filter là **Dimension Filter** bình thường.
Scenario B: Category filter được đặt làm **Context Filter**.

Giá trị FIXED LOD cho Region "East" trong Scenario A và Scenario B lần lượt là bao nhiêu?

(a) A: 500, B: 500 : Context Filter không ảnh hưởng FIXED LOD.

(b) A: 800, B: 800 : FIXED LOD luôn tính trên toàn bộ dữ liệu.

(c) A: 800, B: 500 : Dimension Filter không ảnh hưởng FIXED LOD, nhưng Context Filter chạy trước và thu hẹp dữ liệu cho FIXED LOD.

(d) A: 500, B: 800 : Dimension Filter ảnh hưởng FIXED LOD, nhưng Context Filter thì không.

4. Cho dataset sau:

Row	Product	Sales	Profit	Quantity
1	Alpha	500	120	10
2	Beta	300	80	25
3	Gamma	700	50	15
4	Delta	400	200	8
5	Epsilon	600	150	20

Bạn tạo **Parameter** tên `[Select Measure]` (kiểu String, List: "Sales", "Profit", "Quantity") và Calculated Field:

```
-- Dynamic Measure
CASE [Select Measure]
    WHEN "Sales" THEN [Sales]
```

```
    WHEN "Profit" THEN [Profit]
    WHEN "Quantity" THEN [Quantity]
END
```

View có **Product** trên Rows, `SUM([Dynamic Measure])` trên Columns. Bạn áp dụng **Top 3** filter trên Product by `SUM([Dynamic Measure])`.

Khi user chọn `[Select Measure] = "Profit"`, tổng giá trị `SUM([Dynamic Measure])` hiển thị trên view (tổng của 3 sản phẩm Top 3) là bao nhiêu?

(a) 350

(b) 470

(c) 600

(d) 1800

5. Trong Tableau, mục đích chính của **Dashboard** là gì?

   (a) Kết nối dữ liệu từ nhiều nguồn khác nhau.

   (b) Kết hợp nhiều worksheet vào cùng một màn hình để trực quan hóa dữ liệu tổng hợp.

   (c) Lưu trữ dữ liệu dưới dạng bảng.

   (d) Thay thế hoàn toàn worksheet.

6. Sự khác biệt chính giữa **Tiled** và **Floating** layout trong Tableau là gì?

   (a) Tiled cho phép đặt tự do các đối tượng, Floating tự động căn chỉnh.

   (b) Tiled tự động căn chỉnh theo bố cục lưới, Floating cho phép đặt đối tượng tự do.

   (c) Tiled chỉ dùng cho biểu đồ, Floating chỉ dùng cho filter.

   (d) Không có sự khác biệt giữa hai loại layout này.

7. Trong thiết kế dashboard, nguyên tắc sử dụng màu sắc nào sau đây là phù hợp nhất?

   (a) Sử dụng càng nhiều màu càng tốt để tăng tính trực quan.

   (b) Chỉ sử dụng một màu duy nhất cho toàn bộ dashboard.

   (c) Sử dụng màu sắc để nhấn mạnh thông tin quan trọng và giữ sự nhất quán.

   (d) Sử dụng màu ngẫu nhiên để phân biệt các biểu đồ.

8. **Filter Action** trong Tableau có chức năng gì?

   (a) Làm nổi bật các điểm dữ liệu liên quan giữa các biểu đồ.

   (b) Cho phép chuyển đổi giữa các dashboard khác nhau.

   (c) Cho phép một biểu đồ đóng vai trò bộ lọc cho các biểu đồ khác.

   (d) Thay đổi màu sắc của biểu đồ theo thời gian.

9. (Bài tập tổng hợp Parameter và Actions)
   Trong bài hướng dẫn, để dashboard có thể hiển thị đồng thời cả ba chỉ số `Sales`, `Profit` và `Orders` mà không cần tạo ba phiên bản dashboard riêng biệt, giải pháp được áp dụng là gì?

   A. Tạo ba tab sheet riêng biệt, mỗi tab hiển thị một chỉ số

   B. Tạo một parameter `Selected Metric` và các calculated field kết nối với nó, cho phép toàn bộ biểu đồ chuyển đổi chỉ số chỉ bằng một thao tác chọn

   C. Dùng bộ lọc filter thông thường trên từng biểu đồ để ẩn/hiện chỉ số tương ứng

   D. Tạo ba measure riêng biệt và kéo cả ba vào cùng một biểu đồ để người xem tự so sánh

10. (Bài tập tổng hợp LOD Expression)
    Để tính điểm Recency Score cho mô hình RFM, công thức sử dụng `FIXED` như sau:

    ```
    IF [Recency] >= { FIXED YEAR([Order Date]): PERCENTILE([Recency], 0.75)} THEN 1
    ...
    ```

    Bạn muốn đơn giản hóa bằng cách bỏ `FIXED` đi. Điều gì sẽ xảy ra?

    A. Công thức báo lỗi cú pháp vì `PERCENTILE` bắt buộc phải dùng kèm LOD expression

    B. Kết quả không đổi vì `PERCENTILE` luôn tính trên toàn bộ dataset bất kể có `FIXED` hay không

    C. Ngưỡng phân loại bị thay đổi mỗi khi người dùng áp dụng filter, khiến cùng một khách hàng có thể được xếp hạng khác nhau tùy theo bộ lọc đang chọn

    D. Công thức vẫn đúng nhưng chỉ khi dashboard không sử dụng bất kỳ filter nào

Phụ lục

1. **Hint:** Các file code gợi ý và dữ liệu nếu có được lưu trong thư mục có thể được tải tại đây.
2. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại đây (Lưu ý: Sáng thứ 3 khi hết deadline phần project, ad mới copy các nội dung bài giải nêu trên vào đường dẫn).
3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 giờ.

Hình 23: Hình ảnh group facebook AIO Q&A

AI VIET NAM COURSE 2026

Quiz - Tableau: Dashboard & Storytelling

1. Cho dataset sau:

Row	Region	Sales	Discount
1	East	200	0.1
2	East	300	0.2
3	West	150	0.15
4	West	350	0.05

Bạn tạo 3 Calculated Field trong Tableau:

```
// Formula X
[Sales] * (1 - [Discount])

// Formula Y
[Sales] - SUM([Sales]) / 4

// Formula Z
SUM([Sales]) / COUNT([Sales])
```

Formula nào sẽ gây lỗi **"Cannot mix aggregate and non-aggregate arguments"** trong Tableau, và cách sửa đúng là gì?

(a) Formula X gây lỗi vì nhân hai field row-level. Sửa: `SUM([Sales]) * (1 - SUM([Discount]))`.

(b) Formula Y gây lỗi vì trộn `[Sales]` (row-level) với `SUM([Sales])` (aggregate). Sửa: `SUM([Sales]) - SUM([Sales]) / 4`.

(c) Formula Z gây lỗi vì chia hai aggregate function. Sửa: tách thành 2 Calculated Field riêng.

(d) Cả 3 formula đều hợp lệ, không có lỗi nào.

Đáp án đúng: B

Giải thích chi tiết:

Trong Tableau, một Calculated Field phải hoàn toàn row-level **hoặc** hoàn toàn aggregate. Không được trộn lẫn. Phân tích từng formula:

- **Formula X:** `[Sales] * (1 - [Discount])` : cả `[Sales]` và `[Discount]` đều là row-level ⇒ **hợp lệ** (row-level × row-level).
- **Formula Y:** `[Sales] - SUM([Sales]) / 4` : `[Sales]` là row-level, `SUM([Sales])` là aggregate ⇒ **LỖI mixing!** Tableau báo lỗi: `Cannot mix aggregate and non-aggregate arguments`.
- **Formula Z:** `SUM([Sales]) / COUNT([Sales])` : cả hai đều aggregate ⇒ **hợp lệ** (aggregate / aggregate).

Cách sửa Formula Y: wrap `[Sales]` trong `SUM()` để đưa tất cả về cùng mức aggregate: `SUM([Sales]) - SUM([Sales]) / 4`.

Các lựa chọn khác không đúng vì:

- Formula X nhân hai field row-level, hoàn toàn hợp lệ. Không cần wrap trong SUM (A).
- Formula Z chia hai aggregate (`SUM / COUNT`), hoàn toàn hợp lệ. Không cần tách thành 2 field (C).
- Formula Y rõ ràng gây lỗi mixing, nên không thể nói cả 3 đều hợp lệ (D).

Vì vậy đáp án đúng là **B**.

2. Cho dataset sau:

Row	Region	Category	Sales
1	East	Tech	400
2	East	Tech	100
3	East	Furniture	300
4	West	Tech	100
5	West	Furniture	500
6	West	Furniture	100

View hiển thị **Region** trên Rows (chỉ có 1 dimension trong view). Bạn tạo LOD expression:

```
{ INCLUDE [Category] : SUM([Sales]) }
```

Bạn kéo INCLUDE LOD field vào view và chọn aggregation là `AVG`. Giá trị hiển thị cho Region **"West"** là bao nhiêu?

(a) 200

(b) 350

(c) 400

(d) 700

Đáp án đúng: B (350)

Giải thích chi tiết:

INCLUDE LOD thêm dimension vào mức chi tiết của view để tính, sau đó aggregate lên view level.

Bước 1: View chỉ có `Region`. INCLUDE thêm `Category` ⇒ mức chi tiết tính toán = `(Region, Category)`.

Tính `SUM([Sales])` theo `(Region, Category)`:

Region	Category	SUM(Sales)	INCLUDE LOD Value
East	Tech	$400 + 100 = 500$	500
East	Furniture	300	300
West	Tech	100	100
West	Furniture	$500 + 100 = 600$	600

Bước 2: Aggregate lên view level (Region). Với Region "West", có 2 giá trị LOD ở mức (Region, Category): Tech = 100, Furniture = 600.

$$\text{AVG(INCLUDE LOD) cho West} = \frac{100 + 600}{2} = \boxed{350}$$

Lưu ý: AVG ở đây tính trên số lượng giá trị LOD distinct theo (Region, Category), không phải số rows gốc.

Các lựa chọn khác không đúng vì:

- 200 (A): Lỗi tính SUM(Sales) cho West ($100 + 500 + 100 = 700$) rồi chia 3 rows, hoặc chỉ lấy một giá trị LOD.
- 400 (C): Nhầm lấy AVG của East ($(500 + 300)/2 = 400$) thay vì West.
- 700 (D): Cộng tổng hai giá trị LOD thay vì lấy trung bình ($100 + 600 = 700$).

Vì vậy đáp án đúng là **B (350)**.

3. Cho dataset sau:

Region	Category	Sales
East	Tech	500
East	Furniture	300
West	Tech	400
West	Furniture	200

Bạn tạo FIXED LOD: `{ FIXED [Region] : SUM([Sales]) }`

View có **Region** và **Category** trên Rows. Bạn áp dụng filter: `Category = "Tech"`.

Scenario A: Category filter là **Dimension Filter** bình thường.
Scenario B: Category filter được đặt làm **Context Filter**.

Giá trị FIXED LOD cho Region "East" trong Scenario A và Scenario B lần lượt là bao nhiêu?

(a) A: 500, B: 500 : Context Filter không ảnh hưởng FIXED LOD.

(b) A: 800, B: 800 : FIXED LOD luôn tính trên toàn bộ dữ liệu.

(c) A: 800, B: 500 : Dimension Filter không ảnh hưởng FIXED LOD, nhưng Context Filter chạy trước và thu hẹp dữ liệu cho FIXED LOD.

(d) A: 500, B: 800 : Dimension Filter ảnh hưởng FIXED LOD, nhưng Context Filter thì không.

Đáp án đúng: C

Giải thích chi tiết:

Order of Operations trong Tableau:

Context Filter $\longrightarrow$ **FIXED LOD** $\longrightarrow$ **Dimension Filter** $\longrightarrow$ INCLUDE/EXCLUDE LOD

- **Scenario A** (Category là Dimension Filter): FIXED LOD chạy **trước** Dimension Filter $\Rightarrow$ tính trên **toàn bộ** dữ liệu. `{ FIXED [Region] : SUM([Sales]) }` cho East = 500 + 300 = **800**. Dimension Filter lọc Category = "Tech" chỉ ảnh hưởng rows hiển thị, **không** thay đổi giá trị FIXED LOD.
- **Scenario B** (Category là Context Filter): Context Filter chạy **trước** FIXED LOD $\Rightarrow$ thu hẹp dữ liệu trước. Sau Context Filter (Category = "Tech"), dữ liệu còn lại:

Region	Category	Sales
East	Tech	500
West	Tech	400

FIXED LOD tính trên dữ liệu đã lọc: East = **500**.

Các lựa chọn khác không đúng vì:

- A: 500, B: 500 (A): Sai ở Scenario A — Dimension Filter chạy **sau** FIXED LOD nên không ảnh hưởng, FIXED LOD vẫn tính trên toàn bộ dữ liệu = 800.
- A: 800, B: 800 (B): Sai ở Scenario B — Context Filter chạy **trước** FIXED LOD, nên FIXED LOD chỉ nhìn thấy dữ liệu đã lọc = 500.
- A: 500, B: 800 (D): Đảo ngược hoàn toàn. Dimension Filter chạy sau FIXED LOD, Context Filter chạy trước.

Vì vậy đáp án đúng là **C** (A: 800, B: 500).

4. Cho dataset sau:

Row	Product	Sales	Profit	Quantity
1	Alpha	500	120	10
2	Beta	300	80	25
3	Gamma	700	50	15
4	Delta	400	200	8
5	Epsilon	600	150	20

Bạn tạo **Parameter** tên `[Select Measure]` (kiểu String, List: "Sales", "Profit", "Quantity") và Calculated Field:

```
-- Dynamic Measure
CASE [Select Measure]
    WHEN "Sales" THEN [Sales]
    WHEN "Profit" THEN [Profit]
    WHEN "Quantity" THEN [Quantity]
END
```

View có **Product** trên Rows, `SUM([Dynamic Measure])` trên Columns. Bạn áp dụng **Top 3** filter trên Product by `SUM([Dynamic Measure])`.

Khi user chọn `[Select Measure] = "Profit"`, tổng giá trị `SUM([Dynamic Measure])` hiển thị trên view (tổng của 3 sản phẩm Top 3) là bao nhiêu?

(a) 350

(b) 470

(c) 600

(d) 1800

Đáp án đúng: B (470)

Giải thích chi tiết:

Bước 1: Khi `[Select Measure] = "Profit"`, CASE expression trả về `[Profit]` cho mỗi row:

Product	Profit	Dynamic Measure
Alpha	120	120
Beta	80	80
Gamma	50	50
Delta	200	200
Epsilon	150	150

Bước 2: Top 3 filter by `SUM([Dynamic Measure])` = Top 3 by Profit:

- Delta: 200 (Top 1)
- Epsilon: 150 (Top 2)
- Alpha: 120 (Top 3)

Bước 3: Tổng giá trị hiển thị:

$$200 + 150 + 120 = \boxed{470}$$

Parameter thay đổi cả measure hiển thị **lẫn** tiêu chí Top N, vì cả hai đều dùng cùng `SUM([Dynamic Measure])`.

Các lựa chọn khác không đúng vì:

- 350 (A): Lỗi lấy Top 3 by Sales (Gamma, Epsilon, Alpha) nhưng hiển thị Profit của chúng ($50 + 150 + 120 = 320$), hoặc nhầm cách tính khác cho ra 350.
- 600 (C): Cộng tất cả 5 sản phẩm ($200 + 150 + 120 + 80 + 50 = 600$) thay vì chỉ Top 3.
- 1800 (D): Tính Top 3 by Sales (Gamma 700 + Epsilon 600 + Alpha 500 = 1800), không dùng Profit. Đây là kết quả khi Parameter = "Sales".

Vì vậy đáp án đúng là **B (470)**.

5. (Mục đích chính của `Dashboard` trong Tableau.)

Dashboard là một thành phần quan trọng giúp tổng hợp nhiều biểu đồ để phục vụ việc phân tích dữ liệu.

A. Kết nối dữ liệu từ nhiều nguồn khác nhau.

B. Kết hợp nhiều worksheet vào cùng một màn hình để trực quan hóa dữ liệu tổng hợp.

C. Lưu trữ dữ liệu dưới dạng bảng.

D. Thay thế hoàn toàn worksheet.

Đáp án đúng: B

Giải thích chi tiết:

Trong Tableau, **Dashboard** được sử dụng để:

- Kết hợp nhiều `Worksheet` (biểu đồ, bảng, bản đồ) vào cùng một màn hình.
- Cho phép người dùng quan sát dữ liệu từ nhiều góc nhìn khác nhau trong cùng một không gian trực quan.
- Tạo các tương tác giữa các biểu đồ như filter, highlight hoặc parameter.

Các lựa chọn khác không đúng vì:

- Kết nối dữ liệu (A) là chức năng của phần **Data Source**.
- Dashboard không dùng để lưu dữ liệu dạng bảng (C).
- Dashboard không thay thế worksheet mà chỉ **kết hợp nhiều worksheet** lại (D).

Vì vậy đáp án đúng là **B**.

6. (Phân biệt `Tiled` và `Floating` layout trong Tableau Dashboard.)

Trong Tableau, các thành phần trong dashboard có thể được bố trí theo hai kiểu layout khác nhau.

A. Tiled cho phép đặt tự do các đối tượng, Floating tự động căn chỉnh.

B. Tiled tự động căn chỉnh theo bố cục lưới, Floating cho phép đặt đối tượng tự do.

C. Tiled chỉ dùng cho biểu đồ, Floating chỉ dùng cho filter.

D. Không có sự khác biệt giữa hai loại layout này.

Đáp án đúng: B

Giải thích chi tiết:

Hai loại layout chính trong Tableau Dashboard là:

- **Tiled layout**: các đối tượng được đặt theo dạng **lưới**, Tableau sẽ tự động căn chỉnh kích thước và vị trí để phù hợp với bố cục tổng thể.
- **Floating layout**: cho phép người dùng **đặt các đối tượng ở vị trí tùy ý** trên dashboard, có thể chồng lên nhau và điều chỉnh kích thước tự do.

Tiled giúp bố cục gọn gàng và dễ quản lý, trong khi Floating phù hợp cho các thiết kế cần linh hoạt hoặc chồng lớp các thành phần. Vì vậy đáp án đúng là **B**.

7. (Nguyên tắc sử dụng màu sắc hiệu quả trong thiết kế Dashboard.)

Màu sắc đóng vai trò quan trọng trong việc truyền đạt thông tin trong trực quan hóa dữ liệu.

A. Sử dụng càng nhiều màu càng tốt để tăng tính trực quan.

B. Chỉ sử dụng một màu duy nhất cho toàn bộ dashboard.

C. Sử dụng màu sắc để nhấn mạnh thông tin quan trọng và giữ sự nhất quán.

D. Sử dụng màu ngẫu nhiên để phân biệt các biểu đồ.

Đáp án đúng: C

Giải thích chi tiết:

Một nguyên tắc quan trọng trong thiết kế dashboard là **sử dụng màu sắc có chủ đích**. Cụ thể:

- Màu sắc nên được dùng để **nhấn mạnh thông tin quan trọng**.
- Giữ **sự nhất quán** trong toàn bộ dashboard để người xem dễ hiểu.
- Tránh dùng quá nhiều màu gây rối mắt hoặc làm giảm khả năng nhận diện thông tin chính.

Do đó:

- Dùng quá nhiều màu (A) hoặc màu ngẫu nhiên (D) sẽ làm dashboard khó đọc.
- Chỉ dùng một màu duy nhất (B) có thể làm giảm khả năng phân biệt dữ liệu.

Vì vậy lựa chọn hợp lý nhất là **C**.

8. (Chức năng của `Filter Action` trong Tableau.)

Tableau hỗ trợ nhiều loại tương tác giữa các biểu đồ trong dashboard.

A. Làm nổi bật các điểm dữ liệu liên quan giữa các biểu đồ.

B. Cho phép chuyển đổi giữa các dashboard khác nhau.

C. Cho phép một biểu đồ đóng vai trò bộ lọc cho các biểu đồ khác.

D. Thay đổi màu sắc của biểu đồ theo thời gian.

Đáp án đúng: C

Giải thích chi tiết:

Filter Action là một dạng tương tác trong Tableau cho phép:

- Người dùng chọn một giá trị hoặc một vùng dữ liệu trên một biểu đồ.
- Biểu đồ đó sẽ **lọc dữ liệu** của các biểu đồ khác trong dashboard.

Ví dụ: khi nhấp vào một `Region` trong biểu đồ doanh thu theo khu vực, các biểu đồ khác sẽ chỉ hiển thị dữ liệu liên quan đến khu vực đó.

Các lựa chọn khác không chính xác vì:

- (A) mô tả **Highlight Action**.
- (B) liên quan đến **Navigation Action**.
- (D) không phải chức năng của Filter Action.

Do đó đáp án đúng là **C**.

9. (Bài tập tổng hợp Parameter và Actions.)

Trong bài hướng dẫn, để dashboard có thể hiển thị đồng thời cả ba chỉ số Sales, Profit và Orders mà không cần tạo ba phiên bản dashboard riêng biệt, giải pháp được áp dụng là gì?

A. Tạo ba tab sheet riêng biệt, mỗi tab hiển thị một chỉ số.

B. Tạo một parameter `Selected Metric` và các calculated field kết nối với nó, cho phép toàn bộ biểu đồ chuyển đổi chỉ số chỉ bằng một thao tác chọn.

C. Dùng bộ lọc filter thông thường trên từng biểu đồ để ẩn/hiện chỉ số tương ứng.

D. Tạo ba measure riêng biệt và kéo cả ba vào cùng một biểu đồ để người xem tự so sánh.

Đáp án đúng: B

Giải thích chi tiết:

Parameter `Selected Metric` hoạt động như một công tắc trung tâm, kết hợp với Calculated Field để trả về đúng chỉ số tương ứng, giúp toàn bộ dashboard cập nhật đồng loạt chỉ bằng một thao tác chọn. Vì vậy đáp án đúng là **B**.

Các lựa chọn khác không đúng vì:

- Ba tab riêng biệt (A) buộc người dùng chuyển tab thủ công, không đáp ứng yêu cầu hiển thị linh hoạt trên cùng một dashboard.
- Filter thông thường (C) chỉ có khả năng lọc hàng dữ liệu, không thể hoán đổi giữa các measure độc lập như Sales, Profit hay Orders.
- Kéo cả ba measure vào cùng một biểu đồ (D) khiến biểu đồ mất cân đối do đơn vị và biên độ giá trị khác nhau hoàn toàn, gây khó đọc và không truyền tải được thông điệp rõ ràng.

Vì vậy đáp án đúng là **B**.

10. (Bài tập tổng hợp LOD Expression.)

Để tính điểm Recency Score cho mô hình RFM, công thức sử dụng `FIXED` như sau:

```
IF [Recency] >= { FIXED YEAR([Order Date]): PERCENTILE([Recency], 0.75)} THEN 1
...
```

Bạn muốn đơn giản hóa bằng cách bỏ `FIXED` đi. Điều gì sẽ xảy ra?

A. Công thức báo lỗi cú pháp vì `PERCENTILE` bắt buộc phải dùng kèm LOD expression.

B. Kết quả không đổi vì `PERCENTILE` luôn tính trên toàn bộ dataset bất kể có `FIXED` hay không.

C. Ngưỡng phân loại bị thay đổi mỗi khi người dùng áp dụng filter, khiến cùng một khách hàng có thể được xếp hạng khác nhau tùy theo bộ lọc đang chọn.

D. Công thức vẫn đúng nhưng chỉ khi dashboard không sử dụng bất kỳ filter nào.

Đáp án đúng: C

Giải thích chi tiết:

Khi bỏ `FIXED`, hàm `PERCENTILE` sẽ phụ thuộc vào ngữ cảnh view hiện tại và bị ảnh hưởng bởi filter, khiến ngưỡng phân loại thay đổi theo từng bộ lọc — cùng một khách hàng có thể nhận điểm khác nhau, vi phạm yêu cầu nhất quán của mô hình RFM.

Các lựa chọn khác không đúng vì:

- `PERCENTILE` là hàm hợp lệ trong Tableau, không bắt buộc phải dùng kèm LOD expression (A).
- Không có `FIXED`, kết quả hoàn toàn thay đổi theo filter, không thể cố định trên toàn bộ dataset (B).
- Dù hiện tại dashboard không dùng filter, rủi ro tính toán sai vẫn tồn tại ngay khi bất kỳ filter nào được thêm vào sau (D).

Vì vậy đáp án đúng là **C**.

AI VIET NAM COURSE 2026

Power BI & Data Visualization: Introduction to PowerBI

I. Giới thiệu

Hình 1: Logo PowerBI

Power BI là một nền tảng phân tích dữ liệu và trực quan hóa dữ liệu (*Business Intelligence*) được phát triển bởi *Microsoft*. Công cụ này cho phép người dùng kết nối với nhiều nguồn dữ liệu khác nhau, xử lý và mô hình hóa dữ liệu, sau đó xây dựng các báo cáo và dashboard tương tác phục vụ cho việc phân tích và ra quyết định.

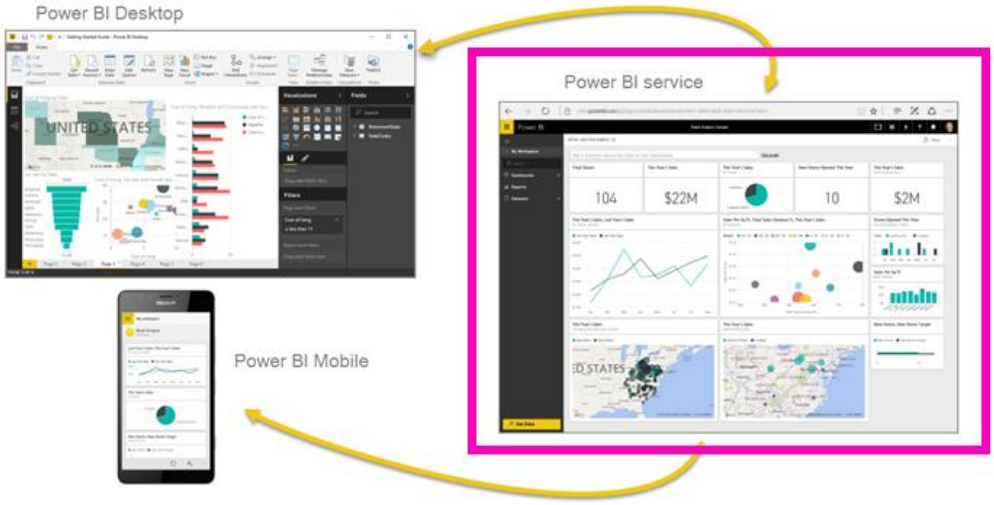

Hình 2: Power BI Server có giao diện tương tự với desktop, phiên bản web của nền tảng

II. Giới thiệu Power BI

Một trong những điểm mạnh của Power BI là khả năng tích hợp chặt chẽ với hệ sinh thái sản phẩm của Microsoft như Excel, Azure, SQL Server và Microsoft 365. Nhờ đó, Power BI thường được sử dụng rộng rãi trong các tổ chức để xây dựng hệ thống phân tích dữ liệu doanh nghiệp. Kiến trúc của Power BI bao gồm một tập hợp các thành phần cốt lõi hoạt động cùng nhau để chuyển đổi dữ liệu thô thành những thông tin kinh doanh có giá trị.

Các chức năng chính của Power BI

- Kết nối và thu thập dữ liệu từ nhiều nguồn khác nhau.
- Làm sạch và biến đổi dữ liệu bằng Power Query.
- Xây dựng mô hình dữ liệu và tạo các phép tính bằng DAX.
- Trực quan hóa dữ liệu thông qua các báo cáo và dashboard tương tác.
- Chia sẻ và cộng tác thông qua Power BI Service.

II.1. So sánh Power BI Desktop và Power BI Service

Trong hệ sinh thái Power BI, hai thành phần được sử dụng phổ biến nhất là **Power BI Desktop** và **Power BI Service**. Power BI Desktop chủ yếu được sử dụng để xây dựng báo cáo và mô hình dữ liệu, trong khi Power BI Service được sử dụng để xuất bản và chia sẻ các báo cáo đó.

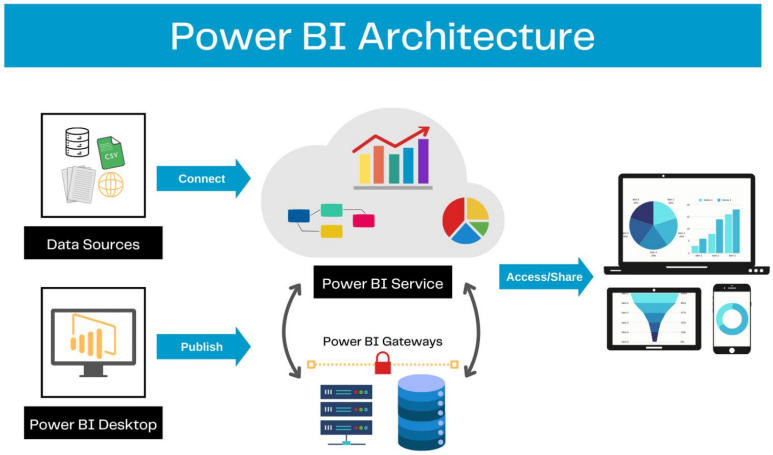

Hình 3: Power BI architecture

Tiêu chí	Power BI Desktop	Power BI Service
Nền tảng	Ứng dụng cài đặt trên máy tính.	Nền tảng chạy trên trình duyệt web (cloud).
Mục đích sử dụng	Tạo báo cáo, mô hình dữ liệu và trực quan hóa.	Xuất bản, chia sẻ và quản lý báo cáo.
Khả năng cộng tác	Làm việc cá nhân hoặc nhóm nhỏ.	Hỗ trợ chia sẻ dashboard và cộng tác trong tổ chức.
Cập nhật dữ liệu	Cập nhật thủ công hoặc theo lịch.	Có thể thiết lập tự động refresh dữ liệu.
Phân quyền truy cập	Không hỗ trợ quản lý quyền truy cập chi tiết.	Hỗ trợ quản lý người dùng và phân quyền truy cập.

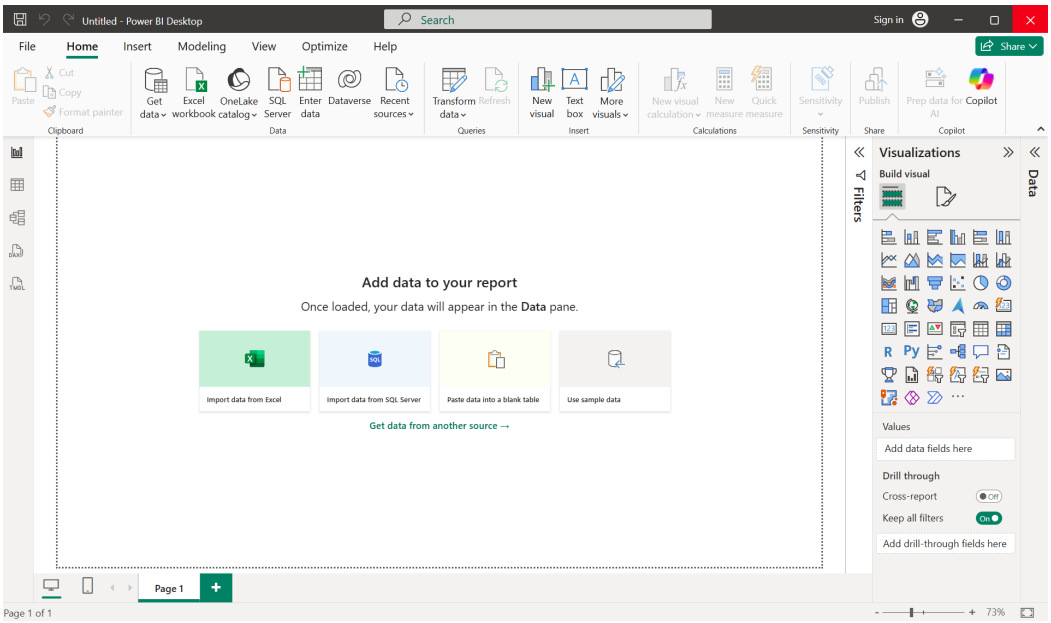

Hình 4: Giao diện chính của Power BI desktop

Khi nào nên dùng Desktop hoặc Service

- Sử dụng **Power BI Desktop** để xây dựng mô hình dữ liệu và thiết kế báo cáo.
- Sử dụng **Power BI Service** để xuất bản, chia sẻ và quản lý dashboard.
- Trong quy trình phân tích dữ liệu, Desktop thường được sử dụng trước, sau đó báo cáo sẽ được publish lên Service để chia sẻ trong tổ chức.

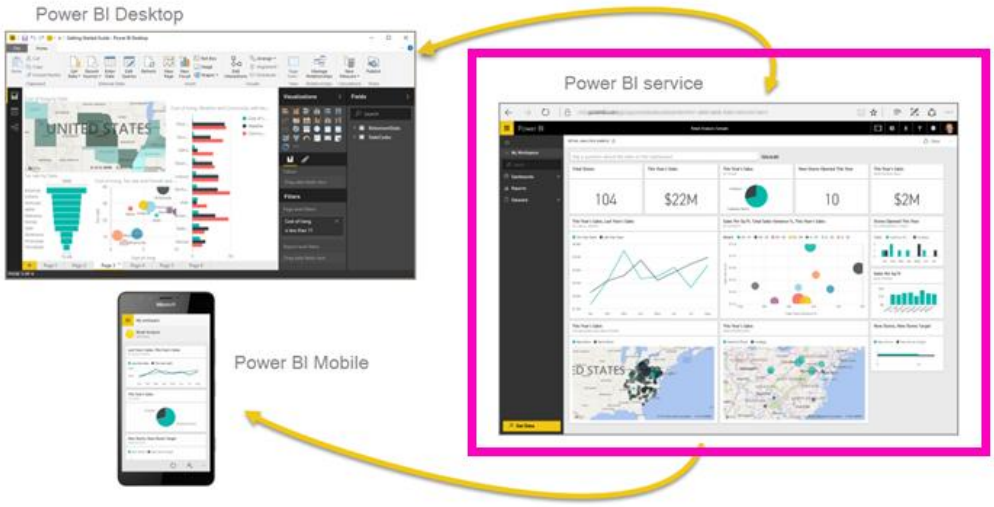

Hình 5: Power BI Server có giao diện tương tự với desktop, phiên bản web của nền tảng

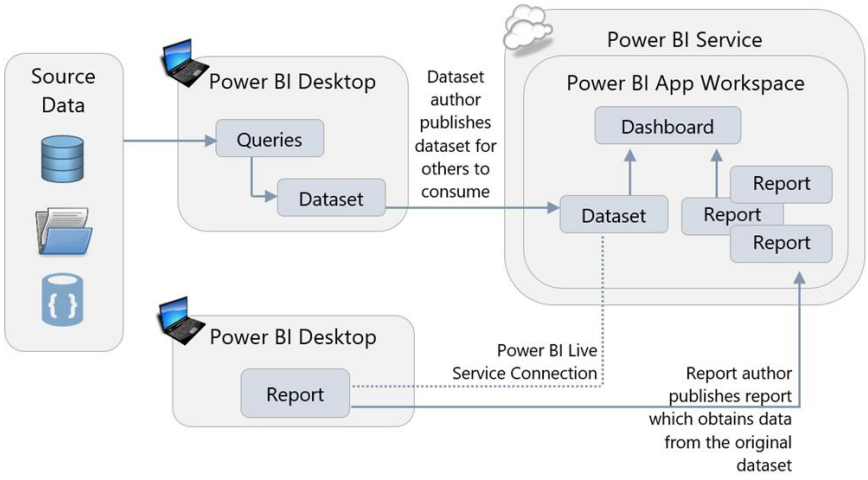

Hình 6: Quy trình sử dụng

Ngoài ra còn có **Power BI Mobile** đây là phiên bản dùng trên điện thoại di động thông minh có hỗ trợ cho cả hệ điều hành iOS, Android.
Power BI Gateway: Cầu nối giữa Power BI Service và các nguồn dữ liệu nội bộ (on-premises), giúp đồng bộ dữ liệu tự động mà không cần chuyển dữ liệu lên mây.

Power Query: Công cụ trích xuất, biến đổi và tải dữ liệu (ETL), tích hợp sẵn trong Power BI Desktop, cho phép làm sạch và chuẩn hóa dữ liệu từ nhiều nguồn khác nhau.

Power Pivot: Thành phần xử lý mô hình dữ liệu, giúp tạo mối quan hệ giữa các bảng và viết các phép tính phức tạp bằng DAX.

DAX (Data Analysis Expressions): Ngôn ngữ công thức dùng để tạo chỉ số tùy chỉnh, tính toán động và phân tích dữ liệu nâng cao trong Power BI, Power Pivot và SSAS.

Mục tiêu bài học

Sau buổi này, các nội dung sẽ được học như sau:

- Hiểu hệ sinh thái Power BI (Desktop vs Service)
- Làm quen giao diện Power BI
- Kết nối dữ liệu từ Excel
- Phân biệt Import và DirectQuery
- Phương pháp chọn biểu đồ phù hợp

III. Interface Navigation

III.1. Màn hình chào mừng

Khi mở trình duyệt Power BI Desktop, giao diện sẽ hiển thị Welcome screen. Từ màn hình Welcom bước vào ta có thể thực hiện **Get data**, xem những nguồn gần đây đã kết nối và những báo cáo cũ gần đây hoặc chọn báo cáo khác thiết bị.

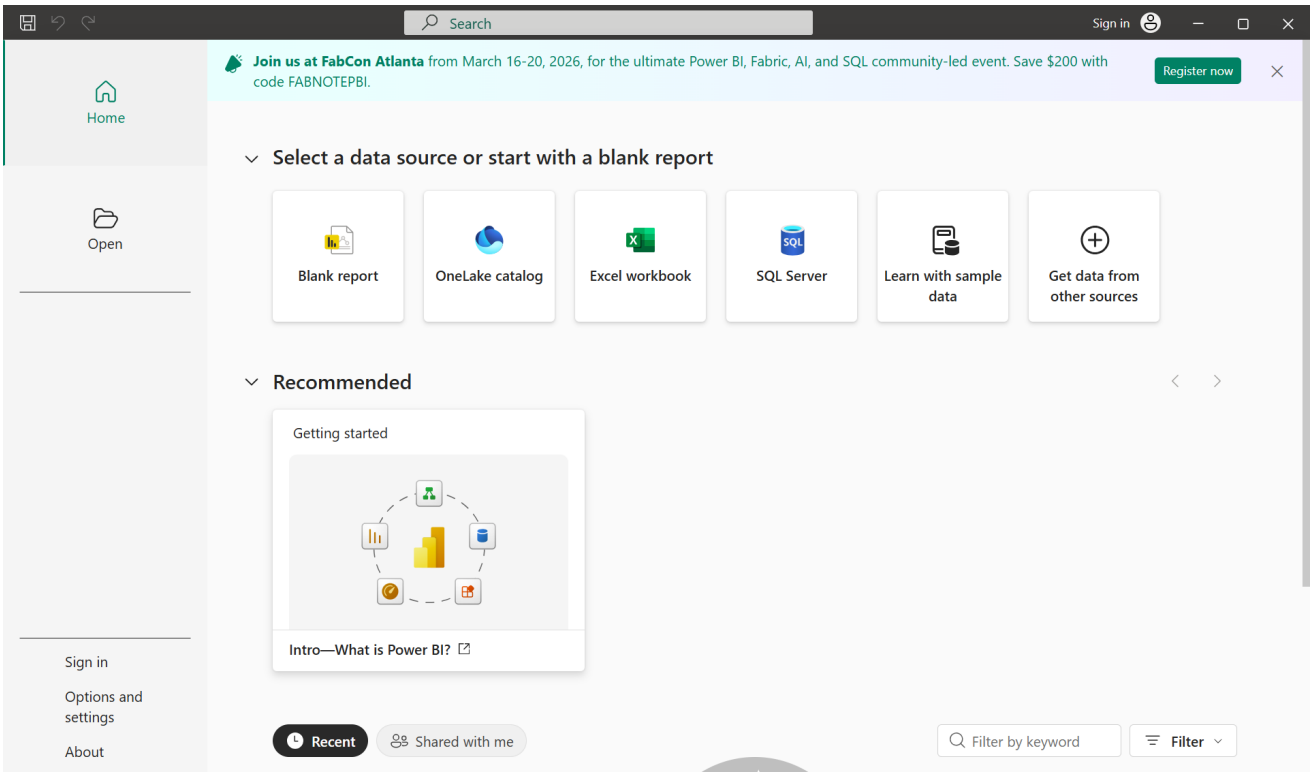

Hình 7: Giao diện Welcome Home

Khi mở Power BI Desktop, người dùng sẽ làm việc với ba chế độ chính (*views*). Mỗi view phục vụ một mục đích khác nhau trong quá trình phân tích và xây dựng báo cáo. Việc hiểu rõ vai trò

của từng view giúp người dùng dễ dàng quản lý dữ liệu, thiết kế báo cáo và xây dựng mô hình dữ liệu hiệu quả.

III.2. Power BI User Interface Ribbon

Thanh Ribbon trong Power BI là một yếu tố quan trọng của giao diện người dùng, cung cấp một bộ công cụ và lệnh tập trung được sắp xếp thành các tab và nhóm. Ribbon cho phép truy cập nhanh vào nhiều tính năng và tùy chọn khác nhau như nhập dữ liệu (*Get Data*), biến đổi dữ liệu (*Transform Data*), quản lý mô hình dữ liệu và thiết lập các tùy chọn báo cáo.

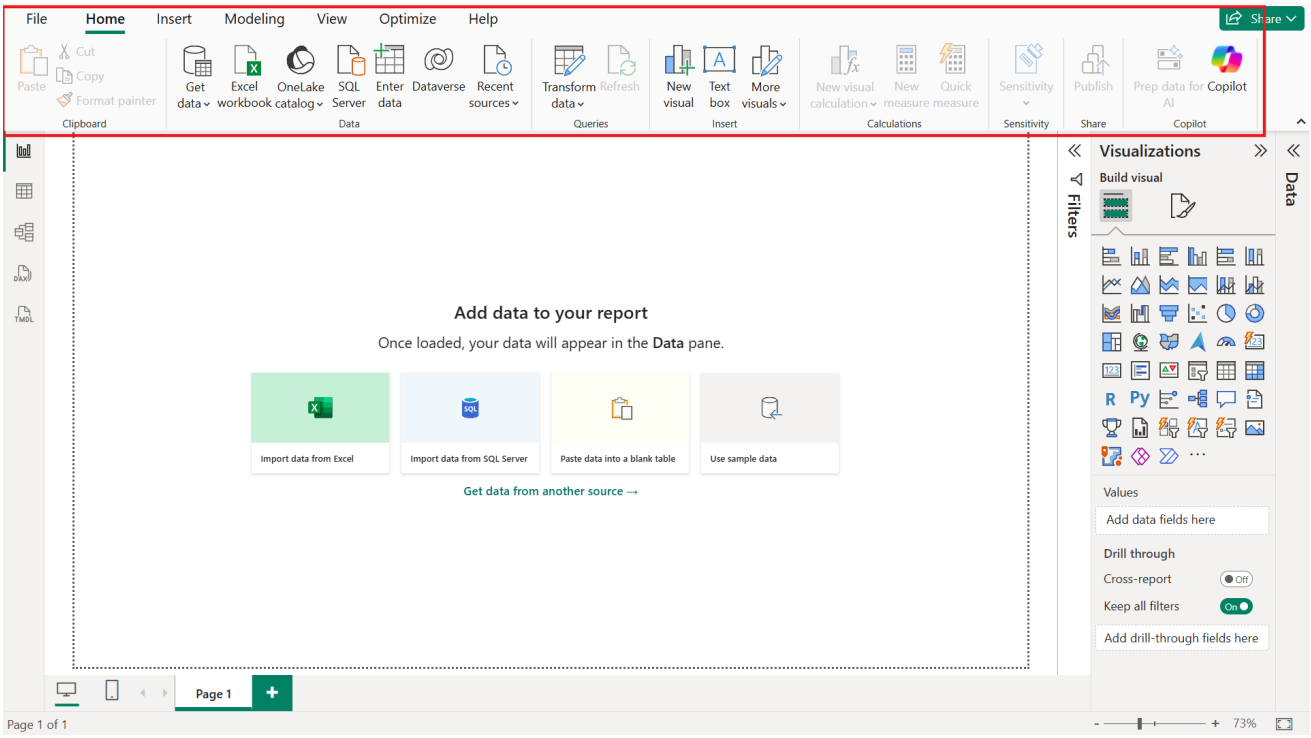

Hình 8: Giao diện thanh Ribbon của Power BI

Report Canvas: đây là khu vực trung tâm của giao diện, nơi mà người dùng sẽ thiết kế dashboard và các biểu đồ bằng cách kéo thả dữ liệu và visual.

III.3. Các tab chính trên thanh Ribbon

1. **Home**: Tab Home chứa các lệnh cơ bản để quản lý báo cáo và dữ liệu như mở, lưu báo cáo, hoàn tác (*Undo*) và làm lại (*Redo*). Ngoài ra, người dùng có thể kết nối nguồn dữ liệu, làm mới dữ liệu và truy cập *Power Query Editor* để xử lý dữ liệu.

2. **Insert**: Tab Insert cho phép thêm các thành phần vào báo cáo như biểu đồ, bảng, ma trận, thẻ (*card*), hình ảnh và hình dạng. Người dùng cũng có thể chèn hộp văn bản, nút và các yếu tố tương tác để tăng tính trực quan của báo cáo.

3. **Modeling**: Tab Modeling cung cấp các công cụ để xây dựng mô hình dữ liệu. Người dùng

có thể tạo *calculated columns*, *measures*, thiết lập quan hệ giữa các bảng và xây dựng cấu trúc phân cấp dữ liệu.

4. **View**: Tab View cho phép tùy chỉnh cách hiển thị của báo cáo như phóng to, thu nhỏ, bật hoặc tắt đường lưới, tiêu đề và nền. Tab này cũng hỗ trợ chuyển đổi giữa các chế độ xem trong Power BI.

5. **Optimize**: Tab Optimize cung cấp các công cụ tối ưu hóa hiệu suất báo cáo, bao gồm tạm dừng hoặc làm mới các hình trực quan, theo dõi hiệu suất bằng *Performance Analyzer* và quản lý bộ lọc.

6. **Help**: Tab Help cung cấp các tài liệu hướng dẫn, liên kết đến cộng đồng Power BI và các nguồn hỗ trợ để giúp người dùng tìm hiểu và sử dụng Power BI hiệu quả.

III.4. Navigation Pane

Navigation Pane: nằm ở phía bên trái của giao diện, cho phép chuyển đổi giữa ba chế độ làm việc chính:

View	Vai trò	Khi sử dụng
Report View	Cho phép thiết kế các biểu đồ và xây dựng báo cáo trực quan trên canvas bằng cách kéo thả các trường dữ liệu.	Khi tạo dashboard, thiết kế visual hoặc xây dựng báo cáo.
Data View	Hiển thị dữ liệu dưới dạng bảng để kiểm tra các cột và giá trị của dataset đã được nhập.	Khi cần kiểm tra dữ liệu hoặc xác nhận các giá trị trong bảng.
Model View	Hiển thị cấu trúc mô hình dữ liệu dưới dạng sơ đồ gồm các bảng và các mối quan hệ giữa chúng.	Khi xây dựng hoặc chỉnh sửa các relationship giữa các bảng.

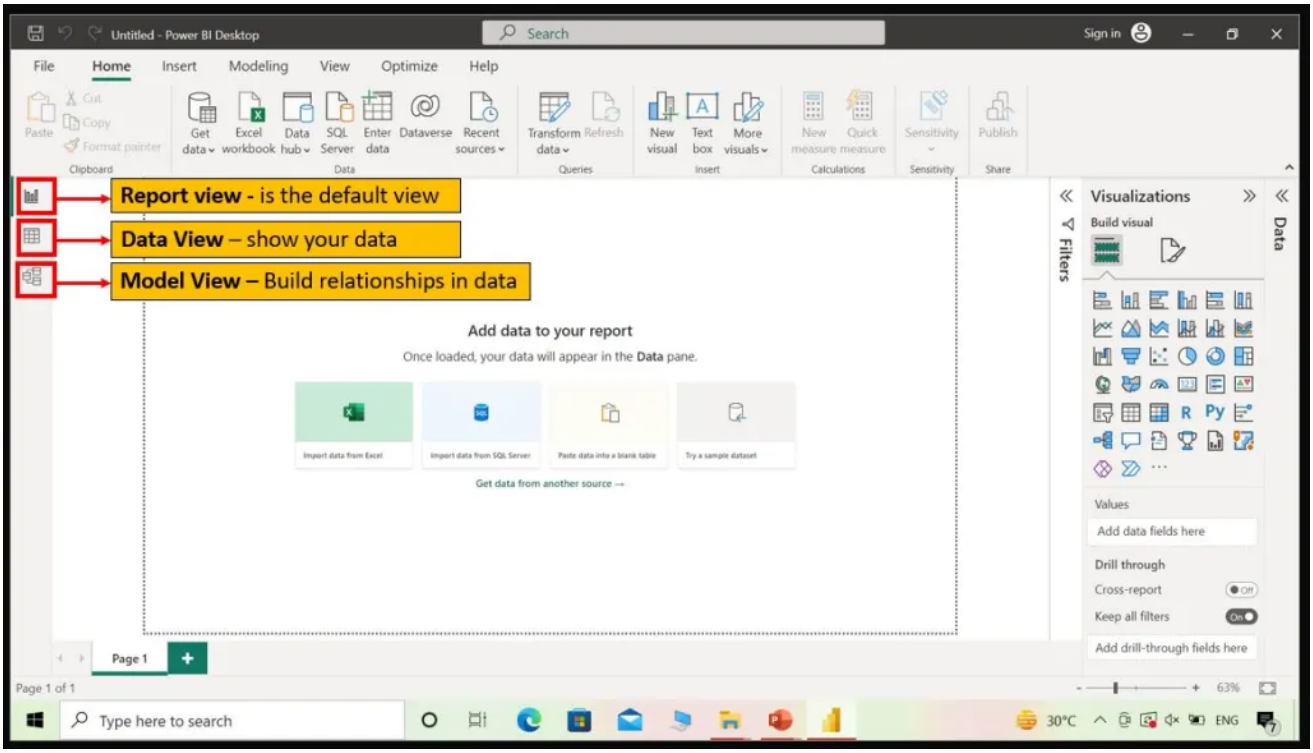

Hình 9: Giao diện thanh Navigation Pane

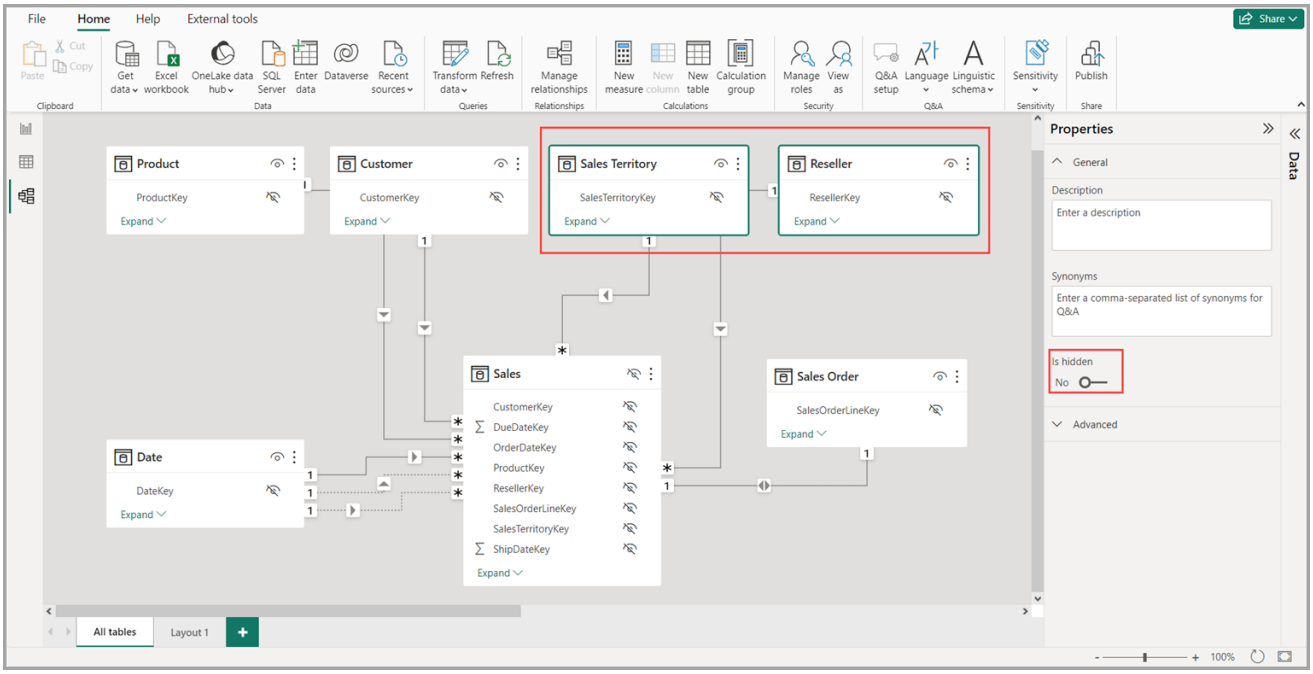

Hình 10: Giao diện thanh Modeling view

III.5. Data Pane, Visualiszation Pane và Filters pane

III.5.1. Data Pane:

Ngăn Dữ liệu nằm ở phía bên phải của khung nhìn báo cáo, bên dưới ngăn Trực quan hóa. Giao diện hiển thị các trường (cột) từ tập dữ liệu. Ở đây ta có thể kéo và thả các trường vào các hình ảnh trực quan, tạo mối quan hệ giữa các bảng và xác định các phép đo và cột được tính toán hoặc sử dụng chúng để tạo bộ lọc và bộ chọn. Trong các phiên bản cũ hơn, ngăn dữ liệu cũng được gọi là ngăn trường.

III.5.2. Visualiszation Pane:

Ngăn **Visualiszation Pane** hiển thị dữ liệu nằm ở phía bên phải của khung nhìn báo cáo. Giao diện cung cấp danh sách các loại hình trực quan có sẵn, chẳng hạn như biểu đồ cột, biểu đồ đường và bản đồ. Từ đây ta có thể kéo và thả các trường từ tập dữ liệu của mình vào các hình trực quan để điền dữ liệu vào đó.

III.5.3. Filter Pane:

Power BI cho chúng ta áp dụng bộ lọc cho các hình ảnh trực quan, giới hạn dữ liệu hiển thị dựa trên các tiêu chí cụ thể. Bộ lọc có thể được áp dụng cho từng hình ảnh trực quan riêng lẻ hoặc được sử dụng chung cho toàn bộ báo cáo. Bộ lọc dạng lát cắt (slicer) là các phần tử trực quan cho phép người dùng lọc dữ liệu một cách tương tác bằng cách chọn các giá trị từ một danh sách.

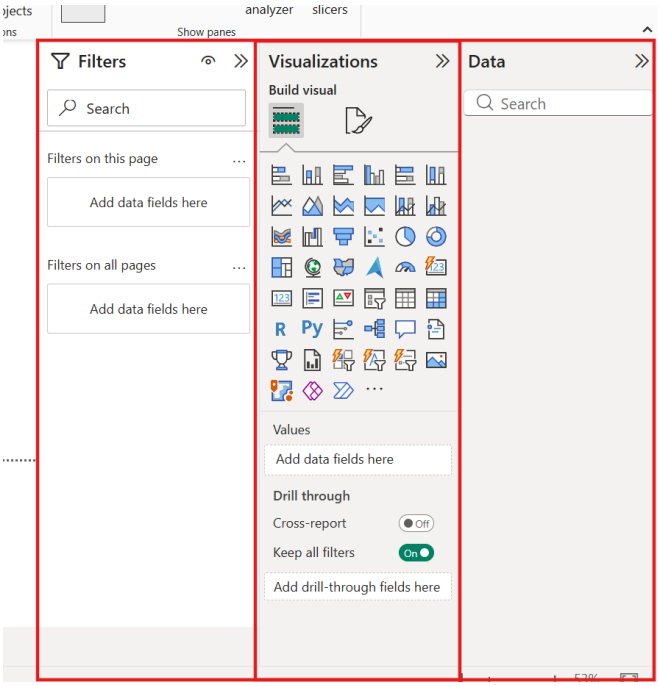

Hình 11: Giao diện thanh Data Pane, Visualiszation Pane và Filters pane

IV. Data Integration

Một trong những chức năng quan trọng của Power BI là khả năng kết nối và tích hợp dữ liệu từ nhiều nguồn khác nhau. Power BI hỗ trợ kết nối với nhiều loại dữ liệu như cơ sở dữ liệu quan hệ, dịch vụ đám mây, API hoặc các tệp dữ liệu phổ biến như Excel và CSV.

Trong các tổ chức, Excel vẫn là nguồn dữ liệu phổ biến nhất. Do đó, việc kết nối và nhập dữ liệu từ Excel vào Power BI là bước đầu tiên trong nhiều quy trình phân tích dữ liệu.

Phương thức	Mô tả
Import Data	Dữ liệu từ Excel được nhập trực tiếp vào Power BI và lưu trữ trong mô hình dữ liệu của báo cáo.
Power Query Transformation	Dữ liệu được làm sạch và biến đổi trước khi được tải vào mô hình dữ liệu thông qua Power Query Editor.
Data Refresh	Power BI có thể cập nhật lại dữ liệu từ tệp Excel khi dữ liệu nguồn thay đổi.

Kết nối dữ liệu từ Excel

Để nhập dữ liệu từ Excel vào Power BI Desktop, người dùng có thể thực hiện các bước sau:

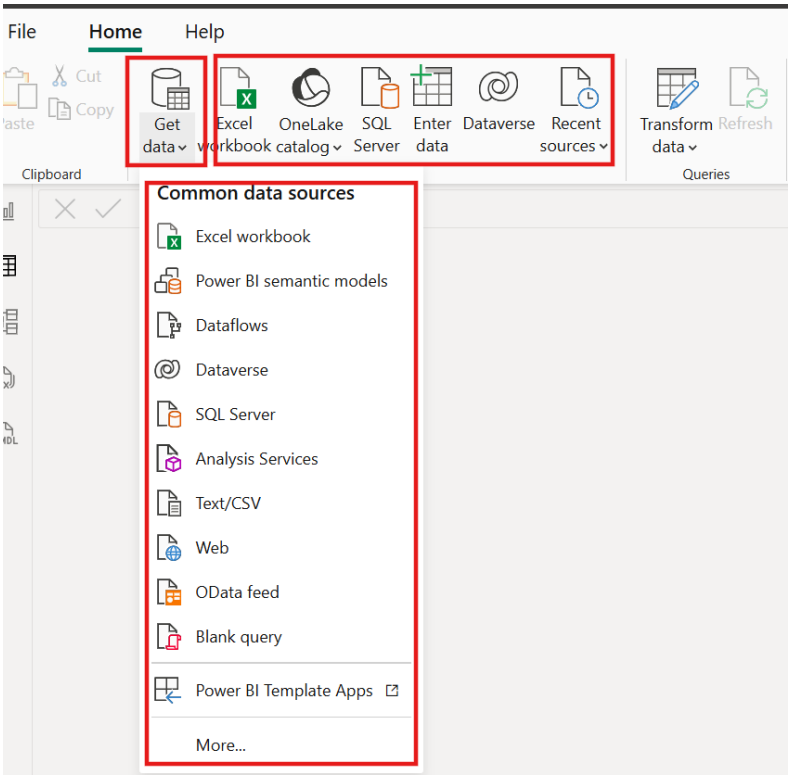

Hình 12: Chọn **Home** → **Get Data**

1. Chọn nguồn dữ liệu **Excel Workbook**.
2. Chọn tệp Excel cần nhập.
3. Trong cửa sổ **Navigator**, chọn các bảng hoặc worksheet cần sử dụng.
4. Chọn **Load** để nhập dữ liệu trực tiếp hoặc **Transform Data** để mở Power Query Editor và biến đổi dữ liệu.

Làm việc với Power Query

Power Query là công cụ được tích hợp trong Power BI cho phép thực hiện các bước xử lý dữ liệu trước khi dữ liệu được tải vào mô hình dữ liệu. Người dùng có thể thực hiện các thao tác như:

- Xóa các cột không cần thiết.
- Đổi tên cột dữ liệu.
- Chuyển đổi kiểu dữ liệu.
- Lọc các giá trị dữ liệu.
- Kết hợp dữ liệu từ nhiều bảng khác nhau.

Best Practices khi nhập dữ liệu từ Excel

- Đảm bảo dữ liệu Excel được tổ chức dưới dạng bảng (*Table*).
- Tránh các dòng trống hoặc tiêu đề không nhất quán.
- Kiểm tra kiểu dữ liệu trước khi tải vào mô hình dữ liệu.
- Sử dụng Power Query để làm sạch dữ liệu trước khi tạo báo cáo.

IV.1. Connection Methodologies

Khi kết nối dữ liệu vào Power BI, người dùng có thể lựa chọn nhiều phương thức kết nối khác nhau. Hai phương thức phổ biến nhất là **Import** và **DirectQuery**. Tuy nhiên, ngoài hai phương thức này, Power BI còn hỗ trợ các mô hình kết nối nâng cao như **Live Connection**, **Composite Model** và **Streaming Dataset**.

Việc lựa chọn phương thức kết nối phù hợp có ảnh hưởng trực tiếp đến hiệu năng, khả năng cập nhật dữ liệu và cách xây dựng báo cáo trong Power BI.

Các phương thức kết nối dữ liệu trong Power BI

- **Import**: dữ liệu được tải vào Power BI và lưu trữ trong mô hình dữ liệu.
- **DirectQuery**: Power BI truy vấn trực tiếp dữ liệu từ nguồn dữ liệu khi cần.
- **Live Connection**: kết nối trực tiếp tới mô hình dữ liệu có sẵn (Analysis Services).
- **Composite Model**: kết hợp Import và DirectQuery trong cùng một mô hình.
- **Streaming Dataset**: dữ liệu được cập nhật theo thời gian thực.

Tiêu chí	Import Mode	DirectQuery Mode
Cách lưu trữ dữ liệu	Dữ liệu được tải và lưu trong bộ nhớ của Power BI.	Dữ liệu vẫn nằm ở nguồn dữ liệu gốc.
Tốc độ truy vấn	Nhanh hơn vì dữ liệu đã được lưu trong mô hình dữ liệu.	Phụ thuộc vào hiệu năng của nguồn dữ liệu.
Cập nhật dữ liệu	Dữ liệu cần được làm mới (*refresh*) để cập nhật thay đổi.	Luôn truy vấn dữ liệu mới nhất từ nguồn dữ liệu.
Khả năng xử lý dữ liệu	Hỗ trợ đầy đủ các tính năng DAX và mô hình dữ liệu.	Một số tính năng DAX và mô hình có thể bị hạn chế.
Khối lượng dữ liệu	Phù hợp với dữ liệu vừa và nhỏ.	Phù hợp với dữ liệu rất lớn hoặc dữ liệu cần truy cập thời gian thực.

Import Mode

Trong chế độ Import, dữ liệu từ nguồn dữ liệu sẽ được tải trực tiếp vào Power BI và lưu trữ trong mô hình dữ liệu của báo cáo. Nhờ đó, các truy vấn và biểu đồ có thể được xử lý nhanh chóng do dữ liệu đã nằm trong bộ nhớ.

Tuy nhiên, dữ liệu trong chế độ Import không tự động cập nhật. Để đồng bộ dữ liệu với nguồn dữ liệu gốc, người dùng cần thực hiện quá trình *data refresh* theo lịch hoặc thủ công.

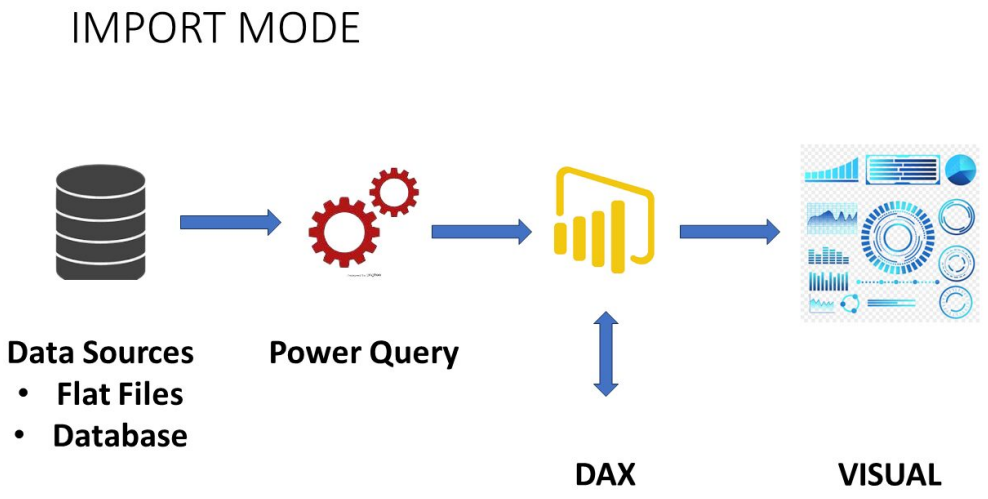

Hình 13: Sơ đồ minh hoạ của chế độ Import

DirectQuery Mode

Trong chế độ DirectQuery, Power BI không lưu trữ dữ liệu trong mô hình dữ liệu. Thay vào đó, mỗi khi người dùng tương tác với dashboard hoặc báo cáo, Power BI sẽ gửi truy vấn trực tiếp

đến nguồn dữ liệu gốc.

Cách tiếp cận này cho phép truy cập dữ liệu gần như theo thời gian thực và đặc biệt hữu ích khi làm việc với các bộ dữ liệu rất lớn.

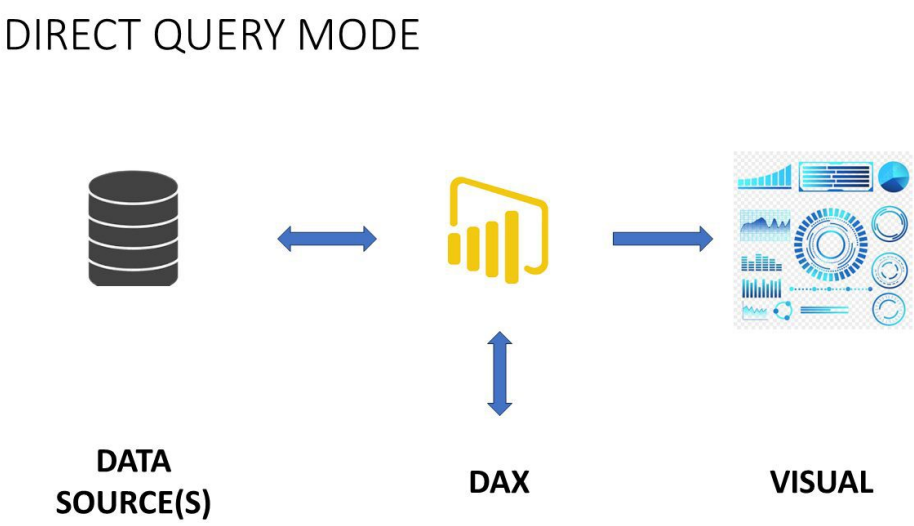

Hình 14: Sơ đồ minh hoạ của chế độ DirectQuery

Live Connection

Live Connection cho phép Power BI kết nối trực tiếp tới các mô hình dữ liệu đã được xây dựng sẵn như SQL Server Analysis Services hoặc Azure Analysis Services. Trong trường hợp này, Power BI chỉ đóng vai trò là công cụ trực quan hóa và không lưu trữ dữ liệu.

Phương thức này giúp đảm bảo tính nhất quán dữ liệu và phù hợp với các hệ thống BI doanh nghiệp đã có sẵn mô hình dữ liệu trung tâm.

Composite Model

Composite Model là sự kết hợp giữa Import và DirectQuery trong cùng một báo cáo. Người dùng có thể lưu trữ một phần dữ liệu trong Power BI (Import) và truy vấn trực tiếp phần còn lại (DirectQuery).

Phương pháp này giúp tối ưu hiệu năng và linh hoạt trong việc xử lý các tập dữ liệu lớn hoặc dữ liệu thay đổi thường xuyên.

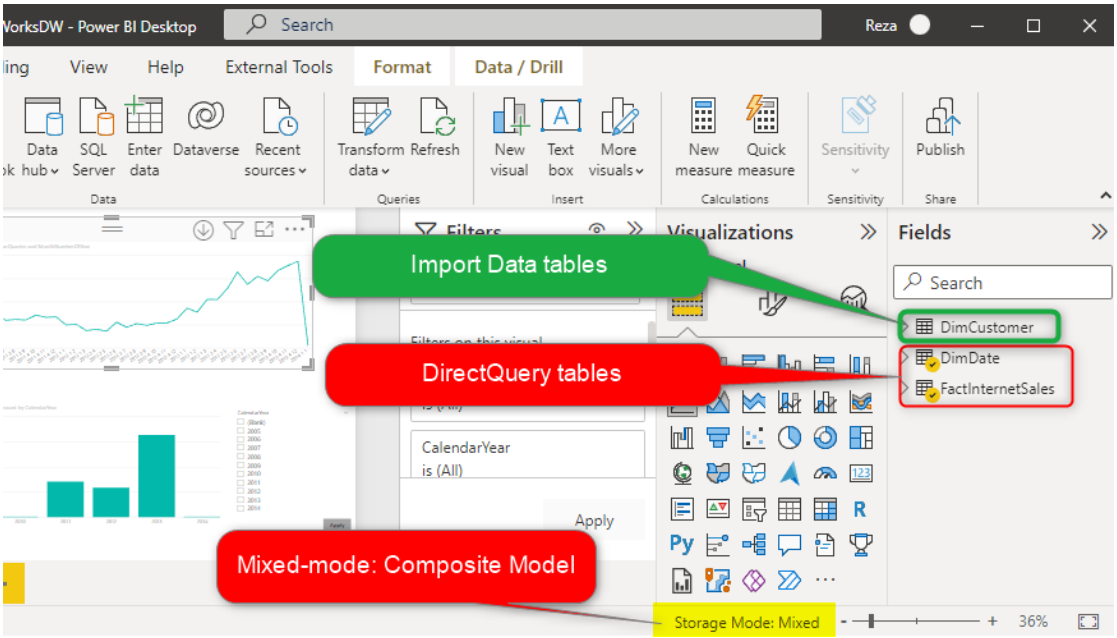

Hình 15: Composite Model

Streaming Dataset

Streaming Dataset cho phép dữ liệu được gửi liên tục vào Power BI theo thời gian thực thông qua API hoặc các dịch vụ streaming. Dữ liệu được cập nhật ngay lập tức trên dashboard mà không cần thực hiện refresh.

Phương thức này thường được sử dụng trong các hệ thống giám sát thời gian thực như IoT, hệ thống theo dõi giao dịch hoặc phân tích sự kiện.

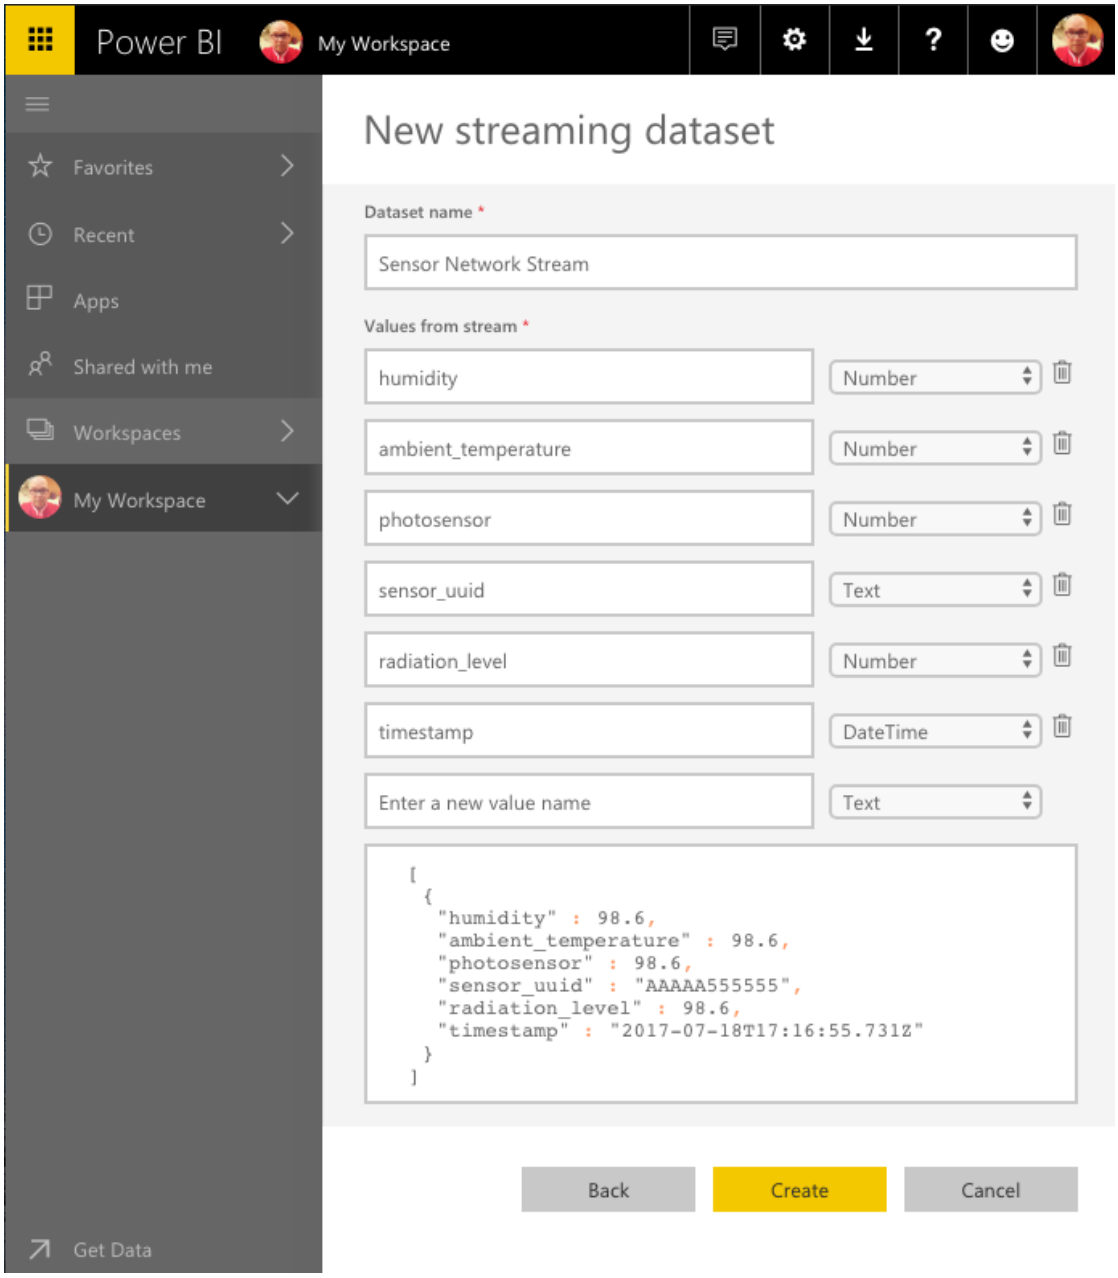

Hình 16: Streaming Dataset

IV.2. Data Refresh and Incremental Refresh

Sau khi dữ liệu được nạp vào Power BI, việc đảm bảo dữ liệu luôn được cập nhật là một yếu tố quan trọng trong quá trình phân tích. Power BI cung cấp nhiều cơ chế làm mới dữ liệu (*data refresh*) nhằm đồng bộ dữ liệu giữa báo cáo và nguồn dữ liệu gốc.

Data Refresh

Data Refresh là quá trình cập nhật dữ liệu trong Power BI từ nguồn dữ liệu ban đầu. Tùy thuộc vào phương thức kết nối, cách thức làm mới dữ liệu sẽ khác nhau:

- **Import Mode**: dữ liệu cần được làm mới thông qua thao tác thủ công hoặc thiết lập lịch làm mới (*scheduled refresh*).
- **DirectQuery**: dữ liệu luôn được truy vấn trực tiếp từ nguồn, do đó không cần thực hiện refresh theo nghĩa truyền thống.
- **Live Connection**: dữ liệu được cập nhật tự động từ mô hình dữ liệu nguồn.

Power BI hỗ trợ hai hình thức làm mới chính:

- **Manual Refresh**: người dùng chủ động làm mới dữ liệu trong Power BI Desktop.
- **Scheduled Refresh**: thiết lập lịch tự động làm mới dữ liệu trong Power BI Service.

Việc lựa chọn tần suất refresh cần cân bằng giữa yêu cầu cập nhật dữ liệu và hiệu năng hệ thống, đặc biệt khi làm việc với các nguồn dữ liệu lớn.

Incremental Refresh

Incremental Refresh là kỹ thuật tối ưu hóa quá trình làm mới dữ liệu bằng cách chỉ cập nhật phần dữ liệu mới hoặc đã thay đổi, thay vì tải lại toàn bộ dữ liệu.

Cơ chế này đặc biệt hữu ích khi làm việc với các tập dữ liệu lớn, giúp giảm thời gian xử lý và tiết kiệm tài nguyên hệ thống.

Nguyên lý hoạt động của Incremental Refresh bao gồm:

- Chia dữ liệu thành các phân vùng (*partitions*) theo thời gian (ví dụ: theo ngày, tháng hoặc năm).
- Chỉ làm mới các phân vùng chứa dữ liệu mới hoặc dữ liệu vừa thay đổi.
- Giữ nguyên các phân vùng dữ liệu cũ không thay đổi.

Để sử dụng Incremental Refresh trong Power BI, người dùng cần:

- Xác định cột thời gian (date/time column) trong dữ liệu.
- Thiết lập các tham số `RangeStart` và `RangeEnd`.
- Cấu hình chính sách refresh trong Power BI Service.

Nhờ đó, hệ thống có thể xử lý dữ liệu hiệu quả hơn, đặc biệt trong các hệ thống phân tích dữ liệu lớn hoặc dữ liệu lịch sử dài hạn.

IV.3. Visualization Selection trong Power BI

Trong Power BI, việc lựa chọn biểu đồ không chỉ phụ thuộc vào dữ liệu mà còn phụ thuộc vào mục tiêu truyền tải thông tin (*narrative intent*). Các nguyên tắc lựa chọn biểu đồ tương tự như trong Tableau, tuy nhiên cách triển khai sẽ thông qua **Visualization Pane** thay vì Rows/Columns.

Nguyên tắc chọn biểu đồ

- Xác định loại dữ liệu: phân loại (categorical), thời gian (temporal) hay địa lý (geographical).
- Xác định câu hỏi phân tích: so sánh, xu hướng hay phân bố.
- Chọn biểu đồ phù hợp để truyền tải thông tin một cách rõ ràng và trực quan.

Bar Chart

Bar Chart được sử dụng khi cần so sánh giá trị giữa các danh mục khác nhau. Trong Power BI, biểu đồ này thường được tạo bằng cách kéo trường dữ liệu vào **Axis** và **Values** trong Visualization Pane.

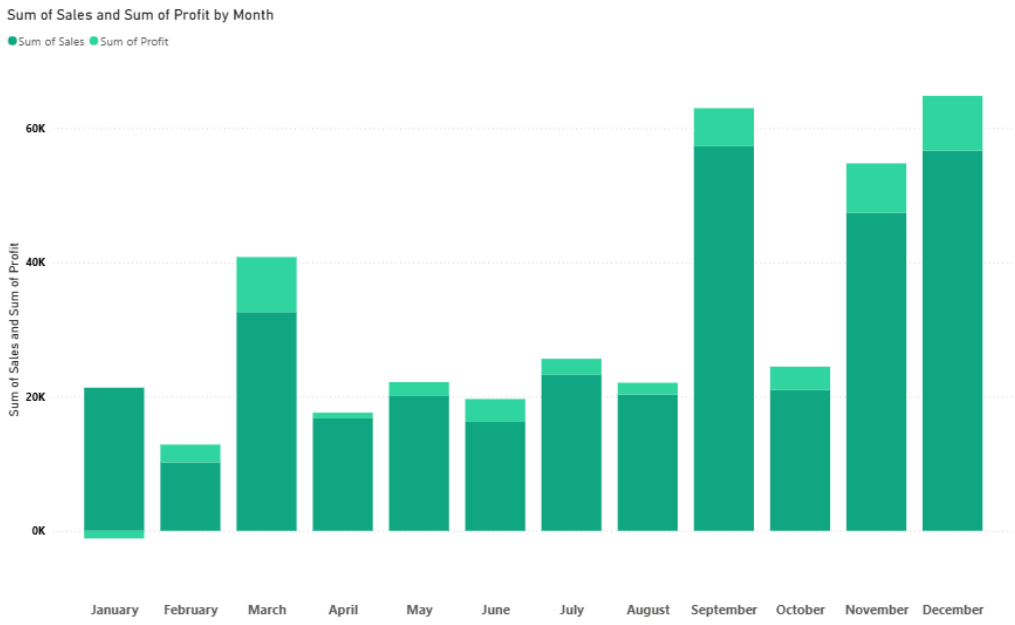

Hình 17: Bar Chart trong Power BI

Khi sử dụng Bar Chart

- So sánh doanh thu giữa các Category hoặc Region
- Xếp hạng các nhóm dữ liệu
- Số lượng danh mục không quá lớn để đảm bảo dễ đọc

Line Chart

Line Chart phù hợp để thể hiện sự thay đổi của dữ liệu theo thời gian. Power BI hỗ trợ tự động xử lý các trường thời gian (date hierarchy), giúp người dùng dễ dàng drill-down từ năm xuống tháng hoặc ngày.

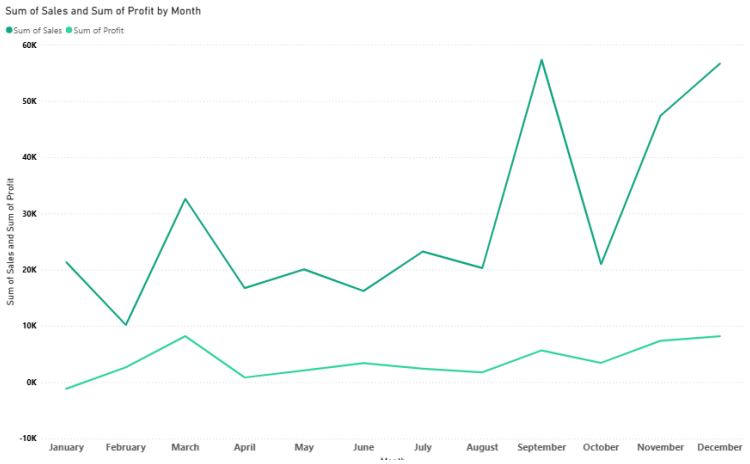

Hình 18: Line Chart trong Power BI

Khi sử dụng Line Chart

- Phân tích xu hướng doanh thu theo thời gian
- Theo dõi tăng trưởng hoặc biến động
- Dữ liệu có thứ tự liên tục (time series)

Map

Khi dữ liệu có yếu tố vị trí như quốc gia, thành phố hoặc khu vực, biểu đồ Map giúp trực quan hóa phân bố không gian của dữ liệu. Power BI hỗ trợ nhiều loại bản đồ và có khả năng tự động nhận diện trường địa lý.

Hình 19: Map Chart trong Power BI

Khi sử dụng Map

- Hiển thị doanh thu theo khu vực hoặc quốc gia
- Phân tích sự phân bố dữ liệu theo địa lý
- So sánh hiệu suất giữa các vùng

Lưu ý

Việc lựa chọn biểu đồ phù hợp giúp tăng khả năng hiểu dữ liệu và tránh gây hiểu nhầm. Trong Power BI, người dùng có thể nhanh chóng thử nghiệm nhiều loại biểu đồ khác nhau bằng cách thay đổi trực tiếp trong Visualization Pane.

V. Tổng kết

Sau khi làm quen với các loại biểu đồ trong Power BI, chúng ta có thể rút gọn quy trình lựa chọn visualization thành một flow đơn giản: dựa vào **kiểu dữ liệu** và **mục tiêu phân tích** để quyết định loại biểu đồ phù hợp.

Loại biểu đồ	Câu hỏi trả lời	Field chính	Cấu hình trong Power BI
Bar Chart	Cái nào lớn hơn/nhỏ hơn?	Category + Measure	X Axis + Y axis
Line Chart	Xu hướng thay đổi thế nào?	Date + Measure	Axis (Date) + Y axis
Area Chart	Khối lượng theo thời gian?	Date + Measure	Axis + Y axis
Scatter Plot	Hai chỉ số liên quan thế nào?	2 Measures	X axis + Y axis
Histogram	Dữ liệu phân bố thế nào?	Continuous variable	Binning + Count
Table	Cần giá trị chính xác?	Dimension + Measure	Table visual
Map	Vùng nào nổi bật?	Geographic field	Location + Size/Color

Bộ câu hỏi quyết định nhanh:

1. Dữ liệu có **địa lý** không? → **Map**
2. Có **thời gian** không?
   - Muốn xem xu hướng → **Line Chart**
   - Muốn xem khối lượng → **Area Chart**
3. Có **2 chỉ số số học** không? → **Scatter Plot**
4. Cần xem **phân phối** không? → **Histogram (binning)**
5. Cần **giá trị chính xác** không? → **Table / Card**
6. Nếu mục tiêu là so sánh giữa các nhóm → **Bar Chart**

Lưu ý

Cạm bẫy phổ biến: dùng Line Chart cho dữ liệu phân loại. Trong Power BI, người dùng có thể kéo `Category` vào trục X của Line Chart, nhưng điều này không có nhiều ý nghĩa phân

tích vì các category không có thứ tự liên tục. Trong trường hợp này, Bar Chart thường là lựa chọn phù hợp hơn.

VI. Thực hành: Xây dựng dashboard với Power BI

Mục tiêu bài thực hành

Sau bài này, học viên có thể:

- Import dữ liệu từ file CSV vào Power BI
- Tạo các biểu đồ cơ bản bằng cách kéo-thả
- Hiểu cách Power BI tự động tính toán (SUM, COUNT)
- Sử dụng slicer để lọc dữ liệu
- Xây dựng một dashboard đơn giản

VI.1. Bước 1: Import dữ liệu

Mở Power BI Desktop và thực hiện:

- Chọn **Home** → **Get Data** → **Text/CSV**

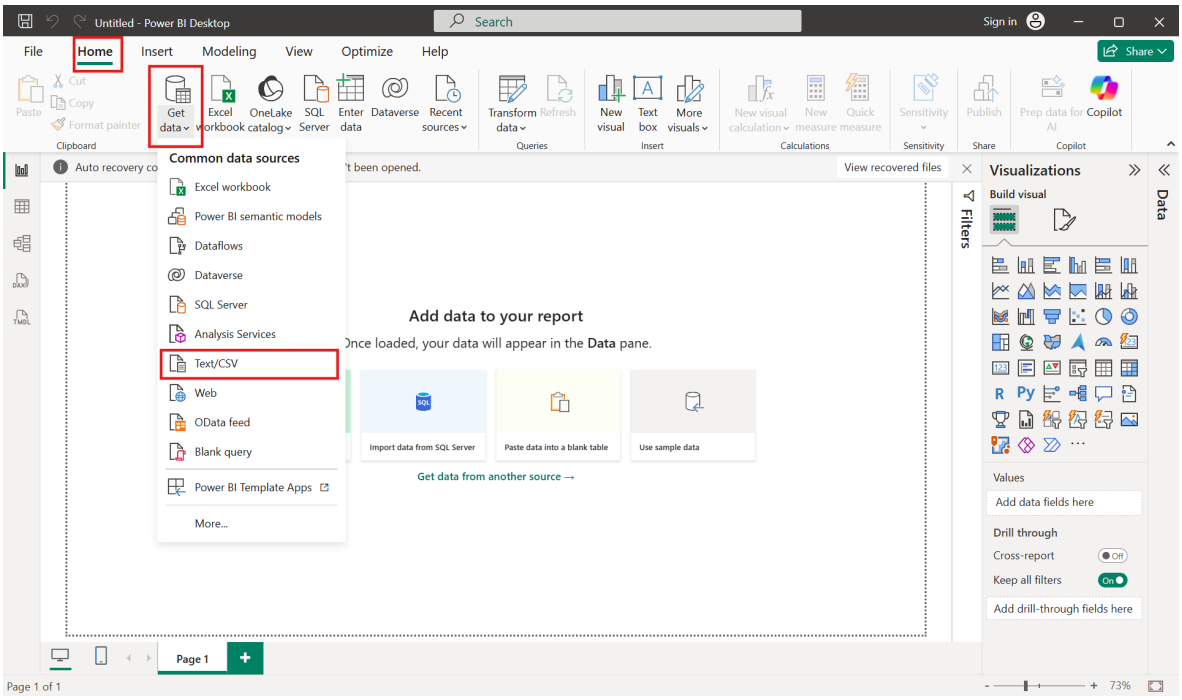

Hình 20: Import dữ liệu từ file CSV vào Power BI

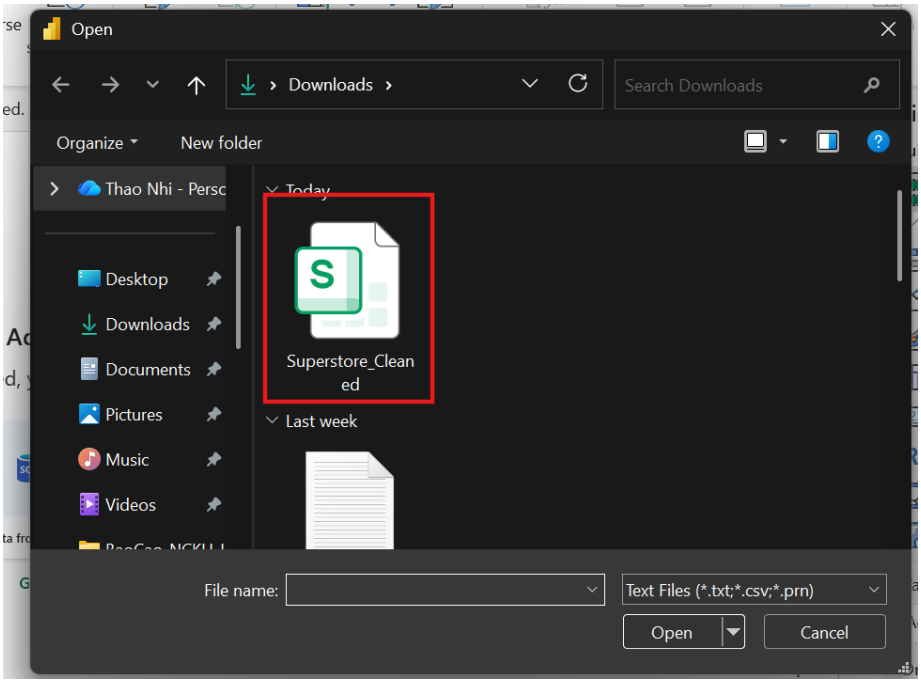

Hình 21: Chọn file `Superstore_Cleaned.csv`

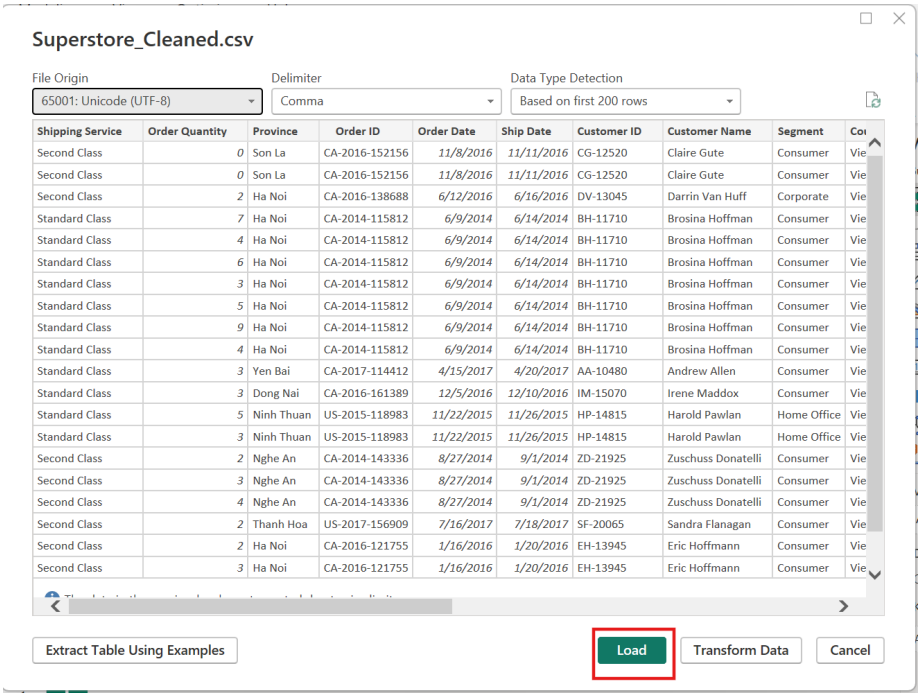

Shipping Service	Order Quantity	Province	Order ID	Order Date	Ship Date	Customer ID	Customer Name	Segment	Co
Second Class	0	Son La	CA-2016-152156	11/8/2016	11/11/2016	CG-12520	Claire Gute	Consumer	Vie
Second Class	0	Son La	CA-2016-152156	11/8/2016	11/11/2016	CG-12520	Claire Gute	Consumer	Vie
Second Class	2	Ha Noi	CA-2016-138688	6/12/2016	6/16/2016	DV-13045	Darrin Van Huff	Corporate	Vie
Standard Class	7	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	4	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	6	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	3	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	5	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	9	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	4	Ha Noi	CA-2014-115812	6/9/2014	6/14/2014	BH-11710	Brosina Hoffman	Consumer	Vie
Standard Class	3	Yen Bai	CA-2017-114412	4/15/2017	4/20/2017	AA-10480	Andrew Allen	Consumer	Vie
Standard Class	3	Dong Nai	CA-2016-161389	12/5/2016	12/10/2016	IM-15070	Irene Maddox	Consumer	Vie
Standard Class	5	Ninh Thuan	US-2015-118983	11/22/2015	11/26/2015	HP-14815	Harold Pawlan	Home Office	Vie
Standard Class	3	Ninh Thuan	US-2015-118983	11/22/2015	11/26/2015	HP-14815	Harold Pawlan	Home Office	Vie
Second Class	2	Nghe An	CA-2014-143336	8/27/2014	9/1/2014	ZD-21925	Zuschuss Donatelli	Consumer	Vie
Second Class	3	Nghe An	CA-2014-143336	8/27/2014	9/1/2014	ZD-21925	Zuschuss Donatelli	Consumer	Vie
Second Class	4	Nghe An	CA-2014-143336	8/27/2014	9/1/2014	ZD-21925	Zuschuss Donatelli	Consumer	Vie
Second Class	2	Thanh Hoa	US-2017-156909	7/16/2017	7/18/2017	SF-20065	Sandra Flanagan	Consumer	Vie
Second Class	2	Ha Noi	CA-2016-121755	1/16/2016	1/20/2016	EH-13945	Eric Hoffmann	Consumer	Vie
Second Class	3	Ha Noi	CA-2016-121755	1/16/2016	1/20/2016	EH-13945	Eric Hoffmann	Consumer	Vie

Hình 22: Nhấn **Load**

VI.2. Bước 2: Kiểm tra dữ liệu

Chuyển sang **Data View** để kiểm tra các cột dữ liệu như:

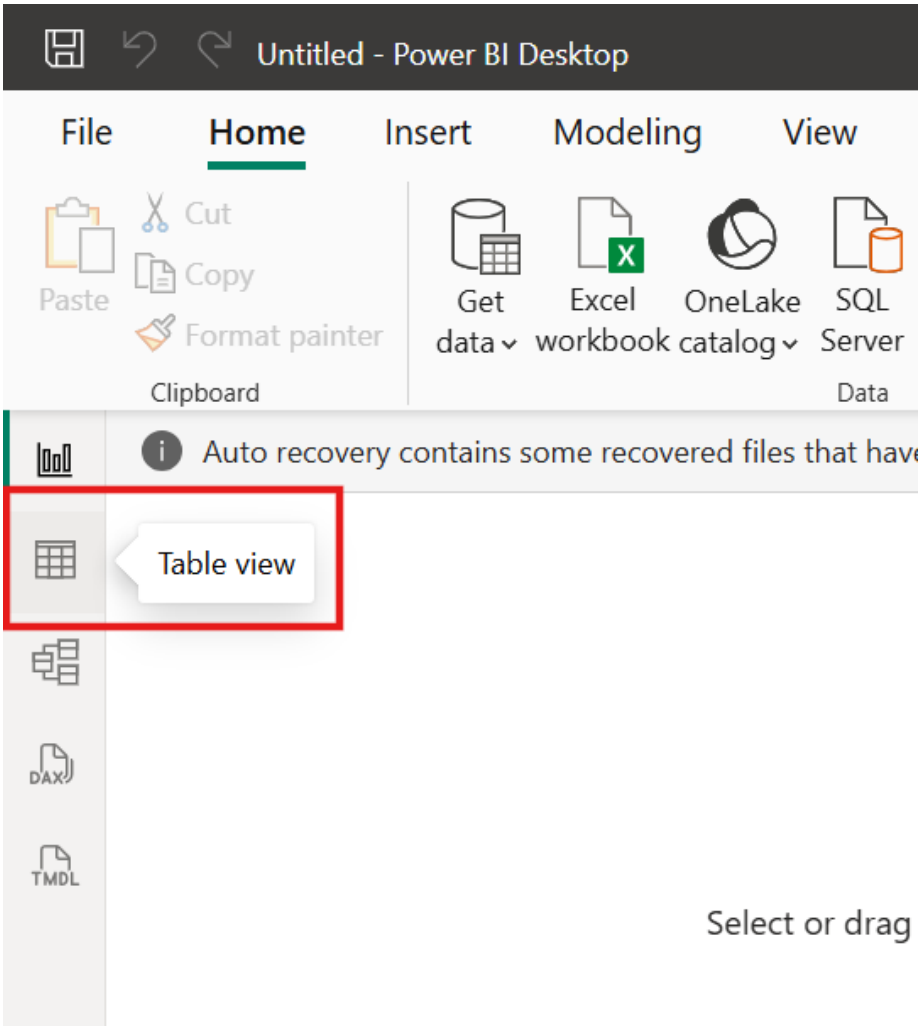

Hình 23: Map Chart trong Power BI

- Order Date, Ship Date (kiểu Date)
- Sales, Profit (kiểu số)
- Category, Province (kiểu text)

Nếu kiểu dữ liệu chưa đúng:

- Chọn cột
- Vào **Column tools** → **Data type**
- Chọn kiểu dữ liệu phù hợp

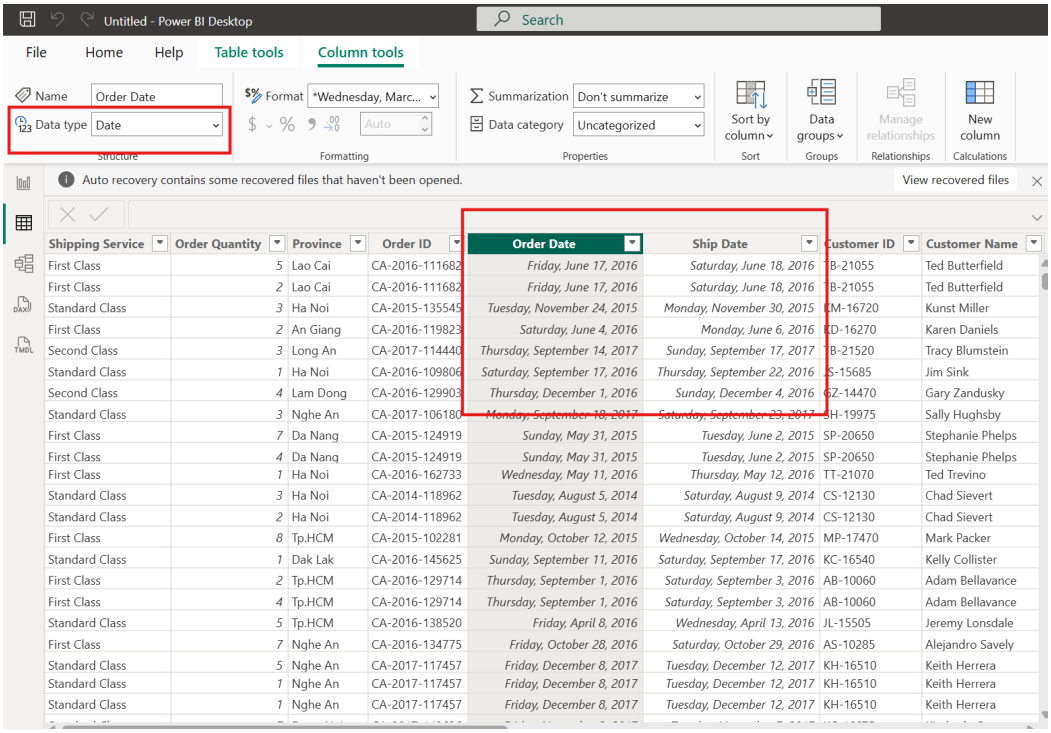

Shipping Service	Order Quantity	Province	Order ID	Order Date	Ship Date	Customer ID	Customer Name
First Class	5	Lao Cai	CA-2016-111682	Friday, June 17, 2016	Saturday, June 18, 2016	TB-21055	Ted Butterfield
First Class	2	Lao Cai	CA-2016-111682	Friday, June 17, 2016	Saturday, June 18, 2016	TB-21055	Ted Butterfield
Standard Class	3	Ha Noi	CA-2015-135545	Tuesday, November 24, 2015	Monday, November 30, 2015	KM-16720	Kunst Miller
First Class	2	An Giang	CA-2016-119823	Saturday, June 4, 2016	Monday, June 6, 2016	KD-16270	Karen Daniels
Second Class	3	Long An	CA-2017-114440	Thursday, September 14, 2017	Sunday, September 17, 2017	TB-21520	Tracy Blumstein
Standard Class	1	Ha Noi	CA-2016-109806	Saturday, September 17, 2016	Thursday, September 22, 2016	JS-15685	Jim Sink
Second Class	4	Lam Dong	CA-2016-129903	Thursday, December 1, 2016	Sunday, December 4, 2016	GZ-14470	Gary Zandusky
Standard Class	3	Nghe An	CA-2017-106180	Monday, September 18, 2017	Saturday, September 23, 2017	SH-19975	Sally Hughsby
First Class	7	Da Nang	CA-2015-124919	Sunday, May 31, 2015	Tuesday, June 2, 2015	SP-20650	Stephanie Phelps
First Class	4	Da Nang	CA-2015-124919	Sunday, May 31, 2015	Tuesday, June 2, 2015	SP-20650	Stephanie Phelps
First Class	1	Ha Noi	CA-2016-162733	Wednesday, May 11, 2016	Thursday, May 12, 2016	TT-21070	Ted Trevino
Standard Class	3	Ha Noi	CA-2014-118962	Tuesday, August 5, 2014	Saturday, August 9, 2014	CS-12130	Chad Sievert
Standard Class	2	Ha Noi	CA-2014-118962	Tuesday, August 5, 2014	Saturday, August 9, 2014	CS-12130	Chad Sievert
First Class	8	Tp.HCM	CA-2015-102281	Monday, October 12, 2015	Wednesday, October 14, 2015	MP-17470	Mark Packer
Standard Class	1	Dak Lak	CA-2016-145625	Sunday, September 11, 2016	Saturday, September 17, 2016	KC-16540	Kelly Collister
First Class	2	Tp.HCM	CA-2016-129714	Thursday, September 1, 2016	Saturday, September 3, 2016	AB-10060	Adam Bellavance
First Class	4	Tp.HCM	CA-2016-129714	Thursday, September 1, 2016	Saturday, September 3, 2016	AB-10060	Adam Bellavance
Standard Class	5	Tp.HCM	CA-2016-138520	Friday, April 8, 2016	Wednesday, April 13, 2016	JL-15505	Jeremy Lonsdale
First Class	7	Nghe An	CA-2016-134775	Friday, October 28, 2016	Saturday, October 29, 2016	AS-10285	Alejandro Savely
Standard Class	5	Nghe An	CA-2017-117457	Friday, December 8, 2017	Tuesday, December 12, 2017	KH-16510	Keith Herrera
Standard Class	1	Nghe An	CA-2017-117457	Friday, December 8, 2017	Tuesday, December 12, 2017	KH-16510	Keith Herrera
Standard Class	1	Nghe An	CA-2017-117457	Friday, December 8, 2017	Tuesday, December 12, 2017	KH-16510	Keith Herrera

Hình 24: Kiểm tra và chỉnh kiểu dữ liệu

Lưu ý

Kiểu dữ liệu đúng giúp Power BI hiển thị biểu đồ chính xác, đặc biệt với dữ liệu thời gian và số.

VI.3. Bước 3: Tạo KPI tổng quan

Tổng doanh thu

- Chọn visual **Card**
- Kéo trường `Sales` vào Card

Power BI sẽ tự động tính tổng (SUM).

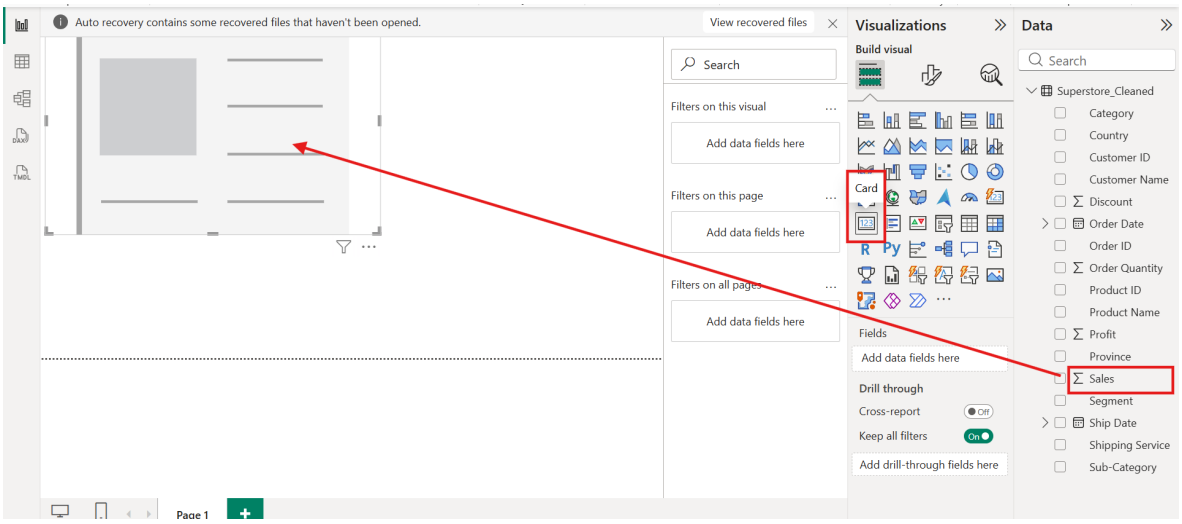

Hình 25: Tạo KPI tổng doanh thu

Tổng lợi nhuận

- Thêm Card mới
- Kéo trường `Profit`

Số lượng đơn hàng

- Kéo trường `Order ID` vào Card
- Chọn **Count (Distinct)**

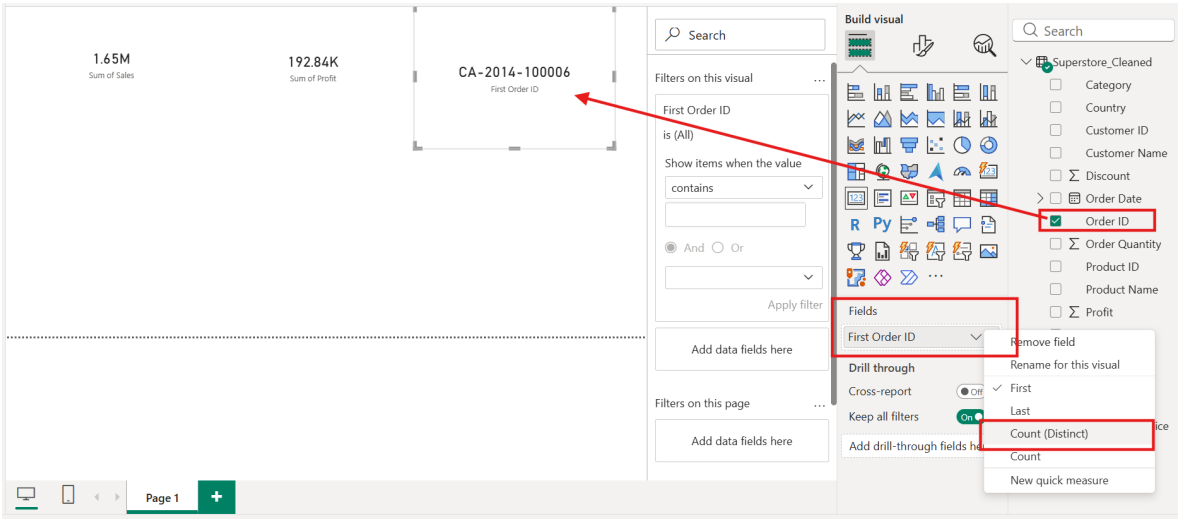

Hình 26: Chọn kiểu đếm Distinct

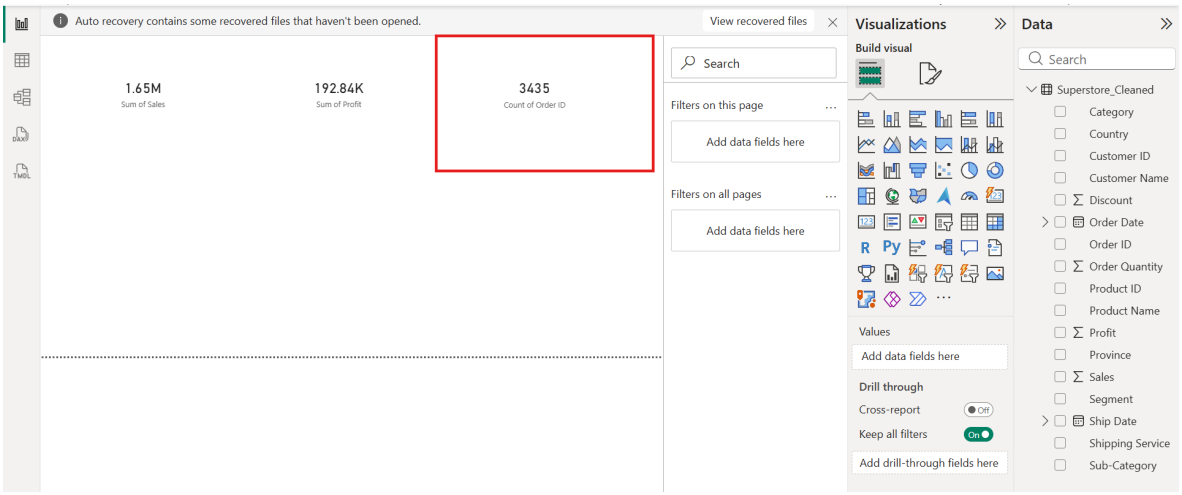

Hình 27: Kết quả

Lưu ý

Power BI tự động chọn phép tính (SUM, COUNT). Người dùng có thể thay đổi bằng cách bấm vào menu của field.

VI.4. Bước 4: Bar Chart

- Chọn **Clustered Column Chart**
- Kéo:
  - `Category` → X Axis
  - `Sales` → Y axis

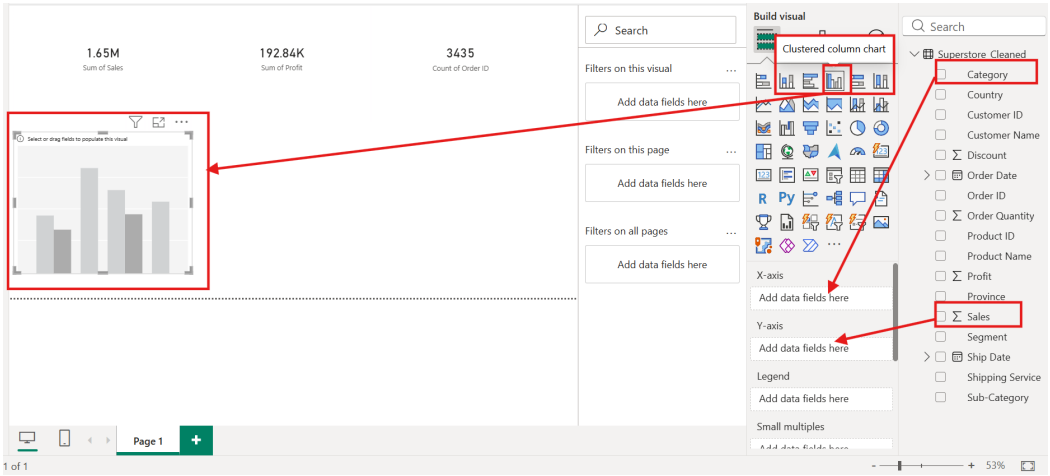

Hình 28: Biểu đồ doanh thu theo Category

Hình 29: Biểu đồ doanh thu theo Category

Khi sử dụng

- So sánh giữa các nhóm dữ liệu
- Xác định nhóm có giá trị cao nhất

VI.5. Bước 5: Line Chart

- Chọn **Line Chart**
- Kéo:
  - `Order Date` → X-axis
  - `Sales` → Y-axis

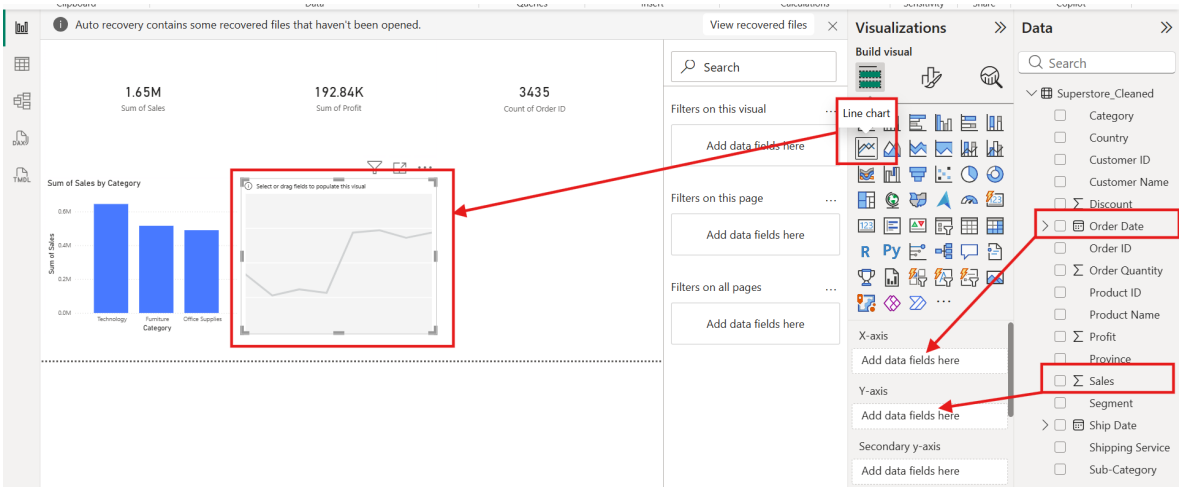

Hình 30: Tạo Line Chart

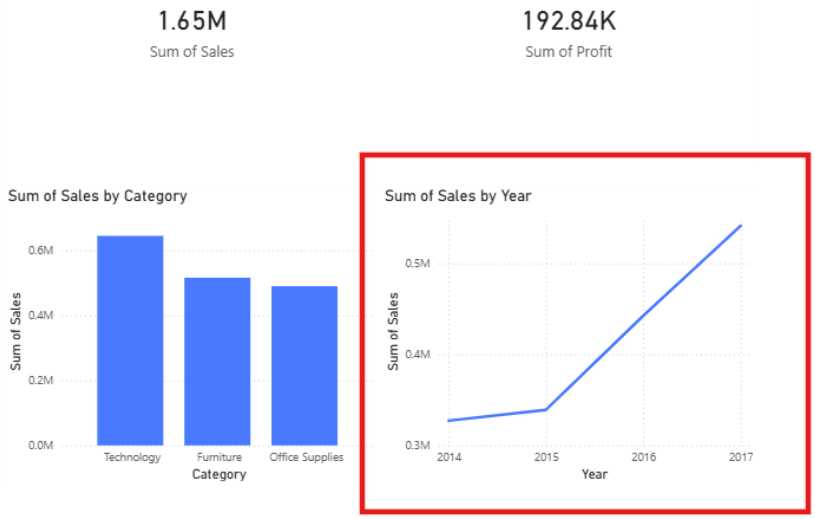

Hình 31: Biểu đồ xu hướng doanh thu theo thời gian

Lưu ý

Power BI tự động tạo Date Hierarchy (Year, Quarter, Month). Có thể drill-down để xem chi tiết.

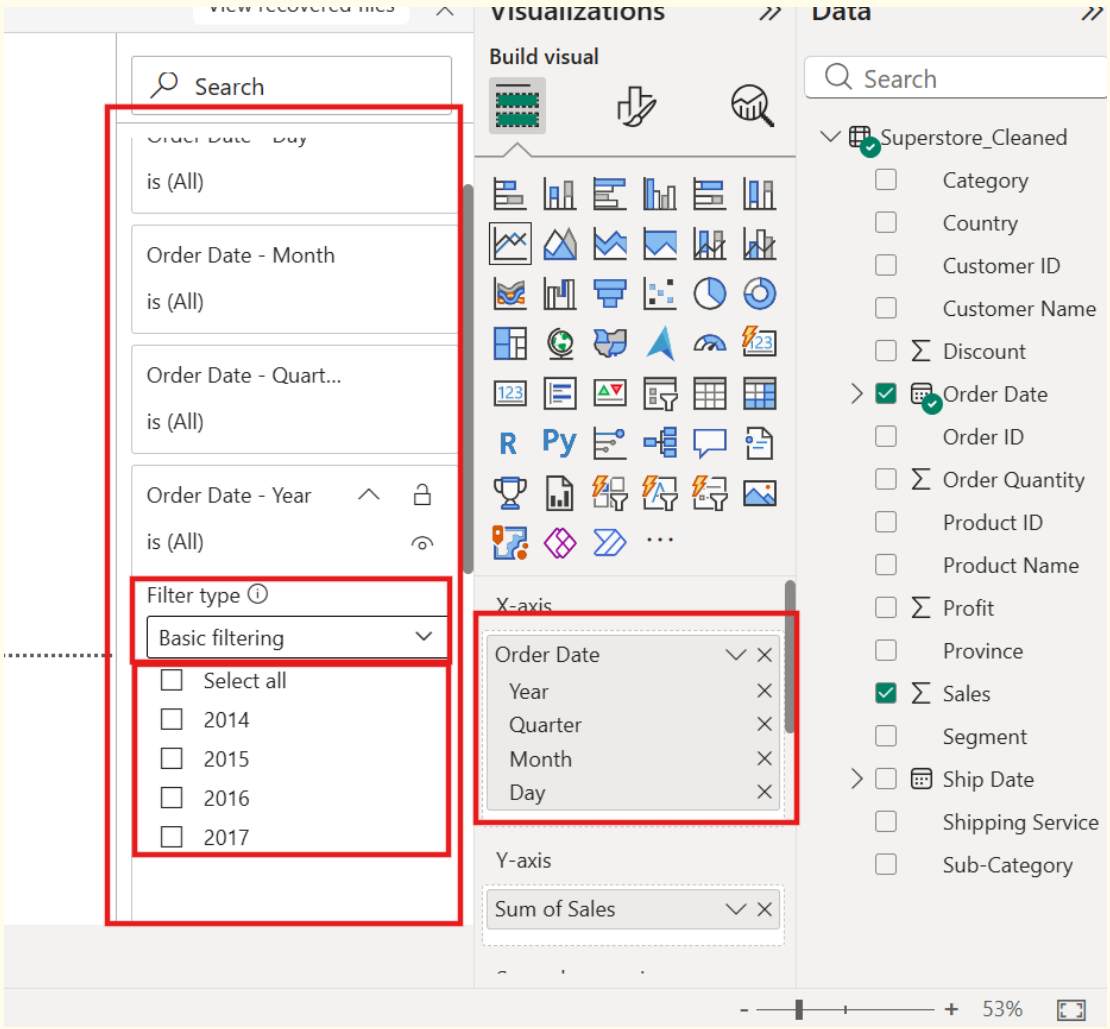

Hình 32: Date Hierarchy (Year, Quarter, Month)

VI.6. Bước 6: Map

- Chọn **ArcGIS for Power BI**
- Kéo:
  - `Province` → Location
  - `Sales` → Size

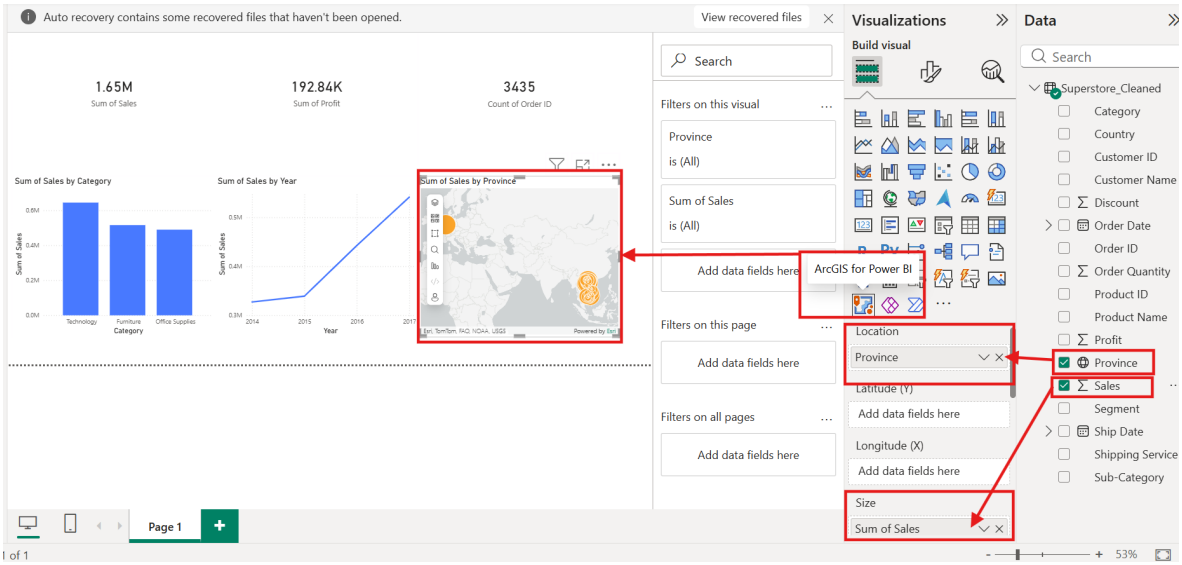

Hình 33: Biểu đồ bản đồ theo tỉnh

Lưu ý

Nếu bản đồ không hiển thị đúng:

- Chọn cột Province
- Đặt **Data Category = Place**

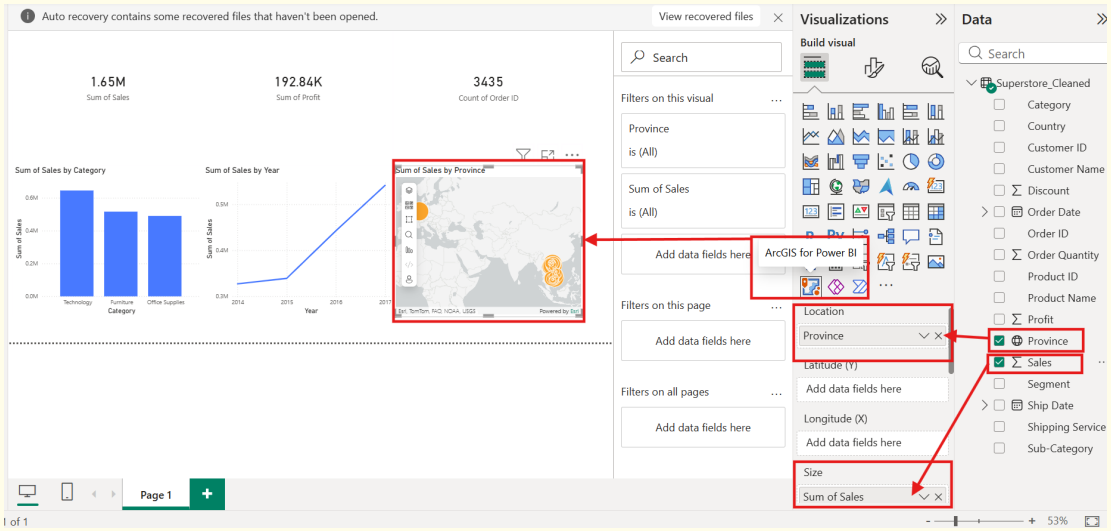

Hình 34: Sửa lại Data Category

VI.7. Bước 7: Top 10 sản phẩm

- Chọn **Clustered Bar Chart**
- Kéo:
  - `Product Name` → `X-axis`

– `Sales` → `Y-axis`

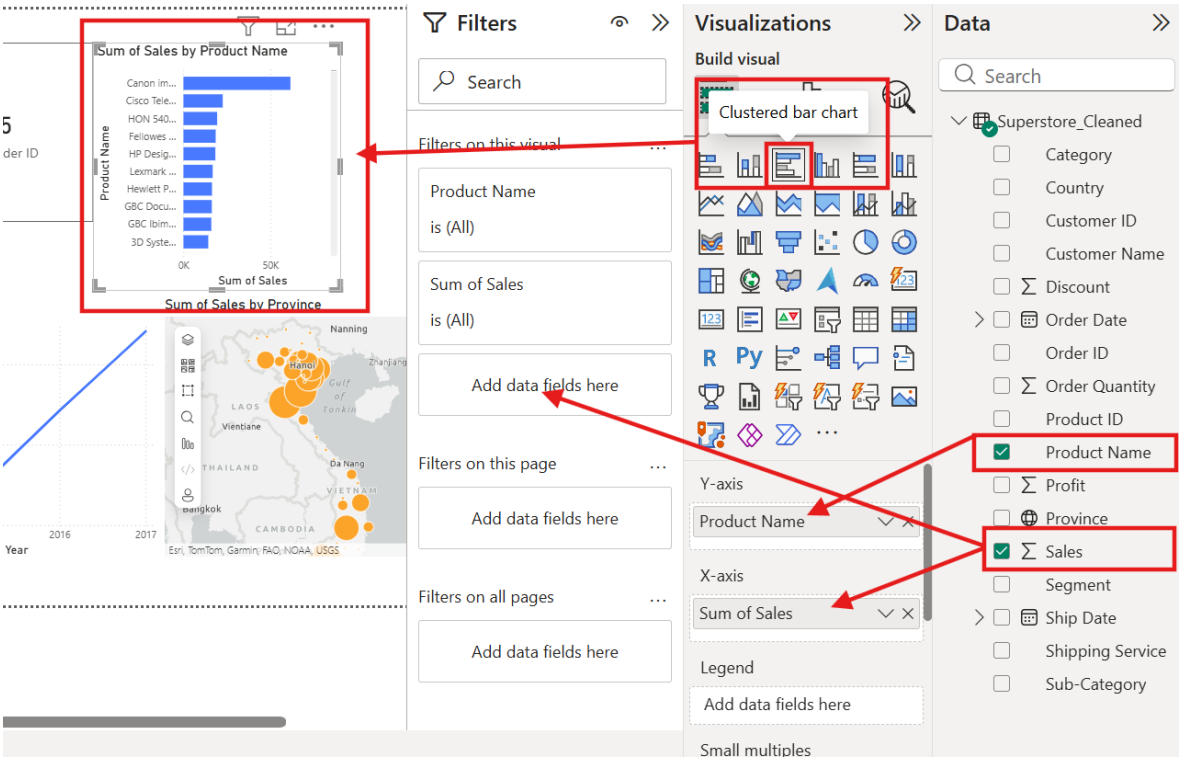

Hình 35: Trước tiên tạo Bar Chart và kéo Sales vào filter

- Trong Filters:
  - Chọn Top N = 10
  - By value: Sales

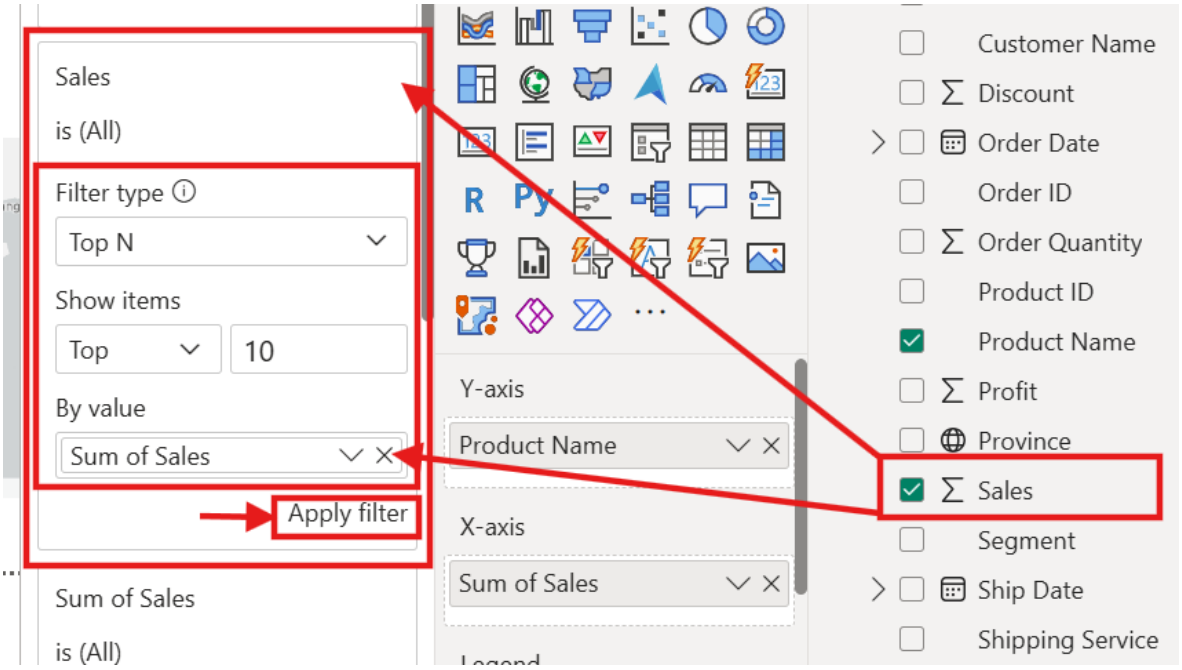

Hình 36: Thiết lập filter

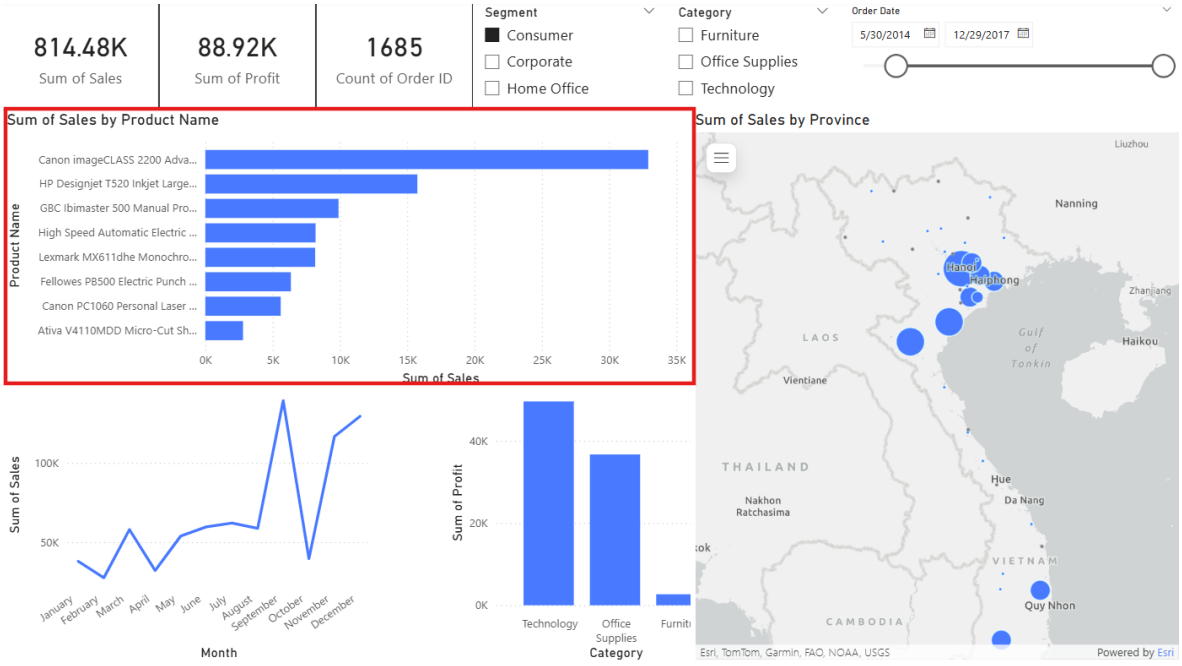

Hình 37: Top 10 sản phẩm theo doanh thu

VI.8. Bước 8: Slicer

- Chọn **Slicer**
- Kéo các trường:

- Category
- Segment
- Order Date

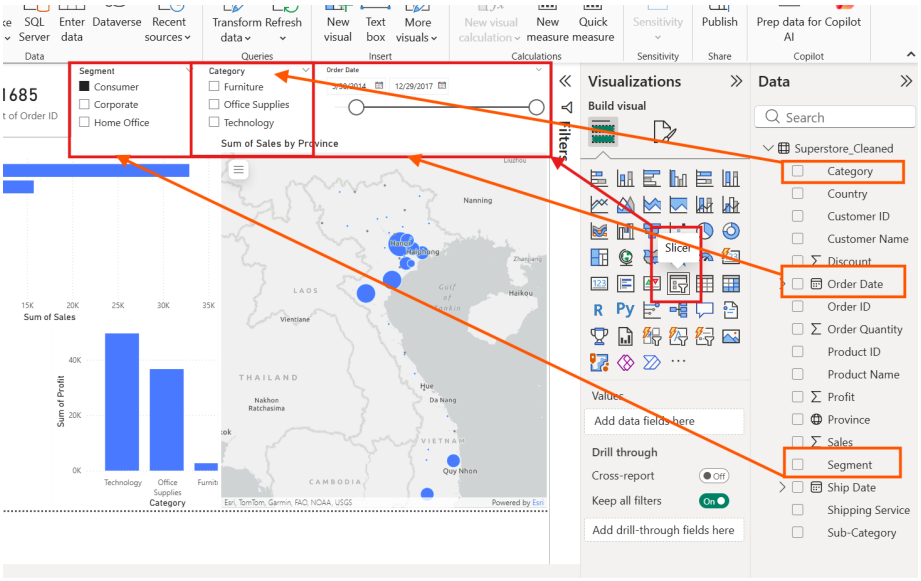

Hình 38: Sử dụng slicer để lọc dữ liệu

Lưu ý

Slicer cho phép lọc toàn bộ dashboard một cách tương tác.

VI.9. Bước 9: Sắp xếp dashboard

Gợi ý bố cục:

- Hàng 1: KPI (Sales, Profit, Orders), Slicer
- Hàng 2: Top 10 sản phẩm
- Hàng 3: Line chart, Bar Chart
- Bên phải: Map

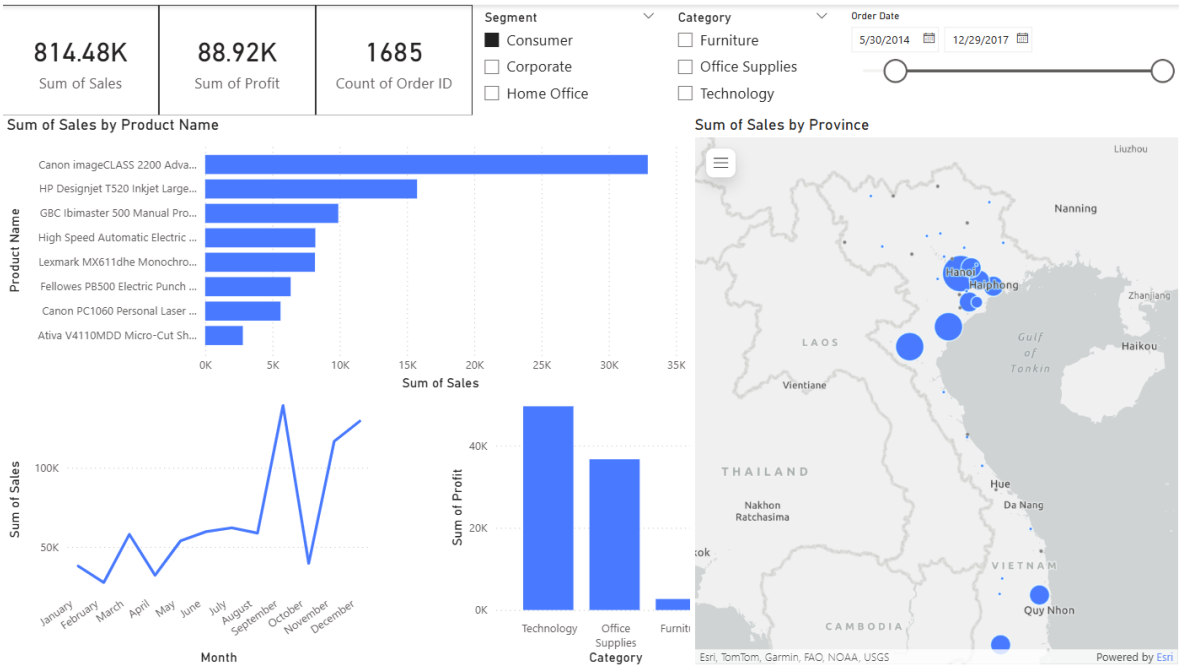

Hình 39: Bố cục dashboard hoàn chỉnh

VI.10. Bài tập thực hành

1. Tạo dashboard gồm:
   - KPI: Sales, Profit, Orders
   - Biểu đồ: Category, Time, Map, Top Products
   - Slicer: Category, Date
2. Trả lời các câu hỏi:
   - Category nào có doanh thu cao nhất?
   - Tỉnh nào có doanh thu nổi bật?
   - Xu hướng doanh thu thay đổi như thế nào theo thời gian?

Tư duy khi xây dựng dashboard

Dashboard không phải là tập hợp các biểu đồ, mà là một công cụ trả lời câu hỏi.
Một dashboard tốt cần:
- Có mục tiêu rõ ràng
- Có cấu trúc logic
- Giúp người dùng ra quyết định nhanh chóng

VII. Tổng kết

Trong Lesson 1, chúng ta đã đi qua những nền tảng quan trọng nhất để bắt đầu học Power BI:

Chủ đề	Nội dung chính	Ý nghĩa
Power BI Ecosystem	Desktop vs Service	Biết nơi xây report và nơi chia sẻ report
Interface Navigation	Report, Data, Model View	Biết từng khu vực dùng để làm gì
Data Integration	Kết nối dữ liệu từ Excel	Biết cách đưa dữ liệu vào Power BI
Connection Methods	Import vs DirectQuery	Hiểu snapshot vs live connection
Visualization Selection	Bar, Line, Map	Chọn đúng biểu đồ theo mục tiêu phân tích

VIII. Câu hỏi trắc nghiệm

1. Power BI Desktop và Power BI Service khác nhau chủ yếu ở điểm nào?
   (a) Desktop dùng để chia sẻ báo cáo, Service dùng để viết DAX.
   (b) Desktop chủ yếu để xây dựng báo cáo, Service chủ yếu để xuất bản và chia sẻ.
   (c) Desktop chỉ dùng để xem dashboard, Service chỉ dùng để nhập dữ liệu Excel.
   (d) Hai thành phần này hoàn toàn giống nhau.

2. Trong Power BI Desktop, ba chế độ làm việc chính là:
   (a) Home View, Insert View, Help View.
   (b) Report View, Data View, Model View.
   (c) Dashboard View, Story View, Data Source View.
   (d) Fields View, Measures View, Service View.

3. Khi nhập dữ liệu từ Excel vào Power BI, lựa chọn **Transform Data** có ý nghĩa gì?
   (a) Xuất dữ liệu sang Power BI Service.
   (b) Mở Power Query Editor để làm sạch và biến đổi dữ liệu trước khi tải vào mô hình.
   (c) Tạo dashboard tự động từ dữ liệu.
   (d) Chỉ đổi tên file Excel trước khi import.

4. Điểm khác biệt quan trọng giữa **Import** và **DirectQuery** là gì?
   (a) Import luôn truy vấn trực tiếp dữ liệu từ nguồn, DirectQuery lưu dữ liệu trong bộ nhớ.
   (b) Import chỉ dùng cho Excel, DirectQuery chỉ dùng cho SQL Server.
   (c) Import lưu dữ liệu trong mô hình Power BI, còn DirectQuery truy vấn trực tiếp từ nguồn dữ liệu.
   (d) Hai chế độ không có khác biệt đáng kể.

5. Khi cần so sánh doanh thu giữa các nhóm sản phẩm như Category hoặc Region, loại biểu đồ phù hợp nhất là:
   (a) Line Chart
   (b) Bar Chart
   (c) Map
   (d) KPI

6. Khi cần theo dõi xu hướng doanh thu theo thời gian, loại biểu đồ phù hợp nhất là:
   (a) Table
   (b) Card
   (c) Line Chart

(d) Map

7. (Bài tập tổng hợp chọn phương thức kết nối dữ liệu)
Bạn đang xây dựng một dashboard theo dõi doanh thu real-time từ hệ thống bán hàng (database SQL Server). Dữ liệu có kích thước rất lớn (hàng chục triệu dòng) và cần hiển thị số liệu cập nhật gần như ngay lập tức khi người dùng tương tác.

   Phương thức kết nối dữ liệu nào phù hợp nhất?

   a. Import mode để tăng tốc độ truy vấn.
   b. DirectQuery để truy vấn trực tiếp dữ liệu từ nguồn.
   c. Excel connection để đồng bộ dữ liệu định kỳ.
   d. CSV import để tối ưu dung lượng file.

8. (Bài tập tổng hợp xác định loại biểu đồ phù hợp)
Bạn cần phân tích mối quan hệ giữa chi phí marketing (`Marketing Spend`) và doanh thu (`Sales`) để xem liệu tăng chi phí có làm tăng doanh thu hay không.

   Loại biểu đồ nào phù hợp nhất?

   a. Bar Chart theo từng chiến dịch
   b. Line Chart theo thời gian
   c. Scatter Plot với `Marketing Spend` và `Sales`
   d. Pie Chart tỷ trọng chi phí

9. (Bài tập tổng hợp xử lý dữ liệu trước khi load)
Bạn nhập dữ liệu từ Excel nhưng nhận thấy:

   - Có nhiều cột không cần thiết
   - Một số cột có kiểu dữ liệu sai
   - Có các dòng dữ liệu bị thiếu (null)

   Bước nào dưới đây là phù hợp nhất để xử lý trước khi xây dựng báo cáo?

   a. Load trực tiếp vào Power BI rồi xử lý sau
   b. Sử dụng Transform Data (Power Query)
   c. Tạo biểu đồ ngay để kiểm tra dữ liệu
   d. Xuất lại file Excel sang CSV

10. (Bài tập tổng hợp thiết kế dashboard hợp lý)
Bạn đang thiết kế dashboard cho CEO với các yêu cầu:

   - Xem tổng doanh thu, lợi nhuận (KPI)
   - So sánh doanh thu theo Category
   - Xem xu hướng theo thời gian

- Phân tích theo khu vực địa lý

Cách kết hợp visualization nào dưới đây là hợp lý nhất?

a. Table + Pie Chart + KPI + Matrix
b. Card + Bar Chart + Line Chart + Map
c. Scatter Plot + Histogram + Card
d. Line Chart + Table + KPI

Phụ lục

1. **Hint:** Các file code gợi ý và dữ liệu nếu có được lưu trong thư mục có thể được tải tại đây.
2. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại đây (Lưu ý: Sáng thứ 3 khi hết deadline phần project, ad mới copy các nội dung bài giải nêu trên vào đường dẫn).
3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 giờ.

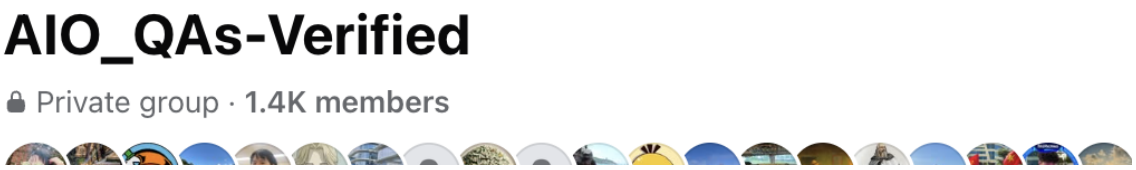

Hình 1: Hình ảnh group facebook AIO Q&A

AI VIET NAM COURSE 2026

Quiz: Introduction to PowerBI

1. Power BI Desktop và Power BI Service khác nhau chủ yếu ở điểm nào?

a. Desktop dùng để chia sẻ báo cáo, Service dùng để viết DAX.

b. Desktop chủ yếu để xây dựng báo cáo, Service chủ yếu để xuất bản và chia sẻ.

c. Desktop chỉ dùng để xem dashboard, Service chỉ dùng để nhập dữ liệu Excel.

d. Hai thành phần này hoàn toàn giống nhau.

Đáp án đúng: B

Giải thích chi tiết:

Power BI Desktop là công cụ dùng để xây dựng báo cáo, mô hình dữ liệu và viết DAX trên máy cá nhân.

Trong khi đó, Power BI Service (nền tảng web) chủ yếu dùng để xuất bản, chia sẻ báo cáo và cộng tác trong tổ chức.

Các lựa chọn khác sai vì:

- (A) đảo ngược chức năng
- (C) mô tả sai hoàn toàn
- (D) không đúng vì hai thành phần có vai trò khác nhau

2. Trong Power BI Desktop, ba chế độ làm việc chính là:

a. Home View, Insert View, Help View.

b. Report View, Data View, Model View.

c. Dashboard View, Story View, Data Source View.

d. Fields View, Measures View, Service View.

Đáp án đúng: B

Giải thích chi tiết:

Ba chế độ chính gồm:

- Report View: tạo và thiết kế báo cáo
- Data View: xem dữ liệu dạng bảng
- Model View: quản lý quan hệ giữa các bảng

Các phương án khác không tồn tại trong Power BI.

3. Khi nhập dữ liệu từ Excel vào Power BI, lựa chọn **Transform Data** có ý nghĩa gì?

a. Xuất dữ liệu sang Power BI Service.

b. Mở Power Query Editor để làm sạch và biến đổi dữ liệu trước khi tải vào mô hình.

c. Tạo dashboard tự động từ dữ liệu.

d. Chỉ đổi tên file Excel trước khi import.

Đáp án đúng: B

Giải thích chi tiết:

Transform Data sẽ mở Power Query Editor, nơi bạn có thể:

- Làm sạch dữ liệu
- Biến đổi cấu trúc dữ liệu
- Xử lý missing values

Các đáp án khác không đúng với chức năng thực tế.

4. Điểm khác biệt quan trọng giữa **Import** và **DirectQuery** là gì?

a. Import luôn truy vấn trực tiếp dữ liệu từ nguồn, DirectQuery lưu dữ liệu trong bộ nhớ.

b. Import chỉ dùng cho Excel, DirectQuery chỉ dùng cho SQL Server.

c. Import lưu dữ liệu trong mô hình Power BI, còn DirectQuery truy vấn trực tiếp từ nguồn dữ liệu.

d. Hai chế độ không có khác biệt đáng kể.

Đáp án đúng: C

Giải thích chi tiết:

- Import: dữ liệu được tải vào bộ nhớ của Power BI → truy vấn nhanh
- DirectQuery: dữ liệu không lưu trong Power BI mà truy vấn trực tiếp từ nguồn

Các lựa chọn khác đều mô tả sai bản chất hai chế độ.

5. Khi cần so sánh doanh thu giữa các nhóm sản phẩm như Category hoặc Region, loại biểu đồ phù hợp nhất là:

a. Line Chart

b. Bar Chart

c. Map

d. KPI

Đáp án đúng: B

Giải thích chi tiết:

Bar Chart phù hợp để:

- So sánh giá trị giữa các nhóm rời rạc
- Dễ dàng nhìn thấy sự chênh lệch giữa các Category hoặc Region

Các biểu đồ khác:

- Line Chart: phù hợp theo thời gian
- Map: dùng cho địa lý
- KPI: hiển thị chỉ số đơn lẻ

6. Khi cần theo dõi xu hướng doanh thu theo thời gian, loại biểu đồ phù hợp nhất là:

a. Table
b. Card
c. Line Chart
d. Map

Đáp án đúng: C

Giải thích chi tiết:

Line Chart là lựa chọn tốt nhất để:

- Thể hiện xu hướng theo thời gian
- Quan sát tăng/giảm liên tục

Các lựa chọn khác không thể hiện xu hướng hiệu quả.

Các phương án khác thuộc về chức năng của các pane khác như Model hoặc Data.

7. (Bài tập tổng hợp chọn phương thức kết nối dữ liệu)
Bạn đang xây dựng một dashboard theo dõi doanh thu real-time từ hệ thống bán hàng (database SQL Server). Dữ liệu có kích thước rất lớn (hàng chục triệu dòng) và cần hiển thị số liệu cập nhật gần như ngay lập tức khi người dùng tương tác.

Phương thức kết nối dữ liệu nào phù hợp nhất?

a. Import mode để tăng tốc độ truy vấn.

b. DirectQuery để truy vấn trực tiếp dữ liệu từ nguồn.

c. Excel connection để đồng bộ dữ liệu định kỳ.

d. CSV import để tối ưu dung lượng file.

Đáp án đúng: B

Giải thích chi tiết:

Yêu cầu bài toán gồm:

- Dữ liệu rất lớn
- Cần cập nhật gần real-time

Import mode (A) sẽ lưu dữ liệu vào Power BI, dẫn đến:

- Không cập nhật ngay lập tức
- Không phù hợp với dữ liệu lớn

DirectQuery (B) cho phép:

- Truy vấn trực tiếp từ database
- Luôn lấy dữ liệu mới nhất

Do đó, đây là lựa chọn phù hợp nhất.

8. (Bài tập tổng hợp xác định loại biểu đồ phù hợp)
Bạn cần phân tích mối quan hệ giữa chi phí marketing (`Marketing Spend`) và doanh thu (`Sales`) để xem liệu tăng chi phí có làm tăng doanh thu hay không.

Loại biểu đồ nào phù hợp nhất?

a. Bar Chart theo từng chiến dịch

b. Line Chart theo thời gian

c. Scatter Plot với `Marketing Spend` và `Sales`

d. Pie Chart tỷ trọng chi phí

Đáp án đúng: C

Giải thích chi tiết:

Bài toán yêu cầu phân tích mối quan hệ giữa hai biến số định lượng:

$$x = \texttt{Marketing Spend}, \quad y = \texttt{Sales}$$

Scatter Plot cho phép:

- Quan sát tương quan (correlation)
- Nhận diện xu hướng tuyến tính hoặc phi tuyến

Các biểu đồ khác không thể hiện trực tiếp mối quan hệ giữa hai biến số.

9. (Bài tập tổng hợp xử lý dữ liệu trước khi load)
Bạn nhập dữ liệu từ Excel nhưng nhận thấy:

- Có nhiều cột không cần thiết
- Một số cột có kiểu dữ liệu sai
- Có các dòng dữ liệu bị thiếu (null)

Bước nào dưới đây là phù hợp nhất để xử lý trước khi xây dựng báo cáo?

a. Load trực tiếp vào Power BI rồi xử lý sau
b. Sử dụng Transform Data (Power Query)
c. Tạo biểu đồ ngay để kiểm tra dữ liệu
d. Xuất lại file Excel sang CSV

Đáp án đúng: B

Giải thích chi tiết:

Power Query (Transform Data) là nơi thực hiện ETL:

- Xóa cột không cần thiết
- Chuyển đổi kiểu dữ liệu
- Xử lý missing values

Nếu không làm sạch dữ liệu trước, các visual có thể:

- Sai lệch kết quả
- Gây lỗi phân tích

10. (Bài tập tổng hợp thiết kế dashboard hợp lý)
Bạn đang thiết kế dashboard cho CEO với các yêu cầu:

- Xem tổng doanh thu, lợi nhuận (KPI)
- So sánh doanh thu theo Category
- Xem xu hướng theo thời gian
- Phân tích theo khu vực địa lý

Cách kết hợp visualization nào dưới đây là hợp lý nhất?

a. Table + Pie Chart + KPI + Matrix
b. Card + Bar Chart + Line Chart + Map
c. Scatter Plot + Histogram + Card
d. Line Chart + Table + KPI

Đáp án đúng: B

Giải thích chi tiết:

Dashboard cần kết hợp nhiều loại biểu đồ:

- KPI → Card (tổng quan nhanh)
- So sánh Category → Bar Chart
- Xu hướng thời gian → Line Chart
- Địa lý → Map

Option (B) bao phủ đầy đủ tất cả yêu cầu phân tích, đồng thời tuân theo nguyên tắc chọn visualization phù hợp với từng loại dữ liệu.

AI VIET NAM COURSE 2026

Power BI: Data Transformation and Modeling

I. Giới thiệu

Ở Lesson 1, chúng ta đã biết cách kết nối và import dữ liệu vào Power BI. Nhưng thực tế, dữ liệu khi vừa import vào hiếm khi không có lỗi và sẵn sàng phân tích ngay.

Hãy tưởng tượng bạn nhận file Excel từ phòng kinh doanh. Cột **Country** có khi ghi United States, có khi US, thậm chí u.s., tất cả đều chỉ cùng một quốc gia. Cột giá bán lẽ ra phải là số, nhưng bị nhận thành text vì ai đó nhập sai. Phân tích trên dữ liệu chưa được làm sạch như vậy, kết quả sẽ hoàn toàn sai lệch.

Lesson 2 sẽ giúp chúng ta giải quyết vấn đề này qua **4 bước cốt lõi**. Bốn bước này tạo thành một **pipeline hoàn chỉnh**, đưa dữ liệu từ trạng thái thô sơ ban đầu đến một data model gọn gàng, sẵn sàng cho visualization:

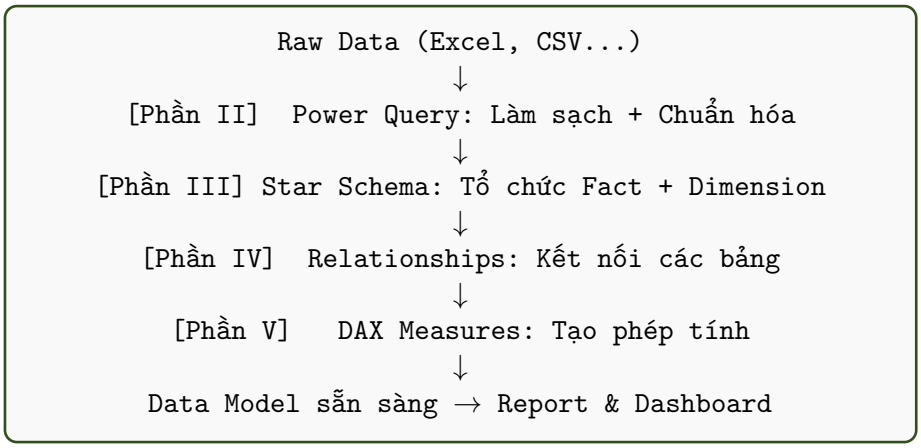

Hình 1: Pipeline xử lý dữ liệu trong Power BI. Mỗi bước tương ứng với một phần trong bài viết.

1. **Làm sạch dữ liệu** bằng Power Query: chuẩn hóa text, xóa dòng thừa, sửa data type → *Phần II*
2. **Tổ chức dữ liệu** theo Star Schema: tách thành Fact table và Dimension table → *Phần III*

3. **Kết nối các bảng** bằng Relationships: để dữ liệu kết nối với nhau → *Phần IV*
4. **Tạo phép tính** bằng DAX: viết các measure cơ bản như Total Sales → *Phần V*

Trong suốt bài viết, chúng ta sẽ sử dụng **Adventure Works DW 2020:** dataset mẫu chính thức của Microsoft, được dùng trong tài liệu Microsoft Learn. Dataset mô phỏng công ty sản xuất xe đạp **Adventure Works**, bán sản phẩm ra thị trường toàn cầu.

Tải dataset

Tải các file .csv tại Github Adventure Works DW 2020.

Dataset gồm **7 bảng** đã được tổ chức theo Star Schema:

Bảng	Vai trò	Các cột chính
Sales	Fact table	Sales Amount, Order Order Order Quantity, Unit Price, OrderDateKey, ProductKey, CustomerKey...
Product	Dimension	Product, Category, Subcategory, Color, List Price, Standard Cost
Customer	Dimension	Customer, City, State-Province, Country-Region
Date	Dimension	Date, Month, Fiscal Quarter, Fiscal Year
Sales Territory	Dimension	Region, Country, Group
Reseller	Dimension	Reseller, Business Type, City, Country-Region
Sales Order	Dimension	Sales Order, Channel

Mỗi bước thực hành đều áp dụng trực tiếp lên dataset này, giúp các bạn thấy rõ kết quả từng giai đoạn.

II. Data Cleaning với Power Query

II.1. Power Query và M Language: Nền tảng

Trước khi đi vào từng kỹ thuật cleaning, chúng ta cần hiểu 2 khái niệm nền tảng: Power Query là gì, và M Language là gì.

Power Query là công cụ **ETL** (**Extract, Transform, Load**: trích xuất, biến đổi, nạp dữ liệu) tích hợp sẵn trong Power BI Desktop. Nếu nhìn lại pipeline ở Hình 10, Power Query nằm ở bước đầu tiên: nhận dữ liệu thô từ nguồn (Excel, CSV, database...), biến đổi cho sạch, rồi nạp vào Data Model.

Một điểm quan trọng: Power Query **không sửa file gốc**. Mọi thao tác cleaning chỉ áp dụng trên bản sao trong bộ nhớ. File Excel ban đầu vẫn nguyên vẹn. Ngoài ra, Power Query ghi lại từng bước biến đổi dưới dạng **Applied Steps**. Khi nhấn **Close & Apply**, các bước này mới thực thi và nạp kết quả vào model. Mỗi lần refresh data, Power Query tự động chạy lại toàn bộ các bước đã cấu hình.

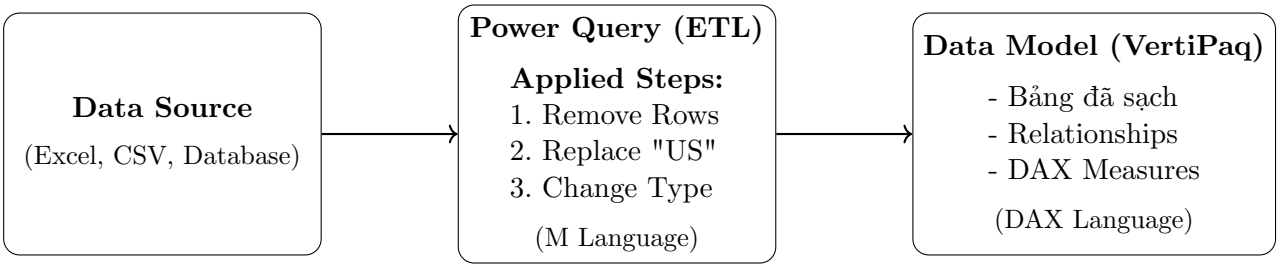

Hình 1: Vị trí Power Query trong kiến trúc Power BI

Vậy **M Language** (**ngôn ngữ M**) là gì? Mỗi khi chúng ta click một nút trên giao diện Power Query (ví dụ: Remove Top Rows, Replace Values, Change Type...), Power Query tự động sinh ra một dòng code M tương ứng. M chính là ngôn ngữ lập trình "phía sau" mọi thao tác trên giao diện.

Ví dụ: khi click **Remove Top Rows** → **3**, Power Query sinh code M:

```
= Table.Skip(Source, 3)
```

Chúng ta có thể xem code M trong **Formula Bar** (thanh công thức phía trên Data Preview). Không cần viết M từ đầu, chỉ cần biết đọc để hiểu Power Query đang làm gì, và sửa khi cần.

M Language vs DAX

Power BI có **2 ngôn ngữ** khác nhau, dùng cho 2 mục đích khác nhau:

	M Language	DAX
Chạy ở đâu	Power Query (tầng ETL)	Data Model (tầng phân tích)
Làm gì	Biến đổi dữ liệu: xóa dòng, đổi type, gộp bảng...	Tính toán: SUM, AVERAGE, CALCULATE...
Khi nào chạy	Khi Close & Apply hoặc Refresh	Khi visual render trên report
Cần biết?	Đọc hiểu cơ bản, GUI làm hầu hết	Cần viết thành thạo

Trong bài này, phần II dùng M (qua GUI), phần V dùng DAX.

Sau khi hiểu Power Query và M, chúng ta sẽ đi qua **5 kỹ thuật cleaning** theo thứ tự:

1. **Power Query Editor** (II.2): Làm quen giao diện, biết mở ở đâu, 4 khu vực chính, Data Profiling
2. **Chuẩn hóa Text** (II.3): Xử lý biến thể dữ liệu ("US" vs "United States"), trim khoảng trắng, thống nhất case
3. **Quản lý Rows/Columns** (II.4): Xóa dòng thừa, cột thừa, tách/gộp cột
4. **Sửa Data Types** (II.5): Đổi Text → Currency, Text → Date, xử lý lỗi khi đổi type
5. **Bẫy lọc nguy hiểm** (II.6): Cạm bẫy khi dùng filter, cách lọc an toàn

Mỗi kỹ thuật giải quyết một loại vấn đề khác nhau, và chúng ta sẽ áp dụng trực tiếp trên dataset Adventure Works.

II.2. Power Query Editor: Công cụ biến đổi dữ liệu

Bước đầu tiên trong quy trình cleaning là làm quen với công cụ. **Power Query Editor** là giao diện chính nơi chúng ta thực hiện mọi thao tác biến đổi. Mở Power Query Editor bằng cách vào **Home → Transform Data**.

Giao diện Power Query Editor gồm 4 khu vực chính:

- **Ribbon (thanh công cụ trên cùng):** Chứa các tab Home, Transform, Add Column, nơi tập trung hầu hết các thao tác biến đổi dữ liệu.
- **Queries Pane (bên trái):** Danh sách tất cả các bảng (query) đang được xử lý. Mỗi bảng import vào sẽ xuất hiện ở đây.

- **Data Preview (giữa):** Hiển thị dữ liệu hiện tại của bảng đang chọn. Đây là nơi chúng ta xem kết quả sau mỗi bước transform.
- **Query Settings (bên phải):** Quan trọng nhất là phần **Applied Steps**, ghi lại **toàn bộ lịch sử** các bước biến đổi. Mỗi step tương ứng với một dòng code M, đúng như đã giải thích ở mục II.1. Click vào step bất kỳ để xem dữ liệu tại thời điểm đó, hoặc sửa, xóa, chèn step mới.

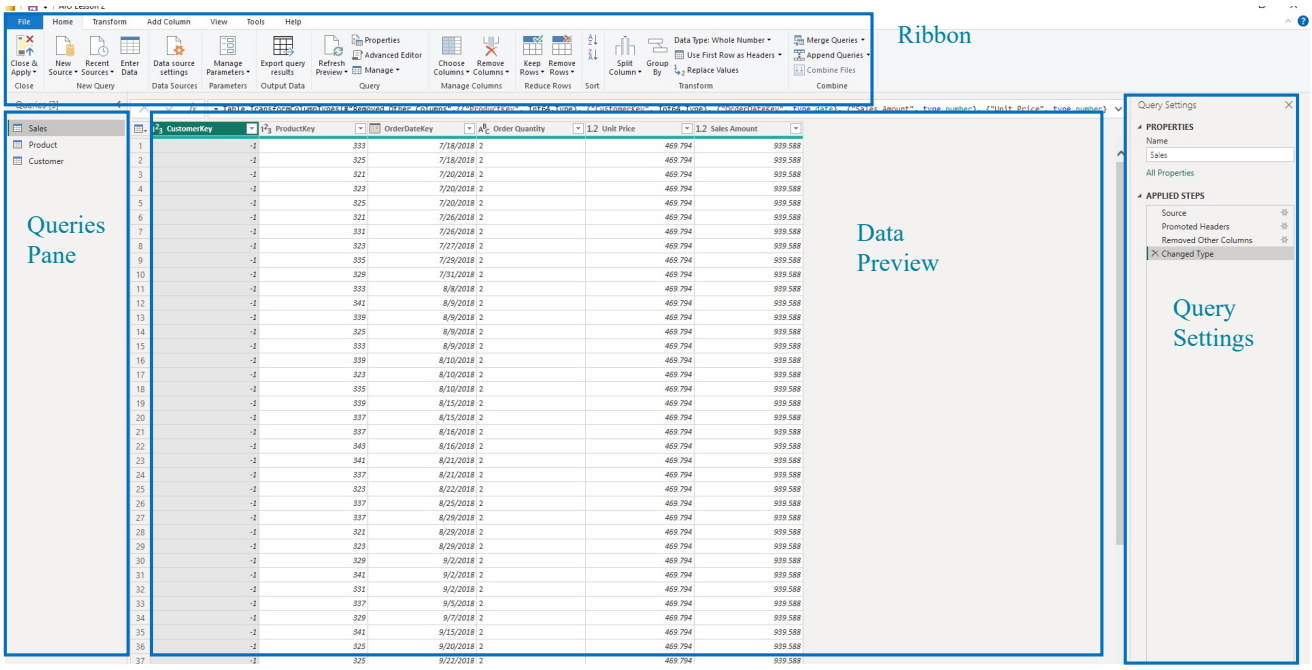

Hình 2: Giao diện Power Query Editor, Ribbon ở trên, Queries bên trái, Data Preview ở giữa, và Applied Steps bên phải.

Mẹo

Nên bật **Formula Bar** (vào tab View → tick Formula Bar) để xem code M phía sau mỗi step. Nhờ đó chúng ta có thể kiểm tra Power BI đang làm gì "phía sau hậu trường". Ngoài ra, chuột phải vào step → **Properties** để đổi tên step cho dễ hiểu hơn, ví dụ đổi "Changed Type" thành "Sửa kiểu dữ liệu cột Sales Amount".

Power Query còn có tính năng **Data Profiling**, giúp đánh giá chất lượng dữ liệu trước khi bắt tay cleaning. Để bật: vào tab **View** → tick chọn:

- **Column Quality:** Hiển thị thanh màu ở đầu mỗi cột, cho biết **% Valid** (hợp lệ), **% Error** (lỗi), và **% Empty** (rỗng). Nếu thấy cột nào có nhiều Error hoặc Empty, đó là cột cần xử lý trước.
- **Column Distribution:** Hiển thị biểu đồ nhỏ cho thấy phân bố giá trị, có bao nhiêu giá trị **distinct** (khác nhau) và bao nhiêu giá trị **unique** (chỉ xuất hiện 1 lần). Hữu ích để phát hiện cột nào nên làm key.

- **Column Profile:** Hiển thị thống kê chi tiết cho cột đang chọn, min, max, count, null count... Rất tiện khi cần hiểu nhanh đặc điểm dữ liệu.

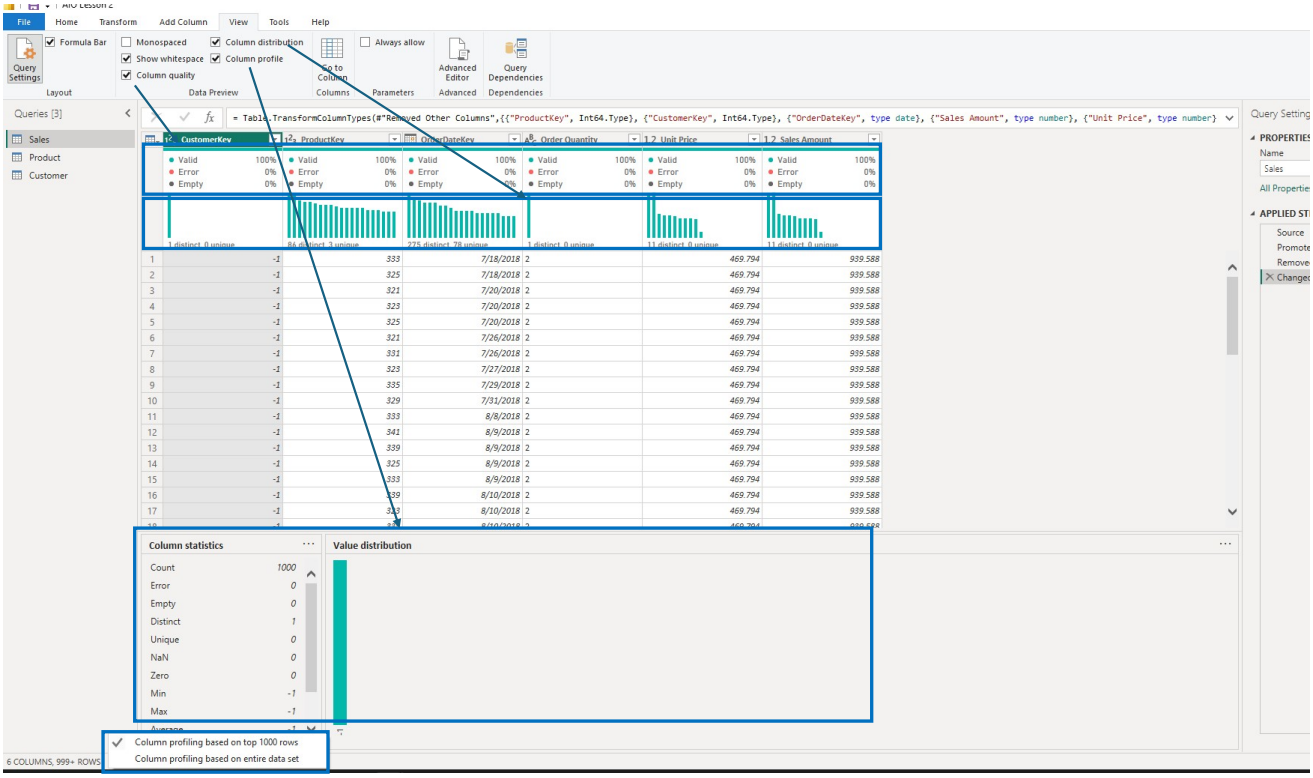

Hình 3: Data Profiling.

Lưu ý

Mặc định, Data Profiling chỉ phân tích **1000 dòng đầu**. Để phân tích toàn bộ dataset, click vào dòng trạng thái phía dưới cửa sổ và chọn **"Column profiling based on entire data set"**.

Mẹo nâng cao: Hàm Table.Profile

M language có hàm `Table.Profile` "viên ngọc ẩn" giúp kiểm tra nhanh chất lượng dữ liệu. Hàm này trả về bảng thống kê cho mỗi cột: Min, Max, Average, Standard Deviation, Count, Null Count, và Distinct Count.

II.3. Chuẩn hóa Text: Giải quyết Biến thể dữ liệu

Sau khi nắc được giao diện Power Query Editor, kỹ thuật cleaning đầu tiên là **chuẩn hóa text**. Đây là vấn đề phổ biến nhất khi làm việc với dữ liệu thực tế: cùng một giá trị nhưng được ghi theo nhiều cách khác nhau, gọi là **biến thể** (**variations**). Ví dụ, trong bảng `Customer` của Adventure Works, cột `Country-Region` có thể chứa:

Giá trị trong cột Country-Region	Ý nghĩa thực
United States	Tên chuẩn
US	Viết tắt cùng nghĩa
U.S.	Viết tắt có dấu chấm
united states	Viết thường

Khi tạo biểu đồ theo quốc gia, Power BI sẽ coi đây là **4 quốc gia khác nhau**, dẫn đến kết quả phân tích sai hoàn toàn. Cùng chuẩn hóa vấn đề này bằng Power Query.

Bước 1: Replace Values

Chọn cột Country-Region trong Data Preview, sau đó vào **Home** → **Replace Values** (hoặc chuột phải → Replace Values). Hộp thoại Replace Values cho phép chúng ta thay thế từng giá trị:

- Value to Find: `US` → Replace With: `United States`
- Value to Find: `U.S.` → Replace With: `United States`

Lặp lại cho mỗi giá trị cần chuẩn hóa. Sau khi thay thế, tất cả các giá trị sẽ thống nhất thành "United States".

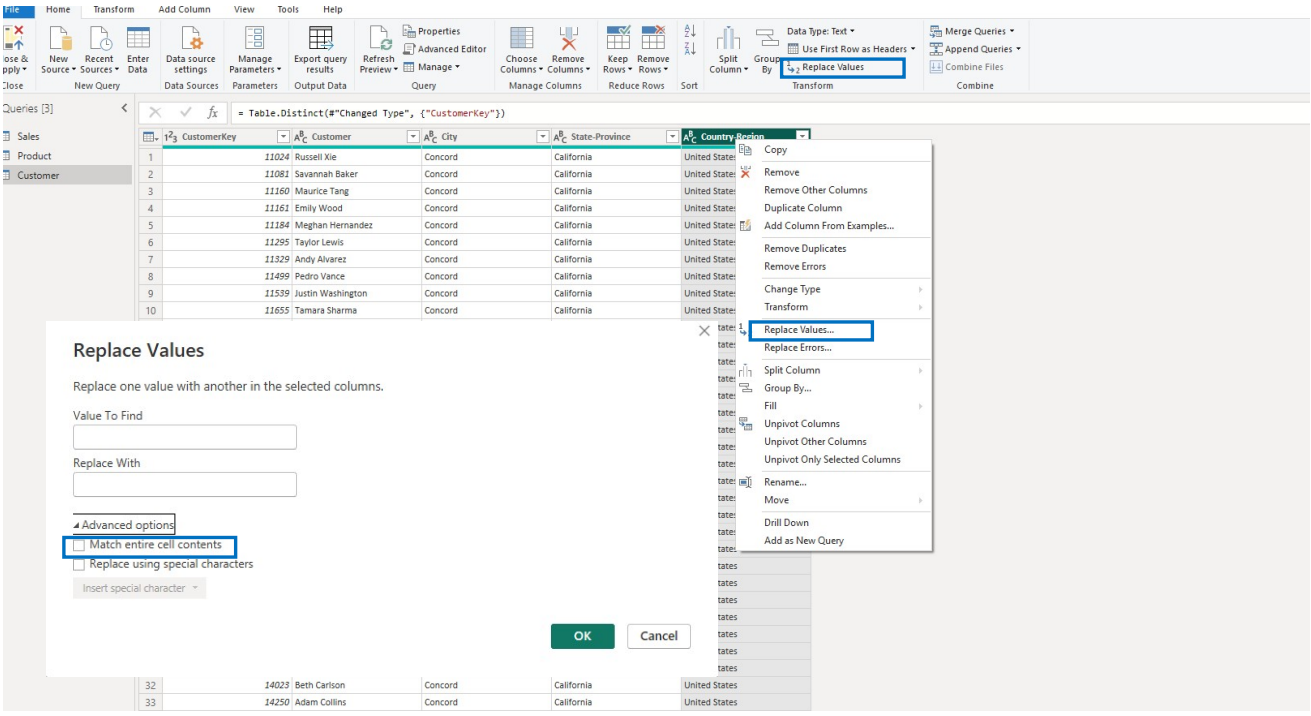

Hình 4: Replace Values và Match Entire Cell Contents.

Lưu ý

Khi Replace Values, hãy mở rộng **Advanced Options** và tick **Match Entire Cell Contents** nếu chỉ muốn thay thế khi **toàn bộ ô** khớp. Không tick tùy chọn này, Power Query sẽ thay thế **một phần:** ví dụ, thay "US" có thể vô tình ảnh hưởng tới giá trị "Australia" (chứa chuỗi con "us").

Bước 2: Trim và Clean

Ngoài biến thể tên gọi, dữ liệu text thường có **khoảng trắng thừa** ở đầu hoặc cuối chuỗi. Ví dụ: `" United States "` (có space ở đầu và cuối) sẽ bị coi là khác với `"United States"`. Để xử lý:

- Chọn cột Country-Region → vào tab **Transform** → **Format** → **Trim:** xóa khoảng trắng đầu/cuối
- Khi cần, dùng **Clean:** xóa các ký tự ẩn không in được (non-printable characters)

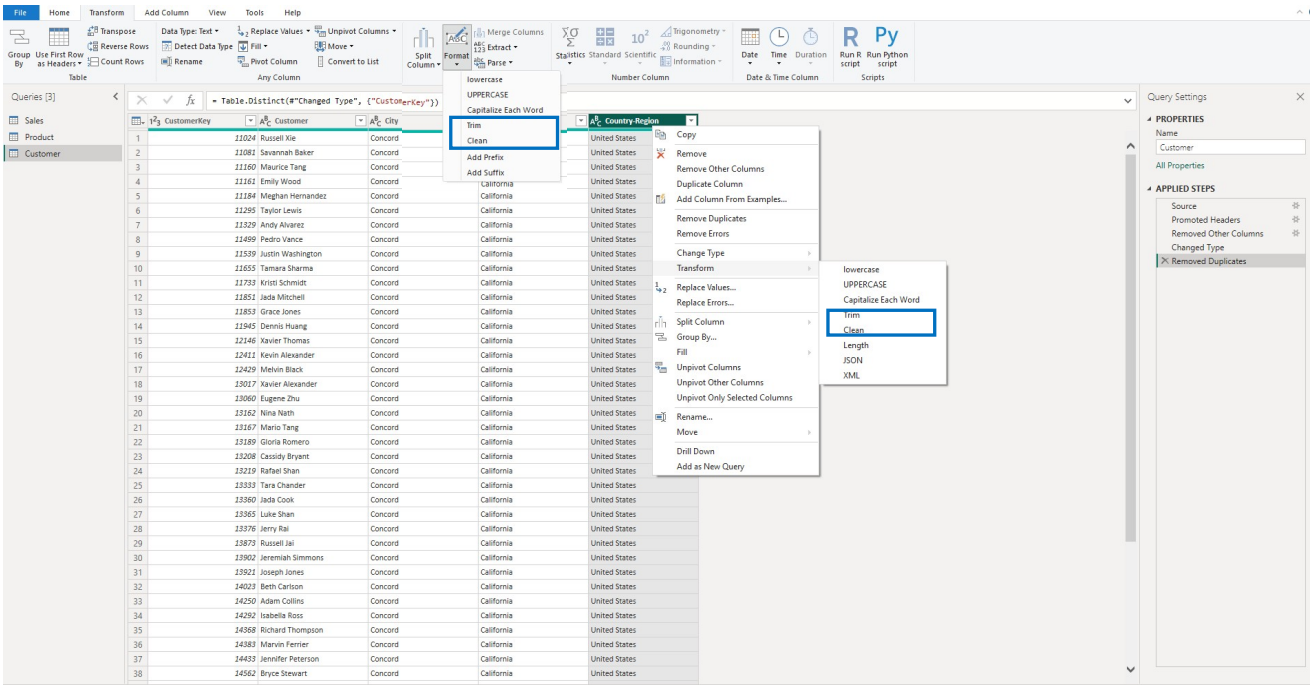

Hình 5: Trim and Clean.

Bước 3: Thống nhất kiểu chữ

Nếu dữ liệu có lẫn chữ hoa/thường ("united states" vs "United States"), chúng ta có thể dùng:

- **Capitalize Each Word:** Viết hoa chữ cái đầu mỗi từ → "united states" thành "United States"

- **UPPERCASE / lowercase:** Chuyển toàn bộ thành chữ hoa hoặc thường

Cách làm chọn cột → tab **Transform** → **Format** → chọn kiểu chữ mong muốn.

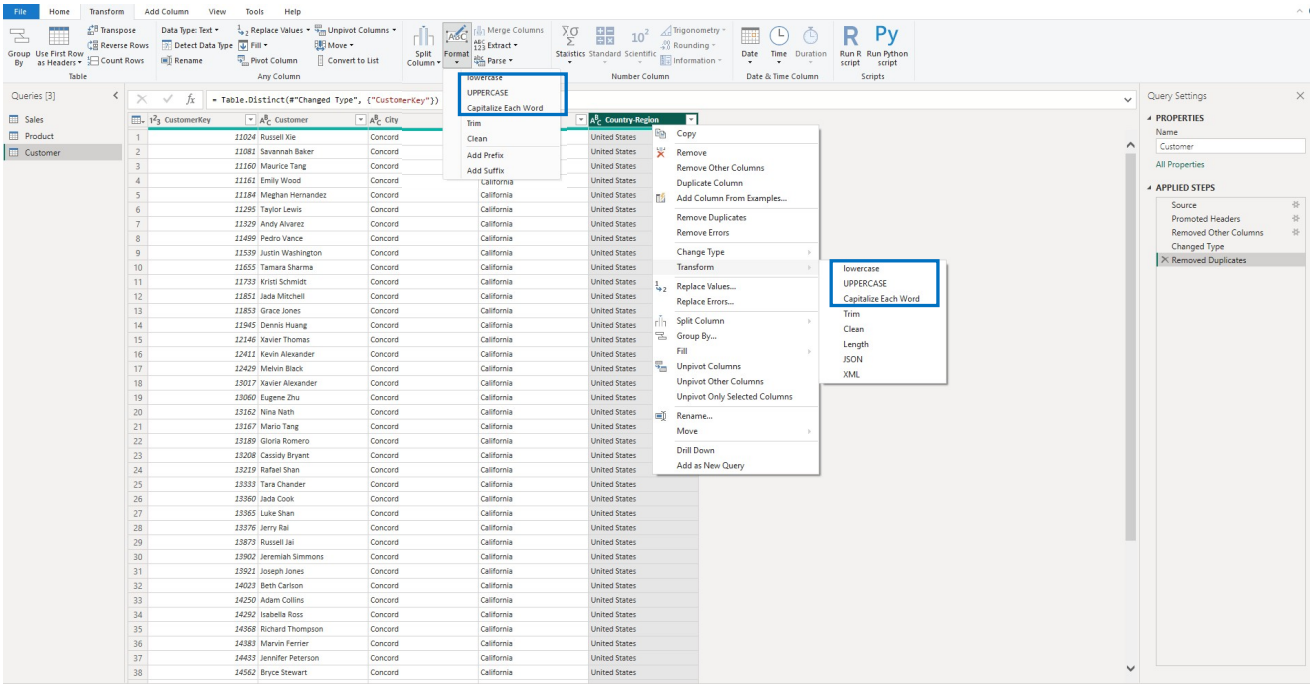

Hình 6: Thống nhất kiểu chữ Capitalize Each Word và UPPERCASE / lowercase.

Mẹo: Lọc không phân biệt hoa/thường

Lưu ý: Power Query **phân biệt hoa/thường** (case-sensitive). Power Query **luôn phân biệt chữ hoa/chữ thường**, trong khi Data Model của Power BI thì **không**.
Nếu cột key có giá trị `"Stock_1"` và `"STOCK_1"`, Power Query coi đây là **2 giá trị khác nhau**, nhưng Data Model coi là **trùng**.
Vì vậy, luôn chuẩn hóa case (Lowercase/Uppercase) **trước khi** Remove Duplicates hoặc tạo Relationship.
Mặc định, khi dùng Text Filters → Contains để lọc "Mountain", Power Query sẽ **bỏ qua các giá trị ghi là** "mountain" (chữ thường).
Để lọc không phân biệt hoa/thường, sửa công thức M trong Formula Bar, thêm `Comparer.OrdinalIgnoreCase` làm tham số thứ ba cho hàm `Text.Contains`:

```
// Phân biệt hoa/thường

Each Text.Contains([Product], "Mountain")

// Không phân biệt hoa/thường

Each Text.Contains([Product], "Mountain", Comparer.OrdinalIgnoreCase
    )
```

Lưu ý

Với dữ liệu lớn, Replace Values từng cái sẽ mất thời gian. Có thể dùng **Merge Queries** để chuẩn hóa hàng loạt, sẽ học ở bài nâng cao.

II.4. Quản lý Rows và Columns

Sau chuẩn hóa text, bước tiếp là **dọn dẹp cấu trúc bảng**: xóa dòng thừa, cột không cần thiết, tách hoặc gộp cột. Power Query cung cấp nhiều công cụ cho việc này.

Xóa dòng thừa (Remove Rows)

Trong tab **Home**, nhóm **Reduce Rows** có các tùy chọn:

- **Remove Top Rows:** Xóa N dòng đầu tiên, hữu ích khi file Excel có tiêu đề phụ hoặc ghi chú ở trên cùng mà không phải header thật.
- **Remove Bottom Rows:** Xóa N dòng cuối, khi file có dòng tổng cộng hoặc ghi chú ở cuối.
- **Remove Blank Rows:** Xóa tất cả các dòng trống, dòng mà toàn bộ các cột đều rỗng.
- **Remove Duplicates:** Xóa các dòng trùng lặp. Mặc định, Power BI so sánh **toàn bộ các cột:** hai dòng phải giống hệt nhau mới bị coi là trùng. Nếu muốn xóa trùng theo **1 cột cụ thể** (VD: chỉ theo CustomerKey), hãy chọn riêng cột đó trước khi bấm Remove Duplicates. Power BI giữ lại dòng **xuất hiện đầu tiên** và xóa các dòng trùng sau đó.
- **Remove Errors:** Xóa các dòng có giá trị lỗi (Error).

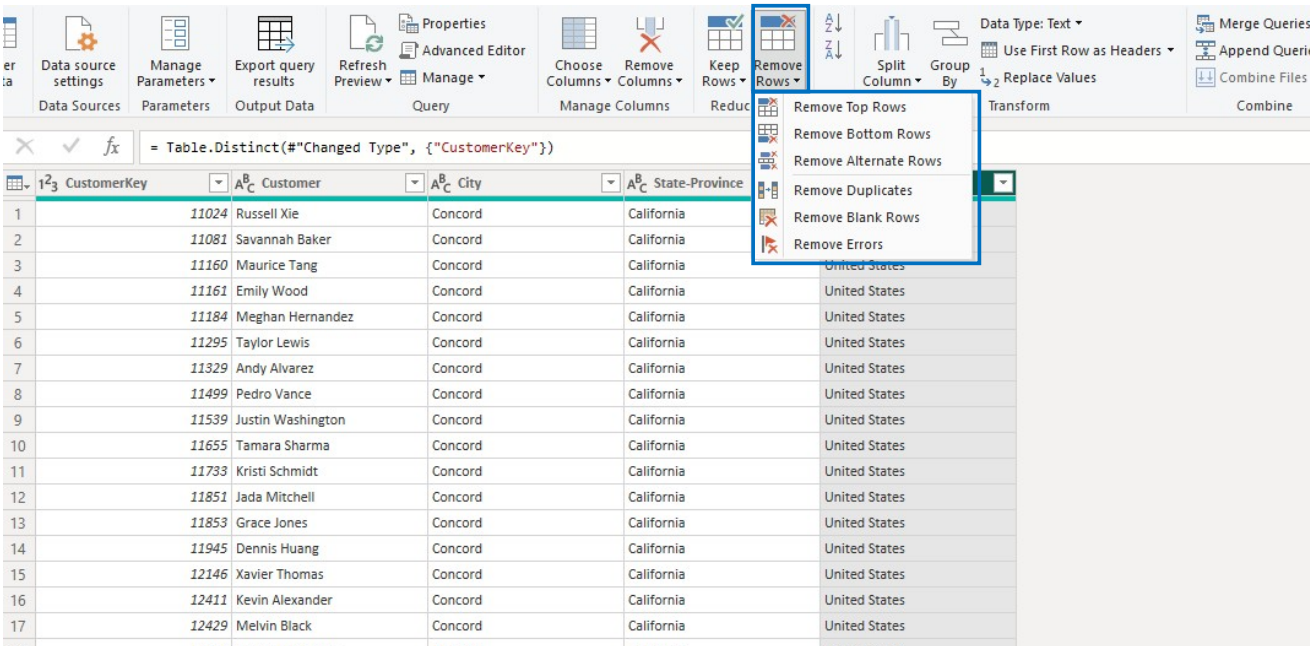

Hình 7: Remove Rows.

Xóa/giữ cột (Remove/Keep Columns)

Không phải cột nào cũng cần thiết cho phân tích. Ví dụ, cột "Ghi chú nội bộ" hay "Mã nhân viên nhập liệu" thường không cần trong report. Có 2 cách tiếp cận:

- **Remove Columns:** Chọn các cột muốn xóa → chuột phải → Remove Columns. Cách này phù hợp khi chỉ cần bỏ vài cột.
- **Choose Columns:** Vào Home → Choose Columns → tick chọn các cột muốn **giữ lại**. Cách này phù hợp hơn khi muốn giữ ít cột và bỏ nhiều cột.

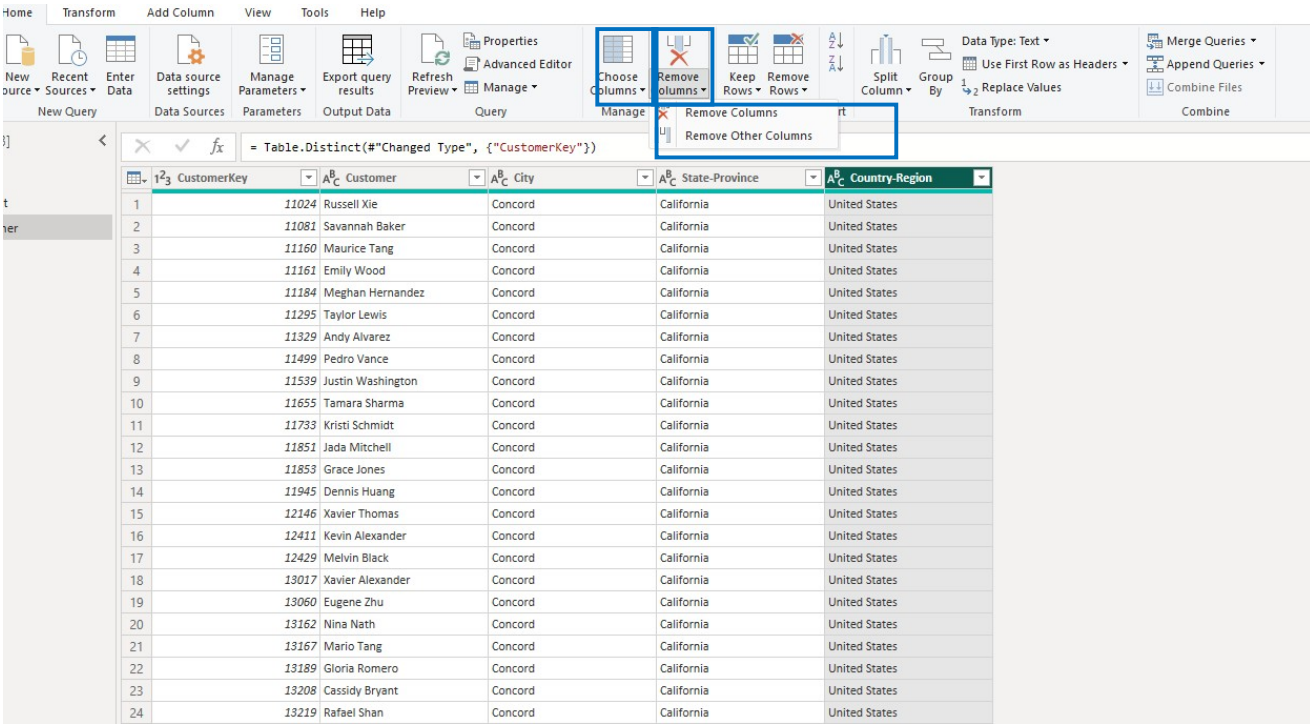

	CustomerKey	Customer	City	State-Province	Country-Region
1	11024	Russell Xie	Concord	California	United States
2	11081	Savannah Baker	Concord	California	United States
3	11160	Maurice Tang	Concord	California	United States
4	11161	Emily Wood	Concord	California	United States
5	11184	Meghan Hernandez	Concord	California	United States
6	11295	Taylor Lewis	Concord	California	United States
7	11329	Andy Alvarez	Concord	California	United States
8	11499	Pedro Vance	Concord	California	United States
9	11539	Justin Washington	Concord	California	United States
10	11655	Tamara Sharma	Concord	California	United States
11	11733	Kristi Schmidt	Concord	California	United States
12	11851	Jada Mitchell	Concord	California	United States
13	11853	Grace Jones	Concord	California	United States
14	11945	Dennis Huang	Concord	California	United States
15	12146	Xavier Thomas	Concord	California	United States
16	12411	Kevin Alexander	Concord	California	United States
17	12429	Melvin Black	Concord	California	United States
18	13017	Xavier Alexander	Concord	California	United States
19	13060	Eugene Zhu	Concord	California	United States
20	13162	Nina Nath	Concord	California	United States
21	13167	Mario Tang	Concord	California	United States
22	13189	Gloria Romero	Concord	California	United States
23	13208	Cassidy Bryant	Concord	California	United States
24	13219	Rafael Shan	Concord	California	United States

Hình 8: Remove/Keep Columns.

Khi xóa hoặc giữ cột, cần lưu ý một số cạm bẫy ẩn mà nhiều người mới hay gặp:

Lưu ý

Mỗi lần dùng Remove Columns, Power Query **hardcode tên cột** vào công thức M. Nếu sau này nguồn dữ liệu **xóa hoặc đổi tên** cột đó, query sẽ **fail khi refresh:** vì Power Query không tìm thấy cột để xóa nữa. **Choose Columns an toàn hơn**: nó chỉ giữ các cột được chọn, tự động bỏ qua cột mới hoặc cột bị xóa từ nguồn.

Promote Headers (Đưa dòng đầu thành tiêu đề)

Đôi khi Power BI không nhận đúng dòng đầu tiên là header. Dữ liệu sẽ có header tự động như "Column1", "Column2"... Để sửa: vào **Home → Use First Row as Headers**. Power Query sẽ lấy giá trị dòng đầu tiên đặt làm tên cột.

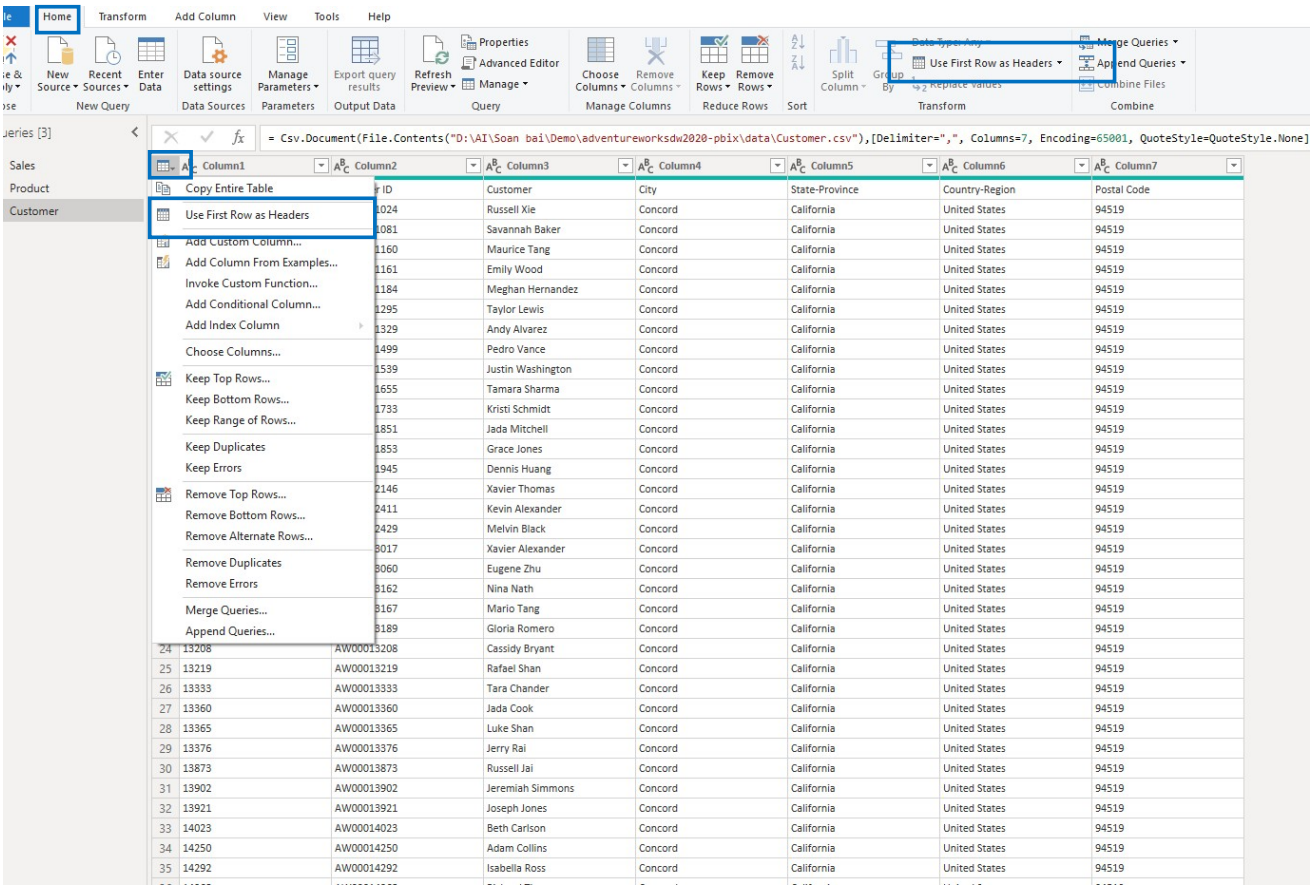

	Column1	Column2	Column3	Column4	Column5	Column6	Column7
	r ID		Customer	City	State-Province	Country-Region	Postal Code
		1024	Russell Xie	Concord	California	United States	94519
		1081	Savannah Baker	Concord	California	United States	94519
		1160	Maurice Tang	Concord	California	United States	94519
		1161	Emily Wood	Concord	California	United States	94519
		1184	Meghan Hernandez	Concord	California	United States	94519
		1295	Taylor Lewis	Concord	California	United States	94519
		1329	Andy Alvarez	Concord	California	United States	94519
		1499	Pedro Vance	Concord	California	United States	94519
		1539	Justin Washington	Concord	California	United States	94519
		1655	Tamara Sharma	Concord	California	United States	94519
		1733	Kristi Schmidt	Concord	California	United States	94519
		1851	Jada Mitchell	Concord	California	United States	94519
		1853	Grace Jones	Concord	California	United States	94519
		1945	Dennis Huang	Concord	California	United States	94519
		2146	Xavier Thomas	Concord	California	United States	94519
		2411	Kevin Alexander	Concord	California	United States	94519
		2429	Melvin Black	Concord	California	United States	94519
		3017	Xavier Alexander	Concord	California	United States	94519
		3060	Eugene Zhu	Concord	California	United States	94519
		3162	Nina Nath	Concord	California	United States	94519
		3167	Mario Tang	Concord	California	United States	94519
		3189	Gloria Romero	Concord	California	United States	94519
24	13208	AW00013208	Cassidy Bryant	Concord	California	United States	94519
25	13219	AW00013219	Rafael Shan	Concord	California	United States	94519
26	13333	AW00013333	Tara Chander	Concord	California	United States	94519
27	13360	AW00013360	Jada Cook	Concord	California	United States	94519
28	13365	AW00013365	Luke Shan	Concord	California	United States	94519
29	13376	AW00013376	Jerry Rai	Concord	California	United States	94519
30	13873	AW00013873	Russell Jai	Concord	California	United States	94519
31	13902	AW00013902	Jeremiah Simmons	Concord	California	United States	94519
32	13921	AW00013921	Joseph Jones	Concord	California	United States	94519
33	14023	AW00014023	Beth Carlson	Concord	California	United States	94519
34	14250	AW00014250	Adam Collins	Concord	California	United States	94519
35	14292	AW00014292	Isabella Ross	Concord	California	United States	94519

Hình 9: Promote Headers: Use First Row as Headers.

Split Column và Merge Columns

Đôi khi cần **tách** hoặc **gộp** cột để phù hợp phân tích:

- **Split Column:** Tách 1 cột thành nhiều cột dựa trên ký tự phân cách. Ví dụ: cột "Full Name" chứa "Jon V. Yang" → tách thành cột "First Name" = "Jon V." và cột "Last Name" = "Yang". Đường dẫn: chọn cột → tab **Home** → **Split Column** → **By Delimiter** → chọn ký tự phân cách (dấu cách, dấu phẩy...).

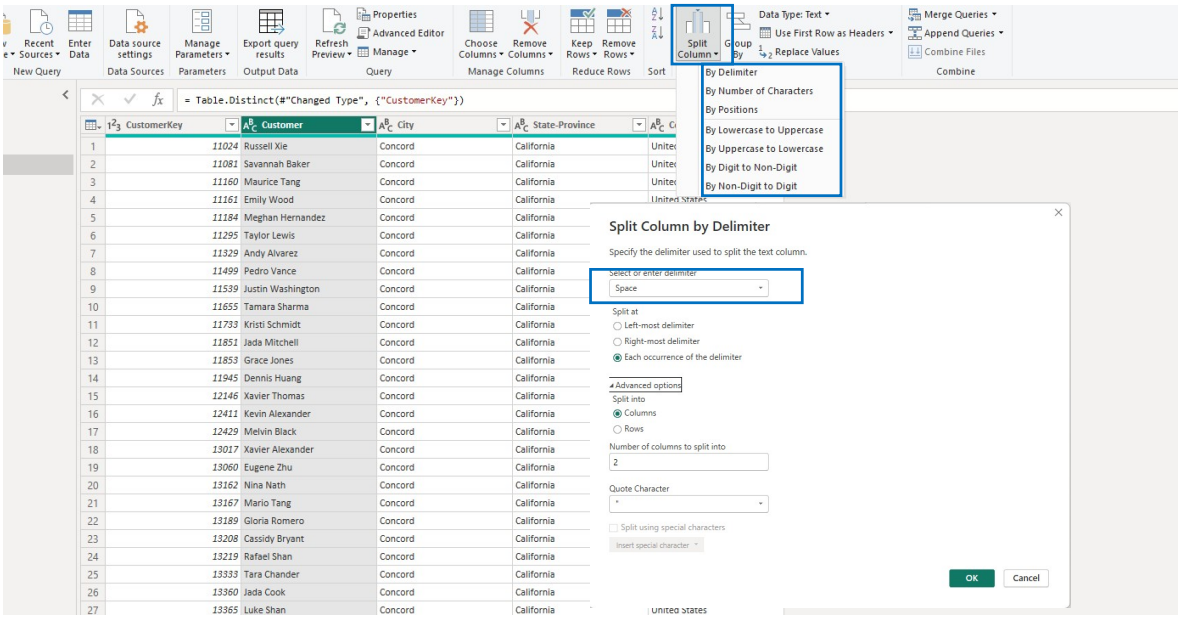

Hình 10: Split Column.

- **Merge Columns:** Gộp nhiều cột thành 1 cột. Ví dụ: gộp cột "City" + "State-Province" thành cột "Full Location" (VD: "Bothell, Washington"). Đường dẫn: chọn nhiều cột (giữ Ctrl) → tab **Transform** → **Merge Columns** → chọn separator.

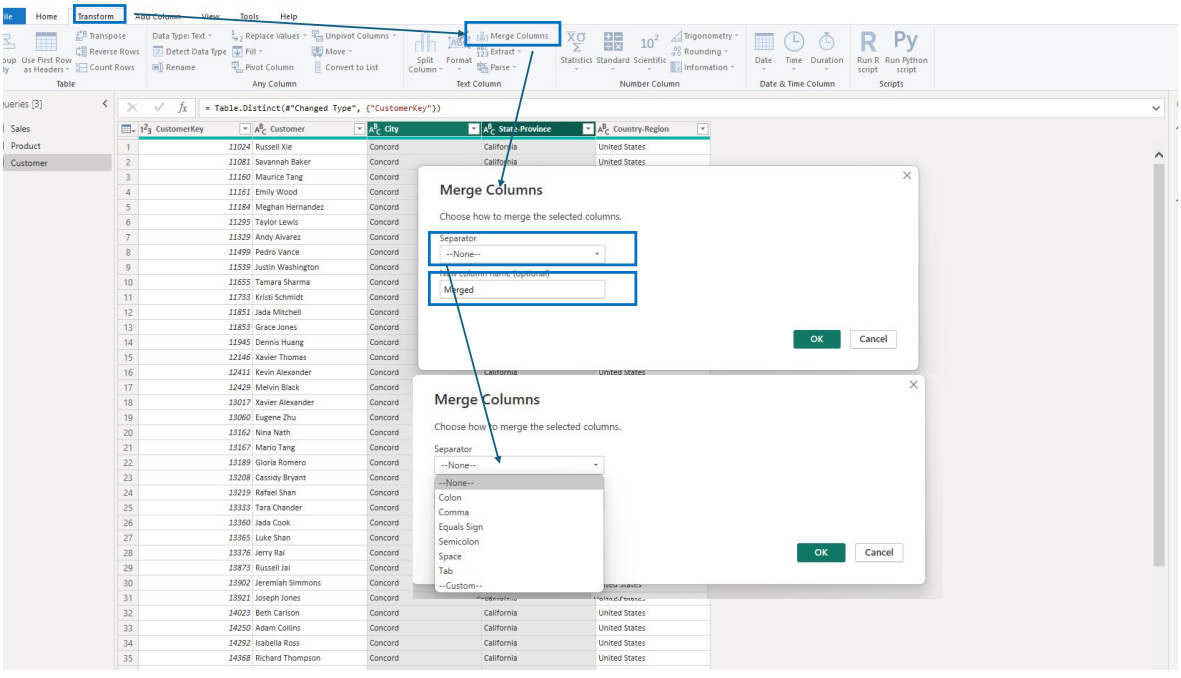

Hình 11: Merge Columns.

Hai thao tác này rất phổ biến khi xử lý dữ liệu từ nhiều nguồn khác nhau. Tuy nhiên, cả Split Column và kéo thả cột đều có những cạm bẫy cần biết:

Lưu ý

Cạm bẫy Split Column: Khi tách cột chứa nhiều giá trị phân cách bằng dấu phẩy (VD: "Red, Blue, Yellow"), tùy chọn mặc định **Split into Columns** sẽ **hardcode số cột** dựa trên dữ liệu hiện tại. Nếu dữ liệu tương lai có nhiều giá trị hơn, các giá trị vượt quá sẽ **biến mất** mà không báo lỗi.

Cách an toàn: Mở **Advanced Options** → chọn **Split into Rows** thay vì Columns. Cách này tạo thêm dòng cho mỗi giá trị, không bị giới hạn số lượng.

Lưu ý

Cạm bẫy kéo thả cột (Column Reordering): Khi kéo thả cột để sắp xếp lại thứ tự, Power Query sinh hàm `Table.ReorderColumns` và **hardcode tên tất cả các cột**. Nếu nguồn dữ liệu thay đổi (đổi tên hoặc xóa cột), query sẽ lỗi khi refresh.

Giải pháp: Hạn chế sắp xếp lại cột. Nếu cần, sửa mã M dùng `List.InsertRange` kết hợp `Table.ColumnNames` để chỉ tham chiếu cột cần di chuyển.

Append Queries vs Merge Queries

Hai phép toán cốt lõi để kết hợp dữ liệu trong Power Query:

Append Queries: Xếp chồng dữ liệu **theo chiều dọc** (thêm dòng). Ví dụ: gộp báo cáo Quý 1 và Quý 2 thành 1 bảng. Nên dùng **Append Queries as New** để tạo query mới, giữ nguyên các query gốc.

Merge Queries: Nối dữ liệu **theo chiều ngang** (thêm cột) dựa trên cột key khớp. Tương tự VLOOKUP trong Excel nhưng mạnh hơn, hỗ trợ nhiều loại Join (Left Outer, Inner, Right Anti...).

Đây là chủ đề nâng cao, sẽ học chi tiết ở các bài sau.

II.5. Change Data Types

Bước cuối cùng trong quy trình cleaning là kiểm tra **data type**. Mỗi cột trong Power BI đều có một **data type** (kiểu dữ liệu) xác định cách Power BI hiểu và xử lý giá trị trong cột đó. Sai data type là một trong những lỗi phổ biến nhất và gây hậu quả nghiêm trọng nhất.

Tại sao data type quan trọng?

Hãy xem ví dụ: cột `Sales Amount` (số tiền bán hàng) bị nhận thành kiểu **Text** thay vì **Number**. Khi đó:

- Không thể tạo measure SUM, AVERAGE trên cột này
- Sắp xếp (sort) sẽ theo thứ tự bảng chữ cái thay vì giá trị số: "9" sẽ đứng sau "80" vì "9" > "8" theo alphabet

- Biểu đồ Bar Chart không thể dùng cột này làm trục giá trị

Các data types thường gặp trong Power BI:

Data Type	Icon	Khi nào dùng	Ví dụ
Whole Number	123	Số nguyên, không phần thập phân	SalesOrderLineKey, Order Quantity
Decimal Number	1.2	Số thực, có phần thập phân	Unit Price, Discount
Currency	$	Giá trị tiền tệ, tự động 4 chữ số thập phân	Amount, Revenue
Percentage	%	Giá trị phần trăm	DiscountRate, GrowthRate
Date	📅	Ngày (không có giờ)	OrderDate, ShipDate
Date/Time	📅🕐	Ngày + giờ	CreatedAt, LoginTime
Text	ABC	Chuỗi ký tự	Product (tên), City
True/False	✔/✘	Giá trị logic	IsActive, HasDiscount

Cách sửa data type trong Power Query:

Có 2 cách thông dụng:

1. **Click icon trên header cột:** Mỗi cột có một icon nhỏ bên cạnh tên cột (ABC cho text, 123 cho number...). Click vào icon → chọn data type phù hợp.
2. **Dùng Transform tab:** Chọn cột → tab **Transform** → **Data Type** → chọn kiểu mong muốn.

Ví dụ với dataset Sales: cột `Sales Amount` đang là Text → click icon → chọn **Currency**. Cột `OrderDate` đang là Text → chọn **Date**.

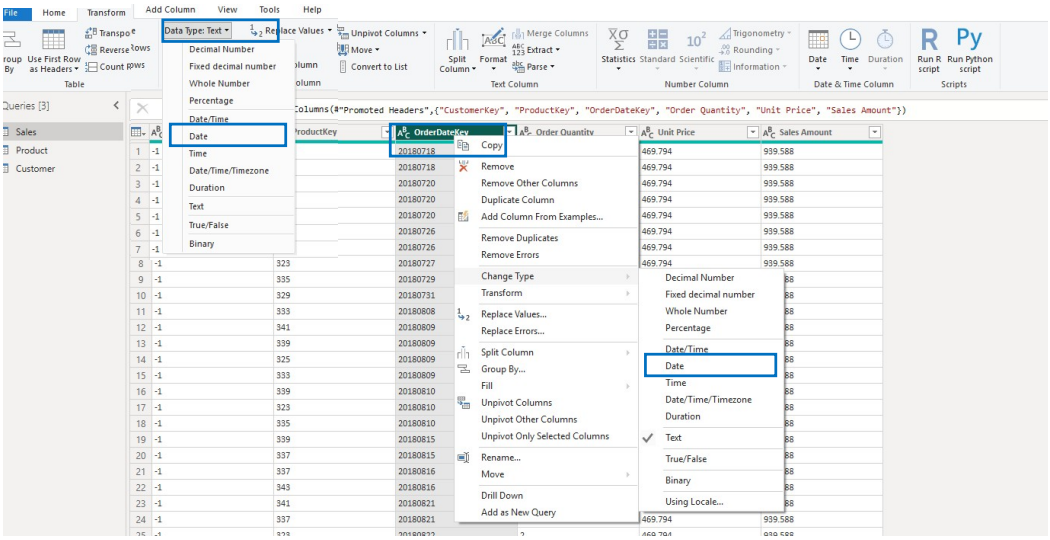

Hình 12: Click icon bên trái tên cột để thay đổi data type, ở đây đổi Sales Amount từ Text sang Currency.

Currency vs Decimal Number

Cả hai đều lưu số có phần thập phân, nhưng **Currency** luôn giữ đúng **4 chữ số thập phân** với độ chính xác cao (fixed decimal). Khi làm việc với tiền tệ, luôn dùng Currency thay vì Decimal để tránh sai số làm tròn.

Ví dụ: `100.1 × 3 = 300.3` (Currency) vs `300.30000000000004` (floating point).

Lưu ý

Rủi ro Changed Type tự động: Khi import dữ liệu, Power Query **tự động thêm step "Changed Type"** vào Applied Steps. Step này hardcode **toàn bộ tên cột** vào công thức M. Nếu nguồn dữ liệu đổi tên hoặc xóa cột, query sẽ **fail khi refresh**. Đây là nguyên nhân #1 gây lỗi.

Cách xử lý:

1. Xóa step Changed Type tự động.
2. Đổi data type **thủ công** cho từng cột cần thiết.
3. Đổi **càng muộn càng tốt**. Đổi type muộn giúp giảm lỗi nếu cột bị xóa, và cải thiện performance.

Tắt hẳn auto-detect: Vào **File** → **Options** → **Current File** → bỏ tick **"Automatically Detect Column Types and Headers for Unstructured Sources"**.

Lưu ý

Locale khác nhau có thể gây lỗi Date: Khi đổi cột Text sang Date, Power Query dùng **locale** mặc định. Nơi dùng "MM/DD/YYYY" (Mỹ) sẽ khác "DD/MM/YYYY" (Anh). Nếu dữ liệu theo locale khác, cần chỉ định locale rõ ràng trong công thức M (VD: `"en-GB"`).

Mẹo: Replace Errors khi đổi data type

Khi đổi cột từ Text sang Number mà có giá trị không chuyển được (VD: "N/A"), Power Query tạo **Error**.

Cách xử lý: Chọn cột → tab **Transform** → **Replace Errors** → nhập `null`. Các ô lỗi sẽ thay bằng giá trị rỗng.

Sau khi hoàn tất tất cả các bước cleaning, nhấn **Home** → **Close & Apply** để đưa dữ liệu đã làm sạch trở lại Power BI Desktop. Các bước transform sẽ được lưu lại và **tự động chạy lại** mỗi khi chúng ta refresh data.

Đây chính là sức mạnh cốt lõi của Power Query: **tự động hóa quy trình chuẩn bị dữ liệu**. đây là **cốt lõi của tự động hóa:** thay vì phải dọn dẹp dữ liệu bằng tay mỗi lần nhận file mới, chỉ cần thiết lập 1 lần trong Power Query, sau đó mọi lần refresh đều tự động áp dụng đúng các bước đã cấu hình.

II.6. Dangerous Filtering

Ngoài 3 kỹ thuật cleaning ở trên, còn một **cạm bẫy ẩn** khi dùng bộ lọc trong Power Query mà nhiều bạn hay mắc phải. Cụ thể: khi click vào filter control rồi **bỏ tick** giá trị muốn loại, cách này tiện nhưng có thể gây lỗi nghiêm trọng mà không dễ phát hiện.

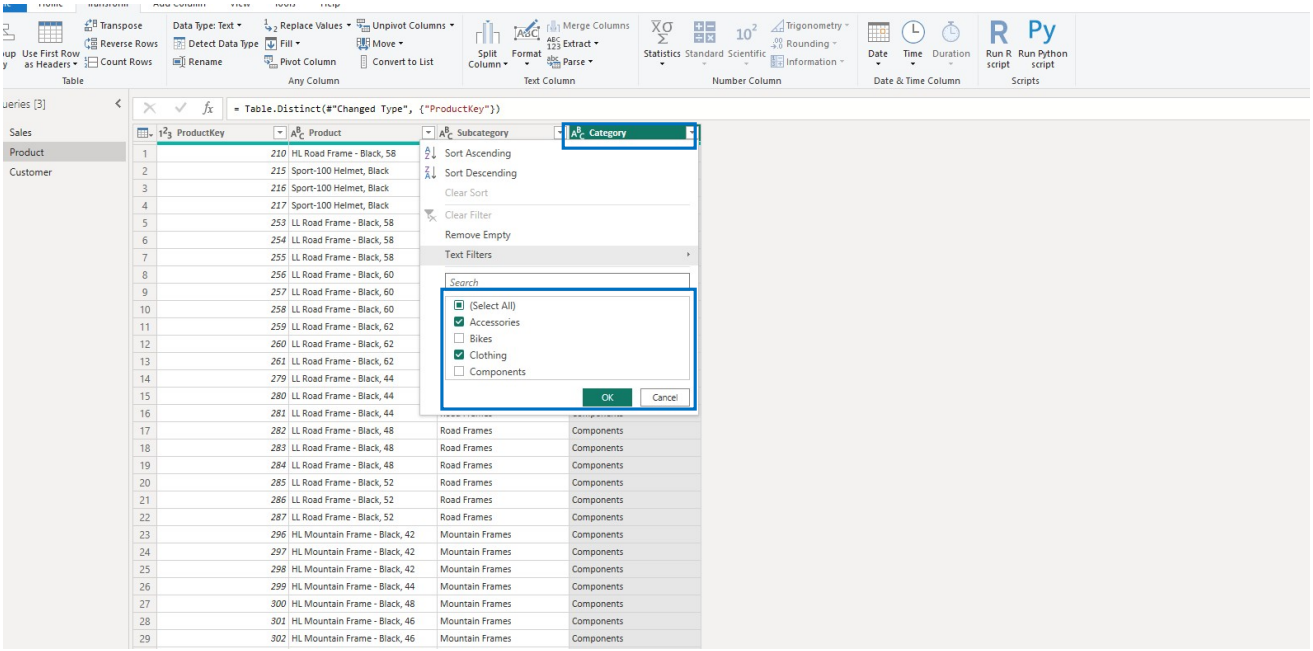

Hình 13: Menu Filtering.

Ví dụ tổng quát dưới đây minh họa cho bất kỳ cột dạng text nào (không riêng dataset mẫu).

Vấn đề: Khi số giá trị được chọn bằng hoặc ít hơn số giá trị bị bỏ chọn, Power Query tạo **điều kiện dương** (positive condition), liệt kê cụ thể các giá trị được giữ lại. Ví dụ, bỏ tick "Đen" trong danh sách 6 màu, Power Query có thể tạo:

```
// X Nguy hiểm: chỉ giữ 5 giá trị cụ thể
= Table.SelectRows(... each [Color] = "Xanh" or [Color] = "Đỏ" or...)
```

Nếu tương lai dữ liệu có thêm màu "Vàng" hoặc "Tím", những màu mới này **tự động bị lọc ra** vì không nằm trong danh sách!

Cách an toàn: Thay vì bỏ tick trong Filter pane, hãy dùng **Text Filters** → **Does Not Equal** → nhập giá trị muốn loại ("Đen"). Power Query sẽ tạo **điều kiện âm** (negative condition):

```
// \faCheck An toàn: loại trừ đúng giá trị không muốn
= Table.SelectRows(... each [Color] <> "Đen")
```

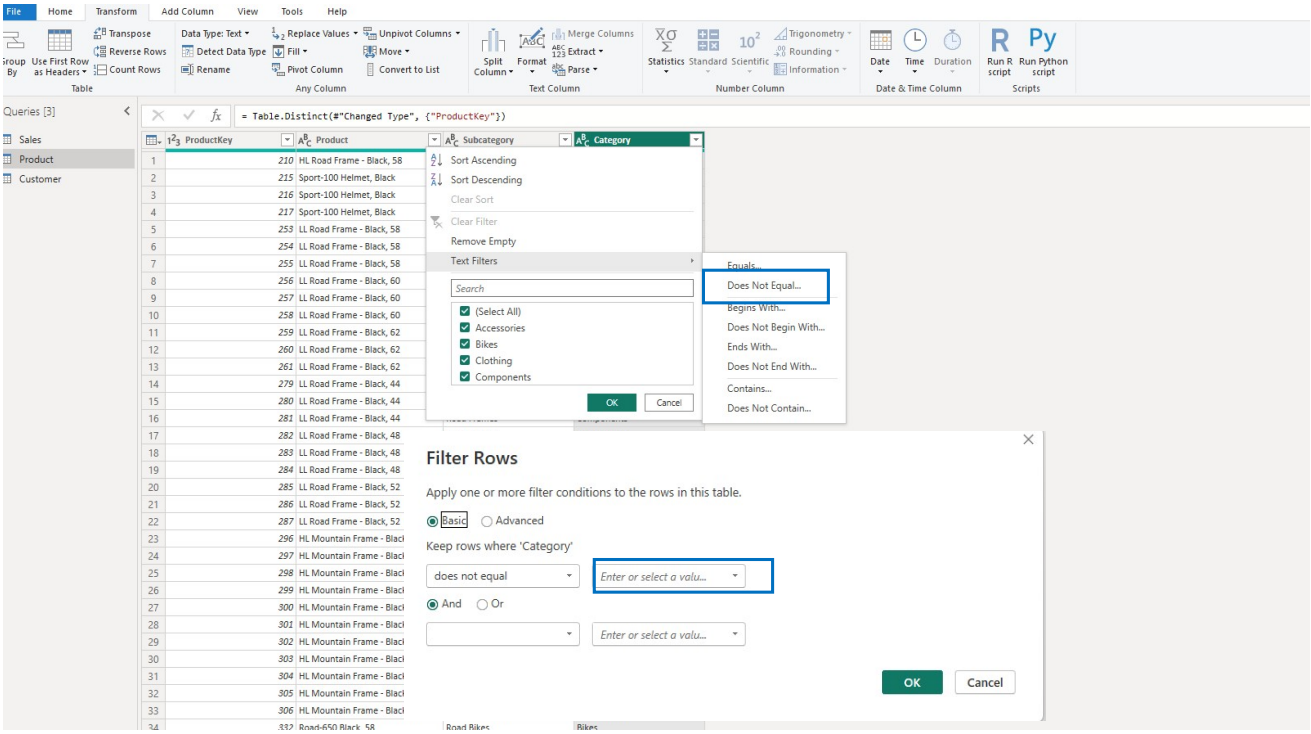

Hình 14: Does Not Equal

Giá trị mới trong tương lai sẽ **tự động được giữ lại:** đúng với ý định ban đầu.

III. Dimensional Modeling: Star Schema

Nhìn lại pipeline ở Hình 10: dữ liệu đã đi qua bước 1 (Power Query: làm sạch). Giờ chúng ta sang bước 2: **tổ chức dữ liệu theo Star Schema**. Nếu bước 1 trả lời *Dữ liệu có sạch không?*, bước 2 trả lời *Dữ liệu được sắp xếp thế nào?*.

III.1. Tại sao cần tổ chức dữ liệu?

Sau khi làm sạch, bước tiếp theo là **tổ chức** dữ liệu. Nhiều bạn mới bắt đầu thường để tất cả trong **một bảng duy nhất** (flat table): tên khách hàng, tên sản phẩm, ngày mua, số tiền, tất cả gom vào một chỗ. Cách này tuy đơn giản nhưng gây nhiều vấn đề:

- **Dữ liệu lặp lại:** Khách hàng "Jon V. Yang" mua 100 đơn hàng → tên, địa chỉ, quốc gia của anh ấy bị lặp 100 lần.
- **File phình to:** Dữ liệu lặp làm bảng nặng hơn nhiều lần so với cần thiết.
- **Khó bảo trì:** Nếu khách hàng đổi địa chỉ, phải sửa ở tất cả 100 dòng.
- **Hiệu năng kém:** Power BI phải xử lý nhiều dữ liệu trùng lặp, làm report chậm.
- **Tốn bộ nhớ:** Power BI nén dữ liệu theo cột, cột có nhiều giá trị lặp lại sẽ được nén tốt. Nhưng flat table làm giảm hiệu quả nén, tăng kích thước model.

Có hai cách tiếp cận để xử lý vấn đề này:

Cách 1: Giữ nguyên flat table, dùng DAX tính toán. Hoàn toàn có thể giữ tất cả dữ liệu trong một bảng rồi dùng DAX (SUMX, CALCULATE, FILTER...) để tính toán. Cách này đơn giản khi bắt đầu, nhưng khi dữ liệu lớn lên, report chậm dần, công thức DAX phức tạp, và bảo trì khó khăn.

Cách 2: Tổ chức lại thành nhiều bảng theo Star Schema. Tách flat table thành các bảng nhỏ, mỗi bảng có vai trò rõ ràng, liên kết qua key columns.

Trong bài này, chúng ta sẽ đi theo **Cách 2** vì Power BI được thiết kế và tối ưu hóa cho Star Schema. Cụ thể:

- **Engine VertiPaq** (bộ máy xử lý bên trong Power BI) nén dữ liệu theo cột. Dimension table nhỏ, ít giá trị lặp → nén cực tốt, giảm RAM đáng kể.
- **Relationships tự động lọc:** Khi chọn "United States" trên Slicer, Power BI tự động lọc bảng Sales qua relationship, không cần viết DAX phức tạp.
- **DAX đơn giản hơn:** `SUM(Sales[Sales Amount])` đã đủ, thay vì phải viết `CALCULATE(SUM(...), FILTER(...))` trên flat table.
- **Microsoft khuyến khích:** Tất cả tài liệu chính thức, mẫu dataset (bao gồm Adventure Works) đều dùng Star Schema.

Vậy **Star Schema** (**Lược đồ hình sao**) là gì? Đó là cách tổ chức dữ liệu thành nhiều bảng nhỏ, liên kết với nhau qua key columns. Khi vẽ sơ đồ, cấu trúc này trông như một ngôi sao, bảng chính ở giữa, các bảng phụ bao quanh.

Star Schema vs Snowflake Schema

Ngoài Star Schema, bạn có thể nghe đến **Snowflake Schema:** tương tự nhưng các Dimension table được **tách nhỏ thêm** (normalize). Ví dụ: thay vì Product chứa cả Category và Subcategory, sẽ tách thêm bảng Category riêng. Tuy nhiên, theo hướng dẫn của Microsoft, **Star Schema được khuyến khích hơn** cho Power BI vì đơn giản và hiệu năng tốt hơn.

III.2. Fact Table vs Dimension Table

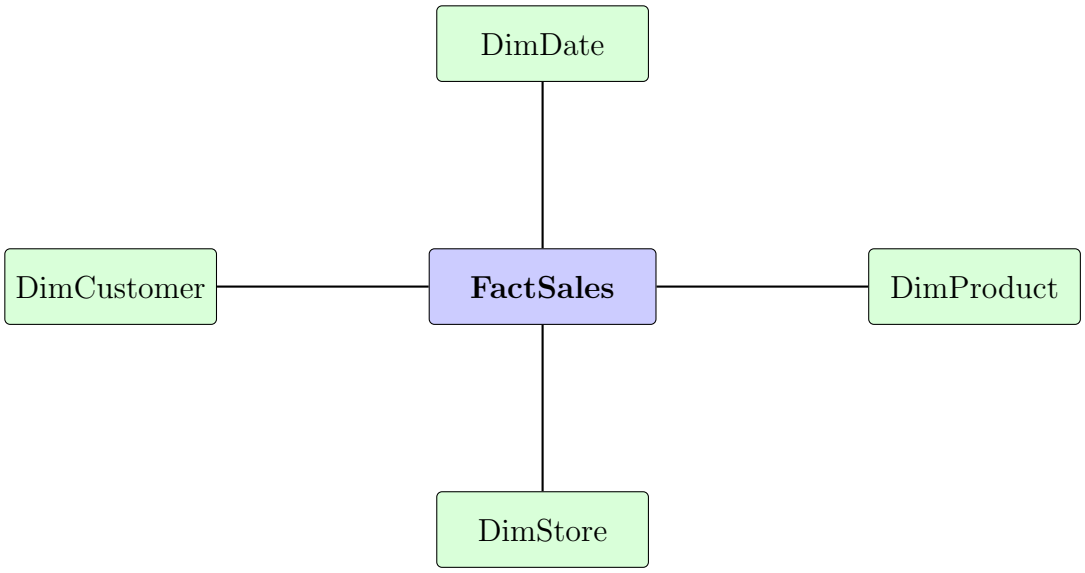

Star Schema gồm 2 loại bảng chính:

Fact Table (**Bảng dữ kiện**) là bảng trung tâm, chứa dữ liệu **giao dịch:** những sự kiện xảy ra trong hoạt động kinh doanh. Mỗi dòng tương ứng với **một giao dịch cụ thể**: một đơn hàng, một lần thanh toán, một lần giao hàng. Bảng này chứa chủ yếu là **số liệu** (measures) mà chúng ta muốn phân tích: số tiền, số lượng, chi phí...

Dimension Table (**Bảng chiều**) là các bảng xung quanh, chứa thông tin **mô tả:** trả lời các câu hỏi "ai?", "cái gì?", "ở đâu?", "khi nào?" cho mỗi giao dịch. Ví dụ: khách hàng nào mua (Customer), sản phẩm nào được bán (Product), vào ngày nào (Date).

Bảng dưới đây tóm tắt sự khác biệt:

Đặc điểm	Fact Table	Dimension Table
Chứa	Số liệu, Order Quantity, Sales Amount, Unit Price	Mô tả, Product (tên), City, MonthName
Số dòng	Rất nhiều (hàng nghìn → hàng triệu)	Ít hơn (hàng chục → hàng trăm)
Số cột	Ít cột (keys + measures)	Nhiều cột (các thông tin mô tả)
Thay đổi	Liên tục (mỗi giao dịch mới = 1 dòng mới)	Ít thay đổi (sản phẩm, khách hàng ổn định)
Vai trò	Đo lường, tổng hợp (SUM, AVG...)	Lọc, nhóm, phân loại

Granularity (Mức chi tiết)

Granularity nói đến mức chi tiết mà mỗi dòng trong Fact table thể hiện. Ví dụ: mỗi dòng là **1 đơn hàng** (order-level) hay **1 sản phẩm trong đơn hàng** (line item-level)? Trong dataset mẫu, mỗi dòng trong `Sales` là một line item, tức một sản phẩm cụ thể trong một đơn hàng. *"Remember the grain of your report, you can't report on anything lower than your grain."* Nếu Fact table lưu theo **tháng**, bạn **không thể** drill-down xuống từng **ngày**. Vì vậy, nên lưu dữ liệu ở mức chi tiết nhất có thể.

III.3. Thiết kế Star Schema cho dataset mẫu

Áp dụng cho bộ dữ liệu bán hàng, chúng ta sẽ tập trung vào **4 bảng chính** trong Adventure Works (dataset đầy đủ có 7 bảng, 3 bảng còn lại sẽ giới thiệu ở cuối section).

Trong thực tế, có 2 cách phổ biến để có được các bảng riêng biệt:

- **Cách 1 (khuyến khích cho người mới):** Chuẩn bị sẵn trong Excel, mỗi **sheet** là một bảng (Sheet "Sales", Sheet "Product"...) rồi import tất cả vào Power BI.
- **Cách 2 (nâng cao hơn):** Import 1 flat table, sau đó trong Power Query, dùng **Reference** (chuột phải vào query → Reference) để tạo bản phân nhánh, rồi **Choose Columns** để chỉ giữ các cột cần thiết cho mỗi bảng, và **Remove Duplicates** để đảm bảo mỗi dòng là duy nhất trong Dimension table.

Reference Query vs Duplicate Query

Reference tạo một query mới phân nhánh từ kết quả cuối của query gốc. Cách làm cụ thể:

1. Chuột phải query gốc → **Reference** → đặt tên (VD: "Product").
2. Trong query mới, dùng **Choose Columns** để chỉ giữ các cột mô tả (ProductKey, Product, Category...).
3. Chọn cột key → **Remove Duplicates** → hoàn thành Dimension table.
4. Tương tự, Reference lần nữa từ query gốc để tạo Fact table, chỉ giữ cột giao dịch và key.

Ưu điểm: Chỉ **đọc file nguồn 1 lần**, tất cả các bảng đều nhánh ra từ đó, tiết kiệm thời gian refresh.

So sánh Reference vs Duplicate: Khác với Reference, **Duplicate** tạo bản sao **độc lập hoàn toàn**, không kế thừa thay đổi từ query gốc. Dùng Duplicate khi muốn **thử nghiệm** mà không ảnh hưởng query gốc; dùng Reference khi muốn **tạo pipeline** từ cùng một nguồn.

Dưới đây là chi tiết từng bảng:

Sales (Fact Table, nên đổi tên thành FactSales):

Cột	Kiểu	Mô tả
SalesOrderLineKey	Whole Number	Mã đơn hàng
OrderDate	Date	Ngày đặt hàng
ProductKey	Whole Number	Mã sản phẩm (key → Product)
CustomerKey	Whole Number	Mã khách hàng (key → Customer)
Order Quantity	Whole Number	Số lượng mua
Unit Price	Currency	Đơn giá
Sales Amount	Currency	Thành tiền (= Order Quantity × Unit Price)

Product (Dim Table, nên đổi tên thành DimProduct):

Cột	Kiểu	Mô tả
ProductKey	Whole Number	Mã sản phẩm (khóa chính)
Product (tên)	Text	Tên sản phẩm
Category	Text	Danh mục (Bikes, Components, Clothing, Accessories)
Subcategory	Text	Danh mục con (Road Bikes, Mountain Bikes, Helmets...)

Customer (Dim Table, nên đổi tên thành DimCustomer):

Cột	Kiểu	Mô tả
CustomerKey	Whole Number	Mã khách hàng (khóa chính)
Customer	Text	Tên khách hàng
City	Text	Thành phố (Bothell, Seattle, London...)
State-Province	Text	Bang/Tỉnh (Washington, New South Wales...)
Country-Region	Text	Quốc gia (United States, Australia, Canada...)

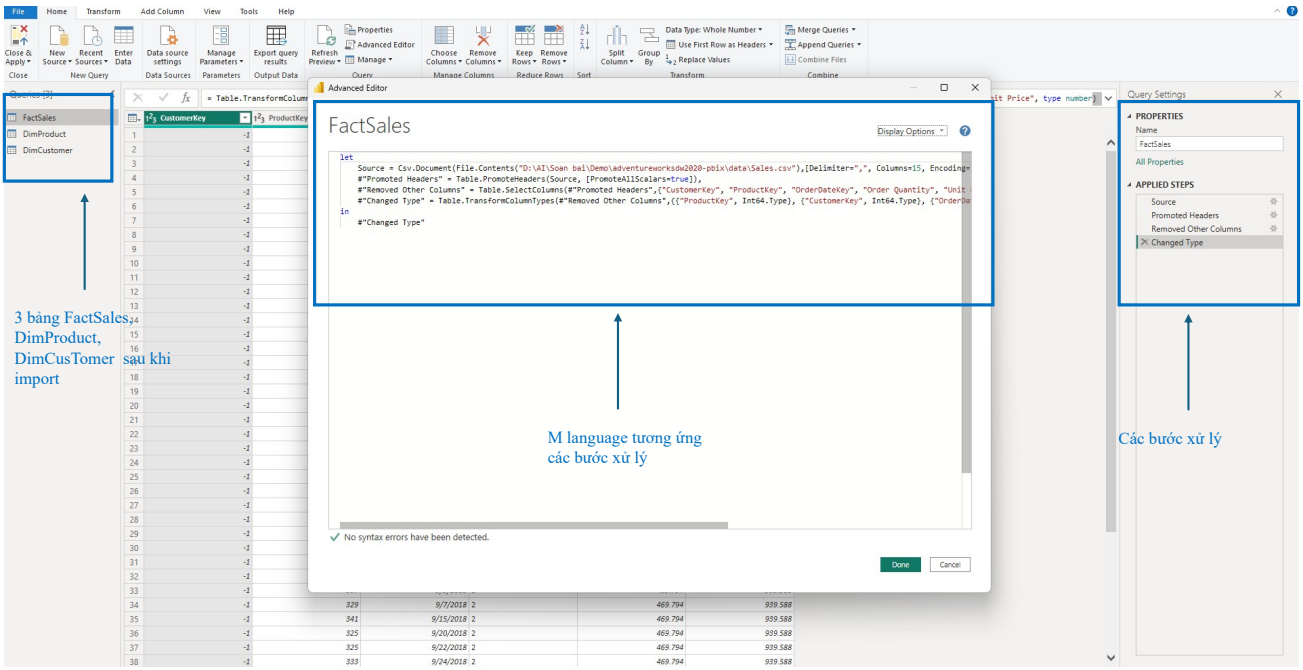

Hình 15: Clean data cho ba bảng FactSales, DimProduct, DimCustomer.

Date (Dim Table, tạo ra đặt tên DimDae):

Cột	Kiểu	Mô tả
Date	Date	Ngày (khóa chính)
Month	Whole Number	Tháng (1-12)
MonthKey	Whole Number	Key tháng (VD: 202301 = tháng 1/2023)
Fiscal Quarter	Text	Quý tài chính (FQ1, FQ2, FQ3, FQ4)
Fiscal Year	Text	Năm tài chính (FY2020, FY2021...)
Full Date	Date	Ngày đầy đủ (hiển thị định dạng dài)

Bước 1: Vào **Home** → **New Table**, gõ:

```
DimDate = CALENDARAUTO()
```

Power BI sẽ tự tạo bảng chứa 1 cột `Date` với danh sách ngày bao phủ toàn bộ khoảng thời gian trong dataset.

Bước 2: Thêm các cột mô tả bằng **Calculated Columns**. Chọn bảng `Date` → **New Column** → gõ lần lượt:

```
Year = YEAR(DimDate[Date])
```

```
Quarter = "Q" & QUARTER(DimDate[Date])
```

```
Month = MONTH(DimDate[Date])
```

```
lstlisting = FORMAT(DimDate[Date], "MMMM")
```

```
DayOfWeek = FORMAT(Date[Date], "dddd")
```

Sau 5 lần New Column, bảng `Date` đã hoàn chỉnh với đầy đủ Year, Quarter, Month, MonthName, DayOfWeek, sẵn sàng tạo relationship với `Sales[OrderDateKey]`.

3 bảng còn lại trong Adventure Works

Ngoài 4 bảng chính trên, dataset Adventure Works DW 2020 còn có 3 bảng phụ:

Bảng	Vai trò	Các cột chính	Ghi chú
Sales Territory	Dimension	Region, Country, Group	Phân vùng bán hàng (VD: Northwest, Europe)
Reseller	Dimension	Reseller, Business Type, City, Country-Region	Đại lý phân phối sản phẩm
Sales Order	Dimension	Sales Order, Channel	Thông tin kênh bán (Internet vs Reseller)

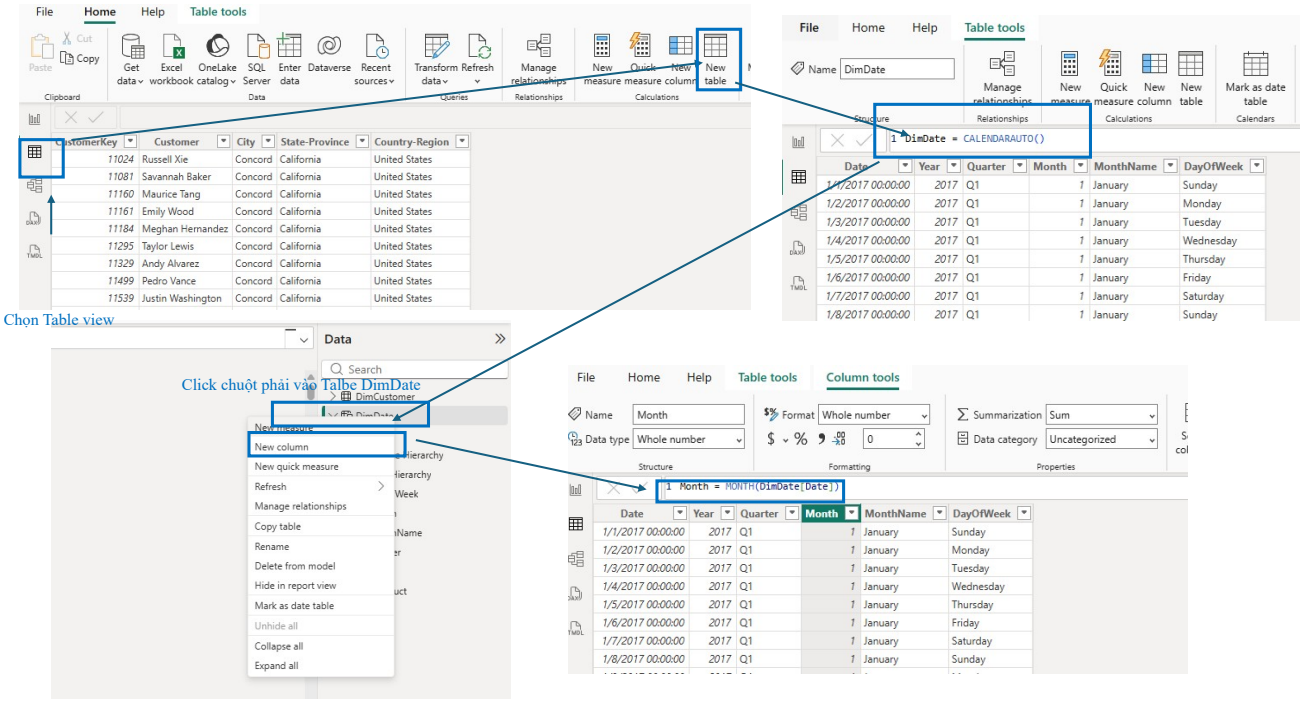

Hình 16: Các bước tạo bảng Dimdate.

Các bảng này liên kết với `Sales` qua các key tương ứng (`SalesTerritoryKey`, `ResellerKey`, `SalesOrderLineKey`). Trong bài này, chúng ta tập trung vào 4 bảng chính để nắm vững nền tảng, các bài sau sẽ khai thác thêm các bảng còn lại.

Khi biểu diễn trong **Model View** của Power BI, sơ đồ sẽ trông như thế này:

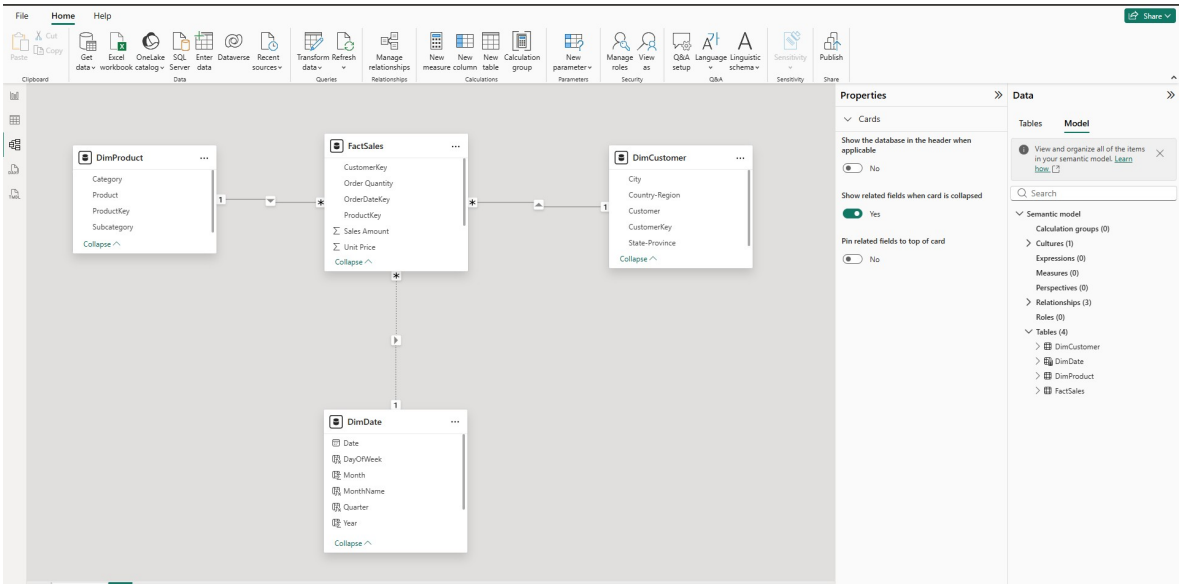

Hình 17: Star Schema cho dataset bán hàng, Sales ở trung tâm, 3 Dimension tables bao quanh. Mũi tên chỉ hướng quan hệ 1(Dim) → ∞(Fact).

Trong sơ đồ này, `Sales` nằm ở trung tâm và kết nối với 3 bảng Dimension qua các key columns: `ProductKey`, `CustomerKey`, và `OrderDate`. Mỗi Dimension table chứa **1 dòng duy nhất** cho mỗi giá trị key (1 ProductKey = 1 sản phẩm), trong khi Fact table có thể có **nhiều dòng** cùng ProductKey (nhiều đơn hàng chứa cùng 1 sản phẩm).

Mẹo: Ẩn key columns trong Fact table

Sau khi tạo relationships, nên **ẩn các cột key** (ProductKey, CustomerKey) trong `Sales` khỏi Report View.

Cách làm: Trong Data Model → chọn Table→ Column cần ẩn, Chuột phải cột → **Hide in report view**.

Lý do: Người dùng report nên lọc bằng tên mô tả (cột `Product` trong bảng Product, cột `Customer` trong bảng Customer) từ Dimension table, không phải bằng mã số. Ẩn key giúp report **gọn gàng hơn** và tránh nhầm lẫn.

Lưu ý: Trong Adventure Works, cột tên sản phẩm và tên khách hàng trùng tên với bảng chứa nó: `Product[Product]`, `Customer[Customer]`. *DAX phân biệt chúng bằng cú pháp* `Bảng[Cột]` *nên không nhầm.*

IV. Establishing Data Relationships

Bước 3 trong pipeline: sau khi đã tách dữ liệu thành Fact + Dimension (bước 2), giờ cần **kết nối** chúng lại. Không có relationship, các bảng chỉ là những thông tin rời rạc, không thể tương tác với nhau trên report.

IV.1. Relationship là gì?

Sau khi đã có các bảng Fact và Dimension, chúng ta cần nói cho Power BI biết chúng **liên quan đến nhau như thế nào**. Đây chính là bước tạo **Relationships** (quan hệ) giữa các bảng.

Mỗi relationship kết nối 2 bảng qua một **key column** chung. Ví dụ: cột `ProductKey` trong `Sales` liên kết với cột `ProductKey` trong `Product`. Nhờ quan hệ này, khi chúng ta lọc theo Category = "Bikes" trong `Product`, Power BI sẽ tự động chỉ hiển thị các đơn hàng liên quan trong `Sales`.

Mỗi relationship có 2 thuộc tính quan trọng:

Cardinality: xác định mỗi dòng bên này liên kết với bao nhiêu dòng bên kia:

Kiểu	Ý nghĩa	Ví dụ
One-to-Many (1:∞)	1 dòng bên Dim → nhiều dòng bên Fact	1 sản phẩm → nhiều đơn hàng
One-to-One (1:1)	1 dòng ↔ 1 dòng	Ít gặp trong thực tế
Many-to-Many (∞:∞)	Nhiều ↔ nhiều	Cần cẩn thận, nên tránh nếu có thể

Trong Star Schema, hầu hết mọi relationship đều là **One-to-Many**: 1 bên Dimension (one) → nhiều bên Fact (many). Đây là kiểu quan hệ "lý tưởng" trong Power BI.

Cross-filter Direction (Hướng lọc chéo), xác định bộ lọc truyền theo hướng nào:

- **Single (Một chiều):** Bộ lọc chỉ truyền từ Dimension → Fact . Đây là mặc định và **nên giữ nguyên** trong hầu hết trường hợp.
- **Both (Hai chiều):** Bộ lọc truyền cả 2 hướng, Dimension lọc Fact **và** Fact cũng lọc ngược lại Dimension. Chỉ dùng trong trường hợp đặc biệt.

Lưu ý

đặt tất cả relationships sang Both có thể gây **giảm hiệu năng**, tạo **sự mơ hồ** trong model, và thậm chí gây **circular dependency** (phụ thuộc vòng tròn), Chỉ dùng Both khi thực sự cần, ví dụ: muốn biết "sản phẩm nào đã bán ở vùng nào" (cần filter từ Region → Sales → Product). **Khái niệm: Filter Propagation (Lan truyền bộ lọc)** Khi người dùng chọn một Slicer (ví dụ: Country-Region = "United States"), bộ lọc sẽ **truyền** từ `Customer` sang `Sales` qua relationship. Kết quả: chỉ có các giao dịch của khách hàng Mỹ được hiển thị trong biểu đồ. Đây là cơ chế cốt

lõi giúp các bảng "nói chuyện" với nhau.

IV.2. Tạo Relationships trong Power BI

Power BI cung cấp 3 cách để tạo relationships. Chuyển sang **Model View** bằng cách click icon thứ 3 ở thanh bên trái (hoặc View → Model View).

Cách 1: Autodetect

Khi chúng ta import nhiều bảng cùng lúc, Power BI sẽ **tự động** tìm các cột có tên giống nhau và tạo relationship. Ví dụ: nếu cả `Sales` và `Product` đều có cột `ProductKey`, Power BI sẽ tự tạo relationship giữa chúng.

Tuy nhiên, autodetect không phải lúc nào cũng chính xác. Luôn kiểm tra lại trong Model View. Nếu muốn chạy lại autodetect: vào **Home** → **Manage Relationships** → **Autodetect**.

Cách 2: Drag-and-Drop trong Model View

Đây là cách **trực quan nhất** và được khuyến khích:

1. Mở **Model View:** các bảng hiển thị dưới dạng các hộp chứa tên cột.
2. Click vào cột `ProductKey` trong bảng `Sales`.
3. **Kéo** (drag) sang cột `ProductKey` trong bảng `Product`.
4. Thả chuột, Power BI tự tạo relationship với đường kẻ nối 2 bảng.

Lặp lại cho các cặp:

- `Sales[CustomerKey]` ↔ `Customer[CustomerKey]`
- `Sales[OrderDate]` ↔ `Date[Date]`

Cách 3: Manage Relationships Dialog

Nếu muốn kiểm soát chi tiết hơn:

1. Vào **Home** → **Manage Relationships** → **New...**
2. Chọn bảng thứ nhất: `Sales` → chọn cột `ProductKey`
3. Chọn bảng thứ hai: `Product` → chọn cột `ProductKey`
4. Power BI tự nhận Cardinality (Many→One) và Cross-filter (Single)
5. Tick "Make this relationship active" → OK

Sau khi tạo đủ relationships, Model View sẽ hiển thị các bảng kết nối với nhau bằng đường kẻ, giống hệt sơ đồ Star Schema mà chúng ta đã thiết kế.

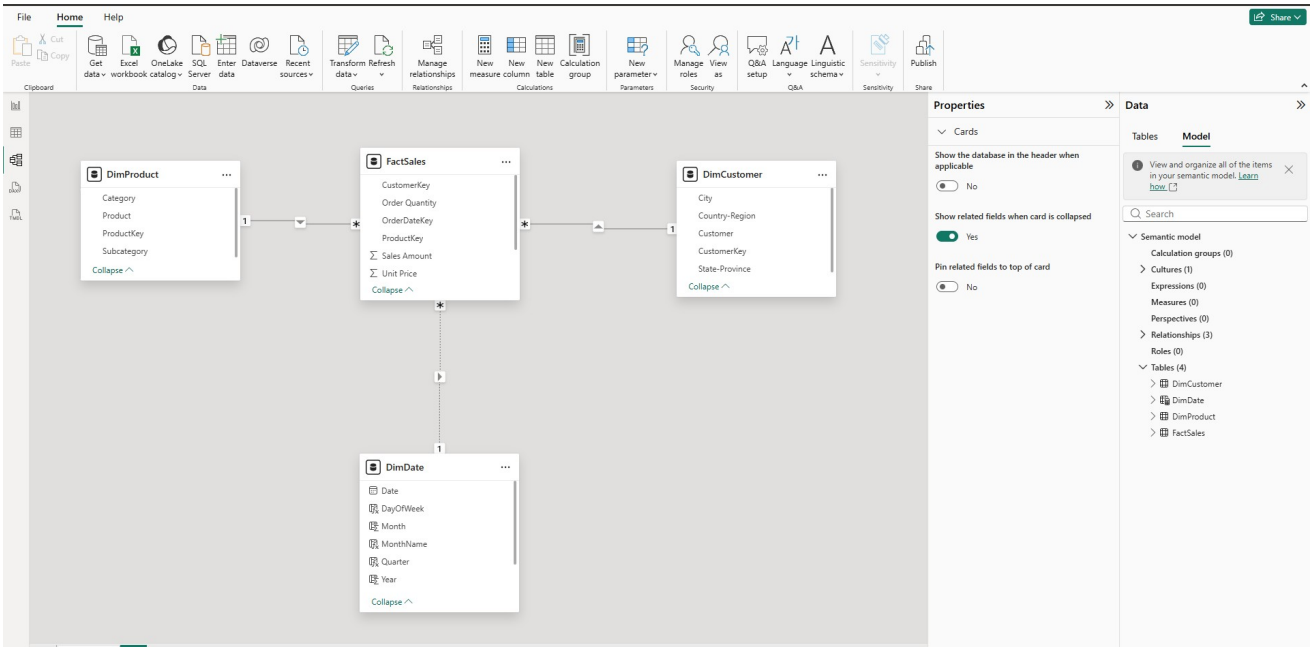

Hình 18: Model View hoàn chỉnh, Sales kết nối với 3 Dimension tables. Dấu "1" và "∞" trên đường kẻ cho biết kiểu quan hệ.

IV.3. Active vs Inactive Relationships

Hai bảng có thể có **nhiều relationship**, nhưng chỉ **1 relationship được active** tại một thời điểm. Relationship active hiển thị bằng **đường liền** trong Model View, còn inactive hiển thị bằng **đường đứt**.

Một tình huống phổ biến: bảng `Sales` trong Adventure Works có cả cột `OrderDateKey` (ngày đặt hàng) và `ShipDateKey` (ngày giao hàng). Cả hai đều cần liên kết với `Date`, nhưng chỉ 1 relationship có thể active. Thông thường, `OrderDateKey` sẽ là active (đường liền), còn `ShipDateKey` là inactive (đường đứt).

Khi muốn tính theo `ShipDateKey`, chúng ta dùng hàm **USERELATIONSHIP** trong DAX:

```
Total Shipped =
 CALCULATE(
 SUM(Sales[Sales Amount]),
 USERELATIONSHIP(Sales[ShipDateKey], Date[DateKey])
 )
```

Measure trên đánh dấu inactive relationship, cho phép `Date` lọc `Sales` theo `ShipDateKey` thay vì `OrderDateKey`. Đây chính là kỹ thuật **Role-playing Dimension** (Bảng chiều đa vai trò), một Dimension table có nhiều vai trò khác nhau.

IV.4. Xử lý Many-to-Many

Khi gặp relationship Many-to-Many (∞:∞), cách tốt nhất là tạo một **Bridge table** (bảng cầu nối) chứa các giá trị duy nhất, rồi tạo 2 relationship One-to-Many thay vì 1 relationship Many-to-Many.

Ví dụ: nếu bảng Manager và bảng Sales đều có cột Region (nhiều manager quản lý 1 region, nhiều đơn hàng thuộc 1 region), hãy tạo bảng Region riêng chứa danh sách region duy nhất, rồi liên kết:

- Region → Sales: One-to-Many
- Region → Manager: One-to-Many

Cách này giải quyết vấn đề performance và tránh kết quả sai lệch.

V. Introduction to DAX

Bước cuối cùng trong pipeline: dữ liệu đã sạch (bước 1), đã tổ chức (bước 2), đã kết nối (bước 3). Giờ chúng ta tạo **phép tính** trên data model hoàn chỉnh đó. Ở phần II, chúng ta đã gặp **M Language** trong Power Query. Đây là ngôn ngữ thứ hai trong Power BI: **DAX**, hoạt động ở tầng hoàn toàn khác. M biến đổi dữ liệu *trước* khi vào model, DAX tính toán trên dữ liệu *đã vào* model (xem bảng so sánh ở mục II.1).

V.1. DAX là gì?

DAX (**Data Analysis Expressions:** Biểu thức phân tích dữ liệu) là ngôn ngữ công thức trong Power BI, dùng để tạo phép tính tùy chỉnh. Nếu đã quen Excel, DAX sẽ khá thân thuộc vì nhiều hàm có tên giống (SUM, AVERAGE, IF...). Nhưng DAX mạnh hơn ở một điểm: nó hiểu **Filter Context** (ngữ cảnh lọc), nghĩa là cùng một công thức có thể cho ra kết quả khác nhau tùy vào bộ lọc đang áp dụng trong report.

Measure vs Calculated Column

Measure và Calculated Column là **2 loại công thức khác nhau** trong DAX, dùng cho **2 mục đích khác nhau**:

	Measure	Calculated Column
Bản chất	Tính **kết quả tổng hợp** trên báo cáo	Tạo **cột mới cho từng dòng dữ liệu**
Tính khi nào	Khi visual render hoặc khi người dùng lọc dữ liệu	Khi refresh/load dữ liệu vào model
Lưu trong model?	Không lưu sẵn giá trị, chỉ lưu công thức	Có lưu kết quả như một cột dữ liệu
Đổi theo filter?	Có, kết quả thay đổi theo filter, slicer, visual	Không, giá trị từng dòng đã được tính sẵn
Dùng để làm gì?	Tính tổng, trung bình, đếm, tỷ lệ, KPI	Phân loại dòng, tạo nhóm, ghép text, tách thời gian

Ví dụ:

- **Measure**: `Total Sales = SUM(Sales[Sales Amount])`
- **Calculated Column**: `Category = IF(Sales[Sales Amount] > 1000000, "High", "Low")`

Đa số trường hợp nên **ưu tiên Measures hơn Calculated Columns**. Lý do: Calculated Columns chiếm bộ nhớ (mỗi giá trị lưu vĩnh viễn), còn Measures chỉ tính khi cần. Chỉ dùng Calculated Column khi kết quả **không thay đổi theo filter:** ví dụ, phân loại sản phẩm thành nhóm giá.

Trong bài này, chúng ta sẽ tập trung vào **Measures:** vì đây là thứ bạn dùng nhiều nhất khi xây dựng dashboard.

V.2. Tạo Measure đầu tiên: Total Sales

Bắt đầu với measure đơn giản nhất: tính **Total Sales** (tổng doanh thu) bằng hàm SUM.

Bước 1: Tạo New Measure

Trong Report View hoặc Data View, chọn bảng `Sales` ở panel Fields (bên phải). Sau đó chọn **Home** → **New Measure** (hoặc chuột phải vào tên bảng → New Measure). Thanh formula bar sẽ xuất hiện ở phía trên.

Bước 2: Viết công thức DAX

Gõ vào formula bar:

```
Total Sales = SUM(Sales[Sales Amount])
```

Giải thích:

- `Total Sales`, tên measure. Nên đặt tên rõ ràng, có nghĩa.
- `=`, dấu bằng bắt đầu công thức.
- `SUM(...)`, hàm DAX tính tổng tất cả giá trị trong cột.
- `Sales[Sales Amount]`, tham chiếu đến cột `Sales Amount` trong bảng `Sales`. Cú pháp DAX luôn là `TenBang[TenCot]`.

Nhấn **Enter** để xác nhận. Measure `Total Sales` sẽ xuất hiện trong bảng `Sales` với icon máy tính (), khác với các cột thường.

Bước 3: Dùng Measure trong visual

- Trước hết, tạo một **Card visual** trên report canvas.
- Sau đó, kéo measure `Total Sales` vào vùng **Value** của Card. Khi chưa áp dụng filter nào, Card sẽ hiển thị **tổng doanh thu của toàn bộ dữ liệu**.

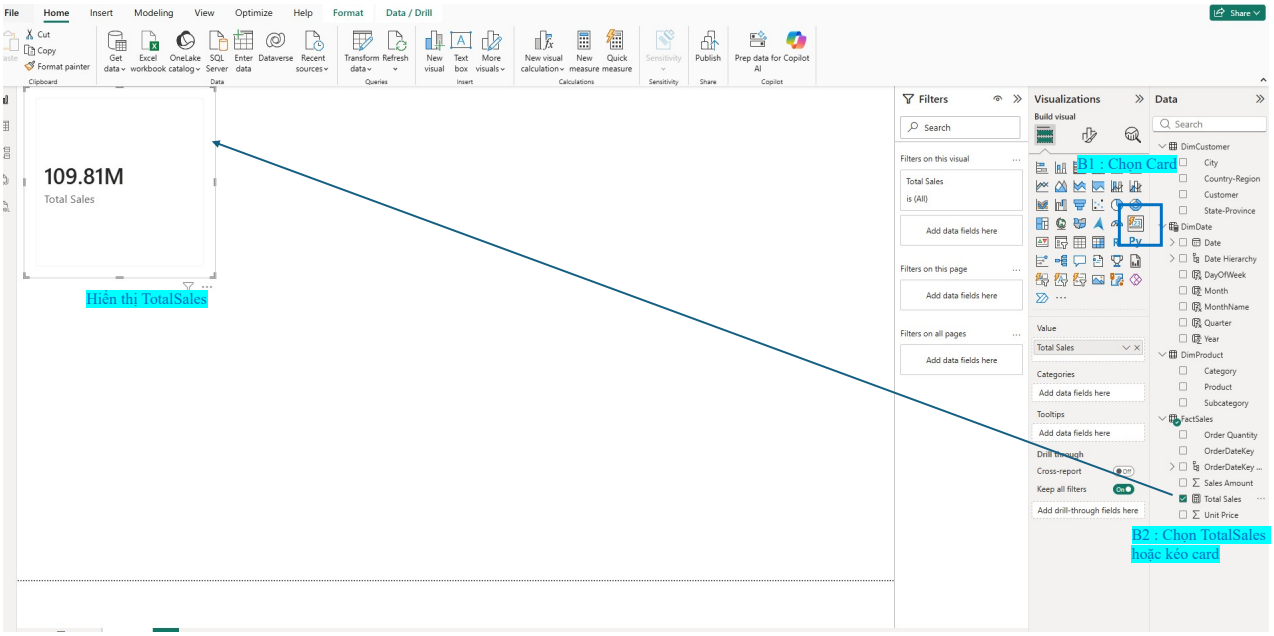

Hình 19: Create Card Total Sales.

- Tiếp theo, bấm vào vùng trống trên canvas rồi chèn thêm một **Slicer**.
- Kéo trường `DimCustomer[Country-Region]` vào Slicer. Lúc này, Slicer sẽ hiển thị danh sách các quốc gia hoặc khu vực để người dùng lựa chọn.
- Chọn giá trị `United States` trong Slicer. Khi đó, report chỉ giữ lại các bản ghi thuộc khách hàng ở **United States**.
- Vì `Total Sales` là một **Measure**, nên nó không lưu sẵn một giá trị cố định mà luôn được tính lại theo **filter context** hiện tại.
- Do đó, giá trị hiển thị trong Card sẽ tự động thay đổi: thay vì hiển thị tổng doanh thu của toàn bộ dataset, Card chỉ còn hiển thị **tổng doanh thu của khách hàng ở United States**.

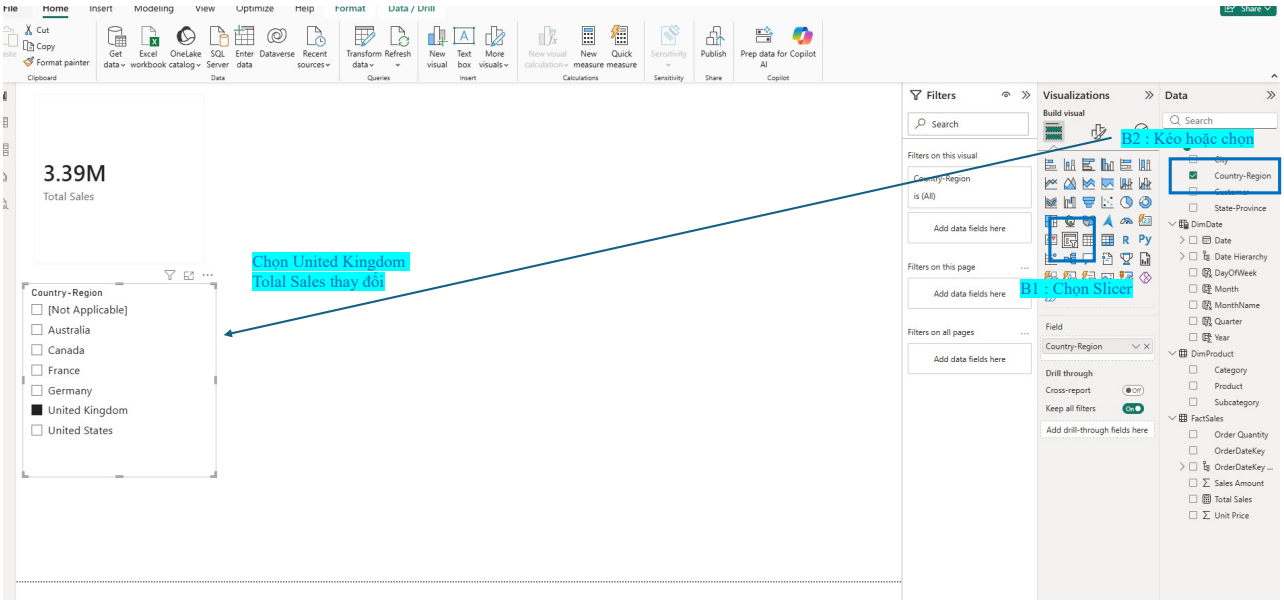

Hình 20: Total Sales hiển thị trong Card. Khi chọn Country-Region = "United States" trên Slicer, giá trị tự động cập nhật. Đây chính là Filter Context đang hoạt động.

Filter Context (Ngữ cảnh lọc)

Filter Context là tập hợp tất cả các bộ lọc đang tác động lên một measure tại thời điểm tính toán. Bộ lọc có thể đến từ Slicer, Row/Column trong visual, hoặc Page/Report level filter. Mỗi dữ liệu trong table visual có filter context riêng. Ví dụ: ô "Total Sales cho Category Bikes, năm FY2020" có filter context = (Category = Bikes) AND (Fiscal Year = FY2020).

Ví dụ thực tế: Total Sales trong Table visual

Để thấy rõ hơn sức mạnh của measure, hãy tạo một **Table visual** và kéo:

- `Product[Category]` vào cột đầu tiên
- `Total Sales` vào cột thứ hai

Tạo thêm **Slicer** như trên.

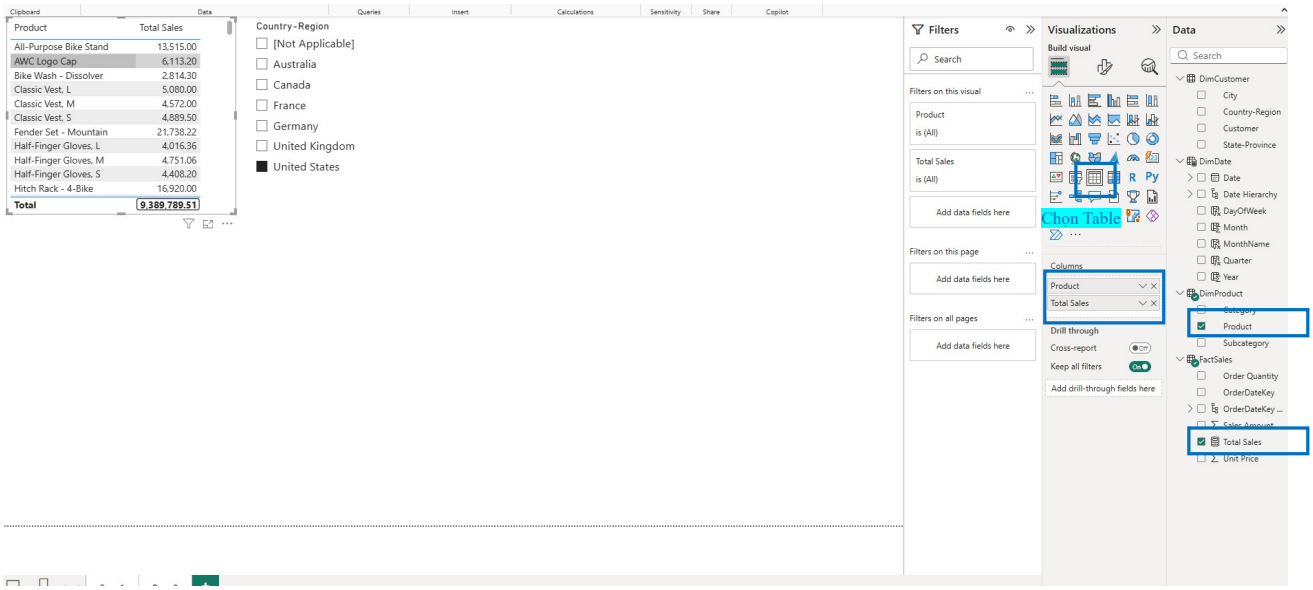

Hình 21: Power BI tự động **chia nhỏ** (breakdown) Total Sales theo từng Category. Cùng một measure `SUM(Sales[Sales Amount])`, nhưng kết quả khác nhau cho mỗi dòng, vì filter context của mỗi dòng khác nhau!

V.3. Các hàm DAX cơ bản

Ngoài SUM, DAX còn nhiều hàm tổng hợp (**aggregation functions**) cơ bản mà chúng ta nên biết. Bảng dưới đây tóm tắt các hàm thường dùng nhất:

Hàm	Cú pháp	Kết quả	Ví dụ
SUM	`SUM(Table[Column])`	Tổng tất cả giá trị	`Total Sales = SUM(Sales[Sales Amount])`
AVERAGE	`AVERAGE(Table[Column])`	Giá trị trung bình	`Avg Price = AVERAGE(Sales[Unit Price])`
COUNT	`COUNT(Table[Column])`	Đếm giá trị non-blank	`Price Count = COUNT(Sales[Unit Price])`
COUNTROWS	`COUNTROWS(Table)`	Đếm tổng số dòng	`Order Lines = COUNTROWS(Sales)`
MIN	`MIN(Table[Column])`	Giá trị nhỏ nhất	`Min Price = MIN(Sales[Unit Price])`
MAX	`MAX(Table[Column])`	Giá trị lớn nhất	`Max Price = MAX(Sales[Unit Price])`
DISTINCTCOUNT	`DISTINCTCOUNT(Table[Column])`	Đếm giá trị không trùng	`DISTINCTCOUNT(Sales[CustomerKey])`

Mỗi hàm đều tuân theo cú pháp `TenMeasure = HAM(TenBang[TenCot])`.

Mẹo: COUNT vs COUNTROWS

Hai hàm này dễ nhầm lẫn nhưng khá khác nhau: - **COUNT(Sales[Sales Amount]):** đếm số giá trị **non-blank** trong cột Amount. Nếu có dòng mà Amount bị trống, dòng đó không được tính. - **COUNTROWS(Sales):** đếm **tổng số dòng** trong bảng, bất kể giá trị cột nào trống hay không. Đây thường là lựa chọn chính xác hơn khi muốn đếm "số đơn hàng".

Ví dụ tạo thêm measures:

Sau khi đã tạo `Total Sales`, chúng ta có thể nhanh chóng tạo thêm vài measure hữu ích:

```
Total Order Quantity = SUM(Sales[Order Quantity])
```

```
Avg Order Value = AVERAGE(Sales[Sales Amount])
```

```
Number of Orders = COUNTROWS(Sales)
```

```
Unique Customers = DISTINCTCOUNT(Sales[CustomerKey])
```

Mỗi measure trên đều hoạt động với filter context, giá trị tự động thay đổi khi chúng ta lọc theo sản phẩm, khu vực, thời gian...

V.4. Bước tiếp theo: CALCULATE

Khi đã quen với các hàm cơ bản (SUM, AVERAGE, COUNT...), bước tiếp theo trong hành trình DAX là hàm **CALCULATE**, được xem là hàm quan trọng nhất và mạnh nhất trong DAX. CALCULATE cho phép bạn **thêm, ghi đè, hoặc thay đổi filter context** trước khi tính toán.

Cú pháp:

```
CALCULATE(<biểu thức measure>, <bộ lọc 1>, <bộ lọc 2>,...)
```

Tất cả các bộ lọc bên trong CALCULATE hoạt động như **AND:** một dòng phải khớp **tất cả** bộ lọc mới được tính vào kết quả.

Ví dụ: muốn tính Total Sales **chỉ cho năm tài chính FY2020**, bất kể người dùng đang lọc gì trên report:

```
Sales FY2020 = CALCULATE(SUM(Sales[Sales Amount]), 'Date'[Fiscal Year] =
    "FY2020")
```

Hoặc tính doanh thu **chỉ cho khách hàng Mỹ**:

```
Sales US = CALCULATE(
 SUM(Sales[Sales Amount]),
 Customer[Country-Region] = "United States"
)
```

V.5. Biến VAR: Viết DAX sạch và hiệu quả hơn

Khi công thức DAX trở nên phức tạp, chúng ta nên dùng **VAR** (variable) để chia nhỏ thành các bước logic. VAR giúp:

- **Dễ đọc hơn:** Mỗi bước có tên rõ ràng
- **Hiệu năng tốt hơn:** Giá trị của VAR chỉ tính **1 lần**, dù được dùng nhiều chỗ trong RETURN
- **Dễ debug:** Có thể thay đổi RETURN để kiểm tra từng biến trung gian

```
Avg Revenue Per Unit =
 VAR TotalRevenue = SUM(Sales[Sales Amount])
 VAR TotalQty = SUM(Sales[Order Quantity])
 RETURN
 DIVIDE(TotalRevenue, TotalQty, 0)
```

Công thức trên tính **doanh thu trung bình trên mỗi sản phẩm**: tổng Sales Amount chia cho tổng Order Quantity. Hàm `DIVIDE` được dùng thay vì `/` để tránh lỗi chia cho 0 (tham số thứ 3 là giá trị trả về khi mẫu bằng 0).

Mẹo viết DAX sạch

- Dùng **Alt+Enter** hoặc **Shift+Enter** để xuống dòng, **Tab** để thụt lề
- Luôn đặt tên bảng trong **dấu nháy đơn**: `'Sales'[Sales Amount]`
- Dùng comment `//` hoặc `/... /` để ghi chú mục đích công thức
- Dùng `VAR` để tránh tính cùng một biểu thức nhiều lần

V.6. Iterator Functions: Hàm lặp SUMX

Các hàm `SUM`, `AVERAGE`, `COUNT` chỉ làm việc với **một cột dữ liệu**. Vì vậy, nếu cần tính **Qty** × **Unit Price** cho **từng dòng** rồi mới cộng tổng, ta không thể dùng cách:

$$\texttt{SUM(Qty)} \times \texttt{SUM(Unit Price)}$$

Vì cách này lấy **tổng số lượng** nhân với **tổng đơn giá**, nên cho kết quả sai.

Ví dụ với 2 đơn hàng: `(Qty = 3, Unit Price = 100.000)` và `(Qty = 2, Unit Price = 200.000)`:

- `SUM(Qty)` × `SUM(Unit Price)` = 5 × 300.000 = **1.500.000** ✗
- Cách đúng là tính theo từng dòng rồi cộng lại: 3×100.000 + 2×200.000 = 300.000 + 400.000 = **700.000** ✓

Như vậy, trong bài toán này, `SUM` không phù hợp.

Đây là lúc dùng **hàm lặp (iterator/X-functions)**. Hàm phổ biến nhất là **SUMX**:

```
Gross Revenue = SUMX(Sales, Sales[Order Quantity] * Sales[Unit Price])
```

Cách hoạt động:

1. SUMX duyệt qua **từng dòng** trong bảng `Sales`
2. Tại mỗi dòng, tính `Order Quantity` × `Unit Price`
3. Sau đó **cộng tổng** tất cả kết quả

Các X-function khác: **AVERAGEX**, **COUNTX**, **MINX**, **MAXX:** đều hoạt động tương tự: duyệt từng dòng, tính biểu thức, rồi tổng hợp.

Lưu ý

SUMX mạnh nhưng **tốn tài nguyên hơn SUM** vì phải tính từng dòng. Chỉ dùng khi cần tính toán đa cột, nếu chỉ cộng 1 cột thì SUM đã đủ.

CALCULATE, VAR, và các X-functions sẽ được trình bày chi tiết ở các bài nâng cao. Ở đây, chúng ta chỉ cần nắm ý tưởng cơ bản, và biết rằng DAX còn rất nhiều khả năng mạnh mẽ đang chờ phía trước!

VI. Tổng kết

Bốn bước trong pipeline đã hoàn thành. Từ dữ liệu thô ban đầu, chúng ta đã đi qua toàn bộ quy trình chuẩn bị dữ liệu trong Power BI:

Bước	Công cụ	Việc đã làm
1. Clean	Power Query Editor	Chuẩn hóa text, xóa dòng/cột thừa, sửa data types, data profiling, tránh bẫy lọc nguy hiểm
2. Model	Star Schema	Tách dữ liệu thành Fact table + Dimension tables, ẩn key columns
3. Relate	Model View	Tạo relationships (One-to-Many), hiểu Active/Inactive, xử lý M:N
4. Calculate	DAX	Viết measures: SUM, AVERAGE, COUNT, CALCULATE, VAR, SUMX

Checklist kiểm tra Data Model:

Trước khi bắt tay vào tạo report, hãy kiểm tra:

- ☐ Tất cả các cột đã có **data type đúng**? (đã xóa step Changed Type tự động, đổi type thủ công)
- ☐ Dữ liệu text đã được **chuẩn hóa** (không còn biến thể, khoảng trắng thừa, case nhất quán)?
- ☐ Đã tách thành **Fact + Dimension tables** theo Star Schema?
- ☐ Tất cả relationships đã được tạo và hiển thị đúng trong **Model View**?
- ☐ Cardinality đều là **One-to-Many** (Dim → Fact)?
- ☐ Cross-filter direction đều là **Single** (Dim → Fact)?
- ☐ Các cột key trong Fact table đã được **ẩn** khỏi Report View?
- ☐ Đã tạo ít nhất 1 **measure** (VD: Total Sales) và test thử với filter?

Nếu checklist trên đều đã hoàn thành, data model đã sẵn sàng. Ở Lesson 3, chúng ta sẽ sử dụng model này để xây dựng **report tương tác** với Slicers, Drill-down, Drill-through, biến dữ liệu khô khan thành insight có giá trị!

AI VIET NAM COURSE 2026

Quiz - Power BI: Data Transformation and Modeling

1. Bạn có 1 flat table chứa toàn bộ dữ liệu bán hàng (`CustomerKey, Customer, City, Country, ProductKey, Product, Category, OrderDate, Quantity, Unit Price, Sales Amount`). Khách hàng Jon V. Yang mua 100 đơn hàng → tên, địa chỉ, quốc gia lặp 100 lần.

Bạn muốn tách thành Star Schema trong Power Query. Cách tiếp cận nào **ĐÚNG**?

a. Tạo **Reference** query nhưng dùng **Remove Columns** (thay vì Choose Columns) để xóa từng cột không cần

b. Tạo **Duplicate** query cho mỗi Dimension, dùng Choose Columns giữ cột mô tả + key, rồi Remove Duplicates trên key

c. Import flat table rồi dùng DAX `SUMMARIZE` để tạo Dimension tables trong Data Model

d. Tạo **Reference** query cho mỗi Dimension, dùng Choose Columns giữ cột mô tả + key, rồi Remove Duplicates trên key. Reference cho Fact chỉ giữ keys + measures

Đáp án đúng: D

Giải thích chi tiết:

Reference tạo query mới tham chiếu output của query gốc, flat table chỉ được đọc từ nguồn **1 lần**. **Choose Columns** chỉ giữ cột đã khai báo, an toàn khi schema thay đổi. **Remove Duplicates** trên key đảm bảo Dimension table có giá trị key duy nhất (yêu cầu cho relationship 1-side).

- (A) sai: Remove Columns có vấn đề forward-compatibility: khi nguồn thêm cột mới, cột đó tự động giữ lại trong Dimension table
- (B) sai: Duplicate tạo bản sao **độc lập**; nguồn bị đọc nhiều lần (5 lần với 4 Dim + 1 Fact)
- (C) sai: `SUMMARIZE` tạo virtual table trong DAX context, không phải physical table; tổ chức dữ liệu nên thực hiện ở tầng Power Query

2. Trong Star Schema, bảng DimCustomer (1) kết nối với FactSales (∞) qua CustomerKey, và DimProduct (1) kết nối với FactSales (∞) qua ProductKey. Cross-filter direction mặc định là **Single** trên tất cả relationships.

```
DimCustomer (1) -Single-> FactSales (∞) <-Single- DimProduct (1)
```

Người dùng chọn Country-Region = "United States"trên Slicer (từ DimCustomer). Bạn muốn biết "sản phẩm nào đã được bán cho khách hàng Mỹ?", tức cần lọc từ DimCustomer qua FactSales tới DimProduct. Với Single direction trên **TẤT CẢ** relationships, điều gì xảy ra?

a. Bộ lọc truyền từ DimCustomer → FactSales thành công, nhưng **KHÔNG** truyền tiếp từ FactSales → DimProduct vì Single chỉ cho phép chiều từ "1"sang "∞"

b. Bộ lọc truyền thành công: DimCustomer → FactSales → DimProduct → hiển thị đúng sản phẩm bán cho khách Mỹ

c. Bộ lọc không truyền được gì vì Single direction chặn mọi filter propagation

d. Power BI tự động chuyển sang Both direction khi phát hiện cần filter nhiều bảng

Đáp án đúng: A

Giải thích chi tiết:

Single direction chỉ cho phép filter đi từ side "1"sang side "∞". DimCustomer(1)→FactSales(∞) đúng hướng nên filter truyền thành công. Nhưng FactSales(∞)→DimProduct(1) là hướng ngược lại, Single **chặn** chiều này. Kết quả: FactSales được lọc nhưng DimProduct **không bị lọc**.

- (B) sai: filter không truyền được từ FactSales ngược lên DimProduct
- (C) sai: Single không chặn mọi filter, chỉ chặn chiều ∞→1; chiều 1→∞ vẫn hoạt động
- (D) sai: Power BI không tự động đổi direction; phải cấu hình thủ công hoặc dùng `CROSSFILTER()` trong DAX

3. Bảng Sales có cột Country. Power Query filter giữ 3 nước:

```
= Table.SelectRows(Source, each (
    [Country] = "Vietnam" or
    [Country] = "Thailand" or
    [Country] = "Cambodia"))
```

Sau 6 tháng, 2 sự kiện xảy ra đồng thời: (1) hệ thống nguồn đổi `"Vietnam"` → `"Viet Nam"` (thêm dấu cách); (2) thêm 2 thị trường mới `"Laos"` và `"Myanmar"`. Sau khi refresh, bảng Sales chứa những Country nào?

a. `"Vietnam"`, `"Thailand"`, `"Cambodia"`, code M không thay đổi nên kết quả giống cũ

b. `"Viet Nam"`, `"Thailand"`, `"Cambodia"`, Power Query tự normalize tên nước

c. `"Thailand"`, `"Cambodia"`, `"Viet Nam"` không khớp `"Vietnam"`; `"Laos"` và `"Myanmar"` không trong whitelist

d. `"Thailand"`, `"Cambodia"`, `"Laos"`, `"Myanmar"`, filter loại `"Vietnam"` vì không còn tồn tại, giữ lại giá trị mới

Đáp án đúng: C

Giải thích chi tiết:

Hai bẫy kết hợp đồng thời: **Bẫy whitelist**, `"Laos"` và `"Myanmar"` không khớp bất kỳ điều kiện nào nên bị lọc ra âm thầm. **Bẫy value change**, M Language so sánh chuỗi chính xác từng ký tự (case-sensitive và space-sensitive), `"Viet Nam"` ≠ `"Vietnam"` nên dữ liệu Việt Nam biến mất **không có cảnh báo**.

- (A) sai: `"Vietnam"` không còn tồn tại trong source; `"Viet Nam"` không khớp chuỗi cũ
- (B) sai: Power Query không có cơ chế tự normalize tên hay sửa lỗi chính tả
- (D) sai: whitelist không "nhường chỗ"cho giá trị mới; `"Laos"`, `"Myanmar"` không khớp nên bị lọc

4. Bạn tạo file `.pbix` mới trên máy cài locale **Việt Nam** (dấu chấm = ngàn, dấu phẩy = thập phân), rồi import CSV từ hệ thống Mỹ. Cột "Revenue"chứa `"1,234,567.89"` (dấu phẩy = ngàn, dấu chấm = thập phân). Power Query tự sinh step:

```
= Table.TransformColumnTypes(Source, {{"Revenue", type number}})
```

Giá trị `"1,234,567.89"` được xử lý như thế nào?

a. Tự động nhận diện định dạng Mỹ → convert đúng = 1,234,567.89

b. Lỗi hoặc trả về `null` vì `"1,234,567.89"` không phải số hợp lệ theo locale VN

c. Convert thành 1.234 vì locale VN coi dấu phẩy đầu tiên là phân cách ngàn rồi dừng

d. Power BI Desktop luôn dùng locale en-US bất kể cài đặt máy

Đáp án đúng: B

Giải thích chi tiết:

`Table.TransformColumnTypes` không chỉ định locale nên dùng locale lưu trong file `.pbix` (locale VN). Trong locale VN, dấu phẩy là ký hiệu thập phân, chỉ được xuất hiện 1 lần. Chuỗi `"1,234,567.89"` có **3 dấu phẩy** nên không hợp lệ → parse fail → `Error` hoặc `null`. Giải pháp: chỉ định locale explicit:

```
= Table.TransformColumnTypes(Source, {{"Revenue", type number}}, "en-
    US")
```

- (A) sai: Power Query không có cơ chế "auto-detect"locale của file nguồn
- (C) sai: engine không parse một phần; khi format không hợp lệ, toàn bộ giá trị trả về Error
- (D) sai: Power BI dùng locale lưu trong file `.pbix`, không phải locale hệ điều hành

5. Model có các bảng: `DimProduct`, `DimSubcategory` (có `CategoryKey`), `DimCategory`, `BridgeProductSubcategory` (ProductKey, SubcategoryKey), `FactSales`. Tất cả relationships đều **Single**:

- `DimCategory`(1) → `DimSubcategory`(∞)
- `DimSubcategory`(1) → `Bridge`(∞)
- `DimProduct`(1) → `Bridge`(∞)
- `DimProduct`(1) → `FactSales`(∞)

Người dùng thêm slicer `DimCategory[CategoryName] = "Bikes"`. Measure `Total Sales = SUM(FactSales[SalesAmount])`. Điều gì xảy ra?

a. Filter truyền đến DimProduct thành công nhưng KHÔNG truyền tiếp xuống FactSales

b. Power BI báo lỗi "ambiguous path"vì có quá nhiều bảng trong chuỗi relationship

c. Total Sales hiển thị đúng doanh thu Bikes, filter truyền qua: DimCategory → DimSubcategory → Bridge → DimProduct → FactSales

d. Filter truyền đến Bridge thành công nhưng **KHÔNG** truyền tiếp lên DimProduct vì Single chặn hướng ∞→1; FactSales không bị lọc

Đáp án đúng: D

Giải thích chi tiết:

Filter đi được: DimCategory(1)→DimSubcategory(∞)→Bridge(∞), toàn bộ là chiều 1→∞, đúng hướng. Nhưng Bridge(∞)→DimProduct(1) là chiều ngược lại, Single **không cho phép** → filter dừng tại đây. DimProduct thấy toàn bộ sản phẩm → FactSales không bị lọc. Giải pháp: đổi `DimProduct`↔`Bridge` sang **Both** direction.

- (A) sai: filter không bao giờ đến được DimProduct (bị chặn tại Bridge→DimProduct)
- (B) sai: Power BI báo lỗi ambiguous chỉ khi có nhiều đường đến cùng một bảng; ở đây chỉ có 1 đường
- (C) sai: Bridge(∞)→DimProduct(1) là Single chặn; filter không qua được

6. Model có:

`DimProduct (1)` ←Both→ `FactSales (∞)` ←Both→ `DimCustomer (1)`

Cả hai relationships đều **Both** direction. Không có relationship trực tiếp giữa DimProduct và DimCustomer. Người dùng thêm slicer `DimProduct[Category] = "Bikes"`. Điều này ảnh hưởng đến DimCustomer như thế nào trong một Table visual có Rows = `DimCustomer[Country]`, Values = `SUM(FactSales[SalesAmount])`?

a. DimCustomer không bị ảnh hưởng, không có relationship trực tiếp Product↔Customer

b. DimCustomer bị lọc: chỉ hiển thị Country có mua Bikes, Both direction cho phép filter truyền DimProduct → FactSales → DimCustomer

c. Power BI báo lỗi circular dependency vì Both direction tạo vòng lặp filter

d. Visual hiển thị đúng nhưng slicer không có tác dụng vì Both chỉ hoạt động trong context của relationship, không phải slicer

Đáp án đúng: B

Giải thích chi tiết:

Both direction cho phép filter truyền cả hai chiều, kể cả chiều ∞→1. Chuỗi filter: slicer lọc DimProduct → Both cho phép truyền xuống FactSales → Both tiếp tục truyền ngược lên DimCustomer. Đây là **side effect thực tế**, người dùng thường ngạc nhiên khi slicer Product ảnh hưởng danh sách Country. Microsoft khuyến nghị dùng `CROSSFILTER()` trong DAX để kiểm soát chính xác hơn.

- (A) sai: không cần relationship trực tiếp; FactSales làm cầu nối qua Both direction
- (C) sai: circular dependency chỉ xảy ra khi có vòng lặp thực sự (A↔B↔C↔A); đây là chuỗi thẳng
- (D) sai: slicer hoạt động bình thường và filter context lan sang visual qua Both direction

7. Cho measure:

```
Market Share =
DIVIDE(
    [Total Sales],
    CALCULATE([Total Sales], ALL(DimProduct))
)
```

Report có Matrix: Rows = `DimProduct[Category]`, Columns = `DimCustomer[Country]`. Slicer: `DimCustomer[Country] = "United States"`. Giá trị Market Share cho ô **(Bikes, United States)** được tính như thế nào?

a. Bikes_US / Total tất cả Category ở US, `ALL(DimProduct)` chỉ xóa filter Product, filter Country = "US"vẫn giữ nguyên

b. Bikes_US / Total toàn bộ dataset, `ALL(DimProduct)` xóa hết filter kể cả Country

c. Bikes_US / Total Bikes toàn quốc, `ALL` chỉ xóa filter Category trong visual, Country vẫn bị ảnh hưởng

d. Lỗi vì `ALL` không thể override filter từ slicer bên ngoài

Đáp án đúng: A

Giải thích chi tiết:

Tại ô (Bikes, US): tử số = `[Total Sales]` với filter Category="Bikes"AND Country="US-**Bikes_US**. Mẫu số = `CALCULATE([Total Sales], ALL(DimProduct))`: `ALL(DimProduct)` xóa **toàn bộ filter từ bảng DimProduct** (xóa Category="Bikes"), nhưng filter Country="US"từ bảng **DimCustomer** không bị xóa → mẫu số = Total_US. Kết quả: Bikes_US / Total_US = market share Bikes tại US.

- (B) sai: `ALL(DimProduct)` không xóa filter từ DimCustomer; để xóa cả Country cần `ALL(DimProduct, DimCustomer)`
- (C) sai: `ALL(DimProduct)` xóa toàn bộ bảng DimProduct, không chỉ cột Category
- (D) sai: `ALL` trong CALCULATE hoàn toàn có thể override filter từ slicer; đây là cơ chế chuẩn

8. Bảng Sales có 4 dòng:

OrderQuantity	UnitPrice
3	100,000
5	200,000
10	150,000
7	80,000

Measure:

```
Tiered Revenue =
SUMX(
    Sales,
    VAR qty = Sales[OrderQuantity]
    VAR price = Sales[UnitPrice]
    VAR discount =
        IF(qty >= 10, 0.15,
        IF(qty >= 5,  0.10,
        0))
    RETURN qty * price * (1 - discount)
)
```

Kết quả `Tiered Revenue` là bao nhiêu?

a. 3,054,000

b. 3,360,000

c. 2,979,000

d. 2,951,000

Đáp án đúng: C

Giải thích chi tiết:

SUMX duyệt từng dòng, evaluate VAR trong row context:

Dòng	qty	price	discount	kết quả
1	3	100,000	0%	$3 \times 100{,}000 \times 1.00 = \mathbf{300{,}000}$
2	5	200,000	10%	$5 \times 200{,}000 \times 0.90 = \mathbf{900{,}000}$
3	10	150,000	15%	$10 \times 150{,}000 \times 0.85 = \mathbf{1{,}275{,}000}$
4	7	80,000	10%	$7 \times 80{,}000 \times 0.90 = \mathbf{504{,}000}$
			Tổng	**2,979,000**

- (A) 3,054,000, sai: áp discount 10% cho dòng 3 (qty=10) thay vì 15%
- (B) 3,360,000, sai: không áp dụng discount nào

- (D) 2,951,000, sai: áp 15% cho dòng qty=7 (nhầm ngưỡng)

Lưu ý: thứ tự IF lồng nhau phải từ ngưỡng **cao** → **thấp**, kiểm tra `qty >= 10` trước.

9. Cho measures:

```
Total Sales = SUM(Sales[SalesAmount])

Sales All Products =
CALCULATE([Total Sales], REMOVEFILTERS(DimProduct[Category]))

Sales All =
CALCULATE([Total Sales], ALL(DimProduct))
```

Filter context hiện tại (từ 3 slicer độc lập): `DimProduct[Category]` = "Bikes", `DimProduct[SubCategory]` = "Mountain Bikes", `DimProduct[ListPrice]` > 1,000,000. Phát biểu nào **ĐÚNG**?

a. `Sales All Products` = doanh thu SubCategory="Mountain Bikes"AND ListPrice>1M (chỉ xóa filter Category). `Sales All` = tổng toàn bộ dataset (xóa hết filter DimProduct)

b. Cả hai đều bằng tổng toàn bộ dataset, `REMOVEFILTERS` và `ALL(DimProduct)` hoàn toàn tương đương

c. `Sales All Products` = doanh thu toàn bộ dataset. `Sales All` = doanh thu ListPrice>1M

d. Cả hai đều bằng doanh thu Bikes toàn quốc vì đều giữ filter từ slicer bên ngoài

Đáp án đúng: A

Giải thích chi tiết:

Điểm khác biệt then chốt: `REMOVEFILTERS(DimProduct[Category])` xóa filter **chỉ trên 1 cột**, SubCategory="Mountain Bikes"và ListPrice>1M vẫn còn hiệu lực. `ALL(DimProduct)` xóa filter của **toàn bộ bảng**, không còn filter Product nào.

Cú pháp	Phạm vi xóa	Kết quả
`REMOVEFILTERS(Table[Col])`	Chỉ cột đó	Mountain Bikes, ListPrice>1M
`ALL(Table)`	Toàn bộ bảng	Tổng doanh thu

- (B) sai: hai hàm không tương đương; `REMOVEFILTERS(Column)` granular hơn nhiều
- (C) sai: logic ngược lại
- (D) sai: cả hai đều override filter từ slicer trong CALCULATE context

10. Model: `FactSales` có cả `OrderDateKey` và `ShipDateKey`, cùng tham chiếu đến `DimDate[DateKey]`. Relationship **active**: `OrderDateKey`→`DateKey`. Relationship **inactive**: `ShipDateKey`→`DateKey`.

Bạn thêm Calculated Column vào FactSales:

```
ShipYear = RELATED(DimDate[Year])
```

Cột `ShipYear` trả về giá trị gì?

a. Year của **ShipDate**, `RELATED` tự nhận diện relationship phù hợp dựa trên tên cột `ShipDateKey`

b. Lỗi, Power BI không cho phép `RELATED` khi có 2 relationships giữa 2 bảng

c. Year của **OrderDate**, `RELATED` luôn dùng active relationship; active là `OrderDateKey`→`DateKey`

d. `BLANK()`, inactive relationship không thể truy xuất bằng `RELATED`

Đáp án đúng: C

Giải thích chi tiết:

`RELATED` **luôn luôn** dùng active relationship, không có ngoại lệ. Tên cột (`ShipDateKey`) chỉ là thuộc tính của bảng FactSales, không ảnh hưởng đến việc RELATED chọn relationship nào. Active relationship là `OrderDateKey`→`DateKey` nên `ShipYear` trả về Year của OrderDate. Để lấy đúng ShipYear, dùng `LOOKUPVALUE`:

```
ShipYear =
LOOKUPVALUE(DimDate[Year], DimDate[DateKey], FactSales[ShipDateKey])
```

- (A) sai: `RELATED` không có cơ chế nhận diện relationship qua tên cột
- (B) sai: Power BI cho phép nhiều relationships giữa 2 bảng miễn là chỉ có 1 active
- (D) sai: `RELATED` không trả về BLANK(); nó traverse active relationship và trả về giá trị hợp lệ

AI VIET NAM COURSE 2026

Power BI: Enhancing Interactivity

I. Giới thiệu

Ở Lesson 2, chúng ta đã xây dựng được một data model hoàn chỉnh: dữ liệu đã sạch, bảng Fact và Dimension đã được tổ chức theo Star Schema, các Relationships đã kết nối, và DAX measures cơ bản đã sẵn sàng. Nhưng nếu chỉ dừng lại ở đây, report của chúng ta vẫn chỉ là một bức tranh tĩnh. Người dùng nhìn vào, thấy một vài biểu đồ, vài con số tổng, rồi... hết.

Lesson 3 sẽ biến report tĩnh đó thành một **công cụ khám phá dữ liệu tương tác**, nơi người dùng tự click, lọc, đào sâu, và tìm câu trả lời cho câu hỏi kinh doanh của họ. Chúng ta sẽ đi qua **6 nhóm tính năng** chính:

1. **Slicers** (Phần II): Bộ lọc trực quan đặt ngay trên canvas, cho phép người dùng lọc dữ liệu theo Year, Region, Category...
2. **Cross-filtering & Cross-highlighting** (Phần III): Hiểu cơ chế tương tác mặc định giữa các visual, và cách kiểm soát bằng Edit Interactions
3. **Drill-down** (Phần IV): Cho phép đào sâu dữ liệu theo phân cấp (Year → Quarter → Month) ngay trong cùng một biểu đồ
4. **Drill-through** (Phần V): Tạo trang chi tiết riêng, người dùng chuột phải một data point để nhảy sang xem thông tin đầy đủ
5. **Bookmarks & Buttons** (Phần VI): Lưu trạng thái report, tạo nút điều hướng, toggle panel ẩn/hiện
6. **Optimizing UX** (Phần VII): Custom Tooltips, Conditional Formatting, KPI Layout, và Performance Analyzer

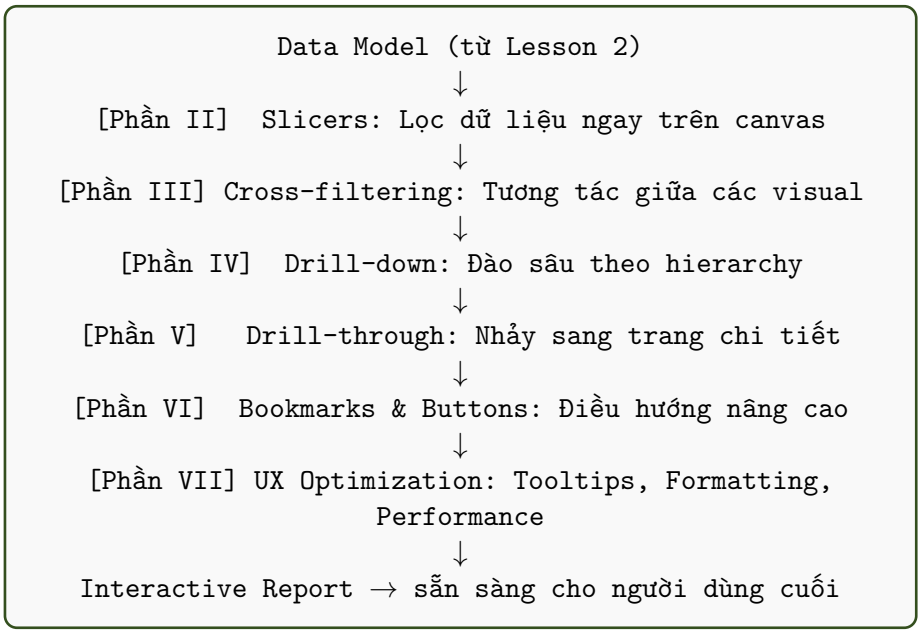

Hình 1: Từ data model đến interactive report. Mỗi phần bổ sung một lớp tương tác mới.

Trong suốt bài viết, chúng ta tiếp tục sử dụng **Adventure Works DW 2020**, dataset mẫu từ Lesson 2. Report sẽ được xây dựng dần: mỗi phần thêm một tính năng mới, giúp các bạn thấy rõ sự khác biệt trước và sau.

Mẹo nhỏ

Nếu chưa có file .pbix từ Lesson 2, các bạn có thể tải **dataset** và làm nhanh các bước import, tạo relationship theo hướng dẫn ở Lesson 2 Phần II-IV. Hoặc tải file .pbix đã có Data Model sẵn nhưng không chỉnh sửa được Table và Data Model do được import từ Azure của Microsoft : **Adventure Works DW 2020.pbix**.

II. Nguyên tắc thiết kế báo cáo hiệu quả

Khi dữ liệu được trình bày theo cách phức tạp hoặc lộn xộn, người dùng có thể gặp khó khăn trong việc trích xuất thông tin chi tiết có ý nghĩa. Phương pháp Tăng cường sự rõ ràng trong trực quan hóa Power BI là rất quan trọng để đảm bảo rằng dữ liệu được trình bày dễ hiểu, cho phép người dùng nhanh chóng diễn giải và hành động dựa trên thông tin. Độ rõ ràng giúp giảm tải nhận thức, làm cho trải nghiệm bảng điều khiển trở nên hài lòng và hấp dẫn hơn.

II.1. Giảm thiểu sự lộn xộn trực quan để rõ ràng

Trong Power BI, mỗi visual không chỉ là một biểu đồ mà còn là một **query gửi đến data model**. Vì vậy, việc thêm nhiều visual không chỉ gây rối mắt mà còn ảnh hưởng trực tiếp đến **performance**. Hiện tượng này được gọi là **visual clutter** - sự lộn xộn trực quan.

Visual Clutter là gì?

Visual clutter xảy ra khi report chứa quá nhiều thành phần thị giác không cần thiết, khiến người dùng:

- khó xác định insight quan trọng nhất,
- mất nhiều thời gian để đọc và so sánh,
- bị quá tải nhận thức (*cognitive overload*),
- và đôi khi hiểu sai dữ liệu.

Trong Power BI, clutter không chỉ làm report khó đọc mà còn có thể làm report **chạy chậm hơn**. Lý do là mỗi visual thường tương ứng với một hoặc nhiều query gửi đến data model. Nghĩa là: càng nhiều visual, càng nhiều tác vụ phải render và tính toán.

II.1.1. Ba nguồn gây clutter phổ biến nhất

Trong quá trình thiết kế dashboard, clutter thường xuất phát từ 3 nhóm lỗi sau:

1. Redundancy Đây là lỗi rất phổ biến ở người mới làm dashboard: một insight được hiển thị bằng nhiều visual khác nhau, nhưng không tạo thêm giá trị.

Ví dụ:

- Một Bar Chart hiển thị Sales by Category
- Một Pie Chart cũng hiển thị Sales by Category
- Một Table bên dưới lại tiếp tục liệt kê Sales by Category

Cả ba visual trên đều trả lời gần như cùng một câu hỏi: *Category nào bán tốt hơn?* Khi đó, ít nhất 1-2 visual là dư thừa.

2. Over-detail Một lỗi khác là cố gắng đưa toàn bộ dữ liệu lên cùng một trang.

Ví dụ:

- Trên landing page, thay vì chỉ hiển thị doanh thu theo tháng, report lại hiển thị luôn doanh thu theo ngày.
- Một bảng Table hiển thị hàng trăm dòng sản phẩm ngay trên trang overview.
- Một biểu đồ bar hiển thị 35 categories khiến nhãn trục bị chồng chéo, khó đọc.

Không phải trang nào cũng cần mức chi tiết tối đa. Trang overview nên tập trung vào **tóm tắt và định hướng**, còn chi tiết nên để ở drill-through page, tooltip, hoặc trang phụ.

3. Visual Noise Visual noise là những thành phần không sai, nhưng **không thật sự cần thiết**, làm report "ồn"hơn mức cần thiết.

Ví dụ về visual noise:

- gridlines quá đậm,
- border ở mọi visual,
- tất cả data labels đều bật,
- quá nhiều màu sắc nổi bật,
- tiêu đề dài dòng,
- icon trang trí không có chức năng,
- background nhiều họa tiết.

Lưu ý

Một report "đầy đủ"không đồng nghĩa với một report "hiệu quả". Càng nhiều chi tiết hiển thị cùng lúc, người dùng càng khó xác định điều gì quan trọng.

II.1.2. Mỗi biểu đồ nên truyền tải một thông tin chính.

Nguyên tắc quan trọng

Mỗi visual nên tồn tại để trả lời **một câu hỏi rõ ràng**. Nếu bạn không thể mô tả nhanh visual đó đang trả lời câu hỏi gì, rất có thể visual đó không cần thiết.

Ví dụ:

- **Card Total Sales** trả lời câu hỏi: Tổng doanh thu hiện tại là bao nhiêu?

- **Line Chart Sales by Month** trả lời câu hỏi: Doanh thu biến động theo thời gian ra sao?
- **Bar Chart Sales by Category** trả lời câu hỏi: Category nào đóng góp doanh thu nhiều nhất?

Nếu có 2 visual cùng trả lời một câu hỏi, hãy giữ lại visual rõ ràng hơn.

II.1.3. Hướng dẫn từng bước: Cách dọn clutter trên một trang report

Giả sử bạn có một trang Overview trong Adventure Works với các thành phần sau:

- 4 KPI Cards
- 1 Bar Chart: Sales by Category
- 1 Pie Chart: Sales by Category
- 1 Table chi tiết sản phẩm
- 1 Line Chart theo Month
- 4 slicers

Trang này có thể đang quá tải. Ta sẽ dọn lại theo từng bước.

Bước 1: Xác định mục tiêu của trang Trước tiên, hãy tự hỏi:

- Trang này là **overview** hay **detail**?
- Người dùng mở trang này lên để làm gì?
- Trong 5 giây đầu tiên, họ cần biết điều gì?

Nếu đây là **overview page**, mục tiêu nên là:

- biết tổng doanh thu,
- biết xu hướng chung,
- biết category nào quan trọng nhất,
- và có thể lọc theo vài tiêu chí chính.

Khi đó, bảng chi tiết dài và pie chart trùng insight có thể chưa cần xuất hiện ở đây.

Bước 2: Loại bỏ visual trùng lặp Kiểm tra từng visual và đặt câu hỏi: *Visual này có mang lại insight mới không?*

Ví dụ:

- Bar Chart: Sales by Category
- Pie Chart: Sales by Category

Cả hai đều trả lời gần như cùng một câu hỏi. Trong đa số trường hợp, **Bar Chart nên được giữ lại** vì:

- dễ so sánh độ dài hơn so với góc của lát cắt pie,
- hiển thị tốt hơn khi có nhiều category,
- dễ gắn data labels,
- trực quan hơn khi sắp xếp top-to-bottom.

Kết luận: **xóa Pie Chart**.

Bước 3: Đưa thông tin chi tiết xuống tầng dưới Nếu trang có Table dài hiển thị từng sản phẩm hoặc từng đơn hàng, hãy cân nhắc:

- chuyển xuống trang chi tiết,
- hoặc dùng Drill-through,
- hoặc chỉ giữ Top N.

Ví dụ: thay vì hiển thị 150 sản phẩm trong một Table, bạn có thể:

- hiển thị Top 10 Products by Sales,
- thêm nút "View Details",
- hoặc tạo Drill-through page "Product Details".

Bước 4: Tắt những yếu tố trình bày không cần thiết Trong từng visual, vào **Format Visual** và kiểm tra:

- **Title:** tiêu đề có ngắn gọn không?
- **Gridlines:** có thực sự cần không?
- **Border:** có cần ở tất cả visual không?
- **Data labels:** có cần bật hết không?

- **Legend:** có thể bỏ nếu tiêu đề hoặc màu đã đủ rõ?
- **Background:** có nên để trong suốt hoặc rất nhẹ?

Rất nhiều trường hợp chỉ cần tắt gridlines, bỏ border và rút ngắn title là report đã "thoáng"hơn rõ rệt.

Bước 5: Giảm số lượng slicers trên một trang Slicer rất hữu ích, nhưng quá nhiều slicer sẽ chiếm diện tích canvas và gây phân tán chú ý.

Trên một trang overview, nên ưu tiên 3-5 slicer thực sự quan trọng, ví dụ:

- Year
- Region
- Category

Các filter ít dùng hơn có thể:

- đưa vào Filter Pane,
- hoặc đặt trong một panel ẩn/hiện bằng Bookmarks + Buttons.

Checklist giảm clutter cho một trang Overview

- Không quá 6-8 visual chính trên một trang
- Mỗi visual trả lời một câu hỏi khác nhau
- Không lặp lại cùng một dimension ở nhiều visual nếu không có mục đích rõ ràng
- Chỉ giữ chi tiết cần thiết cho overview
- Hạn chế bật toàn bộ labels, borders, gridlines
- Sử dụng khoảng trắng (*white space*) để chia nhóm nội dung

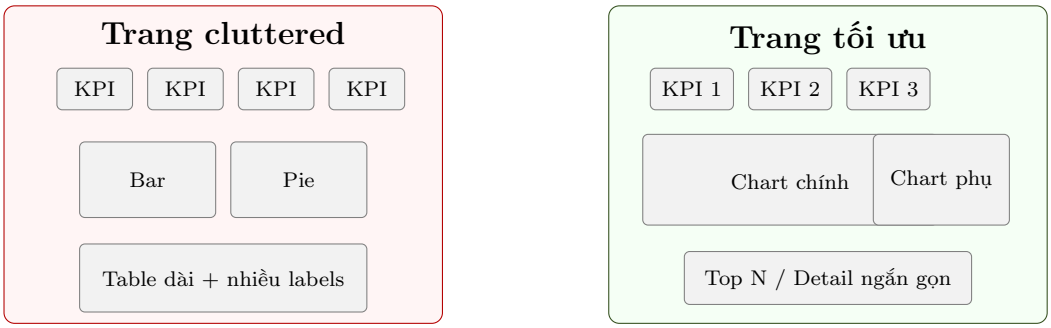

Hình 2: So sánh giữa một trang report bị clutter (trái) và một trang đã tinh gọn lại theo nguyên tắc mỗi visual phục vụ một insight rõ ràng (phải).

II.2. Thiết lập thứ bậc thông tin (Information Hierarchy)

Sau khi đã giảm bớt clutter, câu hỏi tiếp theo là: **người dùng nên nhìn vào đâu trước?**

Đây là lúc **information hierarchy** phát huy vai trò. Một dashboard tốt cần có thứ bậc thông tin rõ ràng, để mắt người dùng được dẫn dắt theo đúng trình tự:

KPI quan trọng → xu hướng chính → phân tích nguyên nhân → chi tiết bổ sung

Information Hierarchy là gì?

Information Hierarchy là cách sắp xếp các thành phần trên report theo mức độ quan trọng, để người dùng biết:

- đâu là thông tin chính,
- đâu là thông tin hỗ trợ,
- đâu là chi tiết chỉ cần đọc khi muốn đào sâu thêm.

Nếu mọi visual đều giống nhau về kích thước, màu sắc và vị trí, người dùng sẽ phải tự "giải mã"dashboard. Điều này làm chậm tốc độ đọc report rất nhiều.

II.2.1. Người dùng thường đọc report theo pattern nào?

Trong thiết kế giao diện, mắt người dùng thường quét nội dung theo:

- **F-pattern**: phổ biến với trang có nhiều thông tin dạng bảng, dashboard, báo cáo
- **Z-pattern**: phổ biến với bố cục đơn giản, ít thành phần

Điểm chung là:

- góc trên trái thường được nhìn đầu tiên,
- hàng trên cùng được chú ý nhiều nhất,
- phần trung tâm là nơi visual chính nên đặt,
- phần dưới cùng phù hợp cho bảng chi tiết hoặc biểu đồ phụ.

Nguyên tắc thực hành

Nếu bạn chỉ có 3 giây để người dùng hiểu report của mình, hãy đảm bảo insight quan trọng nhất xuất hiện ở **góc trên trái** hoặc **hàng trên cùng**.

II.2.2. Bốn công cụ để tạo hierarchy rõ ràng

1. Vị trí (Position) Những gì đặt ở trên cùng và bên trái thường được xem trước.

Trong Power BI:

- Đặt KPI tổng quan ở hàng trên cùng
- Đặt chart quan trọng nhất ở giữa hoặc hơi lệch trái
- Đặt bảng chi tiết ở phía dưới

2. Kích thước (Size) Visual quan trọng hơn nên lớn hơn. Đây là cách nhanh nhất để tạo cảm giác thứ bậc.

Ví dụ:

- 1 Line Chart chính về Sales Trend có thể chiếm 40-50% chiều ngang trang
- một chart phụ về Sales by Segment có thể nhỏ hơn
- các KPI cards chỉ cần vừa đủ rõ

3. Độ tương phản (Contrast) Không phải mọi phần trên report đều cần nổi bật như nhau. Một số thành phần nên đóng vai trò nền, một số nên được nhấn mạnh.

Ví dụ:

- KPI chính dùng font lớn hơn và màu đậm hơn
- visual phụ dùng màu trung tính hơn
- nhãn phụ, chú thích, divider nên nhẹ hơn

4. Nhóm nội dung (Grouping) Những nội dung liên quan nên được đặt gần nhau để người dùng hiểu rằng chúng thuộc cùng một "khối logic".

Ví dụ:

- nhóm 3 KPI liên quan đến Sales đặt cùng một hàng
- slicers đặt cùng một khu vực
- chart phân tích nguyên nhân đặt dưới KPI

II.2.3. Cấu trúc layout gợi ý cho một trang dashboard

Một bố cục phổ biến và hiệu quả trong Power BI là:

1. **Hàng trên cùng:** KPI cards quan trọng nhất
2. **Khu vực giữa:** 1 visual chính + 1 visual phụ
3. **Khu vực dưới:** table, matrix, hoặc chart chi tiết

4. **Cạnh trái hoặc trên:** slicers

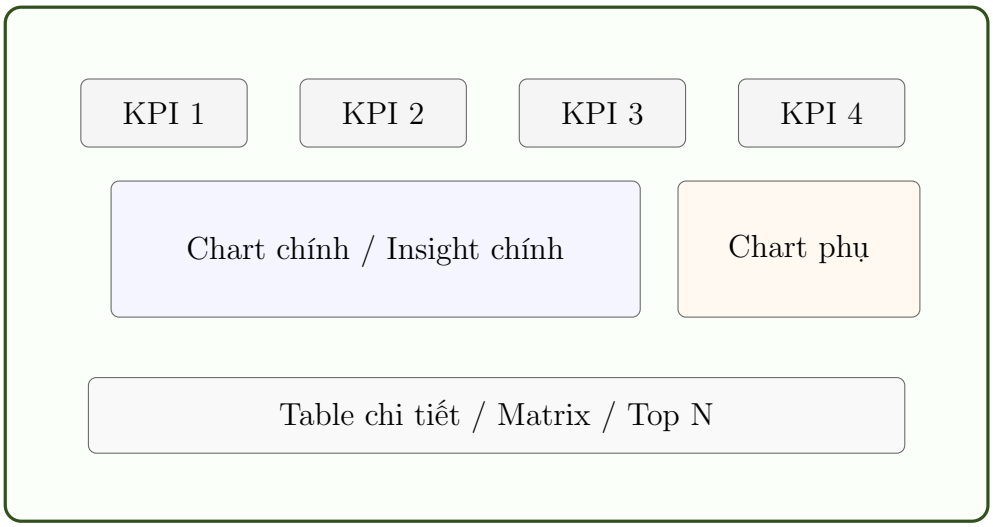

Hình 3: Bố cục dashboard phổ biến: hàng trên cùng cho KPI, khu vực giữa cho chart chính, phía dưới cho chi tiết. Đây là cách tổ chức thông tin theo thứ bậc rất dễ đọc.

II.2.4. Hướng dẫn từng bước: Sắp xếp hierarchy trong Power BI

Bước 1: Xác định KPI quan trọng nhất Trước khi kéo visual lên canvas, hãy quyết định:

- metric nào là quan trọng nhất,
- metric nào chỉ là hỗ trợ,
- insight nào người dùng cần thấy đầu tiên.

Ví dụ với Adventure Works:

- KPI chính: **Total Sales**
- KPI phụ: **Total Orders**, **Avg Order Amount**, **Profit Margin**

Bước 2: Đặt KPI ở hàng trên Trong Report View:

1. Tạo 3-4 Card visuals
2. Căn theo một hàng ngang
3. Dùng **Format** → **Align** để canh thẳng hàng
4. Dùng **Format Painter** hoặc copy/paste style để giữ nhất quán

Bước 3: Chọn 1 visual làm "hero visual" Hero visual là visual quan trọng nhất của trang. Đây là nơi người dùng sẽ nhìn lâu nhất.

Ví dụ:

- Line Chart Sales Trend theo Month
- Bar Chart Sales by Category
- Map by Region

Visual này nên:

- lớn hơn visual khác,
- đặt ngay dưới hàng KPI,
- có title rõ ràng,
- tránh quá nhiều chi tiết phụ.

Bước 4: Đặt visual phụ bên cạnh hoặc phía dưới Visual phụ nên đóng vai trò giải thích thêm cho hero visual.

Ví dụ:

- nếu hero visual là Sales Trend theo thời gian,
- thì visual phụ có thể là Sales by Category hoặc Sales by Region.

Bước 5: Đưa chi tiết xuống cuối trang Các visual như:

- Table
- Matrix
- Top N details
- phân tích sâu

nên được đặt phía dưới, vì đây là nơi người dùng chỉ nhìn đến sau khi đã hiểu bức tranh tổng thể.

Checklist đánh giá hierarchy

- KPI quan trọng nhất có xuất hiện ở trên cùng không?
- Có một visual rõ ràng đóng vai trò hero visual không?
- Visual chi tiết đã được đặt thấp hơn visual tổng quan chưa?

- Người dùng có thể hiểu insight chính trong vài giây đầu tiên không?

Lưu ý

Đừng để tất cả visual có cùng kích thước. Khi mọi thứ đều to và nổi bật như nhau, thực chất là không có gì nổi bật cả.

II.3. Sử dụng màu sắc chiến lược để tạo điểm nhấn và insight

Màu sắc là một trong những công cụ mạnh nhất trong thiết kế dashboard. Chỉ với một màu nhấn đúng chỗ, bạn có thể khiến người dùng ngay lập tức nhận ra điều gì đang quan trọng. Nhưng nếu dùng màu không kiểm soát, dashboard sẽ trở nên rối mắt, thiếu chuyên nghiệp và khó đọc.

Nguyên tắc quan trọng

Màu sắc trong dashboard không nên dùng chủ yếu để trang trí. Màu nên được dùng để:

- phân biệt nhóm dữ liệu,
- nhấn mạnh insight quan trọng,
- thể hiện trạng thái (tốt/xấu, tăng/giảm),
- dẫn hướng sự chú ý của người dùng.

II.3.1. Ba lỗi phổ biến khi dùng màu trong Power BI

1. Mỗi visual một palette khác nhau Đây là lỗi rất thường gặp: chart đầu dùng xanh dương, chart thứ hai dùng tím, chart thứ ba dùng đỏ-cam-vàng, chart thứ tư lại dùng xanh lá. Khi đó, report mất tính nhất quán và người dùng khó xây dựng ngôn ngữ màu trong đầu.

2. Dùng quá nhiều màu nổi cùng lúc Nếu mọi cột bar đều có màu sáng khác nhau, mọi card đều có background màu đậm, mọi icon đều nổi bật, thì mắt người dùng không biết nên tập trung vào đâu.

3. Màu không mang ý nghĩa rõ ràng Ví dụ:

- tháng này màu đỏ, tháng sau màu xanh, tháng khác màu tím, nhưng không có quy luật
- cùng một category nhưng xuất hiện màu khác nhau ở các visual khác nhau

Khi đó màu chỉ tạo nhiễu, không tạo insight.

II.3.2. Nguyên tắc thiết kế màu hiệu quả

1. Neutral first Phần lớn dashboard nên dùng các màu trung tính:

- trắng,
- xám nhạt,
- đen/xám đậm cho text,
- xanh đậm hoặc màu thương hiệu cho nhấn mạnh.

Nguyên tắc là sử dụng màu một cách có chọn lọc. Các yếu tố thông thường nên được trình bày bằng màu trung tính, còn những thông tin quan trọng mới được nhấn mạnh bằng màu sắc.

2. Highlight selectively Không phải lúc nào cũng cần tô màu cho tất cả data points.

Ví dụ tốt:

- toàn bộ category màu xám
- riêng category cao nhất màu xanh thương hiệu

Ngay lập tức, mắt người dùng bị hút vào cột quan trọng nhất.

3. Consistency Nếu "Bikes"đã là màu xanh ở chart 1, hãy cố gắng để "Bikes"vẫn là màu xanh ở chart 2 và chart 3.

Sự nhất quán này giúp người dùng:

- nhận diện nhanh hơn,
- không phải đọc lại legend nhiều lần,
- thấy report chuyên nghiệp hơn.

4. Limited palette Thông thường, một dashboard business chỉ cần:

- 1 màu chính (*primary*),
- 1-2 màu phụ,
- các sắc xám trung tính.

Không nên lạm dụng 6-8 màu nổi trên cùng một trang.

II.3.3. Các use case dùng màu đúng cách

Use case 1: Highlight Top Performer Bar Chart doanh thu theo Category:

- tất cả categories màu xám nhạt,
- category có doanh thu cao nhất màu xanh đậm.

Người dùng nhìn vào là thấy ngay ai đứng đầu.

Use case 2: Tăng/Giảm so với kỳ trước KPI Growth:

- tăng trưởng dương → màu xanh
- tăng trưởng âm → màu đỏ

Nên đi kèm mũi tên lên/xuống, không chỉ dùng màu.

Use case 3: Đạt/Không đạt target Gauge hoặc KPI card:

- đạt target → xanh
- gần đạt → cam
- dưới target đáng kể → đỏ

II.3.4. Accessibility: Không truyền thông tin bằng màu duy nhất

Lưu ý

Khoảng một tỷ lệ đáng kể người dùng có vấn đề phân biệt màu, đặc biệt là đỏ-xanh. Vì vậy, không nên dùng màu như kênh truyền đạt duy nhất.

Ví dụ:

- Không chỉ dùng xanh = tốt, đỏ = xấu
- Hãy kết hợp thêm icon: ↑, ↓, dấu chấm, ký hiệu cảnh báo
- Hoặc thêm label: 'Above Target', 'Below Target'

II.3.5. Hướng dẫn từng bước: Áp dụng màu chiến lược trong Power BI

Tình huống 1: Highlight 1 category quan trọng trong Bar Chart Giả sử bạn có Bar Chart **Sales by Category**. Bạn muốn làm nổi bật category có doanh thu cao nhất.

Cách 1: tô màu thủ công từng data point

1. Chọn Bar Chart
2. Vào **Format Visual**
3. Mở mục **Data colors**
4. Bật **Show all**
5. Chỉnh:
   - các category thường = màu xám
   - category muốn highlight = màu xanh đậm

Cách này đơn giản nhưng phù hợp khi danh sách ít và không thay đổi nhiều.

Cách 2: dùng conditional formatting theo field value

1. Tạo một measure hoặc cột màu
2. Measure trả về mã màu hex tùy theo logic
3. Trong **Data colors**, chọn **fx**
4. Chọn format by = **Field value**
5. Chọn field chứa mã màu

Ví dụ logic:

- nếu category là top performer → trả về màu xanh
- ngược lại → trả về màu xám

Tình huống 2: Tô màu KPI theo trạng thái đạt target Ví dụ bạn có measure **Sales vs Target %**. Muốn card đổi màu theo mức độ đạt target.

1. Tạo measure đánh giá trạng thái
2. Chọn Card visual
3. Vào **Callout value** hoặc **Data label**
4. Chọn **Color** → nhấn **fx**
5. Chọn Rules hoặc Field value

Gợi ý rule:

- $< 90\%$ target → đỏ
- 90-100% → cam
- $\geq 100\%$ → xanh

Tình huống 3: Giữ palette nhất quán cho toàn report bằng Theme Nếu muốn toàn bộ report dùng cùng một hệ màu, Power BI hỗ trợ **Themes**.

Cách làm:

1. Vào **View**
2. Chọn **Themes**
3. Có thể chọn theme có sẵn hoặc **Customize current theme**
4. Định nghĩa:
   - màu chủ đạo,
   - màu phụ,
   - màu cho text,
   - màu cho background,
   - palette dùng cho data series

Nếu muốn chuyên nghiệp hơn nữa, có thể dùng file **JSON Theme** để toàn bộ team sử dụng cùng chuẩn màu.

Best practices khi dùng màu trong dashboard

- Dùng màu trung tính cho phần lớn thành phần
- Chỉ dùng màu nổi để nhấn mạnh insight chính
- Giữ cùng một màu cho cùng một category xuyên suốt report
- Tránh dùng quá nhiều màu sáng trên một trang
- Kết hợp màu với icon/text để đảm bảo accessibility

Hình 4: Bên trái: mỗi cột một màu nổi gây phân tán chú ý. Bên phải: đa số dùng màu trung tính, chỉ một cột quan trọng được highlight để nhấn mạnh insight.

II.4. Ví dụ thực hành hoàn chỉnh: Thiết kế lại một trang dashboard

Để kết nối ba nguyên tắc vừa học gồm **giảm clutter**, **thiết lập hierarchy**, và **dùng màu chiến lược** chúng ta xét một ví dụ hoàn chỉnh.

II.4.1. Phiên bản ban đầu

Trang dashboard ban đầu có:

- 6 KPI cards
- 1 pie chart và 1 bar chart cùng hiển thị Category
- 1 line chart theo Month
- 1 table chi tiết rất dài
- mọi visual đều có border
- tất cả labels đều bật
- mỗi chart dùng một bảng màu khác nhau

Kết quả:

- người dùng bị rối,
- không rõ insight chính là gì,
- trang nặng hơn cần thiết,
- cảm giác thiếu chuyên nghiệp.

II.4.2. Phiên bản cải tiến

Ta thiết kế lại như sau:

1. Giữ lại 4 KPI quan trọng nhất ở hàng trên
2. Xóa Pie Chart vì trùng insight với Bar Chart
3. Giữ 1 hero visual là Line Chart Sales Trend
4. Đặt Bar Chart Sales by Category bên cạnh hoặc bên dưới
5. Rút Table thành Top 10 Products
6. Tắt bớt labels, bỏ border không cần thiết
7. Dùng palette nhất quán:
    - xanh đậm = điểm nhấn chính
    - xám = phần nền / phần còn lại

II.4.3. Kết quả sau khi tối ưu

Người dùng bây giờ có thể:

- nhìn lên hàng trên để biết KPI tổng quan,
- nhìn vào hero visual để hiểu xu hướng chính,
- nhìn sang chart phụ để biết nguyên nhân hoặc breakdown,
- rồi mới xuống phần chi tiết nếu cần.

Tóm tắt 3 nguyên tắc thiết kế report hiệu quả

1. **Minimize clutter:** bỏ những gì không cần thiết
2. **Create hierarchy:** sắp xếp để người dùng biết nhìn vào đâu trước
3. **Use color strategically:** dùng màu để nhấn mạnh, không để trang trí

Checklist cuối cùng trước khi publish report

- Trang có quá nhiều visual không?
- Có visual nào bị trùng insight không?
- KPI quan trọng nhất đã nằm ở vị trí nổi bật chưa?
- Có một hero visual rõ ràng chưa?
- Màu sắc có nhất quán và có ý nghĩa không?
- Có đang lạm dụng màu nổi, border, labels, gridlines không?
- Người dùng mới có thể hiểu bức tranh chính trong 5 giây đầu không?

III. Slicers: Bộ lọc Trực quan trên Canvas

III.1. Slicer là gì?

Khi mở một report Power BI, người dùng thường muốn lọc dữ liệu theo một tiêu chí nhất định: chỉ xem doanh thu năm 2019, chỉ xem khu vực châu Âu, hoặc chỉ xem sản phẩm thuộc danh mục Accessories. Power BI cung cấp 2 cách lọc chính:

- **Filter Pane** (bảng lọc bên phải): Ẩn sau một icon nhỏ, người dùng phải biết click vào mới mở được. Phù hợp cho filter kỹ thuật mà người thiết kế report muốn đặt sẵn.
- **Slicer** (bộ lọc trên canvas): Nằm ngay trên mặt report, nhìn thấy và tương tác được ngay. Phù hợp cho filter mà người dùng **cần thường xuyên thay đổi**.

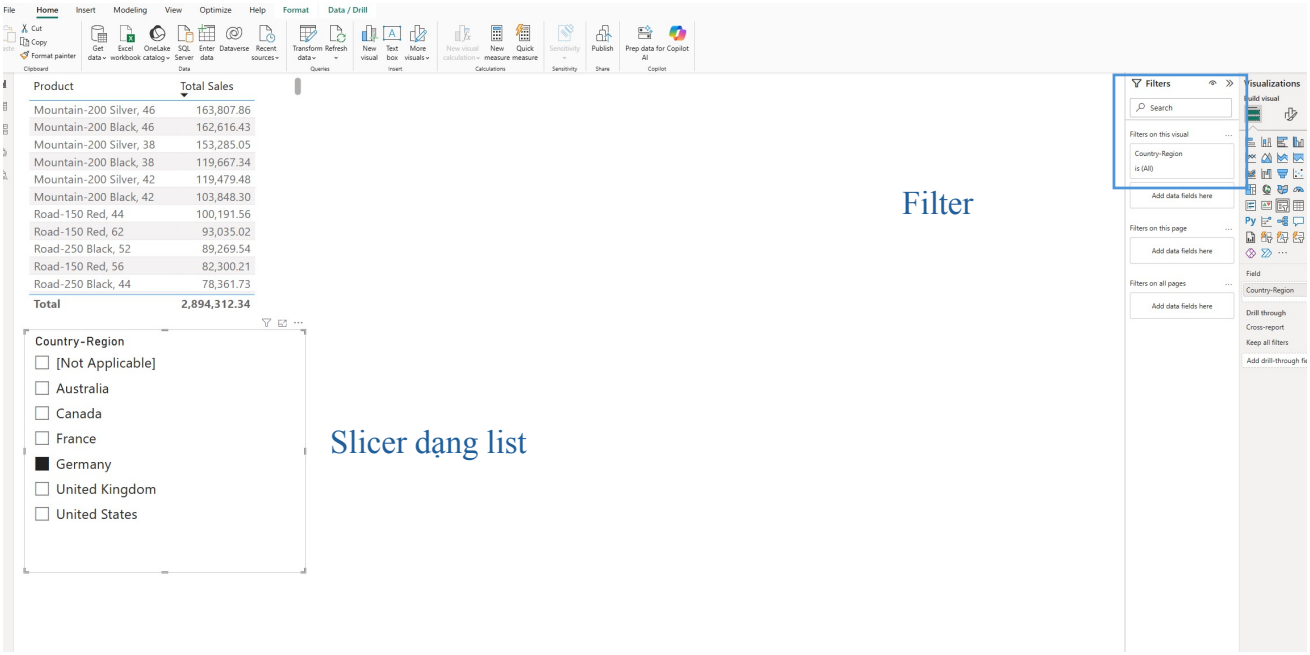

Hình 5: Slicer dạng List (trái, trên canvas) và Filter Pane mở bên phải – cả hai đều lọc dữ liệu, nhưng Slicer hiện ngay trên report để người dùng thấy và tương tác trực tiếp.

Hãy nghĩ về slicer như nút bấm trên remote TV: thay vì phải đi đến TV bấm nút (Filter Pane), bạn chỉ cần nhấn nút trên remote ngay tại chỗ.

Một điểm quan trọng cần nhớ: khi **không có item nào được chọn** trong slicer, Power BI coi như **tất cả đều được chọn**. Nghĩa là slicer ở trạng thái mặc định sẽ không lọc bất kỳ thứ gì.

III.2. Tạo Slicer đầu tiên

Chúng ta sẽ tạo slicer lọc theo **Year** từ bảng Date. Có 2 cách:

Cách 1: Từ Visualizations pane

1. Trong Report View, click vào vùng trống trên canvas.
2. Trong Visualizations pane (bên phải), click icon **Slicer** (hình phễu với thanh ngang).
3. Trong Fields pane, kéo cột **Country-Region** từ bảng **DimCustomer** vào vùng **Field** của slicer.
4. Slicer hiện ra ngay trên canvas với danh sách các Country-Region.

Cách 2: Từ Fields pane (nhanh hơn)

1. Trong Fields pane, tích chọn cột **Fiscal Year** từ bảng **Date**. Một Table visual tự xuất hiện.

2. Với visual đang được chọn, click icon **Slicer** trong Visualizations pane để chuyển đổi.

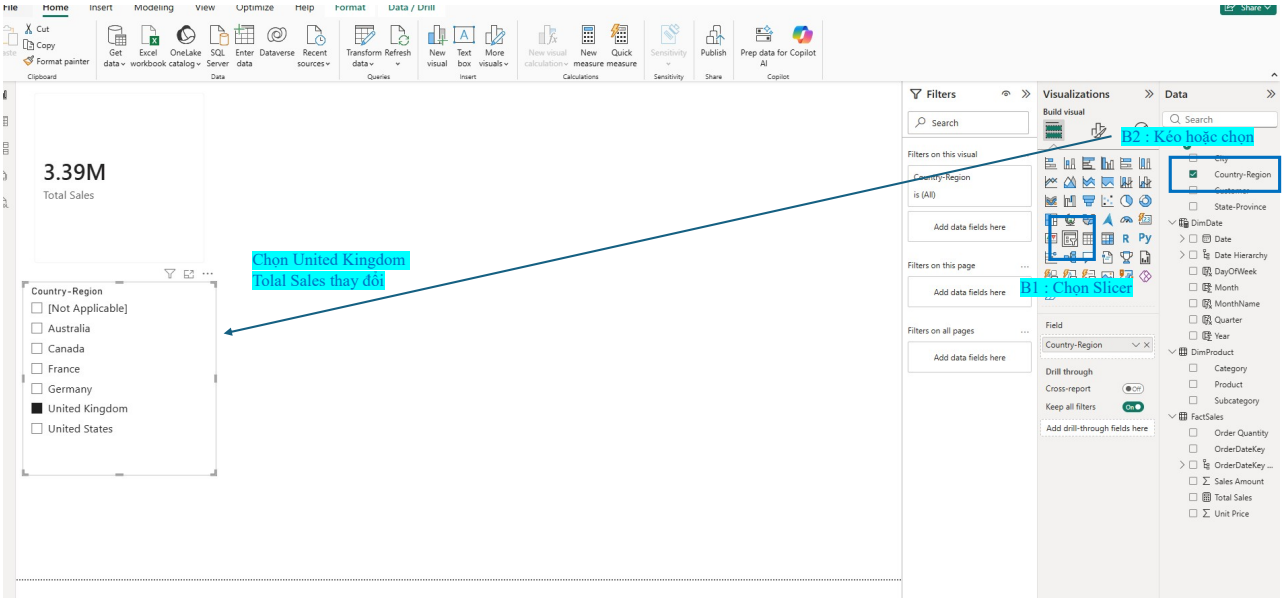

Hình 6: Total Sales hiển thị trong Card. Khi chọn Country-Region = "United States" trên Slicer, giá trị tự động cập nhật. Đây chính là Filter Context đang hoạt động.

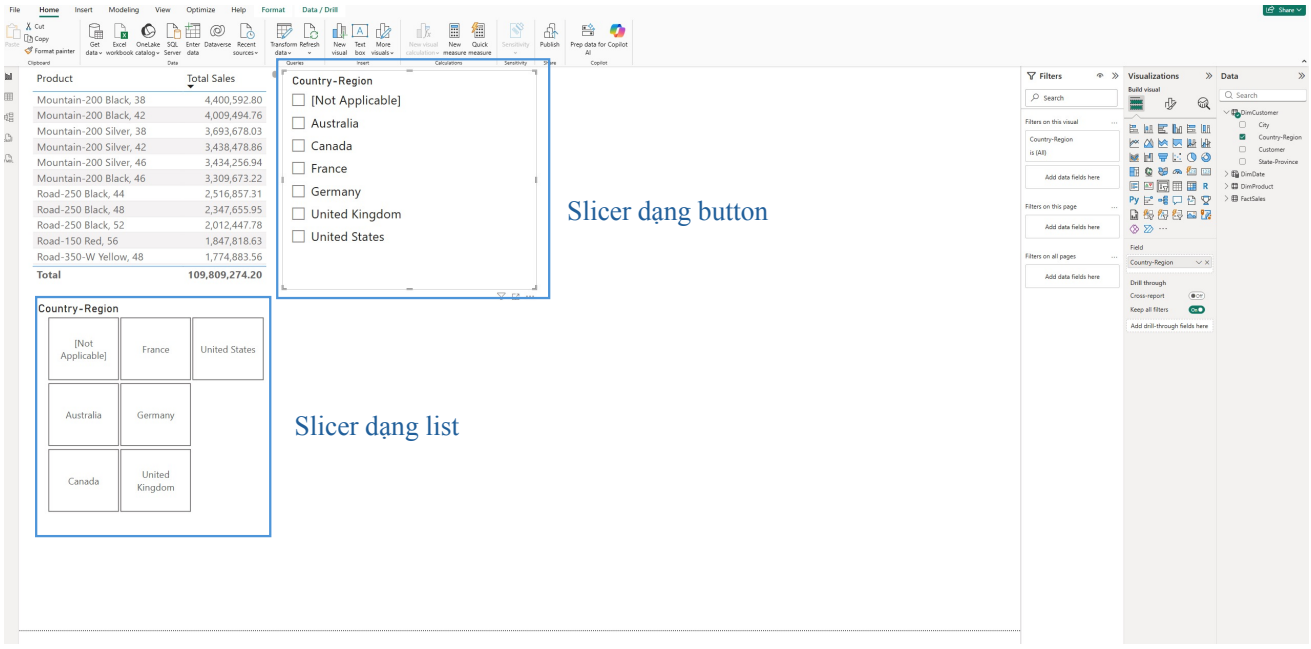

Hình 7: Hai kiểu Slicer phổ biến: Button Slicer (các nút bấm chọn) và Basic Slicer (danh sách checkbox). Cả hai đều nằm ngay trên canvas để người dùng thấy và tương tác trực tiếp, khác với Filter Pane ẩn ở góc phải.

Sau khi tạo xong, thử click vào **United Kingdom** trên slicer. Ngay lập tức, Total Sales sẽ hiển thị tổng doanh thu của **United Kingdom**. Click lại **United Kingdom** để bỏ chọn và quay về trạng thái ban đầu.

Nguyên tắc quan trọng: Luôn tạo slicer từ Dimension table

Trong ví dụ trên, chúng ta kéo Country-Region từ bảng **DimCustomer** (Dimension), không phải từ bảng **FactSales** (Fact). Vì sao?

- Dimension table chứa **giá trị duy nhất** (mỗi Country chỉ xuất hiện 1 lần), nên slicer gọn gàng.
- Fact table chứa hàng triệu giao dịch, nếu tạo slicer từ đây, Power BI phải quét toàn bộ bảng để tìm giá trị duy nhất, rất chậm.

Quy tắc: **Fact table dùng để đo lường (measure), Dimension table dùng để lọc (slicer, filter).**

III.3. Các loại Slicer

Slicer không chỉ có dạng danh sách. Tùy loại dữ liệu, Power BI cung cấp nhiều kiểu hiển thị khác nhau:

III.3.1. List (Danh sách)

Đây là kiểu mặc định cho text/category. Mỗi giá trị hiện trên một dòng với checkbox bên trái.

- **Phù hợp:** Ít giá trị (dưới 10 items), VD: khu vực bán hàng (North America, Europe, Pacific).
- **Chọn nhiều:** Giữ **Ctrl** rồi click (mặc định). Có thể tắt "Multi-select with CTRL" trong settings để click tự do.

Ví dụ: Kéo `DimSalesTerritory[SalesTerritoryGroup]` vào canvas → Power BI tự tạo slicer List với 3 giá trị: North America, Europe, Pacific. Click "North America" để lọc toàn trang. Ctrl+click thêm "Europe" để chọn cả hai.

III.3.2. Dropdown (Menu thả xuống)

Chuyển từ List sang Dropdown bằng cách click icon **mũi tên xuống** ở góc phải trên slicer (hoặc Format → Slicer Settings → Style → Dropdown).

- **Phù hợp:** Danh sách dài (20+ items), VD: danh sách Customer, Product.
- **Tiết kiệm:** Chỉ chiếm 1 dòng khi thu gọn, mở rộng khi click.
- **Search:** Bật tìm kiếm bằng Format → Slicer Settings → Selection → **Show search bar**. Đặc biệt hữu ích khi có hàng trăm giá trị.

III.3.3. Tile / Button (Nút bấm ngang)

Để tạo slicer dạng nút bấm:

1. Tạo slicer bình thường (List).
2. Format → Slicer Settings → Options → **Orientation: Horizontal**.
3. Hoặc chọn Style: **Tile**.

- **Phù hợp:** Lọc trực quan, ít giá trị, dạng tab. VD: `DimSalesTerritory[SalesTerritoryGroup]` có 3 giá trị North America / Europe / Pacific.
- **Hiệu ứng:** Có thể tùy chỉnh formatting states: **Rest** (bình thường), **Hover** (khi rê chuột), **Press** (đang nhấn), **Selected** (đã chọn).

Ví dụ: Kéo `DimSalesTerritory[SalesTerritoryGroup]` vào canvas (3 giá trị: North America, Europe, Pacific) → Format → Slicer Settings → Style: **Tile**. Giờ report có thanh tab 3 nút theo khu vực.

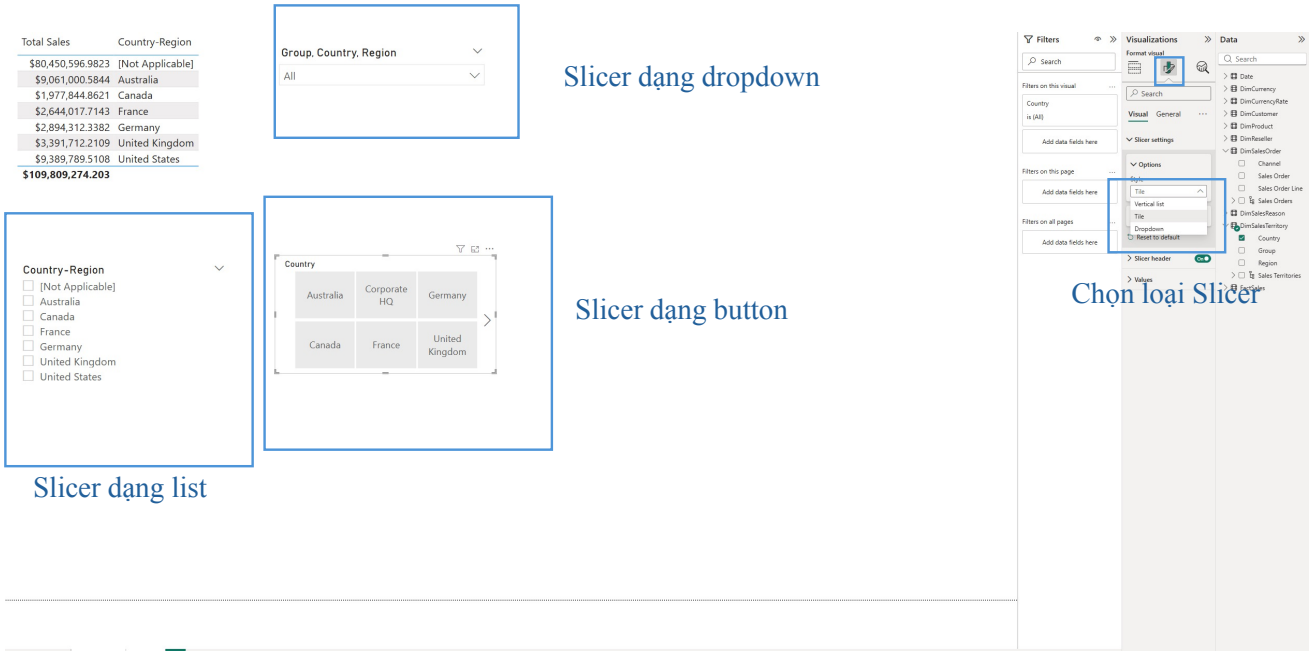

Hình 8: Ba loại Slicer trong PowerBi.

III.3.4. Between / Range (Khoảng giá trị)

Cho các cột **numeric** hoặc **date**, slicer tự động hiện dạng thanh trượt (slider) hoặc bộ chọn "Between":

- **Between:** Chọn giá trị từ... đến... (VD: từ 01/01/2019 đến 31/12/2019).

- **Before / After:** Chỉ hiện dữ liệu trước hoặc sau một mốc.
- **List of values:** Liệt kê từng giá trị riêng lẻ (ít dùng cho date).

Ví dụ: Kéo `FactSales[SalesAmount]` vào slicer → Power BI tự hiện dạng slider Between. Kéo thanh trượt trái sang phải để lọc chỉ hiện đơn hàng có giá trị từ 500$ đến 5,000$.

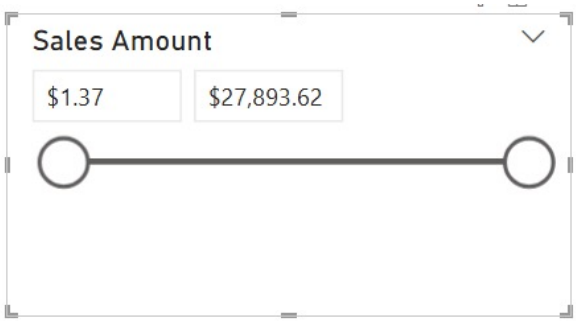

Hình 9: Range Slicer.

Lưu ý

Ví dụ trên chỉ để minh họa kiểu hiển thị Between/slider. Trong thực tế, nên tránh tạo slicer từ cột Fact table (xem Best Practices ở II.F). Nếu cần lọc theo khoảng doanh thu, hãy xem xét thêm cột phân nhóm (VD: "Low/Medium/High") vào bảng Dimension rồi dùng slicer từ đó.

III.3.5. Relative Date / Relative Time

Đây là kiểu slicer đặc biệt cho date, cho phép lọc **tương đối** thay vì tuyệt đối:

- VD: "3 tháng gần nhất", "tuần này", "năm ngoái".
- Power BI tự cập nhật khi data refresh, không cần sửa thủ công.

Cách bật: chọn slicer date → Format Visual → Visual → Slicer Settings → Style → **Relative Date** (hoặc Relative Time).

Ví dụ: Tạo slicer `DimDate[FullDateAlternateKey]` → đổi Style sang **Relative Date** → chọn "is in the last 3 months". Bây giờ mỗi lần data được refresh, report tự động chỉ hiện 3 tháng gần nhất mà không cần đổi filter thủ công.

Tóm tắt lựa chọn kiểu Slicer

Loại dữ liệu	Kiểu slicer khuyên dùng	Ví dụ
Text, ít giá trị	List hoặc Tile	`DimSalesTerritory [SalesTerritoryGroup]`, `DimDate[FiscalYear]`
Text, nhiều giá trị	Dropdown + Search	`DimCustomer [City]`, `DimProduct [EnglishProductName]`
Date	Between hoặc Relative Date	`DimDate [FullDateAlternateKey]`
Number	Between (slider)	`FactSales[SalesAmount]`

III.4. Format và Selection Settings

Sau khi chọn đúng kiểu slicer, chúng ta cần tinh chỉnh hành vi chọn (selection) để phù hợp với use case.

Selection Controls

Chọn slicer → Format Visual → Visual → Slicer Settings → **Selection**:

Setting	Mặc định	Mô tả
Single Select	Off	Bật On → chỉ cho phép chọn **1 giá trị** tại một thời điểm
Multi-select with CTRL	On	Bật On → phải giữ Ctrl để chọn nhiều. Tắt → click tự do để toggle
Show "Select all"	Off	Bật On → thêm checkbox "Select all" ở đầu danh sách

Mẹo

Nếu report dùng cho người dùng cuối không quen Power BI, nên tắt "Multi-select with CTRL" để họ click tự do mà không cần nhớ phím Ctrl.

Clear Selections

Để **bỏ hết** lựa chọn trên slicer (quay về "tất cả"), hover chuột lên header của slicer → click icon **bút xóa** (eraser) xuất hiện ở góc phải.

Responsive Slicer

Slicer có thể tự co giãn theo kích thước visual:

1. Chọn slicer → Format Visual → General → Properties → **Advanced options**.
2. Bật **Responsive: On**.
3. Khi thu nhỏ slicer quá mức, nó tự chuyển thành icon filter nhỏ gọn.

Tính năng này rất hữu ích khi report cần hiển thị trên nhiều kích thước màn hình.

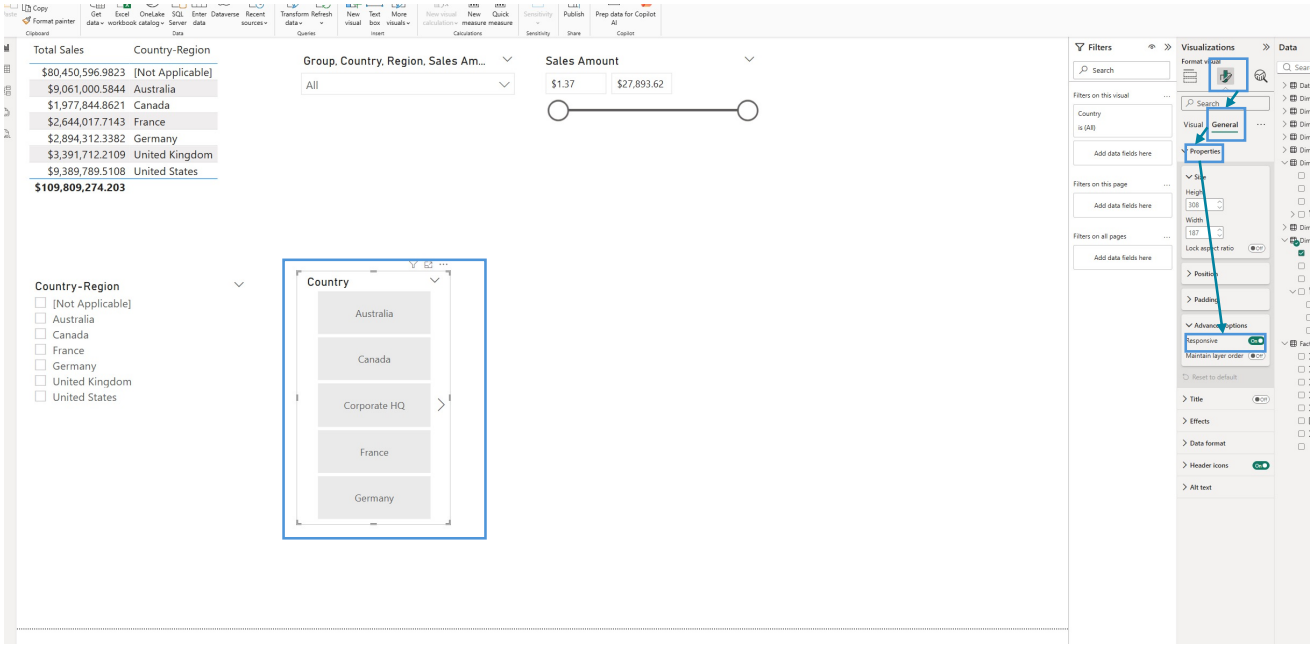

Hình 10: Slicer dạng Tile – mỗi giá trị hiển thị như một ô bấm. Khi bật Responsive trong Format pane, slicer tự co giãn theo kích thước visual; thu nhỏ đủ sẽ chuyển thành icon filter gọn.

III.5. Sync Slicers giữa các trang

Report nhiều trang thường gặp vấn đề: người dùng chọn FY2019 trên trang Overview, nhưng sang trang Sales Detail thì filter lại mất. **Sync Slicers** giải quyết vấn đề này.

Cách thiết lập

1. Chọn slicer muốn đồng bộ.
2. Vào **View** → **Sync slicers** pane (xuất hiện bên phải).
3. Bảng hiện danh sách tất cả trang report, với 2 cột:
   - **Sync** (icon 2 mũi tên tròn): Có đồng bộ filter không?
   - **Visible** (icon con mắt): Có hiện slicer trên trang đó không?

Kết hợp	Ý nghĩa
Sync ✓, Visible ✓	Trang đó nhận filter VÀ hiện slicer
Sync ✓, Visible ×	Trang đó nhận filter nhưng **không hiện** slicer (tiết kiệm canvas)
Sync ×, Visible ×	Trang đó hoàn toàn độc lập

Mẹo nhanh

Copy slicer (Ctrl+C) từ trang này, Paste (Ctrl+V) sang trang khác. Power BI sẽ hỏi "Sync visuals?" → chọn **Sync** để tự động liên kết.

Synchronization Groups

Nếu report có nhiều slicer Year ở nhiều trang và bạn muốn chúng đồng bộ theo nhóm:

1. Chọn slicer → Sync slicers pane → **Advanced options**.
2. Đặt tên **Sync Group** (VD: "Year_Group").
3. Chỉ slicer cùng group mới đồng bộ với nhau.

III.6. Best Practices cho Slicers

Tổng hợp các kinh nghiệm thực tế khi làm việc với slicer:

Nên làm

- **Dimension table:** Luôn tạo slicer từ Dimension, không Fact.
- **Dropdown + Search:** Cho danh sách dài hơn 10 items.
- **Nút "Apply":** Cho dataset lớn, bật Format → Slicer Settings → Selection → **Show Apply button**. Người dùng chọn xong mới nhấn Apply, tránh report refresh liên tục sau mỗi click.
- **Edit Interactions:** Nếu muốn slicer chỉ ảnh hưởng vài visual (không phải tất cả), dùng Edit Interactions (chi tiết ở Phần III).
- **Sync Slicers:** Cho report nhiều trang.

Lưu ý

Tránh:

- Quá nhiều slicer trên 1 trang (3-5 là tối ưu).
- Tạo slicer từ Fact table (chậm, không chính xác).
- Slicer List cho danh sách 100+ items (dùng Dropdown).

IV. Cross-filtering và Cross-highlighting

IV.1. Hành vi mặc định

Ngay cả khi chúng ta không thiết lập gì đặc biệt, report Power BI đã có sẵn khả năng tương tác giữa các visual. Hãy thử: trên một trang report có Bar Chart doanh thu theo `DimProduct [Color]` và Column Chart theo `DimDate[Fiscal Year]`, click vào một thanh sản phẩm trên Bar Chart. Lập tức, Pie Chart bên cạnh cũng phản ứng.

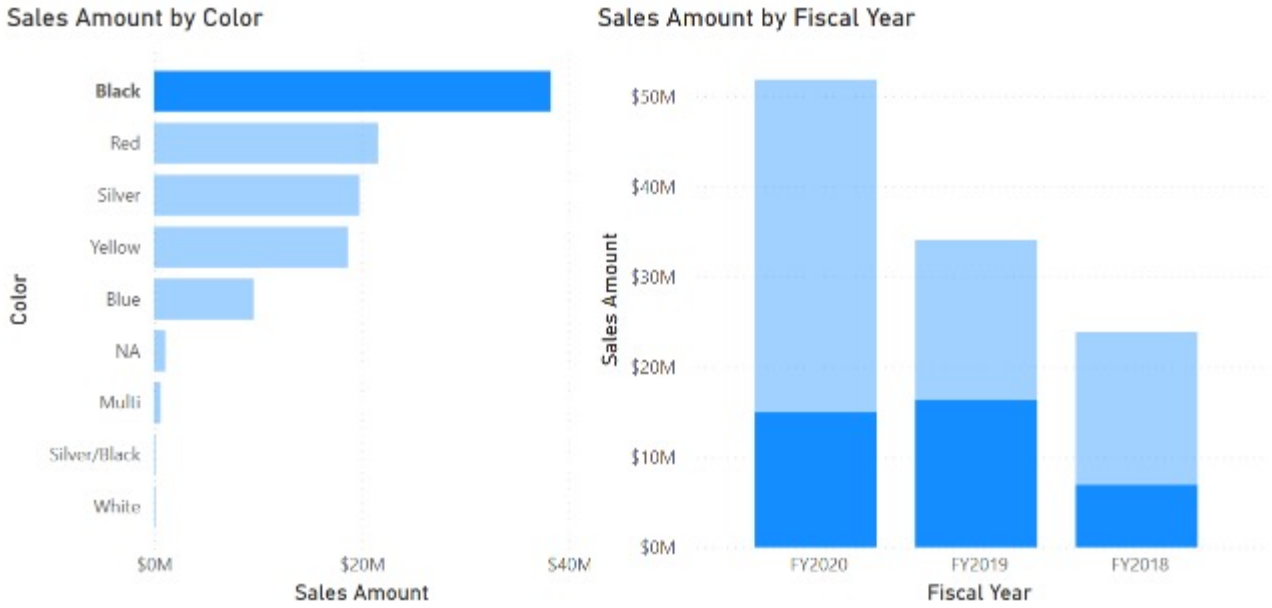

Hình 11: Click vào một thanh bar chart → visual bên cạnh tự động highlight (làm sáng) phần liên quan và làm mờ phần còn lại. Đây là hành vi cross-highlighting mặc định của Power BI.

Đây là hành vi **mặc định** của Power BI, không cần cấu hình. Nhưng phản ứng cụ thể có 2 dạng khác nhau, và việc phân biệt chúng rất quan trọng.

IV.2. Highlight vs Filter: Khác nhau thế nào?

Cross-highlighting (mặc định cho hầu hết visual): Khi click "Black"trên Bar Chart Color, các visual khác **làm mờ** (dim) phần dữ liệu không liên quan đến Black. Phần liên quan được **giữ nguyên màu**. Tổng thể vẫn hiển thị, giúp người dùng nhìn thấy cả bức tranh toàn cảnh và so sánh tỉ lệ.

Cross-filtering: Khi click "Black"trên Bar Chart Color, các visual khác **xóa bỏ hoàn toàn** phần dữ liệu không liên quan đến "Black". Chỉ hiển thị data thuộc Bikes.

So sánh nhanh

	Cross-highlighting	Cross-filtering
Hiệu ứng	Dim (làm mờ) phần không liên quan	Xóa bỏ phần không liên quan
Tổng thể	Vẫn nhìn thấy toàn bộ	Chỉ thấy phần được chọn
Mặc định cho	Bar, Column, Pie, Donut, Treemap...	Table, Matrix, Map
Khi nào dùng	So sánh tỉ lệ, thấy bức tranh chung	Phân tích chi tiết, lọc chính xác

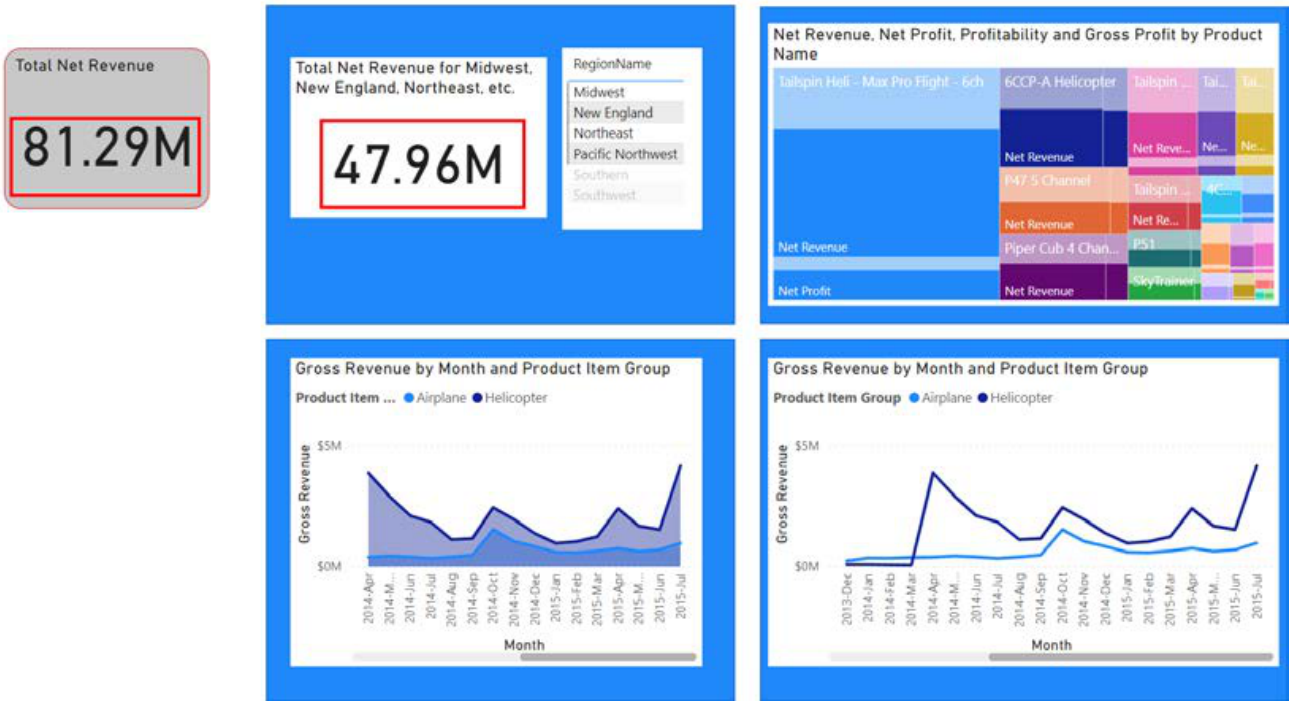

Hình 12: Trang report cho phép người dùng cross-filter theo 4 vùng (màu xanh), trong khi Card "[Total Sales]" ở ô xám luôn hiện tổng toàn bộ – đây là kỹ thuật dùng "None" trong Edit Interactions để Card không bị filter.

IV.3. Edit Interactions: Kiểm soát tương tác

Hành vi mặc định thường phù hợp, nhưng không phải lúc nào cũng vậy. Ví dụ: trên trang dashboard có Card hiển thị **Total Sales Amount** (tổng doanh thu toàn bộ). Khi click vào "Black: trên Bar Chart, Card cũng bị filter và chỉ hiện doanh thu Black. Nhưng người dùng muốn Card luôn hiện **tổng toàn bộ** để so sánh.

Giải pháp: dùng **Edit Interactions** để tùy chỉnh.

Cách dùng Edit Interactions

1. **Chọn visual nguồn** (visual mà khi click sẽ phát sinh tương tác). VD: chọn Bar Chart.
2. Trên ribbon, vào tab **Format** → click **Edit interactions**.
3. Ngay lập tức, ở **góc phải trên** của mỗi visual khác trên trang, xuất hiện bộ icon:
   - **Phễu** (Filter): Visual đích sẽ bị **filter** khi click visual nguồn.
   - **Pie nhỏ** (Highlight): Visual đích sẽ bị **highlight** (mặc định cho chart).
   - **Vòng tròn gạch chéo** (None): Visual đích **không phản ứng** gì.
4. Click icon mong muốn trên từng visual đích.

Ví dụ thực hành: Card Total Sales không bị filter

1. Trang report có: Bar Chart (Sales by Color), Card (Total Sales Amount), Column Bar Chart (Fiscal Year).
2. Chọn **Bar Chart** → Format → Edit interactions.
3. Trên **Card "Total Sales Amount"**, click icon **None** (vòng tròn gạch chéo).
4. Trên **Column Bar Chart** , giữ nguyên **Highlight** (mặc định).
5. Kết quả: khi click "Black"trên Bar Chart → Line Chart highlight, Card giữ nguyên tổng.

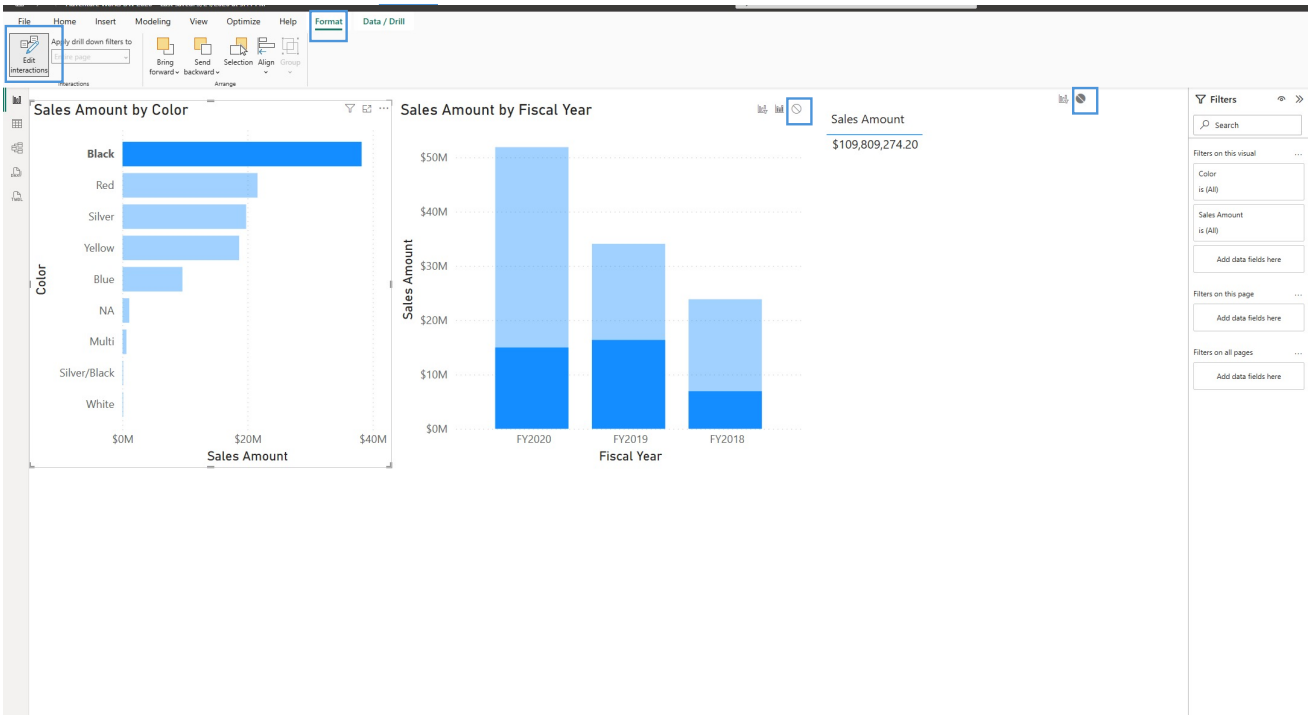

Hình 13: Sau khi bật Edit Interactions, mỗi visual trên trang hiện bộ icon góc phải trên: Filter (phễu), Highlight (pie nhỏ), hoặc None (vòng tròn gạch chéo).

Lưu ý

Phải thực hiện Edit Interactions **cho mỗi visual nguồn riêng biệt**. Nếu trang có 3 chart, bạn cần chọn từng chart rồi thiết lập interaction cho các visual còn lại. Không phải visual nào cũng hỗ trợ cả 3 chế độ. **Card** và **Slicer** chỉ có Filter hoặc None (không có Highlight).

IV.4. Khi nào dùng None?

Dùng **None** là kỹ thuật quan trọng nhưng hay bị bỏ qua. Một số use case phổ biến:

1. **Card tổng cố định:** Card hiển thị Total Revenue, Total Customers cần giữ nguyên giá trị bất kể người dùng click vào đâu.
2. **Visual tham chiếu:** Line Chart hiển thị target/benchmark không nên thay đổi khi click visual khác.
3. **Slicer độc lập:** Đôi khi bạn muốn slicer chỉ ảnh hưởng 1-2 visual cụ thể, không phải toàn trang.

Mẹo nâng cao: Đổi default toàn report

Nếu muốn toàn bộ report dùng **cross-filtering** thay vì cross-highlighting làm mặc định: File → Options and Settings → Options → Report settings → "Change default visual interaction from cross highlighting to cross filtering".

V. Drill-down: Đào sâu theo Phân cấp Dữ liệu

V.1. Hierarchy là gì?

Dữ liệu kinh doanh thường có cấu trúc **phân cấp tự nhiên**. Ví dụ:

- **Thời gian:** Year → Quarter → Month → Day
- **Địa lý:** Country → State → City
- **Sản phẩm:** Category → Subcategory → Product

Drill-down cho phép người dùng bắt đầu từ cấp cao nhất (Year), rồi đi sâu xuống cấp thấp hơn (Quarter, Month) ngay trong cùng một biểu đồ, mà không cần tạo nhiều biểu đồ riêng.

Auto Date Hierarchy

Power BI **tự động tạo** hierarchy cho các cột date. Khi kéo cột **Fiscal** từ bảng **DimDate** vào biểu đồ, Power BI tự thêm các cấp: Year, Quarter, Month. Chúng ta không cần tự tạo.

Tạo Custom Hierarchy

Đối với dữ liệu không phải date, chúng ta cần tạo thủ công:

Ví dụ: Tạo Geographic Hierarchy từ bảng DimCustomer

1. Trong Data pane, mở bảng **DimCustomer**.
2. Chuột phải vào cột **Country-Region** → chọn **Create hierarchy**.
3. Một hierarchy mới xuất hiện với tên "Country-Region Hierarchy".
4. Chuột phải **StateProvince** từ bảng **DimCustomer** → **Add to hierarchy** → "chọn Country-Region Hierarchy"vừa tạo.
5. Tiếp tục làm tương tự với cột **City** để add vào ""Country-Region Hierarchy".
6. Chuột phải vào hierarchy → **Rename** thành “Geographic Hierarchy”. (trong bảng **DimCustomer** đã có 1 hierarchy tạo sẵn là "Geography"các ví dụ sau có thể dùng luôn).

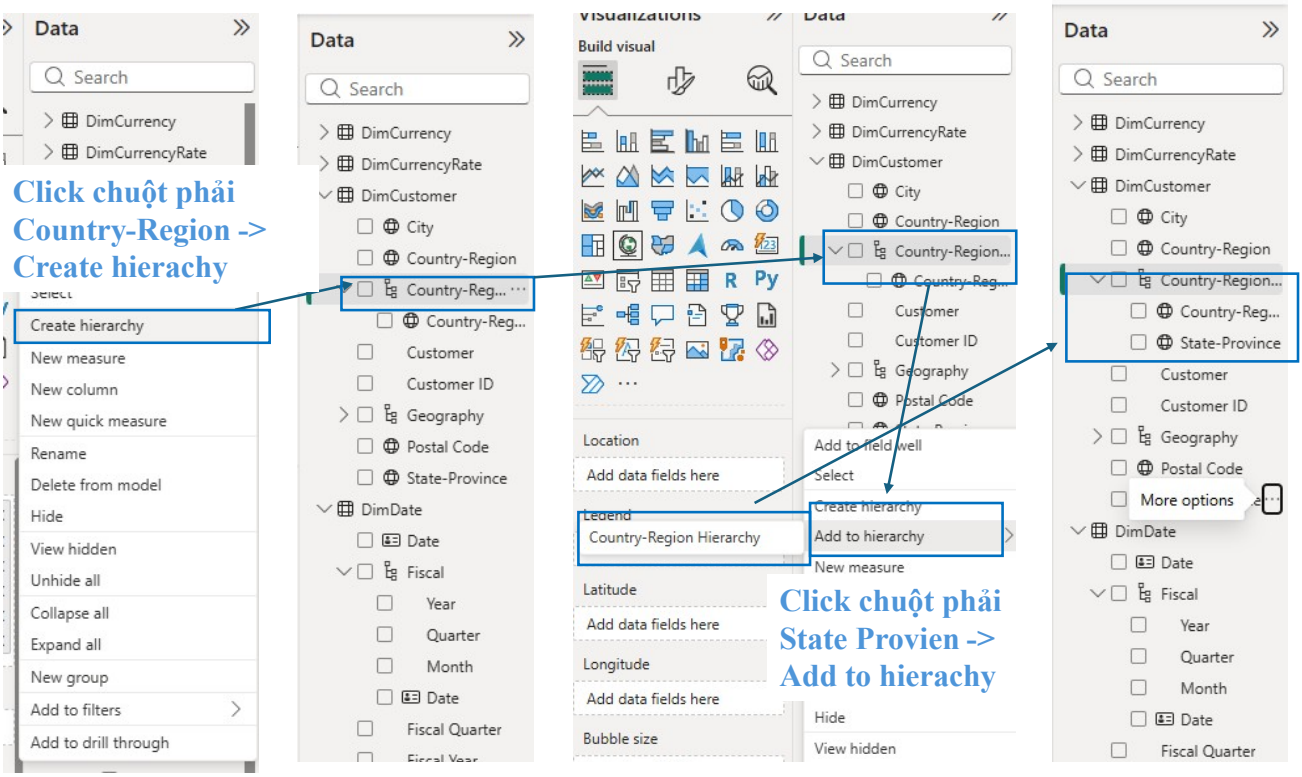

Hình 14: Hierarchy xuất hiện trong Fields pane sau khi tạo các cấp (Country, State, City) được thụt đầu dòng theo phân cấp, có thể kéo vào bất kỳ visual nào để bật tính năng drill-down.

V.2. 4 chế độ Drill-down

Khi visual chứa hierarchy, phía trên visual xuất hiện **Explore menu** (hoặc thanh icon nhỏ ở góc trên). Có 4 chế độ:

V.2.1. Drill Up

Icon: Mũi tên lên trong vòng tròn. **Hành vi:** Quay lại level cao hơn (VD: từ Quarter → Year). **Khi nào dùng:** Sau khi đã drill xuống, muốn quay lại.

V.2.2. Drill Mode và Drill on a single field

Icon: Mũi tên xuống trong vòng tròn (nền xám khi bật). **Hành vi:** Bật chế độ drill. Sau đó, **click vào một data point cụ thể** → visual drill xuống level tiếp **chỉ cho item đó**. **Ví dụ:** Bật Drill Mode → click cột "FY2019" → Bar Chart chuyển sang hiện Quarter 1-4 **chỉ của FY2019**.

V.2.3. Go to Next Level

Icon: 2 mũi tên song song xuống. **Hành vi:** Toàn bộ visual chuyển sang level tiếp theo, **thay thế** level hiện tại. Không filter theo item cụ thể. **Ví dụ:** Đang hiện Year (FY2018, FY2019,

FY2020) → click Go to Next Level → hiện tất cả Quarter (Q1-Q4 của mọi năm, gộp chung).

V.2.4. Expand all one level

Icon: Mũi tên tách nhánh. **Hành vi: Thêm** level tiếp vào, **giữ label** level trước. Khác với Go to Next Level (thay thế). **Ví dụ:** Đang hiện Year → Expand → hiện "FY2018-Q1", "FY2018-Q2"...

So sánh 4 chế độ Drill-down

Chế độ	Icon	Level trước	Phạm vi
Drill Up	↑ trong ○	Quay lại	Toàn bộ
Drill Mode	↓ trong ○ (xám)	Thay thế	Chỉ 1 item được click
Go to Next Level	⇓	Thay thế	Toàn bộ visual
Expand All	↗	**Giữ lại**	Toàn bộ visual

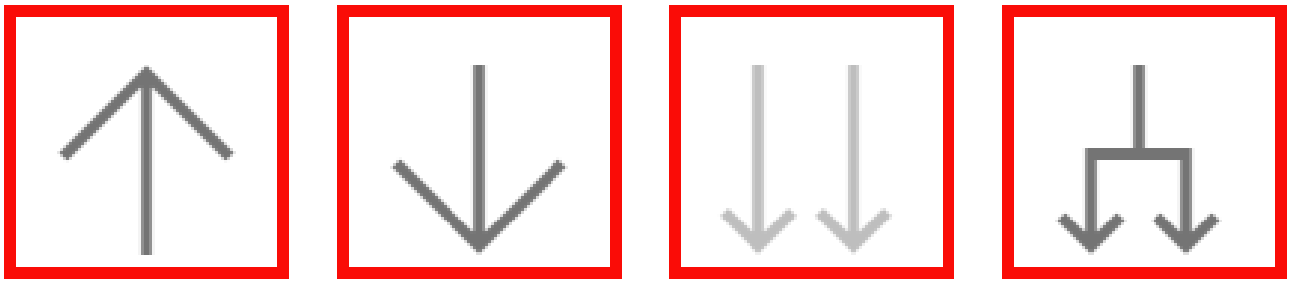

Hình 15: Thanh icon drill navigation xuất hiện phía trên visual chứa hierarchy: Drill Up (↑), Drill Mode (↓ xám), Go to Next Level (⇓), và Expand All (↗).

V.3. Thực hành: Drill-down trên Bar Chart

Chúng ta sẽ tạo Bar Chart doanh thu theo thời gian và thực hành drill-down:

Bước 1: Tạo Bar Chart với Hierarchy

1. Kéo **Fiscal** từ bảng **DimDate**) vào **X-axis** (trục ngang).
2. Kéo measure [**Total Sales**] (đã tạo ở Lesson 2) vào **Y-axis** (trục dọc).
3. Bar Chart hiện doanh thu theo từng năm tài chính.

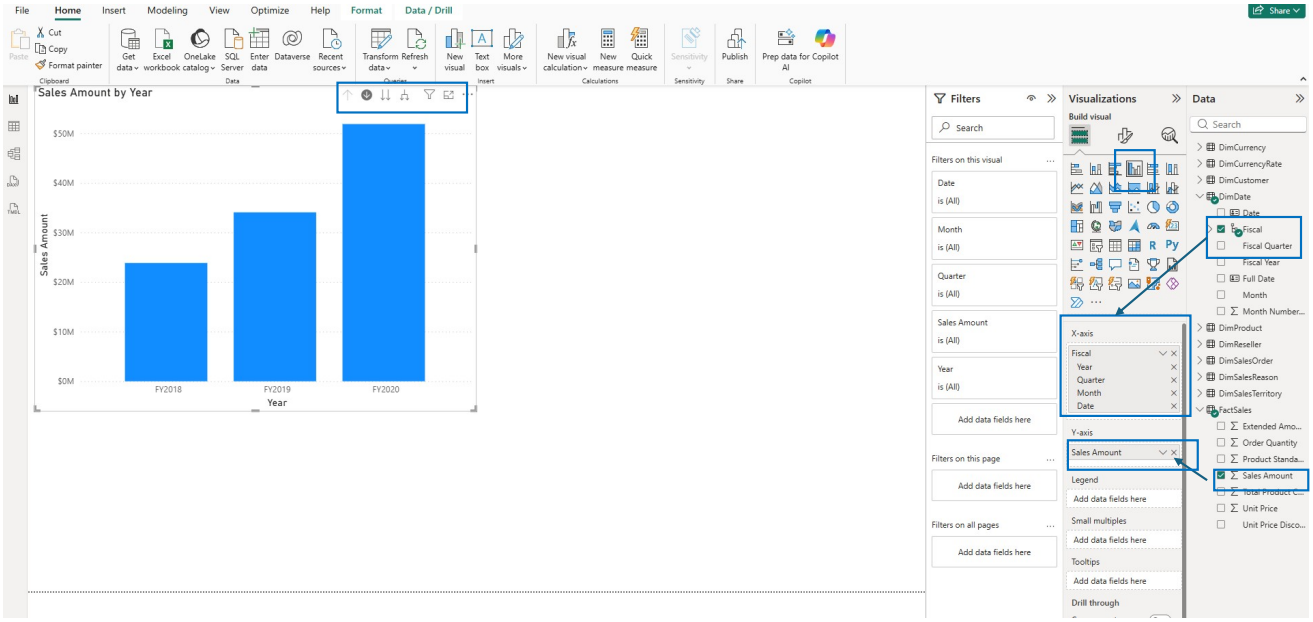

Hình 16: Create Bar Chart with Hierarchy

Bước 2: Drill Mode (đào sâu 1 năm)

1. Click icon **Drill Mode** (↓ nền xám) trên thanh Explore.
2. Click vào cột **FY2019**.
3. Chart chuyển sang hiện 4 quarter (Q1, Q2, Q3, Q4) chỉ của FY2019.
4. Tiếp tục click vào **Q3** → hiện các tháng trong Q3.
5. Click **Drill Up** (↑) để quay lại level Quarter, rồi Year.

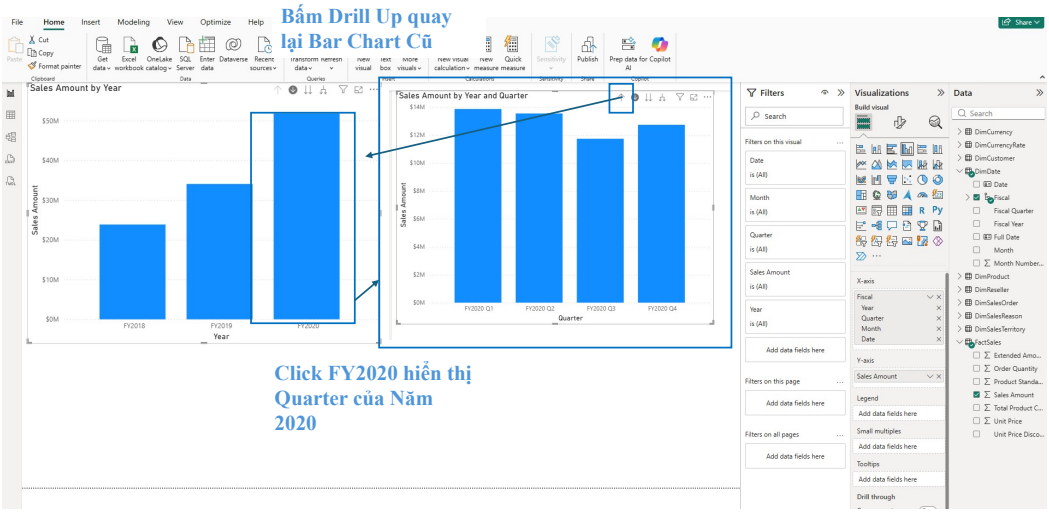

Hình 17: Drill down và Drill up

Bước 3: Expand All (xem 2 level)

1. Quay về level Year.
2. Click icon **Expand All** (↗).
3. Chart hiện "FY2018-Q1", "FY2018-Q2"..., với nhãn kết hợp Year + Quarter.
4. Click Expand All lần nữa → hiện Year + Quarter + Month.

Lưu ý

Expand nhiều level trên một Bar Chart có thể tạo ra rất nhiều cột (VD: 3 năm × 4 quarter × 12 tháng = 144 cột). Chart sẽ rất khó đọc. Nên dùng Expand All cẩn thận, hoặc kết hợp với filter/slicer để giới hạn phạm vi.

V.4. Drill-down trong Matrix

Matrix visual là nơi drill-down phát huy sức mạnh nhất, vì matrix hiển thị dữ liệu dạng bảng phân cấp tự nhiên.

Tạo Matrix với Hierarchy

1. Chọn visual **Matrix** từ Visualizations pane.
2. Kéo **Geographic Hierarchy** ừu bảng **DimCustomer** vào **Rows**.
3. Kéo **Fiscal** (từ bảng **DimDate**) vào **Columns**.
4. Kéo measure [**Total Sales**] vào **Values**.

Kết quả: Matrix hiện doanh thu theo `Coutry-Region` (hàng) × FiscalYear (cột).

Drill-down trên Matrix

- Click chuột phải trên cột Row chọn **Expand All** (↗) trên matrix → cột Rows mở rộng: Country-Region → State-Province.
- Click vào "+" trước tên Country (VD: United States) → mở rộng chỉ nước đó, hiện các State bên dưới.
- Click vào "-" để thu gọn lại.

Matrix cho phép drill từng hàng riêng lẻ (click +/-), không bắt buộc phải mở rộng toàn bộ như Bar Chart.

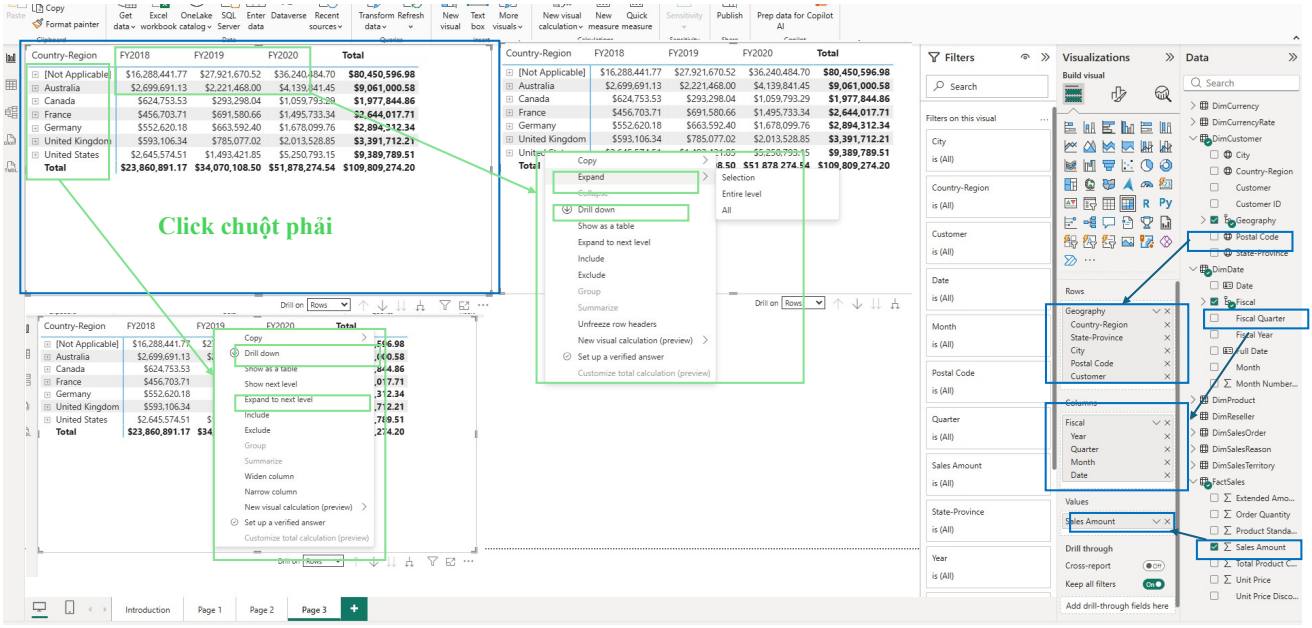

Hình 18: Matrix drill-down – click icon "+" trước một nước để mở rộng chỉ nước đó (hiện các State/Province), trong khi các nước khác vẫn thu gọn. Matrix cho phép drill từng hàng riêng lẻ.

Mẹo: Step Layout vs Tabular

Mặc định, matrix hiện phân cấp dạng **Stepped Layout** (thụt đầu dòng, gọn). Nếu muốn mỗi cấp trên một cột riêng (dạng bảng phẳng), bật Format → Row headers → Options → **Stepped layout: Off**.

VI. Drill-through

Ở phần trước, chúng ta dùng Drill-down để khám phá hierarchy trong cùng 1 visual. Nhưng nếu muốn xem chi tiết tổng hợp của 1 sản phẩm hoặc 1 khách hàng cụ thể ví dụ Sales Amount, Order Quantity, trend theo thời gian, tất cả trên cùng 1 trang chúng ta cần một cách tiếp cận khác: **Drill-through**.

VI.1. Drill-through khác Drill-down ở đâu?

So sánh Drill-down vs Drill-through

Tiêu chí	Drill-down	Drill-through
Diễn ra ở đâu	Ngay trong cùng 1 visual, cùng 1 trang	Nhảy sang một **trang report riêng**
Cơ chế	Đi theo hierarchy (Year → Quarter → Month)	Truyền bộ lọc của data point sang trang mới
Mục đích	Khám phá dữ liệu phân cấp	Deep-dive vào **1 entity cụ thể**
Cách kích hoạt	Click icon Drill hoặc click data point	Chuột phải data point → **Drillthrough**
Setup	Tạo hierarchy trong visual	Tạo Drill-through page + kéo field vào Drillthrough area

Nói đơn giản: **Drill-down** giống lên xuống thang máy các tầng trong cùng tòa nhà. **Drill-through** giống bước sang tòa nhà khác để xem chi tiết.

VI.2. Tạo trang Drill-through Product Details

Chúng ta sẽ tạo trang chi tiết cho từng sản phẩm. Khi người dùng chuột phải một sản phẩm trên bất kỳ chart nào, họ sẽ nhảy sang trang này để thấy chi tiết doanh thu, số lượng, trend theo thời gian.

Bước 1: Tạo trang mới

1. Click **dấu "+"** ở cuối danh sách tab trang (phía dưới canvas) để tạo trang mới.
2. Chuột phải tab → **Rename Page** → đặt tên **"Product Details"**.

Bước 2: Kéo field vào Drillthrough area

1. Ở trang "Product Details", nhìn Visualizations pane phía dưới, tìm vùng **"Add drillthrough fields here"**.

2. Từ bảng **DimProduct**, kéo cột **Product** vào vùng này.

3. Ngay lập tức, Power BI tự thêm một **nút Back** (mũi tên trái trong vòng tròn) ở góc trên trái trang.

Lưu ý

Power BI tự tạo nút Back khi bạn thiết lập Drillthrough. Trong Power BI **Desktop**, phải giữ **Ctrl + Click** vào nút Back mới hoạt động (đây là hạn chế của Desktop mode). Khi publish lên **Power BI Service**, click bình thường.

Bước 3: Thiết kế trang Product Detail

Trang Drill-through nên được thiết kế tập trung, chỉ hiện thông tin liên quan đến entity được chọn. Gợi ý layout:

1. **KPI Cards (hàng trên):** measure [**Total Sales**], [**Total Orders**], và Avg Unit Price:

DAX Measure

```
Total Orders = COUNTROWS(FactSales)
```

DAX Measure

```
Total Sales = SUM(FactSales[Sales Amount])
```

DAX Measure

```
Avg Unit Price = AVERAGE(FactSales[UnitPrice])
```

3. **Line Chart (giữa trang):** measure [**Total Sales**] theo `DimDate[FiscalYear]` trên trục X → xem trend doanh thu theo năm.

4. **Table (dưới cùng):** Chi tiết đơn hàng: `DimProduct[Product]`, `DimDate[Fiscal Year]`, `FactSales[Sales Amount]`, `FactSales[Order Quantity]`, `FactSales[Unit Price]`

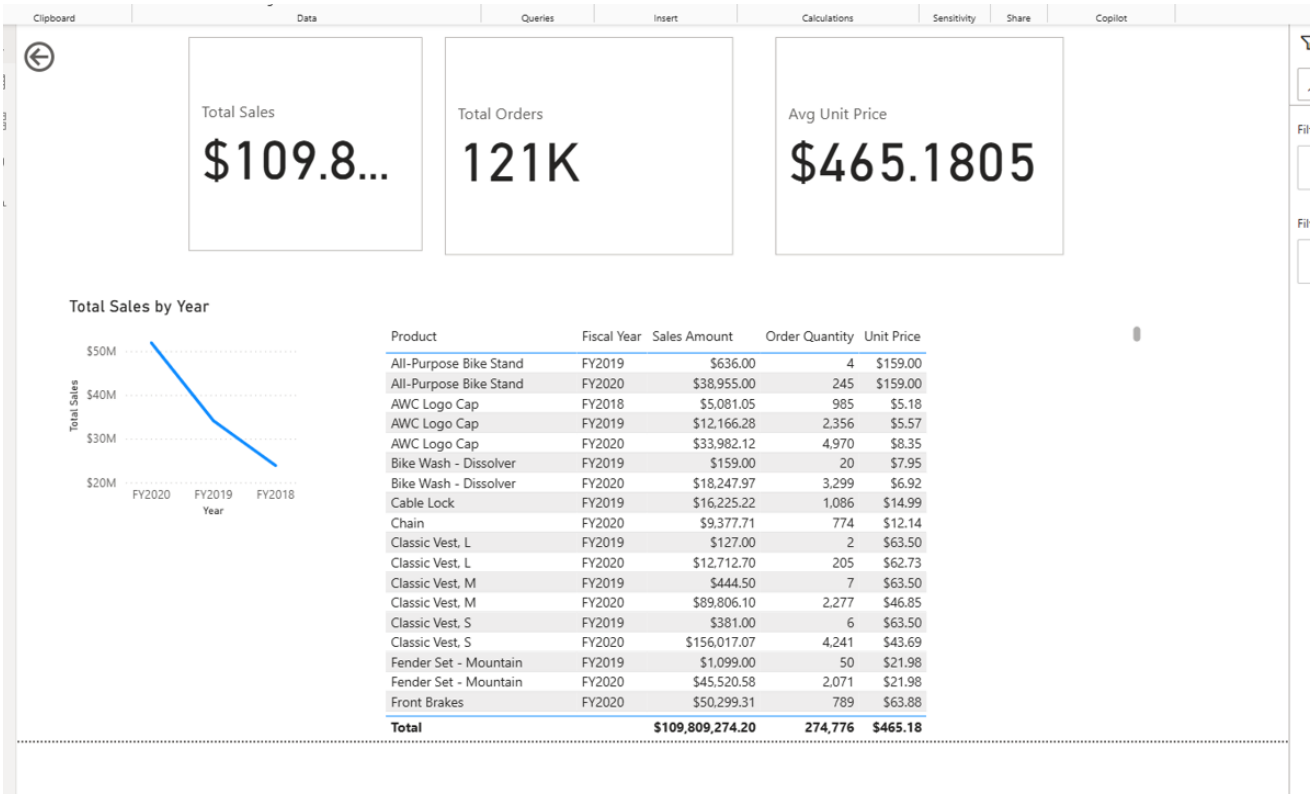

Product	Fiscal Year	Sales Amount	Order Quantity	Unit Price
All-Purpose Bike Stand	FY2019	$636.00	4	$159.00
All-Purpose Bike Stand	FY2020	$38,955.00	245	$159.00
AWC Logo Cap	FY2018	$5,081.05	985	$5.18
AWC Logo Cap	FY2019	$12,166.28	2,356	$5.57
AWC Logo Cap	FY2020	$33,982.12	4,970	$8.35
Bike Wash - Dissolver	FY2019	$159.00	20	$7.95
Bike Wash - Dissolver	FY2020	$18,247.97	3,299	$6.92
Cable Lock	FY2019	$16,225.22	1,086	$14.99
Chain	FY2020	$9,377.71	774	$12.14
Classic Vest, L	FY2019	$127.00	2	$63.50
Classic Vest, L	FY2020	$12,712.70	205	$62.73
Classic Vest, M	FY2019	$444.50	7	$63.50
Classic Vest, M	FY2020	$89,806.10	2,277	$46.85
Classic Vest, S	FY2019	$381.00	6	$63.50
Classic Vest, S	FY2020	$156,017.07	4,241	$43.69
Fender Set - Mountain	FY2019	$1,099.00	50	$21.98
Fender Set - Mountain	FY2020	$45,520.58	2,071	$21.98
Front Brakes	FY2020	$50,299.31	789	$63.88
Total		**$109,809,274.20**	**274,776**	**$465.18**

Hình 19: Trang drill-through với Card visual hiển thị tên entity và Drillthrough area đã cấu hình trong Visualizations pane. Power BI tự tạo nút Back khi có field trong Drillthrough area.

VI.3. Thiết kế Drill-through hiệu quả

Nguyên tắc thiết kế trang Drill-through

1. **Luôn có Card hiện tên entity:** Người dùng cần biết ngay mình đang xem chi tiết của gì.
2. **Giữ trang tập trung:** Chỉ hiện visual liên quan trực tiếp đến entity. Không nhồi thông tin tổng quan vào đây.
3. **Đặt tên trang rõ ràng:** "Product Details", "Customer Analysis", không đặt "Page 5".
4. **Nút Back rõ ràng:** Kiểm tra nút Back có hiện và hoạt động. Nếu cần, thêm nút Back thủ công (Insert → Button → Back).

VI.4. Sử dụng Drill-through từ trang chính

Sau khi thiết lập xong trang **Product Details**, quay về trang chính (Total sales by Prodcut : Bar chart với DimProduct[Product] và Total Sales):

1. **Chuột phải** vào một data point liên quan đến Product. VD: chuột phải vào cột "Touring-1000" trên Bar Chart.
2. Menu context xuất hiện → chọn **Drillthrough** → **Product Details**.
3. Power BI chuyển sang trang "Product Details", tự động filter chỉ hiện data của "Touring-1000".
4. Xem xong, click **nút Back** (Ctrl+Click trong Desktop) để quay về trang chính.

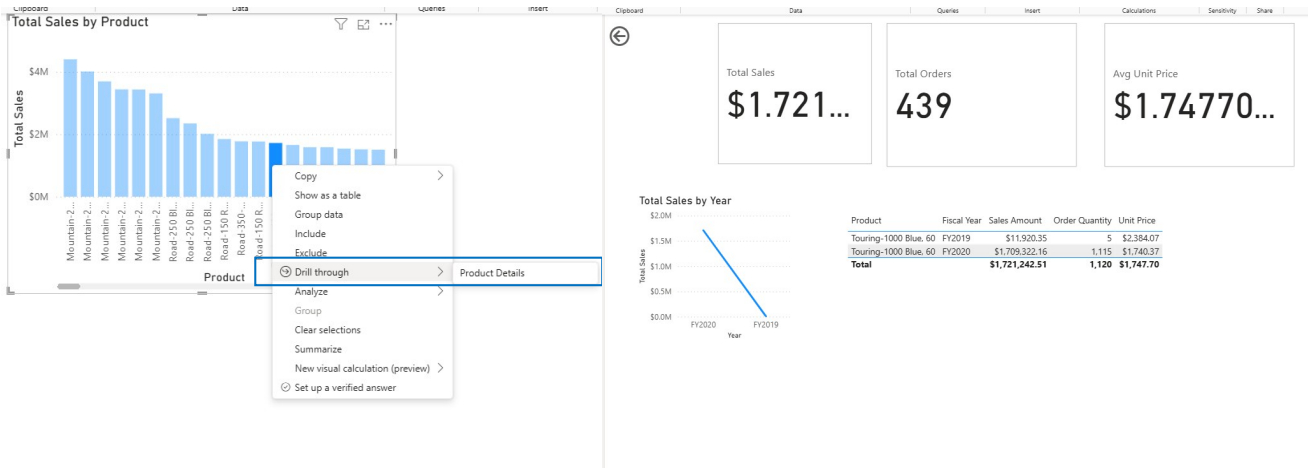

Hình 20: Trang drill-through sau khi Power BI tự động filter theo entity được chọn từ trang nguồn – toàn bộ visuals trên trang chỉ hiện dữ liệu của entity đó. Nút Back (góc trên trái) giúp quay về trang nguồn.

Drillthrough chỉ xuất hiện khi field khớp

Menu "Drillthrough → Product Details" chỉ xuất hiện khi bạn chuột phải vào visual có chứa cột **EnglishProductName** (hoặc cột liên kết qua ProductKey), hoặc field có thể được lọc thành giá trị Product thông qua relationship trong data model. Nếu chuột phải vào chart chỉ có Year mà không liên quan đến Product, menu Drillthrough sẽ không hiện.

Nghĩa là: **Drillthrough field quyết định context**. Trang drill-through lọc theo field nào, thì trang nguồn phải có visual mang field đó (hoặc field liên kết qua relationship).

VII. Bookmarks và Buttons

VII.1. Bookmarks

Bookmark giống như chụp ảnh màn hình trạng thái report tại một thời điểm. Mỗi bookmark lưu:

- Trạng thái **filter/slicer** (đang chọn FY2019, Category = Bikes...)
- Trạng thái **cross-highlight** (đang click data point nào)
- **Sort order** và **drill level** hiện tại
- **Visibility** của từng visual (visual nào đang hiện, visual nào đang ẩn)

Khi kích hoạt bookmark, report tự động quay lại đúng trạng thái đã lưu. Điều đặc biệt: bookmark **không lưu actual data**, chỉ lưu trạng thái hiển thị. Nên khi data refresh, bookmark vẫn hoạt động bình thường.

Cách tạo Bookmark

1. Thiết lập trang report về đúng trạng thái muốn lưu (chọn slicer, drill level, ẩn/hiện visual...).
2. Vào **View** → **Bookmarks pane** (bảng Bookmarks xuất hiện bên phải).
3. Click **Add** (hoặc Add bookmark).
4. Đặt tên mô tả rõ ràng. VD: "FY2019_Bikes_Overview".

Tùy chỉnh Bookmark

Click dấu **"..."** bên cạnh tên bookmark → xuất hiện các tùy chọn:

Tùy chọn	Ý nghĩa	Khi nào bỏ tick?
Data	Lưu trạng thái filter, slicer, cross-highlight	Bỏ tick nếu muốn bookmark **chỉ thay đổi visibility** (VD: toggle panel)
Display	Lưu trạng thái hiển thị (visual nào đang hiện)	Ít khi bỏ
Current page	Khi click bookmark, tự nhảy về trang đã tạo bookmark	Bỏ nếu muốn bookmark áp dụng cho trang hiện tại
All visuals / Selected visuals	Áp dụng cho tất cả hay chỉ visual đã chọn	Chọn "Selected visuals" nếu chỉ muốn ảnh hưởng 1-2 visual

Lưu ý

Rất quan trọng: Uncheck "Data" khi bookmark cho visibility. Nếu tạo bookmark để ẩn/hiện panel (toggle), luôn **bỏ tick "Data"**. Nếu không, mỗi khi click nút toggle, slicer selections sẽ bị reset về trạng thái lúc tạo bookmark, gây khó chịu cho người dùng.

VII.2. Buttons

Bookmark tự nó chỉ là trạng thái được lưu. Để người dùng kích hoạt bookmark, chúng ta cần **nút bấm** (buttons).

Tạo Button

1. Trên ribbon, vào **Insert** → **Buttons** dropdown.
2. Chọn loại button: **Blank** (tùy chỉnh hoàn toàn), **Arrow** (mũi tên), **Back** (quay lại), **Info** (thông tin), hoặc **Bookmark** (trỏ đến bookmark).
3. Button xuất hiện trên canvas. Có thể resize, di chuyển, đổi text và icon.

Gán Action cho Button

1. Chọn button → Format Button pane → **Action** → bật **On**.
2. Chọn **Type** (loại hành động):

Type	Hành vi	Use case
Bookmark	Kích hoạt bookmark cụ thể	Toggle panel, chuyển view
Back	Quay về trang trước (giống nút Back trình duyệt)	Trang drill-through, trang phụ
Page navigation	Nhảy đến trang cụ thể	Menu bar tự tạo
Q&A	Mở Natural Language query	Report self-service
Web URL	Mở link trong trình duyệt	Tài liệu, nguồn dữ liệu

Nếu chọn **Bookmark**, dropdown **Bookmark** xuất hiện → chọn tên bookmark đã tạo.

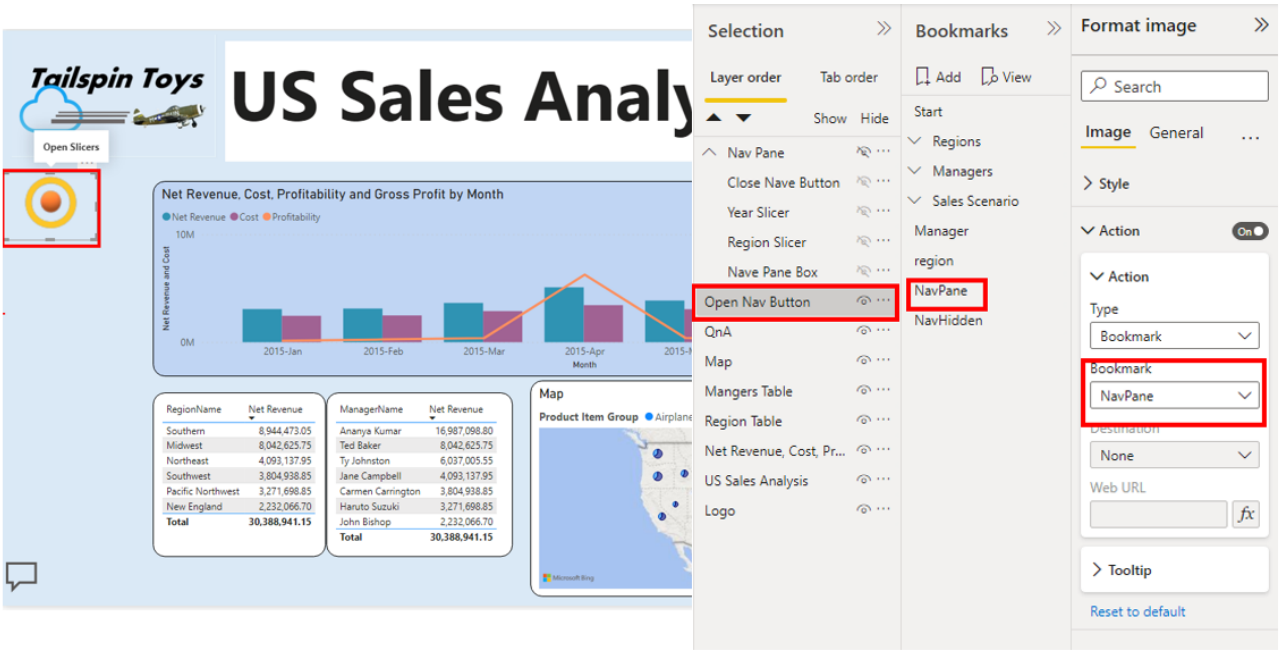

Hình 21: Các button điều hướng được gán Action = Bookmark – click button sẽ kích hoạt bookmark tương ứng, nhảy đến trang hoặc trạng thái đã lưu.

VII.3. Toggle Panel

Đây là kỹ thuật kết hợp Bookmarks + Buttons + Selection pane để tạo một panel slicer có thể ẩn/hiện, giúp canvas sạch hơn. Trước khi làm chuẩn bị 3 Bar Chart Total Sales by Category, Total Sales by Category, Total Sales by Year. Workflow gồm 3 bước:

Bước 1: Tạo panel chứa slicers

1. Vào **Insert** → **Shapes** → chọn **Rectangle**.
2. Kéo to rectangle để che khoảng 1/3 bên trái (hoặc phải) canvas.
3. Format rectangle: đổi màu nền, bo góc, thêm viền nhẹ.
4. Đặt các slicer (Year, Category, Region...) lên trên rectangle.
5. Thêm nút "←" (Đổi tên thành Hide) ở góc phải trên rectangle (Insert → Button → Back : mục đích của nút này là dùng để ẩn pannel slicer
6. thêm nút **i** (Đặt tên là Filter) → Button → Information : mục đích nút này là để hiện pannel slicer
7. Group các slicer, Button bằn cách chọn các slicer, button → Click chuột phải → Group -> Đổi tên thành Nav

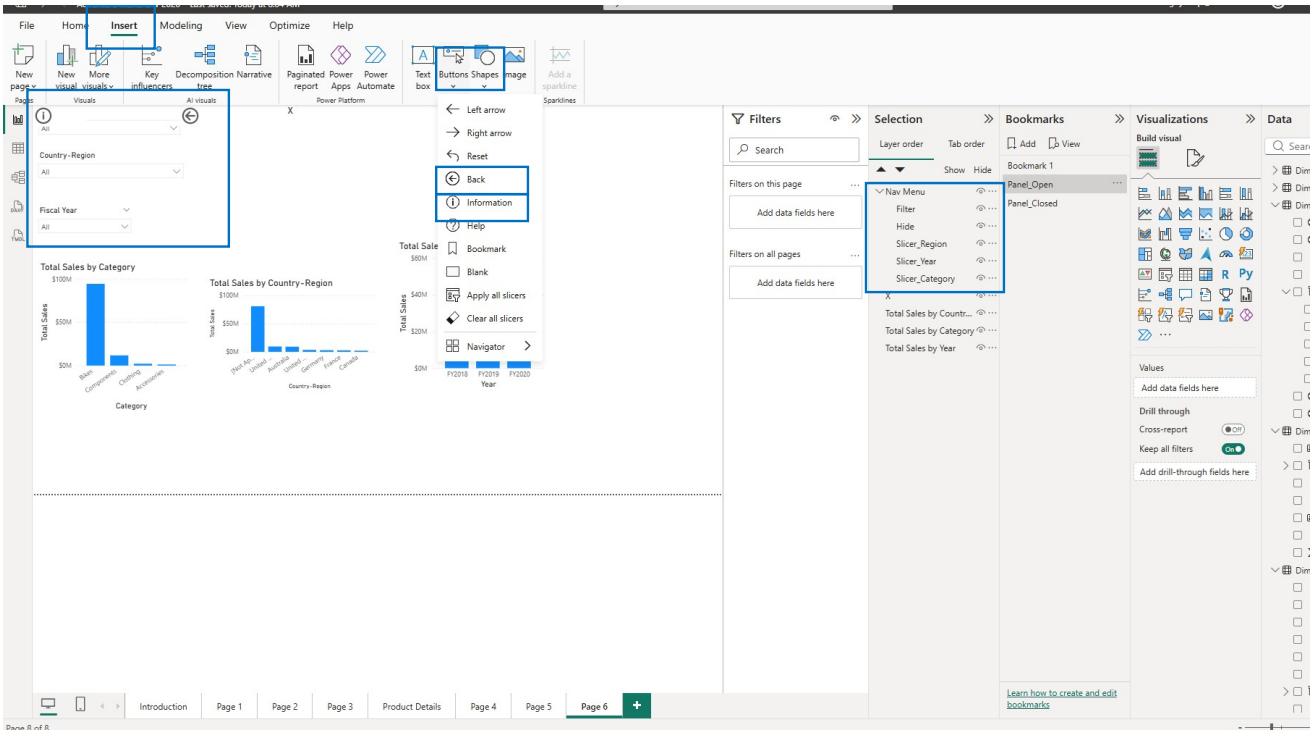

Hình 22: Tạo Nav Slicer.

Bước 2: Tạo 2 Bookmarks

1. **Bookmark "Panel_Open":** Trong Selection pane, **hiện** Rectangle + các slicer + nút Close. View → Bookmarks pane → **Add** → đặt tên "Panel_Open". Click "..." → **bỏ tick "Data"** (chỉ lưu visibility, không lưu filter state).

2. **Bookmark "Panel_Closed":** Trong Selection pane, **ẩn** Rectangle + các slicer + nút Close. Bookmarks pane → **Add** → "Panel_Closed". Bỏ tick "Data".

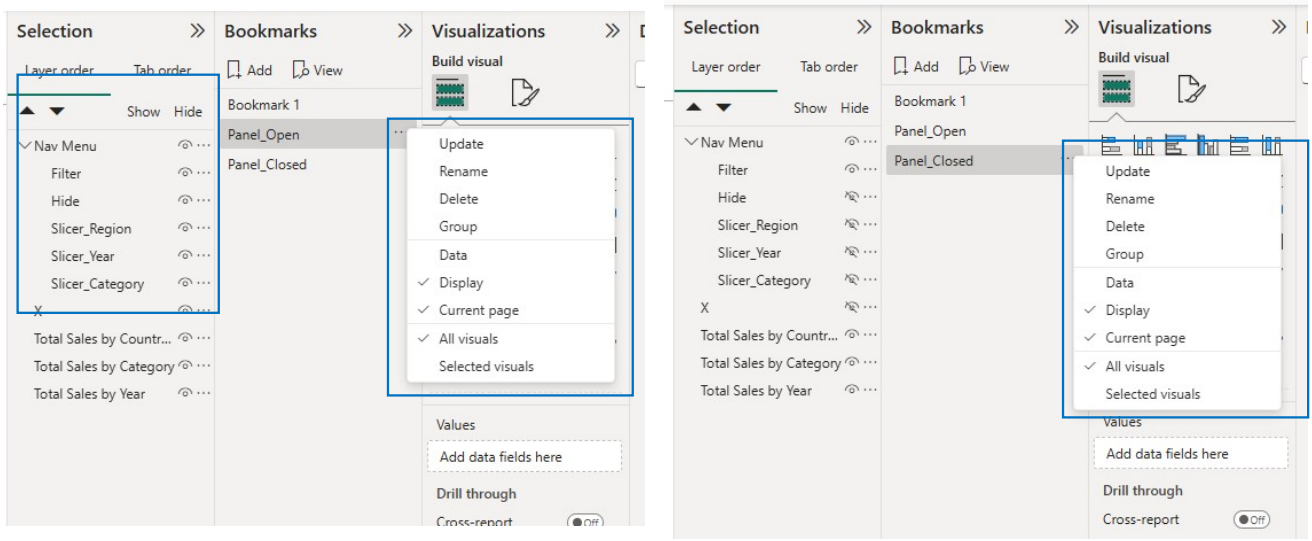

Hình 23: Tạo 2 Bookmark Panel_Open và Panel_Closed.

Bước 3: Gán Bookmarks cho Buttons

1. Chọn nút **"i"** ở trên canvas (luôn hiện, dùng mở panel). Format button → Action → On → Type: **Bookmark** → chọn **"Panel_Open"**.
2. Nút "←" trên panel (đã tạo ở Bước 1): Format → Action → On → Type: **Bookmark** → chọn **"Panel_Closed"**.

Kết quả: Click "i" → panel trượt ra. Click "←" → panel ẩn đi. Slicer selections vẫn giữ nguyên nhờ đã uncheck "Data".

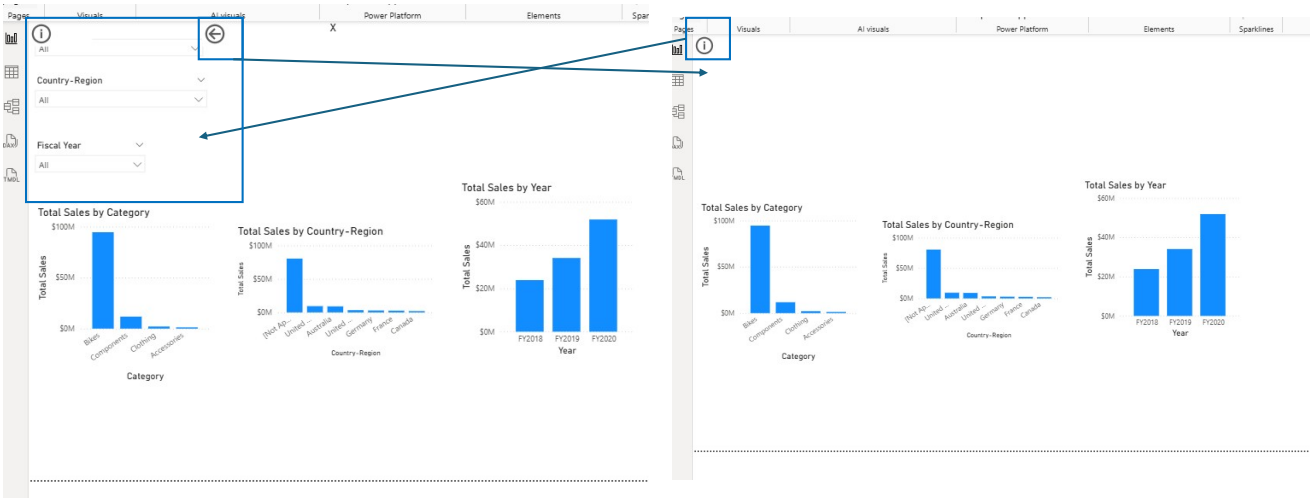

Hình 24: Toggle Panel với mũi tên "←"' – click mũi tên này kích hoạt bookmark "Panel_Closed", ẩn toàn bộ slicer panel. Button **"i"** ở vị trí cố định sẽ mở lại panel bằng bookmark "Panel_Open".

Mẹo nâng cao: Group items trong Selection pane

Giữ Ctrl chọn Rectangle + tất cả slicer + nút Close trong Selection pane → chuột phải → **Group**. Đặt tên group "Filter Panel". Khi tạo bookmark, chỉ cần ẩn/hiện cả group thay vì từng item.

VII.4. Page Navigator

Nếu report có nhiều trang và bạn muốn tạo thanh navigation tab (giống tab trên website), Power BI có sẵn visual **Page Navigator**:

1. Vào **Insert** → **Navigator** → **Page navigator**.
2. Page Navigator tự động hiện tab cho mỗi trang trong report.
3. Khi thêm/xóa/đổi tên trang, Navigator **tự cập nhật**, không cần chỉnh thủ công.

So sánh với cách tạo navigation bằng Buttons + Bookmarks thủ công: Page Navigator dễ dùng hơn nhiều, nhưng ít tùy chỉnh hơn. Dùng Page Navigator khi cần navigation đơn giản, dùng Buttons + Bookmarks khi cần tùy chỉnh cao (toggle panel, switch view...).

Page Navigator vs Bookmark Navigator

	Page Navigator	Bookmark Navigator
Nguồn	Tự động từ danh sách trang	Từ danh sách bookmark
Tự cập nhật	Có (khi thêm/xóa trang)	Không (phải cập nhật bookmark thủ công)
Use case	Navigation chính giữa các trang	Storytelling, guided tour
Layout	Horizontal/Vertical	Horizontal/Vertical/Grid

VIII. Optimizing User Experience

Đến đây, report của chúng ta đã có đầy đủ khả năng tương tác: slicer để lọc, cross-filter để liên kết visual, drill-down/through để đào sâu, và bookmarks để điều hướng. Nhưng một report "tương tác" chưa chắc đã "dễ dùng". Phần này tập trung vào những kỹ thuật giúp người dùng tìm được câu trả lời **nhanh hơn** và **trực quan hơn**.

VIII.1. Custom Tooltips

Mặc định, khi hover chuột lên một thanh bar chart hoặc một slice trong pie chart, Power BI hiện tooltip text nhỏ chứa giá trị. Custom Tooltip cho phép chúng ta thay thế tooltip mặc định bằng **một trang report mini**, chứa biểu đồ, card, và nhiều thông tin phong phú hơn.

Hãy tưởng tượng: hover lên "United States" trên bản đồ → tooltip hiện ra một pie chart nhỏ phân tích doanh thu theo Category (Bikes, Accessories, Clothing) chỉ của US. Người dùng không cần click, không cần nhảy trang, chỉ cần rê chuột.

Bước 1: Tạo Tooltip Page

1. Click dấu **"+"** để tạo trang mới → đặt tên **"Tooltip_SalesByCategory"**.
2. Trên trang mới, **click vào vùng trống trên canvas** (đảm bảo không visual nào được chọn), rồi vào Format pane:
   - **Page information** → bật **Allow use as tooltip: On**.
   - **Canvas settings** → Type: chọn **Tooltip** (canvas tự co nhỏ lại, khoảng 320×240 pixel).
3. Vào **View** → **Page View** → **Actual Size** để thấy đúng kích thước tooltip sẽ hiện.
4. Trong Visualizations pane, tìm vùng **Tooltip** → kéo vào đây field **cùng loại** với field đang dùng trên visual chính. VD: Map dùng `DimCustomer[EnglishCountryRegionName]` → kéo `DimCustomer[EnglishCountryRegionName]` vào Tooltip area.
5. Thiết kế visual nhỏ gọn trên canvas tooltip: một **Donut Chart** (Sales Amount theo `DimSalesTerritory[SalesTerritoryRegion]`) hoặc một **Bar Chart** nhỏ (Sales Amount theo `DimProduct[EnglishProductName]`, lọc Top 5 để gọn).

Tại sao phải khớp field?

Power BI dùng field trong Tooltip area để xác định *context* lọc. Khi hover lên "United States" trên Map, nó tìm xem tooltip page có field nào khớp "EnglishCountryRegionName = United States" rồi filter theo đó. Nếu field không khớp, tooltip sẽ hiện toàn bộ data mà không filter đúng.

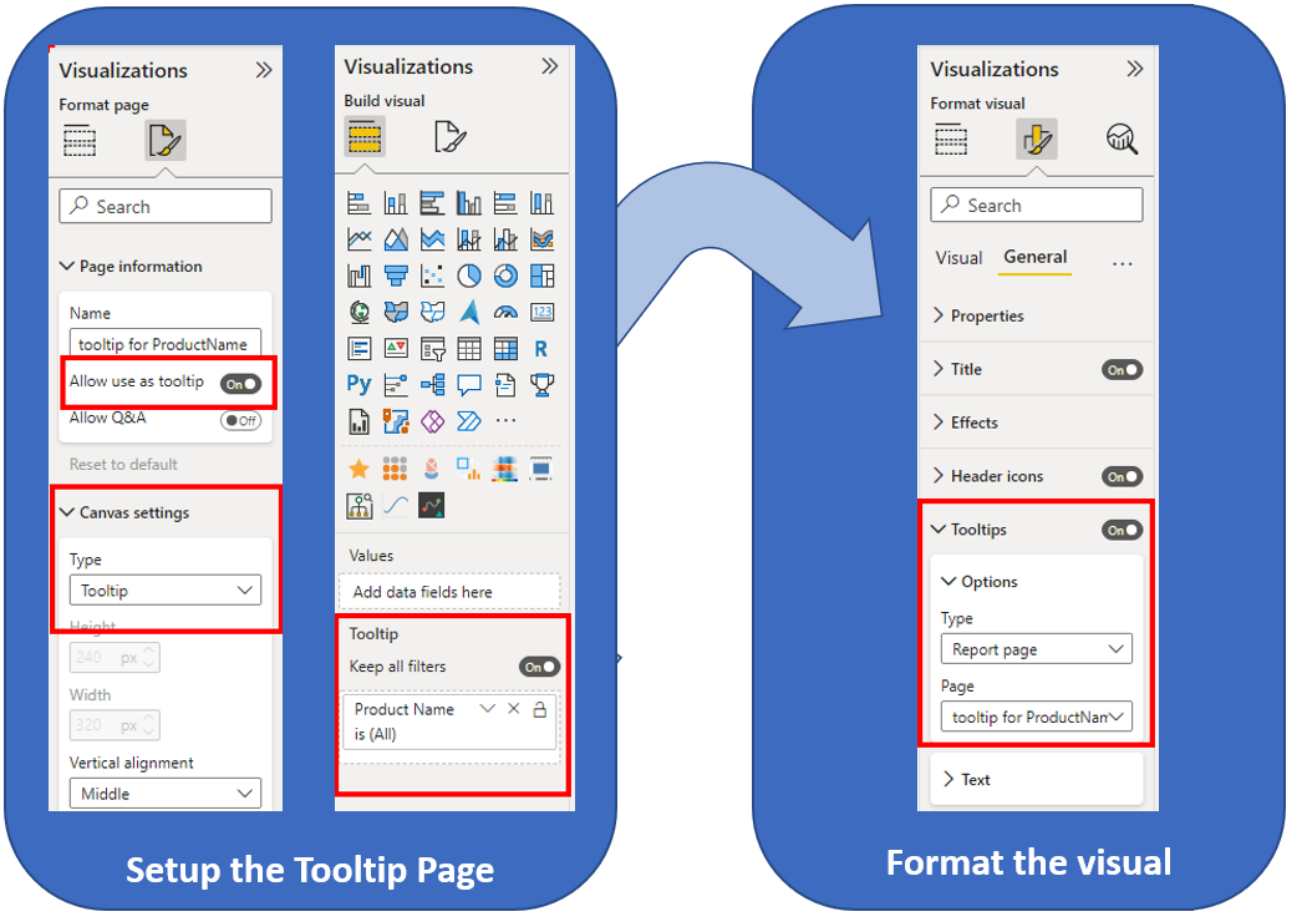

Hình 25: Thiết lập trang làm Tooltip page – trong Format pane bật "Tooltips" slider (Allow use as tooltip: On) và chọn canvas size = Tooltip. Trang này sẽ hiện dạng popup khi hover.

Bước 2: Gán Tooltip cho Visual chính

1. Quay về trang chính (Overview hoặc Sales).
2. Click chọn visual muốn gán tooltip (VD: **Map** hiện doanh thu theo Country).
3. Format pane → mở mục **Tooltips** (trong General tab):
   - **Type:** chọn **Report page**.
   - **Page:** chọn **"Tooltip_SalesByCategory"**.
4. Hover chuột lên "United States" trên Map → Custom Tooltip hiện ra, tự filter cho US.

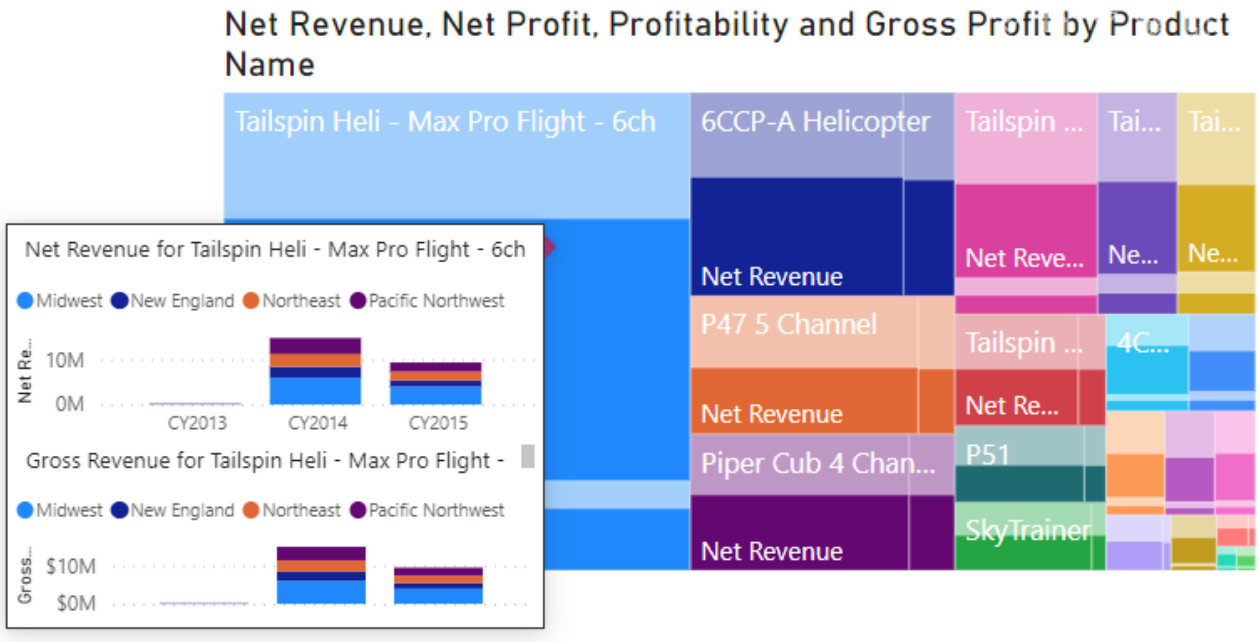

Hình 26: Hover chuột lên data point → Custom Tooltip hiện ra dưới dạng một trang report mini với visual đầy đủ (chart, card...), tự động filter theo data point đang hover.

Best practices cho Custom Tooltips

- **1-2 visual nhỏ** là đủ. Tooltip quá phức tạp gây rối.
- **Ẩn tooltip page:** Chuột phải tab trang → **Hide Page**. Người dùng không cần thấy trang tooltip trong danh sách trang.
- **Đặt tên rõ:** "Tooltip_Sales", "TT_ProductBreakdown" → dễ quản lý khi có nhiều tooltip.
- **Khi nào KHÔNG dùng tooltip:** Thông tin cần tương tác phức tạp (drill, filter) → dùng **Drill-through** thay.

VIII.2. Conditional Formatting

Conditional Formatting tự động thay đổi màu nền, màu chữ, hoặc thêm icon/data bar vào cell dựa trên giá trị. Giúp người dùng nhận ra bất thường hoặc highlight nhanh mà không cần đọc từng con số.

5 kiểu Conditional Formatting

Kiểu	Mô tả	Ví dụ thực tế
Color Scale	Gradient màu tỉ lệ với giá trị	Sales Amount: thấp → đỏ, cao → xanh
Rules	Màu theo ngưỡng cố định (if-then)	Nếu > target → xanh, < target → đỏ
Data Bars	Thanh ngang trong cell, tỉ lệ với giá trị	So sánh nhanh magnitude trong bảng
Icons	Mũi tên, đèn giao thông, hình khối	Trạng thái KPI: ↑ tốt, ↓ xấu
Field Value	Dùng cột chứa tên màu hoặc hex code	Business logic tùy chỉnh

Cách áp dụng (trên Table/Matrix)

1. Tạo **Table** hoặc **Matrix** visual với dữ liệu muốn format.
2. Trong Visualizations pane, chuột phải vào cột trong vùng **Values** (VD: Sales Amount).
3. Chọn **Conditional formatting** → chọn loại: Background color, Font color, Data bars, hoặc Icons.
4. Dialog **Advanced Controls** mở ra → tùy chỉnh.

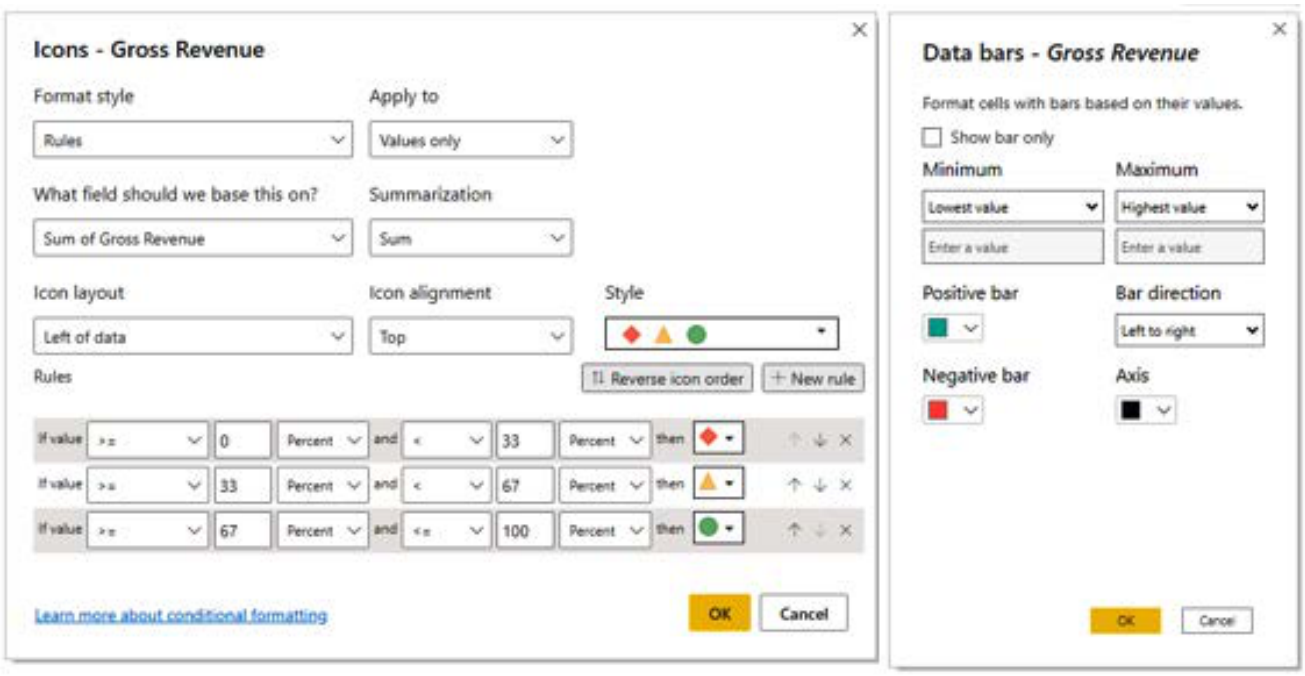

Hình 27: Hai kiểu Conditional Formatting phổ biến: Icons (trái) dùng màu đỏ/vàng/xanh theo % ngưỡng để hiện cảnh báo trực quan; Data Bars (phải) vẽ thanh ngang tỷ lệ với giá trị. Cả hai kết hợp màu sắc và hình dạng giúp người đọc bị mù màu vẫn nhận biết được.

Lưu ý

Accessibility: Không chỉ dùng màu. Khoảng 8% nam giới bị mù màu đỏ-xanh. Khi dùng conditional formatting, luôn kết hợp **màu + icon** (VD: xanh + mũi tên lên, đỏ + mũi tên xuống) để ai cũng đọc được. Tránh dùng màu là phương tiện truyền đạt duy nhất.

VIII.3. KPI Layout và Information Hierarchy

Bố cục report quyết định tốc độ người dùng tìm được câu trả lời. Một report tốt giúp người dùng trả lời câu hỏi kinh doanh trong **5 giây đầu tiên** khi mở report.

Nguyên tắc ưu tiên góc trên bên trái

Nghiên cứu về cách người dùng đọc trang web cho thấy mắt di chuyển theo pattern **F** hoặc **Z**: bắt đầu từ góc trên trái, quét ngang, rồi xuống. Áp dụng vào report:

- **Góc trên trái:** Đặt KPI quan trọng nhất → **Total Sales**, **Revenue Growth %**.
- **Hàng trên:** 3-5 Card/KPI hiển thị metric chính (không quá 5, gây quá tải).
- **Giữa trang:** Chart chính (Bar, Line, Map).
- **Dưới cùng:** Table chi tiết hoặc secondary charts.

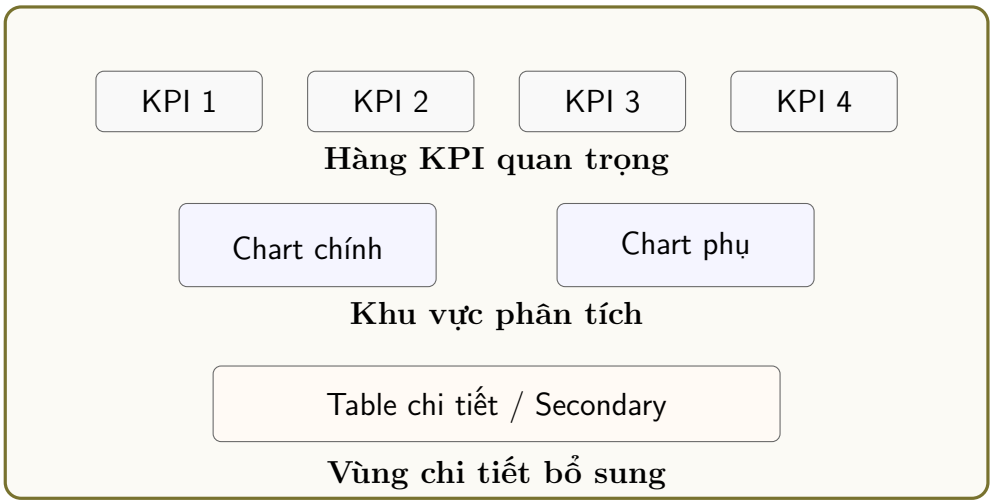

Mỗi KPI cần Context

Một con số đơn lẻ (ví dụ 518M) không nói lên điều gì. Mỗi KPI nên có thêm:

- **Target/Gap:** So sánh với mục tiêu (VD: 518M / 600M target = 86.3%).
- **Trend indicator:** Mũi tên lên/xuống hoặc sparkline cho thấy xu hướng.
- **Conditional coloring:** Xanh nếu đạt, đỏ nếu dưới target.

Visual types cho KPI

Visual	Mô tả	Khi nào dùng
Card	Hiện 1 giá trị đơn (to, rõ)	KPI chính: Total Sales, Avg Order Value
Multi-row Card	Nhiều giá trị xếp dọc	Nhóm 3-4 metric liên quan
Gauge	Kim đồng hồ bán nguyệt, so sánh actual vs target	Khi có target rõ ràng
KPI visual	Indicator + target + trend axis	Theo dõi KPI theo thời gian

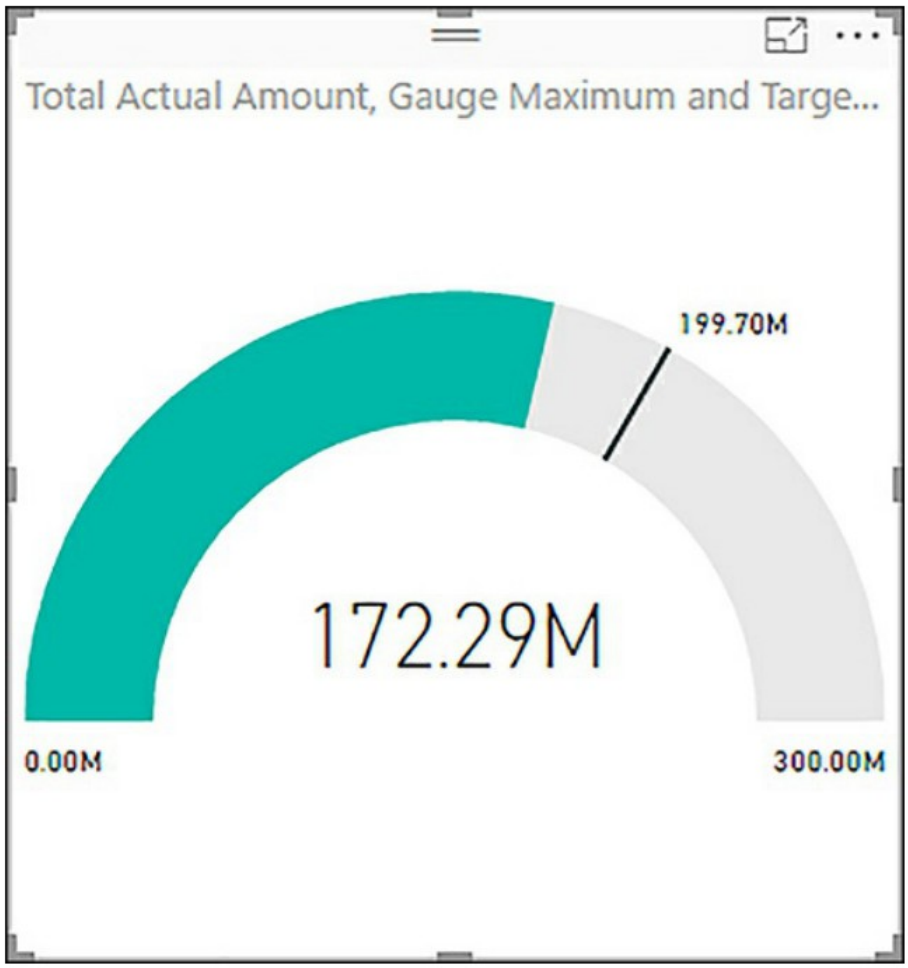

Hình 28: Gauge visual (đồng hồ bán nguyệt) hiện actual value so với target – kim đen chỉ target, màu sắc vùng cho biết hiệu suất. Kết hợp Card (1 số đơn) + Gauge (so sánh target) + KPI visual (trend theo thời gian) để trình bày KPI đầy đủ.

Ví dụ nhanh: Tạo hàng KPI trên Adventure Works

1. Tạo 3 **Card** visual xếp hàng ngang ở góc trên trái canvas:
   - Card 1: kéo measure [**Total Sales**] → hiện tổng doanh thu.
   - Card 2: kéo measure [**Total Orders**] → hiện tổng số đơn hàng.
   - Card 3: tạo measure sau rồi kéo vào Card:

DAX Measure

```
Avg Order Amount = DIVIDE([Total Sales], [Total Orders])
```

2. Bên dưới hàng KPI, đặt một **Bar Chart** để thể hiện doanh thu theo một chiều phân loại phù hợp trong dữ liệu (ví dụ: `Channel` hoặc `Category`), và một **Line Chart** để thể hiện xu hướng theo thời gian nếu model có trường ngày/tháng.

Nguyên tắc "Overview to Detail"

Report nên có ít nhất 2 tầng:

- **Tầng 1 (Landing Page):** Tổng quan, 5 KPI chính, trend lớn, alert. Người dùng mở ra lần đầu thấy ngay bức tranh toàn cảnh.
- **Tầng 2 (Detail Pages):** Truy cập qua Drill-through hoặc Navigation buttons. Root cause, breakdown chi tiết, bảng dữ liệu.

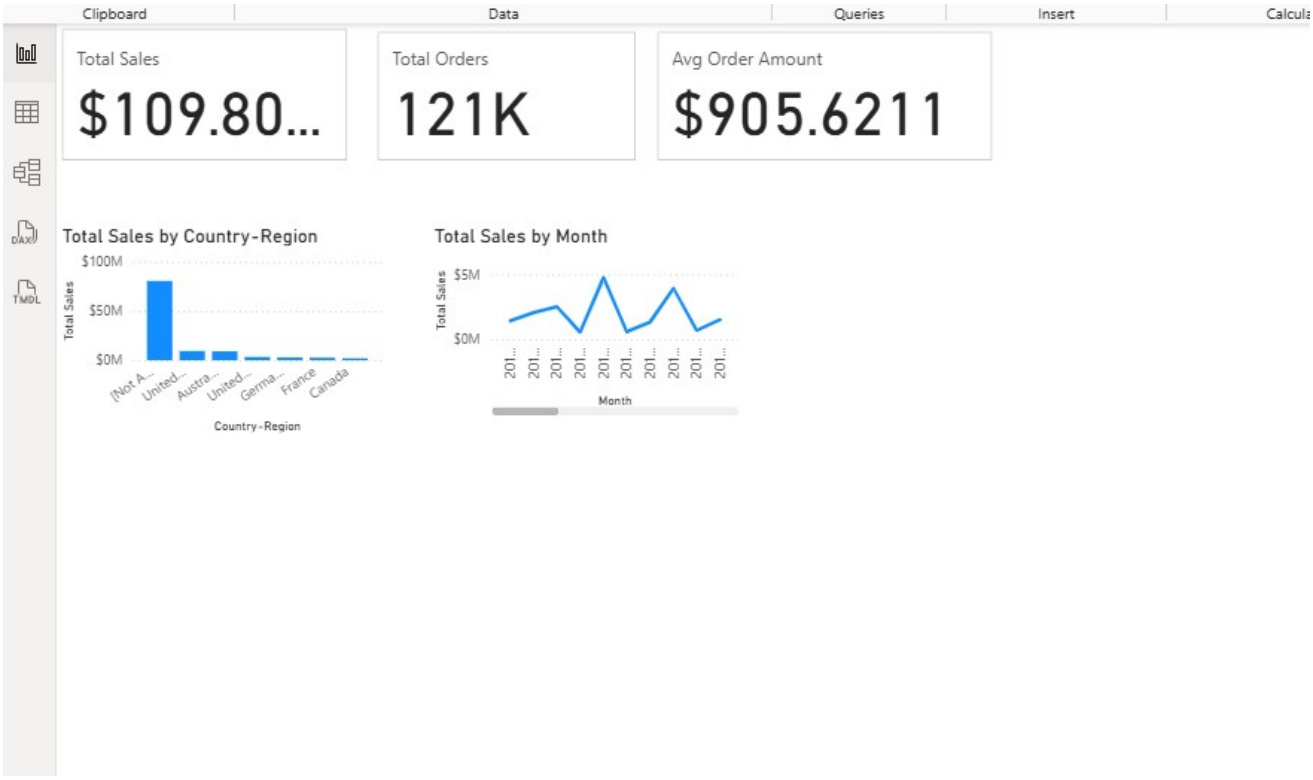

Hình 29: Ví dụ tạo Kpi

Chúng ta đã xây dựng cả 2 tầng này trong Lesson 3: trang chính với Slicers, Cross-filter và Drill-down (Phần II-IV), trang Drill-through chi tiết (Phần V), và navigation giữa chúng (Phần VI).

VIII.4. Performance Analyzer

Report load chậm sẽ gây khó chịu cho người dùng. Nếu người dùng phải chờ hơn 5 giây mỗi lần click slicer hoặc chuyển trang, họ sẽ mất kiên nhẫn và không tin tưởng report.

Sử dụng Performance Analyzer

1. Vào **View** → **Performance Analyzer** (checkbox) → pane mở bên phải.
2. Click **Start recording**.
3. Click **Refresh visuals** (hoặc chuyển trang, click slicer).
4. Pane hiện danh sách mỗi visual kèm thời gian render.
5. Mở rộng (click "+") một visual để thấy:

Metric	Ý nghĩa	Nếu chậm?
DAX query	Thời gian gửi query và nhận data từ model	Optimize measure (DAX), giảm cardinality
Visual display	Thời gian vẽ visual lên canvas	Giảm data rows, simplify visual
Other	Chuẩn bị query, chờ visual khác	Thường không cần optimize

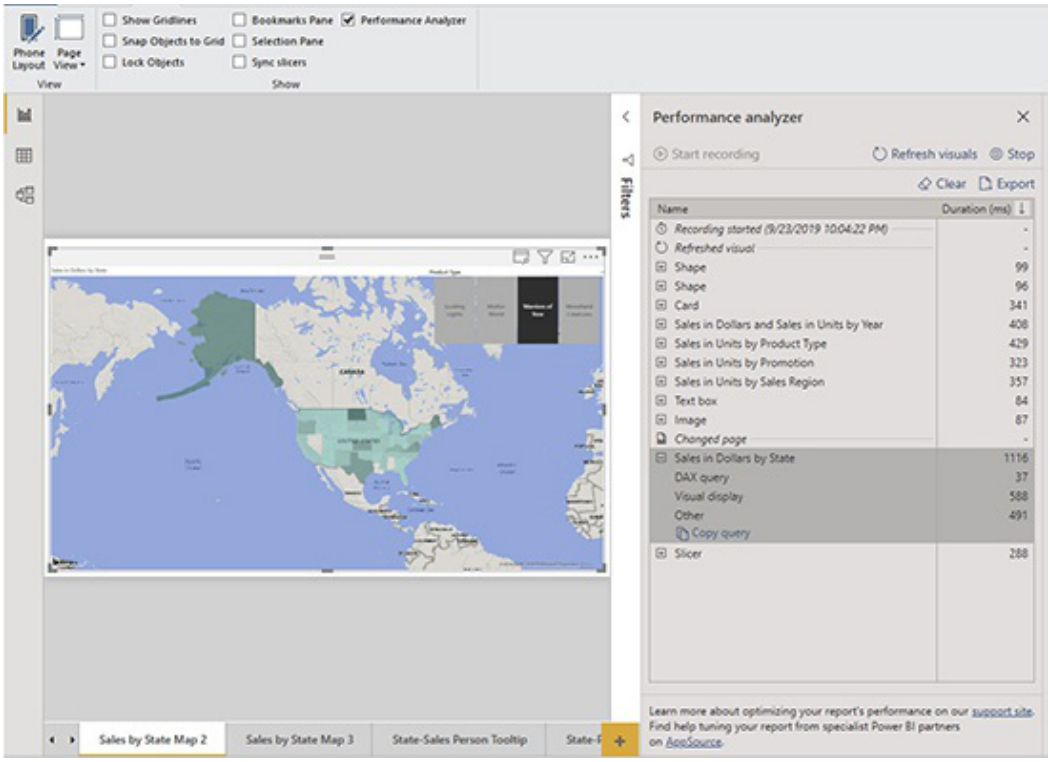

Hình 30: Performance Analyzer pane sau khi click "Start recording" và "Refresh visuals" mỗi visual hiện thời gian DAX query (gửi query đến model), Visual display (vẽ lên canvas), và Other. Visual nào chậm cần được tối ưu.

Tối ưu Data Model

- **Xóa cột không cần:** Trong Power Query, Remove columns không dùng cho visual hoặc measure. Mỗi cột text chiếm nhiều bộ nhớ.
- **Star Schema:** Đã thực hiện ở Lesson 2. Star Schema giúp query nhanh hơn snowflake hoặc flat table.
- **Date table riêng:** Tạo Date table thay vì dùng auto date hierarchy. Auto hierarchy tạo hidden tables tốn bộ nhớ, có thể giảm model size đáng kể. Chúng ta đã xây Date table trong Lesson 2 (Phần III); nếu chưa có, tạo bằng Power Query Blank Query hoặc DAX `CALENDARAUTO()`.

Tối ưu Visual

- **Giới hạn visual trên trang:** Mỗi visual = 1 query đến model. 15+ visual trên 1 trang = 15+ query đồng thời → chậm.
- **Filter sớm:** Áp Top N filter, page filter, hoặc report filter để giảm lượng data mỗi visual cần xử lý.
- **Hạn chế custom/third-party visuals:** Visual từ AppSource có thể chưa được tối ưu performance. Ưu tiên visual native của Power BI.

VIII.5. Mobile Layout (giới thiệu ngắn)

Power BI cho phép tạo layout riêng cho điện thoại, tối ưu cho màn hình dọc:

1. Vào **View** → **Mobile layout**.
2. Canvas chuyển sang phone emulator (dọc).
3. Kéo visual từ **Page visuals pane** (bên phải) lên canvas điện thoại.
4. Resize cho phù hợp. Thay đổi font/background **chỉ ảnh hưởng mobile view**, không thay đổi desktop.
5. Cross-filter, cross-highlight, slicer hoạt động bình thường trên mobile.

Khi publish lên Power BI Service, mobile layout tự động kích hoạt trên ứng dụng Power BI Mobile.

Khi nào nên tạo Mobile Layout?

- **Nên tạo:** Report được dùng bởi sales team hoặc management thường xuyên xem trên điện thoại.
- **Có thể bỏ qua:** Report phân tích phức tạp (nhiều visual, bảng dữ liệu chi tiết) – trải nghiệm mobile sẽ không tốt dù có layout riêng.
- **Tip:** Ưu tiên đưa KPI Cards và 1-2 chart quan trọng nhất lên mobile view. Bỏ qua Table và Matrix vì khó đọc trên màn hình nhỏ.

IX. Tổng kết và So sánh

IX.1. Bảng tổng hợp 6 tính năng tương tác

Tính năng	Diễn ra ở đâu	Mục đích chính	Cách kích hoạt
Slicer	Cả trang (hoặc tùy chỉnh)	Lọc dữ liệu theo tiêu chí	Chọn giá trị trên slicer
Cross-filter/highlight	Giữa các visual cùng trang	Tương tác tự động, so sánh nhanh	Click data point
Drill-down	Trong cùng 1 visual	Đào sâu theo phân cấp	Click icon Drill hoặc data point
Drill-through	Nhảy sang trang khác	Deep-dive vào 1 entity	Chuột phải → Drillthrough
Bookmarks & Buttons	Cả report	Lưu trạng thái, điều hướng	Click nút đã gán action
Custom Tooltip	Hover trên visual	Xem thông tin bổ sung nhanh	Hover chuột

IX.2. Checklist: Report đã đủ tương tác chưa?

Trước khi publish report, chạy qua checklist này:

- ☐ **Slicer từ Dimension table?** Không tạo slicer từ Fact table.
- ☐ **Sync Slicers giữa các trang?** Filter nhất quán khi chuyển trang.
- ☐ **Edit Interactions cho KPI cards?** Card tổng cố định không bị filter.
- ☐ **Hierarchy đã tạo?** Date, Geography, Product hierarchy cho drill-down.
- ☐ **Drill-through page có nút Back?** Kiểm tra Ctrl+Click trong Desktop.
- ☐ **Bookmark uncheck "Data" cho toggle?** Tránh reset slicer selections.
- ☐ **Tooltip page đã Hide?** Không hiện trong danh sách trang cho người dùng.
- ☐ **Conditional Formatting có icon kèm màu?** Accessibility cho người mù màu.
- ☐ **Performance Analyzer $<$ 5s?** Mỗi visual nên render dưới 2-3 giây.
- ☐ **Mobile layout đã setup?** Nếu report dùng trên điện thoại.

AI VIET NAM COURSE 2026

Quiz - Power BI: Enhancing Interactivity

1. Trong một trang Overview của Power BI, người thiết kế đặt các thành phần sau trên cùng một canvas:

- **Card**: Total Sales
- **Bar Chart**: Sales by Category
- **Pie Chart**: Sales by Category
- **Table**: Sales by Category
- **Line Chart**: Sales by Month

Theo nguyên tắc **"One Visual = One Insight"**, phương án đánh giá nào là hợp lý nhất?

a. Giữ nguyên toàn bộ vì mỗi visual có hình thức khác nhau nên đều cần thiết

b. Loại bỏ ít nhất một trong hai visual Bar Chart hoặc Pie Chart vì chúng đang trả lời gần như cùng một câu hỏi

c. Chỉ nên giữ lại Table vì bảng luôn chi tiết hơn biểu đồ

d. Thay toàn bộ bằng nhiều KPI Cards hơn để trang trông ngắn gọn

Đáp án đúng: B

Giải thích chi tiết:

Bar Chart và Pie Chart cùng đang thể hiện gần như một insight: phân bổ doanh thu theo Category. Khi hai visual trả lời cùng một câu hỏi mà không bổ sung góc nhìn mới, đó là dấu hiệu của **redundancy**.

- (a) sai: khác loại visual không đồng nghĩa với khác insight; nếu cùng trả lời một câu hỏi thì vẫn là trùng lặp
- (c) sai: Table tuy chi tiết nhưng không phù hợp để thay thế hoàn toàn biểu đồ trong overview (khó nhìn nhanh insight)
- (d) sai: thay bằng KPI Cards sẽ làm mất khả năng so sánh và phân tích breakdown

2. Một dashboard có các thành phần sau:

- **4 KPI Cards** (Total Sales, Orders, Profit, Margin)
- **Line Chart** theo Month (visual chính)
- **Bar Chart** theo Region (visual phụ)
- **Table** chi tiết

Theo nguyên tắc **information hierarchy**, cách bố trí nào sau đây là phù hợp nhất?

a. Đặt bảng chi tiết ở phía trên cùng để người dùng thấy đầy đủ dữ liệu ngay lập tức

b. Đặt KPI ở hàng trên cùng, biểu đồ chính ở khu vực giữa, bảng chi tiết ở phía dưới

c. Đặt tất cả visual cùng kích thước để tránh thiên vị thông tin nào

d. Đặt biểu đồ phụ lớn hơn biểu đồ chính để tạo cảm giác cân bằng thị giác

Đáp án đúng: B

Giải thích chi tiết:

Information hierarchy yêu cầu người dùng nhìn thấy **thông tin quan trọng nhất trước**. Vì vậy:

- KPI chính nên ở hàng trên cùng
- Hero visual (chart chính) nên ở khu vực trung tâm
- Bảng chi tiết nên đặt phía dưới (chỉ dùng khi cần đào sâu)

- (a) sai: bảng chi tiết không phù hợp làm điểm bắt đầu vì quá nhiều thông tin
- (c) sai: nếu tất cả visual giống nhau sẽ mất hierarchy, người dùng không biết nhìn vào đâu
- (d) sai: kích thước visual nên phản ánh mức độ quan trọng, không phải cân bằng hình thức

3. Một tác giả dashboard muốn làm nổi bật category có doanh thu cao nhất trong Bar Chart `Sales by Category`. Cách làm nào sau đây là **chiến lược màu sắc tốt nhất**?

a. Tô mỗi cột một màu nổi khác nhau để biểu đồ sinh động hơn

b. Tô toàn bộ cột cùng một màu đỏ để tạo cảm giác mạnh

c. Dùng màu trung tính cho hầu hết các cột và chỉ highlight category cao nhất bằng màu nhấn

d. Dùng gradient cầu vồng cho toàn bộ cột để thể hiện mức độ doanh thu

Đáp án đúng: C

Giải thích chi tiết:

Màu sắc nên được dùng để **dẫn hướng sự chú ý**. Khi đa số cột dùng màu trung tính và chỉ một cột được highlight, người dùng sẽ ngay lập tức nhận ra insight quan trọng nhất.

- (a) sai: quá nhiều màu nổi làm phân tán sự chú ý, không có điểm nhấn
- (b) sai: tất cả cùng màu khiến không thể phân biệt mức độ quan trọng
- (d) sai: gradient cầu vồng thường gây nhiễu và không phù hợp với dashboard business

4. Một report designer thiết kế dashboard với các đặc điểm:

- Tất cả visual đều có **border**
- Hầu hết chart bật **data labels** cho mọi điểm dữ liệu
- **Gridlines** đậm trong nhiều biểu đồ
- Mỗi visual dùng một bảng màu khác nhau
- Trang có **10 visual** và **5 slicer**

Người dùng phản hồi rằng report "rối mắt"và "khó đọc". Nguyên nhân chính là gì?

a. Report đang tối ưu tốt cho accessibility vì có nhiều tín hiệu thị giác

b. Report có nguy cơ bị visual clutter, làm giảm tốc độ đọc và tăng cognitive load

c. Report sẽ luôn chạy nhanh hơn vì người dùng có nhiều thông tin hơn

d. Report chắc chắn có information hierarchy tốt vì mỗi visual đều nổi bật

Đáp án đúng: B

Giải thích chi tiết:

Khi quá nhiều thành phần cùng cạnh tranh sự chú ý — như labels, borders, gridlines, màu sắc — report sẽ rơi vào tình trạng **visual clutter**.

- (a) sai: nhiều tín hiệu thị giác không đồng nghĩa với accessibility tốt
- (c) sai: nhiều visual hơn thường làm report chậm hơn, không nhanh hơn
- (d) sai: nếu mọi thứ đều nổi bật thì thực chất không có gì nổi bật → mất hierarchy

5. Xét một trang report Adventure Works có các visual sau:

- **Card** hiển thị measure `[Total Sales]`
- **Slicer dạng List** lọc theo `'DimSalesTerritory'[Group]` (3 giá trị: North America, Europe, Pacific)
- **Bar Chart** hiển thị `[Total Sales]` theo `DimProduct[Category]`

(Lưu ý: Slicer sử dụng cấu hình mặc định.)

Ban đầu, không có item nào được chọn trên Slicer. Người dùng thực hiện lần lượt:

(a) Click chọn **"North America"** trên Slicer.
(b) Giữ **Ctrl + click** thêm **"Europe"** trên Slicer.

Phát biểu nào sau đây mô tả đúng nhất hành vi của report sau bước 2?

a. Card và Bar Chart chỉ hiển thị dữ liệu của Europe (lần click sau ghi đè lần trước)

b. Card và Bar Chart hiển thị dữ liệu tổng hợp của North America VÀ Europe (Slicer cho phép multi-select khi giữ Ctrl)

c. Card hiển thị dữ liệu của North America, Bar Chart hiển thị dữ liệu của Europe (mỗi visual nhận filter riêng)

d. Card và Bar Chart hiển thị dữ liệu của cả 3 vùng vì Slicer multi-select với Ctrl chỉ hoạt động ở chế độ Dropdown

Đáp án đúng: B

Giải thích chi tiết:

Khi "Multi-select with CTRL" đang On (mặc định), giữ Ctrl + click sẽ thêm item vào selection hiện tại. Sau bước 2, cả North America và Europe đều được chọn → Card và Bar Chart hiển thị tổng hợp cả 2 vùng. Slicer tạo filter `Group IN {''North America'', ''Europe''}` → tất cả visual trên trang đều nhận filter này.

- (a) sai: Ctrl+click là thao tác **multi-select**, tức thêm item vào selection chứ không ghi đè. Ghi đè chỉ xảy ra khi click thường (không giữ Ctrl)
- (c) sai: Slicer tạo **một filter context chung** cho toàn trang (trừ khi Edit Interactions chỉnh thành None). Không thể mỗi visual nhận filter khác nhau từ cùng một Slicer
- (d) sai: Multi-select với Ctrl hoạt động ở **tất cả** kiểu Slicer (List, Dropdown, Tile), không giới hạn ở Dropdown

6. Trong report Adventure Works, một sinh viên tạo Slicer bằng cách kéo cột `FactSales[Sales Amount]` vào canvas, rồi đổi sang dạng Between (slider). Một sinh viên khác tạo Slicer từ `'DimSalesTerritory'[Group]` dạng List.

Phát biểu nào sau đây giải thích đúng nhất vấn đề khi tạo Slicer từ Fact table?

a. Không có vấn đề gì, vì Power BI tự động tối ưu bằng cách chỉ lấy giá trị unique từ Fact table cho Slicer, nên performance tương đương Dimension table

b. Slicer từ Fact table sẽ hiển thị sai dữ liệu vì các giá trị Sales Amount bị trùng lặp, dẫn đến một số giá trị bị mất trong danh sách Slicer, gây thiếu tùy chọn lọc

c. Power BI phải quét toàn bộ bảng Fact (có thể hàng triệu dòng) để tìm giá trị duy nhất, gây chậm performance, trong khi Dimension table đã chứa sẵn giá trị duy nhất nên nhanh hơn

d. Slicer từ Fact table chỉ hoạt động với kiểu Between (slider), không thể chuyển sang dạng List hoặc Dropdown vì Sales Amount là continuous numeric

Đáp án đúng: C

Giải thích chi tiết:

Đây là nguyên tắc cốt lõi trong data modeling: **Fact table dùng để đo lường (measure), Dimension table dùng để lọc (slicer, filter)**. Dimension table đã chứa sẵn giá trị duy nhất (mỗi Country/Category/Year chỉ xuất hiện 1 lần), nên Slicer render nhanh. Fact table có thể có hàng triệu dòng → quét toàn bộ để tìm unique values rất chậm.

- (a) sai: Power BI sẽ lấy giá trị unique, nhưng quá trình tìm giá trị unique trên bảng hàng triệu dòng rất tốn tài nguyên. "Tự động tối ưu" là không chính xác
- (b) sai: Slicer sẽ không **mất** giá trị. Power BI đảm bảo Slicer hiện đầy đủ các giá trị unique. Vấn đề là performance (quét lâu), không phải data loss
- (d) sai: Slicer từ Fact table có thể dùng nhiều kiểu hiển thị (List, Dropdown, Between...), không bị giới hạn chỉ Between

7. Xét một trang report có:

- **Bar Chart**: `[Total Sales]` theo `DimProduct[Color]`
- **Pie Chart**: `[Total Sales]` theo `DimProduct[Category]`
- **Table visual**: hiển thị chi tiết từng đơn hàng

Người dùng click vào thanh **"Black"** trên Bar Chart. (Lưu ý: Chưa có bất kỳ thiết lập Edit Interactions nào, tất cả đều ở hành vi mặc định.)

Phát biểu nào sau đây là đúng nhất?

a. Pie Chart bị cross-filtering (chỉ hiện phần "Black") và Table bị cross-highlighting (làm mờ các dòng không phải Black)

b. Pie Chart bị cross-highlighting (toàn bộ pie vẫn hiện, phần liên quan đến Black được giữ sáng, phần còn lại bị mờ) và Table bị cross-filtering (chỉ hiện các dòng liên quan đến Black)

c. Cả Pie Chart và Table đều bị cross-highlighting (làm mờ phần không liên quan đến Black), giữ nguyên tổng thể

d. Cả Pie Chart và Table đều bị cross-filtering (xóa bỏ hoàn toàn phần không liên quan đến Black)

Đáp án đúng: B

Giải thích chi tiết:

Theo bảng so sánh trong bài giảng: **Cross-highlighting** là mặc định cho Bar, Column, Pie, Donut, Treemap... **Cross-filtering** là mặc định cho Table, Matrix, Map. Click "Black" trên Bar Chart → Pie Chart được highlight (phần Black sáng, phần còn lại mờ, tổng thể vẫn hiện) + Table chỉ hiện dòng liên quan đến Black (các dòng khác bị xóa).

- (a) sai: Đảo ngược hành vi mặc định. Pie Chart mặc định là cross-highlighting, Table mặc định là cross-filtering
- (c) sai: Table mặc định là cross-filtering (xóa bỏ), không phải cross-highlighting (làm mờ)
- (d) sai: Pie Chart mặc định là cross-highlighting (làm mờ), không phải cross-filtering (xóa bỏ)

8. Một trang dashboard Adventure Works có:

- **Bar Chart**: `[Total Sales]` theo `DimProduct[Color]`
- **Card**: hiển thị `[Total Sales]` (tổng toàn bộ doanh thu)
- **Column Chart**: `[Total Sales]` theo `DimDate[Fiscal Year]`

Yêu cầu: Khi click vào bất kỳ thanh nào trên Bar Chart, Card phải **luôn giữ nguyên giá trị tổng toàn bộ** (không bị filter), trong khi Column Chart vẫn bị highlight bình thường.

Để đạt yêu cầu trên, cần thực hiện bao nhiêu bước thiết lập Edit Interactions, và thiết lập cụ thể là gì?

a. 1 bước: Chọn Bar Chart → Format → Edit Interactions → trên Card chọn **None**, trên Column Chart giữ **Highlight** (mặc định)

b. 2 bước: Bước 1, chọn Card → Format → Edit Interactions → trên Bar Chart chọn None. Bước 2, chọn Column Chart → Format → Edit Interactions → trên Bar Chart chọn Highlight

c. 1 bước: Chọn Card → Format → Edit Interactions → bật "Lock as static" để Card không bị filter bởi bất kỳ visual nào

d. 2 bước: Bước 1, chọn Card → Format → Edit Interactions → trên Bar Chart chọn None. Bước 2, chọn Card → Format → Edit Interactions → trên Column Chart chọn None

Đáp án đúng: A

Giải thích chi tiết:

Edit Interactions hoạt động theo nguyên tắc: chọn **visual nguồn** (visual phát sinh tương tác khi click) trước, rồi thiết lập hành vi trên **visual đích**. Ở đây, visual nguồn là Bar Chart. Chọn Bar Chart → Format → Edit Interactions → trên Card chọn None (không phản ứng), trên Column Chart giữ Highlight (mặc định). Chỉ cần 1 lần thiết lập vì chỉ có 1 visual nguồn.

- (b) sai: Hiểu ngược logic nguồn/đích. Edit Interactions xuất phát từ **visual nguồn** (Bar Chart) chứ không phải từ visual đích (Card hay Column Chart)
- (c) sai: Không tồn tại tùy chọn "Lock as static" trong Power BI Edit Interactions. Chỉ có 3 chế độ: Filter, Highlight, None
- (d) sai: Hiểu ngược logic. Cả 2 bước đều chọn Card làm visual nguồn, nghĩa là thiết lập "khi click Card thì ảnh hưởng gì", không phải "khi click Bar Chart thì Card phản ứng thế nào"

9. Xét một Bar Chart hiển thị `[Total Sales]` theo Date Hierarchy (`Fiscal Year` → `Fiscal Quarter` → `Month`). Hiện tại chart đang hiển thị 3 cột: FY2018, FY2019, FY2020.

Một người dùng muốn xem doanh thu theo **Quarter chỉ của FY2019** (không thấy Quarter của FY2018 hay FY2020).

Người dùng cần sử dụng chế độ drill nào?

a. **Go to Next Level** (⇓): toàn bộ visual chuyển sang level Quarter, hiện tất cả Quarter của mọi năm

b. **Expand All** (↗): chart hiện "FY2018-Q1", "FY2018-Q2"..., nhãn kết hợp Year + Quarter cho tất cả năm

c. **Drill Mode** (↓ nền xám): bật Drill Mode rồi click vào cột FY2019, chart chuyển sang hiện Q1–Q4 chỉ của FY2019

d. **Drill Up** (↑): quay lại level cao hơn, từ Quarter về Year

Đáp án đúng: C

Giải thích chi tiết:

Drill Mode (icon ↓ nền xám) bật chế độ "click để drill". Khi bật Drill Mode rồi click vào cột FY2019, chart drill xuống level tiếp **chỉ cho item FY2019**, hiện Q1–Q4 chỉ của FY2019. Đây là chế độ duy nhất cho phép drill vào **1 item cụ thể**.

- (a) sai: Go to Next Level chuyển **toàn bộ** visual sang level tiếp theo, không filter theo item cụ thể. Sẽ hiện Q1–Q4 của tất cả năm gộp chung
- (b) sai: Expand All giữ label level trước và thêm level tiếp, hiện tất cả combo "FY2018-Q1"... "FY2020-Q4" ($3 \times 4 = 12$ cột), không filter chỉ FY2019
- (d) sai: Drill Up quay **lên** level cao hơn (từ Quarter → Year), không phải đào sâu xuống

10. Tiếp tục với Bar Chart câu 5, đang hiển thị 3 cột (FY2018, FY2019, FY2020).

Người dùng click **Go to Next Level** (⇓). Sau đó, người dùng click **Drill Up** (↑) để quay lại Year, rồi click **Expand All** (↗).

So sánh kết quả hiển thị giữa Go to Next Level và Expand All:

a. Go to Next Level hiện Q1, Q2, Q3, Q4 (gộp tất cả năm, mỗi Quarter là tổng 3 năm). Expand All hiện "FY2018-Q1", "FY2018-Q2"..., "FY2020-Q4" (giữ label Year, thêm Quarter, mỗi cột là 1 năm–1 quarter cụ thể)

b. Go to Next Level hiện "FY2018-Q1", "FY2018-Q2"..., "FY2020-Q4". Expand All hiện Q1, Q2, Q3, Q4 gộp chung

c. Cả hai đều hiện Q1, Q2, Q3, Q4 gộp chung, chỉ khác nhau ở thứ tự sắp xếp

d. Cả hai đều hiện "FY2018-Q1", "FY2018-Q2"..., "FY2020-Q4", chỉ khác nhau ở nhãn trục

Đáp án đúng: A

Giải thích chi tiết:

Go to Next Level (⇓): Thay thế level hiện tại → hiện Q1, Q2, Q3, Q4. Mỗi Quarter là **tổng gộp** cả 3 năm. Label Year biến mất, chỉ còn Quarter. **Expand All (↗):** Giữ lại level Year + thêm Quarter → hiện "FY2018-Q1", "FY2018-Q2"..., "FY2020-Q4" (12 cột). Mỗi cột là doanh thu của 1 năm cụ thể trong 1 quarter cụ thể. Sự khác biệt cốt lõi: **Thay thế** (Go to Next Level) vs **Thêm vào** (Expand All).

- (b) sai: Đảo ngược hành vi của 2 chế độ
- (c) sai: Kết quả hoàn toàn khác nhau, không chỉ khác thứ tự sắp xếp. Go to Next Level gộp data theo Quarter (mất Year detail), Expand All giữ cả 2 level
- (d) sai: Kết quả hoàn toàn khác nhau. Go to Next Level không giữ label Year

AI VIET NAM COURSE 2026

Introduction to Basic SQL

I. Giới thiệu

Trong các hệ thống dữ liệu hiện đại, thông tin thường được ghi nhận dưới dạng có cấu trúc: danh sách học viên trong một nền tảng học tập, đơn hàng trong một hệ thống thương mại điện tử, sản phẩm trong kho, giao dịch trong ngân hàng hoặc lượt truy cập trên một website. Khi quy mô dữ liệu còn nhỏ, người dùng có thể quan sát trực tiếp bằng bảng tính hoặc thao tác thủ công. Tuy nhiên, khi dữ liệu tăng lên hàng nghìn, hàng triệu dòng và cần được truy xuất nhiều lần theo các điều kiện khác nhau, cách tiếp cận thủ công không còn phù hợp.

Điểm cốt lõi của dữ liệu có cấu trúc là dữ liệu không tồn tại như một đoạn văn bản tự do, mà được tổ chức thành bảng, dòng và cột. Cách tổ chức này giúp dữ liệu có thể được lưu trữ nhất quán, truy xuất chính xác và xử lý lặp lại bằng các câu truy vấn. Trong bối cảnh đó, SQL trở thành một ngôn ngữ nền tảng để làm việc với database. Thay vì đọc toàn bộ dữ liệu bằng mắt, người dùng có thể mô tả rõ phần dữ liệu cần lấy như *Lấy từ bảng nào?, lấy những cột nào?, lọc theo điều kiện nào? và sắp xếp kết quả ra sao?*.

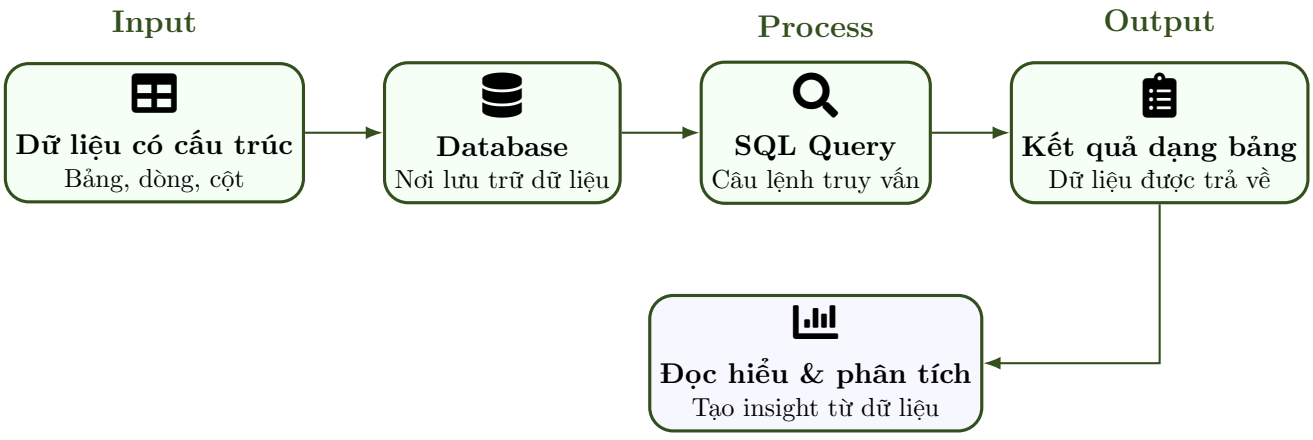

Hình 1: Luồng tổng quát từ dữ liệu có cấu trúc đến kết quả truy vấn bằng SQL.

Một truy vấn SQL cơ bản có thể được xem như một câu hỏi có cấu trúc gửi đến database. Ví dụ, với một bảng lưu thông tin học viên, ta có thể đặt các câu hỏi như: danh sách học viên gồm những ai, học viên nào thuộc một khóa học cụ thể, học viên nào có điểm dưới một ngưỡng nhất

định, hoặc những học viên nào có điểm cao nhất. Các câu hỏi này đều bắt đầu từ nhu cầu đọc dữ liệu, sau đó được chuyển thành các thành phần trong câu lệnh SQL.

Nội dung bài viết tập trung vào các phần chính sau:

- Giới thiệu các khái niệm nền tảng về database, table, row, column, DBMS và SQL.
- Làm rõ tư duy chuyển một câu hỏi dữ liệu thành một truy vấn SQL cơ bản.
- Minh họa các statement đầu tiên thường gặp trong SQL như `SELECT`, `FROM`, `WHERE`, `ORDER BY` và `LIMIT`.
- Áp dụng các statement trên vào một bảng dữ liệu nhỏ tên students để quan sát cách SQL trả lời từng câu hỏi dữ liệu.

II. Cơ sở lý thuyết

II.1. Database là gì?

Database

Database là nơi lưu trữ dữ liệu có tổ chức, giúp dữ liệu được quản lý, truy xuất và cập nhật một cách nhất quán.

Database thường được dùng khi dữ liệu cần được quản lý ổn định, có thể truy cập nhiều lần và cần đảm bảo tính nhất quán. Với dữ liệu nhỏ, bảng tính có thể đủ dùng. Nhưng khi dữ liệu tăng lên hoặc được nhiều người cùng sử dụng, database giúp việc quản lý và truy vấn trở nên đáng tin cậy hơn.

II.2. Table, row và column

Table, row và column

Table là bảng dữ liệu. Row là một dòng dữ liệu, thường biểu diễn một bản ghi cụ thể. Column là một cột dữ liệu, biểu diễn một thuộc tính của bản ghi.

Để đọc một bảng dữ liệu, ta cần phân biệt rõ ba lớp thông tin: toàn bộ bảng, từng cột và từng dòng. Ví dụ dưới đây dùng bảng `students` và tô màu trực tiếp các phần cần chú ý.

student_id	name	course	city	score
1	An	SQL Basic	Hà Nội	8.5
2	**Bình**	SQL Basic	Đà Nẵng	6.5
3	Chi	Python Basic	TP.HCM	9.0

Hình 2: Minh họa table, row, column và cell trong một bảng dữ liệu.

Khái niệm	Cách nhận biết trong ví dụ
Table	Toàn bộ bảng `students`, gồm nhiều dòng và nhiều cột.
Column	Cột `name` được tô xanh, biểu diễn tên của từng học viên.
Row	Dòng học viên `Bình` được tô vàng, biểu diễn một bản ghi cụ thể.
Cell	Ô `Bình` là giao điểm giữa một dòng và một cột.

Lưu ý

Trong một số tài liệu, **row** còn được gọi là **record**, vì mỗi dòng thường biểu diễn một bản ghi cụ thể trong hệ thống. **Column** cũng có thể được gọi là **field** hoặc **attribute**, đặc biệt trong ngữ cảnh database. Trong data warehouse hoặc BI, một số cột mô tả như thành phố, danh mục

sản phẩm hoặc nhóm khách hàng có thể được xem là **dimension**, vì chúng thường được dùng để phân nhóm, lọc hoặc phân tích dữ liệu.

Trong ví dụ trên, bảng có năm cột và ba dòng dữ liệu. Mỗi dòng tương ứng với một học viên. Nếu mỗi dòng không đại diện cho một học viên mà đại diện cho một lần kiểm tra, cách đọc dữ liệu và cách truy vấn sẽ thay đổi.

II.3. DBMS là gì?

DBMS

DBMS là hệ thống phần mềm dùng để tạo, quản lý, truy vấn và cập nhật database. DBMS đóng vai trò trung gian giữa người dùng, câu lệnh SQL và dữ liệu được lưu trữ.

Nói đơn giản, người dùng viết câu lệnh SQL, DBMS tiếp nhận câu lệnh đó, làm việc với database và trả kết quả về cho người dùng. Trong thực tế có nhiều hệ quản trị cơ sở dữ liệu khác nhau; mỗi hệ phù hợp với một nhóm nhu cầu riêng.

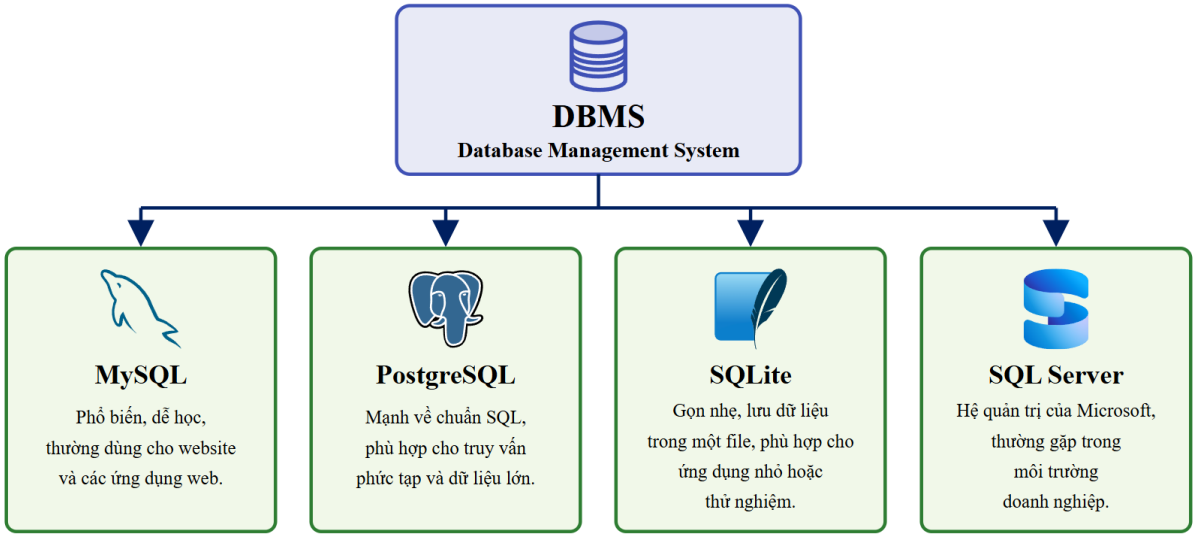

Hình 3: Một số hệ quản trị cơ sở dữ liệu phổ biến.

Điểm chung của các DBMS trên là chúng đều giúp dữ liệu được lưu trữ có tổ chức và cho phép người dùng truy vấn dữ liệu bằng SQL.

II.4. SQL query là gì?

SQL và SQL query

SQL là ngôn ngữ dùng để truy vấn và thao tác với dữ liệu có cấu trúc trong database.

Một SQL query có thể được hiểu như một yêu cầu có cấu trúc gửi đến database. Trong yêu cầu đó, người dùng cần nói rõ mình muốn lấy dữ liệu gì, dữ liệu nằm ở đâu và kết quả cần được xử lý như thế nào.

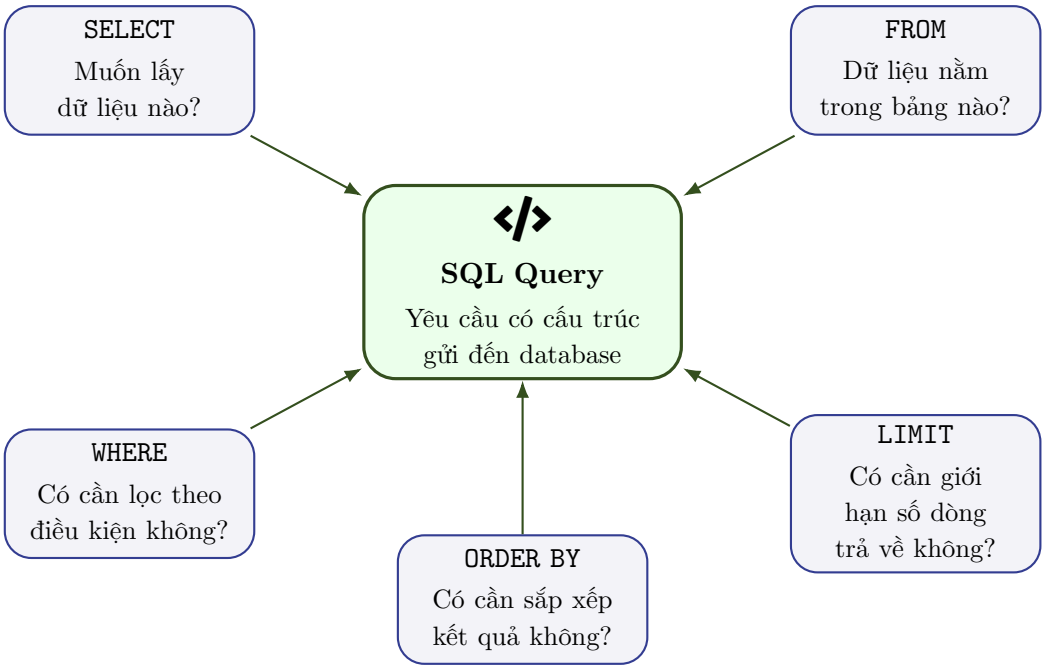

Hình 4: Một SQL query gồm nhiều thành phần, mỗi thành phần mô tả một phần của yêu cầu dữ liệu.

Từ hình minh họa trên, có thể thấy SQL query là một yêu cầu có cấu trúc gửi đến database, trong đó mỗi thành phần đều có một chức năng rõ ràng. Vì vậy, để hiểu và viết được một truy vấn SQL cơ bản, ta cần nắm được vai trò của từng thành phần trong truy vấn. Ở phần tiếp theo, ta sẽ lần lượt đi qua các statement cơ bản như `SELECT`, `FROM`, `WHERE`, `ORDER BY` và `LIMIT`.

III. Case study: thiết kế và truy vấn bảng students

Trong case study này, ta không giả định bảng `students` đã có sẵn từ đầu. Thay vào đó, ta sẽ đi theo một quy trình đầy đủ hơn: trước hết thiết kế schema cho bảng, sau đó tạo bảng bằng `CREATE TABLE`, thêm dữ liệu mẫu bằng `INSERT INTO`, rồi dùng các statement SQL cơ bản để truy vấn dữ liệu.

III.1. Schema của bảng students

Schema có thể hiểu là bản mô tả cấu trúc của một bảng. Với bảng `students`, schema cần cho biết tên cột, ý nghĩa của cột và kiểu dữ liệu dự kiến.

Schema

Schema là phần mô tả cấu trúc của dữ liệu. Với một bảng, schema thường cho biết bảng có những cột nào, mỗi cột lưu loại thông tin gì và kiểu dữ liệu tương ứng là gì.

Cột	Kiểu dữ liệu gợi ý	Ý nghĩa
student_id	INT PRIMARY KEY	Mã định danh duy nhất của học viên.
name	VARCHAR(50)	Tên học viên.
course	VARCHAR(50)	Tên khóa học mà học viên đang tham gia.
city	VARCHAR(50)	Thành phố của học viên.
score	DECIMAL(4,1)	Điểm số của học viên, có tối đa 4 chữ số tất cả và 1 chữ số sau dấu phẩy.

Hình 5: Schema đề xuất cho bảng students.

Từ schema trên, ta có thể hình dung trước bảng `students` sẽ gồm năm cột. Cột `student_id` dùng số nguyên và được chọn làm `PRIMARY KEY`, vì mã học viên là trường định danh cho từng học viên. Các cột `name`, `course` và `city` dùng kiểu chuỗi ký tự. Cột `score` dùng kiểu số thập phân vì điểm số có thể là 8.5, 6.5 hoặc 7.0. Với `DECIMAL(4,1)`, giá trị có tối đa 4 chữ số tất cả và 1 chữ số sau dấu phẩy.

III.2. Tạo bảng bằng CREATE TABLE

Sau khi có schema, ta có thể tạo bảng trong database. Statement `CREATE TABLE` dùng để khai báo một bảng mới và các cột bên trong bảng đó.

CREATE TABLE

`CREATE TABLE` dùng để tạo một bảng mới trong database. Khi tạo bảng, ta cần chỉ định tên bảng, tên các cột và kiểu dữ liệu của từng cột.

Cú pháp tổng quát:

```
CREATE TABLE table_name (
  column_1 data_type,
  column_2 data_type,
  ...
);
```

```sql
CREATE TABLE students (
    student_id INT PRIMARY KEY,
    name VARCHAR(50),
    course VARCHAR(50),
    city VARCHAR(50),
    score DECIMAL(4,1)
);
```

Trong statement trên, `students` là tên bảng cần tạo. Bên trong cặp dấu ngoặc là danh sách các cột của bảng. Mỗi dòng gồm tên cột và kiểu dữ liệu tương ứng. Dấu phẩy được dùng để phân tách các cột. Dấu chấm phẩy ở cuối statement cho biết câu lệnh đã kết thúc.

Trong ví dụ này, `student_id` được khai báo là `PRIMARY KEY`, nghĩa là mỗi học viên cần có một mã định danh duy nhất và không bị thiếu. Về mặt kỹ thuật, một số hệ quản trị cơ sở dữ liệu vẫn cho phép tạo bảng không có khóa chính, nhưng trong thực hành thiết kế database, việc chỉ định khóa chính giúp dữ liệu dễ quản lý và tránh trùng lặp bản ghi.

Thành phần	Vai trò
`CREATE TABLE students`	Tạo một bảng mới tên là `students`.
`student_id INT PRIMARY KEY`	Tạo cột `student_id` lưu số nguyên và dùng làm khóa chính để định danh mỗi học viên.
`name VARCHAR(50)`	Tạo cột `name` lưu chuỗi ký tự tối đa 50 ký tự.
`score DECIMAL(4,1)`	Tạo cột `score` lưu số thập phân có tối đa 4 chữ số tất cả và 1 chữ số sau dấu phẩy.

Hình 6: Giải thích các thành phần chính trong câu lệnh `CREATE TABLE`.

III.3. Thêm dữ liệu bằng INSERT INTO

Sau khi bảng đã được tạo, bảng vẫn chưa có dữ liệu. Statement `INSERT INTO` dùng để thêm các dòng dữ liệu mới vào bảng.

INSERT INTO

`INSERT INTO` dùng để thêm dữ liệu vào một bảng đã tồn tại. Khi thêm dữ liệu, cần đảm bảo thứ tự giá trị khớp với thứ tự các cột được khai báo.

Cú pháp tổng quát:

```
INSERT INTO table_name (column_1, column_2, ...)
VALUES
  (value_1, value_2, ...),
  (value_1, value_2, ...);
```

```
INSERT INTO students (student_id, name, course, city, score)
VALUES
    (1, 'An',   'SQL Basic',      'Hà Nội', 8.5),
    (2, 'Bình', 'SQL Basic',      'Đà Nẵng', 6.5),
    (3, 'Chi',  'Python Basic',   'TP.HCM', 9.0),
    (4, 'Dũng', 'SQL Basic',      'Cần Thơ', 7.5),
    (5, 'Hà',   'Python Basic',   'Hà Nội', 5.5),
    (6, 'Minh', 'SQL Basic',      'TP.HCM', 8.0),
    (7, 'Lan',  'Data Analysis',  'Hà Nội', 7.0),
    (8, 'Nam',  'Data Analysis',  'Đà Nẵng', 6.0);
```

Phần `INSERT INTO students` cho biết dữ liệu sẽ được thêm vào bảng `students`. Danh sách trong ngoặc ngay sau tên bảng cho biết các cột sẽ nhận dữ liệu. Phần `VALUES` chứa các dòng dữ liệu mới. Mỗi cặp ngoặc tròn tương ứng với một dòng dữ liệu trong bảng.

Ví dụ, dòng dữ liệu đầu tiên là:

student_id	name	course	city	score
1	An	SQL Basic	Hà Nội	8.5

Điều quan trọng là thứ tự giá trị phải khớp với thứ tự cột đã khai báo. Giá trị `1` đi vào cột `student_id`, giá trị `An` đi vào cột `name`, giá trị `SQL Basic` đi vào cột `course`, giá trị `Hà Nội` đi vào cột `city` và giá trị `8.5` đi vào cột `score`.

III.4. Quan sát dữ liệu sau khi thêm

Sau khi tạo bảng và thêm dữ liệu, ta có thể quan sát bảng `students` ở dạng dữ liệu mẫu như sau.

student_id	name	course	city	score
1	An	SQL Basic	Hà Nội	8.5
2	Bình	SQL Basic	Đà Nẵng	6.5
3	Chi	Python Basic	TP.HCM	9.0
4	Dũng	SQL Basic	Cần Thơ	7.5
5	Hà	Python Basic	Hà Nội	5.5
6	Minh	SQL Basic	TP.HCM	8.0
7	Lan	Data Analysis	Hà Nội	7.0
8	Nam	Data Analysis	Đà Nẵng	6.0

Hình 7: Bảng students sau khi được tạo và thêm dữ liệu mẫu.

Đến thời điểm này, bảng `students` đã có cấu trúc và dữ liệu mẫu. Từ đây, ta có thể bắt đầu dùng các statement SQL cơ bản để đặt câu hỏi và truy vấn dữ liệu trong bảng.

III.5. SELECT và FROM

SELECT và FROM

Trong một truy vấn đọc dữ liệu từ bảng, `SELECT` và `FROM` thường đi cùng nhau. `SELECT` cho biết người dùng muốn lấy những cột nào. `FROM` cho biết dữ liệu sẽ được lấy từ bảng nào. Nếu muốn lấy tất cả các cột, ta có thể dùng ký hiệu `*`.

Cú pháp tổng quát:

```
SELECT column_1, column_2, ...
FROM table_name;
```

Ví dụ, truy vấn sau lấy hai cột `name` và `score` từ bảng `students`.

```sql
SELECT name, score
FROM students;
```

Trong truy vấn trên, phần `SELECT name, score` cho biết ta muốn xem hai cột `name` và `score`. Phần `FROM students` cho biết dữ liệu được đọc từ bảng `students`. Kết quả trả về chỉ gồm những cột được chỉ định trong phần `SELECT`. Nếu muốn xem toàn bộ các cột trong bảng, ta có thể dùng ký hiệu `*`.

```sql
SELECT *
FROM students;
```

Trong ví dụ này, `SELECT *` nghĩa là lấy tất cả các cột của bảng `students`.

III.6. WHERE

WHERE

`WHERE` dùng để giữ lại các dòng thỏa một điều kiện nhất định. Những dòng không thỏa điều kiện sẽ không xuất hiện trong kết quả.

Cú pháp tổng quát:

```
SELECT column_1, column_2, ...
FROM table_name
WHERE condition;
```

Ví dụ, truy vấn sau chỉ giữ lại các học viên thuộc khóa `SQL Basic`.

```sql
SELECT student_id, name, course, score
FROM students
WHERE course = 'SQL Basic';
```

Trong truy vấn này, database vẫn đọc dữ liệu từ bảng `students`, nhưng chỉ trả về các dòng có `course = 'SQL Basic'`. Ví dụ tiếp theo lọc các học viên có điểm dưới 7.

```sql
SELECT name, course, score
FROM students
WHERE score < 7;
```

Điều kiện `score < 7` giúp giữ lại những học viên có điểm nhỏ hơn 7.

III.7. ORDER BY

ORDER BY

`ORDER BY` dùng để sắp xếp kết quả theo một hoặc nhiều cột. Có thể sắp xếp tăng dần bằng `ASC` hoặc giảm dần bằng `DESC`. Nếu không ghi rõ, nhiều hệ quản trị cơ sở dữ liệu sẽ mặc định sắp xếp tăng dần.

Cú pháp tổng quát:

```
SELECT column_1, column_2, ...
FROM table_name
ORDER BY column_name ASC|DESC;
```

```sql
SELECT name, course, score
FROM students
ORDER BY score DESC;
```

Truy vấn trên lấy các cột `name`, `course` và `score` từ bảng `students`, sau đó sắp xếp kết quả theo `score` giảm dần. Vì vậy, các học viên có điểm cao hơn sẽ xuất hiện trước trong kết quả.

III.8. LIMIT

LIMIT

`LIMIT` dùng để giới hạn số dòng trong kết quả trả về. Statement này thường được dùng khi ta chỉ muốn xem một vài dòng đầu tiên sau khi lọc hoặc sắp xếp.

Cú pháp tổng quát:

```
SELECT column_1, column_2, ...
FROM table_name
LIMIT n;
```

```sql
SELECT name, course, score
FROM students
ORDER BY score DESC
LIMIT 3;
```

Truy vấn trên sắp xếp học viên theo điểm giảm dần, sau đó chỉ lấy 3 dòng đầu tiên. Đây là cách thường dùng để tìm các bản ghi đứng đầu theo một tiêu chí nào đó.

III.9. Kết hợp các statement trong một truy vấn

Truy vấn kết hợp

Một truy vấn SQL thường kết hợp nhiều statement để trả lời một câu hỏi dữ liệu cụ thể.

```sql
SELECT name, city, score
FROM students
WHERE course = 'SQL Basic'
ORDER BY score DESC
LIMIT 2;
```

Truy vấn trên đọc dữ liệu từ bảng `students`, chỉ giữ lại các học viên thuộc khóa `SQL Basic`, sắp xếp theo điểm giảm dần và lấy 2 dòng đầu tiên. Qua ví dụ này, ta thấy mỗi statement đảm nhiệm một vai trò riêng, nhưng khi kết hợp lại chúng giúp trả lời một câu hỏi dữ liệu cụ thể.

AI VIET NAM COURSE 2026

Pandas & SQL for Data Analysis

I. Data Retrieval

I.1. Lý thuyết

Data Retrieval là gì?

Data Retrieval là bước **lấy đúng dữ liệu cần dùng** từ nguồn dữ liệu (CSV/Database) để phục vụ phân tích và mô hình hoá.
Các thao tác thường gặp:

- **Projection**: chọn cột cần thiết.
- **Selection**: lọc dòng theo điều kiện.
- **Ordering & Top-N**: sắp xếp và lấy N dòng theo tiêu chí.
- **Aggregation**: tổng hợp theo nhóm để tạo bảng báo cáo.
- **Computed fields**: tạo thêm cột tính toán (ví dụ GDP $\approx$ dân số $\times$ GDP/người).

I.2. Case study: Gapminder (Simple)

Bộ dữ liệu Gapminder (Simple)

Dataset `gapminder_simple.csv` là phiên bản rút gọn (1000 samples) từ Gapminder. Các cột chính:

- `country`: tên quốc gia
- `continent`: châu lục
- `year`: năm quan sát
- `lifeExp`: tuổi thọ trung bình
- `pop`: dân số
- `gdpPercap`: GDP bình quân đầu người

Mục tiêu: luyện các thao tác retrieval cơ bản (projection, selection, top-N, aggregation, computed fields) bằng cả Pandas và SQL. Các bạn có thể tải data theo link Data.

I.2.1. Import & đọc dataset

Pandas

```python
import pandas as pd

df = pd.read_csv("gapminder_simple.csv")
df.head()
```

I.2.2. Bước 1: Projection

Mục tiêu là chỉ giữ các cột phục vụ phân tích (dataset gọn hơn, dễ nhìn hơn).

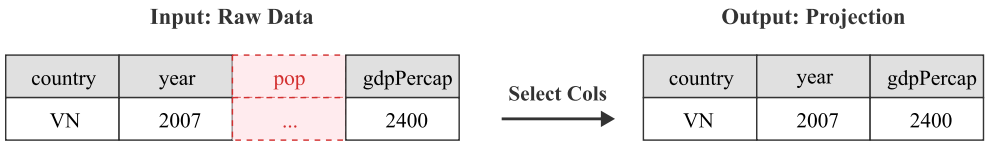

Pandas

```python
use_cols = ["country", "continent", "year", "lifeExp", "gdpPercap"]
df1 = df[use_cols].copy()

df1.head(10)
```

Giải thích (Pandas)

- Projection giúp bỏ các cột chưa cần (ở đây bỏ `pop`) để tập trung vào mục tiêu hiện tại.
- `copy()` giúp thao tác an toàn khi bạn muốn tạo thêm cột hoặc chỉnh sửa sau đó.

SQL

```sql
SELECT country, continent, `year`, lifeExp, gdpPercap
FROM gapminder_simple
LIMIT 10;
```

I.2.3. Bước 2: Selection

Mục tiêu là lọc theo châu lục và năm để lấy đúng phạm vi cần phân tích.

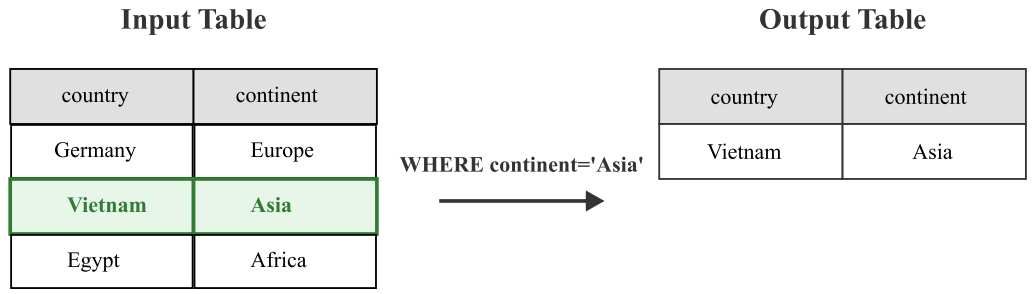

Pandas

```python
# Ví dụ: Chỉ lấy Asia, giai đoạn 1990-2007
mask = (df["continent"] == "Asia") & (df["year"] >= 1990) & (df["year"] <= 2007)
asia_1990_2007 = df.loc[mask, ["country","continent","year","lifeExp","gdpPercap","pop"]].copy()

asia_1990_2007.head(10)
```

Giải thích (Pandas)

- Điều kiện lọc trong Pandas dùng boolean mask, tương đương `WHERE` trong SQL.
- `df.loc[mask, cols]` vừa lọc dòng vừa chọn cột, rất hay dùng trong retrieval.

SQL

```sql
SELECT country, continent, `year`, lifeExp, gdpPercap, pop
FROM gapminder_simple
WHERE continent = 'Asia'
  AND `year` BETWEEN 1990 AND 2007
LIMIT 10;
```

I.2.4. Bước 3: Ordering & Top-N

Mục tiêu là lấy top 10 quốc gia có `gdpPercap` cao nhất trong năm 2007.

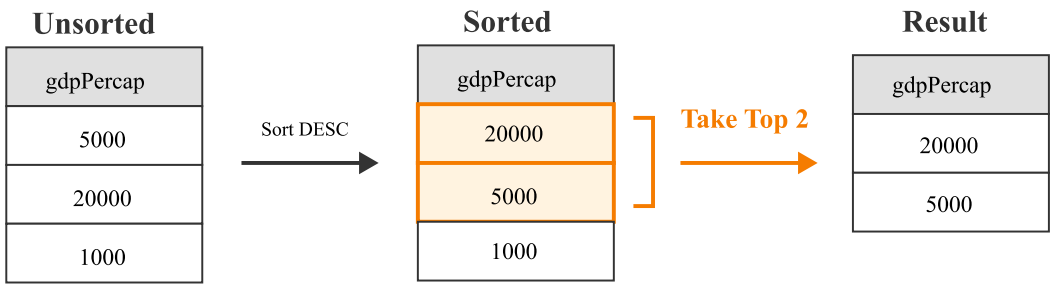

Pandas

```python
df_2007 = df[df["year"] == 2007].copy()

top10_gdpPercap_2007 = (
    df_2007.sort_values("gdpPercap", ascending=False)
           [["country","continent","year","gdpPercap","lifeExp"]]
           .head(10)
)

top10_gdpPercap_2007
```

Giải thích (Pandas)

- `sort_values(..., ascending=False)` sắp xếp giảm dần theo tiêu chí.
- `head(10)` lấy top 10, tương đương `LIMIT 10`.

SQL

```sql
SELECT country, continent, `year`, gdpPercap, lifeExp
FROM gapminder_simple
WHERE `year` = 2007
ORDER BY gdpPercap DESC
LIMIT 10;
```

I.2.5. Bước 4: Aggregation đơn giản

Mục tiêu: tổng hợp theo châu lục trong năm 2007 với 2 chỉ số cơ bản: **tuổi thọ trung bình** và **GDP/người trung bình**.

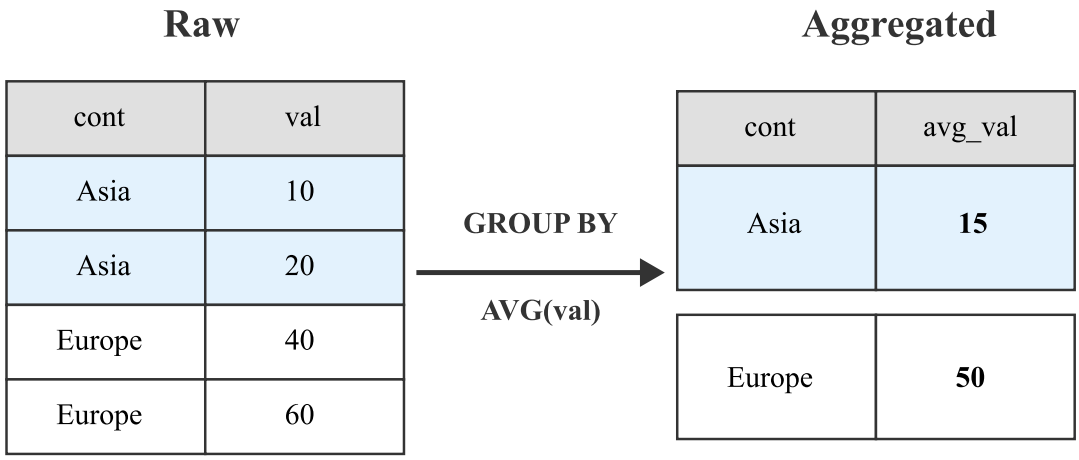

Pandas

```python
tmp = df[df["year"] == 2007].copy()

agg_continent_2007 = (
    tmp.groupby("continent", as_index=False)
       .agg(
           avg_lifeExp=("lifeExp", "mean"),
           avg_gdpPercap=("gdpPercap", "mean")
       )
       .sort_values("avg_gdpPercap", ascending=False)
)

agg_continent_2007
```

Giải thích (Pandas)

- `groupby("continent")` chia dữ liệu theo châu lục.
- `mean()` cho ra bảng summary gọn, đúng tinh thần retrieval cho báo cáo nhanh.

SQL

```sql
SELECT
  continent,
  AVG(lifeExp) AS avg_lifeExp,
  AVG(gdpPercap) AS avg_gdpPercap
FROM gapminder_simple
WHERE `year` = 2007
GROUP BY continent
ORDER BY avg_gdpPercap DESC;
```

I.2.6. Bước 5: Computed fields

Mục tiêu: tạo GDP xấp xỉ theo công thức `GDP = pop * gdpPercap`, rồi lấy top theo GDP trong năm 2007.

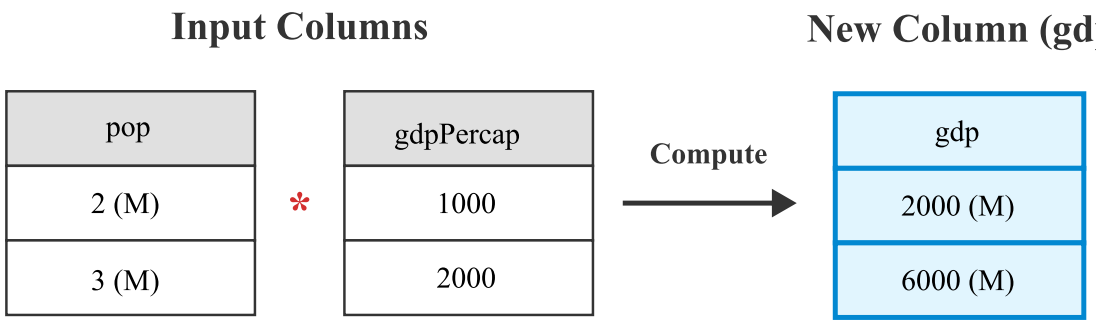

Pandas

```python
tmp = df[df["year"] == 2007].copy()
tmp["gdp"] = tmp["pop"] * tmp["gdpPercap"]

top10_gdp_2007 = (
    tmp.sort_values("gdp", ascending=False)
       [["country","continent","year","pop","gdpPercap","gdp","lifeExp"]]
       .head(10)
)

top10_gdp_2007
```

Giải thích (Pandas)

- `gdp = pop * gdpPercap` là computed field tạo ngay trong bước retrieval.
- Sau khi có cột `gdp`, thao tác `sort + head` giống hệt Top-N.

SQL

```sql
SELECT
  country, continent, `year`,
  pop, gdpPercap,
  (pop * gdpPercap) AS gdp,
  lifeExp
FROM gapminder_simple
WHERE `year` = 2007
ORDER BY gdp DESC
LIMIT 10;
```

I.3. Quiz

Hình sau sẽ được sử dụng cho câu 1-3

order_id	customer_name	ship_date	sales	quantity	category
O001	Alice Nguyen	NULL	150	2	Furniture
O002	Binh Tran	2024-01-03	620	5	Technology
O003	Chau Le	NULL	180	1	Office Supplies
O004	Duy Pham	2024-01-05	980	3	Furniture
O005	Giang Vo	2024-01-06	90	8	Office Supplies
O006	Huy Ho	NULL	540	4	Technology
O007	Khanh Bui	2024-01-08	210	2	Furniture
O008	Linh Do	2024-01-09	1300	6	Technology

Câu 1: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `customer_name`, `ship_date` cho các dòng có `ship_date` bị thiếu dữ liệu và chỉ lấy **3 dòng đầu tiên**?

a)

```sql
SELECT order_id, customer_name, ship_date
FROM orders_q1
WHERE ship_date = NULL
LIMIT 3;
```

b)

```sql
SELECT order_id, customer_name, ship_date
FROM orders_q1
WHERE ship_date IS NULL
LIMIT 3;
```

c)

```sql
SELECT order_id, customer_name
FROM orders_q1
WHERE ship_date IS NULL
LIMIT 3;
```

d)

```sql
SELECT *
FROM orders_q1
WHERE ship_date IS NOT NULL
LIMIT 3;
```

Đáp án: B

Câu 2: Từ bảng trên, câu lệnh SQL nào lấy các cột `sales`, `quantity`, `category` cho các dòng có `sales` nằm trong khoảng từ **100 đến 200**, và sắp xếp theo `sales` giảm dần?

a)

```sql
SELECT sales, quantity, category
FROM orders_q1
WHERE sales BETWEEN 100 AND 200
ORDER BY sales DESC;
```

b)

```sql
SELECT sales, quantity, category
FROM orders_q1
WHERE sales > 100 AND sales < 200
ORDER BY sales ASC;
```

c)

```sql
SELECT sales, quantity
FROM orders_q1
WHERE sales BETWEEN 100 AND 200
ORDER BY sales DESC;
```

d)

```sql
SELECT sales, quantity, category
FROM orders_q1
WHERE sales IN (100, 200)
ORDER BY sales DESC;
```

Đáp án: A

Câu 3: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `customer_name`, `category`, `sales` cho các dòng thuộc **Furniture** hoặc **Technology** và có `sales >= 500`? Sắp xếp theo `quantity` giảm dần, nếu trùng thì theo `sales` giảm dần, và chỉ lấy **4 dòng đầu tiên**.

a)

```sql
SELECT order_id, customer_name, category, sales
FROM orders_q1
WHERE category IN ('Furniture', 'Technology')
  AND sales >= 500
ORDER BY quantity DESC, sales DESC
LIMIT 4;
```

b)

```sql
SELECT order_id, customer_name, category, sales
FROM orders_q1
WHERE category = 'Furniture' OR category = 'Technology'
  OR sales >= 500
ORDER BY quantity ASC, sales DESC
LIMIT 4;
```

c)

```sql
SELECT order_id, customer_name, category, sales
FROM orders_q1
WHERE category IN ('Furniture', 'Technology')
  AND sales > 500
ORDER BY sales DESC
LIMIT 4;
```

d)

```sql
SELECT order_id, customer_name, sales
FROM orders_q1
WHERE category IN ('Furniture', 'Technology')
  AND sales >= 500
ORDER BY quantity DESC, sales DESC
LIMIT 4;
```

Đáp án: A

Hình sau sẽ được dùng cho câu 4-6

order_id	city	state	postal_code	region	product_name
O101	San Jose	California	95112	West	Laptop Stand
O102	San Diego	California	NULL	West	Office Chair
O103	Seattle	Washington	98101	West	Desk Lamp
O104	San Mateo	California	94401	West	Standing Desk
O105	Boston	Massachusetts	02108	East	Monitor
O106	Sacramento	California	95814	West	Office Desk
O107	San Ramon	California	NULL	West	USB Hub
O108	Miami	Florida	33101	East	Desk Chair

Câu 4: Từ bảng trên, câu lệnh SQL nào lấy các cột `city`, `state`, `postal_code` cho các dòng mà `city` bắt đầu bằng **San**, và chỉ lấy **4 dòng đầu tiên**?

a)

```sql
SELECT city, state, postal_code
FROM orders_q2
WHERE city LIKE '%San'
LIMIT 4;
```

b)

```sql
SELECT city, state, postal_code
FROM orders_q2
WHERE city LIKE 'San%'
LIMIT 4;
```

c)

```sql
SELECT city, postal_code
FROM orders_q2
WHERE city LIKE 'San%'
LIMIT 4;
```

d)

```sql
SELECT city, state, postal_code
FROM orders_q2
WHERE city = 'San'
```

```
4 LIMIT 4;
```

Đáp án: B

Câu 5: Từ bảng trên, câu lệnh SQL nào lấy các cột `city`, `state`, `region` cho các dòng thỏa mãn:

- `region` là **West** hoặc **East**
- và `state` là **California**

Sắp xếp kết quả theo `city` tăng dần.

a)

```sql
SELECT city, state, region
FROM orders_q2
WHERE region IN ('West', 'East')
   OR state = 'California'
ORDER BY city ASC;
```

b)

```sql
SELECT city, state, region
FROM orders_q2
WHERE region IN ('West', 'East')
  AND state = 'California'
ORDER BY city ASC;
```

c)

```sql
SELECT city, state, region
FROM orders_q2
WHERE state IN ('West', 'East')
  AND region = 'California'
ORDER BY city ASC;
```

d)

```sql
SELECT city, state
FROM orders_q2
WHERE region IN ('West', 'East')
  AND state = 'California'
ORDER BY city ASC;
```

Đáp án: B

Câu 6: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `city` và một cột mới tên là `clean_zip`? Trong đó:

- nếu `postal_code` bị thiếu thì thay bằng `'N/A'`
- chỉ lấy các dòng mà `postal_code` bị thiếu **hoặc** `product_name` có chứa từ **Desk**

Sắp xếp theo `order_id` tăng dần.

a)

```sql
SELECT order_id, city, postal_code AS clean_zip
FROM orders_q2
WHERE postal_code IS NULL
  AND product_name LIKE '%Desk%'
ORDER BY order_id ASC;
```

b)

```sql
SELECT order_id,
       city,
       COALESCE(postal_code, 'N/A') AS clean_zip
FROM orders_q2
WHERE postal_code IS NULL
   OR product_name LIKE '%Desk%'
ORDER BY order_id ASC;
```

c)

```sql
SELECT order_id,
       city,
       COALESCE('N/A', postal_code) AS clean_zip
FROM orders_q2
WHERE postal_code = NULL
   OR product_name LIKE 'Desk'
ORDER BY order_id ASC;
```

d)

```sql
SELECT order_id,
       city,
       COALESCE(postal_code, 'N/A') AS clean_zip
FROM orders_q2
WHERE product_name LIKE '%Desk%'
ORDER BY city ASC;
```

Đáp án: B

hình sau dùng cho câu 7-10

order_id	customer_name	product_name	sales	discount	ship_mode	order_date
O201	Alice Nguyen	Office Desk	1200	0.10	Standard Class	2024-02-01
O202	Binh Tran	Office Chair	800	0.00	Second Class	2024-02-02
O203	An Le	Desk Lamp	300	0.20	First Class	2024-02-03
O204	Bao Pham	Gaming Chair	950	0.15	Standard Class	2024-02-04
O205	Chau Do	USB Hub	450	0.05	Same Day	2024-02-05
O206	Dung Vo	Writing Desk	700	0.25	Second Class	2024-02-06
O207	An Bui	Monitor Arm	800	0.10	First Class	2024-02-07
O208	Bich Ho	Study Chair	800	0.20	Standard Class	2024-02-08

Câu 7: Từ bảng trên, câu lệnh SQL nào lấy danh sách `ship_mode` không trùng lặp và sắp xếp tăng dần?

a)

```sql
SELECT ship_mode
FROM orders_q3
ORDER BY ship_mode ASC;
```

b)

```sql
SELECT DISTINCT ship_mode
FROM orders_q3
ORDER BY ship_mode ASC;
```

c)

```sql
SELECT UNIQUE ship_mode
FROM orders_q3
ORDER BY ship_mode ASC;
```

d)

```sql
SELECT DISTINCT ship_mode
FROM orders_q3
ORDER BY ship_mode DESC;
```

Đáp án: B

Câu 8: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `customer_name`, `sales` và tạo thêm cột mới tên là `net_sales` với công thức `sales * (1 - discount)`? Chỉ lấy các dòng có `sales >= 500` và `discount > 0`, rồi sắp xếp theo `net_sales` giảm dần.

a)

```sql
SELECT order_id,
       customer_name,
       sales,
       sales * discount AS net_sales
FROM orders_q3
WHERE sales >= 500
  AND discount > 0
ORDER BY net_sales DESC;
```

b)

```sql
SELECT order_id,
       customer_name,
       sales,
       sales * (1 - discount) AS net_sales
FROM orders_q3
WHERE sales >= 500
  OR discount > 0
ORDER BY net_sales DESC;
```

c)

```sql
SELECT order_id,
       customer_name,
       sales,
       sales * (1 - discount) AS net_sales
FROM orders_q3
WHERE sales >= 500
  AND discount > 0
ORDER BY net_sales DESC;
```

d)

```sql
SELECT order_id,
       customer_name,
       sales
FROM orders_q3
WHERE sales >= 500
  AND discount > 0
ORDER BY sales DESC;
```

Đáp án: C

Câu 9: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `product_name`, `sales`, `discount` cho **3 dòng tiếp theo** sau khi:

- sắp xếp toàn bộ bảng theo `sales` giảm dần
- nếu trùng `sales` thì theo `discount` tăng dần
- nếu vẫn trùng thì theo `order_id` tăng dần
- bỏ qua **2 dòng đầu tiên**

a)

```sql
SELECT order_id, product_name, sales, discount
FROM orders_q3
ORDER BY sales DESC, discount ASC, order_id ASC
LIMIT 3 OFFSET 2;
```

b)

```sql
SELECT order_id, product_name, sales, discount
FROM orders_q3
ORDER BY sales ASC, discount ASC, order_id ASC
LIMIT 3 OFFSET 2;
```

c)

```sql
SELECT order_id, product_name, sales, discount
FROM orders_q3
ORDER BY sales DESC, discount DESC, order_id ASC
LIMIT 2 OFFSET 3;
```

d)

```sql
SELECT order_id, product_name, sales, discount
FROM orders_q3
ORDER BY sales DESC
LIMIT 3 OFFSET 2;
```

Đáp án: A

Câu 10: Từ bảng trên, câu lệnh SQL nào lấy các cột `order_id`, `customer_name`, `product_name` cho các dòng thỏa mãn:

- `customer_name` bắt đầu bằng chữ **A** hoặc **B**

- và `product_name` có chứa **Desk** hoặc **Chair**

Sắp xếp theo `order_date` giảm dần.

a)

```sql
SELECT order_id, customer_name, product_name
FROM orders_q3
WHERE customer_name LIKE 'A%' OR customer_name LIKE 'B%'
  AND product_name LIKE '%Desk%' OR product_name LIKE '%Chair%'
ORDER BY order_date DESC;
```

b)

```sql
SELECT order_id, customer_name, product_name
FROM orders_q3
WHERE (customer_name LIKE 'A%' OR customer_name LIKE 'B%')
  AND (product_name LIKE '%Desk%' OR product_name LIKE '%Chair%')
ORDER BY order_date DESC;
```

c)

```sql
SELECT order_id, customer_name, product_name
FROM orders_q3
WHERE customer_name IN ('A%', 'B%')
  AND product_name IN ('%Desk%', '%Chair%')
ORDER BY order_date DESC;
```

d)

```sql
SELECT order_id, customer_name, product_name
FROM orders_q3
WHERE (customer_name LIKE 'A%' OR customer_name LIKE 'B%')
  AND (product_name LIKE '%Desk%' OR product_name LIKE '%Chair%')
ORDER BY order_date ASC;
```

Đáp án: B

II. Data Cleaning

II.1. Lý thuyết

Data Cleaning & Preparation

Data Cleaning & Preparation là quá trình chuyển dữ liệu thô thành dữ liệu sẵn sàng cho phân tích và mô hình hóa. Nội dung thường bao gồm:

- Nhận diện và xử lý **giá trị thiếu** (NULL/NaN/blank/sentinel)
- Chuẩn hóa **kiểu dữ liệu** (number, datetime, boolean, category)
- Chuẩn hóa **chuỗi và biến phân loại** (trim, chữ hoa/thường, mapping)
- Phát hiện và xử lý **trùng lặp** (trùng dòng, trùng khóa nghiệp vụ)
- Phát hiện **giá trị không hợp lệ** và **giá trị bất thường** (invalid/outlier)
- Kiểm tra kết quả sau làm sạch và tổng hợp báo cáo thay đổi

II.2. Case study: Air Quality (UCI)

Bộ dữ liệu Air Quality

Chúng ta sử dụng dữ liệu thực từ UCI (Air Quality), ghi theo **mỗi giờ**.S

- **Cột thời gian**: `Date` (DD/MM/YYYY), `Time` (HH.MM.SS).
- **Biến đo**: nồng độ khí (CO, NOx, NO2, Benzene, . . .) và phản hồi cảm biến (`PT08.*`), kèm nhiệt độ/độ ẩm.
- **Missing**: các giá trị thiếu được gắn bằng `-200`.

Các bạn có thể tải dataset ở đây: link

II.2.1. Chuẩn bị: Import và đọc dataset

Mục tiêu là import các thư viện cần thiết và đọc dataset `airquality_uci_simple.csv`. (Trong Google Colab, file thường được upload vào thư mục `/content`.)

Pandas: Import

```
import numpy as np
import pandas as pd
```

Pandas: Đọc dataset

```
DATA_PATH = "/content/airquality_uci_simple.csv"
df = pd.read_csv(DATA_PATH)

df.shape
df.head()
```

II.2.2. Bước 1: Profiling

Mục tiêu là **xem nhanh dữ liệu** và **đếm mức độ thiếu** ở các cột quan trọng. Với Air Quality, dữ liệu thiếu thường được mã hóa bằng **-200**.

CO(GT)	NO2(GT)	T
2.6	113	13.6
-200	92	-200
1.2	88	11.2

Pandas: Profiling nhanh

```
use_cols = ["CO(GT)", "NO2(GT)", "T", "RH"]

(df[use_cols] == -200).sum()
```

Giải thích code (Pandas)

- `use_cols`: chọn trước các cột quan trọng để thao tác gọn và nhất quán ở các bước sau.
- `df[use_cols] == -200`: tạo bảng **True/False** cho từng ô (ô nào bằng `-200`).
- `.sum()`: Pandas coi `True=1`, `False=0` ⇒ tổng theo cột chính là **đếm số lượng** `-200` theo từng cột.

SQL: Profiling

```sql
SELECT
  COUNT(*) n_rows,
  SUM(`CO(GT)`=-200)  miss_co,
  SUM(`NO2(GT)`=-200) miss_no2,
  SUM(`T`=-200)       miss_t,
  SUM(`RH`=-200)      miss_rh
FROM air_quality;
```

II.2.3. Bước 2: Tạo cột thời gian (timestamp)

Mục tiêu là tạo cột `ts` từ `Date` và `Time` để thao tác theo thời gian.

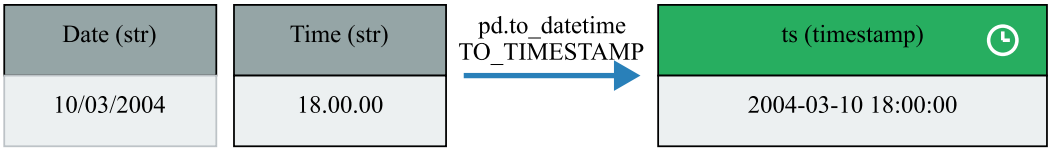

Pandas: Parse timestamp

```python
import pandas as pd

df["ts"] = pd.to_datetime(
    df["Date"].astype(str) + " " + df["Time"].astype(str),
    format="%d/%m/%Y %H.%M.%S",
    errors="coerce"
)

df[["Date", "Time", "ts"]].head()
```

Giải thích code (Pandas)

- Ghép `Date` và `Time` thành chuỗi `"dd/mm/YYYY HH.MM.SS"` để parse một lần.
- `format="%d/%m/%Y %H.%M.%S"`: chỉ rõ định dạng (lưu ý **giờ dùng dấu chấm**).
- `errors="coerce"`: parse lỗi thì trả về `NaT` thay vì báo lỗi, giúp bước sau lọc bỏ dễ dàng.

SQL: Parse timestamp (MySQL)

```sql
SELECT
  `Date`,`Time`,
  STR_TO_DATE(CONCAT(`Date`,' ',`Time`),'%d/%m/%Y %H.%i.%s') ts
FROM air_quality
ORDER BY ts;
```

II.2.4. Bước 3: Chuẩn hóa missing (-200 → NaN/NULL)

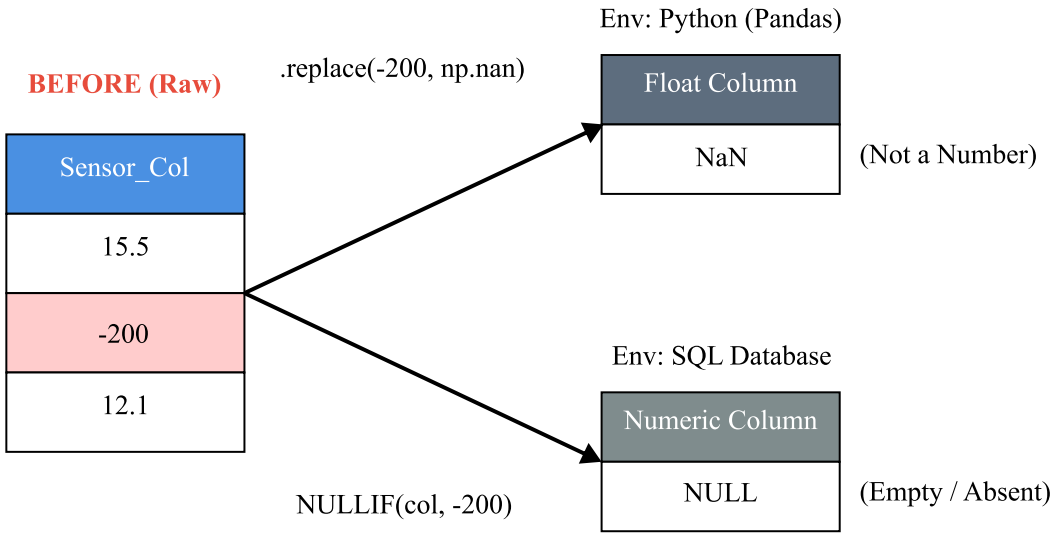

Mục tiêu là đưa missing về dạng chuẩn để dễ xử lý. Ở đây, ta thay **-200** bằng `NaN/NULL`.

Pandas: -200 -> NaN

```
df[use_cols] = df[use_cols].replace(-200, np.nan)
df[use_cols].isna().sum()
```

Giải thích code (Pandas)

- `replace(-200, np.nan)`: đổi sentinel `-200` sang `NaN` (missing chuẩn của Pandas).
- Sau bước này, các thao tác như `isna()`, `ffill()`, `fillna()` hoạt động đúng nghĩa với missing.
- `isna().sum()`: kiểm tra lại số missing theo từng cột sau khi chuẩn hoá.

SQL: -200 -> NULL

```
SELECT
  NULLIF(`CO(GT)`,-200)  co_gt,
  NULLIF(`NO2(GT)`,-200) no2_gt,
  NULLIF(`T`,-200)       temp_c,
  NULLIF(`RH`,-200)      rh
FROM air_quality;
```

II.2.5. Bước 4: Lọc dữ liệu cột ts

Mục tiêu là đảm bảo dữ liệu có thứ tự thời gian rõ ràng. Các dòng không parse được thời gian sẽ bị loại bỏ.

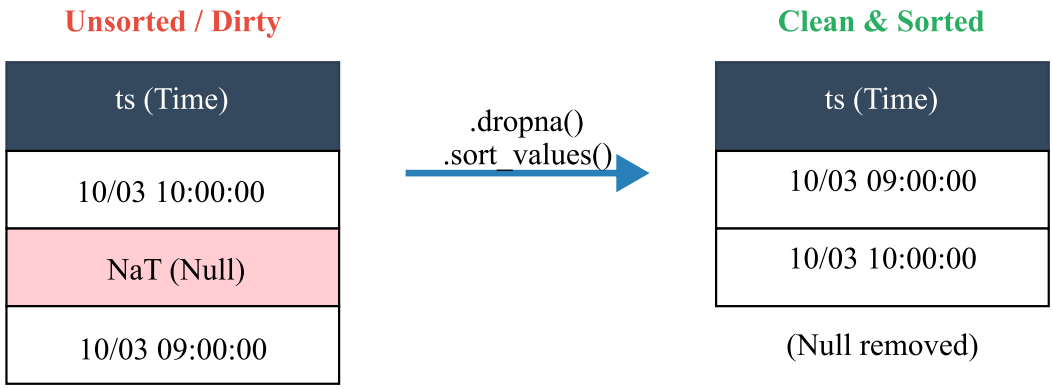

Pandas: Sort theo ts và bỏ ts lỗi

```
df = df.dropna(subset=["ts"]).sort_values("ts").reset_index(drop=True)
df[["ts"] + use_cols].head()
```

Giải thích code (Pandas)

- `dropna(subset=["ts"])`: bỏ các dòng có `ts` bị `NaT` (parse lỗi).
- `sort_values("ts")`: sắp xếp theo thời gian để đúng logic time series.
- `reset_index(drop=True)`: reset index để dữ liệu "sạch" và liên tục sau khi lọc/sort.
- `df[["ts"] + use_cols].head()`: kiểm tra nhanh vài dòng đầu sau khi chuẩn hoá thứ tự thời gian.

SQL: Clean + sort theo ts

```
DROP VIEW IF EXISTS air_quality_clean;
CREATE VIEW air_quality_clean AS
SELECT
  STR_TO_DATE(`Time`, '%Y-%m-%d %H:%i:%s') AS ts,
  NULLIF(`CO(GT)`,-200)  co_gt,
  NULLIF(`NO2(GT)`,-200) no2_gt,
  NULLIF(`T`,-200)       temp_c,
  NULLIF(`RH`,-200)      rh
FROM airquality_uci_simple
WHERE STR_TO_DATE(`Time`, '%Y-%m-%d %H:%i:%s') IS NOT NULL;

SELECT * FROM air_quality_clean ORDER BY ts;
```

II.2.6. Bước 5: Điền missing đơn giản

Mục tiêu là tạo phiên bản dữ liệu ít thiếu hơn để phục vụ phân tích. Trong Pandas, ta dùng **forward-fill**. Trong SQL, ta minh họa bằng **điền trung bình** để giữ câu lệnh đơn giản.

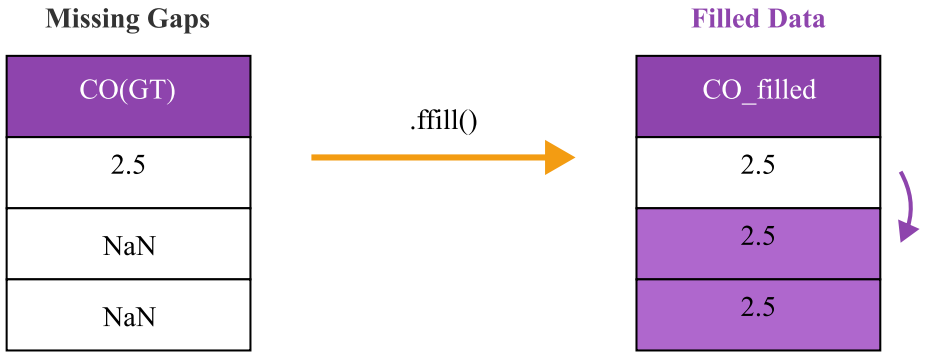

Pandas: Forward-fill

```python
for c in use_cols:
    df[c + "_filled"] = df[c].ffill()

df[["ts"] + [c + "_filled" for c in use_cols]].head()
```

Giải thích code (Pandas)

- Duyệt từng cột trong `use_cols` để impute đồng bộ.
- `ffill()` (forward-fill): điền `NaN` bằng **giá trị hợp lệ gần nhất trước đó** theo thứ tự thời gian.
- Tạo cột mới `*_filled` để **giữ lại cột gốc**, giúp so sánh trước/sau.
- `head()`: kiểm tra nhanh các cột sau khi điền missing.

SQL: Impute mean

```sql
DROP VIEW IF EXISTS air_quality_filled;
CREATE VIEW air_quality_filled AS
SELECT a.ts,
       COALESCE(a.co_gt,s.mu_co)    co_gt_filled,
       COALESCE(a.no2_gt,s.mu_no2)  no2_gt_filled,
       COALESCE(a.temp_c,s.mu_t)    temp_c_filled,
       COALESCE(a.rh,s.mu_rh)       rh_filled
FROM air_quality_clean a
CROSS JOIN (
  SELECT AVG(co_gt) mu_co, AVG(no2_gt) mu_no2, AVG(temp_c) mu_t, AVG(rh)
   mu_rh
  FROM air_quality_clean
) s;
SELECT * FROM air_quality_filled ORDER BY ts;
```

II.2.7. Bước 6: Xác định outlier

Mục tiêu là đánh dấu các giá trị bất thường để kiểm tra. Ở đây dùng quy tắc đơn giản: gắn cờ nếu `CO(GT)` vượt một ngưỡng cố định (ví dụ 5).

CO(GT)	is_outlier
2.1	0
15.5	1
4.8	0

if CO > 5.0:
then 1
else 0

Pandas: Flag outlier theo ngưỡng

```python
THRESH = 5.0  # ngưỡng minh họa

df["is_outlier_co"] = (df["CO(GT)_filled"] > THRESH).astype(int)
df[["ts", "CO(GT)_filled", "is_outlier_co"]].tail()
```

Giải thích code (Pandas)

- `THRESH`: ngưỡng minh hoạ để phát hiện outlier (ở đây chỉ để demo ý tưởng).
- `(df["CO(GT)_filled"] > THRESH)` tạo boolean `True/False` cho từng dòng.
- `astype(int)` chuyển boolean thành `1/0` để tiện đếm, lọc và báo cáo.
- `tail()`: xem vài dòng cuối để kiểm tra cờ outlier có hoạt động đúng.

SQL: Flag outlier theo ngưỡng

```sql
SELECT
  *,
  (co_gt_filled > 5.0) AS is_outlier_co
FROM air_quality_filled
ORDER BY ts;
```

Các bạn có thể tham khảo 2 đoạn code sẵn ở đây:

- Pandas code: link
- Sql script: link

II.3. Quiz

Hình sau sử dụng cho câu 1-3

order_id	customer_id	age	email	status
ORD_001	C001	25	a@x.com	active
ORD_002	C002	NULL	b@x.com	active
ORD_003	C003	-3	c@x.com	active
ORD_004	C004	30		archived
ORD_005	C005	200	e@x.com	unknown

Câu 1. Dựa trên bảng dữ liệu và các quy ước dưới đây, phát biểu nào sau đây **đúng nhất** về việc phân biệt giữa **missing values** và **invalid values**?

Quy ước

- age hợp lệ khi nằm trong khoảng từ 0 đến 120
- status hợp lệ nếu thuộc {active, archived}
- email rỗng hoặc age=NULL được xem là missing

a) ORD_002 và ORD_004 đều chứa invalid values

b) ORD_003 và ORD_005 chứa invalid values theo rule

c) ORD_001 và ORD_002 cần xoá khỏi dataset

d) Chỉ ORD_005 có vấn đề

Đáp án: B

Phân biệt missing và invalid

ORD_003 có `age=-3` nên là invalid. ORD_005 có `age=200` và `status=unknown` nên cũng là invalid. Trong khi đó, ORD_002 chỉ thiếu age và ORD_004 chỉ thiếu email, nên đây là missing. Vì vậy đáp án đúng là B.

Câu 2. Dựa trên quy ước cleaning dành cho cột **age**, phương án nào sau đây là **hợp lý nhất** để xử lý các giá trị thiếu hoặc không hợp lệ?

Quy ước cleaning

- age hợp lệ giữ nguyên
- age thiếu hoặc invalid đưa về NULL
- không xoá cả dòng chỉ vì lỗi age

a) Thay mọi giá trị invalid thành 0

b) Giữ NULL, các giá trị ngoài miền đưa về NULL

c) Xoá toàn bộ các dòng có lỗi age

d) Chuyển age sang kiểu text

Đáp án: B

Chọn rule cleaning phù hợp

Theo đề bài, age hợp lệ thì giữ nguyên, còn age thiếu hoặc invalid thì đưa về NULL. Vì vậy phương án B là đúng. Các phương án còn lại làm sai nghĩa dữ liệu hoặc xử lý quá mạnh tay.

Câu 3. Dựa trên cùng bảng dữ liệu, giả sử bảng trong hình được lưu trong một bảng SQL có tên `raw_table`. Đoạn mã SQL nào sau đây tạo cột **age_clean đúng nhất**, biết rằng age hợp lệ thì giữ nguyên, còn age thiếu hoặc ngoài miền hợp lệ thì đưa về NULL?

a)

```sql
SELECT order_id,
       CASE
           WHEN age < 0 OR age > 120 THEN 0
           ELSE age
       END AS age_clean
FROM raw_table;
```

b)

```sql
SELECT order_id,
       CASE
           WHEN age IS NULL THEN 0
           WHEN age < 0 OR age > 120 THEN NULL
           ELSE age
       END AS age_clean
FROM raw_table;
```

c)

```sql
SELECT order_id,
       CASE
           WHEN age < 0 OR age > 120 THEN NULL
           ELSE age
       END AS age_clean
FROM raw_table;
```

d)

```sql
SELECT order_id,
       CASE
           WHEN age IS NULL OR age < 0 OR age > 120 THEN age
           ELSE NULL
       END AS age_clean
FROM raw_table;
```

Đáp án: C

Đọc CASE WHEN theo đúng rule

Phương án C đúng vì age invalid được đưa về NULL, age hợp lệ giữ nguyên, và age đang NULL vẫn tiếp tục là NULL. Các phương án còn lại đều sai vì đổi invalid hoặc NULL

thành 0, hoặc đảo ngược logic.

Hình sau sử dụng cho câu 4-5

transaction_id	category	payment_method
TXN_101	electronics	credit card
TXN_102	ELECTRONICS	Credit Card
TXN_103	Electronics	CREDIT CARD
TXN_104	home appliances	e-wallet

Câu 4. Giả sử ta cần thống kê số lượng bản ghi theo từng **category** để phục vụ báo cáo. Nếu thực hiện `GROUP BY category` trực tiếp trên bảng dữ liệu thô mà chưa chuẩn hoá text, hậu quả nào sau đây có khả năng xảy ra lớn nhất?

a) SQL tự động gộp các biến thể về cùng một nhóm nên kết quả vẫn đúng

b) Một category có thể bị tách thành nhiều nhóm do khác cách viết

c) Các dòng chứa category không chuẩn sẽ tự động bị loại khỏi kết quả

d) Chỉ các giá trị NULL mới có thể làm sai kết quả GROUP BY

Đáp án: B

GROUP BY trước khi cleaning

Các giá trị như `Electronics`, `electronics`, hay `ELECTRONICS` có thể cùng nghĩa nhưng vẫn là các chuỗi khác nhau. Nếu `GROUP BY` trực tiếp, chúng sẽ bị tách thành nhiều nhóm. Vì vậy đáp án đúng là B.

Câu 5. Dựa trên bảng dữ liệu trên, giả sử bảng trong hình được lưu trong một bảng SQL có tên `raw_table`. Đoạn mã SQL nào sau đây chuẩn hoá cột **payment_method** đúng nhất, biết rằng cần **trim khoảng trắng, chuẩn hoá hoa/thường, gom các biến thể cùng nghĩa về cùng một nhãn chuẩn, và chuẩn hoá cả các giá trị còn lại**?

a)

```sql
SELECT UPPER(payment_method) AS payment_method_clean
FROM raw_table;
```

b)

```sql
SELECT TRIM(payment_method) AS payment_method_clean
FROM raw_table;
```

c)

```sql
SELECT CASE
           WHEN LOWER(TRIM(payment_method)) = 'credit card'
               THEN 'Credit Card'
           WHEN LOWER(TRIM(payment_method)) = 'e-wallet'
               THEN 'Digital Wallet'
           ELSE payment_method
       END AS payment_method_clean
FROM raw_table;
```

d)

```sql
SELECT CASE
           WHEN LOWER(TRIM(payment_method)) IN ('credit card', '
    creditcard')
               THEN 'Credit Card'
           WHEN LOWER(TRIM(payment_method)) IN
                ('e-wallet', 'ewallet', 'digital wallet')
               THEN 'Digital Wallet'
           ELSE INITCAP(TRIM(payment_method))
       END AS payment_method_clean
FROM raw_table;
```

Đáp án: D

Chuẩn hoá payment_method

Đáp án đúng phải vừa `TRIM`, vừa chuẩn hoá hoa/thường, vừa map nhiều biến thể về cùng một nhãn chuẩn. Phương án D làm đủ các bước này, còn các phương án khác chỉ xử lý một phần.

Hình sau sử dụng cho câu 6-8

transaction_id	price_per_unit	transaction_date	discount_applied
TXN_201	10.50	2025-01-05	True
TXN_202	20.00	05/01/2025	yes
TXN_203	1,200.75	2025/01/05 14:30	1
TXN_204	error	2025/13/40	maybe

Câu 6. Xét mục tiêu chuẩn hoá các cột **price_per_unit**, **transaction_date**, và **discount_applied** về đúng kiểu dữ liệu và giá trị chuẩn. Nhóm dòng nào sau đây cần được preprocessing trước khi có thể chuyển kiểu hoặc chuẩn hoá trực tiếp?

a) Chỉ TXN_204 cần cleaning

b) TXN_202, TXN_203, và TXN_204 đều cần preprocessing

c) Chỉ TXN_202 cần cleaning

d) Tất cả các dòng đều đã đủ sạch để xử lý trực tiếp

Đáp án: B

Preprocessing trước khi cast

TXN_202, TXN_203, và TXN_204 đều chứa ít nhất một vấn đề như khoảng trắng thừa, dấu phẩy trong số, định dạng ngày chưa đồng nhất, hoặc giá trị không thuộc tập cho phép. Vì vậy cả ba dòng này đều cần preprocessing trước, nên đáp án đúng là B.

Câu 7. Dựa trên cùng bảng dữ liệu, giả sử bảng trong hình được lưu trong một bảng SQL có tên `raw_table` và cột `price_per_unit` hiện đang được lưu dưới dạng chuỗi. Đoạn mã SQL nào sau đây tạo cột **price_per_unit_clean** đúng nhất, biết rằng giá trị `error` phải được đưa về NULL và các giá trị có dấu phẩy cần được làm sạch trước khi chuyển kiểu số?

a)

```sql
SELECT CAST(price_per_unit AS DECIMAL(10,2)) AS price_per_unit_clean
FROM raw_table;
```

b)

```sql
SELECT CASE
           WHEN LOWER(TRIM(price_per_unit)) = 'error' THEN NULL
           ELSE CAST(REPLACE(TRIM(price_per_unit), ',', '') AS
    DECIMAL(10,2))
       END AS price_per_unit_clean
FROM raw_table;
```

c)

```sql
SELECT CASE
           WHEN price_per_unit IS NULL THEN 0
           ELSE CAST(price_per_unit AS DECIMAL(10,2))
       END AS price_per_unit_clean
FROM raw_table;
```

d)

```sql
SELECT CASE
           WHEN LOWER(TRIM(price_per_unit)) = 'error' THEN 0
           ELSE CAST(TRIM(price_per_unit) AS DECIMAL(10,2))
       END AS price_per_unit_clean
FROM raw_table;
```

Đáp án: B

Làm sạch numeric trước khi CAST

Phương án B đúng vì xử lý đủ ba bước: bỏ khoảng trắng, xoá dấu phẩy, và đưa `error` về NULL trước khi CAST. Các phương án khác hoặc ép kiểu quá sớm, hoặc đổi lỗi thành 0 nên sai về logic.

Câu 8. Xét cùng yêu cầu làm sạch cột **price_per_unit**, đoạn mã **pandas** nào sau đây là đúng nhất để loại bỏ khoảng trắng, xoá dấu phẩy, chuyển `error` thành missing value, rồi chuyển kết quả sang kiểu số?

a)

```
df["price_per_unit_clean"] = df["price_per_unit"].astype(float)
```

b)

```
df["price_per_unit_clean"] = (
    df["price_per_unit"]
    .str.strip()
    .str.replace(",", "", regex=False)
    .replace("error", "0")
    .astype(float)
)
```

c)

```
df["price_per_unit_clean"] = (
    df["price_per_unit"]
    .str.strip()
    .str.replace(",", "", regex=False)
    .replace("error", pd.NA)
    .pipe(pd.to_numeric, errors="coerce")
)
```

d)

```
df["price_per_unit_clean"] = (
    df["price_per_unit"]
    .fillna(0)
    .astype(str)
)
```

Đáp án: C

Biểu diễn cùng rule bằng pandas

Phương án C đúng vì thực hiện đúng pipeline: `strip`, xoá dấu phẩy, đổi `error` thành missing, rồi chuyển sang số an toàn bằng `to_numeric(..., errors="coerce")`. Các phương án còn lại hoặc ép kiểu trực tiếp, hoặc làm sai nghĩa dữ liệu.

Hình sau sử dụng cho câu 9-10

transaction_id	customer_id	item	transaction_date
TXN_301	C010	Item_A	2025-01-05
TXN_302	C011	Item_B	2025-01-06
TXN_302	C011	Item_B	2025-01-06
TXN_303	C011	Item_B	2025-01-06

Câu 9. Nếu mục tiêu là lấy ra **toàn bộ các dòng exact duplicate**, bao gồm cả dòng xuất hiện đầu tiên trong mỗi nhóm trùng lặp, thì đoạn mã **pandas** nào sau đây là phù hợp nhất?

a)

```
df.drop_duplicates()
```

b)

```
df[df.duplicated()]
```

c)

```
df[df.duplicated(keep=False)]
```

d)

```
df[df["transaction_id"].duplicated()]
```

Đáp án: C

Lấy toàn bộ duplicate rows

`duplicated(keep=False)` sẽ đánh dấu tất cả các dòng trong nhóm duplicate, kể cả dòng đầu tiên. Vì vậy phương án C là đúng. Các phương án khác hoặc dùng để xoá duplicate, hoặc chỉ lấy một phần các dòng trùng.

Câu 10. Nếu mục tiêu là loại bỏ các **exact duplicate rows** và chỉ giữ lại một bản ghi đại diện cho mỗi nhóm trùng hoàn toàn, thì đoạn mã **pandas** nào sau đây là đúng nhất?

a)

```
df_clean = df.drop_duplicates()
```

b)

```
df_clean = df.drop_duplicates(
    subset=["customer_id", "item", "transaction_date"]
)
```

c)

```
df_clean = df.sort_values("transaction_date")
```

d)

```
df_clean = df[df["transaction_id"].notna()]
```

Đáp án: A

Loại exact duplicate đúng grain

Vì đề yêu cầu loại **exact duplicate rows**, ta cần so sánh trên toàn bộ dòng. `drop_duplicates()` mặc định làm đúng điều đó, nên A là đáp án đúng. Dùng `subset` ở phương án B có thể xoá nhầm các bản ghi khác nhau nhưng trùng ở vài cột.

Link data và script đáp án

III. Data Aggregation

III.1. Lý thuyết

Data Aggregation & Calculation

Data Aggregation là gom nhóm dữ liệu theo một hoặc nhiều khóa và tính các thống kê tóm tắt cho từng nhóm. **Calculation** là tạo biến dẫn xuất (computed field) để phục vụ phân tích và tổng hợp.

Đặc điểm chính:

- Kết quả thường **giảm số dòng**: mỗi nhóm tương ứng một dòng tổng hợp.
- Thống kê phổ biến: count, sum, average, min, max.
- **WHERE** lọc trước khi gom nhóm, **HAVING** lọc sau khi đã tổng hợp.
- Có thể tổng hợp trực tiếp trên biến mới (vd. $gdp = pop \times gdpPercap$).

III.2. Case study

Bộ dữ liệu Gapminder (Simple)

`gapminder_simple.csv` (1000 mẫu) là bản rút gọn từ Gapminder, mô tả chỉ số phát triển theo **quốc gia** và **năm**.

- **Khóa & phân nhóm:** `country`, `year`, `continent`.
- **Biến số:** `lifeExp`, `pop`, `gdpPercap`; tạo $gdp = pop \times gdpPercap$ để tính GDP tổng.

Các bước thực hành (keywords): computed field → overall summary → groupby(continent) → groupby(year) → filter+TopN(2007) → groupby(continent,year).
Dataset (CSV): link

III.2.1. Bước 0 (Pandas): Import và đọc dataset

Pandas

```
import pandas as pd

DATA_PATH = "/content/gapminder_simple.csv"
df = pd.read_csv(DATA_PATH)
```

Giải thích

Chỉ đọc dữ liệu vào DataFrame để chuẩn bị cho các bước tổng hợp. (Không preview dữ liệu.)

III.2.2. Bước 1: Tạo computed field gdp

Mục tiêu: tạo biến mới `gdp = pop * gdpPercap` để dùng trong các phép `SUM` theo nhóm.

Pandas

```
df["gdp"] = df["pop"] * df["gdpPercap"]
```

SQL

```
SELECT pop * gdpPercap AS gdp
FROM gapminder_simple;
```

Giải thích

Computed field giúp minh hoạ đúng tinh thần "calculation rồi mới aggregation".

III.2.3. Bước 2: Thống kê tổng quan (overall summary)

Mục tiêu: tóm tắt nhanh các cột số quan trọng bằng `COUNT/AVG/MIN/MAX`.

Pandas

```
overall = df[["lifeExp", "gdpPercap", "pop"]].agg(["count", "mean", "min"
    , "max"])
overall
```

SQL

```
SELECT
  COUNT(*)       AS n,
  AVG(lifeExp)   AS avg_lifeExp,
  AVG(gdpPercap) AS avg_gdpPercap
FROM gapminder_simple;
```

Giải thích

Bước này không nhìn từng dòng mà nhìn **thống kê tổng quát** để hiểu thang đo dữ liệu.

III.2.4. Bước 3: Tổng hợp theo châu lục (continent)

Mục tiêu: báo cáo theo `continent`: số quốc gia, dân số tổng, tuổi thọ trung bình.

Pandas

```python
by_continent = (
    df.groupby("continent", as_index=False)
      .agg(
          n_countries=("country", "nunique"),
          sum_pop=("pop", "sum"),
          avg_lifeExp=("lifeExp", "mean")
      )
      .sort_values("sum_pop", ascending=False)
)
by_continent
```

SQL

```sql
SELECT
  continent,
  COUNT(DISTINCT country) AS n_countries,
  SUM(pop)                AS sum_pop,
  AVG(lifeExp)            AS avg_lifeExp
FROM gapminder_simple
GROUP BY continent
ORDER BY sum_pop DESC;
```

Giải thích

`GROUP BY continent` (SQL) tương đương `groupby("continent")` (Pandas): mỗi châu lục ra 1 dòng tổng hợp.

III.2.5. Bước 4: Xu hướng theo năm (year)

Mục tiêu: xem xu hướng theo thời gian với `AVG(lifeExp)` và `AVG(gdpPercap)`.

Pandas

```python
by_year = (
    df.groupby("year", as_index=False)
      .agg(
          avg_lifeExp=("lifeExp", "mean"),
          avg_gdpPercap=("gdpPercap", "mean")
      )
      .sort_values("year")
)
by_year
```

SQL

```sql
SELECT
  year,
  AVG(lifeExp)   AS avg_lifeExp,
  AVG(gdpPercap) AS avg_gdpPercap
FROM gapminder_simple
GROUP BY year
ORDER BY year;
```

Giải thích

Aggregation theo `year` tạo báo cáo dạng **time trend**.

III.2.6. Bước 5 (đơn giản): Top-N châu lục theo GDP tổng năm 2007

Mục tiêu: lọc `year=2007`, tính `sum_gdp` theo châu lục, lấy top 5.

Pandas

```python
top5_cont_2007 = (
    df[df["year"] == 2007]
      .groupby("continent", as_index=False)
      .agg(sum_gdp=("gdp", "sum"))
      .sort_values("sum_gdp", ascending=False)
      .head(5)
)
top5_cont_2007
```

SQL

```sql
SELECT
  continent,
  SUM(pop * gdpPercap) AS sum_gdp
FROM gapminder_simple
WHERE year = 2007
GROUP BY continent
ORDER BY sum_gdp DESC
LIMIT 5;
```

Giải thích

Kết hợp **filter + groupby + sum + top-N**. SQL tương ứng: `WHERE + GROUP BY + ORDER BY + LIMIT`.

III.2.7. Bước 6: GDP tổng theo châu lục và năm (`continent, year`)

Mục tiêu: tạo bảng 2 chiều theo `continent, year` để so sánh theo thời gian trong từng châu lục.

Pandas

```python
gdp_by_cont_year = (
    df.groupby(["continent", "year"], as_index=False)
      .agg(sum_gdp=("gdp", "sum"))
      .sort_values(["year", "sum_gdp"], ascending=[True, False])
)
gdp_by_cont_year
```

SQL

```sql
SELECT
  continent, year,
  SUM(pop * gdpPercap) AS sum_gdp
FROM gapminder_simple
GROUP BY continent, year
ORDER BY year, sum_gdp DESC;
```

Giải thích

`GROUP BY continent, year` giúp so sánh **giữa các châu lục theo từng năm**.

III.3. Quiz

Hình sau sử dụng cho câu 1-3

Bảng: agg_q1

order_id	category	sales	quantity	ship_date
A001	Furniture	300	2	2024-03-01
A002	Technology	1200	1	2024-03-02
A003	Office Supplies	150	5	NULL
A004	Technology	800	2	2024-03-04
A005	Furniture	450	3	NULL
A006	Office Supplies	200	4	2024-03-06
A007	Technology	950	1	2024-03-07
A008	Furniture	600	2	NULL

Câu 1: Từ bảng trên, câu lệnh SQL nào trả về **tổng số đơn hàng** trong bảng?

a)

```sql
SELECT COUNT(ship_date)
FROM agg_q1;
```

b)

```sql
SELECT COUNT(*)
FROM agg_q1;
```

c)

```sql
SELECT SUM(order_id)
FROM agg_q1;
```

d)

```sql
SELECT COUNT(category, sales)
FROM agg_q1;
```

Đáp án: B

Đề bài yêu cầu đếm **tổng số đơn hàng**, tức là đếm toàn bộ số dòng trong bảng. Khi cần đếm tất cả bản ghi, ta dùng `COUNT(*)`.
Vì vậy, phương án B là đúng. Phương án A chỉ đếm các dòng có `ship_date` khác `NULL`, còn C và D không đúng với yêu cầu.

Câu 2: Từ bảng trên, câu lệnh SQL nào trả về **số đơn hàng đã có ship_date**?

a)

```sql
SELECT COUNT(*)
FROM agg_q1
WHERE ship_date IS NULL;
```

b)

```sql
SELECT SUM(ship_date)
FROM agg_q1;
```

c)

```sql
SELECT COUNT(ship_date)
FROM agg_q1
WHERE ship_date IS NULL;
```

d)

```sql
SELECT COUNT(ship_date)
FROM agg_q1;
```

Đáp án: D

Đề bài hỏi số đơn hàng **đã có** `ship_date`, nên cần đếm các giá trị khác `NULL` của cột này. Khi đó dùng `COUNT(ship_date)`.
Vì vậy, phương án D là đúng. Phương án A đếm các dòng chưa có ngày giao, còn B và C không phù hợp.

Câu 3: Từ bảng trên, câu lệnh SQL nào tính **tổng doanh thu** của các đơn hàng thuộc **Technology** và có `sales >= 800`?

a)

```sql
SELECT COUNT(sales)
FROM agg_q1
WHERE category = 'Technology'
  AND sales >= 800;
```

b)

```sql
SELECT SUM(quantity)
FROM agg_q1
WHERE category = 'Technology'
  AND sales >= 800;
```

c)

```sql
SELECT SUM(sales)
FROM agg_q1
WHERE category = 'Technology'
  AND sales >= 800;
```

d)

```sql
SELECT SUM(sales)
FROM agg_q1
WHERE category = 'Technology'
  AND sales > 800;
```

Đáp án: C

Cần lọc các dòng thuộc `Technology` và có `sales >= 800`, sau đó tính **tổng doanh thu** bằng `SUM(sales)`.
Vì vậy, phương án C là đúng. A đếm số dòng, B cộng nhầm cột, còn D dùng `> 800` nên loại mất trường hợp `sales = 800`.

Hình sau sử dụng cho câu 4-6

Bảng: agg_q2

order_id	region	sales	profit	discount
B001	East	500	80	0.10
B002	West	900	120	0.00
B003	East	700	-50	0.20
B004	South	400	60	0.05
B005	West	1500	300	0.15
B006	Central	650	40	0.00
B007	East	1100	200	0.10
B008	West	300	-20	0.30

Câu 4: Từ bảng trên, câu lệnh SQL nào tính **giá trị đơn hàng trung bình** của khu vực **West**?

a)

```sql
SELECT AVG(sales)
FROM agg_q2
WHERE region = 'West';
```

b)

```sql
SELECT SUM(sales)
FROM agg_q2
WHERE region = 'West';
```

c)

```sql
SELECT AVG(profit)
FROM agg_q2
WHERE region = 'West';
```

d)

```sql
SELECT AVG(sales)
FROM agg_q2;
```

Đáp án: A

Đề bài yêu cầu tính **giá trị đơn hàng trung bình** của khu vực West, nên cần dùng `AVG(sales)` và lọc bằng `WHERE region = 'West'`.
Vì vậy, phương án A là đúng. Các đáp án còn lại sai do dùng sai phép tính, sai cột, hoặc không lọc đúng khu vực.

Câu 5: Từ bảng trên, câu lệnh SQL nào tìm **giá trị sales lớn nhất** trong các dòng có `discount > 0`?

a)

```sql
SELECT MIN(sales)
FROM agg_q2
WHERE discount > 0;
```

b)

```sql
SELECT MAX(sales)
FROM agg_q2
WHERE discount > 0;
```

c)

```sql
SELECT MAX(discount)
FROM agg_q2
WHERE sales > 0;
```

d)

```sql
SELECT MAX(sales)
FROM agg_q2
WHERE discount = 0;
```

Đáp án: B

Cần tìm giá trị **sales lớn nhất** trong các dòng có `discount > 0`. Vì vậy, ta lọc trước bằng `WHERE` rồi dùng `MAX(sales)`.
Do đó, phương án B là đúng. Các phương án còn lại sai do dùng sai hàm, sai cột, hoặc lọc ngược điều kiện.

Câu 6: Từ bảng trên, câu lệnh SQL nào tìm **profit nhỏ nhất** trong các khu vực **East** hoặc **West**?

a)

```sql
SELECT MAX(profit)
FROM agg_q2
WHERE region IN ('East', 'West');
```

b)

```sql
SELECT MIN(sales)
FROM agg_q2
WHERE region IN ('East', 'West');
```

c)

```sql
SELECT MIN(profit)
FROM agg_q2
WHERE region = 'East'
  AND region = 'West';
```

d)

```sql
SELECT MIN(profit)
FROM agg_q2
WHERE region IN ('East', 'West');
```

Đáp án: D

Đề bài hỏi **profit nhỏ nhất** trong East hoặc West, nên cần lọc hai khu vực này rồi dùng `MIN(profit)`. Cách viết gọn là `region IN ('East', 'West')`.
Vì vậy, phương án D là đúng. A sai hàm, B sai cột, còn C dùng điều kiện không hợp lý.

Hình sau sử dụng cho câu 7-10

Bảng: agg_q3

order_id	category	region	segment	sales
C001	Furniture	East	Consumer	500
C002	Furniture	West	Corporate	700
C003	Technology	East	Consumer	1200
C004	Technology	West	Home Office	900
C005	Office Supplies	East	Consumer	200
C006	Office Supplies	West	Corporate	300
C007	Furniture	East	Home Office	650
C008	Technology	East	Corporate	1500
C009	Office Supplies	South	Consumer	400
C010	Furniture	West	Consumer	550

Câu 7: Từ bảng trên, câu lệnh SQL nào tính **số đơn hàng theo từng category**?

a)

```sql
SELECT category, SUM(*)
FROM agg_q3
GROUP BY category;
```

b)

```sql
SELECT COUNT(*)
FROM agg_q3
GROUP BY category;
```

c)

```sql
SELECT category, COUNT(*)
FROM agg_q3
GROUP BY category;
```

d)

```sql
SELECT category, COUNT(*)
FROM agg_q3;
```

Đáp án: C

Cụm từ "theo từng category" cho biết đây là bài toán **gom nhóm**. Ta cần dùng `GROUP BY category` và đếm số dòng mỗi nhóm bằng `COUNT(*)`.
Vì vậy, phương án C là đúng. Các đáp án còn lại sai do thiếu `GROUP BY`, sai cú pháp, hoặc không trả về đúng cấu trúc kết quả.

Câu 8: Từ bảng trên, câu lệnh SQL nào tính **tổng doanh thu theo từng region** và sắp xếp theo tổng doanh thu giảm dần?

a)

```sql
SELECT region, SUM(sales) AS total_sales
FROM agg_q3
GROUP BY region
ORDER BY total_sales DESC;
```

b)

```sql
SELECT region, AVG(sales) AS total_sales
FROM agg_q3
GROUP BY region
ORDER BY total_sales DESC;
```

c)

```sql
SELECT region, SUM(sales)
FROM agg_q3
GROUP BY category
ORDER BY SUM(sales) DESC;
```

d)

```sql
SELECT region, SUM(sales) AS total_sales
FROM agg_q3
ORDER BY total_sales DESC;
```

Đáp án: A

Câu này yêu cầu **tổng doanh thu theo từng region** và sắp xếp giảm dần. Vì vậy cần `SUM(sales)`, `GROUP BY region` và `ORDER BY ... DESC`.
Do đó, phương án A là đúng. Các đáp án khác sai do dùng sai hàm hoặc nhóm sai cột.

Câu 9: Từ bảng trên, câu lệnh SQL nào tính **giá trị đơn hàng trung bình theo từng segment** và chỉ giữ các nhóm có **AVG(sales) > 600**?

a)

```sql
SELECT segment, SUM(sales) AS avg_sales
FROM agg_q3
GROUP BY segment
HAVING AVG(sales) > 600;
```

b)

```sql
SELECT segment, AVG(sales) AS avg_sales
FROM agg_q3
GROUP BY segment
HAVING AVG(sales) > 600;
```

c)

```sql
SELECT AVG(sales) AS avg_sales
FROM agg_q3
GROUP BY segment
HAVING AVG(sales) > 600;
```

d)

```sql
SELECT segment, AVG(sales) AS avg_sales
FROM agg_q3
WHERE AVG(sales) > 600
GROUP BY segment;
```

Đáp án: B

Đề bài yêu cầu tính trung bình theo từng `segment` và chỉ giữ các nhóm có `AVG(sales) > 600`. Vì điều kiện nằm trên kết quả tổng hợp, ta phải dùng `HAVING`, không dùng `WHERE`. Vì vậy, phương án B là đúng. Các phương án còn lại sai do sai hàm, thiếu cột nhóm, hoặc dùng `WHERE` không đúng chỗ.

Câu 10: Từ bảng trên, câu lệnh SQL nào tìm các **category có tổng doanh thu lớn hơn 1500**?

a)

```sql
SELECT category, SUM(sales) AS total_sales
FROM agg_q3
WHERE SUM(sales) > 1500
GROUP BY category;
```

b)

```sql
SELECT category, COUNT(sales) AS total_sales
FROM agg_q3
GROUP BY category
HAVING COUNT(sales) > 1500;
```

c)

```sql
SELECT category, SUM(sales) AS total_sales
FROM agg_q3
GROUP BY region
HAVING SUM(sales) > 1500;
```

d)

```sql
SELECT category, SUM(sales) AS total_sales
FROM agg_q3
GROUP BY category
HAVING SUM(sales) > 1500;
```

Đáp án: D

Cần tìm các `category` có **tổng doanh thu** lớn hơn 1500. Vì vậy, ta nhóm theo `category`, tính `SUM(sales)` và lọc nhóm bằng `HAVING`.
Do đó, phương án D là đúng. Các phương án còn lại sai do dùng `WHERE` với hàm tổng hợp, tính sai đại lượng, hoặc nhóm sai cột.

Link data và script đáp án

IV. Window Functions

IV.1. Lý thuyết

Window Function là gì?

Trong xử lý dữ liệu, window function là một kỹ thuật tạo đặc trưng bằng cách tính toán trên một cửa sổ các dòng liên quan đến dòng hiện tại, nhưng không làm mất từng dòng dữ liệu.
Điểm khác với phép gom nhóm:

- Gom nhóm (group aggregation): thu gọn dữ liệu, số dòng giảm (ví dụ: trung bình theo nhóm).
- Window (analytic): giữ nguyên số dòng, nhưng tạo thêm cột kết quả chạy theo nhóm và theo thứ tự (ví dụ: giá trị trước đó, trung bình trượt, thứ hạng).

Vì giữ nguyên từng dòng, window functions đặc biệt hữu ích cho dữ liệu theo thời gian và dữ liệu cần so sánh giữa các dòng liền kề.

IV.2. Case study: Stocks (Vega Datasets)

Bộ dữ liệu Stocks

Dataset Stocks có cấu trúc gọn nên phù hợp để minh hoạ window functions.

- Cột nhóm: `symbol`
- Cột thời gian: `date`
- Giá trị số: `price`

Mục tiêu: minh hoạ `row number`, `lag/delta`, `moving average`, `running sum`, và `top-k theo năm` bằng cả Pandas và SQL.

Các bạn có thể tải dataset ở đây: link

IV.2.1. Bước 1: Row number theo symbol

Mục tiêu là đánh số thứ tự theo thời gian trong mỗi `symbol`.

symbol	date ▾	row_num
AAPL	2023-01-01	1
AAPL	2023-01-02	2
AAPL	2023-01-03	3

Partition: AAPL

Partition: GOOGL

GOOGL	2023-01-01	1
GOOGL	2023-01-03	2

Pandas

```
dfw = df.sort_values(["symbol", "date"]).copy()
dfw["row_num"] = dfw.groupby("symbol").cumcount() + 1
```

Giải thích (Pandas)

- `sort_values(["symbol","date"])`: sắp xếp để trong mỗi `symbol` dữ liệu đi đúng theo thời gian.
- `groupby("symbol")`: tách dữ liệu theo từng mã cổ phiếu; các phép tính phía sau chạy **riêng trong từng nhóm**.
- `cumcount()+1`: đếm số dòng trong mỗi nhóm theo thứ tự hiện tại (bắt đầu từ 0), nên cộng 1 để ra 1,2,3,...
- Kết quả giữ nguyên số dòng của `dfw`, chỉ thêm cột `row_num` làm chỉ số thời gian trong từng `symbol`.

SQL

```
SELECT
  symbol, date, price,
  ROW_NUMBER() OVER (PARTITION BY symbol ORDER BY date) AS row_num
FROM stocks
ORDER BY symbol, date;
```

IV.2.2. Bước 2: Lag và delta

Mục tiêu là lấy giá kỳ trước và tính chênh lệch theo kỳ trong mỗi `symbol`.

date ▾	price	prev_price (LAG)	delta
01-01	100	*NULL*	-
01-02	105	**100**	+5
01-03	102	**105**	-3

Pandas

```python
dfw["prev_price"] = dfw.groupby("symbol")["price"].shift(1)
dfw["delta"] = dfw["price"] - dfw["prev_price"]
```

Giải thích (Pandas)

- `groupby("symbol")["price"]`: lấy cột `price` theo từng nhóm `symbol`.
- `shift(1)`: dịch xuống 1 dòng trong từng nhóm, nên mỗi dòng nhận **giá của kỳ trước** (theo `date`). Dòng đầu tiên mỗi nhóm không có kỳ trước nên `prev_price` là `NaN`.
- `delta = price - prev_price`: chênh lệch giữa hiện tại và kỳ trước (dương = tăng, âm = giảm).
- Đây là mẫu window cơ bản: so sánh "dòng hiện tại" với "dòng liền trước" trong cùng nhóm mà không cần gộp dữ liệu.

SQL

```sql
SELECT
  symbol, date, price,
  LAG(price) OVER (PARTITION BY symbol ORDER BY date) AS prev_price,
  price - LAG(price) OVER (PARTITION BY symbol ORDER BY date) AS delta
FROM stocks
ORDER BY symbol, date;
```

IV.2.3. Bước 3: Moving average và running sum

Mục tiêu là tạo trung bình trượt 3 k và tổng cộng dồn trong mỗi `symbol`.

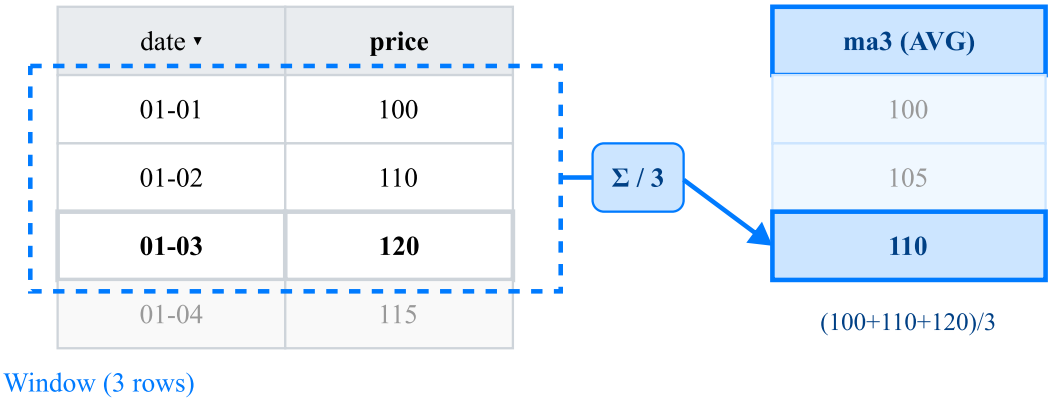

Pandas

```
dfw["ma3"] = (
    dfw.groupby("symbol")["price"]
       .rolling(3, min_periods=1)
       .mean()
       .reset_index(level=0, drop=True)
)

dfw["running_sum"] = dfw.groupby("symbol")["price"].cumsum()
```

Giải thích (Pandas)

- `rolling(3, min_periods=1)`: tạo cửa sổ 3 dòng gần nhất trong từng `symbol` (theo `date`). Các dòng đầu chưa đủ 3 dòng vẫn được tính nhờ `min_periods=1`.
- `mean()`: tính trung bình trên cửa sổ, tạo cột `ma3` (moving average 3 dòng) để làm mượt biến động ngắn hạn.
- `reset_index(level=0, drop=True)`: đưa kết quả `rolling` về cùng index với `dfw` để gán cột trực tiếp.
- `cumsum()`: tổng cộng dồn trong từng `symbol` (tổng từ đầu chuỗi đến dòng hiện tại).

SQL

```
SELECT
  symbol, date, price,
  AVG(price) OVER (
    PARTITION BY symbol ORDER BY date
    ROWS BETWEEN 2 PRECEDING AND CURRENT ROW
  ) AS ma3,
  SUM(price) OVER (
```

```
    PARTITION BY symbol ORDER BY date
    ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW
  ) AS running_sum
FROM stocks
ORDER BY symbol, date;
```

IV.2.4. Bước 4: Top-3 (RANK)

Mục tiêu là xếp hạng theo năm trong từng `symbol` và lấy top-3 tháng có giá cao nhất.

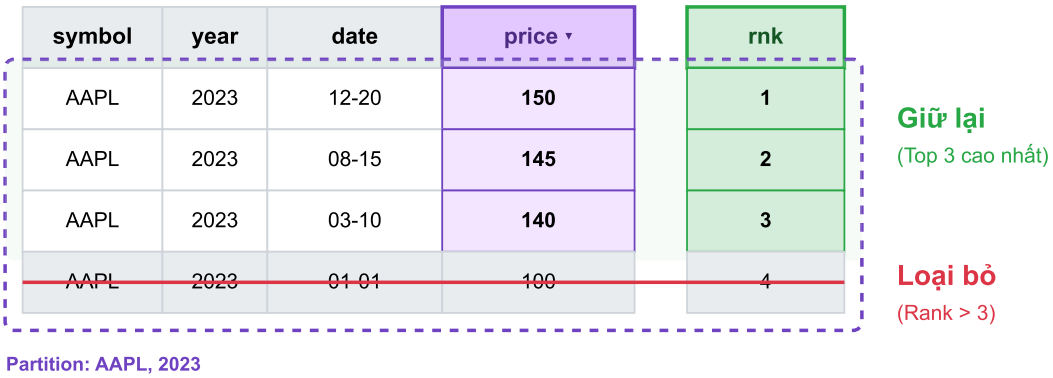

Pandas

```
dfw["year"] = dfw["date"].dt.year
dfw["rank_year"] = dfw.groupby(["symbol", "year"])["price"].rank(
    ascending=False, method="min"
)

top3 = dfw[dfw["rank_year"] <= 3].sort_values(["symbol", "year", "
   rank_year", "date"])
```

Giải thích (Pandas)

- `year = dfw["date"].dt.year`: tách năm từ `date` để dùng cho việc nhóm theo năm.
- `groupby(["symbol","year"])`: mỗi (mã, năm) là một nhóm riêng, xếp hạng độc lập.
- `rank(ascending=False, method="min")`: xếp hạng theo `price` giảm dần (hạng 1 là giá cao nhất). Nếu bị trùng giá, `method="min"` cho tất cả cùng nhận hạng nhỏ nhất (giống `RANK` trong SQL).
- `rank_year <= 3`: lọc top-3 theo từng (mã, năm) — mẫu thường gặp: **tính rank trong nhóm** rồi **lọc theo rank**.

SQL

```sql
WITH ranked AS (
  SELECT
    symbol, date, price,
    YEAR(date) AS year,
    RANK() OVER (
      PARTITION BY symbol, YEAR(date)
      ORDER BY price DESC
    ) AS rnk
  FROM stocks
)
SELECT *
FROM ranked
WHERE rnk <= 3
ORDER BY symbol, year, rnk, date;
```

Các bạn có thể tham khảo 2 đoạn code sẵn ở đây:

- Pandas code: link
- Sql script: link

IV.3. Quiz

Bảng sau sử dụng cho câu 1-3

order_id	region	sales
ord_101	east	120
ord_102	east	80
ord_103	west	200
ord_104	east	100
ord_105	west	50
ord_106	south	90

Câu 1. Dựa trên cùng bảng dữ liệu, giả sử bảng trên được lưu trong một bảng SQL có tên `orders_table`. Ta chạy truy vấn sau:

```sql
SELECT order_id,
       region,
       sales,
       SUM(sales) OVER (PARTITION BY region) AS region_total
FROM orders_table;
```

Giá trị của **region_total** tại dòng `ord_102` là bao nhiêu?

a) 80

b) 200

c) 300

d) 640

Đáp án: C

Đọc đúng kết quả của window aggregate

Dòng `ord_102` thuộc `region = east`. Trong nhóm này có ba dòng với `sales` lần lượt là $120, 80, 100$, nên tổng bằng 300. Vì truy vấn dùng `SUM(sales) OVER (PARTITION BY region)`, mỗi dòng trong cùng `region` đều nhận cùng tổng nhóm đó. Do vậy đáp án đúng là C.

Câu 2. Dựa trên cùng bảng dữ liệu, giả sử bảng trên đã được đọc vào một DataFrame **pandas** có tên `df`. Đoạn mã nào sau đây tạo cột **region_total đúng nhất**, biết rằng mỗi dòng phải nhận **tổng `sales` của `region` tương ứng** nhưng vẫn giữ nguyên số dòng ban đầu?

a)

```
df["region_total"] = df["sales"].sum()
```

b)

```
df["region_total"] = df.groupby("region")["sales"].sum()
```

c)

```
df["region_total"] = (
    df.groupby("region")["sales"]
      .transform("sum")
)
```

d)

```
df["region_total"] = (
    df.groupby("region")["sales"]
      .cumsum()
)
```

Đáp án: C

Dùng transform để giữ nguyên số dòng

`transform("sum")` tính tổng theo từng `region` rồi broadcast kết quả trở lại đúng từng dòng ban đầu. Phương án A chia cho toàn bảng, B trả về kết quả mức nhóm nên không khớp trực tiếp với toàn bộ chỉ mục gốc, còn D là cumulative sum chứ không phải tổng cả nhóm. Vì vậy đáp án đúng là C.

Câu 3. Dựa trên cùng bảng dữ liệu, giả sử bảng trên đã được đọc vào một DataFrame **pandas** có tên `df`. Ta muốn tạo cột **row_num_in_region** với logic tương đương:

```
ROW_NUMBER() OVER (PARTITION BY region ORDER BY sales DESC)
```

Biết rằng DataFrame **không được giả sử là đã sắp sẵn**. Đoạn mã nào sau đây là **đúng nhất**?

a)

```python
df["row_num_in_region"] = (
    df.groupby("region").cumcount() + 1
)
```

b)

```python
df = df.sort_values(["region", "sales"], ascending=[True, True])
df["row_num_in_region"] = (
    df.groupby("region").cumcount() + 1
)
```

c)

```python
df = df.sort_values(["region", "sales"], ascending=[True, False])
df["row_num_in_region"] = (
    df.groupby("region").cumcount() + 1
)
```

d)

```python
df["row_num_in_region"] = (
    df.groupby("region")["sales"]
      .transform("sum")
)
```

Đáp án: C

Mô phỏng ROW_NUMBER bằng pandas

Để biểu diễn đúng `ROW_NUMBER() OVER (PARTITION BY region ORDER BY sales DESC)`, ta phải sắp theo `region` và `sales` giảm dần trước, rồi mới dùng `groupby(...).cumcount() + 1`. Phương án A thiếu bước sắp xếp, B sắp sai chiều của `sales`, còn D là tổng theo nhóm chứ không phải đánh số thứ tự. Vì vậy đáp án đúng là C.

Bảng sau sử dụng cho câu 4-5

category	product_name	sales
furniture	desk_a	500
furniture	desk_b	500
furniture	chair_c	300
furniture	lamp_d	200
office_supplies	pen_x	90
office_supplies	paper_y	90
office_supplies	binder_z	60

Câu 4. Dựa trên cùng bảng dữ liệu, giả sử bảng trên được lưu trong một bảng SQL có tên `product_sales`. Ta chạy truy vấn sau:

```sql
SELECT category,
       product_name,
       sales,
       ROW_NUMBER() OVER (
           PARTITION BY category
           ORDER BY sales DESC
       ) AS row_number_val,
       RANK() OVER (
           PARTITION BY category
           ORDER BY sales DESC
       ) AS rank_val,
       DENSE_RANK() OVER (
           PARTITION BY category
           ORDER BY sales DESC
       ) AS dense_rank_val
FROM product_sales;
```

Bộ giá trị nào sau đây là **đúng nhất** cho dòng `chair_c`?

a) `row_number_val = 3, rank_val = 3, dense_rank_val = 2`

b) `row_number_val = 2, rank_val = 2, dense_rank_val = 2`

c) `row_number_val = 3, rank_val = 2, dense_rank_val = 3`

d) `row_number_val = 1, rank_val = 1, dense_rank_val = 1`

Đáp án: A

Phân biệt ba hàm ranking trong SQL

Trong nhóm `furniture`, hai dòng `desk_a` và `desk_b` cùng có `sales = 500`, nên đều đứng trước `chair_c`. Vì vậy `chair_c` có `row_number = 3`. Với `RANK()`, thứ hạng sau tie sẽ nhảy thành 3; còn với `DENSE_RANK()`, thứ hạng không nhảy nên bằng 2. Do đó đáp án đúng là A.

Câu 5. Dựa trên cùng bảng dữ liệu, giả sử bảng trên đã được đọc vào một DataFrame **pandas** có tên `df`. Ta cần lấy ra **đúng 2 dòng có `sales` cao nhất trong mỗi `category`**. Nếu có tie, vẫn chỉ giữ đúng 2 dòng theo thứ tự `sales DESC, product_name ASC`. Đoạn mã nào sau đây là **đúng nhất**?

a)

```
top2 = (
    df.sort_values(["sales", "product_name"], ascending=[False, True
    ])
       .head(2)
)
```

b)

```
top2 = (
    df.sort_values(["category", "sales", "product_name"],
                   ascending=[True, False, True])
      .groupby("category", group_keys=False)
      .head(2)
)
```

c)

```
top2 = (
    df.sort_values(["category", "sales", "product_name"],
                   ascending=[True, True, True])
      .groupby("category", group_keys=False)
      .head(2)
)
```

d)

```
top2 = (
    df.sort_values(["category", "product_name"], ascending=[True,
    True])
       .groupby("category", group_keys=False)
       .head(2)
)
```

Đáp án: B

Top N per group trong pandas

Phương án B đúng vì sắp đúng theo `category`, rồi theo `sales` giảm dần, dùng `product_name` làm tiêu chí phụ để phá tie, và cuối cùng lấy `head(2)` trong từng nhóm. Phương án A chỉ lấy top 2 toàn bảng, C sắp sai chiều của `sales`, còn D bỏ mất tiêu chí

chính là `sales`. Vì vậy đáp án đúng là B.

Bảng sau sử dụng cho câu 6-8

customer_id	order_date	sales
c001	2024-01-05	100
c001	2024-01-20	160
c001	2024-02-03	120
c002	2024-01-08	90
c002	2024-01-25	130
c002	2024-02-10	70

Câu 6. Dựa trên cùng bảng dữ liệu, giả sử bảng trên được lưu trong một bảng SQL có tên `customer_orders`. Ta chạy truy vấn sau:

```sql
SELECT customer_id,
       order_date,
       sales,
       LAG(sales) OVER (
           PARTITION BY customer_id
           ORDER BY order_date
       ) AS prev_sales
FROM customer_orders;
```

Giá trị của **prev_sales** tại dòng `customer_id = c001` và `order_date = 2024-02-03` là bao nhiêu?

a) 100

b) 120

c) 160

d) NULL

Đáp án: C

Hiểu đúng LAG trong SQL

Trong nhóm `customer_id = c001`, thứ tự thời gian là 2024-01-05 → 2024-01-20 → 2024-02-03. Vì `LAG()` nhìn về dòng trước đó trong cùng nhóm theo `order_date`, dòng ngày `2024-02-03` sẽ nhận `prev_sales = 160`. Do đó đáp án đúng là C.

Câu 7. Dựa trên cùng bảng dữ liệu, giả sử bảng trên được lưu trong một bảng SQL có tên `customer_orders`. Đoạn mã SQL nào sau đây tạo cột **sales_diff đúng nhất**, với quy ước:

```
sales_diff = sales hiện tại - sales của đơn trước đó trong cùng customer
```

a)

```sql
SELECT customer_id,
       order_date,
       sales,
       sales - LAG(sales) OVER (
           ORDER BY order_date
       ) AS sales_diff
FROM customer_orders;
```

b)

```sql
SELECT customer_id,
       order_date,
       sales,
       sales - LAG(sales) OVER (
           PARTITION BY customer_id
           ORDER BY order_date
       ) AS sales_diff
FROM customer_orders;
```

c)

```sql
SELECT customer_id,
       order_date,
       sales,
       sales - LEAD(sales) OVER (
           PARTITION BY customer_id
           ORDER BY order_date
       ) AS sales_diff
FROM customer_orders;
```

d)

```sql
SELECT customer_id,
       order_date,
       sales,
       LAG(sales) OVER (
           PARTITION BY customer_id
       ) - sales AS sales_diff
FROM customer_orders;
```

Đáp án: B

Tạo chênh lệch so với đơn trước

Phương án B đúng vì vừa chia theo `customer_id`, vừa sắp theo `order_date`, rồi lấy `sales hiện tại - sales trước đó`. Phương án A bỏ mất `PARTITION BY`, C nhìn sang dòng sau bằng `LEAD()`, còn D thiếu `ORDER BY` và còn đảo dấu phép trừ. Vì vậy đáp án đúng là B.

Câu 8. Dựa trên cùng bảng dữ liệu, giả sử bảng trên đã được đọc vào một DataFrame **pandas** có tên `df`. Ta muốn tạo cột **prev_sales** với logic tương đương `LAG(sales)` theo từng `customer_id`, sắp theo `order_date`. Biết rằng DataFrame **không được giả sử là đã sắp sẵn**. Đoạn mã nào sau đây là **đúng nhất**?

a)

```
df["prev_sales"] = df["sales"].shift(1)
```

b)

```
df["prev_sales"] = (
    df.groupby("customer_id")["sales"]
      .shift(1)
)
```

c)

```
df = df.sort_values(["customer_id", "order_date"])
df["prev_sales"] = (
    df.groupby("customer_id")["sales"]
      .shift(1)
)
```

d)

```
df = df.sort_values("sales")
df["prev_sales"] = (
    df.groupby("customer_id")["sales"]
      .shift(-1)
)
```

Đáp án: C

Biểu diễn LAG bằng pandas

Muốn mô phỏng đúng `LAG()`, ta phải sắp theo `customer_id` và `order_date` trước, rồi mới dùng `groupby(...).shift(1)`. Phương án A không chia nhóm, B chưa khóa đúng thứ tự thời gian, còn D dùng `shift(-1)` nên thành logic kiểu `LEAD`. Vì vậy đáp án đúng là C.

Bảng sau sử dụng cho câu 9-10

region	month	sales
north	2024-01	100
north	2024-02	130
north	2024-03	170
north	2024-04	190
south	2024-01	80
south	2024-02	120
south	2024-03	100
south	2024-04	140

Câu 9. Dựa trên cùng bảng dữ liệu, giả sử bảng trên được lưu trong một bảng SQL có tên `monthly_sales`. Ta cần tính cột **ma_3** là **moving average 3 kỳ** trong từng `region`, với quy ước mỗi giá trị được tính bằng **tháng hiện tại và 2 tháng liền trước trong cùng region**. Đoạn mã SQL nào sau đây là **đúng nhất**?

a)

```sql
SELECT region,
       month,
       sales,
       AVG(sales) OVER (
           PARTITION BY region
           ORDER BY month
       ) AS ma_3
FROM monthly_sales;
```

b)

```sql
SELECT region,
       month,
       sales,
       AVG(sales) OVER (
           PARTITION BY region
           ORDER BY month
           ROWS BETWEEN 2 PRECEDING AND CURRENT ROW
       ) AS ma_3
FROM monthly_sales;
```

c)

```sql
SELECT region,
       month,
       sales,
       AVG(sales) OVER (
           ORDER BY month
           ROWS BETWEEN 2 PRECEDING AND CURRENT ROW
       ) AS ma_3
FROM monthly_sales;
```

d)

```sql
SELECT region,
       month,
       AVG(sales) AS ma_3
FROM monthly_sales
GROUP BY region, month;
```

Đáp án: B

Phương án B đúng vì vừa chia theo `region`, vừa sắp theo `month`, và còn chỉ rõ cửa sổ gồm `2 PRECEDING` đến `CURRENT ROW`. Phương án A là cumulative average chứ chưa giới hạn 3 kỳ, C trộn dữ liệu giữa các `region`, còn D là aggregate thường chứ không phải window function. Vì vậy đáp án đúng là B.

Câu 10. Dựa trên cùng bảng dữ liệu, giả sử bảng trên đã được đọc vào một DataFrame **pandas** có tên `df`. Ta muốn tạo cột **pct_of_region**, trong đó mỗi dòng được tính theo công thức:

`pct_of_region = sales / tổng sales của region tương ứng`

Đoạn mã nào sau đây là **đúng nhất**?

a)

```python
df["pct_of_region"] = df["sales"] / df["sales"].sum()
```

b)

```python
df["pct_of_region"] = (
    df.groupby("region")["sales"]
      .mean()
)
```

c)

```python
df["region_total"] = (
    df.groupby("region")["sales"]
      .transform("sum")
)
df["pct_of_region"] = df["sales"] / df["region_total"]
```

d)

```python
df["pct_of_region"] = (
    df.groupby("region")["sales"]
      .shift(1)
)
```

Đáp án: C

% of total within group trong pandas

Phương án C đúng vì `transform("sum")` tạo tổng `sales` cho từng `region` nhưng vẫn giữ nguyên số dòng, sau đó ta chia `sales` hiện tại cho tổng nhóm tương ứng. Phương án A chia cho tổng toàn bảng, B trả về mean theo nhóm chứ không phải tỷ trọng, còn D chỉ dịch dòng chứ không tính phần trăm đóng góp. Vì vậy đáp án đúng là C.

AI VIET NAM COURSE 2026

SQL Transformation with dbt

I. Dẫn nhập

Trong một hệ thống dữ liệu thực tế, các phép biến đổi SQL thường được xây dựng nối tiếp nhau để đưa dữ liệu từ trạng thái ban đầu đến dạng sẵn sàng cho phân tích. Một truy vấn có thể chuẩn hóa dữ liệu nguồn, truy vấn tiếp theo kết nối nhiều bảng, còn các bước phía sau tiếp tục tổng hợp dữ liệu thành những chỉ số phục vụ báo cáo. Khi số lượng bảng và yêu cầu phân tích tăng lên, các truy vấn này dần hình thành một pipeline với nhiều quan hệ phụ thuộc.

Ở quy mô nhỏ, Data Engineer có thể quản lý pipeline bằng một tập hợp file SQL và thực thi chúng theo thứ tự định trước. Tuy nhiên, khi project phát triển, cách làm này trở nên khó kiểm soát. Người phát triển cần biết bước nào phải chạy trước, kết quả nào đang được sử dụng ở phía sau và một thay đổi trong logic có thể ảnh hưởng đến những bảng nào. Nếu logic được lặp lại ở nhiều file hoặc được chỉnh sửa bởi nhiều thành viên, nguy cơ xuất hiện kết quả không nhất quán cũng tăng lên.

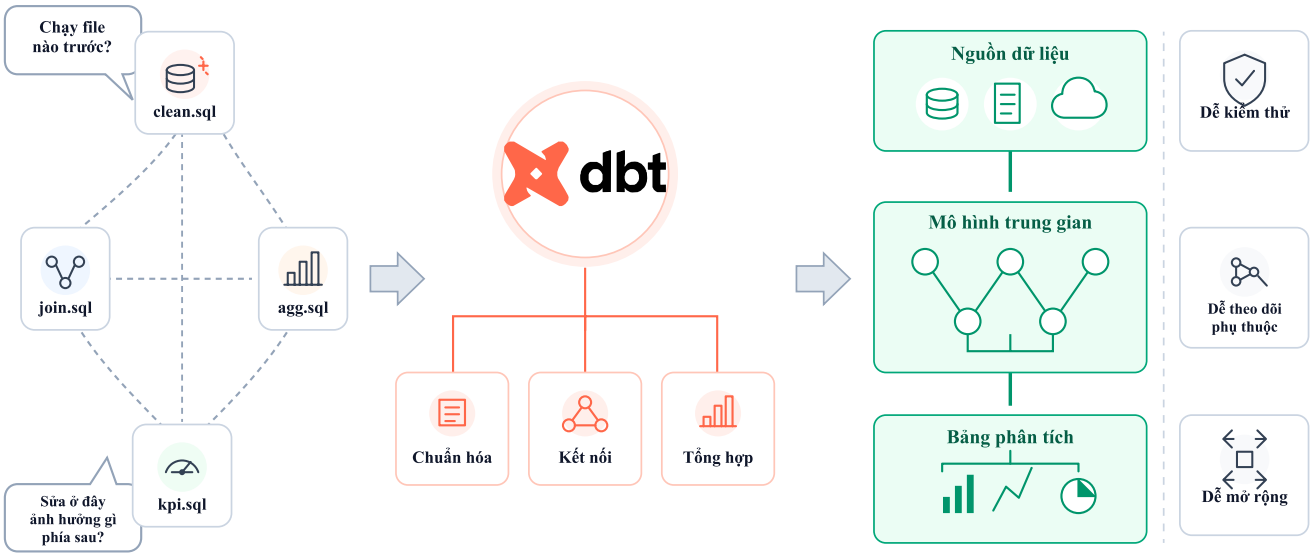

Hình 1: Từ các truy vấn SQL phụ thuộc lẫn nhau đến một quy trình biến đổi dữ liệu có tổ chức.

Khi số lượng transformation tăng lên, thách thức không còn chỉ là viết đúng từng câu truy vấn SQL, mà còn là quản lý quan hệ phụ thuộc giữa các bước, kiểm tra chất lượng dữ liệu và theo

dõi ảnh hưởng của mỗi thay đổi đến các bảng phía sau. Nếu các truy vấn vẫn được tổ chức như những script rời rạc, pipeline sẽ ngày càng khó kiểm soát, bảo trì và mở rộng.

dbt được sử dụng để giải quyết vấn đề này bằng cách tổ chức các transformation SQL thành những model có quan hệ phụ thuộc rõ ràng. Mỗi model đảm nhiệm một vai trò cụ thể trong pipeline, đồng thời có thể được kiểm thử, tài liệu hóa và theo dõi lineage. Trong phần thực hành, người học sẽ sử dụng dbt để xây dựng một SQL transformation pipeline hoàn chỉnh từ dữ liệu vận hành đến các bảng phục vụ phân tích.

II. Lý thuyết căn bản về dbt

II.1. dbt là gì và vị trí trong Modern Data Stack

dbt (data build tool) là một công cụ dòng lệnh mã nguồn mở, cho phép Data Engineer và Analytics Engineer biến đổi dữ liệu ngay trong data warehouse bằng cách sử dụng SQL kết hợp với Jinja templating. Không giống như các công cụ ETL/ELT truyền thống vốn phụ thuộc vào giao diện kéo thả hoặc yêu cầu viết code bằng ngôn ngữ khác (Python, Java, Scala), dbt đưa toàn bộ logic biến đổi về với SQL.

Trong kiến trúc ELT hiện đại, dbt đảm nhiệm chữ **T** (Transform), tức là bước xử lý dữ liệu sau khi đã được Extract và Load vào kho dữ liệu. Các công cụ như Fivetran, Stitch, Airbyte đảm nhiệm việc trích xuất và tải dữ liệu thô vào data warehouse (Snowflake, BigQuery, Redshift, PostgreSQL...). Sau đó, dbt tiếp quản để chuẩn hóa, làm sạch, kết nối và tổng hợp dữ liệu thành các bảng sẵn sàng phục vụ phân tích và báo cáo.

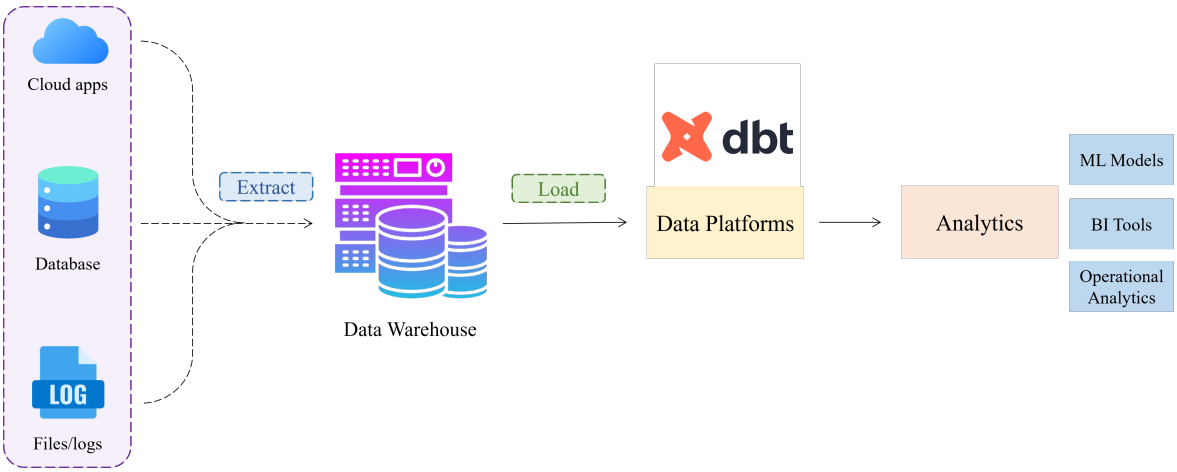

Hình 2: Vị trí của dbt trong kiến trúc ELT hiện đại.

Điểm khác biệt cốt lõi của dbt so với các công cụ ETL truyền thống nằm ở "transformation as code". Toàn bộ logic biến đổi được quản lý dưới dạng các file SQL trong một project có cấu trúc, cho phép áp dụng các best practice của software engineering như version control (Git), code review, testing, CI/CD và documentation tự động.

II.2. Kiến trúc và các thành phần cốt lõi

II.2.1. Project và Profile

Một project dbt được định nghĩa bởi file `dbt_project.yml`, đây là file cấu hình trung tâm khai báo tên project, phiên bản, vị trí các thư mục models, tests, seeds, snapshots, macros, cùng các cấu hình materialization mặc định. File `profiles.yml` (thường nằm ngoài project, trong thư mục `~/.dbt/`) lưu trữ thông tin kết nối đến data warehouse: host, port, database, schema, user, password và các tham số kết nối khác.

Sự tách biệt giữa `dbt_project.yml` và `profiles.yml` cho phép cùng một project có thể triển khai trên nhiều môi trường khác nhau (development, staging, production) chỉ bằng cách thay đổi target trong profile mà không cần sửa đổi code logic.

II.2.2. Models

Model là đơn vị cơ bản nhất trong dbt, tương ứng với một file SQL trong thư mục `models/`. Mỗi model định nghĩa một phép biến đổi SELECT để tạo ra một bảng (table) hoặc khung nhìn (view) trong data warehouse. Kết quả của một model có thể được tham chiếu bởi các model khác thông qua hàm `{{ ref('model_name') }}`.

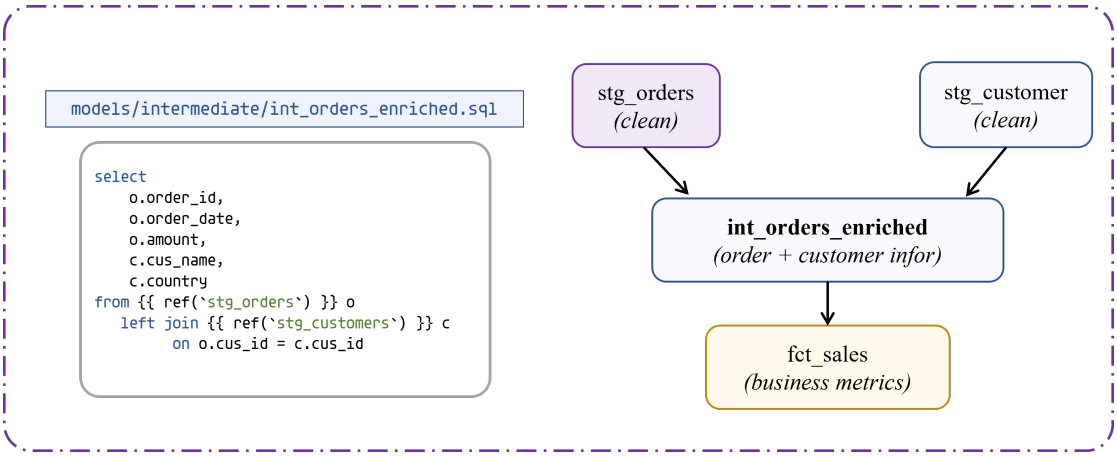

Hình 3: Minh họa quan hệ phụ thuộc giữa các model thông qua hàm ref().

Hàm `ref()` đóng hai vai trò quan trọng. Thứ nhất, nó cho phép dbt tự động xác định Directed Acyclic Graph (DAG), là đồ thị phụ thuộc không chu trình cho biết thứ tự thực thi các model. Model A phụ thuộc vào model B sẽ được chạy sau khi model B hoàn tất. Thứ hai, `ref()` tự động điều chỉnh tham chiếu đến đúng schema và database tương ứng với từng môi trường, giúp code trở nên portable giữa development và production.

Bên cạnh `ref()`, dbt còn cung cấp hàm `source()` để tham chiếu đến các bảng dữ liệu thô, những bảng đã được load vào warehouse bởi công cụ Extract/Load. Các source được khai báo tập trung trong file `sources.yml`, giúp tường minh hóa nguồn gốc dữ liệu và dễ dàng theo dõi lineage.

II.2.3. Materializations

Materialization xác định cách dbt tạo ra đối tượng trong data warehouse từ một model. dbt hỗ trợ bốn chiến lược materialization chính:

- **View:** Tạo một database view. Mỗi lần truy vấn, view sẽ tính toán lại từ dữ liệu nguồn. Phù hợp cho các model staging hoặc các phép biến đổi đơn giản, không tốn nhiều tài nguyên tính toán. Không chiếm dụng dung lượng lưu trữ.
- **Table:** Tạo một physical table và ghi đè toàn bộ mỗi khi chạy lại. Phù hợp cho các model được truy vấn thường xuyên, nơi hiệu năng đọc quan trọng hơn chi phí ghi. Chiếm dụng dung lượng lưu trữ nhưng cho tốc độ truy vấn nhanh hơn view trong nhiều trường hợp.

- **Incremental:** Chỉ xử lý các dòng dữ liệu mới hoặc thay đổi kể từ lần chạy trước. Đây là chiến lược tối ưu cho các bảng fact lớn (hàng trăm triệu đến hàng tỷ dòng), nơi việc rebuild toàn bộ là không khả thi về mặt thời gian và chi phí. Yêu cầu người dùng chỉ định logic xác định dòng mới thông qua điều kiện `is_incremental()`.
- **Ephemeral:** Không tạo ra đối tượng vật lý trong warehouse. Thay vào đó, code SQL của model ephemeral được "nhúng"trực tiếp vào các model phụ thuộc nó thông qua cơ chế CTE (Common Table Expression). Phù hợp cho các phép biến đổi trung gian nhẹ, giúp giảm số lượng bảng/vật thể cần quản lý nhưng vẫn giữ được tính module của code.

Ngoài ra, dbt còn hỗ trợ **Snapshot** — một dạng materialization đặc biệt dùng để theo dõi lịch sử thay đổi của dữ liệu theo thời gian (slowly changing dimension type 2). Snapshot cho phép trả lời câu hỏi "giá trị của cột này là gì vào thời điểm T trong quá khứ?".

II.2.4. Tests

Testing trong dbt được chia thành hai loại: **generic tests** (schema tests) và **singular tests** (data tests). Generic tests là các kiểm thử được định nghĩa sẵn, có thể áp dụng cho bất kỳ cột nào thông qua file YAML. Bốn generic test phổ biến nhất gồm:

- `unique`: Đảm bảo mọi giá trị trong cột là duy nhất.
- `not_null`: Đảm bảo cột không chứa giá trị NULL.
- `accepted_values`: Đảm bảo cột chỉ chứa các giá trị nằm trong tập cho phép.
- `relationships`: Đảm bảo các giá trị trong cột tham chiếu đến khóa chính của bảng khác (referential integrity).

Singular tests là các truy vấn SQL tùy chỉnh được viết trong thư mục `tests/`. Mỗi singular test trả về các dòng vi phạm điều kiện mà người dùng định nghĩa. Nếu truy vấn trả về ít nhất một dòng, test được coi là thất bại. Cách tiếp cận này cho phép kiểm tra các quy tắc nghiệp vụ phức tạp mà generic tests không bao quát được, ví dụ: "tổng số tiền thanh toán không được vượt quá tổng giá trị đơn hàng".

II.2.5. Documentation

dbt cung cấp khả năng sinh tài liệu tự động từ các mô tả được viết trong file YAML và từ metadata trong data warehouse. Tài liệu bao gồm:

- Mô tả cho từng model và từng cột.
- Lineage graph hiển thị toàn bộ DAG, cho phép trace từ bảng đầu ra ngược về các bảng nguồn.
- Kết quả kiểm thử (pass/fail) cho từng model.
- Thông tin về source, freshness và các dependencies bên ngoài.

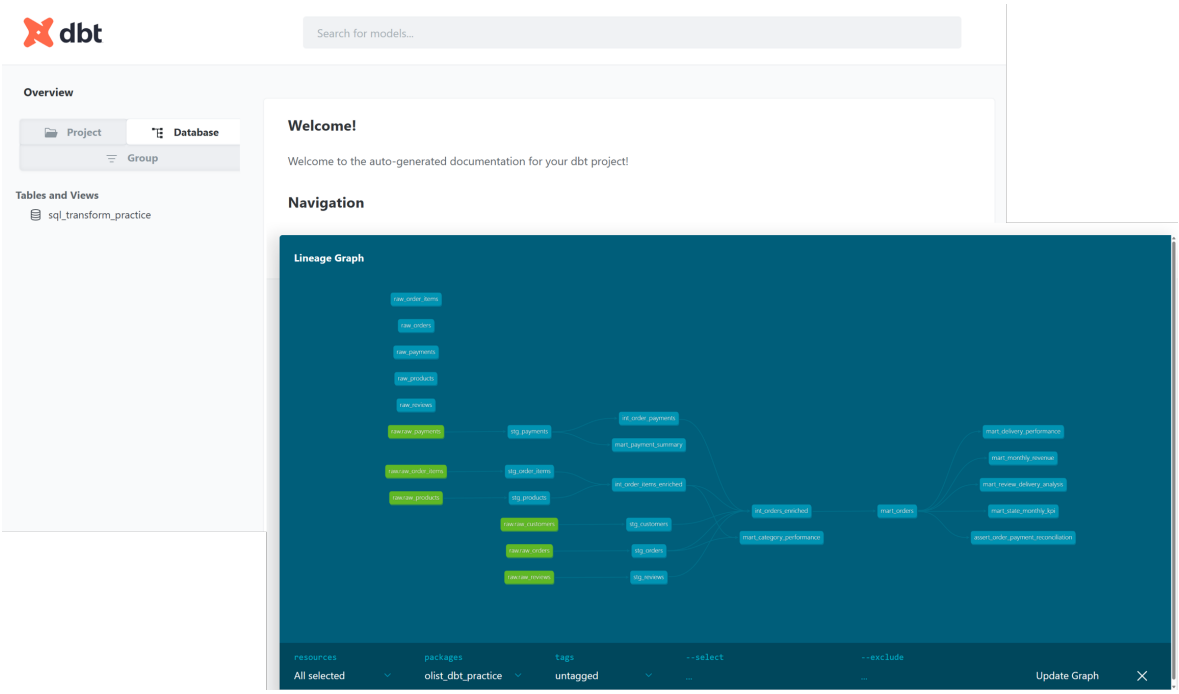

Hình 4: Giao diện tài liệu tự động sinh của dbt với lineage graph.

Tài liệu được tạo bằng lệnh `dbt docs generate` và có thể được serve dưới dạng static website qua `dbt docs serve` hoặc deploy lên web server. Điều này giúp toàn bộ tổ chức có một "data catalog"luôn đồng bộ với code thực tế, giải quyết vấn đề documentation drift thường gặp khi tài liệu được viết thủ công.

II.2.6. Macros

Macros trong dbt tương tự như functions trong lập trình: chúng cho phép đóng gói các đoạn logic SQL và Jinja có thể tái sử dụng trên nhiều model. Macros được định nghĩa trong thư mục `macros/` và có thể được gọi từ bất kỳ model nào bằng cú pháp `{{ macro_name(args) }}`.

Một số use case phổ biến của macros bao gồm:

- Tạo surrogate key từ nhiều cột: `md5(coalesce(col1, '') || '|' || coalesce(col2, ''))`.
- Áp dụng logic tính toán theo quy ước của tổ chức (ví dụ: cách tính customer lifetime value, churn flag...).
- Xử lý các pattern SQL phức tạp phụ thuộc vào dialect của từng warehouse (cross-database macros).
- Tự động sinh các đoạn code lặp đi lặp lại, giảm boilerplate và tăng tính nhất quán.

II.3. Quy trình phát triển với dbt

II.3.1. Mô hình phân lớp dữ liệu

Một trong những best practice quan trọng nhất khi làm việc với dbt là tổ chức models thành các lớp (layers) có trách nhiệm rõ ràng. Kiến trúc phổ biến nhất được cộng đồng dbt đề xuất gồm ba lớp chính:

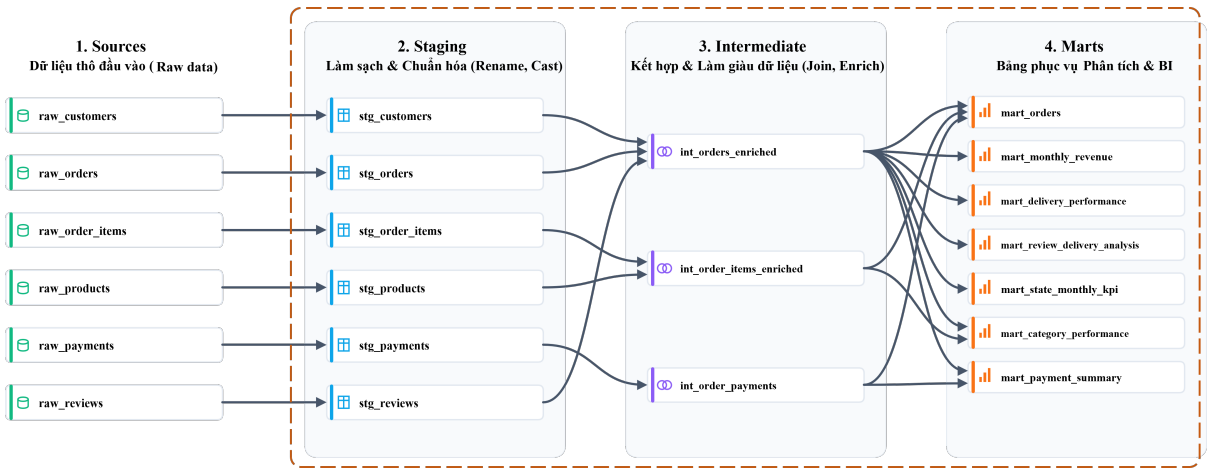

Hình 5: Mô hình phân lớp staging — intermediate — marts trong dbt project.

Lớp Staging (thư mục `models/staging/`): Chứa các model ánh xạ 1-1 với các bảng nguồn. Nhiệm vụ chính của staging là:

- Đổi tên cột theo quy ước (thường là snake_case).
- Chuyển đổi kiểu dữ liệu (CAST).
- Làm sạch cơ bản: trim khoảng trắng, chuẩn hóa NULL, lọc các dòng không hợp lệ.
- **Không** thực hiện JOIN hay aggregation ở lớp này.

Lớp Intermediate (thư mục `models/intermediate/`): Chứa các model trung gian, thực hiện các phép JOIN và transformation phức tạp hơn. Đây là nơi logic nghiệp vụ bắt đầu xuất hiện. Các model intermediate thường phục vụ một mục đích cụ thể và có thể được tái sử dụng bởi nhiều model trong lớp marts.

Lớp Marts (thư mục `models/marts/`): Chứa các bảng final, sẵn sàng cho end-user truy vấn. Marts thường được tổ chức theo business domain (finance, marketing, product, operations...) hoặc theo dimensional modeling (fact tables và dimension tables). Đây là lớp duy nhất mà business users và BI tools nên truy vấn trực tiếp.

II.3.2. dbt Commands cơ bản

Dưới đây là các lệnh dbt quan trọng mà chúng ta sẽ thường xuyên sử dụng trong quá trình phát triển:

- `dbt debug`: Kiểm tra kết nối đến data warehouse và tính hợp lệ của cấu hình project.
- `dbt seed`: Nạp các file CSV từ thư mục `seeds/` vào warehouse dưới dạng bảng.
- `dbt run`: Thực thi tất cả các model trong project theo đúng thứ tự DAG. Có thể giới hạn phạm vi bằng các selector như `-select model_name+` (model đó và tất cả downstream), `-select +model_name` (model đó và tất cả upstream), `-select tag:nightly`.
- `dbt test`: Chạy tất cả các generic tests và singular tests đã được định nghĩa.
- `dbt build`: Tương đương với `dbt run + dbt test + dbt seed + dbt snapshot` — chạy toàn bộ pipeline từ đầu đến cuối, chỉ build những gì cần thiết dựa trên selector.
- `dbt docs generate`: Sinh tài liệu từ metadata và mô tả trong YAML.
- `dbt docs serve`: Serve tài liệu dưới dạng local web server (mặc định tại `localhost:8080`).
- `dbt source freshness`: Kiểm tra thời gian cập nhật gần nhất của các bảng source, cảnh báo nếu dữ liệu bị stale.
- `dbt compile`: Biên dịch các template Jinja thành SQL mà không thực thi, hữu ích cho việc debug hoặc kiểm tra code được sinh ra.

Tổng kết lại, dbt không chỉ là một công cụ chạy SQL, nó là một framework giúp tổ chức áp dụng software engineering best practices vào lĩnh vực dữ liệu, biến quá trình transformation từ một tập hợp script rời rạc thành một pipeline có tổ chức, có khả năng kiểm thử, có tài liệu và dễ dàng bảo trì theo thời gian.

III. Practice: dbt with PostgreSQL

III.1. Bối cảnh dữ liệu

Trong bài thực hành này, chúng ta sử dụng một bộ dữ liệu thương mại điện tử gồm sáu bảng chính: khách hàng, đơn hàng, chi tiết đơn hàng, sản phẩm, thanh toán và đánh giá. Các bảng được liên kết thông qua những khóa định danh như `customer_id`, `order_id` và `product_id`.

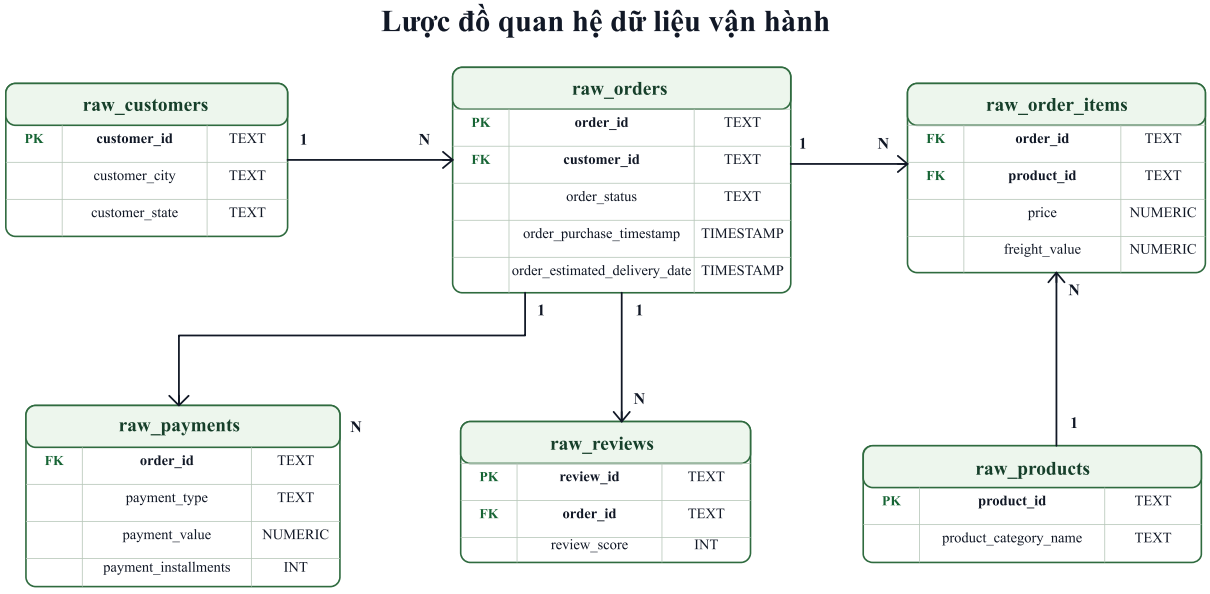

Hình 6: Lược đồ quan hệ giữa các bảng dữ liệu trong bài thực hành.

Hình trên cho thấy một khách hàng có thể phát sinh nhiều đơn hàng. Mỗi đơn hàng tiếp tục liên kết với các dòng sản phẩm, bản ghi thanh toán và đánh giá. Dữ liệu vận hành này phù hợp cho việc ghi nhận giao dịch nhưng chưa ở dạng thuận tiện để phân tích doanh thu, giao hàng hoặc hành vi thanh toán. Vì vậy, chúng ta sử dụng dbt để tổ chức các bước chuẩn hóa, kết nối và tổng hợp dữ liệu trên PostgreSQL.

III.2. Kết nối dbt với PostgreSQL

Trước khi chạy project, dbt cần biết PostgreSQL đang ở đâu và sẽ tạo dữ liệu tại lược đồ nào. Thông tin kết nối được khai báo trong file `profiles.yml`, bao gồm máy chủ, cổng, cơ sở dữ liệu, tài khoản và lược đồ đích.

Tên profile trong `profiles.yml` cần trùng với giá trị `profile` trong `dbt_project.yml`. Khi chạy `dbt debug`, dbt đọc hai file này và kiểm tra khả năng truy cập đến PostgreSQL.

```
olist_dbt_practice:
  target: dev
  outputs:
    dev:
      type: postgres
      host: localhost
      port: 5432
      user: postgres
      password: your_password
      dbname: olist
      schema: dbt_practice
      threads: 4
```

Trong cấu hình trên, `host` và `port` xác định máy chủ PostgreSQL, `dbname` xác định cơ sở dữ

liệu, còn `schema` là nơi dbt tạo các bảng và view của project.

III.3. Cấu trúc dự án

Một project dbt được tổ chức thành nhiều thư mục, mỗi thư mục đảm nhiệm một vai trò riêng. Cách tổ chức này giúp tách dữ liệu đầu vào, logic biến đổi, kiểm thử và cấu hình vận hành.

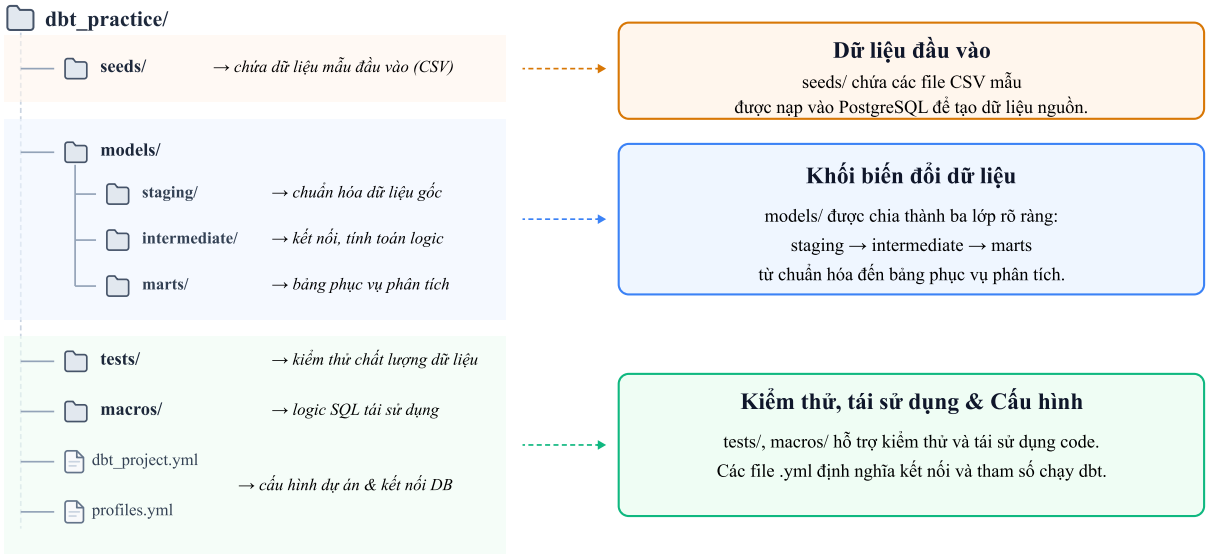

Hình 7: Các thành phần chính trong cấu trúc project dbt.

Các thành phần quan trọng gồm:

- `seeds/`: chứa dữ liệu CSV mẫu được nạp vào PostgreSQL.
- `models/`: chứa các mô hình biến đổi dữ liệu.
- `tests/`: chứa các kiểm thử SQL tùy chỉnh.
- `macros/`: chứa logic có thể tái sử dụng.
- `expected_outputs/`: lưu kết quả mẫu để đối chiếu.
- `dbt_project.yml`: cấu hình project.
- `profiles.yml`: cấu hình kết nối PostgreSQL.

III.4. Các lớp biến đổi dữ liệu

Các mô hình trong thư mục `models/` được chia thành ba lớp chính: `staging`, `intermediate` và `marts`. Dữ liệu bắt đầu từ các bảng nguồn rồi đi qua từng lớp theo thứ tự rõ ràng.

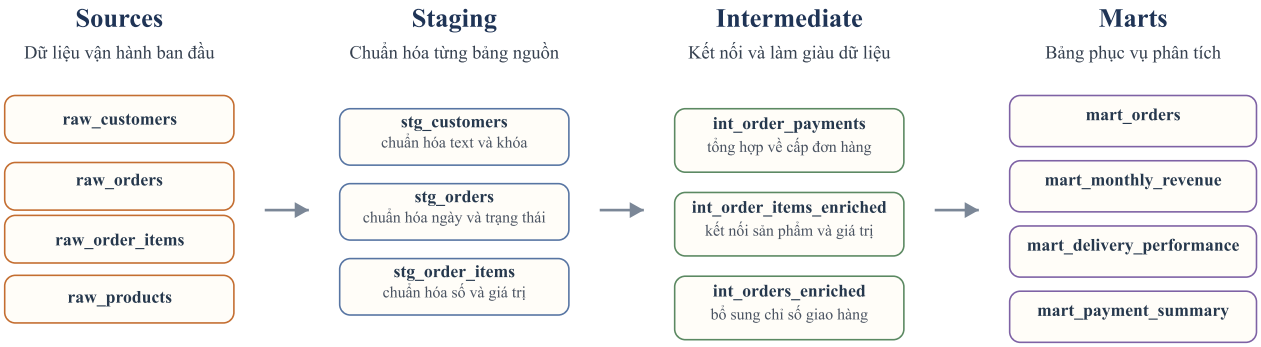

Hình 8: Dòng chảy dữ liệu qua các lớp mô hình trong dbt.

Sources xác định các bảng đầu vào trong PostgreSQL. Đây là điểm bắt đầu của dòng chảy dữ liệu.

Staging chuẩn hóa từng bảng nguồn, chẳng hạn đổi tên cột, chuyển kiểu dữ liệu và chuẩn hóa giá trị văn bản. Mỗi mô hình staging thường giữ cấp độ chi tiết gần với bảng ban đầu.

Intermediate kết nối và làm giàu dữ liệu. Tại lớp này, dữ liệu thanh toán có thể được tổng hợp về cấp đơn hàng, còn dữ liệu chi tiết đơn hàng có thể được kết nối với thông tin sản phẩm.

Marts tạo các bảng sẵn sàng cho phân tích, chẳng hạn bảng đơn hàng, doanh thu theo tháng, hiệu quả giao hàng và tổng hợp thanh toán.

III.5. Kiểm thử, tài liệu hóa và quy trình chạy

Sau khi cấu hình kết nối và xây dựng các mô hình, chúng ta thực hiện project theo từng nhóm công việc: kiểm tra kết nối, nạp dữ liệu, xây dựng mô hình, kiểm thử và tạo tài liệu.

Kiểm tra kết nối

Trước tiên, chúng ta kiểm tra xem dbt có thể kết nối đến PostgreSQL và đọc đúng cấu hình của project hay không.

```
dbt debug
```

Lệnh `dbt debug` kiểm tra file `dbt_project.yml`, profile đang được sử dụng và thông tin kết nối trong `profiles.yml`. Nếu quá trình kiểm tra thành công, chúng ta có thể tiếp tục nạp dữ liệu và chạy các mô hình.

Nạp dữ liệu mẫu

Dữ liệu CSV trong thư mục `seeds/` được nạp vào PostgreSQL bằng lệnh sau:

```
dbt seed --full-refresh
```

Tùy chọn `-full-refresh` yêu cầu dbt tạo lại các bảng seed từ đầu. Sau bước này, các bảng dữ liệu nguồn đã sẵn sàng để được sử dụng trong các mô hình staging.

Xây dựng các mô hình

Khi dữ liệu đầu vào đã có trong PostgreSQL, chúng ta chạy toàn bộ các mô hình trong project:

```
dbt run
```

dbt xác định thứ tự thực thi dựa trên quan hệ phụ thuộc giữa các mô hình. Các mô hình staging được xây dựng trước, sau đó đến intermediate và cuối cùng là marts.

Kiểm thử dữ liệu

Sau khi các mô hình được tạo, chúng ta chạy kiểm thử để kiểm tra chất lượng của kết quả:

```
dbt test
```

Các kiểm thử thường dùng gồm *not null*, *unique*, *relationships* và *accepted values*. Các kiểm thử này giúp phát hiện giá trị bị thiếu, khóa bị trùng, quan hệ không hợp lệ hoặc dữ liệu nằm ngoài tập giá trị cho phép.

Tạo và xem tài liệu

Cuối cùng, chúng ta tạo tài liệu cho project và mở giao diện tài liệu trên trình duyệt:

```
dbt docs generate
dbt docs serve
```

Lệnh `dbt docs generate` tổng hợp thông tin về model, cột, kiểm thử và quan hệ phụ thuộc. Lệnh `dbt docs serve` mở giao diện để chúng ta xem mô tả dữ liệu và dòng chảy giữa các mô hình.

Sau khi hoàn thành các bước trên, project đã có dữ liệu đầu vào, các bảng kết quả, kiểm thử chất lượng và tài liệu mô tả toàn bộ quy trình biến đổi.

IV. Tài liệu tham khảo

AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM COURSE 2026

Project: Marketing Analytics

I. Giới thiệu

Marketing (quảng cáo, truyền thông, xúc tiến bán hàng) là các hoạt động giúp doanh nghiệp đưa sản phẩm đến khách hàng và thúc đẩy hoạt động mua hàng từ người mua. Ngày nay, các lĩnh vực liên quan từ định giá sản phẩm, phân khúc khách hàng, tối ưu kênh phân phối, đến quản lý vòng đời thương hiệu, mỗi quyết định chiến lược đều đòi hỏi một nền tảng dữ liệu vững chắc làm cơ sở để phân tích. Các doanh nghiệp, từ hàng tiêu dùng nhanh (FMCG) đến tài chính và bán lẻ ngày càng tập trung nhiều vào lĩnh vực phân tích marketing (marketing analytics).

Trong các nhánh của marketing analytics, **digital marketing analytics** là mảng có tốc độ tăng trưởng dữ liệu nhanh nhất và mức độ đo lường trực tiếp cao nhất. Marketing truyền thống chỉ ước lượng hiệu quả một cách gián tiếp qua khảo sát hoặc doanh số tổng. Digital marketing đo lường được toàn bộ hành trình khách hàng, từ lần hiển thị quảng cáo đầu tiên đến khi thanh toán, với độ phân giải đến từng chiến dịch, từng kênh, từng phân khúc đối tượng.

Bài học này phân tích hiệu quả các chiến dịch marketing đa kênh trên dữ liệu thật của ba thương hiệu mỹ phẩm (beauty e-commerce) tại thị trường Ấn Độ. Mục tiêu không dừng ở việc tính ra các chỉ số, mà là rèn luyện tư duy đặt đúng câu hỏi, đọc số liệu đúng bối cảnh, và đưa ra khuyến nghị có giá trị cho người ra quyết định.

II. Hành trình của dữ liệu

Dữ liệu marketing sau khi thu thập được lưu trữ là ba tệp CSV riêng biệt, mỗi thương hiệu một tệp, định dạng không đồng nhất và chưa qua xử lý. Vì vậy, dữ liệu chưa thể sử dụng trực tiếp cho việc ra quyết định. Nhiệm vụ của người phân tích là chuyển bộ dữ liệu thô đó thành thông tin có thể sử dụng được, thông qua các bước làm sạch, chuẩn hóa, tính toán và trình bày, sao cho nhà quản lý có thể đọc và ra quyết định dựa trên kết quả.

Toàn bộ quy trình xử lý dữ liệu của Project bao gồm **6 bước**, được tổ chức thành một pipeline liên tục như mô tả ở hình 1.

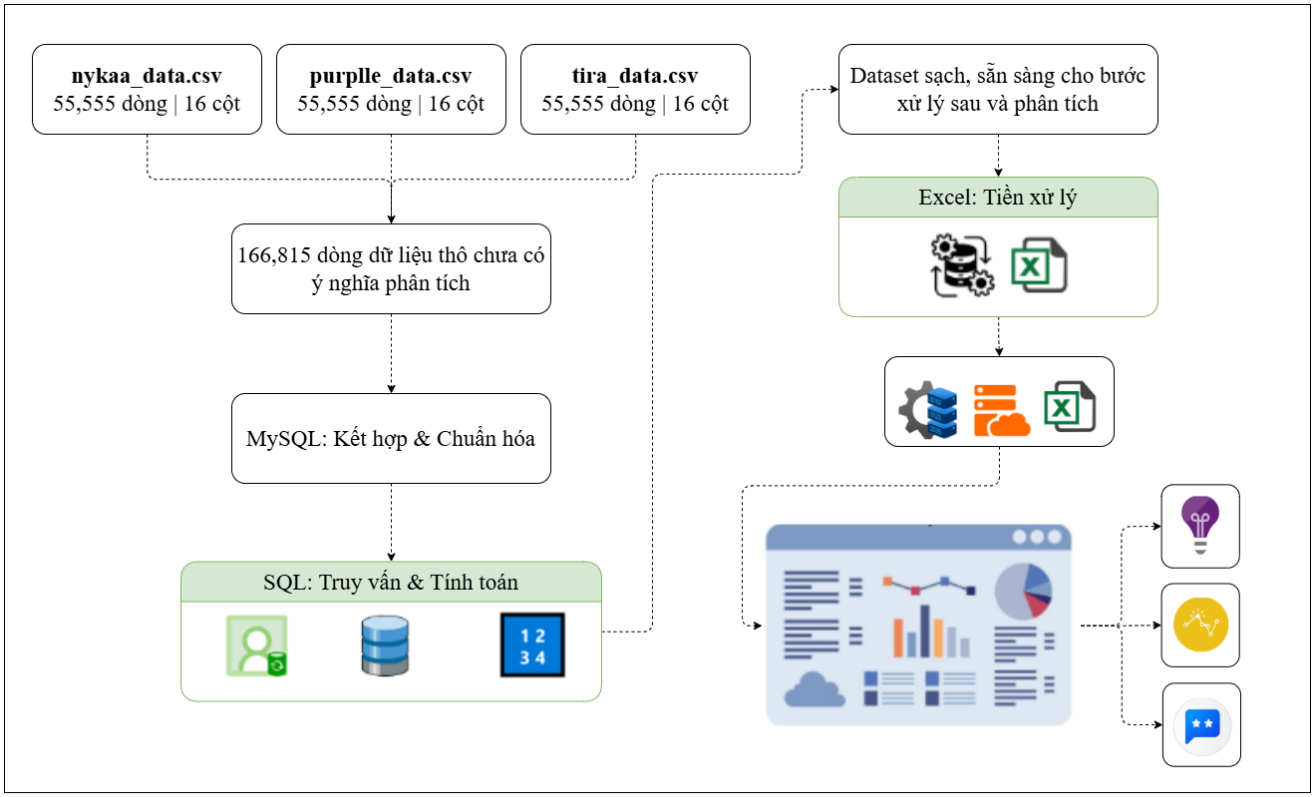

Hình 1: Data pipeline 6 bước từ dữ liệu thô đến insight.

! Lưu ý về cấu trúc dữ liệu đầu vào

Dataset gồm **3 file CSV riêng biệt**, mỗi thương hiệu một tệp. Ở Bước 2, chúng ta sẽ gộp cả ba tệp vào chung một bảng MySQL và thêm cột `Brand` để xác định mỗi dòng dữ liệu thuộc thương hiệu nào.

III. Hiểu về domain: Các chỉ số chính trong digital marketing

Trước khi thực hiện các truy vấn SQL, người phân tích cần hiểu ý nghĩa kinh doanh của từng chỉ số. Phần này trình bày sáu chỉ số cốt lõi của một chiến dịch digital marketing, theo đúng thứ tự phát sinh trong hành trình khách hàng: từ khi quảng cáo hiển thị đến khi doanh nghiệp thu được doanh thu.

1. Impressions (Quảng cáo đã đến tay bao nhiêu người?)

Impressions (lượt hiển thị) là số lần quảng cáo xuất hiện trên màn hình của người dùng. Đây là bước đầu tiên trong hành trình khách hàng, bởi trước khi ai đó mua hàng, họ cần nhìn thấy sản phẩm trước.

Một chiến dịch có 57.804 impressions nghĩa là quảng cáo đó đã được hiển thị gần 58 nghìn lần trên các nền tảng. Nhưng đây chưa phải 58 nghìn người khác nhau.

! Impressions ≠ Số người nhìn thấy

Khi một người nhìn thấy cùng một quảng cáo 5 lần trong một ngày, số lượt hiển thị là 5 (Impressions) nhưng số người tiếp cận thực tế chỉ là 1. Số người tiếp cận quảng cáo được gọi là **Reach**. Với bộ dữ liệu này, chúng ta không tập trung vào phân tích giá trị Reach, mà tập trung vào Impressions.

Insight: Impressions cao cho thấy quảng cáo được phân phối tốt và có độ phủ rộng trên nền tảng. Điều này giúp nhiều người có cơ hội nhìn thấy thương hiệu hoặc sản phẩm hơn. Ngược lại, impressions thấp thường cho thấy quảng cáo chưa được phân phối mạnh, có thể do ngân sách hạn chế hoặc nội dung chưa được nền tảng ưu tiên hiển thị.

2. Clicks (Quảng cáo có đủ hấp dẫn không?)

Clicks là số lần người dùng chủ động bấm vào quảng cáo. Nếu impressions chỉ phản ánh việc quảng cáo được hiển thị, thì clicks là tín hiệu quan tâm đầu tiên: người dùng muốn tìm hiểu thêm về sản phẩm.

Ví dụ: một chiến dịch có 57.804 impressions và 6.156 clicks, nghĩa là hệ thống đã ghi nhận 6.156 lần người dùng bấm vào quảng cáo để tìm hiểu thêm. Chỉ số Clicks này giúp trả lời cho câu hỏi liệu thông điệp, hình ảnh và lời kêu gọi hành động (CTA) của chúng ta đã đủ thuyết phục hay chưa.

Insight: Số lượng clicks cao chứng tỏ quảng cáo có nội dung thu hút và kích thích được người xem hành động. Ngược lại, clicks thấp thường là dấu hiệu cho thấy nội dung quảng cáo chưa đủ hấp dẫn hoặc việc nhắm đối tượng mục tiêu (target audience) chưa chính xác.

3. Leads (Ai thực sự quan tâm đến sản phẩm?)

Leads (khách hàng tiềm năng) là những người thể hiện sự quan tâm rõ rệt khi chủ động để lại email, đăng ký nhận tin, thêm sản phẩm vào giỏ hàng hoặc tải ứng dụng. Lead nằm ở tầng giữa:

người dùng đã bấm vào quảng cáo và đã bày tỏ sự quan tâm đến sản phẩm, nhưng chưa thực hiện mua hàng.

Ví dụ: từ 6.156 clicks, có 3.616 người để lại thông tin hoặc thực hiện hành động và trở thành leads.

Insight: Tỷ lệ chuyển đổi lead (Lead Rate) cao cho thấy trang đích (landing page) hoạt động hiệu quả và thông điệp có sự nhất quán. Ngược lại, nếu tỷ lệ này thấp, vấn đề thường nằm ở trải nghiệm sau khi click như biểu mẫu quá dài, nội dung chưa phù hợp hoặc tốc độ tải trang chậm.

4. Conversions (Kết quả cuối cùng của chiến dịch quảng cáo)

Conversions (lượt chuyển đổi) là kết quả doanh nghiệp hướng tới, và trong bộ dữ liệu này, mỗi conversion tương ứng với một đơn hàng mua thành công. Mọi bước trước đó trong phễu marketing (funnel), từ hiển thị, click đến lead, đều nhằm dẫn tới bước cuối cùng này: khách hàng hoàn tất thanh toán.

Ví dụ: trong 3.616 leads, có 2.355 người thực sự mua hàng thì sẽ tạo ra 2.355 conversions.

Insight: Insight: Tỷ lệ chuyển đổi (Conversion Rate) cao cho thấy sản phẩm, mức giá và trải nghiệm mua sắm đang đáp ứng tốt nhu cầu của khách hàng. Ngược lại, nếu chỉ số này thấp, doanh nghiệp cần rà soát lại chính sách giá (pricing), trải nghiệm người dùng (UX) hoặc mức độ uy tín thương hiệu trong mắt người tiêu dùng.

5. Revenue (Doanh thu thực sự thu về)

Revenue (doanh thu) là tổng tiền thu được từ tất cả các đơn hàng của chiến dịch quảng cáo. Đây là con số trực tiếp phản ánh tác động kinh doanh của chiến dịch.

Ví dụ: nếu 2.355 đơn hàng mang lại tổng doanh thu 1.867.000, thì đây chính là giá trị kinh tế mà chiến dịch tạo ra.

Insight: Revenue cao chưa chắc hiệu quả nếu chi phí cũng cao. Vì vậy, revenue luôn cần được phân tích cùng với chi phí cho mỗi lượt chuyển đổi (CPA - Cost Per Acquisition) và tỉ suất hoàn vốn (ROI - Return On Investment) để đánh giá đúng hiệu quả của chiến dịch.

Lưu ý về đơn vị tiền tệ trong bộ dữ liệu

Với dataset này không ghi rõ đơn vị tiền tệ nên trong quá trình phân tích, chúng ta sẽ tập trung vào **tỷ lệ** (ratio) và **thứ hạng** (ranking) giữa các chiến dịch hơn là giá trị tuyệt đối.

6. Acquisition Cost (Chi phí để có một khách hàng)

Acquisition Cost là số tiền trung bình phải bỏ ra để thu được **một** conversion (một đơn hàng mua thành công). Đây chính là CPA (Cost Per Acquisition) đã được tính sẵn trong bộ dữ liệu.

Ví dụ: nếu một chiến dịch có Acquisition Cost = 111 và tạo ra 2.355 conversions, thì trung bình mỗi đơn hàng tốn 111 đơn vị chi phí marketing.

Insight: Acquisition Cost càng thấp thì chiến dịch càng hiệu quả về mặt chi phí. Tuy nhiên, cần so sánh với giá trị đơn hàng (AOV) hoặc doanh thu tạo ra. Nếu chi phí để có một khách hàng cao hơn giá trị mà khách hàng mang lại thì chiến dịch đó đang bị lỗ.

Chi phí đơn vị và Tổng chi phí

Bộ dữ liệu cung cấp **chi phí đơn vị** (Acquisition_Cost = chi phí cho 1 conversion). Để tính **tổng chi phí** của toàn bộ chiến dịch, chúng ta tính như sau:

$$\text{Total_Spend} = \text{Acquisition_Cost} \times \text{Conversions}$$

Ví dụ: Acquisition_Cost = 111, Conversions = 2.355 $\Rightarrow$ Total_Spend $\approx$ 261.476.

IV. Marketing funnel

Sau khi đã nắm được các chỉ số riêng lẻ, phần này trình bày cách chúng liên kết với nhau qua mô hình **Marketing Funnel** (phễu marketing). Funnel mô tả hành trình của một người từ lần đầu nhìn thấy quảng cáo đến khi trở thành khách hàng. Mỗi tầng funnel tương ứng với một cột dữ liệu cụ thể và hẹp dần theo thời gian.

- **Awareness** (nhận biết) → `Impressions`: khách hàng nhìn thấy quảng cáo. Đây là tầng rộng nhất, gồm tất cả những người quảng cáo tiếp cận được.
- **Interest** (quan tâm) → `Clicks`: một phần trong số đó bấm vào quảng cáo để tìm hiểu thêm, thể hiện sự quan tâm ban đầu.
- **Consideration** (cân nhắc) → `Leads`: một phần nhỏ hơn để lại thông tin hoặc thực hiện một hành động, cho thấy ý định mua đang hình thành.
- **Conversion** (chuyển đổi) → `Conversions`: số ít cuối cùng hoàn tất mua hàng. Đây là tầng hẹp nhất và cũng là mục tiêu của cả chiến dịch.

Để minh họa cách phễu vận hành, hình **??** trình bày phễu của chiến dịch `NY-CMP-1000` thuộc thương hiệu Nykaa, chạy trên các kênh mạng xã hội như WhatsApp và YouTube.

Đọc phễu từ trên xuống, ta thấy rõ số người tương tác giảm dần qua từng tầng. Ở tầng **Awareness**, quảng cáo đạt 57.804 impressions. Sang tầng **Interest**, chỉ còn 6.156 clicks, tức CTR = 10,6%. Đây thực ra là con số tốt, cho thấy nội dung quảng cáo (creative) đủ hấp dẫn. Nhưng nhìn theo hướng ngược lại, có tới 89,4% người thấy quảng cáo mà không bấm vào.

Từ tầng **Interest** xuống **Consideration**, 6.156 clicks tạo ra 3.616 leads, ứng với Lead Rate = 58,7%. Gần 60% người đã bấm để lại thông tin là một tỷ lệ cao, chứng tỏ trang đích (landing page) hoạt động tốt. Xuống tầng cuối **Conversion**, 3.616 leads mang lại 2.355 đơn hàng, tức Conversion Rate = 65,1%. Đây là tỷ lệ rất tốt, cho thấy sản phẩm và mức giá đang thuyết phục được khách hàng, phần 34,9% lead chưa mua là nhóm cần được chú ý thêm.

Tính chung cả phễu, từ 57.804 impressions ban đầu chỉ còn 2.355 conversions, tương ứng tỷ lệ chuyển đổi tổng thể 2.355/57.804 $\approx$ 4,07%. Chiến dịch đạt ROI = 6,14 (bỏ ra 1 đồng thu về

6,14 đồng lợi nhuận) và CPA = 111 cho mỗi đơn hàng, với giá trị đơn hàng trung bình (AOV) khoảng 793.

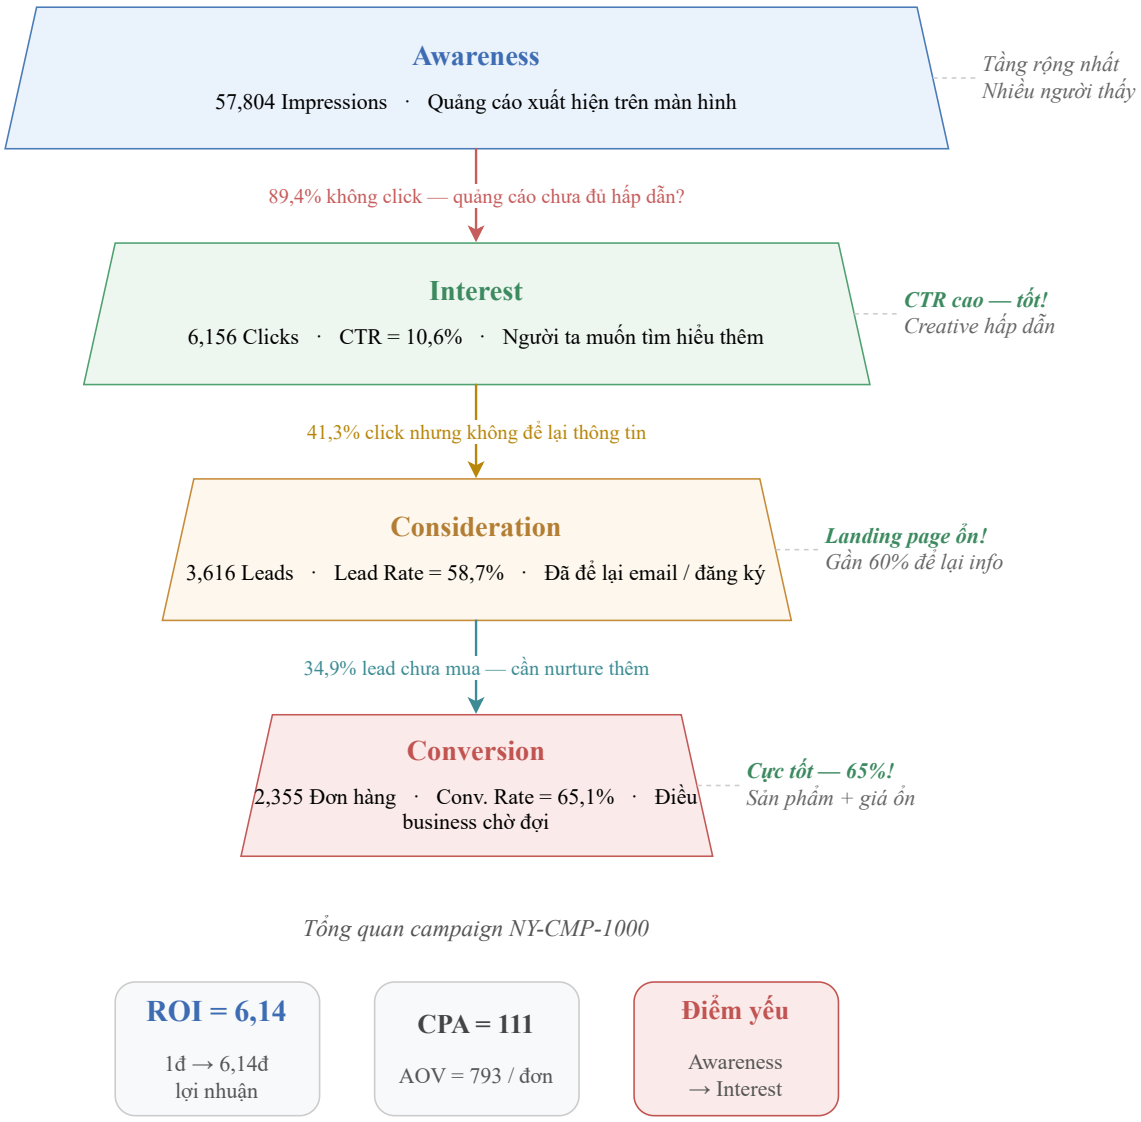

Hình 2: Marketing Funnel của chiến dịch quảng cáo NY-CMP-1000

Điểm mấu chốt rút ra là: ba tầng dưới của phễu (Interest, Consideration, Conversion) đều vận hành tốt, vấn đề duy nhất nằm ở tầng đầu **Awareness → Interest**. Nói cách khác, sản phẩm và trang bán không có vấn đề, điểm cần cải thiện là nội dung quảng cáo để kéo thêm người bấm vào. Qua đó, chúng ta thấy rõ đây chính là thông tin, nhận định mà một nhà phân tích dữ liệu cần chỉ ra để đề xuất hướng hành động cho bộ phận marketing, thay vì chỉ báo cáo lại số liệu.

V. Các KPI chính để đo lường tính hiệu quả

KPI (Key Performance Indicator) là các chỉ số đo lường hiệu quả. Mỗi KPI trả lời một câu hỏi cụ thể ở một tầng cụ thể của phễu. Chúng ta có 6 KPI cần nắm vững.

1. CTR (Click-Through Rate)

CTR CTR đo tỷ lệ số lượt click vào quảng cáo so với tổng lượt hiển thị. Đây là thước đo sức hút của quảng cáo ở tầng Awareness sang Interest.

$$\text{CTR} = \frac{\text{Clicks}}{\text{Impressions}}$$

Cách diễn giải CTR

- **CTR cao (>5%)** cho thấy quảng cáo hấp dẫn, đúng đối tượng, thông điệp rõ ràng.
- **CTR thấp (<1%)** là dấu hiệu của quảng cáo không thu hút, sai đối tượng, hoặc bị hiện tượng bão hoà (người dùng thấy quá nhiều lần đến mức lờ đi).

Chú ý: Không so sánh CTR giữa các kênh mà không có ngữ cảnh

Mức CTR chuẩn khác nhau đáng kể giữa các kênh, vì vậy so sánh trực tiếp dễ dẫn đến kết luận sai. Google Search Ads thường đạt 3–5% vì người dùng đang chủ động tìm kiếm sản phẩm, Facebook/Instagram Ads thường chỉ đạt 0,5–1,5% vì quảng cáo xuất hiện xen giữa nội dung giải trí. Khi so sánh CTR giữa các kênh, cần xét đến đặc điểm vận hành ở tầng Awareness của từng kênh.

2. Lead Rate (Tỷ lệ Khách hàng Tiềm năng)

Lead Rate đo tỷ lệ lượt click trở thành Lead. Đây là thước đo hiệu quả của trang đích ở tầng Interest sang Consideration.

$$\text{Lead Rate} = \frac{\text{Leads}}{\text{Clicks}}$$

Ví dụ: 1.000 clicks tạo ra 400 leads → Lead Rate = 40%.

Cách diễn giải Lead Rate

- **Lead Rate cao**: thể hiện trang đích rõ ràng, nội dung thuyết phục và biểu mẫu đơn giản.
- **Lead Rate thấp**: cho thấy người dùng bấm vào quảng cáo nhưng không thấy giá trị nên quyết định rời đi.

Insight: Nếu CTR cao nhưng Lead Rate thấp cho thấy rằng vấn đề không nằm ở quảng cáo mà nằm ở trang đích.

Chú ý: Luôn kiểm tra sự tương đồng giữa quảng cáo và trang đích

Người dùng bấm vào quảng cáo vì một thông điệp nào đó. Nếu trang đích không đúng với thông điệp đó (khác nội dung, khác ưu đãi), người dùng sẽ rời đi nhanh chóng, làm Lead Rate giảm mạnh. Vì vậy, cần đảm bảo quảng cáo và trang đích nhất quán về nội dung.

3. Lead Conversion Rate (Tỷ lệ Chuyển đổi)

Lead Conversion Rate đo tỷ lệ Lead mà thực sự mua hàng. Đây là thước đo quan trọng nhất ở tầng *Consideration* → *Conversion*.

$$\text{Lead Conversion Rate} = \frac{\text{Conversions}}{\text{Leads}}$$

Ví dụ: 400 leads tạo ra 100 đơn hàng → Conversion Rate = 25%.

Cách diễn giải Conversion Rate

- **Conversion cao**: cho thấy sản phẩm phù hợp, giá hợp lý và trải nghiệm mua hàng tốt.
- **Conversion thấp**: thể hiện rằng khách hàng quan tâm nhưng chưa đủ tin tưởng để mua.

Insight: Conversion thấp thường xuất phát từ vấn đề: giá cả, đánh giá (review) của người mua trước, trải nghiệm sử dụng (UX), hoặc chính sách bán hàng. Nếu CTR và Lead Rate đều tốt nhưng Conversion thấp, vấn đề chúng ta có thể xem xét đến vấn đề nằm ở sản phẩm, chính sách giá (pricing) hoặc khâu thanh toán (checkout), không phải ở marketing. Trong trường hợp này, tối ưu thêm quảng cáo vì vậy không giải quyết được vấn đề.

4. Click Conversion Rate (Tỷ lệ Click chuyển đổi)

Click Conversion Rate hay CVR đo tỷ lệ **lượt click** vào quảng cáo chuyển đổi thành một hành động mục tiêu. Trong bộ dữ liệu này, conversion chính là một đơn hàng mua thành công, tương ứng với cột Conversions.

Khác với **Lead Conversion Rate**, chỉ đo từ tầng **Consideration** đến tầng **Conversion**, chỉ số **Click Conversion Rate** đo hiệu quả chuyển đổi từ tầng **Interest** đến tầng **Conversion**. Nói cách khác, CVR phản ánh khả năng chuyển đổi qua hai tầng trong Marketing Funnel:

$$\text{Interest} \rightarrow \text{Consideration} \rightarrow \text{Conversion}$$

$$\text{CVR} = \frac{\text{Conversions}}{\text{Clicks}}$$

Trong đó:

- **Clicks** là số lượt người dùng click vào quảng cáo, đại diện cho tầng Interest.
- **Conversions** là số đơn hàng mua thành công, đại diện cho tầng Conversion.

Ví dụ: CVR = 22% nghĩa là cứ 100 lượt click thì có khoảng 22 lượt chuyển thành đơn hàng.

Phân biệt Click Conversion Rate và Lead Conversion Rate

- **Click Conversion Rate (CVR)**:

$$\text{CVR} = \frac{\text{Conversions}}{\text{Clicks}}$$

đo tỷ lệ từ tầng **Interest** đến tầng **Conversion**, tức là đi qua hai tầng:

$$\text{Interest} \rightarrow \text{Consideration} \rightarrow \text{Conversion}.$$

Đây là chỉ số thường dùng hơn trong phân tích hiệu quả quảng cáo và hiệu quả trang bán hàng.

- **Lead Conversion Rate**:

$$\text{Lead Conversion Rate} = \frac{\text{Conversions}}{\text{Leads}}$$

đo tỷ lệ từ tầng **Consideration** đến tầng **Conversion**. Chỉ số này hữu ích khi bài toán có bước thu thập các Lead, ví dụ khách hàng để lại số điện thoại, email hoặc thông tin tư vấn trước khi mua.

5. Cost Per Acquisition (Chi phí trên mỗi lượt chuyển đổi)

Chi phí trên mỗi lượt chuyển đổi (CPA - Cost Per Acquisition) cho biết cần bỏ ra bao nhiêu tiền để có được một đơn hàng thành công.

$$\text{CPA} = \text{Acquisition_Cost}$$

Ví dụ: CPA = 100 nghĩa là cần chi 100 đơn vị để có 1 khách hàng.

Cách diễn giải CPA

- **CPA thấp** thể hiện chi phí tối ưu, chiến dịch hiệu quả.
- **CPA cao**: phải chi nhiều tiền cho mỗi khách hàng, cho thấy chưa tạo đủ giá trị so với chi phí.

Insight: CPA chỉ có ý nghĩa khi đặt cạnh giá trị đơn hàng (AOV - Average Order Value) hoặc doanh thu (Revenue). Một chiến dịch có CPA cao vẫn có thể tốt nếu khách hàng mang lại giá trị lớn (giá trị đơn hàng cao hoặc khách hàng mua lại nhiều lần).

6. Return on Investment (Tỷ suất hoàn vốn)

Tỷ suất hoàn vốn (ROI - Return on Investment) là chỉ số tổng thể, trả lời câu hỏi cuối cùng, khi bỏ ra 1 đồng, thu về bao nhiêu đồng lợi nhuận?

$$\text{ROI} = \frac{\text{Revenue} - \text{Total_Spend}}{\text{Total_Spend}}$$

Ví dụ: chi 1 triệu, thu về 7 triệu thì ROI = 6.

Cách diễn giải ROI

- **ROI > 0** doanh thu vượt chi phí, thể hiện chiến dịch có lãi.
- **ROI < 0** thu về ít hơn chi phí, thể hiện chiến dịch đang lỗ.

Insight: ROI là kết quả tổng hợp của toàn bộ phễu, chỉ cần một khâu kém (CTR, Conversion, CPA) cũng có thể kéo ROI xuống. Không nên tối ưu ROI một cách trực tiếp vì đây chỉ là chỉ số kết quả. Thay vào đó, cần xác định KPI yếu nhất trong phễu (CTR, Lead Rate, Conversion hoặc CPA) và cải thiện tại đó; ROI sẽ tăng theo.

Các loại chiến dịch marketing

Ngoài các KPI, hiệu quả còn phụ thuộc vào loại chiến dịch. Bộ dữ liệu chia dữ liệu thành 5 loại chiến dịch (Campaign_Type), mỗi loại có đặc điểm riêng về chi phí và cách tiếp cận khách hàng. Hiểu đặc điểm của từng loại là cơ sở để giải thích sự khác biệt về ROI và CPA giữa chúng ở các phần sau.

Loại chiến dịch	Mô tả	Đặc điểm chi phí
Paid Ads	Quảng cáo trả phí trên Google Ads, Facebook Ads, Instagram Ads... Doanh nghiệp trả tiền để hiển thị quảng cáo đến đối tượng mục tiêu, thanh toán theo lượt click (CPC) hoặc lượt hiển thị (CPM).	Chi phí rõ ràng, đo lường trực tiếp. Tiếp cận nhóm khách hàng đã có nhu cầu tìm kiếm nên tỷ lệ chuyển đổi thường cao.
Social Media	Xây dựng nội dung và cộng đồng trên Facebook, Instagram, TikTok... Bao gồm cả bài đăng tự nhiên (organic) lẫn bài quảng cáo (promoted).	Kết hợp chi phí sản xuất nội dung và chi phí quảng cáo. CTR thường cao nhờ tính tương tác của nền tảng.
Email	Gửi email khuyến mãi, bản tin, hoặc remarketing đến danh sách khách hàng đã đăng ký.	Chi phí thấp nhất trong các kênh. Hiệu quả cao vì người nhận đã biết thương hiệu (warm audience).
SEO	Tối ưu hóa nội dung website để xuất hiện tự nhiên trên kết quả tìm kiếm Google (không trả phí cho mỗi click).	Chi phí chủ yếu là nhân sự và nội dung. Hiệu quả tích lũy theo thời gian chậm ban đầu nhưng bền vững.
Influencer	Hợp tác với KOL (Key Opinion Leader) hoặc KOC (Key Opinion Consumer) để quảng bá sản phẩm qua nội dung cá nhân.	Chi phí cao (phí hợp tác + sản xuất nội dung). Tạo niềm tin thông qua người ảnh hưởng, khách hàng thường có giá trị đơn hàng cao.

Phần phân tích ở các mục sau cho thấy không có một kênh nào sẽ là tốt nhất cho mọi thương hiệu. Xét về ROI ngắn hạn, Paid Ads đạt hiệu quả cao nhất. Xét về giá trị đơn hàng từ đúng tệp khách hàng mục tiêu, Influencer hiệu quả hơn. Ngoài ra, mỗi thương hiệu có một kênh riêng: Nykaa hiệu quả nhất ở Social Media, còn Tira Beauty đạt kết quả tối ưu ở Paid Ads. Do đó, chiến lược phân bổ ngân sách cần dựa trên thế mạnh cốt lõi của từng thương hiệu, thay vì phân bổ đều cho mọi kênh.

VI. Các câu hỏi trung tâm

Một bài toán phân tích tốt bắt đầu từ một câu hỏi trung tâm rõ ràng, không phải từ dữ liệu. Vì vậy, khi đã xác định đúng câu hỏi, việc lựa chọn số liệu để phân tích mới có định hướng và chính xác. Trong dự án này, câu hỏi trung tâm là:

"Trong năm vừa qua, ba thương hiệu của chúng ta đã chi hàng chục nghìn chiến dịch trên nhiều nền tảng. Vậy tiền đó có đang được dùng đúng chỗ không, và năm tới nên phân bổ thế nào?"

Để giải quyết vấn đề này một cách hệ thống, chúng ta cần cụ thể hóa thành ba trụ cột (pillar)

phân tích trọng tâm. Mỗi trụ cột sẽ đại diện cho một cấp độ ra quyết định khác nhau, bao gồm: đo lường tổng thể, chẩn đoán nguyên nhân và đề xuất giải pháp hành động.

Pillar 1: So sánh hiệu quả giữa các thương hiệu

Câu hỏi kinh doanh

Thương hiệu nào đang tạo ra lợi nhuận tốt nhất trên cùng một đồng ngân sách bỏ ra? Sự chênh lệch đó đến từ đâu?

Một brand có tổng doanh thu cao hơn chưa chắc hiệu quả hơn nếu chi phí bỏ ra cũng cao hơn tương ứng. Vì vậy, đơn vị đo lường chuẩn ở đây là **ROI có trọng số** (weighted ROI): cứ bỏ ra 1 đồng marketing, thu về bao nhiêu đồng lợi nhuận. Câu trả lời cho Pillar 1 đặt nền tảng cho toàn bộ phân tích tiếp theo.

Pillar 2: Chẩn đoán hiệu quả theo kênh và loại chiến dịch

Câu hỏi kinh doanh

Loại chiến dịch nào và kênh nào đang hoạt động hiệu quả nhất? Mỗi thương hiệu có điểm mạnh riêng ở loại hình nào?

Pillar này đi sâu vào câu hỏi tại sao thay vì chỉ dừng ở tìm hiểu về cái gì như trong Pillar 1. Một thương hiệu có ROI cao có thể vì họ đang chạy đúng loại chiến dịch phù hợp với tệp khách hàng của mình hoặc đơn giản là vì họ tránh được những kênh có chi phí cao nhưng chuyển đổi thấp.

Pillar này cũng khai thác **Marketing Funnel**: nếu một chiến dịch có tỷ lệ truy cập cao nhưng tỷ lệ mua hàng thấp, vấn đề không nằm ở quảng cáo mà nằm ở trải nghiệm sau click. Đây là sự phân biệt quan trọng vì giải pháp cho hai trường hợp này hoàn toàn khác nhau, với một bên là điều chỉnh nội dung quảng cáo, một bên là cải thiện trang bán hàng.

Pillar 3: Phân bổ ngân sách tối ưu cho năm tới

Câu hỏi kinh doanh

Nếu ngân sách năm tới tăng thêm, nên ưu tiên thương hiệu nào, kênh nào, loại chiến dịch nào để tối đa hóa lợi nhuận?

Đây là một nội dung quan trọng trong việc tối ưu hóa chiến lược phân bổ ngân sách marketing. Mặc dù ROI cao hoặc CPA thấp phản ánh hiệu quả của một thương hiệu hoặc kênh truyền thông tại thời điểm đánh giá, nhưng các chỉ số này chưa đủ để kết luận rằng toàn bộ ngân sách nên được tập trung vào các đối tượng đó. Việc ra quyết định còn cần cân nhắc đến khả năng mở rộng quy mô, mức độ bão hòa và tính bền vững của từng kênh. Vì vậy, Pillar 3 tập trung phân tích cấu trúc tổng thể của danh mục chiến dịch nhằm xác định tỷ lệ chiến dịch mang lại lợi nhuận, tỷ lệ chiến dịch hoạt động kém hiệu quả, đồng thời nhận diện các đặc điểm chung phân biệt giữa các chiến dịch thành công và chưa thành công.

Ba Pillar này hình thành một quy trình phân tích liên tục từ đo lường hiệu quả, xác định nguyên nhân đến đề xuất các hành động cải thiện. Cách tiếp cận này nhấn mạnh vai trò của nhà phân tích trong việc không chỉ tổng hợp và báo cáo dữ liệu mà còn khai thác các thông tin hữu ích nhằm hỗ trợ việc ra quyết định dựa trên dữ liệu (data-driven decision-making).

VII. Chuẩn bị dữ liệu: Từ CSV đến MySQL

Trong quy trình phân tích dữ liệu, giai đoạn tiền xử lý (data preprocessing) đóng vai trò quan trọng nhằm đảm bảo dữ liệu đáp ứng các yêu cầu về chất lượng trước khi phân tích. Phần này trình bày quy trình nhập dữ liệu từ ba tệp CSV vào MySQL, đánh giá chất lượng dữ liệu và thực hiện các bước làm sạch để tạo lập bộ dữ liệu sẵn sàng cho việc tính toán KPI và các phân tích tiếp theo.

VII.1. Tạo database và bảng

Mở MySQL Workbench và kết nối đến MySQL Server và thực hiện chạy các lệnh dưới đây.

Tạo database và bảng campaigns

```
-- Tao database moi cho Project 1
CREATE DATABASE IF NOT EXISTS marketing_analytics;
USE marketing_analytics;

-- Tao bang chua du lieu campaign (gop ca 3 brands)
CREATE TABLE IF NOT EXISTS campaigns (
    Campaign_ID         VARCHAR(20),    -- chua dat PRIMARY KEY: du lieu tho con trung
    Brand               VARCHAR(20),
    Campaign_Type       VARCHAR(50),
    Target_Audience     VARCHAR(100),
    Duration            INT,
    Channel_Used        VARCHAR(200),
    Impressions         INT,
    Clicks              INT,
    Leads               INT,
    Conversions         INT,
    Revenue             INT,
    Acquisition_Cost    DECIMAL(10, 2),
    ROI                 DECIMAL(10, 4),
    Language            VARCHAR(50),
    Engagement_Score    DECIMAL(5, 2),
    Customer_Segment    VARCHAR(100),
    Campaign_Date       DATE
);
```

Trong quá trình tạo bảng và nhập dữ liệu cần lưu ý một số điểm được để cập sau đây.

- **Campaign_ID chưa** được đặt làm `PRIMARY KEY` ngay khi tạo bảng do dữ liệu thô còn 300 bản ghi trùng lặp (được phát hiện ở bước EDA). Nếu thiết lập khóa chính ở giai đoạn này,

quá trình import sẽ phát sinh lỗi *Duplicate entry*. `PRIMARY KEY` sẽ được bổ sung ở Bước 7 sau khi dữ liệu được làm sạch và còn lại 165.525 bản ghi duy nhất.

- **Brand** là cột được bổ sung, không có trong tệp CSV gốc. Giá trị của cột này sẽ được gán tương ứng trong quá trình nhập dữ liệu của từng tệp.
- **Campaign_Date** sử dụng kiểu dữ liệu `DATE`. Do dữ liệu trong tệp CSV được lưu dưới dạng chuỗi theo định dạng `DD-MM-YYYY`, giá trị sẽ được chuyển đổi bằng hàm `STR_TO_DATE()` trong quá trình import.
- **Revenue** sử dụng kiểu dữ liệu `INT` vì toàn bộ giá trị doanh thu trong bộ dữ liệu đều là số nguyên.

VII.2. Import 3 file CSV vào MySQL

Vì dataset có 3 file riêng, chúng ta import từng file và thêm cột Brand.

Cách 1: Dùng MySQL Workbench GUI (khuyến nghị cho người mới)

1. Click phải vào bảng `campaigns` → **Table Data Import Wizard**.
2. Chọn file `nykaa_campaign_data.csv`.
3. Mapping cột: bỏ trống cột Brand (sẽ update sau), map `Date` → `Campaign\_Date`.
4. Nhấn **Next** → **Finish**.

! Import Wizard và kiểu DATE

Table Data Import Wizard có thể không tự convert `DD-MM-YYYY` sang kiểu `DATE`. Nếu gặp lỗi, tạm đổi `Campaign_Date` thành `VARCHAR(20)`, import xong rồi convert sau:

```
ALTER TABLE campaigns MODIFY Campaign_Date VARCHAR(20);
-- Import data ...
UPDATE campaigns
SET Campaign_Date = STR_TO_DATE(Campaign_Date, '%d-%m-%Y');
ALTER TABLE campaigns MODIFY Campaign_Date DATE;
```

Sau khi import, cập nhật Brand cho các dòng vừa thêm:

```
-- Gan Brand cho Nykaa (nhan biet qua prefix Campaign_ID)
UPDATE campaigns SET Brand = 'Nykaa'
WHERE Campaign_ID LIKE 'NY-%' AND Brand IS NULL;

-- Lap lai cho Purplle va Tira Beauty
UPDATE campaigns SET Brand = 'Purplle'
WHERE Campaign_ID LIKE 'PU-%' AND Brand IS NULL;

UPDATE campaigns SET Brand = 'Tira Beauty'
```

```
WHERE Campaign_ID LIKE 'TI-%' AND Brand IS NULL;
```

Cách 2: Dùng LOAD DATA (nhanh hơn)

Import bằng LOAD DATA LOCAL INFILE

```
LOAD DATA LOCAL INFILE 'duong_dan/nykaa_campaign_data.csv'
INTO TABLE campaigns
FIELDS TERMINATED BY ',' ENCLOSED BY '"'
LINES TERMINATED BY '\n'
IGNORE 1 ROWS
(Campaign_ID, Campaign_Type, Target_Audience, Duration,
 Channel_Used, Impressions, Clicks, Leads, Conversions,
 Revenue, Acquisition_Cost, ROI, Language,
 Engagement_Score, Customer_Segment, @date_raw)
SET Campaign_Date = STR_TO_DATE(@date_raw, '%d-%m-%Y');

UPDATE campaigns SET Brand = 'Nykaa'
WHERE Campaign_ID LIKE 'NY-%' AND Brand IS NULL;
-- Tuong tu cho Purplle va Tira Beauty
```

Giải thích kỹ thuật:

- **@date_raw** là biến tạm (user-defined variable) trong MySQL, được sử dụng để nhận giá trị ngày tháng dưới dạng chuỗi từ tệp CSV, ví dụ: `29-04-2025` từ CSV.
- **STR_TO_DATE** là hàm chuyển đổi dữ liệu từ kiểu chuỗi (text/string) sang kiểu `DATE`. Trong ví dụ này, định dạng `'%d-%m-%Y'` được sử dụng, trong đó `%d` = biểu thị ngày, `%m` = biểu thị tháng, `%Y` = biểu thị cho năm gồm bốn chữ số.

Các lỗi thường gặp khi nhập dữ liệu

Trong quá trình nhập dữ liệu bằng lệnh `LOAD DATA LOCAL INFILE`, có thể phát sinh một số lỗi phổ biến. Các lỗi này thường xuất hiện theo thứ tự như ở bảng 1.

Danh sách kiểm tra trước khi khắc phục lỗi

1. Xác nhận đã thực thi lệnh `USE marketing_analytics;`
2. Xác nhận đã bật local_infile bằng lệnh `SET GLOBAL local_infile = 1;`
3. Xác nhận đã cấu hình `OPT_LOCAL_INFILE=1` trong MySQL Workbench.
4. Xác nhận đã Disconnect và Reconnect sau khi thay đổi cấu hình.
5. Kiểm tra đường dẫn của tệp CSV; tránh sử dụng đường dẫn chứa ký tự đặc biệt hoặc quá dài.

Lỗi	Nguyên nhân	Cách sửa
Error 3948: Loading local data is disabled	MySQL 8+ tắt `local_infile` mặc định	`SET GLOBAL local_infile = 1;` + thêm `OPT_LOCAL_INFILE=1` trong Workbench Advanced → Others
Error 2068: File request rejected	Client chưa bật quyền truy cập file	Kiểm tra `OPT_LOCAL_INFILE=1`, **disconnect rồi reconnect**
Error 1046: No database selected	Quên chạy lệnh `USE`	`USE marketing_analytics;` trước khi import
Dữ liệu bị lệch dòng	File CSV trên Windows dùng `\r \n`	Đổi `LINES TERMINATED BY '\r \n '`

Bảng 1: Các lỗi thường gặp khi nạp dữ liệu vào MySQL và hướng khắc phục

Kiểm tra import thành công

```sql
-- Dem tong so dong (ky vong = 166.815, du lieu chua lam sach)
SELECT COUNT(*) AS total_rows FROM campaigns;

-- Dem theo Brand (ky vong = 55.605 moi brand)
SELECT Brand, COUNT(*) AS rows_count
FROM campaigns GROUP BY Brand;
```

Nếu `total_rows` = 166.815 và mỗi brand có 55.605 dòng thì import thành công. Con số 55.605 thay vì 55.555 (con số gốc) cho thấy dataset đã có **dữ liệu trùng lặp**: 50 Campaign_ID bị duplicate ở mỗi brand.

VII.3. Khám phá dữ liệu (EDA)

Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA) là bước đầu tiên trong quy trình phân tích dữ liệu. Mục tiêu của EDA là tìm hiểu đặc điểm của bộ dữ liệu, đánh giá chất lượng dữ liệu và phát hiện các vấn đề cần xử lý trước khi thực hiện các phân tích hoặc tính toán chỉ số KPI.

1. Kiểm tra giá trị unique

Khi tổng hợp số liệu theo loại campaign (`GROUP BY Campaign\_Type`), MySQL phân biệt chính xác từng ký tự: `'Email'` và `' Email '` (có khoảng trắng thừa) là *hai giá trị khác nhau*. Điều này dẫn đến những nhóm campaign sai lệch.

```sql
SELECT DISTINCT Campaign_Type FROM campaigns;
SELECT DISTINCT Language FROM campaigns;
SELECT DISTINCT Customer_Segment FROM campaigns;
```

`DISTINCT` loại bỏ giá trị trùng lặp. Kỳ vọng chỉ có 5 loại Campaign_Type, nhưng kết quả trả về **20 giá trị**! Lý do: một số giá trị có **khoảng trắng thừa** ở đầu/cuối, ví dụ `'  Social Media'` (2 dấu cách đầu) và `'Social Media'` bị coi là 2 giá trị khác nhau.

! Hệ quả với phân tích marketing

Nếu không thực hiện bước chuẩn hóa, bảng KPI theo loại chiến dịch có thể xuất hiện 20 nhóm thay vì 5 nhóm như mong đợi. Khi đó, doanh thu của cùng một loại chiến dịch (ví dụ: "Email") sẽ bị phân tách vào nhiều nhóm khác nhau, dẫn đến kết quả tổng hợp và đánh giá hiệu quả chiến dịch không còn chính xác.

2. Kiểm tra NULL

```sql
SELECT
  SUM(CASE WHEN Impressions IS NULL THEN 1 ELSE 0 END)
    AS null_impressions,
  SUM(CASE WHEN Clicks IS NULL THEN 1 ELSE 0 END)
    AS null_clicks,
  SUM(CASE WHEN Revenue IS NULL THEN 1 ELSE 0 END)
    AS null_revenue,
  SUM(CASE WHEN Acquisition_Cost IS NULL THEN 1 ELSE 0 END)
    AS null_acq_cost
FROM campaigns;
```

Kết quả:

null_imp	null_clicks	null_leads	null_conv	null_rev	null_acq
96	100	93	100	93	118

Bảng 2: Kết quả thống kê số lượng giá trị thiếu (NULL)

Tổng cộng **600 ô NULL** phân bố trong các cột số liệu.

Ví dụ về ảnh hưởng của giá trị NULL: Giả sử chiến dịch `PU-CMP-2050` có `Impressions = NULL`, khi đó:

- Chỉ số CTR không thể tính toán (CTR = Clicks/NULL = NULL), vì vậy bản ghi sẽ bị loại khỏi phép tính `AVG(CTR)`
- Hàm `SUM(Impressions)` không cộng giá trị của bản ghi này, khiến tổng số Impressions không phản ánh đầy đủ dữ liệu thực tế (không ghi nhận được giá trị hoặc giá trị bằng 0).
- Trong khi đó, `COUNT(*)`vẫn tính bản ghi vào tổng số chiến dịch, làm cho các chỉ tiêu tổng hợp có thể không phản ánh chính xác dữ liệu thực tế.

3. Kiểm tra duplicate

```sql
SELECT Campaign_ID, COUNT(*) AS dup_count
FROM campaigns
GROUP BY Campaign_ID
HAVING COUNT(*) > 1
ORDER BY dup_count DESC
LIMIT 10;
```

Có **150 Campaign_ID** bị trùng (mỗi brand 50 ID), tổng cộng **300 dòng trùng**. Ví dụ:

Campaign_ID	dup_count
NY-CMP-10123	2
PU-CMP-40012	2
TI-CMP-80045	2

Bảng 3: Ví dụ Campaign_ID bị trùng lặp

Ví dụ về ảnh hưởng của dữ liệu trùng lặp: Giả sử chiến dịch `NY-CMP-10123` có Revenue = 1.500.000 và xuất hiện hai lần trong tập dữ liệu, khi đó:

- Hàm `SUM(Revenue)` sẽ tính thành 3.000.000 thay vì 1.500.000.
- Các chỉ số tổng hợp như Revenue và ROI của thương hiệu sẽ bị tính cao hơn giá trị thực tế, dẫn đến kết quả phân tích thiếu chính xác.
- Nếu tồn tại nhiều bản ghi trùng lặp (ví dụ: 150 Campaign_ID), sai số của tổng doanh thu có thể trở nên đáng kể, làm ảnh hưởng đến độ tin cậy của các kết quả phân tích.

4. Kiểm tra logic funnel

Marketing funnel có quy tắc: **Impressions** $\geq$ **Clicks** $\geq$ **Leads** $\geq$ **Conversions**. Nếu Clicks $>$ Impressions, dữ liệu có vấn đề.

```sql
SELECT
  SUM(CASE WHEN Clicks > Impressions THEN 1 ELSE 0 END)
    AS clicks_gt_impressions,
  SUM(CASE WHEN Leads > Clicks THEN 1 ELSE 0 END)
    AS leads_gt_clicks,
  SUM(CASE WHEN Conversions > Leads THEN 1 ELSE 0 END)
    AS conversions_gt_leads
FROM campaigns
WHERE Impressions IS NOT NULL
  AND Clicks IS NOT NULL;
```

Kết quả có 375 dòng vi phạm logic funnel.

clicks > impressions	leads > clicks	conv > leads
177	99	99

Bảng 4: Số dòng vi phạm logic funnel

Ví dụ cụ thể: Một campaign có Impressions = 3.000 nhưng Clicks = 5.000. Điều này là bất khả thi: người dùng phải nhìn thấy quảng cáo trước mới click được.

- CTR = 5.000/3.000 = 166,7%, một con số vô nghĩa
- Tương tự, Leads > Clicks nghĩa là "có nhiều người đăng ký hơn người click", điều này chỉ xảy ra khi dữ liệu bị lỗi

5. Kiểm tra giá trị âm

```sql
SELECT
  SUM(CASE WHEN Impressions < 0 THEN 1 ELSE 0 END)
    AS neg_impressions,
  SUM(CASE WHEN Revenue < 0 THEN 1 ELSE 0 END)
    AS neg_revenue
FROM campaigns;
```

Kết quả:

neg_impressions	neg_revenue
75	75

Bảng 5: Số dòng có giá trị âm

150 dòng có giá trị âm.

Ví dụ về ảnh hưởng của giá trị âm: Giả sử một bản ghi có `Impressions = -500` hoặc `Revenue = -120.000`. Các giá trị này không phù hợp với quy tắc nghiệp vụ của bộ dữ liệu vì không phản ánh các sự kiện quảng cáo thực tế. Nếu được đưa vào phân tích, chúng sẽ làm sai lệch các chỉ số thống kê như giá trị trung bình (AVG), đồng thời ảnh hưởng đến tính chính xác của các KPI và kết quả phân tích tổng hợp.

6. Kiểm tra ngày không hợp lệ

```sql
-- Ngay khong parse duoc
SELECT Campaign_Date, COUNT(*) AS cnt
FROM campaigns
WHERE Campaign_Date IS NOT NULL
  AND STR_TO_DATE(Campaign_Date, '%d-%m-%Y') IS NULL
GROUP BY Campaign_Date;
```

64 dòng có ngày không hợp lệ: tháng 13 (`31-13-2025`), ngày 29/02/2025 (không phải năm nhuận), sai format (`15/06/2025` dùng `/` thay vì `-`), giá trị text (`N/A`, `TBD`). Thêm 18 dòng có ngày ngoài phạm vi (năm 1999 và 2030).

7. Tổng hợp vấn đề chất lượng dữ liệu

Vấn đề	Số dòng	Tỷ lệ
NULL values (các cột metric)	600	~0,4%
Duplicate Campaign_ID	300*	~0,2%
Vi phạm logic funnel	375	~0,2%
Giá trị âm (Impressions, Revenue)	150	~0,1%
Ngày không hợp lệ	82	~0,05%
Whitespace trong cột text	240	~0,1%

Bảng 6: Tổng hợp 6 loại lỗi chất lượng dữ liệu

Ở bảng trên, 150 Campaign_ID xuất hiện hai lần (300 lượt). Do đó, bước cleaning sẽ xóa 150 dòng thừa, giữ lại một bản cho mỗi ID.

Tổng cộng khoảng **1% dữ liệu bị lỗi**. Tỷ lệ nhỏ nhưng nếu không xử lý, những bản trùng lặp khiến `SUM(Revenue)` tính gấp đôi, giá trị âm kéo `AVG(Impressions)` xuống, funnel errors tạo ra CTR $>$ 100%.

EDA trước, phân tích sau

Trong thực tế, dataset thường có 5–20% dữ liệu bẩn. Luôn chạy EDA trước khi phân tích. Nếu bỏ qua bước này, insight rút ra từ dữ liệu bẩn sẽ dẫn đến quyết định sai.

VII.4. Xử lý dữ liệu (Data Cleaning)

Trước khi đi vào từng bước, hãy xem tổng quan bức tranh dữ liệu bẩn và quy trình xử lý như được mô tả ở hình 3 sau.

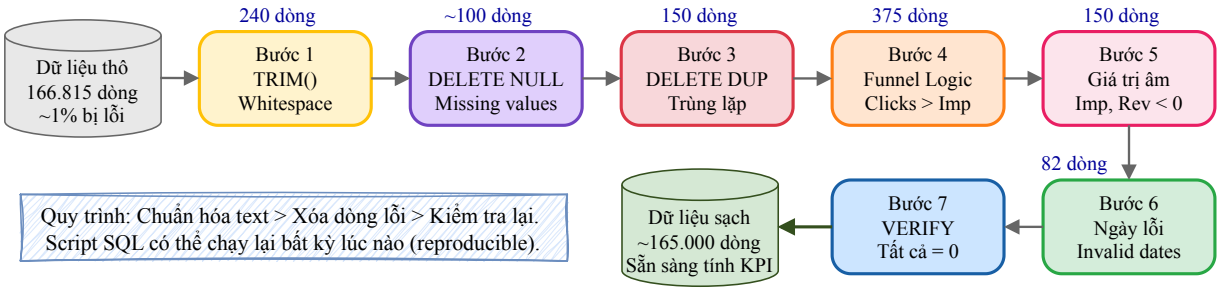

Hình 3: Data Cleaning Pipeline: 7 bước từ dữ liệu bẩn đến dữ liệu sạch.

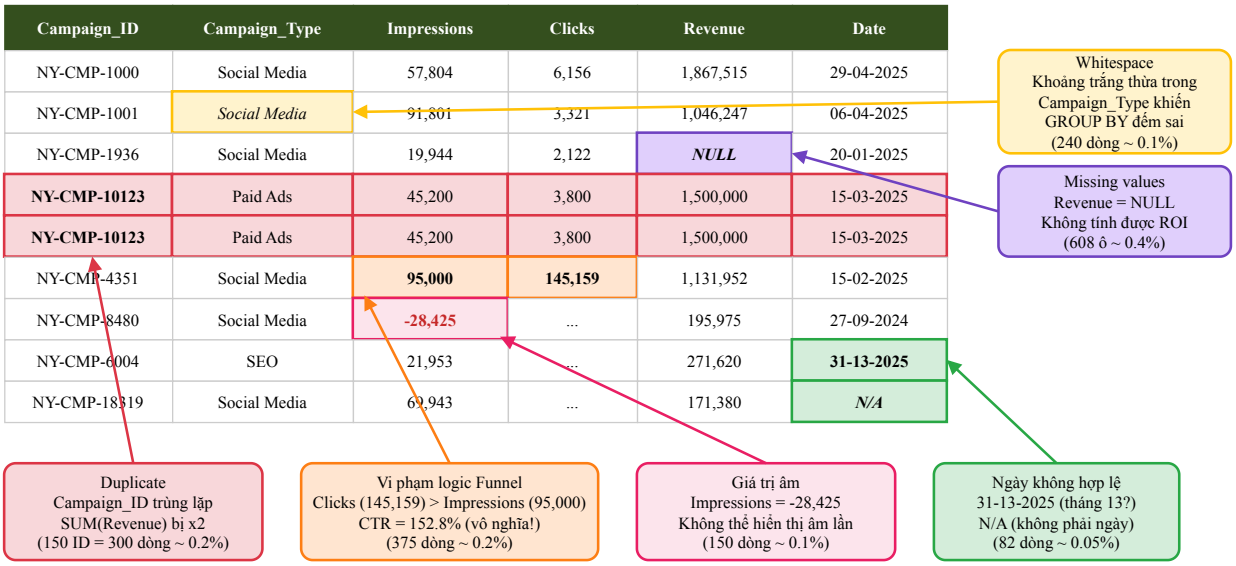

Hình 4: Tổng quan các loại lỗi dữ liệu trong dataset campaigns. Tổng cộng có khoảng 1% dữ liệu bị lỗi (1.755 / 166.815 dòng). Tỷ lệ nhỏ nhưng hệ quả lớn nếu không xử lý.

EDA phát hiện 6 loại vấn đề. Giờ chúng ta xử lý từng loại bằng SQL, đi từ đơn giản đến phức tạp.

Bước 1: Xử lý whitespace bằng TRIM()

Vấn đề: Khi `GROUP BY Campaign_Type`, MySQL coi `'  Email  '` (có khoảng trắng) và `'Email'` là hai nhóm khác nhau. Doanh thu của cùng một loại campaign bị tách ra làm hai.

Giải pháp: Sử dụng hàm `TRIM()` xóa khoảng trắng ở đầu và cuối chuỗi của dữ liệu. Ví dụ kết quả trước và sau khi sử dụng hàm `TRIM()` thể hiện qua bảng dưới đây.

Trước TRIM()	Sau TRIM()
`'  Social Media'`	`'Social Media'`
`'Email  '`	`'Email'`
`'  Paid Ads  '`	`'Paid Ads'`

```
UPDATE campaigns SET Campaign_Type   = TRIM(Campaign_Type);
UPDATE campaigns SET Language         = TRIM(Language);
UPDATE campaigns SET Customer_Segment = TRIM(Customer_Segment);
UPDATE campaigns SET Target_Audience  = TRIM(Target_Audience);
```

Xác thực kết quả sau khi xử lý chúng ta thực hiện chạy lại `SELECT DISTINCT Campaign_Type` sẽ chỉ còn 5 giá trị (thay vì 20).

Bước 2: Xóa dòng có giá trị NULL

Vấn đề: Khi một bản ghi thiếu giá trị ở các trường như **Impressions** hoặc **Revenue**, nhiều chỉ số KPI (ví dụ: CTR, ROI) sẽ không thể tính toán hoặc cho kết quả không đầy đủ. Điều này có thể làm giảm độ chính xác và tính đầy đủ của kết quả phân tích.

Quyết định: Trong bộ dữ liệu này, tỷ lệ bản ghi thiếu dữ liệu chỉ khoảng 0,4%, vì vậy việc loại bỏ các bản ghi này có ảnh hưởng không đáng kể đến kết quả phân tích. Đối với các bộ dữ liệu có tỷ lệ thiếu dữ liệu cao hơn, cần cân nhắc các phương pháp xử lý khác, chẳng hạn như nội suy (imputation) bằng giá trị trung bình, trung vị hoặc các phương pháp phù hợp khác, nhằm hạn chế việc mất mát dữ liệu.

```
DELETE FROM campaigns
WHERE Impressions IS NULL
   OR Clicks IS NULL
   OR Leads IS NULL
   OR Conversions IS NULL
   OR Revenue IS NULL
   OR Acquisition_Cost IS NULL;
```

Xóa vs Điền giá trị (Imputation)

Có hai phương pháp phổ biến để xử lý giá trị NULL: (1) loại bỏ bản ghi khi tỷ lệ dữ liệu thiếu thấp (<5%) và không ảnh hưởng đáng kể đến kết quả phân tích; (2) điền giá trị (trung bình, trung vị) khi cần bảo toàn dữ liệu. Trong bộ dữ liệu này, tỷ lệ giá trị thiếu chỉ khoảng 0,4%, vì vậy phương pháp loại bỏ được lựa chọn.

Bước 3: Xóa duplicate

Vấn đề: EDA phát hiện 150 Campaign_ID xuất hiện 2 lần. Nếu giữ lại, mỗi chỉ số `SUM` đều bị tính gấp đôi.

Giải pháp: Giữ lại 1 bản cho mỗi Campaign_ID bị trùng. Ưu tiên giữ dòng có **Duration nhỏ hơn**; nếu Duration bằng nhau thì giữ **Revenue nhỏ hơn**. Tuy nhiên các dòng trùng ở đây là **bản sao y hệt** (mọi cột bằng nhau), nên cần thêm một khóa thay thế `row_id` để phân định khi hai dòng giống hệt nhau.

```
-- Them khoa thay the de tach cac dong giong het nhau
ALTER TABLE campaigns ADD COLUMN row_id INT AUTO_INCREMENT PRIMARY KEY;

-- Giu Duration nho hon; neu bang thi Revenue nho hon;
-- neu van bang (ban sao y het) thi giu row_id nho nhat
DELETE c1 FROM campaigns c1
INNER JOIN campaigns c2
  ON c1.Campaign_ID = c2.Campaign_ID
WHERE c1.Duration > c2.Duration
   OR (c1.Duration = c2.Duration AND c1.Revenue > c2.Revenue)
   OR (c1.Duration = c2.Duration AND c1.Revenue = c2.Revenue
       AND c1.row_id > c2.row_id);

-- Bo khoa thay the sau khi khu trung xong
ALTER TABLE campaigns DROP COLUMN row_id;
```

! Vì sao chỉ so sánh Duration/Revenue thì không đủ?

Nếu chỉ dùng điều kiện `Duration >` hoặc `Revenue >` mà bỏ `row_id`, thì với các bản sao y hệt sẽ **không dòng nào "lớn hơn" dòng nào**, nên query **không xóa được gì** (kiểm chứng thực tế: 150 ID trùng vẫn còn nguyên). Khóa thay thế `row_id` là tiêu chí phân định cuối cùng để chắc chắn mỗi Campaign_ID chỉ còn 1 dòng.

Nếu cách trên phức tạp, có thể dùng phương pháp tạo bảng tạm:

```
-- Cach 2: bang tam + INSERT IGNORE
-- Phai dat PRIMARY KEY cho bang tam thi INSERT IGNORE moi khu duoc trung
CREATE TABLE campaigns_tmp LIKE campaigns;
ALTER TABLE campaigns_tmp ADD PRIMARY KEY (Campaign_ID);
INSERT IGNORE INTO campaigns_tmp
```

```
SELECT * FROM campaigns
ORDER BY Campaign_ID, Campaign_Date;

DROP TABLE campaigns;
RENAME TABLE campaigns_tmp TO campaigns;
-- Cach nay da dat san PRIMARY KEY -> co the bo qua viec dat PK o Buoc 7
```

Thực hiện kiểm tra kết quả, thực hiện chạy lại query kiểm tra duplicate, kết quả phải trống (không còn Campaign_ID nào xuất hiện > 1 lần).

Bước 4: Xóa dòng vi phạm logic funnel

Vấn đề: Một số dòng có số Clicks lớn hơn Impressions. Về mặt nghiệp vụ những điều này không thể xảy ra như người dùng phải *nhìn thấy* quảng cáo (impression) rồi mới click được. Không thể **sửa** các dòng này vì không biết giá trị đúng là gì (Impressions thiếu hay Clicks thừa?).

! Tại sao xóa thay vì sửa?

Khi dữ liệu vi phạm logic cơ bản của domain (như funnel), không có cách nào biết giá trị nào sai. Nếu đoán bừa (ví dụ "chắc Impressions bị thiếu"), chúng ta đang *tạo ra dữ liệu giả*. Tốt hơn là xóa và chấp nhận mất 375 dòng (0,2% dữ liệu) để giữ nguyên tính chính xác của 99,8% còn lại.

```
DELETE FROM campaigns
WHERE Clicks > Impressions
   OR Leads > Clicks
   OR Conversions > Leads;
```

Bước 5: Xóa dòng có giá trị âm

Vấn đề: Một chiến dịch không thể có -500 lượt hiển thị, cũng không thể tạo ra doanh thu -120.000. Đây là dữ liệu bị lỗi từ nguồn (có thể do hệ thống tracking ghi sai, hoặc lỗi chuyển đổi định dạng).

```
DELETE FROM campaigns
WHERE Impressions < 0
   OR Revenue < 0;
```

Kiểm tra sau khi xóa, thực hiện chạy kiểm tra `SELECT MIN(Impressions), MIN(Revenue) FROM campaigns` phải trả về giá trị ≥ 0.

Bước 6: Xử lý ngày không hợp lệ

Vấn đề: Một số dòng có ngày không tồn tại trên lịch. Ví dụ bảng 7 sau.

Giá trị sai	Lý do
`31-13-2025`	Tháng 13 không tồn tại
`29-02-2025`	2025 không phải năm nhuận
`15/06/2025`	Sai format (`/` thay vì `-`)
`N/A`, `TBD`	Giá trị text, không phải ngày
`01-05-1999`	Ngoài phạm vi dữ liệu (2024–2025)

Bảng 7: Ví dụ các dạng ngày không hợp lệ trong dữ liệu

Giải pháp: Nếu Campaign_Date vẫn là `VARCHAR` (chưa convert sang `DATE` khi import), xóa các dòng không parse được và ngoài phạm vi:

```sql
-- Xoa ngay khong parse duoc (chi ap dung khi cot la VARCHAR)
DELETE FROM campaigns
WHERE Campaign_Date IS NOT NULL
  AND STR_TO_DATE(Campaign_Date, '%d-%m-%Y') IS NULL;

-- Xoa ngay ngoai pham vi
DELETE FROM campaigns
WHERE STR_TO_DATE(Campaign_Date, '%d-%m-%Y') IS NOT NULL
  AND (STR_TO_DATE(Campaign_Date, '%d-%m-%Y') < '2024-01-01'
       OR STR_TO_DATE(Campaign_Date, '%d-%m-%Y') > '2025-12-31');
```

MySQL strict mode và STR_TO_DATE

Trên MySQL bật **strict mode** (mặc định ở nhiều bản 8.x), `STR_TO_DATE` khi gặp giá trị sai định dạng sẽ **báo lỗi** (*Incorrect datetime value*) thay vì trả `NULL`, khiến hai lệnh xóa ngày trên dừng giữa chừng. Cách xử lý: chạy `SET SESSION sql_mode='';` trước rồi thực hiện lại hai lệnh xóa.

Lưu ý

Nếu đã convert Campaign_Date sang kiểu `DATE` khi import (Bước 2), các dòng có ngày sai format sẽ tự động trở thành `NULL`. Trong trường hợp đó, bước xóa NULL (Bước 2) đã xử lý rồi. Chỉ cần xóa ngày ngoài phạm vi: `DELETE FROM campaigns WHERE Campaign_Date < '2024-01-01'OR Campaign_Date > '2025-12-31';`

Bước 7: Verify toàn bộ

Chạy lại EDA để xác nhận dữ liệu đã sạch:

```sql
-- 1. Tong rows
SELECT COUNT(*) AS total_rows FROM campaigns;
```

```
3
4  -- 2. NULL check
5  SELECT
6    SUM(CASE WHEN Impressions IS NULL THEN 1 ELSE 0 END)
7      AS null_imp,
8    SUM(CASE WHEN Revenue IS NULL THEN 1 ELSE 0 END)
9      AS null_rev
10 FROM campaigns;
11
12 -- 3. Duplicate check
13 SELECT COUNT(*) FROM (
14   SELECT Campaign_ID FROM campaigns
15   GROUP BY Campaign_ID HAVING COUNT(*) > 1) t;
16
17 -- 4. Funnel logic check
18 SELECT SUM(CASE WHEN Clicks > Impressions
19   THEN 1 ELSE 0 END) AS errors FROM campaigns;
20
21 -- 5. Negative check
22 SELECT SUM(CASE WHEN Impressions < 0 OR Revenue < 0
23   THEN 1 ELSE 0 END) AS negatives FROM campaigns;
24
25 -- 6. Du lieu da sach -> gio moi dat PRIMARY KEY cho Campaign_ID
26 ALTER TABLE campaigns ADD PRIMARY KEY (Campaign_ID);
```

Tất cả kết quả phải trả về **0**. Nếu còn vấn đề, chạy lại bước tương ứng.

Data Cleaning Pipeline

Trong thực tế, các bước cleaning nên ghi lại thành script SQL có thể chạy lại (*reproducible*). Nếu dataset cập nhật hàng tuần, chỉ cần chạy lại script thay vì làm tay từ đầu.

VII.5. Thống kê mô tả (sau cleaning)

Sau khi dữ liệu sạch, chạy thống kê tổng quan:

```
1  SELECT
2    Brand,
3    COUNT(*)                    AS total_campaigns,
4    ROUND(AVG(Duration), 1)     AS avg_duration,
5    ROUND(AVG(Impressions), 0)  AS avg_impressions,
6    ROUND(AVG(Clicks), 0)       AS avg_clicks,
7    ROUND(AVG(Conversions), 0)  AS avg_conversions,
8    ROUND(SUM(Revenue), 0)      AS total_revenue,
9    ROUND(AVG(ROI), 2)          AS avg_roi
10 FROM campaigns
11 GROUP BY Brand;
```

Kết quả (tính trên 165.525 dòng sau khi làm sạch, 55.175 mỗi brand), theo dõi bảng 8 dưới đây.

Brand	Campaigns	Avg Duration	Avg Impressions	Total Revenue	Avg ROI
Nykaa	55.175	17,5	55.080	28,45B	2,71
Purplle	55.175	17,5	55.086	28,36B	2,68
Tira Beauty	55.175	17,5	55.029	28,25B	2,67

Bảng 8: Thống kê mô tả sau cleaning theo Brand

Ba brand có hiệu suất rất gần nhau. Nykaa nhỉnh hơn chút ở hầu hết chỉ số như avg_clicks cao hơn, total_revenue cao hơn, và avg_roi 2,71 so với 2,67 của Tira Beauty. Trung bình mỗi campaign chạy khoảng 17 ngày, thu được ∼55.000 impressions và ∼1.030 conversions.

Lưu ý

Lưu ý về số lượng bản ghi: Bộ dữ liệu ban đầu gồm 166.815 bản ghi. Sau quá trình loại bỏ dữ liệu trùng lặp và xử lý các bản ghi không đạt yêu cầu (giá trị NULL, vi phạm quy tắc nghiệp vụ, giá trị âm và định dạng ngày không hợp lệ), bộ dữ liệu cuối cùng còn **165.525** bản ghi (55.175 bản ghi cho mỗi thương hiệu). Các chỉ số KPI và kết quả phân tích trong tài liệu đều được tính toán trên bộ dữ liệu đã được làm sạch này.

Dữ liệu giờ đã hoàn toàn sạch để sử dụng, phần tiếp theo sẽ tiến hành tính KPI từ dữ liệu đã chuẩn bị.

VII.6. Tính KPI bằng SQL

Sử dụng các công thức đã học ở phần V, giờ chúng ta viết SQL để tính KPI từ dữ liệu thô.

1. Tính KPI cho từng campaign

```sql
SELECT
  Campaign_ID, Brand, Campaign_Type,
  Impressions, Clicks, Leads, Conversions,
  Revenue, Acquisition_Cost,

  -- Tu tinh KPIs
  ROUND(Clicks / NULLIF(Impressions, 0), 4)
    AS calc_CTR,
  ROUND(Leads / NULLIF(Clicks, 0), 4)
    AS calc_Lead_Rate,
  ROUND(Conversions / NULLIF(Leads, 0), 4)
    AS calc_Conversion_Rate,
  Acquisition_Cost AS calc_CPA,
  ROUND(Acquisition_Cost * Conversions, 2)
    AS calc_Total_Spend,
  ROUND(
    (Revenue - Acquisition_Cost * Conversions)
```

```
    / NULLIF(Acquisition_Cost * Conversions, 0),
    4
  ) AS calc_ROI,

  -- ROI co san trong dataset (de so sanh)
  ROI AS original_ROI
FROM campaigns
LIMIT 20;
```

NULLIF() và xử lý phép chia cho 0

`NULLIF(x, 0)` trả về NULL nếu `x = 0`, ngược lại trả về `x`. Hàm này thường được sử dụng để ngăn ngừa lỗi chia cho 0 khi tính toán các chỉ số KPI. Ví dụ, nếu một chiến dịch có Impressions = 0, phép tính Clicks / Impressions có thể phát sinh lỗi hoặc cảnh báo. Việc sử dụng NULLIF(Impressions, 0) sẽ khiến mẫu số trở thành NULL, từ đó kết quả của phép chia cũng là NULL. Đây là một ví dụ điển hình của lập trình phòng thủ (defensive programming), giúp tăng tính ổn định và khả năng tái sử dụng của các câu lệnh SQL.

Kết quả mẫu (trích 3 dòng đầu):

Campaign_ID	CTR	Lead%	Conv%	CPA	Total Spend	calc_ROI	orig_ROI
NY-CMP-1000	0,1065	0,5874	0,6513	111	261.476	6,14	6,14
NY-CMP-10000	0,0516	0,5396	0,5033	655	98.974	−0,32	−0,32
NY-CMP-10002	0,0749	0,5645	0,7329	24,67	71.888	17,44	17,44

Bảng 9: Kết quả tính toán các chỉ số KPI và đối chiếu ROI của các chiến dịch

Kết quả tính toán cho thấy `calc_ROI` và `original_ROI` gần như trùng khớp; sai khác nhỏ chỉ xuất phát từ việc làm tròn số. Chiến dịch `NY-CMP-10002` có CPA thấp (24,67) và đồng thời đạt ROI = 17,44, phản ánh hiệu quả đầu tư cao. Trong khi đó, chiến dịch `NY-CMP-10000` có CPA cao (655) và ROI = −0,32, cho thấy chi phí đầu tư vượt quá lợi nhuận thu được.

2. KPI tổng hợp theo Brand

```
SELECT
  Brand,
  COUNT(*) AS total_campaigns,
  SUM(Revenue) AS total_revenue,
  SUM(Acquisition_Cost * Conversions) AS total_spend,

  -- KPI tong hop (weighted average)
  ROUND(SUM(Clicks) / SUM(Impressions), 4)
    AS overall_CTR,
  ROUND(SUM(Leads) / SUM(Clicks), 4)
    AS overall_Lead_Rate,
  ROUND(SUM(Conversions) / SUM(Leads), 4)
```

```
    AS overall_Conv_Rate,
  ROUND(SUM(Acquisition_Cost * Conversions)
        / SUM(Conversions), 2)
    AS overall_CPA,
  ROUND(
    (SUM(Revenue) - SUM(Acquisition_Cost * Conversions))
    / SUM(Acquisition_Cost * Conversions),
    4
  ) AS overall_ROI
FROM campaigns
GROUP BY Brand
ORDER BY overall_ROI DESC;
```

! Weighted Average và Simple Average trong tính toán KPI

Khi tính toán các chỉ số KPI ở mức tổng hợp, nên sử dụng `SUM(Clicks) / SUM(Impressions)` thay vì `AVG(Clicks/Impressions)`. Với simple average, một chiến dịch có 1.000 impressions và một chiến dịch chỉ có 1 impressions đều có mức ảnh hưởng như nhau đến kết quả cuối cùng, mặc dù quy mô của chúng rất khác biệt. Trong khi đó, weighted average phản ánh đúng mức đóng góp của từng chiến dịch theo quy mô dữ liệu, nhờ đó kết quả tổng hợp có tính đại diện cao hơn.

Kết quả:

Brand	CTR	Lead%	Conv%	CPA	ROI
Nykaa	0,0851	0,4004	0,5502	169,06	1,9542
Purplle	0,0850	0,3994	0,5497	170,08	1,9382
Tira Beauty	0,0850	0,3992	0,5497	170,39	1,9291

Bảng 10: KPI tổng hợp (weighted average) theo Brand

Nykaa ghi nhận ROI cao nhất với giá trị 1,95, nghĩa là cứ đầu tư 1 đồng chi phí marketing thì tạo ra gần 2 đồng lợi nhuận ròng. Các chỉ số CTR, Lead Conversion Rate và Conversion Rate của cả ba thương hiệu lần lượt dao động quanh 8,5%, 40% và 55%. Nhìn chung, sự khác biệt về hiệu quả giữa các thương hiệu không lớn, với chênh lệch ROI chỉ khoảng 0,02 –0,03 điểm.

Tại sao ROI ở đây (1,95) khác với bảng Thống kê (2,71)?

Bảng Thống kê sử dụng `AVG(ROI)`, , tức trung bình cộng của ROI trên từng chiến dịch. Ngược lại, bảng này tính ROI theo công thức `(SUM(Revenue) - SUM(Spend)) / SUM(Spend)`, tương đương với trung bình có trọng số (weighted average). Cách tính này phản ánh mức đóng góp của từng chiến dịch theo quy mô chi phí, trong khi `AVG` coi mọi chiến dịch có trọng số như nhau. Vì vậy, ROI tổng thể trong bảng này khác với giá trị trung bình trong Bảng Thống kê và phản ánh hiệu quả đầu tư chính xác hơn.

3. KPI theo loại Campaign

```sql
SELECT
  Campaign_Type,
  COUNT(*) AS total_campaigns,
  ROUND(SUM(Clicks) / SUM(Impressions), 4)
    AS overall_CTR,
  ROUND(SUM(Acquisition_Cost * Conversions)
        / SUM(Conversions), 2)
    AS overall_CPA,
  ROUND(
    (SUM(Revenue) - SUM(Acquisition_Cost * Conversions))
    / SUM(Acquisition_Cost * Conversions),
    4
  ) AS overall_ROI
FROM campaigns
GROUP BY Campaign_Type
ORDER BY overall_ROI DESC;
```

Kết quả:

Campaign Type	Campaigns	CTR	CPA	ROI
Paid Ads	33.046	0,0850	169,35	1,9634
Social Media	32.951	0,0853	168,68	1,9535
Email	33.272	0,0850	169,91	1,9411
SEO	32.993	0,0847	170,58	1,9298
Influencer	33.263	0,0852	170,70	1,9148

Bảng 11: KPI theo loại Campaign

Paid Ads đạt ROI cao nhất (1,96), kế đến Social Media (1,95). Influencer có ROI thấp nhất (1,91) và CPA cao nhất (170,70). Social Media có CTR cao nhất (0,0853), cho thấy quảng cáo trên mạng xã hội thu hút click tốt hơn.

4. Phân tích chéo: Brand × Campaign Type

Query này trả lời: *"Nykaa hiệu quả nhất với Social Media hay Paid Ads? Purplle nên đầu tư vào SEO hay Email?"*

```sql
SELECT
  Brand, Campaign_Type,
  COUNT(*) AS campaigns,
  ROUND(SUM(Revenue), 0) AS total_revenue,
  ROUND(
```

```
    (SUM(Revenue) - SUM(Acquisition_Cost * Conversions))
    / SUM(Acquisition_Cost * Conversions),
    4
  ) AS ROI
FROM campaigns
GROUP BY Brand, Campaign_Type
ORDER BY Brand, ROI DESC;
```

Kết quả (top theo ROI mỗi brand):

Brand	Campaign Type	Campaigns	Revenue	ROI
Nykaa	Social Media	11.038	5,71B	1,9739
	SEO	11.020	5,67B	1,9606
	Paid Ads	11.035	5,71B	1,9584
	Influencer	11.046	5,72B	1,9485
	Email	11.036	5,64B	1,9296
Purplle	Paid Ads	10.953	5,69B	1,9603
	Social Media	10.947	5,67B	1,9597
	Email	11.167	5,75B	1,9484
	SEO	10.927	5,59B	1,9222
	Influencer	11.181	5,66B	1,9008
Tira	Paid Ads	11.058	5,72B	1,9716
Beauty	Email	11.069	5,71B	1,9451
	Social Media	10.966	5,61B	1,9269
	SEO	11.046	5,63B	1,9070
	Influencer	11.036	5,58B	1,8950

Bảng 12: Hiệu quả các loại hình Campaign phân theo Brand (sắp xếp theo ROI giảm dần)

Phân tích chuyên sâu từ bảng chéo

- Thương hiệu Nykaa đạt hiệu quả tối ưu nhất trên kênh Social Media với chỉ số ROI đạt 1,97, trong khi Tira Beauty lại chiếm ưu thế dẫn đầu tại kênh Paid Ads với mức ROI tương đương là 1,97
- Kênh Influencer Marketing ghi nhận hiệu quả thấp nhất tại Purplle và Tira Beauty do CPA ở mức cao đã kéo tỷ suất hoàn vốn (ROI) xuống mức tối thiểu, ngược lại đối với Nykaa thì Email Marketing mới là kênh có ROI thấp nhất.
- Kênh Email Marketing xếp vị trí thứ ba tại Purplle với chỉ số 1,95 nhưng lại đứng cuối bảng tại Nykaa với 1,93, điều này chứng minh mỗi thương hiệu đều có những đặc tính thị trường và thế mạnh kênh cốt lõi khác nhau
- Các chỉ số trên là cơ sở khoa học để tối ưu hóa việc phân bổ ngân sách bằng cách tập trung nguồn lực đầu tư vào các loại hình chiến dịch có tỷ suất ROI vượt trội cho từng thương hiệu cụ thể

Với KPI đã tính, chúng ta có đủ căn cứ để đưa ra khuyến nghị cho ban lãnh đạo. Phần tiếp theo sẽ biến những con số này thành hành động cụ thể.

VIII. Kết nối Excel → MySQL bằng Power Query

Phần này hướng dẫn kết nối Excel trực tiếp đến MySQL, chạy SQL query từ phần trước ngay trong Excel, và load dữ liệu vào worksheet.

VIII.1. Cài đặt MySQL Connector/NET

Trước khi kết nối Excel với MySQL, cần cài đặt MySQL Connector/NET. Đây là thư viện .NET do Oracle phát triển, cho phép các ứng dụng dựa trên nền tảng .NET, bao gồm Microsoft Excel thông qua Power Query, kết nối và trao đổi dữ liệu với cơ sở dữ liệu MySQL. Sau khi cài đặt, Excel có thể truy cập dữ liệu trong MySQL để phục vụ việc truy vấn, phân tích và trực quan hóa dữ liệu.

Bước 1: Tải MySQL Connector/NET

1. Truy cập: https://dev.mysql.com/downloads/connector/net/
2. Chọn hệ điều hành (Windows)
3. Chọn phiên bản **8.x** (khớp với MySQL Server đã cài ở phần trước)
4. Tải file **MSI Installer** (ví dụ: `mysql-connector-net-8.0.xx.msi`)
5. Cài đặt: nhấn Next liên tục, giữ mặc định, chọn **Complete** installation

Mẹo: Connector/NET hay Connector/ODBC?

MySQL có 2 loại connector phổ biến cho Excel:

Connector	Dùng khi	Ưu điểm
Connector/NET (khuyến nghị)	Excel → Get Data → From MySQL Database	Đơn giản, tích hợp sẵn vào Power Query
Connector/ODBC (thay thế)	Excel → Get Data → From ODBC	Tương thích nhiều ứng dụng hơn

Trong bài này, chúng ta dùng **Connector/NET** vì đơn giản hơn: chỉ cần cài và dùng ngay, không cần cấu hình DSN hay driver riêng.

Bước 2: Kiểm tra cài đặt thành công

Sau khi cài, kiểm tra nhanh:

1. Mở Excel
2. Vào tab **Data** → nhấn **Get Data** → **From Database**

3. Nếu thấy tuỳ chọn **From MySQL Database** trong danh sách → cài đặt thành công

Nếu không thấy hãy thử các bước hướng dẫn sau:

- Đóng Excel hoàn toàn rồi mở lại (Connector cần restart Excel)
- Kiểm tra lại đã cài phiên bản **Connector/NET** (không phải Connector/ODBC hay Connector/C++)

VIII.2. Kết nối từ Excel

Bây giờ mở Excel và kết nối đến MySQL.

Bước 1: Mở Get Data

1. Mở Excel, tạo file mới (hoặc mở file project)
2. Vào tab **Data** trên ribbon
3. Nhấn **Get Data** → **From Database** → **From MySQL Database**

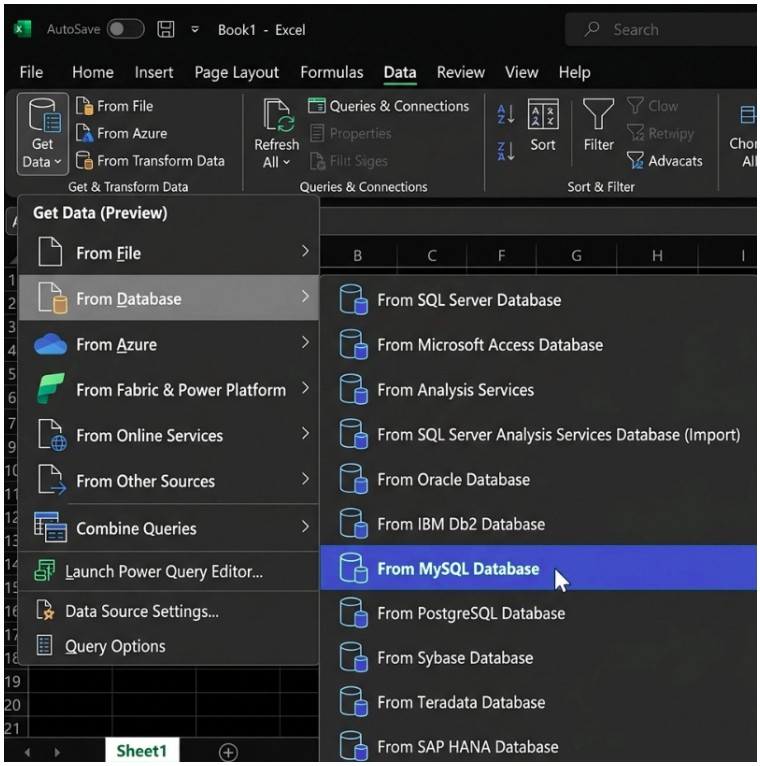

Hình 5: Get data từ MySQL

! Không thấy "From MySQL Database"?

Nếu menu Get Data không có tuỳ chọn MySQL:

- Kiểm tra đã cài **MySQL Connector/NET** chưa
- Kiểm tra phiên bản Excel hiện nên sử dụng bản**Microsoft 365** hoặc **Excel 2019+** (các phiên bản cũ hơn không hỗ trợ)
- Thử khởi động lại Excel sau khi cài Connector
- Nếu vẫn không thấy, thử cách thay thế cài **MySQL Connector/ODBC**

Bước 2: Nhập thông tin kết nối

Hộp thoại **MySQL database** xuất hiện. Hãy điền vào những thông tin sau:

Trường	Giá trị	Giải thích
Server	`localhost`	MySQL đang chạy trên máy cá nhân. Nếu server ở máy khác, nhập IP address
Database	`marketing_analytics`	Tên database đã tạo ở phần trước đấy

Bảng 13: Thông số cấu hình kết nối cơ sở dữ liệu MySQL từ Excel

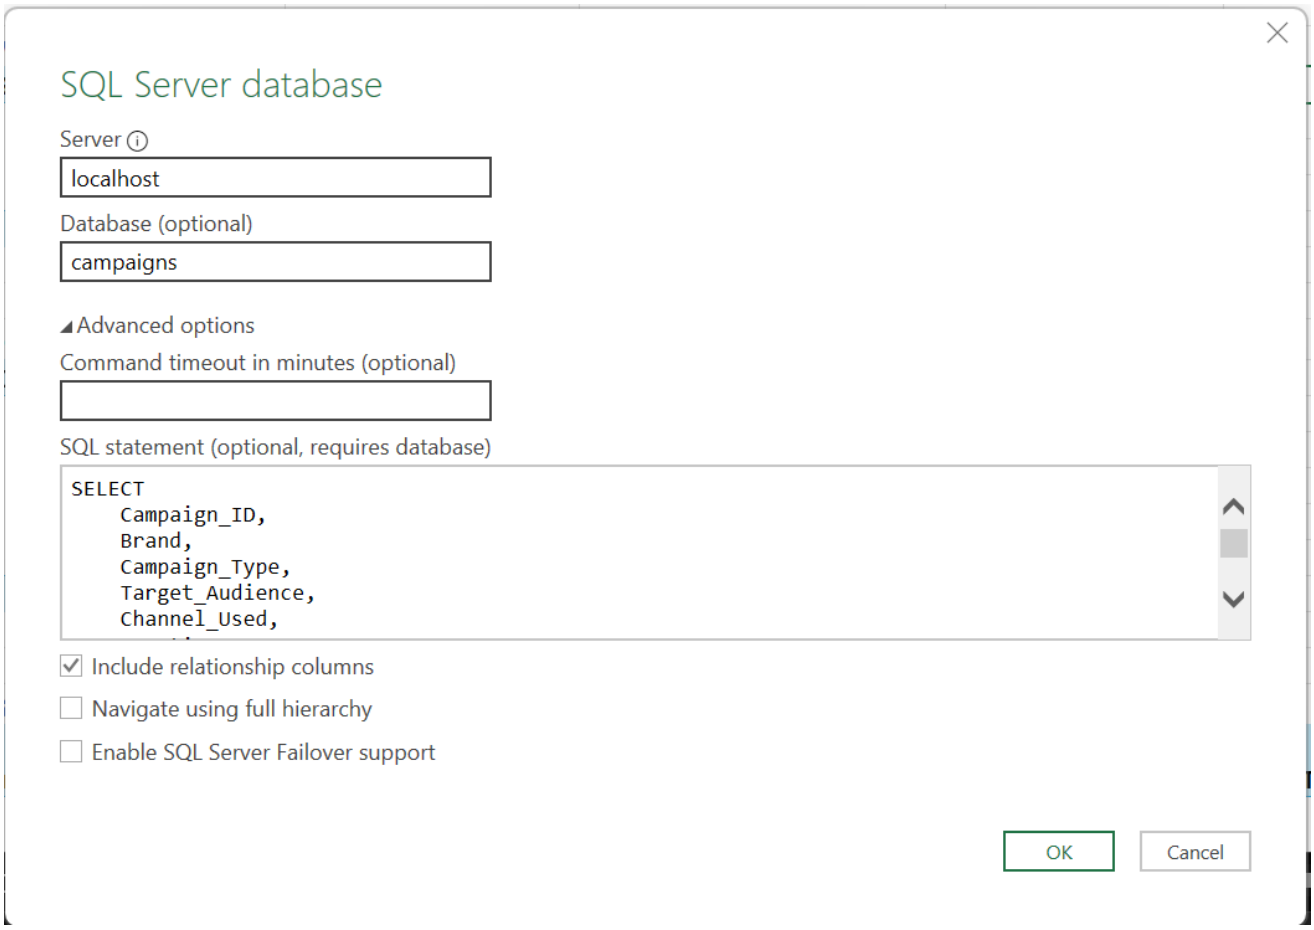

Hình 6: Hộp thoại kết nối MySQL database từ Excel. Nhập server (localhost) và database (marketing_analytics). Phần Advanced options cho phép nhập SQL Statement.

Bước 3: Nhập SQL Statement (quan trọng!)

Đây là bước then chốt. Thay vì lấy toàn bộ bảng `campaigns` (165.525 rows × 17 cột), chúng ta chạy SQL query để tính KPI, tạo cột mới, và phân loại ngay từ server. (Dữ liệu sạch còn 165.525 dòng.)

Mở phần **Advanced options** (nhấn vào mũi tên ▼ để mở rộng), rồi dán SQL query sau vào ô **SQL statement**:

SQL query xuất dataset với KPI và phân loại ROI

```
SELECT
    Campaign_ID,
    Brand,
    Campaign_Type,
    Target_Audience,
    Channel_Used,
    Duration,
    Language,
    Customer_Segment,
```

```
    Campaign_Date,
    Impressions,
    Clicks,
    Leads,
    Conversions,
    Revenue,
    Acquisition_Cost                                    AS CPA,
    ROUND(Acquisition_Cost * Conversions, 2)            AS Total_Spend,
    ROUND(Revenue - Acquisition_Cost * Conversions, 2)  AS Profit,
    ROUND(Clicks / NULLIF(Impressions, 0), 4)           AS CTR,
    ROUND(Leads / NULLIF(Clicks, 0), 4)                 AS Lead_Rate,
    ROUND(Conversions / NULLIF(Leads, 0), 4)            AS Conversion_Rate,
    ROI,
    Engagement_Score,
    CASE
        WHEN ROI > 5 THEN 'Excellent'
        WHEN ROI > 2 THEN 'Good'
        WHEN ROI > 0 THEN 'Moderate'
        ELSE 'Poor'
    END AS ROI_Category
FROM campaigns
ORDER BY Brand, ROI DESC
```

Đây chính là query xuất dataset từ phần trước. SQL query này thực hiện 4 việc sau

- Lấy tất cả dimension columns (`Brand`, `Campaign_Type`, `Target_Audience`...)
- Lấy funnel metrics (`Impressions`, `Clicks`, `Leads`, `Conversions`, `Revenue`)
- **Tính thêm** các cột như`Total_Spend`, `Profit`, `CTR`, `Lead_Rate`, `Conversion_Rate`
- **Phân loại** ROI thành 4 nhóm: Excellent / Good / Moderate / Poor

Nhấn **OK**.

Bước 4: Xác thực (Authentication)

Lần đầu kết nối, Excel yêu cầu đăng nhập MySQL thực hiện các bước dưới đây.

1. Chọn tab **Database** (bên trái)
2. Nhập **User name**: `root` (hoặc user MySQL của bạn)
3. Nhập **vào Password** mật khẩu MySQL đã đặt ở phần trước
4. Nhấn **Connect**

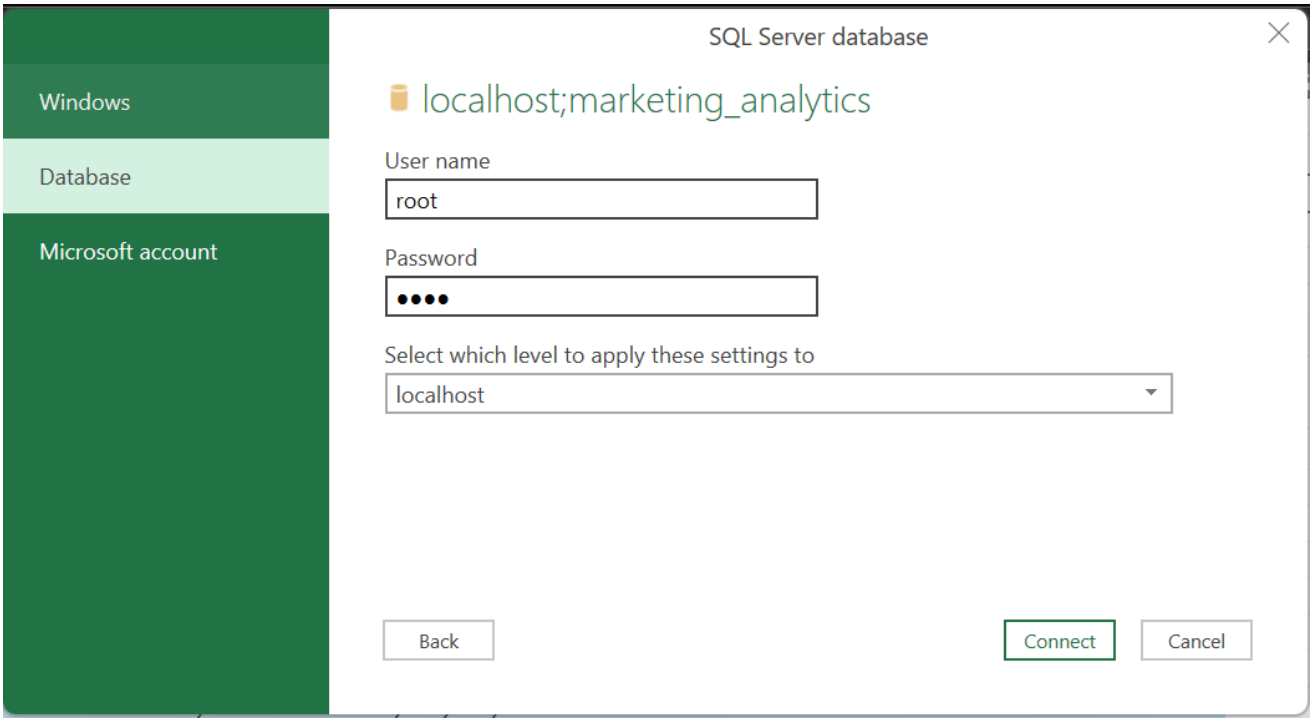

Hình 7: Giao diện đăng nhập MySQL

Bước 4.5: Lưu mật khẩu

Mẹo: Lưu mật khẩu

Excel sẽ lưu thông tin đăng nhập sau lần đầu. Lần sau mở file, không cần nhập lại mật khẩu. Nếu muốn xóa thông tin đăng nhập đã lưu **Data** → **Data Source Settings** → **chọn nguồn** → **Clear Permissions**.

Bước 5: Preview và Load

Sau khi kết nối thành công giao diện Power Query hiển thị preview dữ liệu. Kiểm tra những thông tin như sau

- Có đủ **23 cột** không? (`Campaign\_ID`, `Brand`, ..., `ROI\_Category`)
- Dữ liệu preview có hợp lý không? (Brand = Nykaa/Purplle/Tira Beauty, ROI_Category = Excellent/Good/...)
- Nhấn **Load** để đưa dữ liệu vào Excel worksheet

Khái niệm: Load vs Load To

- **Load** để đưa dữ liệu vào worksheet mới (mặc định)
- **Load To** cho phép chọn nơi để tải dữ liệu tới worksheet hiện tại, workbook mới, hoặc chỉ tạo connection không cần tải dữ liệu.

Chúng ta dùng **Load** để dữ liệu xuất hiện ngay trong 1 sheet.

Bước 6: Kiểm tra dữ liệu đã load

Sau khi load, Excel tạo một sheet mới chứa dữ liệu dạng **Table (bảng Excel)**, hãy kiểm tra các phần sau.

```
So dong: 165,525 (xem o thanh status bar phia duoi, hoac Ctrl+End)
So cot:  23
Sheet name: thuong la "Query1" hoac ten ban dat
```

Nếu số dòng đúng và dữ liệu hiển thị hợp lý vậy là chúng ta đã thực hiện kết nối thành công!

Mẹo: Đổi tên sheet và table

Right-click tab sheet → **Rename** → đổi thành `Data`. Giúp dễ nhận biết khi có nhiều sheet sau này.
Để đổi tên Table thực hiện click vào bảng dữ liệu → tab **Table Design** → thay `Table Name` thành `CampaignData`.

VIII.3. Refresh dữ liệu

Một lợi thế lớn của kết nối trực tiếp: khi dữ liệu MySQL thay đổi (thêm campaign mới, sửa ROI...), chỉ cần nhấn **Refresh** để cập nhật Excel:

- **Refresh nhanh** thực hiện nhấn `Ctrl + Alt + F5` (lúc này sẽ là tải lại toàn bộ connections)
- **Refresh 1 table** thực hiện click phải vào Table → **Refresh**
- **Refresh tự động** tab **Data** → **Connections** → chọn connection → **Properties** → tick **Refresh every X minutes**

Khái niệm của Live Connection vs Static Data

- **Static Data** là dữ liệu tĩnh cho phép import 1 lần, không tự cập nhật. File CSV là static data.
- **Live Connection** (kết nối trực tiếp): dữ liệu được kéo từ nguồn mỗi khi refresh. Kết nối MySQL qua Power Query là live connection.

Trong dự án thực tế, live connection giúp dashboard luôn phản ánh dữ liệu mới nhất. Không cần xuất CSV rồi import lại.

VIII.4. Xử lý lỗi kết nối thường gặp

Nếu gặp lỗi khi kết nối, kiểm tra theo thứ tự:

Lỗi 1: không kết nối được "Unable to connect"

Những nguyên nhân phổ biến thường gặp

1. MySQL Server chưa chạy. Kiểm tra bằng cách mở **Services** (gõ `services.msc`), tìm **MySQL80**, đảm bảo đang **Running**
2. Sai tên server. Nếu MySQL chạy trên máy cá nhân, dùng `localhost` hoặc `127.0.0.1`
3. Firewall chặn port 3306 (đây là port mặc định MySQL)

Lỗi 2: Access denied for user 'root'

Nguyên nhân gặp lỗi này là sai mật khẩu hoặc user không có quyền truy cập database.

Hãy thử những cách hướng dẫn sau

1. Kiểm tra mật khẩu đúng chưa (thử đăng nhập ở MySQL Workbench)
2. Trong MySQL Workbench, chạy:

```
GRANT ALL PRIVILEGES ON marketing_analytics.* TO 'root'@'localhost';
FLUSH PRIVILEGES;
```

Lỗi 3: Không thấy "From MySQL Database" trong menu Get Data

Nguyên nhân là chưa cài MySQL Connector/NET, hoặc cài nhầm loại Connector khác.
Cách sửa:

1. Kiểm tra đã cài đúng **MySQL Connector/NET** (không phải Connector/ODBC hay Connector/C++)

2. Tải lại từ: https://dev.mysql.com/downloads/connector/net/
3. Đóng Excel hoàn toàn, cài Connector, mở lại Excel
4. Nếu vẫn không thấy, thử cách thay thế bằng ODBC

Lỗi 4: "SQL statement error" khi dùng Advanced options

Nguyên nhân lỗi này là SQL query có lỗi cú pháp, hoặc tên bảng/cột sai.

Cách sửa:

1. Copy query chạy thử ở MySQL Workbench trước
2. Kiểm tra tên database/table đúng chưa: `marketing\_analytics.campaigns`
3. Nếu lỗi liên quan comment: xóa tất cả dòng bắt đầu bằng `--` trong SQL query

VIII.5. Checklist kết nối

Trước khi chuyển sang phần tiếp theo, hãy đảm bảo tất cả điều kiện được nêu sau đây

! Checklist kết nối MySQL → Excel

1. MySQL Server có đang chạy không bằng cách kiểm tra Services → MySQL80 = Running.
2. MySQL Connector/NET đã cài thành công
3. Trong Excel thấy "From MySQL Database" trong phần Get Data.
4. Server = `localhost`, Database = `marketing\_analytics`?
5. User/password đúng đã được điền vào đúng (hãy test ở MySQL Workbench trước)?
6. SQL query chạy thành công ở MySQL Workbench?
7. Dữ liệu đã load được 165.525 dòng × 23 cột sau khi kết nối.

VIII.6. Cách thay thế Kết nối bằng MySQL Connector/ODBC

Nếu phương pháp Connector/NET ở trên không hoạt động (ví dụ: Excel không nhận Connector/NET, hoặc dùng Excel phiên bản đặc biệt), có thể dùng **MySQL Connector/ODBC** làm cách thay thế.

ODBC (**Open Database Connectivity**, giao thức kết nối cơ sở dữ liệu mở) là tiêu chuẩn cũ hơn nhưng tương thích rộng hơn.

Bước 1: Tải và cài MySQL Connector/ODBC

1. Truy cập: https://dev.mysql.com/downloads/connector/odbc/

2. Tải **MSI Installer** phiên bản 8.x
3. Chọn đúng kiến trúc: nếu Excel 64-bit → tải Connector/ODBC 64-bit (kiểm tra: Excel → **File** → **Account** → **About Excel**)
4. Cài đặt: nhấn Next liên tục, giữ mặc định

Bước 2: Kiểm tra driver đã cài

1. Nhấn `Win + S`, gõ "ODBC", chọn **ODBC Data Sources (64-bit)**
2. Chọn tab **Drivers**
3. Tìm dòng **MySQL ODBC 8.x Unicode Driver**

Bước 3: Kết nối từ Excel qua ODBC

1. Tab **Data** → **Get Data** → **From Other Sources** → **From ODBC**
2. Chọn **DSN** hoặc nhập **Connection String**:

```
Driver={MySQL ODBC 8.0 Unicode Driver};Server=localhost;
Database=marketing_analytics;User=root;Password=your_password;
```

3. Nhấn **OK** → nhập SQL query (giống Bước II.B.3)
4. Load dữ liệu

Khái niệm: DSN vs Connection String

- **DSN** (**Data Source Name**): là cấu hình kết nối đã lưu sẵn trong ODBC Administrator. Dùng khi muốn tái sử dụng connection nhiều lần.
- **Connection String** là chuỗi kết nối gõ trực tiếp, không cần tạo DSN trước. Nhanh hơn nhưng phải nhớ cú pháp.

Với Power Query, dùng Connection String tiện hơn vì không cần setup DSN.

Phần còn lại (load data, refresh, tạo table) giống hệt cách Connector/NET ở trên.

IX. Chuẩn bị dữ liệu trong Excel

Dữ liệu export từ SQL đã có đủ thông tin KPI cần thiết nhưng đây chưa phải dạng tối ưu để phân tích trong Excel. Một số cột, dữ liệu cần được bổ sung, vấn đề cần được xử lý trước khi tạo Pivot Table hay Dashboard. Ở phần này nội dung sẽ đi qua từng bước chuẩn bị, từ kiểm tra tổng quan đến tạo các cột dữ liệu hỗ trợ phục vụ cho giai đoạn phân tích.

IX.1. Kiểm tra tổng quan dữ liệu

Trước khi làm bất cứ điều gì, cần biết mình đang làm việc với dữ liệu có thông tin và hình dạng như thế nào. Hai thứ cần xác nhận ngay khi nhận dữ liệu để phân tích: kích thước bảng và kiểu dữ liệu từng cột.

Bước 1: Xác nhận kích thước bảng

Click vào bất kỳ ô nào trong bảng, nhấn `Ctrl + End` để nhảy đến ô cuối cùng có dữ liệu. Kết quả mong đợi:

- **Dòng cuối** có 165.526 (tức 165.525 dòng dữ liệu + 1 dòng header).
- **Cột cuối** W (cột thứ 23).

Hoặc chọn cả một cột số **status bar** phía dưới Excel tự hiển thị `Count: 165525`.

Bước 2: Kiểm tra kiểu dữ liệu từng cột

Click vào từng cột và quan sát dữ liệu. Bảng dưới liệt kê những điều cần xác nhận:

Cột	Kiểu mong đợi	Cần kiểm tra
Campaign_ID	Text	Có bị trùng lặp không?
Brand	Text	Phải có đúng 3 giá trị unique
Impressions, Clicks...	Number	Có giá trị text lẫn vào không?
Campaign_Date	Date	Excel nhận là Date, không phải Text?
CTR, Lead_Rate...	Number (decimal)	Có NULL hay lỗi không?
ROI_Category	Text	Đúng 4 giá trị: Excellent/Good/Moderate/Poor?

Bảng 14: Các tiêu chí kiểm tra kiểu dữ liệu và tính hợp lệ cho từng cột

Mẹo: Kiểm tra nhanh giá trị unique bằng Filter

Click vào mũi tên ▼ ở header cột `Brand`. Dropdown liệt kê toàn bộ giá trị unique và phải thấy đúng 3 tên: Nykaa, Purplle, Tira Beauty. Nếu xuất hiện giá trị lạ như khoảng trắng thừa, ký tự đặc biệt..., cần xử lý những dữ liệu này trước khi phân tích.

IX.2. Loại bỏ dữ liệu trùng lặp

`Campaign_ID` là định danh duy nhất của mỗi campaign nên không được phép có 2 dòng cùng giá trị. Kiểm tra và xử lý như sau

1. Click vào bất kỳ ô nào trong bảng dữ liệu.
2. Tab **Data** → **Remove Duplicates**.
3. Trong hộp thoại, **chỉ giữ tick cột Campaign_ID** (bỏ tick tất cả cột còn lại).
4. Nhấn **OK**.

Kết quả mong đợi nhận được *"0 duplicate values found and removed, 165525 unique values remain."* Vì dataset được export từ bảng SQL có `PRIMARY KEY`, duplicates không tồn tại nhưng bước kiểm tra này vẫn nên thực hiện như một thói quen.

Remove Duplicates hoạt động như thế nào?

Khi chọn **1 cột** (ví dụ: `Campaign_ID`), Excel so sánh giá trị cột đó giữa tất cả các dòng. Hai dòng có cùng Campaign_ID được coi là duplicate thì lúc này Excel giữ lại dòng đầu tiên, xóa các dòng sau.
Khi chọn **nhiều cột**, Excel chỉ xóa dòng mà *tất cả* các cột được chọn đều trùng nhau (logic AND, không phải OR). Chọn đúng cột là bước quan trọng nhất.

IX.3. Xử lý cột Campaign_Date

Cột `Campaign_Date` lưu ngày bắt đầu campaign. Để phân tích theo tháng hoặc theo quý, chúng ta cần tạo thêm hai cột từ cột ngày này.

Bước 1: Xác nhận Excel nhận đúng kiểu Date

Click vào một ô trong cột `Campaign_Date`. Nếu Excel nhận đúng kiểu Date, thanh formula hiển thị dạng `mm/dd/yyyy` hoặc `dd/mm/yyyy`. Nếu hiển thị text thuần (ví dụ: `2025-04-29`), cần chuyển trước.

! Date format phụ thuộc vào cài đặt hệ thống

Excel hiển thị ngày theo Regional Settings của máy tính. Máy cài theo locale Việt Nam thường dùng `dd/mm/yyyy`, máy Mỹ dùng `mm/dd/yyyy`. Điều quan trọng không phải format hiển thị mà là Excel phải **nhận đúng kiểu Date** (không phải Text hay General).

Kiểm tra: right-click vào ô Date → **Format Cells**. Nếu **Category** là **Date** thì đúng. Nếu là **General** hoặc **Text**, cần convert bằng `DATEVALUE()` hoặc **Text to Columns**.

Bước 2: Tạo cột Campaign_Month

Thêm cột mới, đặt header là `Campaign_Month`. Nhập công thức:

Campaign_Month

```
=TEXT([@Campaign_Date], "YYYY-MM")
```

Giải thích:

- `[@Campaign_Date]`: structured reference trong Excel Table `@` có nghĩa là dòng hiện tại.
- `TEXT(date, "YYYY-MM")`: chuyển Date thành chuỗi dạng `2025-01`, `2025-02`... Dạng này giúp Pivot Table gom nhóm theo tháng đúng thứ tự (sort alphabetically = sort chronologically).

Nếu bảng đang là Excel Table (có tên), công thức tự động fill xuống tất cả dòng không cần kéo thủ công.

Bước 3: Tạo cột Campaign_Quarter

Thêm cột `Campaign_Quarter` với công thức:

Campaign_Quarter

```
="Q" & ROUNDUP(MONTH([@Campaign_Date]) / 3, 0) & "-" & YEAR([@Campaign_Date])
```

Kết quả trả về: `Q1-2025`, `Q2-2025`, `Q3-2025`, `Q4-2025`. Giải thích từng phần:

- `MONTH(date)`: trả về tháng dưới dạng số (1–12).
- `MONTH / 3`: chia cho 3 để ánh xạ tháng sang quý (tháng 1–3 = 0,33–1,0 → quý 1; tháng 4–6 → quý 2...).
- `ROUNDUP(\ldots, 0)`: làm tròn lên về phía số nguyên (tháng 1: 1/3 = 0,33 → 1; tháng 3: 3/3 = 1,0 → 1).
- `\&`: toán tử nối chuỗi ghép "Q" + số quý + "-" + năm.

IX.4. Xử lý cột Channel_Used (đa giá trị)

Cột `Channel_Used` lưu nhiều kênh trong cùng một ô, phân cách bằng dấu phẩy, ví dụ: `Facebook , Instagram` hoặc `Google, YouTube, WhatsApp`.

Vấn đề phát sinh khi tạo Pivot Table: Excel coi `"Facebook, Instagram"` và `"Facebook"` là hai giá trị hoàn toàn khác nhau. Không thể đếm số campaign chạy trên Facebook nếu Facebook bị gộp chung trong chuỗi multi-value như vậy.

Giải pháp: Tạo cột Primary_Channel

Thay vì tách toàn bộ chuỗi cách này khá phức tạp và có thể bị nhân bản dữ liệu, cách thực tế hơn nên làm là tạo cột `Primary_Channel` lấy **kênh đầu tiên** trong danh sách:

Primary_Channel

```
=LEFT([@Channel_Used], FIND(",", [@Channel_Used] & ",") - 1)
```

Giải thích:

- `[@Channel_Used] \& ","`: nối thêm dấu phẩy vào cuối chuỗi xử lý trường hợp ô chỉ có 1 kênh (không có dấu phẩy thật, nếu không thêm thì `FIND` báo lỗi).
- `FIND(",", \ldots)`: tìm vị trí dấu phẩy đầu tiên.
- `LEFT(text, n-1)`: lấy n−1 ký tự từ trái, tức là từ phần trước dấu phẩy.
- Kết quả: `"Facebook, Instagram"` → `"Facebook"`; `"WhatsApp"` → `"WhatsApp"`.

Bổ sung: Tạo cột Channel_Count

Đếm số kênh mà mỗi campaign sử dụng, cách này hữu ích để phân tích liệu campaign đa kênh coi có ROI cao hơn không:

Channel_Count

```
=LEN([@Channel_Used]) - LEN(SUBSTITUTE([@Channel_Used], ",", "")) + 1
```

Logic: `SUBSTITUTE` xóa toàn bộ dấu phẩy khỏi chuỗi. Hiệu số độ dài trước và sau khi xóa = số dấu phẩy. Số kênh = số dấu phẩy + 1. Ví dụ: `"Facebook, Instagram, Google"` có 2 dấu phẩy → 3 kênh.

Tại sao không tách hẳn từng kênh ra một dòng?

Cách chuẩn trong database là **normalization**: tách thành bảng riêng `campaign_channels` với 2 cột (Campaign_ID, Channel). Nhưng trong Excel, tách hoàn toàn sẽ nhân bản số dòng lên 2–3 lần, khiến `SUM(Revenue)` bị tính trùng.

Cột `Primary_Channel` là giải pháp thiết thực để đủ dùng cho phân tích cơ bản theo kênh chính. Nếu cần phân tích chính xác đến từng kênh phụ, nên dùng Power Query hoặc Python để pivot bảng trước khi đưa vào Excel.

IX.5. Tạo các cột phân loại bổ sung

Ngoài `ROI_Category` đã có từ bước SQL, hai cột dưới đây giúp mở ra các góc phân tích mới trong Pivot Table.

Cột Duration_Group: Phân loại độ dài campaign

Duration_Group

```
=IF([@Duration]<=7,  "Short (1-7 days)",
 IF([@Duration]<=14, "Medium (8-14 days)",
 IF([@Duration]<=21, "Long (15-21 days)",
                     "Very Long (22+ days)")))
```

Công thức `IF` lồng nhau phân campaign thành 4 nhóm theo số ngày chạy. Sau khi có cột này, Pivot Table có thể trả lời: *campaign ngắn hay campaign dài có ROI cao hơn?*

Cột Revenue_Per_Conversion: Giá trị đơn hàng trung bình

Revenue_Per_Conversion

```
=IF([@Conversions]>0, [@Revenue]/[@Conversions], 0)
```

Điều kiện `Conversions > 0` tránh lỗi chia cho giá trị 0. Cột này cho biết mỗi đơn hàng trung bình mang về bao nhiêu doanh thu rất hữu ích để so sánh giá trị khách hàng giữa các brand hay campaign type.

IX.6. Tổng kết: Bảng dữ liệu sau khi chuẩn bị

Sau khi hoàn thành tất cả các bước, bảng dữ liệu được bổ sung **6 cột mới** so với dữ liệu gốc từ SQL:

Tổng cộng bảng bây giờ có **29 cột** (23 cột gốc + 6 cột mới). Dữ liệu sạch, đủ cột phân loại đã sẵn sàng để xây Pivot Table và Dashboard ở các bước tiếp theo.

X. Pivot Table

Sau khi dữ liệu đã được làm sạch và các KPI được tính toán qua SQL, bước tiếp theo là tổng hợp và trực quan hóa. Ở bước này, Pivot Table không nhằm tạo bảng tổng hợp cho đẹp, mà dùng dữ liệu để trả lời các câu hỏi của doanh nghiệp, biến dữ liệu thô thành lời giải cho những bài toán đang gặp phải. Trong Excel, công cụ mạnh nhất cho công việc này là Pivot Table cho phép tóm tắt hàng trăm nghìn dòng dữ liệu thành vài dòng có ý nghĩa chỉ bằng thao tác kéo và thả.

X.1. Tạo Pivot Table đầu tiên: Tổng quan theo Brand

Bước 1: Tạo Pivot Table

1. Click vào bất kỳ ô nào trong bảng dữ liệu (sheet `Data`).

Cột mới	Ý nghĩa	Công thức (tóm tắt)
`Campaign_Month`	Tháng bắt đầu campaign	`TEXT(Date, "YYYY-MM")`
`Campaign_Quarter`	Quý bắt đầu campaign	`"Q"& ROUNDUP(MONTH/3, 0) & "& YEAR`
`Primary_Channel`	Kênh quảng cáo chính (kênh đầu tiên)	`LEFT(..., FIND(",", ...)-1)`
`Channel_Count`	Số kênh mỗi campaign sử dụng	Đếm dấu phẩy +1
`Duration_Group`	Phân nhóm độ dài campaign	`IF` lồng: Short / Medium / Long / Very Long
`Revenue_Per_Conversion`	Doanh thu trung bình mỗi đơn hàng	`Revenue / Conversions`

Bảng 15: Danh sách các trường dữ liệu (Feature Engineering) được tạo thêm trong Excel

2. Tab **Insert** → **PivotTable**.
3. Hộp thoại hiện ra:
   - **Table/Range**: Excel tự nhận diện bảng `CampaignData` (nếu đã đặt tên ở bước trước).
   - **Location**: chọn **New Worksheet** (tạo sheet mới cho Pivot Table).
4. Nhấn **OK**.

Excel tạo sheet mới với Pivot Table trống. Bên phải màn hình xuất hiện phần panel **PivotTable Fields** chứa danh sách cột để kéo thả vào bốn vùng phía dưới: `Filters`, `Columns`, `Rows`, `Values`.

Bước 2: Cấu hình Pivot Table theo Brand

Kéo các cột vào vùng tương ứng:

Mẹo: Thay đổi cách tính (Sum / Average / Count)

Khi kéo cột số vào `Values`, Excel mặc định chọn **Sum**. Để đổi:

1. Click vào tên cột trong vùng Values (ví dụ: Sum of ROI).
2. Chọn **Value Field Settings**.
3. Đổi sang **Average** (hoặc Count, Min, Max...).

Với ROI, chúng ta nên sử dụng công thức tính Weighted Average thay vì tính Sum, vì ROI là một tỷ lệ và không có tính cộng gộp giữa các quan sát.

Vùng	Cột kéo vào	Mục đích
Rows	`Brand`	Mỗi brand 1 dòng
Values	`Revenue` → Sum of `Revenue`	Tổng doanh thu
Values	`Total_Spend` → Sum of `Total_Spend`	Tổng chi phí
Values	`Campaign_ID` → Count of `Campaign_ID`	Đếm số campaigns
Values	Calculated Field trong PivotTable	Trọng số ROI

Bảng 16: Cấu hình các trường dữ liệu cho Pivot Table theo Brand

Tạo calculated field trong PivotTable tính Weighted ROI

- Chọn bất kỳ ô nào bên trong PivotTable vừa tạo.
- Mở menu Calculated Field, trên thanh ribbon chọn vào **PivotTable Analyze** → **Fields, Items, & Sets** → **Calculated Field**. (Ở một số bản Excel có thể là tab **Options** thay vì **PivotTable Analyze**.)
- Cửa sổ **Insert Calculated Field** hiện ra, đặt tên field mới là **Weighted_ROI** và nhập công thức:

```
Weighted_ROI= (Revenue - Total_Spend) / Total_Spend
```

Lưu ý là Calculated Field không tính trên từng dòng rồi mới aggregate. Excel sẽ aggregate trước (SUM) rồi mới áp công thức.

Kết quả:

PIVOT TABLE 1: Brand Overview

Row Labels	Sum of Revenue	Sum of Total_Spend	Count of Campaign_ID	Sum of Weighted_ROI
Nykaa	28,448,659,396.00	9,630,001,507.72	55,175.00	1.95
Purplle	28,358,894,675.00	9,651,749,782.32	55,175.00	1.94
Tira Beauty	28,253,596,130.00	9,645,833,045.30	55,175.00	1.93
Grand Total	**85,061,150,201.00**	**28,927,584,335.34**	**165,525.00**	**1.94**

Hình 8: Kết quả pivot table theo brand

Bước 3: Đọc Insight

Nykaa đạt Weighted ROI cao nhất (1,95), cho thấy thương hiệu này tạo ra mức lợi nhuận trên chi phí quảng cáo tốt nhất trong ba thương hiệu. Purplle xếp thứ hai với Weighted ROI đạt 1,94, trong khi Tira Beauty có Weighted ROI thấp nhất (1,93). Mặc dù doanh thu và chi phí quảng cáo của ba thương hiệu khá tương đồng, Nykaa vẫn đạt hiệu quả đầu tư cao hơn, phản ánh khả năng chuyển đổi ngân sách quảng cáo thành doanh thu tốt hơn.

! Avg ROI trong Pivot Table vs. Weighted ROI

Pivot Table tính Average ROI = trung bình cộng ROI của từng campaign. Đây là phép tính trung bình cộng thông thường, không phải là tính trung bình cộng có trọng số.

Weighted ROI = (Total Revenue − Total Spend) / Total Spend. Với Nykaa:

$$\frac{28{,}45\,B - 9{,}63\,B}{9{,}63\,B} = \mathbf{1{,}9542}$$

Khác biệt đáng kể so với Simple Average (2,71).

Lý do: Simple Average cho mỗi campaign trọng số bằng nhau. Campaign nhỏ có mức spend ít nên ảnh hưởng ít hơn so với chiến dịch lớn. Weighted Average tính trên tổng nên chính xác hơn. Khi trình bày kết quả nên **dùng Weighted ROI**.

X.2. Pivot Table theo Campaign Type

Tạo Pivot Table mới hoặc sao chép từ Pivot Table cũ:

Vùng	Cột
Rows	Campaign_Type
Values	Sum of Revenue, Sum of Total_Spend, Weighted ROI, Count of Campaign_ID
Sắp xếp	Sort by Weight of ROI, giảm dần

Bảng 17: Cấu hình Pivot Table phân tích theo Campaign Type

Kết quả:

PIVOT TABLE 2: Campaign Type Performance

Row Labels	Sum of Revenue	Count of Campaign_ID	Sum of Total_Spend	Sum of Weighted_ROI
Email	17,102,839,442.00	33,272.00	5,815,110,287.55	1.94
Influencer	16,962,763,358.00	33,263.00	5,819,573,613.97	1.91
Paid Ads	17,117,752,729.00	33,046.00	5,776,340,112.39	1.96
SEO	16,892,377,718.00	32,993.00	5,765,615,460.36	1.93
Social Media	16,985,416,954.00	32,951.00	5,750,944,861.07	1.95
Grand Total	**85,061,150,201.00**	**165,525.00**	**28,927,584,335.34**	**1.94**

Hình 9: Kết quả Pivot Table theo Campaign Type

Paid Ads đạt hiệu quả cao nhất (1,96), cho thấy khả năng sinh lời tốt hơn so với các kênh khác. Trong khi đó, Influencer có ROI thấp nhất (1,91), phản ánh mức độ tối ưu ngân sách chưa cao. Social Media đứng thứ hai với ROI đạt 1,95, thể hiện hiệu suất đầu tư tương đối tốt và ổn định.

X.3. Pivot Table theo Brand × Campaign Type

Để trả lời câu hỏi *"Công ty nên đầu tư vào loại campaign nào?"*, cần phân tích Weighted ROI kết hợp Brand và Campaign Type:

Vùng	Cột
Rows	Brand
Columns	Campaign_Type
Values	Weighted ROI

Bảng 18: Cấu trúc thiết lập Pivot Table để phân tích ROI theo thương hiệu

Kết quả:

PIVOT TABLE 3: Brand × Campaign Type (Weighted ROI)

Sum of Weighted_ROI	Column Labels					
Row Labels	Email	Influencer	Paid Ads	SEO	Social Media	Grand Total
Nykaa	1.93	1.95	1.96	1.96	1.97	1.95
Purplle	1.95	1.90	1.96	1.92	1.96	1.94
Tira Beauty	1.95	1.90	1.97	1.91	1.93	1.93
Grand Total	**1.94**	**1.91**	**1.96**	**1.93**	**1.95**	**1.94**

Hình 10: Pivot Table theo Brand × Campaign Type

Đối với Nykaa, chiến dịch Social Media mang lại ROI cao nhất (1,97), trong khi Email có hiệu quả thấp nhất (1,93). Với Purplle và Tira Beauty, Paid Ads là kênh đạt ROI cao nhất lần lượt ở mức 1,96 và 1,97. Nhìn chung, xu hướng cho thấy Paid Ads và Social Media thường mang lại hiệu quả đầu tư tốt hơn, trong khi Influencer là kênh có ROI thấp nhất ở mức tổng thể (1,91), phản ánh hiệu quả sinh lời chưa cao so với các kênh còn lại.

X.4. Pivot Table theo thời gian

Phân tích xu hướng theo tháng giúp phát hiện mùa cao điểm và thấp điểm.

Vùng	Cột
Rows	Campaign_Month
Values	Sum of Revenue, Count of Campaign_ID, Weighted ROI

Bảng 19: Cấu trúc thiết lập Pivot Table để phân tích xu hướng doanh thu và ROI theo tháng

PIVOT TABLE 4: Monthly Trend

Row Labels	Sum of Revenue	Count of Campaign_ID	Sum of ROI
2024-07	7,692,501,737.00	14,792.00	40,561.65
2024-08	7,704,603,412.00	14,897.00	40,073.41
2024-09	7,337,927,479.00	14,385.00	38,249.03
2024-10	7,607,407,532.00	14,843.00	39,550.00
2024-11	7,368,462,304.00	14,322.00	38,280.79
2024-12	7,697,937,218.00	14,902.00	40,575.22
2025-01	7,588,716,016.00	14,722.00	39,673.04
2025-02	6,979,749,890.00	13,454.00	37,109.95
2025-03	7,460,214,948.00	14,467.00	39,186.45
2025-04	7,298,816,562.00	14,491.00	38,150.68
2025-05	7,562,392,474.00	14,822.00	39,500.73
2025-06	2,762,420,629.00	5,428.00	14,470.43
Grand Total	**85,061,150,201.00**	**165,525.00**	**445,381.38**

Hình 11: Pivot Table theo tháng

Mẹo: Group Date trong Pivot Table

Nếu dùng cột `Campaign_Date` gốc (kiểu Date), Excel có thể tự group:

1. Right-click vào giá trị Date trong Pivot Table.
2. Chọn **Group**.
3. Chọn **Months** và/hoặc **Quarters**.

Excel tự tạo nhóm tháng/quý. Nhanh hơn tạo helper column, nhưng kém linh hoạt hơn.

Nếu nhìn theo **tổng ROI cộng dồn** của các chiến dịch trong tháng, **tháng 12/2024** đạt giá trị cao nhất (40.575,22) còn **tháng 6/2025** thấp nhất (14.470,43). Lưu ý đây là tổng cộng ROI của hàng nghìn chiến dịch, không phải một tỷ lệ ROI (Weighted ROI theo tháng vẫn dao động quanh 1,9). Tháng 6/2025 thấp chủ yếu do số lượng campaign ít hơn hẳn (5.428 campaign), kéo theo tổng doanh thu giảm. Nhìn chung, giai đoạn cuối năm 2024 và đầu năm 2025 duy trì hiệu quả marketing ổn định hơn so với các tháng còn lại.

X.5. Pivot Table theo Customer Segment

Mục tiêu: hiểu *nhóm khách hàng nào mang lại giá trị cao nhất?*

Vùng	Cột kéo vào	Mục đích
Rows	Customer_Segment	Mỗi phân khúc một dòng
Values	Revenue → Sum of Revenue	Tổng doanh thu
Values	Campaign_ID → Count	Số lượng campaign
Values	Weighted ROI	ROI trọng số
Values	Conversion_Rate → Average	Tỷ lệ chuyển đổi

Bảng 20: Cấu trúc Pivot Table phân tích hiệu quả theo phân khúc khách hàng

Kết quả:

PIVOT TABLE 5: Customer Segment

Row Labels	Sum of Revenue	Count of Campaign_ID	Average of Conversion_Rate	Sum of Weighted_ROI
College Student	17,148,567,175.00	33,335.00	0.55	1.95
Premium Shopp	16,781,192,101.00	32,845.00	0.55	1.92
Tier 2 City Cust	16,953,410,387.00	32,855.00	0.55	1.95
Working Wome	17,071,220,707.00	33,149.00	0.55	1.95
Youth	17,106,759,831.00	33,341.00	0.55	1.94
Grand Total	**85,061,150,201.00**	**165,525.00**	**0.55**	**1.94**

Hình 12: Pivot Table theo Customer Segment

Doanh thu được phân bổ tương đối đồng đều giữa các customer segment, dao động quanh mức 16–17 tỷ đồng mỗi nhóm. **Working Women** và **College Students** đạt ROI cao nhất (1,95), cho thấy đây là hai nhóm khách hàng mang lại hiệu quả kinh doanh tốt hơn. Ngược lại, **Premium Shopper** có ROI thấp nhất (1,92), dù doanh thu không chênh lệch đáng kể. Tỷ lệ chuyển đổi (Conversion Rate) gần như tương đồng giữa các segment (0,55), cho thấy sự khác biệt về ROI chủ yếu đến từ mức chi tiêu và hiệu quả doanh thu thay vì khả năng chuyển đổi.

Business Question

Phân khúc nào nên ưu tiên đầu tư ngân sách? Trong bộ dữ liệu này chưa có khác biệt rõ ràng, nên cần thêm dữ liệu hành vi cấp khách hàng (retention, tần suất mua lại, CLV). Lưu ý AOV đã có sẵn (= Rev/Conv ∼500) và cũng không khác biệt

X.6. Pivot Table theo Channel Analysis

Mục tiêu: xác định *kênh marketing nào hiệu quả nhất?*

Vùng	Cột	Mục đích
Rows	Channel	Mỗi kênh một dòng
Values	Campaign_ID → Count	Số lượng campaign
Values	Revenue → Sum	Tổng doanh thu
Values	Weighted ROI	Đánh giá hiệu quả
Values	Weighted CPA	Chi phí cho mỗi chuyển đổi

Bảng 21: Cấu trúc Pivot Table phân tích hiệu quả theo kênh marketing

Kết quả:

PIVOT TABLE 6: Primary Channel Analysis

Row Labels	Count of Campaign_ID	Sum of Revenue	Sum of Total_Spend	Sum of Conversions	Sum of Weighted_ROI	Weighted CPA
Email	27,672.00	14,323,888,038.00	4,827,592,345.68	28,644,606.00	1.97	168.53
Facebook	27,463.00	14,084,849,934.00	4,811,466,077.40	28,317,158.00	1.93	169.91
Google	27,655.00	14,134,815,930.00	4,822,807,120.14	28,255,088.00	1.93	170.69
Instagram	27,513.00	14,278,156,114.00	4,807,453,810.24	28,492,709.00	1.97	168.73
WhatsApp	27,546.00	14,112,727,005.00	4,816,371,063.05	28,236,726.00	1.93	170.57
YouTube	27,676.00	14,126,713,180.00	4,841,893,918.83	28,375,037.00	1.92	170.64
Grand Total	**165,525.00**	**85,061,150,201.00**	**28,927,584,335.34**	**170,321,324.00**	**1.94**	**169.84**

Hình 13: Pivot Table theo Channel

Instagram đạt ROI cao nhất (1,97), đây là kênh marketing hiệu quả nhất về khả năng tạo lợi nhuận. **Email** xếp thứ hai với ROI đạt 1,97 và đồng thời có CPA thấp nhất (168,53), phản ánh khả năng tối ưu chi phí chuyển đổi tốt hơn các kênh khác. Ngược lại, **YouTube** và **Google** có ROI thấp nhất (1,92–1,93) cùng CPA cao nhất (gần 170,69), cho thấy chi phí để tạo ra mỗi chuyển đổi tương đối cao.
Số lượng chiến dịch giữa các kênh gần như tương đương nhau (khoảng 27 nghìn chiến dịch mỗi kênh), cho thấy dataset được phân bổ khá cân bằng và giúp việc so sánh hiệu quả giữa các channel trở nên đáng tin cậy hơn.

! Hiểu đúng CPA

CPA cao không phải lúc nào cũng xấu. Nếu khách hàng mang lại giá trị cao (LTV lớn), CPA cao vẫn chấp nhận được. Vì vậy cần kết hợp thêm **Customer Lifetime Value (CLV)** để đánh giá chính xác.

X.7. Pivot Table theo ROI Distribution

Mục tiêu: hiểu *phân bố hiệu quả campaign*

Vùng	Cột	Mục đích
Rows	ROI_Category	Nhóm mức độ hiệu quả (Excellent, Good, Moderate, Poor)
Values	Campaign_ID → Count	Số lượng campaign trong từng nhóm
Values	Campaign_ID → Show as % of Total	Tính tỷ trọng của từng nhóm so với tổng số campaign

Bảng 22: Cấu trúc Pivot Table phân bố chiến dịch theo nhóm ROI

Cách hiển thị % trong Pivot Table

1. Click vào **Count of Campaign_ID**
2. Chọn **Show Values As**
3. Chọn **% of Grand Total**

Kết quả:

PIVOT TABLE 7: ROI Distribution

Row Labels	Count of Campaign_ID	Percent
Excellent	28,736.00	17.36%
Good	36,208.00	21.87%
Moderate	60,911.00	36.80%
Poor	39,670.00	23.97%
Grand Total	**165,525.00**	**100.00%**

Hình 14: Phân bố ROI

Insight:

- Nhóm **Moderate** chiếm tỷ trọng lớn nhất (36,80%), cho thấy phần lớn campaign đang đạt hiệu quả ở mức trung bình. Điều này cho thấy vẫn còn nhiều cơ hội để cải thiện hiệu suất và nâng cao ROI thông qua các hoạt động tối ưu hóa chiến dịch.
- **Good** chiếm 21,87%, trong khi nhóm **Excellent** chỉ đạt 17,36%, phản ánh số lượng campaign thực sự mang lại hiệu quả vượt trội còn khá hạn chế.
- Đáng chú ý, nhóm **Poor** chiếm tới 23,97% tổng số campaign, cho thấy gần 1/4 chiến dịch đang hoạt động kém hiệu quả và có nguy cơ làm lãng phí ngân sách marketing.
- Phân bố ROI hiện tại cho thấy hiệu quả campaign chưa đồng đều, doanh nghiệp cần tập trung tối ưu nhóm Moderate và Poor để cải thiện hiệu suất tổng thể.

Business Action

Mở rộng quy mô chiến dịch thuộc nhóm Excellent. Tối ưu các chiến dịch thuộc nhóm Moderate. Xem xét cắt giảm hoặc cải thiện các chiến dịch thuộc nhóm Poor.

X.8. Kỹ thuật Pivot Table nâng cao

1. Calculated Field: Tính Weighted ROI

Pivot Table không hỗ trợ trực tiếp phép tính "ratio of sums". Nhưng chúng ta có thể dùng **Calculated Field** (trường tính toán) để tạo cột tính toán mới ngay trong Pivot Table:

1. Click vào Pivot Table.
2. Tab **PivotTable Analyze** → **Fields, Items & Sets** → **Calculated Field**.
3. Đặt tên: `Weighted_ROI`.
4. Công thức: `= (Revenue - Total_Spend) / Total_Spend`.
5. Nhấn **Add** → **OK**.

! Tại sao Calculated Field đúng với Weighted ROI?

Calculated Field tính trên **tổng** (Sum) của các cột, không tính trên từng dòng. Ví dụ cụ thể cho Nykaa:

- Calculated Field tính:

$$\frac{\text{SUM Revenue} - \text{SUM Total_Spend}}{\text{SUM Total_Spend}} = \frac{28{,}66\,B - 9{,}70\,B}{9{,}70\,B} = \mathbf{1{,}9545}\ \checkmark$$

- Nếu tính từng dòng rồi lấy trung bình (Simple Average): AVG(ROI) = **2,71** × (sai vì cho trọng số bằng nhau).

Với Weighted ROI, cách "ratio of sums" là **đúng**. Luôn kiểm tra bằng cách so sánh với tính tay trước khi báo cáo.

2. Value Filters: Top N

Cách lọc Top 10 campaign có ROI cao nhất:

1. Click mũi tên ▼ ở **Row Labels**.
2. **Value Filters** → **Top 10**.
3. Chọn: Top **10** Items by **Sum of ROI**.

3. Slicers: Bộ lọc trực quan

Slicer (bộ lọc trực quan) là nút bấm giúp lọc Pivot Table nhanh hơn dropdown. Đặc biệt hữu ích trên dashboard.

1. Click vào Pivot Table.
2. Tab **PivotTable Analyze** → **Insert Slicer**.
3. Tick chọn: **Brand**, **Campaign_Type**, **ROI_Category**.
4. Nhấn **OK**.

Excel tạo 3 bộ slicer. Click vào tên brand/campaign type để lọc Pivot Table ngay lập tức. Giữ `Ctrl` để chọn nhiều giá trị.

Mẹo: Kết nối Slicer với nhiều Pivot Tables

Một Slicer có thể lọc **nhiều** Pivot Table cùng lúc:

1. Right-click Slicer → **Report Connections**.
2. Tick tất cả Pivot Tables cần kết nối.

Rất hữu ích khi xây dashboard: 1 bộ lọc thay đổi tất cả biểu đồ.

X.9. Tổng kết Pivot Tables cần tạo

Pivot Table	Rows	Values	Mục đích
Brand Overview	Brand	Revenue, Spend, Campaigns, ROI	Tổng quan ba thương hiệu
Campaign Type	Campaign_Type	Revenue, ROI, CPA	So sánh hiệu quả giữa các loại campaign
Brand × Type	Brand + Campaign_Type	ROI	Xác định đặc trưng riêng của từng thương hiệu
Monthly Trend	Campaign_Month	Revenue, Campaigns	Phát hiện xu hướng theo thời gian
Customer Segment	Customer_Segment	Revenue, Conversion_Rate, ROI	Xác định phân khúc có tỷ lệ chuyển đổi tốt
Channel Analysis	Primary_Channel	Revenue, ROI, CPA	Đánh giá hiệu quả của các kênh marketing
ROI Distribution	ROI_Category	Count of Campaign_ID	Phân bố các nhóm Excellent, Good, Moderate và Poor

Bảng 23: Tổng hợp các Pivot Table sử dụng trong phân tích dữ liệu marketing

XI. Dashboard: Trực quan hoá dữ liệu với Excel

Pivot Table đã trả lời được các câu hỏi số liệu nhưng số liệu trong bảng không phải thứ sếp muốn nhìn vào mỗi buổi sáng. Một **dashboard** tốt trả lời câu hỏi mà không cần đọc số: nhìn vào là hiểu ngay brand nào đang dẫn đầu, kênh nào đang lỗ, trend đang đi lên hay xuống. Đó là mục tiêu của phần này.

Toàn bộ dashboard được xây trong Excel bằng cách kết hợp **chart từ Pivot Table**, **KPI Cards** từ ô được format, và **Slicers** làm bộ lọc tương tác. Không cần plugin hay công cụ ngoài chỉ cần Excel.

XI.1. Thiết kế layout Dashboard

Trước khi tạo bất kỳ chart nào, hãy quy hoạch layout trên giấy hoặc trực tiếp trên sheet. Bố cục tốt quyết định 50% chất lượng dashboard, chart đẹp nhưng đặt lộn xộn vẫn khó đọc.

Bước 1: Tạo sheet Dashboard

1. Tạo sheet mới, đổi tên thành `Dashboard`.
2. Ẩn gridlines: tab **View** → bỏ tick **Gridlines**. Dashboard không có lưới ô trông sạch và chuyên nghiệp hơn hẳn.

3. Đặt màu nền: chọn toàn bộ sheet (`Ctrl + A`) → **Fill Color** → chọn trắng (`\#FFFFFF`) hoặc xám rất nhạt (`\#F5F5F5`).

Bước 2: Quy hoạch vùng

Vùng	Vị trí	Nội dung
Header	A1:V2	Tiêu đề dashboard và khoảng thời gian phân tích
KPI Cards	A4:V6	4 KPI chính: Revenue, Spend, ROI và số lượng Campaigns
Row 1 Charts	A8:K22 + L8:V22	Biểu đồ so sánh Brand và Campaign Type
Row 2 Charts	A24:K38 + L24:V38	Biểu đồ Funnel và xu hướng theo tháng
Slicers	Bên phải hoặc phía trên charts	Bộ lọc cho Brand, Campaign_Type và ROI_Category

Bảng 24: Bố cục thiết kế Marketing Performance Dashboard trong Excel

Mẹo: Dùng ô Excel như lưới quy hoạch

Trước khi kéo chart vào, hãy tô màu nhạt vào các vùng đã quy hoạch để hình dung bố cục. Sau khi đặt chart xong, xóa màu nền đi. Cách này giúp tránh tình trạng chart bị đặt lệch hoặc chồng lên nhau.

XI.2. KPI Summary Cards

KPI Cards hiển thị 4 con số quan trọng nhất ở vị trí nổi bật nhất dashboard. Người xem nhìn vào đây đầu tiên trước khi đọc bất kỳ chart nào.

Bước 1: Tính giá trị KPI

Ở vùng tính toán ẩn (sheet `Helpers` hoặc vùng ngoài màn hình nhìn), tính các giá trị bằng công thức trực tiếp trên bảng Data:

Công thức KPI Cards

```
Total Revenue:   =SUM(CampaignData[Revenue])
Total Spend:     =SUM(CampaignData[Total_Spend])
Weighted ROI:    =(SUM(CampaignData[Revenue])
                  - SUM(CampaignData[Total_Spend]))
                  / SUM(CampaignData[Total_Spend])
Total Campaigns: =COUNTA(CampaignData[Campaign_ID])
```

Hoặc dùng hàm **GETPIVOTDATA** để kéo giá trị từ Pivot Table (tự cập nhật khi dữ liệu thay đổi):

GETPIVOTDATA từ Pivot Table

```
=GETPIVOTDATA("Revenue", PivotTables!$A$3)
=GETPIVOTDATA("Total_Spend", PivotTables!$A$3)
```

GETPIVOTDATA là gì?

GETPIVOTDATA là hàm lấy giá trị cụ thể từ Pivot Table. Cú pháp: `GETPIVOTDATA(data\_field, pivot\_table\_ref)`. Excel tự sinh hàm này khi bạn click vào ô bên trong Pivot Table từ một ô khác ngoài Pivot Table. Ưu điểm: kết quả tự cập nhật theo Pivot Table kể cả khi dữ liệu gốc thay đổi, không cần sửa công thức.

Bước 2: Format KPI Cards

Mỗi KPI Card chiếm khoảng 5 cột × 3 dòng:

1. **Merge cells**: chọn vùng 5 cột × 3 dòng → **Home** → **Merge & Center**.
2. Dòng trên: label nhỏ, ví dụ `TOTAL REVENUE` (font 10, màu xám `\#808080`, chữ hoa).
3. Dòng giữa: giá trị lớn, ví dụ `85.06B` (font 24, **bold**, màu tối `\#1F2937`).
4. Dòng dưới: thay đổi so với kỳ trước. Tùy chọn, ví dụ `+2.3\%` màu xanh lá nếu tăng, màu đỏ nếu giảm.
5. **Fill color**: mỗi card một màu nền nhạt như xanh lá cho Revenue, xanh dương cho Spend, cam cho ROI, tím cho Campaigns.

Mẹo: Format số lớn thành dạng B/M

85.061.150.201 rất khó đọc. Dùng custom number format để hiển thị gọn hơn:

- Right-click ô → **Format Cells** → **Custom**.
- Nhập `0.00,,"B"` → hiển thị `85.06B`.
- Hoặc `0.0,,"B"` → hiển thị `85.7B`.
- Mỗi dấu phẩy trong format string cắt bớt 3 chữ số: 1 phẩy = nghìn, 2 phẩy = triệu, 3 phẩy = tỷ.

XI.3. Chart 1: Revenue & ROI theo Brand (Combo Chart)

Loại chart: Clustered Column + Line trên Secondary Axis. Mục đích: so sánh cả Revenue/Spend (cột) lẫn ROI (đường) trên cùng một chart mà không cần hai trục Y cùng đơn vị.

Dữ liệu

Brand	Revenue (B)	Spend (B)	Weighted ROI
Nykaa	28,45	9,63	1,95
Purplle	28,36	9,65	1,94
Tira Beauty	28,25	9,65	1,93

Bảng 25: Dữ liệu sử dụng cho biểu đồ Brand Performance

Các bước tạo chart

1. Click vào Pivot Table *Brand Overview* → tab **PivotTable Analyze** → **PivotChart** → chọn **Combo**.
2. Trong hộp thoại Combo: đặt Revenue và Spend là **Clustered Column**, đặt Weighted ROI là **Line** và tick **Secondary Axis**.
3. Tab **Chart Design** → **Add Chart Element**:
   - **Chart Title**: "Revenue, Spend & ROI theo Brand".
   - **Data Labels**: bật cho cả cột lẫn đường.
   - **Legend**: đặt phía dưới chart.
4. Format màu: Revenue = xanh dương (`\#4472C4`), Spend = cam (`\#ED7D31`), đường ROI = xanh lá (`\#70AD47`) với marker tròn.

Tại sao dùng Secondary Axis cho ROI?

Revenue đo bằng tỷ (28–29 B), ROI đo bằng lần (1,93–1,95). Nếu dùng chung một trục Y, đường ROI sẽ bị ép xuống gần đáy và gần như vô hình vì giá trị quá nhỏ so với Revenue. Secondary Axis tạo trục Y riêng bên phải cho ROI, giúp cả hai series hiển thị với tỷ lệ phù hợp.

XI.4. Chart 2: Campaign Type Performance (Horizontal Bar)

Các bước tạo chart

1. Chọn bảng dữ liệu → tab **Insert** → **2-D Bar** → **Clustered Bar**.
2. Sắp xếp: loại ROI cao nhất hiển thị trên cùng. Right-click trục Campaign Type → **Format Axis** → tick **Categories in reverse order**.
3. Bật Data Labels: hiển thị giá trị ROI bên phải mỗi thanh.

Campaign Type	Weighted ROI	Weighted CPA
Paid Ads	1,9634	169,35
Social Media	1,9535	168,68
Email	1,9411	169,91
SEO	1,9298	170,58
Influencer	1,9148	170,70

Bảng 26: Dữ liệu sử dụng cho biểu đồ Campaign Type Performance

4. Màu sắc: dùng gradient từ xanh đậm (cao) đến cam (thấp) để phân biệt hiệu quả trực quan, hoặc chỉ tô màu khác cho thanh dẫn đầu để highlight winner.

Mẹo: Tô màu riêng từng thanh bar

Để mỗi thanh có màu khác nhau theo giá trị ROI:

1. Click vào một thanh bar → click lại lần 2 để chọn riêng thanh đó (không phải toàn bộ series).
2. Right-click → **Format Data Point** → **Fill** → chọn màu.
3. Lặp lại cho từng thanh.

Cách nhanh hơn: giữ nguyên 1 màu cho tất cả, chỉ tô màu khác cho thanh cao nhất (Paid Ads) để mắt người xem tự lập tức chú ý vào winner mà không cần đọc số.

XI.5. Chart 3: Marketing Funnel

Loại chart: Funnel Chart. Mục đích: trực quan hóa hành trình khách hàng từ Impressions → Clicks → Leads → Conversions, cho thấy ngay tầng nào đang rơi rụng nhiều nhất.

Dữ liệu

Tầng	Tổng	Drop-off
Impressions	9,11 B	
Clicks	775 M	91,5% rơi
Leads	310 M	60,0% rơi
Conversions	170 M	45,2% rơi

Bảng 27: Dữ liệu sử dụng cho biểu đồ Marketing Funnel

Tạo Funnel Chart (Excel 2016+ / Microsoft 365)

1. Chọn bảng dữ liệu trên.
2. Tab **Insert** → nhóm **Charts** → chọn **Funnel**.
3. Đặt Chart Title: "Marketing Funnel: Hành trình khách hàng".
4. Bật Data Labels: hiển thị cả giá trị tuyệt đối lẫn tỷ lệ drop-off.

Thay thế nếu phiên bản Excel cũ hơn

1. Dùng **2-D Bar Chart** đơn giản, sắp xếp từ lớn → nhỏ (Impressions trên, Conversions dưới).
2. Thêm cột "khoảng trắng" hai bên để tạo hiệu ứng phễu với **Stacked Bar** đây là kỹ thuật mô phỏng Funnel bằng chart có sẵn.

! Lưu ý về đơn vị trong Funnel Chart

Impressions (9,11 B) và Conversions (170 M) chênh nhau hơn 50 lần. Nếu Excel tự scale trục X, thanh Conversions sẽ gần như biến mất. Giải pháp: hiển thị **tỷ lệ phần trăm** thay vì giá trị tuyệt đối (ví dụ: Clicks = 8,5%, Leads = 3,4%, Conversions = 1,9% so với Impressions), hoặc dùng logarithmic scale nếu phiên bản Excel hỗ trợ.

XI.6. Chart 4: ROI Distribution (Doughnut Chart)

ROI Category	Campaigns	%
Moderate (ROI 0–2)	60.911	37%
Poor (ROI < 0)	39.670	24%
Good (ROI 2–5)	36.208	22%
Excellent (ROI > 5)	28.736	17%

Bảng 28: Dữ liệu sử dụng cho biểu đồ phân bố ROI Campaign

Các bước tạo chart

1. Tạo Pivot Table theo `ROI\_Category` → **Count of Campaign_ID**.
2. Chọn Pivot Table → tab **Insert** → **Doughnut Chart**.
3. Data Labels: tick **Category Name** + **Percentage**.
4. Màu: Excellent = xanh lá (`\#70AD47`), Good = xanh dương (`\#4472C4`), Moderate = vàng (`\#FFC000`), Poor = đỏ (`\#FF0000`).
5. Giảm **Doughnut Hole Size** xuống còn 50–60% để vòng tròn không quá mỏng.

XI.7. Chart 5: Monthly Revenue Trend (Line Chart)

Loại chart: Line Chart. Mục đích: phát hiện mùa vụ, xu hướng tăng/giảm, và các tháng bất thường. Chart này thể hiện những thứ không thể thấy từ bảng số tổng hợp.

Các bước tạo chart

1. Tạo chart từ Pivot Table Monthly (`Campaign\_Month` → **Sum of Revenue**).
2. Tab **Insert** → **Line** → **Line with Markers**.
3. Đặt Chart Title: "Revenue theo thời gian".
4. Trục X: tháng (YYYY-MM), trục Y: Revenue.
5. Thêm Trendline: right-click đường → **Add Trendline** → **Linear** để thấy xu hướng chung.

Mẹo: Thêm Budget Line làm đường tham chiếu

Nếu có thông tin ngân sách mục tiêu, thêm đường ngang **Budget** làm reference:

1. Thêm 1 series "Budget" với cùng giá trị hằng định cho mọi tháng.
2. Format thành đường đứt (**Dash**), màu đỏ, không có marker.
3. Kết quả: nhìn vào chart biết ngay tháng nào Revenue vượt hay dưới target.

XI.8. Chart 6: Top 10 & Bottom 10 Campaigns

Loại chart: Hai Horizontal Bar Charts đặt cạnh nhau. Mục đích: nhìn thấy ngay campaign nào hiệu quả và campaign nào đang không mang lại kết quả tốt, đồng thời tìm mẫu chung của từng nhóm.

Top 10 campaigns theo ROI

1. Dùng Pivot Table với **Value Filter** → **Top 10 by Weighted ROI**.
2. Hoặc dùng hàm `SORT` trên sheet tính toán:

SORT để lấy Top 10

```
=SORT(CampaignData, [ROI column index], -1)
```

3. Tạo **Horizontal Bar Chart** từ 10 dòng đầu.
4. Màu bar: xanh lá (`\#70AD47`).

Bottom 10 campaigns theo ROI

Tương tự nhưng lấy 10 dòng cuối (ROI thấp nhất). Màu bar: đỏ (`\#FF0000`). Đặt hai chart cạnh nhau trên Dashboard.

Câu hỏi cần trả lời khi nhìn vào Top/Bottom 10:

- Top 10 có gì chung? Cùng Campaign Type? Cùng Brand? Cùng kênh?
- Bottom 10 có pattern gì? CPA quá cao? Duration quá dài?
- Nếu tìm được pattern, có thể nhân rộng (với Top) hoặc chủ động tránh (với Bottom) trong các campaigns tiếp theo.

XI.9. Hoàn thiện Dashboard - Visualization trên Excel

Bước 1: Di chuyển charts vào sheet Dashboard

1. Click vào chart → `Ctrl + X` (cắt).
2. Chuyển sang sheet `Dashboard` → click vào vùng đã quy hoạch → `Ctrl + V` (dán).
3. Resize chart cho khớp vùng bằng cách kéo viền. Giữ **Alt** khi kéo để chart tự snap vào lưới ô.

Bước 2: Kết nối Slicers với tất cả charts

1. Di chuyển Slicers từ sheet PivotTables sang sheet Dashboard.
2. Right-click từng Slicer → **Report Connections** → tick chọn tất cả Pivot Tables cần kết nối.
3. Khi click vào Slicer "Nykaa", **tất cả charts** đồng loạt lọc chỉ hiển thị dữ liệu Nykaa.

Bước 3: Thêm Header

Tạo header cho toàn bộ dashboard ở vùng A1:V2:

- Dòng 1: **"Marketing Analytics Dashboard"** font 18, bold, màu tối.
- Dòng 2: *"Project 1 | 3 Brands | 165.525 Campaigns | Period: Jul 2024 – Jun 2025"* font 10, màu xám.

Bước 4: Chuẩn hoá format toàn Dashboard

Bước 5: Ẩn sheet phụ trước khi gửi (tùy chọn)

Khi gửi file cho sếp hoặc đồng nghiệp, ẩn các sheet trung gian để dashboard trông gọn gàng:

1. Right-click tab sheet `Data` → **Hide**.

Yếu tố	Quy chuẩn
Font	Calibri hoặc Segoe UI xuyên suốt, không trộn font
Cỡ chữ	Dashboard title: 18, Chart title: 12, Labels: 10, Data: 9
Màu chính	Xanh dương `\#4472C4`, Cam `\#ED7D31`, Xanh lá `\#70AD47`
Background	Trắng `\#FFFFFF` hoặc xám nhạt `\#F5F5F5`
Border	Nhẹ, xám `\#D9D9D9` và không dùng viền đậm
Number format	Revenue: `0.00,,"B"`, ROI: `0.00`, %: `0.0\%`

Bảng 29: Bảng cấu hình format Dashboard

2. Lặp lại cho sheet `PivotTables` và `Helpers`.
3. Chỉ giữ sheet **Dashboard** hiển thị.
4. Khi cần xem lại: right-click tab bất kỳ → **Unhide** → chọn sheet cần mở.

! Checklist Dashboard hoàn chỉnh

- ☐ Header rõ ràng: tên + period + tổng số campaigns?
- ☐ 4 KPI Cards hiển thị đúng giá trị tổng?
- ☐ Ít nhất 4–6 charts đa dạng: bar, line, funnel, doughnut?
- ☐ Slicers hoạt động lọc đồng loạt tất cả charts?
- ☐ Màu sắc nhất quán, không dùng quá 4–5 màu?
- ☐ Data Labels đầy đủ, số format dễ đọc (B, M, %)?
- ☐ Không có gridlines hay đường kẻ thừa?
- ☐ Print preview vừa trên 1 trang A3 hoặc 2 trang A4?

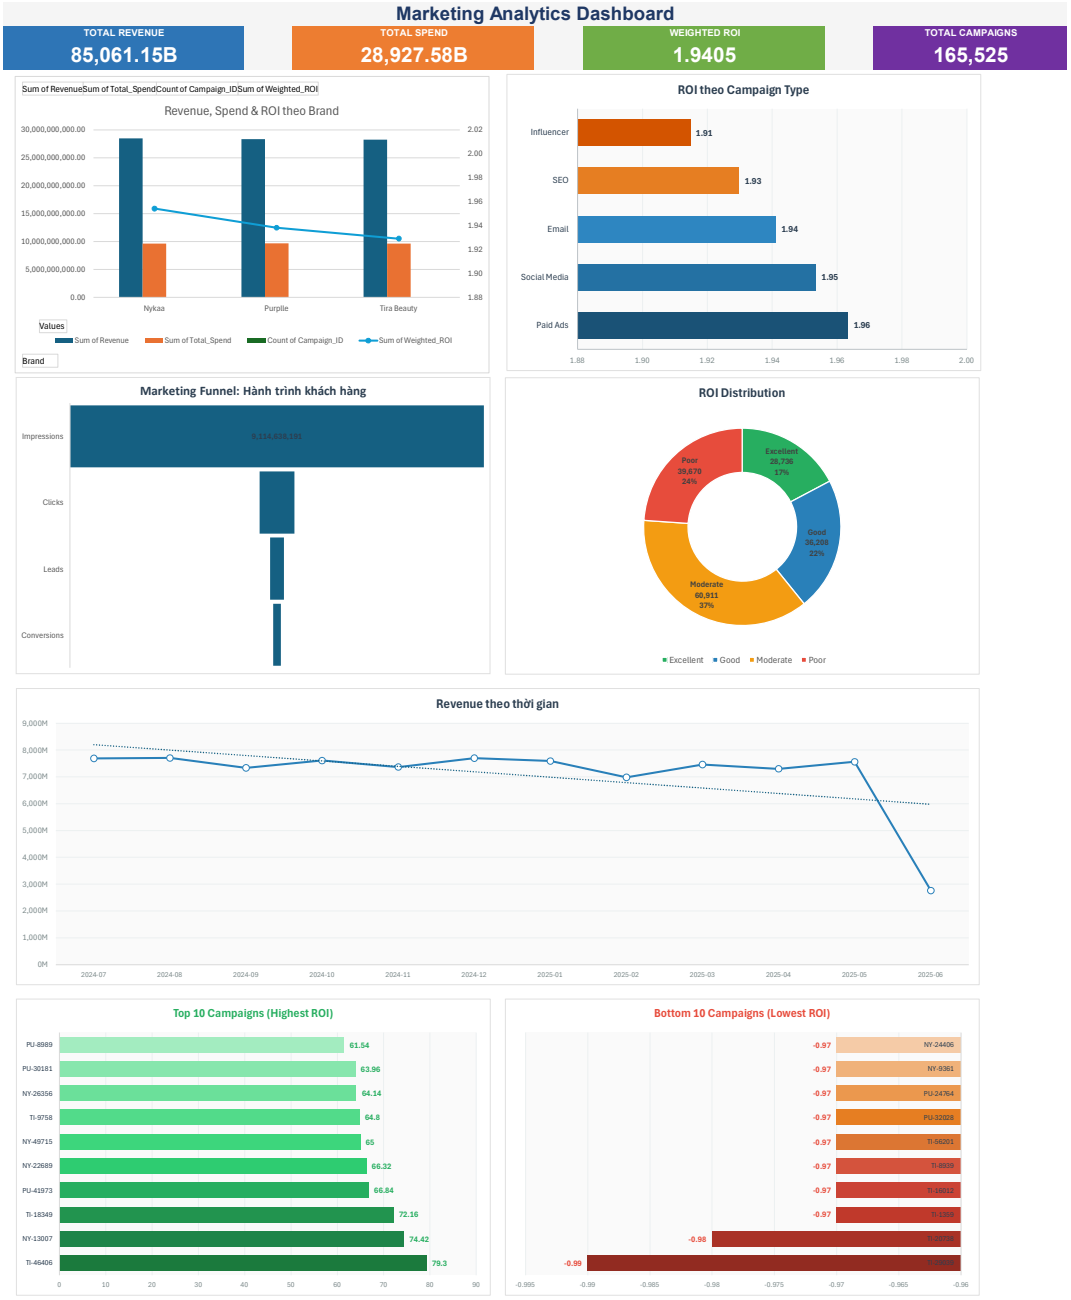

Hình 15: Kết quả visualization trên Excel

XII. Dashboard: Trực quan hoá dữ liệu với Tableau

Tableau và Excel đều tạo được dashboard nhưng theo hai triết lý khác nhau. Excel xây dashboard bằng cách ghép chart vào ô, format thủ công từng pixel. Tableau xây dashboard bằng cách **kéo thả dimension và measure vào canvas**, rồi để Tableau tự tính toán và render trực quan.

Kết quả: Tableau nhanh hơn ở bước đầu, đẹp hơn theo mặc định, và **tương tác tốt hơn** hỗ trợ người dùng có thể click trực tiếp lên biểu đồ để lọc dữ liệu mà không cần cấu hình Slicer riêng.

Dashboard Marketing Analytics trong hướng dẫn này gồm **5 tab chính**, mỗi tab phục vụ một góc nhìn phân tích riêng biệt:

- **Executive Overview**: Tổng quan KPI cấp cao nhất
- **Campaign Performance**: Phân tích hiệu quả theo loại chiến dịch
- **Platform Analysis**: So sánh hiệu quả theo nền tảng
- **Audience & Segment**: Insight theo tệp đối tượng mục tiêu
- **Cost & ROI Optimization**: Tối ưu chi phí và lợi nhuận

Tableau Desktop vs. Tableau Public

- **Tableau Desktop**: phần mềm trả phí, đầy đủ tính năng, kết nối được nhiều nguồn dữ liệu.
- **Tableau Public**: miễn phí, đủ tính năng cho học tập, workbook được lưu công khai trên cloud.

Toàn bộ hướng dẫn trong phần này tương thích với cả hai phiên bản. Tableau Public là lựa chọn phù hợp cho project học tập này.

XII.1. Kết nối dữ liệu

cách 1: Kết nối file Excel

1. Mở Tableau, chọn **Connect** → **Microsoft Excel**,
   dẫn đến file `Marketing\_Analytics\_Dashboard\_View.xlsx`.
2. Kéo sheet dữ liệu vào vùng canvas ở giữa. Tableau hiển thị preview dữ liệu phía dưới.
3. Kiểm tra kiểu dữ liệu từng cột ở hàng header: `Abc` = Text, `\#` = Number, biểu tượng lịch = Date.
4. Nếu cột `Campaign_Date` hiển thị sai kiểu, click vào biểu tượng → chọn **Date**.

Mẹo: Dùng Data Interpreter

Nếu file Excel có header phức tạp hoặc dòng trống thừa, Tableau gợi ý **Use Data Interpreter**. Click vào để Tableau tự dọn dẹp cấu trúc file trước khi import. Thường giúp tránh lỗi kiểu dữ liệu.

Cách 2: Kết nối trực tiếp MySQL → Tableau

Thay vì phải xuất dữ liệu qua Excel, Tableau có thể kết nối trực tiếp đến cơ sở dữ liệu MySQL và tự động đồng bộ dữ liệu mới nhất mỗi khi refresh dashboard. Đây là quy trình phổ biến trong môi trường production vì giúp giảm thao tác thủ công và đảm bảo dữ liệu luôn được cập nhật theo thời gian thực.

MySQL Local vs. MySQL Cloud

- **MySQL Local**: cơ sở dữ liệu được cài đặt và chạy trực tiếp trên máy cá nhân (`localhost`). Hình thức này phù hợp cho mục đích học tập, thử nghiệm và phát triển ban đầu vì dễ cài đặt, không cần cấu hình mạng phức tạp và kết nối với Tableau tương đối đơn giản.
- **MySQL Cloud**: cơ sở dữ liệu được triển khai trên máy chủ từ xa như AWS RDS, Google Cloud SQL, PlanetScale hoặc Aiven. Giải pháp này phù hợp cho môi trường doanh nghiệp và làm việc nhóm vì nhiều người có thể truy cập cùng một nguồn dữ liệu tập trung, đồng thời hỗ trợ khả năng mở rộng, sao lưu và bảo mật tốt hơn.

Mặc dù khác nhau về nơi triển khai, cả MySQL Local và MySQL Cloud đều được kết nối tới Tableau thông qua cùng một giao diện. Điểm khác biệt chủ yếu nằm ở thông tin **Server**, quyền truy cập và cấu hình mạng.

Cài đặt MySQL Connector cho Tableau Để Tableau có thể kết nối và truy vấn dữ liệu từ MySQL, cần cài đặt **MySQL Connector/ODBC**. Đây là driver trung gian giúp Tableau giao tiếp với hệ quản trị cơ sở dữ liệu MySQL.

1. Truy cập trang tải chính thức: https://dev.mysql.com/downloads/connector/odbc/
2. Chọn hệ điều hành phù hợp (**Windows**, macOS hoặc Linux).
3. Tải phiên bản **MySQL Connector/ODBC 8.x** dưới dạng **MSI Installer**. Cần chọn đúng kiến trúc hệ thống:
   - Tableau 64-bit ⇒ Connector 64-bit
   - Tableau 32-bit ⇒ Connector 32-bit
4. Chạy file cài đặt và giữ các thiết lập mặc định: **Next** → **Complete** → **Install**.
5. Sau khi cài đặt hoàn tất, khởi động lại Tableau để hệ thống nhận diện connector mới.

Kiểm tra Tableau đã nhận Connector

Mở Tableau → **Connect** → **To a Server** và kiểm tra xem mục **MySQL** đã xuất hiện trong danh sách hay chưa. Nếu chưa thấy, cần kiểm tra lại:

- Đã cài đúng phiên bản 32/64-bit hay chưa
- Tableau đã được restart sau khi cài connector hay chưa

Kết nối MySQL Local (localhost) Sau khi connector được cài đặt thành công, có thể kết nối Tableau với MySQL Local theo các bước sau:

1. Mở Tableau → **Connect** → **To a Server** → **MySQL**.
2. Nhập thông tin kết nối:

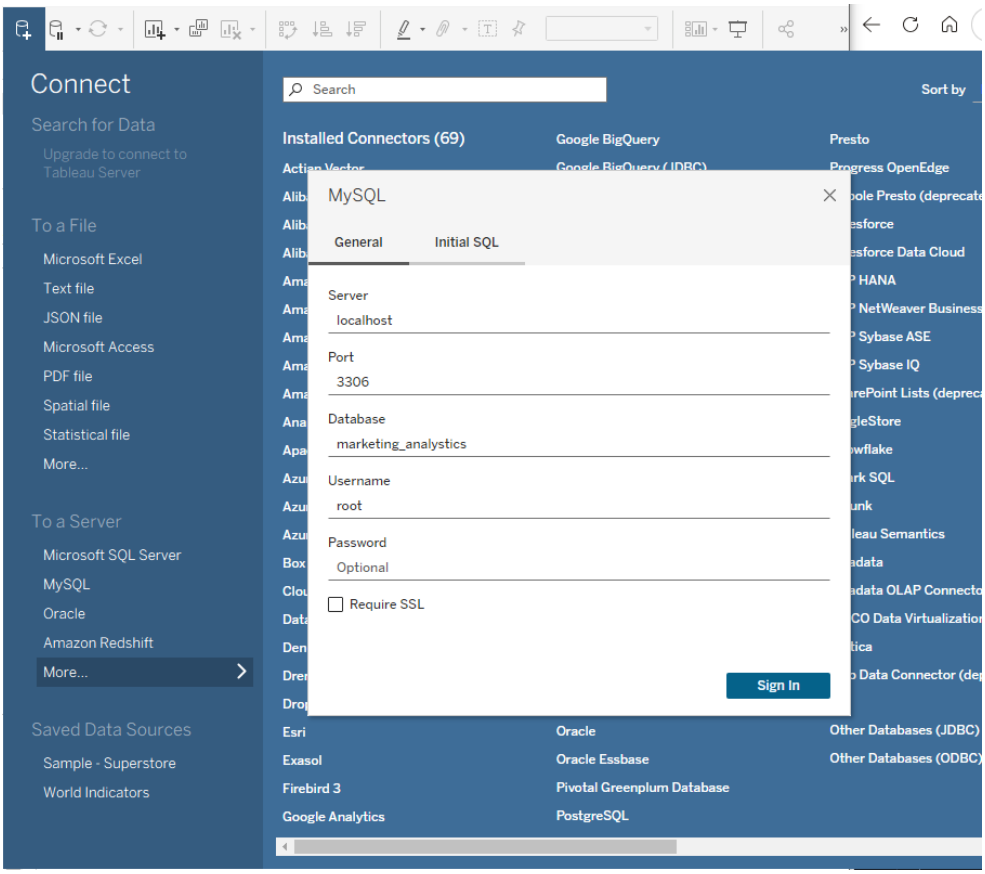

Hình 16: Hộp thoại kết nối MySQL database từ Tableau. Nhập server (localhost) và database (marketing_analytics).

3. Nhấn **Sign In** để kết nối.
4. Tableau sẽ mở tab **Data Source** và hiển thị danh sách các bảng dữ liệu ở khung bên trái.
5. Kéo bảng `campaigns` vào vùng canvas ở giữa màn hình.
6. Tableau sẽ tự động preview dữ liệu và hiển thị khoảng 1.000 dòng đầu tiên để kiểm tra cấu trúc bảng và kiểu dữ liệu.

Trường	Giá trị mẫu	Ý nghĩa
Server	`localhost`	MySQL đang chạy trên chính máy tính hiện tại. Có thể thay bằng `127.0.0.1`
Port	`3306`	Port mặc định của MySQL Server
Database	`marketing_analytics`	Tên database đã tạo trước đó
Username	`root`	Tài khoản MySQL dùng để đăng nhập
Password	*(mật khẩu MySQL)*	Mật khẩu đã thiết lập khi cài MySQL Server
SSL	*(để trống)*	Kết nối local thường không cần SSL

Bảng 30: Thông tin và giải thích các trường kết nối

! Một số lỗi thường gặp khi kết nối MySQL Local

- **"Can't connect to MySQL server on localhost"** ⇒ MySQL Server chưa được khởi động. Kiểm tra trong **Services** xem dịch vụ `MySQL80` có đang ở trạng thái Running hay không.
- **"Access denied for user 'root' "** ⇒ Sai username hoặc password. Nên thử đăng nhập trước bằng MySQL Workbench để xác nhận.
- **MySQL không xuất hiện trong mục Connect** ⇒ Chưa cài MySQL Connector/ODBC hoặc cài sai phiên bản 32/64-bit.

Kết nối MySQL Cloud→ Tableau

Bốn dịch vụ MySQL cloud phổ biến nhất, mỗi dịch vụ có điểm mạnh riêng phù hợp với các nhu cầu khác nhau:

Khuyến nghị cho dự án cá nhân

Aiven là lựa chọn tốt nhất cho dự án này vì: không cần thẻ tín dụng, free tier vĩnh viễn (không bị hết sau 12 tháng như AWS), giao diện đơn giản nhất, và hỗ trợ tạo nhiều user với quyền khác nhau, rất tiện cho làm việc nhóm.

Bước 1: Tạo tài khoản và service Aiven

1. Truy cập https://aiven.io → nhấn **Start Free** → đăng ký bằng email (không cần thẻ tín dụng).
2. Sau khi xác nhận email, đăng nhập vào **Aiven Console**.
3. Nhấn + **Create service** → chọn **MySQL**.
4. Cấu hình service:
   - **Service tier**: chọn **Free**

Tiêu chí	Aiven	PlanetScale	AWS RDS	GCP Cloud SQL
Free tier	Vĩnh viễn, 5 GB	Vĩnh viễn, 5 GB	12 tháng (t2.micro)	90 ngày trial
Thẻ tín dụng	Không cần	Không cần	Cần	Cần
SSL bắt buộc	Có (ca.pem)	Có (tự động)	Có (rds-ca.pem)	Có (server-ca.pem)
Port mặc định	Ngẫu nhiên (vd: 12345)	3306	3306	3306
Độ phức tạp	Thấp nhất	Trung bình	Cao (cần VPC)	Cao
Phù hợp khi	Học tập, project nhóm	Startup, scale nhanh	Production enterprise	Hệ sinh thái Google
URL đăng ký	aiven.io	planetscale.com	aws.amazon.com/rds	cloud.google.com/sql

Bảng 31: So sánh các dịch vụ Cloud Database

- **Cloud**: chọn bất kỳ (Asian Pacific)
- **Plan**: **free - 1 - 1gb**
- **Service name**: đặt tên, ví dụ `mysql-aio2026`

5. Nhấn **Create service**. Đợi 2-3 phút cho đến khi trạng thái chuyển từ *Rebuilding* sang **Running** (chấm tròn màu xanh lá).

! Free tier giới hạn

Aiven free tier giới hạn 1 service cùng lúc và 5 GB dung lượng. Dataset của project này (∼165.525 dòng) chiếm khoảng 30–50 MB, hoàn toàn nằm trong giới hạn. Đủ dùng cho toàn bộ khóa học.

Bước 2: Lấy thông tin kết nối Sau khi service chạy, vào trang Overview của service:

1. Nhấn vào service `mysql-aio2026` trong danh sách.
2. Chọn tab **Overview**.
3. Tìm mục **Connection information**. Thông tin hiển thị dạng:

Thông tin kết nối từ Aiven Console

```
Service URI:  mysql://avnadmin:AVNS_xxxxxxxx@mysql-aio2026-xxx.aivencloud.com:12345/
                                              defaultdb?ssl-mode=REQUIRED

Host:         mysql-aio2026-xxx.aivencloud.com
Port:         12345   # Port ngẫu nhien, khong phai 3306!
Database:     defaultdb
User:         avnadmin
Password:     AVNS_xxxxxxxxxxxxxxx   # Copy va luu lai ngay
SSL Mode:     REQUIRED
```

Lưu ngay thông tin kết nối

Password chỉ hiển thị một lần khi tạo service. Nếu quên, vào **Users** → click **Reset password** (password mới sẽ được tạo, password cũ vô hiệu hóa ngay lập tức).

Bước 3: Tải CA Certificate (ca.pem) Chứng chỉ SSL/TLS là đối tượng kỹ thuật số cho phép các hệ thống xác minh danh tính và sau đó thiết lập kết nối mạng được mã hóa với một hệ thống khác bằng giao thức Lớp cổng bảo mật/Bảo mật lớp truyền tải (SSL/TLS).

1. Vẫn ở trang Overview, tìm mục **CA Certificate** (phía dưới Connection information).
2. Nhấn **Download CA Certificate** → file `ca.pem` được tải về.
3. Lưu file vào một vị trí cố định, ví dụ:

```
Windows:  C:\MySQL_SSL\ca.pem
macOS:    /Users/ten_ban/mysql_ssl/ca.pem
```

4. **Không di chuyển file này** sau khi đã cấu hình Tableau. Nếu di chuyển, kết nối sẽ bị lỗi và phải cập nhật lại đường dẫn.

CA Certificate là gì?

CA là **Certificate Authority**. File `ca.pem` chứa khóa công khai của Aiven, cho phép Tableau xác minh rằng server đang kết nối đến đúng là Aiven, không phải server giả mạo. Tương tự như kiểm tra căn cước công dân trước khi tin tưởng ai đó. Không có `ca.pem`, kết nối vẫn có thể thực hiện nhưng *không an toàn*.

Bước 4: Tạo database và import dữ liệu vào Aiven Aiven tạo sẵn database `defaultdb`. Chúng ta tạo thêm database riêng cho project:

1. Vào service → sidebar trái → **Databases** → **Create database** → nhập `marketing\_analytics` → **Add database**.
2. Kết nối đến Aiven từ **MySQL Workbench**:

Kết nối MySQL Workbench đến Aiven

```
-- Tao ket noi moi trong MySQL Workbench
Connection Name: Aiven - AIO2026
Connection Method: Standard TCP/IP
Hostname: mysql-aio2026-xxx.aivencloud.com
Port:     12345
Username: avnadmin
Password: AVNS_xxxxxxxxxxxxxxx

-- Tab SSL:
Use SSL: REQUIRED
SSL CA File: C:\MySQL_SSL\ca.pem

-- Test Connection -> OK -> Save
```

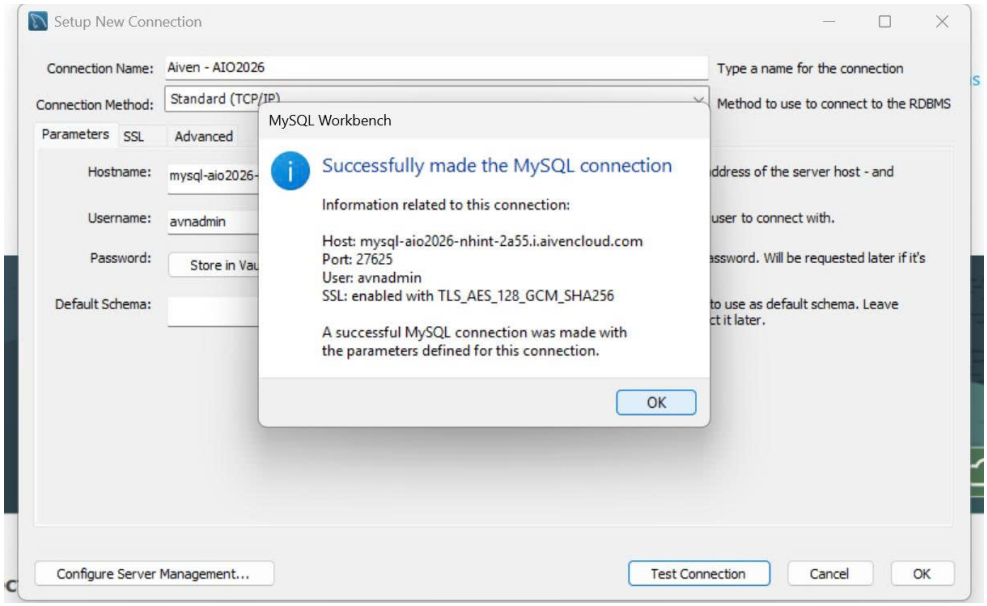

Hình 17: Hộp thoại kết nối MySQL với Aivien

XII.1.1. Kết nối Tableau Desktop → Aiven MySQL với SSL

Bước 1: Cấu hình TDC file cho SSL (chỉ làm một lần) Tableau Desktop từ phiên bản 9.0 trở lên hỗ trợ SSL cho MySQL qua file cấu hình **TDC** (Tableau Datasource Customization). Đây là bước chỉ cần làm *một lần* trên mỗi máy.

1. Mở Notepad (hoặc bất kỳ text editor nào).
2. Tạo file mới với nội dung sau:

File mysql-aiven-ssl.tdc

```
<?xml version='1.0' encoding='utf-8' ?>
<connection-customization class='mysql'
    enabled='true' version='8.0'>
  <vendor name='mysql' />
  <driver name='mysql' />
  <customizations>
    <customization name='odbc-connect-string-extras'
      value='SSLCA={C:\MySQL_SSL\ca.pem};
             SSLMODE=VERIFY_CA' />
  </customizations>
</connection-customization>
```

Chú ý: Thay `C:\MySQL_SSL\ca.pem` bằng đường dẫn thực tế nơi bạn lưu file `ca.pem`. Trên macOS: `/Users/ten_ban/mysql_ssl/ca.pem`.

3. Lưu file với tên `mysql-aiven-ssl.tdc` (đuôi `.tdc`, không phải `.tdc.txt`).
4. Đặt file vào thư mục Tableau Repository:

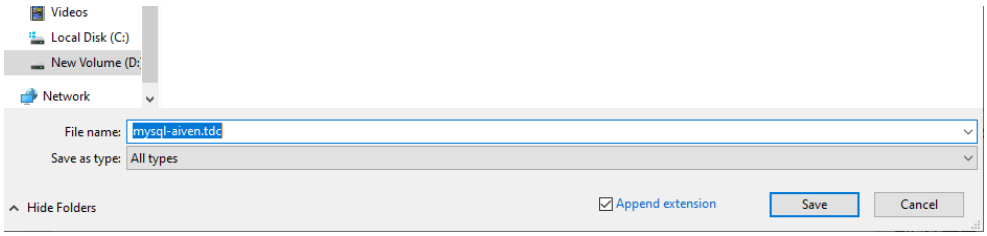

Hình 18: Lưu file mysql-aiven-ssl.tdc để cấu hình TDC file cho SSL

Hệ điều hành	Đường dẫn đặt file TDC
Windows	`Documents\My Tableau Repository\Datasources`
macOS	`~/Documents/My Tableau Repository/Datasources`

Bảng 32: Vị trí lưu Data Source của Tableau theo hệ điều hành

5. **Đóng và mở lại Tableau Desktop** để file TDC được nhận.

Kiểm tra TDC đã có hiệu lực chưa

Sau khi kết nối thành công đến MySQL cloud, mở Tableau logs tại: `Documents\My Tableau Repository\Logs\tabprotosrv.txt` và tìm dòng `SSLCA` nếu xuất hiện nghĩa là TDC đã được áp dụng.

Bước 2: Kết nối Tableau đến Aiven

1. Mở Tableau Desktop → **Connect** → **To a Server** → **MySQL**.
2. Điền thông tin:

Trường	Giá trị	Lấy từ đâu
Server	`mysql-aio2026-xxx.aivencloud.com`	Aiven Console → Overview → Host
Port	`12345` (số ngẫu nhiên)	Aiven Console → Overview → Port
Database	`marketing_analytics`	Tên database đã tạo
Username	`avnadmin` hoặc user read-only	Aiven Console → Users
Password	`AVNS_xxxxxxxx`	Aiven Console (copy lúc tạo)
Require SSL	✓ **Bắt buộc**	Aiven yêu cầu SSL cho mọi kết nối

Bảng 33: Bảng thông tin nguồn giá trị lấy từ Avien kết nối với MySQL

3. Nhấn **Sign In**.
4. Nếu kết nối thành công, Tableau hiển thị **Data Source** tab với bảng `campaigns` xuất hiện ở sidebar trái.

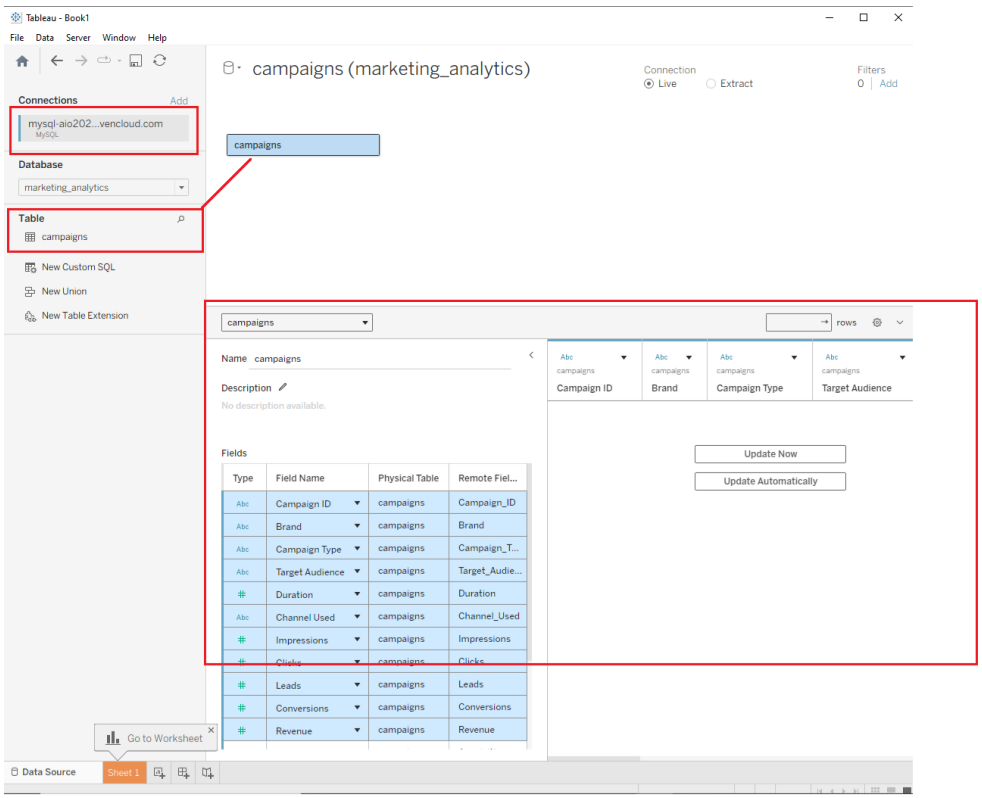

Hình 19: Giao diện Data Source sau khi kết nối với Avien

! Lỗi thường gặp khi kết nối Aiven

- **"SSL connection error"**: File TDC chưa được đặt đúng thư mục, hoặc đường dẫn `ca.pem` trong TDC sai. Kiểm tra lại cả hai.
- **"Can't connect to server"**: Sai port (Aiven dùng port ngẫu nhiên, không phải 3306). Copy đúng port từ Aiven Console.
- **"Access denied"**: User chưa được cấp quyền trên database `marketing_analytics`. Chạy lại lệnh `GRANT SELECT`.
- **"Authentication plugin not supported"**: MySQL Connector/ODBC quá cũ. Cài lại phiên bản mới nhất từ dev.mysql.com/downloads/connector/odbc/.

XII.2. Tiền xử lý dữ liệu trong Tableau sau khi kết nối

Sau khi kết nối thành công đến MySQL (local hoặc Aiven), dữ liệu đã được làm sạch qua 7 bước SQL ở phần trước. Tuy nhiên, Tableau vẫn cần một số bước xử lý bổ sung ở phía client để chuẩn bị cho việc phân tích và xây dashboard.

Phân công xử lý: SQL vs. Tableau

- **SQL đã xử lý**: xóa NULL, xóa duplicate, xóa funnel errors, xóa giá trị âm, chuẩn hóa whitespace.
- **Tableau xử lý tiếp**: kiểm tra kiểu dữ liệu, tạo cột phái sinh (tháng, quý, kênh chính), phân loại campaign theo độ dài và ROI, xử lý NULL phòng thủ.

Nguyên tắc: *tính toán nặng chạy trên server, cấu trúc phục vụ visualization xây ở Tableau.*

Bước 1: Kiểm tra kiểu dữ liệu

Ở **Data Source** tab, mỗi cột có biểu tượng kiểu dữ liệu ngay dưới tên cột. Kiểm tra từng cột quan trọng:

Cách sửa kiểu dữ liệu trong Tableau:

1. Ở Data Source tab, click vào biểu tượng kiểu dữ liệu ngay dưới tên cột.
2. Chọn kiểu đúng từ dropdown: String, Number (decimal), Number (whole), Date, Date & Time, Boolean.
3. Tableau áp dụng ngay lập tức, không cần reconnect.

Cột	Kiểu đúng	Biểu tượng	Nếu sai: cách sửa
`Campaign_Date`	Date	Lịch	Click biểu tượng → chọn **Date**
`Campaign_ID`	String	Abc	Click → **String**
`Impressions`, `Clicks`, `Leads`	Integer	#	Thường đúng ngay nếu là số nguyên
`CTR`, `Lead_Rate`, `ROI`	Decimal	#	Thường đúng ngay nếu là tỷ lệ
`ROI_Category`	String	Abc	Click → **String** nếu bị nhận là Number
`Brand`, `Campaign_Type`	String	Abc	Kiểm tra không có giá trị null hoặc sai format

Bảng 34: Bảng kiểm tra dữ liệu của các cột và gợi ý sửa kiểu dữ liệu phù hợp.

! Campaign_Date bị nhận là String

Đây là lỗi thường gặp khi MySQL trả về DATE nhưng ODBC driver chuyển thành text.
Dấu hiệu nhận biết: cột hiển thị biểu tượng "Abc" thay vì biểu tượng lịch.
Cách sửa nhanh nhất: trong Custom SQL, ép kiểu rõ ràng:

```
-- Them CAST vao Custom SQL
CAST(Campaign_Date AS DATE) AS Campaign_Date
```

Sau đó click **Update Data Source** để Tableau reload query.

Bước 2: Tạo Calculated Fields cột phái sinh

Tương đương với helper columns đã tạo trong Excel (Campaign_Month, Campaign_Quarter...), Tableau dùng **Calculated Field** cột tính toán tồn tại trong Tableau mà không thay đổi dữ liệu gốc. Vào **Analysis** → **Create Calculated Field** (hoặc right-click vào vùng trống trong Data pane → **Create Calculated Field**):

Campaign_Month

Campaign_Month nhóm theo tháng

```
-- Cach 1: giu kieu Date (Tableau tu hien thi "January 2025")
DATETRUNC('month', [Campaign_Date])

-- Cach 2: chuyen sang text dang YYYY-MM (de sort chuan)
STR(YEAR([Campaign_Date])) + "-"
+ RIGHT("0" + STR(MONTH([Campaign_Date])), 2)
-- Ket qua: "2025-01", "2025-02", ...
```

Tương đương công thức Excel: `=TEXT([@Campaign\_Date], "YYYY-MM")`

Campaign_Quarter

Campaign_Quarter nhóm theo quý

```
"Q" + STR(DATEPART('quarter', [Campaign_Date]))
+ "-" + STR(YEAR([Campaign_Date]))
-- Ket qua: "Q1-2025", "Q2-2025", "Q3-2025", "Q4-2025"
```

Tương đương công thức Excel: `="Q" & ROUNDUP(MONTH([@Campaign\_Date])/3,0) & "-" & YEAR(...)`

Primary_Channel kênh marketing chính

Primary_Channel kênh đầu tiên trong danh sách

```
-- SPLIT lay phan tu thu nhat, phan cach bang dau phay
TRIM(SPLIT([Channel_Used], ",", 1))
-- Vi du: "Facebook, Instagram" -> "Facebook"
--        "WhatsApp" -> "WhatsApp"
--        "Google, YouTube, WhatsApp" -> "Google"
```

Tương đương công thức Excel: `=LEFT([@Channel\_Used], FIND(",", [@Channel\_Used] & ",") - 1)`

Channel_Count số kênh mỗi campaign sử dụng

Channel_Count đếm số kênh

```
LEN([Channel_Used])
- LEN(REPLACE([Channel_Used], ",", ""))
+ 1
-- Logic: dem so dau phay + 1 = so kenh
-- "Facebook, Instagram, Google" -> 3
-- "WhatsApp" -> 1
```

Tương đương công thức Excel: `=LEN([@Channel\_Used]) - LEN(SUBSTITUTE(..., ",", "")) + 1`

Duration_Group phân loại độ dài campaign

Duration_Group 4 nhóm theo số ngày chạy

```
IF [Duration] <= 7  THEN "Short (1-7 days)"
ELSEIF [Duration] <= 14 THEN "Medium (8-14 days)"
ELSEIF [Duration] <= 21 THEN "Long (15-21 days)"
ELSE "Very Long (22+ days)"
END
```

Tương đương công thức Excel: `=IF([@Duration]<=7, "Short...", IF([@Duration]<=14, ...))`

Revenue_Per_Conversion giá trị đơn hàng trung bình

Revenue_Per_Conversion AOV mỗi campaign

```
IF [Conversions] > 0
THEN [Revenue] / [Conversions]
ELSE 0
END
-- Tranh chia cho 0 khi campaign chua co conversion nao
```

Profit_Margin tỷ lệ lợi nhuận trên doanh thu

Profit_Margin % lợi nhuận

```
-- Cot Profit da duoc tinh trong Custom SQL:
-- Profit = Revenue - Acquisition_Cost * Conversions
IF [Revenue] > 0
THEN [Profit] / [Revenue]
ELSE 0
END
-- Hien thi dang %: 0.66 = 66%
-- Format: right-click -> Format -> Numbers -> Percentage
```

Calculated Field trong Tableau vs. Helper Column trong Excel

- **Helper Column (Excel)**: tính toán trên từng dòng và lưu kết quả vào bảng. Chiếm dung lượng, khó sửa khi cần thay đổi công thức.
- **Calculated Field (Tableau)**: tính toán *lúc render*, không thay đổi dữ liệu gốc. Có thể tạo, sửa, xóa bất kỳ lúc nào. Không chiếm dung lượng thêm.

Cả hai đều tạo ra cùng một kết quả chỉ khác nhau ở nơi lưu trữ logic tính toán.

Bước 3: Xử lý NULL phòng thủ

Dù SQL đã xóa NULL ở tầng nguồn, dữ liệu qua ODBC đôi khi vẫn có giá trị NULL do lỗi chuyển đổi kiểu. Tạo các Calculated Fields an toàn thay thế NULL bằng giá trị mặc định an toàn:

Calculated Field	Tương đương Excel	Mục đích phân tích
`Campaign_Month`	`TEXT(Date, "YYYY-MM")`	Pivot theo tháng, phát hiện trend
`Campaign_Quarter`	`"Q"&ROUNDUP(MONTH/3,0)`	Pivot theo quý, mùa vụ
`Primary_Channel`	`LEFT(..., FIND(",",...)-1)`	Phân tích hiệu quả theo kênh chính
`Channel_Count`	Đếm dấu phẩy +1	Campaign đa kênh vs. đơn kênh
`Duration_Group`	`IF` lồng 4 nhóm	Campaign ngắn vs. dài
`Revenue_Per_Conversion`	`Revenue/Conversions`	Giá trị đơn hàng theo brand/type
`Profit_Margin`	`Profit/Revenue`	% lợi nhuận trên doanh thu

Bảng 35: Các calculated fields phổ biến và ý nghĩa phân tích trong Tableau

Safe metrics phòng thủ NULL

```
-- Safe CTR: tranh NULL khi Impressions = NULL hoac = 0
IF ISNULL([Impressions]) OR [Impressions] = 0
THEN 0
ELSE [Clicks] / [Impressions]
END

-- Safe ROI: giu NULL thay vi dat = 0
-- (ROI = 0 va khong tinh duoc ROI la 2 truong hop khac nhau)
IF ISNULL([Total_Spend]) OR [Total_Spend] = 0
THEN NULL
ELSE ([Revenue] - [Total_Spend]) / [Total_Spend]
END

-- Safe Conversion Rate
IF ISNULL([Leads]) OR [Leads] = 0
THEN NULL
ELSE [Conversions] / [Leads]
END
```

Khi nào dùng 0 và khi nào giữ NULL?

- **Dùng 0**: cho các chỉ số đếm như Clicks, Leads, Conversions khi NULL thực ra nghĩa là "không có hoạt động".
- **Giữ NULL**: cho các chỉ số tỷ lệ như ROI, CTR, Conversion Rate khi NULL nghĩa là "không tính được". Tableau tự loại NULL khỏi `AVG()` đúng về mặt thống kê, không kéo trung bình xuống sai.
- **Không bao giờ**: thay NULL bằng 0 cho ROI ROI = 0 (hòa vốn) và ROI = NULL (không tính được) là hai trường hợp hoàn toàn khác nhau về ý nghĩa kinh doanh.

Bước 4: Phân loại Dimensions và Measures

Tableau tự động phân loại cột thành Dimension hoặc Measure dựa trên kiểu dữ liệu. Kiểm tra và sửa nếu Tableau phân loại sai:

Loại	Màu	Cột thuộc loại này
Dimension	Xanh dương	Brand, Campaign_Type, Channel_Used, Primary_Channel, Target_Audience, Customer_Segment, Language, ROI_Category, Duration_Group, Campaign_Month, Campaign_Quarter
Measure	Xanh lá	Revenue, Clicks, Impressions, Leads, Conversions, ROI, CTR, Lead_Rate, Conversion_Rate, CPA, Total_Spend, Profit, Profit_Margin, Revenue_Per_Conv, Channel_Count, Duration, Engagement_Score

Bảng 36: Phân loại Dimension và Measure trong bộ dữ liệu marketing analytics

Cách sửa nếu phân loại sai: right-click field trong Data pane → **Convert to Dimension** hoặc **Convert to Measure**.

! Campaign_ID phải là Dimension, không phải Measure

Vì Campaign_ID là chuỗi ký tự (NY-CMP-1000), Tableau thường tự phân loại đúng thành Dimension. Tuy nhiên, nếu Campaign_ID là số nguyên, Tableau có thể nhầm thành Measure và cố tính SUM hoặc AVG vô nghĩa hoàn toàn. Luôn kiểm tra Campaign_ID nằm ở vùng Dimension trước khi xây viz.

Bước 5: Validate dữ liệu

Sau khi thiết lập xong toàn bộ Calculated Fields, chạy kiểm tra nhanh để đảm bảo dữ liệu từ MySQL khớp với kết quả từ Excel:

1. Tạo sheet mới, kéo **Brand** vào Rows, **SUM(Revenue)** vào Columns.

2. So sánh với Pivot Table Brand trong Excel:

Brand	Tableau	Excel	Kết quả
Nykaa	28,66 B	28,66 B	✓
Purplle	28,54 B	28,54 B	✓
Tira Beauty	28,45 B	28,45 B	✓

Bảng 37: So sánh kết quả tính toán giữa Tableau và Excel theo từng brand

3. Kéo **COUNT(Campaign_ID)** vào Text. Kết quả phải là ∼165.525.
4. Kéo **ROI_Category** vào Rows. Kiểm tra đủ 4 giá trị: Excellent, Good, Moderate, Poor.
5. Kéo **Primary_Channel** vào Rows. Kiểm tra đủ 6 kênh: Facebook, Instagram, Google, YouTube, WhatsApp, Email.
6. Kéo **Duration_Group** vào Rows. Kiểm tra đủ 4 nhóm: Short, Medium, Long, Very Long.

Mẹo: Dùng Extract để làm việc offline

Nếu kết nối Aiven chậm hoặc cần làm việc khi không có internet, dùng **Data Extract**:

1. Tab **Data Source** → góc trên phải chọn **Extract** thay vì **Live**.
2. Nhấn **Extract Data** → chọn thư mục lưu.
3. Tableau tải toàn bộ dữ liệu vào file `.hyper` cục bộ và làm việc từ file này, không cần kết nối liên tục.
4. Khi cần đồng bộ dữ liệu mới: **Data** → **Extract** → **Refresh**.

#	Bước	Nội dung	Công cụ
1	Kết nối MySQL	Điền Host, Port, Database, User, Password; bật SSL	Tableau
2	Custom SQL	Chạy query tính sẵn KPI trên MySQL	Tableau
3	Kiểm tra kiểu dữ liệu	Sửa Campaign_Date, ROI_Category nếu bị sai	Data Source tab
4	Tạo Calculated Fields	Month, Quarter, Primary_Channel, Channel_Count, Duration_Group, Revenue_Per_Conv, Profit_Margin	Analysis menu
5	Xử lý NULL phòng thủ	Safe CTR, Safe ROI, Safe Conversion Rate	Calculated Field
6	Phân loại Dim/Measure	Đảm bảo Campaign_ID là Dimension	Data pane
7	Validate	So sánh SUM(Revenue) & COUNT với Excel	Sheet mới
8	Xây Dashboard	5 tab dashboard với 17 views	Dashboard tab

Bảng 38: Quy trình xây dựng dashboard Tableau từ dữ liệu MySQL

Tổng kết: Pipeline đầy đủ từ MySQL đến Tableau

So sánh quy trình tiền xử lý: Excel vs. Tableau

Bước	Excel	Tableau
Kiểu dữ liệu	Power Query tự nhận khi load	Click biểu tượng kiểu dữ liệu ở **Data Source** tab
Cột tháng/quý	Helper column: `TEXT(Date, "YYYY-MM")`	Calculated Field: `DATETRUNC('month', [Date])`
Kênh chính	Helper column: `LEFT([Channel], FIND(",", [Channel])-1)`	Calculated Field: `SPLIT([Channel], ",", 1)`
Phân loại duration	Helper column: `IF` lồng nhau	Calculated Field: `IF...ELSEIF...END`
Xử lý NULL	`IF([@Impressions]>0, ...)`	`IF ISNULL([Impressions]) OR [Impressions]=0 THEN 0`
Kết quả	29 cột (23 cột gốc + 6 helper columns)	23 cột gốc + 7 Calculated Fields

Logic xử lý hoàn toàn giống, chỉ khác cú pháp. Đây là lý do tại sao nắm vững bước tiền xử lý trong Excel giúp làm Tableau dễ dàng hơn: tư duy không thay đổi, chỉ công cụ thay đổi.

XII.3. Thiết lập ban đầu

Bước 1: Tạo Calculated Fields

Trong Excel, chúng ta tạo helper columns (`Campaign_Month`, `Weighted_ROI`...) trực tiếp trên bảng dữ liệu. Trong Tableau, cách làm tương đương là tạo **Calculated Field** cột tính toán tồn tại trong Tableau mà không làm thay đổi file gốc. Vào menu **Analysis** → **Create Calculated Field** (hoặc right-click vào vùng trống trong Data pane → **Create Calculated Field**):

Tên field	Công thức	Mục đích
Campaign_Month	`DATETRUNC('month', [Campaign_Date])`	Nhóm dữ liệu theo tháng
Campaign_Quarter	`DATETRUNC('quarter', [Campaign_Date])`	Nhóm theo quý
Total_Spend	`[Acquisition_Cost] * [Conversions]`	Tổng chi phí marketing
Weighted_ROI	`([Revenue] - [Total_Spend]) / [Total_Spend]`	ROI thực tế sau chi phí
Primary_Channel	`SPLIT([Channel_Used], ",", 1)`	Kênh marketing chính
CTR	`[Clicks] / [Impressions]`	Click-through rate
CPC	`[Total_Spend] / [Clicks]`	Chi phí mỗi click
CPA	`[Total_Spend] / [Conversions]`	Chi phí mỗi acquisition
Weighted_CPA	`SUM([Total_Spend]) / SUM([Conversions])`	Chi phí acquisition trọng số
Revenue_Per_Conv	`[Revenue] / [Conversions]`	Doanh thu trung bình mỗi conversion

Bảng 39: Danh sách calculated fields quan trọng trong Tableau cho phân tích marketing

Calculated Field trong Tableau vs. Helper Column trong Excel

Helper column trong Excel tính toán trên từng dòng và lưu kết quả vào bảng. Calculated Field trong Tableau được tính toán *lúc render*, Tableau không làm thay đổi dữ liệu gốc.

Bước 2: Phân loại Dimensions và Measures

Tableau tự động phân loại cột thành:

- **Dimensions** (màu xanh dương): cột phân loại các cột như Brand, Campaign_Type, Channel_Used, Platform, Target_Audience, Customer_Segment, Language...
- **Measures** (màu xanh lá): cột số như Revenue, Clicks, Impressions, Leads, Conversions, ROI, Total_Spend, CTR, CPA, CPC...

Kiểm tra và sửa nếu Tableau phân loại sai: right-click field → **Convert to Dimension** hoặc **Convert to Measure**.

Bước 3: Thiết lập bảng màu thống nhất

Toàn bộ 5 tab đều dùng bảng màu xanh lá đậm nhất quán. Cách đặt màu mặc định: right-click field dimension trong Data pane → **Default Properties** → **Color**.

Yếu tố	Mã màu	Dùng cho
Màu chính 1	`#1B6B45` (dark green)	KPI card nổi bật, bar cao nhất
Màu chính 2	`#2D9E6B` (medium green)	Bar/line thứ cấp
Màu phụ	`#A8A8A8` (gray)	Paid Ads phân biệt với các kênh khác
Background	`#F5F5F5` (light gray)	Nền sidebar menu
Text tiêu đề	`#0D3D25` (dark green)	Dashboard title, tab headers
Font	Tableau Book / Arial	Xuyên suốt toàn bộ dashboard

Bảng 40: Hệ thống màu và typography chuẩn cho dashboard marketing

XII.4. Tab 1: Executive Overview

Mục tiêu: High-level KPI tracking. Tab này gồm 4 KPI Cards và 4 charts chính hiển thị tổng quan toàn bộ chiến dịch.

KPI Cards (4 thẻ hàng đầu)

Dashboard hiển thị: **Total Revenue** (∼85B) | **Total Spend** (∼29B) | **Total Conversions** (∼170M) | **Weighted ROI** (∼195%, tức 1,95).

1. Tạo sheet mới, đặt tên `KPI\_Revenue`.
2. Kéo **Revenue** vào vùng **Text** trong card Marks, chọn aggregation **SUM**.
3. Format số: right-click `SUM(Revenue)` → **Format** → **Numbers** → **Custom (Number)** → Chọn Display Unit. `86B`.
4. Tăng cỡ chữ: menu **Format** → **Font** → chọn size 36, Bold.

5. Đổi màu nền: **Format** → **Shading** → chọn `\#1B6B45` (xanh đậm) riêng cho card Revenue, chữ trắng để tương phản.
6. Thêm label phụ *Total Revenue*: kéo vào Text, cỡ 14, không bold.
7. Lặp lại cho 3 KPI còn lại với nền trắng, chữ xanh đậm:
`Total\_Spend` → format `"M"`; `Conversions` → format `"M"`; `Weighted\_ROI` → format `0.0"\%"`.

Mẹo: KPI card Revenue có màu khác

Nhìn vào dashboard mẫu, card *Total Revenue* có nền xanh đậm (`\#1B6B45`) và chữ trắng nổi bật hơn 3 card còn lại có nền trắng chữ xanh. Chỉ đặt Shading cho sheet Revenue KPI, 3 sheet còn lại để nền trắng.

View 1: Total Revenue và Total Spend theo Brand (Combo Chart)

1. Tạo sheet `Revenue_Spend_Brand`.
2. Kéo **Brand** vào **Columns**.
3. Kéo **SUM(Revenue)** vào **Rows** Tableau vẽ bar chart tự động.
4. Kéo **SUM(Total_Spend)** vào **Rows**, đặt cạnh `SUM(Revenue)`.
5. Tạo combo chart: right-click `SUM(Total_Spend)` trên Rows → **Dual Axis** → đổi mark type thành **Line**.
6. Đổi màu: bar Revenue = `#1B6B45`, line Total_Spend = `#2D9E6B`.
7. Kéo measure name vào **Color** để thêm legend.

Mẹo: Dual Axis khi đơn vị khác nhau

Revenue tính đơn vị *bn* còn Total_Spend tính đơn vị *M*. **Không** dùng *Synchronize Axis* trong trường hợp này, để hai trục có scale riêng. Chỉ synchronize khi hai measures có cùng đơn vị.

View 2: Total Revenue theo Date (Line Chart)

1. Tạo sheet `Revenue_Date`.
2. Kéo **Campaign_Date** vào **Columns**. Tableau tự nhóm theo Year. Click pill `YEAR` → chọn **Day (continuous)** để xem theo ngày.
3. Kéo **SUM(Revenue)** vào **Rows**. Tableau mặc định chọn Line chart.
4. Đổi màu line: `#2D9E6B`. Thêm circle marks: trong card Marks → chọn **Circle** từ dropdown.

View 3: Total Spend theo Brand (Doughnut Chart)

1. Tạo sheet `Spend_Brand_Donut`.
2. Kéo **Brand** vào **Color**, kéo **SUM(Total_Spend)** vào **Angle**.
3. Trong **Show Me** → chọn **Pie Chart**.
4. Tạo hiệu ứng Doughnut: tạo Calculated Field `Placeholder = MIN(1)`, kéo vào **Rows** → **Dual Axis**. Với trục Placeholder: chọn Pie, giảm Size, đổi màu thành trắng (`#FFFFFF`).
5. Đặt màu: Nykaa = `#1B6B45`, Purplle = `#2D9E6B`, Tira Beauty = `#A8A8A8`.
6. Kéo **Brand** và **SUM(Total_Spend)** vào **Label**, format: `9.70B (33.3%)`.

View 4: Total Spend theo Campaign Type (Horizontal Bar)

1. Tạo sheet `Spend_CampaignType`.
2. Kéo **SUM(Total_Spend)** vào **Columns**, kéo **Campaign_Type** vào **Rows**.
3. Sắp xếp giảm dần: click biểu tượng sort ↓ trên `Campaign_Type`.
4. Tô màu: Paid Ads = `#A8A8A8` (xám), các loại còn lại bằng các shade xanh lá. Kéo **Campaign_Type** vào **Color**.
5. Format trục X: right-click → **Format** → **Numbers** → chọn đơn vị Billions (`Bn`).

XII.5. Tab 2: Campaign Performance

Mục tiêu: Deep dive by campaign type. Tab này gồm 4 KPI Cards khác và 4 views: Spend bar, CTR line, Funnel, Data table.

KPI Sheet	Measure & Aggregation	Format
`KPI_TotalCampaign`	`COUNT(Campaign_ID)`	`#,##0,"K"`
`KPI_AvgCTR`	AVG(CTR)	`0.00`
`KPI_AvgCPC`	AVG(CPC)	`0.00`
`KPI_WeightedCPA`	`SUM([Total_Spend]) / SUM([Conversions])`	

Bảng 41: Các KPI Cards chính dùng để theo dõi hiệu suất campaign

View 5: CTR theo Date (Line Chart)

1. Tạo sheet `CTR_Date`.
2. Kéo **Campaign_Date** vào **Columns** → **Day (continuous)**.
3. Kéo **AVG(CTR)** vào **Rows**.
4. Đổi màu line: `#2D9E6B`. Thêm circle marks. Format trục Y: `0.00`.

View 6: Funnel Chart (Marketing Funnel)

Tableau hỗ trợ Funnel Chart gốc từ phiên bản 2020.4 trở lên. Funnel cần dữ liệu dạng dài (long format): mỗi tầng là một dòng.

Tầng	Calculated Field	Giá trị (tổng)
Impressions	`SUM([Impressions])`	9,11 bn
Clicks	`SUM([Clicks])`	775 M
Leads	`SUM([Leads])`	310 M
Conversions	`SUM([Conversions])`	170 M

Bảng 42: Các tầng dữ liệu sử dụng trong Funnel Chart marketing

Cách 1: Dùng Funnel Chart (Tableau 2020.4+)

1. Tạo sheet mới. Kéo **Stage** (dimension tầng funnel) vào **Rows**, kéo **Value** vào **Columns**.
2. Trong **Show Me** → chọn **Funnel**.
3. Thêm **Label**: tên tầng + giá trị + tỷ lệ drop-off.
4. Tô màu gradient xanh từ đậm (Impressions) → nhạt (Conversions).

Cách 2: Dùng Horizontal Bar Chart (phiên bản cũ hơn)

1. Kéo **Stage** vào Rows, **Value** vào Columns → chọn **Horizontal Bar**.
2. Sắp xếp từ lớn → nhỏ (Impressions trên cùng, Conversions dưới cùng).
3. Thêm Reference Line: **Analytics** pane → kéo **Reference Line** vào chart → chọn giá trị trung bình.

! Lưu ý về logarithmic scale cho Funnel

Khi hiển thị Impressions (9,11 bn) và Conversions (170 M) trên cùng một trục, khoảng cách quá lớn khiến các thanh nhỏ gần như biến mất. Giải pháp: right-click trục X → **Edit Axis** → **Logarithmic**, hoặc hiển thị **tỷ lệ phần trăm** thay vì giá trị tuyệt đối.

View 7: Data Table (Bảng chi tiết)

Bảng dữ liệu phía dưới bên phải với các cột: Brand | Campaign Type | Customer Segment | ROI | Total Revenue.

1. Tạo sheet `Detail_Table`.

2. Kéo **Brand**, **Campaign_Type**, **Customer_Segment** vào **Rows**.
3. Kéo **ROI** và **SUM(Revenue)** vào **Columns**. Trong **Show Me** → chọn **Text Tables**.
4. Sort theo ROI descending. Thêm Total row: **Analysis** → **Totals** → **Show Column Totals**.

XII.6. Tab 3: Platform Analysis

Mục tiêu: Optimize campaigns by platform. Tab này so sánh 3 platform chính: Other, Email, Instagram.

Cột Platform được tạo thế nào?

Dataset không có sẵn cột `Platform`. Đây là một Calculated Field gom `Primary_Channel` thành 3 nhóm nền tảng: **Instagram**, **Email**, và **Other** (gộp Facebook, Google, YouTube, WhatsApp).

Platform gom Primary_Channel thành 3 nhóm

```
IF [Primary_Channel] = "Instagram" THEN "Instagram"
ELSEIF [Primary_Channel] = "Email"     THEN "Email"
ELSE "Other"
END
```

KPI Cards Platform Analysis

Bốn KPI Cards: **Total Revenue** (∼85B) | **Total Spend** (∼29B) | **CTR** (0,09) | **Weighted ROI** (1,94). Tái sử dụng các KPI sheets đã tạo ở Tab 1 và Tab 2 đây là ưu điểm lớn của Tableau, một sheet dùng được ở nhiều dashboard.

View 8: Total Revenue theo Platform (Horizontal Bar)

1. Tạo sheet `Revenue_Platform`.
2. Kéo **SUM(Revenue)** vào **Columns**, kéo **Platform** vào **Rows**.
3. Sort giảm dần. Tô màu theo Platform: Other = `#1B6B45`, Email = `#2D9E6B`, Instagram = `#5AC48A`. Format trục X: đơn vị Billions.

View 9: Total Spend theo Platform (Doughnut Chart)

Tương tự Doughnut Chart ở Tab 1 nhưng dimension thay bằng Platform. Ba phần: Other (∼67%) | Instagram (∼17%) | Email (∼17%).

1. Tạo sheet `Spend_Platform_Donut`.
2. Kéo **Platform** vào **Color**, kéo **SUM(Total_Spend)** vào **Angle**.

3. Áp dụng kỹ thuật Doughnut tương tự Tab 1 (Dual Axis với `Placeholder`).
4. Format label: `19.3B (66.7%)`.

View 10: Data Table Platform Analysis

Bảng chi tiết với các cột: Language | Platform | Channel | Brand | Campaign Type | Total Revenue.

1. Tạo sheet `Platform_Detail_Table`.
2. Kéo **Language**, **Platform**, **Channel**, **Brand**, **Campaign_Type** vào **Rows**.
3. Kéo **SUM(Revenue)** vào **Columns** → **Text Tables**. Sort theo Total Revenue descending.

XII.7. Tab 4: Audience & Segment

Mục tiêu: Audience targeting insights. Tab này phân tích theo 5 tệp đối tượng: Premium Shoppers, Working Women, Youth, Tier 2 City Customers, College Students.

KPI Cards Audience & Segment

Bốn KPI Cards: **Total Conversions** (∼170M) | **CTR** (0,09) | **Weighted ROI** (∼195%) | **Total Campaign** (∼167K).

View 11: Total Conversions theo Audience (Bar Chart)

1. Tạo sheet `Conversions_Audience`.
2. Kéo **Target_Audience** vào **Columns**, kéo **SUM(Conversions)** vào **Rows**.
3. Tô màu theo gradient xanh lá (đậm → nhạt ứng với revenue cao → thấp). Format trục Y: đơn vị Millions.

View 12: CTR và Total Conversions theo Date (Scatter Plot)

Dashboard dùng Scatter Plot với 2 màu (2024 và 2025) để so sánh hai năm hiệu quả.

1. Tạo sheet `CTR_Conversions_Scatter`.
2. Kéo **SUM(Conversions)** vào **Columns** (trục X), kéo **AVG(CTR)** vào **Rows** (trục Y).
3. Kéo **Campaign_Date** vào **Detail** → right-click → Discrete → **Year** → kéo vào **Color**.
4. Đặt màu: 2024 = `#1B6B45` (đậm), 2025 = `#2D9E6B` (nhạt hơn). Trong card Marks → chọn **Circle**.
5. Thêm Trend Line: **Analytics** pane → kéo **Trend Line** → **Linear**.

Mẹo: Scatter Plot so sánh 2 năm

Khi mỗi điểm là một ngày, tô màu theo năm (2024 vs. 2025) cho phép thấy ngay xu hướng so sánh theo thời gian mà không cần hai chart riêng biệt. Đây là kỹ thuật mà Excel không làm được dễ dàng.

View 13: Total Revenue theo Audience (Treemap)

1. Tạo sheet `Revenue_Audience_Treemap`.
2. Kéo **Target_Audience** vào **Color** và **Label**. Kéo **SUM(Revenue)** vào **Size**.
3. Trong **Show Me** → chọn **Treemap**.
4. Đặt palette xanh lá đơn sắc (dark → light ứng revenue cao → thấp). Kéo **SUM(Revenue)** vào **Label**.

XII.8. Tab 5: Cost & ROI Optimization

Mục tiêu: Tối ưu chi phí và lợi nhuận. Tab này so sánh Revenue vs. Spend theo Platform, ROI trend, CPA theo Campaign Type, và Scatter Plot nâng cao.

KPI Cards Cost & ROI Optimization

Bốn KPI Cards: **Total Revenue** (∼85B) | **Total Spend** (∼29B) | **Total Conversions** (∼170M) | **Avg Engagement** (13,8).

Avg Engagement là KPI mới: tạo sheet `KPI_AvgEngagement` → kéo **Engagement_Score** → aggregation **AVG** → format `0.0`.

View 14: Total Revenue và Total Spend theo Platform (Combo Chart)

Tương tự Combo Chart ở Tab 1 nhưng dimension là Platform thay vì Brand.

1. Tạo sheet `Revenue_Spend_Platform`.
2. Kéo **Platform** vào **Columns**.
3. Kéo **SUM(Revenue)** vào **Rows** → Bar chart. Kéo **SUM(Total_Spend)** cạnh đó → Dual Axis → đổi thành Line.
4. Màu bar Revenue = `#1B6B45`, line Spend = `#A8A8A8`.

View 15: ROI theo Date (Line Chart)

1. Tạo sheet `ROI_Date`.
2. Kéo **Campaign_Date** vào **Columns** → **Day (continuous)**.
3. Kéo **AVG(Weighted_ROI)** vào **Rows**. Format trục Y: `0\%` (hiển thị 200%, 300%, 400%).
4. Đổi màu line: `#2D9E6B`. Thêm circle marks.

View 16: CPA theo Campaign Type (Horizontal Bar)

1. Tạo sheet `CPA_CampaignType`.
2. Kéo **AVG(CPA)** vào **Columns**, kéo **Campaign_Type** vào **Rows**.
3. Sort theo CPA giảm dần: SEO > Influencer > Email > Social Media > Paid Ads.
4. Tô màu: Paid Ads = `#A8A8A8`, còn lại = shade xanh lá. Format trục X: `0.0`.

View 17: Spend vs. Revenue theo Date (Scatter Plot)

1. Tạo sheet `Spend_Revenue_Scatter`.
2. Kéo **SUM(Total_Spend)** vào **Columns** (trục X, đơn vị K), kéo **SUM(Revenue)** vào **Rows** (trục Y, đơn vị bn).
3. Kéo **YEAR(Campaign_Date)** vào **Color**: 2024 = `#1B6B45`, 2025 = `#2D9E6B`. Trong Marks → chọn **Circle**.

XII.9. Xây dựng Dashboard trong Tableau

Sau khi hoàn thành toàn bộ 17 views riêng lẻ, bước cuối là lắp ghép chúng vào 5 Dashboard tabs.

Bước 1: Tạo 5 Dashboard sheets

Click biểu tượng **New Dashboard** ở thanh tab phía dưới (hoặc menu **Dashboard** → **New Dashboard**).

Thiết lập kích thước:

- **Fixed size**: chọn **1366** × **768** (laptop phổ biến) hoặc **1920** × **1080** (full HD).
- **Automatic**: Tableau tự scale theo màn hình người xem. Linh hoạt hơn nhưng khó kiểm soát layout chính xác.

Bước 2: Quy hoạch layout chuẩn

Mỗi tab đều có cấu trúc layout nhất quán:

Bước 3: Kéo views vào Dashboard

1. Trong panel **Sheets** bên trái, kéo từng view vào vùng canvas tương ứng với quy hoạch.
2. Tableau hỗ trợ hai chế độ layout: **Tiled** (lưới tự động căn chỉnh) và **Floating** (đặt tự do, chồng lên nhau được). Khuyến nghị dùng **Tiled** cho phần thân dashboard, **Floating** cho sidebar và tiêu đề.
3. Resize từng view bằng cách kéo viền. Giữ **Shift** để resize đồng đều.

Vùng	Vị trí	Nội dung
Left Sidebar	Cột trái ≈250 px, full height	Logo + 5 nút menu navigation
Header	Phần trên cột phải	Tiêu đề tab + Purpose + 4 filter dropdowns
KPI Row	Hàng 1 sau header	4 KPI Cards chia đều theo chiều ngang
Chart Row 1	Hàng 2, chia đôi	Chart chính bên trái + Chart phụ bên phải
Chart Row 2	Hàng 3, chia đôi	Chart chính bên trái + Data table bên phải

Bảng 43: Cấu trúc layout tổng thể của dashboard marketing analytics

Bước 4: Tạo Left Sidebar Navigation

Dashboard mẫu có sidebar với logo *Your Logo* và 5 nút menu. Tableau không có widget nút bấm sẵn:

1. Tạo một **Image** object: Dashboard pane → **Objects** → **Image**. Upload logo.
2. Tạo 5 **Button** objects (Tableau 2018.3+): Dashboard pane → **Objects** → **Button** → **Edit Button** → **Navigate to** → chọn tab đích. Chỉnh text và màu nền `\#1B6B45`.
3. Nút đang active (tab hiện tại): thêm mũi tên chỉ thị bằng Shape object màu trắng đặt bên cạnh.
4. Tạo **Navigation Actions**: **Dashboard** → **Actions** → **Add Action** → **Navigate**.

Bước 5: Tạo KPI Cards

Tableau không có KPI Card sẵn như Excel. Cách làm tương đương:

1. Tạo **Text Sheet** mới: kéo measure vào **Text**, chọn aggregation phù hợp.
2. Format: menu **Format** → **Font** → tăng cỡ chữ lên 36, bold. Đổi màu nền bằng **Format** → **Shading**.
3. Kéo Text Sheet này vào Dashboard như một view thông thường.
4. Lặp lại cho tất cả KPI của từng tab.

Mẹo: Dùng Tableau Extensions cho KPI Cards đẹp hơn

Tableau Marketplace cung cấp các **Extensions** miễn phí như *KPI Indicator* hay *SuperTables* giúp tạo KPI Card chuyên nghiệp hơn mà không cần code. Vào **Dashboard** → **Extensions** → tìm kiếm "KPI" để xem danh sách.

Bước 6: Thêm Global Filters

Mỗi tab đều có bộ filter riêng ở góc trên phải (Channel, Brand, Platform, Campaign Type...):

1. Click vào một view trên Dashboard → biểu tượng ▼ ở góc trên phải → **Filters** → chọn dimension cần filter.
2. Dổi style: click mũi tên trên filter → **Single Value (Dropdown)**.
3. Để filter áp dụng cho *tất cả* views trong tab: click vào filter → **Apply to Worksheets** → **All Using This Data Source**.

Tab	Filters hiển thị
Executive Overview	Channel, Brand, Platform, Campaign Type
Campaign Performance	Channel, Brand, Platform, Campaign Type
Platform Analysis	Language, Channel, Platform, Campaign Type
Audience & Segment	Target Audience, Brand, Segment, Campaign Type
Cost & ROI Optimization	Segment, Brand, Platform, Campaign Type

Bảng 44: Danh sách filters được hiển thị theo từng dashboard tab

Bước 7: Thêm Dashboard Actions

Đây là điểm Tableau vượt trội hoàn toàn so với Excel Slicers:

1. Menu **Dashboard** → **Actions** → **Add Action** → **Filter**.
2. **Source Sheet**: chọn chart nguồn (ví dụ bar chart Brand).
3. **Run Action On**: *Select* (click chuột).
4. **Target Sheets**: chọn tất cả views trong tab.
5. **Clearing the selection**: chọn *Show All Values*.
6. Lặp lại cho các dimension khác: Campaign Type, Platform, Audience.

Kết quả: khi click vào thanh bar "Nykaa" trong Chart 1, **tất cả charts** tự lọc chỉ hiển thị dữ liệu Nykaa mà không cần filter dropdown riêng.

Dashboard Actions: Ba loại chính

- **Filter Action**: click vào một điểm dữ liệu → lọc các charts khác. Đây là loại phổ biến và hữu ích nhất.
- **Highlight Action**: hover chuột → làm nổi bật các điểm dữ liệu liên quan trên charts khác (không ẩn dữ liệu).
- **URL Action**: click → mở URL bên ngoài (hữu ích để link đến báo cáo chi tiết).

Bước 8: Format thống nhất toàn Dashboard

Yếu tố	Quy chuẩn
Font	Tableau Book hoặc Arial xuyên suốt
Cỡ chữ	Dashboard Title: 24 pt; Chart Title: 12 pt; Labels: 10 pt; Tooltip: 9 pt
Màu chính	Xanh đậm `#1B6B45`, Xanh vừa `#2D9E6B`, Xám `#A8A8A8`
Background	Trắng (`#FFFFFF`) hoặc xám rất nhạt (`#F5F5F5`)
Borders	**Format** → **Dashboard** → **Shading**; thêm viền nhạt để phân tách các view
Number Format	Revenue: `#,##0.00,,"B"`;
	Spend: `#,##0.00,"M"`;
	ROI: `0.0"%"`

Bảng 45: Quy chuẩn thiết kế giao diện và định dạng dashboard Tableau

Để format number: right-click measure trong Data pane → **Default Properties** → **Number Format** → chọn **Custom** và nhập format string.

XII.10. Publish và chia sẻ

Tableau Public

1. Menu **Server** → **Tableau Public** → **Save to Tableau Public**.
2. Đăng nhập tài khoản Tableau Public (miễn phí tại `public.tableau.com`).
3. Workbook được publish với URL riêng. Có thể chia sẻ link hoặc embed vào website bằng iframe.
4. Kiểm tra dashboard trên trình duyệt: click từng filter, từng action để xác nhận hoạt động đúng.

! Lưu ý khi dùng Tableau Public

Toàn bộ dữ liệu được upload công khai cùng với workbook. **Không dùng Tableau Public với dữ liệu nhạy cảm hoặc dữ liệu khách hàng thật.** Với project học tập dùng synthetic data, đây không phải vấn đề.

XII.11. Checklist Dashboard hoàn chỉnh

	Hạng mục kiểm tra
☐	5 tab đầy đủ: Executive Overview, Campaign Performance, Platform Analysis, Audience & Segment, Cost & ROI Optimization?
☐	Left sidebar navigation hoạt động click nút chuyển đúng tab?
☐	4 KPI Cards mỗi tab hiển thị đúng giá trị (∼85B / ∼29B / ∼170M / ∼195%)?
☐	Bảng màu nhất quán xanh lá đậm xuyên suốt 5 tab?
☐	Filter dropdowns hoạt động và áp dụng cho tất cả views trong tab?
☐	Dashboard Actions: click Brand/Platform/Audience lọc toàn bộ tab?
☐	Funnel Chart hiển thị đúng 4 tầng với tỷ lệ drop-off?
☐	Scatter Plots phân biệt 2024 vs. 2025 bằng màu?
☐	Doughnut Charts hiển thị đúng label phần trăm?
☐	Data Tables sort đúng thứ tự và có Total row?
☐	Format số chuẩn: bn / M / K / % tương ứng từng metric?
☐	Publish Tableau Public và kiểm tra link hoạt động trên trình duyệt?

Sự khác biệt cốt lõi giữa Tableau và Excel Dashboard

Không phải chart nào trong Tableau cũng "đẹp hơn" Excel mà Tableau **tương tác tốt hơn**. Khi người xem có thể tự click, filter, và khám phá dữ liệu, họ tìm ra insight của riêng mình thay vì chỉ đọc câu chuyện người phân tích kể. Đó là giá trị thực sự của Tableau trong môi trường business: biến người xem từ *bị động* thành *chủ động*.

XIII. Phân tích và Insight

Dashboard đã được hoàn thiện, tuy nhiên đây mới chỉ là bước đầu của quá trình phân tích. Giá trị cốt lõi không nằm ở hình thức trực quan của biểu đồ hay mức độ đầy đủ của bảng số liệu, mà ở khả năng diễn giải dữ liệu thành những kết luận có ý nghĩa đối với hoạt động kinh doanh. Ban lãnh đạo không quan tâm Nykaa có Weighted ROI đạt 1,9545, mà quan trọng hơn là hiểu được kết quả này dẫn đến hành động nào. Ví dụ Nykaa nên ưu tiên tăng ngân sách cho các chiến dịch

Social Media vì đây là loại chiến dịch mang lại hiệu quả đầu tư cao nhất của thương hiệu.Đó mới chính là insight. Phần phân tích dưới đây được triển khai theo hai lớp:

- Phân tích tổng quan để nhìn bức tranh chung của dữ liệu.
- Phân tích đa chiều để tìm ra các xu hướng và mối quan hệ ẩn phía sau các con số.

XIII.1. So sánh hiệu quả giữa các Brand

Bảng dưới đây tổng hợp sáu chỉ số chính của ba thương hiệu từ Pivot Table theo Brand:

Chỉ số	Nykaa	Purplle	Tira Beauty	Nhận xét
Total Revenue	28,45 B	28,36 B	28,25 B	Nykaa dẫn đầu, chênh ∼0,7%
Total Spend	9,63 B	9,65 B	9,65 B	Spend gần bằng nhau
Weighted ROI	1,9542	1,9382	1,9291	Nykaa hiệu quả nhất
Weighted CPA	169,06	170,08	170,39	Tira Beauty weighted CPA cao nhất
CTR	8,51%	8,50%	8,50%	Gần như không chênh lệch
CVR (Conv/Clicks)	22,03%	21,96%	21,94%	Gần như không chênh lệch

Bảng 46: So sánh 6 chỉ số chính giữa 3 thương hiệu

Insight 1: Nykaa dẫn đầu, nhưng khoảng cách không đáng kể.
Hiệu suất của cả ba thương hiệu gần như tương đương nhau. Nykaa đạt ROI cao nhất, nhưng chỉ nhỉnh hơn Tira Beauty khoảng 1,3%. Trong khi đó, Tira Beauty lại có weighted CPA cao nhất, cho thấy thương hiệu này phải bỏ ra chi phí cao hơn để có được một khách hàng.
Tuy nhiên, Nykaa vẫn tạo ra doanh thu cao nhất nhờ tỷ lệ chuyển đổi tốt hơn. Điều này cho thấy hiệu quả không chỉ đến từ việc giảm chi phí quảng cáo mà còn phụ thuộc vào khả năng biến người quan tâm thành khách hàng thực sự.
Trong môi trường kinh doanh thực tế, những chênh lệch nhỏ như vậy thường đến từ các yếu tố khó đo lường trực tiếp như chất lượng nội dung quảng cáo, khả năng nhắm đúng khách hàng hoặc mức độ nhận diện thương hiệu đã được xây dựng trước đó.

Phân phối Weighted ROI điều bị che giấu phía sau giá trị trung bình

Weighted ROI toàn danh mục đạt 1,94 và nhìn qua có vẻ khá tích cực. Tuy nhiên, việc chỉ nhìn vào giá trị trung bình có thể dẫn đến đánh giá sai lệch. Ví dụ:

- Một danh mục có một nửa chiến dịch đạt ROI rất cao và một nửa bị lỗ.
- Một danh mục khác có toàn bộ chiến dịch đạt ROI ổn định quanh mức trung bình.

Hai trường hợp này có thể cho cùng một Weighted ROI trung bình, nhưng mức độ rủi ro và chiến lược quản lý hoàn toàn khác nhau.

Khoảng ROI	Nykaa		Purplle		Tira Beauty	
	SL	%	SL	%	SL	%
ROI > 10	3.376	6,12%	3.258	5,90%	3.213	5,82%
ROI $[5, 10]$	6.388	11,58%	6.279	11,38%	6.222	11,28%
ROI $[2, 5]$	11.981	21,71%	12.023	21,79%	12.204	22,12%
ROI $[0, 2]$	20.152	36,52%	20.289	36,77%	20.470	37,10%
ROI < 0	13.278	**24,07%**	13.326	**24,15%**	13.066	**23,68%**

Bảng 47: Phân phối Weighted ROI theo từng thương hiệu cho thấy tỷ lệ campaign thua lỗ vẫn chiếm gần một phần tư tổng số campaign

Insight 2: Phân phối Weighted ROI giữa ba thương hiệu khá tương đồng, nhưng Tira Beauty cho thấy xu hướng hiệu quả ổn định hơn ở nhóm ROI dương.
Khi quan sát phân phối Weighted ROI thay vì chỉ nhìn giá trị trung bình, có thể thấy phần lớn campaign của cả ba thương hiệu đều tập trung ở nhóm ROI từ 0 đến 5. Tira Beauty có tỷ lệ campaign ROI âm thấp nhất (23,68%), tỷ lệ campaign ROI từ 2 đến 5 cao nhất (22,12%).Trong khi đó, Nykaa nhỉnh hơn nhẹ ở nhóm ROI rất cao (> 10).Điều này cho thấy Nykaa có xu hướng tạo ra nhiều campaign hiệu suất cực cao hơn. Tira Beauty duy trì phân phối ROI dương ổn định hơn trên diện rộng.

Tại sao phân phối Weighted ROI quan trọng hơn trung bình?

Trong quản lý danh mục campaign, Weighted ROI phản ánh thực tế kinh doanh chính xác hơn Average ROI, bởi nó tính đến quy mô chi phí của từng campaign. Hai chỉ số quan trọng không kém Weighted ROI là **độ lệch chuẩn** và **tỷ lệ campaigns lỗ**. Một danh mục có Weighted ROI cao nhưng phân tán rộng khó kiểm soát và khó dự báo hơn một danh mục ổn định. Về dài hạn, tính nhất quán thường có giá trị hơn những đỉnh cao bất thường.

XIII.2. Phân tích theo loại Campaign

Campaign Type	Weighted ROI	Rank	Weighted CPA
Paid Ads	1,9634	**1**	169,35
Social Media	1,9535	**2**	168,68
Email	1,9411	**3**	169,91
SEO	1,9298	4	170,58
Influencer	1,9148	5	170,70

Bảng 48: So sánh hiệu quả Weighted ROI và Weighted CPA giữa các loại campaign marketing

Insight 3: Paid Ads là loại campaign hiệu quả nhất, Influencer thấp nhất về ROI ngắn hạn.
Paid Ads đạt Weighted ROI cao nhất (1,9634), cho thấy đây là loại chiến dịch mang lại hiệu quả đầu tư tốt nhất. Tuy nhiên, Social Media mới là nhóm có Weighted CPA thấp nhất, ở mức (168,68), trong khi Paid Ads đứng thứ hai với (169,35). Kết quả này cho thấy Paid Ads không phải loại chiến dịch có chi phí chuyển đổi thấp nhất, nhưng vẫn tạo ra tỷ suất hoàn vốn cao hơn nhờ khả năng tiếp cận nhóm khách hàng có nhu cầu rõ ràng và tạo ra giá trị doanh thu tốt hơn trên mỗi khoản chi.
Ngược lại, Influencer có Weighted CPA cao nhất (170,70) đồng thời ghi nhận Weighted ROI thấp nhất (1,9148). Điều này cho thấy chi phí triển khai của nhóm chiến dịch này tương đối cao, trong khi hiệu quả chuyển đổi ngắn hạn chưa tương xứng. Tuy vậy, không nên kết luận rằng Influencer hoàn toàn kém hiệu quả, vì loại chiến dịch này còn có thể tạo ra giá trị dài hạn về nhận diện thương hiệu, mức độ tin cậy và khả năng tiếp cận khách hàng mới, những yếu tố chưa được phản ánh đầy đủ qua Weighted ROI trong ngắn hạn.

Insight 4: Mỗi thương hiệu có một kênh thế mạnh riêng, với hiệu suất Weighted CPA khác nhau.
Khi phân tích sâu hơn theo Brand và Campaign Type:

- Nykaa hoạt động tốt nhất trên Social Media, với Weighted CPA thấp nhất ở kênh này nhờ cộng đồng mạng xã hội mạnh.
- Tira Beauty nổi bật ở Paid Ads, cho thấy khả năng tối ưu quảng cáo trả phí hiệu quả với chi phí acquisition thấp.
- Purplle đạt kết quả tốt về Weighted CPA trên Paid Ads và Email, nhưng chi phí acquisition cao hơn ở Influencer.

Điều này cho thấy không tồn tại một công thức marketing chung cho tất cả thương hiệu. Chiến lược hiệu quả của Nykaa chưa chắc phù hợp với Tira Beauty hay Purplle, và việc lựa chọn kênh campaign cần dựa trên Weighted CPA thực tế của từng brand.

Phân tích CPA sâu hơn theo thương hiệu và loại chiến dịch

Từ kết quả trên, cần tiếp tục xem xét CPA ở mức chi tiết hơn theo từng tổ hợp giữa **Brand** và **Campaign Type**. Phân tích này nhằm xác định những tổ hợp có chi phí chuyển đổi thấp, đồng thời làm rõ liệu hiệu quả chi phí có tập trung ở một số thương hiệu hoặc loại chiến dịch cụ thể hay không? Kết quả sẽ là cơ sở để đề xuất ưu tiên ngân sách cho các nhóm chiến dịch có đặc điểm tương tự.

Campaign Type	Nykaa	Purplle	Tira Beauty	Grand Total
Paid Ads	170,17	169,78	168,10	169,35
Social Media	166,86	169,38	169,83	168,68
Email	169,92	169,23	170,61	169,91
SEO	169,24	170,89	171,61	170,58
Influencer	169,16	171,13	171,85	170,70
Grand Total	**169,06**	**170,08**	**170,39**	**169,84**

Bảng 49: Weighted CPA theo thương hiệu và loại chiến dịch

Insight 5: CPA thấp giúp cải thiện hiệu quả đầu tư, nhưng không phải lúc nào campaign có CPA thấp nhất cũng tạo ra ROI cao nhất.
Khi nhìn riêng vào chi phí chuyển đổi, Social Media có Weighted CPA thấp nhất toàn danh mục với 168,68, trong khi Paid Ads đứng sau với 169,35. Tuy nhiên, kết quả về lợi nhuận lại theo thứ tự ngược lại: Paid Ads có Weighted ROI cao nhất, còn Social Media đứng thứ hai. Điều này cho thấy giảm CPA là một phần quan trọng của bài toán, nhưng chưa đủ để xác định campaign nào nên được ưu tiên ngân sách.
Sự khác biệt thể hiện rõ hơn ở Purplle. Email có Weighted CPA thấp nhất của thương hiệu này với 169,23, nhưng Paid Ads mới là loại campaign mang lại Weighted ROI cao nhất. Nói cách khác, một campaign có thể tốn ít chi phí hơn cho mỗi chuyển đổi nhưng chưa chắc tạo ra giá trị kinh tế tốt hơn trên mỗi đồng ngân sách.
Với Nykaa và Tira Beauty, kết quả nhất quán hơn: Social Media của Nykaa và Paid Ads của Tira Beauty vừa có CPA thấp nhất, vừa đạt ROI cao nhất trong từng thương hiệu. Đây là hai trường hợp mà lợi thế về chi phí chuyển đổi thực sự đi cùng với hiệu quả đầu tư.
Từ đây, chúng ta có thể thấy không nên dùng CPA để thay thế cho ROI. CPA phù hợp để xác định nơi chi phí chuyển đổi đang cao hoặc thấp, còn quyết định phân bổ ngân sách vẫn cần dựa trên ROI và giá trị tạo ra từ mỗi chuyển đổi. Một campaign có CPA thấp nên được xem là ứng viên để phân tích tiếp, chứ chưa phải căn cứ đủ để tăng ngân sách.

Duration Group	Weighted CPA	Weighted ROI	Campaigns
Short (1–7 days)	170,98	1,9176	19.183
Medium (8–14 days)	168,99	1,9521	44.566
Long (15–21 days)	169,28	1,9543	44.522
Very Long (22+ days)	170,57	1,9284	57.254

Bảng 50: So sánh hiệu quả Weighted CPA và Weighted ROI theo thời lượng campaign

Phân tích sâu Campaign ngắn hay dài ngày hiệu quả hơn?

Insight 6: Các campaign kéo dài từ 8 đến 21 ngày đang cho thấy sự cân bằng tốt hơn giữa chi phí chuyển đổi và hiệu quả đầu tư.
Nhìn vào bảng số liệu, hai nhóm campaign có thời lượng từ 8 đến 21 ngày đang cho kết quả tốt hơn so với hai nhóm còn lại. Nhóm Medium (8–14 ngày) có Weighted CPA thấp nhất, đạt 168,99, trong khi nhóm Long (15–21 ngày) có Weighted ROI cao nhất, đạt 1,9543.
Điểm đáng chú ý là kết quả của hai nhóm này khá gần nhau. Weighted CPA chỉ chênh lệch 0,29, còn Weighted ROI chênh lệch 0,0022. Vì vậy, chưa có đủ cơ sở để khẳng định nhóm 8–14 ngày hay 15–21 ngày hiệu quả hơn. Thay vào đó, có thể xem từ 8 đến 21 ngày là lựa chọn hợp lý hơn so với các campaign quá ngắn hoặc kéo dài trên 21 ngày.
Nhóm Short có Weighted CPA cao nhất và Weighted ROI thấp nhất, trong khi nhóm Very Long cũng ghi nhận CPA tăng trở lại và ROI giảm xuống. Điều này cho thấy campaign quá ngắn có thể chưa đủ thời gian để tạo chuyển đổi, còn campaign kéo dài quá lâu có thể bắt đầu mất dần hiệu quả.
Từ kết quả này, khoảng 8–21 ngày có thể được sử dụng làm mốc tham chiếu khi thiết kế campaign mới. Tuy nhiên, đây chưa phải một quy tắc cố định. Chúng ta vẫn cần kiểm tra thêm theo từng thương hiệu, loại campaign và quy mô ngân sách trước khi đưa ra khuyến nghị cụ thể.

! Tương quan không đồng nghĩa với nguyên nhân

Việc các campaign kéo dài 8–21 ngày có kết quả tốt hơn không có nghĩa thời gian là nguyên nhân trực tiếp tạo ra hiệu quả đó. Kết quả còn có thể chịu ảnh hưởng của loại campaign, quy mô ngân sách, mục tiêu truyền thông hoặc đặc điểm khách hàng.
Để kiểm tra ảnh hưởng thực sự của thời lượng, cần so sánh các campaign có điều kiện tương đồng hoặc thực hiện A/B Testing với cùng một campaign nhưng thay đổi số ngày chạy.

XIII.3. Phân tích theo kênh (Channel)

Dùng Pivot Table theo `Primary_Channel`:

Primary Channel	Weighted ROI	Weighted CPA
Instagram	1,97	168,73
Email	1,97	168,53
Facebook	1,93	169,91
Google	1,93	170,69
WhatsApp	1,93	170,57
YouTube	1,92	170,64
Grand Total	**1,94**	**169,84**

Bảng 51: Hiệu quả Weighted ROI và Weighted CPA theo kênh marketing chính

Insight 7: Instagram và Email đang cho thấy kết quả tích cực nhất khi xét đồng thời Weighted ROI và Weighted CPA.
Trong sáu kênh được ghi nhận là Primary Channel, Instagram và Email cùng đạt Weighted ROI cao nhất, ở mức 1,97. Tuy nhiên, hai kênh này nổi bật theo những cách khác nhau. Instagram có Weighted CPA là 168,73, trong khi Email đạt mức thấp hơn, chỉ 168,53, cũng là mức thấp nhất trong toàn bộ bảng.
Điều này cho thấy Email đang tạo ra chuyển đổi với chi phí thấp hơn, còn Instagram vẫn duy trì được mức lợi nhuận tương đương dù chi phí trên mỗi chuyển đổi cao hơn một chút. Đây là điểm cần lưu ý: hai kênh có cùng ROI chưa chắc đang vận hành theo cùng một cấu trúc chi phí.
Các kênh Facebook, Google, WhatsApp và YouTube có Weighted ROI dao động từ 1,92 đến 1,93, thấp hơn nhẹ so với Instagram và Email. Đồng thời, Weighted CPA của các kênh này cũng cao hơn, nằm trong khoảng 169,91 đến 170,69. Kết quả cho thấy nhóm kênh này hiện chưa tạo ra lợi thế rõ ràng về cả chi phí lẫn hiệu quả đầu tư.
Do đó Email và Instagram là hai kênh nên được ưu tiên phân tích sâu hơn khi xem xét phân bổ ngân sách. Tuy nhiên, do chênh lệch giữa các kênh không lớn, quyết định cuối cùng vẫn cần được đối chiếu thêm với loại campaign, thương hiệu và quy mô ngân sách.

! Hạn chế của phân tích theo Primary Channel

Trong dữ liệu này, mỗi campaign chỉ được gán cho một Primary Channel, trong khi trên thực tế một campaign có thể sử dụng nhiều kênh cùng lúc. Vì vậy, kết quả trên chỉ phản ánh hiệu quả của kênh được ghi nhận là kênh chính, không thể hiện đầy đủ đóng góp của các kênh còn lại.
Để phân tích chính xác hơn, cần tách trường Channel_Used thành bảng riêng theo từng campaign và từng kênh. Cách này giúp tránh việc gán toàn bộ Revenue, Spend hoặc ROI của một campaign đa kênh cho duy nhất một kênh.

XIII.4. Hiệu quả ngân sách & Phân bổ ROI

Nhìn vào ROI trung bình là chưa đủ để đánh giá chất lượng toàn bộ danh mục campaign. Điều quan trọng hơn là phân bổ ngân sách đang tập trung vào nhóm campaign nào: hiệu quả cao,

hiệu quả trung bình hay đang thua lỗ.

ROI Category	Campaigns	%	Ý nghĩa
Excellent (ROI > 5)	28.736	17,4%	Hoạt động xuất sắc: mỗi đồng chi ra lãi trên 5 đồng
Good (ROI 2–5)	36.208	21,9%	Hiệu quả tốt, nên duy trì
Moderate (ROI 0–2)	60.911	36,8%	Có lãi nhưng thấp, cần cải thiện
Poor (ROI < 0)	39.670	24,0%	Lỗ, cần xem xét dừng hoặc tái cấu trúc

Bảng 52: Phân bổ campaigns theo ROI Category

Insight 8: Gần một phần tư số campaign đang bị lỗ, nhưng có cơ hội tối ưu lớn.
Có tới 39.670 campaign có ROI âm, tương đương 24,0% tổng số campaign. Điều này đồng nghĩa với việc gần một phần tư ngân sách đang được chi cho các hoạt động không tạo ra lợi nhuận. Đây là cơ hội tối ưu rất lớn. Chỉ cần dừng hoặc tái cấu trúc nhóm campaign này, doanh nghiệp đã có thể cải thiện ROI tổng thể mà chưa cần tăng thêm ngân sách marketing.
Ở chiều ngược lại, khoảng 39,2% campaign thuộc nhóm Excellent và Good đang hoạt động hiệu quả với ROI lớn hơn 2. Nhiệm vụ tiếp theo là:

- Tìm đặc điểm chung của nhóm hoạt động tốt để nhân rộng.
- Xác định nguyên nhân thất bại của nhóm Poor để hạn chế lặp lại.

Insight 9: CPA là chỉ số tạo ra sự khác biệt rõ nhất giữa nhóm campaign có ROI cao và thấp trong dữ liệu hiện tại.

Pattern	Top 10 Campaigns (ROI cao)	Bottom 10 Campaigns (ROI thấp)
CPA	Cực thấp: 8–13	Cực cao: 6.471–15.038
Campaign Type	Đa dạng (Email, Paid Ads, Social Media, SEO, Influencer)	Đa dạng (Email, Paid Ads, Social Media, SEO, Influencer)
Channel	Đa dạng (Email, Facebook, Google, Instagram, WhatsApp)	Đa dạng (Email, Facebook, Google, Instagram, WhatsApp)
Duration	Đa dạng (5–30 ngày)	Đa dạng (5–30 ngày)

Khi so sánh nhóm campaign hiệu quả nhất và kém nhất, gần như không thấy sự khác biệt rõ ràng về:

- Loại campaign (Paid Ads, Social Media, Email, SEO, Influencer đều xuất hiện ở cả hai nhóm).
- Kênh truyền thông (Email, Facebook, Google, Instagram, WhatsApp đều có).
- Thời gian chạy campaign (cả hai nhóm đều có campaigns từ 5–30 ngày).

Điểm khác biệt lớn nhất nằm ở **CPA**:

ROI Category	Weighted CPA
Excellent (ROI > 5)	56,53
Good (ROI 2–5)	118,29
Moderate (ROI 0–2)	236,54
Poor (ROI < 0)	669,96

Nhóm campaign tốt nhất (Excellent) có chi phí chuyển đổi chỉ 56,53, trong khi nhóm kém nhất (Poor) có CPA lên tới 669,96 **gần 12 lần**!

Điều này cho thấy:

Tối ưu CPA là đòn bẩy quan trọng để cải thiện ROI tổng thể.

Nói cách khác, dù campaign chạy ở kênh nào hay kéo dài bao lâu, nếu chi phí để có được một khách hàng quá cao thì ROI cuối cùng vẫn sẽ giảm mạnh. Tương quan âm ở mức trung bình giữa CPA và ROI ($r = -0,37$) cho thấy CPA cao thường đi cùng ROI thấp. Đây mới là tương quan, chưa đủ để khẳng định nhân quả; tuy nhiên vì ROI được tính trực tiếp từ CPA (Total_Spend = CPA $\times$ Conversions) nên CPA vẫn là đòn bẩy hợp lý để ưu tiên tối ưu.

Nhóm Poor thất bại ở giai đoạn nào của funnel?

Biết rằng một campaign bị lỗ là chưa đủ. Điều quan trọng hơn là phải hiểu nguyên nhân gây ra thua lỗ nằm ở đâu trong hành trình khách hàng.

Thông thường có hai tình huống chính:

- CTR thấp: người dùng không muốn nhấp vào quảng cáo. Vấn đề nằm ở nội dung quảng cáo, hình ảnh hoặc thông điệp.
- Conversion Rate thấp: người dùng đã nhấp vào quảng cáo nhưng không mua hàng. Vấn đề nằm ở landing page, trải nghiệm người dùng hoặc mức giá sản phẩm.

Chỉ số funnel	**Excellent (ROI > 5)**	**Poor (ROI < 0)**	**Chênh lệch**
Weighted CTR	10,9%	5,4%	$+5,5$ điểm %
Weighted Lead Rate	44,5%	33,8%	$+10,7$ điểm %
Weighted Conversion Rate	59,8%	47,9%	$+11,9$ điểm %
Weighted CPA	56,53	669,96	$\times 11,9$ lần
Total Impressions	2.095.853.262	1.429.097.594	Khác biệt lớn (47%)

Bảng 53: So sánh các chỉ số funnel Weighted giữa nhóm campaign hiệu quả cao và thấp

Insight 10: Nhóm campaign bị lỗ thất bại mạnh nhất ở bước đầu tiên của funnel.
Weighted CTR của nhóm Poor (5,4%) thấp hơn đáng kể so với nhóm Excellent (10,9%), mặc dù cả hai nhóm đều tiếp cận lượng khách hàng lớn (tính theo tổng impressions).
Điều này rất quan trọng: Hai nhóm đều được tiếp cận lượng người dùng đủ lớn để so sánh (hàng tỷ impressions). Tuy nhiên nhóm Poor không thể biến lượt hiển thị thành lượt clicks một cách hiệu quả.
Nói cách khác, vấn đề không nằm ở độ phủ quảng cáo mà nằm ở chất lượng nội dung quảng cáo. Người dùng nhìn thấy quảng cáo nhưng không đủ hứng thú để dừng lại và nhấp vào. Đây là dấu hiệu điển hình của: Hình ảnh chưa đủ nổi bật, thông điệp chưa rõ ràng, CTA chưa đủ hấp dẫn.

Insight 11: Không phải mọi campaign bị lỗ đều thất bại theo cùng một cách.
Khi phân tích sâu hơn, nhóm Poor được chia thành hai kiểu hoàn toàn khác nhau:

Sub-group	CTR	Conv. Rate	Giải pháp
Poor Type A	$< 5\%$	$> 55\%$	Thay creative (hình ảnh, thông điệp, CTA)
Poor Type B	$> 8\%$	$< 35\%$	Tối ưu landing page (tốc độ, UX, giá)

Đây là sự phân biệt mà phân tích Weighted ROI đơn thuần không bao giờ thấy được.
Poor Type A

- Weighted CTR rất thấp nhưng Weighted Conversion Rate vẫn ổn.
- Nghĩa là người dùng không muốn nhấp vào quảng cáo.
- Giải pháp là thay đổi creative: hình ảnh, tiêu đề, thông điệp hoặc CTA.

Poor Type B

- Weighted CTR khá tốt nhưng Weighted Conversion Rate thấp.
- Nghĩa là quảng cáo đủ hấp dẫn để người dùng nhấp vào, nhưng landing page không đủ thuyết phục để mua hàng.
- Giải pháp là tối ưu giao diện, tốc độ tải trang, UX hoặc chiến lược giá.

Điểm quan trọng là hai nhóm này cần hai hướng xử lý hoàn toàn khác nhau. Nếu áp dụng sai giải pháp, doanh nghiệp không chỉ không cải thiện hiệu quả mà còn lãng phí thêm nguồn lực.

XIII.5. Phân tích theo thời gian: Trend và mùa vụ

Cột `Campaign_Month` và `Campaign_Quarter` được tạo ở bước Data Cleaning chưa được khai thác trong các phân tích trên. Thời gian có thể tiết lộ liệu hiệu quả có tính mùa vụ hay không, đây chính là điều mà bảng tổng hợp thuần tuý không bao giờ cho thấy.

Weighted ROI trung bình theo quý

Quarter	Nykaa	Purplle	Tira Beauty	Weighted CPA
Q3-2024	1,98	1,93	1,92	169,82
Q4-2024	1,95	1,92	1,94	169,78
Q1-2025	1,95	1,96	1,96	168,84
Q2-2025	1,92	1,94	1,88	171,19

Bảng 54: Biến động Weighted ROI và Weighted CPA theo quý cho thấy dấu hiệu seasonality

Insight 12: Q1-2025 là giai đoạn hiệu quả nhất, trong khi Q2-2025 là thời kỳ yếu nhất.
Weighted ROI toàn danh mục đạt mức cao nhất vào Q1-2025 (1,9582) với Weighted CPA thấp nhất (168,84). Ngược lại, Q2-2025 ghi nhận Weighted ROI thấp nhất (1,9144) và Weighted CPA cao nhất (171,19).

Xét từng brand, Nykaa thể hiện sự ổn định cao với Weighted ROI 1,98 vào Q3-2024 và duy trì ở mức 1,95 trong Q1-2025. Tira Beauty lại gặp khó khăn hơn vào Q2-2025 với Weighted ROI chỉ 1,88 và Weighted CPA lên tới 173,56.

Kết quả này cho thấy:

- Q1-2025 là giai đoạn khách hàng có sẵn sàng mua hàng cao (New Year resolution, khởi đầu năm mới).
- Q2-2025 có thể đối mặt với cạnh tranh cao hoặc nhu cầu thấp hơn, làm tăng chi phí chuyển đổi.

Lưu ý rằng Q3-2024 mặc dù không phải là cao nhất nhưng vẫn duy trì Weighted ROI khá tốt (1,9455), cho thấy các giai đoạn mùa vụ khác nhau có tác động khác nhau đến từng brand.

Biến động Weighted ROI theo tháng: Influencer có "mùa hiệu quả"riêng

Campaign	T7	T8	T9	T10	T11	T12
Paid Ads	1,98	1,98	1,97	1,91	1,91	1,99
Social Media	1,98	1,98	1,92	1,89	2,02	1,95
Influencer	2,00	1,89	1,78	1,94	1,95	1,93

Bảng 55: Biến động Weighted ROI theo tháng (T7-T12/2024) cho thấy Influencer tăng hiệu quả vào các giai đoạn cao điểm

Insight 13: Không nên đánh giá Influencer chỉ dựa trên Weighted ROI trung bình cả năm.
Trong phần lớn thời gian, Influencer là loại campaign có Weighted ROI thấp nhất (trung bình 1,91). Tuy nhiên, vào một số giai đoạn như tháng 7 (T7), tháng 10–11 (T10–T11), Weighted ROI của Influencer tăng đáng kể và thậm chí vượt qua các kênh khác.

Điều này cho thấy hiệu quả của Influencer mang tính mùa vụ rõ rệt hơn so với các loại campaign khác. Các giai đoạn liên quan đến:

- Tháng 7: Nhu cầu mua sắm khởi động lại sau mùa hè.
- Tháng 10–11: Chuẩn bị cho các lễ hội tháng cuối năm (Diwali, Black Friday).

có thể làm gia tăng mức độ ảnh hưởng của influencer đến quyết định mua hàng của khách hàng.

Hàm ý quản trị ở đây không phải là cắt giảm hoàn toàn ngân sách cho Influencer, mà là tối ưu thời điểm triển khai:

- Tăng Weighted CPA tolerance (hoặc ngân sách) vào các giai đoạn Influencer đạt Weighted ROI cao (T7, T10–T11).
- Giảm ngân sách trong các tháng có Weighted ROI thấp (đặc biệt T9 với ROI chỉ 1,78).

Doanh nghiệp không nhất thiết phải tăng tổng ngân sách marketing, mà có thể cải thiện hiệu quả đầu tư bằng cách phân bổ ngân sách phù hợp với tính mùa vụ của từng loại campaign, tính theo Weighted ROI thực tế thay vì trung bình cộng.

XIII.6. Phân tích theo phân khúc khách hàng

Customer Segment	Weighted ROI	CVR (Conv/Clicks)
College Students	1,95	22,05%
Working Women	1,95	21,90%
Premium Shoppers	1,92	21,94%
Youth	1,94	22,01%
Tier 2 City Customers	1,95	21,98%

Bảng 56: So sánh Weighted ROI và CVR giữa các nhóm khách hàng

Insight 14: Các phân khúc khách hàng nhìn qua có vẻ tương đồng, nhưng giá trị thật sự rất khác nhau.
Trong bộ dữ liệu hiện tại, ROI và Conversion Rate giữa các nhóm khách hàng không chênh lệch nhiều. Tuy nhiên, điều này phần nào đến từ việc dữ liệu được tổng hợp ở mức cao. Trong thực tế, nhóm khách hàng cao cấp thường tạo ra giá trị đơn hàng lớn hơn nhiều. Nhưng đồng thời chi phí để tiếp cận và chuyển đổi nhóm này cũng cao hơn tương ứng.Vì vậy, doanh thu cao chưa chắc đồng nghĩa với ROI cao hơn.

Revenue Per Conversion: nhóm nào tạo ra giá trị đơn hàng lớn hơn?

ROI và Conversion Rate chỉ cho biết số lượng đơn hàng được tạo ra. Trong khi đó, Revenue Per Conversion phản ánh giá trị của mỗi đơn hàng, tức mỗi khách hàng mang về bao nhiêu doanh thu.

Customer Segment	Nykaa	Purplle	Tira Beauty
Premium Shoppers	499	500	499
Working Women	499	499	501
College Students	500	502	498
Youth	499	499	500
Tier 2 City Customers	500	498	499

Bảng 57: Revenue Per Conversion theo từng nhóm khách hàng và brand

Insight 15: Trong dữ liệu này, Revenue Per Conversion gần như đồng đều (∼500) giữa các phân khúc.

Khác với kỳ vọng thông thường rằng nhóm cao cấp tạo giá trị đơn hàng lớn hơn, dữ liệu tổng hợp của project cho thấy Revenue Per Conversion dao động rất hẹp quanh mức ∼500 ở cả 5 phân khúc và cả 3 brand. Chênh lệch giữa các nhóm chỉ vài đơn vị, không đủ để kết luận phân khúc nào mang lại giá trị đơn hàng cao hơn.

Để đánh giá sâu hơn giá trị thực của từng nhóm khách hàng, bước tiếp theo nên là thu thập thêm dữ liệu hành vi ở cấp khách hàng như tần suất mua lại, tỷ lệ giữ chân (retention) và giá trị vòng đời (CLV) thông tin mà một dataset tổng hợp ở cấp campaign chưa thể hiện được.

Revenue Per Conversion theo loại campaign

Campaign Type	Avg Rev/Conv	Weighted CPA	Tỷ lệ Rev/CPA
Influencer	498	170,70	2,9
Social Media	499	168,68	3,0
Email	500	169,91	2,9
Paid Ads	501	169,35	3,0
SEO	500	170,58	2,9

Bảng 58: So sánh giá trị đơn hàng trung bình và hiệu quả CPA giữa các loại campaign

Insight 16: Revenue Per Conversion và tỷ lệ Rev/CPA gần như đồng đều giữa các loại campaign.

Trong dữ liệu này, Revenue Per Conversion của cả 5 loại campaign đều xấp xỉ 500, và tỷ lệ Rev/CPA dao động hẹp quanh 3,0. Không có loại campaign nào (kể cả Influencer) tạo ra giá trị đơn hàng vượt trội so với các loại khác.

Vì cả giá trị đơn hàng lẫn CPA giữa các kênh đều tương đương (CPA dao động 168,68–170,70), khác biệt về hiệu quả (ROI) chủ yếu đến từ tỷ lệ chuyển đổi và biến động ngẫu nhiên, không phải từ giá trị đơn hàng. Để khẳng định một kênh có thực sự mang lại khách hàng "giá trị cao" hay không, nên bổ sung thêm dữ liệu giá trị vòng đời khách hàng (CLV) và lịch sử mua lại; khi đó mới đủ căn cứ so sánh giá trị khách hàng giữa các kênh.

XIII.7. Tổng hợp toàn bộ 16 Insights

#	Insight	Nguồn / Phương pháp	Ưu tiên
1	Nykaa dẫn đầu Weighted ROI, cao hơn Tira Beauty khoảng 1,3%	Pivot Brand	⋆
2	Tira Beauty có tỷ lệ campaign ROI âm thấp nhất và tỷ lệ ROI từ 2–5 cao nhất, trong khi Nykaa tạo ra nhiều campaign ROI cực cao (> 10) hơn	ROI Distribution	⋆⋆
3	Paid Ads đạt Weighted ROI cao nhất; Influencer thấp nhất về hiệu quả ROI ngắn hạn	Pivot Type	⋆⋆
4	Mỗi thương hiệu có một loại campaign thế mạnh riêng; không tồn tại một công thức phân bổ chung cho cả ba thương hiệu	Brand × Type	⋆⋆⋆
5	CPA thấp hỗ trợ cải thiện ROI, nhưng campaign có CPA thấp nhất chưa chắc tạo ra ROI cao nhất	CPA–ROI Analysis	⋆⋆
6	Campaign kéo dài 8–21 ngày (Medium/Long) có sự cân bằng CPA–ROI tốt hơn campaign quá ngắn hoặc quá dài	Duration × KPI	⋆⋆
7	Instagram và Email có Weighted ROI cao nhất; YouTube thấp nhất, trong khi WhatsApp thuộc nhóm hiệu quả thấp hơn	Pivot Channel	⋆
8	24,0% campaign đang lỗ, cần được xem xét dừng hoặc tái cấu trúc	ROI Category	⋆⋆⋆
9	CPA là chỉ số tạo ra sự khác biệt rõ nhất giữa nhóm campaign ROI cao và nhóm campaign ROI thấp trong dữ liệu hiện tại	Top/Bottom Analysis	⋆⋆⋆
10	Nhóm Poor suy giảm mạnh nhất ngay từ tầng CTR; Lead Rate và Conversion Rate cũng thấp hơn nhóm Excellent	Funnel Analysis	⋆⋆⋆
11	Hai nhóm Poor cần hai chiến lược tối ưu khác nhau, tương ứng với điểm nghẽn tại quảng cáo hoặc tại trải nghiệm sau click	Funnel Subgroup	⋆⋆⋆
12	Q1-2025 đạt hiệu quả cao nhất, trong khi Q2-2025 có hiệu quả thấp nhất	Quarterly Trend	⋆⋆
13	Influencer có dấu hiệu thay đổi hiệu quả theo thời điểm, tăng mạnh ở T7 và T10–T11 trong giai đoạn được quan sát	Time-series Type	⋆⋆
14	Các phân khúc khách hàng có Weighted ROI và CVR khá đồng đều trong dữ liệu hiện tại	Pivot Segment	⋆
15	Revenue Per Conversion khá đồng đều, dao động quanh 500 giữa các phân khúc khách hàng	Rev/Conv × Segment	⋆
16	Rev/Conv và Rev/CPA khá đồng đều giữa các loại campaign; không loại campaign nào tạo ra giá trị đơn hàng vượt trội	Rev/Conv × Type	⋆

Quy ước mức ưu tiên: ⋆ = insight mô tả, chủ yếu dùng để theo dõi; ⋆⋆ = insight cần được cân nhắc khi lập kế hoạch; ⋆⋆⋆ = insight có tác động kinh doanh lớn và có thể chuyển thành hành động cụ thể.

Bảng 59: Tổng hợp 16 business insights quan trọng từ phân tích marketing analytics

! Các insight hành động ưu tiên

Những insight dưới đây có tác động kinh doanh lớn và có thể chuyển thành các hành động tối ưu cụ thể. Riêng insight #13 nên được triển khai dưới dạng thử nghiệm có kiểm soát vì khoảng thời gian quan sát chưa đủ dài để khẳng định chắc chắn tính mùa vụ.

- **#4 – Cá nhân hóa chiến lược theo thương hiệu:** Xây dựng cơ cấu campaign riêng cho từng thương hiệu thay vì sử dụng một công thức phân bổ ngân sách chung. Ưu tiên Social Media cho Nykaa và Paid Ads cho Tira Beauty; các thương hiệu còn lại cần được phân bổ dựa trên thứ hạng ROI riêng của từng loại campaign.
- **#8 + #9 – Kiểm soát campaign thua lỗ và CPA cao:** Rà soát 24,0% campaign đang có ROI âm để quyết định dừng, điều chỉnh hoặc tái cấu trúc. Trong quá trình tối ưu, ưu tiên kiểm soát CPA vì đây là chỉ số tạo ra sự khác biệt rõ nhất giữa nhóm campaign ROI cao và nhóm ROI thấp trong dữ liệu hiện tại.
- **#10 + #11 – Xử lý nhóm Poor theo đúng điểm nghẽn:** Phân tách nhóm Poor thành hai nhóm hành động. Với Type A, ưu tiên thay đổi creative, thông điệp và cách target để cải thiện CTR. Với Type B, tập trung tối ưu landing page, trải nghiệm người dùng, chính sách giá và quy trình thanh toán.
- **#13 – Thử nghiệm phân bổ Influencer theo thời điểm:** Thực hiện thử nghiệm điều chỉnh ngân sách Influencer theo các giai đoạn có ROI cao hơn trong dữ liệu quan sát, cụ thể là T7 và T10–T11, đồng thời giảm ngân sách thử nghiệm ở T9. Kết quả cần được tiếp tục theo dõi qua nhiều chu kỳ trước khi chuẩn hóa thành lịch phân bổ ngân sách theo mùa.

XIV. Business Recommendations

Số liệu chỉ có giá trị khi nó dẫn đến hành động. Phần này không nhằm tổng kết những gì đã phân tích, mà nhằm trả lời một câu hỏi duy nhất: với những gì chúng ta biết, bước đi tiếp theo nên là gì?

Dừng những gì đang kém hiệu quả

Trước khi nghĩ đến tăng trưởng, cần nhìn thẳng vào một thực tế không dễ chịu: gần một phần tư tổng số campaigns đang chạy là **đang lỗ**. Không phải kém hiệu quả mà là mỗi đồng bỏ vào thu về ít hơn một đồng. Nhóm này có CPA trung bình cao hơn đáng kể so với mức chung của toàn bộ danh mục, và vẫn đang tiêu tốn ngân sách mỗi ngày.

- **Dừng ngay** các campaigns lỗ nặng (ROI $< -0{,}5$): không chờ hết thời hạn, mỗi ngày tiếp tục chạy là mỗi ngày ngân sách chảy vào chỗ không tạo ra giá trị.
- **Xem xét có chọn lọc** các campaigns cận lỗ (ROI từ $-0{,}5$ đến 0): điều chỉnh targeting hoặc creative trước khi quyết định dừng hẳn.

- **Thiết lập ngưỡng CPA tối đa** như một cơ chế cảnh báo sớm. Khi CPA vượt ngưỡng, hệ thống cảnh báo tự động thay vì chờ báo cáo cuối tháng.

Đầu tư có chủ đích, không dàn trải

Phân bổ đều ngân sách cho tất cả các kênh là một lựa chọn an toàn. Nhưng an toàn không phải lúc nào cũng là tối ưu. Khi Paid Ads và Social Media đang dẫn đầu về hiệu quả, việc tiếp tục đổ cùng một lượng tiền vào Influencer (kênh có chi phí cao nhất nhưng ROI thấp nhất) là đang để cơ hội trôi qua.

Đây không phải lời kêu gọi bỏ hẳn một kênh nào đó. Đây là lời nhắc rằng **mỗi đồng ngân sách có chi phí cơ hội** và phân bổ thông minh hơn không cần tăng tổng chi tiêu, chỉ cần phân phối lại có căn cứ hơn.

Kênh	Hiện tại	Đề xuất	Lý do
Paid Ads	∼20%	**25% (↑)**	ROI dẫn đầu, khả năng mở rộng tốt
Social Media	∼20%	**25% (↑)**	CTR cao nhất, chuyển đổi ổn định
Email	∼20%	20% (=)	Kênh nền tảng, giữ nguyên
SEO	∼20%	18% (↓)	Hiệu quả cận biên thấp hơn
Influencer	∼20%	**12% (↓)**	CPA cao, ROI thấp nhất

Tôn trọng sự khác biệt giữa các thương hiệu

Một trong những phát hiện thú vị nhất và dễ bị bỏ qua nhất là ba brand không hoạt động theo cùng một logic. Nykaa phát huy mạnh nhất trên Social Media. Tira Beauty tìm thấy lợi thế rõ ràng ở Paid Ads. Purplle có danh mục kênh cân bằng hơn, với Paid Ads, Social Media và Email cùng đóng góp ổn định.

Áp dụng cùng một chiến lược cho cả ba không chỉ là bỏ lỡ cơ hội mà còn kìm hãm điểm mạnh tự nhiên của từng thương hiệu. Mỗi brand cần một playbook riêng.

Brand	Nên đẩy mạnh	Nên tinh gọn
Nykaa	Social Media	Email
Purplle	Paid Ads, Social Media	Influencer, SEO
Tira Beauty	Paid Ads	Influencer

Đưa CPA từ kết quả thành công cụ

CPA không chỉ là một chỉ số để báo cáo, nó là **la bàn để điều hướng**. Khoảng cách giữa campaigns có CPA thấp nhất và cao nhất trong dataset này là rất lớn, và khoảng cách đó không

phải ngẫu nhiên. Nó phản ánh sự khác biệt có hệ thống trong cách campaigns được thiết kế và vận hành.

Bốn đòn bẩy để cải thiện CPA:

- **Học từ campaigns CPA thấp**: loại creative nào (hình ảnh, video hay text) đang dẫn đầu? Nhân rộng những gì đang hoạt động trước khi thử nghiệm thứ mới.
- **A/B testing có kỷ luật**: test từng biến thể một, giữ lại cái tốt hơn. Không test tất cả mọi thứ cùng một lúc.
- **Retargeting**: nhóm đã click nhưng chưa mua thường có CPA thấp hơn đáng kể so với cold audience. Đây là nguồn conversion chi phí thấp đang chưa được khai thác đủ.
- **Target CPA bidding**: để nền tảng tự tối ưu theo ngưỡng CPA đã đặt, thay vì đặt giá thủ công và hy vọng.

Roadmap thực thi

Một kế hoạch tốt cần có người chịu trách nhiệm và mốc thời gian rõ ràng. Không có hai yếu tố đó, recommendation dù hay đến đâu cũng chỉ là ý định.

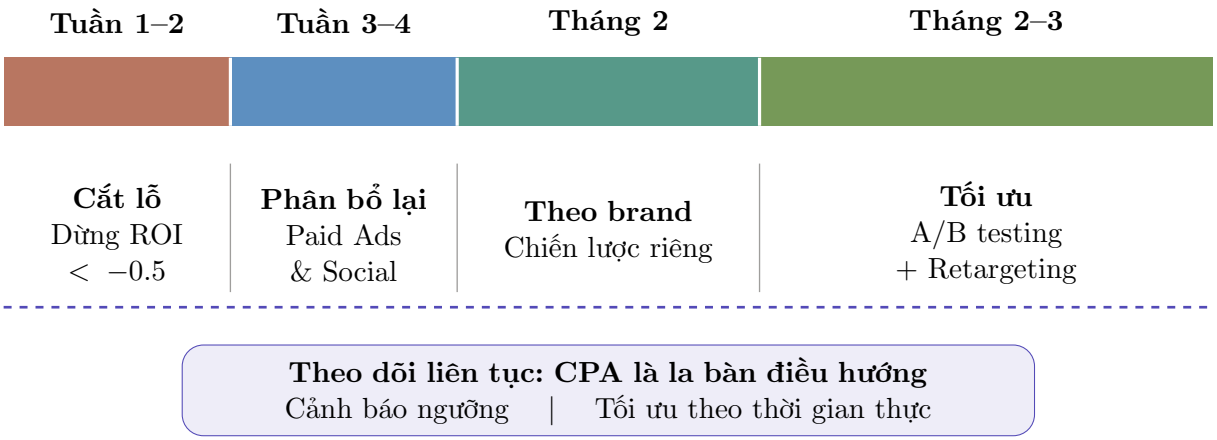

Hình 1: Kế hoạch thực hiện việc cắt lỗ và tối ưu.

XV. Từ phân tích dữ liệu đến mô hình dự đoán

XV.1. Bối cảnh từ Phase 1

Ở **phần 1**, nhóm **Data Analyst** đã chạy xong pipeline ETL → KPI → Dashboard → Insight → Recommendation trên **166,665 campaigns** của ba brand beauty Ấn Độ trên các kênh **Nykaa**, **Purplle**, **Tira Beauty**.Thông qua phân tích cho thấy được nhóm chiến dịch có hiệu quả kém với chỉ số lợi nhuận âm chiếm khoảng 24% tổng số chiến dịch nhưng lại sử dụng tới 28,9 % tổng ngân sách. Đồng thời chi phí để tạo ra một chuyển đổi của nhóm này đạt 970, cao gấp khoảng 2,6 lần so với mức trung bình của toàn bộ dữ liệu là 376.

Từ kết quả đó, đề xuất đặt quy tắc dừng ngay các chiến dịch có chỉ số lợi nhuận nhỏ hơn $-0{,}5$ và tự động gửi cảnh báo khi chi phí cho mỗi chuyển đổi vượt quá 600 nhằm giảm lãng phí ngân sách và nâng cao hiệu quả vận hành.

Ba con số trên cho thấy **thông điệp chính** của nhóm DA: *"có một nhóm thiểu số campaign vừa đông, vừa tiêu nhiều, vừa kém hiệu quả; dừng hoặc cảnh báo chúng sẽ tiết kiệm khoảng 29% ngân sách."*

XV.2. Ba câu hỏi Data Scientist cần trả lời

Câu hỏi đặt ra: các quy tắc này có đúng khi kiểm chứng bằng số liệu không? Nhóm Data Scientist (DS) cần trả lời ba câu hỏi:

1. **Predictability (khả năng dự báo):** có thể nhận diện campaign Poor *trước khi tiêu hết ngân sách* hay không?
2. **Threshold optimality (tính tối ưu của ngưỡng):** ngưỡng CPA = 600 có đạt F1 cao nhất hay không? Nói cách khác: ngưỡng đó có cân bằng tốt nhất giữa bắt trúng campaign lỗ và hạn chế báo nhầm?
3. **Feature contribution (đóng góp đặc trưng):** yếu tố nào ảnh hưởng mạnh nhất đến xác suất campaign bị lỗ?

XV.3. Tại sao chọn bài toán phân loại?

Trong bài này, chúng ta sẽ trả lời câu hỏi: *có nên dừng campaign này không?* Đầu ra là **quyết định nhị phân** (dừng hay tiếp tục), không phải con số liên tục. Có bốn lý do chọn **phân loại** (classification) thay vì **hồi quy** (regression):

1. **Loss function phù hợp.** Nếu dùng hồi quy để dự đoán ROI rồi áp ngưỡng, mô hình sẽ tối ưu **MSE** (Mean Squared Error) trên toàn dải ROI, kể cả vùng ROI = 5.0 dù vùng đó không liên quan đến quyết định dừng hay tiếp. Phân loại tập trung năng lực mô hình vào vùng ranh giới Poor / OK.
2. **Xác suất hiệu chỉnh.** Mô hình phân loại xuất $P(\text{Poor} \mid x)$, cho phép đội vận hành tự chọn ngưỡng theo mức chấp nhận rủi ro (0.7 chặt, 0.3 lỏng) trên cùng một mô hình.

3. **AUC không phụ thuộc ngưỡng. AUC** (Area Under ROC Curve) đo trực tiếp khả năng phân biệt Poor / OK, đúng chỉ số mà DA quan tâm.

4. **Diễn giải đặc trưng.** Mô hình phân loại cho ra trọng số $|\beta|$ (Logistic) hoặc **gain** (nếu dùng mô hình cây như Random Forest/XGBoost), giúp trả lời *tại sao* campaign bị gán nhãn Poor.

Kết luận

Bài A thuộc lớp bài toán **supervised binary classification** (học có giám sát, phân loại nhị phân).

XVI. Thiết kế thí nghiệm: Ba nhóm đặc trưng v1 / v2 / v3

XVI.1. Tại sao chia ba nhóm?

Câu hỏi vận hành: *tại thời điểm nào chúng ta đã có đủ thông tin để quyết định dừng?* Một campaign 30 ngày trải qua ba giai đoạn thông tin:

1. **Giai đoạn thiết lập** (trước khi chiến dịch chạy thực tế, chỉ có các thông số set up ban đầu do marketer chọn).

2. **Sau 1 đến 3 ngày** (đã có tín hiệu hành vi ban đầu).

3. **Sau khi tiêu một phần ngân sách** (đã có tín hiệu chi phí).

Mỗi trạng thái tương ứng với một quyết định kinh doanh khác nhau, nên cần **ba mô hình riêng** để đánh giá năng lực dự báo tại từng mốc.

XVI.2. Chi tiết ba nhóm đặc trưng

Phiên bản	Đặc trưng	Khi nào có thông tin?
Thông số thiết lập ban đầu	Brand, Campaign_Type, Target_Audience, Primary_Channel, Duration_Group, Language, Customer_Segment, Channel_Count, Duration (9 đặc trưng)	Giai đoạn thiết lập đây là bước trước khi chạy
Thêm tín hiệu hành vi sớm	v1 + Impressions, Engagement_Score (11 đặc trưng)	Sau 1–3 ngày chạy
Thêm tín hiệu chi phí	v2 + CPA, CTR, Conversion_Rate (14 đặc trưng)	Sau khi đã tiêu một phần ngân sách

Tại sao chọn các đặc trưng cụ thể trong từng nhóm?

- **Phiên bản 1 (Thông số thiết lập ban đầu):** 9 đặc trưng do người chạy quảng cáo thiết lập lúc khởi tạo chiến dịch, chia theo lý thuyết marketing thành ba trục: **WHO** (Brand, Audience, Segment), **WHAT** (Type, Language), **WHERE / HOW LONG** (Channel, Duration). Bộ này bao phủ các lựa chọn của marketer ở giai đoạn lập kế hoạch.
- **Phiên bản 2 (thêm Impressions, Engagement_Score):** hai chỉ số đầu phễu **AIDA** (**Attention** và **Interest**), ổn định sớm nhất sau 24–72 giờ. Chỉ số giai đoạn Action vẫn còn nhiễu.
- **Phiên bản 3 (thêm CPA, CTR, Conversion_Rate):** ba chỉ số cuối phễu, chỉ ổn định khi có ít nhất 30 chuyển đổi (quy ước thông dụng để confidence interval đủ hẹp).

XVI.3. Kỳ vọng lý thuyết trước thực nghiệm

Dựa trên cấu trúc thông tin, chúng ta kỳ vọng:

- **Phiên bản 1:** AUC khoảng **0.5–0.6** (thông số thiết lập ban đầu hoàn toàn không đủ để tách biệt Poor / OK).
- **Phiên bản 2:** AUC khoảng **0.80–0.90** (Engagement nắm bắt phản ứng người dùng).
- **Phiên bản 3:** AUC từ **0.95 trở lên** (do quan hệ toán học giữa CPA và ROI: ROI = RPC/CPA − 1).

Tip

Thiết lập kỳ vọng trước khi chạy thử nghiệm là thói quen tốt trong nghiên cứu thực nghiệm. Nếu kết quả lệch xa kỳ vọng, cần kiểm tra lại pipeline hoặc giả định.

Khái niệm: Logistic Regression cơ bản

Logistic Regression (**hồi quy logistic**) là mô hình phân loại nhị phân, dùng hàm **sigmoid** để ước lượng xác suất:

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(w^\top x + b)}}$$

Hàm Sigmoid quy mọi giá trị tính toán vào khoảng 0 đến 1, rất phù hợp để biểu diễn xác suất. Mô hình tự học từ dữ liệu để tìm trọng số w sao cho cân bằng nhất giữa phân loại đúng và tránh học vẹt.
Do nhóm Poor chỉ chiếm khoảng 23.7%, chúng ta dùng tham số `class_weight="balanced"`. Để xử lý mất cân bằng lớp (class imbalance) lúc này trọng số phạt tự động tăng cho nhóm thiểu số, giúp mô hình không bị lệch về nhóm đa số là lớp OK.

XVII. Kết quả thực nghiệm

XVII.1. Kết quả trên tập kiểm tra

Dataset gồm 166,665 campaign được chia **80/20** (seed 42): train 133,332, test 33,333.

Phiên bản	Precision (Poor)	Recall (Poor)	F1	AUC
Phiên bản 1 (Thông số thiết lập ban đầu)	0.236	0.514	0.324	0.501
Phiên bản 2 (Thêm tín hiệu hành vi sớm)	0.538	0.800	0.644	0.885
Phiên bản 3 (Thêm tín hiệu chi phí)	0.732	0.870	0.795	0.965

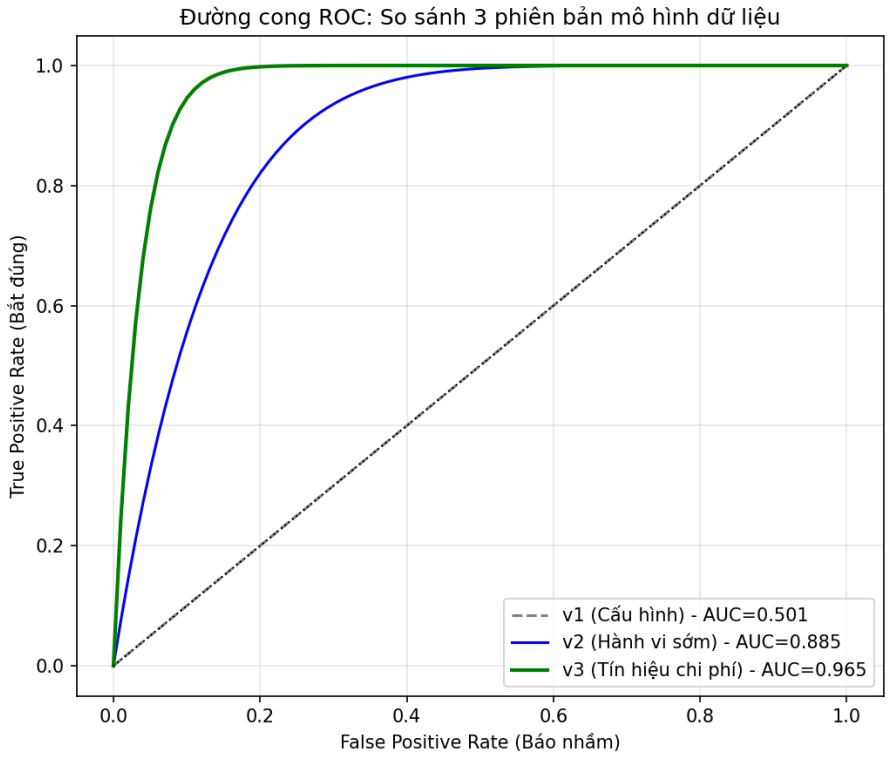

Hình 20: Đường cong ROC biểu diễn hiệu suất của ba phiên bản mô hình, trong đó v3 (xanh lá) có khả năng phân biệt xuất sắc nhất.

Lưu ý

Phát hiện A.1. Chỉ dựa vào thông số thiết lập ban đầu là **KHÔNG ĐỦ** để dự báo Poor (AUC $\approx$ 0.50). Phải có ít nhất **1 ngày dữ liệu chạy thật**, AUC mới nhảy lên 0.89; thêm tín hiệu chi phí thì đạt 0.96.

Đề xuất vận hành bằng cách dành một **warm-up window** (cửa sổ khởi động) **24–72 giờ** trước khi quyết định dừng campaign.

Thực nghiệm cho AUC = **0.501 / 0.885 / 0.965**, khớp với kỳ vọng (0.5–0.6 / 0.80–0.90 / 0.95+). Kết quả này cho thấy thiết kế phiên bản 1/2/3 hợp lý.

XVII.2. Code: Huấn luyện Logistic phiên bản 1/2/3

Đoạn code dưới đây trích từ notebook DS_Marketing_Verification_Classification.ipynb:

Bước 1: Định nghĩa ba nhóm đặc trưng

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score, precision_recall_fscore_support

FEATURES_V1 = ["Brand", "Campaign_Type", "Target_Audience",
               "Primary_Channel ", "Duration_Group", "Language",
               "Customer_Segment", "Channel_Count", "Duration"]
FEATURES_V2 = FEATURES_V1 + ["Impressions", "Engagement_Score"]
FEATURES_V3 = FEATURES_V2 + ["CPA", "CTR", "Conversion_Rate"]

def prep_xy(df, feats):
    X = pd.get_dummies(df[feats], drop_first= True)
    y = df["Is_Poor"].values
    return X, y
```

Ở phần code trên

- `pd.get_dummies(drop_first=True)` biến đổi các cột categorical (Brand, Campaign_Type, ...) thành các cột nhị phân (0/1), bỏ một cột đầu tiên để tránh **multicollinearity** (đa cộng tuyến).
- Nhãn **Is_Poor** được xác định từ điều kiện ROI < 0.

Bước 2: Chia dữ liệu và huấn luyện

```
# Giả sử chúng ta đã load dữ liệu vào DataFrame df từ bước EDA trước đó
# df = pd.read_csv("campaign_data.csv")
X1, y = prep_xy(df, FEATURES_V1)
X1_tr, X1_te, y_tr, y_te = train_test_split(X1, y, test_size=0.2,
                                            random_state=42)

def train_logit(Xtr, Xte, ytr, yte, label):
    m = LogisticRegression(class_weight="balanced",
                           max_iter=1000, random_state=42)
    m.fit(Xtr, ytr)
```

```
    p = m.predict_proba(Xte)[:, 1]    # xác suất P(Poor)
    yp = (p >= 0.5).astype(int)        # ngưỡng mặc định 0.5
    auc = roc_auc_score(yte, p)
    pr, rc, f1, _ = precision_recall_fscore_support(yte, yp,
                        average="binary", pos_label=1)
    print(f"{label}: AUC={auc:.3f} P={pr:.3f} R={rc:.3f} F1={f1:.3f}")
    return m, p, yp
```

Ở phần code trên

- `class_weight="balanced"` tự động điều chỉnh trọng số như lớp Poor (chiếm 24%) được nhân trọng số cao hơn để mô hình không thiên về lớp OK (chiếm 76%).
- `predict_proba(Xte)[:, 1]` trả về $P(\text{Poor} \mid x)$, một số liên tục trong $[0, 1]$. Đây là đầu ra quan trọng nhất ở đây KHÔNG phải nhãn thực tế, mà là **xác suất dự đoán** của mô hình.

XVII.3. Ma trận nhầm lẫn v3

Ma trận được thực hiện trên tập kiểm tra gồm 33,333 campaign và có kết quả như sau:

Thực tế ↓ / Dự đoán →	**Dự đoán OK**	**Dự đoán Poor**	**Tổng (thực tế)**
Thực tế OK	23,022 (TN)	2,494 (FP)	25,516
Thực tế Poor	1,015 (FN)	6,802 (TP)	7,817
Tổng (dự đoán)	24,037	9,296	33,333

Từ bảng trên, chúng ta quan sát được

- **TP = 6,802:** mô hình dự đoán đúng 6,802 campaign là Poor.
- **FP = 2,494:** mô hình dự đoán Poor nhưng thực tế là OK (dương giả : báo nhầm).
- **FN = 1,015:** mô hình bỏ sót 1,015 campaign Poor (âm giả).
- **TN = 23,022:** mô hình dự đoán đúng 23,022 campaign là OK.

Suy rộng cho toàn dataset (166,665 campaign), nhân hệ số 5 như sau:

Thực tế ↓ / Dự đoán →	**Dự đoán OK**	**Dự đoán Poor**	**Tổng**
Thực tế OK	$\approx$ 115,110	$\approx$ 12,470	127,580
Thực tế Poor	$\approx$ 5,075	$\approx$ 34,010	39,085

XVII.4. Xếp hạng đặc trưng

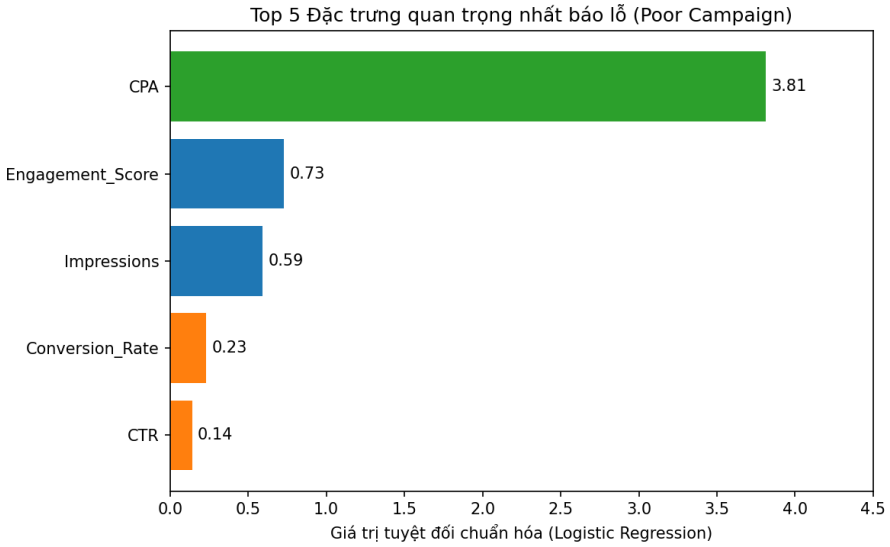

Hình 21: Tầm quan trọng của các đặc trưng, CPA gánh phần lớn năng lực dự báo.

Tip: Tại sao lại nhắc đến XGBoost?

Dù trọng tâm là **Logistic Regression** (mô hình tuyến tính), chúng ta có chạy thêm **XGBoost** (mô hình phi tuyến) để đối chiếu. Mục đích để kiểm tra xem thứ hạng đặc trưng có thay đổi khi đổi thuật toán không. Nếu cả hai loại mô hình đều chấm điểm cao cho cùng một cột thì cột đó có sức dự báo mạnh, không phụ thuộc vào mô hình.

Top 5 đặc trưng quan trọng nhất (theo sự đồng thuận của hai cấu hình Logistic và XGBoost):

Thứ hạng	Đặc trưng	XGBoost Gain	$\lvert\tilde{\beta}\rvert$ chuẩn hoá	Nhóm
1	CPA	0.412	3.81	Tín hiệu chi phí
2	Engagement_Score	0.187	0.73	Tín hiệu hành vi sớm
3	Conversion_Rate	0.142	0.23	Tín hiệu chi phí
4	Impressions	0.098	0.59	Tín hiệu hành vi sớm
5	CTR	0.071	0.14	Tín hiệu chi phí

Robustness check

Dù $|\tilde{\beta}|$ chuẩn hoá (tuyến tính) và gain (phi tuyến, dựa trên cây) đo theo hai cách khác nhau, **top 5 vẫn trùng nhau**. Đây là dấu hiệu **vững (robust)** thông qua tín hiệu nằm trong dữ liệu, không phụ thuộc mô hình.

Cách diễn giải $|\tilde{\beta}|$ chuẩn hoá:

$|\tilde{\beta}|$ trả lời câu hỏi: *log-odds thay đổi bao nhiêu khi đặc trưng tăng lên 1 độ lệch chuẩn (1 SD), giữ các biến khác cố định?*

- $|\tilde{\beta}|_{\text{CPA}} = 3.81$: CPA tăng 1 SD làm odds nhân với $e^{3.81} \approx 45$.
- $|\tilde{\beta}|_{\text{Engagement}} = 0.73$: Engagement tăng 1 SD làm odds nhân với $e^{0.73} \approx 2.07$.

Kết luận: ở cùng một đơn vị độ lệch chuẩn, **CPA tác động đến P(Poor) mạnh gấp khoảng 5 lần Engagement**.

Tip: Bản chất của $|\tilde{\beta}|$ chuẩn hoá

Hệ số này KHÔNG phải là đem chia β thô cho một hằng số. Trình tự đúng:

1. Chuẩn hoá z-score toàn bộ đặc trưng trước khi huấn luyện.
2. Đưa dữ liệu đã chuẩn hóa vào dạy mô hình, rồi trích xuất hệ số $\tilde{\beta}_j$.

(Cách tính tương đương nhanh: $\tilde{\beta}_j = \beta_j \cdot \sigma_j$)

XVIII. Quét ngưỡng CPA và ngưỡng kép WATCH / STOP

XVIII.1. Phân biệt CPA campaign cá nhân và CPA trung bình nhóm

Lưu ý

Phân biệt quan trọng. Ngưỡng T áp cho **CPA của từng campaign riêng lẻ**, KHÔNG phải CPA trung bình nhóm. Cụ thể:

- **CPA của một campaign** = Total_Spend/Conversions. Mỗi campaign có một CPA riêng.
- **CPA trung bình nhóm** (theo Brand, Channel, Segment) là trung bình cộng CPA của các campaign trong nhóm.

Vì sao bảng tổng hợp thường thấy CPA dưới 300 mà ngưỡng lại 400 / 800? Phân phối CPA **right-skewed** (lệch phải) mạnh: **Median ≈ 209**, **Mean = 376**, **Mean nhóm Poor = 970**. Đuôi phải kéo dài đến 15,473.

XVIII.2. (Code lập trình) Quét ngưỡng CPA

Thay vì mò mẫm thủ công, ta định nghĩa logic quét qua hàng loạt ngưỡng T (từ 200 đến 1000) đối với quy tắc `IF CPA > T THEN Poor`. Khối code sau sẽ thực thi việc này và tính độ chính xác tương ứng:

```
def cpa_threshold_sweep(df, thresholds=(200, 300, 400, 500,
                                        600, 700, 800, 900, 1000)):
    rows = []
    truly = df["Is_Poor"].values
    for T in thresholds:
        flagged = (df["CPA"] > T).values
        tp = ((flagged == 1) & (truly == 1)).sum()
        fp = ((flagged == 1) & (truly == 0)).sum()
        fn = ((flagged == 0) & (truly == 1)).sum()

        pr = tp / (tp + fp) if tp + fp > 0 else 0
        rc = tp / (tp + fn) if tp + fn > 0 else 0
        f1 = 2 * pr * rc / (pr + rc) if pr + rc > 0 else 0

        rows. append((T, int(flagged.sum()), round(pr, 3), round(rc, 3), round(f1, 3)))

    return pd.DataFrame(rows, columns=["T_CPA", "Campaigns_Flagged", "Precision", "
                                       Recall", "F1"])

# Gọi hàm chạy trên file data thực tế
# print(cpa_threshold_sweep(df))
```

Ở phần code trên

- Hàm duyệt qua từng ngưỡng T, đếm số campaign bị gắn cờ (`flagged`), đối chiếu với định nghĩa thực tế (`truly` được đếm bằng nhãn Poor).
- Đây là toán đếm thống kê đơn thuần (cũng có thể làm = COUNTIFS trong Excel), không phải Train Machine Learning nên ta không cần chia file `train_test_split`.

XVIII.3. Bảng kết quả quét ngưỡng

Sau khi chạy lệnh trên áp trên toàn bộ 166,665 campaign, kết quả in ra DataFrame như sau:

T (Ngưỡng)	Số campaign bị gắn cờ	Precision	Recall	F1	Tình huống
200	85,951	0.460	1.000	0.630	Quá lỏng
300	60,659	0.620	0.951	0.751	
400	**45,041**	**0.753**	**0.858**	**0.802**	⋆ **WATCH** (F1 tối ưu)
500	34,617	0.859	0.752	0.802	
600 (DA đề xuất)	27,260	0.933	0.644	0.762	Khá bảo thủ
700	21,786	0.983	0.542	0.698	
800	**17,782**	**1.000**	**0.450**	**0.621**	⋆ **STOP** (FP = 0)
1000	12,394	1.000	0.314	0.478	Quá chặt

XVIII.4. Tiêu chí chọn ngưỡng

Lựa chọn ngưỡng WATCH (T = 400) – trọng tâm dùng F1

- WATCH mang tính chất **cảnh báo** bằng cách campaign bị gắn cờ sẽ được Campaign Manager (CM) xem xét lại, không bị dừng ngay.
- Chi phí FP (báo nhầm, tốn CM khoảng 30 phút) và chi phí FN (bỏ sót, mất tiền quảng cáo) **gần nhau**.
- Khi hai chi phí cân bằng, **F1** (trung bình điều hoà của Precision và Recall) là tiêu chí phù hợp.
- Thực nghiệm bằng cách quét T từ 100 đến 1,500 (bước 10), F1 đạt đỉnh tại $T = 440$ với $F1 = 0.808$. Chọn $T = 400$ (con số tròn, F1 = 0.802, chỉ kém đỉnh 0.006).

Lưu ý

Lựa chọn ngưỡng STOP (T = 800), trọng tâm dùng Precision = 1

- STOP mang tính chất **không thể đảo ngược**: campaign bị tự động tạm dừng qua Ads API, khôi phục cần 24–48 giờ và mất toàn bộ tín hiệu học tập của thuật toán quảng cáo.
- Chi phí FP (dừng nhầm) **lớn hơn nhiều** chi phí FN (bỏ sót, vì sẽ bắt được ở vòng WATCH).
- Yêu cầu cần phải giữ **Precision = 1** (FP = 0), chấp nhận Recall thấp.
- Tại $T = 800$ thì Precision = 1.000, FP = 0. Max CPA của nhóm không-Poor bằng 793.80 thì ngưỡng 800 vừa qua đường biên tự nhiên này.

XVIII.5. So sánh với đề xuất DA

DA đề xuất CPA > 600. Nhìn vào bảng ta quan sát được

- Tại $T = 600$, ta có Precision = 0.933, **Recall chỉ 0.644** → nghĩa là **bỏ sót 36% campaign lỗ**.
- Tại $T = 400$ thì có Recall = 0.858, bắt được thêm 21% campaign lỗ so với ngưỡng 600, trong khi false positive rate vẫn chấp nhận được (Precision = 0.75).

Lưu ý

DS đề xuất thay quy tắc A2 bằng ngưỡng kép WATCH / STOP:

- CPA > 400 ⇒ **WATCH** (P = 0.75, R = 0.86) cần gắn cờ để CM xem xét.
- CPA > 800 ⇒ **STOP** (P = 1.00, R = 0.45) dấu hiệu chắc chắn lỗ, nên dừng ngay.

XIX. So sánh hiệu quả và khi nào thì cần Machine Learning?

Câu hỏi đặt ra là quy tắc tĩnh đơn giản (quét ngưỡng CPA) đã cho kết quả tốt, vậy mô hình học máy (Logistic phiên bản 3) có cần thiết không?

XIX.1. So sánh trực tiếp

Phương án	AUC (ước lượng)	F1 tốt nhất	Số đặc trưng	Nhóm xử lý
Quy tắc CPA thuần tuý (sweep)	≈ 0.93	0.802 (T = 400)	1 (chỉ CPA)	Phân tích quy tắc tĩnh
v2 Logistic (chưa có CPA)	0.885	0.644	11	Học máy (Mô hình)
v3 Logistic (có CPA)	0.965	0.795	14	Học máy (Mô hình)

Từ bảng trên, chúng ta có một vài quan sát đáng chú ý như sau:

- F1 của quy tắc CPA thuần tuý (**0.802**) xấp xỉ F1 của v3 Logistic (**0.795**), thậm chí nhỉnh hơn 0.007.

- Trong Logistic v3, $|\tilde{\beta}|_{\text{CPA}} = 3.81$ gấp 5 lần đặc trưng đứng thứ hai → CPA gánh phần lớn năng lực dự báo.

Câu hỏi cốt lõi

Vậy 13 đặc trưng còn lại để làm gì? Phiên bản 3 có thực sự cần thiết không?

XIX.2. Ba tình huống biên mà v3 thắng

Phiên bản 3 không thắng về F1 tổng quát, chỉ thắng ở ba **edge case** (tình huống biên):

- **Tình huống 1: CPA nằm trong vùng xám 400–800**

  Quy tắc CPA chỉ kết luận **WATCH** mà không phân biệt được trong nhóm **WATCH** ấy, campaign nào thực sự sắp rơi xuống Poor.
  Logistic phiên bản 3 có thêm ngữ cảnh: với cùng CPA = 500, nếu Engagement = 9.0 thì $P(\text{Poor}) = 0.35$ (giữ lại); nếu Engagement = 2.1 thì $P(\text{Poor}) = 0.88$ (nâng lên STOP). **Cùng một CPA, ngữ cảnh Engagement đảo ngược quyết định.**

- **Tình huống 2: CPA nhiễu hoặc chưa tính được**
  - Campaign mới chạy 12 giờ, Conversions = 0, dẫn đến CPA = ∞ hoặc NaN. Quy tắc **không xử lý được**.
  - Campaign mới có 1–2 chuyển đổi ngẫu nhiên, CPA biến động cực mạnh, quy tắc **dễ báo động giả**.
  - Phiên bản có thể dựa vào Engagement, Impressions và Conversion_Rate để ra điểm dù CPA còn nhiễu.

- **Tình huống 3: Cần xếp hạng theo mức độ rủi ro**

  Đội CM có 200 campaign WATCH mỗi ngày nhưng chỉ kịp xem 30. Cần **xếp hạng rủi ro** để ưu tiên.
  - Quy tắc CPA chỉ chia ba nhóm (STOP / WATCH / OK), không xếp hạng được trong cùng nhóm.
  - Phiên bản cho ra $P(\text{Poor}) \in [0, 1]$ liên tục, sắp xếp giảm dần để lấy top 30. **Đây là giá trị duy nhất quy tắc không cung cấp được.**

XIX.3. Chiến lược phối hợp: Defense-in-Depth (Lớp 1 + Lớp 2)

Cách tốt nhất là kết hợp cả quy tắc tĩnh và mô hình dự báo theo chiến lược mang lại nhiều phương pháp dự trù khác nhau:

Lớp	Phạm vi bao phủ	Phương pháp	Đội phụ trách	Điều kiện kích hoạt
Lớp 1: Dựa trên quy tắc tĩnh	≈ 90% trường hợp	Quét ngưỡng CPA thuần tuý	Data Analyst	CPA > 800 cho STOP; CPA > 400 cho WATCH
Lớp 2: Mô hình học máy	≈ 10% tình huống biên	Dự báo Logistic phiên bản 3	Data Scientist	$P(\text{Poor}) > 0.70$

Lưu ý

Kết luận: Trong 90% trường hợp, quy tắc tĩnh đã xử lý được. Học máy chỉ cần ở 10% tình huống biên. Cách làm đúng: kết hợp **Lớp 1 (Quy tắc tĩnh) + Lớp 2 (Học máy)**.

XIX.4. Quy trình vận hành WATCH / STOP

Bảng và sơ đồ dưới đây tóm tắt quy trình vận hành hàng ngày:

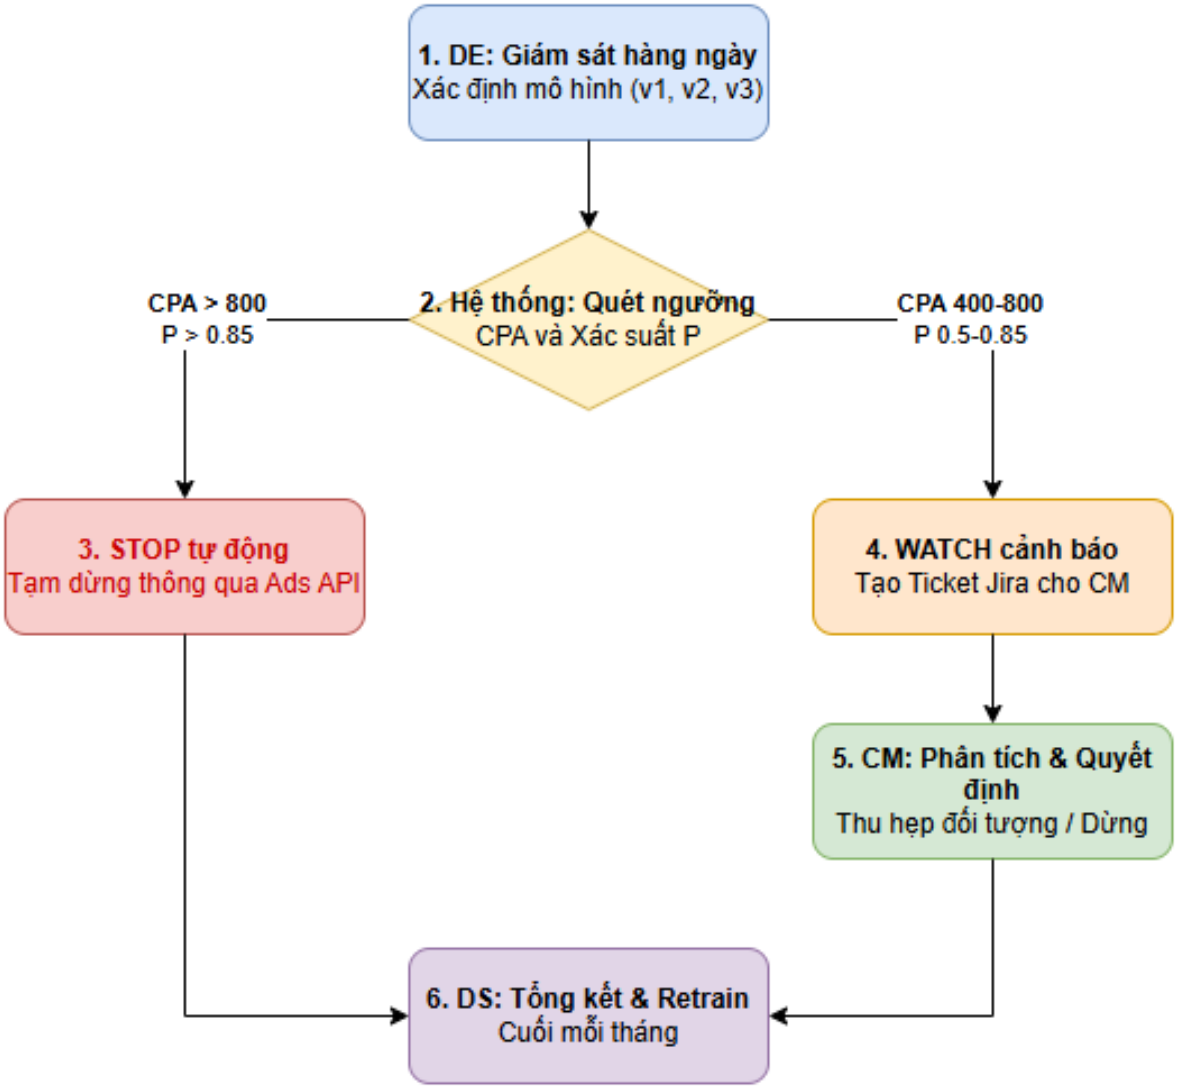

Hình 22: Sơ đồ quy trình vận hành WATCH / STOP

Bước	Điều kiện kích hoạt	Hành động	SLA	Phụ trách
1. Giám sát hàng ngày	00:00 mỗi ngày	Chọn mô hình theo tuổi campaign: $<24h$ → WARM_UP; $24\check{}72h$ → v2; $\geq 72h$ và conv ≥ 30 → phiên bản 3	15 phút	DE
2. STOP tự động	CPA $>$ 800 hoặc P(Poor) $>$ 0.85	Tạm dừng campaign, gửi cảnh báo Slack	Tức thì	Hệ thống
3. WATCH cảnh báo	CPA $\in$ [400, 800] hoặc P(Poor) $\in$ [0.5, 0.85]	Tạo ticket Jira, gán cho CM phụ trách	Cuối ngày	Hệ thống + CM
4. Phân tích nguyên nhân	24h sau cảnh báo	CM mở dashboard chi tiết	2 giờ	CM
5. Quyết định	Sau bước 4	Thu hẹp khán giả hoặc dừng campaign	Trong ngày	CM
6. Tổng kết & retrain	Cuối mỗi tháng	Tổng kết TP/FP, huấn luyện lại mô hình	1 ngày	DS

Ví dụ minh hoạ: Campaign #C-12847 *Nykaa Festive Lipstick*

Campaign khởi chạy ngày 1/3, kênh Influencer. Sau 4 ngày, CPA = 520, $P(\text{Poor}) = 0.62$, hệ thống tạo ticket WATCH.

Campaign Manager (CM) mở dashboard drill-down và phát hiện chiến dịch chia thành hai phân khúc: **Macro KOL** (người nổi tiếng, hàng trăm ngàn follower) đang bị đội giá với CPA = 720, còn **Micro KOL** (lượng follower nhỏ nhưng tương tác sâu) chỉ có CPA = 380.

Quyết định thực hiện dừng phân bổ ngân sách cho Macro KOL, dồn sang Micro KOL. Sau 7 ngày, CPA trung bình giảm còn 340, campaign thoát nhóm WATCH. Ngân sách tiết kiệm ước tính khoảng **180 triệu VND** so với kịch bản không can thiệp.

XIX.5. Kết luận về ứng dụng mô hình học máy

Phần này tổng kết lại nhánh phân tích dùng học máy và rút ra ba kết luận chính cùng một bảng đối chiếu khuyến nghị.

Ba kết luận chính

1. **Không thể dự báo nhóm chiến dịch kém (Poor) nếu chỉ dựa vào thông số thiết lập ban đầu.** AUC của mô hình 1 chỉ đạt ≈ 0.50, vì vậy các thông số thiết lập ban đầu không chứa đủ tín hiệu cảnh báo. Cần ít nhất 24–72 giờ dữ liệu chạy thật.
2. **Ngưỡng 600 của quá trình phân tích là chưa phù hợp.** Ngưỡng này bỏ sót 36% chiến dịch lỗ. Thay bằng ngưỡng kép 400 (WATCH) / 800 (STOP) sẽ chính xác hơn.
3. **DS bổ sung cho DA, chứ không thay thế.** Mô hình học máy chỉ thực sự cần ở khoảng 10% tình huống khó (khi CPA chưa ổn định, khi rơi vào vùng xám 400–800, hoặc khi cần xếp hạng rủi ro). Kiến trúc hợp lý gồm hai lớp: Lớp 1 là các quy tắc do nhà phân tích dữ liệu đặt ra, lớp 2 là mô hình do nhà khoa học dữ liệu xây dựng.

Bảng đối chiếu khuyến nghị

Khuyến nghị DA	Kết luận DS	Hành động điều chỉnh
A1: Dừng khi ROI $<$ -0.5	Phù hợp, bộ phân loại đạt AUC = 0.96 càng củng cố	Triển khai Lớp 2 XGBoost làm cảnh báo sớm, huấn luyện lại hàng tháng
A2: Cảnh báo khi CPA $>$ 600	Bỏ sót 36% chiến dịch lỗ	Dùng ngưỡng kép 400/800 (WATCH/STOP)
Dừng ngay từ đầu	Không khả thi, AUC v1 $\approx$ 0.50	Cần một khoảng thời gian khởi động 24–72 giờ trước khi quyết định
Vai trò DS	Chỉ cần ở 3 tình huống biên: dự báo sớm, xếp hạng, quyết định vùng xám	Chiến lược phòng thủ nhiều lớp (Defense-in-depth): Lớp 1 + Lớp 2

XX. Tổng kết

Bài học này đã đi qua toàn bộ quy trình phân tích marketing từ dữ liệu thô cho đến khuyến nghị hành động và có thể chia thành ba giai đoạn chính.

Giai đoạn 1: Hiểu domain và xác định bài toán

Trước khi phân tích vào dữ liệu, chúng ta dành thời gian nắm vững kiến thức nền tảng: 6 chỉ số marketing cốt lõi (Impressions, Clicks, Leads, Conversions, Revenue, Acquisition Cost), cách chúng kết nối qua Marketing Funnel, 5 loại chiến dịch (Paid Ads, Social Media, Email, SEO, Influencer), và 6 KPI đo lường hiệu quả (CTR, Lead Rate, Lead Conversion Rate, CVR, CPA, ROI). Từ đó, 3 câu hỏi trung tâm được đặt ra: thương hiệu nào hiệu quả nhất, kênh nào tối ưu cho từng thương hiệu, và ngân sách nên phân bổ thế nào.

Giai đoạn 2: Thu thập, làm sạch và chuẩn bị dữ liệu

Dữ liệu gốc (3 file CSV, tổng cộng hơn 166.000 dòng) được tìm nạp vào MySQL, khám phá qua EDA và phát hiện 6 loại lỗi. SQL được dùng để làm sạch từng loại lỗi theo quy trình 7 bước. Dữ liệu sạch sau đó được kết nối sang Excel qua Power Query, bổ sung 6 cột dữ liệu, xây dựng 7 Pivot Tables và dashboard trực quan. Song song, Tableau được dùng để xây 5 dashboard chuyên sâu hơn với tính năng tương tác bộ lọc click-to-filter.

Giai đoạn 3: Phân tích, insight và khuyến nghị

Từ Pivot Tables và Dashboard, 16 insights được rút ra qua phân tích đa chiều (Brand, Campaign Type, Channel, Duration, thời gian, phân khúc khách hàng). Cuối cùng, các insights được chuyển thành 5 nhóm khuyến nghị hành động cụ thể kèm roadmap thực thi.

Ba điểm quan trọng nhất từ dự án

1. **CPA là đòn bẩy quyết định ROI.** Khoảng cách ROI giữa nhóm campaign tốt nhất và tệ nhất không đến từ kênh hay thời lượng, mà đến từ CPA. Tối ưu chi phí chuyển đổi là hành động có tác động lớn nhất.

2. **Mỗi thương hiệu có kênh riêng.** Nykaa mạnh ở Social Media, Tira Beauty ở Paid Ads, Purplle cân bằng (mạnh nhất ở Paid Ads). Không tồn tại một công thức chung, chiến lược tối ưu phải được tối ưu theo thế mạnh tự nhiên của từng thương hiệu.

3. **Phân phối quan trọng hơn trung bình.** ROI trung bình 2,69 đã làm khuất đi một thực tế rằng gần 1/4 chiến dịch đang lỗ. Phân tích phân phối (distribution) luôn cho bức tranh trung thực hơn bất kỳ con số trung bình nào.

XXI. Bảng thuật ngữ

Thuật ngữ / Viết tắt	Tên đầy đủ	Giải thích
CPA	Cost Per Acquisition	Chi phí để có được một khách hàng (một chuyển đổi)
CPC	Cost Per Click	Chi phí trung bình cho mỗi lượt click vào quảng cáo
CPM	Cost Per Mille	Chi phí cho mỗi 1.000 lượt hiển thị quảng cáo
CTR	Click-Through Rate	Tỷ lệ click trên tổng số lượt hiển thị (%)
ROI	Return On Investment	Tỷ suất lợi nhuận trên chi phí đầu tư
KPI	Key Performance Indicator	Chỉ số đo lường hiệu suất chính
KOL	Key Opinion Leader	Người ảnh hưởng có tiếng nói chuyên môn
KOC	Key Opinion Consumer	Người tiêu dùng có ảnh hưởng trong cộng đồng
CLV / LTV	Customer Lifetime Value	Tổng giá trị một khách hàng mang lại trong suốt vòng đời
AOV	Average Order Value	Giá trị trung bình của mỗi đơn hàng
SEO	Search Engine Optimization	Tối ưu hóa nội dung để xếp hạng cao trên công cụ tìm kiếm
CTA	Call To Action	Nút hoặc thông điệp kêu gọi hành động (mua, đăng ký...)
UX	User Experience	Trải nghiệm của người dùng khi tương tác với sản phẩm
EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu tìm hiểu dữ liệu trước khi phân tích chính thức
DSN	Data Source Name	Tên nguồn dữ liệu (cấu hình kết nối lưu sẵn trong ODBC)
ODBC	Open Database Connectivity	Giao thức chuẩn để kết nối ứng dụng với cơ sở dữ liệu
SSL	Secure Sockets Layer	Giao thức mã hóa bảo mật kết nối mạng
CA	Certificate Authority	Tổ chức cấp chứng chỉ số, dùng để xác thực danh tính server

Thuật ngữ / Viết tắt	Tên đầy đủ	Giải thích
CA	Certificate Authority	Tổ chức cấp chứng chỉ số, dùng để xác thực danh tính server
LOD	Level Of Detail	Biểu thức trong Tableau kiểm soát mức chi tiết tính toán
Funnel	Marketing Funnel	Mô hình phễu mô tả hành trình khách hàng từ biết đến mua
Dashboard		Bảng điều khiển trực quan hóa tổng hợp nhiều biểu đồ
Pivot Table		Bảng tổng hợp, công cụ tóm tắt dữ liệu lớn thành vài dòng
A/B Testing		Thử nghiệm so sánh 2 phiên bản để chọn phiên bản tốt hơn
Imputation		Kỹ thuật điền giá trị thay thế cho dữ liệu bị thiếu (NULL)
Primary Key		Khóa chính định danh duy nhất của mỗi dòng trong bảng
Reach		Số người *khác nhau* nhìn thấy quảng cáo (khác Impressions là tổng lượt hiển thị)
CVR	Click Conversion Rate	Tỷ lệ chuyển đổi trên số click (Conversions / Clicks)
Weighted ROI		ROI có trọng số: (tổng Revenue − tổng Spend) / tổng Spend, chính xác hơn trung bình cộng ROI

XXII. Câu hỏi trắc nghiệm

Các câu 1–3 và 8–13 bám sát nội dung bài. Các câu 4–7, 14–15 là phần **nâng cao** về Tableau (LOD expression `FIXED/INCLUDE`, Context Filter, Parameter động, mô hình RFM): đây là kiến thức mở rộng, bạn nên tham khảo thêm tài liệu Tableau chính thức trước khi trả lời.

1. Điều nào sau đây mô tả **chính xác nhất** sự khác biệt giữa cách tiếp cận truyền thống và cách tiếp cận dựa trên dữ liệu trong marketing?

(a) Marketing truyền thống không hiệu quả, còn marketing dựa trên dữ liệu luôn cho kết quả tốt hơn.

(b) Marketing truyền thống ra quyết định dựa trên kinh nghiệm và cảm tính, còn marketing dựa trên dữ liệu thay thế cảm tính bằng đo lường và tính toán.

(c) Marketing dựa trên dữ liệu chỉ phù hợp với các doanh nghiệp lớn có nhiều nguồn lực.

(d) Hai cách tiếp cận này độc lập nhau và không thể kết hợp trong cùng một chiến lược.

2. Trong ba pillar phân tích của dự án này: so sánh hiệu quả theo brand, chẩn đoán theo kênh và loại campaign, phân bổ ngân sách tối ưu. Tại sao chúng được thiết kế theo đúng thứ tự đó thay vì bắt đầu thẳng vào phân bổ ngân sách?

(a) Vì phân bổ ngân sách là bài toán kỹ thuật phức tạp nhất, cần giải quyết sau cùng.

(b) Vì mỗi pillar cung cấp ngữ cảnh cần thiết cho pillar tiếp theo. Không thể đề xuất phân bổ ngân sách nếu chưa biết brand nào hiệu quả và kênh nào đang có vấn đề.

(c) Vì ban lãnh đạo thường quan tâm đến brand trước, kênh sau, và ngân sách là vấn đề của phòng tài chính.

(d) Thứ tự không quan trọng, có thể phân tích theo bất kỳ trình tự nào đều cho ra cùng kết quả.

3. Điều nào sau đây mô tả **đúng nhất** vai trò của một Data Analyst trong một dự án marketing analytics?

(a) Tạo ra các biểu đồ đẹp để trình bày trong báo cáo hàng tháng cho ban lãnh đạo.

(b) Thay thế hoàn toàn team marketing trong việc đưa ra chiến lược quảng cáo.

(c) Biến dữ liệu thành quyết định bằng cách đặt câu hỏi đúng, đo lường có hệ thống và đề xuất hành động cụ thể có căn cứ.

(d) Đảm bảo rằng mọi campaign đều có ROI dương trước khi được phép triển khai.

4. Cho dataset sau:

Row	Region	Sales	Discount
1	East	200	0.1
2	East	300	0.2
3	West	150	0.15
4	West	350	0.05

Bạn tạo 3 Calculated Field trong Tableau:

```
// Formula X
[Sales] * (1 - [Discount])

// Formula Y
[Sales] - SUM([Sales]) / 4

// Formula Z
SUM([Sales]) / COUNT([Sales])
```

Formula nào sẽ gây lỗi **"Cannot mix aggregate and non-aggregate arguments"** trong Tableau, và cách sửa đúng là gì?

(a) Formula X gây lỗi vì nhân hai field row-level. Sửa: `SUM([Sales]) * (1 - SUM([Discount]))`.

(b) Formula Y gây lỗi vì trộn `[Sales]` (row-level) với `SUM([Sales])` (aggregate). Sửa: `SUM([Sales]) - SUM([Sales]) / 4`.

(c) Formula Z gây lỗi vì chia hai aggregate function. Sửa: tách thành 2 Calculated Field riêng.

(d) Cả 3 formula đều hợp lệ, không có lỗi nào.

5. Cho dataset sau:

Row	Region	Category	Sales
1	East	Tech	400
2	East	Tech	100
3	East	Furniture	300
4	West	Tech	100
5	West	Furniture	500
6	West	Furniture	100

View hiển thị **Region** trên Rows (chỉ có 1 dimension trong view). Bạn tạo LOD expression:

`{ INCLUDE [Category] : SUM([Sales]) }`

Bạn kéo INCLUDE LOD field vào view và chọn aggregation là `AVG`. Giá trị hiển thị cho Region **"West"** là bao nhiêu?

(a) 200

(b) 350

(c) 400

(d) 700

6. Cho dataset sau:

Region	Category	Sales
East	Tech	500
East	Furniture	300
West	Tech	400
West	Furniture	200

Bạn tạo FIXED LOD: `{ FIXED [Region] : SUM([Sales]) }`

View có **Region** và **Category** trên Rows. Bạn áp dụng filter: `Category = "Tech"`.

Scenario A: Category filter là **Dimension Filter** bình thường.
Scenario B: Category filter được đặt làm **Context Filter**.

Giá trị FIXED LOD cho Region "East" trong Scenario A và Scenario B lần lượt là bao nhiêu?

(a) A: 500, B: 500 : Context Filter không ảnh hưởng FIXED LOD.

(b) A: 800, B: 800 : FIXED LOD luôn tính trên toàn bộ dữ liệu.

(c) A: 800, B: 500 : Dimension Filter không ảnh hưởng FIXED LOD, nhưng Context Filter chạy trước và thu hẹp dữ liệu cho FIXED LOD.

(d) A: 500, B: 800 : Dimension Filter ảnh hưởng FIXED LOD, nhưng Context Filter thì không.

7. Cho dataset sau:

Row	Product	Sales	Profit	Quantity
1	Alpha	500	120	10
2	Beta	300	80	25
3	Gamma	700	50	15
4	Delta	400	200	8
5	Epsilon	600	150	20

Bạn tạo **Parameter** tên `[Select Measure]` (kiểu String, List: "Sales", "Profit", "Quantity") và Calculated Field:

```
-- Dynamic Measure
CASE [Select Measure]
    WHEN "Sales" THEN [Sales]
    WHEN "Profit" THEN [Profit]
    WHEN "Quantity" THEN [Quantity]
END
```

View có **Product** trên Rows, `SUM([Dynamic Measure])` trên Columns. Bạn áp dụng **Top 3** filter trên Product by `SUM([Dynamic Measure])`.

Khi user chọn `[Select Measure] = "Profit"`, tổng giá trị `SUM([Dynamic Measure])` hiển thị trên view (tổng của 3 sản phẩm Top 3) là bao nhiêu?

(a) 350

(b) 470

(c) 600

(d) 1800

8. Trong Tableau, mục đích chính của **Dashboard** là gì?

(a) Kết nối dữ liệu từ nhiều nguồn khác nhau.

(b) Kết hợp nhiều worksheet vào cùng một màn hình để trực quan hóa dữ liệu tổng hợp.

(c) Lưu trữ dữ liệu dưới dạng bảng.

(d) Thay thế hoàn toàn worksheet.

9. Sự khác biệt chính giữa **Tiled** và **Floating** layout trong Tableau là gì?

(a) Tiled cho phép đặt tự do các đối tượng, Floating tự động căn chỉnh.

(b) Tiled tự động căn chỉnh theo bố cục lưới, Floating cho phép đặt đối tượng tự do.

(c) Tiled chỉ dùng cho biểu đồ, Floating chỉ dùng cho filter.

(d) Không có sự khác biệt giữa hai loại layout này.

10. Trong thiết kế dashboard, nguyên tắc sử dụng màu sắc nào sau đây là phù hợp nhất?

(a) Sử dụng càng nhiều màu càng tốt để tăng tính trực quan.

(b) Chỉ sử dụng một màu duy nhất cho toàn bộ dashboard.

(c) Sử dụng màu sắc để nhấn mạnh thông tin quan trọng và giữ sự nhất quán.

(d) Sử dụng màu ngẫu nhiên để phân biệt các biểu đồ.

11. Filter Action trong Tableau có chức năng gì?

(a) Làm nổi bật các điểm dữ liệu liên quan giữa các biểu đồ.

(b) Cho phép chuyển đổi giữa các dashboard khác nhau.

(c) Cho phép một biểu đồ đóng vai trò bộ lọc cho các biểu đồ khác.

(d) Thay đổi màu sắc của biểu đồ theo thời gian.

12. (Bài tập tổng hợp – Parameter và Actions)
Trong bài hướng dẫn, để dashboard có thể hiển thị đồng thời cả ba chỉ số `Sales`, `Profit` và `Orders` mà không cần tạo ba phiên bản dashboard riêng biệt, giải pháp được áp dụng là gì?

A. Tạo ba tab sheet riêng biệt, mỗi tab hiển thị một chỉ số

B. Tạo một parameter `Selected Metric` và các calculated field kết nối với nó, cho phép toàn bộ biểu đồ chuyển đổi chỉ số chỉ bằng một thao tác chọn

C. Dùng bộ lọc filter thông thường trên từng biểu đồ để ẩn/hiện chỉ số tương ứng

D. Tạo ba measure riêng biệt và kéo cả ba vào cùng một biểu đồ để người xem tự so sánh

13. (Bài tập tổng hợp – LOD Expression)
Để tính điểm Recency Score cho mô hình RFM, công thức sử dụng `FIXED` như sau:

```
IF [Recency] >= { FIXED YEAR([Order Date]): PERCENTILE([Recency], 0.75)} THEN 1
...
```

Bạn muốn đơn giản hóa bằng cách bỏ `FIXED` đi. Điều gì sẽ xảy ra?

A. Công thức báo lỗi cú pháp vì `PERCENTILE` bắt buộc phải dùng kèm LOD expression

B. Kết quả không đổi vì `PERCENTILE` luôn tính trên toàn bộ dataset bất kể có `FIXED` hay không

C. Ngưỡng phân loại bị thay đổi mỗi khi người dùng áp dụng filter, khiến cùng một khách hàng có thể được xếp hạng khác nhau tùy theo bộ lọc đang chọn

D. Công thức vẫn đúng nhưng chỉ khi dashboard không sử dụng bất kỳ filter nào

Phụ lục

1. **Hint:** Các file code gợi ý và dữ liệu nếu có được lưu trong thư mục có thể được tải tại đây.
2. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại đây (Lưu ý: Sáng thứ 3 khi hết deadline phần project, ad mới copy các nội dung bài giải nêu trên vào đường dẫn).
3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 giờ.

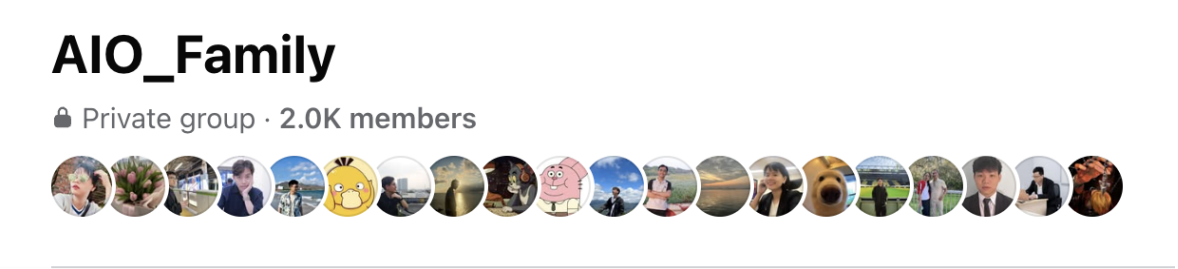

Hình 23: Hình ảnh group facebook AIO Q&A

AI VIET NAM COURSE 2026

Retail Analytics Forecasting

A. Giới thiệu chung

VinDatathon 2026 (Round 1) xoay quanh một bộ dữ liệu thương mại điện tử mô phỏng một doanh nghiệp Việt Nam, trải dài 11 năm (04/07/2012–31/12/2022) với 15 bảng phủ đủ các khía cạnh: đơn hàng, sản phẩm, khách hàng, giao vận, tồn kho và web traffic. Dựa trên dữ liệu này chúng ta sẽ phân tích đưa ra đặc điểm cụ thể, xây dựng mô hình dự đoán và giải thích thông qua phân tích để nắm rõ những câu chuyện từ dữ liệu. Trong phần này chúng ta sẽ đi tìm hiểu hai khía cạnh như sau:

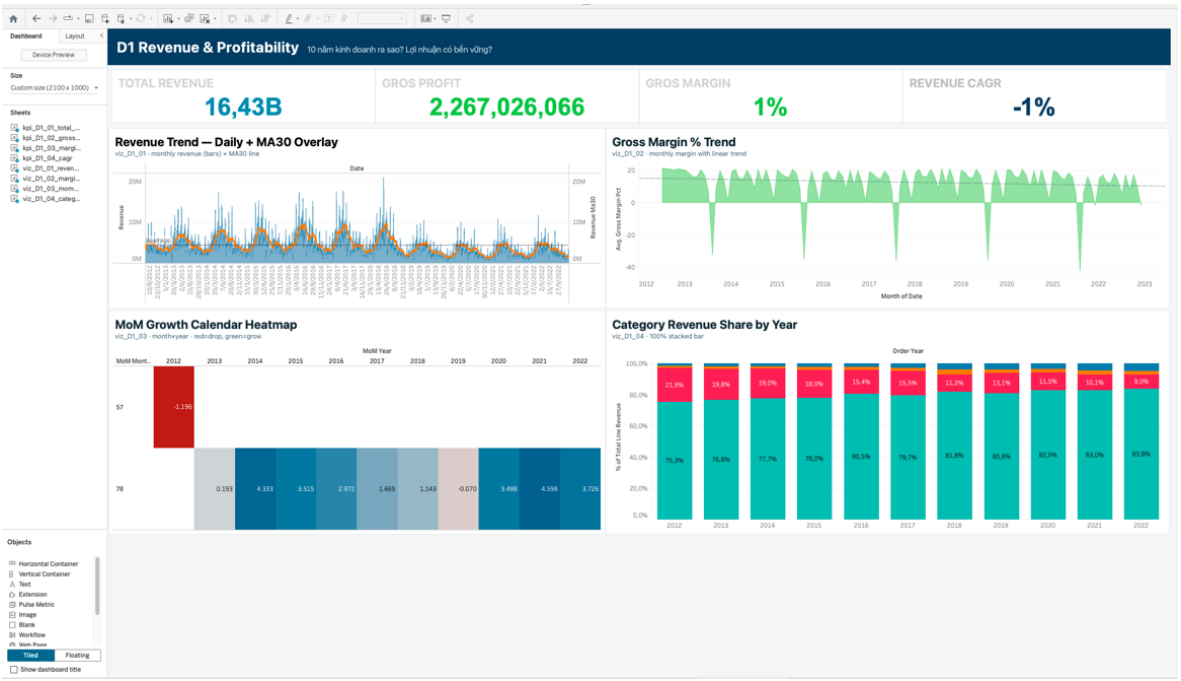

Hình 1: Phần A Dashboard & Analysis: trực quan hoá và phân tích dữ liệu bán lẻ.

Phần A Dashboard & Analysis (DA) trả lời câu hỏi *điều gì đã xảy ra và vì sao*. Phần này trực quan hoá doanh thu và lợi nhuận, phân khúc khách hàng theo RFM, phân tích cohort retention và hiệu quả các kênh marketing; mỗi dashboard đi đủ bốn cấp phân tích Descriptive

→ Diagnostic → Predictive → Prescriptive và kết thúc bằng đề xuất hành động cụ thể, định lượng.

Phần B Dự báo chuỗi thời gian (DS) chuyển từ mô tả sang *dự đoán*. Từ các quy luật quan sát được, phần này xây dựng một pipeline dự báo `Revenue` và `COGS` cho 548 ngày kế tiếp (01/01/2023–01/07/2024): feature engineering thuần lịch, ba mô hình nền (Ridge, LightGBM, Prophet), bốn mô hình chuyên biệt theo quý, một tầng ensemble, và cuối cùng là phần giải thích mô hình (explainability).

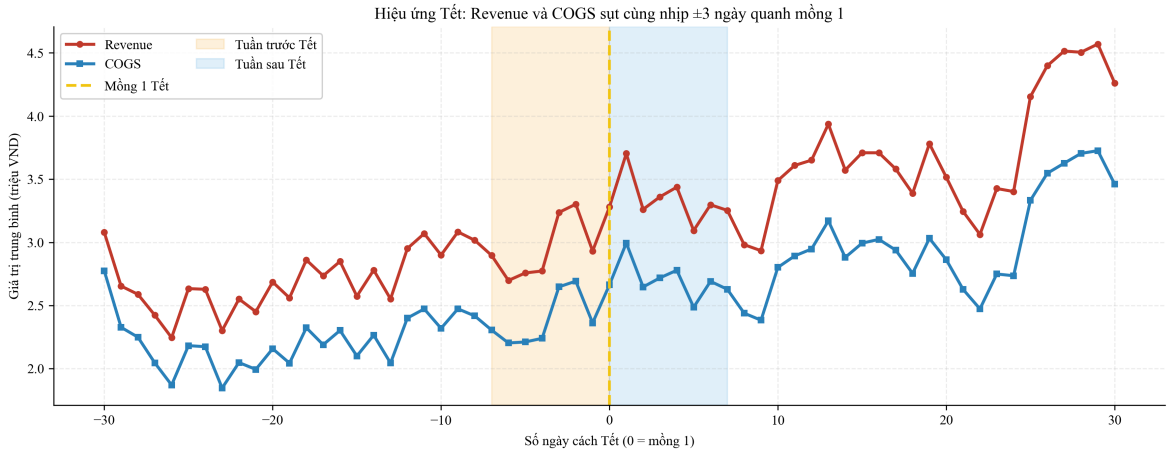

Hình 2: Phần B Dự báo chuỗi thời gian: hiệu ứng Tết được khai thác cho mô hình.

Hai phần bổ trợ chặt chẽ cho nhau: các insight và giả định rút ra ở Phần A gồm doanh thu đã qua đỉnh với CAGR âm, mùa vụ bền vững qua các năm, margin biến động mạnh theo quý chính là điểm để đưa ra các nhận định và những quyết định thiết kế mô hình ở Phần B.

B. Phân tích dữ liệu

I. Giới thiệu

Datathon 2026 Round 1 đặt ra một bài toán rất thực tế: chúng ta nhận được 15 file CSV mô phỏng toàn bộ hoạt động của **một doanh nghiệp thời trang thương mại điện tử** tại Việt Nam, giai đoạn 04/07/2012 đến 31/12/2022. Dữ liệu trải rộng từ đơn hàng, sản phẩm, khách hàng, giao vận, cho đến web traffic và inventory. Nhiệm vụ của chúng ta: biến đống dữ liệu thô đó thành một bộ dashboard có khả năng kể chuyện, đủ sâu để thuyết phục CEO hành động.

Phần 2 (Trực quan hoá & Phân tích) chiếm **60/100 điểm** của Round 1, quyết định thứ hạng. Câu hỏi đặt ra là: bắt đầu từ đâu khi trước mặt là 15 file, hàng trăm nghìn dòng, và một rubric chấm điểm khá chi tiết?

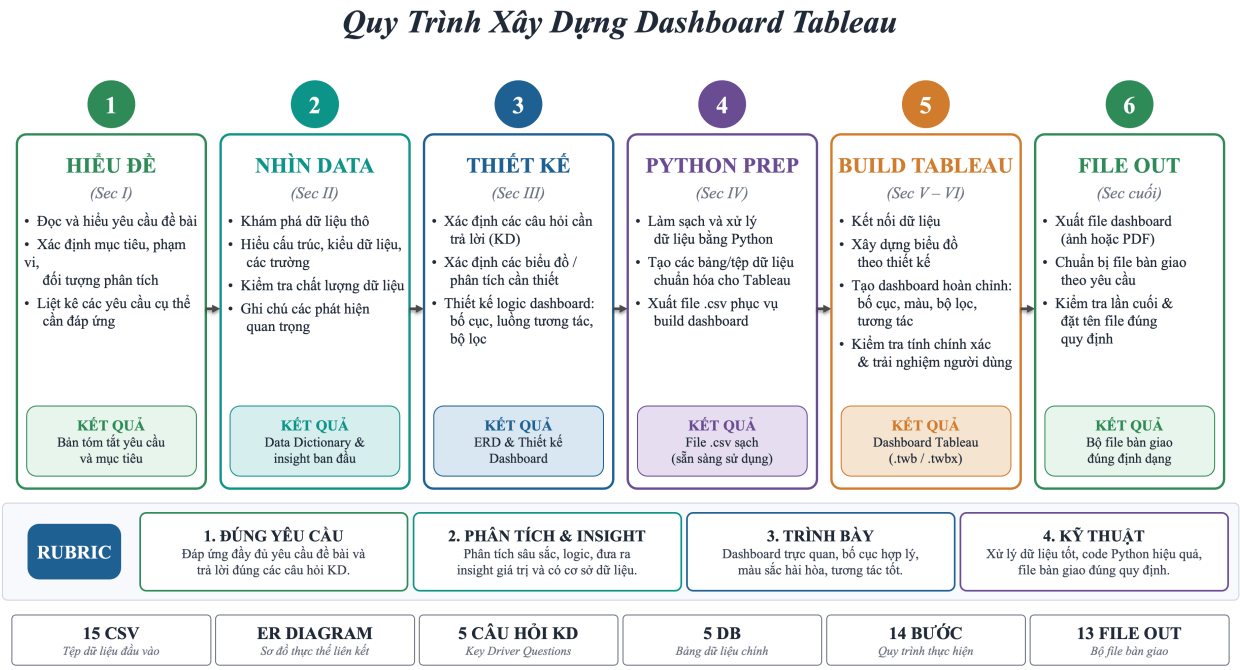

Hình 3: Quy trình phân tích dữ liệu.

Dataset là synthetic (mô phỏng)

Đơn vị tiền không xác định rõ. Khi phân tích, tập trung vào **tỷ lệ và ranking** hơn là giá trị tuyệt đối. Ví dụ: "Category A chiếm 35% doanh thu" thuyết phục hơn "Category A đạt 500 triệu".

Bài hướng dẫn này sẽ đưa chúng ta qua toàn bộ quy trình, từ phân tích đề bài cho đến build hoàn chỉnh Dashboard đầu tiên (Revenue & Profitability). Sau khi nắm vững quy trình qua Dashboard 1, chúng ta sẽ có đủ nền tảng để tự build 4 Dashboard còn lại theo cùng một pattern.

I.1. Cấu trúc đề thi

Datathon 2026 Round 1 chia thành 3 phần, trong đó Phần 2 chiếm tỷ trọng lớn nhất:

Phần	Điểm	Nội dung
Phần 1: Trắc nghiệm	20đ	10 câu hỏi tính toán từ dữ liệu
Phần 2: Visualization & Analysis	**60đ**	EDA, dashboard, insight, đề xuất hành động
Phần 3: Sales Forecasting	20đ	Dự báo Revenue trên Kaggle

Chỉ riêng Phần 2 đã chiếm quá nửa tổng điểm. Một bộ dashboard tốt có thể bù cho phần Forecasting chưa hoàn hảo, nhưng ngược lại thì khó.

I.2. Rubric: Ban giám khảo chấm những gì?

Hiểu rubric trước khi bắt tay làm giúp chúng ta biết đâu là nơi "ghi điểm" hiệu quả nhất:

Tiêu chí	Điểm	Ghi điểm cao khi...
Chất lượng trực quan hoá	15đ	Mọi biểu đồ có tiêu đề, nhãn trục, chú thích đầy đủ. Loại chart phù hợp dữ liệu
Chiều sâu phân tích	**25đ**	Đạt cả 4 cấp: Descriptive → Diagnostic → Predictive → Prescriptive
Insight kinh doanh	15đ	Đề xuất cụ thể, định lượng, áp dụng được ngay
Tính sáng tạo & kể chuyện	5đ	Góc nhìn độc đáo, kết nối nhiều bảng dữ liệu

Tiêu chí "Chiều sâu phân tích" chiếm đến 25 điểm, nặng nhất. Muốn đạt 21–25đ, bài nộp cần nhất quán ở cấp **Prescriptive** (đề xuất hành động cụ thể) trên nhiều phân tích.

4 cấp độ phân tích dữ liệu

Mỗi cấp trả lời một loại câu hỏi khác nhau:

- **Descriptive** (Chuyện gì đã xảy ra?): "Revenue giảm 3.8%/năm."
- **Diagnostic** (Tại sao xảy ra?): "Margin giảm vì COGS tăng nhanh hơn revenue."
- **Predictive** (Điều gì sẽ xảy ra?): "Q1 mỗi năm đều giảm, dự kiến Q1/2023 tương tự."
- **Prescriptive** (Nên làm gì?): "Giảm tỷ trọng category margin thấp, tăng đầu tư Stars-quadrant."

Mỗi dashboard trong bài hướng dẫn đều có ít nhất 1 chart ở mỗi cấp.

I.3. Tổng quan quy trình

Bài hướng dẫn chia thành 6 giai đoạn, mỗi giai đoạn xây trên giai đoạn trước:

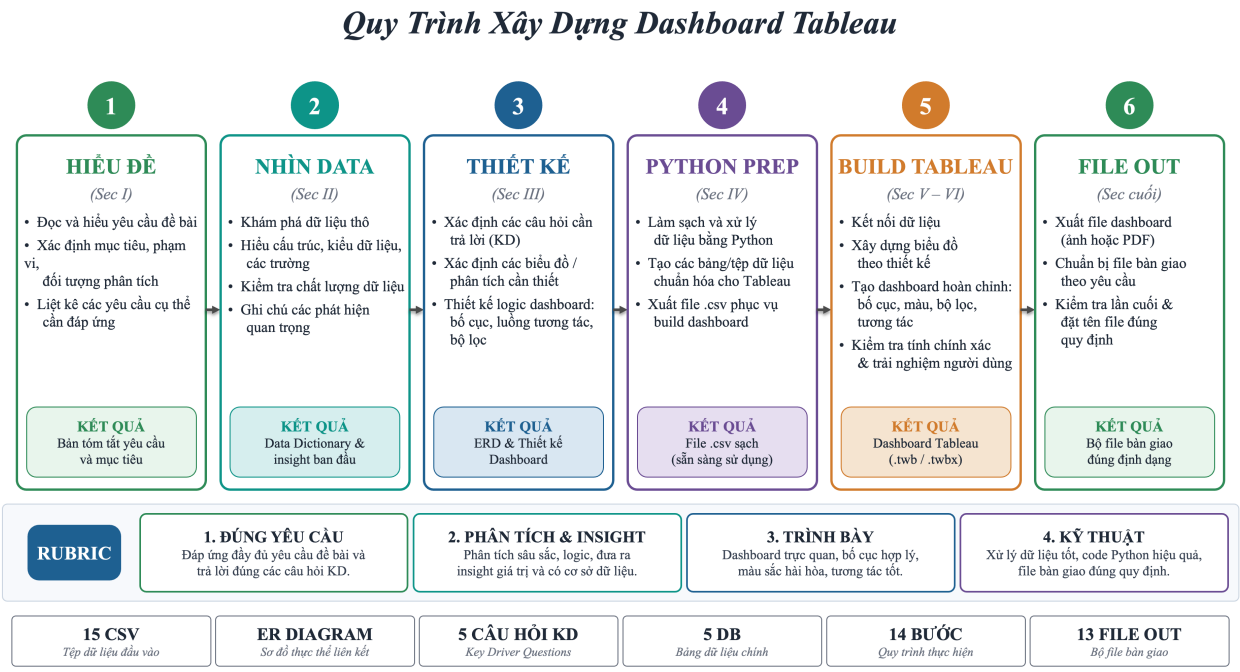

Hình 4: Quy trình phân tích dữ liệu.

Hiểu rubric giúp chọn đúng câu hỏi. Nhìn data giúp thiết kế dashboard sát thực tế. Python prep giúp Tableau chạy nhanh và công thức gọn.

II. Khám phá dữ liệu

Trước khi quyết định phân tích gì, chúng ta cần biết data có gì. Mở thư mục `Data/` và phân loại 15 file theo 4 lớp.

II.1. Bản đồ dữ liệu

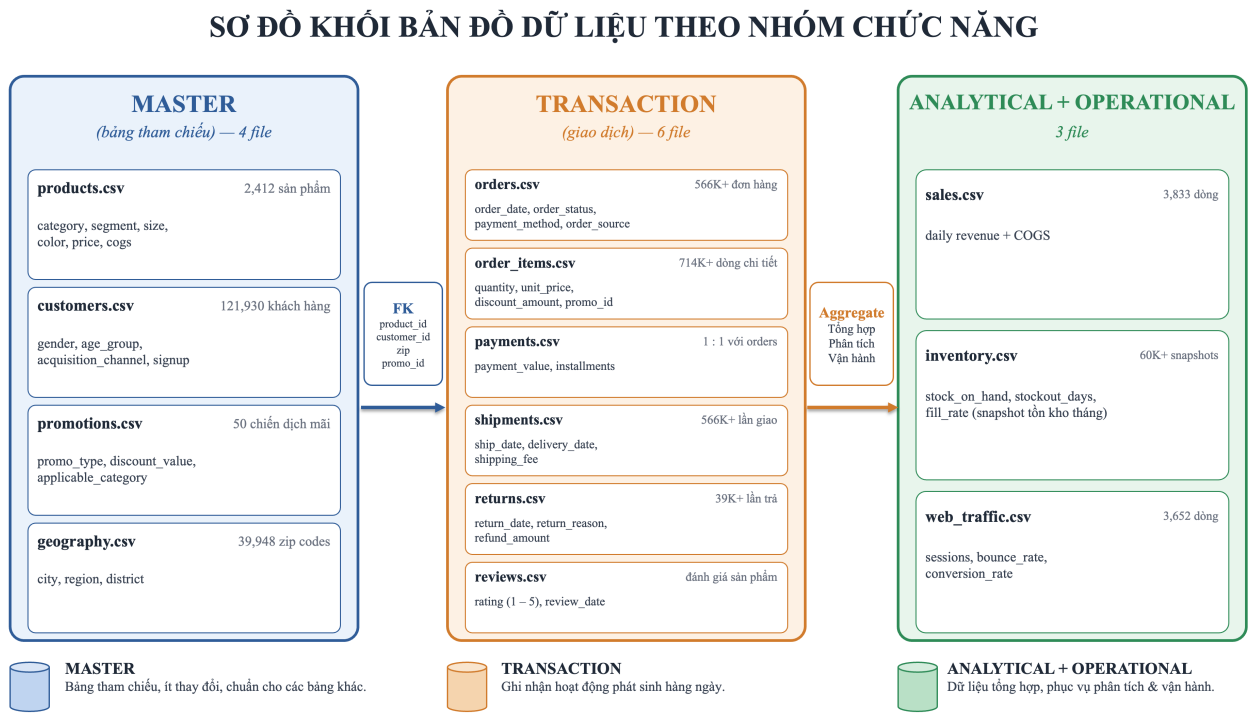

Hình 5: Bản đồ dữ liệu 15 file CSV phân theo 3 lớp: Master (bảng tham chiếu), Transaction (giao dịch), và Analytical + Operational.

Ba lớp cho thấy dữ liệu phủ đủ các khía cạnh của một doanh nghiệp: bán hàng, khách hàng, sản phẩm, marketing, và vận hành.

II.2. Quan hệ giữa các bảng

Trước khi join dữ liệu, chúng ta cần hiểu **cardinality** (số lượng quan hệ) giữa các bảng:

Quan hệ	Cardinality	Ý nghĩa
orders ↔ payments	1:1	Mỗi đơn có đúng 1 thanh toán
orders ↔ order_items	1:N	1 đơn có nhiều sản phẩm
orders ↔ shipments	1:0..1	Chỉ đơn shipped/delivered có giao hàng
orders ↔ returns	1:0..N	1 đơn có thể trả nhiều sản phẩm
orders ↔ reviews	1:0..N	Chỉ ∼20% đơn có review
order_items ↔ promotions	N:0..1	Mỗi line item có thể áp 0–2 promo
products ↔ inventory	1:N	1 sản phẩm có nhiều snapshot tháng

II.3. Ba nhận xét quan trọng

Dữ liệu đủ cho phân tích đa chiều. Có đủ 5 khía cạnh: tài chính (`sales`, `payments`), khách hàng (`customers`), sản phẩm (`products`, `reviews`, `returns`), marketing (`orders.order_source`, `web_traffic`), vận hành (`shipments`, `inventory`). Đây là cơ sở thuận lợi để xây dựng phần phân tích có tính sáng tạo và câu chuyện dữ liệu rõ ràng.

Nhiều bảng cần join mới có ý nghĩa. Muốn biết category nào có return rate cao nhất thì cần join `returns` → `products`. Muốn biết kênh nào mang KH giá trị cao thì cần join `orders` → `order_items` → `payments` → `customers`.

Grain khác nhau giữa các bảng. `sales.csv` có 1 dòng = 1 ngày, `order_items.csv` có 1 dòng = 1 sản phẩm trong 1 đơn. Không thể join trực tiếp hai bảng này trong Tableau mà không xử lý trước. Đây là lý do chúng ta cần Python prep.

Khái Niệm: Grain (mức chi tiết)

Grain là đơn vị nhỏ nhất mà mỗi dòng trong bảng đại diện. Ví dụ: grain của `order_items` là một sản phẩm trong một đơn hàng, grain của `sales` là một ngày. Hiểu đúng grain giúp tránh lỗi tính toán: `SUM(line_revenue)` cho đúng tổng doanh thu, nhưng `COUNT(order_id)` sẽ đếm trùng nếu 1 đơn có nhiều sản phẩm.

III. Thiết kế hướng phân tích

Giờ chúng ta ánh xạ data vào câu hỏi kinh doanh. Mỗi câu hỏi trở thành 1 dashboard:

III.1. Mapping: Data → Câu hỏi → Dashboard

#	Câu hỏi kinh doanh	Data cần	Tại sao?
1	Tăng trưởng ra sao? Lợi nhuận bền vững?	`sales` + `order_items`	3,833 ngày revenue, dễ vẽ trend
2	Ai là KH giá trị? Ai đang rời?	`customers` + `orders` + `payments`	Demographics + RFM
3	SP nào tốt? Tại sao bị trả?	`products` + `returns` + `reviews`	Price/cogs cho margin, reviews cho rating
4	Kênh marketing nào hiệu quả?	`orders` + `web_traffic` + `promotions`	Channel data + bounce/conversion
5	Delivery và inventory có vấn đề?	`shipments` + `inventory`	Delivery time + stockout metrics

III.2. Narrative arc (mạch chuyện)

5 dashboards xếp theo logic kinh doanh, từ tổng quan đến chi tiết:

```
DB1: Revenue Overview → 10 năm kinh doanh thế nào?
                        ↓
   DB2: Customer → Ai mua hàng? Ai đang rời đi?
                        ↓
     DB3: Product → Bán gì? Chất lượng ra sao?
                        ↓
       DB4: Marketing → Kênh nào mang KH đến?
                        ↓
  DB5: Operations → Giao hàng, tồn kho ổn không?
                        ↓
          Story: 5 đề xuất hành động cho CEO
```

Mỗi dashboard bao phủ đủ 4 cấp phân tích. Mỗi dashboard kết nối ít nhất 3 bảng dữ liệu. Mỗi dashboard kết thúc bằng đề xuất hành động cụ thể.

III.3. Tại sao cần Python trước khi mở Tableau?

Nhìn bảng mapping, mỗi dashboard cần join 2–5 bảng. Nếu join trực tiếp trong Tableau:

- **Performance kém:** Tableau Public xử lý chậm khi join bảng 714K dòng với 566K dòng

- **Logic phức tạp:** Tính RFM score, cohort retention, margin % cần code Python, không phải Tableau calc field
- **Lặp lại công việc:** 5 dashboards cùng cần phép join `orders + order_items + products`, sao không tính 1 lần?

Vì vậy, chúng ta dùng Python để: **join** (gộp nhiều bảng thành bảng phẳng), **compute** (tính sẵn RFM, margin, moving averages), và **aggregate** (tạo bảng tổng hợp cohort, monthly KPI).

IV. Chuẩn bị dữ liệu bằng Python

Script `prepare_tableau_data.py` là xương sống của toàn bộ pipeline. Chúng ta sẽ đi qua từng bước: đọc code, hiểu logic, và biết kết quả dùng ở đâu trong Tableau.

IV.1. Cấu hình và helper functions

```python
import pandas as pd
import numpy as np
import os

DATA_DIR = r"Data"
OUT_DIR  = r"tableau_data"
os.makedirs(OUT_DIR, exist_ok= True)

def load(name, **kw):
    path = os.path.join(DATA_DIR, name)
    df = pd.read_csv(path, **kw)
    print(f"  Loaded {name}: {df.shape[0]:,} rows x {df.shape[1]} cols")
    return df

def save(df, name):
    path = os.path.join(OUT_DIR, name)
    df.to_csv(path, index= False)
    size_mb = os.path.getsize(path) / 1024 / 1024
    print(f"  Saved {name}: {df.shape[0]:,} rows ({size_mb:.1f} MB)")
```

`load()` đọc CSV và in số dòng. `save()` ghi ra `tableau_data/`. Cần Python 3.8+:

```
python --version   # Can Python 3.8+
pip install pandas numpy
python prepare_tableau_data.py
```

Script mất khoảng 1–2 phút, tạo **13 file CSV** (tổng ∼277 MB).

IV.2. Tổng quan 14 bước xử lý

Các bước đánh dấu ⋆ được phân tích code chi tiết:

Step	Output	Xử lý chính
1	(load vào RAM)	Parse dates, đọc 15 file
2 ⋆	`dim_products`	products + reviews + returns → margin, avg rating, return stats
3	`dim_geography`	Copy nguyên
4	`dim_promotions`	Copy nguyên
5 ⋆	`fact_orders_enriched`	**JOIN 5 bảng** + tính revenue, cost, margin, date dims
6	`fact_returns_enriched`	returns + products + orders → days_to_return
7 ⋆	`dim_customers_rfm`	**RFM Segmentation** (R, F, M scores + 8 segment labels)
8	`fact_shipments`	delivery_days, processing_days, delivery_bucket
9 ⋆	`fact_sales_daily`	Gross profit, margin, MA7/MA30, YoY growth
10	`fact_inventory`	health label, sell_through
11	`fact_web_traffic`	pages_per_session
12 ⋆	`agg_cohort_retention`	Ma trận retention 24 tháng
13	`agg_monthly_summary`	KPI rollup hàng tháng
14	`agg_reviews_summary`	Rating theo tháng × category

IV.3. Step 1: Load dữ liệu gốc

```
orders      = load("orders.csv",      parse_dates=["order_date"])
order_items = load("order_items.csv")
payments    = load("payments.csv")
products    = load("products.csv")
customers   = load("customers.csv",   parse_dates=["signup_date"])
geography   = load("geography.csv")
promotions  = load("promotions.csv",  parse_dates=["start_date", "end_date"])
shipments   = load("shipments.csv",   parse_dates=["ship_date", "delivery_date"])
returns     = load("returns.csv",     parse_dates=["return_date"])
reviews     = load("reviews.csv",     parse_dates=["review_date"])
inventory   = load("inventory.csv",   parse_dates=["snapshot_date"])
web_traffic = load("web_traffic.csv", parse_dates=["date"])
sales       = load("sales.csv",      parse_dates=["Date"])
```

`parse_dates` chỉ định cột ngày để pandas parse thành `datetime64`. Nếu bỏ qua, `order_date` sẽ là chuỗi, không thể tính `.dt.year`.

IV.4. Step 2: dim_products (Sản phẩm enriched)

Bắt đầu từ `products.csv` (2,412 SP), bổ sung 3 nhóm thông tin:

```
# a) Margin tai cap san pham
dim_products = products. copy()
dim_products["gross_margin_pct"] = (
```

```
    (dim_products["price"] - dim_products["cogs"]) / dim_products["price"] * 100
).round(2)
dim_products["profit_per_unit"] = (dim_products["price"] - dim_products["cogs"]).round(
                                        2)

# b) Join avg rating tu reviews
avg_rating = reviews.groupby("product_id")["rating"].agg(["mean", "count"]).reset_index
                                        ()
avg_rating.columns = ["product_id", "avg_rating", "review_count"]

# c) Join return stats tu returns
ret_stats = returns.groupby("product_id").agg(
    total_returns    = ("return_id", "count"),
    total_return_qty = ("return_quantity", "sum"),
    total_refund     = ("refund_amount", "sum")
).reset_index()

dim_products = dim_products.merge(avg_rating, on="product_id", how="left")
dim_products = dim_products.merge(ret_stats, on="product_id", how="left")

# d) Xu ly NaN
dim_products[["review_count", "total_returns", "total_return_qty"]] = \
    dim_products[["review_count", "total_returns", "total_return_qty"]].fillna(0).
                                        astype(int)
dim_products["total_refund"] = dim_products["total_refund"].fillna(0)
```

`.copy()` tạo bản sao để không sửa DataFrame gốc. `.merge(how="left")` giữ nguyên tất cả 2,412 SP; SP chưa có review sẽ là `NaN`. `.fillna(0)` thay `NaN` bằng 0.

IV.5. Step 3 và 4: dim_geography, dim_promotions

```
save(geography, "dim_geography.csv")    # 39,948 dong
save(promotions, "dim_promotions.csv")  # 50 dong
```

Copy nguyên, không xử lý. Tableau dùng làm bảng tham chiếu khi cần filter theo vùng hoặc loại promotion.

IV.6. Step 5: fact_orders_enriched (Bảng fact trung tâm)

Bước quan trọng nhất. Grain = **từng line item**.

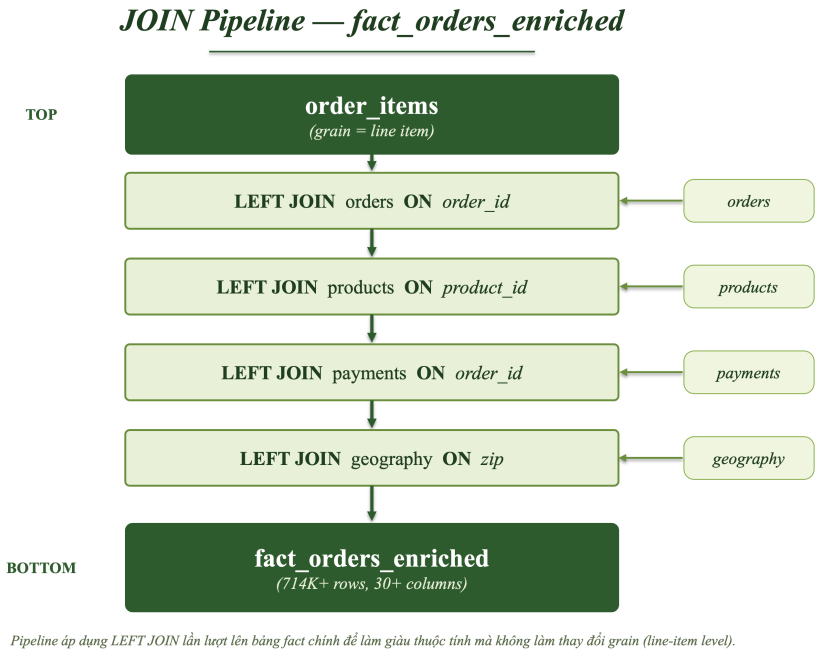

Hình 6: Pipeline JOIN 5 bảng để tạo `fact_orders_enriched`.

```python
fact = order_items. copy()
fact = fact.merge(
    orders[["order_id","order_date","customer_id","zip",
            "order_status","payment_method","device_type","order_source"]],
    on="order_id", how="left")
fact = fact.merge(
    products[["product_id","product_name","category","segment",
              "size","color","price","cogs"]],
    on="product_id", how="left")
fact = fact.merge(
    payments[["order_id","payment_value","installments"]],
    on="order_id", how="left")
fact = fact.merge(
    geography[["zip","city","region"]].drop_duplicates(subset="zip"),
    on="zip", how="left")
```

Tại sao dùng LEFT JOIN?

Một số đơn hàng có thể thiếu geography hoặc payment. LEFT JOIN giữ nguyên tất cả line items; cột thiếu sẽ là NULL. Nếu dùng INNER JOIN, chúng ta mất dữ liệu.

Computed fields:

```
fact["line_revenue"]      = (fact["quantity"] * fact["unit_price"]).round(2)
fact["line_cost"]         = (fact["quantity"] * fact["cogs"]).round(2)
fact["line_gross_profit"] = (fact["line_revenue"] - fact["line_cost"]).round(2)
fact["line_margin_pct"]   = np.where(
    fact["line_revenue"] > 0,
    (fact["line_gross_profit"] / fact["line_revenue"] * 100).round(2), 0)

fact["has_promo"]    = (~fact["promo_id"].isna() & (fact["promo_id"] != '')).astype(int
                                                )
fact["discount_pct"] = np.where(
    fact["line_revenue"] + fact["discount_amount"] > 0,
    (fact["discount_amount"] / (fact["line_revenue"] + fact["discount_amount"]) * 100).
                                                round(2), 0)
```

`np.where(condition, true, false)` tương đương IF-ELSE, tránh chia cho 0.

Date dimensions:

```
fact["order_year"]     = fact["order_date"].dt.year
fact["order_month"]    = fact["order_date"].dt.month
fact["order_quarter"]  = fact["order_date"].dt.quarter
fact["order_dow"]      = fact["order_date"].dt.dayofweek   # 0=Monday
fact["order_dow_name"] = fact["order_date"].dt.day_name()
fact["order_ym"]       = fact["order_date"].dt.to_period("M").astype( str)
```

IV.7. Step 6: fact_returns_enriched

```
fact_ret = returns. copy()
fact_ret = fact_ret.merge(
    products[["product_id","product_name","category","segment",
              "size","color","price","cogs"]],
    on="product_id", how="left")
fact_ret = fact_ret.merge(
    orders[["order_id","order_date","customer_id","order_source","device_type"]],
    on="order_id", how="left")
fact_ret["days_to_return"] = (fact_ret["return_date"] - fact_ret["order_date"]).dt.days
```

`days_to_return` = số ngày từ lúc mua đến lúc trả. Category bị trả sớm (lỗi SP) vs trả muộn (đổi ý).

IV.8. Step 7: RFM Segmentation (phức tạp nhất)

Khái Niệm: RFM Analysis

RFM phân khúc KH dựa trên 3 hành vi: **Recency** (mua gần đây?), **Frequency** (mua thường xuyên?), **Monetary** (mua giá trị?). Mỗi chiều chia thành 5 quintile.

Phần 1–2: Tính R, F, M + gán quintile

```
ref_date = orders["order_date"].max() + pd.Timedelta(days=1)
rfm = orders.merge(payments[["order_id", "payment_value"]], on="order_id", how="left")
rfm = rfm[rfm["order_status"] != "cancelled"]

rfm_agg = rfm.groupby("customer_id").agg(
    last_order_date  = ("order_date", "max"),
    first_order_date = ("order_date", "min"),
    frequency        = ("order_id", "nunique"),
    monetary         = ("payment_value", "sum"),
    avg_order_value  = ("payment_value", "mean"),
).reset_index()
rfm_agg["recency_days"] = (ref_date - rfm_agg["last_order_date"]).dt.days
rfm_agg["tenure_days"]  = (ref_date - rfm_agg["first_order_date"]).dt.days

rfm_agg["R_score"] = pd.qcut(rfm_agg["recency_days"], q=5, labels=[5,4,3,2,1]).astype(
                                            int)
rfm_agg["F_score"] = pd.qcut(rfm_agg["frequency"].rank(method="first"), q=5, labels=[1,
                                            2,3,4,5]).astype(int)
rfm_agg["M_score"] = pd.qcut(rfm_agg["monetary"].rank(method="first"), q=5, labels=[1,2
                                            ,3,4,5]).astype(int)
rfm_agg["RFM_score"] = rfm_agg["R_score"]*100 + rfm_agg["F_score"]*10 + rfm_agg["
                                            M_score"]
```

Lưu ý

RFM loại `cancelled`. `fact_orders_enriched` giữ lại tất cả đơn. Nếu cần revenue "net", thêm filter trong worksheet.

Phần 3: Gán segment label

```
def rfm_segment(row):
    r, f, m = row["R_score"], row["F_score"], row["M_score"]
    if r >= 4 and f >= 4:        return "Champions"
    elif r >= 3 and f >= 3:      return "Loyal Customers"
    elif r >= 4 and f <= 2:      return "New Customers"
    elif r >= 3 and m >= 3:      return "Potential Loyalists"
    elif r <= 2 and f >= 3:      return "At Risk"
    elif r <= 2 and f >= 4 and m >= 4: return "Cant Lose Them"
    elif r <= 2 and f <= 2:      return "Lost"
    elif r == 3 and f <= 2:      return "About To Sleep"
```

```
    else:                          return "Need Attention"

rfm_agg["rfm_segment"] = rfm_agg.apply(rfm_segment, axis=1)
```

Phần 4: Merge demographics

```
dim_cust = customers.merge(rfm_agg, on="customer_id", how="left")
dim_cust = dim_cust.merge(
    geography[["zip","region"]].drop_duplicates(subset="zip"),
    on="zip", how="left")
dim_cust["frequency"]    = dim_cust["frequency"].fillna(0).astype(int)
dim_cust["monetary"]     = dim_cust["monetary"].fillna(0)
dim_cust["rfm_segment"] = dim_cust["rfm_segment"].fillna("Never Purchased")
```

LEFT JOIN `customers` (121,930) với `rfm_agg` (chỉ KH đã mua). KH chưa mua → `NaN` → segment "Never Purchased".

Kết quả phân khúc:

Segment	Số KH	%	Ý nghĩa
Never Purchased	33,807	27.7	Đăng ký nhưng chưa mua
Lost	24,996	20.5	Đã lâu không quay lại
Champions	24,490	20.1	Mua gần, thường xuyên
Loyal Customers	18,163	14.9	Khách trung thành
At Risk	10,221	8.4	Từng mua nhiều, giờ thưa
New Customers	4,865	4.0	Mới mua
About To Sleep	4,222	3.5	Đang giảm tương tác
Potential Loyalists	1,166	1.0	Có tiềm năng

IV.9. Step 8: Shipments enriched

```
fact_ship = shipments. copy()
fact_ship["delivery_days"]   = (fact_ship["delivery_date"] - fact_ship["ship_date"]).dt
                                                                    .days
fact_ship = fact_ship.merge(
    orders[["order_id","order_date","zip","order_status"]],
    on="order_id", how="left")
fact_ship["processing_days"] = (fact_ship["ship_date"] - fact_ship["order_date"]).dt.
                                                                    days
fact_ship["total_lead_time"] = (fact_ship["delivery_date"] - fact_ship["order_date"]).
                                                                    dt.days

fact_ship["delivery_bucket"] = pd.cut(
```

```
    fact_ship["delivery_days"],
    bins=[-1, 2, 5, 7, 14, 999],
    labels=["1-2 days", "3-5 days", "6-7 days", "8-14 days", "15+ days"])
```

`pd.cut()` phân nhóm giá trị liên tục vào bucket rời rạc. Tableau dùng `delivery_bucket` để tạo histogram.

Lưu ý

Dataset hiện tại chỉ có giá trị ở "1–2 days", "3–5 days", "6–7 days". Hai bucket sau reserve cho data tương lai.

IV.10. Step 9: fact_sales_daily (Revenue + trends)

```
fact_sales = sales. copy()
fact_sales.columns = ["date", "revenue", "cogs"]
fact_sales["gross_profit"]     = (fact_sales["revenue"] - fact_sales["cogs"]).round(2)
fact_sales["gross_margin_pct"] = (
    fact_sales["gross_profit"] / fact_sales["revenue"] * 100).round(2)
fact_sales["year_month"] = fact_sales["date"].dt.to_period("M").astype( str)

# Rolling averages
fact_sales = fact_sales.sort_values("date")
fact_sales["revenue_ma7"]  = fact_sales["revenue"].rolling(7, min_periods=1).mean().
                                          round(2)
fact_sales["revenue_ma30"] = fact_sales["revenue"].rolling(30, min_periods=1).mean().
                                          round(2)

# YoY growth
fact_sales["revenue_ly"] = fact_sales["revenue"].shift(365)
fact_sales["yoy_growth_pct"] = np.where(
    fact_sales["revenue_ly"] > 0,
    ((fact_sales["revenue"] - fact_sales["revenue_ly"]) / fact_sales["revenue_ly"] *
                                          100).round(2),
    np.nan)
fact_sales.drop(columns=["revenue_ly"], inplace= True)
```

Khái Niệm: Moving Average (MA)

Moving Average tính trung bình N ngày liên tiếp. MA7 loại nhiễu ngày-qua-ngày. MA30 cho xu hướng dài hạn. `min_periods=1` giúp N ngày đầu không NULL.

Lưu ý

`yoy_growth_pct` null 365 ngày đầu (không có năm trước để so). Nếu overlay YoY trên chart, filter `date` $\geq$ `2013-07-04`.

IV.11. Step 10: Inventory + health labels

```
fact_inv = inventory. copy()
fact_inv = fact_inv.merge(
    products[["product_id","price","cogs"]].rename(
        columns={"price":"product_price","cogs":"product_cogs"}),
    on="product_id", how="left")
fact_inv["inventory_value_retail"] = (fact_inv["stock_on_hand"] * fact_inv["
                                        product_price"]).round(2)
fact_inv["inventory_value_cost"]   = (fact_inv["stock_on_hand"] * fact_inv["
                                        product_cogs"]).round(2)

def inv_health(row):
    if row["stockout_flag"] == 1:   return "Stockout"
    elif row["overstock_flag"] == 1: return "Overstock"
    elif row["reorder_flag"] == 1:  return "Reorder Needed"
    else:                           return "Healthy"

fact_inv["inventory_health"] = fact_inv.apply(inv_health, axis=1)
```

IV.12. Step 11: Web traffic

```
fact_web = web_traffic. copy()
fact_web.rename(columns={"date": "traffic_date"}, inplace= True)
fact_web["pages_per_session"] = (fact_web["page_views"] / fact_web["sessions"]).round(2
                                    )
```

Đổi `date` → `traffic_date` vì "date" là keyword trong SQL.

IV.13. Step 12: Cohort Retention

Khái Niệm: Cohort Analysis

Cohort = nhóm KH có cùng tháng mua đầu tiên. **Retention** = % KH quay lại mua ở tháng thứ N. Ma trận cho thấy "KH tháng 3/2020, 6 tháng sau còn bao nhiêu % quay lại?"

```
# 1. Xac dinh cohort = thang mua dau tien
first_order = orders[orders["order_status"] != "cancelled"] \
    .groupby("customer_id")["order_date"].min().reset_index()
first_order.columns = ["customer_id", "cohort_date"]
first_order["cohort_month"] = first_order["cohort_date"].dt.to_period("M")

# 2. Tinh period_number
orders_cohort = orders[orders["order_status"] != "cancelled"][
    ["order_id", "customer_id", "order_date"]]. copy()
orders_cohort["order_month"] = orders_cohort["order_date"].dt.to_period("M")
```

```
orders_cohort = orders_cohort.merge(
    first_order[["customer_id", "cohort_month"]], on="customer_id")
orders_cohort["period_number"] = (
    (orders_cohort["order_month"].dt.year - orders_cohort["cohort_month"].dt.year) * 12
                                            +
    (orders_cohort["order_month"].dt.month - orders_cohort["cohort_month"].dt.month))

# 3. Tinh retention rate
cohort_sizes = orders_cohort.groupby("cohort_month")["customer_id"].nunique().
                                                reset_index()
cohort_sizes.columns = ["cohort_month", "cohort_size"]

retention = orders_cohort.groupby(["cohort_month", "period_number"]) \
    ["customer_id"].nunique().reset_index()
retention.columns = ["cohort_month", "period_number", "active_customers"]
retention = retention.merge(cohort_sizes, on="cohort_month")
retention["retention_rate"] = (
    retention["active_customers"] / retention["cohort_size"] * 100).round(2)
retention = retention[retention["period_number"] <= 24]
```

Kết quả: hàng = `cohort_month`, cột = `period_number` (0–24), giá trị = `retention_rate` (%).

IV.14. Step 13 và 14: Bảng tổng hợp

Step 13: `agg_monthly_summary`

```
monthly = fact_sales.groupby("year_month").agg(
    revenue       = ("revenue", "sum"),
    cogs          = ("cogs", "sum"),
    gross_profit  = ("gross_profit", "sum"),
    avg_daily_rev = ("revenue", "mean"),
    days_in_month = ("revenue", "count"),
).reset_index()
monthly["revenue_prev"] = monthly["revenue"].shift(1)
monthly["mom_growth_pct"] = np.where(
    monthly["revenue_prev"] > 0,
    ((monthly["revenue"] - monthly["revenue_prev"]) / monthly["revenue_prev"] * 100).
                                            round(2),
    np.nan)
```

`.shift(1)` lấy giá trị tháng trước. `mom_growth_pct` = % thay đổi MoM. Dashboard 1 Chart 3 dùng trường này.

Step 14: `agg_reviews_summary`

```
# Enrich reviews voi category tu products
reviews_enriched = reviews.merge(
    products[["product_id", "category", "segment"]],
    on="product_id", how="left")
```

```
reviews_enriched["review_ym"] = reviews_enriched["review_date"].dt.to_period("M").
                                                astype(
                                                str)

rev_summary = reviews_enriched.groupby(["review_ym", "category"]).agg(
    avg_rating   = ("rating", "mean"),
    review_count = ("review_id", "count"),
    pct_5_star   = ("rating", lambda x: (x == 5).mean() * 100),
    pct_1_star   = ("rating", lambda x: (x == 1).mean() * 100),
).reset_index()
```

`lambda x: (x == 5).mean() * 100` = tỷ lệ % review 5 sao. Bảng này (504 dòng) dùng cho Dashboard 3 Rating Trend.

V. Thiết lập Tableau Public

V.1. Tạo Data Source

1. Mở **Tableau Public Desktop**
2. Chọn **Connect** → **Text File**
3. Chọn file cần dùng (ví dụ `fact_sales_daily.csv`)

Tách data source riêng cho mỗi dashboard thay vì gộp tất cả (Tableau Public giới hạn performance):

Dashboard	Files cần load
1: Revenue	`fact_sales_daily` + `agg_monthly_summary` + `fact_orders_enriched`
2: Customer	`dim_customers_rfm` + `agg_cohort_retention`
3: Product	`fact_orders_enriched` + `dim_products` + `fact_returns_enriched` + `agg_reviews_summary`
4: Marketing	`fact_orders_enriched` + `fact_web_traffic` + `dim_promotions`
5: Operations	`fact_inventory` + `fact_shipments_enriched`

V.2. Kiểm tra Data Types

Cột	Kiểu đúng	Lưu ý
`order_date`, `return_date`	**Date**	Nếu hiện String, click icon để đổi
`zip`, `customer_id`, `order_id`	**String** (Dimension)	Không để Number
`year_month`, `order_ym`	**String**	Dùng làm discrete axis
`has_promo`, `stockout_flag`	**Number** (Boolean)	0/1

V.3. Template layout chung

Mỗi dashboard dùng layout chung:

```
Dashboard ( bg #F6F7F9)
|- Banner (Horizontal, h=72, bg #1F3A5F, text trắng 22pt)
|- Filter bar (Horizontal, h=44, bg white)
|- KPI Strip (Horizontal, h=120, 4 KPI cards)
+- Chart Grid 2×2 (Vertical → 2 Horizontal rows, h∼382/row)
```

Layout panel

Dùng **Layout panel** (trái dưới) để xem cây containers. Click container để chỉnh Padding, Background, Size. Khi kéo worksheet sai vị trí, layout tree dễ dùng hơn click trực tiếp trên canvas.

V.4. Dashboard Actions

Dashboard Action cho phép click/hover vào chart này để filter/highlight chart khác:

1. Menu **Dashboard** → **Actions** → **Add Action**
2. Chọn loại: **Filter** (click drill-down), **Highlight** (hover), hoặc **Go to Sheet** (nav button)
3. Chỉ định Source sheets, Target sheets, Run on (Select/Hover), và Target Filters

V.5. KPI Delta

Thuật ngữ Tableau dùng trong phần này

- **LOD** (Level of Detail): biểu thức `{FIXED ... : ...}` tính aggregation ở cấp khác với chart
- **COUNTD**: đếm giá trị duy nhất (không đếm trùng)
- **Quick Table Calculation**: phép tính nhanh trên cell so với cell khác
- **Marks Card**: bảng điều khiển chứa Color/Size/Text/Label/Detail/Tooltip

Pattern chính (LOD Expression):

```
Current Year Rev  = { FIXED : SUM(IIF(YEAR([date]) = { MAX(YEAR([date]))
    }, [revenue], 0)) }
Prior Year Rev    = { FIXED : SUM(IIF(YEAR([date]) = { MAX(YEAR([date]))
    } - 1, [revenue], 0)) }
Revenue YoY Delta = ([Current Year Rev] - [Prior Year Rev]) / [Prior Year
     Rev] * 100
```

`{FIXED : ...}` scope toàn bộ dataset, không phụ thuộc filter. `MAX(YEAR([date]))` = năm mới nhất (2022).

Hiển thị delta trên KPI card:

1. Kéo delta measure vào Text, dòng 2, size 12pt
2. Conditional color: `IIF([Delta] >= 0, "up", "down")` → green/red
3. Custom format: ▲ +0.0%; ▼ -0.0%

Test delta nhanh

Kéo field vào Marks Card → Text → xem giá trị. Nếu ra NULL: kiểm tra (a) `MAX(YEAR([date]))` hoạt động không, (b) Prior year có dữ liệu không, (c) Divisor có = 0 không.

VI. Dashboard 1: Revenue & Profitability

Câu hỏi chủ đạo: "10 năm kinh doanh, doanh nghiệp tăng trưởng thế nào? Lợi nhuận có bền vững?"

Chart	Data source
KPI Cards + Chart 1–2	`fact_sales_daily.csv`
Chart 3 (MoM Heatmap)	`agg_monthly_summary.csv`
Chart 4 (Category Contribution)	`fact_orders_enriched.csv`

Dashboard gồm 4 KPI cards + 4 charts, mỗi chart ở 1 cấp phân tích.

VI.1. 4 KPI Cards

KPI 1: Total Revenue font Accent `#2E86AB`. BAN: `SUM([revenue])`. Format: K/M/B.

```
Current Year Rev  = { FIXED : SUM(IIF(YEAR([date]) = { MAX(YEAR([date]))
    }, [revenue], 0)) }
Prior Year Rev    = { FIXED : SUM(IIF(YEAR([date]) = { MAX(YEAR([date]))
    } - 1, [revenue], 0)) }
Revenue YoY Delta = ([Current Year Rev] - [Prior Year Rev]) / [Prior Year
     Rev] * 100
```

KPI 2: Gross Profit font Accent `#6BBF59`. BAN: `SUM([gross_profit])`. Delta: cùng pattern, thay `revenue` bằng `gross_profit`.

KPI 3: Gross Margin % BAN: `SUM([gross_profit]) / SUM([revenue]) * 100`. Format: `0.0%`. Delta dùng **pp** (percentage-point):

```
Current Year Margin = SUM(IIF(YEAR([date])={MAX(YEAR([date]))}, [
    gross_profit], 0))
                    / SUM(IIF(YEAR([date])={MAX(YEAR([date]))}, [revenue
    ], 0)) * 100
Prior Year Margin   = SUM(IIF(YEAR([date])={MAX(YEAR([date]))}-1, [
    gross_profit], 0))
                    / SUM(IIF(YEAR([date])={MAX(YEAR([date]))}-1, [
    revenue], 0)) * 100
Margin pp Delta = [Current Year Margin] - [Prior Year Margin]
```

Lưu ý

pp vs %: Nếu margin từ 22% xuống 14%, pp delta = −8 pp (không phải −36%). Format: ▲ + 0.0 "pp"; ▼ − 0.0 "pp".

KPI 4: Revenue CAGR (2013 → 2022) font Accent `#1F3A5F`.

```
annual_rev_2013 = { FIXED : SUM(IIF(YEAR([date]) = 2013, [revenue], 0)) }
annual_rev_2022 = { FIXED : SUM(IIF(YEAR([date]) = 2022, [revenue], 0)) }
CAGR = (POWER([annual_rev_2022] / [annual_rev_2013], 1.0/9) - 1) * 100
```

Format: `0.0%`. Không có delta. Dưới BAN ghi chú tĩnh "9-year compound".

Tại sao 2013–2022, không phải 2012–2022?

`fact_sales_daily` bắt đầu từ 2012-07-04 (nửa năm cuối 2012), nên tổng 2012 không đại diện. Dùng 2013–2022 = 9 năm đầy đủ.

VI.2. Chart 1: Revenue Trend (Descriptive)

Khái Niệm: Dual Axis

Dual Axis đặt 2 measure trên 2 trục Y. Bật: right-click measure thứ 2 → **Dual Axis**. **Synchronize** khi cùng đơn vị. KHÔNG Synchronize khi khác đơn vị (sessions vs bounce_rate).

Loại: Dual-axis Line. **Build:**

1. New Worksheet → rename `viz_D1_01_revenue_trend`
2. Kéo `date` vào Columns → **Month (continuous, xanh lá)**. KHÔNG chọn discrete
3. Kéo `revenue` vào Rows → line mỏng
4. Kéo `revenue_ma30` vào Rows → right-click → **Dual Axis**
5. Right-click trục phải → **Synchronize Axis**
6. Line `revenue`: color `#2E86AB55` (nhạt), width 1
7. Line `revenue_ma30`: color `#1F3A5F` (navy đậm), width 2
8. Reference Line: right-click trục 1 → Add Reference Line → Average, color `#5D6D7E` dashed

Insight mẫu: "Revenue trung bình giảm dần qua 10 năm, CAGR khoảng −3.8%/năm."

Lưu ý

`yoy_growth_pct` null 365 ngày đầu (2012-07-04 → 2013-07-03). Nếu overlay YoY, giai đoạn đầu trống. Workaround: filter `date` ≥ `2013-07-04`.

VI.3. Chart 2: Gross Margin Trend (Diagnostic)

Loại: Area Chart + Trend Line. **Build:**

1. New Worksheet → rename `viz_D1_02_margin_trend`
2. Kéo `date` vào Columns (Month continuous)
3. Kéo `gross_margin_pct` vào Rows (AVG)
4. Marks card: chuyển sang **Area**
5. Color: `#6BBF59` solid green. Area fill opacity: 20%
6. Analytics pane → kéo **Trend Line** → Linear, color `#5D6D7E` dashed

Insight mẫu: "Gross Margin giảm từ ~22% xuống ~14%. Nguyên nhân: cạnh tranh giá hoặc COGS tăng nhanh hơn revenue."

VI.4. Chart 3: MoM Growth Heatmap (Predictive)

Loại: Highlight Table (Calendar Heatmap). Data: `agg_monthly_summary`.

Lưu ý

`year_month` là String "YYYY-MM". Không thể dùng Part → Year/Month trực tiếp. Tách thành 2 field.

Build:

1. New Worksheet → rename `viz_D1_03_mom_heatmap`
2. Tạo calc: `MoM Year` = `LEFT([year_month], 4)` (String, discrete)
3. Tạo calc: `MoM Month Num` = `INT(MID([year_month], 6, 2))` (Integer, discrete)
4. `MoM Year` vào Columns, `MoM Month Num` vào Rows (sort ascending)
5. `mom_growth_pct` vào Color (AVG). Marks: **Square**
6. Color: Diverging: Red `#A8312C` ← White `#F4F4F4` → Green `#2F855A`
7. Label: `mom_growth_pct`, format `0%`

Insight mẫu: "Q1 mỗi năm có growth âm so với Q4, mùa vụ rõ. Dự kiến Q1/2023 tiếp tục pattern."

Lưu ý

`mom_growth_pct` của 2012-07 = NULL (không có tháng trước). Ô (Jul, 2012) sẽ trống.

VI.5. Chart 4: Category Revenue Contribution (Prescriptive)

Loại: 100% Stacked Bar. Data: `fact_orders_enriched`.

1. Kéo `order_year` vào Columns (discrete)
2. Kéo `line_revenue` vào Rows (SUM)
3. Right-click → Quick Table Calculation → Percent of Total
4. Right-click → **Edit Table Calculation** → Compute Using: chọn `category` (KHÔNG để Table)
5. Kéo `category` vào Color. Marks → Bar. Label: `0.0%`

Tại sao Compute Using `category`?

Compute Using `category` = tính % trong phạm vi mỗi year → tổng 4 category = 100% mỗi năm. Nếu chọn Table (default), % tính trên toàn 11 năm, mất ý nghĩa market share.

Lưu ý

Kiểm chứng nhanh: Hover qua 1 bar → tổng tất cả segment phải đúng **100.0%** cho mỗi năm. Nếu ra khác, Compute Using đang sai.

Insight mẫu: "Nếu category doanh thu cao nhất đồng thời margin thấp nhất, đề xuất pivot mix: giảm tỷ trọng đó, tăng đầu tư category margin cao."

VI.6. Ghép Dashboard 1

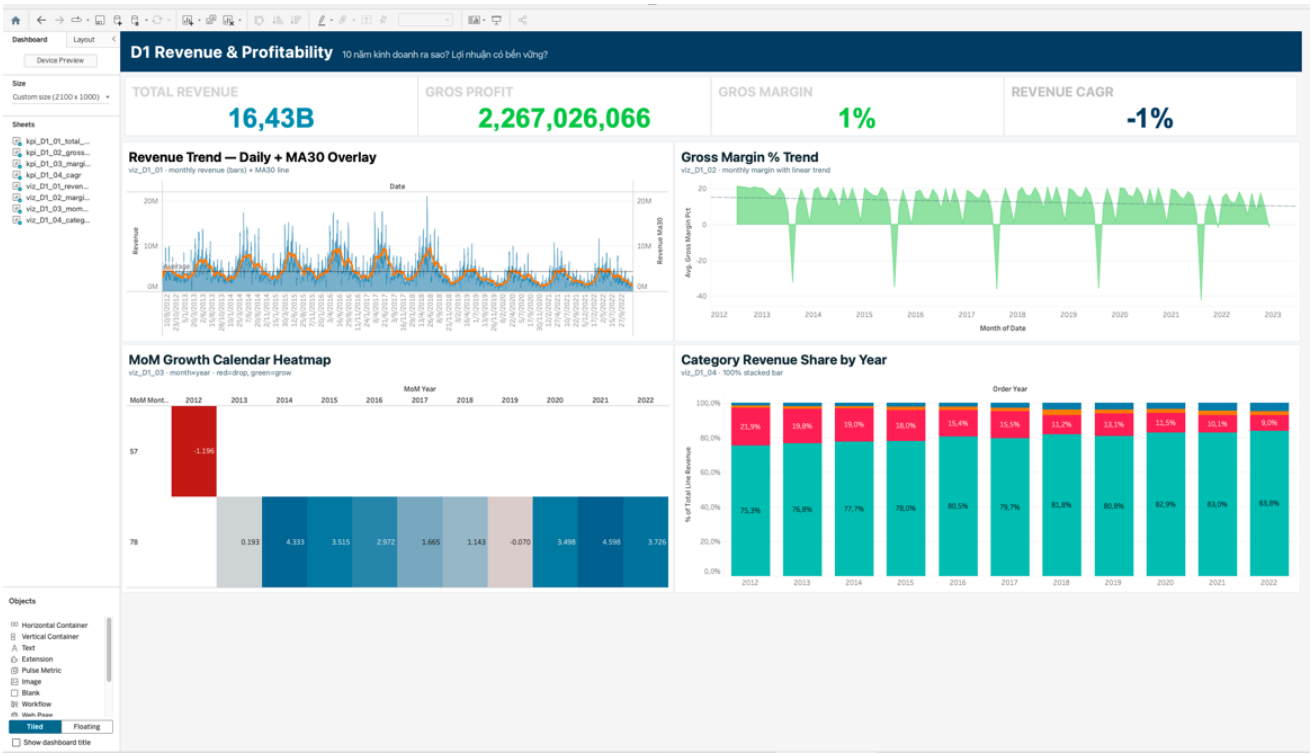

Hình 7: Wireframe layout Dashboard 1: Revenue & Profitability: Fixed 2100 × 1000.

Các bước ghép:

1. Dashboard → New Dashboard → Size Fixed 2100×1000
2. Kéo Horizontal container: Banner h=72, bg `#1F3A5F`, text 22pt white
3. Kéo Horizontal container: Filter bar h=44, chứa filter `flt_G_year` (multi-select dropdown)
4. Kéo Horizontal container: KPI strip h=120 → kéo 4 KPI worksheet, width 25% mỗi card
5. Kéo Vertical container → 2 Horizontal rows:
   - Row 1: `viz_D1_01` (w=1040) + `viz_D1_02` (w=1040)
   - Row 2: `viz_D1_03` (w=1040) + `viz_D1_04` (w=1040)
6. Text object footer ở đáy

VII. Dashboard D2 Customer Segmentation & Lifecycle

Dashboard D2 tập trung giải quyết bài toán: *"Ai là khách hàng giá trị? Ai đang rời đi?"*. Phần này hướng dẫn xây dựng hệ thống phân tích dựa trên phương pháp RFM (Recency, Frequency, Monetary) và ma trận Cohort Retention để theo dõi vòng đời khách hàng.

VII.1. Tổ chức & Chuẩn bị Dữ liệu

VII.1.1. Các file CSV cần thiết

Việc phân tích khách hàng đòi hỏi sự kết hợp giữa thông tin định danh và lịch sử giao dịch đã được làm giàu (enriched):

File	Vai trò trong dashboard
`dim_customers_rfm.csv`	Nguồn chính: Chứa `rfm_segment`, `R/F/M_score`, `monetary` (LTV).
`agg_cohort_retention.csv`	Dùng cho ma trận giữ chân khách hàng (Retention Matrix).
`orders.csv`	Thông tin về `order_date` để tính toán các chỉ số về thời gian.
`geography.csv`	Cung cấp thông tin `region`, `city` để filter theo địa lý.

VII.1.2. Kết nối dữ liệu trong Tableau

1. Mở Tableau → **Connect** → chọn `dim_customers_rfm.csv` làm bảng trung tâm.
2. Kết nối (Relationship) với `geography.csv` qua trường `zip` để hỗ trợ filter vùng miền.
3. Sử dụng `agg_cohort_retention.csv` làm **Data Source riêng biệt** để tránh làm nhiễu grain dữ liệu của bảng RFM.

Lưu ý

Grain của dữ liệu khách hàng: Bảng `dim_customers_rfm` có grain là **1 dòng = 1 khách hàng**. Khi tính toán các chỉ số như Total Customers, cần sử dụng `COUNTD([customer_id])` hoặc `COUNT([customer_id])` để đảm bảo tính chính xác.

VII.1.3. Các cột quan trọng trong Dashboard 2

Cột	Kiểu	Dùng cho
`rfm_segment`	String	Phân lớp khách hàng (Champions, Lost,...).
`recency_days`	Float	Số ngày kể từ lần mua cuối.
`monetary`	Float	Tổng giá trị mua sắm trọn đời (LTV).
`signup_date`	Date	Thời điểm khách hàng đăng ký hệ thống.
`active_status`	Integer	Flag xác định khách hàng còn hoạt động hay không.

VII.2. Xây dựng dashboard

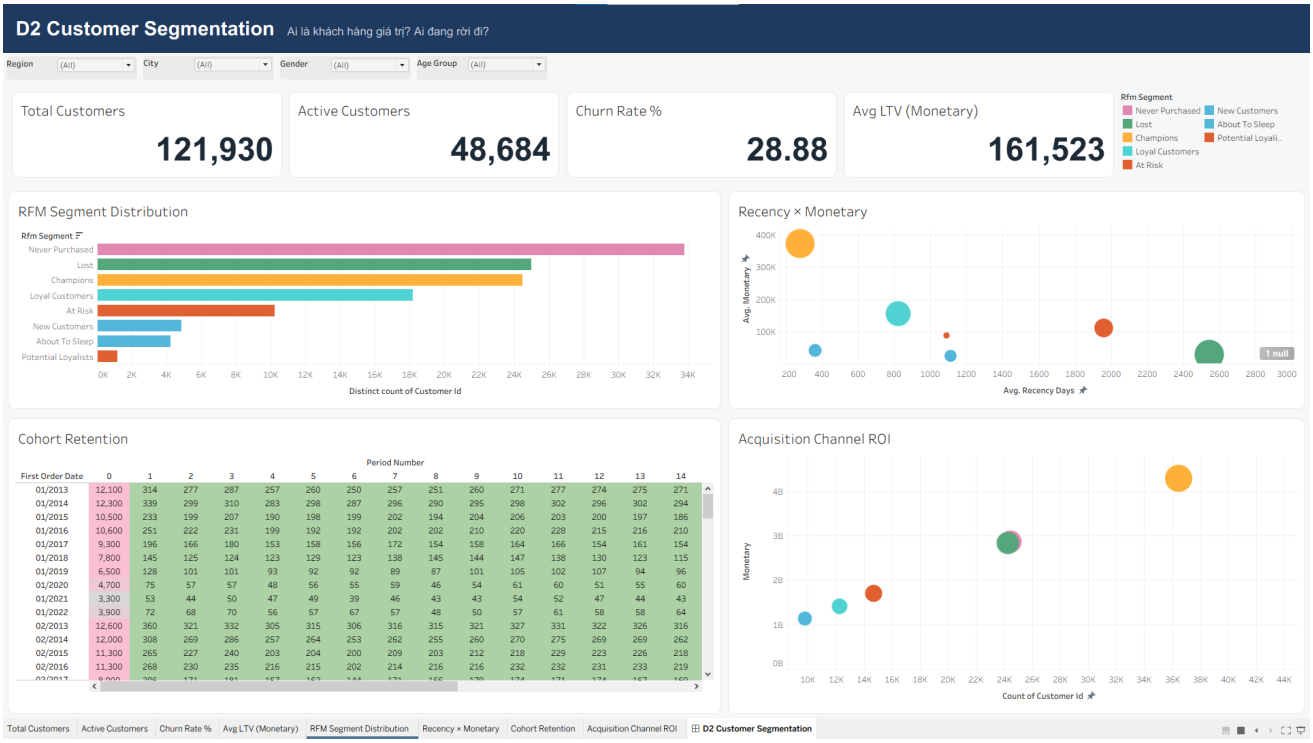

Hình 8: Dashboard D2: Customer Segmentation & Lifecycle

VII.2.1. Calculated Fields cho 4 KPI Cards

```
// [Total Customers]
COUNTD([customer\_id]) // Expected ~121.9K

// [Active Customers]
// Khach hang thuoc nhom: Champions, Loyal, Potential Loyalists, New
   Customers
```

```
SUM(
  IF [rfm\_segment] IN ("Champions", "Loyal Customers", "New Customers",
   "Potential Loyalists")
  THEN 1 ELSE 0 END
)

// [Churn Rate %]
// Khach hang thuoc nhom: Lost, At Risk
SUM(
  IF [rfm\_segment] IN ("Lost", "At Risk")
  THEN 1 ELSE 0 END
)
/ COUNTD([customer\_id])

// [Avg LTV]
// Gia tri mua hang trung binh loai tru nhom Never Purchased
AVG(
  IIF([rfm\_segment] != "Never Purchased", [monetary], NULL)
)
```

VII.2.2. Calculated Fields cho 4 Visualization

Viz D2_01 - RFM Segment Distribution (Descriptive)

Cấu hình chart: **Horizontal Bar**, Rows = `[rfm_segment]`, Columns = `COUNT([customer_id])`, Color = `[rfm_segment]`.

Sắp xếp (Sort): Giảm dần theo số lượng khách hàng để thấy rõ các nhóm chiếm tỷ trọng lớn như *Never Purchased* (27.7%) và *Lost* (20.5%).

Viz D2_02 - Recency vs Monetary Scatter (Diagnostic)

```
// X-Axis: AVG([recency_days])
// Y-Axis: AVG([monetary])
// Detail: [rfm_segment]
// Size:   COUNT([customer_id])
```

Cấu hình chart: **Scatter Plot**. Lưu ý right-click trục Recency → chọn **Reversed** để khách hàng mua gần đây (Recency thấp) nằm bên phải, đúng với logic của ma trận RFM chuẩn.

Viz D2_03 - Cohort Retention Heatmap (Predictive)

Sử dụng bảng `agg_cohort_retention`.

- Columns: `Month Since First Order` (0 đến 24).
- Rows: `Cohort Month` (tháng khách hàng bắt đầu mua).
- Label & Color: `Retention Rate %`.

Sử dụng dải màu *Sequential* (ví dụ: Teal hoặc Navy) để làm nổi bật các điểm rơi (drop-off) của khách hàng theo thời gian.

Viz D2_04 - Acquisition Channel ROI (Prescriptive)

```
// [Avg LTV per Channel]
SUM([monetary]) / COUNTD([customer_id])

// [Total Revenue per Channel]
SUM([monetary])
```

Cấu hình chart: **Bubble Chart** hoặc **Scatter**.

X-axis = Số lượng khách hàng (`Volume`) Y-axis = `Avg LTV` Size = `Total Revenue`

Chart này giúp CEO xác định kênh nào mang về khách hàng "chất lượng" (LTV cao) thay vì chỉ nhìn vào số lượng (Volume).

VII.3. Chiến lược ghi điểm cho Dashboard 2

Insight từ dữ liệu thực tế

Dữ liệu cho thấy tỷ lệ khách hàng không hoạt động (Never Purchased + Lost) lên tới gần **48%**.
Thay vì tập trung tìm khách hàng mới, hãy đề xuất chiến dịch *"Win-back"* cho nhóm *At Risk* và *"Activation"* cho nhóm *Never Purchased* để tối ưu hóa chi phí vận hành.

Với D1 và D2, chúng ta đã nắm vững quy trình: chuẩn bị data source, tạo calculated field, build chart, ghép dashboard. Giờ chúng ta sẽ nhảy sang **D4 (Marketing)** vì dashboard này minh hoạ thêm 2 kỹ thuật quan trọng: **Data Blending** (dùng web_traffic làm secondary source) và **LOD Expression nâng cao**. D3 (Product) và D5 (Operations) sẽ có gợi ý build ở Section sau.

VIII. Dashboard D4 Marketing & Channel Effectiveness

Dashboard D4 trả lời câu hỏi: *"Kênh nào ROI tốt nhất? Promo có hiệu quả không? Traffic chuyển hoá ra sao?"* Chúng ta sẽ đi qua từng bước: chuẩn bị dữ liệu, tạo calculated field, và build 4 visualization chính.

VIII.1. Tổ chức & Chuẩn bị Dữ liệu

VIII.1.1. Các file CSV cần thiết

Trước khi vào Tableau, cần xác định rõ vai trò của từng file trong bộ dữ liệu được cung cấp:

File	Vai trò trong dashboard
`orders.csv`	Nguồn chính: `order_source`, `device_type`, `payment_method`
`order_items.csv`	Doanh thu từng dòng, `promo_id` để xác định đơn có khuyến mãi
`payments.csv`	`payment_value` để tính AOV
`web_traffic.csv`	Sessions + bounce_rate theo `traffic_source`
`products.csv`	Tên category (Casual, GenZ, Outdoor, Streetwear)
`promotions.csv`	Chi tiết promo (`discount_value`, `promo_type`)
`geography.csv`	Mapping `zip` → `region` cho filter vùng

VIII.1.2. Kết nối dữ liệu trong Tableau

1. Mở Tableau → **Connect to Data** → **Text File** → chọn `orders.csv` làm bảng chính.
2. Kéo `order_items.csv` vào canvas, dùng **Relationship** (Tableau 2020.2+) liên kết qua `order_id`.
3. Kéo tiếp `payments.csv` liên kết qua `order_id` (quan hệ 1:1).
4. Kéo `products.csv` liên kết `product_id` (với `order_items`) để lấy `category`.
5. Kéo `promotions.csv` liên kết `promo_id` để lấy `discount_value`, `promo_type`.
6. Kéo `geography.csv` liên kết `zip` (với `orders`) để lấy `region`.
7. `web_traffic.csv` nên đặt làm **secondary data source** riêng, blended với primary qua `date = order_date` cho viz D4_03.

Lưu ý

Relationship vs Join: Với Tableau 2020.2+, nên ưu tiên **Relationship** thay vì Join cổ điển. Relationship giữ granularity của từng bảng riêng biệt, tránh inflate dữ liệu khi join nhiều bảng có cardinality khác nhau (ví dụ: `orders` 1:N `order_items`). Nếu dùng Join thông thường, `payment_value` sẽ bị nhân lên nhiều lần theo số dòng trong `order_items`.

VIII.1.3. Các cột quan trọng sau khi join

Cột	Kiểu	Dùng cho
`order_date`	Date	Trục thời gian
`order_source`	String	Phân tách kênh marketing
`device_type`	String	Filter thiết bị
`payment_method`	String	Filter thanh toán
`region`	String	Filter vùng
`payment_value`	Float	Tính AOV, Revenue
`promo_id`	String (nullable)	Xác định đơn có promo
`discount_value`	Float	Avg discount %
`category`	String	Phân tách danh mục
`order_id`	Int	`COUNTD` → Total Orders

VIII.2. Xây dựng dashboard

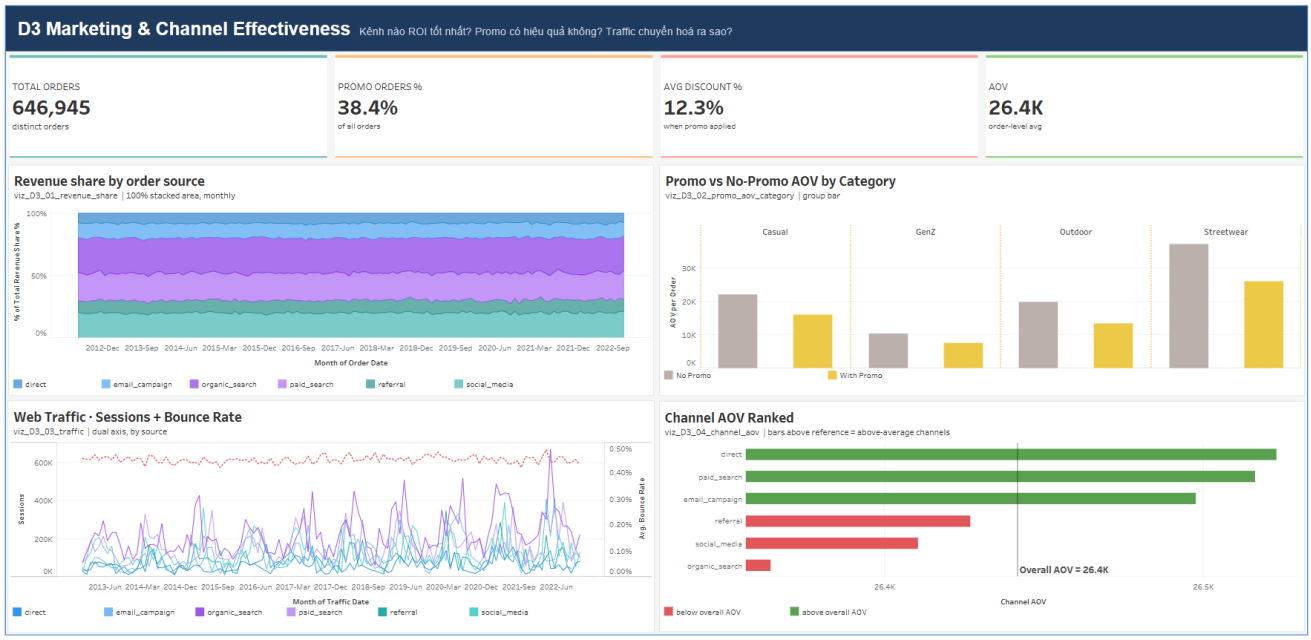

Hình 9: Dashboard D4: Marketing & Channel Effectiveness

VIII.2.1. Calculated Fields cho 4 KPI Cards

```
// [Total Orders]
COUNTD([order_id])

// [Promo Orders %]
COUNTD(IF [has_promo] = 1 THEN [order_id] END)
/ COUNTD([order_id])
// Format: Percentage, 1 decimal --> expected ~38.4%

// [Avg Discount %]
AVG(IF [has_promo] = 1 THEN [discount_value] END)
// Chi tinh tren don co promo --> expected ~12.1%

// [AOV]
SUM([payment_value]) / COUNTD([order_id])
// Format: #,##0.0K --> expected ~24.2K
```

VIII.2.2. Calculated Fields cho 4 Visualization

Viz D4_01: Revenue Share by Order Source (Descriptive)

```
// Dung Quick Table Calculation --> Percent of Total
SUM([payment_value])
// Partitioning: [order_source]
// Addressing:   MONTH([order_date])
```

Cấu hình chart: **100% Stacked Area**, Columns = `MONTH(order_date)` (continuous), Rows = `SUM(payment_value)` (với Percent of Total Table Calc), Color = `[order_source]`. Legend hiển thị 6 kênh: *direct, email_campaign, organic_search, paid_search, referral, social_media.*

Viz D4_02: Promo vs No-Promo AOV by Category (Diagnostic)

```
// [Promo Label]
IF [has_promo] = 1 THEN "With Promo" ELSE "No Promo" END

// [AOV per Order] -- tu dong aggregate khi dua vao view
SUM([payment_value]) / COUNTD([order_id])
```

Cấu hình chart: **Grouped Bar**, Columns = `[category]`, Rows = `[AOV per Order]`, Color = `[Promo Label]`.

Viz D4_03: Web Traffic: Sessions + Bounce Rate (Predictive, Dual Axis)

Dùng `web_traffic.csv` làm data source riêng, blended với primary qua `date`.

```
// Truc trai:  SUM([sessions])
// Truc phai:  AVG([bounce_rate]) * 100    --> hien thi %
// Color by [traffic_source]
// Bounce Rate line dung net dut (Dashed), mau do
```

Cấu hình: **Dual-Axis Combo Chart**. Kéo `SUM(sessions)` vào Rows đầu tiên, rồi kéo `AVG(bounce_rate)` vào Rows lần thứ 2. Right-click trục phải → **Dual Axis**. **Quan trọng:** right-click trục → **Synchronize Axis = OFF** (hai scale khác nhau hoàn toàn).

Viz D4_04: Channel AOV Ranked (Prescriptive)

```
// [Overall AOV] -- Fixed LOD (khong bi anh huong boi dimension [
   order_source])
{ FIXED : SUM([payment_value]) / COUNTD([order_id]) }

// [Channel AOV] -- aggregate theo kenh
SUM([payment_value]) / COUNTD([order_id])

// [Above Average Flag]
[Channel AOV] >= [Overall AOV]
```

Cấu hình chart: **Horizontal Bar**, Rows = `[order_source]` (sorted descending by `[Channel AOV]`), Columns = `[Channel AOV]`, Color = `[Above Average Flag]`. Thêm **Reference Line** tại `[Overall AOV]` (Analytics pane → drag *Reference Line* vào trục X, Value = Overall AOV).

IX. Gợi mở: Dashboard tiếp theo

Sau khi hoàn thành Dashboard 1, 2 và 4, chúng ta đã nắm vững quy trình. Hai dashboard còn lại (D3 và D5) follow cùng pattern.

IX.1. Dashboard D3: Product Analysis

Câu hỏi: "Chiến lược sản phẩm nào hiệu quả? Tại sao hàng bị trả?". D3 đi sâu vào khía cạnh Product: phân tích lợi nhuận theo danh mục, chất lượng sản phẩm qua reviews, và nguyên nhân trả hàng.

Chart	Loại	Cấp	Gợi ý
Category Contribution	Pie/Donut Chart	Descriptive	Tỷ trọng từng danh mục
Return Rate Hotspot	Highlight Table	Diagnostic	Phân tích return rate theo kích cỡ & danh mục
Review Sentiment	Line Chart	Predictive	Đề xuất hành động từ biểu đồ xu hướng đánh giá
Top & Bottom Products	Bar Chart	Prescriptive	Xếp hạng sản phẩm để đẩy mạnh hoặc loại bỏ

IX.2. Dashboard 5: Operations & Supply Chain

Câu hỏi: "Giao hàng, tồn kho có vấn đề?": Data: `fact_inventory` + `fact_shipments_enriched`.

Chart	Loại	Cấp	Gợi ý
Inventory Health	Stacked Bar	Descriptive	3 states: Stockout/Overstock/Healthy
Delivery by Region	Stacked Bar (horizontal)	Diagnostic	processing_days + delivery_days cùng trục
Delivery Bucket	Bar	Predictive	Manual sort: 1–2 → 3–5 → 6–7
Stockout Impact	Scatter	Prescriptive	X = stockout_days, Y = sell_through_rate, Trend line

Insight mục tiêu: "Stockout chiếm 67% snapshots. Top-seller bị stockout nhiều nhất. Đề xuất tăng safety stock top 20 SKUs."

IX.3. Story: CEO Narrative (6 Story Points)

Sau khi build đủ 5 dashboards, tạo Story ghép thành bản trình bày:

SP	Caption (có con số)	DB
1	Revenue suy giảm: CAGR −3.8%/năm, margin co từ ∼22% xuống ∼14%	D1
2	48% KH đã mất hoặc chưa mua (27.7% Never + 20.5% Lost)	D2
3	Return rate 3.4% tập trung vào hotspot size × category	D3
4	38% đơn có promo, discount ∼12%: AOV kênh chênh lệch rõ	D4
5	Stockout 67% snapshots, fill rate vẫn 0.96	D5
6	5 đề xuất hành động cho CEO	Text

X. Phân tích

Phần này áp dụng framework **Descriptive → Diagnostic → Predictive → Prescriptive** cho 3 dashboard đã build chi tiết: D1, D2, D4. Mỗi dashboard được phân tích độc lập, sau đó kết nối lại thành một câu chuyện kinh doanh thống nhất.

X.1. Dashboard D1 Revenue & Profitability Overview

Câu hỏi trung tâm: "10 năm kinh doanh ra sao? Lợi nhuận có bền vững?"

X.1.1. Descriptive: Bức tranh tổng thể 10 năm

Dashboard trình bày 4 KPI tổng quan: **Total Revenue**, **Gross Profit**, **Gross Margin %** và **Revenue CAGR**. Điểm đáng chú ý đầu tiên là Revenue CAGR **âm**, cho thấy tổng doanh thu không tăng trưởng mà có xu hướng *suy giảm kép* qua giai đoạn 9 năm. Đây là tín hiệu cần được đặt ở vị trí trung tâm của mọi phân tích tiếp theo.

Biểu đồ `viz_D1_01` (Revenue Trend: Daily + MA30 Overlay) cho thấy doanh thu hàng tháng có **biên độ dao động lớn**, với các đỉnh cao xuất hiện lặp lại theo chu kỳ năm. Đường MA30 (moving average) giúp làm mượt pattern mùa vụ, qua đó lộ ra xu hướng dài hạn: **các đỉnh cao nhất rơi vào giai đoạn giữa (2016–2017), sau đó suy giảm dần đến 2022**. Nói cách khác, doanh nghiệp đã qua "peak" cách đây vài năm và đang ở pha đi xuống của vòng đời kinh doanh.

X.1.2. Diagnostic: Tại sao lợi nhuận mong manh?

Biểu đồ `viz_D1_02` (Gross Margin % Trend) tiết lộ một điểm bất thường quan trọng: margin trung bình dao động quanh vùng dương thấp, nhưng **xuất hiện các đợt tụt sâu xuống vùng âm mạnh**. Những đợt âm này không phải ngoại lệ đơn lẻ: chúng rải đều qua các năm với tần suất đáng kể. Điều này đặt ra hai giả thuyết:

- **Giả thuyết 1:** Các đợt khuyến mãi lớn (flash sale, clearance) khiến giá bán thấp hơn COGS trên nhiều đơn hàng, kéo margin cục bộ xuống âm.
- **Giả thuyết 2:** Chi phí hoàn hàng (refund) cao trong một số tháng làm revenue net bị âm cục bộ.

Biểu đồ `viz_D1_03` (MoM Growth Calendar Heatmap) củng cố pattern mùa vụ rất rõ: tháng **March mỗi năm đều có growth rất cao** (màu xanh đậm lặp lại qua hầu hết các năm). Ngược lại, các tháng **Jul–Sep đa số có growth âm** (màu đỏ phủ gần như toàn bộ hàng ngang ba tháng này). Đây là pattern "high season: low season" ổn định qua năm, có thể khai thác để lập kế hoạch ngân sách và inventory.

X.1.3. Predictive: Hướng đi của 2023–2024

Từ xu hướng CAGR âm và pattern mùa vụ rõ nét, có thể dự báo:

- Nếu không có can thiệp, tổng doanh thu năm tiếp theo **tiếp tục giảm** theo nhịp suy thoái đã thiết lập.
- **Mùa hè** vẫn sẽ là những tháng cao điểm: nên được ưu tiên về ngân sách và chuẩn bị vận hành.
- Biểu đồ `viz_D1_04` (Category Revenue Share by Year) cho thấy **Streetwear chiếm tỷ trọng áp đảo** và ổn định qua các năm, trong khi Casual, GenZ, Outdoor chỉ chiếm phần nhỏ. **Dependency vào một category duy nhất** là rủi ro tập trung cần được nhìn nhận.

X.1.4. Prescriptive: 3 hướng hành động

1. **Kiểm soát margin các đợt khuyến mãi:** Đặt floor price ràng buộc theo COGS để tránh các đợt tụt margin xuống vùng âm. Vấn đề không nằm ở việc có khuyến mãi hay không, mà ở chỗ khuyến mãi đang được áp dụng không có giới hạn dưới về giá.
2. **Khai thác mùa cao điểm March:** Dồn ngân sách marketing và chuẩn bị inventory vào February–March (trước mùa cao điểm) thay vì phân bổ đều cả năm. Đây là "window of opportunity" được dữ liệu lặp lại xác nhận.
3. **Đa dạng hoá category:** Giảm dần sự phụ thuộc vào Streetwear bằng cách đầu tư mở rộng SKU và marketing riêng cho Casual, GenZ, Outdoor. Rủi ro tập trung không chỉ đến từ thị trường mà còn từ chính cấu trúc sản phẩm.

X.2. Dashboard D2: Customer Segmentation & Lifecycle

Câu hỏi trung tâm: "Ai là khách hàng giá trị? Ai đang rời đi?"

X.2.1. Descriptive: Chân dung tập khách hàng

Dashboard trình bày 4 KPI: **Total Customers**, **Active Customers**, **Churn Rate** và **Avg LTV (Monetary)**. Điểm đáng chú ý là tỷ lệ Active chỉ chiếm một phần nhỏ hơn nửa tổng số khách đã đăng ký: phần còn lại thuộc về các segment không còn hoạt động hoặc chưa bao giờ mua. Churn Rate (Lost + At Risk) ở mức **đáng lo ngại cho một doanh nghiệp e-commerce trưởng thành**.

Biểu đồ `viz_D2_01` (RFM Segment Distribution) cho thấy phân bố khách hàng rất **mất cân bằng**: nhóm **Never Purchased** chiếm tỷ trọng lớn nhất: tức là một lượng lớn khách đã đăng

ký tài khoản **nhưng chưa từng chuyển đổi** thành giao dịch thực. Nhóm **Champions** và **Lost** có quy mô tương đương nhau: nghĩa là cứ có một khách đẳng cấp nhất thì cũng có khoảng một khách đã bỏ đi. Các segment trung gian (Potential Loyalists, About To Sleep, New Customers) chiếm tỷ trọng nhỏ hơn nhiều, cho thấy **phễu chuyển đổi giữa các tầng không mượt**: khách hoặc là ở lại hẳn (Champions/Loyal), hoặc rơi thẳng xuống Lost mà không qua các tầng đệm.

X.2.2. Diagnostic: Tại sao khách rời đi?

Biểu đồ `viz_D2_02` (Recency × Monetary Scatter) cho thấy mối quan hệ rõ ràng giữa thời gian mua gần nhất và giá trị đơn hàng:

- **Champions** (bubble lớn nhất, góc phải trên): Recency rất gần, Monetary cao nhất: segment đẳng cấp nhất cần được ưu tiên giữ.
- **Loyal Customers** và **Potential Loyalists**: Recency trung bình, Monetary trung bình: nhóm có tiềm năng nâng cấp lên Champions nếu được kích hoạt đúng.
- **At Risk** và **About To Sleep**: Recency khá xa, Monetary không còn cao: đây là nhóm cần can thiệp *ngay* trước khi chuyển sang Lost.
- **Lost**: Recency rất xa, Monetary thấp: chi phí reactivate cao hơn chi phí acquisition mới, không nên ưu tiên.

Biểu đồ `viz_D2_03` (Cohort Retention Heatmap) tiết lộ pattern retention **rất đáng lo**:

- Retention rơi **mạnh ngay từ tháng +1** sau first order: đa số khách không quay lại trong tháng đầu tiên.
- Từ tháng +2 trở đi, retention **ổn định ở mức thấp** và gần như không phục hồi.
- Đây là pattern **"one-and-done customer"** điển hình của e-commerce chưa có chương trình retention bài bản: khách mua một lần rồi biến mất, không có email nurture, không có loyalty program hoạt động.

X.2.3. Predictive: Rủi ro churn tương lai

Từ pattern retention thấp và Churn Rate cao, có thể dự báo:

- Một phần đáng kể khách thuộc **At Risk** sẽ chuyển thành Lost trong 6–12 tháng tới nếu không can thiệp.
- Segment **About To Sleep** là "At Risk tương lai": cần được đặt trong vòng theo dõi trước khi quá muộn.
- Nhóm **Never Purchased** là pool lớn nhưng *chi phí activate thấp hơn nhiều* so với acquire khách mới: đây là nguồn tăng trưởng đang bị bỏ ngỏ.

X.2.4. Prescriptive: Hành động theo segment

Biểu đồ `viz_D2_04` (Acquisition Channel ROI) cho thấy các kênh acquisition khác nhau mang về khách có giá trị LTV khác nhau. Nhìn tổng thể, **organic_search** và **social_media** có bubble lớn nhất (volume cao) với LTV trung bình cạnh tranh: đây là các kênh có khả năng scale. Ngược lại, một số kênh có LTV cao hơn nhưng volume nhỏ (referral, paid_search), cho thấy cơ hội để mở rộng có chọn lọc.

1. **Champions:** VIP program, early access sản phẩm mới, exclusive discount: mục tiêu là *nâng LTV*, không phải tăng tần suất.
2. **At Risk:** Win-back campaign với discount + free shipping: mục tiêu là *ngăn rơi xuống Lost*, chấp nhận biên lợi nhuận thấp hơn trong giao dịch reactivate.
3. **Never Purchased:** Welcome sequence 3-email (Day 1 chào mừng, Day 3 gợi ý sản phẩm, Day 7 first-purchase discount): mục tiêu là *activate first transaction*, kích hoạt pool khách đang nằm yên.
4. **Ưu tiên kênh acquisition:** Đẩy mạnh các kênh đã chứng minh có volume + LTV tốt (organic_search, social_media). Giảm dần đầu tư vào kênh có bubble nhỏ và LTV không vượt trội.

X.3. Dashboard D4: Marketing & Channel Effectiveness

Câu hỏi trung tâm: "Kênh nào ROI tốt nhất? Promo có hiệu quả không? Traffic chuyển hoá ra sao?"

X.3.1. Descriptive: Cấu trúc hoạt động marketing

Dashboard trình bày 4 KPI quan trọng: **Total Orders**, **Promo Orders %**, **Avg Discount %** và **AOV**. Điểm đáng chú ý là gần *hai phần năm* tổng số đơn hàng đều có ít nhất một chương trình khuyến mãi: một tỷ lệ khá cao, cho thấy doanh nghiệp đang phụ thuộc đáng kể vào công cụ giá để thúc đẩy giao dịch. Mức chiết khấu trung bình khi có promo cũng không nhỏ, làm cho câu hỏi "promo có thực sự mang lại giá trị tương xứng không" trở thành trọng tâm của toàn dashboard.

Biểu đồ `viz_D4_01` (Revenue Share by Order Source: 100% Stacked Area) cho thấy cơ cấu doanh thu theo kênh **tương đối ổn định suốt 10 năm**. **organic_search** (xanh dương) chiếm tỷ trọng lớn nhất và duy trì vai trò xương sống, tiếp theo là **paid_search** và **social_media**. Các kênh còn lại (direct, email_campaign, referral) đóng góp phần nhỏ hơn nhưng ổn định. Điều này cho thấy thương hiệu đã xây dựng được nền tảng nhận diện tự nhiên vững chắc, **không phụ thuộc quá mức vào quảng cáo trả phí đơn lẻ**: một cấu trúc kênh đáng mong muốn về mặt rủi ro.

X.3.2. Diagnostic: Hiệu quả khuyến mãi theo danh mục

Biểu đồ `viz_D4_02` (Promo vs No-Promo AOV by Category) tiết lộ một kết quả **đáng chú ý và phản trực giác**: AOV của đơn hàng có promo **đều thấp hơn** so với đơn không promo ở *tất*

cả 4 danh mục. Đây không phải hiện tượng riêng của một category mà là pattern lan toả toàn hệ thống.

Danh mục **Streetwear có mức chênh lệch tuyệt đối lớn nhất**: do bản thân AOV của Streetwear đã cao hơn nhiều so với các category khác, nên mỗi đơn có promo mất đi một khoản giá trị đáng kể. Ba category còn lại (Casual, GenZ, Outdoor) có AOV thấp hơn nhưng *tỷ lệ giảm tương đối cũng không nhỏ*.

Giải thích 1 (tiêu cực): Khuyến mãi đang "ăn mòn" giá trị đơn hàng của những khách vốn đã có ý định mua: họ chỉ chờ có promo để mua rẻ hơn, không tăng volume mua.

Giải thích 2 (tích cực): Promo thu hút thêm nhóm khách mới có giỏ hàng nhỏ hơn (price-sensitive segment): nhóm này kéo AOV trung bình xuống nhưng tăng tổng số đơn, nên tổng doanh thu vẫn tăng.

Để phân biệt, cần phân tích thêm: **promo có tăng số đơn/khách không?** và **những khách mua có promo có quay lại mua tiếp không?** Đây là hướng mở rộng cần thực hiện ở bước phân tích tiếp theo.

X.3.3. Predictive: Tín hiệu từ lưu lượng truy cập

Biểu đồ `viz_D4_03` (Web Traffic: Sessions + Bounce Rate, dual-axis) cho thấy hai pattern song song:

- **Sessions có xu hướng tăng theo thời gian**, đặc biệt mạnh trong giai đoạn gần cuối (khoảng 2021). Điều này trùng với giai đoạn COVID-19 và xu hướng mua sắm online bùng nổ: có thể là hiệu ứng thị trường chứ không hoàn toàn đến từ nỗ lực marketing.
- **Bounce rate dao động ở vùng rất thấp** và tương đối đồng đều giữa các kênh: cho thấy chất lượng landing page **không phải là nút thắt**.
- Tín hiệu tích cực: traffic tăng nhưng engagement không giảm: khi ngân sách tăng, conversion không bị kéo xuống. **Đây là điều kiện lý tưởng để scale ngân sách marketing** mà không lo overspend.

X.3.4. Prescriptive: Xếp hạng kênh và hành động

Biểu đồ `viz_D4_04` (Channel AOV Ranked) với reference line tại AOV trung bình chia 6 kênh thành 2 nhóm rõ rệt:

- **Trên trung bình (xanh lá: above-average):** direct, paid_search, email_campaign: 3 kênh có AOV vượt ngưỡng trung bình.
- **Dưới trung bình (đỏ: below-average):** referral, organic_search, social_media: 3 kênh có AOV thấp hơn ngưỡng trung bình.

Khi đối chiếu D4_01 và D4_04, pattern rõ ràng hiện ra: `organic_search` và `social_media` chiếm tỷ trọng **doanh thu lớn nhất** nhưng **AOV thấp nhất**. Nghĩa là: 2 kênh này mang lại nhiều đơn nhưng mỗi đơn có giá trị nhỏ. Ngược lại, `email_campaign` có AOV cao nhưng volume chưa lớn. Đây chính là **đòn bẩy tái phân bổ ngân sách** mà doanh nghiệp đang chưa khai thác.

XI. Tổng kết

Bài hướng dẫn đã trình bày từ **15 file CSV thô** đến **5 dashboard Tableau hoàn chỉnh** kèm theo khung phân tích kinh doanh có chiều sâu. Quy trình có thể gói gọn trong bốn bước then chốt:

1. **Hiểu đề & rubric trước khi đi vào data:** Phần 2 chiếm 60/100 điểm, trong đó "Chiều sâu phân tích" là tiêu chí nặng nhất. Mỗi biểu đồ nên đi đủ 4 cấp **Descriptive** → **Diagnostic** → **Predictive** → **Prescriptive** để tối đa hoá điểm.
2. **Thiết kế data model trước khi build:** 15 file được phân thành 3 lớp (Master, Transaction, Analytical + Operational). Hiểu rõ grain và cardinality giúp tránh những lỗi tính toán bị "inflate" khi join nhiều bảng.
3. **Python tiền xử lý:** 14 bước trong `prepare_tableau_data.py` sinh ra bộ 13 file đã enrich (RFM, cohort, moving averages, margin, delivery buckets). Tableau chỉ còn lo phần trực quan hoá.
4. **Mỗi dashboard kể một câu chuyện có đề xuất hành động:** D1 Revenue, D2 Customer, D3 Product, D4 Marketing, D5 Operations ghép lại thành Story 6 Story Points cho CEO với các con số cụ thể.

Năm phát hiện kinh doanh nổi bật từ quá trình phân tích:

- Revenue CAGR **âm** (khoảng -3.8%/năm), margin co từ $\sim$22% xuống $\sim$14%: doanh nghiệp đã qua đỉnh.
- Gần **48% khách hàng** không hoạt động (Never Purchased + Lost); retention rơi mạnh ngay từ tháng +1: thiếu chương trình giữ chân.
- Promo áp dụng cho $\sim$38% đơn nhưng làm **AOV giảm đều qua mọi category**: cần kiểm soát floor price.
- **Streetwear** chi phối doanh thu nhưng rủi ro tập trung cao: cần đa dạng hoá category.
- `organic_search` + `social_media` có volume lớn nhưng AOV thấp; `email_campaign` có AOV cao nhưng volume nhỏ: **cơ hội tái phân bổ ngân sách** chưa được khai thác.

C. XÂY DỰNG MÔ HÌNH DỰ ĐOÁN

XII. Giới thiệu

Trong cuộc thi VinDatathon 2026 Round 1, tác vụ tập trung với một bộ dữ liệu thương mại điện tử 11 năm và ba nhiệm vụ kế tiếp nhau. Phần 1 là trắc nghiệm, Phần 2 là Visualization & Analysis, và Phần 3 là phân tích và huấn luyện mô hình **Sales Forecasting**. Yêu cầu của bài toán: từ dữ liệu doanh thu hàng ngày đến hết 2022, hãy dự báo **Revenue** và **COGS** cho 548 ngày kế tiếp (01/01/2023 đến 01/07/2024).

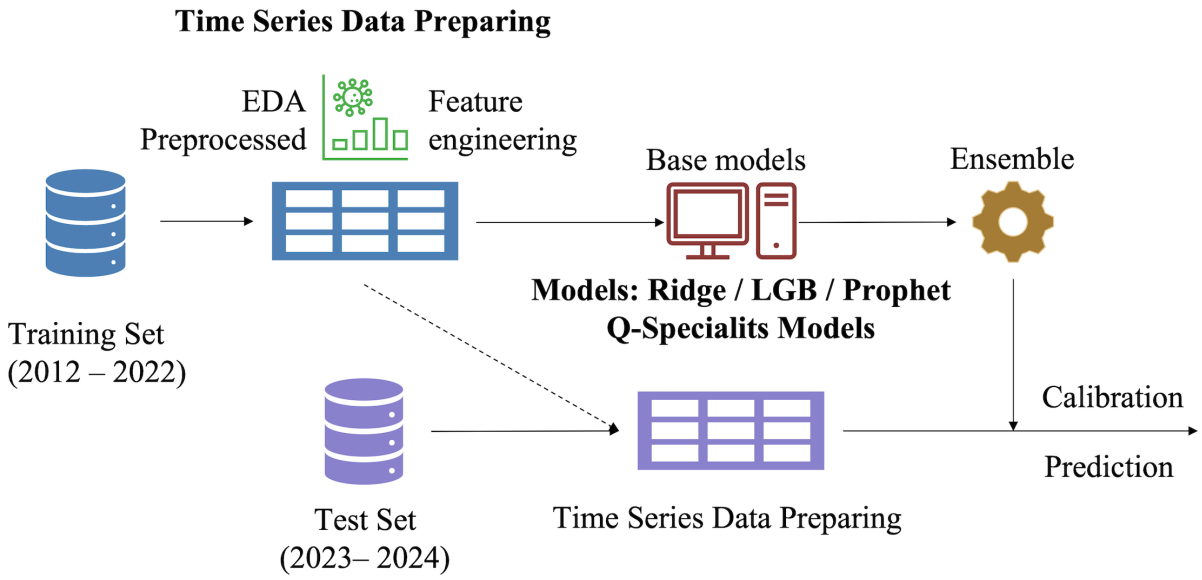

Hình 10: Tổng quan pipeline forecasting.

Quan hệ giữa Phần 2 và Phần 3

Phần 2 yêu cầu *hiểu dữ liệu đã xảy ra trong quá khứ*: trend, segmentation, cohort retention, hiệu quả kênh. Các biểu đồ Revenue, Gross Margin, Category Contribution đã được trình bày chi tiết trong tài liệu **"Datathon 2026: Dashboard Tableau từ A đến Z"**. Phần 3, yêu cầu *dự đoán điều sẽ xảy ra*: từ các pattern đã quan sát, xây mô hình extrapolate sang tương lai. Tài liệu này sẽ sử dụng kế thừa các insight từ Phần 2 nhưng tập trung vào khía cạnh *xây dựng mô hình* (modelling).

Phương pháp tiếp cận theo hướng: Phân tích dữ liệu, kết hợp kỹ thuật Feature Engineering dựa trên calendar, ba mô hình cơ bản học song song (Ridge, LightGBM, Prophet), bốn mô hình chuyên biệt theo quý, và một tầng calibration tune.

XIII. Phát biểu bài toán

XIII.1. Input và Output

Dữ liệu chính từ file `sales.csv` với ba cột `Date`, `Revenue`, `COGS`, phủ liên tục từ ngày 01/01/2012 đến 31/12/2022. Ngoài ra còn mười hai bảng phụ (promotions, inventory, returns, customers, web_traffic, ...) đã được khai thác chi tiết trong Phần 2. Lưu ý rằng *tất cả các bảng phụ trợ đều dừng ở năm 2022*, nên chúng chỉ có thể được dùng để rút ra *pattern có thể lặp lại* (ví dụ: lịch khuyến mãi) chứ không thể dùng trực tiếp như feature cho giai đoạn test.

Mục tiêu huấn luyện mô hình dự đoán tương lai, với output một file `submission.csv` gồm 548 dòng, mỗi dòng mang một `Date` trong khoảng 2023-01-01 đến 2024-07-01 và hai giá trị dự báo `Revenue`, `COGS`.

XIII.2. Hàm mục tiêu

Hàm chấm điểm của cuộc thi là MAE (Mean Absolute Error), RMSE và R2 và được tổng hợp trên cả hai biến Revenue và COGS.

Một số đặc trưng nhận thấy rằng *một số đặc điểm cùng xuất hiện*. Thứ nhất, **horizon dài 18 tháng** vượt xa khả năng extrapolate của các mô hình tuyến tính đơn giản hay mô hình neural time-series có dự đoán ngắn hạn. Thứ hai, **regime drift** rất mạnh: phân phối giai đoạn sau 2020 khác xa phân phối 2012–2018 cả về mean lẫn variance. Thứ ba, **không có ground truth feedback**: ta không biết sai ở ngày nào nên phải suy luận gián tiếp. Thứ tư, **calibration bias** tồn tại ở hầu hết mô hình học sâu trên log-space: chúng có xu hướng dự đoán thấp hơn thực tế vì hàm loss pull prediction về mean.

Chú ý forecasting horizon dài

Khi horizon quá dài, **feature lag** (ví dụ y_{t-1}, y_{t-7}) không còn truy cập được: ta không biết Revenue hôm qua của 548 ngày tương lai. Phương án duy nhất ổn định là dùng *feature calendar thuần* mọi đặc trưng đều tính được từ ngày tháng, không phụ thuộc vào lịch sử.

XIV. Phân tích dữ liệu

Trước khi quyết định mô hình, chúng ta cần hình dung rõ dữ liệu đang nói lên điều gì: bắt đầu từ bức tranh tổng thể (regime và mùa vụ dài hạn), các pattern lịch biểu chi tiết hơn (Tết, day-of-week, chu kỳ năm), và tính phân phối cùng mối liên hệ giữa hai biến mục tiêu.

Liên hệ với Phần 2 (Visualization & Analysis)

Phần 2 cũng thực hiện khám phá dữ liệu, nhưng tập trung vào việc trình bày các phát hiện kinh doanh cho CEO. Ở Mục **phân tích** cuối Phần 2 có ba kết luận đã được viết ra: *(a)* Revenue CAGR âm và doanh thu đã qua peak giai đoạn 2016–2017, *(b)* tháng March mỗi năm đều có growth cao nhất và Jul–Sep đa số growth âm, *(c)* margin xuất hiện các đợt tụt sâu xuống vùng âm. Ba kết luận này chính là *ba giả định xuất phát* cho Phần 3: chúng củng cố nhu cầu về sample weighting, về Fourier seasonality, và về mô hình chuyên biệt cho quý biến động. Trong Mục này chúng ta định lượng lại ba giả định đó qua biểu đồ, để suy ra các quyết định kỹ thuật cụ thể.

XIV.1. Bức tranh tổng thể: Biểu đồ qua các năm

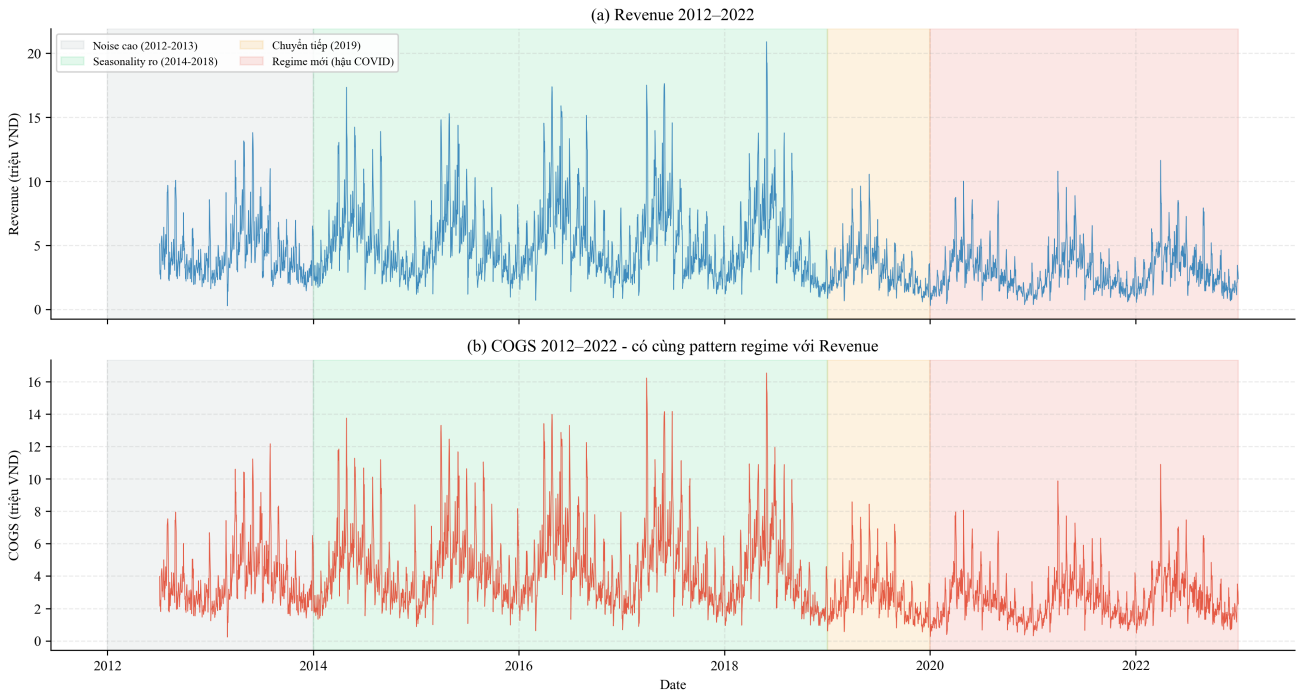

Hình 11: Timeline Revenue và COGS 2012–2022.

Câu hỏi đầu tiên cần trả lời là: *dữ liệu có đồng nhất theo thời gian hay không?* Đây là câu hỏi then chốt vì nó quyết định chúng ta có thể coi toàn bộ 11 năm như một khối duy nhất, hay phải tách nhỏ và xử lý riêng. Để trả lời, chúng ta nhìn vào Hình 11.

Chuỗi không đồng nhất. Bốn vùng được đánh dấu có những *tính chất* rất khác nhau chứ không chỉ khác về con số. Giai đoạn 2012–2013 có noise trùm lên tín hiệu, mô hình học từ đây sẽ dễ bị phân tán. Giai đoạn 2014–2018 là *vùng peak* với biên độ doanh thu lớn nhất ($\sim$ 0 đến 20 triệu/ngày) và seasonality định hình rõ ràng đây là vùng dữ liệu không lỗi lý tưởng để mô hình học pattern. Năm 2019 là bước nhảy giảm đột ngột. Giai đoạn 2020 - 2022 chuyển sang một regime mới với *mức doanh thu thấp hơn* $\sim 40\%$ so với 2014 - 2018 và biên độ thu hẹp ($\sim$ 0 đến 10 triệu/ngày). Điều này khớp với kết luận từ Phần 2 về CAGR âm.

Từ quan sát này, hai ý tưởng thiết kế phù hợp. Thứ nhất, khi huấn luyện nên *ưu tiên vùng có seasonality rõ nhất* (2014–2018) bằng trọng số mẫu, để mô hình tập trung học *hình dạng* (shape) của các pattern. Thứ hai, vì vùng học có level khác hẳn vùng test, prediction sẽ bị lệch về phía của vùng học vì vậy cần một cơ chế *điều chỉnh mức* (calibration) tách rời để khớp lại với mức thực tế của test. Hai ý tưởng này sẽ được thực thi trong Mục XVII. và Mục XVIII..

XIV.2. Cấu trúc thời gian: Tính mùa vụ có bền vững không?

Giả sử ta đã chấp nhận rằng level thay đổi theo chế độ; câu hỏi tiếp theo là: *shape mùa vụ có thay đổi theo không, hay vẫn giữ ổn định?* Nếu shape ổn định, chiến lược học shape ở vùng sạch rồi rescale là khả thi; nếu shape cũng biến đổi, chiến lược đó sụp đổ. Hình 12 giúp ta trả lời.

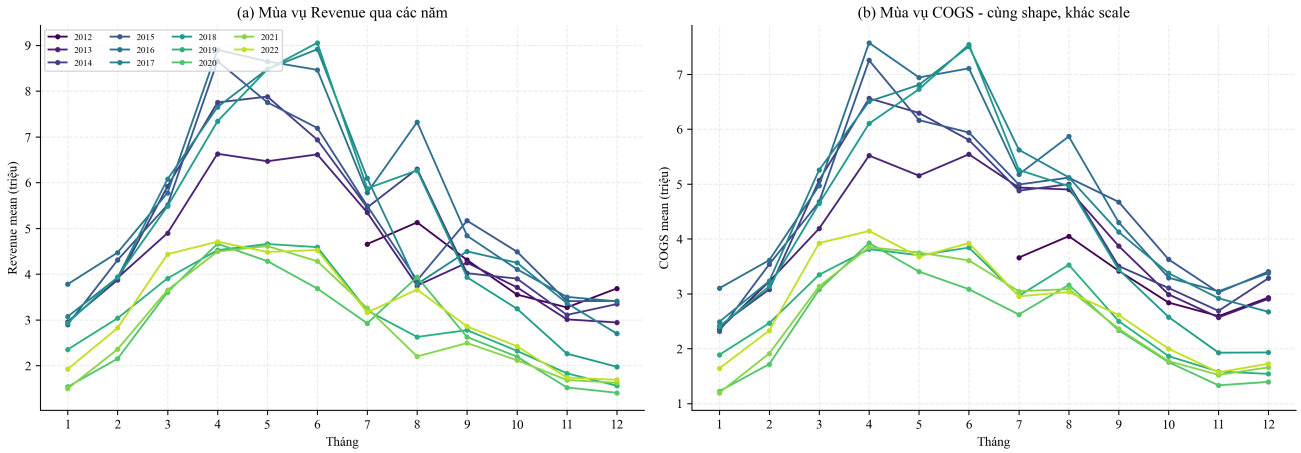

Hình 12: Doanh thu trung bình tháng qua các năm. Hình dạng đường cong lặp lại rất ổn định giữa các năm: sụt Q1 vì Tết, Q2 và Q4 là đỉnh năm. Sự khác biệt giữa các năm chủ yếu nằm ở *level* (mức trung bình), còn *shape* gần như bất biến.

Câu trả lời là *có ổn định*. Tất cả các đường cong đều có cùng một dáng: đi xuống ở tháng 1 - 2, bật lên ở tháng 3 - 4, plateau giữa năm, và bung cao ở Q4. Đây là một trong những quan sát quan trọng nhất cho toàn bộ pipeline vì nó xác nhận giả thuyết "**mùa vụ bền vững, level thay đổi**". Chúng ta có thể dùng Fourier features để mô hình hoá seasonality (Mục XV.).

XIV.3. Các pattern lịch biểu chi tiết

Sau khi đã nắm bức tranh tổng quát, chúng ta phân tích các pattern nhỏ hơn. Có ba pattern xem xét lần lượt: hiệu ứng Tết, pattern theo thứ/ngày-trong-tháng, và chu kỳ năm chẵn/lẻ. Mỗi pattern sẽ dẫn đến một nhóm feature cụ thể trong hàm `build_features()`.

(a) Hiệu ứng Tết Âm lịch

Tết là sự kiện lớn nhất trong năm về mặt hành vi tiêu dùng. Câu hỏi thực tế cần trả lời là: *ảnh hưởng của Tết kéo dài bao lâu, và có đối xứng trước/sau không?*

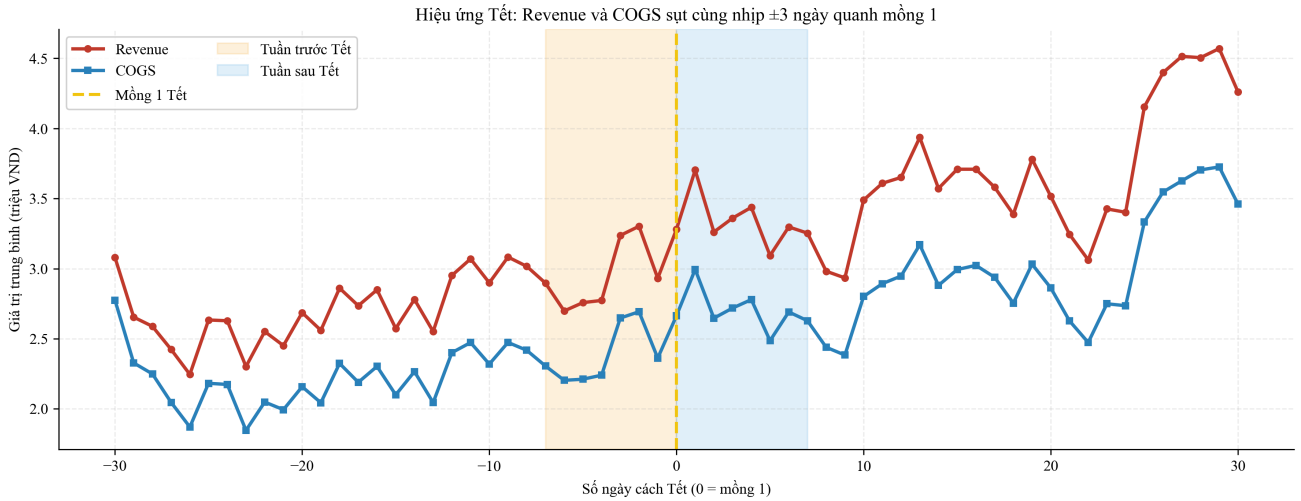

Hình 13: Hiệu ứng Tết Âm lịch, tổng hợp từ mười năm 2013–2022. Trục hoành là số ngày cách mồng 1 Tết, trục tung là doanh thu trung bình. Sụt sâu nhất nằm ở khoảng ±3 ngày quanh mồng 1, hồi phục sau khoảng một tuần.

Hình 13 cho thấy pattern Tết. Trước Tết $\sim$ 30 ngày, doanh thu thấp ($\sim$ 2.5–3.0 triệu); càng gần mồng 1, doanh thu *tăng dần* chứ không sụt đỉnh nhỏ ngay quanh mồng 1 ($\sim$ 3.5–3.7 triệu). Sau Tết khoảng 20 ngày, doanh thu mới thực sự bứt lên ($\sim$ 4–4.5 triệu). Revenue và COGS đi cùng nhịp. Đặc điểm quan trọng là Tết rơi vào các ngày dương lịch khác nhau mỗi năm (từ 21/01 đến 19/02), nên feature cố định theo tháng không bắt được. Giải pháp là dùng feature *khoảng cách tới Tết gần nhất*. Đó là biến `tet_days_diff` mã hoá chính xác đặc điểm này và áp dụng được cho cả 2023 (Tết 22/01) lẫn 2024 (Tết 10/02).

(b) Day-of-week và Day-of-month

Tiếp theo, chúng ta hỏi: *doanh thu có phụ thuộc vào thứ trong tuần hay vị trí trong tháng không?* Hai pattern này nhỏ hơn nhưng vẫn có ý nghĩa cho mô hình gốc cây.

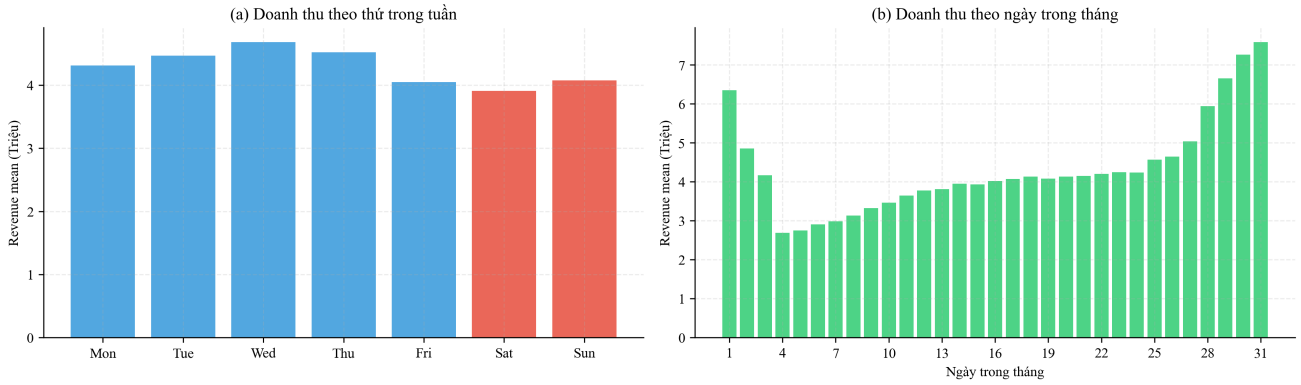

Hình 14: (a) Doanh thu theo thứ trong tuần khá đồng đều, không có hiệu ứng weekend mạnh điển hình của B2C. (b) Doanh thu theo ngày trong tháng có spike rõ ở đầu tháng và giữa tháng, gợi ý pattern lương hoặc thói quen mua sắm đầu kỳ.

Hai đặc điểm cần chú ý. Thứ nhất, doanh nghiệp này có hiệu ứng *weekend ngược* vì weekday (Mon-Fri $\sim$ 4.0–4.7 triệu) cao hơn weekend (Sat-Sun $\sim$ 3.9–4.1 triệu), khác với retail B2C thông thường. Thứ hai, pattern *day-of-month rất mạnh* (bảng bên phải): ngày 28–31 cuối tháng cao gấp đôi ngày giữa tháng (đỉnh $\sim$ 7.5 triệu vào ngày 31), ngày 1–3 cũng cao ($\sim$ 5–6 triệu). Vùng giữa tháng (ngày 4–20) là plateau thấp $\sim$ 3–4 triệu. Quan sát "cuối tháng quan trọng hơn đầu tháng" dẫn đến nhóm feature `is_last1`, `is_last2`, `is_last3` và `days_to_eom`, song song với nhóm `is_first1..3` cho đầu tháng.

(c) Chu kỳ năm chẵn / năm lẻ

Kiểm tra bảng `promotions.csv` cho thấy có hai chiến dịch chỉ xuất hiện ở năm lẻ: Urban Blowout (cuối tháng 7) và Rural Special (cuối tháng 1). Điều này dẫn đến câu hỏi: *hai nhóm năm chẵn / lẻ có thực sự khác nhau trong dữ liệu không?*

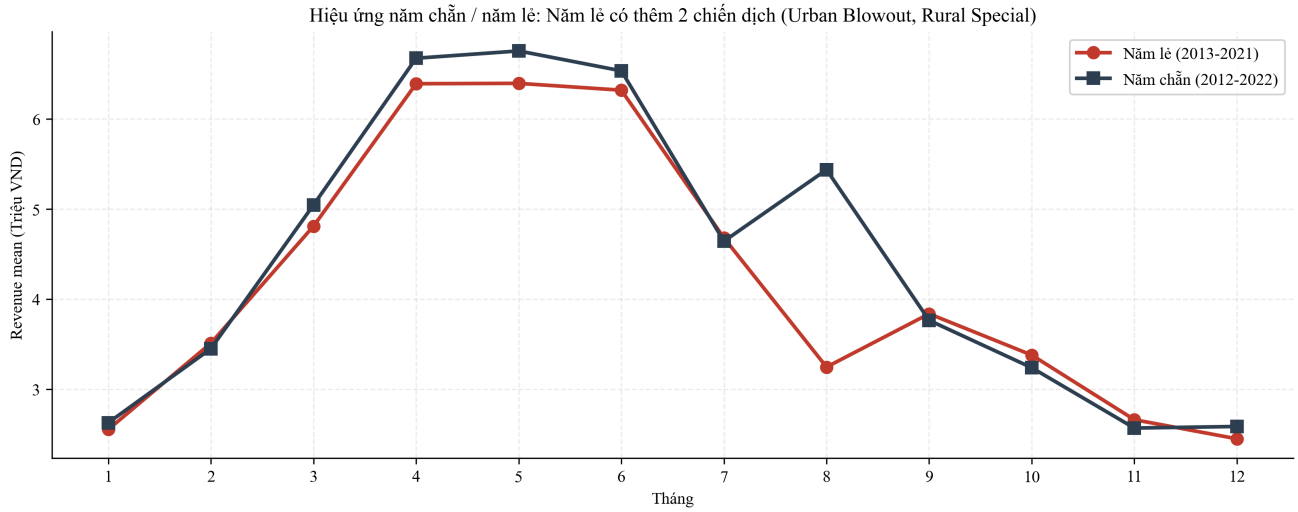

Hình 15: Doanh thu trung bình tháng, tách theo năm chẵn và năm lẻ. Năm lẻ có bump nhỏ nhưng nhất quán ở tháng 1 (Rural Special) và tháng 7–8 (Urban Blowout).

Khác biệt rõ nhất nằm ở *tháng 8*: năm chẵn có doanh thu cao đột biến ($\sim$ 5.4 triệu) trong khi năm lẻ chỉ ($\sim$ 3.3 triệu) chênh gần 1.6×. Các tháng còn lại gần như trùng nhau. Pattern này nhất quán qua các năm, không phải nhiễu ngẫu nhiên. Vì test gồm 2023 (năm lẻ) và 2024 (năm chẵn), một feature binary `is_odd_year` cho phép mô hình chuyển đổi giữa hai pattern trong từng năm của giai đoạn test.

XIV.4. Phân phối và mối liên hệ giữa hai biến mục tiêu

Hai phân tích cuối cùng liên quan đến cấu trúc phân phối của biến mục tiêu. Chúng ta cần biết: *phân phối Revenue có tách biệt giữa các era không*, và *mối liên hệ Revenue–COGS có đặc điểm gì đáng chú ý cho việc dự báo*?

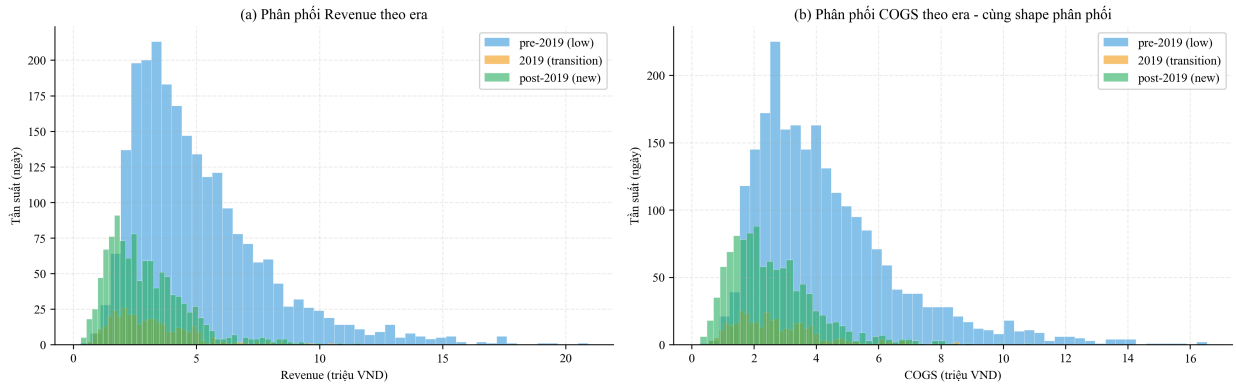

Hình 16: Histogram Revenue chia theo ba era. Ba phân phối gần như không chồng lấp, củng cố nhu cầu về một cơ chế điều chỉnh mức giữa giai đoạn học và giai đoạn dự báo.

Hình 16 cho thấy ba phân phối tách biệt rõ ràng. Hệ quả định lượng là nếu trainer để mọi mẫu có cùng trọng số, mô hình sẽ thoả hiệp ở một mức trung bình không thuộc về phân phối nào cụ thể prediction trên 2023 (thuộc phân phối xanh lá) sẽ bị kéo xuống thấp. Đây chính là nguồn gốc của **calibration bias** đã đề cập ở Mục XIII., và là lý do pipeline cần một tầng calibration tách rời.

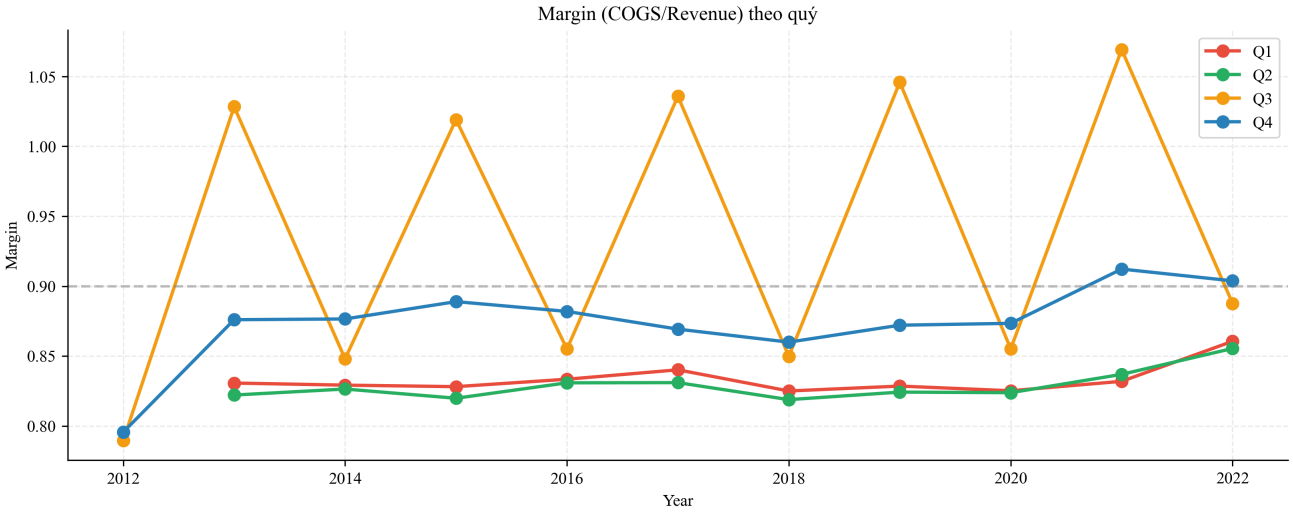

Hình 17: Margin (COGS / Revenue) theo quý qua từng năm. Q1, Q2, Q4 nằm gọn trong khoảng 0.80–0.92. Riêng Q3 dao động rất mạnh trong lịch sử từng chạm đến giá trị ngoài 1.0.

Hình 17 cho thấy một pattern rất đặc biệt: Q1, Q2, Q4 có margin ổn định trong khoảng 0.82–0.91, nhưng **Q3 dao động zig-zag rõ rệt theo chu kỳ năm chẵn/lẻ**. Năm lẻ (2013, 2015, 2017, 2019, 2021) margin Q3 vọt lên $\sim$ 1.02–1.07 (COGS vượt Revenue là bán lỗ). Năm chẵn (2014, 2016, 2018, 2020) margin Q3 trở lại bình thường $\sim$ 0.85. Pattern này gần như chắc chắn liên quan tới chiến dịch `urban_blowout` (chỉ chạy năm lẻ, vào cuối tháng 7) là một chiến dịch có vẻ hy sinh margin để đẩy volume. Một mô hình chung sẽ bị trung bình hoá và không bắt được pattern Q3-năm-lẻ này. Quan sát này trực tiếp dẫn đến hai ý tưởng: *(a)* feature `is_odd_year`, và *(b)* **mô hình chuyên biệt theo quý** (Q-specialist) sẽ xây ở Mục XVII. mỗi specialist được phép quan tâm hơn đến một quý, đặc biệt Spec_Q3 cho hiện tượng phức tạp này.

XIV.5. Scatter Revenue–COGS: cơ sở cho hướng dự báo qua tỉ số

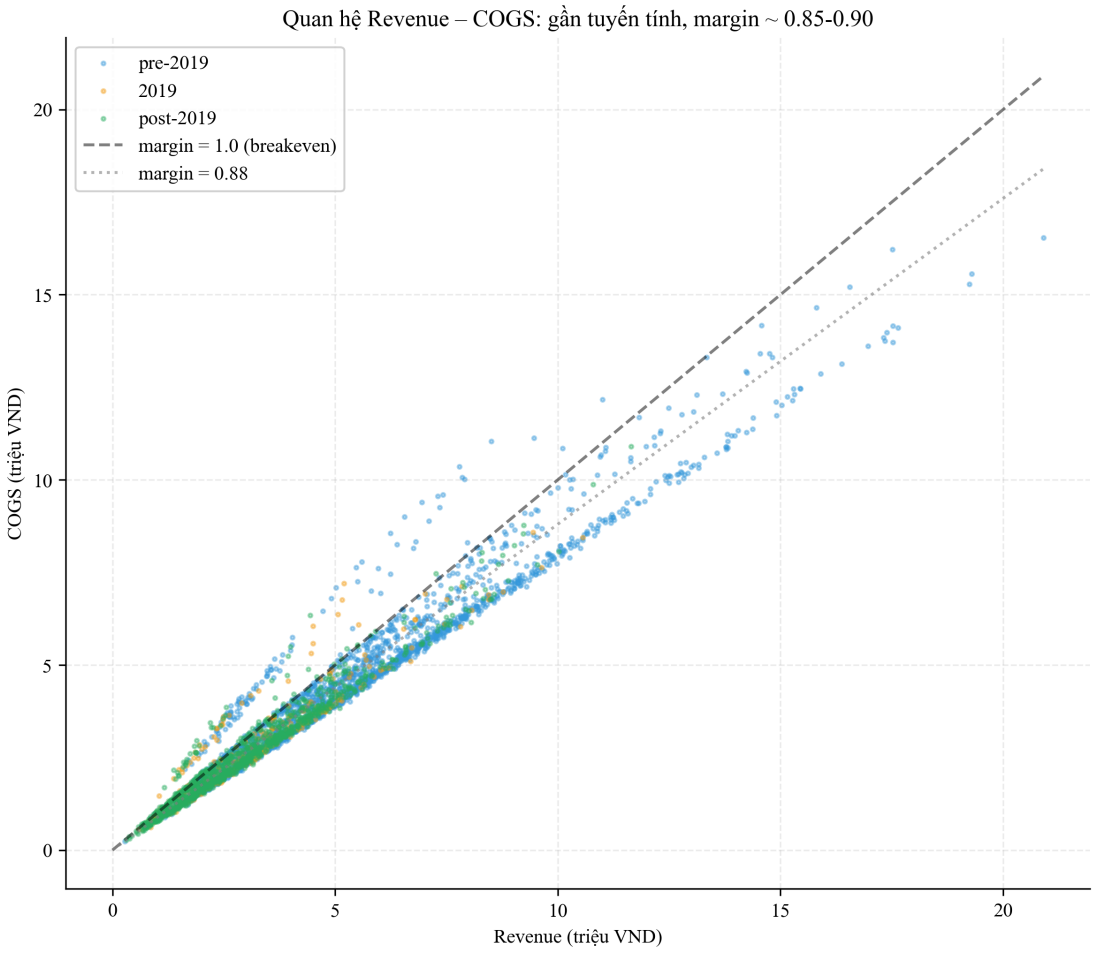

Hình 18: Scatter plot Revenue vs COGS qua ∼4000 ngày, tách màu theo era. Đường nét đứt là margin = 1.0 (breakeven), đường chấm chấm là margin = 0.88. Phần lớn điểm nằm bên dưới margin = 1.0 với độ dốc gần 0.88.

Hình 18 cho thấy hai điều quan trọng cho việc xây dựng mô hình. Thứ nhất, **COGS gần như tuyến tính theo Revenue** với hệ số góc ~ 0.85–0.90. Điều này có nghĩa: nếu ta đã có một mô hình dự báo Revenue tốt, ta có thể lấy COGS bằng $0.88 \times \hat{R}$ (margin trung bình) làm baseline, không cần model riêng. Thứ hai, các **outlier nằm phía trên đường margin** $= 1.0$ (COGS $>$ Revenue) tập trung ở vùng pre-2019 mức thấp chính là Q3 năm lẻ đã thấy ở Hình 17. Pre-2019 cũng có đuôi Revenue cao hơn nhiều (lên tới ~ 20 triệu) trong khi post-2019 chỉ tới ~ 10 triệu, củng cố lại quan sát về regime drift.

Khi thiết kế: pipeline này chọn dự báo COGS *độc lập* (M2 train trên `log(COGS)`) thay vì dự báo qua tỉ số. Lý do là Q3 năm lẻ có margin > 1.0 vi phạm giả định "margin ổn định", nên train trên ratio sẽ truyền lỗi của outlier sang prediction. Tuy nhiên, hướng *cogs_ratio* vẫn được Mục XX.4. đề cập như một hướng mở rộng tiềm năng nếu kết hợp khôn ngoan với Q-specialist.

XIV.6. Tóm tắt: từ EDA đến các quyết định mô hình

Sáu phát hiện ở trên có thể được tổng kết trong bảng sau, để thấy được sự kết nối giữa quan sát dữ liệu và quyết định thiết kế:

Quan sát	**Đặc trưng được tạo**	**Cơ chế bù đắp**
Ba regime riêng biệt	–	Sample weight + calibration
Mùa vụ ổn định qua các năm	Fourier annual $k = 1..5$	–
Hiệu ứng Tết & đỉnh sau Tết	`tet_days_diff`, `tet_in_7`, ...	–
EOM spike (ngày 28–31 cao nhất)	`is_last1..3`, `days_to_eom`	–
SOM spike (ngày 1–3)	`is_first1..3`, `days_from_som`	–
Năm chẵn cao đột biến tháng 8	`is_odd_year`	–
Q3 zig-zag chẵn/lẻ (urban_blowout)	–	Q-specialist + `is_odd_year`

XV. Feature Engineering

Như đã phân tích ở Mục XIII., mọi feature cần tính được từ `Date` mà không phụ thuộc dữ liệu lịch sử. Điều này loại trừ các feature lag truyền thống ($y_{t-1}, y_{t-7}, y_{t-365}$) nhưng cho phép chúng ta tính sẵn toàn bộ ma trận đặc trưng cho cả 2023 và 2024 ngay từ đầu.

Calendar-only featurization

Với *mọi* ngày t ta trích ra ba nhóm thông tin. Trước hết là **vị trí trong lịch** (năm, tháng, ngày, thứ, ngày trong năm, quý). Tiếp theo là **quan hệ với các mốc lễ**: khoảng cách tới Tết, có phải Black Friday, có trùng ngày lễ cố định nào không. Cuối cùng là **trạng thái promo**: có đang trong cửa sổ của 4 chiến dịch thường niên và 2 chiến dịch năm lẻ hay không, đã diễn ra được bao nhiêu ngày, còn bao nhiêu ngày đến kết thúc.

Mã nguồn tạo ra các đặc trưng

```
import numpy as np, pandas as pd

#  Lich khuyen mai thuong nien (trich tu bang promotions)
PROMO_SCHEDULE = [
    ('spring_sale',   3, 18, 30, 12,  True),
    ('mid_year',      6, 23, 29, 18,  True),
    ('fall_launch',   8, 30, 32, 10,  True),
    ('year_end',     11, 18, 45, 20,  True),
    ('urban_blowout', 7, 30, 33,  None, 'odd'),   # chi nam le
    ('rural_special', 1, 30, 30, 15,   'odd'),
]

#  Ngay le co dinh VN
VN_FIXED_HOLIDAYS = [
    (1,1,'new_year'), (3,8,'womens_day'), (4,30,'reunification'),
    (5,1,'labor_day'), (9,2,'national_day'), (10,20,'vn_womens_day'),
    (11,11,'dd_1111'), (12,12,'dd_1212'),
    (12,24,'christmas_eve'), (12,25,'christmas'),
]

#  Tet luu cap nhat 2013-2024
TET_DATES = TET   # dung lai tu cell EDA

def build_features(dates: pd.DatetimeIndex) -> pd.DataFrame:
    df = pd.DataFrame({'Date': dates})
    d = df['Date']

    # (a) Calendar basics
    df['year']    = d.dt.year
    df['month']   = d.dt.month
    df['day']     = d.dt.day
    df['dow']     = d.dt.dayofweek
    df['doy']     = d.dt.dayofyear
    df['quarter'] = d.dt.quarter
    df['is_weekend']    = (df['dow']>=5).astype(int)
```

```
    df['days_to_eom']   = d.dt.days_in_month - df['day']
    df['days_from_som'] = df['day'] - 1
    df['dim']           = d.dt.days_in_month

    # (b) Edge-of-month indicators
    for k in [1,2,3]:
        df[f'is_last{k}']  = (df['days_to_eom']  <= k-1).astype(int)
        df[f'is_first{k}'] = (df['days_from_som'] <= k-1).astype(int)

    # (c) Trend anchor + regime
    df['t_days']   = (d - pd.Timestamp('2020-01-01')).dt.days
    df['t_years']  = df['t_days']/365.25
    df['regime_pre2019']  = (df['year']<=2018).astype(int)
    df['regime_2019']     = (df['year']==2019).astype(int)
    df['regime_post2019'] = (df['year']>=2020).astype(int)

    # (d) Fourier (annual k=1..5, weekly, monthly)
    TAU = 2*np.pi
    for k in (1,2,3,4,5):
        df[f'sin_y{k}'] = np.sin(TAU*k*df['doy']/365.25)
        df[f'cos_y{k}'] = np.cos(TAU*k*df['doy']/365.25)
    for k in (1,2):
        df[f'sin_w{k}'] = np.sin(TAU*k*df['dow']/7.0)
        df[f'cos_w{k}'] = np.cos(TAU*k*df['dow']/7.0)
    for k in (1,2):
        df[f'sin_m{k}'] = np.sin(TAU*k*(df['day']-1)/df['dim'])
        df[f'cos_m{k}'] = np.cos(TAU*k*(df['day']-1)/df['dim'])

    # (e) VN holidays
    for (m, dd_, name) in VN_FIXED_HOLIDAYS:
        df[f'hol_{name}'] = ((df['month']==m) & (df['day']==dd_)).astype(int)

    # (f) Tet features
    tet_lut = {y: pd.Timestamp(v) for y,v in TET_DATES.items()}
    def nearest_tet_diff(dd):
        cands = [tet_lut.get(dd.year), tet_lut.get(dd.year-1), tet_lut.get(dd.year+1)]
        cands = [c for c in cands if c is not  None]
        valid = [(dd-c).days for c in cands if abs((dd-c).days)<=45]
        return min(valid) if valid else 999
    diffs = np.array([nearest_tet_diff(dd) for dd in d])
    df['tet_days_diff'] = diffs
    df['tet_in_7']      = (np.abs(diffs)<=7).astype(int)
    df['tet_in_14']     = (np.abs(diffs)<=14).astype(int)
    df['tet_before_7']  = ((diffs>=-7) & (diffs<0)).astype(int)
    df['tet_after_7']   = ((diffs>0) & (diffs<=7)).astype(int)
    df['tet_on']        = (diffs==0).astype(int)

    # (g) Black Friday (Thu 6 cuoi thang 11)
    def is_black_friday(dd):
        if dd.month != 11: return 0
        last = pd.Timestamp(year=dd.year, month=11, day=30)
        last_fri = last - pd.Timedelta(days=(last.dayofweek - 4) % 7)
        return int(dd == last_fri)
    df['hol_black_friday'] = [is_black_friday(dd) for dd in d]
```

```python

    # (h) Promo windows
    yrs = sorted( set(df['year'].tolist()))
    for (name, sm, sd, dur, disc, recur) in PROMO_SCHEDULE:
        in_prom = np.zeros( len(df), dtype=int)
        since   = np.full( len(df), -1.0)
        until   = np.full( len(df), -1.0)
        discount= np.zeros( len(df))
        for y in range(min(yrs)-1, max(yrs)+2):
            if recur=='odd' and y%2==0: continue
            start = pd.Timestamp(year=y, month=sm, day=sd)
            end   = start + pd.Timedelta(days=dur)
            mask  = (d>=start) & (d<=end)
            in_prom[mask] = 1
            since[mask]   = (d[mask]-start).dt.days
            until[mask]   = (end-d[mask]).dt.days
            discount[mask]= disc or 0
        df[f'promo_{name}']       = in_prom
        df[f'promo_{name}_since'] = since
        df[f'promo_{name}_until'] = until
        df[f'promo_{name}_disc']  = discount

    # (i) Odd-year flag
    df['is_odd_year'] = (df['year'] % 2).astype(int)

    return df

# Test
test_features = build_features(pd.date_range('2023-01-01', '2023-01-10'))
print(f'Feature columns: {test_features.shape[1]}')
test_features.head()
```

Lưu ý

Xây dựng các **đặc trưng Fourier** (sin/cos của day-of-year, day-of-week, day-of-month) đóng vai trò quan trọng đặc biệt cho mô hình tuyến tính Ridge. Giúp một mô hình tuyến tính học được pattern *lặp định kỳ* theo nhiều tần số khác nhau.

XVI. Chiến lược validation

Vì horizon test rất dài và phân phối lại khác biệt so với training, lựa chọn fold validation như sau.

XVI.1. Ba fold theo thời gian

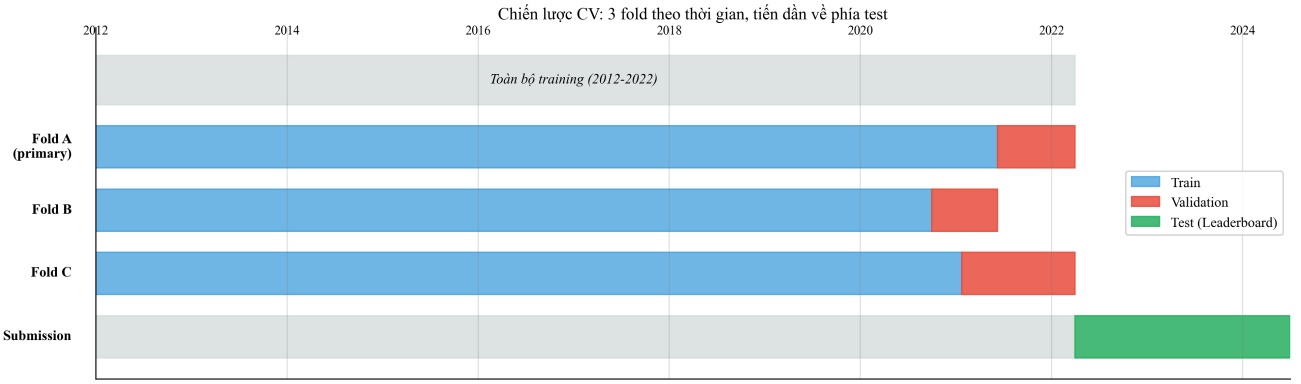

Hình 19: Chiến lược CV ba fold theo thời gian. Fold A chọn 2022 làm validation, là fold chuẩn chính vì năm 2022 có phân phối gần nhất với test 2023. Fold B (validate 2021) kiểm tra độ ổn định giữa các năm. Fold C có cửa sổ rolling 12 tháng, gần với horizon submission.

Ba fold được thiết kế với ba mục tiêu bổ sung nhau:

- **Fold A (primary).** Train $\leq$ 2021-12, validate 2022. Đây là fold có phân phối validation *gần nhất* với test; mọi quyết định ablation quan trọng nên dựa trên fold này.
- **Fold B (stability).** Train $\leq$ 2020-12, validate 2021. Fold này kiểm tra xem một cải tiến có *ổn định qua năm* hay chỉ đúng cho 2022.
- **Fold C (horizon).** Train $\leq$ 2021-06, validate 2021-07 $\rightarrow$ 2022-06. Fold này mô phỏng cửa sổ 12 tháng liên tục, gần với horizon test nhất.

XVII. Lựa chọn và huấn luyện mô hình

XVII.1. Lựa chọn mô hình như thế nào?

Phân tích lựa chọn các mô hình ensemble học máy là các mô hình cần có tính diversity. Nếu hai mô hình cùng sai một hướng thì trung bình chúng vẫn sai hướng đó, không tạo ra thông tin bổ sung. Ngược lại, nếu một mô hình sai cao và một mô hình sai thấp, trung bình triệt tiêu một phần sai số,

Chúng ta chọn ba mô hình đại diện cho **ba họ giải thuật khác biệt nhất** trong bài toán forecasting cổ điển:

- **Ridge Regression** đại diện *mô hình tuyến tính tham số*. Ridge học một hàm tuyến tính toàn cục trên không gian feature. Khi được cung cấp đủ Fourier features, Ridge có thể tái hiện dạng mùa vụ theo kiểu *tổng trọng số sin/cos nhiều tần số*. Ridge *ổn định*: train lại nhiều lần cho ra weight rất gần nhau, ít bị nhiễu bởi outlier. Nó đóng vai trò là điểm neo thành phần khó bị lệch bất thường trong ensemble.
- **LightGBM** là *mô hình cây gradient boosting*. Khác với Ridge, LGB không giả định quan hệ tuyến tính; mà học hàm dạng bậc thang (piecewise-constant) qua việc chia feature space. Ưu điểm là nắm được *tương tác* giữa các feature (ví dụ: "nếu là cuối tháng và có promo thì tăng mạnh"). LGB mạnh nhất nhưng cũng variance cao nhất giữa các seed, nên cần regularize bằng trọng số trong ensemble.
- **Prophet** là *mô hình phân rã có cấu trúc* (decomposition-based). Prophet chia chuỗi thành ba thành phần độc lập: trend (piecewise linear có changepoint), seasonality (Fourier đa tần số), và holidays. Vì cấu trúc được định trước, Prophet rất mạnh ở việc extrapolate seasonal component cho horizon dài cần cho bài toán 18 tháng.

Ngoài ra các mô hình hiện đại như neural network hay foundation model có thể bổ sung thêm diversity.

Kiểm chứng diversity bằng số

Một cách đo diversity nhanh: tính *Pearson correlation* của **vector residuals** (sai số) giữa mỗi cặp mô hình trên fold validation. Khi các cặp có correlation khoảng 0.6–0.7 (không quá cao, không quá thấp), blend đem lại cải thiện rõ. Trong thực nghiệm, ba cặp (Ridge, LGB), (Ridge, Prophet), (LGB, Prophet) đều rơi vào khoảng này.

XVII.2. M1: Ridge Regression

```
from sklearn.linear_model import Ridge

def train_ridge(X_train, y_train, alpha=3.0):
    mu    = X_train.mean(axis=0)
    sigma = X_train.std(axis=0).replace(0, 1)
```

```
    Xs    = (X_train - mu) / sigma
    model = Ridge(alpha=alpha, random_state=42)
    model.fit(Xs, y_train)
    return model, (mu, sigma)

def predict_ridge(model, X_test, stats):
    mu, sigma = stats
    return model.predict((X_test - mu) / sigma)

# Train tren log(Revenue)
y_train_log = np.log(feat["Revenue"].values)
ridge, stats = train_ridge(pd.DataFrame(X_train, columns=cols), y_train_log)
p_ridge = np.exp(predict_ridge(ridge, pd.DataFrame(X_test, columns=cols), stats))
```

Hai điểm quan trọng: (i) chuẩn hoá z-score trước khi fit vì Ridge nhạy cảm với scale, và (ii) train trên `log(Revenue)` rồi exp ngược ra ngoài, vì log-space ổn định hơn khi biên độ dao động lớn.

XVII.3. M2: LightGBM với sample weighting

Cấu hình hyperparameter được chọn khá conservative (learning rate nhỏ, leaves vừa phải, regularization nhẹ) để tránh overfit. Thêm nữa là *sample weight theo era*: chúng ta ưu tiên giai đoạn 2014–2018 khi train.

Era-based sample weighting

Đây là một kỹ thuật cổ điển nhưng rất hiệu quả cho data có regime drift: thay vì để mọi mẫu có trọng số bằng nhau trong hàm loss, ta *upweight* vùng mà model cần học pattern tốt nhất, và *downweight* vùng gây nhiễu. Hiệu ứng là mô hình tập trung học *shape* từ vùng sạch, sau đó chỉ cần một tầng điều chỉnh mức là đủ cho phân phối mới.

```
import lightgbm as lgb

LGB_PARAMS =  dict(
    objective="regression", metric="mae",
    learning_rate=0.03, num_leaves=63,
    min_data_in_leaf=30,
    feature_fraction=0.85, bagging_fraction=0.85, bagging_freq=5,
    lambda_l2=1.0, seed=42, verbosity=-1,
)

#  Sample weight: era-focused
years = feat["Date"].dt.year.values
w = np.full( len(feat), 0.01)
w[(years >= 2014) & (years <= 2018)] = 1.0   # scheme "high_era"

#  Huan luyen 2 giai doan
# (1) Early stopping tren internal holdout (180 ngay cuoi)
intern  = feat["Date"].max() - pd.Timedelta(days=180)
fit_idx = (feat["Date"] <= intern).values
```

```
ins_idx = (feat["Date"] >  intern).values

booster_es = lgb.train(
    LGB_PARAMS,
    lgb.Dataset(X_train[fit_idx], y_train_log[fit_idx], weight=w[fit_idx]),
    num_boost_round=5000,
    valid_sets=[lgb.Dataset(X_train[ins_idx], y_train_log[ins_idx])],
    callbacks=[lgb.early_stopping(300, verbose= False),
               lgb.log_evaluation(0)])

# (2) Retrain toan bo du lieu voi best_iteration
booster_final = lgb.train(
    LGB_PARAMS,
    lgb.Dataset(X_train, y_train_log, weight=w),
    num_boost_round=booster_es.best_iteration)

p_lgb = np.exp(booster_final.predict(X_test))
```

Lưu ý

Mô hình được huấn luyện hai giai đoạn. Giai đoạn 1 dùng 180 ngày cuối làm validation để xác định `best_iteration`. Giai đoạn 2 huấn luyện lại trên *toàn bộ* dữ liệu với số vòng đã chọn. Cách này giúp model tận dụng được cả 180 ngày cuối trong khi tránh overfit.

XVII.4. M3: Prophet

```
from prophet import Prophet

def fit_prophet(train_df, post_regime_only= True):
    if post_regime_only:
        train_df = train_df[train_df["ds"] >= "2020-01-01"]
    m = Prophet(
        yearly_seasonality= True, weekly_seasonality= True,
        daily_seasonality= False,
        seasonality_mode="multiplicative",
        changepoint_prior_scale=0.05)
    for col in [c for c in train_df.columns if c.startswith("promo_")]:
        m.add_regressor(col)
    m.fit(train_df)
    return m

tdf = pd.DataFrame({"ds": sales["Date"], "y": np.log(sales["Revenue"])}) \
        .merge(build_promo_regressors(sales["Date"]), on="ds")
model_p = fit_prophet(tdf, post_regime_only= True)

vdf = pd.DataFrame({"ds": test_df["Date"]}) \
        .merge(build_promo_regressors(test_df["Date"]), on="ds")
p_prophet = np.exp(model_p.predict(vdf)["yhat"].values)
```

`post_regime_only=True`: Prophet chỉ học trên dữ liệu 2020–2022. Lý do là component trend của Prophet xử lý kém với jump lớn (ví dụ bước nhảy 2019–2020): khi train trên toàn bộ lịch sử, trend đoạn cuối có thể bị bóp méo.

XVII.5. Mô hình huấn luyện theo quý

Quan sát từ Hình 17 cho thấy các quý có mức độ biến động rất khác nhau. Một mô hình chung được train với trọng số như nhau cho mọi ngày sẽ bị trung bình hoá pattern riêng của mỗi quý đặc biệt Q3 với biên độ biến động lớn nhất sẽ bị bỏ sót. Giải pháp được thiết kế ở đây là huấn luyện **bốn mô hình cụ thể theo quý** (Q-specialist), mỗi mô hình nhận thêm trọng số boost cho các ngày thuộc quý mà nó "phụ trách".

Mô hình LightGBM cho các quý

Về *kiến trúc*, bốn specialist hoàn toàn giống nhau và giống mô hình M2 ở Mục XVII..3 (cùng LightGBM, cùng 150+ feature, cùng hyperparameter). Khác biệt duy nhất nằm ở **sample weight**: mỗi specialist có một quý "trọng điểm" được nhân hệ số 2×:

Specialist	Quý trọng điểm	Pattern tập trung học
Spec_Q1	Tháng 1–3	Hiệu ứng Tết Âm lịch, sụt giảm đầu năm
Spec_Q2	Tháng 4–6	Chiến dịch mid-year sale, đỉnh giữa năm
Spec_Q3	Tháng 7–9	Quý có margin biến động nhất, cần bắt chi tiết
Spec_Q4	Tháng 10–12	Đỉnh năm (Black Friday, 11.11, 12.12, Noel)

Cơ chế sample weight

Công thức weight chung cho mỗi specialist là sự kết hợp của hai layer:

```
#  Vi du: specialist cho Q3 tren Revenue
TARGET_Q = 3       # quy trong diem
QBOOST   = 2.0     # he so boost

# Layer 1: high_era base (giong M2)
w = np.full( len(feat), 0.01)
w[(years >= 2014) & (years <= 2018)] = 1.0

# Layer 2: quarter boost - nhan 2x cho quy trong diem
Q_train = feat["Date"].dt.quarter.values
w[Q_train == TARGET_Q] *= QBOOST

# Huan luyen 2 giai doan (giong M2, chi thay weight)
y = np.log(feat["Revenue"].values)
# ...
p_spec_Q3 = np.exp(booster_final.predict(X_test))
np.save("v50_specialist_Q3_Revenue.npy", p_spec_Q3)
```

Ví dụ với Spec_Q3, ta có ba mức weight khác nhau:

- Ngày Q3 trong giai đoạn 2014–2018: weight = 2.0 (bằng 1.0×2.0)
- Ngày Q1, Q2, Q4 trong giai đoạn 2014–2018: weight = 1.0
- Các ngày ngoài giai đoạn 2014–2018: weight = 0.01 (gần như bị bỏ qua)

Kết quả là hàm loss phạt *gấp đôi* khi Spec_Q3 dự đoán sai một ngày Q3 so với dự đoán sai một ngày của quý khác. Model học tốt hơn riêng cho Q3 trong khi vẫn có ngữ cảnh của các quý còn lại.

Vì sao không train chỉ trên quý đích?

Một phương án có vẻ đơn giản hơn là *chỉ train Spec_Q3 trên những ngày Q3* (weight = 0 cho các quý khác). Chúng tôi không chọn hướng này vì hai nhược điểm:

1. **Mất ngữ cảnh xuyên quý.** Các feature trend, regime, promo mang ý nghĩa trên toàn năm. Model chỉ thấy Q3 sẽ không học được xu hướng tăng trưởng nội năm.
2. **Giảm kích thước training xuống 1/4.** Chỉ còn $\sim$ 450 ngày hiệu dụng, rất dễ overfit.

Q-boost = 2.0 là compromise: vẫn train trên toàn bộ dữ liệu để giữ ngữ cảnh, nhưng *nghiêng* loss về phía quý đích.

Vì pipeline cần dự báo hai biến khác nhau (Revenue và COGS), mỗi trong bốn vị trí Q-specialist trên thực tế là hai model được train song song

Trong sơ đồ pipeline ở Hình 10, khối "Q-Specialists 4 models" được gộp lại theo số quý cho gọn; số lượng thực tế là **4 quý** $\times$ **2 biến target** = 8 **LightGBM**.

Prediction

Một điểm trong giai đoạn dự báo: chúng ta *không trung bình* prediction của bốn specialist. Thay vào đó, với mỗi ngày của test, ta chọn specialist thuộc đúng quý của ngày đó:

```
# Ghep prediction theo quy - Khong trung binh
Q_test = test_df["Date"].dt.quarter.values
spec   = {q: np.load(f"v50_specialist_Q{q}_Revenue.npy") for q in [1,2,3,4]}

p_spec_composed = np.zeros(548)
for q in [1, 2, 3, 4]:
    mask = Q_test == q
    p_spec_composed[mask] = spec[q][mask]    # chi dung Spec_Qq cho ngay Q_q
# Vi du:
#   15/02/2023 (Q1)  -> lay gia tri tu spec[1]
#   20/08/2023 (Q3)  -> lay gia tri tu spec[3]
```

Sau bước ghép này, `p_spec_composed` là một chuỗi 548 giá trị, được kết hợp từ bốn specialist theo đúng quý của từng ngày. Đây là output sẽ đi vào Tầng 1 của ensemble ở Mục XVIII..

XVIII. Chiến lược ensemble learning

Sau khi đã có nhiều mô hình thành phần (ba mô hình nền và bốn mô hình chuyên biệt theo quý), câu hỏi tiếp theo là: *kết hợp chúng ra sao để được một dự báo cuối cùng?* Có hai hướng tiếp cận chính mà chúng ta sẽ lần lượt xem xét. Hướng đầu đơn giản và trực quan nhưng hạn chế, hướng sau phức tạp hơn nhưng tận dụng được toàn bộ cấu trúc của bài toán.

XVIII.1. Hướng 1: Ensemble đơn giản

Ý tưởng đơn giản nhất là *trung bình trọng số phẳng* trên tất cả mô hình thành phần. Mỗi mô hình được xem như một vote bình đẳng, và công thức tổng hợp chỉ là một phép cộng tuyến tính:

$$\hat{y} = w_1 \cdot \text{Ridge} + w_2 \cdot \text{LGB}_{\text{base}} + w_3 \cdot \text{Prophet} + w_4 \cdot \text{LGB}_{\text{Q-spec}},$$

với các trọng số w_i có thể chọn đều nhau (kiểu "trung bình đơn") hoặc tune qua grid search trên validation.

```
# Ensemble don gian: trung binh co trong so
w_ridge, w_lgb, w_prophet, w_spec = 0.10, 0.45, 0.10, 0.35  # tune tren CV
pred_simple = (w_ridge   * p_ridge
             + w_lgb     * p_lgb
             + w_prophet * p_prophet
             + w_spec    * p_spec_composed)   # p_spec da ghep theo quy

# Calibration thong nhat
final = 1.26 * pred_simple     # cho Revenue
```

Cách tiếp cận này có ưu điểm *rất rõ ràng và dễ giải thích*, nhưng trong thực nghiệm nó không đạt kết quả tốt nhất vì hai lý do. Thứ nhất, các mô hình thành phần có bản chất khác nhau rõ rệt: LightGBM (kể cả base và specialist) mạnh hơn đáng kể so với Ridge hay Prophet. Thứ hai, hai thành phần LGB (base và specialist) có *mối liên hệ đặc biệt* với nhau chúng cùng là gradient boosting, chỉ khác nhau ở trọng số mẫu. Đặt chúng song song bên cạnh Ridge và Prophet không tận dụng được cấu trúc này.

XVIII.2. Hướng 2: Ensemble phân tầng

Thay vì ép tất cả thành phần vào cùng một công thức, chúng ta chia quá trình kết hợp thành *nhiều tầng*, mỗi tầng giải quyết một bài toán con có cấu trúc riêng. Ý tưởng là: *hợp nhất những thành phần gần nhau trước, rồi mới hợp nhất các họ mô hình khác biệt; cuối cùng xử lý riêng vấn đề level.*

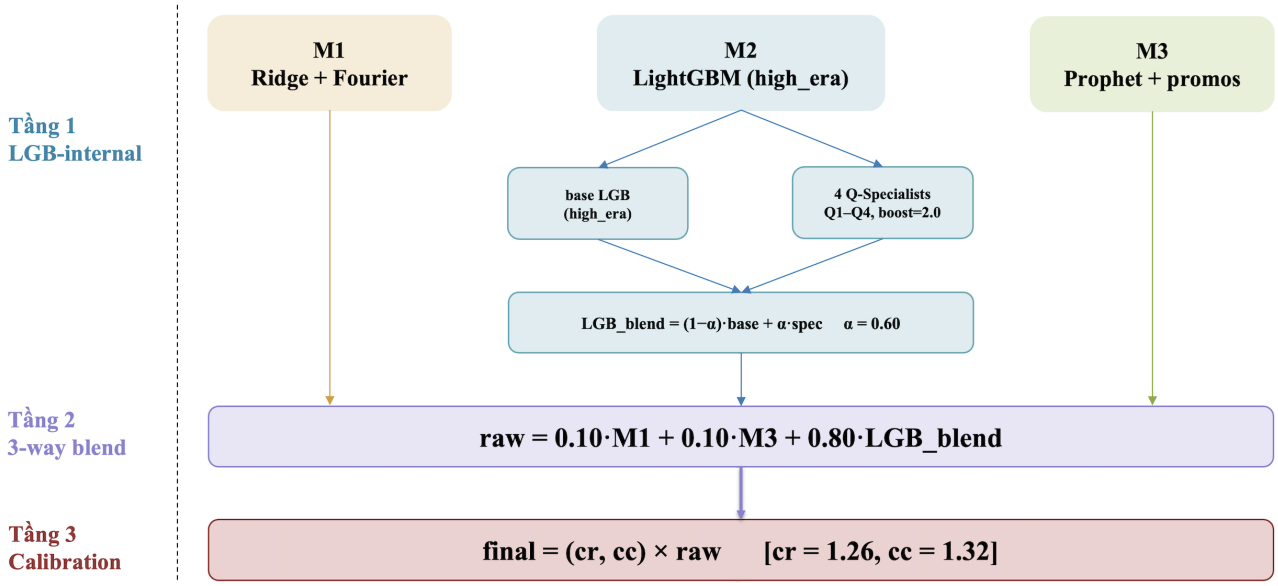

Hình 20: Kiến trúc ensemble. Base LGB và các specialist được hợp nhất trước ở Tầng 1 qua hệ số α. Kết quả LGB_blend tiếp tục được pha trộn với Ridge và Prophet ở Tầng 2 bằng trọng số 0.10/0.10/0.80. Tầng 3 áp hai hệ số calibration *cr*, *cc* để scale output về mức phù hợp với 2023–2024.

Ba tầng được tổ chức tuần tự theo logic sau:

1. **Tầng 1 Hợp nhất trong cùng một họ mô hình.** Base LGB và bốn Q-specialist đều là gradient boosting, chỉ khác nhau ở trọng số mẫu. Vì cùng một họ, chúng có cấu trúc sai số tương tự. Ta cần *một* hệ số α duy nhất để điều phối: $\text{LGB}_{\text{blend}} = (1-\alpha)\cdot\text{base} + \alpha\cdot\text{Q-spec}$. Giá trị α càng lớn thì specialist càng được trust nhiều hơn.

2. **Tầng 2 Hợp nhất giữa các họ mô hình khác nhau.** Sau khi đã gộp LGB nội bộ, kết quả đầu ra được xem như họ LGB tổng hợp đặt cùng hàng với Ridge và Prophet. Ba họ này có bản chất rất khác nhau, nên cần ba trọng số riêng. Trong thực nghiệm, tỉ trọng $(0.10, 0.10, 0.80)$ cho Ridge / Prophet / LGB_blend cho kết quả tốt nhất LGB mạnh hơn hẳn, Ridge và Prophet giữ vai trò anchor ổn định, chống overshoot.

3. **Tầng 3 Điều chỉnh mức (calibration).** Kết quả raw sau Tầng 2 vẫn nằm ở *level* của vùng học (2014 - 2018), cần được scale lên mức của 2023 - 2024. Đây là vấn đề khác hẳn với bài toán blend, nên giải quyết riêng bằng hai hệ số nhân *cr* (cho Revenue) và *cc* (cho COGS) tune trực tiếp trên Leaderboard.

Vì sao cần tách calibration khỏi blend?

Cross-validation nội bộ không mô phỏng được *mức thật* của 2023 vì năm 2022 (fold validation) có phân phối khác với 2023. Nếu để calibration được tune bằng CV, kết quả sẽ bị chệch. Do đó chiến lược tối ưu là: các hệ số blend ở Tầng 1 và Tầng 2 được chọn trên CV để tối thiểu hoá MAE của *hình dạng* prediction; hai hệ số calibration ở Tầng 3 được chọn để phủ đúng *mức* của test.

So với Hướng 1, kiến trúc phân tầng ở đây có hai lợi ích định tính: *(a)* cho phép dùng trọng số khác nhau cho các cặp thành phần có bản chất khác nhau, *(b)* tách riêng vấn đề level ra khỏi quá trình blend, giúp mỗi bước tối ưu độc lập.

XVIII.3. Mã nguồn ensemble phân tầng

```
#  Tai cac prediction raw da cache
cache = np.load("v26_high_era_test_raw.npz", allow_pickle= True)
p_ridge,  p_ridge_c   = cache["p_rd_rev"],  cache["p_rd_cog"]
p_prophet, p_prophet_c = cache["p_pr_rev"],  cache["p_pr_cog"]
p_lgb,     p_lgb_c     = cache["p_lgb_rev"], cache["p_lgb_cog"]

dates = pd.to_datetime(cache["dates"])
Q = dates.quarter.values

# Specialists ghep theo quy
spec_rev = {q: np.load(f"v50_specialist_Q{q}_Revenue.npy") for q in [1,2,3,4]}
spec_cog = {q: np.load(f"v50_specialist_Q{q}_COGS.npy")    for q in [1,2,3,4]}
lgb_spec_rev = np.zeros(548); lgb_spec_cog = np.zeros(548)
for q in [1,2,3,4]:
    mask = Q == q
    lgb_spec_rev[mask] = spec_rev[q][mask]
    lgb_spec_cog[mask] = spec_cog[q][mask]

#  Hyperparameter ensemble (chi tiet cach chon trong Muc VIII)
ALPHA = 0.60
CR, CC = 1.26, 1.32

# Tang 1: hop nhat LGB noi bo
lgb_blend_rev = ALPHA * lgb_spec_rev + (1 - ALPHA) * p_lgb
lgb_blend_cog = ALPHA * lgb_spec_cog + (1 - ALPHA) * p_lgb_c

# Tang 2: hop nhat 3 ho mo hinh
raw_rev = 0.10 * p_prophet   + 0.10 * p_ridge   + 0.80 * lgb_blend_rev
raw_cog = 0.10 * p_prophet_c + 0.10 * p_ridge_c + 0.80 * lgb_blend_cog

# Tang 3: calibration
final_rev = CR * raw_rev
final_cog = CC * raw_cog

#  Xuat submission
pd.DataFrame({
    "Date":    dates.strftime("%Y-%m-%d"),
```

```
    "Revenue": final_rev,
    "COGS":    final_cog,
}).to_csv("submission.csv", index= False)
```

XIX. Parameters Tuning

Pipeline có nhiều hyperparameter, nhưng không phải tham số nào cũng được tune bằng cùng một cách.

XIX.1. Tổng quan: ba nhóm tham số và công cụ tuning tương ứng

Tất cả hyperparameter của pipeline có thể được xếp vào một trong ba nhóm, tuỳ theo việc chúng ảnh hưởng đến khía cạnh nào của prediction.

Nhóm	Tham số điển hình	Công cụ tuning
(A) Hình dạng	LGB params, sample weight scheme, blend weights	CV trên fold A/B/C
(B) Tinh chỉnh	α, Q-boost	CV $\rightarrow$ xác nhận trên LB

Nhóm (A) tham số shape ảnh hưởng *độ uốn lượn* của prediction theo thời gian. Chúng có thể được đánh giá tin cậy bằng CV vì hình dạng mùa vụ ổn định qua các năm (đã kiểm chứng ở Mục XIV.). Chiến lược: tìm kiếm tham lam trên fold A, chọn điểm tốt nhất, xác nhận tính ổn định trên fold B và C trước khi chốt.

Nhóm (B) tham số tinh chỉnh nằm ở giữa hai nhóm trên. Chúng có thể tune sơ bộ bằng CV (nhận định hướng) nhưng kết quả cuối cần được xác nhận bằng LB. Ví dụ: α có thể đánh giá được trên CV vì nó liên quan đến sai số shape của specialist, nhưng ảnh hưởng đến level cũng có (thay đổi α thay đổi trung bình LGB_blend), nên cần cross-check.

XIX.2. Chiến lược tuning cho từng nhóm

Nhóm (A) tune bằng Cross-Validation

Các tham số của LightGBM (`learning_rate`, `num_leaves`, `min_data_in_leaf`, `lambda_l2`) được tune trên fold A. Vì LGB có variance giữa seed, ta lấy trung bình qua 3 seed để đánh giá ổn định. Giá trị cuối cùng được xác nhận bằng việc rerun trên fold B.

Sample weight scheme (`high_era`, `t1718`, `up_HIGH`, `uniform`, ...) cũng thuộc nhóm (A). Chiến lược: thử mỗi scheme, ghi MAE CV trên fold A. Scheme nào cho CV tốt nhất và ổn định trên fold B là scheme được chọn. Trong thực nghiệm, `high_era` thắng trên cả hai fold.

Trọng số blend 3-way $(w_{\text{ridge}}, w_{\text{lgb}}, w_{\text{prophet}})$ được thay đổi trên các giá trị $\{0.05, 0.10, 0.15, 0.20\}$ với ràng buộc tổng bằng 1. Điểm tối ưu ổn định rơi vào $(0.10, 0.80, 0.10)$.

Nhóm (B)

Hai hệ số *cr* và *cc* được tune *song song* nhưng độc lập: mỗi lần cố định một hệ số ở midpoint và quét hệ số còn lại. Dải thử ban đầu là $\{1.18, 1.22, 1.26, 1.30, 1.34\}$ cho *cr* và $\{1.28, 1.30, 1.32, 1.34, 1.36\}$ cho *cc*.

Hệ số	Dải thử	Kết quả trên LB
cr (Revenue)	1.18, 1.22, 1.26, 1.30	Đỉnh tại $cr = 1.26$
cc (COGS)	1.28, 1.30, 1.32, 1.34	Đỉnh tại $cc = 1.32$

Sau khi có dải rộng, tinh chỉnh bước 0.01 quanh điểm đỉnh để chắc chắn. Giá trị $(cr, cc) = (1.26, 1.32)$ là kết quả empirical: tổng hợp giữa raw prediction của blend (đã pha trộn từ nhiều nguồn có level khác nhau LGB `high_era` dự báo cao, Prophet post-regime dự báo thấp, Ridge ở giữa) và level thực của test 2023–2024. Cần lưu ý rằng cr không có ý nghĩa "scale lên" hay "scale xuống" đơn giản nó là tham số bù trừ cho mọi thiên lệch hệ thống còn lại sau ensemble, được tune trên LB để đạt MAE thấp nhất. Tham số α (tỉ lệ specialist trong LGB_blend) trước hết được sweep sơ bộ qua $\{0.3, 0.5, 0.7\}$ trên CV fold A để định hướng. Sau đó các giá trị gần đỉnh (0.45, 0.50, 0.55, 0.60, 0.70) được submit lên LB để xác nhận.

Tham số Q-boost (hệ số nhân weight cho quý target trong specialist) tune theo cách tương tự: thử $\{1.5, 2.0, 3.0\}$ trên CV, chọn giá trị tốt nhất, xác nhận bằng một lượt submit. Kết quả chốt: Q-boost = 2.0.

XX. Khả năng giải thích mô hình

Sau khi pipeline đã hoàn chỉnh ba mô hình gốc, bốn Q-specialist, ensemble phân tầng (Mục XVIII.) và các hệ số calibration đã tune (Mục XIX.) một câu hỏi đặt ra: *mô hình thực sự đã học được điều gì, và nó dựa vào yếu tố nào để dự báo?* Trả lời câu hỏi này không chỉ để hiểu rõ cơ chế dự báo bên trong, mà quan trọng hơn là để **kiểm chứng ngược**: xác nhận rằng các pattern phát hiện trong Mục XIV. (Tết, cuối tháng, chu kỳ chẵn/lẻ) đã được mô hình sử dụng *đúng*, và *định lượng* mức độ quan trọng của từng pattern.

XX.1. Đối tượng và công cụ giải thích

Ensemble cuối là tổ hợp nhiều mô hình, nhưng trọng số không đồng đều. Gồm tổ hợp các mô hình: họ cây (base LightGBM cùng bốn Q-specialist) chiếm 0.80 tổng trọng số, trong khi Ridge và Prophet mỗi nhánh chỉ 0.10. Vì vậy ta tập trung giải thích **base LightGBM** mô hình đại diện chi phối $\sim 80\%$ dự báo và dùng **Prophet** làm đối chứng.

Công cụ là **SHAP** (SHapley Additive exPlanations), cụ thể TreeSHAP tính trực tiếp qua LightGBM bằng `predict(pred_contrib=True)` cho kết quả *chính xác* cho mô hình cây, không cần xấp xỉ và không cần thư viện ngoài. SHAP có tính cộng tính: với mỗi ngày x

$$f(x) \;=\; \phi_0 \;+\; \sum_{i=1}^{n} \phi_i(x),$$

trong đó ϕ_0 là giá trị cơ sở (kỳ vọng đầu ra của mô hình) và $\phi_i(x)$ là đóng góp của feature thứ i. Tính cộng tính này được kiểm tra trực tiếp: sai số thiếp lập lại $\left|\phi_0 + \sum_i \phi_i - f(x)\right|$ tối đa chỉ $\sim 3 \times 10^{-14}$ trên toàn bộ 548 ngày, xác nhận phân rã là đúng. Vì mô hình học trên log(Revenue), đóng góp cộng trong không gian log tương đương phép *nhân* trên doanh thu gốc; một đóng góp $\Delta\phi$ quy ra phần trăm theo $e^{\Delta\phi} - 1$. Vì vậy các giải thích chúng ta dùng sẽ phát biểu được trực tiếp bằng %.

Tính TreeSHAP và gom feature thành nhóm nghiệp vụ

```
import numpy as np, pandas as pd

# TreeSHAP cho base LightGBM; cot cuoi cung la base value (ky vong dau ra)
def tree_shap(bf, X):
    contrib = bf.predict(X, pred_contrib= True)        # (n, n_features + 1)
    return contrib[:, :-1], float(contrib[0, -1])

X_te = test_df[cols].values.astype(float)
sv_rev, base_rev = tree_shap(bf_rev, X_te)
sv_cog, base_cog = tree_shap(bf_cog, X_te)

# Kiem tra tinh cong tinh (log space): base + tong(SHAP) ~ prediction
err = np.max(np.abs(base_rev + sv_rev.sum(1) - bf_rev.predict(X_te)))
print("Sai so cong tinh:", err)                        # ~ 3e-14

# Gom 81 dac trung thanh nhom nghiep vu (khu nhieu do feature Fourier tuong quan)
def group_of(c):
```

```
    if c == 'is_odd_year': return 'Year-parity'
    if c.startswith('tet_'): return 'Tet'
    if c.startswith('hol_'): return 'Le VN & BF'
    if c.startswith('promo_'): return 'Promo'
    if c.startswith(('is_first','is_last')) or c in ('days_to_eom','days_from_som'):
                                        return 'Edge-of-month'
    if c.startswith(('sin_w','cos_w')) or c in ('dow','is_weekend'): return 'Weekly'
    if c.startswith(('sin_y','cos_y','sin_m','cos_m')) or c in ('month','doy','quarter'
                                        ,'day','dim'): return 'Seasonality'
    if c.startswith('regime_') or c in ('t_days','t_years','year'): return 'Regime &
                                        trend'
    return 'Khac'
groups = [group_of(c) for c in cols]

def group_pct(sv):                                  # dong gop % moi nhom = tong
                                        mean|SHAP|
    mab = np.abs(sv).mean(0)
    d = {}
    for c, g, v in  zip(cols, groups, mab): d[g] = d.get(g, 0.0) + v
    tot = sum(d.values())
    return {g: 100*v/tot for g, v in sorted(d.items(), key=lambda x: -x[1])}
gp_rev, gp_cog = group_pct(sv_rev), group_pct(sv_cog)
```

Global importance và Local effect là hai góc nhìn khác nhau

Global importance đo trung bình $|\phi_i|$ trên cả 548 ngày trả lời pattern nào quan trọng *xét trên toàn horizon*. **Local effect** đo độ lớn đóng góp *ngay tại những ngày pattern đó xuất hiện*. Một pattern hiếm như Tết (chỉ ~ 2 tuần mỗi năm) sẽ có global importance *thấp* dù tác động cục bộ rất rõ. Vì vậy hai mục dưới đây báo cáo song song cả hai góc nhìn để tránh kết luận sai.

XX.2. Global importance

Hình 21 gom 81 features đã sử dụng thành tám nhóm nghiệp vụ đặc trưng rồi cộng dồn $|\phi_i|$ theo nhóm. Việc gom nhóm còn có tác dụng kỹ thuật: các feature Fourier vốn tương quan cao nên SHAP chia nhỏ tầm quan trọng cho từng feature, khiến xếp hạng đơn lẻ kém ổn định cộng theo nhóm khử được nhiễu này.

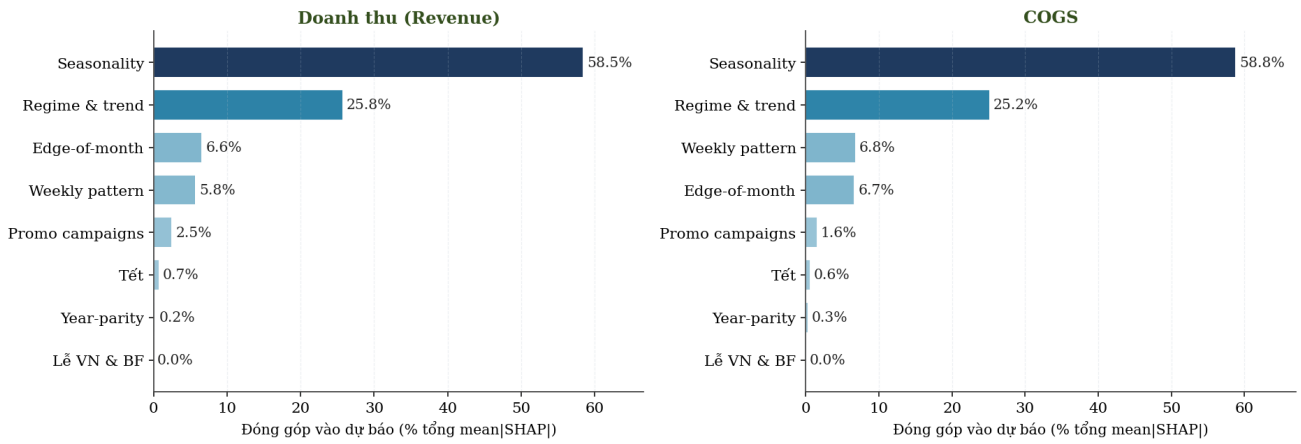

Hình 21: Đóng góp của tám nhóm pattern vào dự báo, đo bằng tổng `mean|SHAP|` trên giai đoạn test 2023–2024, cho Revenue (trái) và COGS (phải). Hai nhóm Seasonality và Regime & trend chi phối, chiếm $\sim$ 84%.

Biểu đồ đóng góp theo nhóm và bảng global importance

```
import matplotlib.pyplot as plt
fig, axes = plt.subplots(1, 2, figsize=(13.5, 4.6))
for ax, (gp, title) in  zip(axes, [(gp_rev, 'Doanh thu'), (gp_cog, 'COGS')]):
    names, pct =  list(gp.keys()),  list(gp.values())
    ax.barh(names[::-1], pct[::-1],
            color=[plt.cm.Blues(0.35 + 0.6*(p/max(pct))) for p in pct][::-1])
    ax.set_title(title); ax.set_xlabel('% tong mean|SHAP|')
plt.tight_layout(); plt.show()

df_global = pd.DataFrame({'Nhom':  list(gp_rev.keys()),
    'Revenue (%)': [round(gp_rev[g], 1) for g in gp_rev],
    'COGS (%)':    [round(gp_cog.get(g, 0.0), 1) for g in gp_rev]})
print(df_global)
```

Kết quả nổi bật: dự báo doanh thu dựa **chủ yếu vào mùa vụ năm** (58.5%) **và mặt bằng regime/trend** (25.8%), hai nhóm chiếm $\sim$ 84% tầm quan trọng. Phần còn lại chia cho cuối tháng (6.6%), thứ trong tuần (5.8%) và promo (2.5%); riêng Tết và chu kỳ chẵn/lẻ đóng góp global rất nhỏ ($\leq$ 0.7%). COGS có cấu trúc gần như y hệt (mùa vụ 58.8%, regime 25.2%) xác nhận COGS rất gần với Revenue, đúng như quan hệ tuyến tính chặt đã thấy ở Hình 18.

Nhóm pattern	Revenue (%)	COGS (%)	Ý nghĩa
Seasonality (mùa vụ năm)	58.5	58.8	Hình mùa vụ trong năm (Fourier $k = 1..5$)
Regime & trend	25.8	25.2	Mặt bằng theo thời gian, ba regime
Edge-of-month	6.6	6.7	Hiệu ứng cuối/đầu tháng
Weekly pattern	5.8	6.8	Thứ trong tuần (weekday > weekend)
Promo campaigns	2.5	1.6	Sáu chiến dịch khuyến mãi theo lịch
Tết	0.7	0.6	Hiếm nên global thấp
Year-parity	0.2	0.3	Pattern năm chẵn/lẻ
Lễ VN & Black Friday	0.0	0.0	Gần như không đáng kể

Phát hiện này nhất quán với hai thành phần quan trọng khi thiết kế của pipeline: Fourier seasonality (Mục XV.) và sample weighting kết hợp calibration cho regime (Mục XVII., Mục XVIII.). Qua đây, SHAP cho thấy rõ mô hình đã học được những đặc trưng nổi bật và cho thấy những phân tích EDA dự đoán là đúng và có cơ sở.

XX.3. Local effect

Global importance cho biết nhóm nào đóp góp nhiều; để hiểu rõ cơ chế, sử dụng dependence plot cho ta thấy quan hệ giữa giá trị feature và đóng góp SHAP (Hình 22). Để đo độ lớn cục bộ, ta dùng hai phép đo bổ sung cho nhau, được tính trong khối lệnh dưới đây.

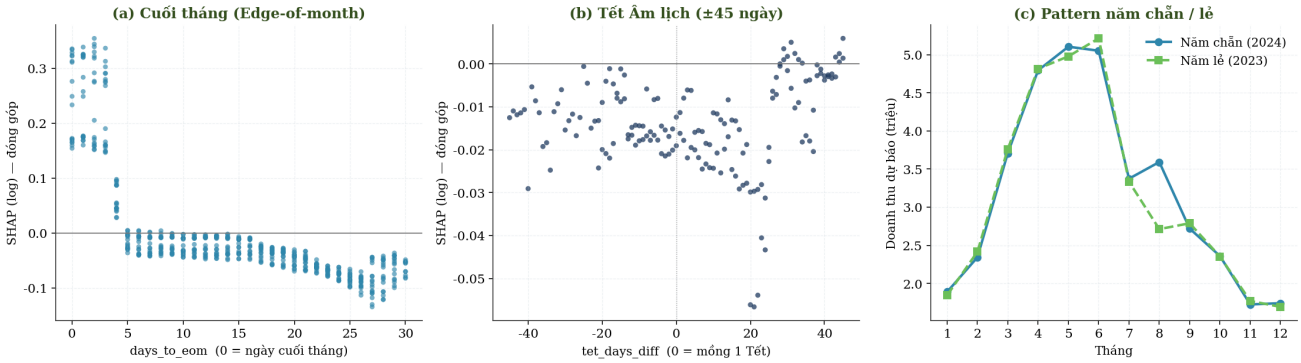

Hình 22: Dependence plot của ba driver then chốt. (a) `days_to_eom`: đóng góp SHAP tăng mạnh và dương ở 0–3 ngày cuối tháng. (b) `tet_days_diff`: đóng góp âm quanh mồng 1 Tết. (c) Doanh thu dự báo theo tháng, tách năm chẵn/lẻ: tháng 8 năm chẵn cao hơn rõ rệt.

Hiệu ứng cục bộ: chênh lệch tổng và SHAP cô lập theo nhóm

```
def shap_of(name): return sv_rev[:, cols.index(name)], test_df[name].values   # cho
                                                    dependence plot

```

```
# Luoi day du 2023-2024 (bao gom thang 8 nam chan, vi cua so test dung o 2024-07-01)
grid = build_features(pd.date_range('2023-01-01', '2024-12-31', freq='D'))
glog_rev = bf_rev.predict(grid[cols].values.astype(float))
glog_cog = bf_cog.predict(grid[cols].values.astype(float))

def gidx(g): return [i for i, gg in  enumerate(groups) if gg == g]
ti = test_df.reset_index(drop= True)
# (1) chenh lech du bao TONG giua hai nhom ngay (gom ca confound mua vu, dung cach EDA do)
def eff_total(sv, a, b): return 100*np.expm1(sv[a.values].sum(1).mean() - sv[b.values].sum(1).mean())
# (2) SHAP CO LAP: chi cong SHAP cua rieng nhom driver
def eff_iso(sv, g, a, b):
    c = sv[:, gidx(g)].sum(1); return 100*np.expm1(c[a.values].mean() - c[b.values].mean())

a_eom, b_eom = ti['is_last1']==1, ti['day'].between(13,17)
a_tet, b_tet = ti['tet_in_7']==1, ti['tet_days_diff'].abs()>30
a_yp,  b_yp  = ti['is_odd_year']==0, ti['is_odd_year']==1
augE = (grid['month']==8)&(grid['is_odd_year']==0); augO = (grid['month']==8)&(grid['is_odd_year']==1)
aug_rev = 100*np.expm1(glog_rev[augE.values].mean() - glog_rev[augO.values].mean())
aug_cog = 100*np.expm1(glog_cog[augE.values].mean() - glog_cog[augO.values].mean())
sv_grid = bf_rev.predict(grid[cols].values.astype(float), pred_contrib= True)[:, :-1]
yp_grid = sv_grid[:, gidx('Year-parity')].sum(1)        # SHAP co lap year-parity, rieng thang 8
aug_iso = 100*np.expm1(yp_grid[augE.values].mean() - yp_grid[augO.values].mean())

df_local = pd.DataFrame({
    'Driver':          ['Cuoi thang', 'Quanh Tet', 'Thang 8 chan/le'],
    'Rev tong (%)':    [round(eff_total(sv_rev,a_eom,b_eom)), round(eff_total(sv_rev,a_tet,b_tet)), round(aug_rev)],
    'Rev co lap (%)': [round(eff_iso(sv_rev,'Edge-of-month',a_eom,b_eom),1),
                       round(eff_iso(sv_rev,'Tet',a_tet,b_tet),1),
                       round(aug_iso, 1)],
    'COGS tong (%)':   [round(eff_total(sv_cog,a_eom,b_eom)), round(eff_total(sv_cog,a_tet,b_tet)), round(aug_cog)]})
print(df_local)

gain = bf_rev.feature_importance(importance_type='gain')                # kiem tra cheo
overlap =  len({cols[i] for i in np.argsort(gain)[::-1][:10]} &
               {cols[i] for i in np.argsort(np.abs(sv_rev).mean(0))[::-1][:10]})
print("SHAP cap gain (top-10):", overlap, "/10")
```

Gọi A và B là hai nhóm ngày được so sánh. Nhờ tính cộng tính của SHAP, tổng đóng góp của mọi đặc trưng trong một ngày bằng log dự báo trừ giá trị cơ sở: $\sum_i \phi_i(x) = \log f(x) - \phi_0$. Ta dùng hai đại lượng bổ sung cho nhau.

(1) Chênh lệch dự báo tổng cộng SHAP của *tất cả* đặc trưng:

$$\Delta_{\text{tổng}} \;=\; \exp\!\Big(\overline{\textstyle\sum_i \phi_i}\Big|_A \;-\; \overline{\textstyle\sum_i \phi_i}\Big|_B\Big) - 1.$$

(2) SHAP cô lập của nhóm g chỉ cộng SHAP của các đặc trưng thuộc nhóm g:

$$\Delta_{\text{cô lập}}(g) \;=\; \exp\Big(\overline{\textstyle\sum_{i\in g}\phi_i}\Big|_A \;-\; \overline{\textstyle\sum_{i\in g}\phi_i}\Big|_B\Big) - 1,$$

trong đó $\overline{(\cdot)}\big|_A$ là trung bình trên các ngày thuộc nhóm A. Phép $\exp(\cdot)-1$ đưa hiệu trong không gian log về phần trăm trên doanh thu gốc. Ba cặp nhóm ngày A/B được định nghĩa như sau.

Driver	**Nhóm** A	**Nhóm** B **(đối chứng)**
Cuối tháng	`is_last1`= 1 (ngày cuối tháng)	ngày 13–17 (giữa tháng)
Tết	trong ±7 ngày quanh mồng 1	cách Tết $>$ 30 ngày
Tháng 8 chẵn/lẻ	tháng 8 năm chẵn	tháng 8 năm lẻ

Cách đọc hai cột hiệu ứng cục bộ

Chênh lệch tổng trả lời doanh thu dự báo ở nhóm A cao/thấp hơn nhóm B bao nhiêu %, gộp mọi yếu tố khác biệt giữa hai nhóm ngày (kể cả mùa vụ) đúng cách phần phân tích dữ liệu so sánh mức doanh thu thực. **SHAP cô lập** trả lời mô hình gán trực tiếp bao nhiêu cho riêng nhóm đặc trưng đó. Khi hai số lệch nhau, phần chênh là do các nhóm khác.

Ví dụ tính (Tết). Hiệu hai trung bình trong không gian log là $\Delta = \overline{\sum_i \phi_i}\big|_A - \overline{\sum_i \phi_i}\big|_B \approx -0.56$. Quy ra phần trăm: $e^{-0.56} - 1 \approx -0.43$, tức doanh thu quanh Tết thấp hơn ngày thường khoảng 43%.

Hai phép đo cho hai ý nghĩa khác nhau. *Rev tổng* là chênh lệch dự báo giữa hai nhóm ngày, đo theo đúng cách EDA so sánh mức doanh thu thực, nên bao hàm cả thành phần mùa vụ của các ngày đó. *Rev cô lập* chỉ cộng đóng góp của riêng nhóm đặc trưng tương ứng, cho biết mô hình gán trực tiếp bao nhiêu cho chính nhóm đó. Kết quả tổng hợp trong bảng sau:

Driver	**Rev tổng (%)**	**Rev cô lập (%)**	**COGS tổng (%)**	**Đối chiếu EDA**
Cuối tháng (cuối vs giữa tháng)	+69	+31.7	+79	Hình 14 (gấp đôi)
Quanh Tết (±7 ngày vs thường)	−43	≈ 0	−44	Hình 13 (sụt sâu)
Tháng 8 năm chẵn vs lẻ	+35	+0.5	+2	Hình 15 ($\sim 1.6\times$)

Hai cột *tổng* và *cô lập* cho thấy một điểm quan trọng. Với hiệu ứng cuối tháng, chênh lệch tổng +69% nhưng riêng nhóm Edge-of-month chỉ đóng góp +31.7%; phần còn lại đến từ vị trí mùa vụ của các ngày cuối tháng. Với Tết, chênh lệch tổng −43% nhưng đóng góp cô lập của nhóm

đặc trưng Tết ≈ 0; tương tự, chênh lệch tháng 8 năm chẵn/lẻ +35% nhưng đóng góp cô lập của `is_odd_year` chỉ +0.5%. Nghĩa là mô hình tái hiện mức sụt giảm dịp Tết và chu kỳ chẵn/lẻ gần như hoàn toàn thông qua thành phần mùa vụ năm (Fourier), *không* qua các đặc trưng chuyên dụng cho Tết và năm chẵn/lẻ các đặc trưng này gần như thừa trong cấu hình hiện tại. Đây là một phát hiện trực tiếp gợi ý hướng cải thiện: tăng trọng số hoặc thiết kế lại để mô hình dựa vào chúng nhiều hơn, qua đó tái hiện đúng *biên độ* (EDA ước lượng sơ bộ tháng 8 chênh $\sim 1.6\times$, mức tổng mô hình tái hiện chỉ $\sim 1.35\times$) thay vì chỉ đúng *chiều*. COGS cho hiệu ứng cục bộ cùng dấu và độ lớn tương đương (cuối tháng +79%, Tết −44%).

Từ các con số này có thể rút ra ba đề xuất vận hành: *(i)* tập trung khuyến mãi, tồn kho và năng lực giao vận vào tuần cuối tháng; *(ii)* không tung khuyến mãi lớn đúng dịp Tết mà chuyển ngân sách sang giai đoạn hậu-Tết khi cầu hồi phục; *(iii)* chuẩn bị tồn kho cho mức tăng doanh thu tháng 8 của năm chẵn (2024).

XX.4. Đối chứng định lượng với Prophet

Prophet là một họ mô hình hoàn toàn khác (phân rã có cấu trúc thay vì cây), nên việc kiểm tra phân tích Prophet độc lập với SHAP sẽ là một cách xác minh hiệu quả.

Phép giải thích trên chỉ dựa vào một mô hình (LightGBM). Để kiểm chứng độc lập, ta đối chiếu với Prophet một họ mô hình khác hẳn, dự báo bằng cách *phân rã* chuỗi thành xu hướng, thành phần theo tuần và thành phần mùa vụ năm. Việc đối chứng gồm hai phần. **Định tính**: vẽ ba thành phần của Prophet để quan sát trực tiếp hình dạng mùa vụ nó học được (Hình 23). **Định lượng**: so sánh *đường cong mùa vụ* của hai mô hình theo ngày trong năm (day-of-year, 1–365). Với LightGBM, đóng góp mùa vụ của mỗi ngày là tổng SHAP của nhóm Seasonality; lấy trung bình theo ngày trong năm ta được một đường cong. Với Prophet, thành phần `yearly` sẵn là đường cong đó. Hệ số tương quan Pearson giữa hai đường cong cho biết hai mô hình có *đồng thuận* về việc doanh thu cao/thấp vào thời điểm nào trong năm hay không r càng gần 1 thì kết luận giải thích càng đáng tin vì không phụ thuộc một mô hình duy nhất.

Đối chứng định lượng với Prophet

```
# Phan ra Prophet (trend / weekly / yearly / regressor promo)
vdf = pd.DataFrame({'ds': test_df['Date']}).merge(build_promo_regressors(test_df['Date'
                                            ]), on='ds')
fc = mp_r.predict(vdf)
mp_r.plot_components(fc); plt.show()
# Tuong quan thanh phan mua vu nam cua Prophet vs SHAP mua vu cua LGB (theo day-of-year
                                            )
doy = test_df['Date'].dt.dayofyear.values
lgb_seas = pd.Series(sv_rev[:, gidx('Seasonality')].sum(1), index=doy).groupby(level=0)
                                            .mean()
pro_year = pd.Series(fc['yearly'].values, index=doy).groupby(level=0).mean()
common = lgb_seas.index.intersection(pro_year.index)
print("Tuong quan r =", round(np.corrcoef(lgb_seas[common], pro_year[common])[0,1], 3))
                                                # ~0.87
```

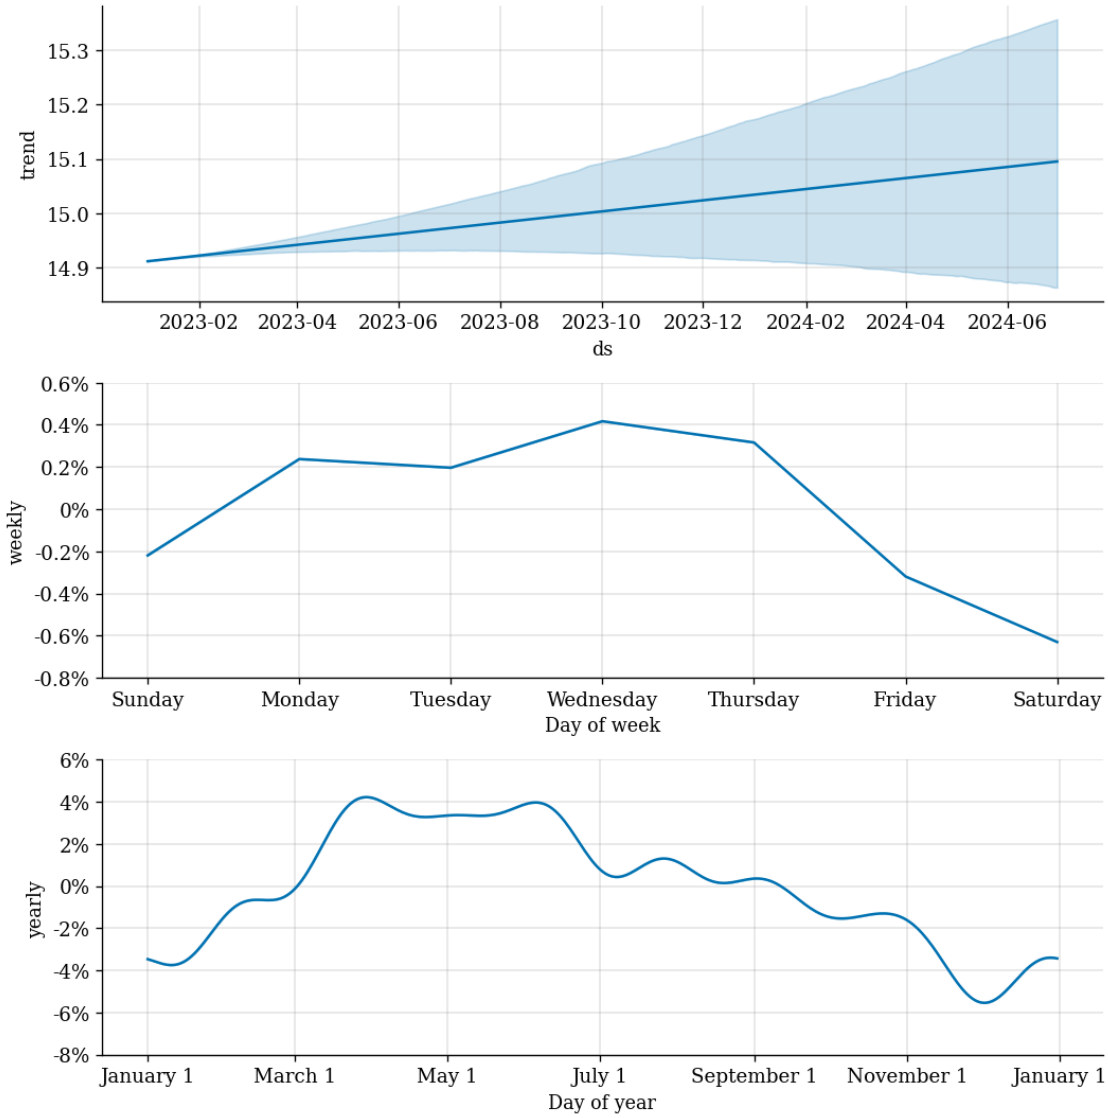

Hình 23: Phân rã Prophet (Revenue): trend, thành phần theo tuần và thành phần mùa vụ năm. Thành phần mùa vụ năm có dạng trùng với SHAP mùa vụ của LightGBM; thành phần tuần cho ngày thường cao hơn cuối tuần.

Thành phần mùa vụ năm của Prophet (Hình 23) tương quan rất cao với SHAP mùa vụ của LightGBM theo ngày trong năm, hệ số Pearson $r \approx 0.87$; thành phần theo tuần của Prophet cũng cho ngày thường cao hơn cuối tuần, trùng với nhóm Weekly mà SHAP xếp hạng. Một phép kiểm tra chéo thứ hai trong nội bộ LightGBM: 8 trong 10 đặc trưng quan trọng nhất theo `gain importance` trùng với 10 đặc trưng đứng đầu theo SHAP. Cả hai phép kiểm tra đều làm tăng độ tin cậy của kết luận.

Hướng mở rộng

Cuối cùng, phần này trình bày một số các hướng để có thể tiếp tục mở rộng và cải thiện tính hiệu quả của mô hình:

Adaptive per-quarter blend fraction

Phương pháp ở Mục 9.1 dùng hệ số blend $\beta = 0.3$ đồng đều cho cả bốn quý. Nhưng Q1, Q2, Q4 vốn đã có margin hợp lý trong output áp $\beta = 0.3$ cho chúng là *can thiệp không cần thiết*. Ngược lại, Q3 cần β lớn hơn để kéo margin về đúng vùng. Một hệ số β cố định là tối ưu dưới *trung bình* nhưng chưa tối ưu cho mỗi quý.

CV-optimized ensemble weights (NNLS)

Trong quá trình huấn luyện, chúng ta thử nhiều scheme sample weighting khác nhau (`high_era`, `t1718`, `up_HIGH`, `analog`, `up_2018`), mỗi cái cho ra một LGB khác nhau. Pipeline chỉ dùng `high_era`, vứt bỏ thông tin từ các scheme còn lại. Nhưng liệu một tổ hợp tuyến tính của chúng có thể tốt hơn bất kỳ thành viên đơn lẻ nào?

Phân tích thử nghiệm sự features

Phương pháp tập trung vào tạo các đặc trưng nhưng chưa nghiên cứu sâu vào sự ảnh hưởng thực sự. Nên cần có những ước tính và đo lường cụ thể hơn để xem xét đâu là đặc trưng có nhiều ý nghĩa.

Fine-tuning foundation models

Thử nghiệm, các foundation model (Chronos, NHITS, TTM, PatchTST, TimesFM). Các foundation model mang đến diversity hoàn toàn khác so với họ cây/tuyến tính.

Tổng kết

Đặc trưng dữ liệu cho bài toán

Khi horizon dài, feature calendar thuần là lựa chọn an toàn nhất. Việc loại bỏ hoàn toàn feature lag ($y_{t-1}, y_{t-7}, y_{t-365}$) có vẻ hạn chế nhưng lại là điều kiện tiên quyết để pipeline không bị "đứt" khi dự báo xa. Mọi đặc trưng được mã hoá chỉ từ ngày tháng, nhờ vậy ma trận test có thể tính sẵn đầy đủ ngay từ đầu, không phải tính lại trong lúc rolling.

Tách bài toán "học shape" khỏi bài toán "điều chỉnh level". Khi dữ liệu có regime drift, cố gắng dạy một mô hình duy nhất cả shape lẫn level thường không hiệu quả. Pipeline này chia thành hai pha rõ ràng: sample weight giúp mô hình tập trung học shape từ vùng sạch 2014–2018, rồi hai hệ số calibration tune trên LB phủ khoảng cách level. Cả hai thành phần đơn giản nhưng khi kết hợp đem lại cải thiện lớn.

Diversity có chủ đích trong ensemble. Ba mô hình nền không được chọn ngẫu nhiên mà đại diện ba họ giải thuật khác nhau (tuyến tính, cây, phân rã). Bốn quarter specialist không được train song song vô hướng mà mỗi cái được kéo về một quý cụ thể qua Q-boost. Kết quả là các thành viên ensemble không chồng lấp về sai số, cho phép blend tạo ra cải thiện thực sự.

Quy trình tổng quát

Pipeline này có thể được gói thành một *công thức 4 bước* dùng được cho nhiều bài toán forecasting horizon dài khác:

1. **Nhận diện regime và mùa vụ.** Vẽ timeline, phân vùng, kiểm tra tính ổn định của seasonality. Nếu shape ổn định thì cơ chế "học shape + calibrate level" khả thi.
2. **Xây feature calendar thuần.** Mã hoá mọi pattern tự nhiên theo công thức từ `Date`: Fourier, Tet/holidays, promo schedule, edge-of-month.
3. **Ensemble đa họ với trọng số CV-tune + calibration LB-tune.** Ba họ khác nhau (tuyến tính, cây, phân rã). Blend nội bộ trong từng họ nếu có variant. Tầng calibration riêng xử lý level drift.
4. **Phân tích sai số per-segment, xây specialist cho segment lệch nhất.** Nếu một segment (quý, vùng, kênh) có sai số cao bất thường, train mô hình riêng cho nó và blend lại với mô hình chung.

Pipeline này đạt LB khoảng 680,000 sau khi tuning một số tham số nhưng vẫn còn cách đáng kể so với điểm lý thuyết tối ưu. Một số điểm có thể phân tích tiếp:

- **Chỉ dùng feature từ sales.csv.** Các bảng phụ trợ (web_traffic, inventory, ...) chưa được khai thác, một phần vì chúng dừng ở 2022. Nhưng có thể trích pattern ổn định từ chúng (ví dụ: chu kỳ tồn kho trung bình, correlation giữa lưu lượng truy cập và doanh thu) để thêm feature cho test.
- **Chưa khai thác diversity của neural model.** Foundation model fine-tuned có thể là hướng tốt có sự diversity hoàn toàn khác cho ensemble.

Phụ lục

1. **Hint:** Các file code gợi ý và dữ liệu nếu có được lưu trong thư mục có thể được tải tại đây.
2. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại đây (Lưu ý: Sáng thứ 3 khi hết deadline phần project, ad mới copy các nội dung bài giải nêu trên vào đường dẫn).
3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 giờ.

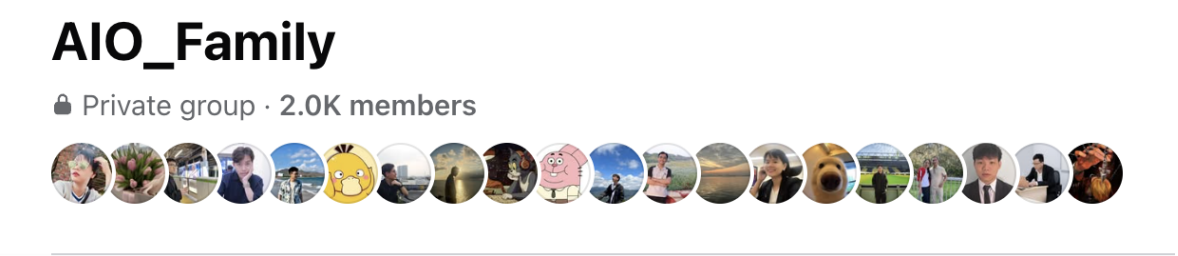

Hình 24: Hình ảnh group facebook AIO Q&A

Lớp AIO-2025
Bài thi: DATA SCIENCE

Thời gian làm bài: 4 tiếng

Nhóm ra đề thi AIO

Các file dữ liệu hoặc code cho bài kiểm tra có thể tải về **TẠI ĐÂY**

I. SQL & Relational Schema

Bạn là Data Analyst cho chuỗi bán lẻ đa kênh, vận hành đồng thời tại cửa hàng vật lý và sàn thương mại điện tử. Hệ thống dữ liệu gồm các bảng sau:

Bảng	Các cột chính	**Ghi chú / Grain**
customers	customer_id (PK), name, city	Mỗi dòng = 1 khách hàng duy nhất.
orders	order_id (PK), customer_id (FK), order_date, channel, order_total	Mỗi dòng = 1 đơn hàng.
order_items	item_id (PK), order_id (FK), product_id (FK), quantity, unit_price, discount_amount	Mỗi dòng = 1 dòng sản phẩm trong đơn hàng.
products	product_id (PK), product_name, category	Mỗi dòng = 1 sản phẩm duy nhất.
shipments	shipment_id (PK), order_id (FK), ship_date, delivery_date	Mỗi dòng = 1 lô giao hàng.
store_inventory	store_id, product_id, inv_date, stock_quantity PK: (store_id, product_id, inv_date)	Mỗi dòng = tồn kho của 1 sản phẩm tại 1 cửa hàng vào 1 ngày.
ad_events	event_id (PK), customer_id (FK), campaign_id, variant, event_type, event_ts	Mỗi dòng = 1 sự kiện quảng cáo / A-B testing của 1 khách hàng.

Bảng 1: Schema hệ thống

Quy ước chung cho toàn bộ phần SQL:

- **Grain** là đơn vị quan sát của một dòng dữ liệu trong bảng.
- **Giá trị trước giảm giá** của một dòng `order_items`:

$$\texttt{quantity} \times \texttt{unit_price} + \texttt{discount_amount}$$

- **Discount rate** của một category:

$$\frac{\text{Tổng discount_amount}}{\text{Tổng giá trị trước giảm giá}}$$

- **Lead time**:

$$\texttt{delivery_date} - \texttt{order_date}$$

AIO25-DS-SQL-01

Sơ đồ dưới đây mô tả quan hệ giữa ba bảng trong hệ thống bán lẻ. Mỗi ô chứa tên bảng và **grain** – tức đơn vị quan sát của một dòng dữ liệu trong bảng.

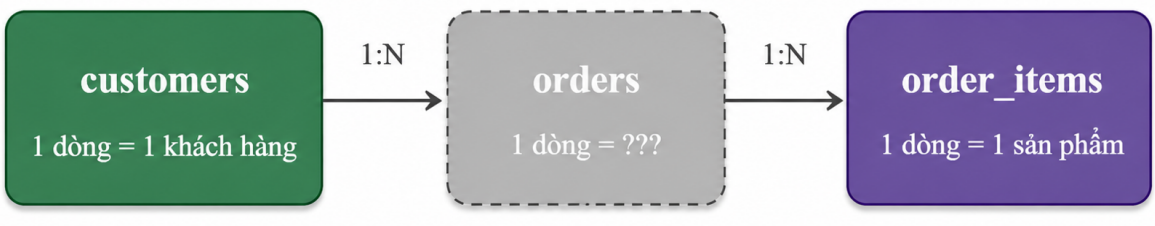

Hình 1: Quan hệ giữa ba bảng `customers`, `orders` và `order_items`

Bảng `orders` có ô grain bị để trống, được biểu diễn bằng ô gạch nét đứt. Dựa vào vị trí của `orders` trong sơ đồ – nằm giữa `customers` với grain "1 dòng = 1 khách hàng" và `order_items` với grain "1 dòng = 1 sản phẩm trong đơn" – grain chính xác của bảng `orders` là gì?

A. 1 dòng = 1 khách hàng duy nhất.

B. 1 dòng = 1 đơn hàng duy nhất.

C. 1 dòng = 1 sản phẩm trong đơn hàng.

D. 1 dòng = 1 cặp (khách hàng – sản phẩm).

AIO25-DS-SQL-02

Trong schema đã cung cấp, `customers.customer_id` là khóa chính (PK), còn `orders.customer_id` là khóa ngoại (FK) tham chiếu đến bảng `customers`.

Xét hai nhóm truy vấn sau:

SQL query — so sánh COUNT và COUNT DISTINCT

```
-- Nhom A: bang customers
SELECT COUNT(customer_id)          FROM customers; -- Ket qua: X
SELECT COUNT(DISTINCT customer_id) FROM customers; -- Ket qua: Y

-- Nhom B: bang orders
-- Gia su moi don hang deu co customer_id, khong co don an danh
SELECT COUNT(customer_id)          FROM orders; -- Ket qua: A
SELECT COUNT(DISTINCT customer_id) FROM orders; -- Ket qua: B
```

Doanh nghiệp đang hoạt động bình thường, trong đó một khách hàng có thể đặt nhiều đơn hàng. Mối quan hệ nào phản ánh đúng bản chất của PK và FK trong tình huống này?

A. $X > Y$ và $A > B$

B. $X = Y$ và $A = B$

C. $X = Y$ và $A > B$

D. $X > Y$ và $A = B$

AIO25-DS-SQL-03
Bảng `store_inventory` có khóa chính phức hợp:

```
PRIMARY KEY (store_id, product_id, inv_date)
```

Mỗi dòng trong bảng ghi nhận tồn kho của một sản phẩm tại một cửa hàng vào một ngày cụ thể.

Bạn muốn tính "số lượng tồn kho trung bình của sản phẩm `P001` trong tháng 1/2026 trên toàn hệ thống" và viết:

SQL query — tồn kho trung bình của sản phẩm P001 trong tháng 1/2026

```sql
SELECT product_id, AVG(stock_quantity)
FROM store_inventory
WHERE product_id = "P001"
  AND inv_date BETWEEN "2026-01-01" AND "2026-01-31"
GROUP BY product_id;
```

Về mặt bản chất, hàm `AVG()` này đang tính trung bình trên đơn vị nào?

A. Trung bình theo từng ngày.

B. Trung bình theo từng cửa hàng.

C. Trung bình trên mỗi cặp (ngày – cửa hàng).

D. Tổng tồn kho toàn hệ thống chia cho 31 ngày trong tháng.

AIO25-DS-SQL-04
Từ schema đã cung cấp, xét pipeline JOIN giữa ba bảng:

`customers` → `orders` → `shipments`

Snapshot dữ liệu tại một thời điểm cụ thể như sau:

- Bảng `customers` có 1000 khách hàng, mỗi dòng là một khách.
- Trong 1000 khách đó, có 300 khách đã từng đặt hàng và 700 khách chưa từng đặt hàng.
- Bảng `orders` có 310 đơn hàng, do 300 khách tạo ra.
- Trong 300 khách đã mua hàng, có 290 khách mua đúng 1 lần và 10 khách mua đúng 2 lần.
- Bảng `shipments` có 240 shipment, tương ứng với 240 đơn hàng đã được giao.
- Như vậy, trong 310 đơn hàng, có 240 đơn đã có shipment và 70 đơn chưa có shipment.
- Giả sử mỗi order có tối đa 1 shipment.

Ghép đúng từng pipeline SQL ở Cột X với số dòng kết quả ở Cột Y.

Pipeline	Cột X: SQL	Cột Y

P1	`FROM customers c`
	`LEFT JOIN orders o`
	`  ON c.customer_id = o.customer_id`
	`LEFT JOIN shipments s`
	`  ON o.order_id = s.order_id`
		R1. 1010 dòng

P2	`FROM customers c`
	`LEFT JOIN orders o`
	`  ON c.customer_id = o.customer_id`
	`INNER JOIN shipments s`
	`  ON o.order_id = s.order_id`
		R2. 240 dòng

P3	`FROM customers c`
	`INNER JOIN orders o`
	`  ON c.customer_id = o.customer_id`
	`LEFT JOIN shipments s`
	`  ON o.order_id = s.order_id`
		R3. 310 dòng

P4	`FROM customers c`
	`LEFT JOIN orders o`
	`  ON c.customer_id = o.customer_id`
	`LEFT JOIN shipments s`
	`  ON o.order_id = s.order_id`
	`WHERE s.shipment_id IS NULL`
		R4. 770 dòng

Bảng 2: Ghép 4 pipeline JOIN với 4 số dòng kết quả

Chọn phương án ghép đúng:

A. P1 $\rightarrow$ R1, P2 $\rightarrow$ R2, P3 $\rightarrow$ R3, P4 $\rightarrow$ R4.

B. P1 $\rightarrow$ R3, P2 $\rightarrow$ R2, P3 $\rightarrow$ R1, P4 $\rightarrow$ R4.

C. P1 $\rightarrow$ R1, P2 $\rightarrow$ R4, P3 $\rightarrow$ R3, P4 $\rightarrow$ R2.

D. P1 $\rightarrow$ R4, P2 $\rightarrow$ R2, P3 $\rightarrow$ R3, P4 $\rightarrow$ R1.

AIO25-DS-SQL-05

Team Product thử nghiệm A/B Testing trên nút "Thêm vào giỏ" (add to cart).

Dữ liệu được ghi nhận trong bảng `ad_events` với hai loại sự kiện:

`event_type = "enter_test"` (khách vào trang sản phẩm) và

`event_type = "click"` (khách bấm nút)

Một số khách hàng bị mạng lag nên bấm nút nhiều lần trong cùng một phiên, tạo ra nhiều dòng `click` cho cùng một khách.

Bạn cần tính **tỷ lệ người dùng thực tế có bấm nút**, không phải tỷ lệ lượt click. Xét hai công thức:

SQL query — so sánh công thức đếm event thường và DISTINCT

```
-- Cong thuc A
COUNT(CASE WHEN event_type = "click" THEN customer_id END)
/
COUNT(CASE WHEN event_type = "enter_test" THEN customer_id END)

-- Cong thuc B
COUNT(DISTINCT CASE WHEN event_type = "click" THEN customer_id END)
/
COUNT(DISTINCT CASE WHEN event_type = "enter_test" THEN customer_id END)
```

Nhận định nào đúng nhất?

A. Cả hai công thức cho kết quả như nhau vì đã `GROUP BY` theo từng variant.

B. Công thức A đúng cho bài toán tỷ lệ người dùng; công thức B đếm tỷ lệ lượt click.

C. Công thức A có thể trả về giá trị lớn hơn 100%; công thức B mới đúng cho tỷ lệ người dùng.

D. Cả hai đều sai vì SQL không hỗ trợ `COUNT(DISTINCT CASE WHEN ...)`.

AIO25-DS-SQL-06
Team Product chạy thử nghiệm A/B trên hai nhóm khách hàng:

`variant = "ctrl"` và `variant = "treat"`

Dữ liệu được ghi vào bảng `ad_events`. Sau khi thử nghiệm kết thúc, bạn muốn trả lời hai câu hỏi kinh doanh khác nhau:

- **Câu hỏi kinh doanh 1:** Trong số những khách hàng đã vào trang sản phẩm

  `event_type = "enter_test"`,

  nhóm nào có tỷ lệ bấm nút

  `event_type = "click"`

  cao hơn?

- **Câu hỏi kinh doanh 2:** Sau khi gom nhóm theo `variant`, chỉ giữ lại những nhóm có số lượng khách đã bấm nút đạt điều kiện phân tích; trong các nhóm còn lại, nhóm nào có tỷ lệ sự kiện thuộc chiến dịch

  `campaign_id = "CMP_A"`

  cao hơn?

Hai câu hỏi trên đều tính tỷ lệ và đều gom nhóm theo `variant`, nhưng khác nhau ở vị trí đặt điều kiện lọc trong luồng xử lý dữ liệu. Sơ đồ dưới đây mô tả hai luồng xử lý tương ứng:

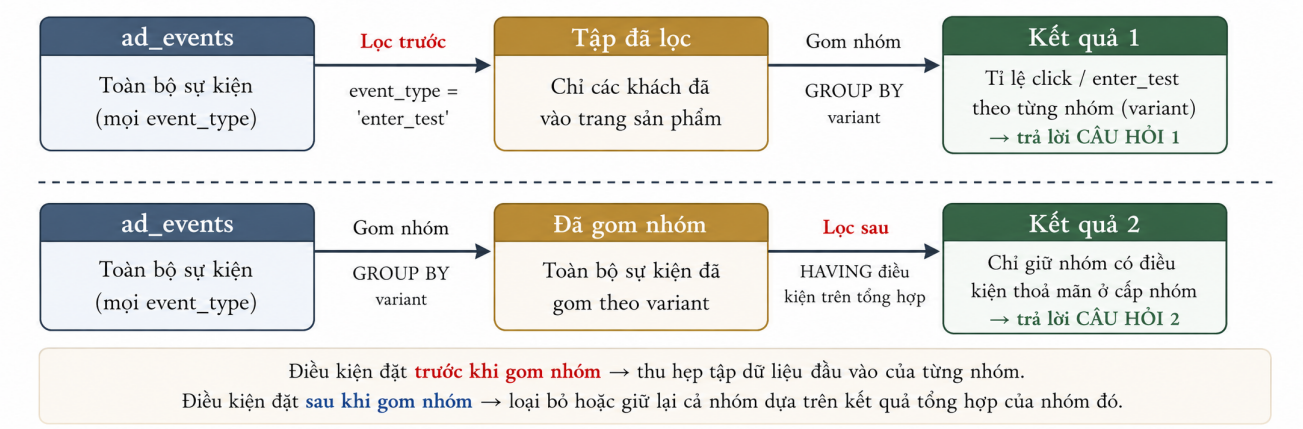

Hình 2: Hai luồng xử lý: lọc trước khi gom nhóm và lọc sau khi gom nhóm

Bạn nhận thấy một tình huống đặc biệt: nếu đặt điều kiện lọc sau khi gom nhóm để trả lời **Câu hỏi kinh doanh 1**, kết quả sẽ bị sai lệch so với việc lọc trước khi gom nhóm.

Nhận định nào giải thích đúng nhất tại sao hai luồng xử lý này không thể hoán đổi cho nhau?

A. Vì `WHERE` lọc dữ liệu ở cấp dòng trước khi tính toán, còn `HAVING` lọc ở cấp nhóm sau khi đã tổng hợp. Với Câu hỏi 1, nếu gom nhóm trước rồi mới lọc, tập khách hàng dùng làm mẫu số không còn đúng là nhóm đã `enter_test`.

B. Vì `HAVING` chỉ nên dùng với các hàm tổng hợp như `COUNT`, `SUM`, `AVG`; còn điều kiện liên quan đến `event_type` bắt buộc phải đặt trong `WHERE`. Nếu đặt sai vị trí, SQL sẽ không thực thi được truy vấn.

C. Vì sau khi `GROUP BY variant`, mỗi nhóm chỉ còn một dòng đại diện nên không thể phân biệt các loại sự kiện bên trong nhóm. Do đó mọi phép đếm theo `event_type` sau bước gom nhóm đều cho cùng một kết quả.

D. Vì `WHERE` và `HAVING` chỉ khác nhau về hiệu năng xử lý dữ liệu trung gian, không khác về ý nghĩa phân tích. Nếu điều kiện được viết tương đương, hai luồng luôn trả về cùng một kết quả.

AIO25-DS-SQL-07

Bạn viết câu lệnh sau để tính tổng doanh thu theo từng kênh bán hàng trong tháng 1/2026, chỉ giữ các kênh có tổng doanh thu lớn hơn 10000.

SQL query — tổng doanh thu theo kênh bán hàng

```
SELECT
    o.channel,
    SUM(oi.quantity * oi.unit_price) AS total_revenue
FROM orders o
INNER JOIN order_items oi
    ON o.order_id = oi.order_id
WHERE o.order_date BETWEEN "2026-01-01" AND "2026-01-31"
GROUP BY o.channel
HAVING SUM(oi.quantity * oi.unit_price) > 10000;
```

Biết rằng quan hệ giữa `orders` và `order_items` là quan hệ $1 : N$, tức một đơn hàng có thể có nhiều dòng sản phẩm.

Theo **thứ tự thực thi logic** của SQL, thứ tự nào là đúng?

A. `FROM` → `JOIN` → `WHERE` → `GROUP BY` → `HAVING` → `SELECT`.

B. `FROM` → `WHERE` → `JOIN` → `GROUP BY` → `HAVING` → `SELECT`.

C. `SELECT` → `FROM` → `JOIN` → `WHERE` → `GROUP BY` → `HAVING`.

D. `FROM` → `JOIN` → `GROUP BY` → `SELECT` → `WHERE` → `HAVING`.

AIO25-DS-SQL-08
Bạn cần tính cho từng kênh bán hàng trong tháng 1/2026:

- Tổng doanh thu từ các đơn hàng.
- Tổng số sản phẩm đã bán.

Bạn viết câu lệnh sau:

SQL query — doanh thu và số lượng bán theo kênh

```sql
SELECT
    o.channel,
    SUM(o.order_total) AS total_revenue,
    SUM(oi.quantity)   AS total_units_sold
FROM orders o
LEFT JOIN order_items oi
    ON o.order_id = oi.order_id
WHERE o.order_date BETWEEN "2026-01-01" AND "2026-01-31"
GROUP BY o.channel;
```

Biết rằng:

- Bảng `orders` có grain là 1 dòng trên 1 đơn hàng.
- Cột `o.order_total` lưu tổng tiền của cả đơn.
- Bảng `order_items` có grain là 1 dòng trên 1 sản phẩm trong đơn.
- Một đơn hàng có thể có nhiều dòng sản phẩm.

Khi chạy, `total_units_sold` đúng nhưng `total_revenue` bị phóng đại nhiều lần. Cách sửa nào là đúng nhất?

A. Thay `SUM(o.order_total)` bằng `SUM(DISTINCT o.order_total)`.

B. Thay `SUM(o.order_total)` bằng `SUM(o.order_total) / COUNT(oi.item_id)`.

C. Gom `order_items` về grain 1 dòng trên 1 đơn hàng trước khi JOIN, rồi mới tính tổng.

D. Dùng `ROW_NUMBER()` để chia nhỏ `o.order_total` trên từng dòng sản phẩm.

AIO25-DS-SQL-09

Bạn được giao tính **discount rate tổng thể** cho từng category sản phẩm.

Với mỗi dòng trong bảng `order_items`, giá trị trước giảm giá được định nghĩa là:

$$\text{pre_discount_value} = \texttt{quantity} \times \texttt{unit_price} + \texttt{discount_amount}$$

Discount rate tổng thể của một category được định nghĩa là:

$$\text{discount_rate} = \frac{\text{Tổng số tiền giảm giá}}{\text{Tổng giá trị trước giảm giá}}$$

Xét bốn cách viết SQL sau:

SQL query — so sánh các cách tính discount rate theo category

```sql
-- Option A
SELECT
    p.category,
    AVG(
        oi.discount_amount /
        (oi.quantity * oi.unit_price + oi.discount_amount)
    ) AS discount_rate
FROM order_items oi
JOIN products p
    ON oi.product_id = p.product_id
GROUP BY p.category;
-- Option B
SELECT
    p.category,
    SUM(oi.discount_amount) /
    SUM(oi.quantity * oi.unit_price + oi.discount_amount)
        AS discount_rate
FROM order_items oi
JOIN products p
    ON oi.product_id = p.product_id
GROUP BY p.category;
-- Option C
SELECT
    p.category,
    SUM(oi.discount_amount) / COUNT(*) AS discount_rate
FROM order_items oi
JOIN products p
    ON oi.product_id = p.product_id
GROUP BY p.category;
-- Option D
SELECT
    p.category,
    AVG(oi.discount_amount) / AVG(oi.quantity) AS discount_rate
FROM order_items oi
JOIN products p
    ON oi.product_id = p.product_id
```

```
GROUP BY p.category;
```

Câu lệnh nào tính đúng nhất?

A. Option A – lấy trung bình tỷ lệ từng dòng cho kết quả chính xác.

B. Option B – lấy tổng discount chia tổng giá trị trước giảm giá.

C. Option C – chia tổng discount cho số dòng để ra tỷ lệ chiết khấu.

D. Option D – chia trung bình discount cho trung bình quantity để triệt tiêu nhiễu.

AIO25-DS-SQL-10

Một nền tảng thương mại điện tử sử dụng bảng dữ liệu sau để lưu hồ sơ khách hàng. Mỗi dòng biểu diễn một khách hàng. Mã khách hàng (`customer_id`) là trường định danh chính, dùng để phân biệt khách hàng trong hệ thống. Mã bưu chính/khu vực (`zip`) được quy ước gồm đúng 6 chữ số. Ngày đăng ký (`signup_date`) ghi nhận thời điểm khách hàng tạo tài khoản và cần là một ngày hợp lệ theo định dạng `YYYY-MM-DD`. Các trường giới tính (`gender`), nhóm tuổi (`age_group`) và kênh thu hút khách hàng (`acquisition_channel`) là thông tin phân khúc; theo đặc tả của bảng này, các trường phân khúc có thể để trống.

customer_id	zip	signup_date	gender	age_group	acquisition_channel
C001	700000	2021-03-15	female	25-34	organic_search
C002	100000	2021-03-15	male	35-44	paid_search
C003	700000	2022-01-20	female	25-34	social_media
C004	200000	2021-08-09	female	45-54	email_campaign

Từ đặc tả nghiệp vụ và bảng trên, phương án nào mô tả đúng nhất **các ràng buộc dữ liệu/nghiệp vụ quan trọng**?

A. Có 4 nhóm ràng buộc: mã bưu chính/khu vực (`zip`) gồm đúng 6 chữ số; ngày đăng ký (`signup_date`) là ngày hợp lệ; mã khách hàng (`customer_id`) cần duy nhất nhưng có thể thiếu; các trường phân khúc có thể để trống.

B. Có 4 nhóm ràng buộc: ngày đăng ký (`signup_date`) là ngày hợp lệ; các trường phân khúc có thể để trống; mã khách hàng (`customer_id`) cần duy nhất và không được thiếu; mã bưu chính/khu vực (`zip`) cần duy nhất cho từng khách hàng.

C. Có 4 nhóm ràng buộc: các trường phân khúc có thể để trống; mã bưu chính/khu vực (`zip`) gồm đúng 6 chữ số; ngày đăng ký (`signup_date`) là ngày hợp lệ; mã khách hàng (`customer_id`) cần duy nhất và không được thiếu.

D. Có 4 nhóm ràng buộc: mã khách hàng (`customer_id`) cần duy nhất và không được thiếu; mã bưu chính/khu vực (`zip`) gồm đúng 6 chữ số; ngày đăng ký (`signup_date`) cần duy nhất trong bảng; các trường phân khúc có thể để trống.

AIO25-DS-SQL-11

Một hệ thống bán hàng trực tuyến sử dụng bảng dữ liệu sau để ghi nhận đơn hàng. Mỗi dòng biểu diễn một đơn hàng. Mã đơn hàng (`order_id`) là trường định danh chính, không được thiếu và không được trùng. Ngày đặt hàng (`order_date`) cần là một ngày hợp lệ theo định dạng `YYYY-MM-DD`. Mã khách hàng (`customer_id`) là thông tin bắt buộc để biết khách hàng nào đã đặt đơn. Mã bưu chính/khu vực giao hàng (`zip`) được quy ước gồm đúng 6 chữ số. Trạng thái đơn hàng (`order_status`) chỉ được nhận một trong các giá trị: `created`, `paid`, `shipped`, `delivered`, `returned`, `cancelled`.

order_id	order_date	customer_id	zip	order_status	payment_method	order_source
O1001	2022-04-18	C001	700000	paid	credit_card	organic_search
O1002	2022-04-19	C002	100000	shipped	paypal	paid_search
O1003	2022-04-20	C001	700000	delivered	cod	social_media
O1004	2022-04-21	C004	200000	cancelled	bank_transfer	email_campaign

Từ đặc tả nghiệp vụ và bảng trên, phương án nào mô tả đúng nhất **các ràng buộc dữ liệu/nghiệp vụ quan trọng**?

A. Có 5 nhóm ràng buộc: trạng thái đơn hàng (`order_status`) thuộc tập giá trị hợp lệ; mã bưu chính/khu vực giao hàng (`zip`) gồm đúng 6 chữ số; ngày đặt hàng (`order_date`) là ngày hợp lệ; mã khách hàng (`customer_id`) không được thiếu; mã đơn hàng (`order_id`) cần duy nhất và không được thiếu.

B. Có 5 nhóm ràng buộc: ngày đặt hàng (`order_date`) là ngày hợp lệ; mã đơn hàng (`order_id`) cần duy nhất và không được thiếu; mã khách hàng (`customer_id`) không được thiếu; mã bưu chính/khu vực giao hàng (`zip`) gồm đúng 6 chữ số; trạng thái đơn hàng (`order_status`) có thể nhận mọi chuỗi bất kỳ.

C. Có 5 nhóm ràng buộc: mã bưu chính/khu vực giao hàng (`zip`) gồm đúng 6 chữ số; trạng thái đơn hàng (`order_status`) thuộc tập giá trị hợp lệ; mã đơn hàng (`order_id`) cần duy nhất và không được thiếu; mã khách hàng (`customer_id`) cần duy nhất trong bảng đơn hàng; ngày đặt hàng (`order_date`) là ngày hợp lệ.

D. Có 5 nhóm ràng buộc: mã khách hàng (`customer_id`) không được thiếu; trạng thái đơn hàng (`order_status`) thuộc tập giá trị hợp lệ; mã bưu chính/khu vực giao hàng (`zip`) cần duy nhất trong bảng; ngày đặt hàng (`order_date`) là ngày hợp lệ; mã đơn hàng (`order_id`) cần duy nhất và không được thiếu.

AIO25-DS-SQL-12

Một hệ thống thương mại điện tử sử dụng bảng dữ liệu sau để ghi nhận thanh toán cho các đơn hàng. Mỗi dòng biểu diễn một bản ghi thanh toán. Theo đặc tả của bảng này, mỗi mã đơn hàng (`order_id`) chỉ được xuất hiện một lần trong bảng thanh toán. Giá trị thanh toán (`payment_value`) là số tiền khách hàng thanh toán cho đơn hàng, nên không được âm. Số kỳ trả góp (`installments`) biểu diễn số lần thanh toán và phải là số nguyên dương.

order_id	payment_method	payment_value	installments
O1001	credit_card	420000	1
O1002	paypal	650000	3
O1003	cod	780000	1
O1004	bank_transfer	180000	2

Từ đặc tả nghiệp vụ và bảng trên, phương án nào mô tả đúng nhất **các ràng buộc dữ liệu/nghiệp vụ quan trọng**?

A. Có 3 nhóm ràng buộc: giá trị thanh toán (`payment_value`) không được âm; số kỳ trả góp (`installments`) phải là số nguyên dương; mã đơn hàng (`order_id`) có thể xuất hiện nhiều lần nếu đơn hàng có nhiều phương thức thanh toán.

B. Có 3 nhóm ràng buộc: số kỳ trả góp (`installments`) phải là số nguyên dương; mã đơn hàng (`order_id`) chỉ xuất hiện một lần trong bảng; giá trị thanh toán (`payment_value`) có thể âm khi hệ thống ghi nhận hoàn tiền.

C. Có 3 nhóm ràng buộc: mã đơn hàng (`order_id`) chỉ xuất hiện một lần trong bảng; giá trị thanh toán (`payment_value`) không được âm; số kỳ trả góp (`installments`) có thể bằng 0 khi khách hàng thanh toán một lần.

D. Có 3 nhóm ràng buộc: số kỳ trả góp (`installments`) phải là số nguyên dương; giá trị thanh toán (`payment_value`) không được âm; mã đơn hàng (`order_id`) chỉ xuất hiện một lần trong bảng.

II. Data Preprocessing

Tiếp theo là 6 câu hỏi về xử lý dữ liệu Preprocessing tập trung vào xử lý dữ liệu thô ban đầu nhận được.

Thông tin dữ liệu đầu vào:

Trong 6 câu hỏi tiếp theo dữ liệu được sử dụng từ tệp `campaigns.csv` có 29 cột với 166.665 dòng trong quãng thời gian từ 2024 - 2025.

AIO25-DS-PRE-01
Trong dataset `campaigns.csv`, các cột `CTR`, `Lead_Rate`, `Conversion_Rate`, và `ROI` không phải là

dữ liệu được thu thập trực tiếp mà được **dẫn xuất từ dữ liệu thô** dựa trên pipeline marketing funnel. Pipeline này mô tả quá trình người dùng tương tác với chiến dịch marketing từ khi nhìn thấy quảng cáo đến khi tạo ra doanh thu:

$$\text{Impressions} \longrightarrow \text{Clicks} \longrightarrow \text{Leads} \longrightarrow \text{Conversions} \longrightarrow \text{Revenue}$$

Ý nghĩa của các metric được mô tả như sau:

- **CTR (Click-Through Rate)**: phản ánh mức độ hấp dẫn của quảng cáo thông qua khả năng chuyển đổi lượt hiển thị thành lượt nhấp.
- **Lead Rate:** đo lường khả năng chuyển đổi người dùng đã nhấp quảng cáo thành khách hàng tiềm năng.
- **Conversion Rate:** đánh giá mức độ hiệu quả trong việc chuyển đổi khách hàng tiềm năng thành khách hàng thực tế.
- **ROI (Return on Investment):** phản ánh hiệu quả tài chính của chiến dịch bằng cách so sánh doanh thu tạo ra với chi phí đầu tư.

Việc sử dụng các metric dẫn xuất này giúp chuẩn hóa quá trình đánh giá hiệu suất chiến dịch và hỗ trợ phân tích hiệu quả ở từng giai đoạn của marketing funnel. Bốn nhân viên phân tích dữ liệu mỗi người viết lại **một** công thức theo cách hiểu của mình. Dựa trên mô ta trên người nào viết **SAI**?

A. **An:** `df["CTR"] = df["Clicks"] / df["Impressions"]`
(Tỉ lệ người click trên tổng số lần hiển thị quảng cáo)

B. **Bình:** `df["Conversion_Rate"] = df["Conversions"] / df["Clicks"]`
(Tỉ lệ chuyển đổi tính trên số người đã click vào quảng cáo)

C. **Châu:** `df["Lead_Rate"] = df["Leads"] / df["Clicks"]`
(Tỉ lệ người để lại thông tin trên số người đã click)

D. **Dũng:** `df["ROI"] = (df["Revenue"] - df["Total_Spend"]) / df["Total_Spend"]` *(Lợi nhuận ròng trên mỗi đồng chi tiêu quảng cáo)*

Gợi ý phân tích: *Mỗi chỉ số đo tỉ lệ chuyển đổi* ***giữa hai bước liền kề*** *trong funnel.* `Conversion_Rate` *đo bao nhiêu lead trở thành conversion không phải bao nhiêu click trở thành conversion.*

AIO25-DS-PRE-02

Tệp `campaigns.csv` (166.665 dòng) có cột `Campaign_Type` gồm 5 loại: *Email, Paid Ads, Social Media, SEO, Influencer*. Sau khi nhập từ hệ thống ngoài, một số dòng bị thêm khoảng trắng đầu/cuối chuỗi (e.g. `"Email"`, `"Paid Ads "`). Hoàn thành đoạn code sau để trả lời câu hỏi.

Python - whitespace_fix.py

```python
import pandas as pd

df = pd.read_csv('campaigns.csv')

# Simulate: inject khoảng trắng vào 1/7 và 1/11 dòng
df_dirty = df. copy()
mask1 = df_dirty.index % 7 == 0
mask2 = df_dirty.index % 11 == 0
df_dirty.loc[mask1, 'Campaign_Type'] += ' '
df_dirty.loc[mask2, 'Campaign_Type'] = ' ' + df_dirty.loc[mask2, 'Campaign_Type']

#  Code A: groupby KHÔNG xử lý
result_a  = df_dirty.groupby('Campaign_Type')['Revenue'].sum()
unique_a  = df_dirty['Campaign_Type'].nunique()

#  Code B: strip() rồi groupby
df_clean = df_dirty. copy()
df_clean['Campaign_Type'] = df_clean['Campaign_Type']. str.strip()
result_b  =  # tính tổng group by 'Campaign Type'['Revenue']
unique_b  = #nunique Campaign Type

print(f"Code A  số nhóm Campaign_Type: {unique_a}")
print(f"Code B  số nhóm Campaign_Type: {unique_b}")
```

Kết quả nào mô tả đúng sự khác biệt giữa Code A và Code B?

A. Python tự động bỏ khoảng trắng thừa nên không có sự khác biệt.

B. Code A tách nhóm phân mảnh thành ∼20 nhóm; Code B thu về đúng 5 nhóm.

C. Code B làm hỏng dữ liệu vì `.strip()` xóa cả khoảng trắng giữa chuỗi.

D. Hàm `groupby` tự xử lý khoảng trắng nên cả hai cho kết quả giống nhau.

AIO25-DS-PRE-03

CTR (Click-Through Rate) = Clicks / Impressions. Khi tổng hợp CTR theo từng loại chiến dịch (Campaign Type), có 2 cách phổ biến:

(1) Trung bình cộng CTR của từng nhóm (*Simple Average CTR*)

(2) Tổng Clicks chia tổng Impressions (*Weighted CTR*)

Campaign Type	Total Impressions	Total Clicks	Avg CTR	Weighted CTR
Email	1.840.785.851	156.471.621	8,48%	8,50%
Influencer	1.837.177.162	156.531.226	8,53%	8,52%
Paid Ads	1.838.406.238	156.264.327	8,51%	8,50%
SEO	1.828.167.042	154.817.943	8,47%	8,47%
Social Media	1.832.180.954	156.301.670	8,53%	8,53%

Python - ctr_aggregation.py

```python
if 'CTR' not in df.columns:
    df['CTR'] = df['Clicks'] / df['Impressions']

# Group theo Campaign_Type
result = (
    df.groupby('Campaign_Type')
      .agg(
          Total_Impressions=('Impressions', 'sum'),
          Total_Clicks=('Clicks', 'sum'),
          Avg_CTR=('CTR', 'mean')
      )
)

# Weighted Average CTR
result['Weighted_CTR'] = #Hãy viết code để chạy kết quả

# Đổi sang %
result['Avg_CTR'] = (result['Avg_CTR'] * 100).round(2)
result['Weighted_CTR'] = (result['Weighted_CTR'] * 100).round(2)

print(result.reset_index())

# Trung bình cộng CTR giữa các nhóm
simple_avg = #Hãy viết code để chạy kết quả

# Weighted CTR toàn bộ dataset
weighted_avg = (
    result['Total_Clicks'].sum()
    / result['Total_Impressions'].sum()
) * 100

print(f"Simple AVG CTR:   {simple_avg:.2f}%")
print(f"Weighted AVG CTR: {weighted_avg:.2f}%")
```

Từ đặc trưng dữ liệu cho bảng trên, nhận định nào phản ánh đúng bản chất của hai phương pháp tính CTR tổng hợp?

A. Simple Average luôn phản ánh chính xác hiệu quả toàn bộ dataset.

B. Weighted CTR luôn lớn hơn Simple Average CTR.

C. Cả hai cách đều có thể sử dụng tuỳ mục đích phân tích.

D. Weighted CTR không phụ thuộc vào số lượng impressions.

AIO25-DS-PRE-04

Cột `Campaign_Date` lưu ngày chạy chiến dịch. Để mã hoá tính mùa vụ (*seasonality*) cho mô hình dự báo, ta tạo **Fourier features** từ ngày trong năm và ngày trong tuần.

Python - Fourier.py

```python
import numpy as np, pandas as pd

df['Campaign_Date'] = pd.to_datetime(df['Campaign_Date'])
df['day_of_year']   = df['Campaign_Date'].dt.dayofyear
df['day_of_week']   = df['Campaign_Date'].dt.dayofweek

# Seasonality nam (chu ky 365 ngay)
df['sin_year_k1'] = np.sin(2 * np.pi * 1 * df['day_of_year'] / 365)
df['cos_year_k1'] = np.cos(2 * np.pi * 1 * df['day_of_year'] / 365)
df['sin_year_k2'] = np.sin(2 * np.pi * 2 * df['day_of_year'] / 365)
df['cos_year_k2'] = np.cos(2 * np.pi * 2 * df['day_of_year'] / 365)

# Seasonality tuan (chu ky 7 ngay)
df['sin_week_k1'] = np.sin(2 * np.pi * 1 * df['day_of_week'] / 7)
```

Mục đích chính của Fourier features và công thức tạo `sin_year_k1` là gì?

A. Chuẩn hoá giá trị ngày về [0, 1] để tránh scale lớn; `sin_year_k1 = day_of_year / 365`

B. Mã hoá tính tuần hoàn của thời gian để mô hình học được seasonality;
`sin_year_k1 = np.sin(2 * np.pi * 1 * day_of_year / 365)`

C. Thay thế cột `Campaign_Date` dạng string bằng số nguyên; `sin_year_k1 = int(Campaign_Date)`

D. Tạo dummy variable cho từng tháng trong năm; `pd.get_dummies(df["month"])`

AIO25-DS-PRE-05

Khi xử lý giá trị NULL trong dataset, một framework phổ biến phân loại theo **tỉ lệ missing** và áp dụng chiến lược tương ứng theo nhóm `Brand`.

Python - missing.py

```python
import numpy as np, pandas as pd

def handle_nulls(df, group_col='Brand'):
    result = df. copy()
    numeric_cols = df.select_dtypes(include=[np.number]).columns

    for col in numeric_cols:
        null_rate = df[col].isnull().mean()

        if null_rate == 0:
            continue                                # khong can xu ly

        elif null_rate < 0.05:                      # < 5%: Drop rows
            result = result.dropna(subset=[col])

        elif null_rate < 0.30:                      # 5-30%: Group median impute
            result[col] = result.groupby(group_col)[col].transform(
                lambda x: x.fillna(x.median())
            )

        elif null_rate < 0.60:                      # 30-60%: Flag + global median
            result[f'{col}_missing'] = result[col].isnull().astype(int)
            result[col] = result[col].fillna(result[col].median())

        else:                                       # > 60%: Drop column
            result = result.drop(columns=[col])

    return result
```

Theo framework trên, ánh xạ **tỉ lệ missing** → **chiến lược** nào là **đúng**?

A. $< 5\%$: Drop rows, 5–30%: Group-median impute, 30–60%: Flag + global median, $> 60\%$: Drop column

B. $< 10\%$: Drop rows, 10–50%: Mean impute, 50–80%: KNN impute, $> 80\%$: Drop column

C. $< 5\%$: Mean impute, 5–30%: Drop rows, 30–60%: Drop column, $> 60\%$: Flag + global median

D. $< 20\%$: Forward-fill, 20–50%: Group mean, 50–70%: Flag + mean, $> 70\%$: Drop column

AIO25-DS-PRE-06

Khi xây dựng mô hình dự báo `ROI` với **horizon = 60 ngày**, một kỹ sư tạo lag feature `ROI_lag7` (giá trị ROI của 7 ngày trước).

Python - ROI.py

```python
import pandas as pd

# VAN DE: lag 7 ngay khi horizon = 60 ngay
df['ROI_lag7'] = df.groupby('Brand')['ROI'].shift(7)
# De du bao t+60, model can ROI tai t+60-7 = t+53
# Nhung t+53 chua xay ra luc du bao --> DATA LEAKAGE!

#  Giai phap an toan
# Rolling statistics voi shift >= horizon dam bao an toan
df['ROI_roll30_mean'] = df.groupby('Brand')['ROI'].transform(
    lambda x: x.shift(60).rolling(30).mean()
)
df['ROI_roll30_std'] = df.groupby('Brand')['ROI'].transform(
    lambda x: x.shift(60).rolling(30).std()
)
# Ket hop Fourier features (sin_year_k1, ...) --> khong gay leakage
```

Feature	Cần dữ liệu tại	Horizon = 60d	An toàn?
`ROI_lag7`	$t + 53$	Chưa có tại thời điểm t	**Không**
`roll(30).shift(60)`	$\leq t$	Chỉ dùng dữ liệu quá khứ	**Có**
Fourier features	N/A	Hàm tất định của ngày	**Có**

Bảng 3: So sánh lag feature vs. rolling + Fourier khi horizon = 60 ngày

Lý do nào giải thích đúng tại sao `ROI_lag7` gây **data leakage** khi horizon = 60 ngày và giải pháp thay thế phù hợp là gì?

A. `lag7 < horizon(60)`: model sẽ dùng giá trị tương lai $t + 53$ chưa tồn tại lúc dự báo; thay bằng `rolling(30).shift(60)` kết hợp Fourier features.

B. Lag feature luôn gây leakage bất kể horizon; chỉ dùng Fourier features là đủ cho mọi bài toán dự báo.

C. `lag7` ổn khi horizon = 60 vì $60 > 7$; chỉ cần thêm regularisation L2 để tránh overfitting.

D. Đổi từ `ROI_lag7` sang `ROI_lag60` là đủ, không cần rolling statistics hay Fourier features.

III. Data Analysis

Các câu hỏi tiếp theo trong phần này tập trung vào phân tích dữ liệu Marketing, Doanh thu và Vận hành E-commerce.

Bối cảnh chung:

Tệp `exam_campaigns.csv` ghi nhận 55.000 chiến dịch quảng cáo. Mỗi dòng tương ứng với một chiến dịch (campaign) bao gồm các cột sau:

`Cột`	**Ý nghĩa**
`Campaign_ID`	Mã định danh duy nhất
`Campaign_Type`	Loại chiến dịch: Email, Paid Ads, Social Media, SEO, Influencer
`Impressions`	Số lần quảng cáo hiển thị trên màn hình người dùng
`Clicks`	Số lần người dùng bấm vào quảng cáo
`Leads`	Số khách hàng để lại thông tin liên hệ
`Conversions`	Số đơn hàng được thanh toán thành công
`Revenue`	Tổng doanh thu phát sinh
`Acquisition_Cost`	Chi phí trung bình để thu về một đơn hàng
`Date`	Ngày triển khai chiến dịch (dd-mm-yyyy)

Bảng 4: Mô tả các cột trong tệp `exam_campaigns.csv`

Tệp `exam_sales.csv` ghi nhận báo cáo doanh thu 50 ngày liên tiếp:

`Cột`	**Ý nghĩa**
`Date`	Ngày giao dịch
`Revenue`	Tổng doanh thu ghi nhận
`COGS`	Vốn gốc sinh ra doanh thu (Cost of Goods Sold)

Bảng 5: Mô tả các cột trong tệp `exam_sales.csv`

Quy định chung:

- **Lãi gộp (Gross Profit):** Revenue trừ COGS.
- **Biên lãi gộp (Gross Margin):** Lãi gộp chia cho Revenue, tính theo phần trăm. Khi COGS lớn hơn Revenue, biên lãi gộp âm.

AIO25-DS-DA-01
Khai phá dữ liệu (EDA)

Trước khi phân tích sâu, bước đầu tiên là **EDA (Exploratory Data Analysis : Khai phá dữ liệu)**: xem xét phân bố, phát hiện giá trị thiếu và các bất thường. Dưới đây là 4 đoạn code Python (P1 đến P4) và 4 mục đích kiểm tra (Q1 đến Q4):

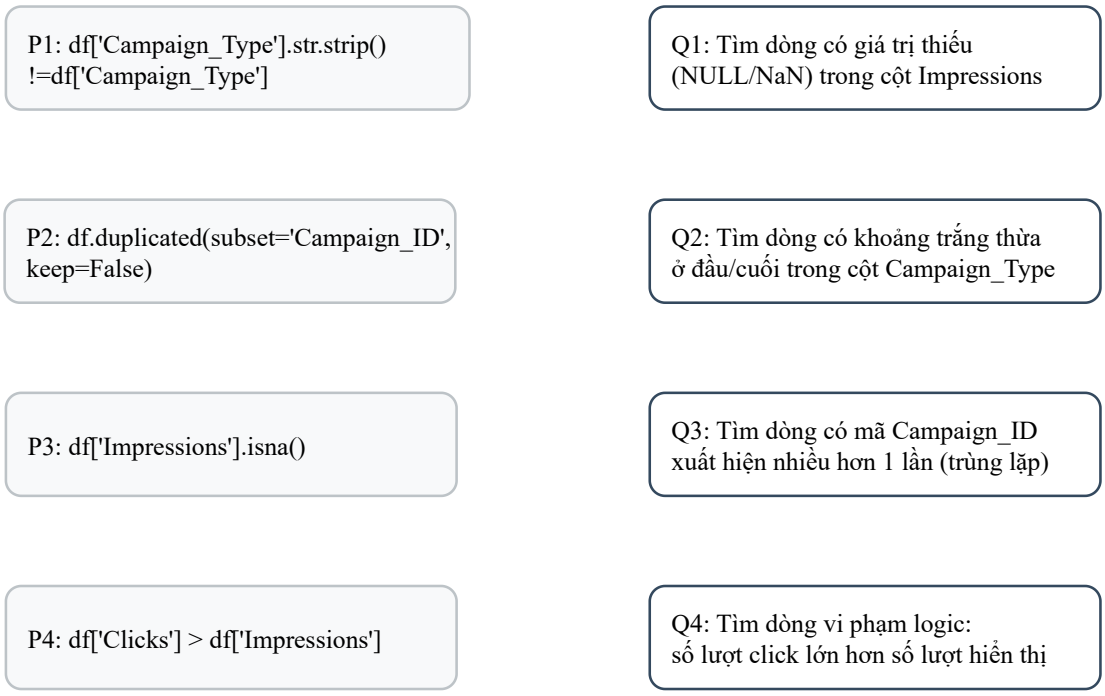

Hình 3: Ghép code EDA (P1–P4) với mục đích kiểm tra (Q1–Q4)

Phương án nào ghép đúng từng đoạn code với mục đích kiểm tra tương ứng?

A. P1-Q1, P2-Q2, P3-Q3, P4-Q4

B. P1-Q2, P2-Q3, P3-Q1, P4-Q4

C. P1-Q4, P2-Q1, P3-Q2, P4-Q3

D. P1-Q3, P2-Q4, P3-Q1, P4-Q2

AIO25-DS-DA-02
Xử lý dữ liệu vi phạm logic

Dữ liệu marketing tuân theo quy tắc phễu: **Impressions** (Lượt hiển thị quảng cáo) $\geq$ **Clicks** (Lượt bấm vào quảng cáo) $\geq$ **Leads** (Khách hàng tiềm năng để lại thông tin liên hệ) $\geq$ **Conversions** (Lượt chuyển đổi/đơn hàng thanh toán thành công). Đây là nguyên lý tất yếu vì người dùng phải thấy quảng cáo trước khi bấm, bấm vào trước khi để lại thông tin, và để lại thông tin trước khi mua hàng.

Kiểm tra phát hiện 220 dòng có số Clicks lớn hơn số Impressions. Đây là dữ liệu vi phạm logic thực tế.

Cách xử lý nào tối ưu nhất?

A. Gán Impressions bằng Clicks.

B. Gán Clicks bằng Impressions.

C. Xóa các dòng này.

D. Giữ nguyên.

AIO25-DS-DA-03
Tính chỉ số CTR (Click-Through Rate)

CTR (Click-Through Rate Tỷ lệ lượt bấm khi xem quảng cáo) tính bằng Clicks chia cho Impressions, đo lường tỷ lệ người dùng bấm vào quảng cáo sau khi nhìn thấy.

Chiến dịch	Impressions	Clicks	CTR
Camp A	100.000	8.000	8,0%
Camp B	2.000	400	20,0%
Camp C	98.000	8.820	9,0%

Bảng 6: Dữ liệu Impressions, Clicks và CTR của ba chiến dịch mẫu

Hai phương pháp tính CTR tổng hợp cho tất cả chiến dịch:

- **Cách 1 (Trung bình cộng):**

$$\frac{8{,}0\% + 20{,}0\% + 9{,}0\%}{3} = \mathbf{12{,}3}\%$$

- **Cách 2 (Weighted Average – Trung bình có trọng số):**

$$\frac{8.000 + 400 + 8.820}{100.000 + 2.000 + 98.000} = \frac{17.220}{200.000} = \mathbf{8{,}6}\%$$

Từ đặc trưng dữ liệu trong bảng trên, nhận định nào phản ánh đúng bản chất của hai phương pháp tính CTR tổng hợp cho trường hợp này?

A. Cách 1 là phương pháp chính xác.

B. Cách 2 là phương pháp chính xác.

C. Cả hai cách đều có thể sử dụng được.

D. Cả hai cách đều cho kết quả sai lệch.

AIO25-DS-DA-04
Lựa chọn Chart phù hợp

Trình bày số liệu đòi hỏi lựa chọn chart phù hợp với từng câu hỏi phân tích. Dưới đây là 4 câu hỏi thực tế (H1 đến H4) và 4 dạng chart (G1 đến G4).

(Lưu ý: **ROI** Return on Investment/Tỷ suất hoàn vốn, đo lường mức độ sinh lời của mỗi đồng chi phí bỏ ra; **Campaign** Chiến dịch quảng cáo, dự án)

H1: Ngân sách đang được phân bổ cho từng loại campaign (Email, Paid Ads,...) theo tỷ trọng nào?

H2: Doanh thu có xu hướng tăng hay giảm theo thời gian?

H3: Loại campaign nào mang lại ROI cao nhất?

H4: Trong 10 campaign chi tiêu lớn nhất, campaign nào đang lỗ (ROI < 0)?

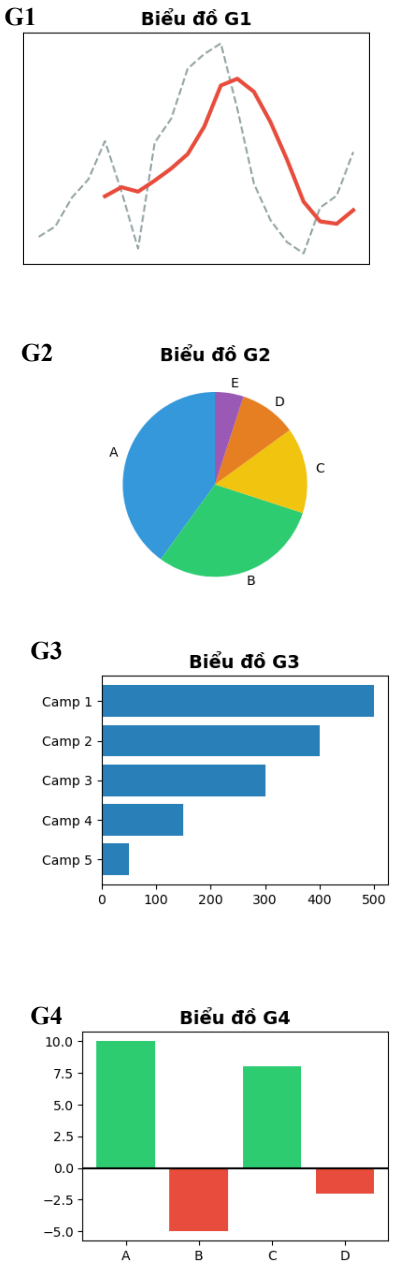

Hình 4: Ghép câu hỏi phân tích (H1–H4) với loại chart phù hợp (G1–G4)

Thứ tự ghép nối nào thể hiện sự lựa chọn chart hợp lý nhất?

A. H1-G2, H2-G1, H3-G3, H4-G4

B. H1-G1, H2-G3, H3-G4, H4-G2

C. H1-G3, H2-G1, H3-G2, H4-G4

D. H1-G2, H2-G4, H3-G1, H4-G3

AIO25-DS-DA-05
Insight từ Marketing Funnel

Marketing Funnel (Phễu Marketing) mô tả hành trình của người dùng qua 4 giai đoạn:

1. **Impressions:** Quảng cáo hiển thị trên màn hình.
2. **Clicks:** Người dùng bấm vào xem chi tiết.
3. **Leads:** Người dùng điền thông tin liên hệ.
4. **Conversions:** Đơn hàng được thanh toán.

Sau mỗi giai đoạn, một phần người dùng rời bỏ.

Phân tích `exam_campaigns.csv` cho ra 2 báo cáo:

Báo cáo 1: Marketing Funnel

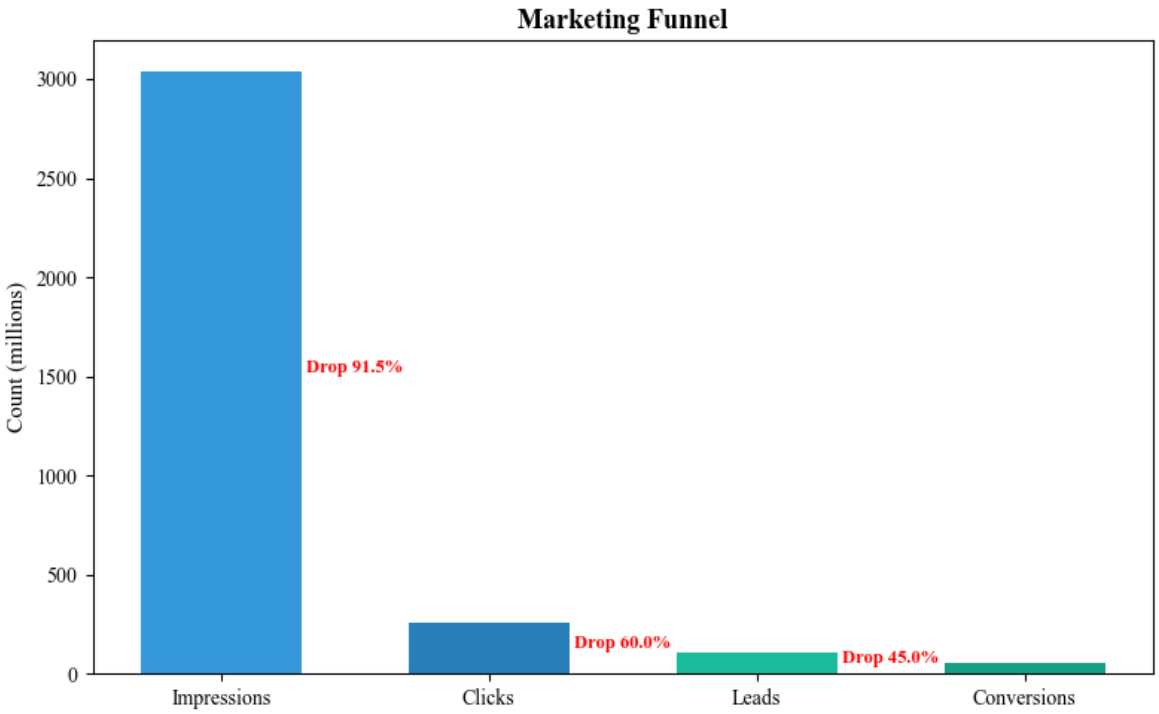

Hình 5: Marketing Funnel: tỷ lệ giữ chân và drop rate theo từng giai đoạn

Giai đoạn	Tổng số	Giữ lại so với bước trước	Drop rate
Impressions	~3 tỷ	100%	(điểm bắt đầu)
Clicks	~259 triệu	8,5%	**91,5%**
Leads	~104 triệu	40,0%	60,0%
Conversions	~57 triệu	55,0%	45,0%

Bảng 7: Tỷ lệ giữ lại và drop rate qua từng giai đoạn Marketing Funnel

Báo cáo 2: ROI (Return on Investment Tỷ suất hoàn vốn, đo lường mức độ sinh lời của mỗi đồng chi phí bỏ ra) theo loại chiến dịch

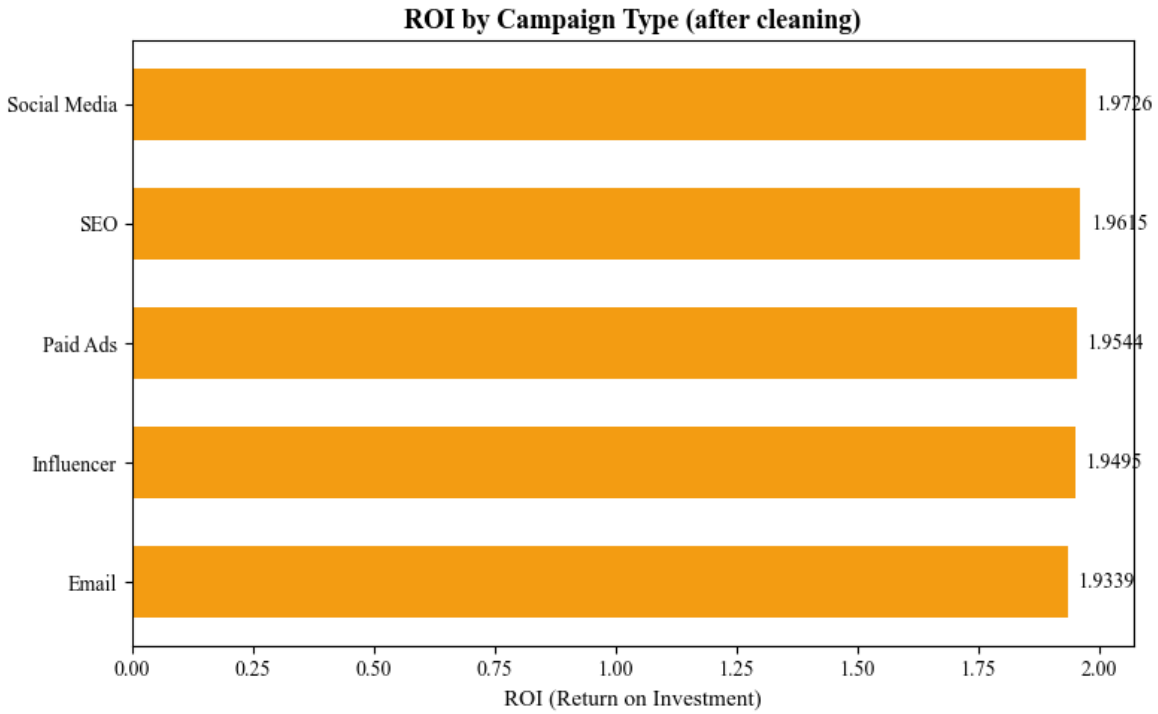

Hình 6: ROI theo từng loại chiến dịch quảng cáo

Thông tin bổ sung: Kênh Influencer (Kênh tiếp thị qua người nổi tiếng) có Revenue/Conversion (Doanh thu bình quân trên mỗi lượt chuyển đổi/đơn hàng) cao nhất (1.247), tiếp theo là Social Media (1.198).

Kết luận nào phù hợp nhất với dữ liệu trên?

A. Ngừng triển khai Influencer, gộp toàn bộ ngân sách sang Social Media.

B. Giữ nguyên 100% ngân sách và chiến lược hiện tại.

C. Giữ hoạt động Influencer, ưu tiên tối ưu nội dung thông điệp quảng cáo.

D. Tập trung tung mã giảm giá mạnh đặc biệt ở giai đoạn Leads.

AIO25-DS-DA-06
Đọc kết quả thống kê Gross Margin (Biên lãi gộp)

Phân tích tệp `exam_sales.csv`, tính Gross Margin (Biên lãi gộp là tỷ lệ phần trăm lợi nhuận giữ lại sau khi trừ giá vốn) 50 ngày:

```
df['margin_pct'] = (df['Revenue'] - df['COGS']) / df['Revenue'] * 100
print(df['margin_pct'].describe())
```

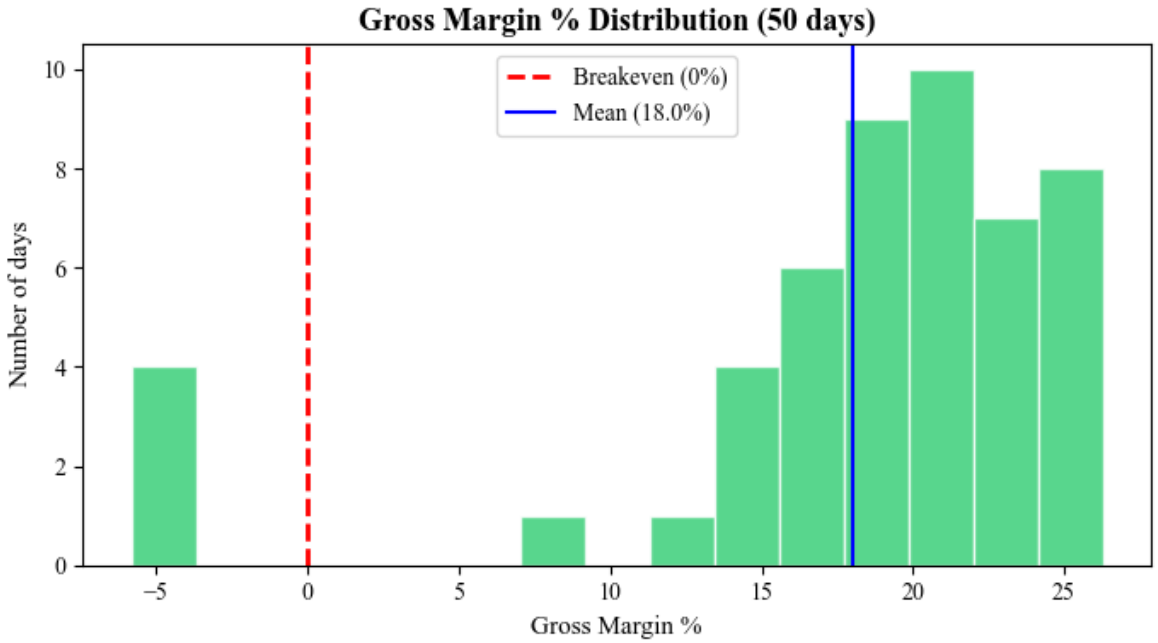

Hình 7: Phân bố Gross Margin (%) qua 50 ngày bán hàng

Chỉ số	Giá trị
count (số lượng dữ liệu)	50
mean (giá trị trung bình)	18,0%
std (độ lệch chuẩn)	7,9%
min (giá trị nhỏ nhất)	−5,8%
25% (tứ phân vị thứ nhất)	16,6%
50% (median - trung vị)	19,5%
75% (tứ phân vị thứ ba)	23,0%
max (giá trị lớn nhất)	26,3%

Bảng 8: Kết quả describe() Gross Margin qua 50 ngày

Phát biểu nào đánh giá đúng nhất kết quả trên?

A. Giá trị âm ($-5{,}8\%$) là dữ liệu lỗi kỹ thuật cần xóa bỏ.

B. Giá trị Mean 18% cảnh báo công ty hiện đang bị thua lỗ dài hạn.

C. Giá trị Mean và Median thể hiện trạng thái hệ thống hoàn toàn ổn định.

D. Giá trị âm ($-5{,}8\%$) là tín hiệu rủi ro kinh doanh cần điều tra.

AIO25-DS-DA-07
Bốn cấp độ Analytics

Phân tích dữ liệu chuyên nghiệp có 4 cấp độ từ đơn giản đến phức tạp:

1. **Descriptive Analytics** (Phân tích Mô tả)
2. **Diagnostic Analytics** (Phân tích Chẩn đoán)
3. **Predictive Analytics** (Phân tích Dự đoán)
4. **Prescriptive Analytics** (Phân tích Đề xuất, Khuyến nghị)

Nhận định dưới đây áp dụng vào bài toán Gross Margin (Biên lãi gộp):

Mã	Nhận định
F1	"Qua 50 ngày khảo sát, Gross Margin trung bình đạt 18%. Giá trị thấp nhất là −5,8% và cao nhất là 26,3%."
F2	"Sau khi tra cứu lịch sử, 3 ngày có biên lãi âm trùng khớp với đợt nhà cung cấp tăng giá nguyên vật liệu đột ngột."
F3	"Dựa vào tốc độ chi phí tăng hiện tại, Gross Margin kỳ tới có nguy cơ giảm xuống dưới 10%."
F4	"Yêu cầu bộ phận IT lập trình hệ thống tự động gửi email cảnh báo mỗi khi COGS vượt 85% doanh thu trong ngày."

Bảng 9: Bộ nhận định F1–F4 áp dụng vào bài toán Gross Margin (Biên lãi gộp)

Đáp án nào ghép đúng từng nhận định với cấp độ analytics tương ứng?

A. F1: Descriptive, F2: Diagnostic, F3: Predictive, F4: Prescriptive

B. F1: Diagnostic, F2: Descriptive, F3: Prescriptive, F4: Predictive

C. F1: Descriptive, F2: Predictive, F3: Diagnostic, F4: Prescriptive

D. F1: Prescriptive, F2: Diagnostic, F3: Descriptive, F4: Predictive

Câu 8 đến Câu 16 tập trung vào kỹ năng nâng cao và phân tích vận hành thương mại điện tử.

Bối cảnh chung:

Câu 8 đến Câu 11 sử dụng dữ liệu mẫu nhỏ được cung cấp trực tiếp trong từng câu hỏi.

Câu 12 đến Câu 16 sử dụng bộ dữ liệu vận hành sàn thương mại điện tử gồm 3 bảng:

Bảng	Các cột chính
`orders.csv`	`order_id` (mã đơn), `order_date` (ngày đặt), `customer_id`, `Order_Total` (tổng tiền đơn hàng)
`order_items.csv`	`order_id`, `product_id` (mã sản phẩm), `quantity` (số lượng), `unit_price` (đơn giá từng sản phẩm)
`shipments.csv`	`order_id`, `ship_date` (ngày xuất kho), `delivery_date` (ngày giao đến tay khách)

Bảng 10: Cấu trúc dữ liệu vận hành e-commerce (Câu 12–16)

AIO25-DS-DA-08
Heatmap và Seasonality (Quy luật mùa vụ)

Heatmap thể hiện giá trị theo hai chiều bằng màu sắc: hàng ngang là các năm, cột dọc là tháng trong năm. Màu xanh/đậm biểu thị tăng trưởng dương, màu đỏ biểu thị tăng trưởng âm.

Bảng dưới đây là heatmap tốc độ tăng trưởng doanh số (% Growth) từng tháng:

Năm	T1	T2	T3	T4	T5	T6	T7	T8	T9	T10	T11	T12
2023	−8%	−3%	+5%	+2%	+1%	−6%	−4%	+3%	+12%	+15%	+25%	+8%
2024	−10%	−5%	+4%	+3%	+2%	−7%	−3%	+4%	+10%	+18%	+22%	+6%

Bảng 11: Heatmap: tốc độ tăng trưởng doanh số (% Growth) theo từng tháng, 2023–2024

Nhận xét nào mô tả đúng quy luật thể hiện trong heatmap trên?

A. Doanh số tăng trưởng đều đặn tuyến tính, không có diễn biến mùa vụ.

B. Dữ liệu hai năm bị lệch biên độ nên không thể khẳng định có mùa vụ.

C. Có thể quan sát quy luật mùa vụ (seasonality) lặp lại rõ ràng suốt hai năm.

D. Giảm sút mạnh vào tháng 12 chứng tỏ thị trường hoàn toàn mất sức mua.

AIO25-DS-DA-09
Tính ROI (Return on Investment) và xử lý trường hợp đặc biệt

ROI (Return on Investment Tỷ suất hoàn vốn) đo lường hiệu quả sinh lời của một chiến dịch so với chi phí bỏ ra, cho biết cứ 1 đồng chi phí quảng cáo thì thu về thêm bao nhiêu đồng lợi nhuận dọc theo phễu chuyển đổi.

Bảng kết quả 4 chiến dịch quảng cáo:

Chiến dịch	Impressions	Clicks	Conversions	Revenue	Cost/Conversion
Camp A	80.000	6.400	1.200	960.000	150
Camp B	50.000	7.500	900	200.000	650
Camp C	120.000	4.800	0	0	350
Camp D	30.000	4.500	1.500	1.800.000	80

Bảng 12: Kết quả 4 chiến dịch quảng cáo: Impressions, Clicks, Conversions, Revenue và Cost

Công thức tính ROI:

- **Conversions**: số lượt chuyển đổi hoặc số đơn hàng.
- **Revenue**: tổng doanh thu tạo ra từ các lượt chuyển đổi.
- **Cost**: tổng chi phí quảng cáo.
- **Lợi nhuận** = Revenue − Cost
- **ROI** = $\dfrac{Revenue - Cost}{Cost}$

Phân tích nào đúng nhất khi áp dụng công thức trên vào bảng dữ liệu?

A. Camp B đang lỗ. Camp C không sinh chuyển đổi nên kích hoạt lỗi chia cho 0.

B. Camp A đang lỗ do hụt chi tiêu trầm trọng hơn so với phần vốn đầu tư.

C. Camp D đang hoạt động lý tưởng và không có bất kỳ dấu hiệu bất thường.

D. Camp C rơi vào trạng thái hòa vốn nên thuật toán lập trình tự động bằng 0.

AIO25-DS-DA-10
Phân tích Retention Cohort Matrix

Retention Cohort Matrix (Ma trận giữ chân khách hàng theo nhóm) cho biết trong số khách hàng mua lần đầu ở tháng T, có bao nhiêu phần trăm quay lại mua ở các tháng tiếp theo. Mỗi hàng là một nhóm khách hàng (Cohort tập hợp người dùng có chung thời điểm mua hàng đầu tiên) theo tháng mua đầu tiên.

Cohort	Tháng 0	Tháng 1	Tháng 2	Tháng 3	Tháng 4
T1	100%	12%	8%	7%	6%
T2	100%	11%	7%	6%	5%
T3	100%	15%	10%	9%	8%
T4	100%	13%	9%	7%	*Chưa có dữ liệu*
T5	100%	10%	6%	*Chưa có dữ liệu*	*Chưa có dữ liệu*

Bảng 13: Retention Cohort Matrix: tỷ lệ khách hàng quay lại theo từng tháng ("Chưa có dữ liệu" = thời gian chưa đủ để quan sát)

Chiến lược nào phù hợp nhất với dữ liệu Retention Matrix trên?

A. Tỷ lệ mất khách đã ổn định dần sau tháng 2 nên không cần chạy remarketing.

B. Tất cả các cohort đều giữ chân rất kém nên việc phân tích retention là vô ích.

C. Cohort T5 có tỷ lệ giữ chân thấp nhất nên đây là vùng duy nhất báo động.

D. Giai đoạn rời bỏ mạnh nhất là 30 ngày đầu, cần ưu tiên remarketing ngay.

AIO25-DS-DA-11
Thứ tự đúng của quy trình Analytics

Quy trình analytics chuyên nghiệp có thứ tự logic chặt chẽ. Nếu đảo ngược bước, kết quả sẽ sai lệch hoàn toàn (ví dụ: tính KPI trước khi làm sạch dữ liệu).

Dưới đây là 6 bước chưa được sắp xếp:

Bước	Mô tả
①	Tính toán các chỉ số KPI (Key Performance Indicators)
②	Đưa ra khuyến nghị và chiến lược dựa trên báo cáo
③	Khai phá dữ liệu ban đầu (EDA): xem phân bố, phát hiện giá trị thiếu và bất thường
④	Trực quan hóa dữ liệu bằng chart phù hợp
⑤	Làm sạch dữ liệu (Data Cleaning): xử lý lỗi, giá trị thiếu, ngoại lệ
⑥	Đọc và diễn giải insight từ các chart đã vẽ

Bảng 14: Sáu bước của quy trình analytics (chưa sắp xếp)

Thứ tự thực hiện đúng là gì?

A. ③ → ⑤ → ① → ④ → ⑥ → ②

B. ⑤ → ③ → ① → ④ → ⑥ → ②

C. ③ → ① → ⑤ → ④ → ⑥ → ②

D. ① → ③ → ⑤ → ④ → ⑥ → ②

AIO25-DS-DA-12
Data Duplication khi JOIN bảng

Sinh viên thực hiện LEFT JOIN bảng `orders` (mỗi dòng là một đơn hàng) với bảng `order_items` (mỗi dòng là một sản phẩm trong đơn hàng). Quan sát kết quả được minh hoạ dưới đây:

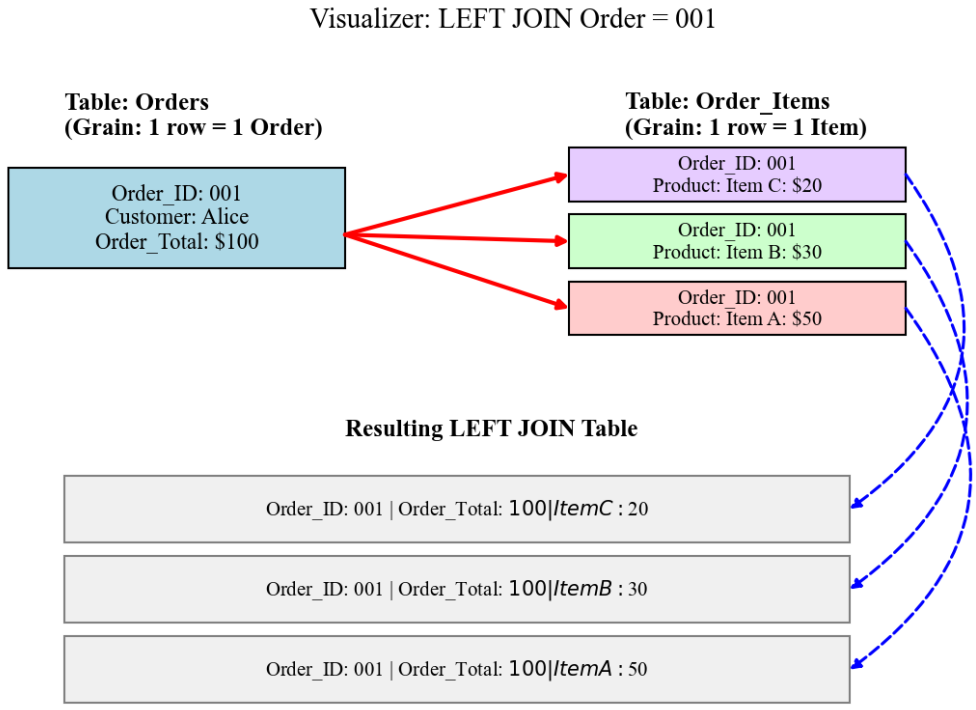

Hình 8: Minh họa Data Duplication khi LEFT JOIN bảng orders và order_items có Grain khác nhau

Kết quả cho thấy tổng doanh thu tính được là $300 thay vì giá trị thực tế $100.

Nguyên nhân gốc rễ gây ra sai lệch này là gì?

A. LEFT JOIN sinh ra lỗi Null ở vế phải nên hệ thống tự động suy ra số 300.

B. Hệ thống gặp lỗi nhân bản dữ liệu (Data Duplication).

C. SQL báo lỗi tính toàn vẹn khóa ngoại (Foreign Key) đứt gãy luồng xử lý.

D. Sử dụng sai hàm trung bình (AVERAGE) gây tự động tách nhỏ và cộng gộp.

AIO25-DS-DA-13
Chẩn đoán Bottleneck trong Shipping

Đội Customer Service ghi nhận khách hàng phàn nàn do Total Lead Time kéo dài 6 ngày. Hệ thống chia Total Lead Time thành hai thành phần:

1. **Processing_Days:** Từ lúc đặt đơn (`order_date`) đến lúc xuất kho (`ship_date`).
2. **Transit_Days:** Từ lúc xuất kho (`ship_date`) đến lúc giao hàng (`delivery_date`).

Tính trung bình (Mean) từ dữ liệu: `Processing_Days` = 4,5 ngày, `Transit_Days` = 1,5 ngày.

Biện pháp nào giải quyết hiệu quả nhất vấn đề giao hàng chậm?

A. Ưu tiên thay đổi đối tác giao vận vì tốc độ giao hàng quá chậm.

B. Áp dụng miễn phí vận chuyển để đền bù vì hai quy trình chênh lệch ít.

C. Nút thắt chính là chuẩn bị xuất kho, cần tập trung tối ưu quy trình nội bộ.

D. Ngừng kinh doanh ở vùng có số ngày Transit quá tải để chặn đứng rủi ro.

AIO25-DS-DA-14
Phân khúc khách hàng theo RFM

Phân tích RFM phân khúc khách hàng theo 3 yếu tố: **R**ecency (mua gần đây không), **F**requency (mua bao nhiêu lần), **M**onetary (tổng chi tiêu bao nhiêu). Dựa trên chỉ số RFM, khách hàng được chia vào 4 nhóm với chiến lược can thiệp riêng biệt.

Sơ đồ dưới đây thể hiện 4 nhóm khách hàng (Khối A) và 4 chiến lược (Khối B), nhưng các đường nối đã bị đảo lộn. Ghép đúng từng nhóm với chiến lược phù hợp:

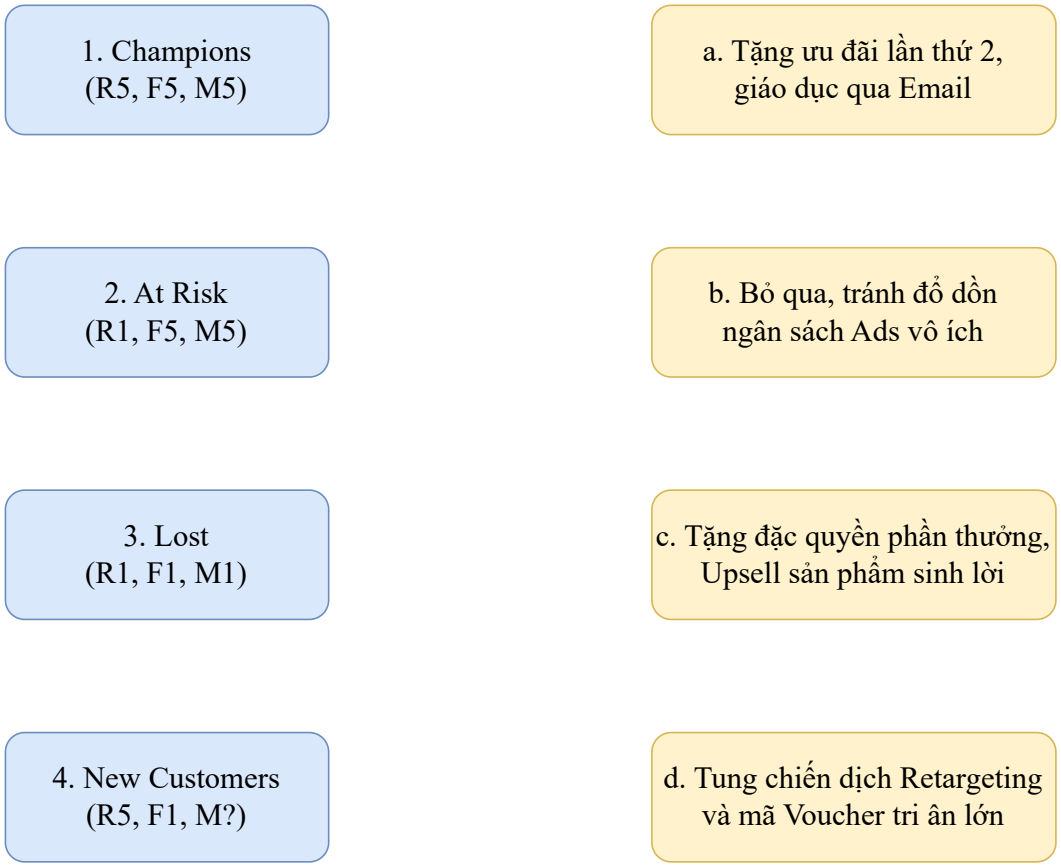

Hình 9: Sơ đồ ghép nhóm khách hàng RFM (Khối A) với chiến lược can thiệp (Khối B)

Cách ghép nào đúng theo nguyên lý RFM?

A. 1-a, 2-b, 3-c, 4-d

B. 1-c, 2-d, 3-b, 4-a

C. 1-c, 2-a, 3-b, 4-d

D. 1-b, 2-d, 3-a, 4-c

AIO25-DS-DA-15
Phân tích Trả hàng theo Pareto Principle

Pareto Principle (80/20) cho rằng phần lớn vấn đề (khoảng 80%) thường đến từ một số ít nguyên nhân (khoảng 20%). **Pareto Chart** kết hợp cột (tỷ trọng từng nguyên nhân, sắp xếp giảm dần) và đường lũy kế.

Bạn phân tích nguyên nhân trả hàng cho danh mục giày bán chạy nhất:

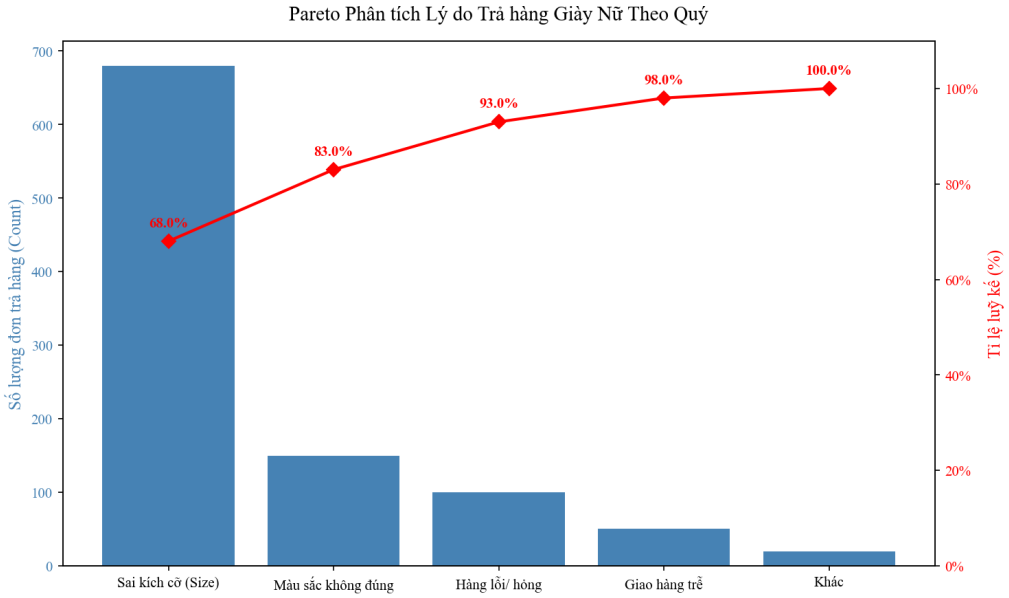

Hình 10: Pareto Chart phân tích nguyên nhân trả hàng danh mục giày

Theo Pareto Principle, biện pháp nào giải quyết hiệu quả nhất tỷ lệ trả hàng?

A. Tạm đóng danh mục bán giày trong hai quý tới để siết chặt lại quy trình quản lý.

B. Bổ sung công cụ hướng dẫn chọn size chi tiết ngay trực tiếp trên trang sản phẩm.

C. Tăng chiết khấu đền bù cho các nhóm khách hàng mục tiêu do nhận hàng quá chậm.

D. Triển khai chiến dịch hình ảnh mới vì nội dung thiếu chân thực gây hủy đơn ồ ạt.

AIO25-DS-DA-16
Quản trị Inventory Health (Sức khỏe Tồn kho)

Khi quản lý hàng hóa, rủi ro lớn nhất là chênh lệch cung cầu. Dữ liệu cho thấy:

- Sản phẩm **Alpha:** Tồn kho rất cao nhưng tốc độ bán ra rất thấp.
- Sản phẩm **Beta:** Tồn kho chạm đáy (mức 10) nhưng nhu cầu tìm kiếm rất cao.

Quan sát Scatter Plot đo lường Inventory Health:

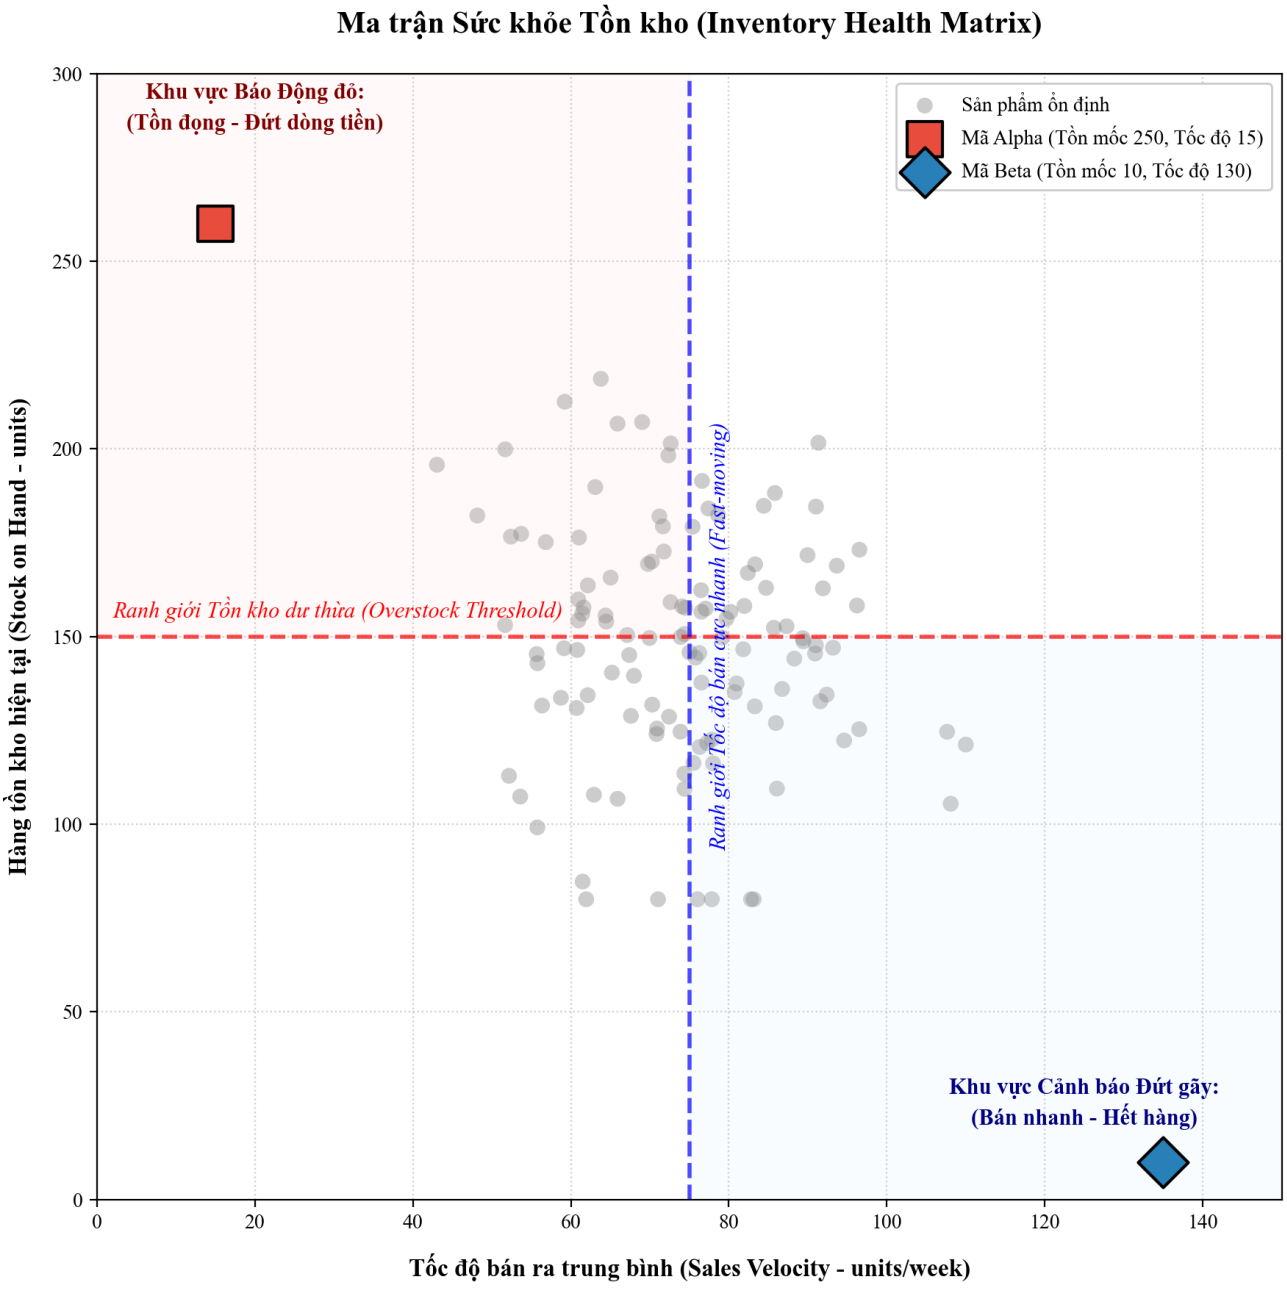

Hình 11: Inventory Health Matrix: tốc độ bán so với mức tồn kho hiện tại

Kết luận nào chẩn đoán đúng hiện trạng và đưa ra giải pháp luân chuyển vốn tốt nhất?

A. Mã Alpha đang dư dả dòng tiền, mã Beta đang bị đọng vốn quá lớn.

B. Mã Alpha cháy kho do tiêu thụ mạnh, phải liên tục nhập hàng quy mô.

C. Mã Alpha đang vướng vào đứt cung, còn mã Beta gánh chịu lượng tồn.

D. Mã Beta bị đứt cung, cần thanh lý cắt lỗ mã Alpha giải cứu nguồn vốn.

IV. Machine Learning & Forecasting

Bối cảnh chung: Trong bài toán dự báo doanh thu hàng ngày, dữ liệu lịch sử từ năm 2012 đến hết 2022 được dùng để xây dựng mô hình dự báo cho **548 ngày tiếp theo** (01/01/2023 – 01/07/2024). Đường doanh thu lịch sử có **regime drift** mạnh: doanh thu trung bình 2014–2018 vào khoảng 10–15 triệu/ngày, sau đó giảm xuống còn 5–7 triệu/ngày từ 2020.

AIO25-DS-ML-01
Tính MAE và RMSE – chọn chỉ số phù hợp khi có giá trị bất thường

Một mô hình dự báo doanh thu hàng ngày được kiểm tra trên 5 ngày. Ngày thứ 4 có một sự kiện khuyến mãi đặc biệt khiến doanh thu thực tế tăng đột biến – mô hình không lường trước được nên dự báo sai rất lớn:

Ngày	Dự báo $\hat{y}$ (triệu)	Thực tế y (triệu)
1	100	100
2	100	100
3	100	100
4	100	200
5	100	100

Bảng 15: 5 ngày kiểm tra, dòng tô vàng là ngày khuyến mãi đặc biệt.

Công thức nhắc lại:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Hãy tính MAE và RMSE, sau đó cho biết **chỉ số nào phù hợp hơn** khi mục tiêu là phát hiện các ngày sai bất thường (như ngày khuyến mãi)?

A. MAE = 20, RMSE ≈ 44,7 – chọn **RMSE** vì bình phương sai số làm nó nhạy hơn với ngày sai đột biến (outlier).

B. MAE = 20, RMSE ≈ 44,7 – chọn **MAE** vì đơn giản hơn và không bị 1 ngày outlier làm méo kết quả chung.

C. MAE = 20, RMSE = 20 – hai chỉ số luôn cho cùng giá trị nên chọn cái nào cũng tương đương.

D. MAE = 25, RMSE = 50 – chỉ số nào cũng được vì tỉ số RMSE/MAE = 2,0 vẫn là 2 lần cố định.

AIO25-DS-ML-02
Chiến lược cross-validation cho chuỗi thời gian

Trong bài toán dự báo doanh thu liên tục 18 tháng tương lai (test: 01/01/2023 – 01/07/2024, tổng 548 ngày), do tập test thuộc về tương lai chưa quan sát, cần chọn hyperparameter qua **cross-validation theo thứ tự thời gian**. Một sơ đồ 3 fold thường dùng được minh hoạ ở Hình 12:

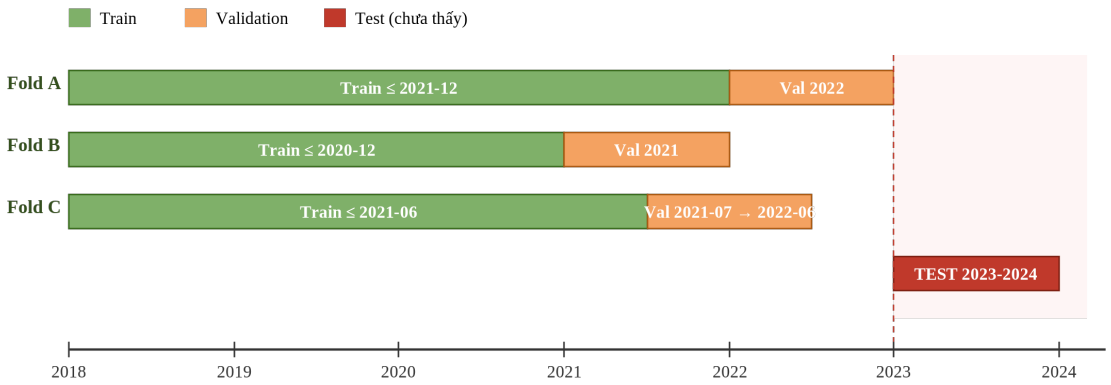

Hình 12: Ba fold validation theo thời gian. Vùng đỏ nhạt là test (mô hình chưa thấy).

Câu hỏi gồm hai phần: **(i)** Vì sao *không* dùng *random k-fold* (chia ngẫu nhiên) cho bài toán này? **(ii)** Trong 3 fold trên, fold nào nên được chọn làm **"fold chính"** để chốt các quyết định quan trọng?

A. (i) Vì làm sai thứ tự thời gian, gây rò rỉ thông tin từ tương lai về quá khứ; (ii) **Fold B** là fold chính vì khoảng train ngắn nhất nên đánh giá khắt khe.

B. (i) *Random k-fold* vẫn dùng được nếu xáo trộn theo năm; (ii) **Fold A** là fold chính vì có nhiều dữ liệu train nhất.

C. (i) Vì *random k-fold* chạy quá chậm với chuỗi thời gian; (ii) **Fold C** là fold chính vì khoảng dự báo 12 tháng giống test 18 tháng.

D. (i) Vì làm sai thứ tự thời gian, gây rò rỉ thông tin từ tương lai về quá khứ; (ii) **Fold A** là fold chính vì validation năm 2022 có phân phối *gần test 2023 nhất*.

AIO25-DS-ML-03
Đặc trưng trễ (lag feature) ở khoảng dự báo dài

Định nghĩa — *lag feature* (đặc trưng trễ): là **giá trị của chính biến mục tiêu ở các thời điểm trước**, được dùng làm đầu vào để dự báo thời điểm hiện tại. Ví dụ với chuỗi doanh thu y_t:

- y_{t-1} = doanh thu **hôm qua** (lag-1) – dùng để dự báo doanh thu hôm nay.
- y_{t-7} = doanh thu **7 ngày trước** (lag-7) – bắt pattern theo tuần.
- y_{t-365} = doanh thu **cùng ngày năm trước** – bắt pattern theo năm.

Lag feature rất mạnh khi dự báo **ngắn hạn** (1–2 ngày tiếp theo), vì giá trị quá khứ thường tương quan cao với hiện tại.

Trong bài toán dự báo doanh thu **18 tháng tương lai** (548 ngày, từ 01/01/2023 đến 01/07/2024), hàm tạo đặc trưng được xây dựng **chỉ dựa trên thông tin ngày tháng** (năm, tháng, ngày, ngày-trong-năm, ...). Hàm không bao gồm bất kỳ đặc trưng trễ nào ($y_{t-1}, y_{t-7}, y_{t-365}$). Thay vào đó, **Fourier features** được dùng để mô hình hoá mùa vụ:

Tạo đặc trưng dựa vào Fourier

```
# Fourier annual k = 1..5 -- pattern mua vu dinh ky theo nam
TAU = 2 * np.pi
for k in (1, 2, 3, 4, 5):
    df[f'sin_y{k}'] = np.sin(TAU * k * df['doy'] / 365.25)
    df[f'cos_y{k}'] = np.cos(TAU * k * df['doy'] / 365.25)
# 'doy' = day-of-year (1..366), bo k=1..5 cho 10 dac trung mua vu
```

Bối cảnh quan trọng: Mô hình chỉ tiếp xúc với dữ liệu đến hết **31/12/2022**. Khi dự báo cho ngày **01/06/2023**, giá trị doanh thu thật của ngày 31/05/2023 hay 25/05/2023 *chưa được quan sát* – toàn bộ 548 ngày tương lai phải được dự đoán **cùng một lúc**, không có giá trị thực (ground truth) để tính lag.

Phát biểu nào **giải thích đúng nhất** hai quyết định: (a) tại sao loại lag feature, (b) tại sao bù bằng Fourier?

A. (a) Loại lag vì các đặc trưng trễ thường gây quá khớp (overfit) khi train trên chuỗi dài; (b) Fourier để giảm số chiều input bằng cách nén thông tin mùa vụ thành 10 đặc trưng sin/cos.

B. (a) Loại lag vì $y_{t-1}, y_{t-7}, y_{t-365}$ không tính được *đồng nhất* cho cả 548 ngày dự báo (đa số cần giá trị tương lai); (b) Fourier chỉ phụ thuộc ngày tháng nên tính được cho mọi ngày tương lai, giúp Ridge học pattern lặp định kỳ.

C. (a) Loại lag vì lag vi phạm giả định stationarity (chuỗi không dừng) của hồi quy Ridge; (b) Fourier để chuẩn hoá tất cả đặc trưng về khoảng $[-1, 1]$ giúp Ridge hội tụ nhanh hơn.

D. (a) Loại lag vì LightGBM huấn luyện chậm hơn $\sim$3 lần khi có lag features; (b) Fourier để tạo tương tác (interaction) giữa các đặc trưng (mùa vụ $\times$ ngày-trong-tuần) cho LightGBM khai thác.

AIO25-DS-ML-04
Tính trọng số mẫu (sample weight) khi huấn luyện

Khi dữ liệu lịch sử doanh thu có sự khác biệt mạnh giữa các giai đoạn, một kỹ thuật phổ biến là dùng **trọng số mẫu (sample weight)** để mô hình LightGBM **tập trung học từ giai đoạn 2014–2018** (dữ liệu "sạch", mùa vụ rõ) và **nhấn mạnh vào quý 3** (quý có biến động lớn nhất). Quy tắc trọng số 2 bước được áp dụng như sau:

Bước	Điều kiện	Hệ số
1	Mẫu thuộc năm 2014–2018	$w = 1{,}0$
	Mẫu ngoài 2014–2018	$w = 0{,}1$
2	Nếu mẫu thuộc quý 3 (tháng 7, 8, 9)	$w \leftarrow w \times 2$
	Nếu mẫu thuộc các quý khác (Q1, Q2, Q4)	$w \leftarrow w \times 1$

Bảng 16: Trọng số cuối = giá trị Bước 1 (rồi nhân thêm 2 nếu thuộc quý 3).

Cách tính trọng số mẫu khi huấn luyện

```
# Khoi tao weight mac dinh (0.1) cho moi mau
w = np.full( len(df), 0.1)

# Buoc 1: nang weight cho nam 2014-2018
w[(df['year'] >= 2014) & (df['year'] <= 2018)] = 1.0

# Buoc 2: nhan 2.0 cho cac mau thuoc quy trong tam (Q3)
w[df['quarter'] == 3] *= 2.0
```

Theo quy tắc trên, **trọng số của ngày 15/08/2017** bằng bao nhiêu?

A. 0,2

B. 1,0

C. 2,0

D. 0,1

AIO25-DS-ML-05
Vai trò của tính đa dạng (diversity) trong kết hợp mô hình

Trong dự báo chuỗi thời gian, một kỹ thuật phổ biến để cải thiện độ chính xác là **kết hợp nhiều mô hình** (ensemble): mỗi mô hình cho ra dự báo riêng, sau đó các dự báo được **trộn theo trọng số** thành một dự báo cuối. Tuy nhiên, ensemble chỉ cải thiện rõ rệt so với mô hình đơn lẻ khi các mô hình thành phần có **tính đa dạng (diversity)** – tức sai số (residuals) của chúng *không tương quan quá cao*:

- Khi các mô hình "sai cùng hướng"(tương quan residuals cao), phép trộn trung bình giữ nguyên hướng sai → không cải thiện.
- Khi các mô hình "sai khác hướng nhau"(tương quan thấp), các sai số *triệt tiêu* một phần khi cộng → MAE giảm.

Xét hai phương án xây dựng ensemble cho bài toán dự báo doanh thu:

Phương án A — Ba mô hình thuộc ba họ giải thuật khác nhau:

- M_{Ridge} — hồi quy tuyến tính có chuẩn hoá L2 (dùng Fourier features cho mùa vụ).
- M_{LGB} — gradient boosting trên cây (LightGBM).
- M_{Prophet} — phân rã thành phần: xu hướng + mùa vụ + ngày lễ (Prophet).

Ma trận hệ số tương quan Pearson của residuals:

	M_{Ridge}	M_{LGB}	M_{Prophet}
M_{Ridge}	1,00	0,68	0,62
M_{LGB}	0,68	1,00	0,65
M_{Prophet}	0,62	0,65	1,00

Bảng 17: Ma trận tương quan residuals của Phương án A (giá trị trung bình $\approx 0{,}65$).

Phương án B — Ba phiên bản LightGBM cùng họ, khác hyperparameter (chẳng hạn `num_leaves` = 31 / 63 / 127). Vì cả ba đều là gradient boosting trên cây và học từ cùng tập dữ liệu, các phiên bản này có sai số tương tự nhau: ma trận tương quan residuals nằm trong khoảng **0,92–0,95**.

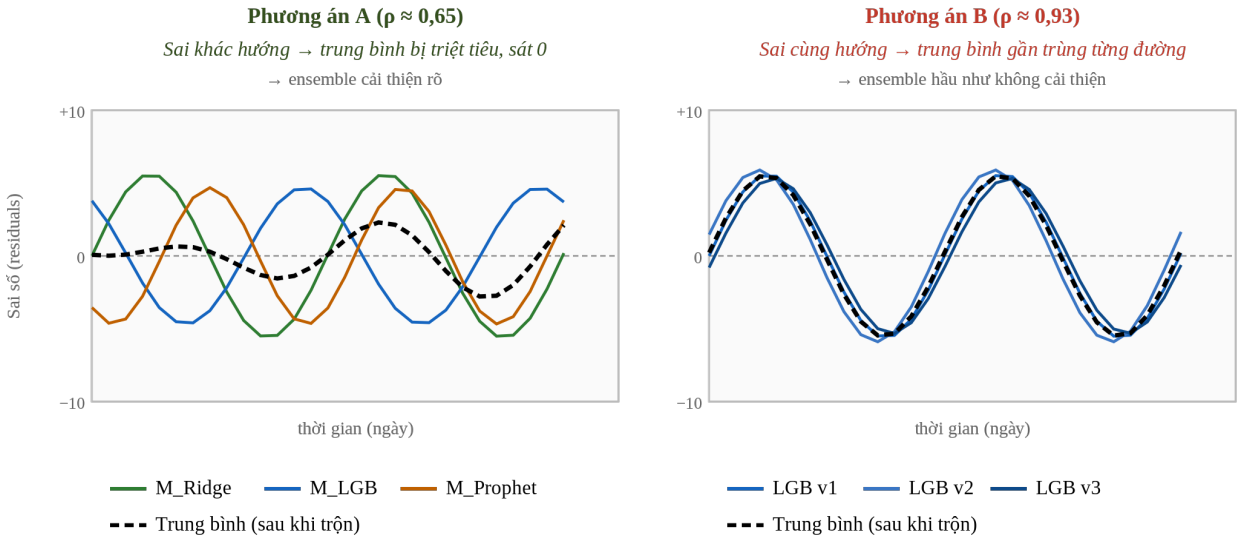

Hình 13: Sai số (residuals) của 3 mô hình theo thời gian. Đường đen đứt nét là trung bình sau khi trộn. **Bên trái** (Phương án A): các mô hình khác họ sai khác pha → trung bình dao động sát 0. **Bên phải** (Phương án B): 3 phiên bản LGB sai gần như cùng pha → trung bình gần trùng với từng đường.

Cả hai phương án đều dùng trọng số trộn bằng nhau (1/3 cho mỗi mô hình). Phát biểu nào sau đây **đúng nhất**?

A. Phương án B tốt hơn vì ba LightGBM cùng họ tin cậy hơn một LightGBM cộng hai mô hình thuộc họ khác (Ridge và Prophet) vốn yếu hơn về sức mạnh đơn lẻ.

B. Cả hai phương án đều không cải thiện được vì lý thuyết bagging chỉ ra rằng cần ít nhất 5 mô hình đa dạng mới giảm variance đáng kể.

C. Cả hai phương án cải thiện như nhau vì đều dùng đúng ba mô hình; số lượng mô hình mới là yếu tố quyết định chất lượng ensemble, không phải bản chất giải thuật.

D. Phương án A tốt hơn vì $\rho \approx 0{,}65$ (thấp) → trộn trung bình triệt tiêu một phần sai số; Phương án B có $\rho \approx 0{,}93$ → các mô hình sai cùng hướng nên không cải thiện.

AIO25-DS-ML-06
Cấu hình huấn luyện Prophet khi chuỗi thời gian có bước nhảy

Trong một quy trình dự báo doanh thu, **Prophet** là một mô hình thuộc họ **phân rã thành phần** (decomposition): tách chuỗi thời gian thành xu hướng (trend), mùa vụ (seasonality) và ngày lễ (holidays). Cấu hình Prophet được sử dụng:

Cấu hình huấn luyện Prophet

```python
def fit_prophet(train_df, use_recent_data_only= True):
    # Khi True, chi huan luyen tren du lieu tu 2020-01-01 tro di
    if use_recent_data_only:
        train_df = train_df[train_df["ds"] >= "2020-01-01"]
    m = Prophet(
        yearly_seasonality= True,
        weekly_seasonality= True,
        seasonality_mode="multiplicative",
        changepoint_prior_scale=0.05)
    m.fit(train_df)
    return m
```

Bối cảnh dữ liệu: Đường doanh thu 2012–2022 có một **bước nhảy giảm mạnh khoảng 40%** giữa cuối 2018 và đầu 2020. Trước cú nhảy, doanh thu trung bình ∼10–15 triệu/ngày; sau cú nhảy chỉ ∼5–7 triệu/ngày. Mục tiêu là dự báo giai đoạn sau (2023–2024).

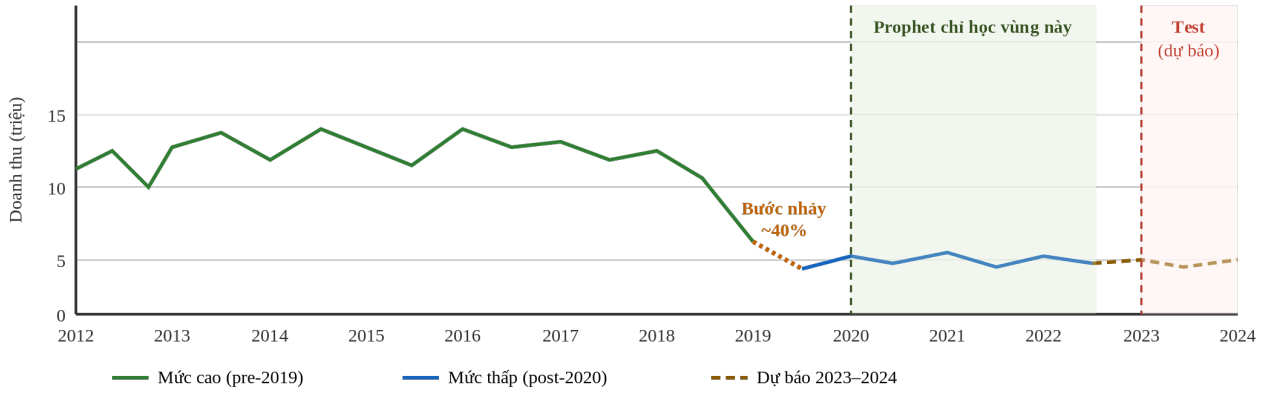

Hình 14: Đường doanh thu 2012–2024 với bước nhảy ∼40% (2019–2020). Vùng xanh nhạt là dữ liệu Prophet được phép học (post-2020); vùng cam nhạt là khoảng cần dự báo.

Trong cấu hình trên, Prophet được huấn luyện chỉ trên dữ liệu **từ 01/01/2020 trở đi** (thay vì toàn bộ 11 năm). Lý do nào sau đây **giải thích đúng nhất** quyết định này?

A. Trend của Prophet (piecewise linear với "điểm gãy"changepoint) xử lý kém các bước nhảy

đột ngột; lọc từ 2020 giúp Prophet học trên một giai đoạn đồng nhất, tránh trend bị bóp méo.

B. Prophet có giới hạn về số điểm dữ liệu trong stan optimizer; cắt bớt dữ liệu pre-2020 giúp giảm bộ nhớ và tăng tốc huấn luyện đáng kể trên dataset lớn.

C. Prophet yêu cầu khoảng cách dữ liệu đều theo năm để mô hình hoá đúng yearly seasonality; dữ liệu trước 2020 không đều nên cần loại bỏ để tránh sai lệch.

D. Giai đoạn 2012–2019 có quá nhiều giá trị bất thường do thị trường bất ổn; cần loại bỏ để mô hình không bị nhiễu khi học pattern mùa vụ chuẩn.

- Hết -

AI VIET NAM COURSE 2026

Logic Thinking and Problem Solving for Data Science and Artificial Intelligence

I. Giới thiệu

Trong kỷ nguyên số hóa mạnh mẽ và sự bùng nổ của dữ liệu, Trí tuệ nhân tạo (AI) và khoa học dữ liệu (Data Science) đã trở thành những động lực cốt lõi, định hình lại cách chúng ta sống, làm việc và kinh doanh. Từ việc dự đoán xu hướng thị trường, tối ưu hóa quy trình sản xuất, đến phát triển các hệ thống tự lái và chẩn đoán y tế, những lĩnh vực này đang mở ra vô số cơ hội và tiềm năng chuyển đổi.

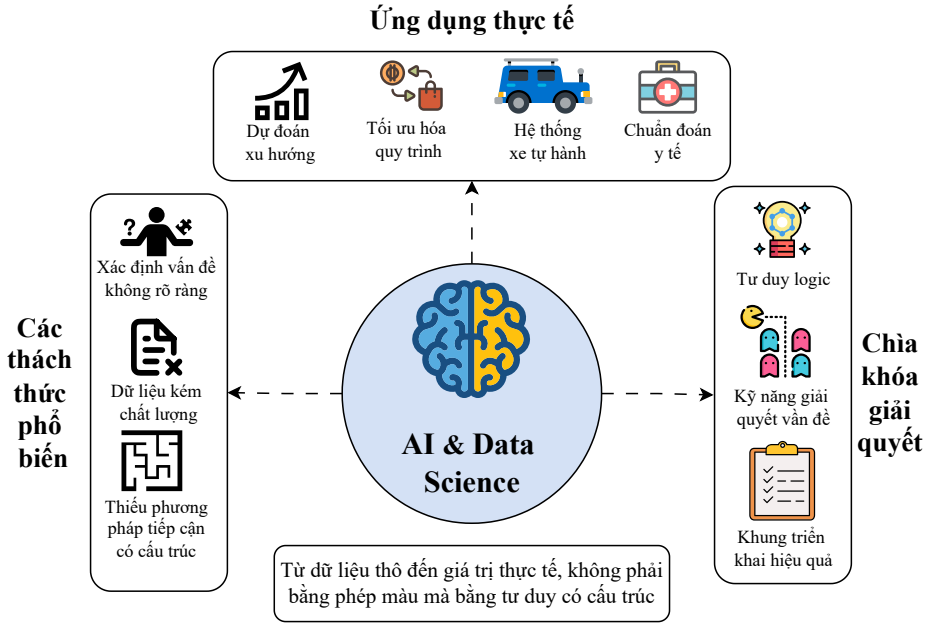

Hình 1: Vai trò trung tâm của trí tuệ nhân tạo và khoa học dữ liệu trong thế giới thực

Tuy nhiên, bất chấp tiềm năng to lớn, nhiều dự án AI và Data Science hiện nay đang đối mặt với những thách thức đáng kể, dẫn đến tỷ lệ thất bại cao hoặc không đạt được kỳ vọng. Những

thất bại này thường không xuất phát từ sự thiếu hụt về công nghệ hay thuật toán, mà lại từ những vấn đề cơ bản hơn liên quan đến việc xác định vấn đề không rõ ràng, chất lượng dữ liệu kém hoặc thiếu một phương pháp tiếp cận có cấu trúc để triển khai. Điều này làm nổi bật một thực tế quan trọng: AI không phải là một công cụ tự động mang lại kết quả, mà đòi hỏi một nền tảng tư duy vững chắc để chuyển hóa dữ liệu thô thành giá trị kinh doanh thực sự.

Bài viết này tập trung làm rõ tầm quan trọng của **Tư duy logic (Logical Thinking)** và **Kỹ năng giải quyết vấn đề (Problem Solving)** như những năng lực cốt lõi không thể thiếu đối với những người hoạt động trong lĩnh vực AI và Data Science. Bài viết trình bày một khung quy trình 7 bước có hệ thống nhằm giúp bạn vượt qua các rào cản phổ biến và triển khai các dự án AI/Data Science một cách hiệu quả, từ giai đoạn định nghĩa vấn đề cho đến khi thiết kế và trình bày giải pháp. Theo đó, nội dung bài viết sẽ đi sâu vào các khía cạnh chính sau:

- **Xác định vấn đề:** Tập trung vào việc định nghĩa rõ ràng thách thức kinh doanh và tìm ra nguyên nhân gốc rễ bằng các kỹ thuật phân tích.
- **Phân rã vấn đề:** Hướng dẫn cách chia nhỏ các vấn đề phức tạp thành các thành phần dễ quản lý hơn, đảm bảo tính bao quát và không trùng lặp.
- **Ưu tiên hóa giải pháp:** Tập trung nguồn lực vào những giải pháp mang lại tác động lớn nhất và có tính khả thi cao.
- **Thu thập và phân tích dữ liệu:** Đề xuất các phương pháp khoa học để đảm bảo chất lượng dữ liệu và trích xuất các insight có giá trị.
- **Thiết kế và trình bày giải pháp:** Hướng dẫn cách xây dựng và truyền đạt các giải pháp AI một cách thuyết phục, có giá trị kinh doanh rõ ràng.

II. Nội dung bài học

II.1. Nền tảng của tư duy logic và giải quyết vấn đề

II.1.1. Logical Thinking and Problem Solving trong AI/Data Science

Trong lĩnh vực AI và Data Science, dù tiềm năng là vô hạn trong việc tối ưu hóa các quy trình, dự đoán xu hướng và đưa ra quyết định thông minh dựa trên dữ liệu, nhưng thực tế lại cho thấy một tỷ lệ đáng báo động các dự án thất bại. Các dự án AI thường gặp khó khăn trong không phải vì thiếu thuật toán phức tạp hay tài nguyên tính toán, mà do những yếu tố phi kỹ thuật cốt lõi.

Thống kê cho thấy **80%** dự án AI thất bại ngay từ giai đoạn định nghĩa vấn đề ban đầu, thường do việc xác định mục tiêu không rõ ràng, dữ liệu không phù hợp hoặc thiếu hạ tầng cần thiết **OrionHealthAI**. Thêm vào đó, **70%** dự án không thể vượt qua giai đoạn Proof of Concept (PoC) do thiếu sự gắn kết rõ ràng với bài toán kinh doanh cụ thể **ResearchHutAI**. Những vấn đề như "Garbage In, Garbage Out" (dữ liệu kém chất lượng, ví dụ như việc: Gợi ý tã em bé cho người độc thân) và "Wrong Problem Definition" (chỉ tập trung thuật toán mà bỏ qua hành vi khách hàng) đã dẫn đến lãng phí đáng kể về thời gian và chi phí. Minh chứng rõ ràng cho điều này là trường hợp của chuỗi siêu thị, hệ thống AI đề xuất sản phẩm chỉ tăng 3% doanh thu thay vì 25% như kỳ vọng, đã cho thấy AI không thể tự động mang lại kết quả kỳ diệu. Hơn nữa, thiếu một "Systematic Approach" khiến việc phân tích nguyên nhân gốc rễ trở nên khó khăn, dẫn đến các chỉ số kém như tỷ lệ click thấp hay tỷ lệ rời trang cao.

Những thách thức này khẳng định một điều: **Tư duy logic** và **Kỹ năng giải quyết vấn đề** không chỉ là kỹ năng bổ trợ, mà còn là chìa khóa cốt lõi để đảm bảo thành công trong dự án AI/Data Science. Cách tư duy này giúp chúng ta vượt qua "AI Hype" bằng cách tập trung vào các giải pháp thực sự hiệu quả và tối ưu hóa nguồn lực. Trên thực tế, các dự án AI áp dụng phương pháp giải quyết vấn đề có cấu trúc mang lại lợi nhuận đầu tư đáng kể, trung bình **3.7x ROI Singh2023Framework**.

Với mục tiêu đó, nội dung phần này sẽ đặt nền móng vững chắc trong việc suy nghĩ logic với việc:

- Phân tích sâu hơn về thực trạng và nguyên nhân thất bại của các dự án AI trong bối cảnh thực tiễn.
- Giới thiệu tầm quan trọng và lợi ích cụ thể mà tư duy logic và kỹ năng giải quyết vấn đề mang lại cho các chuyên gia AI/Data Science.
- Đặt ra khung quy trình 7 bước tổng quan mà bài viết sẽ đi theo để giải quyết vấn đề một cách có hệ thống.
- Bắt đầu đi sâu vào bước đầu tiên và quan trọng nhất của khung quy trình: Xác định ấn đề, cùng với các kỹ thuật hỗ trợ như **5W1H** và **5 Whys**.

II.1.2. Khung quy trình 7 bước giải quyết vấn đề trong AI/Data Science

Để giải quyết các vấn đề phức tạp trong lĩnh vực AI/Data Science một cách có hệ thống và tối ưu, việc tuân thủ một khung quy trình rõ ràng là vô cùng cần thiết. Quy trình này giúp chuyển đổi từ một thách thức kinh doanh rộng lớn thành các bước hành động cụ thể, có thể quản lý và đo lường được. Khung quy trình 7 bước này bao gồm các thành phần như sau:

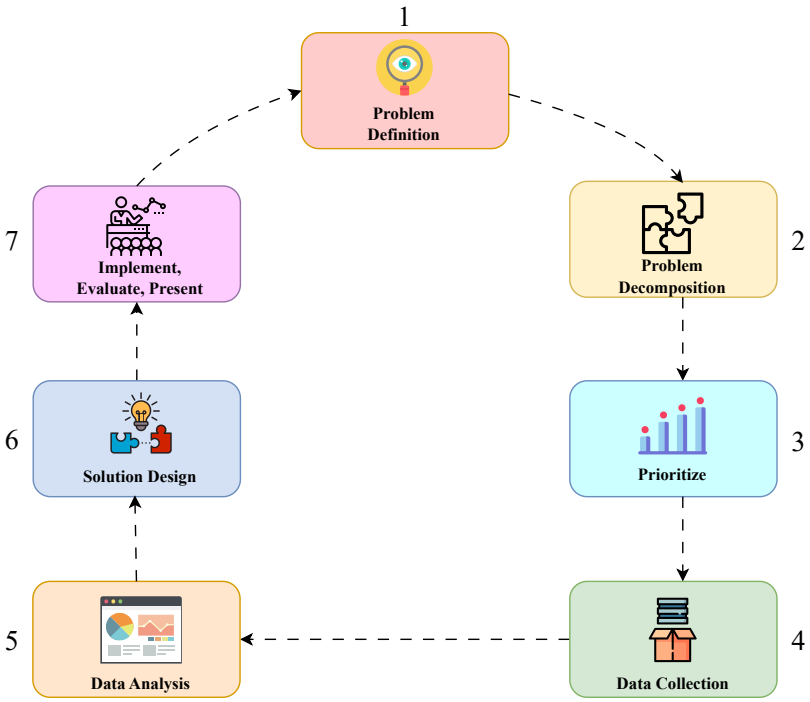

Hình 2: Khung quy trình 7 bước giải quyết vấn đề trong AI/Data Science

1. **Xác định vấn đề (Problem Definition):** Đây là bước khởi đầu, nơi vấn đề chính cần giải quyết được định nghĩa một cách rõ ràng và cụ thể. Việc này bao gồm việc hiểu rõ hiện trạng, mục tiêu mong muốn và các chỉ số đo lường thành công.

2. **Chia nhỏ vấn đề (Problem Decomposition):** Sau khi xác định vấn đề tổng thể, bước này tập trung vào việc phân rã nó thành các thành phần nhỏ hơn, độc lập và dễ quản lý. Trong bước thực hiện này, nguyên tắc MECE (Mutually Exclusive Collectively Exhaustive) là kim chỉ nam, đảm bảo việc không trùng lặp và không bỏ sót khía cạnh nào.

3. **Ưu tiên hóa (Prioritization):** Sau khi đã xác định được nhiều nguyên nhân và giải pháp tiềm năng, bước này xác định những yếu tố quan trọng nhất cần được giải quyết thông qua các công cụ như ma trận tác động - khả thi (Impact-Feasibility Matrix) được sử dụng để tối ưu hóa nguồn lực.

4. **Thu thập dữ liệu (Data Collection):** Dữ liệu chính là trái tim của mọi dự án AI. Bước này tập trung vào việc xác định, thu thập và chuẩn bị các tập dữ liệu cần thiết, đảm bảo chất lượng và độ tin cậy để phục vụ phân tích.

5. **Phân tích dữ liệu (Data Analysis):** Sau khi thu thập, dữ liệu sẽ được phân tích sâu để khám phá các mẫu hình, xu hướng và trích xuất những hiểu biết (insights) có giá trị. Mục tiêu của việc này là biến dữ liệu thô thành thông tin hữu ích để định hình giải pháp.

6. **Thiết kế giải pháp (Solution Design):** Dựa trên các insights thông qua phân tích dữ liệu, bước này tập trung vào việc xây dựng và phát triển các giải pháp AI cụ thể như: lựa chọn mô hình, kiến trúc hệ thống,... để đáp ứng trực tiếp vấn đề đã xác định.

7. **Triển khai, đánh giá và trình bày (Implementation, Evaluation, Presentation):** Bước cuối cùng là đưa giải pháp vào thực tế và liên tục đánh giá hiệu suất của nó so với các mục tiêu đã định. Thêm vào đó, kết quả và giá trị của dự án cần được trình bày một cách rõ ràng, thuyết phục cho các bên liên quan.

Trong quá trình thực hiện, mỗi khi có dữ liệu mới, ta nên quay lại các bước thực hiện trước để có khi cần tinh chỉnh hoặc tối ưu hóa giải pháp giúp cho quy trình làm việc trở lên linh hoạt hơn.

II.1.3. Xác định vấn đề

Đây là bước đầu tiên và quan trọng nhất và là nền tảng quyết định sự thành công hay thất bại của toàn bộ dự án.

A. Định nghĩa "vấn đề"
Trong ngữ cảnh của AI và khoa học dữ liệu, "vấn đề" được hiểu là khoảng cách giữa tình trạng hiện tại (AS-IS) và tình trạng mong muốn (TO-BE), hay còn được hiểu là sự chênh lệch giữa hiệu suất thực tế và mục tiêu kỳ vọng. Đây là khoảng cách cần được thu hẹp hoặc giải quyết để đạt được các mục tiêu cụ thể trong dự án. Các vấn đề thường gặp trong các dự án AI bao gồm:

- **Data drift:** Dữ liệu thực tế trong quá trình vận hành khác biệt đáng kể so với dữ liệu huấn luyện (training data), làm giảm hiệu suất mô hình.
- **Model bias:** Mô hình thiên vị một nhóm người dùng hoặc một loại dữ liệu cụ thể, dẫn đến kết quả không công bằng hoặc không chính xác cho tác vụ tổng quát.
- **Model decay:** Hiệu suất của mô hình giảm dần theo thời gian do sự thay đổi của dữ liệu hoặc hành vi người dùng.
- **Resource bottleneck:** Thiếu hụt tài nguyên tính toán, lưu trữ hoặc nhân sự cần thiết để phát triển và triển khai giải pháp.

B. Tầm quan trọng của việc xác định đúng vấn đề

Xác định vấn đề chính xác là yếu tố then chốt quyết định sự thành bại của mọi dự án AI. Một định nghĩa rõ ràng, cụ thể sẽ định hướng toàn bộ quy trình phát triển và tối ưu hóa kết quả, trong khi sự mơ hồ ngay từ đầu là nguyên nhân phổ biến dẫn đến thất bại. Việc xác định vấn đề có thể được so sánh giữa hai cách tiếp cận:

Xác định vấn đề KHÔNG đúng	Xác định vấn đề ĐÚNG
• Tập trung vào triệu chứng thay vì nguyên nhân gốc rễ. • Định nghĩa mơ hồ, thiếu cụ thể. • Hướng đến giải pháp kỹ thuật thay vì vấn đề kinh doanh. • Thiếu các chỉ số (metrics) để đo lường.	• Bắt đầu từ vấn đề kinh doanh cụ thể. • Phân tích để tìm ra nguyên nhân gốc rễ (tình trạng hiện tại - AS-IS). • Áp dụng tiêu chí SMART để đặt mục tiêu. • Xác định rõ ràng KPI đo lường.

Bảng 1: So sánh giữa cách xác định vấn đề đúng và không đúng trong các dự án AI.

Để minh họa rõ hơn những điểm khác biệt và tác động của việc xác định vấn đề đúng và không đúng, hãy cùng xem xét một ví dụ thực tế sau đây:

Xác định vấn đề KHÔNG đúng	Xác định vấn đề ĐÚNG
Ví dụ: "Cần xây dựng hệ thống AI dự đoán tại sao khách hàng rời bỏ."	**Ví dụ:** "Tỷ lệ khách hàng rời bỏ tăng 15% trong quý vừa qua, làm giảm doanh thu 2 tỷ đồng."
• Tập trung vào **giải pháp kỹ thuật** thay vì **vấn đề kinh doanh**. • Thiếu ngữ cảnh về nguyên nhân và mục tiêu. • Không xác định KPI đo lường thành công. • Không phân tích chi phí và lợi ích.	• Xác định **vấn đề kinh doanh** với số liệu cụ thể. • Phân tích nguyên nhân: 70% khách hàng rời bỏ do trải nghiệm kém. • Mục tiêu **SMART**: Giảm tỷ lệ rời bỏ 5% trong 6 tháng. • Đề xuất giải pháp AI phù hợp với **nguyên nhân gốc rễ**.
Hậu quả: Lãng phí đáng kể nguồn lực, giải pháp kém hiệu quả, và không thực sự giải quyết được gốc rễ của vấn đề.	**Lợi ích:** Tối ưu hóa nguồn lực, nâng cao hiệu quả giải pháp, đo lường thành công rõ ràng, và đảm bảo sự đồng thuận giữa các bên liên quan.

Bảng 2: So sánh giữa cách xác định vấn đề đúng và không đúng trong các dự án AI.

Việc áp dụng tiêu chí SMART là chìa khóa để định hình vấn đề một cách chuẩn xác. Để hiểu rõ hơn cách biến những mục tiêu mơ hồ thành kết quả cụ thể, chúng ta sẽ khám phá chi tiết tiêu chí này trong phần E. SMART Framework cho AI tiếp theo.

C. Kỹ thuật đặt câu hỏi 5W1H

Đặt câu hỏi đúng là bước đầu tiên và quan trọng nhất để xác định vấn đề một cách toàn diện. Phương pháp **5W1H** (What, Who, Where, When, Why, How) giúp phân tích vấn đề từ nội dung cụ thể đến tác động kinh doanh và các bên liên quan:

- **What** (Vấn đề là gì?): Vấn đề cụ thể là gì? Các KPI nào bị ảnh hưởng? Mức độ nghiêm trọng ra sao?
- **Who** (Ai liên quan?): Ai là các stakeholders? Người dùng, khách hàng, đội ngũ nội bộ nào bị ảnh hưởng? Ai bị ảnh hưởng nhiều nhất?
- **Where** (Vấn đề xảy ra ở đâu?): Vấn đề xảy ra ở đâu? Trên nền tảng nào, khu vực nào? Có mẫu hình địa lý nào không?
- **When** (Khi nào vấn đề bắt đầu?): Vấn đề bắt đầu khi nào? Có yếu tố thời gian, mùa vụ nào không? Có mẫu hình theo thời gian không?
- **Why** (Tại sao vấn đề quan trọng?): Tại sao vấn đề này quan trọng? Tác động kinh doanh là gì? Hậu quả nếu không giải quyết?
- **How** (Đang giải quyết thế nào?): Hiện tại đang giải quyết như thế nào? Các giải pháp đã thử? Hiệu quả ra sao?

Để minh họa cách thức áp dụng kỹ thuật 5W1H vào việc xác định vấn đề một cách toàn diện, chúng ta hãy xem xét tình huống *tỷ lệ học sinh vắng mặt ở trường học đang tăng cao*:

- **What**: Tỷ lệ học sinh vắng mặt không phép đã tăng đột biến lên **15%** tổng số buổi học trong tháng vừa qua, gây ảnh hưởng đến kết quả học tập chung và chất lượng giảng dạy.
- **Who**: Nhóm học sinh khối 10 (đặc biệt là hai lớp 10A2 và 10C5) có tỷ lệ vắng mặt cao nhất (20%). Học sinh có học lực trung bình khá có xu hướng vắng mặt nhiều hơn.
- **Where**: Tình trạng này phổ biến nhất ở các tiết học tự chọn vào buổi chiều và các môn học xã hội.
- **When**: Sự gia tăng vắng mặt bắt đầu rõ rệt sau kỳ thi giữa kỳ cách đây 2 tháng và thường xảy ra vào các ngày cuối tuần hoặc sau các dịp lễ dài.
- **Why**: Tỷ lệ vắng mặt cao dẫn đến điểm trung bình của trường giảm, giáo viên khó hoàn thành chương trình học và làm giảm uy tín của nhà trường trong mắt phụ huynh.
- **How**: Nhà trường đã thử gọi điện cho phụ huynh sau mỗi buổi vắng mặt và tổ chức nhắc nhở chung trong các buổi sinh hoạt dưới cờ, nhưng vấn đề vẫn chưa được giải quyết triệt để. Cần phân tích sâu hơn để hiểu nguyên nhân gốc rễ..

D. Phương pháp 5 Whys (Tìm nguyên nhân gốc rễ)

Trong khi 5W1H giúp bao quát vấn đề, phương pháp **5 Whys** là kỹ thuật đặt câu hỏi liên tiếp "Tại sao?" để đi sâu vào bản chất, tìm ra nguyên nhân gốc rễ thay vì chỉ giải quyết triệu chứng bề mặt. Giống như một tảng băng trôi, chỉ **20%** vấn đề là nhìn thấy được (triệu chứng), **80%** còn lại là ẩn sâu dưới bề mặt (nguyên nhân gốc rễ).

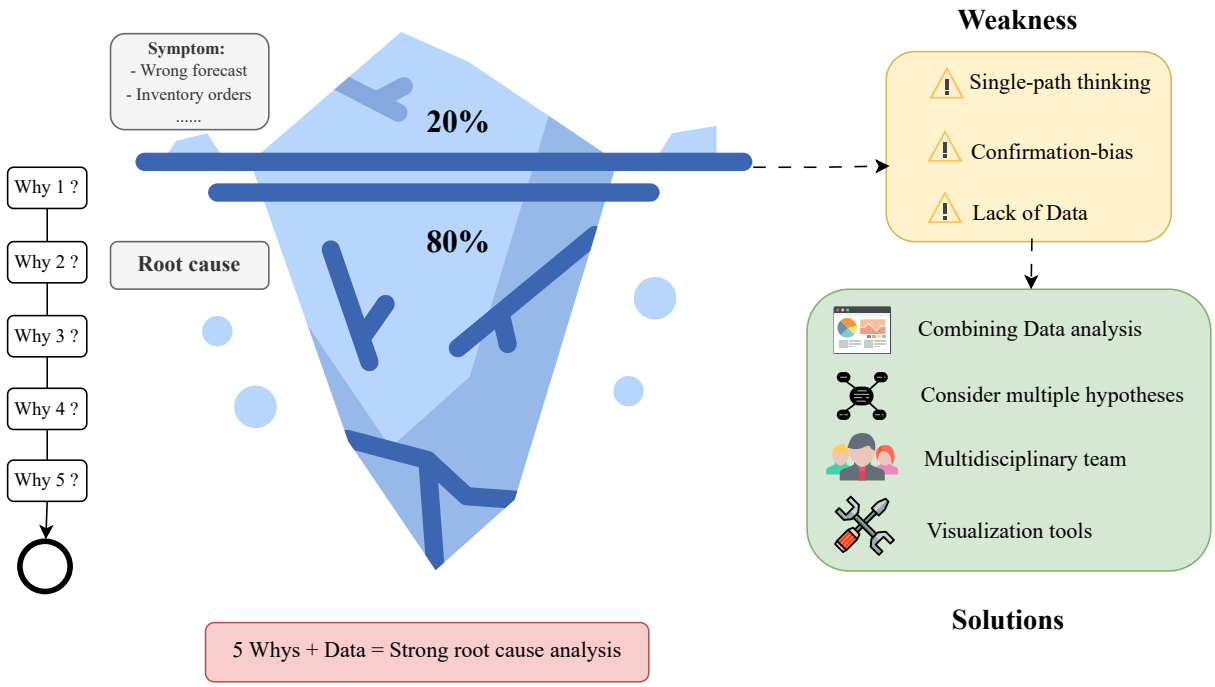

Hình 3: Sơ đồ quy trình Phương pháp 5 Whys. Từ triệu chứng ban đầu, liên tục đặt câu hỏi "Tại sao?" để đào sâu tìm ra nguyên nhân gốc rễ và cơ hội cải tiến hệ thống.

Ví dụ: Ứng dụng 5 Whys để phân tích tỷ lệ học sinh vắng mặt. Một chuỗi cửa hàng bán lẻ lớn đang đối mặt với tình trạng doanh số giảm sút đáng kể. Để tìm ra nguyên nhân gốc rễ, nhóm phân tích đã áp dụng phương pháp 5 Whys:

- **Why 1: Tại sao tỷ lệ học sinh vắng mặt lại tăng cao?**
  Answer: Vì học sinh cảm thấy thiếu động lực hoặc không hứng thú với một số môn học/bài giảng.
- **Why 2: Tại sao học sinh thiếu động lực hoặc không hứng thú?**
  Answer: Vì phương pháp giảng dạy chưa thực sự cá nhân hóa để phù hợp với sở thích và phong cách học của từng em.
- **Why 3: Tại sao phương pháp giảng dạy chưa được cá nhân hóa?**
  Answer: Vì giáo viên thiếu thông tin sâu sắc và công cụ hỗ trợ để hiểu rõ từng học sinh (thói quen học tập, môn học yêu thích, vấn đề khó khăn đang gặp phải,...).
- **Why 4: Tại sao giáo viên thiếu thông tin và công cụ hỗ trợ đó?**
  Answer: Vì nhà trường chưa có một hệ thống phân tích dữ liệu học tập và hành vi của học sinh một cách toàn diện.
- **Why 5:Tại sao chưa có hệ thống phân tích dữ liệu toàn diện?**
  Answer: Vì nhà trường chưa đầu tư vào hạ tầng công nghệ và giải pháp trí tuệ nhân tạo (AI) để theo dõi và dự đoán các vấn đề học tập/hành vi của học sinh.

Qua 5 bước hỏi "Why?", nguyên nhân gốc rễ được xác định là *thiếu hệ thống phân tích dữ liệu và giải pháp AI để dự đoán và hỗ trợ học sinh.* Từ đó, giải pháp cốt lõi được đề xuất là **Triển khai hệ thống AI phân tích hành vi và kết quả học tập của học sinh để dự đoán nguy cơ vắng mặt và gợi ý các phương pháp hỗ trợ/can thiệp sớm** nhằm giảm tỷ lệ học sinh vắng mặt và nâng cao chất lượng học tập.

Mục tiêu của 5 Whys là vượt qua các giải pháp tạm thời, tìm ra và giải quyết nguyên nhân gốc rễ để ngăn chặn vấn đề tái diễn. Tuy nhiên, bên cạnh đó, phương pháp 5 Whys có ba hạn chế chính:

1. **Single-path thinking:** Chỉ theo một chuỗi nguyên nhân, có thể bỏ qua các nguyên nhân khác.
2. **Confirmation bias:** Dễ dẫn theo giả định có sẵn, tìm kiếm bằng chứng ủng hộ giả thuyết ban đầu.
3. **Lack of data:** Dựa trên suy đoán thay vì bằng chứng dữ liệu, có thể dẫn đến kết luận sai.

Để khắc phục nhược điểm này và nâng cao độ tin cậy của phương pháp 5 Whys, ta có thể áp dụng các phương pháp bổ trợ như sau:

- **Kết hợp phân tích dữ liệu:** Luôn xác thực mỗi giả thuyết "Tại sao?" bằng các chỉ số (metrics) cụ thể và phân tích dữ liệu thực tế. Điều này giúp chuyển đổi từ suy đoán sang bằng chứng đáng tin cậy và định lượng.
- **Xem xét đa giả thuyết:** Tránh tư duy một chiều. Thay vào đó, hãy đồng thời xem xét và kiểm tra nhiều nguyên nhân tiềm ẩn khác nhau để đảm bảo không bỏ sót các yếu tố quan trọng, đặc biệt khi vấn đề có nhiều khía cạnh phức tạp.
- **Đa dạng hóa đội ngũ:** Tập hợp một đội ngũ bao gồm các chuyên gia đa ngành: các chuyên gia miền (domain experts) để hiểu rõ nghiệp vụ, nhà khoa học dữ liệu (data scientists) để phân tích dữ liệu và người dùng kinh doanh (business users) để đảm bảo giải pháp phù hợp với mục tiêu kinh doanh. Sự đa dạng này giúp mở rộng góc nhìn và giảm thiểu việc thiên kiến.
- **Sử dụng công cụ trực quan hóa:** Áp dụng các công cụ như Cây quyết định (Decision Trees) hoặc Biểu đồ xương cá (Fishbone Diagrams) để trực quan hóa mối quan hệ nhân quả và mở rộng phân tích một cách có cấu trúc, giúp khám phá các nguyên nhân ẩn sâu và trình bày chúng rõ ràng.

Best Practice

5 Whys + Data = Strong Root Cause Analysis. Việc kết hợp chặt chẽ phương pháp 5 Whys với phân tích dữ liệu chuyên sâu sẽ là chìa khóa để khắc phục các hạn chế cố hữu, từ đó nâng cao đáng kể độ tin cậy và tính chính xác của kết quả phân tích nguyên nhân gốc rễ.

E. SMART framework cho AI

Sau khi đã xác định và phân tích vấn đề, bước tiếp theo là đặt ra mục tiêu cụ thể. Trong bối cảnh AI và Data Science, việc chuyển đổi những ý tưởng mơ hồ thành các mục tiêu rõ ràng, khả thi và có thể đo lường là rất quan trọng. Khung **SMART** là một công cụ mạnh mẽ giúp hiện thực điều này, với mỗi chữ cái đại diện cho một tiêu chí then chốt: **S**pecific (Cụ thể), **M**easurable (Đo lường được), **A**chievable (Khả thi), **R**elevant (Liên quan) và **T**ime-bound (Có thời hạn). Cụ thể hơn, mỗi tiêu chí trong khung có ý nghĩa riêng như sau:

- **S - Specific (Cụ thể):** Mục tiêu phải được định nghĩa rõ ràng, chi tiết, và không gây hiểu nhầm, cần trả lời chính xác câu hỏi "Điều gì cần đạt được?" hoặc "Ai chịu trách nhiệm?"
  Ví dụ: Thay vì "Giảm học sinh vắng mặt", hãy đặt mục tiêu "Triển khai hệ thống AI dự đoán nguy cơ vắng mặt để hỗ trợ giảm 10% tỷ lệ học sinh vắng mặt không phép."

- **M - Measurable (Đo lường được):** Mục tiêu cần có các chỉ số định lượng cụ thể để theo dõi tiến độ và đánh giá mức độ hoàn thành. Nếu không đo lường được, chúng ta sẽ không biết mình có đang đi đúng hướng hay không.
  Ví dụ: Giảm tỷ lệ học sinh vắng mặt từ 15% xuống 5% và tăng điểm trung bình các môn học khó thêm 5% trong các lớp được áp dụng.

- **A - Achievable (Khả thi):** Mục tiêu phải thực tế và có thể đạt được với các nguồn lực (nhân lực, công nghệ, ngân sách) và ràng buộc hiện có. Mục tiêu quá xa vời có thể làm nản lòng đội ngũ.
  Ví dụ: Sử dụng dữ liệu điểm số, lịch sử chuyên cần có sẵn của học sinh và tích hợp với hệ thống quản lý học sinh (SIS) hiện tại của trường.

- **R - Relevant (Liên quan):** Mục tiêu phải phù hợp và có ý nghĩa đối với chiến lược tổng thể, mục tiêu kinh doanh của tổ chức hoặc các bên liên quan chính.
  Ví dụ: Mục tiêu phù hợp với chiến lược nâng cao chất lượng giáo dục của nhà trường và giúp cải thiện kết quả học tập của học sinh.

- **T - Time-bound (Có thời hạn):** Mục tiêu cần có một khung thời gian cụ thể để hoàn thành. Điều này tạo ra sự cấp bách và giúp lập kế hoạch hiệu quả.
  Ví dụ: Hoàn thành triển khai thử nghiệm (MVP) trong Q4 2025 và triển khai đầy đủ cho toàn trường trong Q1 2026.

Kết hợp các yếu tố SMART, một mục tiêu ban đầu mơ hồ như "Muốn dùng AI để giảm tỷ lệ học sinh vắng mặt" có thể được chuyển đổi thành một mục tiêu SMART rõ ràng và có tính hành động cao: "Triển khai hệ thống AI phân tích hành vi học sinh để dự đoán nguy cơ vắng mặt, nhằm giảm tỷ lệ học sinh vắng mặt không phép từ 15% xuống 5% và tăng điểm trung bình các môn học khó thêm 5% trong các lớp được áp dụng, bằng cách sử dụng dữ liệu có sẵn và tích hợp với hệ thống quản lý học sinh (SIS), nhằm mục đích nâng cao chất lượng giáo dục và cải thiện kết quả học tập, hoàn thành triển khai thử nghiệm (MVP) trong Q4 2025 và triển khai đầy đủ cho toàn trường trong Q1 2026."

Lưu ý Quan trọng

SMART chỉ là một công cụ hướng dẫn, không phải là một công thức cứng nhắc. Để đảm bảo mục tiêu thực sự có giá trị, điều quan trọng là phải luôn xem xét mục tiêu trong bối cảnh chiến lược tổng thể của doanh nghiệp. Một mục tiêu SMART có thể đạt được nhưng nếu không phù hợp với tầm nhìn dài hạn sẽ không mang lại giá trị bền vững.

F. Problem definition worksheet

Để tổng hợp và chuẩn hóa quá trình xác định vấn đề, một **Problem Definition Worksheet (Bảng xác định vấn đề)** là công cụ vô cùng hữu ích. Worksheet này cung cấp một cấu trúc chi tiết để ghi lại các thông tin quan trọng, giúp đảm bảo mọi khía cạnh của vấn đề được xem xét kỹ lưỡng và thống nhất.

Problem statement (Tuyên bố vấn đề)

Mô tả hiện trạng, mục tiêu mong muốn và khoảng cách (gap) cần giải quyết một cách cụ thể và định lượng được.
Ví dụ: Tỷ lệ học sinh vắng mặt không phép hiện tại là **15%** tổng số buổi học hàng tháng. Mục tiêu là giảm tỷ lệ này xuống dưới **5%** trong 6 tháng tới. Khoảng cách cần cải thiện là **10%**.

Success metrics (Các chỉ số thành công)

Bao gồm các chỉ số chính (Primary KPI), chỉ số phụ (Secondary KPIs) và các chỉ số dẫn dắt (Leading Indicators) giúp theo dõi tiến độ và đánh giá tác động của giải pháp.
Ví dụ:
- Primary KPI: Tỷ lệ học sinh vắng mặt không phép đạt 5%.
- Secondary KPIs: Điểm trung bình môn học tăng 5%, tỷ lệ học sinh tham gia hoạt động ngoại khóa tăng 15%.
- Leading Indicators: Số lượt học sinh hỏi bài trên lớp, thời gian truy cập tài liệu học trực tuyến, tỷ lệ hoàn thành bài tập về nhà.

Constraints (Các ràng buộc)

Các giới hạn thực tế về ngân sách, thời gian, yêu cầu kỹ thuật và khả năng cung cấp dữ liệu mà dự án phải tuân thủ.
Ví dụ:
- Ngân sách: 20,000 USD (tối đa 12,000 USD cho giai đoạn phát triển và triển khai thử nghiệm).
- Thời gian: Xây dựng giải pháp thử nghiệm (MVP) trong Q4 2025, triển khai đầy đủ cho toàn trường trong Q1 2026.
- Kỹ thuật: Yêu cầu tích hợp với hệ thống quản lý học sinh (SIS) hiện tại của trường, đảm bảo bảo mật thông tin cá nhân học sinh.
- Dữ liệu: Chỉ có dữ liệu điểm số, lịch sử vắng mặt, thông tin cơ bản về học sinh; không

có dữ liệu về tâm lý hoặc môi trường gia đình.

Assumptions (Các giả định)

Những yếu tố được giả định là đúng để dự án có thể tiến hành. Các giả định này cần được ghi nhận rõ ràng và kiểm tra, xác thực trong quá trình thực hiện dự án.
Ví dụ:
- Về kinh doanh: Việc giảm tỷ lệ vắng mặt sẽ cải thiện kết quả học tập và nâng cao danh tiếng của trường.
- Về kỹ thuật: Dữ liệu hiện có đủ để xây dựng một mô hình dự đoán tương đối chính xác.
- Về hành vi người dùng (học sinh/phụ huynh/giáo viên): Giáo viên sẽ sẵn lòng sử dụng công cụ hỗ trợ và học sinh/phụ huynh sẽ hợp tác khi được can thiệp.

Các công cụ này không chỉ giúp xác định đúng vấn đề của dự án AI mà còn đảm bảo toàn bộ đội ngũ hiểu rõ mục tiêu cần đạt được, với các chỉ số đo lường cụ thể trong khung thời gian và ngân sách cho phép.

II.2. Phân rã vấn đề và nguyên tắc MECE

Trong bất kỳ dự án AI nào, từ phân tích kinh doanh đến khoa học dữ liệu, chúng ta thường đối mặt với những vấn đề lớn và mơ hồ. Việc nhảy thẳng vào phân tích hay xây dựng mô hình mà không có cấu trúc rõ ràng thường dẫn đến lãng phí thời gian, bỏ sót các khía cạnh quan trọng và cuối cùng là một giải pháp không hiệu quả. Đây chính là lúc kỹ năng **phân rã vấn đề (problem decomposition)** trở nên vô giá.

Đây là bước thứ hai trong Framework 7 bước giải quyết các vấn đề trong DS/AI của chúng ta, là một giai đoạn nền tảng quyết định hướng đi cho toàn bộ dự án. Bằng cách chia nhỏ một vấn đề phức tạp thành các phần đơn giản và dễ dàng quản lý về mặt thời gian lẫn độ khó, chúng ta có thể phân tích một cách có hệ thống, xác định nguyên nhân gốc rễ và xây dựng một lộ trình giải quyết hiệu quả.

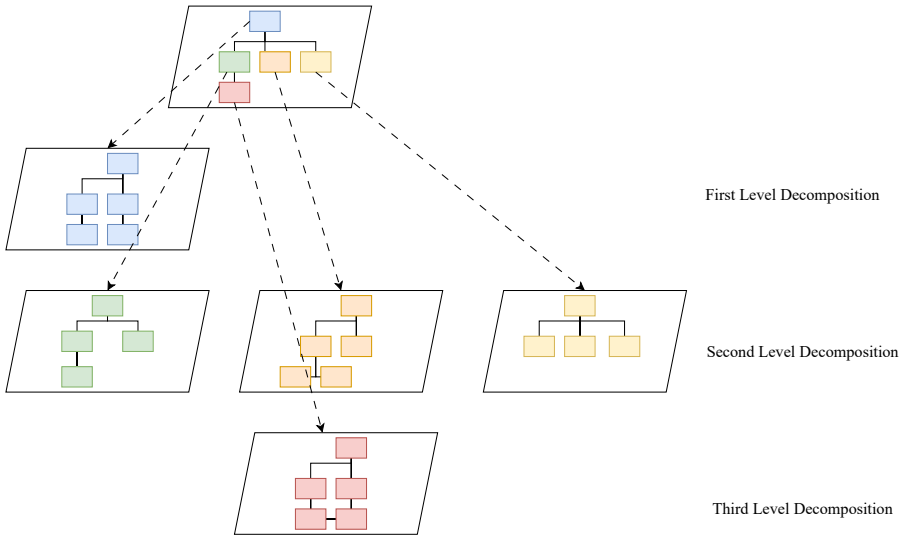

Hình 4: Phân rã vấn đề trong 1 dự án với các tầng khác nhau.

II.2.1. Phương pháp phân rã vấn đề

Tư duy cốt lõi ở đây là **"chia để trị" (divide and conquer)**. Thay vì cố gắng giải quyết một vấn đề khổng lồ, ta phân chia nó thành các thành phần nhỏ hơn, độc lập tương đối để có thể phân tích riêng biệt.

Bối cảnh: Hãy tưởng tượng bạn là một nhà phân tích dữ liệu cho một sàn thương mại điện tử lớn. Ban lãnh đạo giao cho bạn một nhiệm vụ khẩn cấp: "Doanh thu (Sales) quý 2 giảm 20% so với cùng kỳ. Hãy tìm hiểu nguyên nhân." Vấn đề "doanh thu giảm" là quá rộng. Để giải quyết, chúng ta cần phân rã nó.

Bằng cách áp dụng phương pháp này, chúng ta không còn đối mặt với một câu hỏi mơ hồ nữa, mà là một tập hợp các câu hỏi cụ thể cần trả lời:

- **Ngành hàng:** Sự sụt giảm có tập trung ở một ngành hàng cụ thể nào không (ví dụ: Điện tử giảm 35%, May mặc giảm 18%)?
- **Phân khúc khách hàng:** Nhóm khách hàng nào đang rời bỏ chúng ta? Khách hàng mới hay khách hàng trung thành?
- **Kênh Marketing:** Hiệu quả của các kênh quảng cáo có thay đổi không (ví dụ: Tỷ lệ chuyển đổi (Conversion Rate) giảm từ 2.8% xuống 1.5%)?

II.2.2. Nguyên tắc MECE

Phân rã vấn đề là một nghệ thuật, và để thực hiện nó một cách khoa học, chúng ta cần phải tuân theo một bộ các nguyên tắc. Đó chính là **nguyên tắc MECE**. MECE là viết tắt của **Mutually Exclusive** (Loại trừ lẫn nhau) và **Collectively Exhaustive** (Bao quát toàn bộ).

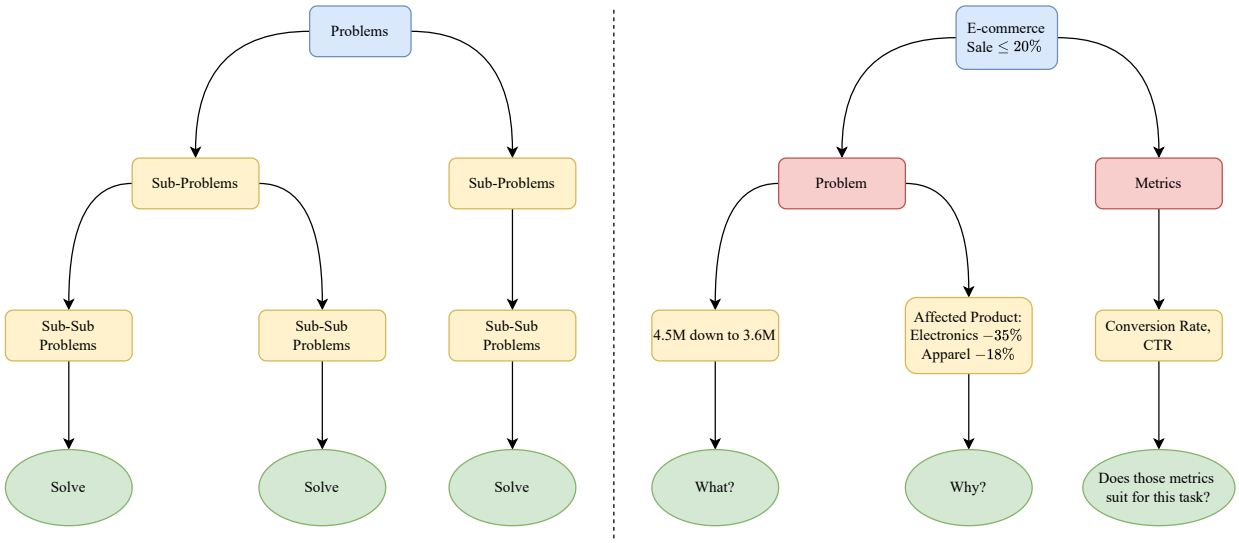

Hình 5: Sơ đồ phân rã vấn đề sụt giảm doanh thu trên sàn thương mại điện tử. Vấn đề lớn được chia thành ba nhánh chính để phân tích: Ngành hàng, Phân khúc khách hàng, và Kênh Marketing.

- **Mutually Exclusive**: Các thành phần sau khi chia nhỏ phải hoàn toàn độc lập, không có sự trùng lặp về nội dung. Điều này đảm bảo chúng ta không phân tích một yếu tố hai lần, tránh lãng phí nỗ lực.
- **Collectively Exhaustive**: Toàn bộ các thành phần sau khi chia nhỏ phải bao quát được 100% vấn đề ban đầu, không bỏ sót bất kỳ khía cạnh quan trọng nào.

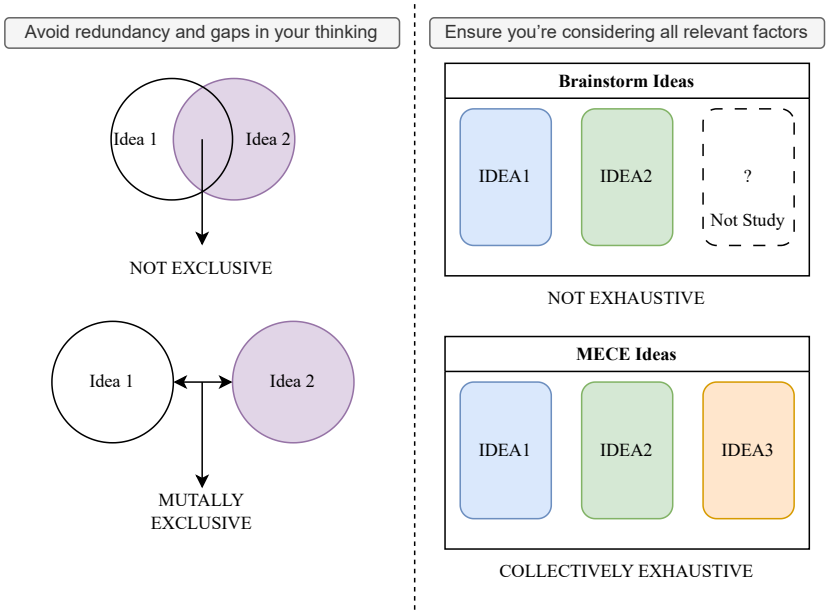

Hình 6: Minh họa nguyên tắc MECE. Các ý tưởng phải vừa không trùng lặp, vừa bao quát hết các khả năng.

Việc áp dụng MECE mang lại lợi thế vượt trội so với phương pháp brainstorm ngẫu nhiên.

Vấn đề của Brainstorming	Lợi ích của MECE
• Ý tưởng trùng lặp và chồng chéo • Bỏ sót những khía cạnh quan trọng • Không có cấu trúc logic • Khó để ưu tiên hóa • Dễ rơi vào tê liệt phân tích (analysis paralysis)	• **Hệ thống:** Bao quát mọi góc độ • **Không trùng lặp:** Không lãng phí nỗ lực • **Có thể ưu tiên:** So sánh rõ ràng • **Dễ truyền đạt:** Trình bày đơn giản • **Có tính hành động:** Rõ ràng các bước tiếp theo

Bảng 3: So sánh giữa phương pháp Brainstorming và phương pháp tiếp cận có cấu trúc MECE.

II.2.3. MECE trong Machine Learning

Lấy ví dụ về MECE trong Machine Learning, việc chia bộ dữ liệu thành các tập Huấn luyện (Train), Kiểm định (Validation), và Kiểm tra (Test) là một ví dụ kinh điển của việc áp dụng nguyên tắc MECE. Các tập này phải loại trừ lẫn nhau (một điểm dữ liệu không thể vừa thuộc tập train vừa thuộc tập test) và phải bao quát toàn bộ (tổng hợp ba tập phải ra được bộ dữ liệu ban đầu). Một sự phân chia không-MECE sẽ dẫn đến việc "rò rỉ dữ liệu" (data leakage) và đánh giá sai hiệu năng của mô hình.

Rò rỉ dữ liệu thường xảy ra dưới hai hình thức chính:

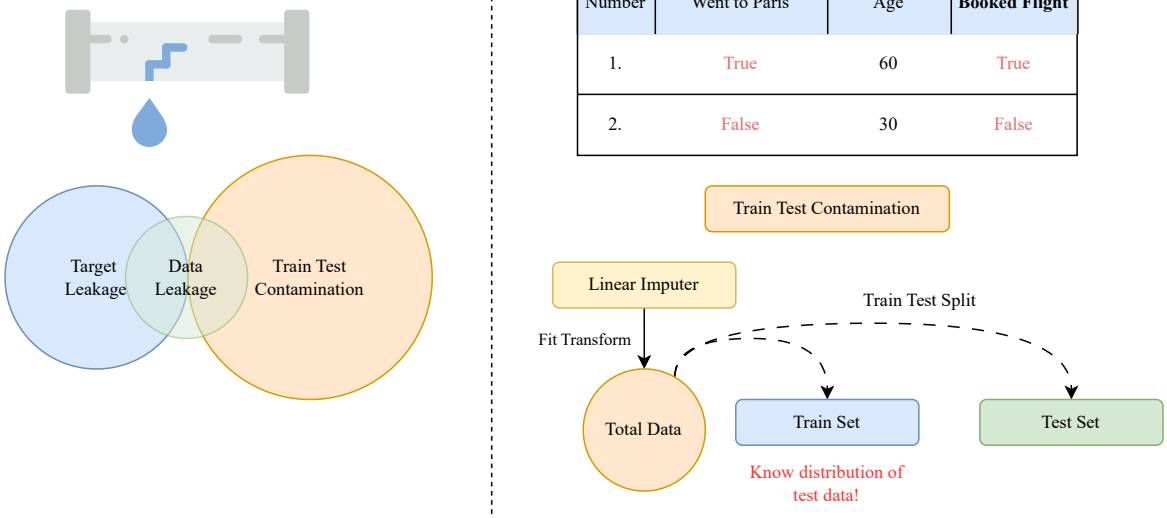

Hình 7: Minh họa hai trường hợp rò rỉ dữ liệu. Ở Target Leakage, ta thấy rằng hai cột tô đỏ hoàn toàn tương quan (correlation) với nhau, và cột "Booked Flight" là cột mục tiêu ta muốn dự đoán. Còn ở Train-Test Contamination, việc dùng một Imputer cho cả bộ dữ liệu dẫn tới dữ liệu huấn luyện biết được phân phối của dữ liệu kiểm tra. Cả hai trường hợp đều khiến mô hình tốt hơn so với thực tế.

- **Rò rỉ mục tiêu (target leakage):** Xảy ra khi các đặc trưng (features) trong tập huấn luyện chứa thông tin về biến mục tiêu, nhưng thông tin này lại không có sẵn tại thời điểm dự đoán trong thực tế. Ví dụ, sử dụng thông tin "đã đặt vé máy bay" để dự đoán một người "có đi Paris hay không". Rõ ràng việc đặt vé xảy ra sau khi có quyết định đi, do đó thông tin này sẽ không có khi cần dự đoán trong thực tế.
- **Nhiễm bẩn tập train-test (train-test contamination):** Xảy ra khi thông tin từ tập kiểm tra (hoặc kiểm định) vô tình bị rò rỉ vào quá trình huấn luyện mô hình. Một ví dụ phổ biến là khi thực hiện các bước tiền xử lý dữ liệu (như điền giá trị thiếu "data imputation" hoặc co giãn dữ liệu "data scaling") trên toàn bộ bộ dữ liệu *trước khi* chia thành các tập huấn luyện và kiểm tra. Điều này khiến mô hình "học" được một phần tri thức từ tập dữ liệu mà lẽ ra nó không được thấy.

II.3. Cây Logic (Logic Trees)

Sau khi đã phân rã vấn đề thành các thành phần MECE, chúng ta cần một công cụ để hệ thống hóa và trực quan hóa mối quan hệ giữa chúng. Việc chỉ liệt kê các ý tưởng ra giấy là chưa đủ. Để thực sự "nhìn thấy" cấu trúc của một vấn đề, chúng ta sử dụng cây Logic.

Đây là một công cụ tư duy trực quan, giúp chúng ta sắp xếp các giả thuyết một cách có trật tự, logic và phân cấp. Nó biến một danh sách phẳng các yếu tố thành một sơ đồ có chiều sâu, cho

phép chúng ta đi từ "triệu chứng" ở cấp cao nhất xuống đến các "nguyên nhân gốc rễ" tiềm năng ở các cấp thấp hơn.

II.3.1. Xây dựng cây Logic từ nguyên tắc cốt lõi

Việc xây dựng một cây logic đòi hỏi tư duy có cấu trúc. Mục tiêu là tạo ra một mô hình hoàn chỉnh của vấn đề, nơi mỗi nhánh con giải thích một phần của nhánh cha.

Hãy bắt đầu với vấn đề chính cần giải quyết (ví dụ: "Doanh thu giảm 20%") làm **gốc của cây**. Sau đó, hãy tự hỏi: "Những yếu tố trực tiếp nào cấu thành nên vấn đề này?" Câu trả lời sẽ tạo thành các nhánh ở cấp độ đầu tiên. Tại mỗi cấp độ của cây, hãy bảo đảm rằng các nhánh được chia ra phải tuân thủ nghiêm ngặt nguyên tắc MECE. Tiếp tục quá trình "bẻ gãy" này cho đến khi chúng ta đạt đến các yếu tố đủ cụ thể để có thể được kiểm chứng bằng dữ liệu.

II.3.2. Áp dụng cây Logic cho bài toán thương mại điện tử

Hãy quay trở lại với bài toán chúng ta đang nói ở phía trên: Doanh thu sàn thương mại điện tử giảm 20%. Thay vì đoán mò, chúng ta sẽ xây dựng một cây logic dựa trên công thức toán học cơ bản của doanh thu. Đây là cách tiếp cận khách quan hơn việc đoán mò nguyên nhân dẫn tới là gì. Công thức của doanh thu có thể được tính như sau:

$$\text{Doanh thu} = (\text{Số lượng đơn hàng}) \times (\text{Giá trị trung bình mỗi đơn hàng})$$

Từ công thức này, chúng ta có thể xây dựng cây Logic như sau:

Với cây logic này, việc điều tra nguyên nhân của chúng ta trở nên tập trung vào những nhân tố chính hơn. Thay vì câu hỏi mơ hồ "Tại sao doanh thu giảm?", giờ đây chúng ta có một loạt các giả thuyết có thể kiểm chứng (testable hypotheses):

- Lượng truy cập ('Traffic') vào website có giảm không?
- Tỷ lệ người dùng thêm hàng vào giỏ nhưng không thanh toán ('Cart Abandonment Rate') có tăng không?
- Khách hàng có mua ít sản phẩm hơn trên mỗi đơn hàng không?
- Hay họ đang chuyển sang mua các sản phẩm có giá trị thấp hơn?

II.4. Ưu tiên hóa (Prioritization)

Sau khi xây dựng một cây Logic chi tiết, ta có hàng chục giả thuyết và nguyên nhân tiềm năng mà ta phải tính đến. Thế nhưng nguồn lực của chúng ta dù là thời gian, nhân sự hay ngân sách thì đều có hạn. Chúng ta không thể giải quyết tất cả mọi thứ cùng một lúc. Vậy, chúng ta nên bắt đầu từ đâu?

Đây chính là lúc kỹ năng ưu tiên hóa phát huy tác dụng. Đây là quá trình có hệ thống để xác định những nhiệm vụ hoặc giải pháp nào sẽ mang lại giá trị lớn nhất với nỗ lực bỏ ra trong các dự án cả lớn và nhỏ. Nó giúp chúng ta tập trung vào những "điểm yếu" mạnh mẽ nhất, thay vì dàn trải nguồn lực một cách lãng phí và không chắc mang lại giá trị thật.

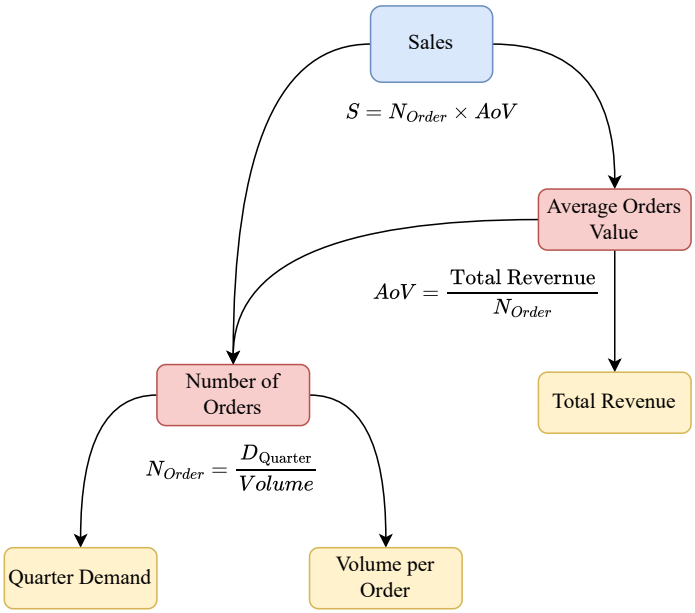

Hình 8: Cây Logic phân rã vấn đề sụt giảm doanh thu. Gốc là "Doanh thu", phân rã thành "Số lượng đơn hàng" và "Giá trị đơn hàng trung bình (AOV)". Mỗi nhánh lại được phân rã tiếp thành các yếu tố cấu thành, tạo ra một lộ trình phân tích rõ ràng.

II.4.1. Impact-Feasibility Matrix

Một trong những công cụ ưu tiên hóa đơn giản và hiệu quả nhất là **ma trận tác động và khả thi** ở dạng 2×2. Ma trận này giúp chúng ta đánh giá các sáng kiến dựa trên hai tiêu chí cốt lõi:

- **Tác động (Impact):** Sáng kiến này sẽ giải quyết được bao nhiêu phần trăm của vấn đề gốc nếu thành công? Mức độ ảnh hưởng của nó đến mục tiêu cuối cùng (ví dụ: doanh thu, sự hài lòng của khách hàng) là gì?
- **Khả thi (Feasibility/Effort):** Để thực hiện sáng kiến này cần bao nhiêu nỗ lực? Mức độ phức tạp về kỹ thuật, chi phí, và thời gian là bao nhiêu?

Bằng cách sắp xếp các giả thuyết hoặc giải pháp vào ma trận, chúng ta có thể phân loại chúng thành bốn nhóm hành động rõ rệt.

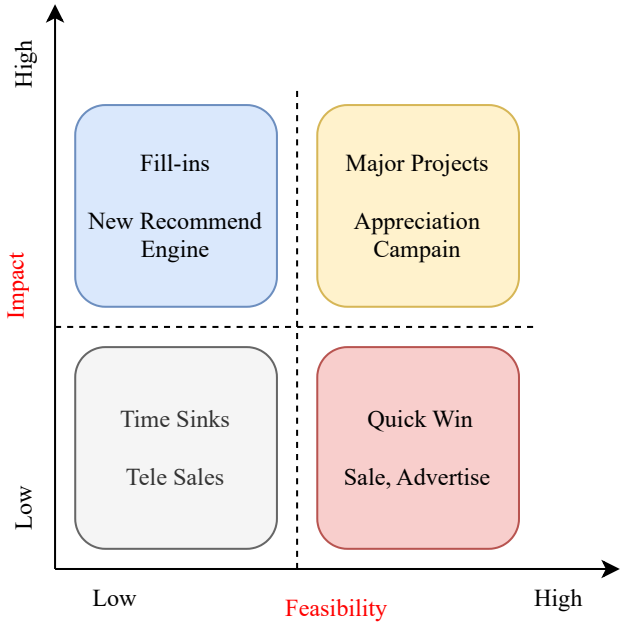

Hình 9: Hình minh họa ma trận tác động - khả thi ở dạng 2×2.

Bốn nhóm chiến lược bao gồm:

1. **Thắng lợi nhanh chóng (Quick Wins):** Tác động cao, Nỗ lực thấp. Đây là những nhiệm vụ ưu tiên hàng đầu mà ta cần thực hiện chúng ngay lập tức để tạo ra giá trị nhanh chóng hay xử lý những vấn đề đang gặp phải.
2. **Dự án lớn (Major Projects):** Tác động cao, Nỗ lực cao. Đây là những sáng kiến chiến lược, có khả năng thay đổi cuộc chơi nhưng đòi hỏi kế hoạch và nguồn lực đáng kể.
3. **Công việc phụ (Fill-ins):** Tác động thấp, Nỗ lực thấp. Chỉ thực hiện khi có thời gian rảnh. Chúng không tạo ra nhiều giá trị nhưng cũng không tốn nhiều công sức.
4. **Lãng phí thời gian (Time Sinks):** Tác động thấp, Nỗ lực cao. Hãy tránh xa những ý tưởng này. Chúng là những cái bẫy ngốn nguồn lực mà không mang lại kết quả tương xứng.

Mô hình trên là một công cụ khởi đầu tuyệt vời để có cái nhìn tổng quan và phân loại nhanh các sáng kiến. Tuy nhiên, trong thực tế, không phải lúc nào các nhiệm vụ cũng rơi vào các thái cực "Cao" hoặc "Thấp" một cách rõ ràng. Nhiều sáng kiến có tác động hoặc đòi hỏi nỗ lực ở mức độ vừa phải.

Để việc lựa chọn nhiệm vụ ưu tiên hóa một cách chính xác và linh hoạt hơn, chúng ta có thể mở rộng ma trận này thành dạng 3×3 bằng cách thêm vào mức độ "Trung bình" (Medium) cho cả hai trục.

II.4.2. Nguyên lý Pareto (80/20)

Làm thế nào để ước tính "Tác động" một cách hiệu quả? Nguyên lý Pareto, hay quy tắc 80/20, là một mô hình tư duy (mental model) hữu ích cho mọi người có dùng thể đưa ra thang điểm

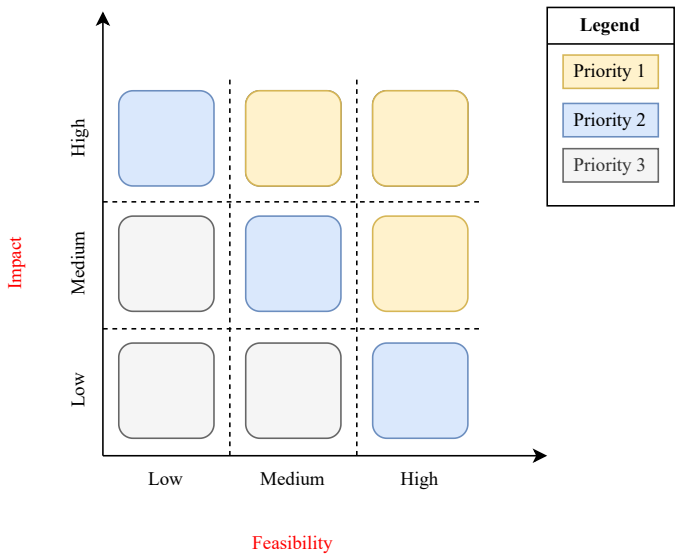

Hình 10: Ma trận tác động - khả thi mở rộng 3 × 3,
thể hiện ba cấp độ ưu tiên để ra quyết định chi tiết hơn.

về việc này. Nguyên lý này phát biểu rằng trong nhiều sự kiện, khoảng 80% kết quả đến từ 20% nguyên nhân.

- 80% doanh thu của bạn có thể đến từ 20% khách hàng trung thành.
- 80% các lỗi phần mềm ('bugs') đến từ 20% các module phức tạp nhất.
- 80% sự sụt giảm doanh thu có thể đến từ 20% các vấn đề cốt lõi.

Khi phân tích cây logic, đừng xem mọi nhánh là như nhau. Hãy tích cực tìm kiếm "20% nguyên nhân cốt lõi" gây nên vấn đề hay là giải pháp của chúng ta. Bằng cách tập trung giải quyết nhóm thiểu số quan trọng này, chúng ta có thể tạo ra phần lớn tác động mong muốn. Nguyên lý Pareto giúp chúng ta xác định các ứng cử viên sáng giá cho ô "Tác động cao" trong ma trận được nói ở trên.

Tổng kết lại, khi muốn vẽ ma trận tác động - khả thi, ta sẽ thực hiện các bước sau:

1. Kẻ một bảng, với mỗi giả thuyết, hãy chấm điểm **Tác động** và **Nỗ lực** trên thang điểm từ 1 đến 10 (trong đó Tác động 10 là cao nhất, Nỗ lực 10 là tốn nhiều công sức nhất).
2. Dựa trên điểm số, hãy xác định mỗi giả thuyết thuộc nhóm nào trong ma trận (Quick Win, Major Project, Fill-in, hay Time Sink).
3. Đưa ra đề xuất: Nhóm của bạn nên ưu tiên thực hiện giải pháp nào **trước tiên**? Tại sao?

II.4.3. Quản lý kỳ vọng

Ta đã dành nhiều tháng để xây dựng một mô hình AI có độ chính xác kỹ thuật rất cao. Nhưng khi trình bày, các bên liên quan (stakeholders) lại thất vọng. Tại sao? Có thể họ mong đợi mô

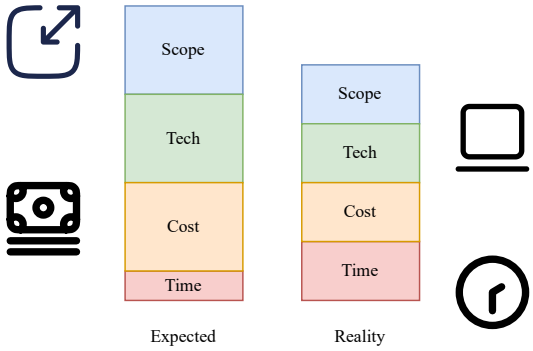

Factor	Expectation	Reality
Scope	Clear and comprehensive	Often reduced to meet deadlines
Tech	High quality	Can be compromised, technical debt
Cost	Within budget	Often over budget
Time	On schedule	Often takes longer than expected

Hình 11: Minh họa các kỳ vọng và thực tế của các dự án AI/DS thường được quan tâm nhất.

hình giải quyết một vấn đề khác, hoặc họ kỳ vọng kết quả sẽ được tích hợp theo một cách hoàn toàn khác. Một giải pháp AI tốt về mặt kỹ thuật vẫn có thể thất bại nếu nó không đáp ứng được kỳ vọng của khách hàng và các cấp quản lý.

Đây là lý do tại sao quản lý kỳ vọng không phải là một "kỹ năng mềm" thứ yếu, mà là một trụ cột thiết yếu trong bất kỳ dự án thành công nào. Đó là quá trình liên tục nhằm đảm bảo tất cả mọi người từ đội ngũ kỹ thuật đến ban lãnh đạo đều có chung một sự thấu hiểu và đồng thuận về mục tiêu, phạm vi và kết quả của dự án.

II.4.4. Xác định mục tiêu, phạm vi, và kết quả đầu ra

Sự mơ hồ là kẻ thù của mọi dự án. Để tránh nó, ta phải làm rõ ba yếu tố nền tảng ngay từ đầu, lý tưởng nhất là trong một **tài liệu khởi động dự án** (project charter). Bộ tài liệu khởi động dự án không nhất thiết phải là một tài liệu hoàn chỉnh, mà có thể là một vài dòng liệt kê để mọi người có thể hiểu các việc sẽ nên làm. Thêm nữa, bộ tài liệu nói trên **chỉ nên có ba điều** được liệt kê để tránh lẫn lộn với kế hoạch dự án và làm phức tạp những điều cần thiết cần biết. Các yếu tố trên được miêu tả như sau:

a. **Mục tiêu (Objectives):** Trả lời câu hỏi "Tại sao chúng ta làm dự án này?". Mục tiêu phải cụ thể, đo lường được, và gắn liền với một chỉ số kinh doanh.
   - *Kém:* "Cải thiện trải nghiệm người dùng."
   - *Tốt:* "Giảm tỷ lệ rời bỏ (churn rate) của người dùng gói Pro từ 5% xuống dưới 3.5% trong vòng 6 tháng tới."

b. **Phạm vi (Scope):** Trả lời câu hỏi "Chúng ta sẽ làm chính xác những gì?". Quan trọng không kém là phải xác định rõ những gì nằm **ngoài phạm vi (out of scope)**. Điều này giúp ngăn chặn hiện tượng "scope creep" sự phình to của các yêu cầu một cách không kiểm soát.
   - *Ngoài phạm vi:* "Xây dựng hệ thống tự động gửi email cho người dùng có nguy cơ rời bỏ."
   - *Trong phạm vi:* "Xây dựng mô hình phân loại để xác định 5 lý do rời bỏ hàng đầu."

c. **Kết quả Đầu ra (Deliverables):** Trả lời câu hỏi "Sản phẩm hữu hình cuối cùng của dự án là gì?". Đây không chỉ là "một mô hình". Nó có thể là:

Churn Rate Dashboard Data - 2025

Target Churn	Current Churn	Status
3.5%	4.1%	On Track

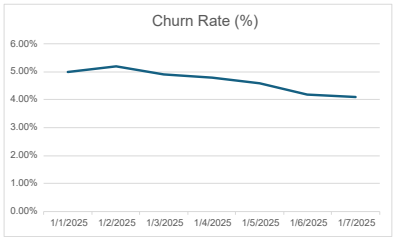

Summary: While churn decreased following the new onboarding launch, it remains above target. The next priority is to improve the mobile UI/UX.

Date	Action	Status	Result	Owner
15/02/2025	Survey churned users	Done	Find 30% of complaints is about mobile	Product
20/05/2025	New user onboarding process	Done	Churn decreased for 0.6%	Dev Team
01/07/2025	Redesign mobile interface.	In Progress	Reduce mobile-related support tickets	Design
15/08/2025	Implement A/B test	To Do	Increase Free-to-Pro conversion rate by 5%	Product
30/08/2025	Build a predictive model	To Do	Enable proactive outreach	Data Scientist

Hình 12: Ví dụ về một dashboard báo cáo tiến độ đơn giản. Nó hiển thị rõ ràng mục tiêu chính (Target Churn), chỉ số hiện tại (Current Churn), xu hướng theo thời gian, và các hành động đã/sẽ thực hiện.

- Một file 'pickle' chứa mô hình đã huấn luyện.
- Một API endpoint để các dịch vụ khác có thể gọi.
- Một báo cáo phân tích chi tiết dưới dạng notebook.
- Một dashboard trực quan hóa kết quả theo thời gian thực.

II.4.5. Giao tiếp và báo cáo tiến độ

Việc thống nhất kỳ vọng ở đầu dự án là cần thiết, nhưng chưa đủ. Kỳ vọng có thể thay đổi, và những hiểu lầm mới có thể nảy sinh. Chìa khóa để ta có thể quản lý điều này là giao tiếp chủ động và đều đặn với mọi thành viên trong nhóm.

Giải quyết việc này ta cần thiết lập một nhịp điệu giao tiếp ('communication cadence') có thể đoán trước. Ví dụ, một email cập nhật ngắn gọn vào mỗi sáng, hoặc một buổi demo sản phẩm 15 phút vào cuối tuần. Việc này xây dựng lòng tin và giúp mọi người cảm thấy được tham gia vào quá trình. Việc giao tiếp điều đặn với nhau sẽ giúp những việc chúng ta làm không đi chệch hướng quá nhiều nếu có sai sót xảy ra.

II.5. Thu thập và phân tích dữ liệu

Trong bất kỳ dự án AI nào, việc chuyển đổi từ một giả định ban đầu sang một giải pháp có căn cứ và hiệu quả đều bắt đầu từ dữ liệu. Một câu nói nổi tiếng trong ngành khẳng định: **"Data is the new oil, but unrefined oil isn't useful"** (Dữ liệu là dầu mỏ mới, nhưng dầu thô thì không hữu dụng). Điều này nhấn mạnh rằng chỉ thu thập thôi là chưa đủ; dữ liệu phải được sàng lọc, phân tích và đánh giá một cách cẩn thận để thực sự mang lại giá trị cho mô hình AI.

Yếu tố	Phía Kỹ thuật	Phía Nghiệp vụ	Xung đột
Khởi tạo dự án	Cung cấp kế hoạch rõ ràng, ước tính nguồn lực và xác định phạm vi.	Nhận được giải pháp cho một vấn đề kinh doanh cụ thể, có ROI dự kiến.	Xây dựng mô hình chỉ vì nó "hay ho" thay vì giải quyết vấn đề chung.
Kết quả ngoài mong đợi	Cung cấp các phát hiện có giá trị từ dữ liệu dù không nằm trong kế hoạch.	Nhận được lợi ích bất ngờ, vượt qua cả KPI đã đề ra ban đầu.	Kỳ vọng rằng các phát hiện đột phá sẽ luôn xảy ra trong mọi dự án.
Khả năng mở rộng	Xây dựng giải pháp với code có thể tái sử dụng, API linh hoạt để tích hợp.	Nhận được một sản phẩm bền vững, có thể mở rộng và tích hợp vào nhiều hệ thống khác.	Xây dựng một giải pháp "mì ăn liền" để có thể demo nhanh, nhưng không thể đưa ra thị trường.
Rủi ro kỹ thuật	Báo cáo minh bạch về các rủi ro đã biết: bias, model drift, vấn đề bảo mật.	Hiểu rõ giới hạn của mô hình và có kế hoạch để giảm thiểu các tác động tiêu cực.	Giấu các kết quả xấu cho đến phút cuối, không có kế hoạch dự phòng.
Tính bất định của việc R&D	Chia sẻ tiến độ nghiên cứu và các kết quả ban đầu.	Thấu hiểu rằng AI không phải phép thuật, kết quả không thể được đảm bảo 100% và cần thời gian khám phá.	Hứa hẹn "chắc chắn đạt 99% độ chính xác" cho một vấn đề chưa từng được giải quyết.
Thay đổi yêu cầu	Cung cấp một quy trình quản lý thay đổi rõ ràng, phân tích tác động của yêu cầu mới lên tiến độ.	Có được sự linh hoạt để điều chỉnh dự án khi có thông tin hoặc điều kiện thị trường mới.	Liên tục thêm yêu cầu mới mà không điều chỉnh thời gian và ngân sách.

Bảng 4: Phân tích ma trận quản lý kỳ vọng trong các dự án AI/Data Science. Bảng mô tả các kỳ vọng và nguồn gốc xung đột tiềm tàng giữa phía kỹ thuật và phía nghiệp vụ.

Đọc thêm tại đây: Link.

Hãy tưởng tượng bạn đang xây dựng một hệ thống gợi ý sản phẩm cho một trang thương mại điện tử. Ban đầu, hệ thống hoạt động kém hiệu quả, các gợi ý không liên quan và tỷ lệ chuyển đổi thấp. Để cải thiện, chúng ta không thể đoán mò. Chúng ta cần **bằng chứng** nằm trong dữ liệu từ người dùng.

II.5.1. Những câu hỏi cốt lõi

Trước khi bắt tay vào thu thập, đội ngũ phát triển cần trả lời một loạt câu hỏi chiến lược để định hình hướng đi. Quá trình này giúp tiết kiệm nguồn lực và đảm bảo dữ liệu thu về có thể sử dụng được. Các câu hỏi này bao gồm:

- **Loại dữ liệu nào cần thu thập?** Chúng ta cần dữ liệu gì để hiểu người dùng và vấn đề? Ví dụ: hồ sơ người dùng (user profiles), dữ liệu tương tác (lịch sử click, thời gian xem trang), lịch sử mua hàng (purchase history), và các chỉ số hệ thống (system metrics).
- **Tìm dữ liệu ở đâu (Nguồn)?** Dữ liệu này đang tồn tại ở đâu trong hệ thống của bạn hoặc bên ngoài? Các nguồn có thể là cơ sở dữ liệu nội bộ (databases), các giao diện lập trình ứng dụng (APIs), khảo sát người dùng (surveys), hoặc file ghi lại hoạt động (logs). Lưu ý: nếu nguồn của các bạn sử dụng là một website, hãy kiểm tra file robot.txt từ website đó.
- **Sử dụng phương pháp nào?** Làm thế nào để trích xuất dữ liệu từ các nguồn đã xác định? Các phương pháp phổ biến bao gồm viết truy vấn SQL (SQL queries), cào dữ liệu web (web scraping), hoặc thiết lập các thử nghiệm A/B (A/B testing).
- **Làm sao để đảm bảo chất lượng?** Đây là bước cực kỳ quan trọng. Chúng ta cần một quy trình để kiểm tra và đảm bảo chất lượng dữ liệu, thường xoay quanh các tiêu chí như tính đầy đủ (completeness), độ chính xác (accuracy), tính nhất quán (consistency), và tính kịp thời (timeliness).

II.5.2. Các Phương pháp Thu thập Dữ liệu

Thu thập dữ liệu cho AI là một quá trình đa dạng và có chiều sâu. Chúng ta có thể phân loại các phương pháp chính vào bốn nhóm như sau:

II.5.3. Thu thập trực tiếp (Direct Collection)

Phương pháp này tập trung vào việc tương tác trực tiếp với người dùng hoặc môi trường để thu thập dữ liệu định tính (qualitative insights).

- **Phỏng vấn 1-1:** Giúp hiểu sâu về hoạt động, môi trường, và tương tác của người dùng.
- **Nhóm tập trung (Focus groups):** Thảo luận với một nhóm nhỏ (6-8 người) để thu thập ý kiến và cảm tính (sentiment).
- **Nghiên cứu theo ngữ cảnh (Contextual inquiry):** Quan sát người dùng trong môi trường làm việc thực tế của họ.

- **Nhật ký người dùng (User diary studies):** Yêu cầu người dùng ghi lại trải nghiệm của họ trong một khoảng thời gian (ví dụ: 7-14 ngày).

II.5.4. Khai thác nguồn sẵn có (Exploiting Existing Sources)

Tận dụng các nguồn dữ liệu đã và đang được tạo ra giúp tiết kiệm tài nguyên đáng kể.

- **Dữ liệu click-stream:** Phân tích luồng di chuyển của người dùng trên trang web bằng các công cụ như Hotjar hoặc Google Analytics 4.
- **Nhật ký hệ thống (System logs):** Khai thác logs từ các hệ thống như ELK Stack để tìm ra các mẫu sử dụng hoặc lỗi.
- **Bộ dữ liệu công khai (Public Datasets):** Dùng các bộ dữ liệu từ Kaggle, Google's Open Images, hoặc các kho lưu trữ học thuật.
- **Mạng xã hội (Social media):** Phân tích cảm tính từ các nền tảng mạng xã hội bằng các công cụ như VADER.

II.5.5. Thí nghiệm và Thử nghiệm (Experimentation & Testing)

Chủ động tạo ra dữ liệu thông qua các thí nghiệm có kiểm soát để xác thực giả thuyết.

- **Thử nghiệm A/B (A/B testing):** So sánh hai phiên bản của một sản phẩm để xem phiên bản nào hoạt động tốt hơn dựa trên một chỉ số cụ thể.
- **Theo dõi ánh mắt (Eye-tracking):** Tích hợp các thiết bị như Tobii Pro Glasses để biết người dùng đang nhìn vào đâu.
- **Ghi lại phiên làm việc (Session recordings):** Các công cụ như FullStory ghi lại toàn bộ tương tác của người dùng, giúp phát hiện các điểm "rage clicks" hay do dự.

II.5.6. Hợp tác và Mua dữ liệu (Collaboration & Purchase)

Khi dữ liệu nội bộ không đủ, việc tìm đến các nguồn bên ngoài là một lựa chọn hợp lý.

- **Sàn giao dịch dữ liệu (Data exchange platforms):** Các nền tảng như Snowflake Data Marketplace và AWS Data Exchange.
- **API chuyên biệt:** Sử dụng các API trả phí cho các tác vụ cụ thể, ví dụ như NLP Cloud cho xử lý ngôn ngữ tự nhiên.
- **Bộ dữ liệu ngành:** Mua dữ liệu từ các công ty nghiên cứu thị trường như Nielsen.
- **Thuê ngoài cộng đồng (Crowdsourcing):** Sử dụng các nền tảng như Amazon Mechanical Turk hoặc Scale AI để gán nhãn dữ liệu trên quy mô lớn.

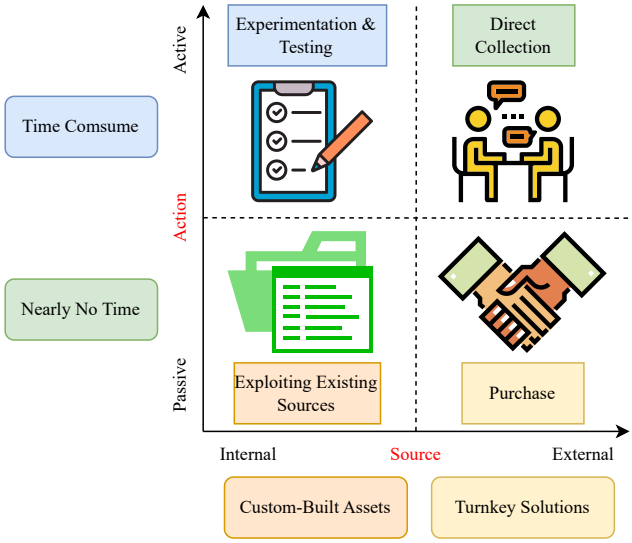

Hình 13: Phân loại bốn nhóm phương pháp thu thập dữ liệu cho AI theo hai trục: nguồn dữ liệu (nội bộ - bên ngoài) và mức độ chủ động (thụ động - tích cực).

II.5.7. Đánh giá chất lượng dữ liệu

Nguyên tắc vàng "Rác đầu vào, Rác đầu ra" **(Garbage In, Garbage Out)** là kim chỉ nam cho mọi dự án AI. Việc đánh giá chất lượng dữ liệu **trước khi** phát triển mô hình giúp tránh lãng phí thời gian và nguồn lực. Một đánh giá toàn diện dựa trên 6 tiêu chí sau đây là cực kỳ cần thiết cũng như cô đọng để mọi người có thể theo dõi và thực hành theo.

II.6. Quy trình phân tích dữ liệu

Sau khi đã thu thập và đánh giá chất lượng dữ liệu, bước tiếp theo là biến khối dữ liệu thô đó thành những dữ liệu có thể dùng được. Đây không phải là một hành động đơn lẻ mà là một quy trình có hệ thống, đặc biệt quan trọng trong các dự án phức tạp. Một quy trình phân tích chuẩn sẽ đảm bảo rằng dữ liệu dùng để đưa ra các quyết định được đảm bảo đúng đắn.

Quy trình này thường được chia thành bốn bước chính. Đáng chú ý, phần lớn thời gian và công sức của một người làm khoa học dữ liệu không nằm ở việc xây dựng mô hình, mà ở giai đoạn chuẩn bị và làm sạch dữ liệu ban đầu.

II.6.1. Bước 1: Làm sạch dữ liệu *(Khoảng 40% thời gian)*

Đây là giai đoạn nền tảng và tốn nhiều công sức nhất. Dữ liệu trong thực tế luôn lộn xộn: có thể bị trùng lặp, thiếu sót, sai định dạng, hoặc chứa các giá trị bất thường. Mục tiêu của bước này là xử lý dữ liệu thô để đảm bảo tính chính xác và nhất quán.

- **Loại bỏ bản ghi trùng lặp (Deduplication):** Xóa các ID người dùng hoặc giao dịch bị lặp lại.
- **Xử lý giá trị ngoại lệ (Outlier Handling):** Phát hiện và xử lý các mốc thời gian (timestamps) hoặc giá trị bất thường không tuân theo logic thông thường.

Tiêu chí	Mô tả và Ví dụ
Tính chính xác (Accuracy)	Dữ liệu phản ánh đúng thực tế. *Ví dụ: Địa chỉ khách hàng khớp với hệ thống bưu chính.*
Tính đầy đủ (Completeness)	Tất cả các trường dữ liệu cần thiết đều có mặt, không có giá trị bị thiếu (null/missing) ở những cột quan trọng. *Ví dụ: Mọi giao dịch đều phải có mã khách hàng và số tiền.*
Tính nhất quán (Consistency)	Dữ liệu được định dạng đồng nhất trong toàn bộ tập dữ liệu. *Ví dụ: Ngày tháng có cùng định dạng 'YYYY-MM-DD', đơn vị tiền tệ được quy về một loại duy nhất.*
Tính kịp thời (Timeliness)	Dữ liệu được cập nhật và phản ánh tình trạng hiện tại. *Ví dụ: Dữ liệu tồn kho được cập nhật theo thời gian thực thay vì theo ngày.*
Tính hợp lệ (Validity)	Dữ liệu tuân thủ các quy tắc nghiệp vụ đã định sẵn. *Ví dụ: Cột tuổi chỉ chứa giá trị từ 0-120, email phải có định dạng hợp lệ.*
Tính duy nhất (Uniqueness)	Không có bản ghi nào bị trùng lặp. *Ví dụ: Mỗi khách hàng chỉ có một mã ID duy nhất trong hệ thống.*

Bảng 5: Sáu tiêu chí cốt lõi trong Đánh giá Chất lượng Dữ liệu.

- **Chuẩn hóa dữ liệu (Standardization):** Đưa các trường dữ liệu về cùng một định dạng, ví dụ như chuẩn hóa cột 'timestamp' về định dạng DD/MM/YYYY.

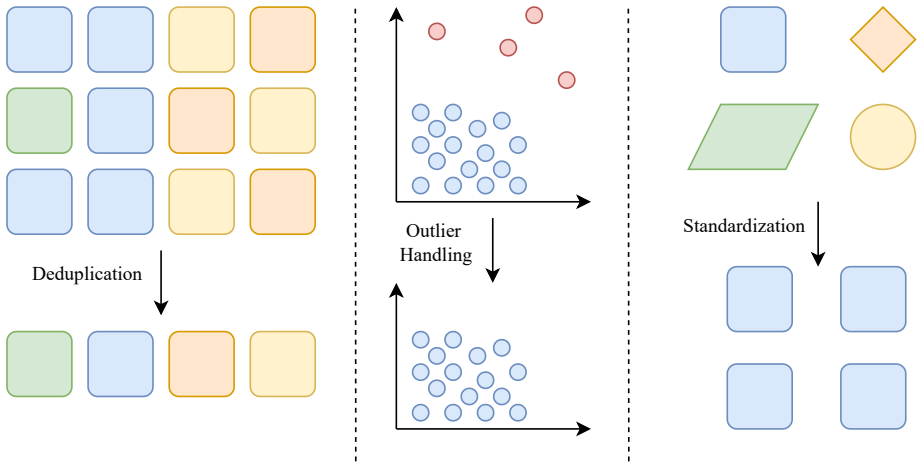

Hình 14: Các phương thức tiền xử lý dữ liệu thường gặp.

II.6.2. Bước 2: Phân tích khám phá dữ liệu *(Khoảng 30% thời gian)*

Sau khi dữ liệu đã sạch, chúng ta bắt đầu phân tích nó. *Phân tích khám phá dữ liệu (EDA)* là quá trình sử dụng các **kỹ thuật thống kê và trực quan hóa** để tìm ra các mẫu, các mối quan

hệ, và các điểm bất thường. Mục tiêu ở đây là hình thành các giả thuyết ban đầu.

- **Phân tích phân phối:** Sử dụng biểu đồ histogram để xem phân phối của các hành vi (ví dụ: số lần mua hàng, giá trị đơn hàng).
- **Phân tích tương quan:** Tìm kiếm mối tương quan giữa các biến, ví dụ như giá sản phẩm và tỷ lệ nhấp chuột (Click-Through Rate - CTR).
- **Phân khúc người dùng (User Segmentation):** Áp dụng các mô hình như RFM (Recency, Frequency, Monetary) để phân nhóm người dùng (ví dụ: khách hàng trung thành, khách hàng có nguy cơ rời bỏ).

II.6.3. Bước 3: Phân tích chẩn đoán *(Khoảng 20% thời gian)*

Nếu EDA giúp ta trả lời câu hỏi "Cái gì đã xảy ra?", thì phân tích chẩn đoán sẽ trả lời câu hỏi "Tại sao nó lại xảy ra?". Bước này đi sâu vào việc xác định nguyên nhân gốc rễ của các hiện tượng quan sát được.

- **Xác định nguyên nhân gốc rễ:** Điều tra tại sao một chỉ số quan trọng (ví dụ: CTR) lại giảm đột ngột.
- **Kiểm định giả thuyết:** Sử dụng các phương pháp thống kê hoặc mô hình hồi quy để kiểm tra mối quan hệ nhân quả (correlation), ví dụ như thời gian xem ảnh hưởng đến quyết định mua hàng.
- **Phân tích kết quả A/B testing:** Đánh giá hiệu quả của các phiên bản khác nhau để đưa ra quyết định sản phẩm.

II.6.4. Bước 4: Tạo ra actionable insights *(Khoảng 10% thời gian còn lại)*

Đây là bước cuối cùng và cũng là mục tiêu cao nhất của phân tích dữ liệu: chuyển đổi những con số và biểu đồ thành các đề xuất kinh doanh cụ thể, có thể đo lường được. Toàn bộ bước phân tích dữ liệu chỉ có ý nghĩa khi ta biến nó thành hành động.

- **Đề xuất tối ưu:** Dựa trên kết quả phân tích, đề xuất các thay đổi cụ thể (ví dụ: "Tăng ngân sách marketing cho kênh X vào Quý 3 vì đây là mùa cao điểm").
- **Thiết lập lộ trình (Roadmap):** Xây dựng một kế hoạch cải tiến sản phẩm hoặc chiến dịch dựa trên dữ liệu.
- **Truyền đạt kết quả:** Xây dựng câu chuyện dữ liệu (data story) và trình bày cho các bên liên quan một cách dễ hiểu.
- **Xây dựng Dashboard:** Thiết lập các bảng điều khiển (dashboards) để theo dõi các chỉ số hiệu suất chính (KPIs) một cách tự động và liên tục.

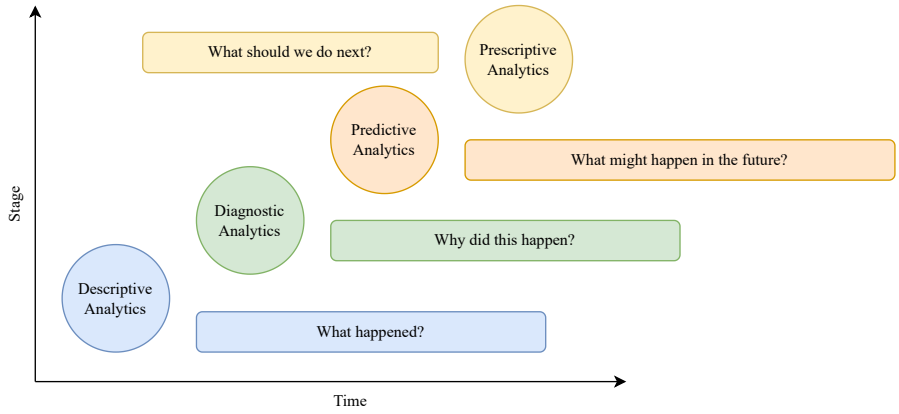

Hình 15: Các giai đoạn của từng bước phân tích dữ liệu, và các câu hỏi mà những bước này trả lời.

II.7. Quy trình thiết kế giải pháp AI

Trong bối cảnh công nghiệp, một mô hình AI có độ chính xác 99% nhưng không giải quyết được bài toán kinh doanh thực tế là một thất bại. Ngược lại, một mô hình đơn giản hơn nhưng tạo ra tác động thương mại rõ rệt lại được ưu tiên hơn. Do đó, việc thiết lập một **quy trình thiết kế giải pháp (solution design process)** có cấu trúc là yêu cầu tiên quyết để đảm bảo các dự án AI không chỉ khả thi về mặt kỹ thuật mà còn mang lại giá trị thực tiễn cho doanh nghiệp.

Chúng ta sẽ đi qua bốn giai đoạn cốt lõi, được minh họa bằng một case study thực tế về dự báo nhu cầu trong ngành bán lẻ như sau.

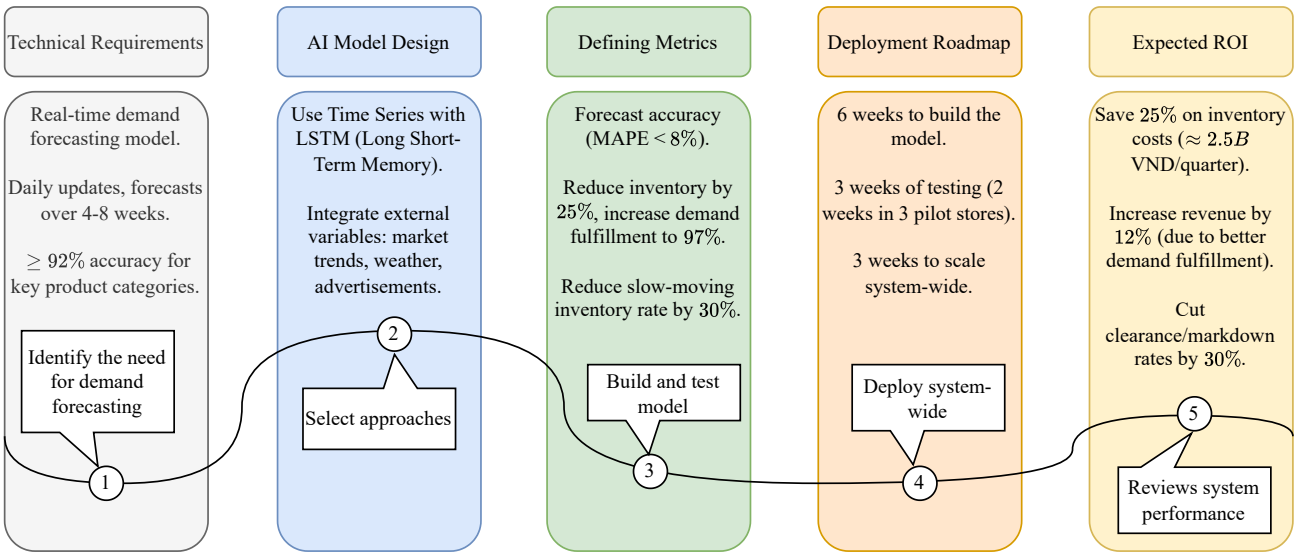

Hình 16: Case study về quy trình thiết kế giải pháp AI cho bài toán dự báo nhu cầu bán lẻ. Roadmap được thiết kế từ insight của các bước trước rằng dữ liệu mùa vụ, xu hướng là nền tảng để giảm tồn kho 25% và tăng tỷ lệ đáp ứng nhu cầu lên đến 97%.

II.7.1. Giai đoạn 1: Xác định mục tiêu

Các giải pháp AI đều nên bắt đầu bằng việc xác định một mục tiêu kinh doanh rõ ràng và có thể đo lường được. Ta cần trả lời câu hỏi: "Chúng ta đang cố gắng giải quyết vấn đề gì, và thành công trông như thế nào?" Mục tiêu phải phù hợp với chiến lược tổng thể và giải quyết được **nguyên nhân gốc rễ (root cause)** của vấn đề. Việc đặt ra một mục tiêu có thể đo lường được tránh cho chúng ta gặp phải sự không rõ ràng những gì phải làm trong dự án.

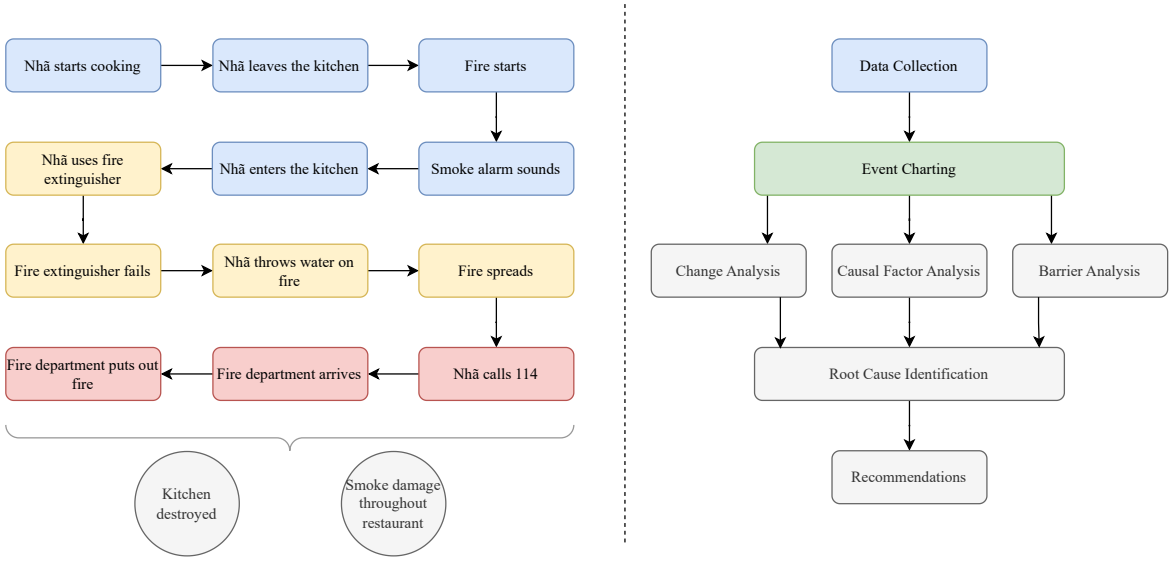

Hình 17: Ứng dụng phương pháp Event Charting trong phân tích nguyên nhân gốc sự cố.

Ví dụ, để biết được nguyên nhân tại sao đám cháy không được xử lý nhanh chóng, ta sẽ dùng phương pháp **Event Charting** như ở hình 17. Phương pháp này là một kỹ thuật phân tích trực quan nhằm xác định và sắp xếp trình tự các sự kiện dẫn đến một sự cố. Mỗi hành động, phản ứng, và thất bại được mô tả dưới dạng một chuỗi sự kiện liên tiếp, giúp phát hiện các nguyên nhân tiềm ẩn, rào cản và điểm cần cải thiện. Đây là bước trung gian quan trọng trong quá trình phân tích nguyên nhân gốc (Root Cause Analysis), hỗ trợ đưa ra các khuyến nghị cụ thể để phòng tránh tái diễn sự cố.

Việc áp dụng các phương pháp như Event Charting, 5 Whys, Pareto Chart,... sẽ giúp ta đi đến được chính xác điểm bắt đầu của vấn đề, đồng thời loại bỏ sự bất đồng quan điểm trong việc phân tích này. Các framework trên đồng thời hỗ trợ ta tránh xử lý các vấn đề đệ quy lặp lại mà không mang lại kết quả, cũng sử dụng cách giải quyết tạm thời mà không dứt điểm.

II.7.2. Giai đoạn 2: Phát triển phương án

Sau khi có mục tiêu, đội ngũ sẽ tiến hành **brainstorming** các phương án khả thi dựa trên dữ liệu và phân tích. Giai đoạn này cần sự sáng tạo nhưng phải dựa trên nguyên tắc **MECE** được nói ở phần II.2.2. để đảm bảo không bỏ sót hướng tiếp cận nào. Các phương án cần cân bằng giữa kỹ thuật, giao diện người dùng (UI), và khả năng tích hợp. Một kế hoạch tốt không nên thiếu thành phần nào được liệt kê ở trên.

II.7.3. Giai đoạn 3: Đánh giá và lựa chọn

Không phải mọi ý tưởng hay đều khả thi. Giai đoạn 3 này ta cần sử dụng các ma trận đánh giá, như **ma trận tác động khả thi** ở chương II.4.1., để lựa chọn phương án tối ưu. Các tiêu chí đánh giá bao gồm: tác động kinh doanh, chi phí triển khai, rủi ro kỹ thuật, và thời gian hoàn thành.

Xác định mục tiêu và lộ trình

- **Mục tiêu cụ thể (Specific Goal):** Thay vì mục tiêu chung chung, hãy xác định rõ ràng: "Tăng **CTR** của Recommendation Engine thêm 2% lên 8% trong vòng 3 tháng tới."
- **Phương án kỹ thuật (Technical Solution):** Để giải quyết bài toán dự báo nhu cầu bán lẻ, phương án có thể là: "Áp dụng mô hình **Time Series LSTM** và kết hợp các biến ngoại sinh (xu hướng thị trường, thời tiết, quảng cáo) để tăng độ chính xác."
- **Ưu tiên hóa (Prioritization):** Một giải pháp có **tác động cao** (cải thiện 80% CTR) nhưng đòi hỏi 2 năm R&D có thể sẽ được xếp sau một giải pháp khác có tác động trung bình nhưng chỉ cần 2 tuần để triển khai.
- **Chỉ số đo lường (Metrics):** Xác định rõ các chỉ số thành công cho bài toán bán lẻ: Độ chính xác dự đoán **MAPE (Mean Absolute Percentage Error)** $< 8\%$, tồn kho giảm 25%, và tỷ lệ đáp ứng nhu cầu đạt 97%.
- **Lộ trình triển khai (Roadmap):** Chia nhỏ kế hoạch thành các giai đoạn cụ thể, ví dụ: 6 tuần xây dựng mô hình, 3 tuần testing lịch sử, 2 tuần thử nghiệm, và 3 tuần triển khai toàn hệ thống.

II.7.4. Giai đoạn 4: Triển khai và theo dõi

Sau khi ta có được một kế hoạch đầy đủ các bước cần làm, việc triển khai cũng là một phần quan trọng cần chú ý trong các dự án AI/DS. Phương án được chọn sẽ được triển khai theo một lộ trình cụ thể, với việc đo lường hiệu quả song song với việc phát triển. Các kỹ thuật như **A/B testing** thường được sử dụng để so sánh phiên bản mới với phiên bản cũ trên một nhóm nhỏ người dùng trước khi triển khai trên toàn bộ hệ thống.

II.7.5. Các phương pháp thiết kế giải pháp AI

Sau khi nói qua các bước tạo ra một hệ thống giải quyết các vấn đề tồn đọng. Sau đây là bốn phương pháp hiệu quả giúp chúng ta tư duy một cách có cấu trúc để tìm ra giải pháp AI tốt nhất cho từng mục được nói ở trên.

Phương pháp	Mô tả và ứng dụng
Brainstorming có cấu trúc	Sử dụng tập hơn các thành viên đa ngành và một bộ quy tắc rõ ràng (ví dụ: không phán xét ý tưởng) để tạo ra một lượng lớn ý tưởng. Sau đó, phân loại ý tưởng theo nguyên tắc **MECE** (Mutually Exclusive, Collectively Exhaustive) giúp bao quát mọi khía cạnh của vấn đề.
Kỹ thuật SCAMPER	Đây là một checklist các câu hỏi khơi gợi sự sáng tạo, giúp biến đổi các giải pháp hiện có thành những ý tưởng mới. Các hành động bao gồm: **S**ubstitute (Thay thế), **C**ombine (Kết hợp), **A**dapt (Điều chỉnh), **M**odify (Sửa đổi), **P**ut to another use (Sử dụng cho mục đích khác), **E**liminate (Loại bỏ), và **R**everse (Đảo ngược).
Đối sánh chuẩn	Phân tích các vấn đề ta đang giải quyết, các giải pháp của đối thủ cạnh tranh, hoặc các bài báo khoa học để ta không rơi vào việc "phát minh lại bánh xe" và nhanh chóng tiếp cận các giải pháp đã được chứng minh hiệu quả trong vấn đề của mình.
Xây dựng nguyên mẫu	Phát triển một phiên bản tối thiểu khả thi (**MVP - Minimum Viable Product**), thực hiện kiểm thử A/B, hoặc xây dựng một giao diện demo để trình bày với các stakeholder. Cách tiếp cận này giúp kiểm tra nhanh tính khả thi và tiềm năng của giải pháp trước khi đầu tư nguồn lực lớn để triển khai đầy đủ.

Bảng 6: Bốn phương pháp chính trong việc thiết kế giải pháp AI hiệu quả.

Để minh họa, hãy xem cách áp dụng kỹ thuật **SCAMPER** vào bài toán dự đoán *customer churn* mà chúng ta đã làm quen ở bài tập trước.

Sử dụng SCAMPER để định hình lại bài toán

Ví dụ: Áp dụng cho bài toán dự đoán Customer Churn

- **Substitute:** Thay vì dự đoán khả năng rời bỏ của người dùng bằng các biến nhị phân (Yes/No), chúng ta có thể thay thế bằng việc dự đoán **giá trị trọn đời (Lifetime Value - LTV)** của khách hàng không?
- **Combine:** Chúng ta có thể kết hợp dữ liệu giao dịch với dữ liệu từ mạng xã hội để hiểu rõ hơn về tâm tư của khách hàng không?

- **Adapt:** Có thể điều chỉnh một mô hình phát hiện gian lận thẻ tín dụng để áp dụng cho việc phát hiện hành vi churn không? Cả hai đều tìm kiếm các mẫu hành vi bất thường.
- **Modify:** Thay vì chỉ đưa ra xác suất churn, liệu mô hình có thể điều chỉnh đầu ra bằng XAI để cung cấp **3 lý do hàng đầu** khiến khách hàng có nguy cơ rời bỏ không?
- **Put to another use:** Mô hình dự đoán churn có thể dùng để xác định các **khách hàng trung thành nhất** và thực hiện các chiến dịch *upsell* không?
- **Eliminate:** Chúng ta có thể loại bỏ các feature khó thu thập để mô hình đơn giản, dễ diễn giải và chạy nhanh hơn không?
- **Reverse:** Đảo ngược vấn đề: thay vì dự đoán "ai sẽ rời đi", chúng ta xây dựng mô hình dự đoán "làm thế nào để một khách hàng ở lại thêm 6 tháng?"

II.8. Kỹ thuật trình bày

Trong lĩnh vực trí tuệ nhân tạo, một mô hình kỹ thuật xuất sắc chỉ là một nửa của trận chiến. Nửa còn lại, và thường là phần quyết định của các bên liên quan, nằm ở **khả năng trình bày** giải pháp một cách thuyết phục cho các bên liên quan từ ban lãnh đạo, các phòng ban kinh doanh đến đội ngũ kỹ thuật. Một giải pháp dù mạnh mẽ đến đâu cũng sẽ trở nên vô nghĩa nếu không được tin tưởng và triển khai. Phần này sẽ giới thiệu một framework trình bày đã được kiểm chứng để giúp ta cấu trúc và truyền đạt các đề xuất về AI một cách hiệu quả nhất.

II.8.1. Nền tảng: Nguyên lý hình chóp

Nguyên lý hình chóp (Pyramid Principle) là một phương pháp cấu trúc cách thông tin nên được trình bày do Barbara Minto phát triển. Nguyên tắc cốt lõi của phương pháp này là: **Bắt đầu bằng câu trả lời trước**. Chúng ta đưa ra thông điệp chính, kết luận quan trọng nhất ngay từ đầu cho người nghe, sau đó mới đi vào các luận điểm và bằng chứng hỗ trợ chi tiết. Cách tiếp cận "top-down" này giúp người nghe nắm bắt ngay lập tức ý tưởng của ta và theo dõi logic một cách dễ dàng.

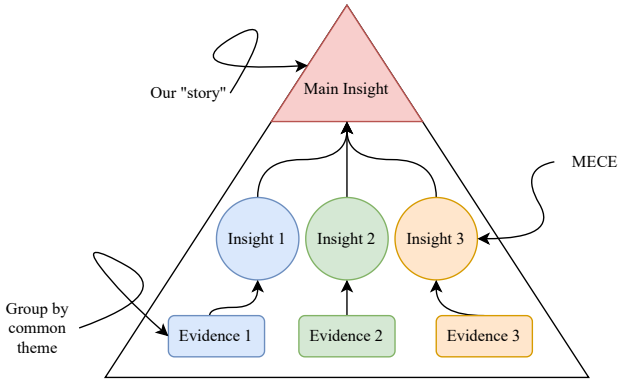

Hình 18: Cấu trúc của nguyên lý hình chóp. Thông điệp chính (Main Insight) ở đỉnh được hỗ trợ bởi các luận điểm (Insights) và được chứng minh bởi các bằng chứng cụ thể (Evidence) ở nền tảng. Cấu trúc này đảm bảo lập luận chặt chẽ và dễ theo dõi **strategyu_pyramid**.

Cấu trúc này bao gồm ba tầng chính:

- **Thông điệp chính**: Một câu duy nhất, súc tích, **định lượng được**, trả lời cho câu hỏi cốt lõi của người nghe. Đây là "kết luận" của ta.
- **Các luận điểm ủng hộ**: Từ 2-3 luận điểm chính nhằm giải thích **tại sao** thông điệp chính của chúng ta là đúng. Mỗi luận điểm phải logic và có tính thuyết phục cao.
- **Bằng chứng**: Dữ liệu, số liệu cụ thể, kết quả phân tích, hoặc các quan sát thực tế để chứng minh cho các luận điểm ủng hộ. Đây là nền tảng không thể thiếu của mọi lập luận.

II.8.2. Case Study: Áp dụng vào bài toán hệ thống gợi ý

Để biến lý thuyết thành thực tiễn, hãy cùng phân tích một ví dụ về việc đề xuất một hệ thống gợi ý được miêu tả ở trên. Nhóm AI cần thuyết phục ban lãnh đạo đầu tư vào dự án này.

Case Study: Đề xuất hệ thống gợi ý.	
Thông điệp chính	**Triển khai hệ thống khuyến nghị kết hợp *collaborative filtering* và *content-based* để đạt mục tiêu CTR 8% và tăng doanh số 15% trong 3 tháng.**
Các luận điểm	1. Giải quyết nguyên nhân gốc rễ (thiếu dữ liệu hành vi người dùng và metadata sản phẩm). 2. Thời gian triển khai nhanh chỉ 8 tuần so với 24 tuần khi cải tổ toàn bộ ML pipeline. 3. Chi phí triển khai thấp hơn 60% so với xây dựng lại. 4. Đã chứng minh CTR 6-8% và tăng thời gian dừng lại trên sàn sản phẩm 20% tại các nhà bán lẻ tương tự.
Bằng chứng	1. **Nghiên cứu người dùng**: từ 500 khách hàng cho thấy 80% ưa chuộng các khuyến nghị dựa trên lịch sử duyệt web. 2. **Đánh giá kỹ thuật**: Tích hợp API có sẵn giúp triển khai trong 8 tuần với 1 data scientist và 2 ML engineers. 3. **Phân tích ROI**: cho thấy mỗi 1% tăng CTR mang lại doanh thu tăng thêm 120 triệu đồng/tháng.

Bảng 7: Ví dụ áp dụng nguyên lý hình chóp để trình bày giải pháp hệ thống gợi ý.

II.8.3. Từ lập luận đến cấu trúc toàn diện

Nguyên lý hình chóp là framework con cho từng lập luận của ta. Để có một bài trình bày hoàn chỉnh, cần đặt các "kim tự tháp" này vào một framework tổng lớn hơn. Đây chính là khung sườn 5 bước mà các chuyên gia tại Google, McKinsey hay các công ty công nghệ lớn thường sử dụng.

Mỗi phần trong framework này (ví dụ: *Problem Analysis*, *Solution Design*) đều có thể được trình bày theo nguyên lý hình chóp. Ví dụ, trong phần *Solution Design*, thông điệp chính sẽ là "Chúng tôi đề xuất kiến trúc X," được hỗ trợ bởi các luận điểm về tính khả thi, khả năng mở rộng, và được chứng minh bằng các sơ đồ kỹ thuật và kết quả PoC (Proof of Concept).

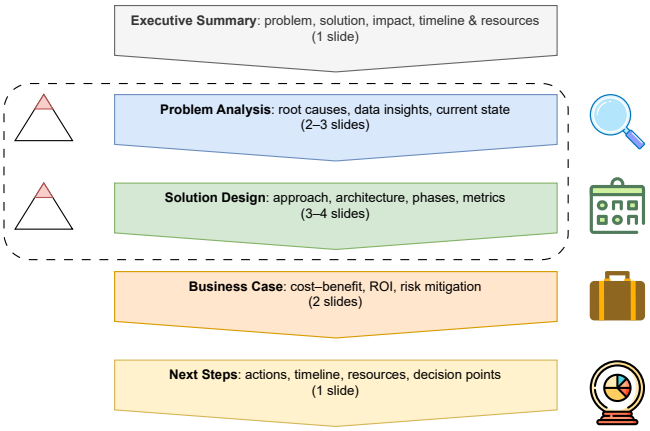

Hình 19: Framework trình bày giải pháp AI 5 thành phần. Mỗi thành phần có thể được cấu trúc như một kim tự tháp nhỏ để đảm bảo tính logic và thuyết phục.

II.9. Tổng kết

Sai lầm phổ biến nhất là coi AI như một "**hộp đen**" (*magical black box*) chỉ cần đưa dữ liệu vào và chờ đợi kết quả. Để thực sự thành công, chúng ta phải thấu hiểu các yếu tố cấu thành bên trong: từ bản chất của dữ liệu, logic của thuật toán, cho đến nhu cầu thực sự của bài toán kinh doanh. Việc phối hợp nhịp nhàng giữa dữ liệu, các chuyên gia và đội ngũ là yếu tố tiên quyết để bảo đảm dự án đi đúng hướng, thay vì chỉ xây dựng những mô hình phức tạp nhưng không giải quyết được vấn đề gốc rễ.

II.9.1. Framework và bộ công cụ thiết yếu

Để hệ thống hóa quá trình giải quyết vấn đề được nêu từ đầu bài tới điểm này, chúng ta cần một bộ công cụ mạnh mẽ và linh hoạt. Việc áp dụng nhất quán các phương pháp luận sau đây sẽ giúp chúng ta xác định vấn đề một cách chính xác, phân tích nguyên nhân gốc rễ, và ưu tiên hóa các giải pháp một cách hiệu quả.

- **Framework 7 bước giải quyết vấn đề AI:** Một quy trình toàn diện từ việc xác định vấn đề cho đến triển khai và giám sát giải pháp.
- **Phân tích nguyên nhân gốc rễ:** Sử dụng kết hợp phương pháp **5 Whys** và cây phân tích **Logic Trees** dựa trên nguyên tắc **MECE** để bảo đảm không bỏ sót khía cạnh nào.
- **Xác định và ưu tiên hóa:** Dùng **5W1H** để làm rõ phạm vi, **SMART Framework** để đặt mục tiêu, và ma trận **tác động-khả thi** (*Impact-Feasibility*) để lựa chọn giải pháp tối ưu.
- **Đánh giá chất lượng dữ liệu:** Áp dụng khung **ACCURATE** để bảo đảm dữ liệu đầu vào luôn *đúng đắn, đầy đủ, và phù hợp.*

Bảng dưới đây tóm tắt các công cụ chính và bối cảnh sử dụng của chúng trong các dự án AI thực tế.

Công cụ	Mục đích	Ví dụ
MECE Principle	Phân tách vấn đề thành các yếu tố độc lập, không trùng lặp để phân tích toàn diện.	Phân tích nguyên nhân khách hàng rời bỏ (churn), thấy rằng 48% đến từ chất lượng sản phẩm và 32% đến từ dịch vụ hỗ trợ.
Impact-Feasibility Matrix	Ưu tiên các sáng kiến hoặc tính năng dựa trên giá trị mang lại và nguồn lực cần thiết.	Quyết định cải thiện tính năng đề xuất sản phẩm (impact cao, feasibility trung bình) trước khi xây dựng chatbot (impact cao, feasibility thấp).
Pyramid Principle	Trình bày và diễn đạt ý tưởng một cách logic, thuyết phục, đặc biệt khi báo cáo cho cấp quản lý.	Bắt đầu bài thuyết trình bằng kết luận "Chúng ta có thể tiết kiệm 40% chi phí marketing", sau đó mới trình bày các luận điểm hỗ trợ.

Bảng 8: Tổng hợp các công cụ tư duy chiến lược trong dự án AI.

II.9.2. Yếu tố thành công

Tư duy và công cụ chỉ là điều kiện cần. Để đạt được thành công trong các dự án AI/DS, điều kiện đủ chính là sự rèn luyện không ngừng và khả năng giao tiếp hiệu quả.

- **Thực hành liên tục:** Chúng ta phải chủ động áp dụng các kiến thức đã học vào những dự án AI trong thực tế, dù là dự án cá nhân hay tại công ty. Đây là cách duy nhất để biến lý thuyết thành kỹ năng.
- **Điều chỉnh ngôn ngữ kỹ thuật:** Phải biết cách "dịch" các thuật ngữ chuyên môn như 'precision', 'recall' hay 'F1-score' thành ngôn ngữ kinh doanh mà các bên liên quan có thể hiểu được, tùy vào từng đối tượng.
- **Phối hợp đa ngành:** Thành công của một dự án AI không chỉ nằm ở mô hình, mà ở sự cộng hưởng giữa đội ngũ kỹ sư dữ liệu, chuyên gia sản phẩm và marketing.

II.9.3. Điểm mấu chốt

Để kết lại, hãy luôn ghi nhớ bốn điểm sau:

1. **Tư duy đi trước công nghệ:** Thay đổi cách tiếp cận từ "AI là hộp đen" sang "AI là công cụ" để giải quyết bài toán kinh doanh cụ thể.

2. **Công cụ mang lại cấu trúc:** Sử dụng các framework như MECE, SMART để đảm bảo quá trình phân tích và ra quyết định có hệ thống.

3. **Dữ liệu là nền tảng:** Chất lượng của giải pháp AI không thể vượt qua chất lượng của dữ liệu đầu vào.

4. **Thực thi quyết định thành bại:** Khả năng triển khai ý tưởng và giao tiếp hiệu quả là cầu nối cuối cùng đến thành công.

III. Tài liệu tham khảo

AI VIET NAM COURSE 2026

Project: Xây dựng công cụ tối ưu hoá quy trình phân bổ hàng hoá cho chuỗi cửa hàng

I. Giới thiệu

Trong bối cảnh thị trường bán lẻ cạnh tranh khốc liệt, việc quản lý hàng tồn kho hiệu quả là một trong những yếu tố then chốt quyết định sự thành bại của một doanh nghiệp. Các chuỗi cửa hàng lớn, với mạng lưới hàng trăm chi nhánh, phải đối mặt với bài toán điều phối hàng hóa cực kỳ phức tạp. Sự khác biệt về vị trí địa lý, đặc điểm khách hàng và nhu cầu thị trường tại mỗi điểm bán dẫn đến một thách thức chung đó là **mất cân bằng tồn kho (inventory imbalance)**. Tình trạng này gây ra hệ quả kép là một số cửa hàng thì thừa hàng, làm phát sinh chi phí lưu kho và đọng vốn; trong khi các cửa hàng khác lại thiếu hàng, dẫn đến mất doanh thu và suy giảm sự hài lòng của khách hàng.

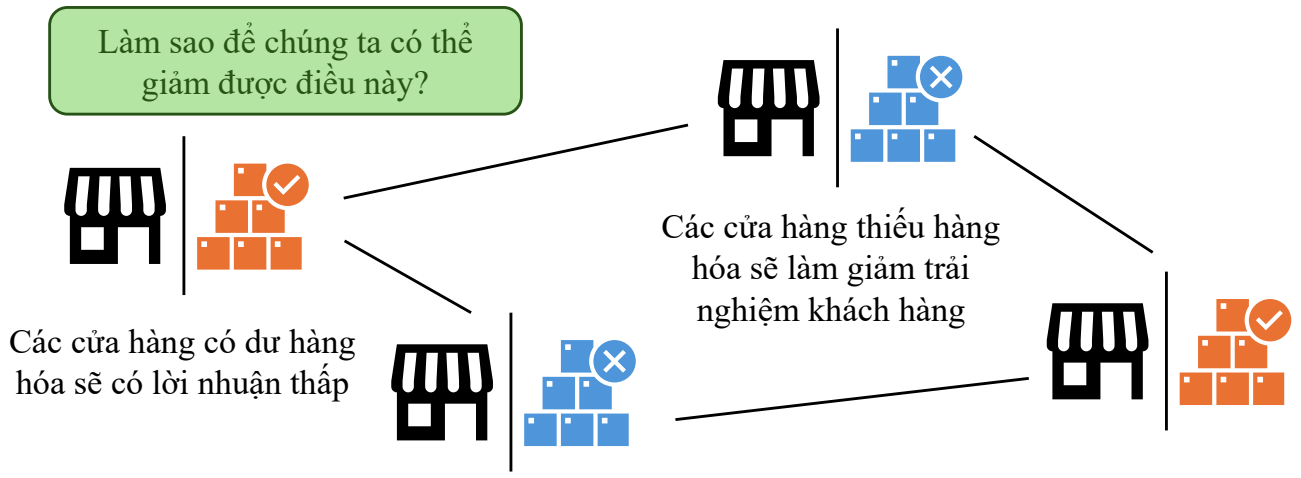

Hình 1: Bối cảnh thực tế của một chuỗi cửa hàng bán lẻ với thách thức về mất cân bằng tồn kho và nhu cầu về một giải pháp chuyển hàng thông minh và nhanh chóng.

Việc điều phối hàng hóa một cách thủ công, dựa nhiều vào kinh nghiệm cá nhân, thường không đủ nhanh nhạy và chính xác để giải quyết triệt để vấn đề. Hình bên phải minh họa sự bùng nổ của các lựa chọn: chỉ với 3 cửa hàng, người quản lý đã phải xem xét $3 \times 2 = 6$ tuyến điều chuyển hàng khác nhau. Nếu áp dụng vào bài toán thực tế với 300 cửa hàng, con số này sẽ là $300 \times 299 = 89,700$ lựa chọn. Việc đánh giá thủ công một không gian quyết định khổng lồ như vậy là bất khả thi.

	CH1	CH2	CH3
CH1		10	20
CH2	0		0
CH3	0	0	

Hình 2: Sự bùng nổ tổ hợp của các quyết định điều chuyển. Với n cửa hàng, một người quản lý phải cân nhắc $n(n-1)$ luồng vận chuyển hàng hóa. Với ví dụ $n = 300$, có gần 90,000 quyết định cần được đưa ra.

Do đó, nhu cầu về một hệ thống thông minh, có khả năng tự động hóa và tối ưu hóa các quyết định phân bổ hàng hóa trở nên cấp thiết hơn bao giờ hết. Chuyên đề này sẽ hướng dẫn học viên xây dựng một hệ thống tối ưu hóa phân bổ hàng hóa (Inventory Transfer Optimization System), ứng dụng nội dung bài học của khoa học dữ liệu và giải thuật di truyền (Genetic Algorithm) để giải quyết bài toán thực tiễn này.

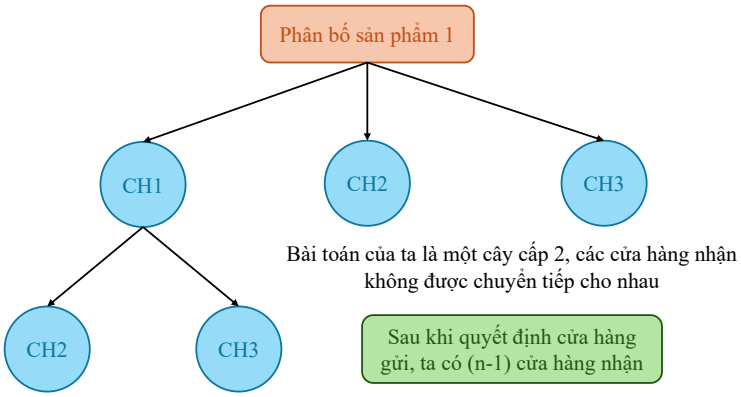

Hình 3: Mô hình hóa bài toán phân bổ dưới dạng cây quyết định 2 cấp. Trong thực tế chúng ta có thể góp chuyển chở hàng.

Để hệ thống hóa không gian quyết định này, chúng ta có thể mô hình hóa bài toán dưới dạng một cây quyết định 2 cấp, như được minh họa trong Hình bên. Cách tiếp cận này giúp làm rõ quy trình ra quyết định:

- **Cấp 1 (Chọn cửa hàng gửi):** Đầu tiên, hệ thống phải quyết định sẽ lấy sản phẩm từ cửa hàng nào trong tổng số n cửa hàng.
- **Cấp 2 (Chọn cửa hàng nhận):** Sau khi đã xác định được cửa hàng gửi, hệ thống sẽ tiếp tục chọn một cửa hàng nhận từ $n-1$ cửa hàng còn lại.

Một giả định quan trọng được thể hiện trong mô hình này là các cửa hàng nhận sẽ không thực hiện chuyển tiếp hàng hóa đi nơi khác. Đây là một bài toán điều chuyển một lượt **(single-hop)**, giúp đơn giản hóa vấn đề nhưng vẫn giữ được tính thực tiễn cốt lõi. Cách cấu trúc này là tiền đề để chúng ta xây dựng một mô hình tối ưu hóa chính xác.

Mục tiêu bài viết: Chuyên đề này được thiết kế nhằm giúp học viên hiểu rõ cách ứng dụng khoa học dữ liệu vào một bài toán tối ưu thực tế, thay vì tập trung vào việc xây dựng một hệ

thống tối ưu phức tạp. Người học sẽ được tiếp cận hai hướng giải quyết khác nhau là: rule-based và genetic algorithm. Qua đó rèn luyện tư duy phân tích, kỹ năng mô hình hóa và khả năng đánh giá trade-offs giữa các thuật toán.

Nội dung được xây dựng phù hợp cho:

- **Sinh viên ngành AI/Data Science:** Học cách áp dụng optimization vào bài toán thực tế và thực hành trực tiếp với Pandas/NumPy.
- **Người trái ngành muốn chuyển sang Data/AI:** Làm một dự án thực hành có tính ứng dụng cao, dễ dàng trình bày trong portfolio.
- **Tư vấn viên mới vào nghề (Beginner Consultants):** Hiểu và áp dụng framework tư duy tối ưu, nắm được cách cân nhắc giữa các giải pháp kỹ thuật.

Bài học tập trung vào ý tưởng và phương pháp tiếp cận, mang lại nền tảng vững chắc để người học mở rộng sang các bài toán lớn hơn trong tương lai, đồng thời đảm bảo tuân thủ tính bảo mật của dự án đã triển khai trong thực tế.

Danh sách các module trong project. Để tiện theo dõi, bảng dưới đây tổng hợp các phần chính trong module của chúng ta. Toàn bộ dự án được chứa trong link Github đây.

Bảng Thành phần Project

Thành phần	Ý nghĩa và Chức năng
`src/main.py`	File thực thi chính của dự án. Chịu trách nhiệm điều phối toàn bộ quy trình: khởi tạo, tạo dữ liệu (nếu cần), chạy phân tích, thực thi các thuật toán tối ưu và lưu kết quả.
`src/config.py`	Tệp cấu hình trung tâm, chứa tất cả các hằng số và tham số quan trọng như đường dẫn thư mục, ngưỡng tồn kho an toàn (`MIN_INVENTORY_DAYS`, `MAX_INVENTORY_DAYS`), và các tham số cho thuật toán di truyền (kích thước quần thể, tỷ lệ lai ghép, đột biến).
`src/engine/analyzer.py`	Chứa lớp `InventoryAnalyzer`. Module này thực hiện các phân tích: tính toán doanh số trung bình hàng ngày, xác định mức tồn kho an toàn, và quan trọng nhất là xác định các sản phẩm đang **thừa** (*excess*) và **thiếu** (*needed*) tại mỗi cửa hàng cho các bước tiếp theo.
`src/engine/rule_based.py`	Triển khai thuật toán tối ưu dựa trên luật (`RuleBasedOptimizer`). Đây là một phương pháp tiếp cận tham lam (greedy), ưu tiên đáp ứng các nhu cầu từ nguồn cung có chi phí vận chuyển thấp nhất.
`src/engine/genetic_algorithm.`	Triển khai thuật toán di truyền (`GeneticAlgorithmOptimizer`). Đây là phương pháp tối ưu hóa phức tạp hơn, tìm kiếm giải pháp tối ưu toàn cục bằng cách mô phỏng quá trình tiến hóa tự nhiên (chọn lọc, lai ghép, đột biến).
`src/engine/results_manager.py`	Quản lý việc lưu trữ và định dạng các kết quả đầu ra, bao gồm kế hoạch điều chuyển hàng hóa và các bản tóm tắt hiệu suất.
`data/`	Thư mục chứa tất cả các tệp dữ liệu đầu vào ở định dạng CSV, bao gồm dữ liệu bán hàng, tồn kho, thông tin sản phẩm, cửa hàng và ma trận chi phí vận chuyển.
`notebooks/`	Jupyter Notebook mẫu của dự án này với phân tích chi tiết, trực quan và từng bước của toàn bộ quy trình.

II. Lý thuyết

II.1. Tại sao cần tối ưu hóa phân bổ hàng hóa?

Trước khi đi vào giải pháp kỹ thuật, chúng ta cần hiểu rõ các vấn đề mà một doanh nghiệp phải đối mặt khi hệ thống phân bổ hàng hóa không hiệu quả. Như được tóm tắt trong Hình 4, có bốn động lực chính thúc đẩy nhu cầu cấp thiết này.

Quay trở lại vấn đề, như được tóm tắt trong Hình 4, có bốn động lực chính thúc đẩy nhu cầu cấp thiết về tối ưu hóa phân bổ hàng hóa.

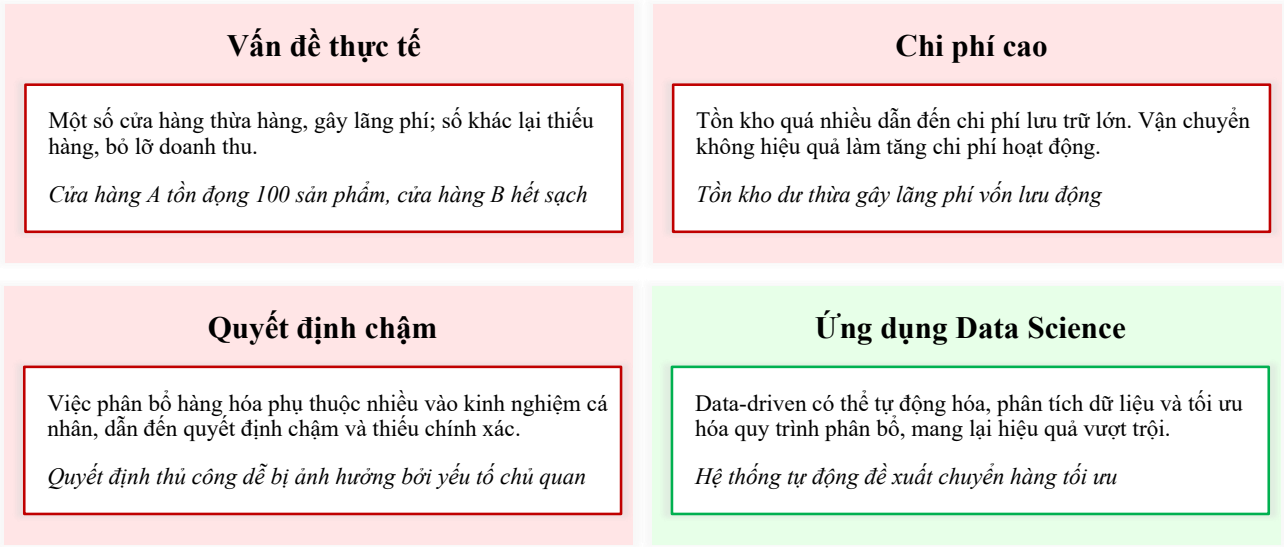

Hình 4: Tóm tắt và ví dụ ba vấn đề và một hướng giải quyết cho bài toán tối ưu.

Mỗi khía cạnh này đều ẩn chứa những thách thức và cơ hội riêng:

- Về mặt thực tế, sự mất cân bằng tồn kho là một lãng phí tài nguyên hữu hình. Ví dụ về "Cửa hàng A tồn kho 100 sản phẩm, cửa hàng B hết sạch" không chỉ đơn thuần là vấn đề lưu trữ, mà nó trực tiếp dẫn đến việc bỏ lỡ doanh thu tại cửa hàng B và làm suy giảm trải nghiệm của khách hàng.
- Về chi phí, bài toán không chỉ dừng lại ở chi phí vận chuyển. Tồn kho dư thừa gây lãng phí vốn lưu động, phát sinh chi phí bảo quản, bảo hiểm, và đối mặt với rủi ro hàng hóa lỗi thời hoặc hư hỏng. Một hệ thống không tối ưu sẽ khuếch đại tất cả các loại chi phí này.
- Về quyết định, sự phụ thuộc vào kinh nghiệm cá nhân khiến quy trình trở nên chậm chạp và thiếu nhất quán. Các quyết định thủ công khó có thể phản ứng kịp thời trước các biến động đột ngột của thị trường (ví dụ: một xu hướng mới, một chương trình khuyến mãi của đối thủ) và dễ bị sai lệch bởi yếu tố chủ quan.

- Về cơ hội, đây chính là khía cạnh then chốt. Dữ liệu bán hàng, tồn kho, và lưu lượng khách hàng không còn là những con số. Khi được khai thác đúng cách, chúng trở thành nền tảng cho một hệ thống **data-driven** có khả năng tự động hóa toàn bộ quy trình: từ dự báo nhu cầu, phân tích các kịch bản điều chuyển, cho đến việc đề xuất lộ trình tối ưu nhất. Đây chính là giải pháp mà chúng ta sẽ xây dựng.

II.2. Định nghĩa bài toán

Một bài toán tối ưu về cơ bản là việc tìm ra phương án tốt nhất (ví dụ: kế hoạch luân chuyển hàng) dựa trên một bộ tiêu chí (mục tiêu) và tuân thủ các điều kiện cho trước (ràng buộc).

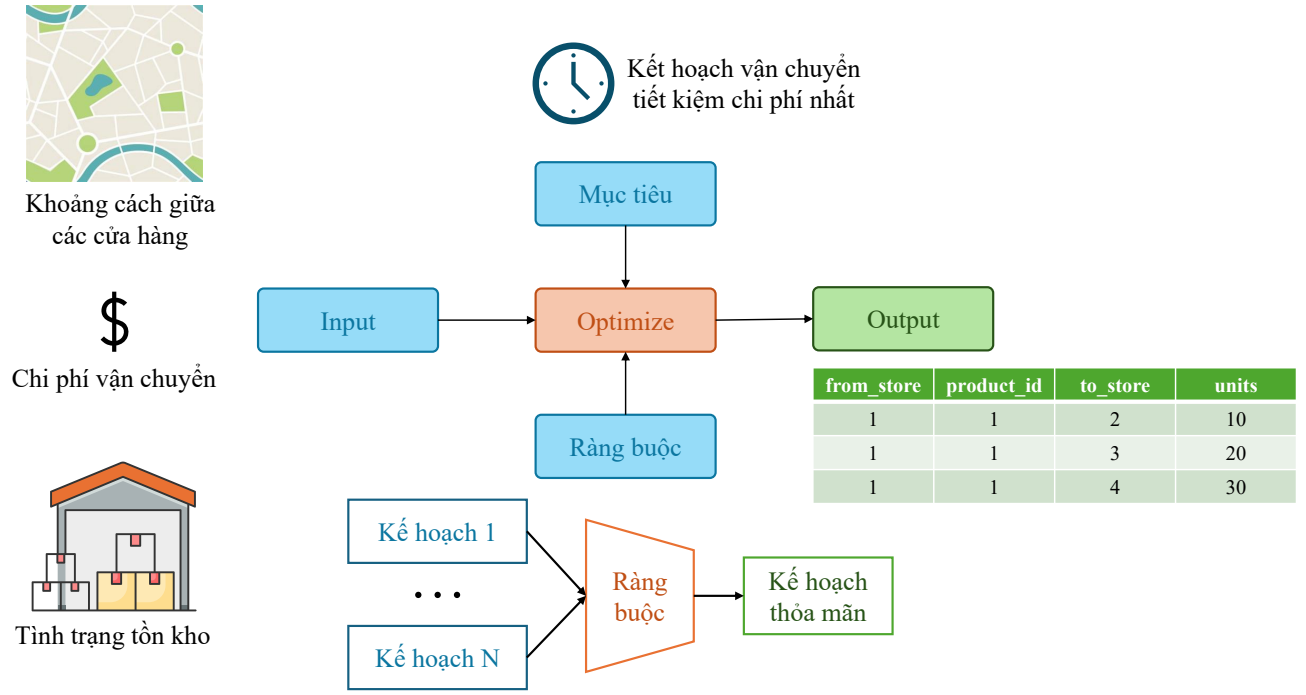

Hình 5: Các thành phần cốt lõi của một bài toán tối ưu:
Mục tiêu, Dữ liệu đầu vào, Ràng buộc và Kết quả đầu ra.

Để máy tính có thể hiểu và giải quyết, chúng ta cần diễn đạt bài toán này bằng ngôn ngữ toán học. Mô hình toán học giúp chúng ta lượng hóa mục tiêu và các ràng buộc một cách chính xác.

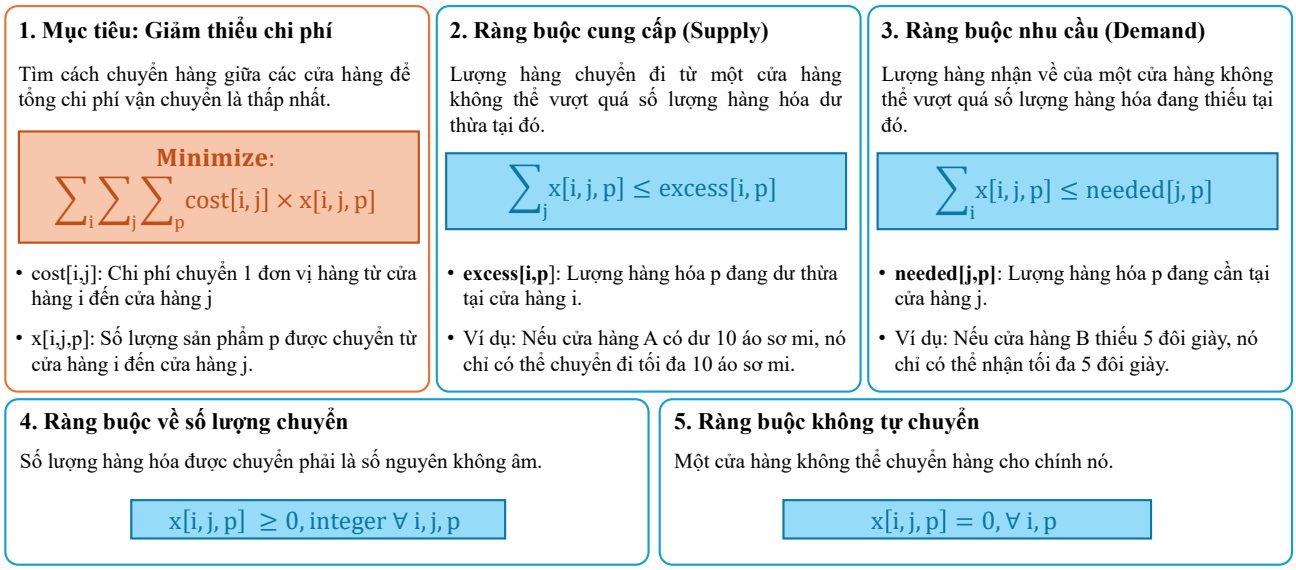

Hình 6: Mô hình toán học cho bài toán phân bổ hàng hóa nhằm tối thiểu hóa chi phí vận chuyển.

Thay vì diễn giải lại từng công thức, chúng ta sẽ tập trung vào bước quan trọng tiếp theo: làm thế nào để lập trình dự án này để có thể tìm ra lời giải. Quá trình này bao gồm ba bước chính:

1. **Cấu trúc dữ liệu đầu vào:** Đầu tiên, chúng ta cần biểu diễn các dữ liệu đầu vào dưới dạng các cấu trúc mà chương trình có thể xử lý. Trong các dự án phân tích dữ liệu với Python, cách tiếp cận hiệu quả nhất là sử dụng thư viện **Pandas**. Dữ liệu về chi phí, hàng thừa và hàng thiếu sẽ được chứa trong các đối tượng `DataFrame`.

Ví dụ cấu trúc dữ liệu trong Python với Pandas

```
# Dữ liệu về chi phí vận chuyển được tải từ file CSV
# transport_costs_df có các cột: from_store_id, to_store_id, cost
transport_costs_df.head()
#    from_store_id to_store_id   cost
# 0  CH01          CH02          15000
# 1  CH01          CH03          25000
# ...

# Dữ liệu hàng thừa và hàng thiếu được tính toán bởi InventoryAnalyzer
# và trả về dưới dạng DataFrame.
excess_df, needed_df = analyzer.identify_inventory_imbalances()

# excess_df chứa thông tin các sản phẩm đang thừa ở cửa hàng
excess_df[['store_id', 'product_id', 'excess_units']].head()
#    store_id  product_id  excess_units
# 5  CH01      AO_SO_MI    10
# 12 CH01      QUAN_JEAN   5
# ...

```

```
# needed_df chứa thông tin các sản phẩm đang thiếu ở cửa hàng
needed_df[['store_id', 'product_id', 'needed_units']].head()
#    store_id  product_id  needed_units
# 3  CH02      AO_SO_MI    8
# 9  CH03      AO_SO_MI    12
# ...
```

2. **Biểu diễn lời giải:** Thành phần chính của dự án chúng ta là cấu trúc của một "kế hoạch luân chuyển". Trong dự án này, một kế hoạch hoàn chỉnh là một danh sách các giao dịch vận chuyển. Mỗi giao dịch là một bộ thông tin xác định:

   - **Từ đâu:** Cửa hàng gửi (`from_store_id`).
   - **Đến đâu:** Cửa hàng nhận (`to_store_id`).
   - **Mặt hàng gì:** Mã sản phẩm (`product_id`).
   - **Số lượng:** Bao nhiêu đơn vị sản phẩm sẽ được chuyển (`units`).

   Đây chính là cấu trúc dữ liệu đầu ra mà các thuật toán của chúng ta phải tạo ra.

3. **Xây dựng thuật toán:** Với dữ liệu đầu vào và cấu trúc lời giải đã định nghĩa, bước cuối cùng là hiện thực hóa các thuật toán để tìm ra kế hoạch tốt nhất. Dự án này tiếp cận bài toán bằng hai phương pháp:

   - **Phương pháp dựa trên luật (Rule-Based):** Đây là một chiến lược đơn giản và trực quan. Thuật toán sẽ duyệt qua từng món hàng đang thiếu, tìm kiếm trong danh sách hàng thừa và chọn ra phương án vận chuyển có chi phí thấp nhất để đáp ứng nhu cầu đó.
   - **Phương pháp giải thuật di truyền:** Đây là một hướng tiếp cận phức tạp hơn, lấy cảm hứng từ quá trình tiến hóa tự nhiên. Thuật toán sẽ khởi tạo một "quần thể" gồm nhiều kế hoạch vận chuyển ngẫu nhiên, sau đó đánh giá, lai tạo và đột biến chúng qua nhiều thế hệ để "tiến hóa" ra lời giải tối ưu nhất dựa trên tổng chi phí.

Bằng cách chuyển đổi mô hình toán học trừu tượng thành các cấu trúc dữ liệu và thuật toán cụ thể, chúng ta đã sẵn sàng để yêu cầu máy tính tìm ra kế hoạch vận chuyển tối ưu nhất.

III. Xây dựng hệ thống

Sau khi đã có cái nhìn tổng quan về mô hình toán học và các hướng tiếp cận, chúng ta sẽ đi sâu vào chi tiết kỹ thuật của dự án. Phần này sẽ giải thích cách hệ thống được xây dựng, từ việc đọc dữ liệu thô cho đến khi tạo ra một kế hoạch luân chuyển hàng hóa hoàn chỉnh.

Sơ đồ hệ thống

```
[Dữ liệu thô]
    data/stores.csv
    data/products.csv
    data/sales_data.csv
    data/inventory_data.csv
    data/transport_cost_matrix.csv
[src/engine/analyzer.py: InventoryAnalyzer]
      1. Đọc và hợp nhất dữ liệu
      2. Tính toán tốc độ bán hàng, số ngày tồn kho
      3. Xác định hàng thừa và hàng thiếu
[Dữ liệu đã phân tích]
    excess_df (Bảng hàng thừa)
    needed_df (Bảng hàng thiếu)
[src/engine/{rule_based | genetic_algorithm}.py]
      1. Nhận excess_df, needed_df, và ma trận chi phí
      2. Áp dụng logic thuật toán
      3. Tìm kiếm kế hoạch luân chuyển
[Kết quả]
    transfer_plan_df (Kế hoạch luân chuyển tối ưu)
```

III.1. Đọc dữ liệu

Dự án sử dụng 6 file CSV trong thư mục 'data/', nhưng trong luồng phân tích chính, chúng ta chỉ làm việc trực tiếp với 5 file.

- **Các file đầu vào chính:** 'stores.csv', 'products.csv', 'sales_data.csv', 'inventory_data.csv'
- **File chi phí:** 'transport_cost_matrix.csv' chứa chi phí vận chuyển (VNĐ) giữa các cửa hàng.

Lớp `InventoryAnalyzer` sẽ đọc 4 file dữ liệu chính, trong khi file chi phí được đọc riêng để truyền vào các thuật toán. Chúng ta có cách chạy lớp InventoryAnalyzer như sau.

Đọc dữ liệu đầu vào

```python
import pandas as pd
from src.engine.analyzer import InventoryAnalyzer

# Khởi tạo analyzer
analyzer = InventoryAnalyzer()

# Tải 4 file dữ liệu kinh doanh cốt lõi
analyzer.load_data(
    sales_path="data/sales_data.csv",
    inventory_path="data/inventory_data.csv",
```

```
    stores_path="data/stores.csv",
    products_path="data/products.csv"
)

# Dữ liệu chi phí vận chuyển cũng được đọc riêng
transport_costs_df = pd.read_csv("data/transport_cost_matrix.csv")
```

Sau khi tải, phương thức `identify_inventory_imbalances` sẽ tạo ra hai "bảng" dữ liệu, là đầu vào cốt lõi cho cả hai thuật toán tối ưu.

- **Bảng hàng thừa ('excess_df'):** Liệt kê những sản phẩm tại các cửa hàng có lượng tồn kho vượt quá MAX_INVENTORY_DAYS. Bảng này sẽ có thêm cột excess_units cho biết số lượng đơn vị đang thừa.
- **Bảng hàng thiếu ('needed_df'):** Liệt kê những sản phẩm tại các cửa hàng có lượng tồn kho thấp hơn MIN_INVENTORY_DAYS. Bảng này có cột needed_units cho biết số lượng cần bổ sung.

Với hai bảng dữ liệu này cùng với ma trận chi phí vận chuyển, chúng ta đã có đầy đủ thông tin cần thiết để bắt đầu tìm kiếm một kế hoạch luân chuyển hàng hóa hiệu quả.

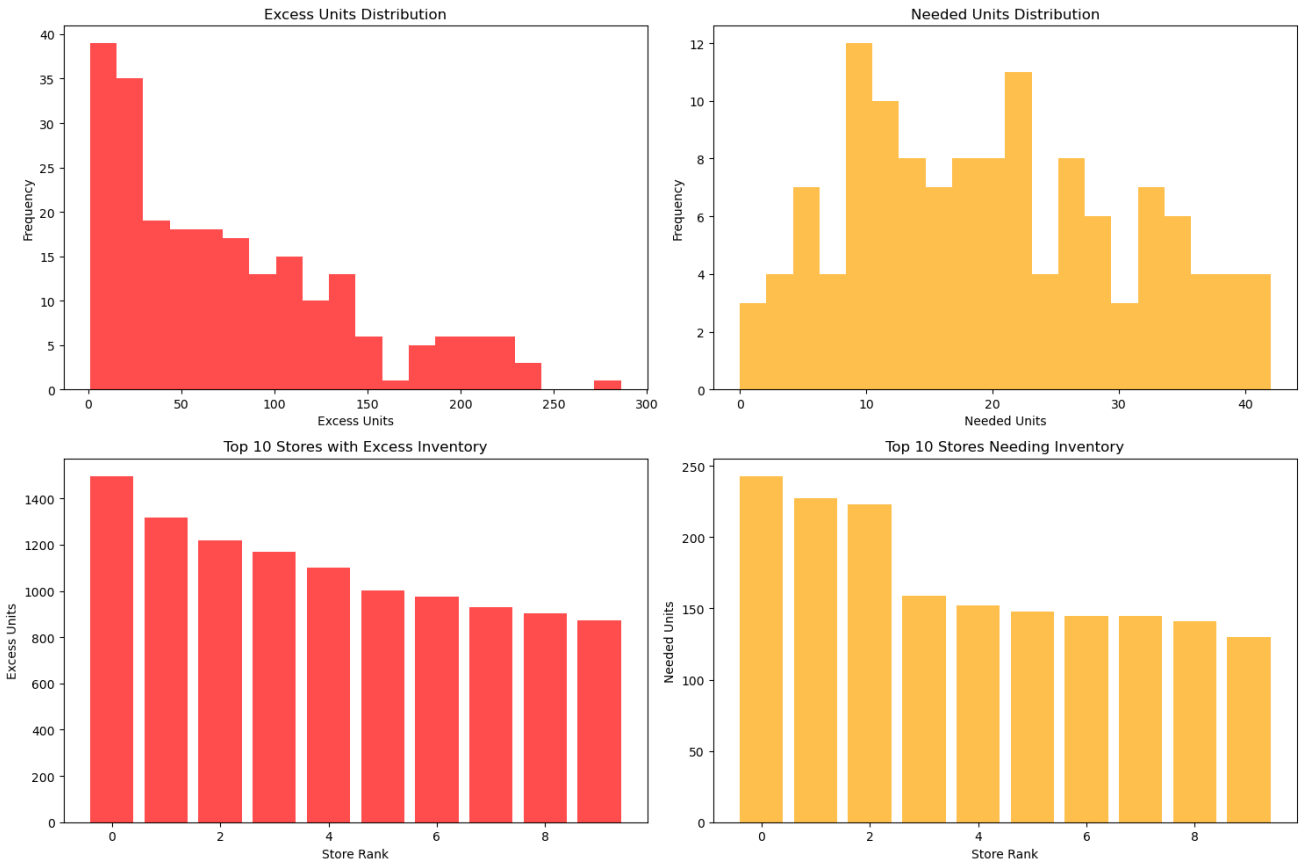

Hình 7: Phân phối của dữ liệu. Ta thấy rằng số lượng hàng dư ít hơn số lượng hàng cần rất nhiều. Đây là một bộ dữ liệu bị mất cân bằng.

III.2. Phương pháp dựa trên các luật

Đây là phương pháp tiếp cận đầu tiên và đơn giản nhất để giải quyết bài toán. Ý tưởng cốt lõi của nó là một chiến lược "tham lam" (greedy): với mỗi món hàng đang thiếu, chúng ta sẽ ngay lập tức tìm cách đáp ứng nó bằng nguồn cung có chi phí vận chuyển rẻ nhất. Phương pháp này không đảm bảo sẽ tìm ra lời giải tối ưu nhất trên toàn cục, nhưng nó rất nhanh, dễ hiểu và thường cho ra một kết quả "đủ tốt".

Logic hoạt động Thuật toán được thực hiện trong lớp `RuleBasedOptimizer`. Luồng của thuật toán có thể được mô tả như sau:

1. **Sắp xếp nhu cầu:** Đầu tiên, thuật toán sắp xếp bảng `needed_df` để ưu tiên những nhu cầu lớn nhất. Điều này giúp giải quyết các vấn đề thiếu hụt nghiêm trọng trước.
2. **Duyệt qua từng nhu cầu:** Với mỗi dòng trong bảng `needed_df` (tức là mỗi sản phẩm `p` đang thiếu tại cửa hàng `j`), thuật toán sẽ:
   (a) Tìm tất cả các cửa hàng `i` có thừa sản phẩm `p` từ bảng `excess_df`.

(b) Với mỗi cửa hàng `i` tìm được, lấy ra chi phí vận chuyển từ `i` đến `j` trong ma trận chi phí.

(c) Sắp xếp các cửa hàng cung cấp tiềm năng này theo chi phí vận chuyển tăng dần.

3. **Thực hiện vận chuyển:** Thuật toán bắt đầu duyệt qua danh sách các nguồn cung đã sắp xếp (từ rẻ nhất đến đắt nhất). Nó sẽ lấy hàng từ nguồn rẻ nhất cho đến khi nhu cầu được đáp ứng, hoặc nguồn cung đó hết hàng. Nếu nhu cầu vẫn chưa đủ, nó sẽ tiếp tục lấy từ nguồn rẻ thứ hai, và cứ thế tiếp tục.

4. **Cập nhật và lặp lại:** Sau mỗi lần vận chuyển, số lượng hàng thừa và thiếu ở các kho liên quan sẽ được cập nhật lại. Thuật toán tiếp tục cho đến khi tất cả các nhu cầu đã được xem xét.

Logic trên có thể được biểu diễn bằng đoạn mã giả sau, giúp làm rõ cấu trúc của vòng lặp chính trong phương thức `optimize`. Ở đây, ta có thể thấy thuật toán có độ phức tạp là $O(N \times M \times log(M))$ với N là số lượng như cầu, và M là số lượng hàng thừa.

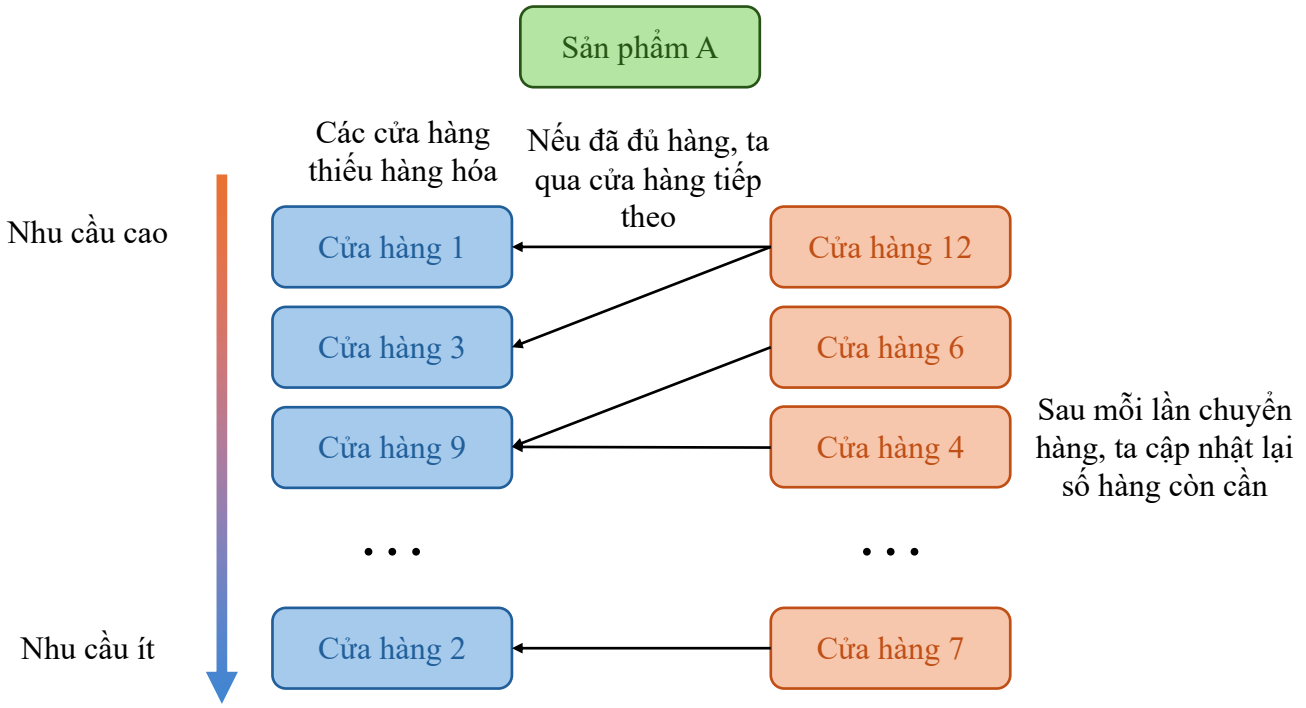

Hình 8: Hình minh họa thuật toán rule-based dựa trên một sản phẩm. Tiêu chí chúng ta chọn cửa hàng cung cấp hàng hóa cần là chi phí vận chuyển thấp nhất.

Thuật toán Rule-Based

```
def rule_based_optimizer(excess_df, needed_df, transport_cost_matrix):

    transfer_plan = []
```

```
    # Tạo bản sao để cập nhật số lượng mà không ảnh hưởng đến DataFrame gốc
    excess_inventory = excess_df.set_index(['store_id', 'product_id'])

    # Sắp xếp các nhu cầu từ lớn nhất đến nhỏ nhất
    needed_sorted = needed_df.sort_values(by='needed_units', ascending= False)

    # Vòng lặp chính: duyệt qua từng nhu cầu
    for _, need_row in needed_sorted.iterrows():
        product_id = need_row['product_id']
        to_store = need_row['to_store_id']
        needed_units = need_row['needed_units']

        # Tìm các nguồn cung có cùng sản phẩm
        supplies = excess_inventory.query(f"product_id == '{product_id}'")

        if supplies.empty:
            continue

        # Tính chi phí vận chuyển từ mỗi nguồn cung đến nơi cần
        supplies['cost'] = supplies.index.map(
            lambda from_store: transport_cost_matrix.loc[from_store, to_store]
        )

        # Sắp xếp các nguồn cung theo chi phí rẻ nhất
        supplies = supplies.sort_values(by='cost', ascending= True)

        # Bắt đầu đáp ứng nhu cầu từ nguồn cung rẻ nhất
        for from_store, supply_row in supplies.iterrows():
            available_units = supply_row['excess_units']

            # Xác định số lượng có thể chuyển
            transfer_units = min(needed_units, available_units)

            if transfer_units > 0:
                # Ghi nhận một giao dịch
                transfer_plan. append({
                    'from_store_id': from_store,
                    'to_store_id': to_store,
                    'product_id': product_id,
                    'units': transfer_units,
                    'transport_cost': supply_row['cost'] * transfer_units
                })

                # Cập nhật lại số lượng
                excess_inventory.loc[from_store, 'excess_units'] -= transfer_units
                needed_units -= transfer_units

                # Nếu đã đủ hàng, chuyển sang xử lý nhu cầu tiếp theo
                if needed_units == 0:
                    break

    return pd.DataFrame(transfer_plan)
```

Sau khi đã định nghĩa thuật toán xong, việc sử dụng thuật toán này rất đơn giản. Sau khi đã có `excess_df` và `needed_df` từ `InventoryAnalyzer`, chúng ta chỉ cần khởi tạo `RuleBasedOptimizer` và gọi phương thức `optimize`.

Thực thi thuật toán Rule-Based

```
# Khởi tạo Rule-Based Optimizer với ma trận chi phí
rule_optimizer = RuleBasedOptimizer(
    transport_cost_matrix=transport_cost_matrix
)

# Chạy thuật toán
rule_transfer_plan = rule_optimizer.optimize(excess_df, needed_df)

# In ra kết quả
print(f"Tổng chi phí vận chuyển: {rule_transfer_plan['transport_cost'].sum():,.0f} VND"
                                                                                )
display(rule_transfer_plan.head())
```

Kết quả trả về là một DataFrame chứa kế hoạch chi tiết: sản phẩm nào cần được chuyển, từ đâu, đến đâu, với số lượng và chi phí là bao nhiêu. Đây là một giải pháp nhanh chóng và dễ dàng để cải thiện tình hình tồn kho.

idx	from_store_id	to_store_id	product_id	units	distance (km)	transport_cost (VND)
0	5	7	3	42	20.53	2.07×10^6
1	19	14	23	42	6.79	6.84×10^5
2	5	2	4	42	7.41	7.47×10^5
3	18	15	24	40	6.20	5.95×10^5
4	19	17	19	39	2.69	2.52×10^5
5	19	20	19	19	12.91	5.89×10^5
6	14	20	19	20	14.61	7.01×10^5
7	8	10	25	22	3.34	1.76×10^5
8	20	10	25	16	596.07	1.14×10^7
9	8	15	28	38	611.75	2.79×10^7

Bảng 1: Ví dụ về kết quả đầu ra của kế hoạch vận chuyển. Với mỗi hàng là kết hoạch vận chuyển của một sản phẩm, và một sản phẩn có thể được vận chuyển nhiều lần.

III.3. Phương pháp thuật toán di truyền

Nếu phương pháp dựa trên luật là một chiến lược đơn giản và nhanh chóng, thì thuật toán di truyền (GA) là một cách tiếp cận phức tạp hơn, được thiết kế để khám phá không gian lời giải một cách rộng hơn nhằm tìm ra kết quả tiệm cận tối ưu toàn cục. Thuật toán này mô phỏng lại quá trình tiến hóa tự nhiên: tạo ra một "quần thể" các lời giải, cho chúng "giao phối" và "đột biến" qua nhiều thế hệ để tìm ra lời giải tốt nhất (có chi phí thấp nhất).

Thuật toán được xây dựng trong lớp `GeneticAlgorithmOptimizer`. Để hiểu nó, chúng ta cần nắm các khái niệm sau:

- **Cá thể (Individual):** Mỗi cá thể là một lời giải hoàn chỉnh, tức là một kế hoạch luân chuyển hàng hóa.
- **Quần thể (Population):** Là một tập hợp gồm nhiều cá thể. Ví dụ, một quần thể có 50 cá thể tức là 50 kế hoạch luân chuyển khác nhau.
- **Hàm thích nghi (Fitness Function):** Đây là hàm đánh giá chất lượng của một cá thể. Trong bài toán này, thích nghi đồng nghĩa với chi phí thấp. Hàm này tính tổng chi phí vận chuyển của một kế hoạch. Cá thể nào có fitness thấp hơn thì được coi là tốt hơn.
- **Chọn lọc (Selection):** Quá trình chọn ra các cá thể tốt (chi phí thấp) từ quần thể để làm cha mẹ cho thế hệ tiếp theo. Dự án sử dụng phương pháp *Tournament Selection*.
- **Lai ghép (Crossover):** Quá trình hai cha mẹ giao phối để tạo ra con. Về bản chất, nó trộn lẫn các phần của hai kế hoạch vận chuyển để tạo ra một kế hoạch mới, hy vọng sẽ tốt hơn.
- **Đột biến (Mutation):** Thay đổi nhỏ, ngẫu nhiên trên một cá thể con để tạo ra sự đa dạng trong quần thể, tránh việc bị mắc kẹt ở một lời giải cục bộ.

Để vận hành thuật toán, chúng ta cần tinh chỉnh các tham số cốt lõi như sau. *Kích thước quần thể (population size)* quyết định số lượng lời giải được duy trì trong mỗi vòng lặp, trong khi *số thế hệ (generations)* xác định độ dài của quá trình tiến hóa. Bên cạnh đó, *tỷ lệ lai ghép (crossover rate)* và *tỷ lệ đột biến (mutation rate)* là hai xác suất quan trọng, điều khiển tần suất các cá thể mới được tạo ra thông qua việc kết hợp từ cha mẹ hoặc thay đổi ngẫu nhiên, từ đó cân bằng giữa việc khai thác các lời giải tốt hiện có và khám phá những vùng lời giải tiềm năng mới. Các tham số được nói trên có thể được tin chỉnh ở file 'src/config.py'.

Hàm thích nghi (`_calculate_fitness`) Đây là hàm lõi để đánh giá mỗi kế hoạch vận chuyển. Logic của nó dựa trên hàm mục tiêu mà ta đã định nghĩa ở trên: duyệt qua từng hàng trong kế hoạch, tra cứu chi phí trên mỗi đơn vị từ ma trận chi phí, nhân với số lượng, rồi cộng dồn lại.

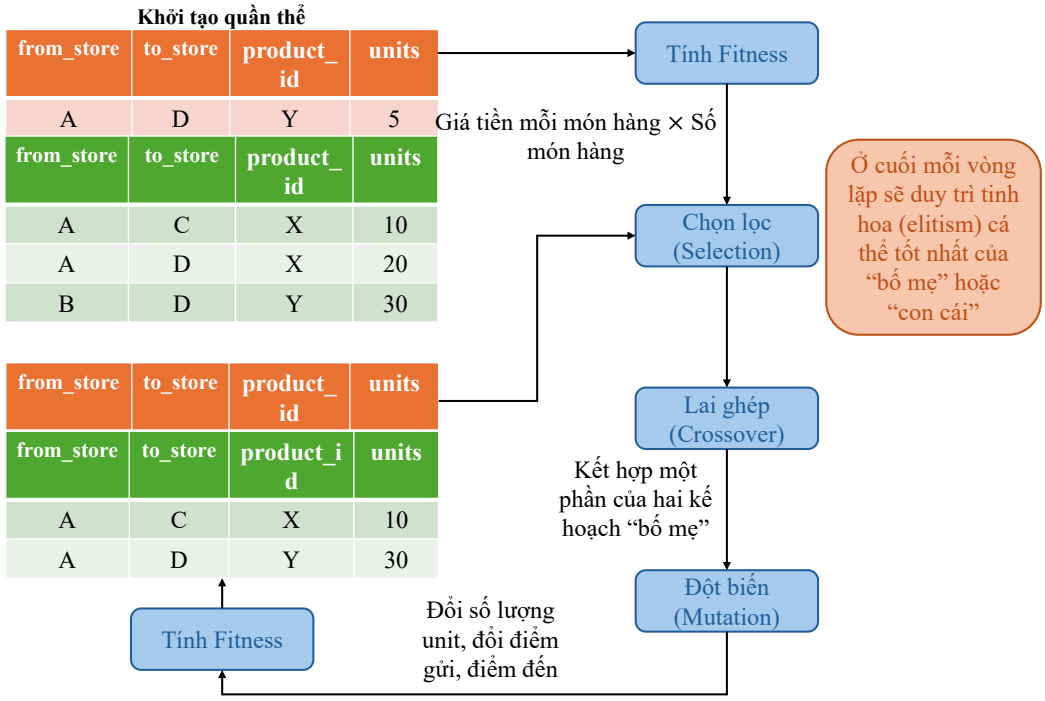

Hình 9: Quá trình thuật toán Genetic sẽ thực hiện trong hệ thống.

Giả mã hàm `_calculate_fitness`

```
def _calculate_fitness(transfer_plan, transport_cost_matrix):
    total_cost = 0

    for transfer in transfer_plan:
        from_store = transfer['from_store']
        to_store = transfer['to_store']
        units = transfer['units']

        # Tra cứu chi phí trên mỗi đơn vị
        cost_per_unit = transport_cost_matrix.loc[from_store, to_store]

        # Cộng dồn vào tổng chi phí
        total_cost += cost_per_unit * units

    return total_cost
```

Lai ghép (`_crossover`) Hàm này nhận hai kế hoạch (cha và mẹ) và tạo ra hai kế hoạch mới (con). Dự án sử dụng phương pháp lai ghép một điểm (single-point crossover) đơn giản.

Giả mã hàm `_crossover`

```
def _crossover(parent1_plan, parent2_plan):
    # Chọn một điểm ngẫu nhiên để cắt
    crossover_point = random.randint(1, min( len(parent1_plan),
                                             len(parent2_plan)) - 1)

    # Tạo ra hai cá thể con
    # Con 1 = đầu của cha 1 + đuôi của cha 2
    child1_plan = parent1_plan[:crossover_point] + parent2_plan[crossover_point:]

    # Con 2 = đầu của cha 2 + đuôi của cha 1
    child2_plan = parent2_plan[:crossover_point] + parent1_plan[crossover_point:]

    # "Sửa chữa" các kế hoạch con để đảm bảo chúng hợp lệ
    child1_plan = _repair_solution(child1_plan)
    child2_plan = _repair_solution(child2_plan)

    return child1_plan, child2_plan
```

Đột biến (`_mutate`) Để duy trì sự đa dạng, một cá thể con có thể bị đột biến ngẫu nhiên. Hàm `_mutate` sẽ chọn một trong bốn loại đột biến sau:

Giả mã các loại đột biến trong hàm `_mutate`

```
def _mutate(individual_plan):
    mutation_type = random.choice(['change_quantity', 'remove_transfer', 'add_transfer'
                                             , 'change_route'])

    if mutation_type == 'change_quantity':
        # 1. Thay đổi số lượng của một giao dịch ngẫu nhiên
        random_transfer = random.choice(individual_plan)
        max_possible_units = get_max_transfer(random_transfer['from_store'], ...)
        random_transfer['units'] = random.randint(1, max_possible_units)

    elif mutation_type == 'remove_transfer':
        # 2. Xóa một giao dịch ngẫu nhiên
        if  len(individual_plan) > 1:
            individual_plan.pop(random.randint(0,  len(individual_plan) - 1))

    elif mutation_type == 'add_transfer':
        # 3. Thêm một giao dịch hoàn toàn mới và ngẫu nhiên
        new_transfer = _create_random_transfer()
        if new_transfer:
            individual_plan. append(new_transfer)

    elif mutation_type == 'change_route':
        # 4. Thay đổi nguồn hoặc đích của một giao dịch
        random_transfer = random.choice(individual_plan)
        if random.random() < 0.5:
            # Thay đổi cửa hàng gửi (from_store)
```

```
            new_from_store = find_another_store_with_excess(random_transfer['product_id
                                                    '])
            random_transfer['from_store'] = new_from_store
        else:
            # Thay đổi cửa hàng nhận (to_store)
            new_to_store = find_another_store_with_need(random_transfer['product_id'])
            random_transfer['to_store'] = new_to_store

    # Cuối cùng, sửa chữa lại kế hoạch để đảm bảo tính hợp lệ
    individual_plan = _repair_solution(individual_plan)
    return individual_plan
```

Tương tự như thuật toán trước, việc gọi GA cũng rất đơn giản. Chúng ta khởi tạo lớp GAOptimizer và gọi phương thức `optimize`, truyền vào các tham số cấu hình như kích thước quần thể, số thế hệ, v.v. Ta có thể thấy rằng với thiết lập của thuật toán này, thời gian cần để đưa ra đáp án sẽ nhiều hơn đáng kể so với thuật toán Rule-based được nói ở trên.

Thực thi thuật toán Genetic Algorithm

```
# Khởi tạo GA Optimizer
ga_optimizer = GeneticAlgorithmOptimizer(
    transport_cost_matrix=transport_cost_matrix
)

# Chạy thuật toán với các tham số từ file config
ga_transfer_plan = ga_optimizer.optimize(
    excess_inventory=excess_df,
    needed_inventory=needed_df,
    population_size=GA_POPULATION_SIZE,
    num_generations=GA_GENERATIONS,
    verbose= True  # Hiển thị tiến trình qua các thế hệ
)

# In ra kết quả
print(f"Tổng chi phí vận chuyển (GA): {ga_transfer_plan['transport_cost'].sum():,.0f}
                                                    VND")
display(ga_transfer_plan.head())
```

Quá trình này sẽ mất nhiều thời gian hơn so với phương pháp dựa trên luật, nhưng nó có khả năng tìm ra một kế hoạch luân chuyển với tổng chi phí thấp hơn đáng kể.

III.4. So sánh hiệu năng và lựa chọn thuật toán

Sau khi đã hiện thực hóa cả hai phương pháp, chúng ta cần so sánh và lựa chọn ra chiến lược tối ưu nhất cho bài toán hiện tại. Dựa trên kết quả thực thi được ghi nhận trong notebook (xem Hình 10), chúng ta có những kết luận như sau.

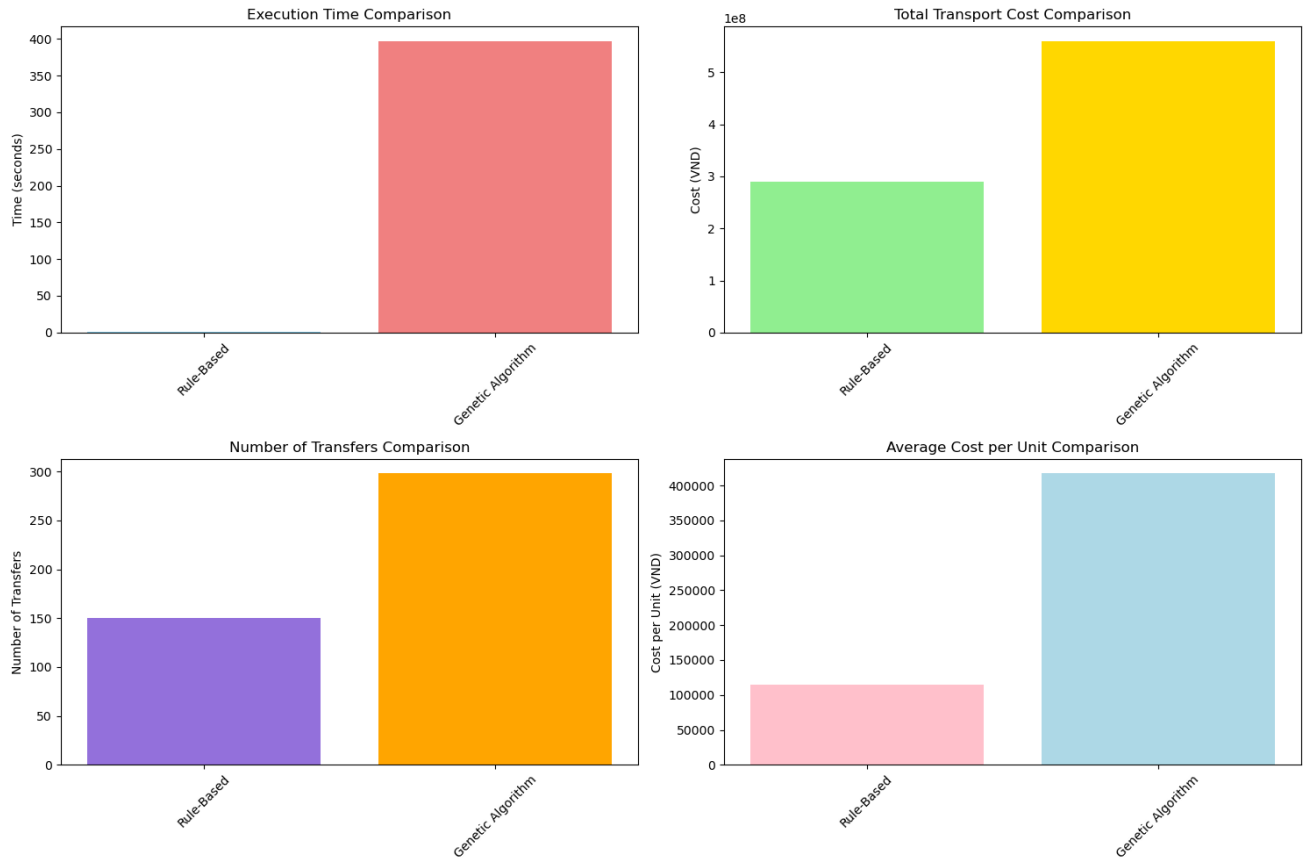

Hình 10: Biểu đồ so sánh hiệu năng giữa thuật toán Rule-Based và thuật toán di truyền trên bốn tiêu chí: thời gian thực thi, tổng chi phí, số lượng chuyến hàng, và chi phí trung bình trên mỗi đơn vị.

Về **thời gian thực thi**, sự khác biệt của hai thuật toán là rất lớn: thuật toán Rule-Based hoàn thành gần như tức thì chỉ trong vài giây, trong khi thuật toán di truyền đòi hỏi năng lực tính toán lớn và mất vài trăm giây để chạy qua tất cả các thế hệ (thay đổi mỗi lần chạy). Tuy nhiên, kết quả bất ngờ và quan trọng nhất nằm ở **tổng chi phí vận chuyển**. Thuật toán Rule-Based, với logic tham lam đơn giản, lại tìm ra một kế hoạch có tổng chi phí thấp hơn đáng kể so với thuật toán di truyền. Điều này cho thấy chiến lược ưu tiên tuyến đường rẻ nhất tỏ ra rất hiệu quả với bộ dữ liệu hiện tại. Phân tích sâu hơn về **số lượng chuyến hàng**, thuật toán di truyền có xu hướng tạo ra một kế hoạch phân mảnh hơn với số lượng giao dịch gần như gấp đôi, trong khi Rule-Based lại gộp các giao dịch hiệu quả hơn. Cuối cùng, **chi phí trung bình trên mỗi đơn vị** một lần nữa khẳng định điều này, khi chi phí của GA cao hơn nhiều so với Rule-Based, chứng tỏ các quyết định của thuật toán đơn giản lại hiệu quả hơn về mặt chi phí.

Vì sao Rule-Based lại hiệu quả hơn?

Lý giải cho kết quả nói trên nằm ở cấu trúc rất rõ ràng của bài toán. Luồng xử lý được định nghĩa rất cụ thể: mỗi sản phẩm chỉ được phép di chuyển từ một cửa hàng đang thừa sang một cửa hàng đang thiếu, và phải tuân thủ ràng buộc chặt chẽ là không được vận chuyển vượt quá số lượng tồn kho. Mục tiêu duy nhất là tối thiểu hóa chi phí.
Nhờ cấu trúc chặt chẽ được nói trên, phương pháp Rule-Based có thể tận dụng logic đặc thù của bài toán một cách triệt để, giúp nó nhanh chóng tìm ra lời giải tốt, dễ kiểm soát và mang lại hiệu quả cao.

IV. Hướng cải tiến

Hệ thống hiện tại đã cung cấp một giải pháp hoàn chỉnh cho bài toán luân chuyển tồn kho. Tuy nhiên, trong một kịch bản vận hành thực tế, luôn có những cơ hội để cải tiến và tối ưu hơn nữa. Dưới đây là hai hướng đi tiềm năng có thể giúp nâng cao đáng kể hiệu quả của hệ thống.

IV.1. Tích hợp dữ liệu thực và mô hình dự báo

Một trong những hạn chế lớn nhất của hệ thống hiện tại là nó mang tính phản ứng (reactive). Nó xác định hàng thừa và thiếu dựa trên tốc độ bán hàng *trong quá khứ* được ghi ở trong file "sales_data.csv". Một cải tiến mà chúng ta có thể thực hiện ở đây chuyển hệ thống sang phương pháp chủ động (proactive) bằng cách tích hợp các mô hình dự báo (forecasting models) để dự đoán nhu cầu tương lai.

Ví dụ với dữ liệu thực tế Để đưa hệ thống đến gần hơn với thực tế, chúng ta có thể sử dụng các bộ dữ liệu bán lẻ công khai. Mặc dù dữ liệu nội bộ của doanh nghiệp là không có sẵn, chúng ta có thể dùng một bộ dữ liệu tương đương là **Brazilian E-Commerce Public Dataset by Olist**.

Áp dụng bộ dữ liệu Olist vào dự án

Nguồn dữ liệu: Brazilian E-Commerce Public Dataset by Olist trên Kaggle.

Bộ dữ liệu này chứa thông tin của gần 100,000 đơn hàng và có thể được ánh xạ vào dự án của chúng ta như sau:

- **Dữ liệu bán hàng ('sales_data.csv'):** Có thể được tổng hợp từ file `olist_order_items_dataset.csv`. Mỗi `seller_id` sẽ được coi là một cửa hàng.
- **Dữ liệu sản phẩm ('products.csv'):** Lấy trực tiếp từ file `olist_products_dataset.csv`.
- **Dữ liệu cửa hàng ('stores.csv'):** Lấy từ `olist_sellers_dataset.csv`, trong đó mỗi người bán (`seller_id`) là một cửa hàng.
- **Ma trận khoảng cách và chi phí:** File `olist_geolocation_dataset.csv` cung cấp tọa độ địa lý thực của các mã zip cho mỗi người bán ở trên, cho phép chúng ta tính toán ma trận khoảng cách và chi phí vận chuyển cho bài toán hiện tại.
- **Dữ liệu tồn kho ('inventory_data.csv'):** Đây là phần duy nhất bị thiếu của bộ dữ liệu E-Commerce nói trên. Chúng ta cần tự tạo ra nó (synthesize) bằng cách tính tốc độ bán hàng trung bình của mỗi sản phẩm tại mỗi cửa hàng, sau đó gán một mức tồn kho ngẫu nhiên nhưng hợp lý (ví dụ: tồn kho bằng 20-100 ngày bán hàng). Các bạn có thể tham khảo folder 'src/data_generator' trong bài toán để có thể biết cách tạo dữ liệu ở đây.

Việc sử dụng bộ dữ liệu này giúp kiểm thử các thuật toán trên một quy mô lớn hơn và với các đặc tính phân phối địa lý thực tế.

Sau khi có dữ liệu bán hàng theo chuỗi thời gian từ Olist, chúng ta có thể huấn luyện các mô hình dự báo như **ARIMA**, **Prophet**, hoặc **LSTM**. Thay vì tính `avg_daily_sales` dựa trên quá khứ, chúng ta sẽ dùng `forecasted_daily_sales` cho 30 ngày tới. Từ đó, hệ thống có thể xác định các sản phẩm *sẽ sớm* bị thiếu hoặc thừa, phù hợp hơn trong các bài toán thực tế của chúng ta.

IV.2. Cải tiến và tối ưu hóa giải thuật di truyền

Bên cạnh việc tích hợp dữ liệu dự báo, bản thân thuật toán di truyền cũng có rất nhiều vị trí cần để cải thiện, giúp nó tìm ra lời giải tốt hơn cho bài toán đơn mục tiêu hiện tại. Hướng cải tiến đầu tiên và cơ bản nhất chính là **tối ưu hóa tham số**. Các tham số như kích thước quần thể, tỷ lệ lai ghép, và tỷ lệ đột biến có ảnh hưởng trực tiếp đến sự cân bằng giữa tốc độ hội tụ và khả năng khám phá không gian lời giải. Việc đánh giá và so sánh kết quả khi thay đổi từng tham số sẽ giúp chúng ta hiểu rõ mức độ ảnh hưởng của chúng đến hiệu quả thuật toán.

Các hướng nâng cấp cấu trúc cho thuật toán i truyền

Khi bài toán trở nên phức tạp hơn, chúng ta có thể xem xét các nâng cấp sâu hơn về mặt cấu trúc như sau:

- **Cải tiến khởi tạo quần thể:** Thay vì khởi tạo hoàn toàn ngẫu nhiên, ta có thể tạo ra một quần thể ban đầu "thông minh" hơn bằng cách kết hợp một tỷ lệ nhỏ (ví dụ: 20%) các cá thể tốt được tạo ra từ phương pháp Rule-Based với phần còn lại (80%) được tạo ngẫu nhiên.
- **Thiết kế toán tử lai ghép đặt biệt cho bài toán này (Problem-aware Crossover):** Phép lai ghép mặc định có thể phá vỡ các tuyến vận chuyển tốt đang có. Một phép lai ghép được thiết kế riêng cho bài toán (ví dụ: route-preserving crossover) sẽ giữ lại các chuỗi quyết định hợp lý từ cặp "cha mẹ".
- **Sử dụng toán tử thích ứng (Adaptive Operators):** Thay vì giữ cố định các tỷ lệ như tỉ lệ đột biến, tỉ lệ lai, . . . , thuật toán có thể tự động điều chỉnh chúng trong quá trình chạy. Ví dụ, giảm tỷ lệ đột biến khi thuật toán gần hội tụ để tinh chỉnh lời giải một cách chính xác hơn.
- **Sử dụng phương pháp lai ghép (Hybrid Approach):** Đây là một kỹ thuật kết hợp GA với một thuật toán tìm kiếm cục bộ (local search). Sau mỗi thế hệ, những cá thể tốt nhất sẽ được một thuật toán cục bộ tối ưu hóa thêm. Cách tiếp cận này còn được gọi là **Memetic Algorithm** và đã được áp dụng hiệu quả trong dự án thực tế.

Những cải tiến này đặc biệt phù hợp khi bài toán có **quy mô lớn** (ví dụ: trên 500 cửa hàng, 1,000 sản phẩm) hoặc có các **ràng buộc động** thay đổi theo thời gian (chi phí, giới hạn kho, điều kiện vận hành), khiến cho các lời giải đơn giản không còn hiệu quả.

IV.3. Áp dụng thuật toán đa mục tiêu (NSGA-II)

Thuật toán di truyền hiện tại được thiết kế để tối ưu một mục tiêu duy nhất: **tổng chi phí vận chuyển**. Tuy nhiên, trên thực tế, một doanh nghiệp có thể muốn cân bằng nhiều mục tiêu khác nhau và chúng thường mâu thuẫn với nhau. Ví dụ:

- **Giảm chi phí vận chuyển** (mục tiêu hiện tại).
- **Giảm số lượng chuyến hàng** (giảm chi phí nhân công, vận hành).
- **Tối đa hóa mức độ đáp ứng nhu cầu** (fill rate).
- **Cân bằng tồn kho sau luân chuyển** (giảm rủi ro trên toàn hệ thống).

Để giải quyết bài toán này, chúng ta có thể sử dụng một biến thể của thuật toán di truyền có tên là **NSGA-II (Non-dominated Sorting Genetic Algorithm II)**. Thay vì tìm ra một lời giải tốt nhất, NSGA-II sẽ tìm ra một tập hợp các lời giải tối ưu được gọi là **mặt trận Pareto (Pareto Front)**. Mỗi lời giải trên mặt trận này đại diện cho một sự đánh đổi khác nhau giữa

các mục tiêu (ví dụ: một lời giải chi phí thấp nhưng đáp ứng nhu cầu thấp, một lời giải khác chi phí cao nhưng đáp ứng nhu cầu cao). Điều này cho phép người quản lý lựa chọn kịch bản phù hợp nhất với chiến lược kinh doanh tại từng thời điểm.

V. Câu hỏi trắc nghiệm

1. Trong file `src/config.py`, biến `MIN_INVENTORY_DAYS` được sử dụng để làm gì?

   A. Xác định tuổi tối thiểu của một sản phẩm để được coi là hàng tồn kho.

   B. Tính toán mức tồn kho an toàn tối thiểu mà một cửa hàng nên duy trì cho mỗi sản phẩm.

   C. Quy định thời gian vận chuyển tối thiểu giữa hai cửa hàng bất kỳ.

   D. Đặt ra số ngày tối thiểu mà một sản phẩm phải có trong kho trước khi được bán.

2. Lớp `InventoryAnalyzer` trong file `src/engine/analyzer.py` xác định một sản phẩm tại một cửa hàng là hàng thừa (excess) dựa trên tiêu chí chính nào?

   A. Khi số lượng tồn kho của nó lớn hơn tổng nhu cầu của toàn bộ hệ thống.

   B. Khi chỉ số `days_of_supply` của nó cao hơn giá trị `MAX_INVENTORY_DAYS`.

   C. Khi chỉ số `days_of_supply` của nó thấp hơn giá trị `MIN_INVENTORY_DAYS`.

   D. Khi sản phẩm đó không bán được trong suốt `MAX_INVENTORY_DAYS` ngày.

3. Logic cốt lõi của thuật toán `RuleBasedOptimizer` là gì?

   A. Nó tạo ra các cặp điều chuyển ngẫu nhiên giữa nơi thừa và nơi thiếu.

   B. Nó ưu tiên thực hiện các lệnh điều chuyển có số lượng lớn nhất trước.

   C. Đây là một thuật toán tham lam (greedy), với mỗi mặt hàng đang thiếu, nó sẽ tìm nguồn hàng thừa có chi phí vận chuyển rẻ nhất để đáp ứng.

   D. Nó xây dựng một đồ thị phức tạp và tìm đường đi ngắn nhất cho tất cả các lệnh điều chuyển.

4. Trong thuật toán di truyền (`GeneticAlgorithmOptimizer`), hàm `_calculate_fitness` đánh giá một cá thể dựa trên tiêu chí nào là chính?

   A. Số lượng đơn vị hàng hóa được vận chuyển nhiều nhất.

   B. Thời gian thực thi nhanh nhất của giải pháp.

   C. Tổng chi phí vận chuyển của toàn bộ kế hoạch điều chuyển (càng thấp càng tốt).

   D. Số lượng cửa hàng tham gia vào quá trình điều chuyển.

5. Tại sao thuật toán di truyền (GA) thường tìm ra giải pháp có tổng chi phí thấp hơn so với thuật toán dựa trên luật (Rule-based)?

   A. Vì GA luôn chạy trong thời gian lâu hơn nên có nhiều thời gian để tính toán hơn.

   B. Vì GA có khả năng thoát khỏi các "tối ưu cục bộ" bằng cách khám phá một không gian giải pháp rộng lớn hơn thông qua lai ghép và đột biến.

   C. Vì GA luôn thực hiện ít lệnh điều chuyển hơn, do đó giảm chi phí.

   D. Vì thuật toán dựa trên luật không tính đến chi phí vận chuyển.

6. Trong file `notebooks/01_full_process_step_by_step.ipynb`, mục đích chính của việc chạy hai thuật toán và so sánh kết quả là gì?

   A. Để chứng minh rằng cả hai thuật toán đều cho ra cùng một kết quả chính xác.

   B. Để kiểm tra xem Python đã được cài đặt đúng hay chưa.

   C. Để đánh giá sự đánh đổi (trade-off) giữa tốc độ thực thi (Rule-based nhanh hơn) và chất lượng giải pháp (GA thường có chi phí thấp hơn).

   D. Để xác định xem nên sử dụng Pandas hay NumPy cho việc phân tích.

7. Hàm `_repair_solution` trong `GeneticAlgorithmOptimizer` có vai trò gì?

   A. Sửa các lỗi cú pháp trong mã nguồn của thuật toán.

   B. Đảm bảo rằng một giải pháp (sau khi lai ghép hoặc đột biến) không vi phạm các ràng buộc cơ bản, ví dụ như chuyển nhiều hơn số lượng đang có.

   C. Tối ưu hóa lại chi phí vận chuyển sau khi đã có giải pháp.

   D. Làm tròn số lượng hàng hóa vận chuyển thành số nguyên gần nhất.

8. Dữ liệu trong file `transport_cost_matrix.csv` biểu diễn điều gì?

   A. Chi phí để vận chuyển một đơn vị sản phẩm giữa hai cửa hàng bất kỳ.

   B. Khoảng cách (km) giữa các cửa hàng.

   C. Thời gian vận chuyển trung bình (giờ) giữa các cửa hàng.

   D. Chi phí lưu kho cho mỗi sản phẩm tại mỗi cửa hàng.

9. Trong thuật toán di truyền, toán tử lai ghép (Crossover) thực hiện nhiệm vụ gì?

   A. Thay đổi ngẫu nhiên một vài gen trong một cá thể để tạo sự đa dạng.

   B. Đánh giá chất lượng của từng cá thể trong quần thể.

   C. Kết hợp thông tin từ hai cá thể "cha mẹ" để tạo ra các cá thể "con" mới, kế thừa các đặc tính tốt.

   D. Lựa chọn những cá thể tốt nhất từ quần thể hiện tại để giữ lại cho thế hệ sau.

10. Yếu tố nào sau đây là một ưu điểm của thuật toán `RuleBasedOptimizer` so với `GeneticAlgorithmOptimizer`?

    A. Luôn tìm ra giải pháp có tổng chi phí vận chuyển thấp nhất.

    B. Tốc độ thực thi rất nhanh và logic đơn giản, dễ hiểu.

    C. Có khả năng xử lý các bài toán có nhiều mục tiêu cùng lúc.

    D. Đảm bảo đáp ứng 100% nhu cầu của tất cả các cửa hàng.

VI. Tài liệu tham khảo

Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.

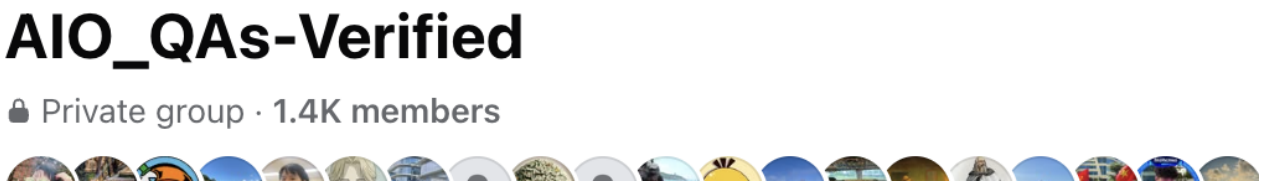

Hình 11: Hình ảnh group facebook AIO Q&A.

AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM COURSE 2026

Project (Case Study): Phân cụm khách hàng dùng K-Means

I. Phân khúc khách hàng

Trong kỷ nguyên Big Data, việc áp dụng một chiến lược kinh doanh duy nhất cho toàn bộ thị trường (hay còn gọi là mass marketing) không còn mang lại hiệu quả tối ưu. Khách hàng ngày nay mong đợi sự cá nhân hóa trong trải nghiệm mua sắm và dịch vụ. Đây là lúc bài toán **Customer Segmentation** (tạm dịch: phân khúc khách hàng) trở nên cấp thiết.

Phân khúc khách hàng là quá trình chia cơ sở khách hàng thành các nhóm nhỏ dựa trên những đặc điểm tương đồng như hành vi mua sắm, nhân khẩu học, hoặc tần suất chi tiêu. Mục tiêu cốt lõi của việc này bao gồm:

- **Tối ưu hóa Marketing (Targeted Marketing):** Thay vì gửi một email quảng cáo cho tất cả, doanh nghiệp có thể gửi khuyến mãi "đồ mẹ và bé" cho nhóm khách hàng là phụ huynh, hoặc "thiết bị công nghệ" cho nhóm khách hàng trẻ yêu thích kỹ thuật số.
- **Giữ chân khách hàng (Customer Retention):** Nhận diện nhóm khách hàng có nguy cơ rời bỏ (Churn rate cao) để có chính sách chăm sóc đặc biệt.
- **Phân bổ nguồn lực:** Tập trung ngân sách vào nhóm khách hàng mang lại giá trị lợi nhuận cao nhất (nhóm VIP).

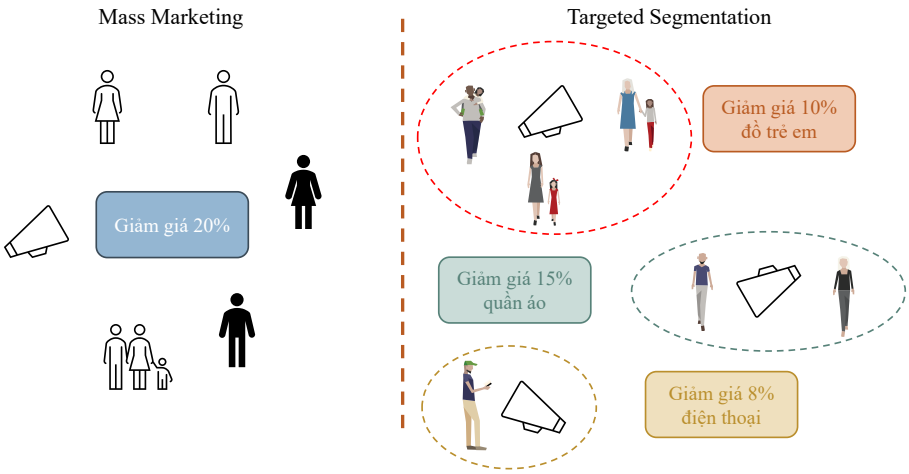

Hình 1: Sự chuyển dịch từ tiếp thị đại trà kém hiệu quả sang phân khúc mục tiêu được cá nhân hóa.

Để thực hiện việc phân loại này một cách tự động và chính xác trên tập dữ liệu lớn, chúng ta không thể thực hiện thủ công. Ta cần sự hỗ trợ của các thuật toán Machine Learning, cụ thể là nhóm thuật toán học không giám sát (Unsupervised Learning).

Trong dự án này, chúng ta sẽ sử dụng **K-Means Clustering** (Phân cụm K-Means) - một trong những thuật toán phổ biến và hiệu quả nhất để giải quyết bài toán phân nhóm dữ liệu chưa được dán nhãn.

Tiêu chí	Phân loại thủ công	K-Means Clustering
Độ phức tạp	Khó xử lý nhiều chiều dữ liệu cùng lúc.	Xử lý tốt đa chiều (Tuổi, Thu nhập, Tần suất mua...).
Tính khách quan	Dễ bị ảnh hưởng bởi cảm tính người phân loại.	Dựa hoàn toàn vào khoảng cách toán học giữa các điểm dữ liệu.
Khả năng mở rộng	Tốn thời gian khi dữ liệu lớn.	Tốc độ xử lý nhanh, phù hợp với Big Data.

Bảng 1: So sánh hiệu quả giữa phân loại thủ công và thuật toán K-Means.

Trong bài học này, chúng ta sẽ đóng vai là một Data Scientist cho một chuỗi bán lẻ. Nhiệm vụ của chúng ta là phân tích dữ liệu giao dịch và xây dựng mô hình K-Means để nhóm khách hàng. Các bước thực hiện bao gồm:

1. **Khám phá dữ liệu (EDA):** Hiểu cấu trúc và phân bố của tập dữ liệu.
2. **Tiền xử lý:** Chuẩn hóa dữ liệu để đảm bảo thuật toán hoạt động chính xác.
3. **Lựa chọn số cụm K tối ưu:** Sử dụng phương pháp Elbow Method hoặc Silhouette score để tìm K tốt nhất.
4. **Huấn luyện mô hình:** Khởi tạo và huấn luyện K-Means.
5. **Phân tích kết quả:** Trực quan hóa các cụm và đưa ra đề xuất kinh doanh (Actionable Insights).

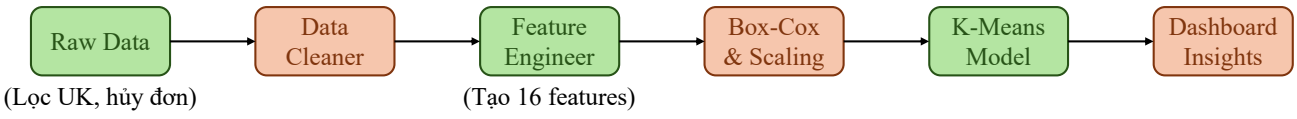

Hình 2: Pipeline của bài toán phân cụm khách hàng.

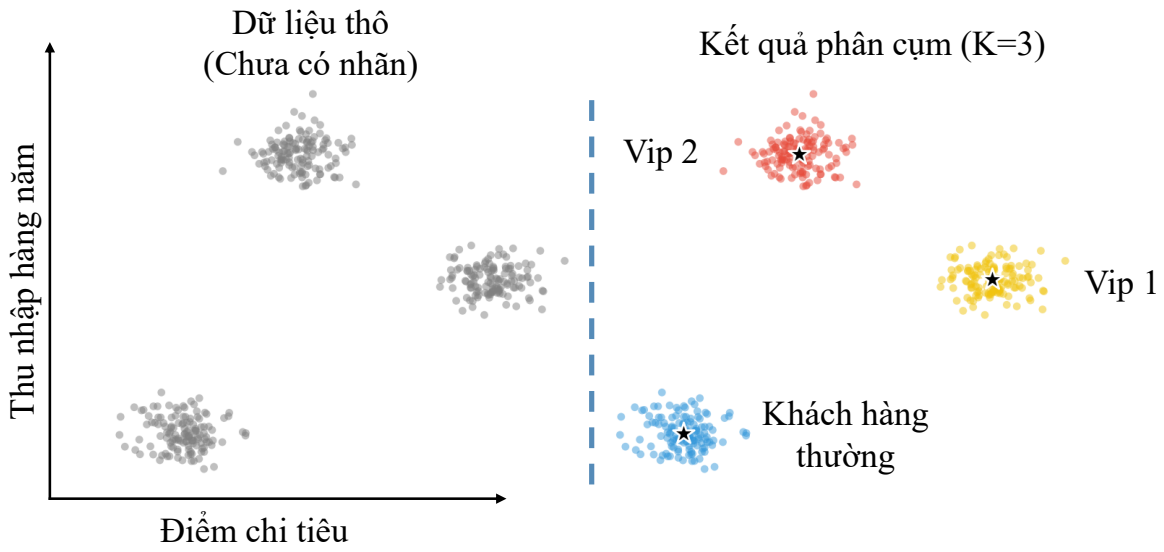

Hình 3: Trực quan hóa cách K-Means nhóm các điểm dữ liệu thô (trái) thành các cụm có tâm xác định (phải).

Danh sách các module trong project. Để tiện theo dõi, bảng dưới đây tổng hợp các phần chính trong module của chúng ta. Toàn bộ dự án được chứa trong link Github này.

Bảng thành phần Project

Thành phần	Ý nghĩa và chức năng
`src/clustering_library.py`	Thư viện trung tâm của dự án, chứa các lớp (class) xử lý chính: `DataCleaner` (làm sạch dữ liệu), `FeatureEngineer` (tạo đặc trưng khách hàng), `ClusterAnalyzer` (thực hiện phân cụm K-Means) và `DataVisualizer` (trực quan hóa).
`notebooks/01_cleaning_and_eda`	Notebook bước 1: Thực hiện tải dữ liệu thô, xử lý các giá trị thiếu, lọc dữ liệu rác (đơn hàng bị hủy) và thực hiện phân tích khám phá dữ liệu (EDA) để hiểu tổng quan về tập dữ liệu.
`notebooks/02_feature_engineer`	Notebook bước 2: Chịu trách nhiệm tạo ra 16 đặc trưng (features) hành vi khách hàng từ dữ liệu giao dịch, thực hiện biến đổi Box-Cox để chuẩn hóa phân phối và Scaling dữ liệu.
`notebooks/03_modeling.ipynb`	Notebook bước 3: Tìm số cụm tối ưu (sử dụng Elbow Method và Silhouette Score), huấn luyện mô hình K-Means, và phân tích đặc điểm của từng nhóm khách hàng được tạo ra.
`data/`	Thư mục chứa dữ liệu đầu vào (`online_retail.csv`) và lưu trữ các dữ liệu trung gian đã qua xử lý (processed data) để sử dụng giữa các bước phân tích.
`setup_code.py`	Script hỗ trợ khởi tạo cấu trúc thư mục chuẩn cho dự án, tạo các file cấu hình ban đầu và cài đặt môi trường cần thiết.

II. Phân tích và làm sạch dữ liệu

Trong bất kỳ dự án nào, việc hiểu và làm sạch dữ liệu là bước nền tảng quan trọng nhất. Dữ liệu thực tế thường chứa nhiễu, giá trị thiếu hoặc các ngoại lệ (outliers) có thể làm sai lệch kết quả của mô hình phân cụm. Trong phần này, ta sẽ sử dụng bộ dữ liệu *Online Retail* để thực hiện quy trình từ làm sạch đến phân tích khám phá (Exploratory Data Analysis - EDA).

Tại sao chúng ta dùng OOP?

Để đảm bảo tính chuyên nghiệp khi trình bày cho người nghe, dự án này áp dụng tư duy Lập trình hướng đối tượng (OOP). Thay vì viết hàng trăm dòng script xử lý rối rắm vào chính những file notebook mà chúng ta trình bày, chúng ta đóng gói logic vào các lớp (Class) trong một file riêng. Sau đó, khi làm việc với notebook ta có, ta sẽ sử dụng hàm `import` để sử dụng các lớp nói trên. Điều này giúp notebook sạch sẽ, tập trung vào kết quả và dễ dàng tái sử dụng.
Ví dụ minh họa sự tinh gọn:

```
from clustering_library import DataCleaner, DataVisualizer

# Code ngắn gọn, dễ hiểu cho người đọc
cleaner = DataCleaner(file_path='online_retail.csv')
df_uk = cleaner.clean_data()
```

Tiếp theo, chúng ta sẽ sử dụng class `DataCleaner` này để xử lý tập dữ liệu *Online Retail*, bao gồm việc loại bỏ các hóa đơn hủy và lọc khách hàng UK.

II.1. Tải và kiểm tra dữ liệu ban đầu

Đầu tiên, ta cần tải dữ liệu và kiểm tra cấu trúc cơ bản. Bộ dữ liệu bao gồm các giao dịch từ tháng 12/2010 đến tháng 12/2011 của một doanh nghiệp bán lẻ trực tuyến tại Anh.

Ta sử dụng lớp `DataCleaner` từ thư viện `clustering_library` để quản lý việc tải dữ liệu:

Tải dữ liệu

```
from clustering_library import DataCleaner, DataVisualizer

# Khởi tạo và tải dữ liệu
data_path = "../data/raw/online_retail.csv"
cleaner = DataCleaner(data_path)
df = cleaner.load_data()

# Kiểm tra thông tin cơ bản
print(f"Kích thước: {df.shape}")
print(f"Số lượng khách hàng: {df['CustomerID'].nunique()}")
```

Dữ liệu thô ban đầu chứa hơn 500,000 dòng, tuy nhiên bao gồm cả các giao dịch bị hủy, dữ liệu thiếu thông tin khách hàng và các giao dịch từ nhiều quốc gia khác nhau.

II.2. Làm sạch dữ liệu

Để đảm bảo tính nhất quán cho việc phân khúc khách hàng, ta thực hiện các bước làm sạch sau:

1. **Tính toán tổng giá trị:** Tạo cột `TotalPrice` = `Quantity` × `UnitPrice`.
2. **Xử lý đơn hàng hủy:** Loại bỏ các hóa đơn bắt đầu bằng ký tự 'C' (Cancelled).
3. **Lọc theo địa lý:** Chỉ giữ lại các giao dịch tại **United Kingdom** để tránh nhiễu do sự khác biệt về hành vi mua sắm giữa các quốc gia.
4. **Xử lý dữ liệu thiếu:** Loại bỏ các bản ghi không có `CustomerID` vì ta cần định danh khách hàng để phân cụm.
5. **Làm sạch giá trị:** Loại bỏ các giao dịch có số lượng hoặc đơn giá âm/bằng 0.

Thực hiện làm sạch dữ liệu

```
# Thực hiện quy trình làm sạch
df_uk = cleaner.clean_data()

# Tạo thêm các đặc trưng thời gian (Giờ, Ngày trong tuần)
cleaner.create_time_features()

print(f"Số lượng giao dịch sau khi làm sạch: {len(df_uk)}")
```

Sau quá trình này, ta thu được bộ dữ liệu sạch, sẵn sàng cho việc phân tích sâu hơn.

II.3. EDA

Sau khi có được bộ dữ liệu đã được làm sạch, sau đây chúng ta sẽ thực hiện việc nghiên cứu bộ dữ liệu này qua phương pháp trực quan hóa. Các bạn muốn tìm hiểu về cách vẽ nên các chart như dưới đây có thể xem thêm ở file `src/clustering_library.py` và lớp `DataVisualizer` trong dự án.

II.3.1. Doanh thu theo thời gian

Trước tiên, việc hiểu rõ xu hướng doanh thu giúp ta nhận diện tính mùa vụ và sức khỏe chung của doanh nghiệp. Biểu đồ dưới đây thể hiện doanh thu theo ngày và theo tháng.

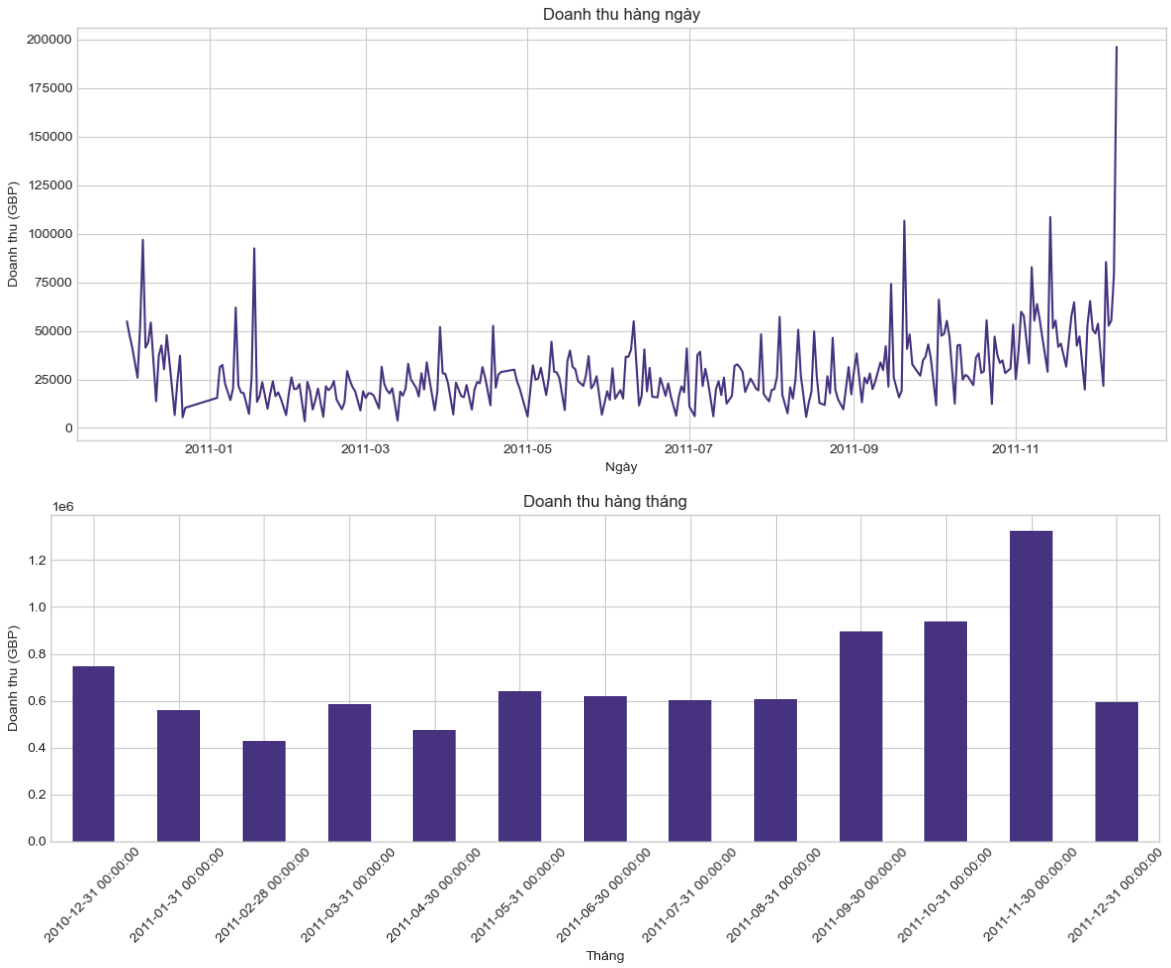

Hình 4: Biểu đồ xu hướng doanh thu theo ngày và tháng. Ta có thể quan sát thấy sự biến động doanh thu và các đỉnh điểm mua sắm vào dịp cuối năm.

II.3.2. Hành vi mua sắm

Để tối ưu hóa các chiến dịch marketing, ta cần biết khách hàng thường mua sắm vào khung giờ nào trong ngày và ngày nào trong tuần.

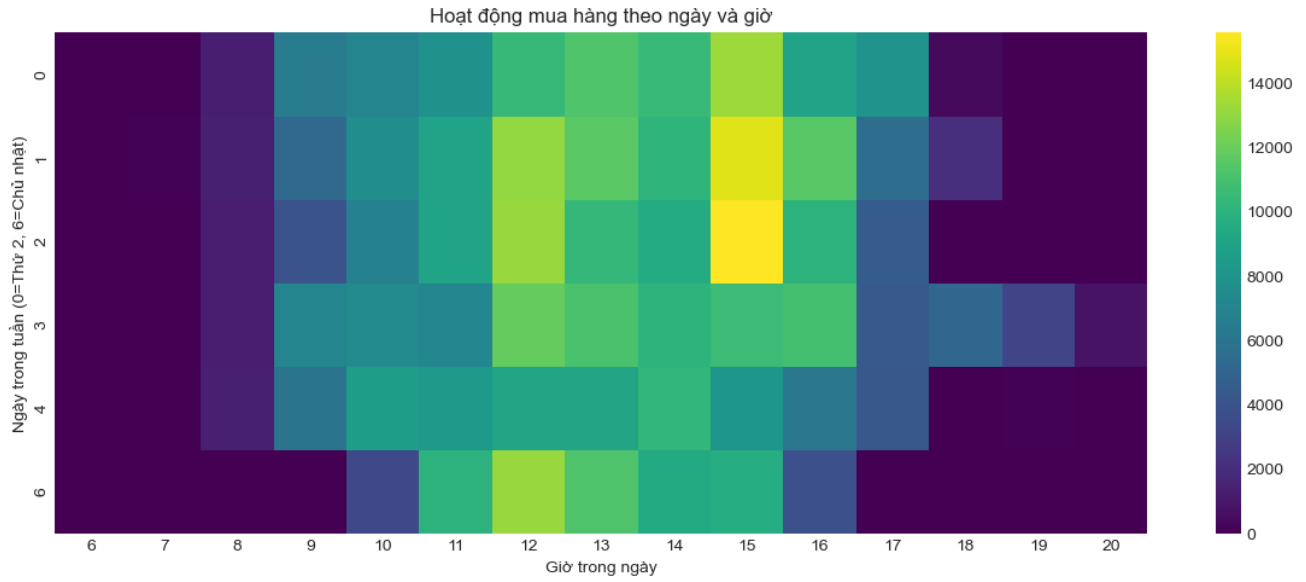

Hình 5: Heatmap thể hiện tần suất mua hàng theo "giờ" trong ngày và "ngày" trong tuần. Vùng màu sáng hơn thể hiện mật độ giao dịch cao hơn. Khách hàng của chúng ta thường mua vào giờ hành chính.

II.3.3. Phân tích sản phẩm và khách hàng

Ta cũng cần xem xét các sản phẩm bán chạy nhất và phân phối chi tiêu của khách hàng để có cái nhìn tổng quan về danh mục sản phẩm hay còn gọi là product portfolio.

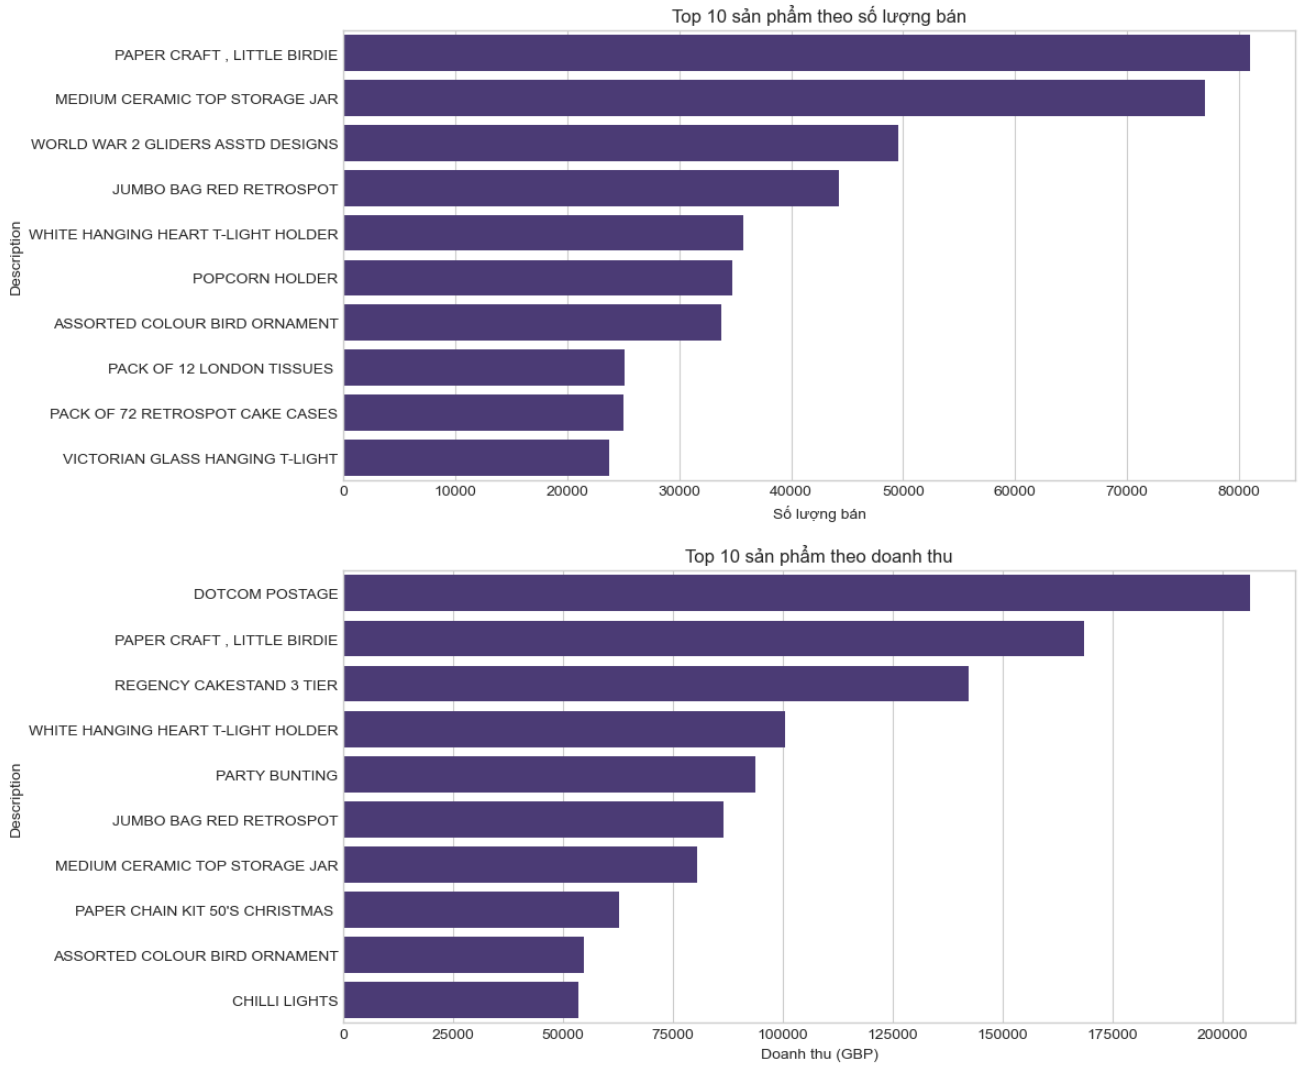

Hình 6: Top 10 sản phẩm bán chạy nhất theo số lượng và doanh thu. Các sản phẩm này thường là các mặt hàng trang trí hoặc quà tặng phổ biến.

II.3.4. Phân tích RFM (Recency - Frequency - Monetary)

Và cuối cùng, trước khi đi vào các kỹ thuật phân cụm phức tạp, ta xem xét phân phối của ba chỉ số cơ bản RFM. Đây không chỉ là các con số thống kê, mà là ba trụ cột giúp trả lời các câu hỏi chiến lược về hành vi khách hàng:

- **Recency (sự mới mẻ):** Số ngày kể từ lần mua cuối cùng.
  → *Ý nghĩa:* Đo lường **mức độ gắn kết**. Khách hàng mới mua gần đây có xác suất quay lại cao hơn, trong khi Recency cao báo hiệu nguy cơ rời bỏ.
- **Frequency (tần suất):** Tổng số đơn hàng đã thực hiện.
  → *Ý nghĩa:* Đo lường **độ trung thành**. Giúp phân biệt giữa khách vãng lai và khách hàng thân thiết có thói quen mua sắm định kỳ.

- **Monetary (giá trị tiền tệ):** Tổng số tiền khách hàng đã chi tiêu.
  → *Ý nghĩa:* Đo lường **giá trị trọn đời**. Giúp nhận diện nhóm "Cá mập" - những người đóng góp phần lớn doanh thu theo nguyên lý Pareto (80/20).

Tính toán chỉ số RFM

```
# Tính toán RFM
rfm_data = cleaner.calculate_rfm()
visualizer.plot_rfm_analysis(rfm_data)
```

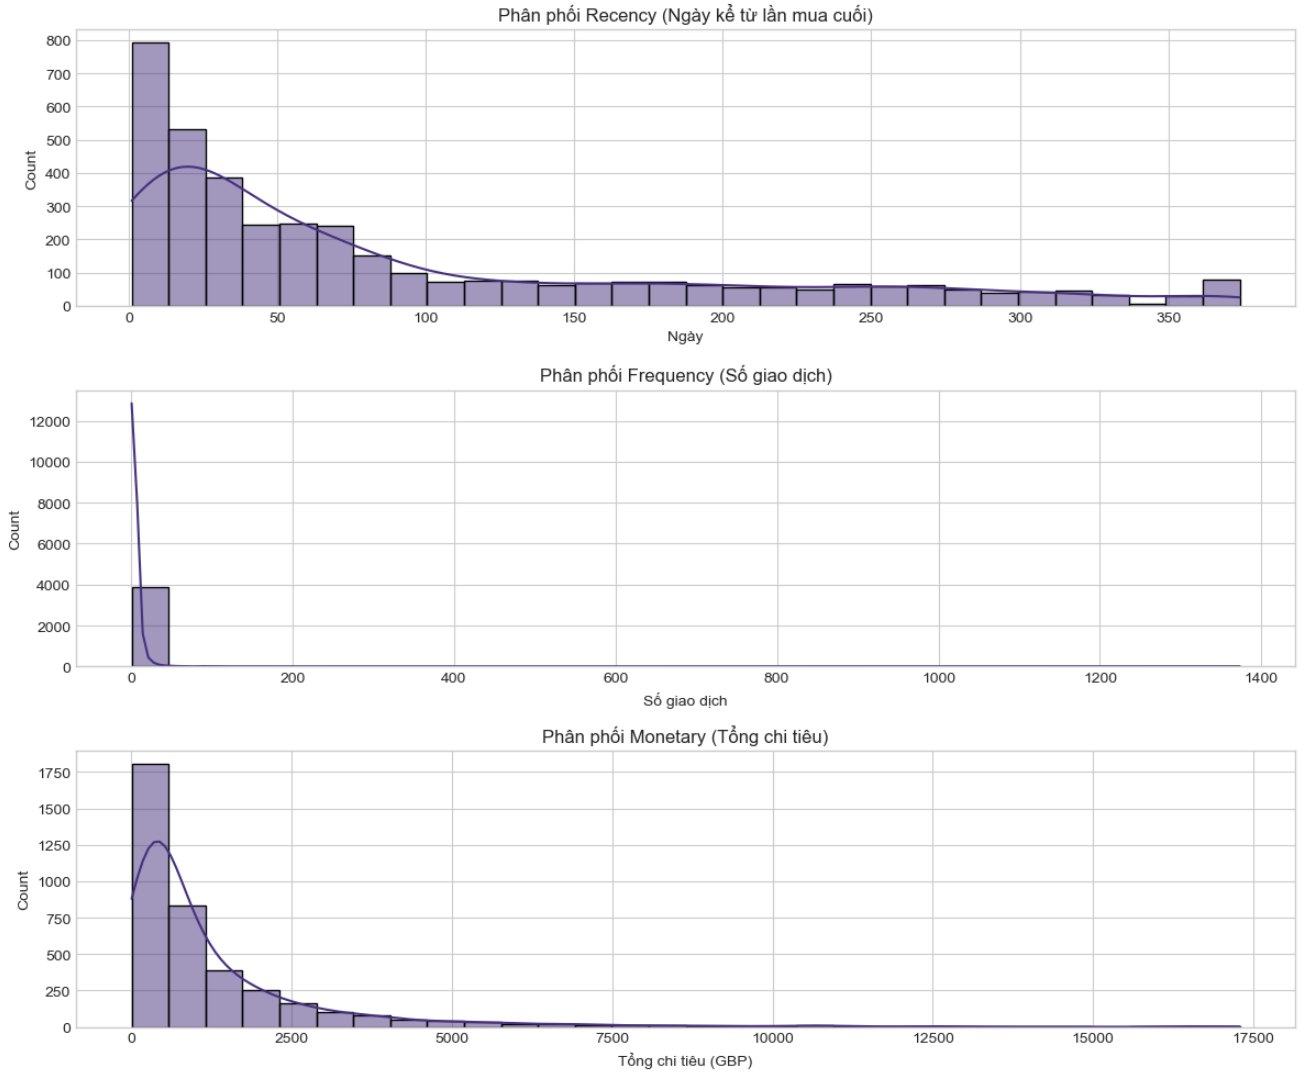

Hình 7: Phân phối của các chỉ số Recency, Frequency và Monetary. Đồ thị cho thấy sự phân phối lệch (skewed), đặc trưng của dữ liệu bán lẻ (quy luật 80/20).

Sau quá trình làm sạch và EDA, ta đã có một bộ dữ liệu chất lượng cao từ thị trường UK. Các phân tích ban đầu cho thấy sự đa dạng lớn trong hành vi khách hàng, từ những người mua sắm thường xuyên đến những khách hàng vãng lai. Đây là tiền đề vững chắc để ta bước sang giai

đoạn tiếp theo: Feature Engineering (tạm dịch: tạo thêm đặc trưng) để xây dựng các biến số đầu vào cho mô hình K-Means.

Tổng quan bước 1

Trong phần này, chúng ta đã hoàn tất quy trình chuẩn bị dữ liệu từ tập dữ liệu Online Retail thô. Sau khi tiền xử lý, ta tinh lọc được một bộ dữ liệu chất lượng cao gồm **354,321** giao dịch từ **3,920** khách hàng duy nhất trong giai đoạn từ tháng 12/2010 đến tháng 12/2011.
Quá trình EDA đã cho ta thấy những xu hướng quan trọng: doanh thu toàn cục có xu hướng tăng trưởng tích cực theo thời gian và hoạt động mua sắm tập trung chủ yếu vào khung giờ hành chính các ngày trong tuần. Đặc biệt, việc phân tích sơ bộ chỉ số **RFM** (Recency, Frequency, Monetary) cho thấy sự đa dạng lớn trong tần suất và giá trị chi tiêu của từng cá nhân.

III. Tạo đặc trưng

Sau khi làm sạch dữ liệu, bước tiếp theo là chuyển đổi dữ liệu giao dịch thô thành các đặc trưng có ý nghĩa ở cấp độ khách hàng. Thay vì chỉ sử dụng mô hình RFM truyền thống (3 biến), ta sẽ xây dựng một bộ 16 đặc trưng toàn diện để nắm bắt đa chiều hành vi mua sắm của người dùng.

III.1. Tại sao cần mở rộng Features?

Mô hình RFM (Recency, Frequency, Monetary) là tiêu chuẩn trong việc phân khúc khách hàng, nhưng nó có những hạn chế nhất định:

- **Thiếu chiều sâu về sản phẩm:** RFM không cho biết khách hàng mua đa dạng sản phẩm hay chỉ tập trung vào một vài mặt hàng.
- **Bỏ qua hành vi trong từng giao dịch:** RFM chỉ nhìn vào tổng thể, không phản ánh thói quen chi tiêu trong mỗi lần mua (ví dụ: mua ít nhưng giá trị cao vs mua nhiều nhưng giá trị thấp).
- **Độ nhạy với giá:** RFM không tách biệt rõ ràng giữa khách hàng mua hàng giá rẻ số lượng lớn và khách hàng mua hàng cao cấp số lượng ít.

Do đó, ta xây dựng bộ 16 features chia làm 4 nhóm chính để khắc phục các hạn chế trên.

III.2. Xây dựng bộ đặc trưng

Ta sử dụng lớp `FeatureEngineer` để tự động hóa quá trình này.

Khởi tạo Feature Engineering

```
from clustering_library import FeatureEngineer

# Tải dữ liệu đã làm sạch
data_path = '../data/processed/cleaned_uk_data.csv'
engineer = FeatureEngineer(data_path)
df = engineer.load_data()

# Tạo features
customer_features = engineer.create_customer_features()
```

Dưới đây là chi tiết ý nghĩa của 4 nhóm đặc trưng được tạo thêm. Để đọc đầy đủ ý nghĩa của từng thuộc tính một trong 16 thuộc tính, bạn có thể tham khảo file `notebooks/02_feature_engineering-.ipynb`:

III.2.1. Nhóm 1: Chỉ số cơ bản (Volume & Value)

Nhóm này mở rộng từ dữ liệu RFM, cung cấp cái nhìn tổng quan về quy mô tiêu dùng.

- `Sum_Quantity`: Tổng số lượng sản phẩm đã mua.
- `Mean_UnitPrice`: Mức giá trung bình của các sản phẩm khách hàng chọn (độ nhạy về giá).
- `Sum_TotalPrice`: Tổng chi tiêu trọn đời (tương đương Monetary).
- `Count_Invoice`: Số lần mua hàng (tương đương Frequency).
- `Count_Stock`: Số lượng mã sản phẩm khác nhau đã mua (độ đa dạng).

III.2.2. Nhóm 2: Hành vi theo Giao dịch (Transaction Behavior)

Nhóm này trả lời câu hỏi: "Mỗi lần vào cửa hàng, khách hàng cư xử thế nào?"

- `Mean_QuantitySumPerInvoice`: Giỏ hàng trung bình to hay nhỏ?
- `Mean_TotalPriceSumPerInvoice`: Giá trị trung bình mỗi hóa đơn.
- `Mean_StockCountPerInvoice`: Trung bình mỗi lần mua bao nhiêu loại hàng?

III.2.3. Nhóm 3 & 4: Hành vi theo Sản phẩm (Product Preference)

Nhóm này đi sâu vào sở thích sản phẩm cụ thể.

- `Mean_InvoiceCountPerStock`: Trung bình một sản phẩm được mua lại bao nhiêu lần (độ trung thành với sản phẩm).
- `Mean_UnitPriceMeanPerStock`: Giá trị trung bình của từng dòng sản phẩm khách hàng chọn.

III.3. Chuẩn hóa và biến đổi Dữ liệu

Quan sát trực quan dữ liệu gốc qua biểu đồ Histogram và Boxplot (hình dưới), ta nhận thấy một vấn đề nghiêm trọng: dữ liệu khách hàng bị lệch phải (right-skewness). Hầu hết dữ liệu tập trung ở các giá trị thấp, chẳng hạn số lượng mua ít, trong khi một nhóm nhỏ giá trị rất lớn làm phân phối kéo dài về phía bên phải.

Thay vì chỉ sử dụng Logarit thông thường, ta áp dụng phép biến đổi Box-Cox ở đây. Đây là kỹ thuật tìm ra tham số λ tối ưu để biến đổi dữ liệu về dạng gần với phân phối chuẩn (Gaussian) nhất có thể, giúp:

1. Co ngắn khoảng cách của các giá trị ngoại lai (xử lý đuôi dài).
2. Ổn định phương sai.
3. Tạo ra không gian dữ liệu đối xứng hơn cho K-Means hoạt động hiệu quả.

III.3.1. Box-Cox Transformation

Code cho thuật toán Box-Cox được trình bày như dưới đây. Trước hết, 'CustomerID' được tách ra làm index để không bị biến đổi nhầm, tránh gây nhiễu mô hình. Tiếp theo, dữ liệu được cộng thêm 1 ($x + 1$) để xử lý các giá trị bằng 0 (do toán học của Box-Cox yêu cầu đầu vào dương tuyệt đối). Cuối cùng, hàm 'boxcox' được áp dụng lần lượt lên từng đặc trưng để tự động tìm ra tham số λ tối ưu riêng biệt, giúp đưa biểu đồ phân phối của các chỉ số RFM từ dạng lệch (skewed) về dạng hình chuông (Gaussian).

Định nghĩa hàm Box-Cox

```
def transform_features(self):
    # Set CustomerID as index
    customer_features_indexed = self.customer_features.set_index("CustomerID")

    # Apply Box-Cox transformation
    feature_values = customer_features_indexed.values + 1
    self.customer_features_transformed = customer_features_indexed. copy()

    for i, feature in  enumerate(self.feature_customer):
        transformed, lambda_param = boxcox(feature_values[:, i])
        self.customer_features_transformed.iloc[:, i] = transformed

    return self.customer_features_transformed
```

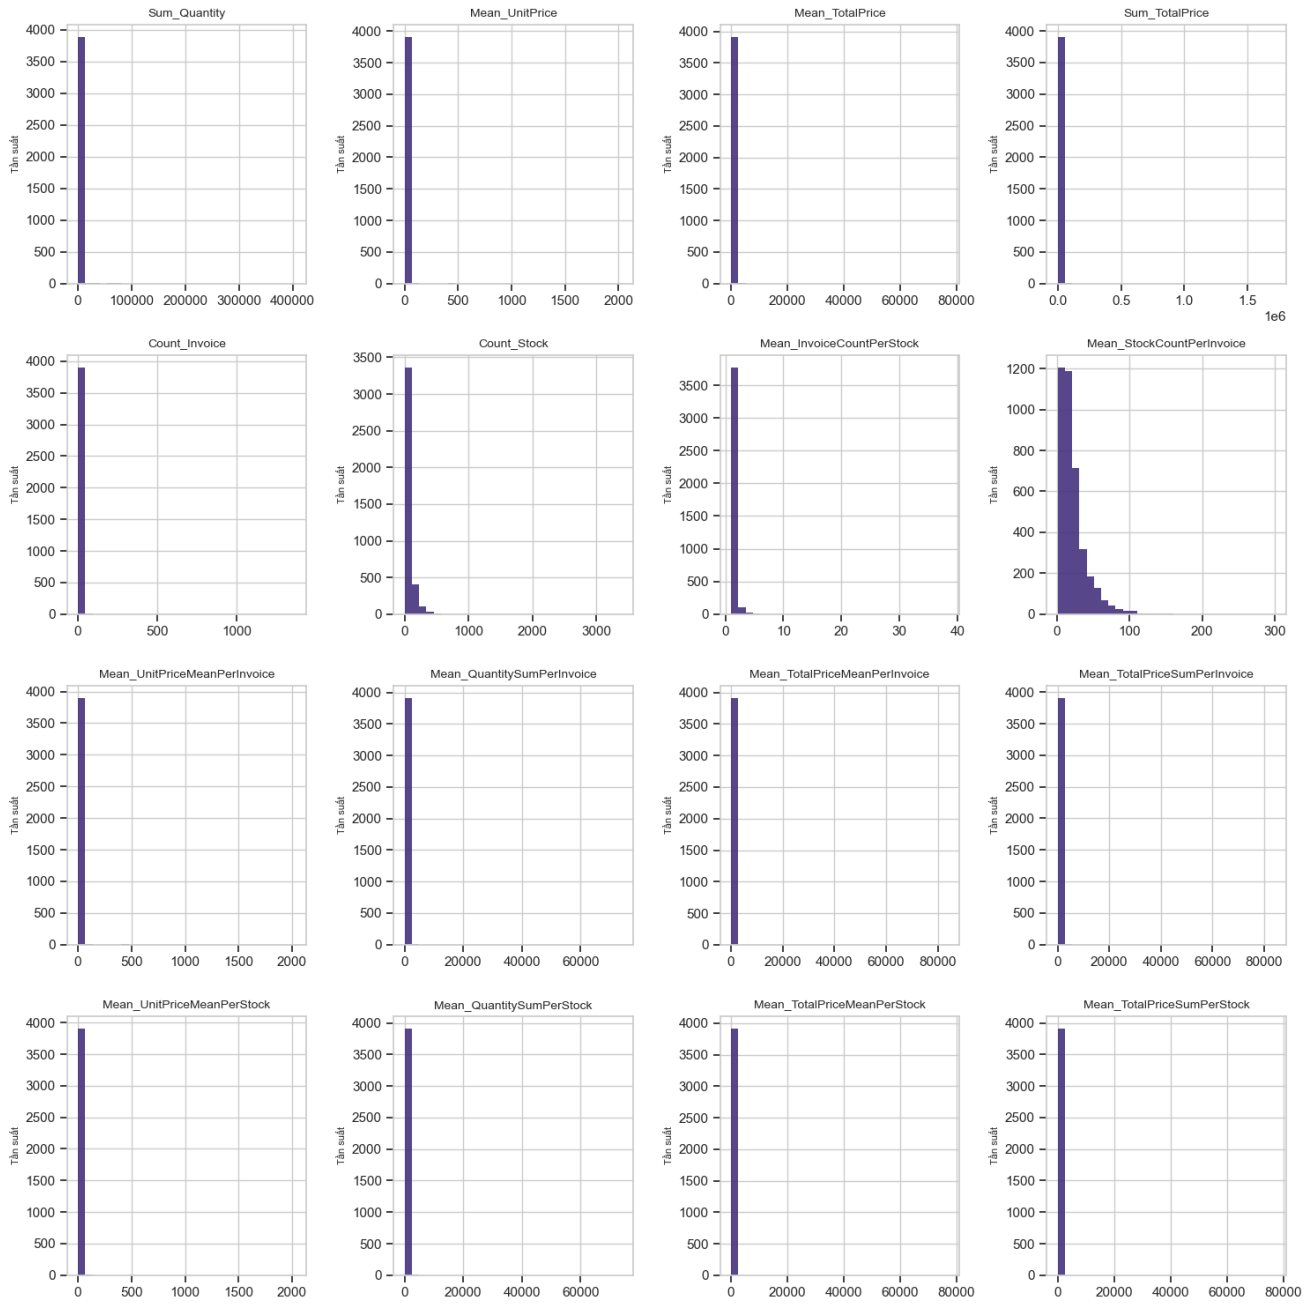

Hình 8: Phân phối của các features trước khi biến đổi. Ta thấy rõ sự lệch phải của dữ liệu.

Sử dụng hàm Box-Cox

```
# Áp dụng Box-Cox transformation
customer_features_transformed = engineer.transform_features()

# Trực quan hóa sau khi biến đổi
engineer.plot_features_histograms(transformed= True)
```

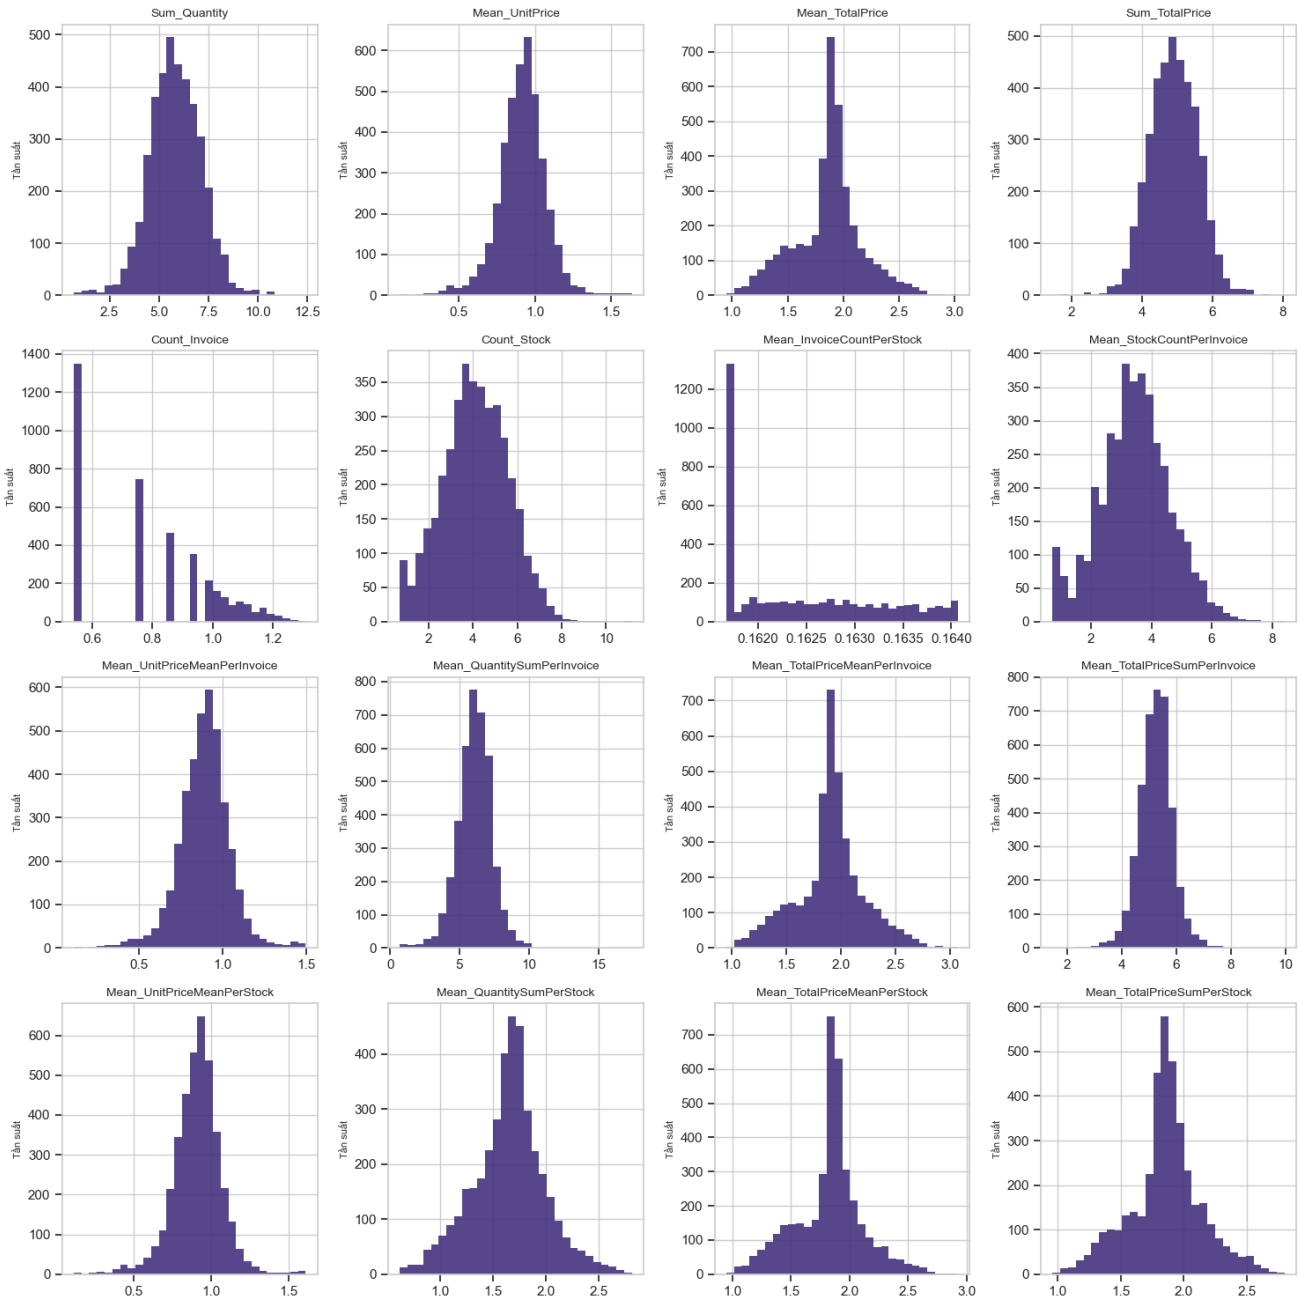

Hình 9: Phân phối của các features sau khi áp dụng Box-Cox. Dữ liệu đã trở nên đối xứng hơn, phù hợp cho K-Means.

III.3.2. Standard Scaling

Cuối cùng, ta đưa tất cả features về cùng một thang đo (mean=0, std=1) để đảm bảo không có feature nào lấn át các feature khác do đơn vị lớn hơn (ví dụ: Doanh thu hàng nghìn bảng vs Số lần mua hàng chục lần).

Standard Scaling

```
# Chuẩn hóa dữ liệu (Z-score normalization)
customer_features_scaled = engineer.scale_features()
engineer.save_features()
```

IV. Mô hình hóa và phân cụm

Sau khi đã có bộ dữ liệu đặc trưng chất lượng cao, ta tiến hành bước quan trọng nhất: Phân nhóm khách hàng sử dụng thuật toán học máy không giám sát. Trong dự án này, ta sử dụng thuật toán K-Means clustering.

IV.1. Giới thiệu về K-Means clustering

K-Means là một trong những thuật toán phân cụm phổ biến nhất nhờ sự đơn giản và hiệu quả. Mục tiêu của K-Means là chia N điểm dữ liệu thành K cụm sao cho khoảng cách giữa các điểm trong cùng một cụm là nhỏ nhất.

Để hiểu rõ hơn về cơ chế hoạt động và ứng dụng thực tế của K-Means, bạn có thể tham khảo bài viết chi tiết tại đây.

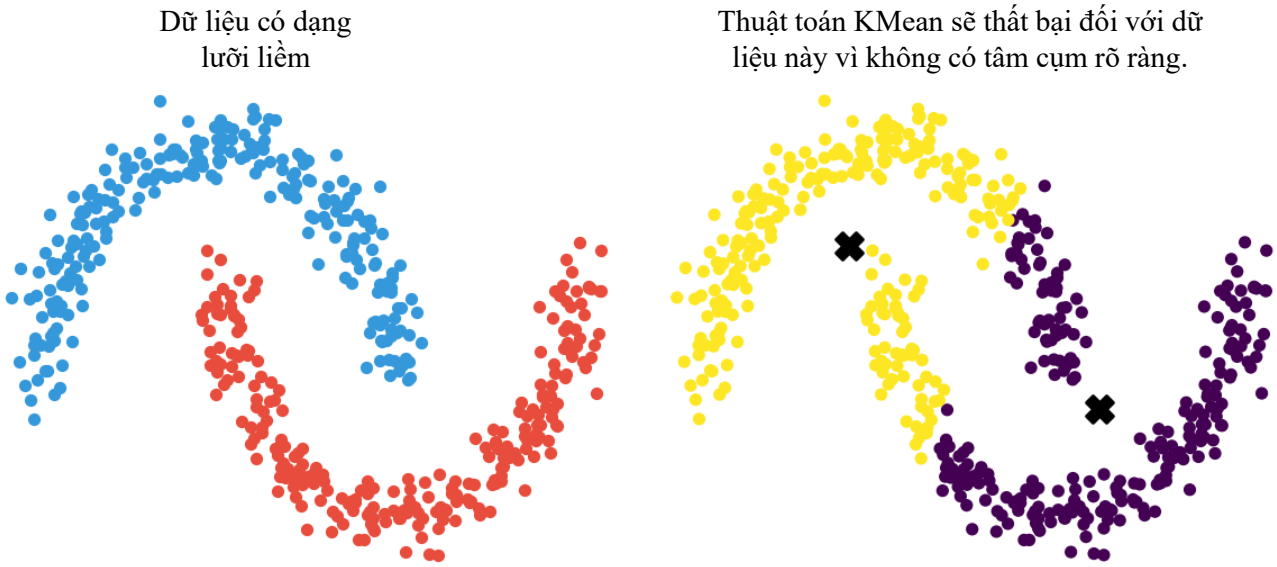

Hình 10: Minh họa điểm yếu của K-Means với dữ liệu không có dạng hình cầu. Thuật toán thất bại trong việc phân tách hai cụm hình lưỡi liềm do dựa trên khoảng cách Euclidean.

IV.2. Xác định số cụm tối ưu

Việc lựa chọn số cụm K phù hợp cần cân bằng giữa chất lượng phân cụm và khả năng diễn giải kết quả. Để xác định K, có thể kết hợp hai phương pháp.

Phương pháp thứ nhất là *Elbow Method*. Phương pháp này xem xét mức giảm của tổng bình phương khoảng cách trong cụm khi K tăng và chọn giá trị mà mức cải thiện bắt đầu chậm lại.

Phương pháp thứ hai là *Silhouette Score*. Chỉ số này đánh giá đồng thời mức độ gắn kết của các điểm trong cùng cụm và mức độ tách biệt giữa các cụm. Giá trị càng gần 1 cho thấy kết quả phân cụm càng rõ ràng.

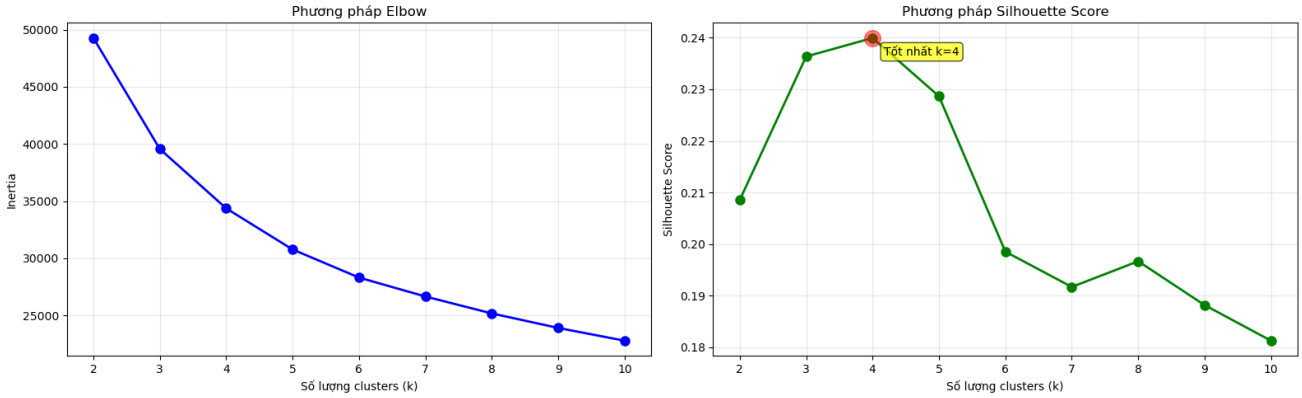

Hình 11: Biểu đồ Elbow và Silhouette score. Dựa trên biểu đồ, ta thấy K=3 hoặc K=4 là các lựa chọn tối ưu.

IV.3. Phân tích thành phần chính (PCA)

Trước khi phân cụm, ta sử dụng PCA để giảm chiều dữ liệu, giúp trực quan hóa dữ liệu nhiều chiều (16 chiều) xuống còn 2 hoặc 3 chiều để dễ quan sát cấu trúc phân bố.

Thực hiện PCA

```
# Áp dụng PCA
df_pca = analyzer.apply_pca()

# Biểu đồ tỷ lệ phương sai được giải thích
analyzer.plot_pca_variance()
```

IV.4. So sánh phân cụm K=3 và K=4

Việc lựa chọn số lượng cụm K là một quyết định quan trọng. Dựa trên biểu đồ Elbow và Silhouette score, ta cân nhắc giữa K=3 và K=4. Dưới đây là sự so sánh trực quan kết quả phân cụm trên không gian PCA 2D và 3D.

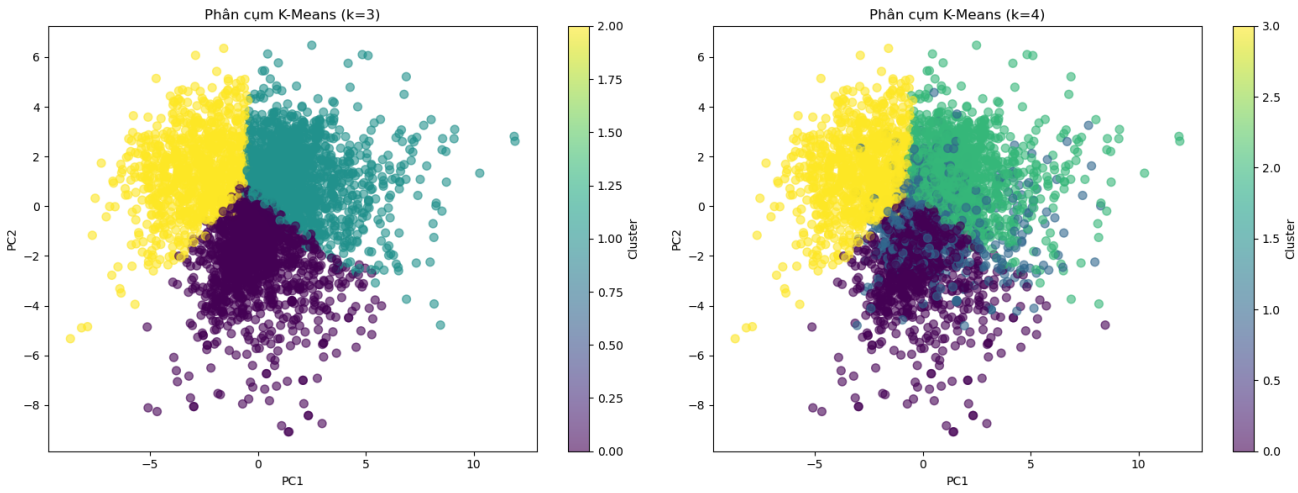

Hình 12: So sánh phân cụm trên không gian 2D. Bên trái là K=3, bên phải là K=4.

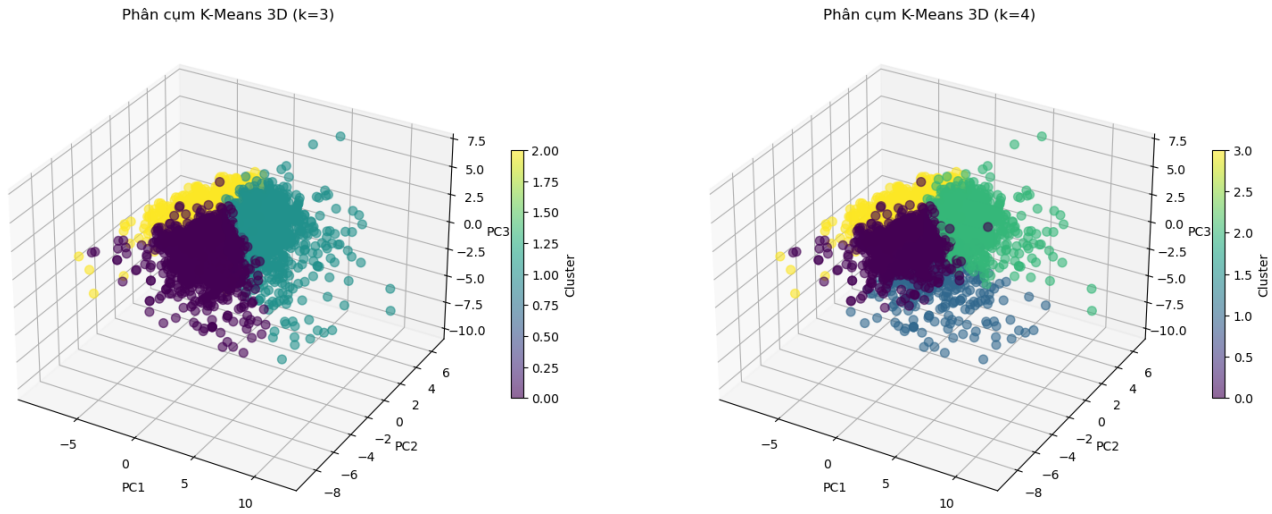

Hình 13: So sánh phân cụm trên không gian 3D. K=4 cho thấy sự tách biệt rõ ràng hơn ở vùng trung tâm.

Quan sát hình ảnh trực quan, ta thấy sự khác biệt rõ rệt:

Với K=3, dữ liệu được chia thành 3 vùng lớn:

- Vùng màu vàng bên trái: Tách biệt khá rõ, đại diện cho nhóm khách hàng có hành vi mua sắm đặc thù (thường là nhóm chi tiêu thấp hoặc ít hoạt động).
- Vùng màu xanh ngọc ở trên: Tập trung mật độ cao.
- Vùng màu tím ở dưới: Phân bố trải rộng hơn.

Với K=4, cấu trúc dữ liệu trở nên chi tiết hơn:

- Vùng màu vàng bên trái vẫn giữ nguyên sự ổn định, cho thấy đây là một nhóm khách hàng rất đặc trưng và tách biệt.

- Sự thay đổi lớn nhất nằm ở khối dữ liệu bên phải. Vùng giao thoa giữa nhóm xanh ngọc và tím ở K=3 nay đã được tách ra thành một cụm mới (màu xanh dương nhạt trong hình 3D hoặc màu xanh đậm hơn trong hình 2D).
- Điều này cho thấy K=4 giúp phát hiện ra một nhóm khách hàng trung gian hoặc nhóm chuyển đổi mà K=3 đã gộp chung vào các nhóm lớn. Về mặt kinh doanh, việc tách nhóm này ra giúp ta có chiến lược tiếp cận tinh tế hơn, tránh đánh đồng những khách hàng có hành vi "lưng chừng" với những khách hàng điển hình của nhóm lớn.

Dưới đây là mã nguồn để thực hiện phân cụm và vẽ các biểu đồ trên:

Thực hiện K-Means và trực quan hóa

```
# Áp dụng K-Means với k=3 và k=4
cluster_results = analyzer.apply_kmeans([3, 4])

# Trực quan hóa clusters trong không gian PCA 2D
analyzer.plot_clusters_pca([3, 4])

# Trực quan hóa clusters trong không gian PCA 3D
analyzer.plot_clusters_pca_3d([3, 4])
```

IV.5. Phân tích chuyên sâu biểu đồ Radar

Biểu đồ Radar (hay Spider Chart) là công cụ đắc lực để trực quan hóa hồ sơ (profile) của từng nhóm khách hàng trên đa chiều dữ liệu. Thay vì chỉ nhìn vào các con số thống kê khô khan, biểu đồ Radar giúp ta nhận diện ngay lập tức hình dáng hành vi của từng cụm.

IV.5.1. So sánh cấu trúc phân cụm: K=3 và K=4

Trong quá trình thử nghiệm, ta nhận thấy sự chuyển dịch thú vị khi tăng số lượng cụm từ $K = 3$ lên $K = 4$. Việc này không chỉ đơn thuần là chia nhỏ dữ liệu, mà còn giúp tách biệt các nhóm hành vi bị gộp chung hay còn gọi là under-segmented.

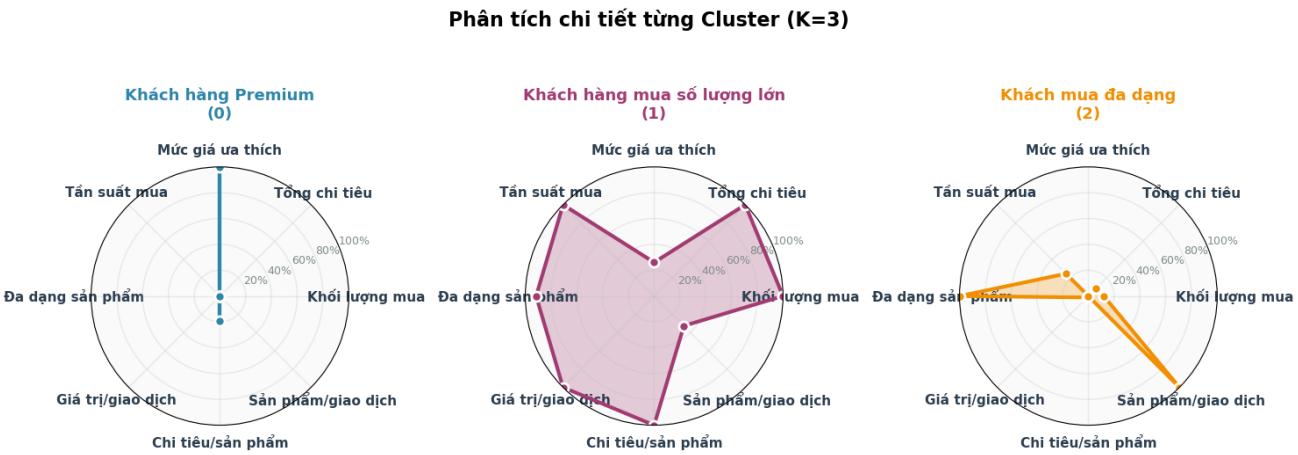

(a) Kết quả phân cụm với K=3: Các nhóm còn khá tổng quát.

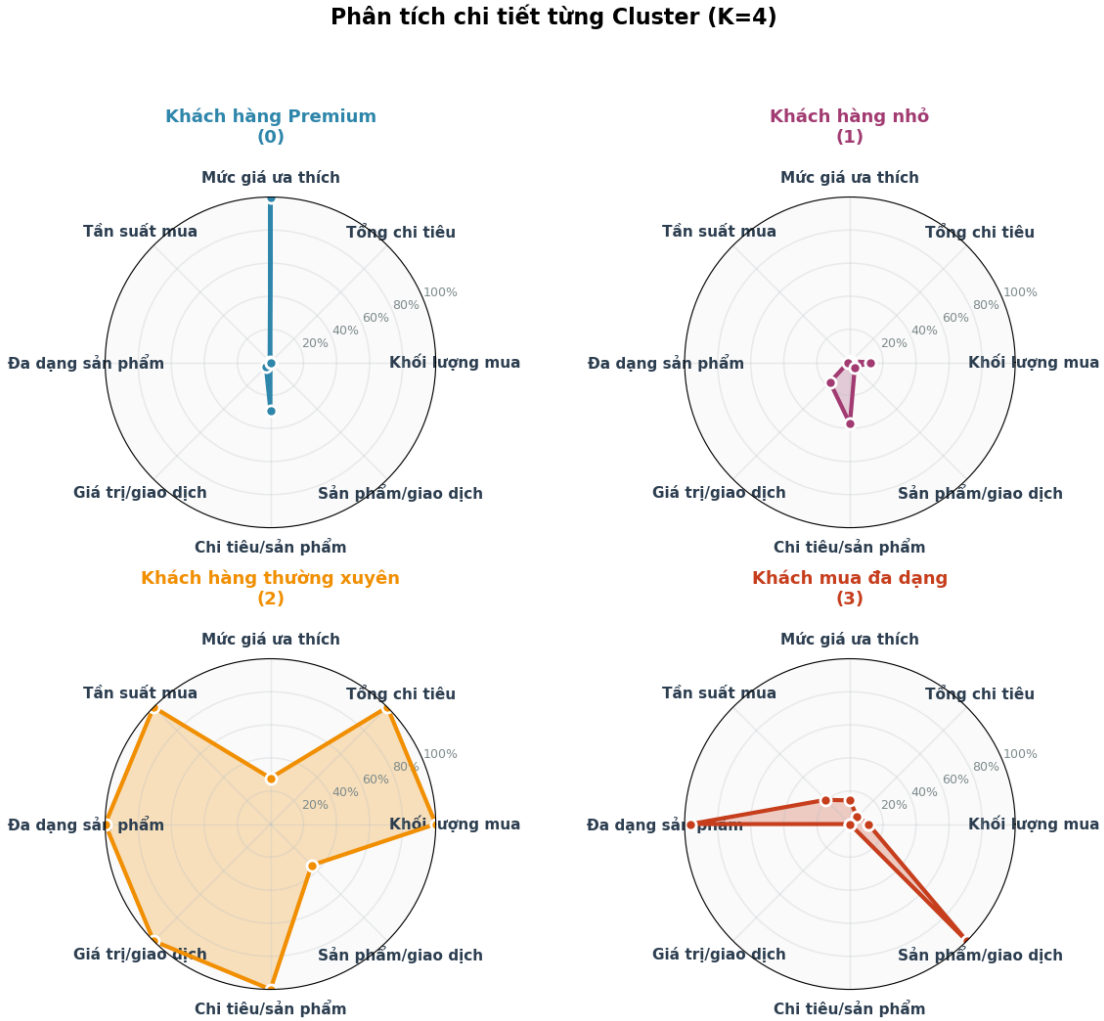

(b) Kết quả phân cụm với K=4: Nhóm "Khách hàng nhỏ" và "Thường xuyên" tách biệt rõ hơn.

Hình 14: So sánh hồ sơ khách hàng trên biểu đồ Radar. Việc tăng số cụm từ K=3 lên K=4 giúp nhận diện chi tiết hơn các hành vi mua sắm của người tiêu dùng.

Dựa trên kết quả phân tích định lượng, ta có các quan sát quan trọng sau:

1. **Sự ổn định của nhóm premium (Cluster 0):** Dù ở $K = 3$ hay $K = 4$, nhóm này vẫn giữ nguyên đặc tính với mức giá trung bình (UnitPrice) cao vượt trội (6.35 so với mức trung bình $2.6 - 3.5$). Đây là nhóm khách hàng High-margin (biên lợi nhuận cao), ít nhạy cảm về giá nhưng số lượng mua chỉ ở mức trung bình.
2. **Sự phân tách của nhóm mua số lượng lớn:** Tại $K = 3$, Cluster 1 chiếm tới 38.6% dữ liệu, gộp chung cả khách hàng doanh nghiệp lớn và các khách hàng mua sỉ nhỏ lẻ. Khi chuyển sang $K = 4$, nhóm này được tách thành hai phân khúc rõ ràng hơn:
   - **Cluster 1 (Mới - 16.5%):** Nhóm khách hàng nhỏ, mua ít hơn, có thể là các hộ kinh doanh bán lẻ.
   - **Cluster 2 (Mới - 33.6%):** Nhóm khách hàng mua sỉ thực thụ với tần suất và số lượng cực lớn.
3. **Nhóm khám phá (Cluster 3):** Đặc trưng bởi sự cân bằng trong đa dạng danh mục sản phẩm nhưng giá trị đơn hàng thấp. Đây là nhóm khách hàng đang trong giai đoạn tìm hiểu sản phẩm.

Việc lựa chọn $K = 4$ mang lại tính Actionability (khả năng hành động) cao hơn cho doanh nghiệp, cho phép thiết kế các chiến lược khuyến mãi riêng biệt cho nhóm số lượng lớn lớn và nhóm hộ kinh doanh nhỏ, thay vì áp dụng chung một chính sách bán sỉ chung chung.

IV.6. Đánh giá với thuật toán SHAP

SHAP (SHapley Additive exPlanations) là phương pháp giúp giải thích kết quả phân cụm bằng cách đo lường ảnh hưởng của từng đặc trưng. Mặc dù biểu đồ radar cho thấy đặc điểm trung bình, nó không giải thích được lý do cụ thể một khách hàng thuộc về nhóm này thay vì nhóm khác. SHAP giải quyết vấn đề này bằng cách định lượng tầm quan trọng của đặc trưng và so sánh các nhóm với nhau.

Vì k-means là thuật toán học không giám sát, ta cần huấn luyện một mô hình phân loại như "random forest" để dự đoán kết quả phân cụm, sau đó áp dụng SHAP để giải thích mô hình này. Kết quả cho thấy sự bổ sung giữa hai phương pháp: radar chart giúp hình dung tổng quát các thuộc tính mà ta quan tâm của một nhóm khách hàng, còn SHAP đi sâu vào chi tiết sự khác nhau của từng nhóm đó.

Áp dụng SHAP giải thích KMeans

```
# Huấn luyện mô hình thế cho k=3
surrogate_results_3 = analyzer.train_surrogate_model(3)

# Tính SHAP values cho k=3
shap_results_3 = analyzer.calculate_shap_values(3)

# Vẽ biểu đồ độ quan trọng của từng cluster với k=3
analyzer.plot_shap_summary(3)
```

Dựa trên biểu đồ Radar và biểu đồ SHAP Summary cho 3 cụm khách hàng, chúng ta có thể rút ra các so sánh chi tiết dưới đây.

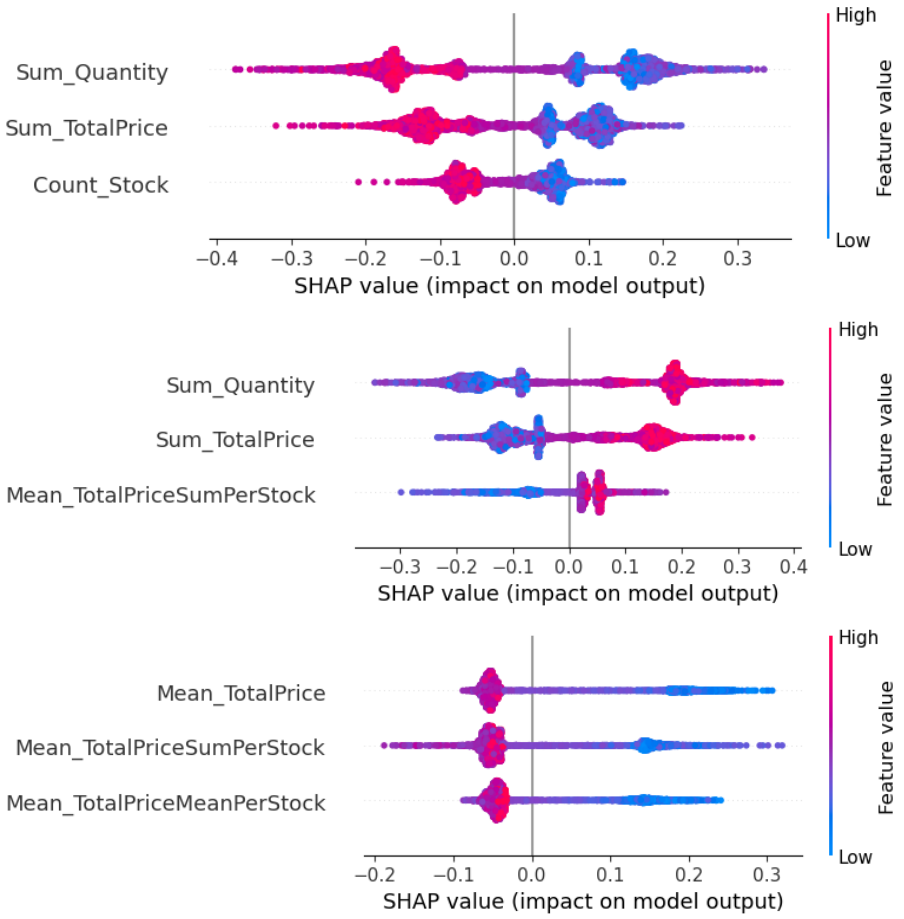

Hình 15: Top 3 thuộc tính quan trọng nhất theo thuật toán SHAP cho từng cụm.

Cluster 0 (Khách hàng Premium)

- **Radar Chart:** Thể hiện rõ sự vượt trội ở trục "Mức giá ưa thích" (Mean_UnitPrice) trong khi các trục về khối lượng và tần suất thấp.
- **SHAP:** Các biến "Khối lượng mua" (Sum_Quantity), "Tổng chi tiêu" (Sum_TotalPrice) và "Đa dạng sản phẩm" (Count_Stock) đóng vai trò quan trọng, khác biệt so với trục Mean_UnitPrice được chọn ở Radar Chart.

Cluster 1 (Khách hàng mua số lượng lớn)

- **Radar Chart:** Bao phủ diện tích lớn nhất về phía các trục "Tổng chi tiêu" (Sum_TotalPrice), "Khối lượng mua" (Sum_Quantity) và "Tần suất mua" (Count_Invoice).

- **SHAP:** Các biến Sum_Quantity, Sum_TotalPrice đóng vai trò quan trọng nhất. Giá trị cao của các biến này đẩy mô hình phân loại khách hàng vào nhóm 1. Ta thấy được biến hai biến này mang tính hiệu ngược với nhóm khách hàng premium. Nếu như hai biến nói trên cao, thì thuật toán KMeans sẽ phân loại vào nhóm khách mua số lượng lớn và ngược lại.

Cluster 2 (Khách mua đa dạng)

- **Radar Chart:** Mở rộng về phía trục "Đa dạng sản phẩm" (Count_Stock) và "Sản phẩm trên giao dịch" (Mean_StockCountPerInvoice)
- **SHAP:** Biến Mean_TotalPrice và Mean_TotalPriceSumPerStock là hai biến mà thuật toán SHAP thấy quan trọng nhưng không được thêm vào trong Radar Chart. Ta thấy biến cả ba biến được SHAP liệt kê ra đều nằm bên trái của plot.

Việc kết hợp Radar Chart và SHAP Beeswarm Chart mang lại cái nhìn đa chiều:

- **Radar Chart** giúp hình dung nhanh "hình dáng" đặc trưng của từng nhóm dựa trên các chỉ số KPI chính.
- **SHAP** đi sâu vào giải thích "tại sao" và phát hiện các biến ẩn quan trọng mà Radar Chart có thể bỏ sót (như Mean_TotalPriceMeanPerStock).

Sự kết hợp này giúp doanh nghiệp không chỉ nhận diện được khách hàng mà còn hiểu sâu động lực hành vi của họ để có chiến lược tác động phù hợp.

Thử thách: Tự suy luận với K=4

Chúng ta đã phân tích kỹ lưỡng cho trường hợp K=3. Bây giờ, hãy nhìn vào biểu đồ SHAP Summary cho K=4 ở trên và tự mình rút ra các nhận xét.
Gợi ý suy luận:

1. **Sự tách nhóm:** Nhóm "Mua số lượng lớn" (Cluster 1 cũ) dường như đã được tách thành 2 nhóm mới (Cluster 1 và Cluster 2 trong K=4). Dựa vào SHAP, yếu tố nào (biến nào) quyết định sự tách biệt này?
2. **Cluster 0 (Premium):** Các đặc trưng quan trọng của nhóm này có thay đổi gì so với khi K=3 không?
3. **Cluster 3 (Đa dạng):** Vai trò của biến `Count_Stock` đối với nhóm này như thế nào trên biểu đồ SHAP?

Việc tự mình đọc và giải thích biểu đồ SHAP sẽ giúp bạn hiểu sâu hơn về cách mô hình "nhìn" dữ liệu và đưa ra quyết định phân cụm.

IV.7. Quy trình định danh khách hàng với ChatGPT

Việc gán nhãn cho các cụm số vô tri (Cluster 0, 1, 2...) thành các chân dung khách hàng có hồn là bước quan trọng để chuyển đổi từ kỹ thuật sang giá trị trong kinh doanh. Đây là lúc chúng ta kết hợp dữ liệu định lượng với "trực giác" của các mô hình ngôn ngữ lớn (LLMs). Thay vì đưa toàn bộ dữ liệu thô, chúng ta cần một bảng tóm tắt các chỉ số trung bình để ChatGPT có thể hiểu dễ dàng hơn bức tranh tổng quát của đề bài. Ta sử dụng code sau để tạo ra bảng markdown chứa các dòng dữ liệu đại diện cho toàn bộ một cluster:

Tạo bảng thống kê trung bình

```
cluster_results = analyzer.apply_kmeans([3, 4])

display(cluster_means_3.round(2).style.background_gradient(cmap='viridis', axis=0))
display(cluster_means_4.round(2).style.background_gradient(cmap='viridis', axis=0))
```

Sau khi có được các dòng dữ liệu tiêu biểu nói trên, ta sẽ sử dụng một prompt đơn giản để có thể yêu cầu mô hình LLMs cho ta tên của từng cụm. Một prompt hiệu quả không chỉ đưa dữ liệu, mà phải cung cấp luật và ngữ cảnh cần thiết cho mô hình. Dưới đây là mẫu Prompt chi tiết bạn có thể copy trực tiếp vào ChatGPT/Claude:

Prompt phân tích hồ sơ khách hàng

Role: Bạn là giám đốc marketing và chuyên gia phân tích dữ liệu của một chuỗi bán lẻ online tại UK.
Context: Tôi vừa thực hiện thuật toán K-Means Clustering và chia khách hàng thành 4 nhóm. Dưới đây là định nghĩa các biến: ...
Data: [DÁN BẢNG KẾT QUẢ TỪ BƯỚC TRÊN VÀO ĐÂY]
Task: Hãy phân tích từng cụm (Cluster) và thực hiện các yêu cầu sau:

1. **Đặt tên (Naming):** Đặt 1 tên tiếng Anh chuyên nghiệp và 1 tên tiếng Việt dễ nhớ (Ví dụ: "Big Spenders", "Lost Customers").
2. **Mô tả (Persona):** Mô tả ngắn gọn hành vi của nhóm này trong 1 câu.
3. **Chiến lược (Action):** Đề xuất 1 hành động marketing cụ thể (Ví dụ: gửi email, upsell, kích cầu...).

Hãy trình bày kết quả dưới dạng bảng Markdown.

AI sẽ cung cấp một góc nhìn tham khảo rất tốt. Tuy nhiên, chúng ta cần đối chiếu lại với biểu đồ Radar Chart nói trên để đảm bảo tên gọi phản ánh đúng thực tế của mẫu dữ liệu, tránh trường hợp ảo giác của mô hình.

Ví dụ kết quả sau khi tinh chỉnh:

- **Cluster 0 - The Whales:** Chi tiêu cực lớn, mua thường xuyên. → Chiến lược: Chăm sóc VIP 1-1, mời tham gia sự kiện lớn.

- **Cluster 2 - Hibernating:** Đã từng mua nhưng lâu không quay lại. → Chiến lược: Gửi email "We miss you" kèm mã giảm giá. Tạo ra chương trình tri ân khách hàng.
- **Cluster 3 - Small Sales:** Nhóm khách hàng chi tiêu nhỏ nhưng mua nhiều loại mặt hàng. → Chiến lược: Giới thiệu nhiều mẫu mặt hàng cho nhóm này, tạo ra catalog để họ có thể dễ theo dõi những mặt hàng mới tốt hơn.

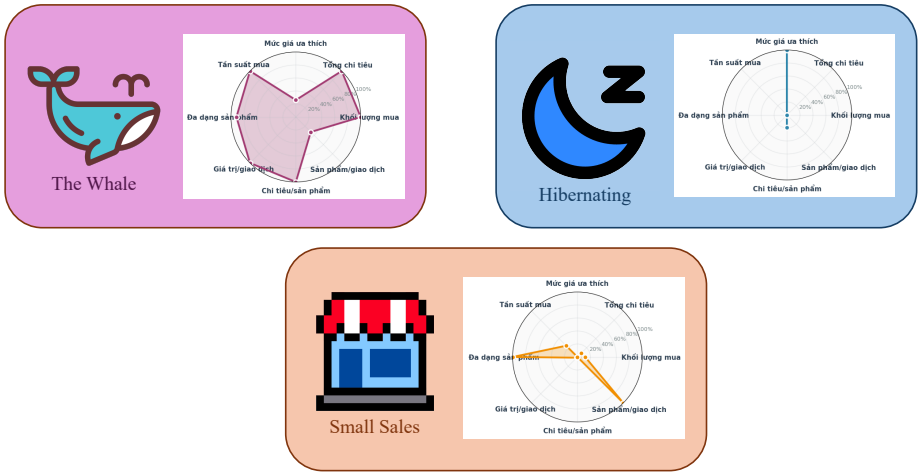

Hình 16: Portfolio của khách hàng sau các bước phân tích.

V. Các hướng cải tiến

Mặc dù mô hình K-Means hiện tại đã mang lại những kết quả khả quan trong việc định hình chân dung khách hàng, phương pháp này vẫn tồn tại một số hạn chế như giả định các cụm có dạng hình cầu lồi và kích thước tương đồng. Để nâng cao chất lượng phân khúc và khai thác sâu hơn dữ liệu, ta có thể cân nhắc các hướng tiếp cận nâng cao sau:

1. **Giảm chiều dữ liệu phi tuyến tính:** PCA là thuật toán tuyến tính, có thể bỏ sót các cấu trúc dữ liệu phức tạp. Ta có thể thử nghiệm với t-SNE hoặc UMAP. Các thuật toán này bảo toàn cấu trúc cục bộ tốt hơn, giúp việc phân tách các cụm trở nên rõ ràng hơn trong không gian thấp chiều, đặc biệt khi dữ liệu có tính phi tuyến cao.

Minh họa sử dụng UMAP

```python
import umap

# Khởi tạo UMAP reducer
reducer = umap.UMAP(
    n_neighbors=15,
    min_dist=0.1,
    metric='euclidean'
)

# Giảm chiều dữ liệu xuống 2D
embedding = reducer.fit_transform(df_scaled)
```

2. **Phân cụm dựa trên mật độ (Density-based Clustering):** K-Means buộc phải gán mọi điểm dữ liệu vào một cụm, ngay cả khi đó là nhiễu. DBSCAN hoặc HDBSCAN là những lựa chọn thay thế tốt, cho phép phát hiện các cụm có hình dạng bất kỳ và tự động loại bỏ nhiễu, giúp mô hình bền vững hơn trước các dữ liệu bất thường.

3. **Tích hợp thông tin sản phẩm:** Hiện tại, mô hình chủ yếu dựa trên hành vi giao dịch (RFM). Một hướng đi tiềm năng là sử dụng kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) như TF-IDF hoặc Word2Vec để phân tích mô tả sản phẩm trong lịch sử mua hàng. Điều này giúp gom nhóm khách hàng dựa trên "gu" thẩm mỹ hoặc nhu cầu sử dụng thực tế (ví dụ: nhóm thích đồ trang trí cổ điển so với nhóm thích đồ gia dụng hiện đại), thay vì chỉ dựa trên số tiền họ chi trả.

VI. Câu hỏi trắc nghiệm

1. Đâu là mục tiêu cốt lõi của việc "Phân khúc khách hàng" so với tiếp thị đại trà?

   A. Giảm thiểu tối đa chi phí vận hành hệ thống IT của doanh nghiệp.

   B. Gửi cùng một email quảng cáo cho tất cả mọi người để tiết kiệm thời gian.

   C. Tối ưu hóa Marketing, giữ chân khách hàng và phân bổ nguồn lực hiệu quả.

   D. Loại bỏ hoàn toàn sự cần thiết của các nhân viên chăm sóc khách hàng.

2. Tại sao thuật toán K-Means Clustering được đánh giá cao hơn phương pháp phân loại thủ công trong bối cảnh Big Data?

   A. Vì nó phụ thuộc nhiều vào cảm tính của người phân loại để đưa ra quyết định nhân văn hơn.

   B. Vì nó có khả năng xử lý tốt dữ liệu đa chiều, tính khách quan cao và tốc độ xử lý nhanh.

   C. Vì nó chỉ hoạt động tốt trên các tập dữ liệu nhỏ dưới 100 dòng.

   D. Vì nó không đòi hỏi dữ liệu đầu vào phải được làm sạch hay chuẩn hóa.

3. Trong bước làm sạch dữ liệu của dự án này, các hóa đơn bắt đầu bằng ký tự nào sẽ bị loại bỏ?

   A. Ký tự 'A' (Approved).

   B. Ký tự 'R' (Return).

   C. Ký tự 'C' (Cancelled).

   D. Ký tự 'F' (Failed).

4. Tại sao mô hình RFM truyền thống (Recency, Frequency, Monetary) lại được cho là có hạn chế và cần được mở rộng thêm các features khác?

   A. Vì RFM quá phức tạp để tính toán trên máy tính cá nhân thông thường.

   B. Vì RFM thiếu chiều sâu về độ đa dạng sản phẩm, hành vi trong từng giao dịch và độ nhạy với giá.

   C. Vì RFM chỉ áp dụng được cho các cửa hàng vật lý, không dùng được cho online.

   D. Vì các chỉ số RFM không thể trực quan hóa được trên biểu đồ.

5. Mục đích chính của việc áp dụng phép biến đổi **Box-Cox** lên dữ liệu trước khi đưa vào mô hình K-Means là gì?

   A. Để loại bỏ các giá trị thiếu (missing values) trong dữ liệu.

   B. Để chuyển đổi dữ liệu dạng chữ (string) sang dạng số (numeric).

   C. Để xử lý vấn đề dữ liệu bị lệch phải (right-skewness) và đưa về dạng gần phân phối chuẩn.

   D. Để tăng số lượng dòng dữ liệu lên gấp đôi nhằm huấn luyện tốt hơn.

6. Tại sao trước khi áp dụng hàm `boxcox`, ta cần thực hiện phép tính $x + 1$ trên các giá trị dữ liệu?

   A. Để đảm bảo dữ liệu luôn dương tuyệt đối, do toán học của Box-Cox yêu cầu đầu vào dương.

   B. Để làm tròn số liệu doanh thu cho dễ nhìn hơn.

   C. Để tạo ra sự nhiễu ngẫu nhiên giúp mô hình không bị overfitting.

   D. Để chuyển đổi đơn vị tiền tệ từ Bảng Anh sang USD.

7. Hai phương pháp nào được sử dụng trong bài để xác định số cụm K tối ưu?

   A. Random Forest và Decision Tree.

   B. Elbow Method và Silhouette Score.

   C. Gradient Descent và Backpropagation.

   D. Mean Squared Error và R-squared.

8. Khi so sánh kết quả phân cụm giữa $K = 3$ và $K = 4$, sự khác biệt lớn nhất mang lại tính hành động cao hơn là gì?

   A. Nhóm khách hàng VIP (Whales) bị biến mất hoàn toàn.

   B. Nhóm mua số lượng lớn (vốn gộp chung ở K=3) được tách thành hai nhóm: hộ kinh doanh nhỏ và nhà bán sỉ thực thụ.

   C. Tất cả các nhóm đều bị trộn lẫn vào nhau khiến việc phân biệt trở nên khó khăn hơn.

   D. Nhóm khách hàng vãng lai chiếm 90% dữ liệu.

9. Biểu đồ nào được sử dụng để trực quan hóa "hồ sơ" (profile) hành vi của từng nhóm khách hàng trên đa chiều dữ liệu?

   A. Biểu đồ Pie Chart.

   B. Biểu đồ Radar (Spider Chart).

   C. Biểu đồ Line Chart theo thời gian.

   D. Biểu đồ Gantt Chart.

10. Để khắc phục hạn chế của K-Means (giả định cụm hình cầu) và xử lý dữ liệu phi tuyến tính tốt hơn, bài viết đề xuất hướng cải tiến nào?

    A. Quay lại sử dụng phương pháp phân loại thủ công bằng Excel.

    B. Sử dụng thuật toán giảm chiều dữ liệu t-SNE/UMAP và phân cụm dựa trên mật độ (DBSCAN).

    C. Chỉ sử dụng duy nhất chỉ số Monetary để phân nhóm.

    D. Tăng số lượng cụm K lên 100 để chi tiết hóa tối đa.

VII. Tài liệu tham khảo

Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.

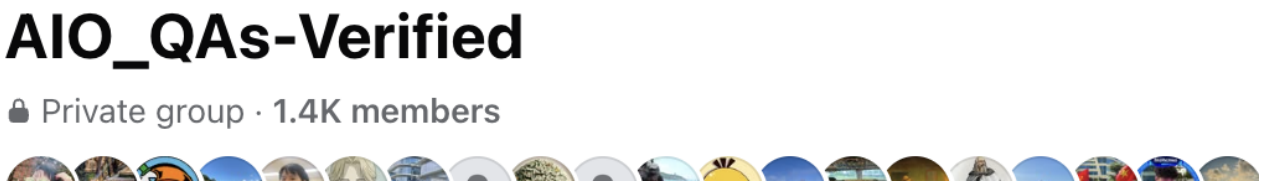

Hình 17: Hình ảnh group facebook AIO Q&A.

AI VIET NAM COURSE 2026

Giới thiệu về thuật toán SHAP

> Nothing in life is to be feared, it is only to be understood.
> Now is the time to understand more, so that we may fear less.
>
> — Marie Curie

I. Giới thiệu

Con người chúng ta luôn sợ hãy những điều bản thân không biết. Trong lĩnh vực học máy, nỗi sợ về những điều không thể lý giải cũng hiện hữu tương tự. Các mô hình học máy, đặc biệt là các mô hình học sâu, thường được ví như những "black boxes" (tạm dịch: hộp đen). Chúng có thể đưa ra những dự đoán với độ chính xác đáng kinh ngạc, nhưng chúng ta lại không thể hiểu rõ cơ sở hay logic đằng sau những quyết định đó. Tại sao một mô hình lại từ chối đơn xin vay vốn của một khách hàng? Dựa vào những đặc điểm nào mà một hệ thống chẩn đoán y tế lại kết luận một khối u là ác tính?

Sự thiếu minh bạch này tạo ra những rủi ro lớn, từ việc gây ra sự thiếu tin tưởng, những quyết định sai lệch, bias (tạm dịch: thiên vị) cho đến các vấn đề pháp lý và đạo đức. Ở quy mô nhỏ hơn, việc không thể hiểu một mô hình học máy cũng dẫn đến việc chúng ta không thể tối ưu mô hình một cách tốt nhất mà chỉ có thể thử và sai. Đây chính là lúc eXplainable AI - XAI (tạm dịch: trí tuệ nhân tạo có thể giải thích được) vào cuộc.

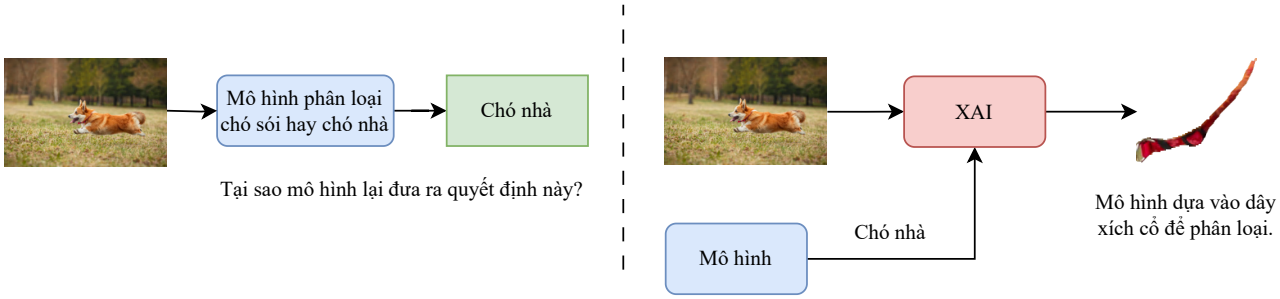

Hình 1: Làm sao chúng ta biết mô hình phân loại của ta hợp với logic? Ở đây ta thấy rằng chó nhà được phân biệt với chó sói qua dây xích cổ, mô hình đáng tin ở trường hợp này.

XAI là một tập hợp các kỹ thuật và phương pháp giúp con người có thể hiểu và tin tưởng vào kết quả do các mô hình học máy tạo ra. Thay vì chỉ nhận được câu trả lời cuối cùng, XAI giúp

chúng ta "nhìn" vào bên trong hộp đen, lý giải tại sao mô hình lại đưa ra quyết định như vậy. Điều này không chỉ giúp các nhà nghiên cứu và người xây dựng các mô hình AI tối ưu tốt hơn, mà còn mang lại sự minh bạch và trách nhiệm, giúp con người tự tin hơn khi ứng dụng AI vào các lĩnh vực quan trọng như y tế, tài chính và pháp luật. Nói một cách đơn giản, XAI biến nỗi sợ về những điều không chắc chắn thành sự tin tưởng dựa trên sự thấu hiểu.

Để trả lời câu hỏi "Tại sao mô hình lại đưa ra dự đoán như vậy?", có rất nhiều phương pháp XAI đã được phát triển. Trong số đó, SHAP (SHapley Additive exPlanations) nổi lên như một trong những cách tiếp cận mạnh mẽ và đáng tin cậy nhất. Dựa trên khái niệm Game Theory (tạm dịch: lý thuyết trò chơi) và Shapley Values (tạm dịch: giá trị Shapley), SHAP cung cấp một phương pháp nhất quán để tính toán mức độ đóng góp của từng đặc trưng vào kết quả dự đoán của mô hình đối với một điểm dữ liệu cụ thể.

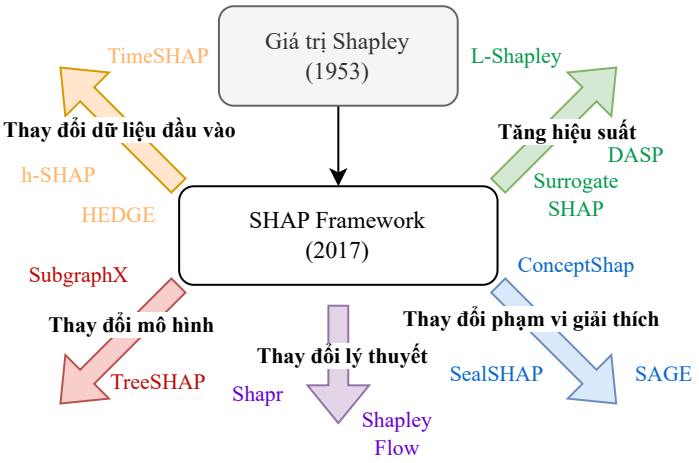

Hình 2: SHAP là một trong những framework XAI được phát triển dựa trên nhiều nhất kế bên LIME.

Không giống như một số phương pháp chỉ cho biết đặc trưng nào là quan trọng một cách tổng thể, SHAP có khả năng giải thích chi tiết cho từng dự đoán riêng lẻ. Nó cho chúng ta biết đặc trưng nào đã "đẩy" dự đoán của mô hình tăng lên và đặc trưng nào đã "kéo" dự đoán xuống. Chính nhờ khả năng giải thích ở cấp độ cá thể này mà SHAP trở thành một công cụ vô giá để gỡ lỗi (debug) mô hình, phát hiện thiên vị và xây dựng niềm tin đối với người sử dụng mô hình. Trong viết này, chúng ta sẽ tìm hiểu về cách hoạt động của SHAP và các sử dụng thư viện nêu trên.

Bảng ký hiệu toán học. Để tiện theo dõi, bảng dưới đây tổng hợp một số ký hiệu sử dụng xuyên suốt bài viết này:

Bảng Ký hiệu Toán học

Ký hiệu	Ý nghĩa
N	Tổng số người chơi (trong lý thuyết trò chơi) hoặc tổng số đặc trưng (trong học máy).
S	Một liên minh (coalition), tức là một tập hợp con các đặc trưng.
$\|S\|$	Kích thước của liên minh S, tức số đặc trưng trong liên minh đó.
$v(S)$	Hàm đặc trưng (characteristic function), đại diện cho đầu ra của mô hình khi chỉ sử dụng các đặc trưng trong liên minh S.
$\varphi_i(v)$	Giá trị Shapley của người chơi (hoặc đặc trưng) i.
$f(x)$	Mô hình hộp đen (black-box model) gốc cần được giải thích.
$g(x')$	Mô hình giải thích tuyến tính, dùng để xấp xỉ mô hình $f(x)$ một cách cục bộ.
x'	Vector nhị phân biểu diễn sự "có mặt" (1) hay "vắng mặt" (0) của một đặc trưng.
φ_i	Giá trị SHAP của đặc trưng thứ i, đo lường đóng góp của đặc trưng đó vào dự đoán.
φ_0	Giá trị cơ sở (base value), là dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu nền.
$E[f(x)]$	Giá trị kỳ vọng của đầu ra mô hình, được dùng làm giá trị cơ sở φ_0.
B	Tập dữ liệu nền (background dataset), thường được lấy mẫu từ tập huấn luyện.
Z	Một mẫu dữ liệu "lai" được tạo ra bằng cách kết hợp giá trị từ mẫu gốc và tập nền.
w_C	Trọng số của hạt nhân Shapley (Shapley kernel) gán cho một liên minh C.

Bảng thuật ngữ

Thuật ngữ	Ý nghĩa
Lý thuyết trò chơi	Nền tảng toán học được SHAP sử dụng để phân chia một cách công bằng "đóng góp" của từng đặc trưng vào kết quả dự đoán của mô hình.
Trò chơi hợp tác	Một kịch bản trong đó các "người chơi" (tức các đặc trưng) phải phối hợp với nhau trong các "liên minh" để tạo ra một giá trị chung (tức dự đoán của mô hình).
Giá trị Shapley	Một giá trị duy nhất, đại diện cho đóng góp trung bình của một đặc trưng qua tất cả các liên minh có thể có. Đây là cốt lõi của giá trị SHAP.
Mô hình hộp đen	Các mô hình học máy phức tạp (ví dụ: mạng nơ-ron, gradient boosting) mà cơ chế ra quyết định bên trong rất khó hoặc không thể hiểu được trực tiếp.
Tính diễn dịch	(Interpretability) Khả năng một mô hình vốn đã minh bạch và dễ hiểu (ví dụ: cây quyết định), không cần một công cụ giải thích bên ngoài.
Tính giải thích	(Explainability) Việc sử dụng các kỹ thuật hậu kiểm (post-hoc) như SHAP để tạo ra lời giải thích cho các mô hình hộp đen.
Tính trung thực	(Fidelity) Mức độ mà một lời giải thích phản ánh đúng logic ra quyết định thực sự của mô hình.
Giá trị cơ sở	Dự đoán trung bình của mô hình trên tập dữ liệu nền ($E[f(x)]$). Đây là điểm bắt đầu của mọi mô hình khi dự đoán. Cơ sở ở đây mang nghĩa "tập dữ liệu mô hình được huấn luyện dựa trên".
Đóng góp cận biên	Sự thay đổi trong dự đoán của mô hình khi một đặc trưng được thêm vào một liên minh đã có. Giá trị Shapley là trung bình của tất cả các đóng góp cận biên.

II. Nội dung chính

II.1. Các khái niệm trong XAI

Để bắt đầu hành trình tìm hiểu và sử dụng XAI, chúng ta cần phân biệt rõ ba khái niệm chính của các nghiên cứu XAI nói chung: Interpretability (tạm dịch: tính diễn dịch), Explainability (tạm dịch: tính giải thích) và Fidelity (tạm dịch: tính trung thực). Việc hiểu các thuật ngữ trên có thể giúp ta biết khi nào nên áp dụng phương pháp nào và đưa ra những kết luận tin cậy mà ta cần.

Trước tiên ta sẽ đến với hai cặp thuật ngữ chính thường bị nhầm lẫn trong XAI là tính diễn dịch và tính giải thích. Nhiều người thường dùng hai thuật ngữ này thay thế cho nhau, nhưng chúng lại mô tả hai cách tiếp cận rất khác nhau để hiểu mô hình.

Tính diễn dịch (hay còn gọi là tính thông dịch) là khả năng con người có thể hiểu được cách một mô hình đưa ra quyết định **một cách tự nhiên** mà không cần một công cụ giải thích phụ trợ. Những mô hình có tính diễn dịch cao thường được ví như những **hộp kính** (**glass-box models** hoặc **white-box models**). Chúng ta có thể nhìn thẳng vào cơ chế bên trong và hiểu được mối quan hệ nhân-quả giữa đầu vào và đầu ra. Ví dụ điển hình là mô hình cây quyết định (Decision Tree). Bằng cách đi theo các nhánh của cây, bất kỳ ai cũng có thể hiểu được tại sao một quyết định cụ thể được đưa ra.

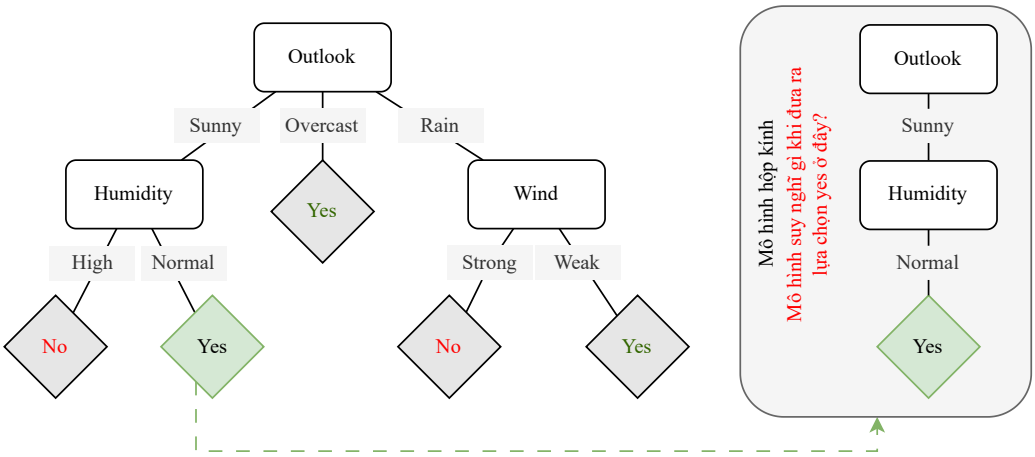

Hình 3: Một mô hình cây quyết định. Ta quan sát thấy quyết định 'Yes' được đưa ra khi Outlook=Sunny và Humidity=Normal.

Mặt khác, **tính giải thích** thường được áp dụng cho các mô hình **hộp đen** (**black-box models**) như mạng nơ-ron học sâu hoặc các mô hình ensemble phức tạp. Bản thân các mô hình này quá phức tạp để con người có thể diễn dịch trực tiếp. Do đó, chúng ta cần các phương pháp **post-hoc** (tạm dịch: hậu kiểm) để tạo ra một lời giải thích gần đúng về hành vi của mô hình. Tính giải thích là việc xây dựng một người phiên dịch đứng giữa mô hình hộp đen và con người. SHAP và LIME là những ví dụ kinh điển của kỹ thuật này.

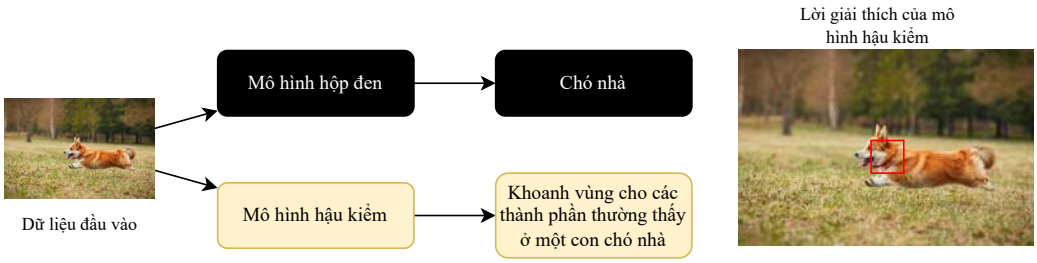

Hình 4: Tính giải thích hoạt động như một lớp diễn giải bên ngoài mô hình hộp đen, cung cấp lý do cho một quyết định cụ thể. Các phương pháp/mô hình hậu kiểm thường sẽ cho lời giải thích từ dữ liệu đầu vào thay vì sử dụng thông tin nội tại của mô hình.

Bảng dưới đây tóm tắt sự khác biệt cốt lõi giữa hai khái niệm được nhắc tới ở trên.

Tính diễn dịch (Interpretability)	**Tính giải thích (Explainability)**
Mô hình vốn minh bạch và dễ hiểu (hộp kính).	Áp dụng cho các mô hình phức tạp (hộp đen).
Hiểu được toàn bộ logic của mô hình.	Chỉ giải thích được hành vi cho một hoặc một nhóm dự đoán cụ thể.
Là một thuộc tính nội tại của mô hình.	Là một kỹ thuật hậu kiểm, áp dụng sau khi mô hình đã được huấn luyện.
Ví dụ: Linear Regression, Decision Trees, Logistic Regression.	Ví dụ: SHAP, LIME, LRP áp dụng cho Neural Networks, Gradient Boosting.

Bảng 1: So sánh giữa tính diễn dịch và tính giải thích.

Thuộc tính còn lại là khái niệm cực kỳ quan trọng để đánh giá chất lượng của một phương pháp giải thích. **Tính trung thực** (còn gọi là fidelity) đo lường mức độ mà một lời giải thích **phản ánh đúng** cơ chế ra quyết định thực sự của mô hình.

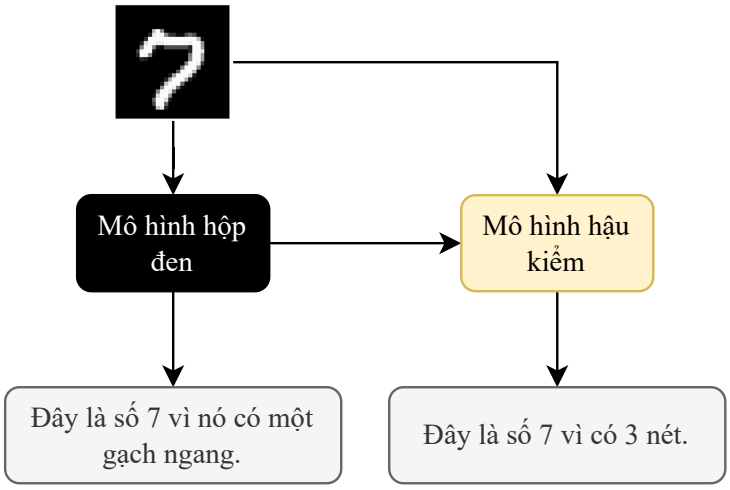

Hình 5: Minh họa tính trung thực. Lời giải thích tuy dễ hiểu (và hợp khoa học hơn), nhưng lại không đúng những gì mô hình đang suy nghĩ.

Hãy tưởng tượng một lời giải thích rất đơn giản và dễ hiểu, nhưng nó lại hoàn toàn sai lệch so với logic mà mô hình hộp đen đang sử dụng. Lời giải thích đó không những vô dụng mà còn nguy hiểm cho chúng ta vì nó tạo ra một niềm tin sai lầm đối với mô hình. Một phương pháp giải thích có độ trung thực cao sẽ tạo ra những lý giải gần nhất với sự thật về cách mô hình hoạt động. Ví dụ, nếu mô hình phân loại chó sói và husky dựa vào trong bức ảnh đó có tuyết không, một lời giải thích trung thực phải chỉ ra được "tuyết" là yếu tố quyết định, thay vì các đặc điểm hình thái của con vật.

Việc cân bằng giữa sự đơn giản của lời giải thích và độ trung thực của nó là một trong những thách thức lớn nhất trong lĩnh vực XAI.

II.2. Giới thiệu thuật toán SHAP

Sau khi đã nắm vững các khái niệm nền tảng, một câu hỏi tự nhiên được đặt ra: "Làm thế nào để chúng ta tìm được một phương pháp vừa có **tính giải thích** mạnh mẽ cho các mô hình hộp đen, lại vừa đảm bảo được **tính trung thực** ở mức cao nhất?"

Trong vô số các kỹ thuật XAI đã được phát triển, phương pháp **SHAP (SHapley Additive exPlanations)** là một trong những phương pháp được sử dụng nhiều nhất. SHAP không chỉ là một thuật toán; nó là một framework hợp nhất dựa trên khái niệm **lý thuyết trò chơi** và **giá trị Shapley**. Chính nhờ nền tảng này mà SHAP có thể cung cấp những lời giải thích thỏa mãn các thuộc tính công bằng và nhất quán, đặc biệt là **tính chính xác cục bộ (local accuracy)**, đảm bảo rằng tổng đóng góp của các đặc trưng sẽ bằng đúng chênh lệch giữa dự đoán và giá trị cơ sở (sẽ giải thích ở sau). Điều này trực tiếp giải quyết yêu cầu về **tính trung thực** nghĩa là bảo đảm rằng lời giải thích chúng ta nhận được phản ánh đúng những gì mô hình đang "suy nghĩ".

II.2.1. Nền tảng của lý thuyết trò chơi

Để hiểu được cốt lõi của SHAP, chúng ta hãy bắt đầu với một bối cảnh giả định về startup công nghệ như sau. Giả sử startup này có 3 thành viên chủ chốt: An, Bình, và Châu. Lợi nhuận cuối cùng của công ty không chỉ là tổng lợi nhuận mỗi người tự làm ra, mà còn phụ thuộc vào sự phối hợp của họ. Đây chính là bản chất của một **trò chơi hợp tác**.

Trong lý thuyết trò chơi, chúng ta định nghĩa các khái niệm sau:

- **Người chơi (Players)**: Các thành viên tham gia. Trong ví dụ này là {An, Bình, Châu}.
- **Liên minh (Coalition)**, ký hiệu là S: Một tập hợp con bất kỳ của những người chơi. Ví dụ, liên minh chỉ có An và Bình là $S = \{\text{An, Bình}\}$.
- **Hàm đặc trưng (Characteristic Function)**, ký hiệu là $v(S)$: Giá trị (lợi nhuận, kết quả) mà một liên minh S có thể tạo ra. Ví dụ, $v(\{\text{An, Bình}\})$ là lợi nhuận mà An và Bình tạo ra khi làm việc cùng nhau.

Vấn đề cốt lõi được đặt ra là: "Làm thế nào để phân chia tổng lợi nhuận $v(\{\text{An, Bình, Châu}\})$ một cách **công bằng** cho từng thành viên?" Việc chia đều là không hợp lý, vì chắc chắn mỗi người có đóng góp khác nhau. Đây chính là bài toán mà giá trị Shapley giải quyết.

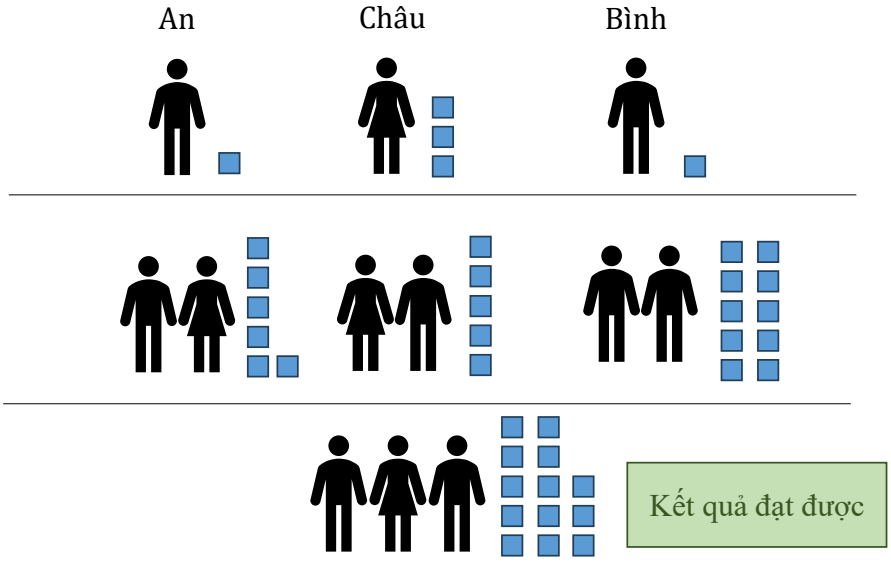

Hình 6: Sự hợp tác giữa các thành viên tạo ra giá trị tổng thể. Đôi khi, sự kết hợp (liên minh) tạo ra giá trị lớn hơn tổng các phần riêng lẻ (hiệu ứng cộng hưởng - *synergy*).

II.2.2. Marginal contribution (tạm dịch: đóng góp cận biên)

Một cách tư duy trực quan khác để hiểu về sự đóng góp là hãy tưởng tượng các thành viên không tham gia vào một "liên minh" có sẵn, mà họ lần lượt xuất hiện để tạo nên một đội hoàn chỉnh. Người đến đầu tiên sẽ đóng góp toàn bộ giá trị cá nhân của họ. Người đến thứ hai sẽ đóng góp phần giá trị gia tăng mà họ tạo ra *dựa trên* sự có mặt của người đầu tiên. Rõ ràng, giá trị đóng góp của cùng một người sẽ rất khác nhau nếu họ là người tiên phong so với khi họ là mảnh ghép cuối cùng. Khái niệm này, được gọi là **đóng góp cận biên**, đo lường chính xác sự gia tăng giá trị này tại một thời điểm cụ thể.

Ví dụ, để tính đóng góp của Châu cho liên minh {An, Bình}, ta tính:

$$\Delta v = v(\{\text{An, Bình, Châu}\}) - v(\{\text{An, Bình}\})$$

Câu hỏi đặt ra cho chúng ta là: Ta có thể nói người màu xám chỉ đóng góp 3 đơn vị trong mọi trường hợp không? có câu trả lời dứt khoát là **Không**. Chúng ta không thể kết luận vội vàng về giá trị của một thành viên chỉ dựa trên một bối cảnh duy nhất.

Vậy, con số nào mới thực sự đại diện cho "giá trị" công bằng của Châu? Một phương pháp giải thích đáng tin cậy không thể đưa ra những kết quả khác nhau cho cùng một đặc trưng chỉ vì chúng ta thay đổi thứ tự đánh giá. Chúng ta cần một giá trị duy nhất, tổng hợp, và công bằng, phản ánh được đóng góp của Châu trên *tất cả các kịch bản có thể xảy ra.*

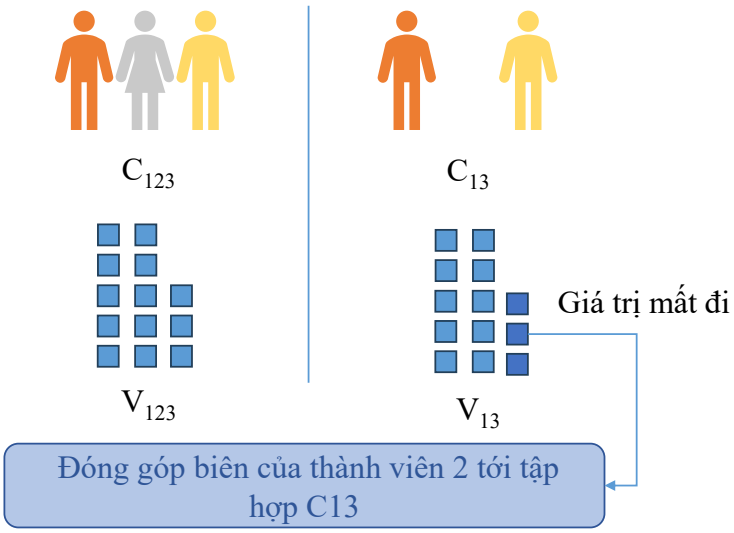

Hình 7: Đóng góp của một thành viên (người màu xám) được tính bằng chênh lệch giá trị của liên minh trước và sau khi họ tham gia. Tuy nhiên, giá trị này không cố định mà thay đổi theo từng liên minh.

Tuy nhiên, cách tính này có một điểm yếu lớn: giá trị đóng góp của một người phụ thuộc rất nhiều vào **bối cảnh**, tức là họ tham gia vào liên minh nào. Đóng góp của Châu khi tham gia vào nhóm chỉ có An có thể rất khác so với khi tham gia vào nhóm đã có cả An và Bình.

Vấn đề cốt lõi ở đây là **sự phụ thuộc vào thứ tự (order dependency)**. Giá trị đóng góp mà chúng ta tính được cho một thành viên bị phụ thuộc hoàn toàn vào "kịch bản" hay "thứ tự hoán vị" (permutation) mà chúng ta đang xét. Nếu chúng ta tính đóng góp của Châu khi tham gia vào nhóm rỗng $\emptyset$, giá trị sẽ là $v(\{\text{Châu}\})$. Nếu Châu tham gia cuối cùng, giá trị lại là $v(\{\text{An, Bình, Châu}\}) - v(\{\text{An, Bình}\})$. Cả hai đều là những đóng góp cận biên hợp lệ, nhưng chúng lại đưa ra những con số rất khác nhau.

II.2.3. Giá trị Shapley

Năm 1953, nhà toán học đoạt giải Nobel Lloyd Shapley đã đề xuất một giải pháp để giải quyết vấn đề nói trên: để có được sự phân chia công bằng, chúng ta phải tính đến đóng góp cận biên của một người chơi trong *tất cả các liên minh có thể có* mà họ có thể tham gia, sau đó lấy trung bình có trọng số của các đóng góp này. Đây chính là **giá trị Shapley**.

Công thức tính giá trị Shapley cho người chơi i là:

$$\varphi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Trong đó:

- $\varphi_i(v)$ là giá trị Shapley (đóng góp công bằng) của người chơi i.
- N là tập hợp tất cả người chơi.
- S là một liên minh không chứa người chơi i.
- $v(S \cup \{i\}) - v(S)$ chính là đóng góp cận biên của i khi tham gia vào liên minh S.
- Phần phân số $\frac{|S|!(|N|-|S|-1)!}{|N|!}$ là trọng số, đại diện cho tất cả các thứ tự hoán vị mà liên minh S có thể hình thành trước khi i tham gia.

Nói một cách đơn giản, giá trị Shapley là **trung bình của tất cả các đóng góp cận biên có thể có** của một người chơi.

II.2.4. Từ Giá Trị Shapley đến SHAP trong Machine Learning

Framework SHAP áp dụng trực tiếp ý tưởng của giá trị Shapley vào việc giải thích các mô hình học máy. Sự tương ứng được thiết lập như sau:

- **Người chơi** $\rightarrow$ **Các đặc trưng (features)** của tập dữ liệu.
- **Trò chơi** $\rightarrow$ Việc đưa ra một **dự đoán duy nhất** cho một điểm dữ liệu cụ thể.
- **Hàm đặc trưng** $v(S)$ $\rightarrow$ **Đầu ra của mô hình** khi chỉ sử dụng tập hợp các đặc trưng trong liên minh S.
- **Giá trị Shapley** φ_i $\rightarrow$ **Giá trị SHAP** của đặc trưng i. Nó cho biết đặc trưng i đã đóng góp bao nhiêu vào việc dịch chuyển dự đoán của mô hình đi từ giá trị cơ sở (trung bình dự đoán trên toàn bộ tập dữ liệu) đến giá trị dự đoán cuối cùng cho điểm dữ liệu đó.

Một câu hỏi quan trọng là: "Làm thế nào mô hình có thể đưa ra dự đoán chỉ với một tập con các đặc trưng?" Các thuật toán SHAP hiện đại sử dụng các kỹ thuật xấp xỉ, chẳng hạn như thay thế các đặc trưng còn thiếu bằng các giá trị đại diện từ tập dữ liệu, để mô phỏng hiệu quả việc loại bỏ đặc trưng ra khỏi mô hình.

II.3. Phương pháp giải thích cộng tính và Kernel SHAP

Sau khi đã hiểu nền tảng lý thuyết của giá trị Shapley, chúng ta đối mặt với một rào cản lớn: tính toán. Việc tính toán giá trị Shapley chính xác đòi hỏi phải duyệt qua **tất cả các liên minh** có thể có của các đặc trưng. Điều này là bất khả thi trong thực tế. Hình bên thể hiện cách tính độ quan trong của node xanh nước biển, với mỗi cặp hình là liên minh trước và sau khi loại bỏ node đó.

Chính vì thách thức này, chúng ta cần một phương pháp xấp xỉ hiệu quả. Kernel SHAP ra đời để giải quyết bài toán này, dựa trên một ý tưởng thuộc họ các **Additive Feature Attribution Methods - AFAMs (tạm dịch: phương pháp gán đặc trưng cộng tính)**.

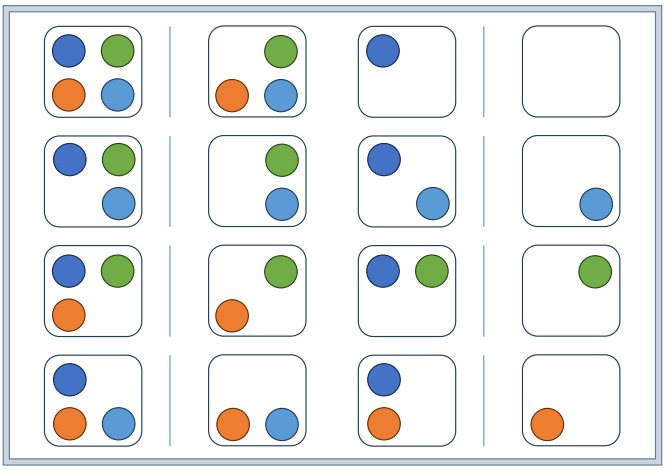

$n = 4 \rightarrow 4 \times 2^4 = 64$ *times*
$n = 32 \rightarrow 32 \times 2^{32} = 17.1$ *billions times*

Hình 8: Chi phí tính toán của giá trị Shapley bùng nổ theo tổ hợp. Với chỉ 32 đặc trưng, số lượng liên minh cần xét đã lên đến hàng tỷ, khiến việc chạy mô hình lặp đi lặp lại là không thể.

II.3.1. Mô hình giải thích cộng tính

Ý tưởng cốt lõi của AFAMs là xấp xỉ một mô hình hộp đen phức tạp $f(x)$ bằng một mô hình giải thích đơn giản hơn, có thể diễn giải được $g(x')$. Dạng mô hình đơn giản nhất mà con người có thể hiểu là mô hình tuyến tính.

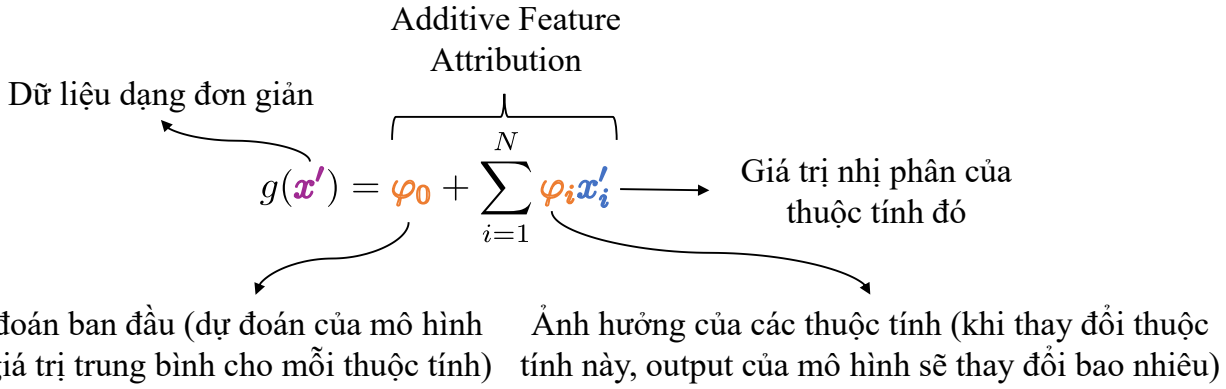

Hình 9: Mô hình giải thích $g(x')$ là một xấp xỉ cục bộ của mô hình hộp đen $f(x)$. "Cộng tính" có nghĩa là đóng góp của mỗi đặc trưng được cộng lại để tạo thành dự đoán cuối cùng.

Như được minh họa trong công thức trên, các thành phần của mô hình giải thích được định nghĩa như sau:

- $g(x')$ là đầu ra của mô hình giải thích.
- x' là một vector nhị phân ($x'_i \in \{0, 1\}$) thể hiện sự "có mặt" (1) hay "vắng mặt" (0) của đặc trưng i.
- φ_0 là đầu ra của mô hình khi không có đặc trưng nào được đưa vào (giá trị cơ sở - *base value*).
- φ_i là **hiệu ứng (effect)** của đặc trưng i, chính là giá trị SHAP mà chúng ta cần tìm.

SHAP đảm bảo rằng các giá trị φ_i này chính là các giá trị Shapley, mang lại cho mô hình giải thích các thuộc tính lý thuyết mong muốn như **tính chính xác cục bộ**. Vấn đề bây giờ chúng ta phải giải quyết là: Làm thế nào để tìm ra các giá trị φ_i này một cách hiệu quả?

II.3.2. Kernel SHAP: hướng tiếp cận dựa trên hồi quy tuyến tính

Kernel SHAP là một thuật toán model-agnostic (tạm dịch: không phụ thuộc vào mô hình) thuộc họ LIME (Local Interpretable Model-agnostic Explanations). Nó biến bài toán tìm giá trị Shapley thành một bài toán **hồi quy tuyến tính có trọng số (weighted linear regression)**. Với cách biến đổi này, ta sẽ có thể tìm được giá trị Shapley cho từng thuộc tính thông qua cách huấn luyện mô hình hồi quy tuyến tính có trọng số. Quy trình hoạt động của Kernel SHAP như sau:

0. Xác định giá trị cơ sở (baseline balue): Trước khi có thể đo lường đóng góp của từng đặc trưng, chúng ta cần một điểm xuất phát. Đây được gọi là **giá trị cơ sở (base value)**, ký hiệu là φ_0. Giá trị này đại diện cho dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu, hay nói cách khác, là dự đoán của mô hình khi nó "không có thông tin" về bất kỳ đặc trưng nào của điểm dữ liệu cụ thể mà chúng ta đang giải thích.

Cách tính giá trị cơ sở có thể được thực hiện qua 3 bước trực quan như sau:

1. Lấy một phần của tập dữ liệu train và gọi nó là **tập dữ liệu nền (background dataset)** B.
2. Tính giá trị kỳ vọng (thường là giá trị trung bình) cho từng cột đặc trưng. Kết quả là chúng ta có một vector duy nhất, $E[x_{bg}]$, đại diện cho một "mẫu dữ liệu trung bình".
3. Đưa vector trung bình này vào mô hình hộp đen f để nhận được dự đoán. Dự đoán này chính là giá trị cơ sở φ_0.

$$\varphi_0 = f(E[x_{bg}])$$

Giá trị này sẽ là mốc tham chiếu để ta có thể biết được mô hình của chúng ta bắt đầu điểm dữ đoán từ đâu. Toàn bộ các giá trị SHAP (φ_i) mà chúng ta tính toán ở các bước sau sẽ giải thích cách chúng "đẩy" dự đoán của mô hình đi từ giá trị cơ sở φ_0 này đến dự đoán cuối cùng $f(x)$ cho điểm dữ liệu cụ thể.

1. Tạo dữ liệu huấn luyện cho mô hình đơn giản: Chúng ta không thể "loại bỏ" một đặc trưng khỏi mô hình rồi dùng mẫu dữ liệu được cắt bớt đó để đưa vào mô hình "hộp đen". Việc này không được bởi vì khi ta bỏ trống một features, ta đã thực hiện việc giảm chiều đầu vào của dữ liệu. Thay vào đó, chúng ta mô phỏng sự vắng mặt của nó bằng cách thay thế giá trị của nó bằng các giá trị từ một tập dữ liệu nền.

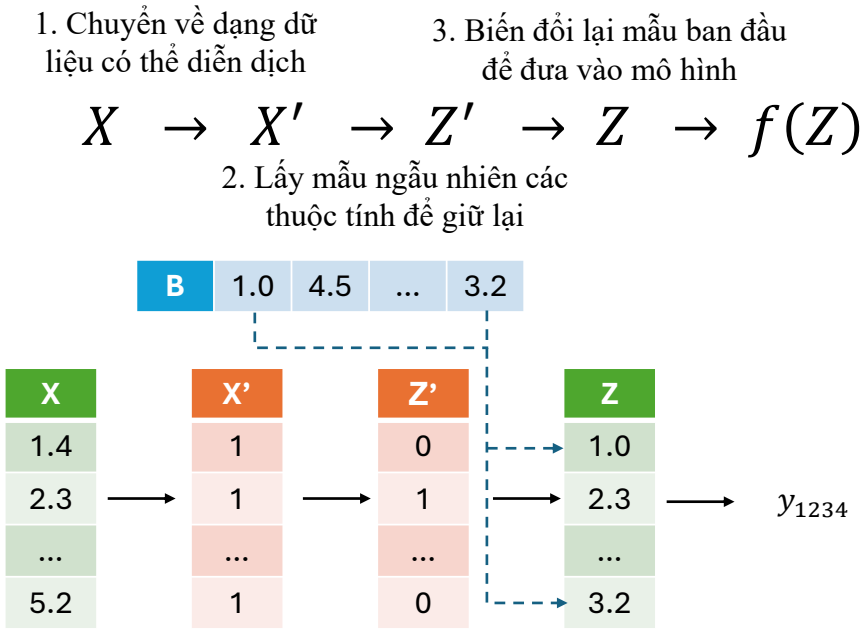

Hình 10: Để mô phỏng các liên minh đặc trưng, chúng ta tạo ra các điểm dữ liệu mới bằng cách lấy mẫu các giá trị từ tập nền để thay thế cho các đặc trưng "vắng mặt".

Quá trình tạo ra một điểm dữ liệu huấn luyện cho mô hình giải thích được minh họa chi tiết trong Hình 10. Ta bắt đầu với điểm dữ liệu gốc X cần giải thích (ví dụ: '[1.4, 2.3, ..., 5.2]') và một mẫu ngẫu nhiên từ **tập dữ liệu nền** B (ví dụ: '[1.0, 4.5, ..., 3.2]'). Đầu tiên, một liên minh đặc trưng được lấy mẫu và biểu diễn dưới dạng một vector nhị phân Z', chẳng hạn như $Z' = [0, 1, \ldots, 0]$. Vector này đóng vai trò như một "mặt nạ", quy định đặc trưng nào của dữ liệu gốc sẽ được giữ lại và đặc trưng nào sẽ bị thay thế. Dựa trên mặt nạ này, chúng ta xây dựng một điểm dữ liệu "lai" Z bằng cách lấy giá trị từ điểm gốc X tại các vị trí mà Z' bằng 1 (giữ lại giá trị '2.3' ở vị trí thứ hai) và lấy giá trị từ tập nền B tại các vị trí mà Z' bằng 0 (thay thế bằng giá trị '1.0' ở vị trí đầu và '3.2' ở vị trí cuối). Điểm dữ liệu lai hoàn chỉnh $Z = [1.0, 2.3, \ldots, 3.2]$ sau đó được đưa vào mô hình hộp đen f để thu về một dự đoán $f(Z)$.

Tại sao chúng ta lại cần vector nhị phân Z'? Câu trả lời nằm ở mục tiêu cuối cùng của chúng ta: huấn luyện một **mô hình giải thích tuyến tính** g. Cặp giá trị $(Z', f(Z))$ vừa tạo ra chính là một mẫu huấn luyện, trong đó Z' là *dữ liệu đầu vào* và $f(Z)$ là *nhãn* (pseudo-label). Bằng cách lặp lại quy trình này nhiều lần, chúng ta tạo ra một tập dữ liệu để huấn luyện mô hình $g(Z') \approx f(Z)$. Vì g là mô hình tuyến tính, nó cần đầu vào đơn giản (vector nhị phân Z') để học ra các hệ số φ_i, chính là các giá trị SHAP mà chúng ta tìm kiếm.

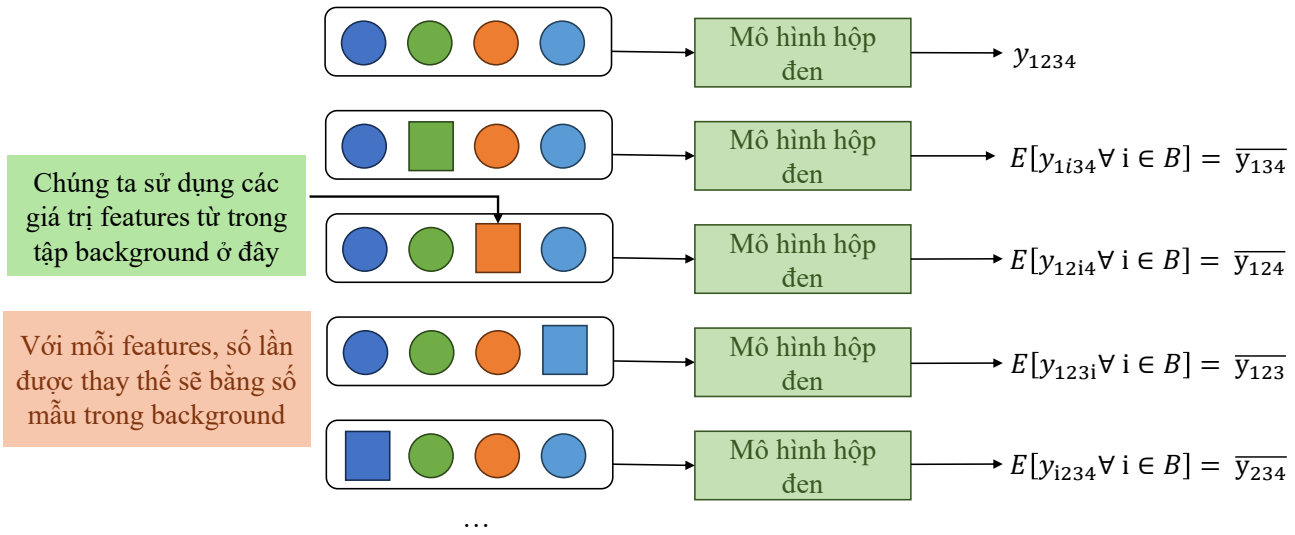

Hình 11: Các đầu ra của mô hình hộp đen cho các liên minh được lấy mẫu sẽ được dùng làm nhãn giả (pseudo-label) để huấn luyện mô hình giải thích tuyến tính.

2. Shapley Kernel: trọng số cho mô hình: Một câu hỏi quan trọng được đặt ra: "Liệu mỗi mẫu dữ liệu giả lập này có quan trọng như nhau không?". Câu trả lời là **Không**. Bởi vì chúng ta lấy mẫu ngẫu nhiên, và chỉ một phần của dữ liệu gốc, các trường hợp của mẫu dữ liệu ít xuất hiện hơn phải có trọng số cao hơn.

Lý thuyết Shapley chỉ ra rằng một số liên minh cung cấp nhiều thông tin hơn về đóng góp của một đặc trưng so với các liên minh khác. Cụ thể, các liên minh có rất ít đặc trưng (ví dụ, chỉ 1) hoặc có gần như đầy đủ các đặc trưng (ví dụ, $N-1$) là quan trọng nhất. Kernel SHAP định nghĩa một hàm trọng số đặc biệt, gọi là **Shapley kernel**, để gán trọng số cao hơn cho các liên minh này.

Một câu hỏi có thể nảy sinh là tại sao chúng ta lại sử dụng tổ hợp (combination) để định nghĩa các liên minh mà không phải là chỉnh hợp (permutation). Lý do là vì giá trị Shapley không phụ thuộc vào thứ tự các đặc trưng xuất hiện trong một liên minh, mà chỉ quan tâm đến việc đặc trưng nào có mặt hoặc vắng mặt. Chỉnh hợp, vốn xem xét đến thứ tự, sẽ không phù hợp. Do đó, việc sử dụng tổ hợp là cách tiếp cận tự nhiên và chính xác trong bối cảnh này.

$$w_C = \frac{\#\text{ total features} - 1}{\#\text{ permutations of size } |C| \times \#\text{ included features in } C \times \#\text{ excluded features in } C}$$

Số lượng tổ hợp cùng kích thước (số features giữ lại) với mẫu đang xét

Trong lý thuyết, nếu trường hợp chia cho 0 xảy ra, ta sẽ gán trọng số rất lớn cho mẫu đó.

Chúng ta loại bỏ hai trường hợp giữ lại toàn bộ features trong mẫu hoặc không có trường hợp nào trong mẫu (để tránh trường hợp chia cho 0)

Hình 12: Công thức trọng số của hạt nhân Shapley. Nó ưu tiên các liên minh có kích thước gần 0 hoặc gần N (tổng số đặc trưng), nơi mà đóng góp cận biên của một đặc trưng được thể hiện rõ nhất.

Công thức tính trọng số cho một liên minh C có $|C|$ đặc trưng là:

$$w_C = \frac{N-1}{\binom{N}{|C|} \times |C| \times (N - |C|)}$$

Để hiểu sâu hơn về cấu trúc của công thức này, chúng ta có thể phân tách mẫu số của nó thành hai thành phần chính, mỗi thành phần mang một ý nghĩa riêng trong việc đảm bảo sự công bằng:

Thành phần thứ nhất: $\binom{N}{|C|}$ Đây là số lượng tổ hợp chập $|C|$ của N phần tử, tức là có tổng cộng bao nhiêu liên minh khác nhau có cùng kích thước $|C|$. Bằng cách đặt số hạng này ở mẫu số, chúng ta đang thực hiện một phép **chuẩn hóa dựa trên độ hiếm**. Các liên minh có kích thước rất nhỏ (ví dụ $|C| = 1$) hoặc rất lớn (ví dụ $|C| = N - 1$) có số lượng ít hơn nhiều so với các liên minh có kích thước ở khoảng giữa (ví dụ $|C| \approx N/2$). Do đó, việc chia cho $\binom{N}{|C|}$ sẽ gán một trọng số cao hơn cho các liên minh "hiếm" và quan trọng này, đúng như tinh thần của lý thuyết Shapley.

Thành phần thứ hai: $|C| \times (N - |C|)$ Thành phần này có thể được diễn giải từ góc độ lý thuyết hoán vị (permutation theory). Nó liên quan đến việc một đặc trưng cụ thể được thêm vào một liên minh tại một **ranh giới (boundary)** nhất định. Tích số này đạt giá trị nhỏ nhất khi $|C|$ gần 1 hoặc gần N, và đạt giá trị lớn nhất khi $|C|$ ở khoảng giữa. Việc đặt nó ở mẫu số cũng có tác dụng khuếch đại trọng số cho các liên minh ở hai cực (rất nhỏ hoặc rất lớn). Về mặt trực quan, thành phần này giúp điều chỉnh và "sửa lỗi" cho sự thay đổi đóng góp của một đặc trưng ngay tại thời điểm nó được thêm vào một liên minh.

Ví dụ về SHAP Kernal với số features bằng 5

Như đã nói ở trên, chúng ta sẽ không lấy mẫu hai trường hợp cạnh biên ở đây

K (số lượng features được giữ lại)	Kích thước tổ hợp	Trọng số của toàn bộ mẫu trong tổ hợp	
1	5	4/20 = 0.20	$\frac{5-1}{\binom{5}{1} \times 1 \times 4} = \frac{4}{20}$
2	10	4/60 = 0.06	
3	10	4/60 = 0.06	$\frac{5-1}{\binom{5}{2} \times 2 \times 3} = \frac{4}{60}$
4	5	4/20 = 0.20	

Hình 13: Ví dụ về trọng số của hạt nhân Shapley với 5 đặc trưng. Các liên minh có 1 hoặc 4 đặc trưng được gán trọng số cao nhất (0.20), trong khi các liên minh có 2 hoặc 3 đặc trưng có trọng số thấp hơn (0.06).

3. Huấn luyện mô hình: Sau khi đã có tập dữ liệu giả lập, nhãn tương ứng (dự đoán của mô hình hộp đen) và trọng số (từ hạt nhân Shapley), chúng ta tiến hành huấn luyện một mô hình hồi quy tuyến tính có trọng số. Điều kỳ diệu nằm ở đây: Lundberg và Lee (2017) đã chứng minh rằng nếu chúng ta giải bài toán hồi quy có trọng số này, các hệ số φ_i tìm được chính là **giá trị Shapley duy nhất** thỏa mãn các thuộc tính mong muốn. Về bản chất, Kernel SHAP đã chuyển một bài toán tổ hợp phức tạp thành một bài toán hồi quy hiệu quả và dễ giải quyết.

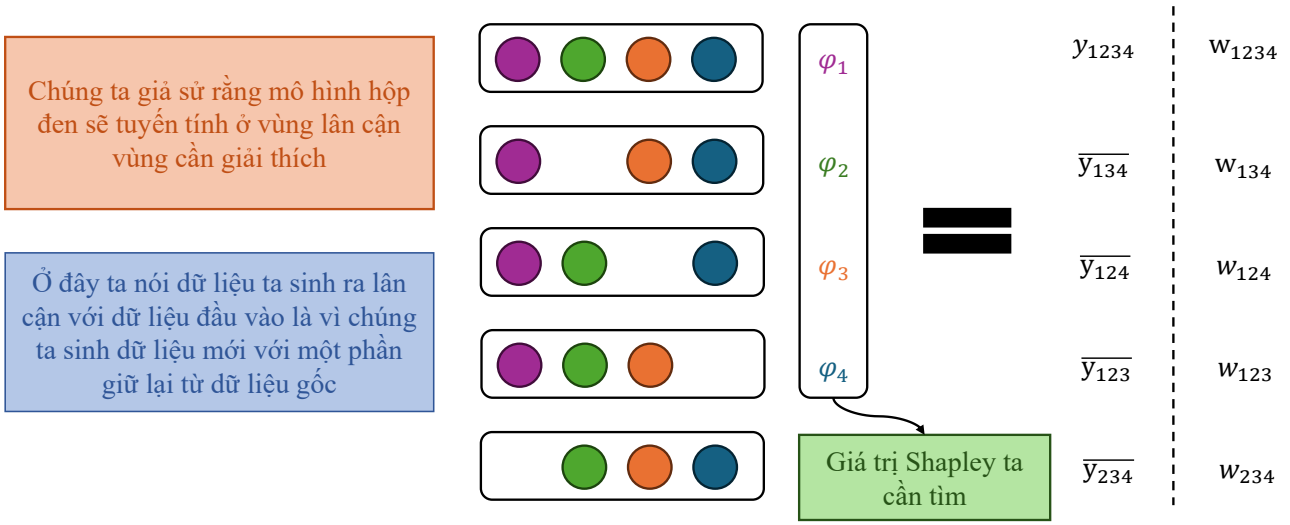

Hình 14: Ta khớp một mô hình tuyến tính có trọng số vào dữ liệu được tạo ra từ mô hình hộp đen. Các hệ số hồi quy (slope) của mô hình tuyến tính này chính là các giá trị Shapley.

4. Đưa ra lời giải thích: Để trình bày những thông tin độ quan trọng của các thuộc tính một cách trực quan và dễ hiểu nhất, thư viện SHAP cung cấp **biểu đồ thác nước (Waterfall Plot)**. Sau khi đã lấy được trọng số Shapley xong, chúng ta cần đưa ra lời giải thích dễ hiểu cho người dùng. Lời giải thích mặc định đưa chia làm các phần chính sau: điểm bắt đầu dự đoán của mô hình, dự đoán của mô hình ở trường hợp đang xét, giá trị của các features, và ảnh hưởng của các features đó đến mô hình.

Biểu đồ bắt đầu từ **giá trị cơ sở** ($E[f(x)]$), thường được hiển thị ở dưới cùng của trục hoành. Sau đó, mỗi đặc trưng được thêm vào tuần tự, và giá trị SHAP tương ứng của nó sẽ "đẩy" hoặc "kéo" dự đoán:

- **Các thanh màu đỏ**: Đại diện cho các đặc trưng có giá trị SHAP dương, làm *tăng* giá trị dự đoán. Trong các bài toán multi label, thuật ngữ làm tăng giá trị dự đoán mang nghĩa làm tăng xác suất của lớp gốc trong mẫu dữ liệu đang xét. Ví dụ: chúng ta sử dụng ảnh con mèo trong tập dữ liệu ImageNet1k để đưa qua mô hình hộp đen, làm tăng giá trị dự đoán của ta ở đây là làm tăng P(Mèo) so với P(Toàn bộ các lớp còn lại).
- **Các thanh màu xanh**: Đại diện cho các đặc trưng có giá trị SHAP âm, làm *giảm* giá trị dự đoán.

Độ dài của mỗi thanh tỷ lệ thuận với độ lớn ảnh hưởng của đặc trưng đó. Quan trọng nhất, các đặc trưng thường được sắp xếp theo mức độ ảnh hưởng từ lớn nhất đến nhỏ nhất, giúp người dùng ngay lập tức xác định được những yếu tố then chốt nào đã quyết định kết quả dự đoán. Quá trình này tiếp diễn cho đến khi tất cả các đóng góp được cộng lại, và giá trị cuối cùng trên trục hoành chính là **dự đoán thực tế** của mô hình ($f(x)$) cho điểm dữ liệu đó.

Lưu ý

Tuy các thuộc tính được sắp xếp từ trên xuống theo độ quan trọng, nhưng ta phải đọc cách mô hình đưa ra quyết định từ dưới lên. Như trong hình minh họa bên dưới, các thuộc tính sẽ được thêm tuần tự từ "ít đóng góp nhất" đến "đóng góp nhiều nhất", nếu ta đổi thứ tự đóng góp của các thuộc tính, giá trị Shapley của chúng có thể thay đổi.

Nhờ vậy, biểu đồ thác nước không chỉ cho biết đặc trưng nào quan trọng, mà còn định lượng chính xác từng đóng góp và cho thấy quá trình "suy luận" của mô hình một cách minh bạch.

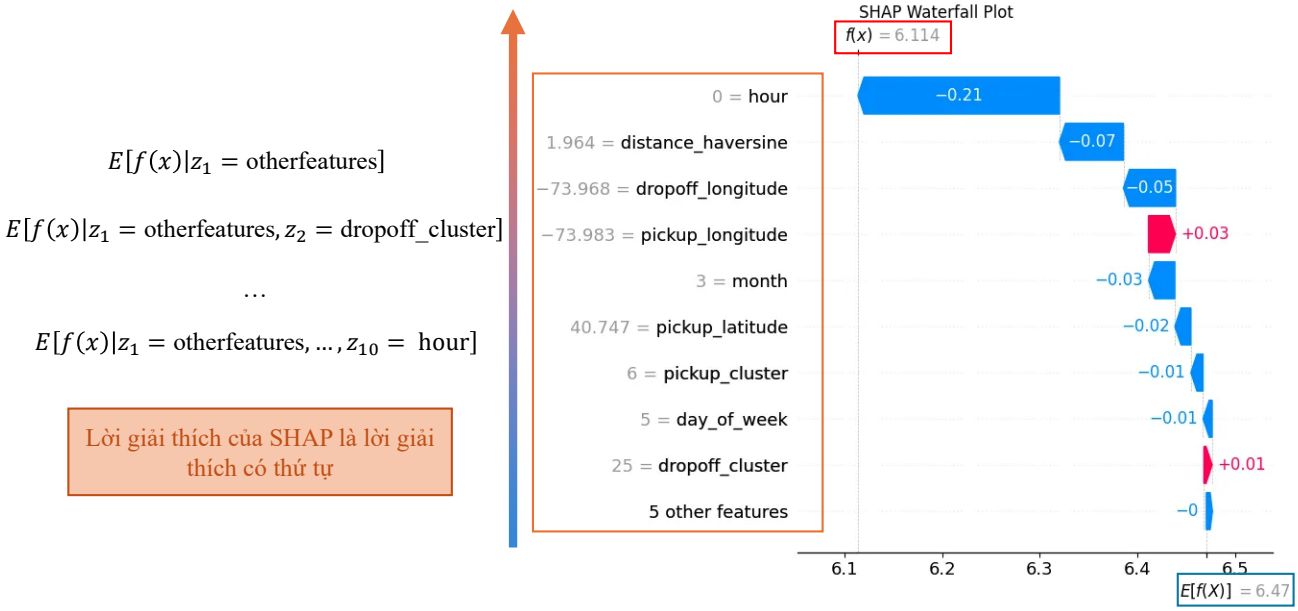

Hình 15: Biểu đồ thác nước SHAP cho một dự đoán cụ thể. Biểu đồ bắt đầu từ giá trị cơ sở $E[f(x)] = 6.47$ (với khung xanh). Mỗi thanh tiếp theo biểu diễn giá trị SHAP của một đặc trưng: thanh màu đỏ làm tăng dự đoán, trong khi thanh màu xanh làm giảm dự đoán. Sau khi cộng dồn tất cả các ảnh hưởng, ta thu được dự đoán cuối cùng của mô hình là $f(x) = 6.114$ (với khung màu đỏ).

II.4. Tổng quan thuật toán SHAP

Quy trình bắt đầu với một mô hình hộp đen đã được huấn luyện và một điểm dữ liệu X cụ thể mà chúng ta muốn giải thích. Để có một mốc so sánh, thuật toán cần một tập dữ liệu nền, thường được lấy mẫu ngẫu nhiên (ví dụ: 100 mẫu) từ chính tập huấn luyện. Tập nền này đại diện cho phân phối dữ liệu chung. Đồng thời, giá trị cơ sở φ_0, tức là dự đoán trung bình của mô hình trên toàn bộ tập nền cũng được tính toán ở bước này.

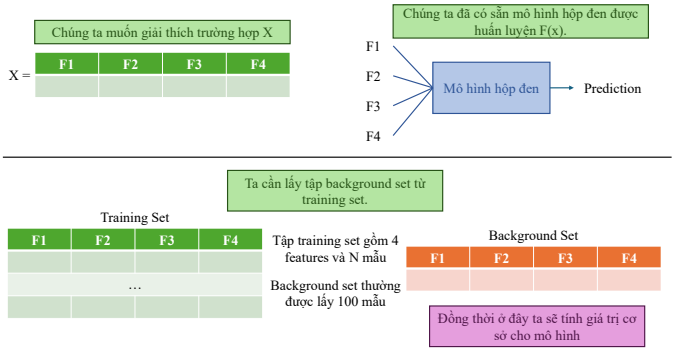

Hình 16: Khởi tạo thuật toán: xác định mẫu cần giải thích X, lấy tập dữ liệu nền từ tập huấn luyện và tính toán giá trị cơ sở.

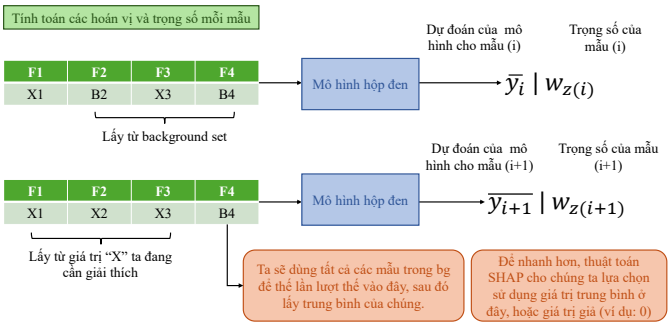

Hình 17: Tạo các mẫu dữ liệu "lai" bằng cách kết hợp giá trị từ X và tập nền, sau đó đưa qua mô hình hộp đen để lấy dự đoán.

Tiếp theo, chúng ta cần mô phỏng sự "vắng mặt" của các đặc trưng. Thuật toán tạo ra nhiều mẫu dữ liệu "lai" mới bằng cách lấy một số giá trị từ điểm dữ liệu gốc X và thay thế các giá trị còn lại bằng dữ liệu từ tập nền. Mỗi mẫu lai này đại diện cho một "liên minh" đặc trưng. Tất cả các mẫu lai sau đó được đưa vào mô hình hộp đen để thu về các dự đoán tương ứng, cùng với trọng số của từng mẫu được tính bằng Shapley Kernel.

Các mẫu lai phức tạp được chuyển đổi thành các vector nhị phân đơn giản, trong đó '1' đại diện cho sự hiện diện của đặc trưng từ mẫu gốc X, và '0' đại diện cho sự vắng mặt (được thay bằng giá trị từ tập nền). Các vector nhị phân này (đầu vào), cùng với các dự đoán thu được ở Bước 2 (nhãn) và trọng số tương ứng, được sử dụng để huấn luyện một mô hình hồi quy tuyến tính có trọng số. Các hệ số $(\varphi_1, \varphi_2, \dots)$ của mô hình tuyến tính này chính là các giá trị SHAP mà chúng ta cần tìm.

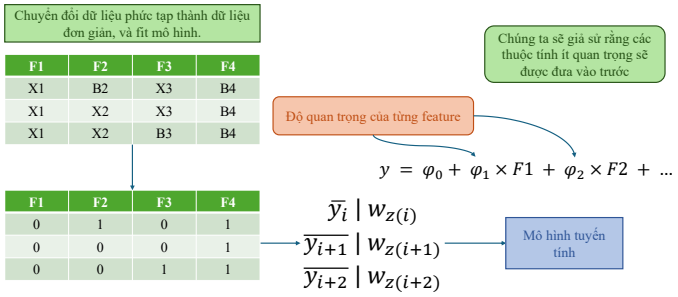

Hình 18: Dữ liệu được đơn giản hóa thành dạng nhị phân và được dùng để huấn luyện một mô hình tuyến tính, từ đó suy ra các giá trị SHAP.

II.5. Ví dụ tính toán Kernel SHAP từng bước

Để thực sự hiểu rõ cách Kernel SHAP hoạt động, chúng ta sẽ cùng nhau thực hiện một ví dụ tính toán chi tiết như dựa trên các bước được nói ở trên với bộ dữ liệu dạng bảng đơn giản dưới đây.

Bối cảnh bài toán (Problem Setup)

Giả sử chúng ta có một mô hình hộp đen f đã được huấn luyện. Để đơn giản cho việc tính toán, mô hình này chỉ có 3 đặc trưng đầu vào $(F1, F2, F3)$ và được định nghĩa như sau:

$$f(F1, F2, F3) = 5 + 2 \times F1 + 3 \times F2 - F3$$

Điểm dữ liệu X cần giải thích

F1	F2	F3
5	2	4

Bảng 2: Điểm dữ liệu X cần giải thích.

Tập dữ liệu nền (background set) B

F1	F2	F3
1	2	8
3	0	6
$\mathbf{E[X_{bg}] = 2}$	$\mathbf{E[X_{bg}] = 1}$	$\mathbf{E[X_{bg}] = 7}$

Bảng 3: Tập dữ liệu nền B và giá trị trung bình.

Các giá trị cần tính:

- **Giá trị cơ sở** φ_0: là dự đoán của mô hình trên mẫu dữ liệu nền trung bình.

$$\varphi_0 = f(E[X_{bg}]) = f(2, 1, 7) = 5 + (2 \times 2) + (3 \times 1) - 7 = \mathbf{5}$$

- **Dự đoán cuối cùng** $f(x)$: là dự đoán của mô hình trên điểm dữ liệu X.

$$f(x) = f(5, 2, 4) = 5 + (2 \times 5) + (3 \times 2) - 4 = \mathbf{17}$$

II.5.1. Bước 1 và 2: Tạo hoán vị, lấy dự đoán và tính trọng số

Với 3 đặc trưng, chúng ta sẽ có $2^3 = 8$ liên minh (hoán vị) có thể có. Với mỗi liên minh, ta tạo một mẫu dữ liệu lai Z bằng cách kết hợp giá trị từ $X = (5, 2, 4)$ và $E[X_{bg}] = (2, 1, 7)$, sau đó tính dự đoán $F(Z)$ và trọng số W tương ứng.

ID	Liên minh	Vector nhị phân Z'	Mẫu lai Z	Dự đoán $F(Z)$	Trọng số W
Z0	{}	(0,0,0)	(2,1,7)	5	∞
Z1	{F1}	(1,0,0)	(5,1,7)	11	0.333
Z2	{F2}	(0,1,0)	(2,2,7)	8	0.333
Z3	{F3}	(0,0,1)	(2,1,4)	8	0.333
Z4	{F1, F2}	(1,1,0)	(5,2,7)	14	0.333
Z5	{F1, F3}	(1,0,1)	(5,1,4)	14	0.333
Z6	{F2, F3}	(0,1,1)	(2,2,4)	11	0.333
Z7	{F1, F2, F3}	(1,1,1)	(5,2,4)	17	∞

Bảng 4: Tập dữ liệu huấn luyện cho mô hình giải thích tuyến tính.

Cách tính trọng số: Trọng số W được tính bằng công thức Shapley Kernel. Ví dụ, với các liên minh có 1 đặc trưng ($|Z'| = 1$):

$$w = \frac{M-1}{\binom{M}{|Z'|} \times |Z'| \times (M - |Z'|)} = \frac{3-1}{\binom{3}{1} \times 1 \times (3-1)} = \frac{2}{3 \times 1 \times 2} = \frac{2}{6} \approx 0.333$$

Các trường hợp $|Z'| = 0$ và $|Z'| = M$ có trọng số vô hạn (∞) để đảm bảo mô hình hồi quy tuyến tính luôn đi qua điểm bắt đầu và điểm kết thúc. Đây là cách ta đảm bảo mô hình của ta giống với mô hình gốc (nghĩa là ta xấp xỉ mô hình tuyến tính với mô hình hộp đen).

II.5.2. Bước 3: Huấn luyện mô hình giải thích và tìm giá trị SHAP

Bây giờ, chúng ta sử dụng các cột Z', $F(Z)$ và W từ bảng trên để huấn luyện một mô hình hồi quy tuyến tính có trọng số (weighted linear regression).

$$F(Z) \approx g(Z') = \varphi_0 + \varphi_1 Z'_1 + \varphi_2 Z'_2 + \varphi_3 Z'_3$$

Kết quả giải bài toán hồi quy này (hoặc giải hệ phương trình) sẽ cho chúng ta các hệ số φ_i chính là giá trị SHAP:

$$\varphi_1(\text{cho F1}) = 6.0$$
$$\varphi_2(\text{cho F2}) = 3.0$$
$$\varphi_3(\text{cho F3}) = 3.0$$

Một thuộc tính quan trọng của SHAP là **tính cộng tính (additivity)**. Tổng của giá trị cơ sở và tất cả các giá trị SHAP phải bằng đúng dự đoán cuối cùng.

$$\varphi_0 + \varphi_1 + \varphi_2 + \varphi_3 = 5.0 + 6.0 + 3.0 + 3.0 = \mathbf{17.0}$$

Kết quả này khớp chính xác với giá trị $f(x) = 17$ mà chúng ta đã tính ban đầu. Nghĩa là mô hình của chúng ta đã giải thích được mô hình hộp đen từ bài toán và vẫn đảm bảo 3 tính chất của lớp mô hình "giải thích cộng tính".

Lời giải thích cuối cùng cho người dùng là:

- Mô hình bắt đầu từ dự đoán trung bình là **5.0**.
- Đặc trưng **F1** (có giá trị là 5) đã có đóng góp **lớn nhất**, làm **tăng** dự đoán lên **6.0** đơn vị.
- Đặc trưng **F2** (có giá trị là 2) làm **tăng** dự đoán lên **3.0** đơn vị.
- Đặc trưng **F3** (có giá trị là 4) cũng làm **tăng** dự đoán lên **3.0** đơn vị.
- Tổng hợp lại, dự đoán cuối cùng là **17.0**.

III. Câu hỏi trắc nghiệm

1. Tại sao khái niệm "Tính trung thực" (Fidelity) lại cực kỳ quan trọng đối với một phương pháp giải thích như SHAP?

   A. Vì nó đảm bảo lời giải thích phải đơn giản và bất kỳ ai cũng có thể hiểu được.

   B. Vì nó đảm bảo lời giải thích phản ánh đúng logic và cơ chế ra quyết định thực sự của mô hình.

   C. Vì nó đảm bảo phương pháp giải thích có thể áp dụng cho mọi loại mô hình học máy.

   D. Vì nó giúp mô hình hộp đen ban đầu đạt được độ chính xác cao hơn sau khi được giải thích.

2. Sự khác biệt cơ bản nhất giữa một mô hình có "Tính diễn dịch" (Interpretability) và một mô hình cần "Tính giải thích" (Explainability) là gì?

   A. Mô hình diễn dịch luôn chính xác hơn mô hình cần giải thích.

   B. Mô hình diễn dịch vốn đã minh bạch (hộp kính), trong khi mô hình cần giải thích thường phức tạp (hộp đen).

   C. Mô hình diễn dịch chỉ dùng cho bài toán hồi quy, còn mô hình cần giải thích chỉ dùng cho bài toán phân loại.

   D. Mô hình diễn dịch không cần dữ liệu để huấn luyện, còn mô hình cần giải thích thì có.

3. Tại sao việc tính toán giá trị Shapley một cách chính xác lại là một thách thức lớn trong thực tế?

   A. Vì công thức toán học của giá trị Shapley quá phức tạp để lập trình.

   B. Vì nó đòi hỏi phải biết trước giá trị đóng góp chính xác của từng đặc trưng.

   C. Vì nó yêu cầu phải xét qua tất cả các liên minh (tổ hợp) đặc trưng có thể có, dẫn đến bùng nổ tổ hợp về mặt tính toán.

   D. Vì nó chỉ hoạt động với các mô hình tuyến tính, không áp dụng được cho các mô hình phức tạp.

4. Trong Kernel SHAP, mục đích của việc sử dụng một "tập dữ liệu nền" (background dataset) là gì?

   A. Để huấn luyện lại mô hình hộp đen từ đầu nhằm tăng độ chính xác.

   B. Để tính toán giá trị cơ sở (base value) và để mô phỏng sự "vắng mặt" của một đặc trưng.

   C. Để kiểm tra xem mô hình có bị overfitting hay không.

   D. Để tạo ra các đặc trưng mới (feature engineering) cho mô hình giải thích.

5. Theo bài viết, tại sao giá trị Shapley được coi là một cách phân chia "công bằng"?

   A. Vì nó luôn gán giá trị dương cho các đặc trưng quan trọng và giá trị âm cho các đặc trưng không quan trọng.

B. Vì nó chia đều tổng đóng góp cho tất cả các đặc trưng.

C. Vì nó tính đến đóng góp của một đặc trưng trong mọi bối cảnh (liên minh) có thể có, rồi lấy trung bình.

D. Vì nó dựa trên một cuộc bỏ phiếu dân chủ giữa các chuyên gia.

6. Trong Waterfall Plot của SHAP, giá trị ở điểm cuối cùng (ví dụ: $f(x) = 6.114$) đại diện cho điều gì?

A. Dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu.

B. Giá trị SHAP lớn nhất trong số tất cả các đặc trưng.

C. Dự đoán cuối cùng và thực tế của mô hình hộp đen cho điểm dữ liệu cụ thể đó.

D. Tổng độ lớn (giá trị tuyệt đối) của tất cả các giá trị SHAP.

7. Kernel SHAP biến bài toán tìm giá trị Shapley phức tạp thành một bài toán đơn giản hơn. Đó là bài toán gì?

A. Bài toán phân cụm (Clustering).

B. Bài toán cây quyết định (Decision Tree).

C. Bài toán tối ưu hóa mạng nơ-ron (Neural Network Optimization).

D. Bài toán hồi quy tuyến tính có trọng số (Weighted Linear Regression).

8. Mục đích của "SHAP Kernel" là gì?

A. Gán trọng số cao hơn cho các liên minh có kích thước trung bình (ví dụ, có $N/2$ đặc trưng).

B. Gán trọng số bằng nhau cho tất cả các liên minh để đảm bảo sự công bằng.

C. Gán trọng số cao hơn cho các liên minh có rất ít hoặc rất nhiều đặc trưng.

D. Chỉ chọn ra những liên minh quan trọng nhất và bỏ qua phần còn lại.

9. Quan sát bảng dữ liệu được tạo ra trong quá trình hoạt động của Kernel SHAP với tổng số 4 features (M=4). Dựa vào công thức của SHAP Kernel, hãy tính giá trị trọng số W cho các mẫu Z1 và Z2 (trường hợp liên minh chỉ có 1 feature, tức $|Z'| = 1$)?

Số lượng features bằng 4

ID	Z	Z'	W
Z0	(1,1,1,4)	(0,0,0,0)	?
Z1	(3,1,1,4)	(1,0,0,0)	?
Z2	(1,4,1,4)	(0,1,0,0)	?
	…		…
Z15	(3,4,2,10)	(1,1,1,1)	?

A. 0.125

B. 0.25

C. ∞ (vô cùng)

D. 1.0

10. Tiếp tục với bảng dữ liệu ở trên (M=4), giá trị trọng số W cho mẫu Z0 (liên minh rỗng, $|Z'| = 0$) và Z15 (liên minh đầy đủ, $|Z'| = 4$) là bao nhiêu theo lý thuyết, và tại sao chúng thường bị loại bỏ trong các thư viện lập trình?

    A. W = 0, vì chúng không cung cấp thông tin về sự tương tác giữa các feature.

    B. W = 1, vì chúng là các trường hợp cơ sở để so sánh.

    C. W = ∞ (vô cùng), vì mẫu số trong công thức bằng 0, và chúng bị loại bỏ để tránh lỗi tính toán.

    D. W = 0.125, vì chúng có độ quan trọng thấp nhất trong các liên minh.

IV. Tài liệu tham khảo

Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.

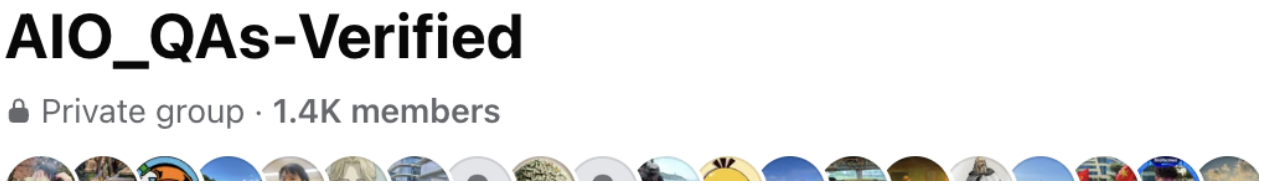

Hình 19: Hình ảnh group facebook AIO Q&A.